输入标记（即 sVt、sLt），并采用以下目标进行训练：

$$\max_{\pi,f,D} \mathbb{E}_{D_E}\left[\sum_{t=0}^{T}\log\pi(a_t|f(s_t^V,s_t^L),\cdots,f(s_0^V,s_0^L))+\lambda\sum_{t=0}^{T}\left[\log D(f(s_t^V,s_t^L))+\log(1-D(f(s_t^V,\tilde{s}_t^L)))\right]\right] \quad (82)$$

其中，f 表示用于提取特征的转换器，π 是由多个组件构成的整体策略（除 f 外），D 是判别器（如GANs中所用），其引入的目的是促使 f 为匹配的视觉与文本数据（即（sVt，sLt））和不匹配的数据（即（sVt，$\tilde{s}_{Lt}$））。这种模态匹配辅助任务（同样应用于（Mees等人， 2022a））已被证实能显著提升智能体的性能。

我们在表9 中总结了本节讨论的代表性算法，重点突出了它们的核心创新点和评估任务。如本节开头所述，基于Transformer的逆向学习算法本质上依赖于直接的BC框架。然而，这些算法在复杂机器人操作任务中展现出令人鼓舞的成果，无论是模拟环境还是真实场景。这为构建鲁棒机器人学习提供了启发性范式——即通过模仿学习在大量高质量演示数据上训练出强大的基础模型。未来研究方向可能包括开发低成本合成高质量训练数据的方法，或用更先进的替代方案改进/替换基础算法BC。

7 离线策略学习中的扩散模型

本节主要介绍扩散模型（DM）在交互式学习（IL，即第 7.2 节）和离线强化学习（RL，即第 7.3 节）中的应用，其中基于扩散模型的离线RL算法已有大量新兴研究，而基于扩散模型的交互式学习还有更多的拓展和探索空间。

7.1 扩散模型背景

扩散模型在计算机视觉（Amit等人， 2021； Baranchuk等人， 2021）、自然语言处理（Austin等人， 2021b； Hoogeboom 等人， 2021）和多模态学习（Avrahami等人， 2022； Ramesh等人， 2022）等多个领域展现出卓越性能，其生成细节丰富、多样性强的实例的能力令人印象深刻。扩散模型包含两个相互关联的过程：前向扩散过程和后向去噪过程（Yang等人， 2022a）。具体而言，前向过程是预先定义好的，它会以某种（但未知的）分布对数据进行转换，即，$x\sim P_X(\cdot)$，将其转换为（标准高斯）随机噪声 z。该过程通过在每个扩散步骤中逐步添加不同强度的噪声，对输入数据进行渐进式破坏。相应地，逆向过程采用神经网络作为去噪函数，逐步逆向还原正向变换，从而从随机噪声 z 中重建数据 x。扩散模型主要分为三大类：基于分数的生成模型（SGM）（Song与Ermon， 2019； 2020）、去噪扩散概率模型（DDPM）（Sohl- Dickstein等人， 2015； Ho等人， 2020； Nichol与Dhariwal， 2021），以及基于随机微分方程的模型（Score SDE）（Song等人， 2020； 2021）。接下来，我们将通过阐述其正向/逆向过程和学习目标来介绍这些模型，并探讨它们之间的相互关联。

- **SGM** 为每个扩散步骤的样本学习（Stein）评分函数（Hyvarinen， 2005），即 $S_\theta(x_t, t)$，*其中*$t\in[1,\cdots,T]$。根据定义，x 的Stein评分函数是其对数似然函数的梯度。
  ∇_x 对数 $P(x)$，通过多种高效的基于评分的采样方案（如 Song与Ermon 2019； Jolicoeur-Martineau等 2021）可生成数据样本 $x\sim P(\cdot)$。具体而言，SGM的前向过程从 $x_0\sim P_X(\cdot)$ 出发，通过注入增强型高斯噪声生成 $x_{1:T}$：（$\beta_{1:T}$ 为预定义的方差水平调度表）。

  $$x_t\sim F(\cdot|x_0)=N(x_0,\beta_t I),\quad 0<\beta_1<\beta_2<\cdots<\beta_T \quad (83)$$

  每个步骤的得分函数$S_\theta(x_t, t)$被训练为近似 $\nabla_{x_t}\log P(x_t)$，其中 $P(x_t)=\int F(x_t|x_0)P_X(x_0)dx_0$。特别地，训练目标如下：

  $$\min_\theta \mathbb{E}_{t\sim\mathcal{U}[1,T],x_0\sim P_X(\cdot),\epsilon\sim\mathcal{N}(0,I)}\left[\lambda(t)||\epsilon+\sqrt{\beta_t}S_\theta(x_t,t)||^2\right] \quad (84)$$

其中， $U[1, T]$是[1，…，T]上的均匀分布， $\lambda(t)$是正权函数，该目标是基于前向过程的定义推导的, i.e., $x_t = x_0 + \sqrt{\beta_t}\epsilon,\ \epsilon \sim \mathcal{N}(0, I)$.关于 $\lambda(t)$的详细推导与定义，请参阅（宋与埃蒙2019）的研究。在逆向生成过程中，分数函数 $S_\theta(x_t, t)$（*其中*$t \in [T, \cdots, 1]$）*作为去噪函数依次使用，用于从*$x_t x_{t-1}$ 生成数据样本。最终可获得数据样本 $x_0 \sim P_X(\cdot)$。如前所述，该过程中可采用多种基于分数的采样方案。以退火朗之万动力学采样方案（宋与埃蒙 2019）为例：（$x_T = x_0 T$，$x_0 = x_{00}$）

$$x_t^{i+1} = x_t^i + \frac{1}{2}s_t S_\theta(x_t^i, t) + \sqrt{s_t}\epsilon,\ (i = 0, \cdots, N-1),\ x_{t-1}^0 = x_t^N \tag{85}$$

N 和 s_t 是超参数，表示去噪 x_{0t} 到 x_{0t-1}（$t = T \rightarrow 1$）的迭代次数和步长。

- **DDPM** 在正向过程中，会 *在时间步长序列*（x_0，…，$_T$）中逐步向数据添加随机噪声，其中 $x_0 = x$，$x_T = z$。具体而言，每个时间步的样本都从高斯分布中抽取，且该样本的条件是基于前一时间步的样本（$\beta_{1:T}$为预定义参数）。

$$x_t \sim F(\cdot|x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I) \tag{86}$$

使用等式（86），在每一步 t 中，样本可以表示为 x_0 的函数：$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon$,在哪里 $\alpha_t = \prod_{s=0}^{t}(1-\beta_s)$$\epsilon \sim N(0, I)$（Sohl-Dickstein等人， 2015）。 α_T 被设计为趋近于0，使得 $z = x_T$ 近似服从 N（0，I）分布。反之，通过逆去噪过程， x_T 可逐步还原为 x_0：（$t = T \rightarrow 1$）

$$x_{t-1} \sim G_\theta(\cdot|x_t) = N(\mu_\theta(x_t, t)), \Sigma_\theta(x_t, t)) \tag{87}$$

其中 μ_θ 和 Σ 可以通过神经网络实现。学习该去噪函数的目标是使 $x_{0:T}$ 在前向和反向过程中的联合分布相匹配，即最小化 $_\theta D_{KL}(F(x_0, \cdots, x_T)) || G_\theta(x_0, \cdots, x_T))$，这等价于：（Sohl-Dickstein等人，2015）

$$\min_\theta \mathbb{E}_{x_0 \sim P_X(\cdot), x_{1:T} \sim F(\cdot|x_0)}\left[-\log P(x_T) - \sum_{t=1}^{T}\log\frac{G_\theta(x_{t-1}|x_t)}{F(x_t|x_{t-1})}\right] \tag{88}$$

请注意， $P(x_T)$和 $F(x_t|x_{t-1})$具有解析形式，该目标函数是负对数似然$\mathrm{E}_{x0 \sim PX}(\cdot)[-\log P_\theta(x_0)]$的上界。尽管该目标函数可以通过蒙特卡洛采样直接优化，但 Ho等人（2020）提出了其变体以降低方差。由于所有（前向或后向）变换都基于高斯分布，通过指定方差调度 $\beta_{1:T}$并固定后向方差 $_\theta(x_t, t)$为 $\beta_t I$，等式（88）可以
转换为：（Ho等人（2020））

$$\min_\theta \mathrm{E}_{t \sim U[1, T], x0 \sim PX(\cdot), \epsilon \sim N(0, I)}[\lambda(t) || \epsilon - \epsilon_\theta(\sqrt{\alpha_t}x_0 + \sqrt{1-\alpha_t}\epsilon, t) ||^2] \tag{89}$$

此处， $\lambda(t)$是一个具有闭式表达式的正权函数，但在实际应用中，为提升样本质量，通常将 $\lambda(t)$设为所有 t 值的1。直观来说，去噪函数 ϵ_θ 的训练目标是预测每个步骤中样本所受的噪声注入量。此外，通过设置 $\epsilon_\theta(x, t) = -\sqrt{\beta_t}S_\theta(x, t)$, SGM（等式（84））和 DDPM（等式（89））的客观形式可以统一。最后，通过学习得到的 ϵ_θ，采样过程 $x_{t-1} \sim G_\theta(\cdot|x_t)$等价于: $x_{t-1} = \frac{1}{\sqrt{1-\beta_t}}(x_t - \frac{\beta_t}{\sqrt{1-\alpha_t}}\epsilon_\theta(x_t, t)) + \sqrt{\beta_t}\epsilon,\ \epsilon \sim \mathcal{N}(0, I)$.

- **Score SDE** 基于随机微分方程（SDE）理论，将前两种离散时间方案扩展为统一的连续时间框架。
  在前向过程中，它通过以下微分方程控制的扩散过程，将数据转换为噪声：

$$dx = \mathrm{f}(\mathrm{x}, \mathrm{t})\ dt + g(t)\ dw, \text{其中} t \in [0, T] \tag{90}$$

其中 w 为标准维纳过程（Ricciardi， 1976），f（x，t）、g（t）分别为扩散函数和漂移函数。特别地，DDPM 和SGM的前向过程可分别通过以下两个方程描述（Song等人， 2020），其中 f（x，t）和 g（t）的具体形式如下：

$$dx = -\frac{1}{2}\beta(t)x\,dt + \sqrt{\beta(t)}\,dw,\ dx = \sqrt{\frac{d\beta(t)}{dt}}\,dw \tag{91}$$

逆过程可通过求解逆时 SDE（Anderson， 1982）来实现：

$$dx = [f（x，t） — g^2（t） \nabla_x \log P_t（x）]\,dt + g（t）\,d\bar{w} \tag{92}$$

在哪里$\bar{w}$ 表示时间逆向流动时的标准维纳过程，P_t（x）表示 t 时刻正向过程中的 x 分布。与SGM类似，每个时间点的评分函数
$\nabla_{x_t} \log P_t（x_t）$可通过基于神经网络的函数 $S_\theta（x_t，t）$进行估计，该方法采用多种分数匹配技术（文森特 2011； 宋等人 2019）。此外，在（宋等人 2020）中，他们提出了一种更高效的去噪方法——通过移除随机噪声注入 $g（t）dw$，并证明所得方程是一个概率流常微分方程（ODE），其边际密度与逆时 SDE 相同。这两个方程均可用于从目标数据分布中进行采样，即 P_X（x）。

7.2 模仿学习中的扩散模型

大多数关于在强化学习中应用扩散模型的研究都基于行为克隆（BC）框架（Pomerleau， 1991），该框架在第 2.2.1 节中介绍。扩散模型在建模复杂、高维数据分布方面表现出色。因此，许多近期研究提出通过将策略网络实现为扩散模型来改进BC，以建模专家数据 D_E 中的条件分布 $P_{A|S}（a|s）$。此外，如第 7.1 节所示，训练扩散模型（即等式（88））的目标为负对数似然（即BC的目标）提供了上界，这自然将扩散模型与BC联系起来。接下来，我们将详细介绍这些研究，它们旨在从多个角度解决原始BC算法的缺陷。

7.2.1 基于扩散模型的策略近似

第一组研究（Pearce等人（2023）； Chi等人（2023）； Reuss等人（2023））试图提升所学策略的表达能力。BC策略 π_θ 被训练为输出点估计值[18]，这使其无法捕捉 D_E 中状态-动作对的多模态特性。此外， π_θ 被鼓励学习平均分布，因为目标（即等式（11））是最大化期望值，这会导致对高频动作产生偏倚。另外， $\pi_\theta（a|s）$通常被实现为对角高斯策略，因此每个动作维度的预测是独立的，这可能导致在高维动作空间中出现不协调的行为。另一方面，DM在生成符合复杂多模态分布的高维样本方面展现出巨大潜力，同时确保了精度和多样性。在此案例中， **扩散边界条件**（Pearce等人， 2023）被提出利用去噪（评分）函数 ϵ_θ 在 DDPM（Ho等人， 2020）中生成给定状态 s 下的动作 a。与等式（89）类似，IL目标如下：（请参阅第 7.1 节的符号定义。）

$$\min_\theta \mathbb{E}_{t\sim\mathcal{U}[1,T],(s,a)\sim D_E,\epsilon\sim\mathcal{N}(0,I)} \left[||\epsilon - \epsilon_\theta(a_t = \sqrt{\alpha_t}a + \sqrt{1-\alpha_t}\epsilon, t; s)||^2\right] \tag{93}$$

需注意， s 是扩散过程中不会中断的调节器。通过学习得到的 ϵ_θ，在经过 DDPM 的去噪处理后，可生成专家动作 $a = a_0$ 的估计值。

$$a_{t-1} = \frac{1}{\sqrt{1-\beta_t}}(a_t - \frac{\beta_t}{\sqrt{1-\alpha_t}}\epsilon_\theta(a_t, t; s)) + \sqrt{\beta_t}\epsilon,\ t = T, \cdots, 1,\ a_T \sim \mathcal{N}(0, I) \tag{94}$$

此外， **《扩散策略》**（Chi等人， 2023）提出利用 DDPM 进行闭环动作序列预测。该方法通过在 D_E 中建模 $P_{A|S}（a|s）$的分布，其中 s 和 a 分别表示前一动作序列和当前动作序列。

[18] 每个数据点对应一个状态-动作对（s，a）。

T_s 状态和未来 T_p 行动分别表示。 $T_{-\nparallel} T_p$ 行动在无需重新规划的情况下执行。该框架允许进行长期规划，鼓励动作序列的时间一致性，并通过滚动时域规划对变化的环境保持响应。为了学习基于历史状态的 T_p 行动联合分布——这一任务本质上是高维的—— Chi等人（2023）建议将其建模为 $\epsilon_\theta(a_t, t|s_t)$，该模型通过等式（93）和（94）中描述的 DDPM 框架进行训练和采样。

最后， Reuss等人（2023）提出了 **BESO** 方法用于目标条件强化学习。具体而言，该方法将同一轨迹中（s，a）对应的一个或多个未来状态作为目标 g。其核心目标是获取目标条件策略 $\pi_\theta(a|s, g)$，该策略通过Score SDE 框架（Karras 等人， 2022）中的条件评分函数 $S_\theta(a_t, t; s, g)$ 进行学习。 基于 $S_\theta(a_t, t; s, g)$， s 状态下的目标 g 行动可通过概率流常微分方程生成，如第 7.1 节所述。目标条件策略能提炼出有用的目标导向行为，这些行为可与高层规划器结合，用于各类下游任务，这与分层强化学习的思路一致。然而，引入目标调节器能显著增强演示数据的多模态特性——因为同一目标可能通过多种不同路径实现，这凸显了使用数据迁移（DM）的必要性。值得注意的是，所有三项研究都建议采用Transformer作为去噪函数（即 ϵ_θ，S_θ），而非常用的U-Net网络（Ronneberger等人， 2015）来进行数据迁移。

7.2.2 用扩散模型解决模仿学习的常见问题

除了提升政策表达能力外，多项研究还探讨了扩散模型（DM）在智能法律（IL）领域应对其他挑战的应用，包括虚假相关性（Saxena等人， 2023）和不完美演示（Wang 等人， 2023e； Yuan等人， 2023b）。具体而言，由于存在虚假相关性，像扩散模型这样的表达式模型可能会过度关注与行动预测无关的干扰因素，导致在实际应用中表现脆弱——这与第 3.3.5 节提出的因果误识别问题如出一辙。为此， Saxena 等人（2023）提出了 **C3DM** 方法，通过以下方式改进扩散行为准则（DiffusionBC）的去噪过程：

$$s_t = C(s; \text{pos}(a_t), t),\ a_{t-1} = \frac{1}{\sqrt{1-\beta_t}}(a_t - \frac{\beta_t}{\sqrt{1-\alpha_t}}\epsilon_\theta(a_t, t; s_t)) + \sqrt{\beta_t}\epsilon,\ t = T, \cdots, 1,\ a_T \sim \mathcal{N}(0, I) \quad (95)$$

与等式（94）相比，唯一的区别是用 s_t 替换了调节器 s，该参数通过去噪过程进行更新。特别地，在每次去噪迭代 t 中，图像状态 s 会被放大到中间动作（即 a_t）周围的区域，以获取更多决策细节，同时忽略其他区域的干扰因素。需要注意的是，本研究假设可以获取动作与状态空间之间的转换关系来确定 a_t 的位置。因此，他们通过用 $C(s;\ \text{pos}(a),\ t)$ 替换 s 来修改等式（93）中的训练过程。此外，考虑到现实场景中的专家演示通常存在噪声， Wang等人（2023e）提出了 **DP-IL** 方法，采用动态匹配（DM）来净化/去噪演示数据。随后，任何强化学习算法都可以应用于这些净化后的数据。具体而言，基于 DDPM 框架，他们将（s，a）视为数据点 x（在等式（89）中），并学习一个去噪函数 $\epsilon_\theta(x_t, t)$ 以从被高斯噪声中断的样本（即 x_t）中恢复原始的状态-动作演示（即 x_0）。需要注意的是，这一训练过程是基于一组“干净”的演示。Then, for imperfect data points $\tilde{x}$, the learned
DM can be used to purify them by first adding random noise to $\tilde{x}$ to get $\tilde{x}_t$ (i.e., via the forward process) and 然后使用 $\epsilon_\theta$in the reverse denoising process to get the purified data $\tilde{x}_0$。Theoretically, they prove that $\tilde{x}$ 随着 t 的增加， $_t$ 和 x_t 可以任意地在分布中闭合，因此 ϵ_θ 在 x_t 上训练可以用来转换$\tilde{x}_t$ 还被应用于纯化演示中。与DP-IL中的两阶段框架不同， **smile**（Yuan 等人（2023b））被提出用于联合执行噪声演示的自动过滤和专家策略的学习。它基于扩散BC（即，等式（93）和（94））， 但改变了 DDPM 的前向扩散过程如下：

$$a_t \sim \pi^t(\cdot|s),\ \pi^t(a_t|s) = \int \pi^0(a_0|s)\mathcal{N}(a_t|a_0, \sigma_t^2 I)\ da_0,\ \sigma_t^2 = \sum_{k=1}^{t} \beta_k^2 \quad (96)$$

此处， π^0 表示所提供演示的底层策略。通过该等式，微笑的扩散过程是在策略层面而非数据点层面进行的，因此所学的去噪函数 ϵ_θ 可用于比较不同轨迹中行为策略的次优性（即，使用等式（13）在（Yuan等人（2023b））中）。随后，从训练数据集中过滤掉使用比当前所学策略更嘈杂的策略生成的轨迹。

算法	DM类型	DM 使用情况	IL 框架	已定位 IL问题	评估任务
扩散BC	分布式数据处理管理	策略生成器	字幕	多峰值 分布	厨房， CSGO
扩散策略	分布式数据处理管理	策略生成器	字幕	多峰值 分布 & HD 数据	厨房，推杆，推杆块，仿生机器人
BESO	分数 SDE	策略生成器	字幕	多峰值 分布	厨房 块推送， 卡尔文
C3DM	分布式数据处理管理	策略生成器	字幕	虚假 相关系数	欧特克， 真实机器人
DP-IL	分布式数据处理管理	数据降噪	不 有限的	嘈杂 数据	MuJoCo
微笑	分布式数据处理管理	策略生成器	字幕	嘈杂 数据	MuJoCo

表10：基于深度学习的交互式学习算法综述。其中“HD”代表“高维”。在评估任务方面，Kitchen（Gupta等人， 2019b）、Block-Push与Push-T（Florence等人， 2022）、Robomimic（Mandlekar等人， 2021b）、calvin（Mees等人， 2022b）是不同场景下的机器人操作任务； CSGO（Pearce与Zhu， 2022）是一款3D第一人称射击类电子游戏；Autodesk（Koga 等人， 2022）和Real Robot（Saxena等人， 2023）分别基于Autodesk模拟器和真实机器人平台构建了机器人操作任务；MuJoCo（Todorov等人， 2012）则提供了一系列机器人运动学任务。

虽然 Shi等人（2023）和 Sridhar等人（2023）的研究并非专门针对基于决策机制的智能导航（DM-IL），但他们提出的 **AWE** 和 **MCNN** 技术，分别显著提升了扩散策略和扩散行为准则的性能。这两种技术的核心目标都是缓解智能导航中的累积误差问题——即预测误差在决策周期内不断叠加。具体来说，AWE技术能自动提取专家轨迹中的导航节点，其生成的节点序列在决策周期内更为紧凑，特别适用于纯节点模仿场景。而 MCNN 技术则通过增强策略模型来减少累积误差，无需修改训练数据。在评估阶段，该技术会先确定当前状态在专家数据集中的最近邻状态，再将对应的专家动作与学习策略网络的输出相结合，最终形成具有误差约束的智能导航策略。

在表 10 中，我们总结了基于决策机制（DM）的智能决策（IL）方法。内容涵盖其基础算法、解决的具体问题，以及如何运用决策机制来应对这些挑战。该领域存在多个前景广阔的研究方向：首先，尽管现有研究多依赖决策机制（DDPM）的稳健性能，但未来可探索更先进的决策机制，特别是那些对序列决策至关重要的高效采样方案 [19] 。其次，鉴于这些研究涉及多种智能决策问题，开发能同时解决多个问题的统一决策机制算法（详见第 2.3 节）也是重要方向。最后，如表 6 所示，将决策机制与更先进的智能决策框架相结合，可为行为准则（BC）的核心问题提供解决方案。

7.3 离线强化学习中的扩散模型

近年来，扩散模型在离线强化学习领域的应用研究不断取得新进展（Zhu等人， 2023c）。具体而言，如第 7.3.1 - 7.3.3 节所述，扩散模型可作为离线强化学习中的策略、规划器或数据合成器。此外，我们在第 7.3.4 节详细阐述了扩散模型在扩展型离线强化学习场景中的应用。针对每个应用类别，我们首先通过经典案例解析其核心范式，随后重点介绍各扩展方向的关键创新点。

[19] 在每个时间步长中，为了采样 $a \sim __(\cdot|s)$，整个去噪过程（包含 T 次迭代）如等式（94）所示需要由于执行过程，因此DM的采样效率至关重要。

7.3.1 扩散模型作为策略

如第 2.1.1 节所述，为解决 OOD 动作导致的价值函数高估问题，我们开发了四种离线强化学习方案。其中，基于决策机制的离线强化学习通常采用策略约束方法，即在最大化Q函数的同时，将学习到的策略 π_θ 约束为行为策略 μ：

$$\max_\theta \mathrm{E}_{s\sim D\mu}\left[\mathrm{E}_{a\sim\pi\theta(\cdot|s)}\, Q_\phi(s,a) - \lambda D_{KL}(\pi_\theta(\cdot|s)\,||\,\mu(\cdot|s))\right] \quad (97)$$

其中 Q_ϕ 是当前策略 π_θ 的学习得到的Q函数，$\lambda>0$是拉格朗日乘数[20]。这样的优化问题有闭式解，即，$\pi^*(a|s)=\frac{1}{Z(s)}\mu(a|s)\exp(\frac{1}{\lambda}Q_\phi(s,a))$，其中 $Z(s)$ 是用于归一化的配分函数。假设 π^* 可以表示为参数化函数，那么最优策略可以通过加权回归（王等（2020））学习，具体如下：

$$\max_\theta \mathbb{E}_{(s,a)\sim D_\mu}\left[\frac{1}{Z(s)}\log\pi_\theta(a|s)\exp(\frac{1}{\lambda}Q_\phi(s,a))\right] \quad (98)$$

因此，*参数化策略* π_θ 应具有足够的表达能力以恢复最优策略。

在此场景中，可采用决策机制（DM）来建模策略 π_θ。**(1) SfBC**（陈等人，2023b）提供了一种简便的实现方法。该方法首先在强化学习框架中，通过 $\pi_\theta(a|s)$（具体为Score SDE）来模拟行为策略 $\mu(a|s)$，如第 7.2.1 节所述。随后，对于任意状态 s，通过 $\pi_\theta(\cdot|s)$ 从候选动作中采样 N 个动作，再从这些候选动作中以指数分布（exp）重新采样一个动作。$\frac{1}{\lambda}Q_\phi(s,a)$作为采样权重。通过这种方式，$a\sim\pi^*(\cdot|s)$可借助重要性采样进行近似。值得注意的是，$Q_\phi(s,a)$可通过任何离线强化学习协议进行学习。**IDQL**（Hansen-Estruch等人（2023））采用了相同的重采样方案，但通过 DDPM 来模拟 $\mu(a|s)$。此外，不同于使用$\exp(\frac{1}{\lambda}Q_\phi(s,a))$，他们基于隐式Q学习框架（Kostrikov等人，2022）设计了采样权重，该框架是一种 SOTA 离线强化学习算法。**(2)** 另一种方法是直接将Q函数 $Q_\phi(s,a)$ 引入决策机制策略 $\pi_\theta(a|s)$ 的训练过程。特别地，**Diffusion-QL**（Wang等人，2023f）通过以下目标函数学习基于 DDPM 的策略：

$$\min_\theta \mathcal{L}_{DM}(\theta) - \frac{\eta}{\mathbb{E}_{(s,a)\sim D_\mu}[|Q_\phi(s,a)|]}\mathbb{E}_{s\sim D_\mu, a_0\sim\pi_\theta(\cdot|s)}[Q_\phi(s,a_0)] \quad (99)$$

在此，$L_{DM}(\theta)$被定义为等式（93）（即一个IL目标），如果采用不同类型的DM，则可以用相应的训练目标替换。π_θ 由去噪函数 ϵ_θ 推导得出，a_0 是经过 T 次迭代去噪后的动作样本（带有等式·（94））。$\mathrm{E}_{(s,a)\sim D\mu}[|Q_\phi(s,a)|]$ 被纳入以适应不同尺度的Q函数。直观上，Q函数在DM的逆生成过程中起到引导作用。此外，等式（99）反映了等式（97），因为这两个等式都鼓励学习策略在接近行为策略的同时最大化Q值。值得注意的是，**DiffCPS**（He等人，2023b）提供了等式（99）和等式（97）之间的理论联系。

在Diffusion-QL之后，已有多个采用类似目标设计的算法被提出，这些算法与等式（99）相似，包括 SR-DP（Ada等人，2023）、EDP（Kang等人，2023）和Consistency-AC（Ding与 Jin，2023）。具体而言，**SRDP** 还在等式（99）中引入了一个状态重构损失项，通过自监督学习实现对 OOD 状态的泛化（Liu等人，2023a）。**EDP** 通过修改等式（97）中的采样过程 $a_0\sim\pi_\theta(\cdot|s)$，提高了Diffusion-QL的采样效率。与使用等式（94）的迭代采样不同，它首先通过前向过程采样 a_t，然后将 a_0 进行近似。$\frac{1}{\sqrt{\alpha_t}}\ \frac{\sqrt{1-\alpha_t}}{\sqrt{\alpha_t}}$

最后，有两项研究：QGPO（Lu等人，2023）和 CPQL（Chen等人，2023f），旨在直接学习最优策略的评分函数：（该函数源自 π^* 的定义，其中 $\alpha=1/\lambda$。）

$$\nabla_{\text{在}}\text{对数}\,\pi^*(a_t|s)\ \text{处的导数}\ \mathbb{X}\ \nabla_{\text{在}}\text{对数}\,\mu(a_t|s)\ \text{处的导数加上}\ \nabla_{\text{在}}\alpha Q_\phi(s,a_t)\ \text{处的导数} \quad (100)$$

[20] 作为一种常见做法，λ 可以作为超参数进行微调，以控制两个目标项之间的权衡。

如第 7.1 节所述， *在* $\log \pi^*$（$a_t|s$）处的评分函数 ∇ 下，可通过多种高效的评分采样方案生成 $a_t \sim \pi^*$（$\cdot|s$）样本[21]。其中， $\log \mu$（$a_t|s$）处的评分函数 ∇ 可通过第 7.1 节所述的 D_μ 的评分决策机制进行学习，而 αQ_ϕ（s，a_t）处的 $\nabla_{a_t} \alpha Q_\phi$（$s$，$a_t$）则依赖于中间样本 a_t 的Q函数，这在实际操作中难以实现。针对这一挑战， **QGPO** 提出了一种对比学习框架，用于估计 αQ_ϕ（s，a_t）（*其中t* 为时间步）。同时， **CPQL** 采用一致性模型作为策略，将等式（100）中的得分函数估计重新表述为与等式（99）类似的目标函数，并在理论上证明了当等式（99）中两个项的权重被适当选择时，两者具有等价性。

在表 11 中，我们对这些算法进行了总结。本类别所有算法均已在D4RL基准测试中完成评估，读者可查阅相关论文获取具体数值评估结果以便对比性能。特别值得注意的是，目前已有三种基于扩散模型作为离线强化学习策略的研究方案：SfBC与 IDQL 、 QGPO 与 CPQL ，以及后续发展自扩散Q学习（Diffusion-QL）的研究。其中， QGPO 与 CPQL 选择直接学习对应最优策略的评分函数，这一方向虽然极具挑战性，但为未来研究开辟了广阔前景。

7.3.2 扩散模型作为规划者

对于基于模型的学习，需要首先从数据集 D_μ 中近似得到动态函数 T_ψ（$s^{k+1}|s^k$，a^k），然后通过最大化回报同时避免 OOD 个动作来规划最优动作序列（a_1*，$\cdots$，aK*），其目标如等式（9）所示。需要注意的是，为清晰起见，我们使用上标 k 表示时间步长，下标 t 表示扩散过程的迭代次数。 **SGP**（Suh等人，2023）提出将不确定性度量 u（s，a）（如等式（9）所示）实现为（s，a）在扰动分布下的负对数似然，即。， $-\log P_\sigma$（（s，a）； D_μ），其中 $P_\sigma(x;\ D_\mu) = \frac{1}{|D_\mu|}\sum_{x_i \in D_\mu} N(x;\ x_i, \sigma^2 I)$。直观来说，这个似然度衡量了点（$s$，$a$）与数据集 D_μ 的距离，距离越大表明该点（s，a）的不确定性越高，因为它可能是 OOD 。为了优化轨迹规划的等式（9），需要估计评分函数 $\nabla_a \log P_\sigma$（（s，a）； D_μ）。如（Suh 等人（2023）所述，该估计可以通过DM中的去噪函数（具体为SGM）获得。

一种更广泛采用的使用DM进行规划的方法，最初由 **Diffuser**（Janner 等人（2022）提出，是将上述两个过程： $1{:}K$ 的 转移动态建模和轨迹优化 ，折叠为一个使用DM的轨迹建模过程。将轨迹 τ =（（s^1，a^1），$\cdots$，（s^K，a^K））视为数据点（即等式（89）中的 x）， DDPM 用于通过等式（89）建模 D_μ 中 τ 的分布，其中学习了用于轨迹生成的去噪函数 ϵ_θ（τ_t，t）。然后，可以通过从当前状态开始使用学习到的DM采样轨迹来进行规划。采样过程类似于等式（94）。然而，作为强化学习算法，该过程由轨迹样本的（单独训练的）返回函数引导，即， J_ϕ（$\hat{\tau}_t$，α_t，Σ^t是超参数，定义在 第7.1 节中。）

$$\tau_{t-1} \sim G_\theta(\cdot|\tau_t, g) = \mathcal{N}(\mu_t + \Sigma_t g, \Sigma_t),\ \mu_t = \frac{1}{\sqrt{1-\beta_t}}(\tau_t - \frac{\beta_t}{\sqrt{1-\alpha_t}}\epsilon_\theta(\tau_t, t)),\ g = \nabla_{\hat{\tau}} J_\phi(\hat{\tau})|_{\hat{\tau}=\mu_t} \tag{101}$$

该过程也被称为 **分类器引导采样**（CG，由 Dhariwal与Nichol 于 2021 年提出），在扩散模型的条件生成任务中被广泛应用。其核心原理是通过梯度 $\nabla_\tau J$（τ）进行引导，使期望收益 J（τ）达到最大化，这与强化学习（RL）的思路高度契合。在 Janner 等人（2022）的研究中，作者将这种引导采样设计与强化学习的“控制即推理”框架（Levine， 2018）相结合，并指出此类生成过程产生的轨迹遵循 $P(\tau|O_{1:K}=1)$ 分布，其中 O_k =1表示时间步 k 的最优性。在评估阶段，所学
DM可按如下方式应用：（T 是真实动态。）

$$[\tau_t(s^1) \leftarrow s^k,\ \tau_{t-1} \sim G_\theta(\cdot|\tau_t, g)|_{1\,t=T},\ a^k \leftarrow \tau_0(a^1),\ s^{k+1} \sim T(\cdot|s^k, a^k),\ k=1, \cdots, K \tag{102}$$

为确定 一个 ^{k}，在每次迭代中，轨迹样本都必须从当前状态开始，即 $\tau_t(s^1) \leftarrow s^k$（$t$=1，…，$T$）。这一思路借鉴了修复问题的解决方法（Sohl-Dickstein等人， 2015），其中

21 注意， a_t 表示 t 次扩散迭代的样本，而不是时间步 t 的动作。

22 J_φ（$\hat{\tau}$）被训练用于估计原始轨迹的回报，即，$J(\tau) = \sum_{k=1}^K r(s^k, a^k)$, 其中$\hat{\tau}$ 可以是任何扩散迭代中的轨迹样本，即 π 。

未观测部分的生成方式与观测约束保持一致。此外，生成计划中仅执行第一个动作，即 $\tau_0(a^1)$，且无需重新规划，这与滚动时域控制（Mayne & Michalska 1988）相一致。 **Decision Diffuser**（Ajay等人 2023）采用了类似的设计，但有两个关键改进。首先，他们没有训练分类器引导采样的回报函数，而是采用 **分类器无关引导采样**（CFG 2022），其中条件和无条件去噪函数，即 $\epsilon_\theta(\tau_t, t; J(\tau))$ 和 $\epsilon_\theta(\tau_t, t; \varnothing)$，被联合训练（使用等式（89）通过随机丢弃条件器 $J(\cdot)$ 实现。轨迹生成过程与等式（94）相同，但用 $\sim\epsilon_\theta(\tau_t, t)$ 替换了标准去噪函数 $\epsilon_\theta(\tau_t, t)$，并添加了 $\sim\epsilon_\theta(\tau_t, t; J(\cdot))+(1-\sim)\epsilon_\theta(\tau_t, t; \varnothing)$。增加 $\sim$ 的值会降低样本多样性，但能使轨迹分布更接近 $P(\cdot|O_{1:K}=1)$。值得注意的是，CG和 CFG 均可用于生成满足特定条件 y 的样本。在强化学习的语境中，y 可以是期望回报 $J(\cdot)$、需遵守的约束条件、需达成的目标或子目标（适用于多任务或层次化强化学习），等等。其次，动态模型（DM）仅对状态序列进行建模和预测，即 $\hat{\cdot}=(s^1, \cdots, s^K)$，而动作则通过独立的逆动力学模型进行预测，即 $a^k = T_{\text{inv}}(s^k, s^{k+1})$。这是因为动作序列往往具有更高的频率和更不平滑的特性，这使得它们的预测和建模难度显著增加。

在Diffuser和Decision Diffuser的基础上，我们在采样过程（SafeDiffuser、Discrete Diffuser）、网络结构（EDGI）、训练目标（PlanCP）以及条件器（TCD）等多个方面进行了改进。以下将简要概述这些改进与原版Diffuser和Decision Diffuser的对比。值得注意的是，只有TCD继承了Decision Diffuser的设计，其余均沿用了Diffuser的架构。 **SafeDiffuser**（Xiao等人， 2023）旨在确保扩散过程中数据的安全生成。在每次迭代 t 中，扩散动态 $u_t=\frac{\tau_{t-1}-\tau_t}{\Delta t}$ 该算法经过重新优化以满足特定安全约束，生成的动态 u^*t 用于更新 $\hat{\cdot}_{t-1}$ 为 $\hat{\cdot}_t+\Delta t^*u^*t$。$\grave{}$ t 作为扩散时间间隔，其数值应足够小。研究者通过理论证明，采用此方法生成的 $\hat{\cdot}_0$ 能以接近1的概率满足安全约束。 **Discrete Diffuser**（Coleman等人， 2023）针对无法应用高斯扩散机制的离散状态与动作空间，提出了三种扩散引导采样技术。这些引导采样方法可与D3PM（Austin等人， 2021a）等离散扩散机制兼容。 **EDGI**（Brehmer等人， 2023）则为具身智能体在三维环境中操控 n 个物体的场景，提出了一种等变网络架构。该网络设计考虑了几何结构，并确保轨迹及其对应轨迹在应用特定空间/时间平移或物体置换时具有相等的可能性。因此，可以在发生此类平移或置换的场景中实现更好的泛化能力。 **PlanCP**（Sun等人， 2023）提出使用保形预测（Vovk等人， 2005）来量化决策扩散器（DM）的不确定性。具体而言， M 条轨迹由 D_μ 中的 $_M$ 条轨迹对应的DM生成，每对轨迹都有一个预测误差 e_i。$\{e_i\}$ 之间的保形性反映了DM的不确定性。将这一保形项作为辅助项引入 DDPM 训练目标（即等式（89））中，可能有助于降低使用DM采样的不确定性。与决策扩散器相比， **TCD**（Hu等人（2023a）通过引入更多时间信息作为去噪函数 ϵ_θ 的条件参数，指导采样过程。具体而言，借鉴决策变换器（决策变换器在 6.2.1 节中已作介绍）的思路，将当前时间步的返回状态和奖励分别作为前瞻条件和即时条件，从而在更聚焦当前生成步骤的同时，合理推断采样进程。

7.3.3 扩散模型作为数据合成器

离线强化学习的性能受限于给定的静态数据集 D_μ。一旦使用 D_μ 完成训练，决策模块（DM）便能生成多种高质量轨迹数据。这些新生成的数据可进一步扩充 D_μ，形成持续优化决策模块的反馈循环。此外，在未见过但相关任务中，决策模块的通用特性使其能够生成高性能轨迹，用于在新环境中对模型进行微调。目前已有多个研究沿着这一方向展开，分别基于扩散器（Hwang等人， 2023； Liang等人， 2023b）或决策扩散器（He等人， 2023a）进行开发。具体而言， **AdaptDiffuser**（Liang等人（2023b）提出了一种基于规则的方法，用于从Diffuser生成的轨迹 $\hat{\cdot}=((s^1, a^1), \cdots, (s^K, a^K))$ 进行过滤和增强，该方法基于返回值和动态一致性。从 $k=1$开始，对动作进行修订。$\tilde{a}^k$ 是通过使用经过良好训练或定义的逆动力学模型 T_{inv} 来确定的 $(\tilde{s}^k, s^{k+1})$ (with $\tilde{s}^1 = s^1$). Subsequently, the next state is adjusted according to the (learned) environment dynamic function as $\tilde{s}^{k+1} = \mathcal{T}(\tilde{s}^k, \tilde{a}^k)$. Trajectories with states s^k significantly deviating from

their counterparts $\tilde{s}^k$ 被过滤掉。The remaining trajectories $\tilde{\tau}$ 根据其回报率进一步筛选 $J_\phi(\tilde{\tau}) = \sum_{k=1}^{K} r_\phi(s^k, a^k)$. Finally, the chosen trajectories are of high quality and can be used for effective 数据增强。在更直接的方法中， **MTDiff**（He等人， 2023a）通过基于同一环境的专家演示数据（记为 y）构建轨迹模型 =(（s^1，a^1，r^1），···，（（s^K，a^K，r^K））。随后，直接使用从学习到的条件去噪函数 ϵ_θ（ $_t$，t； y）生成的轨迹样本进行数据增强。对于未见过的任务，可使用少量演示数据作为提示（即 y），通过 ϵ_θ($_t$，t； y）生成高质量训练数据。这些数据可用于调整决策机制策略以适应新任务。

7.3.4 扩展离线强化学习设置中的扩散模型

扩散模型已成功应用于多任务、多智能体及分层离线强化学习场景。不过这些方法仍基于前述基础算法构建，例如扩散强化学习（Diffusion-QL）、扩散器（Diffuser）和决策扩散器（Decision Diffuser）。MTDiff（He等人， 2023a）和MetaDiffuser（Ni等人， 2023）致力于学习任务条件规划器来解决任务分布问题。它们采用按任务分类的离线数据，即 $^{u}{}_i D_{\mu i}$，其中 μ_i 表示任务 i 的行为策略。与决策扩散器类似，**MTDiff** 在任务 i 的规划器中引入了专家轨迹 y_i 作为额外条件，该条件表示为 ϵ_θ（ $_t$，t； J（ ），y_i）。通过训练，智能体能够潜移默化地掌握提示轨迹 y_i 中存储的转移模型和奖励函数，并基于这些内化知识进行任务特定规划。当在新但相关任务中进行评估时，基于对应演示 y_i 的去噪函数可直接用于规划。相比之下， **MetaDiffuser** 通过学习编码器（记为 E_η）将轨迹编码为紧凑表示，从而显式建模奖励和转移动态。该编码器与近似奖励模型和动态模型（作为解码器）在 VAE 框架下联合训练，其架构类似于第 3.2.4 节提出的BoReL方法：

$$\min_{\eta,} \text{其中} \quad , \quad \text{x} = \text{E} \quad \sim uiD\mu i\,, y = E \quad (\quad)\,, \quad (s^k, a^k, r^k, s^{k+1}) \sim \quad [\log T_\psi(s^{k+1}|s^k, a^k, y) + \log r_\phi(r^k|s^k, a^k, y] \quad (103)$$

通过这种方式， y 被训练以嵌入任务特定的奖励和动态函数。当为特定任务 i 规划时，表示 $y_i = E_\eta$（ $_i$）， $_i \sim D_{\mu_i}$ 可作为规划器的额外条件。值得注意的是，MetaDiffuser基于Diffuser，并采用学习到的奖励和动态模型来定义等式（101）中的采样引导 g，以增强生成轨迹的动态一致性，同时鼓励高回报，具体如（Ni等人 2023）中的等式(7)。

DOM2（Li等人， 2023c）和MADiff（Zhu等人， 2023b）致力于完全合作的多智能体离线强化学习。基于Diffusion-QL框架， **DOM2** 在完全去中心化的框架下为每个智能体学习Q函数和基于决策机制的策略。该策略专门用于将每个智能体的个体观察映射为其自身动作，通过等式（99）进行训练。继Decision Diffuser之后， **MADiff** 被开发用于规划所有智能体的联合轨迹。每个智能体 i 都有一个独立的去噪函数 用于规划其对应轨迹。为促进全局信息交换以实现更好协调，去噪函数包含一个注意力层，用于聚合来自其他智能体的轨迹嵌入。显然，关于基于决策机制的多智能体强化学习（MARL）可以开发更多扩展，例如针对完全竞争或混合（部分合作/竞争）多智能体任务的MARL算法，以及将决策机制与最先进的集中式训练&去中心化执行（CTDE）MARL方法相结合。

LDCQ（Venkatraman等人， 2023）和HDMI（Li等人， 2023b）提出了一种从离线数据集中学习分层策略/规划器的方法，这对长期决策尤其有益。 **LDCQ** 通过学习 $_{\text{高层策略}} z|s$ 来实现技能选择，同时为每个技能 z 学习 $_{\text{low}} a|s, z$ 的低层策略。特别地，他们采用 - VAE 方法从离线数据集 D_μ 中发现技能（该目标与第 3.2.4 节介绍的OPAL目标相同）。

$$\max_{\phi,\theta} \mathbb{E}_{\tau \sim D_\mu, z \sim P_\phi(\cdot|\tau)} \left[\sum_{k=1}^{K} \log P_\theta(a^k|s^k, z) - \beta D_{KL}(P_\phi(z|\tau)||\text{prior}(z|s^1)) \right] \qquad (104)$$

与OPAL类似，训练完成后， P_θ 作为 $_{\text{low}}$ 使用，而 P_ϕ 用于将 D_μ 转换为一系列形式为（s^1，$z \sim P_\phi$（·| ））*的转换* ， $\sum_{k=0}^{K-1}$<sp_