http://htkz.cn
引用格式:许越越,杜华军,郭尚伟. 低空无人机具身导航研究进展[J]. 航天控制,2025,43(4):7-14. (XU Yueyue, DU Huajun, GUO Shangwei. Research progress on embodied navigation of low-altitude UAV[J]. Aerospace Control, 2025, 43(4): 7-14.)

低空无人机具身导航研究进展

许越越[1,2],杜华军[1,2],郭尚伟[1,2]
1. 北京航天自动控制研究所,北京 100854
2. 宇航智能控制技术全国重点实验室,北京 100854

摘 要 围绕低空经济背景下低空无人机具身导航的发展需求,本文从理论基础、关键技术路径与应用挑战3个维度进行系统梳理与分析:明确了具身导航相较传统导航在语义理解、环境交互和群体协同等方面的优势与研究价值;从传统同步定位与地图构建(SLAM)发展至视觉语言导航(VLN)与视觉语言动作模型(VLA)的技术演进过程出发,构建了面向低空无人机的具身导航技术框架;通过分析两个典型的应用案例,探讨了低空无人机具身导航在复杂环境下的实际应用趋势;对低空无人机具身导航的未来发展方向进行了展望,期望为智能自主导航的理论研究与行业应用提供有益参考。

关键词 低空无人机;具身智能;具身导航;视觉语言动作模型
中图分类号:V249.32 **文献标识码**:A **文章编号**:1006-3242(2025)04-0007-08
DOI:10.16804/j.cnki.issn1006-3242.2025.04.004

Research progress on embodied navigation of low-altitude UAV

XU Yueyue[1,2], DU Huajun[1,2], GUO Shangwei[1,2]
1. Beijing Aerospace Automatic Control Institute, Beijing 100854, China
2. National Key Laboratory of Science and Technology on Aerospace Intelligence Control, Beijing 100854, China

Abstract Under the background of the vigorous development of theory and application of embodied intelligence, in order to further improve the intelligence level of low altitude UAVs and expand their application boundaries, the development requirements of low altitude UAVs are focused on the context of low altitude economy, and the researches are implemented and systematically analyzed, regarding three domains in terms of the theoretical basis, key technology paths and application challenges. Firstly, the advantages and research value of embodied navigation compared with traditional navigation on semantic understanding, environment interaction and group collaboration are determined. Secondly, derived from the development of traditional simultaneous location and mapping(SLAM) to the technology evolution of visual language navigation(VLN) and visual language action(VLA) model, one special navigation tech-

收稿日期:2025-05-20
作者简介:**许越越**(2003-),女,硕士研究生,主要研究方向为导航、制导与控制;**杜华军**(1976-),男,研究员,主要研究方向为导航、制导与控制,本文通信作者。

中国知网 https://www.cnki.net

nology framework for low altitude UAVs is established. Thirdly, through analysis of two typical application cases, the practical application trend of low altitude UAV in complex environment is discussed. Finally, future development directions of low altitude UAV embodied navigation are overviewed, the proposed achievement can serve as valuable references for theoretical research and industrial application to intelligent autonomous navigation.

Key words Low altitude UAV; Embodied intelligence; Embodied navigation; Vision language action model

0 引 言

随着低空经济的迅速发展,低空飞行器在低空经济中发挥着越来越重要的作用,在物流配送、城市巡查以及应急救援等领域有了越来越广泛的应用,但也面临着城市环境、多障碍物及恶劣天气等挑战。低空经济正促使无人机技术朝着自主化和智能化方向快速发展,且要求无人机具备多种智能化能力。智能自主导航是低空无人机必须具备的核心智能化能力之一。

具身导航为低空无人机智能自主导航能力的实现提供了发展契机。具身导航作为具身智能的关键组成部分,随着深度学习、强化学习和大型预训练模型等技术的进步,特别是随着大语言模型(Large language model,LLM)、视觉语言模型(Vision language model,VLM)及视觉语言动作模型 VLA 等关键技术的突破,其理论和应用正得到蓬勃发展。

目前关于无人机自主导航的综述[1-3]多数没有涉及具身智能,而且具身导航的综述[4-7]大都关注室内机器人,还没有系统分析低空无人机具身导航的综述。本文结构如图 1 所示。

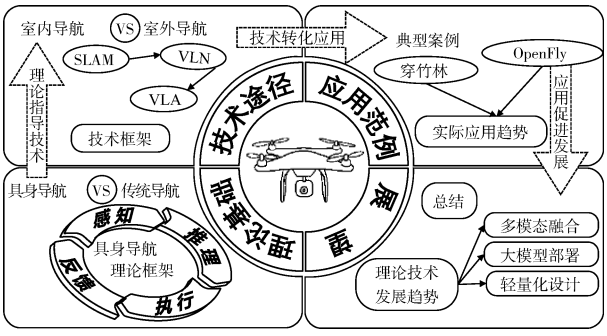


图 1 本文结构

1 低空无人机具身导航理论基础

1.1 具身导航定义

传统无人机自主导航以路径规划与定位技术为核心,利用全球导航卫星系统(GNSS)、惯性测量单元、激光雷达及深度相机等传感器,在几何空间搜索从起点到目标的最优路径,控制实现多约束下的高效运动,采用的方法主要包括感知与避障[8]及 SLAM[9]等。目前,传统导航仅解决了静态环境下的导航与地图构建问题,还没有解决动态环境下智能自主导航面临的多传感器融合、动态路径规划、自主避障与决策、广域语义理解和集群协同导航等挑战性问题,急需发展新的导航理论和技术。具身智能是指具有身体的智能,是能够与环境交互的人工智能系统,要求智能体在持续互动中不断学习适应动态环境[10]。与只能处理和生成数据的传统人工智能模型不同,具身智能主要研究如何使智能体具备类似人类的感知、规划、决策和行为能力[11]。具身导航指智能体在复杂动态环境中根据任务目标,通过与物理环境的实时交互,预测并执行导航行动的能力。具身导航为低空无人机在复杂动态环境中进行智能自主导航提供了发展契机,相比于传统自主导航具有多方面优势,如表 1 所示。

表 1 传统自主导航与具身导航的对比

对比维度	传统导航	具身导航
决策依据	历史数据滤波	语义推理
硬件依赖	高精度传感器	多模态传感器
动态响应	依赖预设规则	实时自适应
环境交互	被动感知	实时反馈
适用场景	结构化环境	复杂动态环境
技术工具	SLAM、卡尔曼滤波	强化学习、大模型

1.2 具身导航的内涵和理论框架

具身导航的内涵涉及以下 3 方面:语义升级、环

中国知网 https://www.cnki.net

境交互和群体智能。语义升级是指智能体在理解几何结构的基础上理解环境和指令中的语义内容,并在构建几何地图的基础上构建语义地图,加强了导航系统的目标理解能力和人机交互能力;环境交互是指智能体要与环境进行包括感知、动态调整和实时反馈在内的交互并形成闭环,增强了导航系统的鲁棒性和对动态环境的适应性;群体智能是指导航系统通过多智能体的分布式协作解决复杂场景下的任务分配、资源竞争和路径冲突等问题[12]。低空无人机具身导航的理论框架如图2所示。

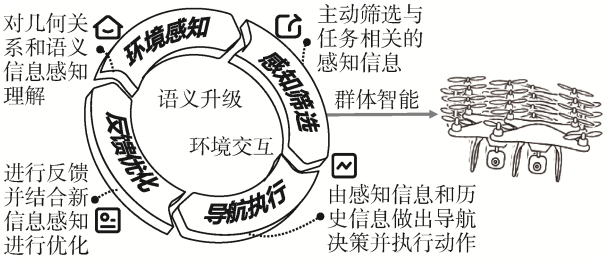


图2　具身导航理论框架

1.3　视觉语言导航(VLN)

在具身智能牵引下,具身导航逐渐向基于学习的导航方向发展,其主要特点是利用深度学习与强化学习技术从大量数据中学习环境特征和导航策略,从而实现强自适应性和高灵活性的导航。结合无人机的应用特点分析,视觉导航已发展成为无人机导航的关键技术,它有利于克服传统的GNSS导航易受干扰的缺陷和惯性导航易随时间漂移的不足,具有广阔的发展前景。其中,VLN逐渐成为视觉具身导航领域的重要研究方向之一。

VLN模型是基于视觉输入和语言指令的导航任务专用模型[13],能使智能体与周围环境交互进行感知理解。视觉语言导航任务包括指令导向(如R2R[14])、目标导向(如REVERIE[15])、需求导向(如DDN[16])和对话导向任务(如DialFRED[17]),都要求智能体基于自然语言指令解析环境语义、构建空间表征、规划动态路径并做出实时决策[18]。随着计算机视觉和自然语言处理领域的进步,如对象分类、对象检测、语义分割和大规模预训练语言模型等技术的突破促进了VLN的发展。VLN可应用于室内、室外和空中等多个场景,其中空中视觉语言导航(如AerialVLN[19]和OpenUAV[20])主要针对无人机导航任务,需要考虑飞行高度和复杂的空间关系。目前低空无人机具身导航的VLN技术还存在多模态信息整合困难、训练数据有限和泛化能力不足等问题。

1.4　视觉语言动作模型(VLA)

VLA由谷歌DeepMind的RT-2[21]等开创,结合了视觉处理、语义理解和动作生成,旨在弥合感知、理解及与物理世界互动之间的差距[7]。VLA的架构一般包括提取环境特征的视觉编码器、解析指令的语言模型和生成控制信号的动作解码器等。VLA方案包括基于预训练的LLM或VLM(如RT-2[21]、OpenVLA[22])、基于扩散模型(如Diffusion Policy[23])、LLM+扩散模型(如Octoπ0[24])、显式端到端和隐式端到端(如SWIM[25])等方案。其中,VLA的显式端到端方案将视觉语言信息直接映射到动作空间,具有低延迟高响应特性,因此更适合无人机导航。VLA模型的学习范式主要依赖大规模数据集和高效的训练策略。近年来许多适用于无人机的VLA数据集被提出,如OpenBench[26]和OpenFly[27]等。

2　低空无人机具身导航技术途径

2.1　室内外具身导航场景特性对比

具身导航呈现出从室内到室外发展的趋势,并趋向于室内外融合的特点。目前,室内机器人应用的具身导航发展迅速,比如不依赖于特定机器人配置的室内通用导航策略RING[28]。低空无人机主要应用的室外环境与室内环境之间的具身导航特性对比如表2所示。

表2　室内外具身导航特性对比

维度	室内导航	室外导航
导航空间	受限二维空间为主	三维立体空间为主
干扰因素	光线变化等	气象变化等
语义密度	物体型语义密集	地标型语义稀疏
技术重心	精确局部定位	实时重规划、长距离
应用场景	医疗、家务等	物流、农业、巡检等
静态障碍物	家具、门廊等	建筑、高压线网等
动态障碍物	行人、移动设备等	临时飞行物等

室内导航在结构化环境中具有语义明确的特点,包含明确的建筑结构特性和密集的视觉特征,这为依托VLM的VLN提供了天然优势。室内VLN一般侧重于语义地图的不断更新,比如MapNav[29]的语义地图通过实时融合RGB-D传感器数据与语义分割结果,动态更新标注语义地图。结合表2分

中国知网　https://www.cnki.net

析，相比于室内环境的VLN，无人机VLN在室外环境中应用面临更大空间尺度、更复杂环境和更稀疏路标等挑战。目前有相关研究来应对这些挑战，比如中科院提出的多尺度环境融合增强VLN模型NavAgent[30]，整合了全局环境拓扑图、当前观测位置的全景视图和局部精细路标数据，有助于无人机实现更准确且稳定的VLN。另外，低空无人机VLN需考虑垂直与水平动作之间的相互作用后再做出决策，导航路径更长。比如在MeM2Ego[31]导航框架中，若要获得全景感知信息，需从6个方向捕获观测图像形成天空盒，而不是4个方向。

2.2 SLAM到VLN再到VLA的演进

对于无人机在实际低空环境中的导航任务，技术上需要解决多模态数据融合、环境感知和动态适应的问题，SLAM、VLN和VLA都能助力低空无人机解决这些问题，并呈现出从SLAM到VLN再到VLA的发展趋势。

作为无人机传统自主导航关键技术之一的SLAM，其发展经历了从传感器驱动（如基于激光雷达的GMapping[32]）到算法创新（视觉SLAM如PTAM[33]）再到智能融合（结合自然语言的SLAM如NL-SLAM[34]）的过程。SLAM主要解决了定位与地图构建问题，为导航提供了空间认知能力，但在动态环境适应、高算力需求和任务导向理解方面存在挑战。VLN在SLAM的空间认知基础上引入了自然语言理解和任务导向的决策，发展出了包括LLM导航、价值地图、VLM导航在内的多种范式[35]，实现了人类语言指令驱动的导航，但缺乏直接的动作执行能力。VLA是VLN能力的进一步扩展与深化，统一融合了视觉处理、语义理解和动作生成。对无人机而言，V代表低空场景感知，L代表语言指令理解，A代表精确的导航动作执行，适用于复杂的交互任务。但是低空无人机的高速运动可能导致视觉、语言和动作之间的时空错位风险和动作的物理不可行风险。VLA还需要大规模的优质数据用于训练以减小偏差。

SLAM为VLN和VLA提供了环境感知和空间理解的基础能力，VLN在此基础上增加了语言理解和交互能力，VLA则进一步整合了动作生成能力，随着VLA模型的成熟，SLAM与VLN的能力正被整合为多模态基础模型的子模块，推动低空无人机具身智能技术发展。

2.3 低空无人机VLA模型进展

近年来，针对低空无人机的VLA模型取得一定进展。文献[22]中提出的OpenVLA基于97万次真实机器人演示数据训练而成，是第一个广泛被使用的7B参数开源VLA模型。OpenVLA基于Llama 2[36]语言模型构建，并结合了融合DinoV2[37]和SigLIP[38]的预训练特征的可视化编码器，将输入的给定图像观察和语言指令，输出为预测的7维机器人控制动作。OpenVLA在通用操作任务上对比55B参数的封闭模型RT-2-X[39]有更高的成功率。通过对OpenVLA进行高效的微调，能够快速适应新的机器人领域和任务，目前很多适用无人机的VLA模型都是基于它提出的。例如文献[40]中提出的RaceVLA，它是基于OpenVLA架构进行了优化的专门针对竞速无人机设计的VLA模型，将车载摄像头的第一人称视角视频流和自然语言命令生成四分量控制信号，相比于OpenVLA有更好的运动泛化能力和语义泛化能力。RaceVLA主要应用在室内的竞速无人机，对于更复杂环境中的室外低空无人机，VLA依然有一定的应用效果。例如文献[41]中的CognitiveDrone，它是一个专为无人机认知任务设计的VLA模型，融合了基于OpenVLA模型改编的用于实时生成控制命令的VLA模型和用于对任务指令进行优化处理的VLM推理模块，其在任务复杂度上相比于RaceVLA有明显提升，并且通过引入认知任务处理能力扩展了无人机VLA的应用场景。上述这些模型的参数都超过了7B，计算成本和部署门槛高。但无人机的机载算力有限，所以需要通过模型压缩和边缘计算对VLA进行轻量化。目前机器人平台的VLA模型已有的轻量级解决方案NORA[42]可将参数降至3B。未来，可通过提出专为无人机任务优化的轻量化VLA模型解决VLA模型在真实无人机任务中存在的“落地难”问题。

近年来，针对低空无人机VLA数据集的研究也取得显著进展。文献[43]中提出的UAV-VLA系统引入的专为无人机任务生成设计的基准测试平台UAV-VLPA-nano-30，包含了30张高分辨率卫星图像，每张卫星图像的分辨率约为每像素1.5 m，每张图覆盖大约760 m^2的区域，每张图像都有地理位置描述，允许计算特征点的经纬度，以便生成飞行策略。相比于包含30幅卫星图像的基准测试数据集UAV-VLPA-nano-30，文献[27]中的OpenFly构建了目前最大的空中VLN数据集，通过自动化工具链

中国知网 https://www.cnki.net

减少了人工标注的工作量。相比于OpenVLA[22]中运用的Open X-Embodiment[39]数据集,OpenFly的数据集提升了数据规模和场景多样性。

缺乏大规模高质量的数据集是目前VLA发展面临的核心挑战之一,未来应在收集更大规模和更高质量的数据集方面做努力。本文总结了近年来提出的适用于无人机具身导航的数据集[19-20,26-27,43-46]如图3所示。

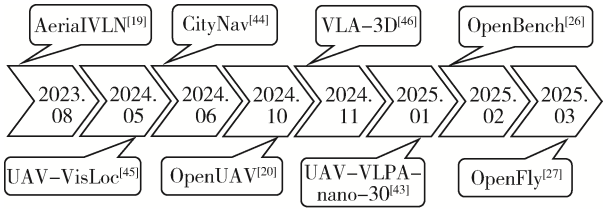


图3　近年来适用于低空无人机具身导航的数据集

2.4　低空无人机具身导航技术框架

具身导航的技术框架包含环境感知与建模层、任务理解与规划层及运动控制与执行层3个层级。近年来,多种智能体的具身导航技术在这3个层面上蓬勃发展。首先是环境感知与建模层,如P3Nav[47]的自适应3D感知历史采样策略通过增强历史语义特征减少冗余感知数据,提高环境信息的利用率,WMNav[48]通过视觉输入预测各视点的"好奇心值",量化目标物体存在的可能性,实现对感知信息的有效提取并建模;其次是任务理解与规划层,如PReP[49]通过反思与规划机制提升任务理解能力,从而在缺乏指令的情况下实现自主导航,Tube-RRT*算法[50]通过改进RRT算法生成同伦路径并构建虚拟管道,提升群体运动的整体效率和安全性;再次是运动控制与执行层,如OpenFly[27]定义六自由度动作,并将连续动作空间离散化为多个分箱,每个分箱对应动作的量化单位,UAV-VLA[43]利用VLM生成高层航点,实现端到端指令执行。结合针对低空无人机的VLA和室内机器人具身导航研究进展,本文梳理出一个低空无人机具身导航技术框架如图4所示。

3　低空无人机具身导航案例与启示

3.1　两个应用案例

第1个案例是文献[51]中浙大团队开发的一种完全自主的带有轨迹规划器的微型无人机。在仅使用机载视觉及机载计算资源的情况下,实现了在

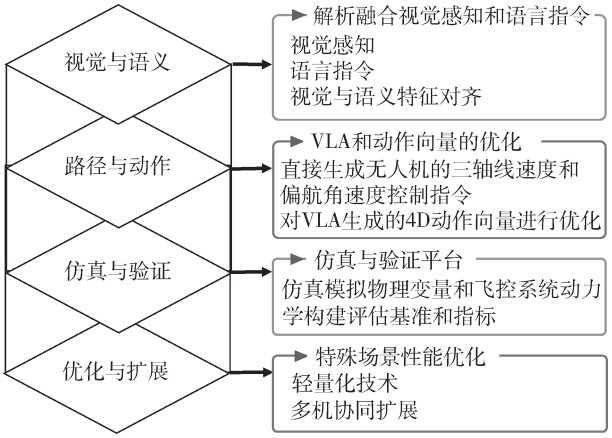


图4　一个低空无人机具身导航的技术框架

野外复杂竹林环境下感知周围障碍物、定位自身位置和生成飞行路径等任务,并能够共享数据来规划路线和跟踪目标。如图5所示,对于单体无人机,每架无人机都配备了完整的感知、定位、规划和控制功能,并设计了基于机载超宽带(UWB)的局部定位校正算法,结合改进的视觉惯性里程计(VIO)实现了无GPS环境下的相对定位;对于无人机集群,采用同步调整轨迹形状和时间分配实现最优路径规划。该具身导航案例体现了无人机的多传感器融合、动态路径规划、自主避障与决策和集群协同导航等智能化能力。

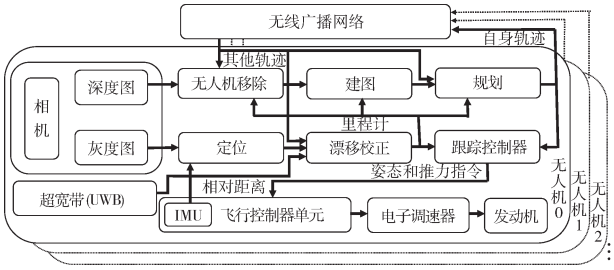


图5　"穿竹林"案例系统架构[51]

第2个案例是上海人工智能实验室携手多家机构共同开发而成的空中视觉语言导航平台OpenFly。它包括3个部分[27]:高度自动化的数据收集工具链、大规模空中VLN数据集和如图6所示的关键帧感知VLN模型OpenFly-Agent。该平台中的模型采用一系列图像来表征观测结果,能够基于观测特征信息和语言指令直接在室外低空环境中预测飞行动作,其动作解码器将预测的令牌映射到无人机特定的6种动作类型。

3.2　低空无人机具身导航应用趋势

"穿竹林"案例与OpenFly平台的技术对比如表

中国知网　https://www.cnki.net

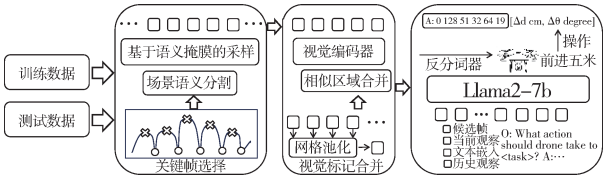


图6 OpenFly-Agent的架构[27]

3所示。从自主性和泛化能力方面分析，“穿竹林”案例是典型的反应式导航系统，通过时空联合优化实现毫秒级避障决策，其重点在于密集动态环境下的避障，优势在于动态环境的实时性；而OpenFly案例是认知式导航系统，优势在于更强的泛化能力，其重点在于语言指令引导的全局路径规划，其中引入的视觉语言导航让无人机能够理解自然语言指令，打开了人机协同的新篇章。从部署门槛方面分析，OpenFly-Agent使用的Llama-7B模型按FP16精度需14GB显存，而“穿竹林”的规划器仅需STM32H7级别MCU，这种千倍算力差决定了前者短期内难以微型化。

结合表3分析，为满足更广阔的低空无人机应用市场需求，未来低空无人机具身导航系统设计重点可参考下列途径：1)将轻量级模型控制和大模型语义理解相结合，提高系统自主能力；2)综合考虑应用环境差异性、任务目标动态性和用户群体广泛性，提升系统的泛化能力；3)平衡商用器件算力约束和硬件成本，降低系统部署门槛。

表3 “穿竹林”案例与OpenFly平台的技术对比

对比维度	“穿竹林”	OpenFly
自主能力	实时时空轨迹优化动态避障，群体协作自主决策	依赖预训练VL模型生成指令，关键帧决策降低冗余
泛化能力	导航任务扩展性强，依赖优化算法调参	跨场景指令理解强，依赖仿真数据多样性
部署门槛	无人机全嵌入式部署，无外部设施依赖，	GPU算力(Llama-7B+视觉编码器)，依赖高精度仿真数据
应用场景	通信带宽要求低竹林环境监测等	生成工具链城市物流、地质勘探等
主要优势	实时避障、群体协同鲁棒性、微型化硬件	语言-视觉对齐、人机交互、大规模场景覆盖

4 总结与展望

本文围绕低空无人机的具身导航展开综述。在理论层面，通过对比分析传统自主导航与具身导航的区别(如表1)，提出了一种具身导航理论框架(如图2)；在技术层面，通过分析从SLAM到VLN再到VLA的具身智能发展路径，结合室内外无人机具身导航技术发展需求(如表2)，梳理出面向低空无人机的具身导航技术框架(如图4)；在应用层面，通过分析“穿竹林”和“OpenFly”案例(如表3)，对低空无人机具身导航应用趋势进行了预测。归纳起来，未来低空无人机具身导航的理论技术发展趋势如下：

1)将致力于整合规模更大、类型更加多样化的多模态融合数据集，以提升导航系统在多变环境中的泛化能力，增强其跨场景适应性；

2)现有具身导航框架将不断迭代升级，以应对更为复杂的导航任务和动态环境，其中大模型技术在低空无人机具身导航中的部署有望实现关键突破；

3)导航决策机制将持续优化采用，轻量化设计提高任务执行效率与智能体反应速度，从而增强系统的实时性和稳定性；

4)虚拟到现实的迁移能力将进一步增强，使得导航算法能够在现实世界中稳定运行，逐步摆脱对模拟环境的依赖，推动低空无人机具身导航系统真正走出实验室，迈向实际应用。

参 考 文 献

[1] 郭子恒，蔡晨晓. 基于改进深度强化学习的无人机自主导航方法[J]. 信息与控制，2023，52(6)：736-746+772.(GUO Ziheng, CAI Chenxiao. Autonomous navigation algorithm of UAV based on improved deep-reinforcement-learning [J]. Information and Control, 2023,52(6):736-746+772.)

[2] 赵春晖，刘安萌，吕洋，等. 无人机韧性自主定位技术综述[J]. 航空学报，2024，45(8)：028839.(ZHAO Chunhui, LIU Anmeng, LYU Yang, et al. A survey of resilient self-localization for UAV[J]. Acta Aeronautica et Astronautica Sinica, 2024, 45(8): 028839.)

[3] YE X Y, SONG F J, ZHANG Z Y, et al. A review of small UAV navigation system based on multisource sensor fusion [J]. IEEE Sensors Journal, 2023, 23(17): 18926-18948.

[4] LIU Y H, LIU L, ZHENG Y W, et al. Embodied navigation[J]. Science China Information Sciences, 2025,

中国知网 https://www.cnki.net

68(4): 141101.

[5] LIN J Z, GAO H, FENG X X, et al. Advances in embodied navigation using large language models: A survey [EB/OL]. 2024 [2025]. https://arxiv. org/abs/2311. 00530.

[6] 孙长银, 袁心, 王远大, 等. 具身智能自主无人系统技术[J]. 自动化学报, 2025, 51(4): 762-777. (SUN Changyin, YUAN Xin, WANG Yuanda, et al. Embodied intelligence autonomous unmanned systems technology [J]. Acta Automatica Sinica, 2025, 51 (4): 762-777.)

[7] SAPKOTA R, CAO Y, ROUMELIOTIS K I, et al. Vision-language-action models: Concepts, progress, applications and challenges [EB/OL]. 2025 [2025]. http://arxiv. org/abs/2505. 04769.

[8] GAGEIK N, BENZ P, MONTENEGRO S. Obstacle detection and collision avoidance for a UAV with complementary low-cost sensors [J]. IEEE Access, 2015, 3: 599-609.

[9] KARLSSON R, SCHON T B, TORNQVIST D, et al. Utilizing model structure for efficient simultaneous localization and mapping for a UAV application [C]//IEEE Aerospace Conference, Big Sky, MT, USA, March 1-8, 2008.

[10] SKRZYPCZYŃSKI P. Machine learning for embodied agents: From signals to symbols and actions [C]// 2019 Signal Processing: Algorithms, Architectures, Arrangements, and Applications (SPA), Poznan, Poland, September 18-20, 2019.

[11] 白辰甲, 许华哲, 李学龙. 大模型驱动的具身智能: 发展与挑战[J]. 中国科学:信息科学, 2024, 54(9): 2035-2082. (BAI Chenjia, XU Huazhe, LI Xuelong. Embodied-AI with large models: Research and challenges [J]. Scientia Sinica Informationis, 2024, 54 (9): 2035-2082.)

[12] TOŽIČKA J, SZULYOVSZKY B, CHAMBRIER G D, et al. Application of deep reinforcement learning to UAV fleet control [C]//Intelligent Systems and Applications: Proceedings of the 2018 Intelligent Systems Conference (IntelliSys), London, UK, September 6-7, 2018.

[13] ANDERSON P, WU Q, TENEY D, et al. Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments [C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Salt Lake City, UT, USA, June 18-23, 2018.

[14] KU A, ANDERSON P, PATEL R, et al. Room-across-room: Multilingual vision-and-language navigation with dense spatiotemporal grounding [EB/OL]. 2020 [2025]. https://arxiv. org/abs/2010. 07954v1.

[15] QI Y K, WU Q, ANDERSON P, et al. Reverie: remote embodied visual referring expression in real indoor environments [C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, USA, June 13-19, 2020.

[16] WANG H C, CHEN A G H, LI X Q, et al. Find what you want: learning demand-conditioned object attribute space for demand-driven navigation [C]// 37th Conference on Neural Information Processing Systems (NeurIPS 2023), Pittsburgh, PA, USA, December 10, 2023.

[17] GAO X F, GAO Q Z, GONG R, et al. Dialfred: dialogue-enabled agents for embodied instruction following [J]. IEEE Robotics and Automation Letters, 2022, 7(4): 10049-10056.

[18] KRANTZ J, WIJMANS E, MAJUMDAR A, et al. Beyond the Nav-Graph: Vision-and-language navigation in continuous environments [C]// Computer Vision-ECCV 2020: 16th European Conference, Glasgow, UK, August 23-28, 2020.

[19] LIU S B, ZHANG H S, QI Y K, et al. AerialVLN: Vision-and-language navigation for UAVs [C]// 2023 IEEE/CVF International Conference on Computer Vision (ICCV), Paris, France, October 2-6, 2023.

[20] WANG X Y, YANG D L, WANG Z Q, et al. Towards realistic UAV vision-language navigation: Platform, benchmark, and methodology [EB/OL]. 2024 [2025]. http://arxiv. org/abs/2410. 07087.

[21] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: Vision-language-action models transfer web knowledge to robotic control [EB/OL]. 2023 [2025]. http://arxiv. org/abs/2307. 15818.

[22] KIM M J, PERTSCH K, KARAMCHETI S, et al. OpenVLA: An open-source vision-language-action model [EB/OL]. 2024 [2025]. http://arxiv. org/abs/2406. 09246.

[23] CHI C, Xu Z J, Feng S Y, et al. Diffusion policy: Visuomotor policy learning via action diffusion [C]// Robotics: Science and Systems, Daegu, Republic of Korea, July 10-14, 2023.

[24] TEAM O M, GHOSH D, WALKE H, et al. Octo: An open-source generalist robot policy [EB/OL]. 2024 [2025]. http://arxiv. org/abs/2405. 12213.

[25] MENDONCA R, BAHL S, PATHAK D. Structured world models from human videos [EB/OL]. 2023 [2025]. http://arxiv. org/abs/2308. 10901.

[26] WANG J H, HUO D J, XU Z H, et al. OpenBench: A new benchmark and baseline for semantic navigation in smart logistics [EB/OL]. 2025 [2025]. http://arxiv. org/abs/2502. 09238.

[27] GAO Y P, LI C H, YOU Z R, et al. OpenFly: A versatile toolchain and large-scale benchmark for aerial

中国知网 https://www.cnki.net

vision-language navigation [EB/OL]. 2025 [2025]. http://arxiv.org/abs/2502.18041.

[28] EFTEKHAR A, WEIHS L, HENDRIX R, et al. The one RING: a robotic indoor navigation generalist [EB/OL]. 2024[2025]. http://arxiv.org/abs/2412.14401.

[29] ZHANG L F, HAO X S, ZHANG Q W, et al. MapNav: a novel memory representation via annotated semantic maps for VLM-based vision-and-language navigation [EB/OL]. 2025 [2025]. http://arxiv.org/abs/2502.13451.

[30] LIU Y Z, YAO F L, YUE Y C, et al. NavAgent: multi-scale urban street view fusion for UAV embodied vision-and-language navigation [EB/OL]. 2024[2025]. http://arxiv.org/abs/2411.08579.

[31] ZHANG L F, LIU Y C, ZHANG Z G, et al. Mem2Ego: Empowering vision-language models with global-to-ego memory for long-horizon embodied navigation [EB/OL]. 2025[2025]. http://arxiv.org/abs/2502.14254.

[32] WANG H N, NI J Y, QI Y, et al. Optimal design of laser SLAM algorithm based on RBPF improved resampling technology [C]//IEEE International Conference on Mechatronics and Automation (ICMA), Beijing, China, October 13-16, 2020.

[33] KLEIN G, MURRAY D. Parallel tracking and mapping for small AR workspaces [C]//6th IEEE and ACM International Symposium on Mixed and Augmented Reality, Nara, Japan, November 13-16, 2007.

[34] YUAN S H, SHAFIQUE M, BAGHDADI M R, et al. Zero-shot object navigation with vision-language foundation models reasoning [C]//10th International Conference on Automation, Robotics and Applications (ICARA), Athens, Greece, February 22-24, 2024.

[35] ZHAO G L, LI G B, PAN J, et al. Aerial vision-and-language navigation with grid-based view selection and map construction [EB/OL]. 2025 [2025]. http://arxiv.org/abs/2503.11091.

[36] TOUVRON H, MARTIN L, STONE K, et al. Llama 2: open foundation and fine-tuned chat models [EB/OL]. 2023[2025]. http://arxiv.org/abs/2307.09288.

[37] OQUAB M, DARCET T, MOUTAKANNI T, et al. DINOv2: learning robust visual features without supervision [EB/OL]. 2024[2025]. http://arxiv.org/abs/2304.07193.

[38] ZHAI X H, MUSTAFA B, KOLESNIKOV A, et al. Sigmoid loss for language image pre-training [C]// IEEE/CVF International Conference on Computer Vision (ICCV), Paris, France, October 1-6, 2023.

[39] COLLABORATION O X E, O'NEILL A, REHMAN A, et al. Open X-embodiment: robotic learning datasets and RT-X models [C]//IEEE International Conference on Robotics and Automation (ICRA), Yokohama, Japan, May 13-17, 2024.

[40] SERPIVA V, LYKOV A, MYSHLYAEV A, et al. RaceVLA: VLA-based racing drone navigation with human-like behaviour [EB/OL]. 2025 [2025]. http://arxiv.org/abs/2503.02572.

[41] LYKOV A, SERPIVA V, KHAN M H, et al. Cognitive-Drone: A VLA model and evaluation benchmark for real-time cognitive task solving and reasoning in UAVs [EB/OL]. 2025[2025]. http://arxiv.org/abs/2503.01378.

[42] HUNG C Y, SUN Q, HONG P F, et al. NORA: A small open-sourced generalist vision language action model for embodied tasks [EB/OL]. 2025[2025]. http://arxiv.org/abs/2504.19854.

[43] SAUTENKOV O, YAQOOT Y, LYKOV A, et al. UAV-VLA: Vision-language-action system for large scale aerial mission generation [C]//20th ACM/IEEE International Conference on Human-Robot Interaction (HRI), Melbourne, Australia, March 4-6, 2025.

[44] LEE J, MIYANISHI T, KURITA S, et al. CityNav: Language-goal aerial navigation dataset with geographic information [EB/OL]. 2024 [2025]. http://arxiv.org/abs/2406.14240.

[45] XU W J, YAO Y X, CAO J Q, et al. UAV-VisLoc: A large-scale dataset for UAV visual localization [EB/OL]. 2024[2025]. http://arxiv.org/abs/2405.11936.

[46] ZHANG H C, ZANTOUT N, KACHANA P, et al. VLA-3D: A dataset for 3D semantic scene understanding and navigation [EB/OL]. 2024[2025]. http://arxiv.org/abs/2411.03540.

[47] ZHONG Y F, FENG C J, YAN F, et al. P3Nav: A unified framework for embodied navigation integrating perception, planning, and prediction [EB/OL]. 2025 [2025]. http://arxiv.org/abs/2503.18525.

[48] NIE D J, GUO X D, DUAN Y Q, et al. WMNav: Integrating vision-language models into world models for object goal navigation [EB/OL]. 2025 [2025]. http://arxiv.org/pdf/2503.02247.

[49] ZENG Q B, YANG Q L, DONG S N, et al. Perceive, reflect, and plan: designing LLM agent for goal-directed city navigation without instructions [EB/OL]. 2024 [2025]. http://arxiv.org/pdf/2408.04168.

[50] MAO P D, LV S L, QUAN Q. Tube RRT*: Efficient homotopic path planning for swarm robotics passing-through large-scale obstacle environments [J]. IEEE Robotics and Automation Letters, 2025, 10(3): 2247-2254.

[51] ZHOU X, WEN X Y, WANG Z P, et al. Swarm of micro flying robots in the wild [J]. Science Robotics, 2022, 7(66): eabm5954.

中国知网 https://www.cnki.net