分类号： TP391　　单位代码： 10431
密　级：　　学　　号： 10431210558

齊魯工業大學

硕士学位论文

（专业学位）

动态环境下机械臂碰撞检测与轨迹规划研究

作者姓名　赵鹏
领　　域　计算机技术
所在学部　数学与人工智能学部
指导教师姓名　王英龙
专业技术职务　研究员

2024 年 6 月 7 日

中国知网 https://www.cnki.net

A Thesis Submitted for the Application of
the Master's Degree of Engineering

Collision Detection and Trajectory Planning of Robotic Manipulator in Dynamic Environment

Candidate: ZhaoPeng

Specialty: Computer Technology

Supervisor: Yinglong Wang

Qilu University of Technology, Jinan, China

June, 2024

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 碰撞检测算法.....2
1.2.2 深度强化学习算法及其在机械臂控制中的应用.....4
1.3 研究内容.....6
1.4 论文结构.....7
第 2 章 相关技术理论.....9
2.1 机械臂建模与运动学分析.....9
2.1.1 刚体位姿描述.....9
2.1.2 正逆运动学分析.....10
2.2 图神经网络理论.....13
2.2.1 图卷积神经网络.....14
2.2.2 图注意力网络.....14
2.2.3 关系图神经网络.....15
2.3 深度强化学习理论.....16
2.3.1 强化学习简介.....16
2.3.2 基于价值函数的强化学习算法.....16
2.3.3 基于策略梯度的强化学习算法.....18
2.3.4 价值函数与策略梯度相结合的强化学习算法.....19
2.4 本章小结.....21
第 3 章 基于关系子图神经网络的碰撞检测方法.....22
3.1 研究动机.....22
3.2 模型介绍.....23
3.2.1 初始图构造模块.....23
3.2.2 关系图更新模块.....25
3.2.3 碰撞距离估计模块.....27
3.3 实验设置及结果分析.....28
3.3.1 数据集及实验设置.....28
3.3.2 基线模型.....30
3.3.3 评价指标.....30
3.3.4 性能比较.....31
3.3.5 消融实验.....34
3.4 本章小结.....36

中国知网 https://www.cnki.net

第 4 章 基于深度强化学习的机械臂动态避障轨迹规划框架.....37
4.1 研究动机.....37
4.2 框架介绍.....38
4.2.1 经验回放机制设计.....39
4.2.2 奖励函数设计.....42
4.2.3 状态空间与动作空间设计.....44
4.3 实验设置及结果分析.....44
4.3.1 参数及任务设置.....44
4.3.2 评价指标.....45
4.3.3 实验结果分析与讨论.....46
4.4 本章小结.....52
第 5 章 总结与展望.....53
5.1 本文总结.....53
5.2 研究展望.....54
参考文献.....55

中国知网 https://www.cnki.net

摘　要

随着机械臂应用场景逐渐向复杂化、动态化方向发展，对其控制算法的要求也在相应提升。在复杂动态环境中，机械臂轨迹规划任务需应对场景动态时变、不确定性强和状态维度高等多重挑战。因此，确保机械臂动态避障轨迹规划可行性的同时，兼顾算法的实时性、安全性和最优性，成为了当前研究的重难点。近年来，深度学习与深度强化学习的快速发展为解决这一问题提供了新思路。本文基于这两种技术，以进一步提高机械臂动态避障轨迹规划性能为目的，分别从碰撞检测和轨迹规划两个层面开展研究，具体工作归纳如下：

（1）针对动态环境下，现有碰撞检测方法精度不高、效率低及泛化能力弱的问题，本文提出了一种基于关系子图神经网络的碰撞检测方法。首先，该方法将机械臂和障碍物建模为图数据，以捕获二者的形状及相对位置信息。其次，不同于直接估计机械臂与障碍物整图之间全局碰撞距离的传统方法，该方法将机械臂和障碍物整图分割为若干子图对，估计这些子图对之间的碰撞距离，从中选取最小值作为全局碰撞距离，降低了碰撞距离函数的学习难度，同时也提高了碰撞检测方法的泛化能力。最后，在估计子图对的碰撞距离时，采用注意力机制将子图对构建为关系连通图，并通过关系图上的消息传递不断聚合图中的形状和相对位置信息，以精确回归碰撞距离。在不同环境中的实验结果表明，该方法在碰撞距离回归和碰撞分类任务上的表现均优于现有基于数据驱动的方法。且由于独特的子图设计，该方法无需重新训练，就能应用于由已知子图对组成的其他环境，具有一定的鲁棒性。

（2）针对动态环境下，现有基于深度强化学习的机械臂轨迹规划方法收敛速度慢、收敛性能差以及生成轨迹质量不佳的问题，本文提出了一种基于深度强化学习的机械臂动态避障轨迹规划框架，包括基于神经网络的专家引导三重经验回放机制以及一种改进奖励函数。其中回放机制结合模仿学习的数据快速拟合能力和深度强化学习的自优化特性，可以将少量人类专家演示及算法产生的成功经验扩增为大量质量不断优化的专家经验。通过神经网络动态调整成功、失败和专家经验在算法学习过程中的比例，能够有效整合专家经验与算法自身生成的经验，提高经验利用率。另外，改进奖励函数在人工势场法中的引力势场中加入了动态目标的速度信息，去除了动态障碍物的斥力势场作用范围，不仅能使机械臂末端执行器与动态目标运动趋势保持一致，也提高了机械臂对动态障碍物的感知能力。实验结果证明，所提出框架能显著加快算法的收敛速度，提高收敛性能及生成轨迹的质量。

关键词：机械臂；碰撞检测；轨迹规划；图神经网络；深度强化学习

中国知网　https://www.cnki.net

ABSTRACT

As the application scenarios for manipulators become more complex and dynamic, the requirements for their control algorithms increase accordingly. In complex dynamic environments, the task of manipulator trajectory planning has to cope with multiple challenges, such as dynamic time-varying scenes, strong uncertainty, and high state dimension. Therefore, ensuring the feasibility of dynamic obstacle avoidance trajectory planning for manipulators while taking into account the real-time, safety, and optimality of the algorithm has become a major challenge in the current research. In recent years, the rapid development of deep learning and deep reinforcement learning has provided new ideas to solve this problem. Based on these two techniques, this thesis aims to further improve the dynamic obstacle avoidance trajectory planning performance of the manipulator and carries out the research at the two levels of collision detection and trajectory planning, respectively. The specific work is summarized as follows:

(1) Aiming at the problems of low accuracy, low efficiency, and weak generalization ability of existing collision detection methods in dynamic environments, this thesis proposes a collision detection method based on relational subgraph neural networks. First, the method models the manipulator and the obstacle as graph data to capture the shape and relative position information of both. Second, unlike the traditional method that directly estimates the global collision distance between the manipulator and the obstacle whole graph, this method splits the manipulator and the obstacle whole graph into a number of subgraph pairs, estimates the collision distances between these subgraph pairs, and selects the minimum value as the global collision distance from them, which reduces the learning difficulty of the collision distance function and at the same time improves the generalization ability of the collision detection method. Finally, in estimating the collision distance of subgraph pairs, an attention mechanism is used to construct the subgraph pairs as a relational connectivity graph, and the shape and relative position information in the graph is continuously aggregated through message passing on the relational graph to accurately regress the collision distance. Experimental results in different environments show that the method outperforms existing data-driven-based methods on both collision distance regression and collision classification tasks. Moreover, the method can be applied to all other simulation environments in the experiment by only training in a single environment, showing a high degree of generalization.

中国知网 https://www.cnki.net

(2) Aiming at the existing deep reinforcement learning-based dynamic trajectory planning algorithms for manipulators with slow convergence speed, poor convergence performance, and poor quality of generated trajectories, this thesis proposes a deep reinforcement learning-based dynamic obstacle avoidance trajectory planning framework for manipulators, including a neural network-based expert-guided triple-memory and an improved reward function. Among them, the neural network-based expert-guided triple memory combines the fast data fitting ability of imitation learning with the self-optimization property of deep reinforcement learning, which can amplify a small number of human expert demonstrations and successful experiences generated by the algorithm into a large number of expert experiences with continuously optimized quality. By dynamically adjusting the proportion of success, failure, and expert experience in the algorithm learning process through the neural network, it can effectively integrate the expert experience with the experience generated by the algorithm itself and improve the experience utilization rate. In addition, the improved reward function adds the velocity information of the dynamic target to the attractive field in the artificial potential field method and removes the scope of action of the repulsive field of the dynamic obstacle, which not only makes the end-effector of the manipulator consistent with the motion trend of the dynamic target but also improves the ability of the manipulator to perceive the dynamic obstacle. The experimental results demonstrate that the proposed method can significantly speed up the convergence of the algorithm and improve the convergence performance and quality of the generated trajectories.

Keywords: Manipulator, Collision Detection, Trajectory Planning, Graph Neural Networks, Deep Reinforcement Learning

中国知网 https://www.cnki.net

第1章 绪论

1.1 研究背景与意义

机器人是集现代制造技术、新型材料技术和信息控制技术为一体的自动化装置，被誉为“制造业皇冠顶端的明珠”。近年来，机器人已成为高端装备，智能制造的核心工具，其研发、制造和应用也已成为衡量一个国家科技创新能力和制造业水平的重要标志[1]。

我国机器人产业发展迅速，据国家统计局数据显示，2023 年 1 至 6 月我国工业机器人累计产量为 22 万套，同比增长 5.4%。据《中国机器人技术与产业发展报告（2023 年）》，未来几年，我国工业机器人行业仍将保持高速发展态势。近年来，美国和欧洲一些国家提出了工业物联网以及第四次工业革命的概念，我国也提出了以智能制造为核心目标的“中国制造 2025”[2]，该战略的目标是实现制造智能化，实施制造强国。要实现制造智能化，则需要具体的工厂承担制造任务，即智能工厂。在智能工厂中，机械臂作为核心设备，其重要性正日益显著[3]。

机械臂最初被应用于传统行业，如汽车制造业，这些行业的生产环境和工业流程相对固定，且比较简单。所以机械臂主要依赖人工示教进行操作[4]。然而，这种方式效率十分低下，且每当生产任务或工作环境发生改变时，都需重新进行示教[5]。随着传统行业逐渐饱和，人们开始探寻将机械臂应用在更复杂环境中的可能性，如海洋开发、生物工程和电子信息技术等领域。与传统领域不同，这些领域的工作环境中往往存在大量动态障碍物。要将机械臂应用其中，最重要的一个子问题就是如何使机械臂自主避开动态障碍物，实时地在环境中规划出一条最优且安全的轨迹，以确保机械臂能够顺利完成既定目标[6,7]。

为了解决这个问题，学者们提出了多种方法，如随机快速搜索树（RRT）[8-10]、概率路图法（PRM）[11-13]以及人工势场法（APF）[14-16]等。虽然这些方法也具备一定避障能力，但在面对动态障碍物时还是表现不佳。相对于静态环境，机械臂在动态环境中的避障轨迹规划任务仍面临以下挑战：

（1）在机械臂轨迹规划过程中，必须进行成百上千次的碰撞检测，以判断环境中是否发生碰撞。有些规划算法还需要获得机械臂和障碍物之间的最短距离（碰撞距离）。传统碰撞检测方法直接计算物体的复杂几何形状，非常耗时，且需要耗费大量计算资源。尽管研究人员尝试了多种优化方法，但碰撞检测在机械臂轨迹规划任务中仍占据了大量时间，有时甚至会达到总时间的 90%[17-20]。为了解决这个问题，有学者提出了基于数据驱动的碰撞检测方法，即通过收集足够多的环境数据，

中国知网 https://www.cnki.net

使用机器学习模型预测环境中是否发生碰撞。这类方法能够极大减少碰撞检测所需时间及计算量，提高轨迹规划算法的效率。但同时这种方法也丢失了大量机械臂和障碍物的形状信息，导致模型检测精度较低。另外，现有方法对环境中的微小变化非常“敏感”，如在环境中新增一些障碍物，或障碍物位置发生变化，大多数算法都需要重新收集数据并再次训练模型。

（2）在面对动态环境时，由于环境在不断变化，所以机械臂缺乏环境的精确模型以及相应的先验知识，而传统轨迹规划方法的参数又都是基于特定环境模型建立的，这就导致很难将其应用在动态环境中。为了解决这个问题，有学者考虑使用深度强化学习（Deep Reinforcement Learning，DRL）来控制机械臂[21]。深度强化学习结合了深度学习的强大感知能力和强化学习的高效决策能力，能使机械臂通过与环境的实时交互，自主探索并发现最优或近最优的行为策略。相对于传统的机械臂控制方法，基于深度强化学习的方法有很强的泛化能力以及鲁棒性[22]。然而，这种控制方法也存在一些问题[23]。在面对机械臂轨迹规划这种复杂任务时，算法需控制机械臂从零开始通过大量试错学习，这会使算法收敛速度变慢，甚至难以收敛[24-26]。另外，不合适的奖励函数也会使机械臂陷入大量无效探索中，加剧这种情况的发生[27,28]。

本文着眼于以上问题，一方面，对机械臂的碰撞检测模型做出改进，以提高碰撞距离回归精度和碰撞检测准确度。另一方面，对控制机械臂的深度强化学习算法进行改进，以提高算法收敛速度及性能。对机械臂动态避障轨迹规划的研究是进一步推动智能机械臂发展的重要一环，具有一定的科学意义和工程价值。

1.2 国内外研究现状

1.2.1 碰撞检测算法

碰撞检测（Collision Detection）是计算机图形学、机器人学和 CAD 领域中的重要研究内容[29]。在机械臂轨迹规划中，碰撞检测需实时监控机械臂各部分与工作环境中障碍物之间的空间位置关系，以确保机械臂能够及时识别并避开潜在的碰撞风险。快速准确的碰撞检测对于机械臂的安全性和效率至关重要。特别是在动态非结构化环境中，不仅要求碰撞检测算法具备高度的准确性，还要求其能实时响应环境的变化。

碰撞检测算法可分为两大类，其中一类是基于计算几何的方法。Gilbert–Johnson–Keerthi 算法[30]是该领域中的经典算法，由 Gilbert、Johnson 和 Keerthi 在 1988 年共同开发。GJK 算法的输入是两个凸体的顶点集，通过闵可夫斯基差和有限次迭代过程计算这两个凸集之间的最短距离，以判断是否发生碰撞。为了减少碰撞检测算法的计算量，有学者提出了层次包围盒法（Bounding Volume Hierarchies，

中国知网 https://www.cnki.net

BVHs）。BVHs 利用简单规则的几何体包围形状复杂的物体，近似代表复杂物体的实际几何特征，并基于此设计碰撞检测算法。Hubbard 等人[31]提出了一种利用球体层次结构包围物体的高效碰撞检测算法，这种算法即使在物体几何复杂度增加的情况下也能严格控制计算时间，提高了碰撞检测的效率，但这种方法同时也降低了算法的准确度。Klosowdki 等人[32]基于离散有向多面体，提出了一种适用于高度复杂环境中运动物体的碰撞检测方法。为了加速 BVHs 的构建和查询，Lauterbach 等人[33]提出一种使用多核 GPU 快速构建 BVHs 的方法，Zellmann 等人[34]基于三角形网格表面光线追踪，提出了一种以线性时间复杂度构建 BVHs 的方法。

另一类是基于数据驱动的碰撞检测方法。在这种方法中，一些方法基于分类模型。Pan 等人[35]使用增量式支持向量机表示一对物体在构型空间中的精确碰撞边界，并使用主动学习策略迭代地改进边界。次年，Pan 等人[36]又提出了一种在高维构型空间中执行快速碰撞检测的方法。这种方法首先保存之前碰撞查询的结果，在查询新样本时，利用 K 最近邻（k-Nearest Neighbor，K-NN）找到与新构型最接近的先前查询样本，根据先前查询样本的碰撞检测结果估计新样本发生碰撞的概率。该方法还使用局部敏感哈希加速 K-NN 查询。Huh 等人[37]提出了一种基于 RRT 的高维构型空间快速碰撞检测方法，该方法基于使用增量期望最大化聚类算法学习的高斯混合模型，并且该方法能随 RRT 规划算法的进行不断改进。另外还有一些基于构型空间建模的方法。Zhi 等人[38]提出了一个完全自动可微的碰撞检测方法 DiffCo，DiffCo 使用正向运动学核感知器对机械臂的碰撞和无碰撞构型空间进行建模，通过对其碰撞分数函数进行微分生成碰撞梯度，从而避免碰撞。

最后，还有一些基于回归模型的方法。Das 等人[39]使用高斯过程（Gaussian process，GP）回归和正向运动学（FK）核估计机械臂和周围障碍物的最小碰撞距离。Kew 等人[40]提出了一个基于神经网络的碰撞检测方法 ClearanceNet，ClearanceNet 通过机械臂和周围障碍物的构型来预测碰撞距离，虽然极大地提升了碰撞检测的速度，但精度较低。为了保留机械臂和障碍物的形状信息，Cao 等人[41]提出了一种基于 Transformer 的碰撞检测模型 DistFormer，该模型首先将机械臂和障碍物建模为边界序列，利用基于自注意力机制的编码器将点信息聚合为边信息。其次使用交叉注意力机制融合机械臂和障碍物的特征序列，最后使用自注意力机制将融合了障碍物位置信息的机械臂序列转换为碰撞距离。Kim 等人[74]提出了一种基于图神经网络的碰撞距离估计模型 GraphDistNet，该模型将机械臂和障碍物建模为同构整图，利用基于边特征的卷积运算精确编码机械臂和障碍物几何图形之间的结构信息，极大地提高了模型碰撞检测的精度，但其泛化能力较弱，且仅在 2D 环境中进行了评估。

虽然这些基于数据驱动的碰撞检测方法极大地提高了碰撞检测的效率，但也存在着一些缺点，如准确性不佳，泛化能力差等。

中国知网 https://www.cnki.net

1.2.2 深度强化学习算法及其在机械臂控制中的应用

（一）深度强化学习算法

强化学习（Reinforcement Learning，RL）是机器学习的一个重要分支，自 20 世纪 80 年代以来，强化学习就已经在机器人控制、自动驾驶和组合优化等多个领域得到了广泛应用[42]。深度强化学习作为一个新兴领域，结合了深度学习的感知能力和强化学习的决策能力，大大提高了智能体处理复杂环境的能力。目前，深度强化学习正处于快速发展阶段。

DeepMind 团队于 2013 年提出了深度 Q 网络（DQN）[43,44]，DQN 首次结合了深度学习和强化学习，使用神经网络逼近 Q-learning 算法的值函数。实验证明，DQN 在多个游戏中的表现均优于人类，验证了 DQN 算法的有效性和实用性，这也标志着深度强化学习的正式诞生。为了解决 Q 值“过估计”的问题，DeepMind 团队在 Double Q-learning 算法的基础上结合了 DQN 的思想，于 2015 年提出了 Double DQN 算法[45]。Double DQN 的关键改进在于使用两个估计 Q 值的神经网络，在更新 Q 值时，两个神经网络相互制约。通过这种方法，Double DQN 减少了对动作价值的过高估计，从而提高了学习过程的稳定性和可靠性。随后，该团队针对 DQN 算法收敛速度慢的问题，提出了 Dueling DQN 算法[46]，Dueling DQN 的输入与 DQN 算法的输入一致，但其将输出分解为两部分：值函数和优势函数，这种分解加快了 Dueling DQN 的收敛速度。

在标准经验回放中，每一步的经验都会被算法以相同的概率选取进行学习，这会忽视其中重要经验的作用。为解决这个问题，2016 年，DeepMind 团队提出了优先经验回放(Prioritized Experience Replay，PER)[47]，PER 使用 TD 误差来衡量经验的重要性，优先学习具有高 TD 误差的经验，从而提高了算法的收敛速度。

传统的基于价值的方法（如 DQN 及其变种）在离散动作空间中表现良好，但它们不适合连续动作空间。为解决这个问题，DeepMind 团队基于确定性策略梯度理论，提出了深度确定性策略梯度算法（Deep Deterministic Policy Gradient，DDPG）[48]，DDPG 算法采用的是 Actor-Critic 框架，Actor-Critic 框架是一种既基于值又基于策略的方法。在 Actor-Critic 框架中，Actor 负责选择动作，而 Critic 则负责评估这些动作，接着 Actor 通过 Critic 的评估结果来改进自己。2016 年 Mnih 等人[49]提出了异步更新机制和多代理学习框架（Asynchronous Advantage Actor-Critic，A3C），通过并行处理加速了学习过程。jinglian 等人[50]通过将回报分布函数嵌入最大熵 DL 中，提出一种分布式软策略迭代框架 DSAC，DSAC 通过将状态-行动回报的方差保持在合理范围内来直接学习连续回报分布，从而解决了梯度爆炸和梯度消失问题。近端策略优化算法（Proximal Policy Optimization，PPO）。PPO 引入了 clip 函数，该函数将策略更新限制在一定范围内，防止了过大的策略变动，从而保证了算

中国知网 https://www.cnki.net

法稳定的收敛。2022 年，Xuanhua 等人[51]提出了一种约束 SAC 算法 Cconstrained Soft Actor-Critic，CSAC），CSAC 将拉格朗日原始对偶优化引入到了 SAC 框架中。仿真结果表明，CSAC 能够学习一种自适应策略，这种策略能够针对不同的设备位置输出最优轨迹。此外，为了解决多智能体之间的交互和协作问题，一些多智能体深度强化学习方法被提出，例如 QMIX[52]、MADDPG[53]、MAPPO[54]、COMA[55]等算法。

目前，在处理具有连续动作空间的问题时，DDPG、PPO、SAC 和 A3C 算法均展现出了卓越的性能。这些方法各有其独特的优势，因此在实际应用场景中选择哪一种深度强化学习方法，需要根据具体的任务环境和需求来决定。

（二）基于深度强化学习的机械臂控制算法

近年来，深度强化学习在机械臂控制领域中的应用正逐渐成为研究新热点[56]。这种方法模仿人类学习使用手臂的过程，不依赖传统的示教或复杂的算法，而是通过与环境的不断交互和试错来逐渐学习操作技能。基于 DRL 的机械臂控制方法展现出了良好的泛化能力、鲁棒性和自适应性。尽管机械臂状态动作空间连续性和高维性的特点使它比其他 DRL 应用更具挑战，但结合了深度学习感知能力和强化学习决策能力的 DRL 依然被证明是机械臂智能化的有效途径。

Gu 等人[57]为解决传统深度 Q 学习方法在处理连续动作空间问题时的局限性，优化了传统 DQN 网络的输出，提出了一种适用于连续动作空间的 Q-learning 算法：（Normalized Adantage Functions，NAF），这种方法扩展了 DQN 的应用范围，使其可以应用于机械臂的控制任务中。Mahmood 等人[58]使用深度确定性策略梯度、信赖域策略优化、软 Q 学习和近端策略优化四种算法实现了 6-DoF 机械臂的运动控制。在实验中，这些算法分别被用来控制机械臂的两个、六个关节。研究结果显示，机械臂的控制关节数越少，深度强化学习算法的效果越佳；反之，随着关节数的增加，学习有效策略的难度也随之增加。Lim 等人[59]提出了一种使用稀疏高斯过程预测未知奖励函数的方法，该方法使用具有不同奖励函数的 DRL 生成的轨迹-奖励对训练模型，能够准确地从极少人类专家演示数据中推断出奖励函数。Qi 等人[60]提出了一种改进的深度确定性策略梯度算法，首先，针对传统 DDPG 奖励函数的不足，设计了一种复合奖励函数，其次，针对机械臂采样效率低的问题，向经验回放池中添加了一批教学数据以提高学习效率。最后，他们将改进后的 DDPG 算法应用在机械臂的抓取任务上，抓取准确率得到了显著的提高。Li 等人[61]基于最大熵框架和 Tsallis 熵，提出了一种带有自动熵调整的 DRL 算法，使机械臂能够应对多样化任务。并且，他们还提出了一种结合传统路径规划方法和 DRL 的改进路径规划方法，提高了规划性能。Ma 等人[62]为解决随机且不必要探索导致的收敛速度慢的问题，提出了一个使用少量演示数据指导探索的新框架。其中，他们使用神经网络将演示数据建模为方向偏好与目标状态距离之间的函数。Ying 等人[63]提出

中国知网 https://www.cnki.net

了一种双经验回放池结构策略，利用成功经验和无偏数据采样提高了早期训练效果。同时，他们还开发了一种模糊反馈奖励机制，建立了从状态变量到奖励的直接映射。

总的来说，虽然深度强化学习在机械臂控制方面取得了一定进展，但也存在一些问题，如算法训练效率差、奖励函数设计困难等，还有很大的发展潜力。

1.3 研究内容

本文针对机械臂的动态避障轨迹规划问题进行研究，主要涉及碰撞检测和轨迹规划两大关键任务。目前，这两项任务均存在一定问题。首先，现有基于数据驱动的碰撞检测方法检测精度较低，且每当环境发生变动（增加、减少或移动障碍物）时，都必须重新训练碰撞检测模型，泛化性较差；其次，现有基于深度强化学习的机械臂控制方法训练速度慢、经验利用率低，且缺少适合动态环境的奖励函数。因此，本文主要围绕碰撞检测和轨迹规划两个层面开展研究工作。

（1）提出了一种基于关系子图神经网络的碰撞检测方法（Relation Subgraph Neural Network，RSGNet）。首先，针对现有方法未能充分利用机械臂和障碍物的形状信息，导致模型碰撞检测精度低的问题，该方法将机械臂和障碍物建模为图数据，以保存二者的拓扑信息。其次，针对直接估计机械臂和障碍物图全局碰撞距离，导致模型学习难度高、泛化性差的问题，该方法将机械臂和障碍物图分割为若干子图对，估计这些子图对之间的碰撞距离，再选择其中的最小值作为全局碰撞距离。最后，在估计子图对之间的碰撞距离时，RSGNet 使用注意力机制将子图对构建为关系连通图，通过图中边和节点间的消息传递不断聚合机械臂与障碍物子图的形状信息以及相对位置信息。在经过多层消息传递后，RSGNet 提取分层输出图的注意力加权特征输入 Readout 层，以回归子图对间的碰撞距离。在不同仿真环境中的实验结果表明，RSGNet 模型在碰撞检测准确性和碰撞距离回归误差上的表现均优于基线模型。并且，RSGNet 仅需在一种环境中进行训练，便可适用于实验中的其他所有仿真环境，显示出了高度的泛化能力。

（2）提出了一种基于深度强化学习的机械臂动态避障轨迹规划框架，其中包括基于神经网络的专家引导三重经验回放机制（Neural network-based Expert-guided Triple-Memory，NETM）以及一种改进奖励函数（Improved Artificial Potential-field Reward，IAPR）。首先，针对专家经验获取难度大的问题，NETM 使用生成对抗模仿学习（Generative Adversarial Imitation Learning，GAIL），将少量人类演示及算法训练中产生的成功经验扩增为大量专家经验。得益于深度强化学习的策略优化能力，扩增得到的专家经验数据的质量也能随训练进程不断提高。其次，针对算法经验利用率较低的问题，NETM 中的经验采样策略将算法产生的经验分为成功

中国知网 https://www.cnki.net

经验和失败经验，通过神经网络动态调整成功、失败和专家经验在算法学习过程中的比例，有效整合了专家经验与算法自身生成的经验，提高了经验利用率。另外，针对现有基于人工势场法思想设计的奖励函数对动态障碍物感知能力弱的问题，IAPR 取消了动态障碍物的斥力作用范围，赋予了机械臂对障碍物的全局感知能力。并且，IAPR 还在引力势场中加入了末端执行器和动态目标的速度约束，以确保末端执行器的运动趋势与动态目标保持一致。在轨迹规划仿真环境中的实验表明，所提出的框架能够加快算法的收敛速度，提高收敛后的性能及生成轨迹的质量。

1.4 论文结构

本文主要包括五个章节，章节结构如图 1.1 所示。

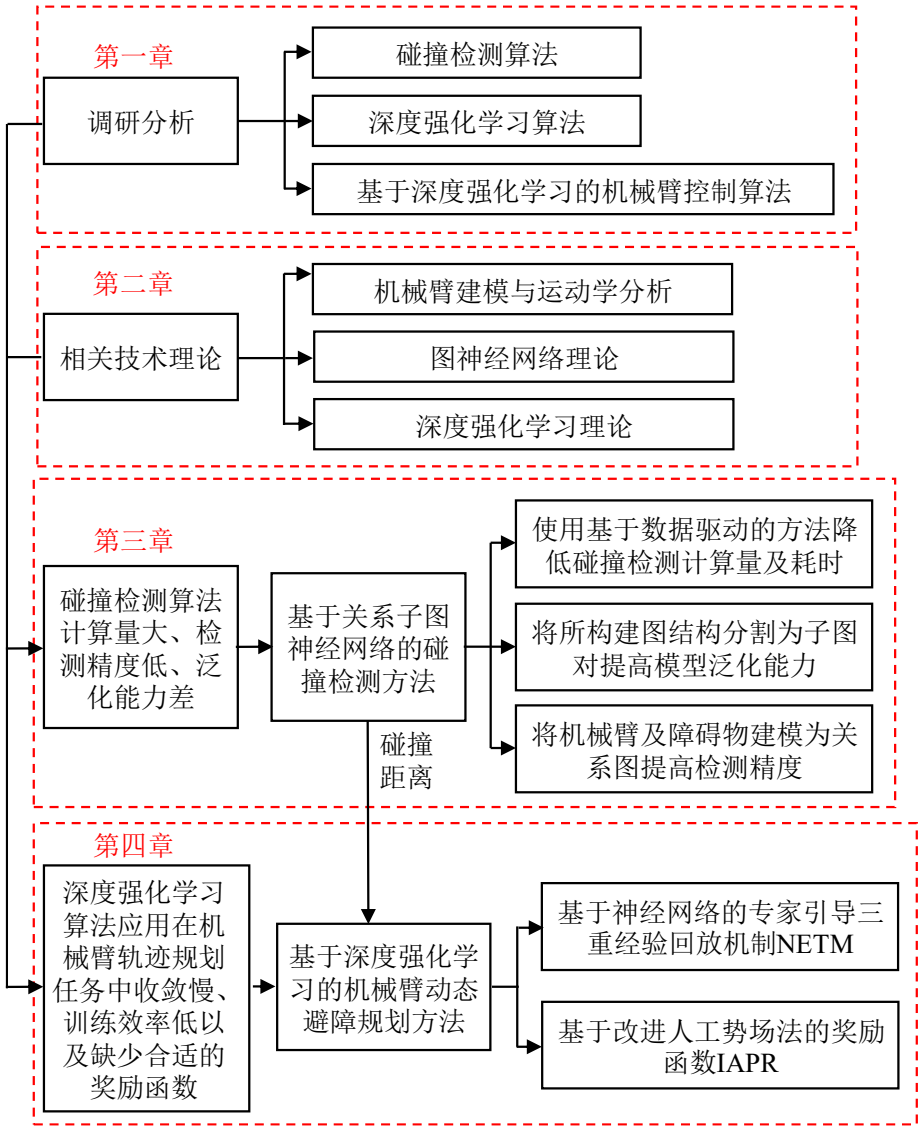


图 1.1 章节结构图

中国知网 https://www.cnki.net

第一章首先介绍了课题研究背景与意义，其次调研了碰撞检测方法、深度强化学习方法以及基于深度强化学习的机械臂控制方法的研究现状，并分析了相关技术的优缺点。最后阐述了本文的主要工作和贡献，给出了本文的组织结构。

第二章首先对机械臂运动学进行了分析，包括物体位姿描述以及正逆运动学求解，其次介绍了几种常见的图神经网络模型，最后对深度强化学习的原理进行了介绍。

第三章提出了一种基于关系子图神经网络的碰撞检测方法。首先介绍了该方法的研究动机，展示了模型的总体架构图。其次进一步详细介绍了初始图构造模块、关系图更新模块以及碰撞距离估计模块的具体细节。最后通过大量实验分析展现了模型的优越性。

第四章提出了一种基于深度强化学习的机械臂动态避障轨迹规划框架。首先介绍了基于神经网络的专家引导三重经验回放机制的研究动机及框架详情，其次提出了一种适用于动态环境的改进奖励函数，最后在实验中对所提出方法进行了验证。

第五章对本文主要工作及贡献进行了陈述，并根据本文研究存在的不足之处对未来研究计划做出了展望。

中国知网 https://www.cnki.net

第2章 相关技术理论

本章将介绍机械臂碰撞检测和轨迹规划任务所涉及的相关技术理论，包括机械臂建模与运动学分析、图神经网络经典模型及深度强化学习基本理论。

2.1 机械臂建模与运动学分析

2.1.1 刚体位姿描述

为了描述三维空间中任意点p的位置，首先需建立一个空间直角坐标系$\{A\}$作为基准坐标系。如图 2.1 所示，$\{A\}$由三个相互垂直的轴X_A、Y_A和Z_A组成。

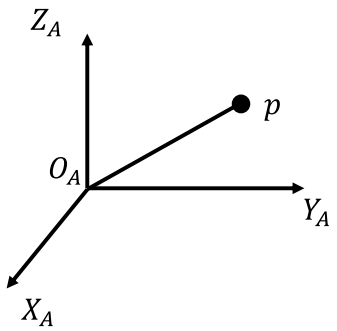


图 2.1 位置矢量的表示方法

点p相对于坐标系$\{A\}$的位置可以用一个三维位置矢量表示：

$$^{A}p = \begin{bmatrix} p_x \\ p_y \\ p_z \end{bmatrix} = [p_x \quad p_y \quad p_z]^T \tag{2.1}$$

式中p_x，p_y，p_z为点p在坐标系$\{A\}$三个坐标轴上的投影。

在空间直角坐标系$\{A\}$中，若要描述刚体B的姿态，如图 2.2 所示，可以在刚体B上某点建立一个附着于刚体的空间直角坐标系$\{B\}$。

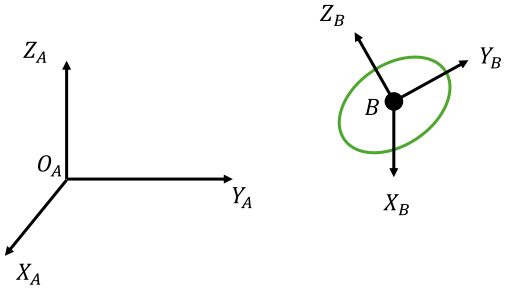


图 2.2 物体姿态的表示方法

中国知网 https://www.cnki.net

坐标系$\{B\}$的原点通常在刚体B的质心上，当刚体姿态发生变化时，坐标系$\{B\}$也随之改变。可以用平行于直角坐标系$\{B\}$三个轴的单位向量${}^{A}x_B$，${}^{A}y_B$，${}^{A}z_B$来描述刚体B在坐标系$\{A\}$中的姿态：

$$\begin{cases} {}^{A}x_B = r_{11}i + r_{21}j + r_{31}k \\ {}^{A}y_B = r_{12}i + r_{22}j + r_{32}k \\ {}^{A}z_B = r_{13}i + r_{23}j + r_{33}k \end{cases} \tag{2.2}$$

用矩阵表示上式，可得出描述刚体姿态的旋转矩阵：

$${}^{A}_{B}R = [\,{}^{A}x_B \quad {}^{A}y_B \quad {}^{A}z_B] = \begin{bmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{bmatrix} \tag{2.3}$$

式中${}^{A}_{B}R$是刚体B相对于坐标系$\{A\}$的旋转矩阵，又因为${}^{A}x_B$，${}^{A}y_B$，${}^{A}z_B$两两正交，所以${}^{A}_{B}R$是单位正交矩阵，虽然${}^{A}_{B}R$中有 9 个数字，但矩阵中隐含有六个条件，故${}^{A}_{B}R$中只有三个数字独立。

刚体B的位姿，即为刚体B相对于坐标系$\{A\}$的位置和姿态的组合。刚体的姿态可由旋转矩阵${}^{A}_{B}R$表示，刚体的位置可由坐标系$\{B\}$的原点相对于坐标系$\{A\}$的位置矢量${}^{A}_{B}p$表示，所以刚体的位姿可以被描述为：

$$\{B\} = \{{}^{A}_{B}R \quad {}^{A}_{B}p\} \tag{2.4}$$

为了便于运算，通常用齐次变换矩阵来表示刚体的位姿：

$${}^{A}_{B}T = \begin{bmatrix} {}^{A}_{B}R & {}^{A}_{B}p \\ 0 & 1 \end{bmatrix} \tag{2.5}$$

2.1.2 正逆运动学分析

在机械臂建模过程中，为了唯一确定机械臂各连杆和末端执行器在空间中的位置和姿态信息，首先会选定一个合适的位置建立空间直角坐标系，然后再定义各连杆以及末端执行器上的关节坐标系，通过描述这些坐标系相对于基坐标系的位姿，来确定机械臂的关节模型。对于机械臂各连杆之间位置关系的描述，应用最广泛的是 D-H 法。

机械臂由若干个关节和连杆连接而成，假设第i个连杆为C_i，第i个关节轴线为J_i。如图 2.3 所示，可以找到唯一一条线段同时和J_i、J_{i-1}垂直，这条线段为J_{i-1}与J_i的公垂线。公垂线的长度a_{i-1}被称为连杆长度，表示第$\mathrm{i}-1$个连杆C_{i-1}的长度。J_i与由J_{i-1}和公垂线组成的平面的夹角记为连杆扭转角α_{i-1}，用于确定相邻关节之间的方向。

中国知网 https://www.cnki.net

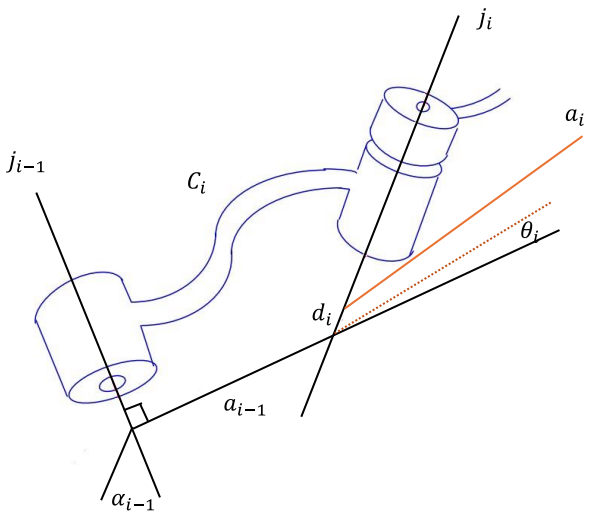


图 2.3 机械臂连杆图

同理，在机械臂中，相邻转轴J_{i+1}与J_i之间的关系可用a_i表示，a_{i-1}与a_i在J_i上的距离叫做连杆偏距，记为d_i，指相邻两个连杆在J_i上的距离。α_i与a_{i-1}在以J_i为法线的平面上投影的夹角叫做关节角度，记为θ_i。对于移动关节，只有d_i是变量，其余参数为常数，对于旋转关节则只有θ_i是变量。a_i、α_i、d_i和θ_i这四个参数可以用来描述机械臂全部连杆坐标系的转换关系。一般来说，机械臂的最后一杆带有执行器，机械臂的第 0 杆是一个固定连杆，二者的参数通常被设为 0。

如图 2.4 所示，通常按照以下规则定义各个关节坐标系：首先，将a_{i-1}与J_{i-1}的交点定义为坐标系$\{i-1\}$的原点，坐标系的 Z 轴Z_{i-1}与J_{i-1}重合，X 轴X_{i-1}与a_{i-1}在同一条直线上，方向由J_{i-1}轴指向J_i轴，最后按照右手定则确定 Y 轴Y_{i-1}。

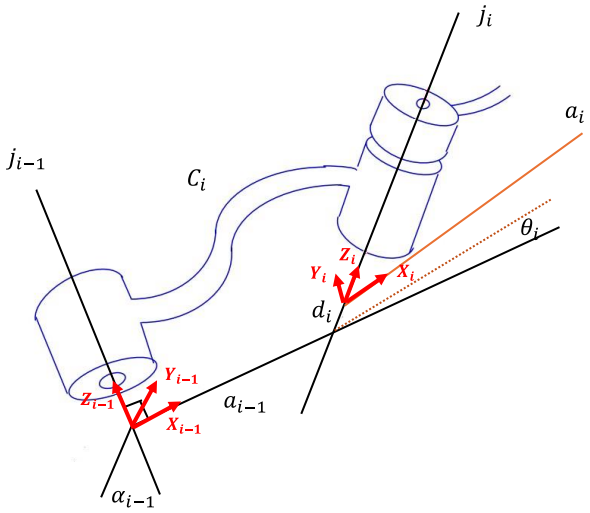


图 2.4 机械臂坐标系图

在建立了坐标系$\{i-1\}$与坐标系$\{i\}$之后，接下来便可求出这两个坐标系之间

中国知网 https://www.cnki.net

的关系，也就是二者之间的转移矩阵${}_{i}^{i-1}T$。

在 D-H 法中，两个相邻坐标系的变换通常通过两次平移和两次旋转进行。首先将坐标系$\{i-1\}$的 Z 轴Z_{i-1}转动a_{i-1}角度，使Z_{i-1}与Z_i同向；其次将坐标系$\{i-1\}$的原点沿X_{i-1}方向移动a_{i-1}距离；再次将坐标系$\{i-1\}$转动θ_i角度，使X_{i-1}与X_i同向；最后将坐标系$\{i-1\}$的原点沿Z_i的方向移动d_i，得到坐标系$\{i\}$。将上述步骤用矩阵表示可以得到坐标系$\{i-1\}$与坐标系$\{i\}$的转移矩阵：

$$ {}_{i}^{i-1}T = \begin{bmatrix} c\theta_i & -s\theta_i & 0 & a_{i-1} \\ s\theta_i c\alpha_{i-1} & c\theta_i c\alpha_{i-1} & -s\alpha_{i-1} & -s\alpha_{i-1}d_i \\ s\theta_i s\alpha_{i-1} & c\theta_i s\alpha_{i-1} & c\alpha_{i-1} & c\alpha_{i-1}d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{2.6} $$

其中，$c\theta_i = cos(\theta_i)$, $s\theta_i = sin(\theta_i)$, $s\alpha_i = sin(\alpha_{i-1})$, $c\alpha_{i-1} = cos(\alpha_{i-1})$。

通过${}_{i}^{i-1}T$，可以将坐标系$\{i\}$中的位置转移到坐标系$\{i-1\}$中的相对位置上：

$$ {}^{i-1}P = {}_{i}^{i-1}T\ {}^{i}P \tag{2.7} $$

对于一个高自由度机械臂，正运动学求解是指计算其末端执行器位姿的过程，这个过程依赖于机械臂各关节的角度，其求解步骤如下：

（1）确定机械臂的 D-H 参数：连杆长度a_i，连杆扭转角α_i，连杆偏距d_i，关节角度θ_i。其中，关节角度θ_i通常依赖于机械臂的传感器数据，或由控制器计算得出。

（2）计算齐次变换矩阵：基于 D-H 参数，计算每个关节坐标系的齐次变换矩阵，连杆i相对于连杆$i-1$的变换矩阵为${}_{i}^{i-1}T$。

（3）连乘齐次变换矩阵：将所有齐次变换矩阵相乘，便可得到一个总的齐次变换矩阵，它描述了从机械臂的基座到末端执行器的整体变换：

$$ {}_{7}^{0}T = {}_{1}^{0}T\,{}_{2}^{1}T\,{}_{3}^{2}T\,{}_{4}^{3}T\,{}_{5}^{4}T\,{}_{6}^{5}T\,{}_{7}^{6}T \tag{2.8} $$

（4）提取末端执行器的位姿：

$$ {}_{7}^{0}T = \begin{bmatrix} n_x & o_x & a_x & p_x \\ n_y & o_y & a_y & p_y \\ n_z & o_z & a_z & p_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{2.9} $$

式中$[n_x \quad n_y \quad n_z]$, $[o_x \quad o_y \quad o_z]$, $[a_x \quad a_y \quad a_z]$为机械臂末端执行器的姿态，$[p_x \quad p_y \quad p_z]$为机械臂末端执行器的位置。

（5）验证结果：通过仿真或实际操作机械臂，验证计算结果是否正确。

和正向运动学相反，逆运动学则是用于计算在给定末端执行器的目标位置和

中国知网 https://www.cnki.net

姿态时，机械臂各关节所需达到的角度$\{\theta_1, \theta_2, \theta_3, \ldots, \theta_n\}$。机械臂逆运动学求解一般包括如下步骤：

（1）确定机械臂的 D-H 参数：连杆长度a_i，连杆扭转角α_i，连杆偏距d_i。

（2）确定末端执行器的位置和姿态：根据任务需求确定末端执行器相对于基座的位置和姿态。

（3）计算关节变量：

$$\begin{bmatrix} n_x & o_x & a_x & p_x \\ n_y & o_y & a_y & p_y \\ n_z & o_z & a_z & p_z \\ 0 & 0 & 0 & 1 \end{bmatrix} = {}^{0}_{1}T\,{}^{1}_{2}T\,{}^{2}_{3}T\,{}^{3}_{4}T\,{}^{4}_{5}T\,{}^{5}_{6}T\,{}^{6}_{7}T \tag{2.10}$$

在计算关节角度时，通常使用转移矩阵的逆变换连续左乘上方矩阵来分离关节变量。然而在一些情况下，逆运动学是非线性的，因此不能直接求出解析解。这种情况下，需采用数值方法，如迭代法和数值优化法等方法求解。

（4）验证结果：通过仿真或实际操作机械臂，验证计算结果是否能使末端执行器达到期望位姿。

在进行逆解计算之前，必须确保机械臂末端执行器所需到达的目标位置坐标处于机械臂的工作空间中，否则将会使逆解计算无效。另外，机械臂通常具有多个自由度，因此一个目标位置可能对应多个解。其中某些解可能由于机械结构或关节限制无法实现。所以，在获得逆解之后，还需对它们进行筛选，以确保其能满足实际需求。机械臂的逆解流程如图 2.5 所示。

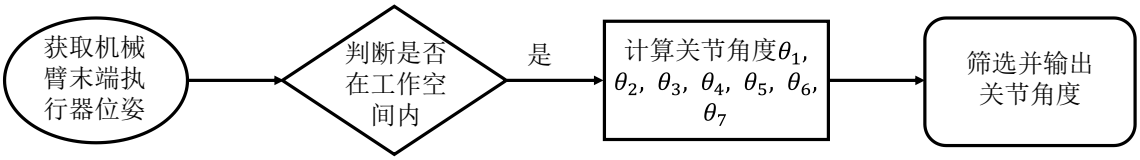


图 2.5 机械臂逆解流程图

2.2 图神经网络理论

图数据是一种用于表示各种关系和网络结构的数据形式，可以被用于描述许多现实世界中的问题，如社交网络、交通路线及化学分子结构等。图由节点（Vertex）和边（Edge）组成，其中节点代表实体或对象，而边表示节点之间的关系或连接。图神经网络（Graph Neural Networks，GNN）是一种针对图数据进行建模和学习的神经网络模型[64-65]。随着场景需求的变化，图神经网络出现了许多变体，如图卷积神经网络（Graph Convolutional Networks，GCN）[66]、图注意力网络（Graph Attention Network，GAT）[67]及关系图神经网络（Relational GCN，RGCN）[68]等。

中国知网 https://www.cnki.net

2.2.1 图卷积神经网络

图卷积神经网络是一种典型的 GNN 算法，它在图结构上执行卷积操作，以实现对图中节点特征的学习和表示。GCN 的核心思想是利用节点的邻域信息更新节点的表示。对于每个节点，GCN 将其自身特征与邻居节点的特征进行聚合，从而获得更新后的节点表示。Defferrard 等人将 GCN 的模型总结为：

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right) \tag{2.11}$$

式中$\tilde{A} = A + I$是邻接矩阵A加上自连接的结果，I是单位矩阵，确保每个节点都考虑到自身的节点特征，$\tilde{D}$是$\tilde{A}$的度矩阵，$W^{(l)}$是第l层的权重矩阵，σ是激活函数，通常采用 ReLU 激活函数，图 2.6 为 GCN 的结构示意图。图中X_i为节点i的输入特征向量，C为节点的输入特征维度，F为节点输出特征的维度，Z_i为节点i的输出特征向量，Y_i表示节点i的真实标签。

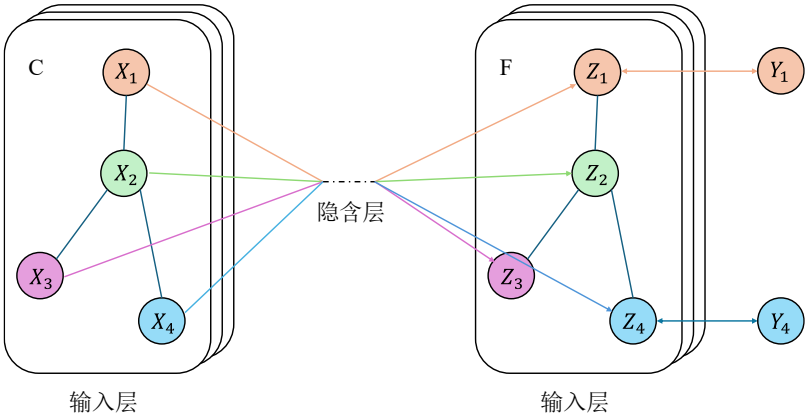


图 2.6 GCN 架构图

2.2.2 图注意力网络

图注意力网络是一种使用了注意力机制的图神经网络，其主要思想是对图中节点之间的关系赋予不同的权重，而不是像传统的 GCN 一样采用固定的权重参数。这种做法可以让网络更加灵活地学习到不同节点之间的重要性和相关性。具体而言，图注意力网络将每个节点的邻居节点视为待加权的源，利用注意力机制计算出不同节点之间的注意力系数，然后使用这些系数对邻居节点的特征进行加权求和，最后得到更新后的节点表示。图注意力网络的更新规则如下所示：

$$H_i^{(l+1)} = \sigma\left(\sum_{j\in N(i)} \alpha_{ij}W^{(l)}h_j^{(l)}\right) \tag{2.12}$$

式中σ为激活函数，$N(i)$为节点i的邻居节点集合，α_{ij}为节点i和节点j之间的注意力

中国知网 https://www.cnki.net

系数，可以通过注意力机制计算得出，$W^{(l)}$是学习得到的权重矩阵。

通过引入注意力系数α_{ij}，图注意力网络可以动态地调整节点之间的信息传播权重，从而更好地捕捉节点之间的关系。α_{ij}通过以下公式计算：

$$\alpha_{ij} = \frac{exp\left(LeakyRelu(a^T[Wh_i \parallel Wh_j])\right)}{\sum_{k\in N_i} exp(LeakyRelu(a^T[Wh_i \parallel Wh_k]))} \tag{2.13}$$

式中W是学习得到的权重矩阵，h_i和h_j分别为节点i和节点j的特征表示，$\parallel$表示向量的连接操作，a^T为学习得到的注意力参数向量。

2.2.3 关系图神经网络

当图中边的类型大于 2 时，该图就被称为关系图。在关系图中，不同边代表了节点之间不同类型的关系。关系图卷积网络就是为了处理关系图而设计的神经网络，它是对传统图卷积网络（GCN）的扩展，允许网络有效地处理图中的多种关系类型。图 2.7 为 RGCN 的结构示意图。

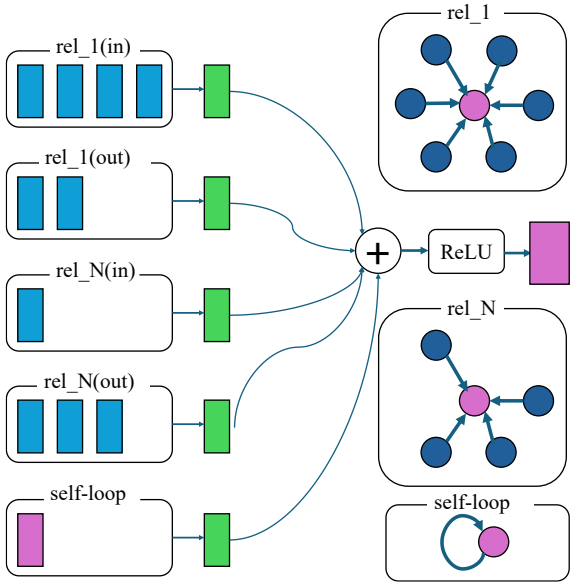


图 2.7 RGCN 架构图

RGCN 的核心思想是引入关系参数矩阵，以区分不同类型的边。传统的 GCN 在进行节点聚合时，对所有的邻居节点都使用了相同的权重，而 RGCN 则是为每种关系类型学习独立的参数，这能使 RGCN 可以更好地捕捉图中的多种关系。对于每个节点v_i，其更新规则如下：

$$h_i^{(l+1)} = \sigma\left(\sum_{r\in R}\sum_{j\in N^*(i)} \frac{1}{c_{i,r}} W_r^{(l)} h_j^{(l)} + W_0^{(l)} h_i^{(l)}\right) \tag{2.14}$$

中国知网 https://www.cnki.net

式中R是关系集合，每个关系r对应一个特定的参数矩阵$W_r^{(l)}$，$N^*(i)$ 为节点v_i在关系r下的邻居节点集合，$c_{i,r}$为归一化常数，$W_0^{(l)}$是自连接权重矩阵。

2.3 深度强化学习理论

2.3.1 强化学习简介

强化学习作为机器学习的一个重要分支，其学习方式不同于监督学习或无监督学习。在强化学习中，智能体（Agent）通过与环境（Environment）的交互学习最优行为策略。这种交互基于状态（State）、动作（Action）和奖励（Reward），目标是优化策略以最大化长期奖励。强化学习基本架构如图 2.8 所示。

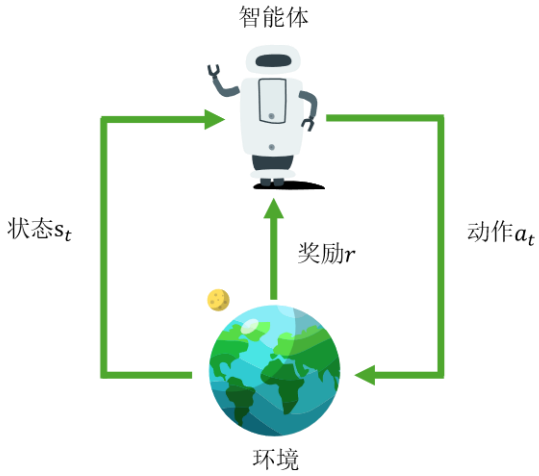


图 2.8 强化学习基本架构图

智能体是强化学习中的决策者，它通过学习来选择给定状态下的最佳动作；环境是智能体所处的外部世界，它为智能体提供当前的状态信息，并对智能体的动作做出响应；状态是智能体对环境当前情况的描述，在每个时间步中，智能体根据当前的状态选择动作；动作是智能体在某状态下可以选择的行为。智能体的目标是通过选择最佳动作来最大化长期奖励；奖励是环境对动作的反馈，它是衡量动作好坏的实时反馈；策略是从状态到动作的映射，它定义了智能体在特定状态下应该选择哪个动作。首先，智能体通过观察当前环境的状态，基于策略选择一个动作并执行。然后，环境对此动作做出反馈，提供新的状态和相应的奖励。最后，智能体利用奖励信息更新自己的策略，以期在未来的决策中做得更好。这个迭代过程持续进行，直到达到规定的时间步。

2.3.2 基于价值函数的强化学习算法

（深度）强化学习算法通常可以分为三大类：基于策略（Policy-Based）的算法、基于价值（Value-Based）的算法以及价值函数与策略梯度相结合（Actor-Critic）

中国知网 https://www.cnki.net

的算法，三种强化学习算法的关系如图 2.9 所示。

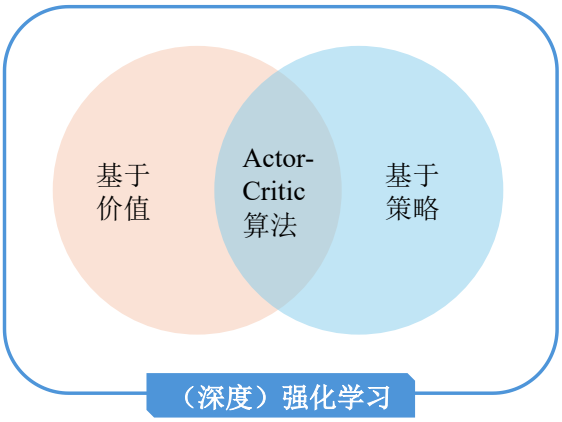


图 2.9 三种（深度）强化学习算法示意图

基于价值函数的强化学习算法如图 2.10 所示，它通过交替执行两个步骤来逐步改进策略：策略估计（Policy Evaluation）和策略改进（Policy Improvement）。

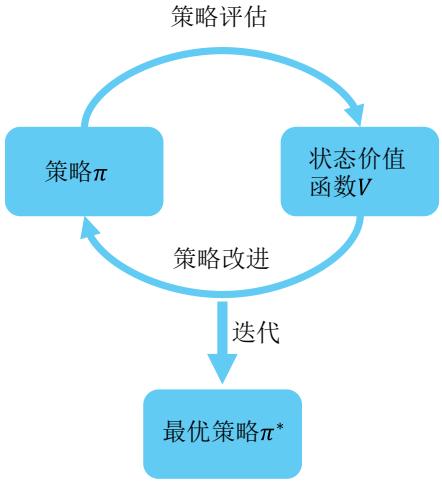


图 2.10 策略评估与策略改进

在策略估计中，算法估计给定策略π下，所有状态的价值函数$V^{\pi}(s)$。在策略改进中，算法基于所有状态的价值函数，贪心地改进策略。由于算法按价值函数贪心地更新策略，所以新的策略要强于当前策略，或和当前策略一样好。这两个步骤不断交替运行，每一次策略改进都是基于当前最新的价值函数估计，每一次价值函数估计都是基于当前最新的策略。通过循环迭代这两个过程，策略和价值函数都逐渐改进和逼近最优。最终，这个过程会收敛到最优策略π^*和最优价值函数V^*。

在基于价值函数的强化学习算法中，最重要的步骤是策略估计，根据策略估计方法的不同，强化学习衍生出了不同的基本方法：动态规划法、蒙特卡洛法以及时序差分法。动态规划是一种基于模型的方法，其适用于环境模型已知（即状态转移

中国知网 https://www.cnki.net

概率和奖励函数已知）的情况。在许多实际应用中，环境的状态转移概率是未知的或者太复杂，无法完全获得，所以很少被使用。

蒙特卡洛（Monte Carlo，MC）法和时序差分（Temporal Difference，TD）法都不依赖于环境的状态转移概率，属于无模型的强化学习算法。蒙特卡洛法的基本思路是，通过多次执行一个策略，产生多个 episode，每个 episode 都是从初始状态到终止状态的状态、动作、奖励序列，然后对于每个状态或状态动作对，计算它在所有回合中出现的平均奖励，作为其值函数的估计值。蒙特卡洛法只能用于回合制任务，并且其估计值的偏差会很大。

TD 算法结合了动态规划法的自举（Bootstrap）思想和蒙特卡洛法从经验中学习的特点，可以利用学到的估计值更新值函数，而不需要等一个完整的 episode 结束后再更新。以最基本的时序差分算法TD(0)为例，其首先计算 TD 误差：TD 误差 $= r_{t+1} + \gamma V(S_{t+1}) - V(S_t)$，式中$r_{t+1}$是算法在$t$时间步转移到$t+1$时间步时的奖励，$\gamma$是折扣因子，$V(S_{t+1})$是下一状态的价值估计，而$V(S_t)$是当前状态的价值估计。然后使用 TD 误差更新当前状态的价值估计：$V(S_t) \leftarrow V(S_t) + \alpha \times$ TD 误差，式中α是学习率。相比于蒙特卡洛法，时序差分法有更低的方差，并且 TD 算法还能单步更新，无需等待整个轨迹的完成。

2.3.3 基于策略梯度的强化学习算法

与基于价值函数的方法不同，基于策略梯度的算法直接对策略本身进行优化，使用梯度上升法调整策略参数，从而寻找最优策略。其算法原理如图 2.11 所示。

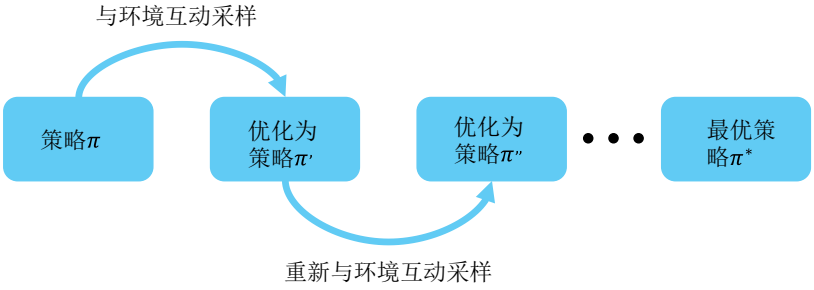


图 2.11 基于策略梯度的强化学习算法原理

在基于策略梯度的强化学习算法中，首先初始化一个策略$\pi_\lambda(s)$，其中，λ为策略网络的参数。智能体根据策略$\pi_\lambda(s)$与环境进行交互，记录交互过程中产生的经验数据，即状态、动作、奖励序列。然后使用经验数据对策略进行改进，得到改进后的新策略，再使用新策略与环境交互收集经验数据。经验数据的收集过程与策略改进过程循环往复，直到算法收敛到最优策略。

策略梯度方法的目标是最大化累积奖励的期望值，单个回合的累积奖励为：

中国知网 https://www.cnki.net

$$R_\lambda = \sum_{step=1}^{N} r_{step} \tag{2.15}$$

式中r_{step}为单个时间步的奖励值。累积奖励的期望为：

$$\overline{R_\lambda} = \sum_{\alpha} R(\alpha)P(\alpha \mid \lambda) \approx \frac{1}{M}\sum_{m=1}^{M} R(\alpha^m) \tag{2.16}$$

式中α表示智能体与环境交互产生的经验序列，$P(\alpha \mid \lambda)$表示在智能体使用策略$\pi_\lambda(s)$时生成序列α的概率。策略梯度方法的目标为找出使累积奖励期望值最大的参数λ^*的过程：

$$\lambda^* = argmax_\lambda \bar{R}_\lambda \tag{2.17}$$

使用梯度上升来更新参数λ：

$$\lambda' = \lambda + \sigma\nabla\overline{R_\lambda} \tag{2.18}$$

式中σ为学习率

式(2.18)中：

$$\nabla\overline{R_\lambda} \approx \frac{1}{M}\sum_{m=1}^{M}\sum_{step=1}^{N} R(\alpha^m)\nabla log\ p(a_{step}^m|s_{step}^m,\lambda) \tag{2.19}$$

2.3.4 价值函数与策略梯度相结合的强化学习算法

如图 2.12 所示，演员-评论家算法是将以上两种方法相结合的强化学习算法。

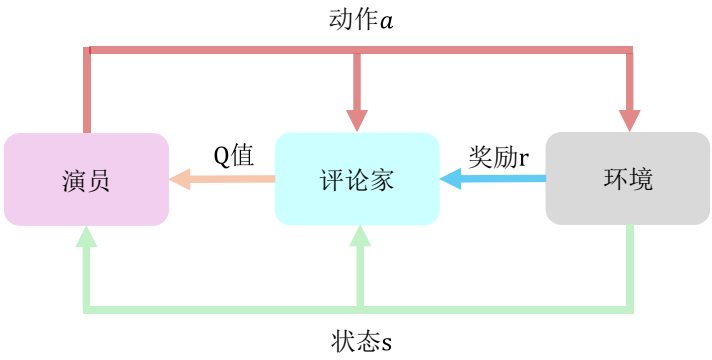


图 2.12 Actor-Critic 算法原理

Actor-Critic 算法由演员（Actor）和评论家（Critic）两个模型组成[69]。演员（Actor）

中国知网 https://www.cnki.net

是一个策略梯度模型，其基于当前状态s，生成一个动作a，并控制智能体执行动作a。评论家（Critic）则是一个值函数估计器，其负责评价动作a的“好坏”，它基于当前状态s和动作a，为演员（Actor）选择的动作“打分”，记为q。演员（Actor）利用梯度上升，根据打分q不断改进自己的“动作水平”。而评论家（Critic）则利用 TD 算法，根据环境的奖励r不断改进自己的“打分水平”。

深度确定性策略梯度算法 DDPG 是一种使用 Actor-Critic 作为基本框架的强化学习算法。如图 2.13 所示，在 DDPG 中，Actor 和 Critic 各自有两个神经网络（现实网络和目标网络），这种构造显著提高了算法的收敛速度和学习稳定性。DDPG 算法中的 Actor 根据输入状态产生确定动作，而 Critic 则评估这些动作的 Q 值。经过训练后，Actor 能够输出 Q 值最大的动作，而 Critic 则能够准确估计 Q 值。此外，DDPG 还借鉴了 DQN 的经验回放机制，将经验数据存储在经验池中，以去除样本间的相关性和依赖性。

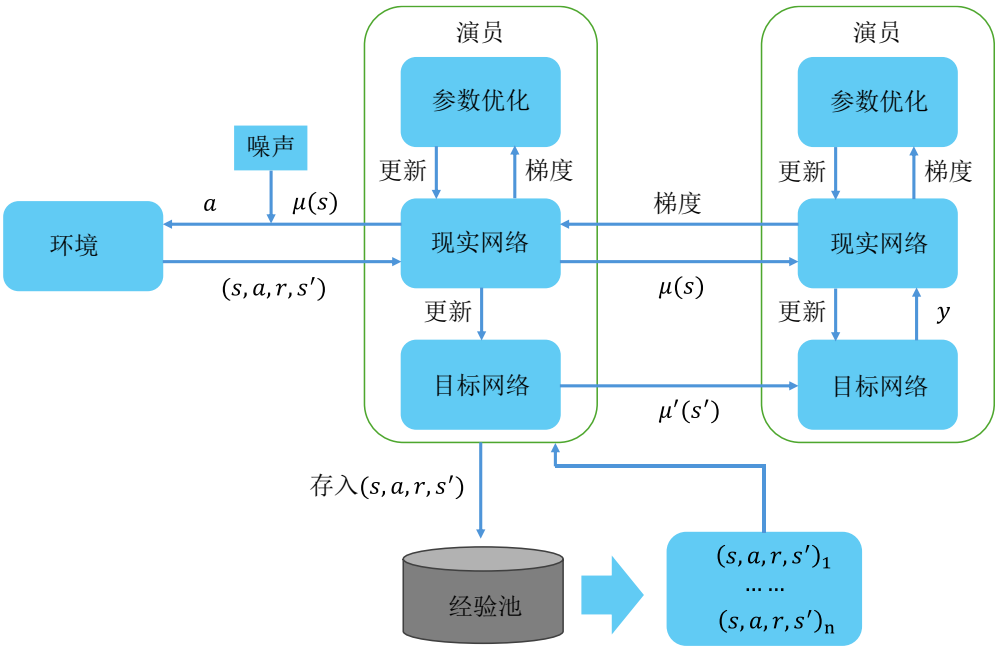


图 2.13 DDPG 算法原理图

图中 Actor 现实网络的参数为θ^{μ}，Actor 目标网络的参数为$\theta^{\mu'}$，Critic 现实网络的参数为θ^{Q}，Critic 目标网络的参数为$\theta^{Q'}$。

Actor 中的现实网络首先基于环境中的当前状态s_t得到动作a_t。其中，为了增加探索，在动作a_t中加入了噪声。智能体在执行动作a_t后，环境输出相应的奖励r_t以及下一个状态s_{t+1}。将s_t、a_t、r_t、s_{t+1}组成四元组(s_t、a_t、r_t、s_{t+1})并放入经验回放池中，同时判断经验回放池中数据量是否达到预先设定的数量，若达到就开始训练，若未达到，则继续执行采样流程。

中国知网 https://www.cnki.net

训练时，从经验回放池中按照采样规则采样 N 条经验。将经验中下一状态s_{t+1}输入到 Actor 中的目标网络中，得到输出动作$\mu'(s_{t+1})$，然后将其输入到 Critic 中的目标网络，目标网络基于动作$\mu'(s_{t+1})$和下一状态s_{t+1}计算得到$\mathrm{y} = \mathrm{r} + \gamma \mathrm{Q}'(\mathrm{s_{t+1}}, \mu'(\mathrm{s_{t+1}}))$。将y与 Critic 中现实网络估计出的当前状态值$\mathrm{Q}(s, a)$的均方误差作为 loss 函数训练 Critic 中的现实网络。

将 Actor 中现实网络输出的动作$\mu(s_t)$输入给 Critic 的现实网络，输出$\mathrm{Q}(s_t, \mu(s_t))$。将$-\frac{1}{N}\sum_i Q(s_i, \mu(s_i))$作为 loss 函数训练 Actor 中的现实网络。最后在训练时，逐步更新两个目标网络的参数：

$$\begin{cases} \theta^{Q'} \leftarrow \tau\theta^{Q} + (1-\tau)\theta^{Q'} \\ \theta^{\mu'} \leftarrow \tau\theta^{\mu} + (1-\tau)\theta^{\mu'} \end{cases} \tag{2.20}$$

式中τ为更新参数。

软演员-评论家算法 SAC 也是一种基于 Actor-Critic 框架的深度强化学习算法。该算法将策略的熵作为额外优化目标，在最大化未来累积奖励的同时，也尽可能增大策略熵，其中策略熵被定义为：

$$\mathcal{H}(\pi) = -\mathbb{E}_{\pi}[log\ (\pi)] \tag{2.21}$$

策略网络的优化目标被定义为：

$$\pi^* = \underset{\pi}{argmax}\mathbb{E}\left[\sum_{t=0}^{n}\left(r(s_t, a_t) + \alpha\mathcal{H}(\pi(\cdot\,|s_t))\right)\right] \tag{2.22}$$

式中α为熵的温度系数，$r(s_t, a_t)$为当前状态动作对的奖励值，

2.4 本章小结

本章首先介绍了刚体在三维空间中的位姿描述，利用 D-H 参数法对七自由度机械臂进行运动学建模与分析；然后介绍了图神经网络相关知识及经典模型；最后介绍了深度强化学习的相关理论。

中国知网 https://www.cnki.net

第3章 基于关系子图神经网络的碰撞检测方法

在机械臂动态避障轨迹规划中，必须实时检测机械臂与周围障碍物之间的碰撞距离，以便及时调整机械臂的运动轨迹，从而避免碰撞或生成不合理的轨迹。然而，现有方法在碰撞距离回归误差和碰撞检测准确性方面仍存在一些不足之处。为解决这些问题，本章提出了一种基于关系子图神经网络的碰撞检测方法。

3.1 研究动机

近年来，机械臂在人类的生产和生活中逐渐扮演着日益重要的角色，它能协助人类完成高精度、高风险和重复性的工作。在机械臂工作前，必须设定一个有效的轨迹，以确保其安全运行。与移动机器人不同，机械臂具有更高的自由度和更复杂的结构，因此它的轨迹规划更为困难。所以，机械臂的轨迹规划一般通过离线仿真进行。在离线仿真中，大多数算法都需要执行大量的碰撞检测，来获取碰撞距离（即机械臂和周围障碍物之间的最小距离），以便找到安全有效的无碰撞轨迹。众所周知，计算该距离需要找到机械臂的每个连杆与障碍物之间的最小距离，这种计算密集型任务十分耗时，有时甚至会占据轨迹规划算法总时间的 90%。

为了减轻计算负担，一些研究者利用数据训练碰撞距离函数。他们收集大量由机械臂构型及其相应碰撞距离组成的数据，使用机器学习模型如核感知机[38]、支持向量机[70]和神经网络[71-74]学习这些数据，然后用训练好的模型快速判断给定新构型的碰撞情况或估计碰撞距离。这种方法能为机械臂提供更快的碰撞检测能力，从而提升机械臂的工作效率。然而，这种方法也存在一些局限性。首先，在面对高自由度机械臂或复杂环境时，碰撞距离函数将变得异常复杂且高度非凸。这种复杂性会显著增加模型学习碰撞距离函数的难度。其次，目前基于数据驱动的方法很少考虑机械臂和障碍物的几何形状，这会导致模型的精确度不高，进而会影响到机械臂轨迹规划任务的安全性。最后，这些方法对环境中的变化非常敏感，即使环境中发生任何微小变化，如新增或减少一些障碍物，大多数算法也都需要重新收集数据并再次训练模型。

为了解决上述问题，本章提出了一种基于关系子图神经网络的碰撞检测方法 RSGNet。RSGNet 首先将机械臂和障碍物建模为图数据，以此保存机械臂和障碍物的形状及相对位置信息。其次，与预测两个整图全局碰撞距离的方法不同，RSGNet 将机械臂和障碍物图分解为若干子图对，利用注意力机制将子图对构造为关系图，然后通过消息传递回归子图对之间的局部碰撞距离。最后，将所有局部碰撞距离中

中国知网 https://www.cnki.net

的最小值定义为全局碰撞距离。与复杂且高度非凸的全局碰撞距离函数相比，这些子图对的碰撞距离函数通常更为简单，且易于训练。此外，RSGNet 还具有较强的泛化能力。由于 RSGNet 是基于环境中子图对训练的，因此一旦训练完成，它就能适应于由这些子图对组成的任意环境，无需进行额外训练或修改。

3.2 模型介绍

本章将详细介绍所提出的 RSGNet 碰撞检测模型，其总体框架如图 3.1 所示，RSGNet 包括三个部分：初始图构造模块，关系图更新模块以及碰撞距离估计模块。

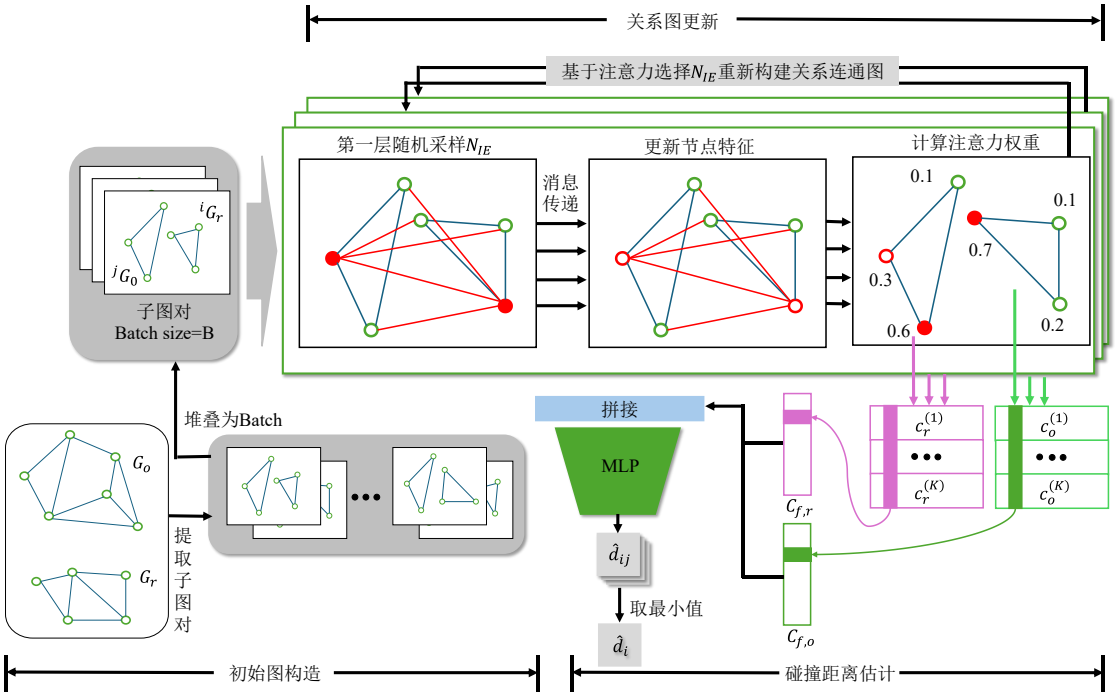


图 3.1 RSGNet 整体框架

3.2.1 初始图构造模块

在含有障碍物的机械臂环境中，通常用机械臂的构型$Z=\{Z_1,Z_2,\ldots,Z_N\}$和障碍物的构型Y来表示它们在工作环境中的位姿，并以此估计碰撞距离。其中Z_i表示机械臂的第i个关节的关节角度，Y表示障碍物的位姿信息。然而，这种传统的表示方法忽略了机械臂各连杆和障碍物的形状信息，导致碰撞检测方法距离估计精确度不高，增加了机械臂的操作风险。为了解决此问题，本章使用图数据来建模机械臂和障碍物，更全面地保存二者的形状信息和相对位置信息，并以此估计碰撞距离。

为将机械臂和障碍物建模为图数据，首先要对二者表面进行点采样。一个N自由度机械臂由N个连杆组成，在世界坐标系中，这些连杆的位姿可以通过第二章中的正向运动学计算得出：

中国知网 https://www.cnki.net

$$A_n = G\prod_{i=1}^{n} T_i^{i-1} \tag{3.1}$$

式中A_n为机械臂第n个关节在世界坐标系中的位姿，G是机械臂基座相对于世界坐标系的转移矩阵，T_i^{i-1}是第$i-1$个关节坐标系相对于第i个关节坐标系的转移矩阵。因此，对于第n个连杆上一点c，给定其在n关节坐标系中的位置，便可获得该点在世界坐标系中的位置：

$$p_n^c = A_n P_n^c \tag{3.2}$$

式中p_n^c表示第n个关节连杆上采样的点c在世界坐标系中的位置，P_n^c则表示点c在n关节坐标系中的位置。在机械臂各连杆上采样C个点并连接，可以获得机械臂的图$G_R = (V_R, \mathcal{E}_R)$。

在图中，V_R是节点的集合，$v_{R_i} \in V_R$是图中第i个节点；$\mathcal{E}_R$是边的集合，$e_{R_{ij}} \in \mathcal{E}_R$是节点$V_{R_i}$和$V_{R_j}$之间的边。

环境中障碍物的位姿信息是已知的，因此，障碍物相对于世界坐标系的转移矩阵也是已知的。所以，给定环境中障碍物上一点s在障碍物上的位置，即可获得该点在世界坐标系中的位置：

$$p^s = BP^s \tag{3.3}$$

式中p^s表示点s在世界坐标系中的位置，B表示障碍物相对于世界坐标系的转移矩阵，P^s则表示点s在障碍物上的位置。在每个障碍物上采样S个点并连接获得障碍物的图$G_O = (V_O, \mathcal{E}_O)$。在构造图数据时，点和边的选取要最大限度地保存机械臂和障碍物的形状信息。

在获得机械臂图$G_R = (V_R, \mathcal{E}_R)$和障碍物图$G_O = (V_O, \mathcal{E}_O)$后，将二者分割为若干子图对$({}^iG_r, {}^jG_o)_{i,j}$。其中${}^iG_r$为机械臂图中第$i$个子图，${}^jG_o$为障碍物图中第$j$个子图。

通过将机械臂和障碍物图分别分割为若干子图，估计所有子图对的局部碰撞距离，RSGNet 能够实现鲁棒的距离估计性能。因此，分割策略对模型的性能有很大的影响。分割时，每个子图所对应的子元素必须是形状不变的刚体，在面对现实世界中的复杂障碍物时，还需尽量简化子图的形状。虽然 RSGNet 并不要求子图所对应的子元素都是凸体，但如果一个元素的形状非常复杂且非凸，那么学习其相对应的碰撞距离就会非常困难，从而降低 RSGNet 的效率。

图 3.2 为使用 RSGNet 模型估计全局碰撞距离的一个示例，其中，机械臂被按连杆分割，每个子图对应机械臂的每个连杆，桌子则被分割为一个桌面，四个桌脚。估计出所有子图对的碰撞距离后，取其中的最小值作为全局碰撞距离。

中国知网 https://www.cnki.net

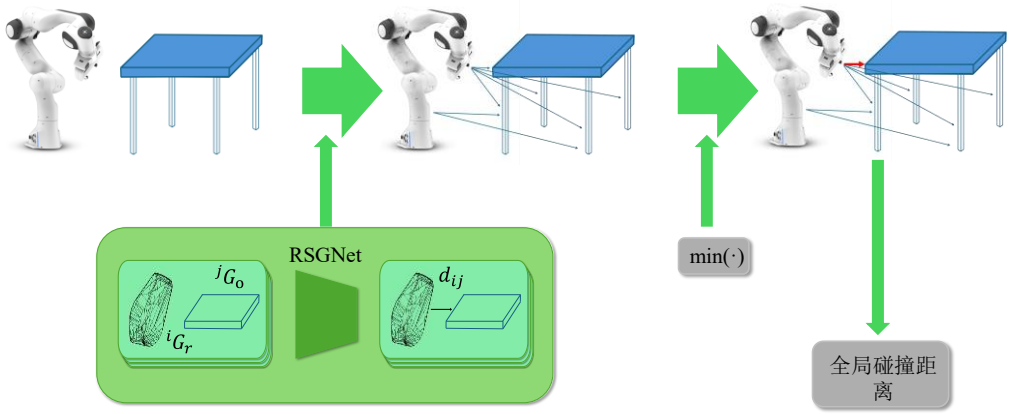


图 3.2 RSGNet 模型估计碰撞距离示例

3.2.2 关系图更新模块

为了交换子图$^{i}G_r$和$^{j}G_o$的形状信息和相对位置信息，逐步聚合二者之间的最小距离信息，如图 3.3 所示，分别在$^{i}G_r$和$^{j}G_o$中采样$n_{IE}/2$个节点，将这些节点称为信息节点，信息节点为图 3.3 中红色节点，记为N_{IE}。然后将N_{IE}与另一子图全部节点相连构造传输通道，生成二部图$G_{IE}=(V_{IE},\mathcal{E}_{IE})$，并以此构造关系连通图$G_u=^{i}G_r\cup{}^{j}G_o\cup G_{IE}=(V_u,\mathcal{E}_u,X_u,R)$。其中$\mathrm{X}_u$是节点特征的集合，$r\in\mathrm{R}=\{r_1,r_2\}$是$G_u$中边的类型，$r_1$表示机械臂和障碍物子图自身节点间的关系，对应于$G_u$中的$\varepsilon_o$与$\varepsilon_r$。$r_2$表示机械臂和障碍物子图之间节点间的关系，对应于$G_u$中的$\varepsilon_{IE}$。

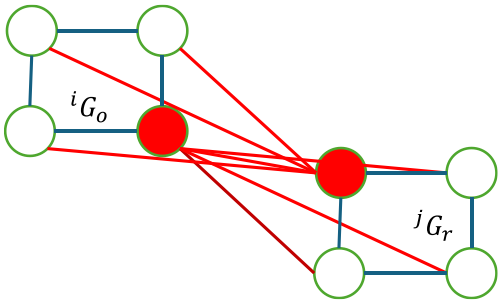


图 3.3 $n_{IE}=2$构建关系连通图示例

在第一次节点更新之前，本章在机械臂和障碍物子图中随机采样N_{IE}构造模型的初始输入图$G_u^{(0)}$。由于G_u需要经过多次节点更新，所以将经过 k 次节点更新后的图定义为$G_u^{(k)}$，其中，$k=1,\ldots,K$，在$G_u^{(k)}$中，N_{IE}由基于注意力机制的采样策略进行选择。

为了在图中嵌入机械臂和障碍物的形状信息和相对位置信息，将两个图中的初始节点特征定义为：

$$x_i^{(0)}=(p_i,{}^{o}p_i),\quad v_i\in\mathcal{V}_r \tag{3.4}$$

中国知网 https://www.cnki.net

$$x_j^{(0)} = \left(p_j, {}^r p_j\right), \quad v_j \in \mathcal{V}_o \tag{3.5}$$

式中p_i为机械臂子图中节点v_i在世界坐标系中的三维坐标，${}^o p_i$为节点v_i在障碍物子图中心坐标系中的三维坐标。p_j为障碍物子图中节点v_j在世界坐标系中的三维坐标，${}^r p_j$为节点v_j在机械臂子图中心坐标系上的三维坐标。对于每个子图，都可以通过齐次变换矩阵计算出其初始图的节点特征。

虽然采样点可以初步表示机械臂和障碍物的几何形状，但最小碰撞距离信息同样也和采样点之间的边相关，所以本章使用边特征和节点特征的组合来迭代更新关系图，本章将边特征定义为相邻两个节点的节点特征差值：

$$\boldsymbol{x}_{ij}^{(k)} = \boldsymbol{x}_j^{(k)} - \boldsymbol{x}_i^{(k)} \tag{3.6}$$

为了最小化模型迭代过程中丢失原始几何信息的退化问题，对以上边特征进行改进：

$$\boldsymbol{x}_{ij}^{(k)} = \begin{cases} \left(\boldsymbol{x}_j^{(0)} - \boldsymbol{x}_i^{(0)}\right), & if \ \ k = 0 \\ \left(\boldsymbol{x}_j^{(0)} - \boldsymbol{x}_i^{(0)} \parallel \boldsymbol{x}_j^{(k)} - \boldsymbol{x}_i^{(k)}\right), & otherwise \end{cases} \tag{3.7}$$

式中$\parallel$表示两个向量的串联。

将关系图G_u中r_1类型的边特征定义为$\mathbf{x}_{ij,r_1}^{(k)}$，$r_2$类型的边特征定义为$\mathbf{x}_{ij,r_2}^{(k)}$。考虑到碰撞距离只与碰撞发生的地方或两个物体距离最短的局部位置相关，并不需要远距离的边，所以将目标节点v_i的节点特征更新过程定义为：

$$h_i^{(k)} = \sum_{j \in \mathcal{N}_{ro}(i) \cup \{i\}} h_{\theta_k}^{(k)} \left(x_{ij,r_1}^{(k)}, x_{ij_{N_{IE}},r_2}^{(k)}\right) \tag{3.8}$$

在聚合边特征后，还需在关系图上进行节点更新，以进一步捕获机械臂和障碍物子图间的相对位置信息：

$$x_i^{(k+1)} = \sigma\left(\sum_{r \in R} \sum_{j \in \mathcal{N}_{ro}{}^*(i)} \frac{1}{c_{i,r}} W_r^{(k)} h_j^{(k)} + W_0^{(k)} h_i^{(k)}\right) \tag{3.9}$$

式中$\mathcal{N}_{ro}(i)$是节点v_i的 1-hop 节点集合，$h_{\theta_k}^{(k)}$是 MLP 编码器，$j_{N_{IE}}$是另一子图上的信息节点。σ是 ReLU 激活函数，$\mathcal{N}_{ro}{}^*(i)$是与节点v_i通过类型为r的边相连的邻居节点的集合，$W_r^{(k)}$和$W_0^{(k)}$为权重矩阵。在经过K层消息传递后，可以得到图$G_u^{(1)}$，$G_u^{(2)}$,…, $G_u^{(k)}$。

中国知网 https://www.cnki.net

由于机械臂和障碍物子图所对应子元素几何形状的复杂性，所以需要经过多次节点更新以传递二者必要的几何特征。因此，在每层节点更新后，RSGNet 都会重新选择N_{IE}构建下一层输入图。由于依靠N_{IE}构建信息传输通道，所以关系连通图所能传递的信息量取决于N_{IE}的选择，随机均匀地选择可能会使模型因聚合到距离较远（含有较低碰撞信息）的边而降低性能。为了解决这个问题，本章采用基于图注意力机制[67]的采样[75]策略来寻找最具信息量的节点N_{IE}。为此，本章分别计算${}^{i}G_r$和${}^{j}G_o$中所有节点的注意力权重：

$$\alpha_{r_i}^{(k)} = \frac{exp\left(a^{(k)T} x_{r_i}^{(k)}\right)}{\sum_n exp\left(a^{(k)T} x_{r_j}^{(k)}\right)} \tag{3.10}$$

$$\alpha_{o_i}^{(k)} = \frac{exp\left(a^{(k)T} x_{o_i}^{(k)}\right)}{\sum_m exp\left(a^{(k)T} x_{o_j}^{(k)}\right)} \tag{3.11}$$

式中$\alpha_{\mathrm{r_i}}^{(k)}$和$\alpha_{\mathrm{o_i}}^{(k)}$分别为两个子图中第$i$个节点的注意力权重，$a^{(k)T}$为可训练参数向量，$x_{\mathrm{r_i}}^{(k)}$和$x_{\mathrm{o_i}}^{(k)}$分别为${}^{i}G_r$和${}^{i}G_o$中节点的节点特征，$m$、$n$为图中节点数量。分别取${}^{i}G_r$和${}^{j}G_o$中注意力权重最大的前$n_{IE}/2$个节点作为$N_{IE}$构建新的关系连通图。

模型通过K层消息传递，逐渐寻找具有最大几何信息的节点以回归最小距离。在每一层中，RSGNet 利用更新后的节点特征计算注意力权重，图 3.4 为一次信息节点采样的示例，通过不断迭代，整个图就会朝着能够传递最大信息的方向更新。

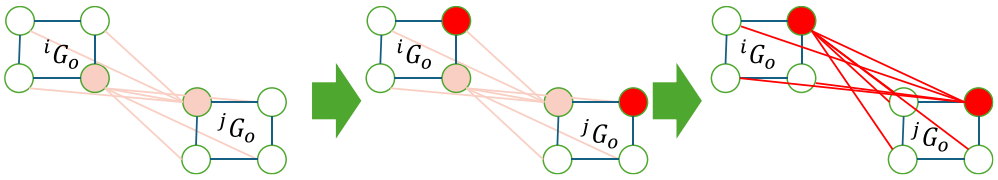


图 3.4 信息节点采样示意图

3.2.3 碰撞距离估计模块

RSGNet 将分层输出图$\left((G_r^{(0)}, G_o^{(0)}), \ldots, (G_r^{(K)}, G_o^{(K)})\right)$的节点特征输入 Readout 层以预测子图对之间的碰撞距离。具体来说，模型首先分别计算机械臂和障碍物子图的注意力加权特征：

$$c_r^{(k)} = LeakyReLU(\sum_n \alpha_{r_i}^{(k)} x_{r_i}^{(k)}) \tag{3.12}$$

$$c_o^{(k)} = LeakyReLU(\sum_m \alpha_{o_i}^{(k)} x_{o_i}^{(k)}) \tag{3.13}$$

中国知网 https://www.cnki.net

分别堆叠注意力加权特征获得$(c_r^{(1)\mathrm{T}},\dots,c_r^{(K)\mathrm{T}})$和$(c_o^{(1)\mathrm{T}},\dots,c_o^{(K)\mathrm{T}})$之后，对二者执行逐元素最大池化保持排列不变性，得到$C_{f,r}$和$C_{f,o}$，最后将$C_{f,r}$和$C_{f,o}$输入到多层感知机（Readout 层）中，回归出碰撞距离$\hat{d}_{ij}$：

$$\hat{d}_{ij} = MLP(C_{f,r}||C_{f,o}) \tag{3.14}$$

计算得到所有子图对的局部碰撞距离后，选择这些碰撞距离中的最小值作为全局碰撞距离$\hat{d}_i$：

$$\hat{d}_i = min_{ij}\left(\hat{d}_{ij}\right) \tag{3.15}$$

在一些轨迹规划应用中，还需为 RSGNet 设置一个阈值ε：

$$Is\ collision? = \begin{cases} True, & if\ \ \hat{d}_i \le \varepsilon \\ False, & otherwise \end{cases} \tag{3.16}$$

如果机械臂和障碍物的碰撞距离低于阈值ε，则判定机械臂处于碰撞状态。

3.3 实验设置及结果分析

本小节展示了所提出 RSGNet 模型的实验效果，通过对比实验在多方面分析了 RSGNet 模型的优势。

3.3.1 数据集及实验设置

为了评估所提出的方法以及基线方法，本章搭建了四种仿真环境，其中每个环境中都放有一个固定底座的 Franka Emika Panda 7-DoF 机械臂，以及若干边长为 0.1m 的立方体障碍物，每个环境的具体设置如下：

（1）静态三障碍物环境：在机械臂工作环境中，随机选择 3 个位置并将障碍物固定在这 3 个位置上。

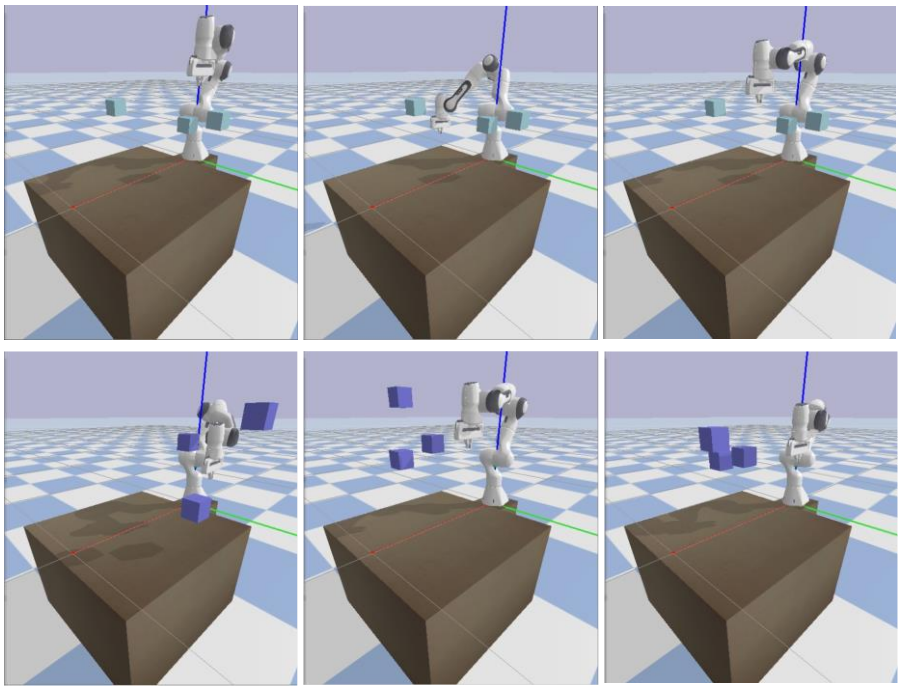
（2）动态三障碍物环境：在机械臂工作环境中，3 个障碍物的位置随机变化。

（3）静态二十障碍物环境：在机械臂工作环境中，随机选择 20 个位置并将障碍物固定在这 20 个位置上。

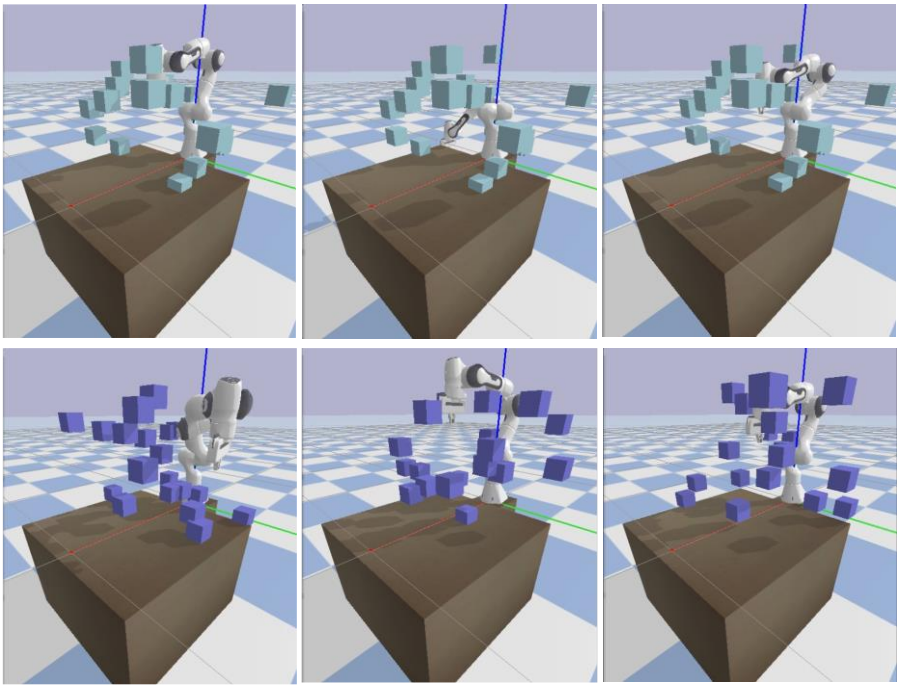
（4）动态二十障碍物环境：在机械臂工作环境中， 20 个障碍物的位置随机变化。

图 3.5 展示了四种不同的仿真环境，其中，浅蓝色立方体表示固定障碍物，深蓝色立方体表示移动障碍物。

中国知网 https://www.cnki.net



(a) 两种三障碍物仿真环境



(b) 两种二十障碍物仿真环境

图 3.5 四种仿真环境

在每个仿真环境中随机采样 50000 个机械臂构型及障碍物位置的组合作为输入数据，并以此获得机械臂和障碍物的图数据。然后再从这二者的图中提取子图对$({}^{i}G_r, {}^{j}G_o)_{i,j}$，根据机械臂的关节角度及障碍物的位姿信息，可以计算出图中节点的

中国知网 https://www.cnki.net

特征。在本章实验中，机械臂的每个连杆被视为一个子图，每个立方体障碍物被视为一个子图，使用 Pybullet 中的碰撞距离模块计算所有子图对的碰撞距离。如果两个子图发生碰撞，则将其碰撞距离设置为二者穿透深度的负值。将每个环境相对应的数据集按照 0.8:0.1:0.1 的比例划分为训练集、验证集和测试集。

在本章中，信息节点的数量N_{IE}取值为 2， MLP 编码器的大小为（32,32,32），LeakyReLU 激活函数的斜率为 0.2，算法学习率为 1e-3，迭代次数为 2000，另外，本章在 Tesla A100 GPU 中运行代码并完成所有实验。

3.3.2 基线模型

为验证所提出 RSGNet 模型的有效性，本章训练了 RSGNet 模型与另外几种基于数据驱动的碰撞检测方法：

1）ClearanceNet[40]：一种以关节构型作为输入的神经网络模型，使用两个全连接层，每个全连接层都带有一个 dropout 层。

2）GraphDistNet[74]：一种基于同构图的全局碰撞检测方法，将机械臂和障碍物建模为同构图。

3）DiffCo[38]：一种核感知器模型，以关节构型作为输入，输出碰撞分数。

4）DistFormer[41]：一种基于 transformer 的高精度碰撞检测方法，将机械臂和障碍物建模为边界序列，使用注意力机制融合边界序列并转换为碰撞距离。

5）Pointnet++[80]：使用 Point++ set abstraction 结构编码，基于点云的碰撞检测方法。

3.3.3 评价指标

本小节的主要目的是评估所提出模型的碰撞距离回归和碰撞分类性能，因此本节选择了 MSE、AUROC、Accuracy 和 Safe_FPR 作为主要评估标准。在碰撞分类任务中，如果模型所预测的碰撞距离低于设置的阈值ε，则此数据被划分为碰撞类别（对于 DiffCo，如果碰撞得分高于阈值，则判定为碰撞类别）。

MSE 表示真实碰撞距离与估计碰撞距离之间的均方误差：

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(\hat{d}_i - d_i)^2 \tag{3.17}$$

式中n是样本总数，$\hat{d}_i$是模型预测的碰撞距离，d_i是真实的碰撞距离。

Accuracy 是阈值ε为 0 时，碰撞分类的准确率：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{3.18}$$

中国知网 https://www.cnki.net

式中 TP 和 TN 是真正例和真负例的数量，FP 和 FN 则是假正例和假负例的数量。

AUROC 是碰撞分类的接收者操作特征曲线下面积，即 ROC 曲线下的面积，ROC 是以不同阈值下真正例率（TPR）和假正例率（FPR）为坐标轴绘制的曲线：

$$TPR = \frac{TP}{TP + FN} \tag{3.19}$$

$$FPR = \frac{FP}{FP + TN} \tag{3.20}$$

最后，在将碰撞检测模型应用在实际轨迹规划任务中时，为了确保安全，必须设置一个较高的阈值以确保不会发生碰撞。然而，较高的阈值虽然可以减少漏报率（将碰撞类别错误地分类为非碰撞类别），但是会增加误报率（将非碰撞类别错误地分类为碰撞类别）。为此，本章为每种方法分别设置了一个无碰撞保证阈值ϵ_{safe}，该阈值是指漏报率为 0（即在这个阈值下，模型能将测试数据集中所有碰撞类别正确分类为碰撞）时的最小阈值。Safe_FPR 就是指使用ϵ_{safe}时的假正例率：

$$Safe_FPR = \frac{FP}{FP + TN}, \quad \varepsilon = \epsilon_{safe} \tag{3.21}$$

3.3.4 性能比较

表 3.1 三障碍物环境

环境	模型	MSE	AUROC	Accuracy	Safe_FPR
环境 1（3 固定障碍物）	ClearanceNet	9.9e-4	0.9846	0.9805	0.1803
	GraphDistNet	3.11e-4	0.9963	0.9929	0.0665
	DiffCo	N/A	0.9856	0.9842	0.1469
	DistFormer	4.58e-4	0.9958	0.9911	0.0999
	Pointnet++	8.25e-4	0.9934	0.9889	0.1258
	RSGNet	**2.51e-4**	**0.9984**	**0.9937**	**0.0436**
环境 2（3 移动障碍物）	ClearanceNet	1.47e-3	0.9835	0.9766	0.1985
	GraphDistNet	3.29e-4	0.9971	0.9924	0.0992
	DiffCo	N/A	0.9852	0.9855	0.1632
	DistFormer	4.96e-4	0.9954	0.9901	0.1208
	Pointnet++	8.96e-4	0.9925	0.9879	0.1476
	RSGNet	**2.49e-4**	**0.9989**	**0.9941**	**0.0785**

中国知网 https://www.cnki.net

表 3.2 二十障碍物环境

环境	模型	MSE	AUROC	Accuracy	Safe_FPR
环境 3（20 固定障碍物）	ClearanceNet	4.25e-3	0.9687	0.9225	0.4128
	GraphDistNet	5.01e-4	0.9841	0.9662	0.3025
	DiffCo	N/A	0.9722	0.9158	0.4987
	DistFormer	3.79e-4	0.9946	0.9791	0.2552
	Pointnet++	8.21e-4	0.9807	0.9452	0.4458
	RSGNet	**3.44e-4**	**0.9968**	**0.9794**	**0.1242**
环境 4（20 移动障碍物）	ClearanceNet	7.58e-3	0.8235	0.8429	0.7854
	GraphDistNet	5.58e-4	0.9842	0.9402	0.5064
	DiffCo	N/A	0.8563	0.8872	0.6944
	DistFormer	4.87e-4	0.9911	0.9458	0.4865
	Pointnet++	1.02e-3	0.9754	0.9179	0.6625
	RSGNet	**3.85e-4**	**0.9954**	**0.9711**	**0.1985**

表 3.1 和表 3.2 显示了本章所提出模型与基线模型在四种环境下碰撞分类能力以及碰撞距离估计能力的比较结果。

（一）模型性能对比

（1）从表 3.1 和表 3.2 中可以看出，与现有方法相比，本章提出的 RSGNet 模型在四种不同环境中的每个评价指标上都超越了所有基线模型，验证了本章所提出方法的优越性。在简单环境 1 中，RSGNet 的 MSE 提升了 19.29%，AUROC 和 Safe_FPR 分别提升了 0.21%和 34.59%，在复杂环境 4 中，RSGNet 的 MSE 提升了 20.92%，AUROC 和 safe_FPR 分别提升了 0.43%和 60.84%。表现最好的指标用粗体标出。这表明将两个物体建模为关系图能有效捕获二者之间的形状和相对位置信息，而基于注意力机制的关系图重构策略以及本文提出的消息传递策略也能够利用形状及相对位置信息准确回归出碰撞距离。

（2）Safe_FPR 可以被视为模型在“最坏”情况下的性能指标，虽然 RSGNet 在碰撞分类性能 AUROC 和 Accuracy 上的提升并不明显，但这对机械臂的避障任务来说却非常重要，Safe_FPR 就是基于这一原理开发的。相较于传统的预测全局碰撞距离的基线方法，RSGNet 在 Safe_FPR 上提升最大，远超其他基线模型。较高的 Safe_FPR 会导致模型在碰撞检测时过于“谨慎”，进而会导致规划算法生成过于“保守”的轨迹。这些轨迹虽然能避免碰撞，但同时也可能会导致轨迹长度增

中国知网 https://www.cnki.net

加或生成不自然的轨迹等问题，从而降低规划方法的效率和性能。

（二）模型泛化性对比

（1）上表中的基线方法需针对不同环境单独训练模型，然后再分别估计相应测试数据集中的碰撞距离。这种方法需要大量的数据收集和模型训练工作，在实际应用中，这意味着要投入更多的资源。此外，对于一些不断变化的环境，如增加、减少或移动障碍物，每一次环境变化，这些方法都需要重新收集数据并训练模型。这不仅显著增加了时间和经济成本，也降低了模型的适应性和灵活性。

与之相反的是，由于独特的子图设计，RSGNet 学习的是环境中子图对的碰撞距离，所以仅需训练一个 RSGNet 模型，就可以估计所有全部由这些子图对组成的新环境中的碰撞距离。无论新环境发生什么改变，如障碍物的增加、减少或移动，只要新环境完全由经过训练的子图对组成，模型就无需重新训练或修改。这极大地提高了模型在面对不断变化环境时的灵活性。在本章中，由于四种环境含有相同子图对，所以 RSGNet 方法仅在环境 2 所对应的训练数据集上进行训练，就可以估计所有四个测试数据集中的碰撞距离，其性能甚至比使用单独模型的基线方法更好。

（2）理想情况下，RSGNet 应该在所有完全由已知形状（经过充分训练）组成的环境中表现出相同的性能，但在本章中，RSGNet 在四种不同环境中的评价指标略有差异。这可能是由测试数据集的随机性导致的，本章对每种测试集都采样了 5000 个关节构型，但是对于含有 20 个障碍物的复杂环境来说，5000 个构型可能还不够，这会导致四个测试集在特征分布上存在差异，进而导致评价指标出现差异。

（三）模型估计碰撞距离实例

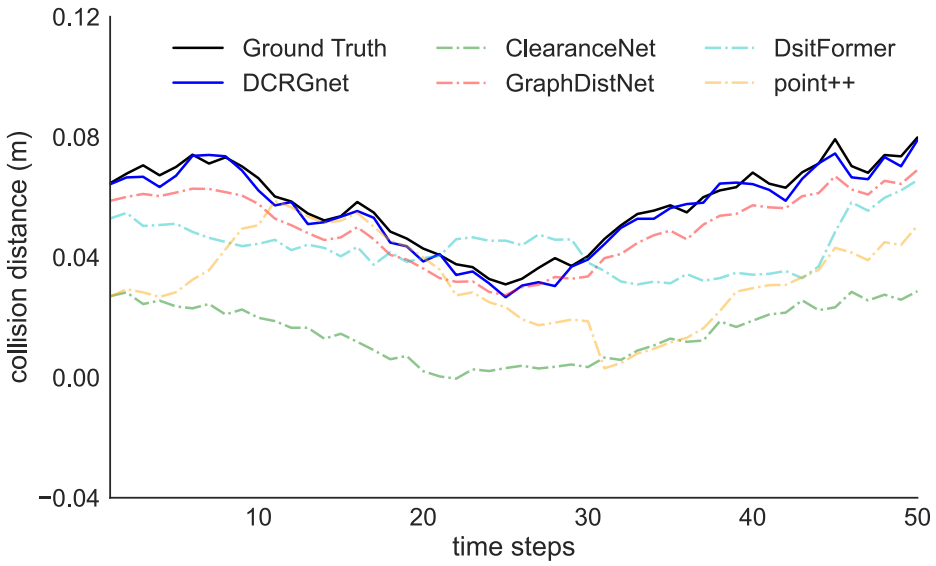


图 3.6 轨迹规划任务中碰撞距离估计实例

另外，本章还展示了在基于深度强化学习的机械臂动态避障轨迹规划任务中，

中国知网 https://www.cnki.net

不同碰撞检测方法对实际碰撞距离的估计结果。如图 3.6 所示，为了更好的可视化，本节截取了算法训练初期阶段某一 episode 中的 50 个临近碰撞状态的时间步。可以看出，在所有方法中，RSGNet 所估计的碰撞距离最为接近 Ground Truth，其性能得到了证实。

3.3.5 消融实验

本小节介绍了消融研究的策略并在图 3.7 中展示了消融研究的结果，其目的是为了分析所提出模型中不同组件的作用，以下是用于消融研究的 RSGNet 的衍生模型：

（1）RSGNet-A：此衍生模型删除了基于注意力机制的关系图构建策略，在构造关系连通图时，随机地选择N_{IE}。

（2）RSGNet-B：此衍生模型删除了边特征以及后续的边聚合操作，仅使用节点特征学习机械臂和障碍物子图的碰撞距离。

（3）RSGNet-C：此衍生模型将机械臂和障碍物子图建模为同构图，仅使用边特征学习机械臂和障碍物子图的碰撞距离。

分别在四个仿真环境中评估这些衍生模型，结果如图 3.7 所示。

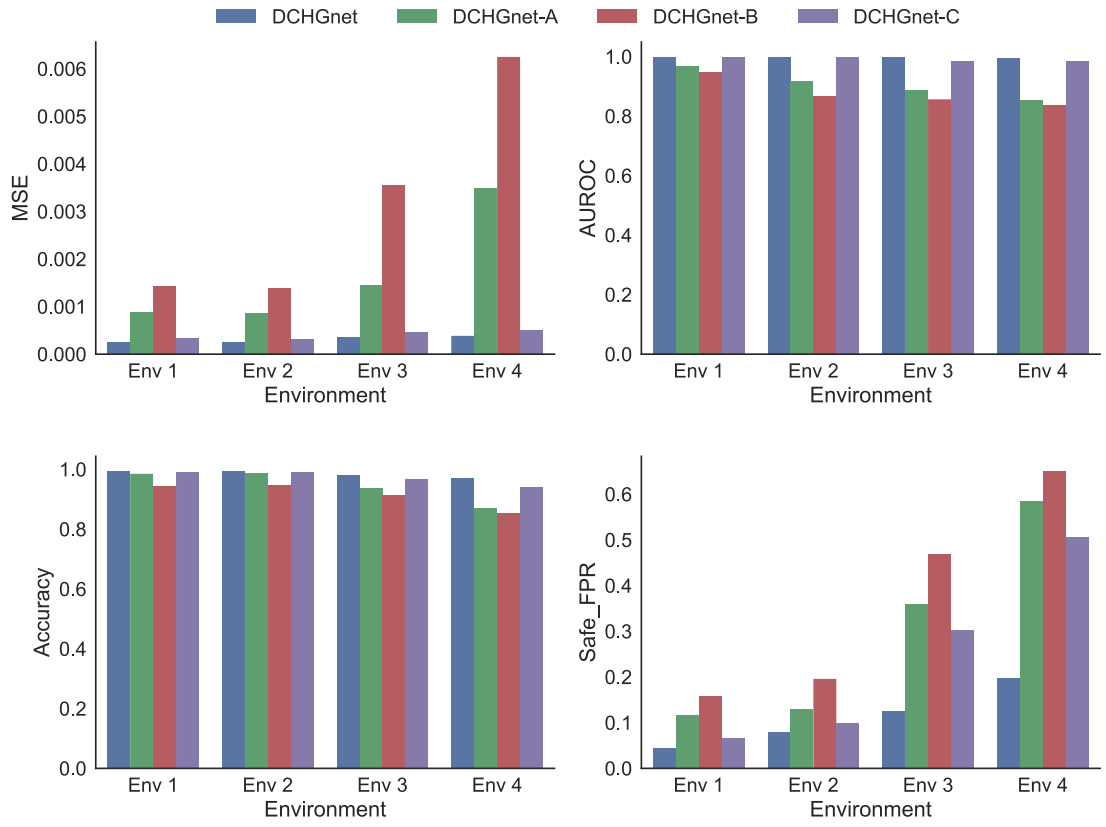


图 3.7 RSGNet 不同衍生模型的消融研究

中国知网 https://www.cnki.net

可以看出，在所有环境中，三种衍生模型的性能均不及 RSGNet。其中，RSGNet-B 的表现最差，其预测结果远差于 RSGNet 及其他衍生模型。这表明，在碰撞距离的学习中，边特征能够很好地使模型学习到机械臂和障碍物的形状信息，而仅靠节点特征则不足以全面理解这种形状信息，从而会导致模型性能下降。相比之下，RSGNet-A 的性能略好，这表明基于注意力机制的采样策略能够找到最具有信息量的信息节点N_{IE}，而随机采样策略会使模型聚合到含有较低碰撞距离信息的特征，进而影响到模型的性能。最后，RSGNet-C 的性能虽然优于 RSGNet-B 和 RSGNet-A，但也没有达到 RSGNet 的水平，这表明，不同物体节点之间的差异以及相对位置信息对模型学习碰撞距离也非常有帮助。

最后，为了研究在构建关系连通图时，N_{IE}节点的数量n_{IE}对模型性能的影响，分别取n_{IE}为 2、8、16、32 和 64 训练模型，并在复杂环境 4 中评估这些模型的 MSE 和推理时间。推理时间是指模型估计 5000 个测试数据集中所有碰撞距离所需的总时间，图 3.8 展示了实验结果。

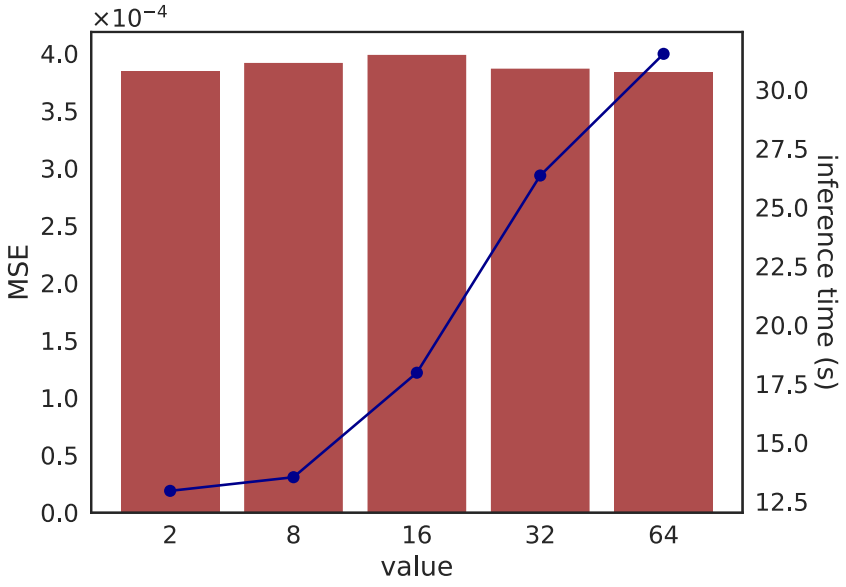


图 3.8 参数n_{IE}对模型性能的影响

可以看出，随着n_{IE}不断变大，模型的均方误差并没有发生显著变化。这表明当n_{IE}为 2 时，所构建的关系连通图已具备足够的能力，能够有效传输两个子图间所有含有碰撞距离的信息。另外可以看出，n_{IE}的增大会导致模型所需推理时间显著增多。这是因为随着n_{IE}不断变大，所构建的关系图会变得越来越复杂，从而会导致内存占用以及计算成本变高，最终影响到模型的推理速度。因此，本研究中将n_{IE}设置为 2。

中国知网 https://www.cnki.net

3.4 本章小结

本章针对现有基于数据驱动的碰撞检测方法在动态环境中检测精度低、泛化性差的问题，提出了一种基于关系子图神经网络的碰撞检测方法 RSGNet。该方法首先将机械臂和周围障碍物建模为若干子图对，利用注意力机制将这些子图对构建为关系图，通过关系图上的消息传递，RSGNet 能够准确估计各子图对之间的局部碰撞距离。最后，将这些局部碰撞距离中的最小值定义为机械臂和周围障碍物之间的全局碰撞距离。所提出方法在四种不同仿真环境中进行了实验，结果充分证明了与现有方法相比，RSGNet 在碰撞距离回归误差和碰撞检测准确性方面存在一定优势。值得注意的是，由于 RSGNet 学习的是子图对之间的局部碰撞距离，所以仅在一个仿真环境中进行训练的 RSGNet，就能适用于所有四种不同的测试环境，且效果甚至比为每个环境单独训练的基线模型要好。

中国知网 https://www.cnki.net

第4章 基于深度强化学习的机械臂动态避障轨迹规划框架

在第三章的研究中，RSGNet 有效提升了机械臂的碰撞分类与碰撞距离估计能力。在此基础上，本章将进一步对动态环境下的机械臂避障轨迹规划问题进行研究。现有基于深度强化学习的规划方法在动态环境中面临着收敛速度慢、收敛性能不佳以及生成轨迹质量较低的问题。为解决这些问题，本章提出了一种基于深度强化学习的机械臂动态避障轨迹规划框架。

4.1 研究动机

近年来，深度强化学习在机械臂轨迹规划领域中的应用正逐渐成为研究新热点。这种方法拥有较强的泛化能力、鲁棒性和自适应性，因此，本章使用深度强化学习算法作为机械臂的控制算法。深度强化学习算法又可分为 on-policy 和 off-policy 两大类，其中，off-policy 算法允许机械臂从旧策略产生的经验中学习，这种方式提高了数据的利用率以及学习的稳定性，尤其适合机械臂轨迹规划这种与环境交互成本较高的场景。

在 off-policy 算法训练时，尤其是算法训练前期，策略优化非常缓慢。为了解决这一问题，研究者通常使用优先经验回放机制 PER 加速训练过程。该方法通过智能地选择对学习过程更有价值的样本进行重点训练，提高了经验数据的运用效率。但 PER 的效果在很大程度上依赖于高质量数据的可用性。在数据质量低下的情况下，即使通过优先级进行采样，也无法有效地提高算法的学习效率和性能。而在轨迹规划任务训练早期阶段，机械臂主要通过随机探索与环境互动，这就会导致经验池中积累大量的低质量数据，尤其是在动态非结构化环境中，这种情况更为明显。此时，使用 PER 的加速效果并不显著。

为了解决这个问题，一些研究者提出了专家引导的策略学习方法，即在经验回放池中添加额外的专家经验数据，从而加速学习过程[76]。但是，这种方法也存在着一些问题。首先，获取高质量的人类专家演示往往耗时且成本高昂。其次，有些人类专家的操作和决策是基于经验和直觉给出的，并不是最优轨迹，以这种专家策略为训练目标，可能会使机械臂受限于专家的知识，无法学习出更优的策略。最后，在实际操作环境中，工作场景中的任何微小变化都会影响到先前学习到的策略的有效性。在这种情况下，必须重新获取适应新环境的专家策略，这显然不切实际。

另外，为了选择高价值的经验进行学习，PER 还需计算经验数据的优先度以及重要性采样权重，这显著增加了算法的时间复杂度。并且其还引入了新的超参数，

中国知网 https://www.cnki.net

找到合适的超参数设置需要进行大量的试验和调整，这也是一个繁琐且耗时的过程。因此，非常有必要设计一种能由少量专家经验引导、时间复杂度较低且不引入超参数的经验回放机制。

最后，在机械臂避障轨迹规划任务中，一个较为通用的奖励函数能显著提高其自主生成可避障轨迹的效率。目前，针对避障的奖励函数设计通常采用人工势场法思想，这种方法对动态障碍物的感知能力较弱，且在面对动态目标时表现较差，加剧了算法学习的难度。因此，还需设计一个适用于机械臂动态避障轨迹规划任务的通用奖励函数。

针对以上问题，本章首先提出了一种基于神经网络的专家引导三重经验回放机制 NETM。该方法可以将少量人类专家演示及算法产生的成功经验扩增为大量专家经验，使机械臂在整个训练过程中都能获得大量高质量的经验数据。另外，不同类型的经验数据在不同训练阶段中的价值会动态变化，所以在 DRL 算法训练的不同阶段，NETM 中的动态采样策略使用神经网络动态调整抽取专家经验以及算法自身生成成功、失败经验进行学习的比例，将专家经验融入算法的同时，提高了经验数据的利用率。NETM 并没有引入额外的超参数，时间复杂度也相对较低。其次，针对轨迹规划中的动态目标，本章在人工势场法的引力势场中加入了末端执行器和动态目标的速度约束，针对环境中的动态障碍物，本章取消了障碍物斥力势场的作用范围，并基于此提出了一种适用于动态环境的奖励函数 IAPR。

4.2 框架介绍

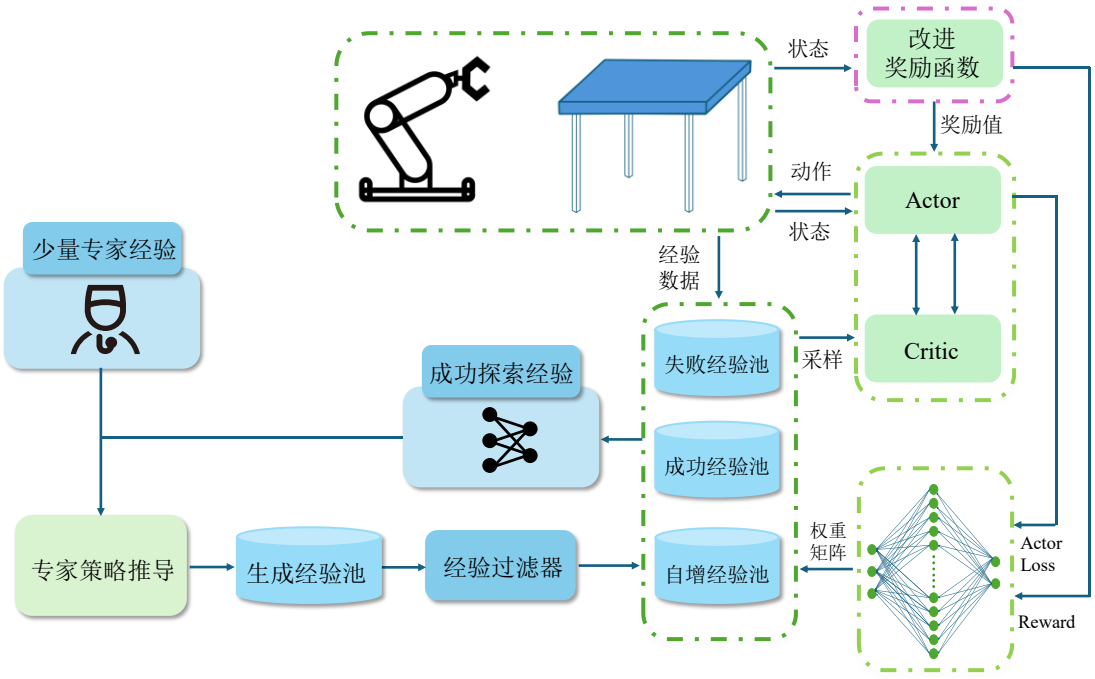


图 4.1 动态避障轨迹规划框架

中国知网 https://www.cnki.net

本章将详细介绍所提出基于深度强化学习的机械臂动态避障轨迹规划框架，框架如图 4.1 所示。它包含两部分：基于神经网络的专家引导三重经验回放机制 NETM 以及适用于动态环境的奖励函数 IAPR。

4.2.1 经验回放机制设计

基于神经网络的专家引导三重经验回放机制包括三个部分：专家演示、专家策略推导模块以及基于神经网络的经验采样模块。在专家演示部分，可以通过人类专家演示、基于传统逆运动学的轨迹规划或其他基于人类专家的技术获取少量专家演示数据；在专家策略推导部分，使用生成对抗模仿学习[77]增广专家演示部分及算法产生的成功经验，并设置一个自增专家经验回放池，将生成的成功专家经验存入自增专家经验回放池中；在基于神经网络的经验采样模块部分，将原始经验池分割为成功经验回放池和失败经验回放池，使用神经网络自主学习一个权重矩阵，将其附着于自增专家经验回放池、成功经验回放池和失败经验回放池上，根据 DRL 算法训练的不同阶段，动态调整权重矩阵，从而使 DRL 算法能够按需抽取不同的经验进行学习，提高了经验数据的利用率。

（一）专家策略推导模块

在进行专家策略推导之前，首先将专家演示部分中的专家轨迹样本集定义为：

$$RM_e = \{\Psi_1, \Psi_2, \cdots, \Psi_i, \cdots, \Psi_N\} \tag{4.1}$$

式中RM_e为专家轨迹样本集，Ψ_i为第i条专家轨迹样本，N为专家轨迹样本的数量，Ψ_i可进一步被转化为一组状态-动作对(s_t, a_t)。

在专家策略推导中，本章首先设置一个自增专家经验回放池M_e，使用 GAIL 增广少量的专家轨迹数据及算法产生的成功数据，然后将生成的专家经验数据存入自增专家经验回放池M_e中。GAIL 是一种结合了生成对抗网络（Generative Adversarial Network，GAN）和模仿学习（Imitation Learning，IL）的方法，本章旨在通过 GAN 中的对抗框架训练策略，以生成尽可能接近专家行为的数据。在 GAIL 中，存在两个主要结构：生成器G和判别器$D(s_t, a_t|\theta^D)$。

判别器$D(s_t, a_t|\theta^D)$由三层全连接网络构成，其将生成器G生成的状态-动作对作为负样本，专家轨迹数据及算法产生的成功经验数据生成的状态-动作对作为正样本，输出正负样本的相似性，用D_t表示，D_t的取值范围为[0,1]，生成器生成的动作越接近专家动作，D_t的取值就越接近 1。为了更好地区分生成器生成的行为和专家行为，判别器$D(s_t, a_t|\theta^D)$的优化目标是最小化：

$$\nabla_\theta^D D|_{s_i,a_i} = \hat{E}_{T_G}\left[\nabla_\theta^D log\left(D(s_i, a_i)\right)\right] + \hat{E}_{RM_e}\left[\nabla_\theta^D log\left(1 - D(s_i, a_i)\right)\right] \tag{4.2}$$

中国知网 https://www.cnki.net

式中T_G是从生成器获得的轨迹样本集。

生成器G可以是任意常规的强化学习算法（如 DDPG，SAC），以当前环境状态s_t作为输入，以判别器的输出D_t作为奖励函数，输出与专家越来越相似的动作a_t。

在 GAIL 中，交替训练判别器和生成器，在训练判别器时，固定生成器的参数，反之亦然。通过这个对抗的过程，生成器不断学习和改进，以产生越来越接近专家水平的行为。所以，即使初始时只有少量专家经验，GAIL 也能通过内部的学习过程，生成大量的高质量经验数据。

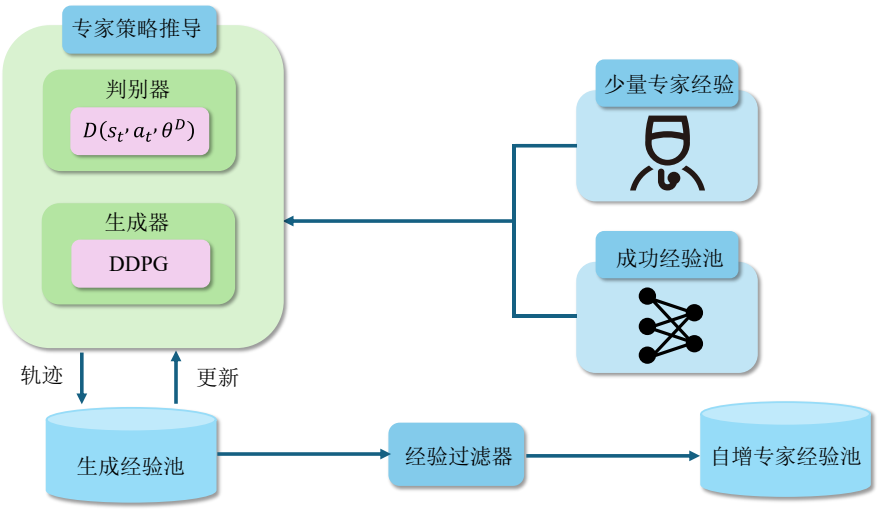


图 4.2 自增专家经验回放池

如图 4.2 所示，在 GAIL 训练前，将通过专家示教获得的专家经验作为判别器的正样本，然后在 GAIL 训练的每一回合，生成器会尝试模仿专家的行为，生成一整条轨迹存储在生成经验回放池中。但这些生成轨迹并不总是高质量的成功轨迹，对算法的引导效果有限，于是本章设置了一个经验过滤器，将其中的成功（末端执行器能到达目标点附近，并能一直维持在目标周围）轨迹筛选到自增专家经验回放池M_e中。经验过滤器的原理是：将生成器所产生的状态-动作对按照时间序列传递给机械臂，由环境的反馈判断是否完成任务。自增专家经验池M_e采用先进先出的更新方式，当经验回放池中的经验数量大于所设置的经验池最大容量时，新加入的数据会逐渐替换掉最早的数据。随着训练的进行，生成器的能力会在对抗的过程中不断提升，学习到更加接近专家策略的行为模式，从而逐渐提高生成数据的质量。

值得注意的是，有些专家轨迹并不是最优轨迹，这可能会使机械臂学习到次优策略。因此，本文将 DRL 算法训练中产生的成功经验也输入 GAIL 中进行扩增，以保证自增专家经验回放池中经验的质量。在 DRL 训练前期阶段，由于 GAIL 极快的训练速度，自增专家经验回放池中很快就会充满大量成功轨迹，无论这些成功轨迹的质量如何，它都会对机械臂的训练产生很大的引导效果。随着训练的进行，DRL 逐渐收敛，产生的成功经验会越来越多，在判别器的正样本中会逐渐占据主

中国知网 https://www.cnki.net

导地位，并且这些经验的质量也在不断优化，这就会逐渐减弱某些低质量专家经验的影响，从而提高自增专家经验回放池中数据的质量，为机械臂提供更强的引导效果。因此，在 DRL 算法训练的所有阶段，机械臂都会获得数量足够且质量能够满足当前训练要求的专家经验数据。

（二）基于神经网络的经验采样模块

为了在引入专家经验的同时，提高经验利用率，本节提出了一种基于神经网络的经验采样模块。该模块首先将原始经验回放池一分为二，分为成功经验回放池$M_{success}$和失败经验回放池M_{fail}。将机械臂成功完成任务所对应的经验存入成功经验回放池中，失败经验存入失败经验回放池中。由于强化学习的回报延时性，还需将之前经验数据也存入相关经验回放池中。因此，本章新增一个缓存池，缓存池的容量为最大时间步长。当某一 episode 结束时，这段时间内所有相关经验（即缓存池中的经验）会根据结果一同被转移到相应的经验回放池中。例如，如果机械臂成功完成了任务，则这期间的所有经验都会被从缓存池转移到成功经验回放池中，相反，如果未能完成任务，这些经验则会被转移到失败经验回放池中。

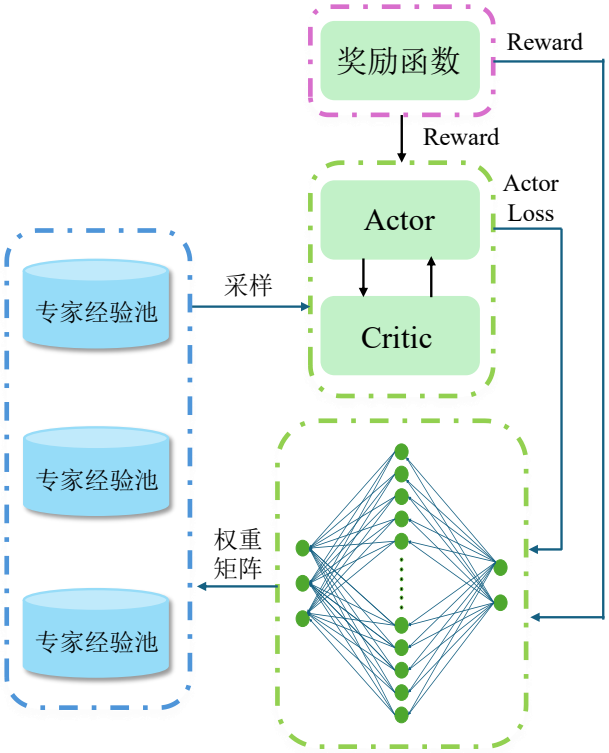


图 4.3 基于神经网络的经验采样模块

在深度强化学习算法训练时，不同类型经验数据的价值不同，所以 NETM 按不同比例分别抽取三个经验回放池中的经验进行学习。并且，三种经验的价值还会随着训练阶段的不同而动态改变，所以，采样比例也应随着训练阶段的变化而变化。如果在算法开始训练前就给出抽样比例，会影响算法的收敛速度和最终性能。为最

中国知网 https://www.cnki.net

大化经验数据的利用率，本章通过神经网络学习一个权重系数矩阵$\alpha = [\alpha_z, \alpha_{success}, \alpha_{fail}]$，并将其附加到自增专家经验回放池、成功经验回放池和失败经验回放池上，从而能使算法按训练进度动态地控制抽取经验学习的比例：

$$\begin{cases} N = \alpha_z * N + \alpha_{success} * N + \alpha_{fail} * N \\ \alpha_z + \alpha_{success} + \alpha_{fail} = 1 \end{cases} \tag{4.3}$$

所设计的学习权重系数矩阵α的神经网络如图 4.3 所示。为了动态地调整抽样比例，NETM 使用神经网络，利用已有知识学习权重系数矩阵α，其中神经网络的参数为ω。在 DDPG 和 SAC 中，算法的奖励值与策略网络的损失值是体现算法性能和策略网络优化程度的重要指标，也是宝贵的已有知识。所以，本章使用算法的奖励值与策略网络的损失值作为神经网络的输入，为最大化奖励，将神经网络的 loss 定义为奖励值的相反数：

$$J(\omega) = -R \tag{4.4}$$

4.2.2 奖励函数设计

在深度强化学习算法中，设计一个高效的奖励函数至关重要。目前，针对避障的奖励函数通常采用人工势场法思想，即在环境中附加一个势场，这个势场包括由目标位置产生的引导机械臂向目标位置运动的引力势场，以及由障碍物产生的引导机械臂避开障碍物的斥力势场[78]。一般来说，依据这种思想定义的奖励函数（Artificial Potential-field Reward，APR）通常如下形式：

$$R_f = -R_T - R_O \tag{4.5}$$

其中R_T为引力势场奖励函数，R_O为斥力势场奖励函数。R_T由机械臂末端执行器与目标位置之间的距离提供，距离越大受到的引力越大，反之则受力越小。

当末端执行器到达目标位置时，引力为 0。引力势场奖励函数定义为：

$$R_T = c_1 d_T^2 \tag{4.6}$$

其中c_1为引力势场系数，d_T为末端执行器与目标位置之间的距离。

R_O由机械臂与障碍物之间的最小距离提供，距离越大受到的斥力越小，反之则受力越大。现有工作通常为障碍物的斥力势场设置影响范围，称其为局部斥力势场奖励函数，一般定义为：

$$R_o = \begin{cases} c_2\left(\dfrac{\varphi}{d_O} - 1\right), & d_O \le \varphi \\ 0, & d_O > \varphi \end{cases} \tag{4.7}$$

中国知网 https://www.cnki.net

其中c_2为斥力势场系数，d_O是由 RSGNet 模型估计出的机械臂与障碍物之间的最近距离，φ为障碍物影响范围半径。只有当机械臂与障碍物的距离小于φ时，R_o才会起作用。

虽然 APR 的效果在简单场景（静态目标及静态障碍物）下得到了验证，但其在动态环境中往往表现不佳。因此，本小节就动态环境对这种奖励函数进行了改进。首先，针对环境中出现的动态目标，除距离信息外，将其与末端执行器的速度信息也加入引力势场奖励函数中，使末端执行器与目标的运动趋势保持一致：

$$R_{TV} = c_1 d_T^2 + c_3 |v_e - v_t|^2 \tag{4.8}$$

式中c_3为速度影响因子，v_e和v_t分别为末端执行器与目标的速度。

其次，在局部斥力势场奖励函数中，只有当d_O小于φ时，它才会影响机械臂的训练[79]。这种避障惩罚项在面对动态障碍物时，无法及时反映出动态障碍物的位置变化。因此，本节设计了一个可以在整个环境中感知动态障碍物的全局斥力势场奖励函数：

$$R_{OG} = c_2 (\frac{1}{1 + d_O})^n \tag{4.9}$$

式中n同样根据具体任务调整。对于训练全过程，R_{O2}都会为机械臂提供全局障碍物感知能力。

另外，当末端执行器到达目标位置时，还需将末端执行器与目标位置的距离d_T保持在一定范围内，此时d_T的变化会非常小，从而会导致机械臂对末端执行器的细微位置变化不够敏感。因此，为了学习到这些细微的动作变化，使末端执行器不断朝着目标位置移动，本节添加了一个附加奖励：

$$R_1 = \begin{cases} \tau, & d_T^n < d_T^{n-1} \\ 0, & d_T^n = d_T^{n-1} \\ -\tau, & d_T^n > d_T^{n-1} \end{cases} \tag{4.10}$$

式中τ是一个大于零的常数，d_T^n是第 n 个时间步中末端执行器与目标之间的距离。

另外，对于将末端执行器位置保持在目标附近的时间步，为其额外定义一个稀疏奖励：

$$R_2 = \begin{cases} \delta, & d_T^n \le \varepsilon \\ 0, & d_T^n > \varepsilon \end{cases} \tag{4.11}$$

式中δ是一个大于零的常数，ε为最大允许位置误差。

综上，改进后的奖励函数 IAPR 定义为：

中国知网 https://www.cnki.net

$$R_t = R_{TV} + R_{OG} + R_1 + R_2 \tag{4.12}$$

4.2.3 状态空间与动作空间设计

机械臂的状态空间是指环境状态和机械臂自身状态的总和，它为机械臂提供了进行决策和执行动作所需的全部必要信息。在本章中，使用 7-DoF 机械臂进行实验，如果直接将机械臂的关节角度和速度作为观测值，机械臂的学习效率会非常低，甚至还会无法找到最优轨迹。为此，本章将末端执行器的位置p_e和速度$\dot{p}_e$设为观测值，然后计算逆运动学（IK）控制关节角度。此外，对于环境状态，本章使用障碍物和目标相对于末端执行器的相对位置$\bar{p}_o/\bar{p}_t$和速度$\dot{\bar{p}}_o/\dot{\bar{p}}_t$来代替二者的绝对位置和速度。因此，状态空间$S$被定义为：

$$S = \{p_e, \dot{p}_e, \bar{p}_t, \dot{\bar{p}}_t, \bar{p}_o, \dot{\bar{p}}_o\} \tag{4.13}$$

由于本章将末端执行器的位置设为观测值，因此动作空间A的维度就可以从七维减少到三维：

$$A = \{\Delta x, \Delta y, \Delta z\} \tag{4.14}$$

式中$\Delta x, \Delta y, \Delta z$为机械臂末端执行器在 X、Y 和 Z 轴方向上的移动量，为了避免机械臂在单个时间步中因动作输出过大而突然移动，将$\Delta x, \Delta y, \Delta z$的取值范围限制在-0.1m 至 0.1m 之间。

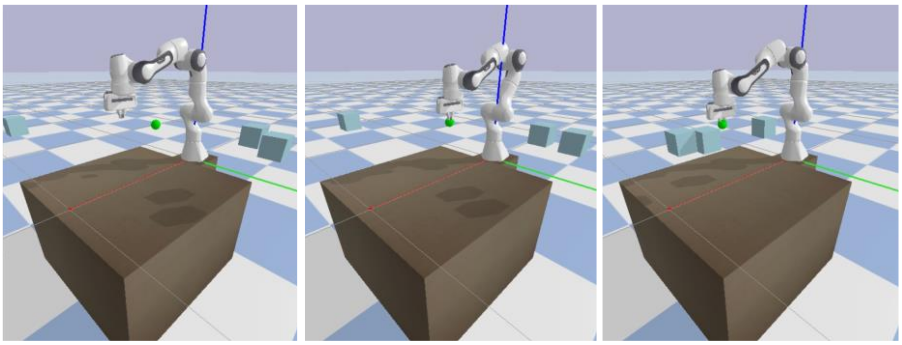
4.3 实验设置及结果分析

4.3.1 参数及任务设置

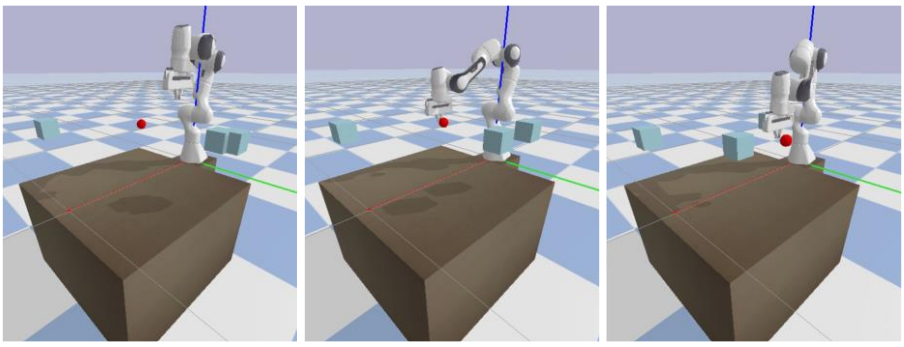
本文基于 Pybullet 平台搭建了 Franka Emika Panda 7-DoF 机械臂仿真实验环境。如图 4.4 所示，为了评估所提出的方法，设置了（1）静态目标-动态障碍物和（2）动态目标-动态障碍物两种评估场景。在场景 1 中，任务目标为机械臂到达并尽可能长地保持在静态目标（绿色球体）附近，在场景 2 中，任务目标为机械臂找到并尽可能长地跟随动态目标（红色球体）。在两个场景中，均存在三个以恒定速度移动的正方体障碍物，机械臂还需避开这些障碍物。此外，为了保证模型在不确定条件下的学习能力，目标和三个障碍物的起始位置均在一定范围内进行均匀随机采样，此外。目标的初始位置和移动范围均被限制在机械臂的可达工作空间中。

本章使用 RSGNet 碰撞检测模型获取机械臂与周围障碍物之间的碰撞距离。其中，机械臂及障碍物图构建策略和子图划分策略与第三章中所使用方法相同。障碍物包括三个移动正方体以及桌子。

中国知网 https://www.cnki.net



(a) 静态目标-动态障碍物场景



(b) 动态目标-动态障碍物场景

图 4.4 两种仿真场景

表 4.1 中给出了训练过程的主要超参数。此外，本章在 Tesla A100 GPU 中运行代码并完成所有实验。

表 4.1 超参数设置

参数	数值	参数	数值
Actor 网络学习率	0.00015	经验池总容量	1000000
Critic 网络学习率	0.0015	ε	0.05
奖励折扣因子	0.99	c_1	250
软更新率	0.001	c_2	15
Batch_size	64	n	35
专家记忆库容量	10000	τ	0.2
最大时间步	100	δ	4

4.3.2 评价指标

为了评估所提出经验回放机制以及改进奖励函数的有效性，本章使用了两个评价指标：安全率（Safe rate）和准确率（Accuracy），二者定义如下：

中国知网 https://www.cnki.net

$$\text{Safe rate}=\frac{\text{未发生碰撞时间步数}}{\text{总时间步数}} \tag{4.15}$$

安全率为一个 episode 中，未发生碰撞的时间步占总时间步的比例。

$$\text{Accuracy}=\frac{\text{成功时间步数}}{\text{总时间步数}} \tag{4.16}$$

准确率是指将机械臂末端执行器位置与目标位置的距离保持在 0.05m 以内的成功时间步占总时间步的比例。由于总时间步中必定包含机械臂从初始位置到目标位置之间的时间步，所以准确率不可能达到 100%。

4.3.3 实验结果分析与讨论

在本章实验中，每回合包括 100 个时间步，达到 100 时间步后，无论结果如何，立即开始下一回合的训练。每个时间步都会进行碰撞检测，如果发生碰撞，碰撞时间步数+1。回合结束后，根据碰撞时间步数计算安全率，在本章中，将碰撞检测模型 RSGNet 的阈值ε设为 0。如果某一时间步末端执行器位置与目标位置的距离小于 0.05 米，则成功时间步数+1。回合结束后，根据成功时间步数计算准确率。实验的训练流程如图 4.5 所示。

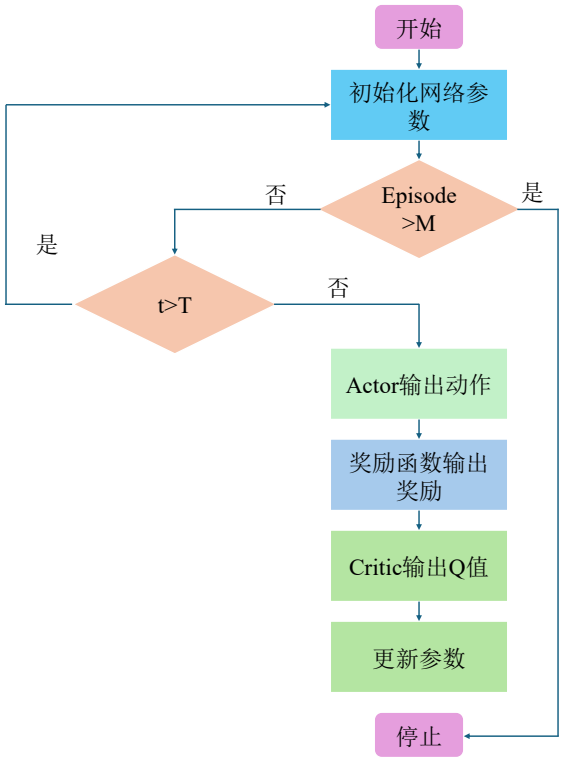
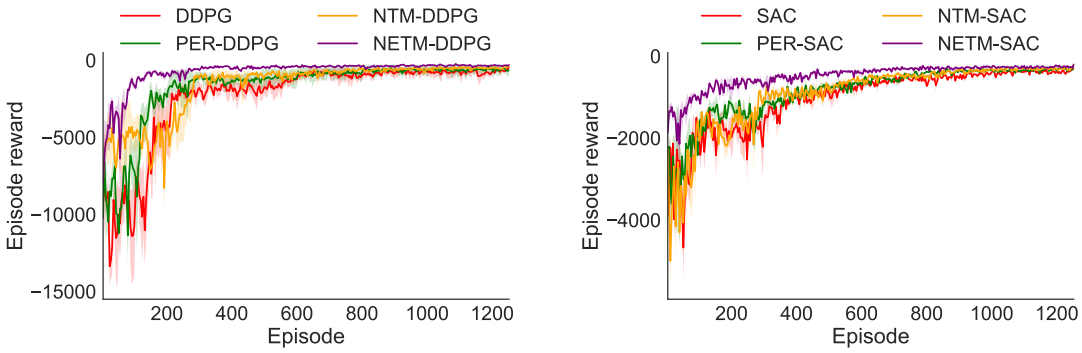


图 4.5 实验训练流程示意图

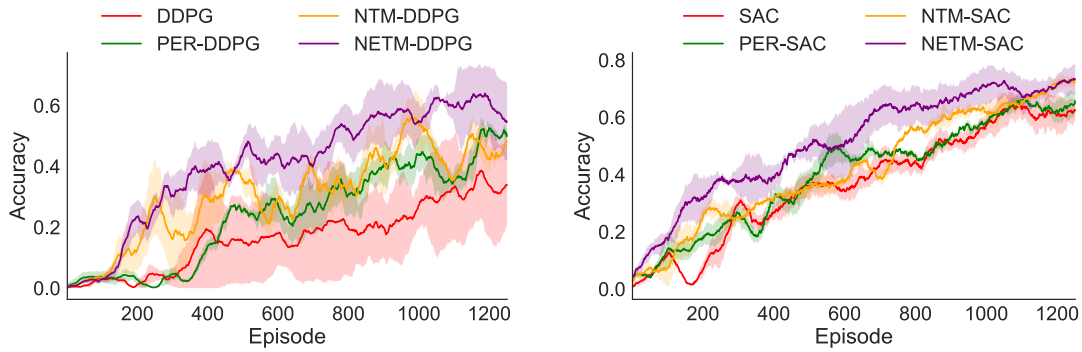
中国知网 https://www.cnki.net

（一）经验回放机制实验效果对比

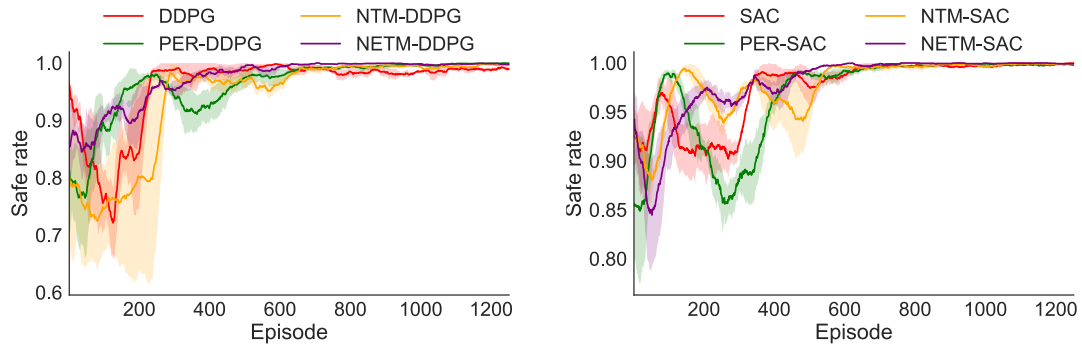
首先，本小节基于两种具有代表性的深度强化学习算法（DDPG 和 SAC），采用原始奖励函数 APR，分别在静态目标-动态障碍物和动态目标-动态障碍物两种评估场景中，就原始 DRL、PER-DRL、NETM-DRL 和 NTM-DRL 四种方法进行了对比实验。



(a) 回合奖励曲线



(b) 回合准确率曲线



(c) 回合安全率曲线

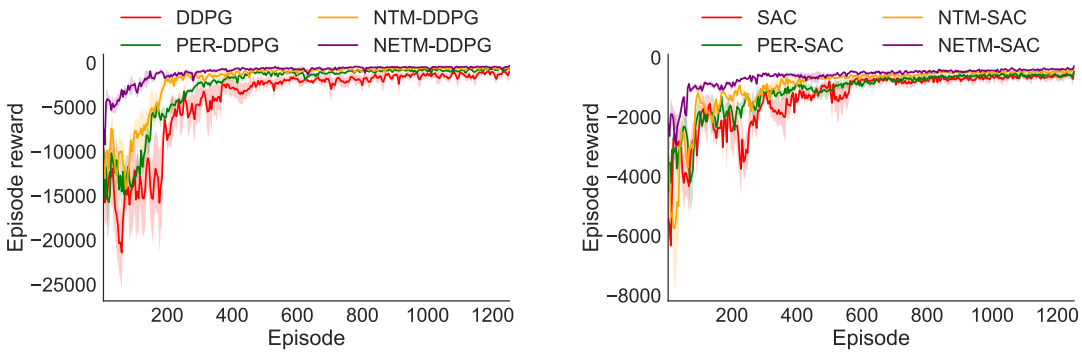
图 4.6 不同算法在场景 1 中的性能对比

其中，对于 NETM-DRL，在训练开始前，扩增 10000 条专家经验初始化自增专家经验回放池。NTM-DRL 为删除自增专家经验回放池时的 NETM-DRL 方法。NTM-DRL 不使用专家策略引导，仅将原始经验分为成功经验和失败经验，使用神

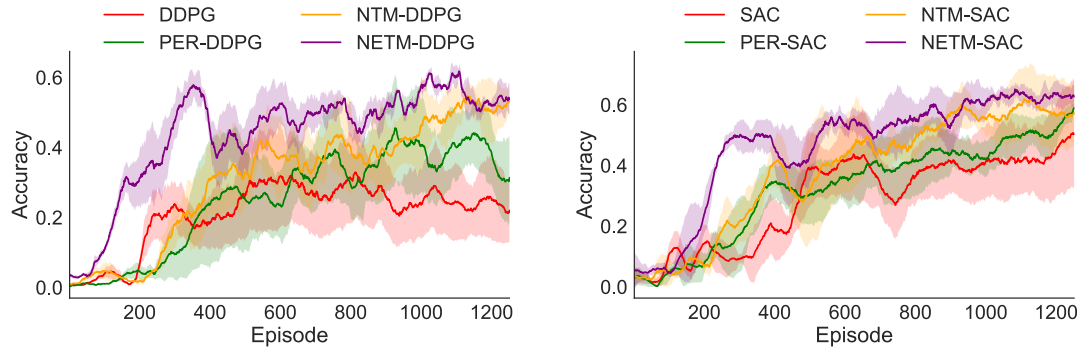
中国知网 https://www.cnki.net

经网络动态调整两种经验在算法学习过程中的比例。

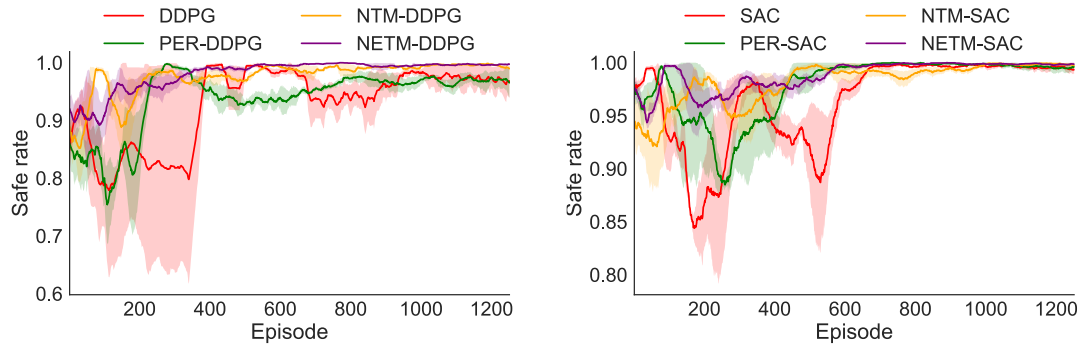
另外，在 PER-DRL 中，优先级采样指数α_{per}的选择对算法的性能有很大影响，因此，本章选择不同α_{per}进行实验，然后只展示性能最优时的 PER-DRL。对于每一种方法，本章汇报了 3 个随机种子下算法的平均表现。图 4.6 和图 4.7 为场景 1 和场景 2 中不同算法训练时的性能对比图，表 4.2 为算法训练 1000 回合后的评价指标结果，其中R_c、A_c和S_c分别表示算法从第 1000 回合至训练结束时的平均回合累积奖励、平均准确率以及平均安全率。



(a) 回合奖励曲线



(b) 回合准确率曲线



(c) 回合安全率曲线

图 4.7 不同算法在场景 2 中的性能对比

中国知网 https://www.cnki.net

表 4.2 不同算法评价指标结果

模型	场景 1			场景 2		
	R_c	A_c	S_c	R_c	A_c	S_c
DDPG	-1161	32.15%	98.81%	-2144	22.18%	97.40%
PER-DDPG	-885	43.22%	99.80%	-1209	34.30%	96.93%
NTM-DDPG	-804	44.68%	99.42%	-856	50.76%	99.57%
NETM-DDPG	**-405**	**59.93%**	**99.80%**	**-616**	**55.89%**	**99.68%**
SAC	-701	61.43%	99.88%	-939	43.35%	99.58%
PER-SAC	-596	63.26%	99.82%	-808	50.26%	99.65%
NTM-SAC	-565	67.25%	99.85%	-636	57.94%	99.86%
NETM-SAC	**-360**	**70.51%**	**99.96%**	**-500**	**62.69%**	**99.86%**

（1）如图 4.6、4.7 及表 4.2 所示，对于两个场景，所有基于 NETM 的 DRL 算法都显示出了比基准算法更快的收敛速度、更高的准确率以及安全率。从回合奖励中可以看出，在训练前期阶段，NETM-DDPG 和 NETM-SAC 的回合奖励值都迅速达到了较高的水平。这表明，自增专家经验回放池中所扩增经验数据的质量已经达到了专家水平，能够给机械臂提供良好的专家策略引导，使机械臂在极短的时间内学会动态避障策略。

（2）NETM-DRL 在场景 2 中的加速效果优于其在场景 1 中的加速效果，这是因为场景 2 中的目标是动态的，任务比较复杂，原始 DRL 算法很难学习到有效的轨迹规划策略。这就会导致在训练时，算法的经验回放池里充斥着低质量的数据，致使机械臂无法找到更高的累积奖励，而 NETM-DRL 通过源源不断地为机械臂提供大量高质量的专家数据解决了这个问题。

（3）在训练后期，NETM-DRL 所获得的累积奖励值是最高的。除了专家策略的引导外，还因为在 DRL 训练中存在一种链式效应（Chain Effect），即算法前期性能的提升会链式地影响到算法中后期的训练性能，使算法能够获得更高的累积奖励值。最后，两种场景下的准确率以及安全率进一步验证了专家经验引导的有效性。

（4）除 NETM-DRL 之外，NTM-DDPG 和 NTM-SAC 的提升效果是最高的，这表明在训练的不同阶段，按照不同比例动态学习成功和失败经验能够提高经验数据的利用率，对机械臂的训练很有帮助。尽管在场景 1 中，NTM-DRL 前期收敛速度相较于 PER-DRL 和原始 DRL 较慢，这是因为在训练前期，NTM-DRL 还没有学到一个好的抽样比例，但最终 NTM-DRL 的表现性能是最优的。

中国知网 https://www.cnki.net

（二）经验回放机制时间复杂度对比

接下来，本章从单个时间步长下的平均采样、平均更新和平均总时间三方面比较了 NETM-DDPG、PER-DDPG 和基准 DDPG 三类算法的时间复杂度。

表 4.3 不同算法时间复杂度对比

方法	总时间（ms）	采样时间（ms）	更新时间（ms）
NETM-DDPG	1356.21	6.17	1007.65
DDPG	1306.08	4.84	974.82
PER-DDPG	**1456.39**	**31.51**	**1269.87**

由表 4.3 可知，PER-DDPG 的时间复杂度最高，这是因为在采样阶段，PER-DDPG 根据优先级选择经验，并且 PER-DDPG 同时计算经验的重要性采样权重，以减少由优先级采样引入的偏差。在更新阶段，PER-DDPG 还需根据 TD 误差更新经验池中经验数据的优先级。

（三）奖励函数训练效果对比

最后，为了验证所提出改进奖励函数 IAPR 的可行性，本章基于使用 NETM 经验回放机制的 SAC 算法，就困难场景 2，采用原始奖励函数 APR 和改进奖励函数 IAPR 进行了对比实验。对于每一种方法，本节同样汇报了 3 个随机种子下算法的平均表现。图 4.8 展示了不同算法训练时的性能对比结果。

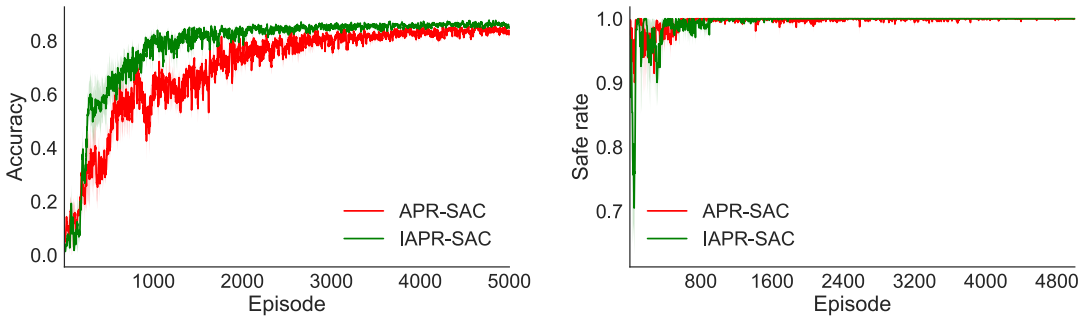


图 4.8 不同算法在困难场景 2 中的性能对比

如图 4.8 所示，IAPR-SAC 算法的性能相较于 APR-SAC 有明显提升。就准确率而言，IAPR-SAC 算法收敛速度要比 APR-SAC 更快、波动幅度更小，并且收敛后能获得较高的准确率。这是因为目标的位置一直在移动，当机械臂使用原始奖励函数时，没有考虑末端执行器与目标位置的速度，即使末端执行器在某一时间步进入目标位置附近区域，也可能会因为速度不同，在下一时间步被移动中的目标甩开，这就会降低任务的准确率，并且也会增加准确率的波动。而 IAPR 通过在奖励函数

中国知网 https://www.cnki.net

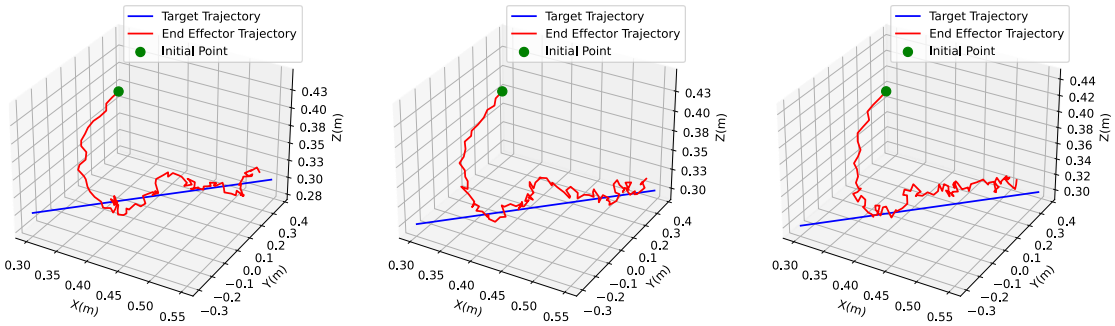
中加入末端执行器和目标位置的速度信息，使机械臂在追踪到目标位置的同时运动趋势也与之保持一致，提高了轨迹规划算法的性能。

另外，当机械臂处于目标位置附近时，d_T的变化会非常小，这会导致机械臂对末端执行器的细微位置变化不够敏感，同样也会加剧这种情况的发生。IAPR 中的附加奖励会增加机械臂对d_T微小变化的敏感性，进一步提高机械臂的性能。

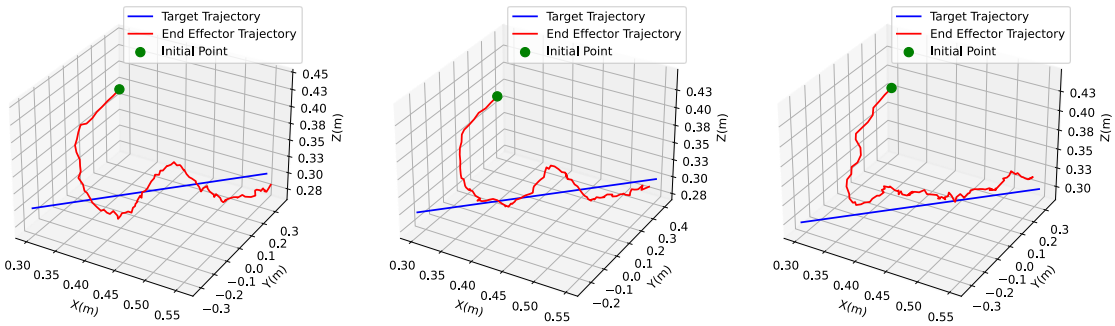
最后，尽管 IAPR-SAC 在训练前期阶段的安全率低于 APR-SAC 算法，但在训练 2000 回合后，IAPR-SAC 在不同随机种子下发生碰撞的平均回合数为 3，而 APR-SAC 则为 170。可以看出，取消动态障碍物斥力势场的范围，能够赋予机械臂全局感知障碍物的能力，进而使机械臂学习到有效的动态避障策略。

（四）奖励函数生成轨迹对比

此外，为了证明所提出奖励函数的实际效果，本章在相同条件下，基于 NETM-SAC 算法，分别采用 IAPR 与 APR 进行了多次仿真，然后展示两种方法在准确率为 83%，安全率为 100%时所规划出的路径。如图 4.9 所示，每种方法选取了三组具有代表性的仿真结果。



(a) 原始奖励函数 APR



(b) 改进奖励函数 IAPR

图 4.9 不同算法生成轨迹质量对比

图中绿色原点表示机械臂末端执行器初始位置，红色线是算法为末端执行器规划的轨迹，蓝色线为目标的轨迹。可以看出，在准确率和安全率相同的情况下，

中国知网 https://www.cnki.net

基于 IAPR 奖励函数的深度强化学习算法所规划出的路径更为平滑且自然。

4.4 本章小结

本章针对现有基于深度强化学习的机械臂避障轨迹规划方法获取专家策略困难、经验利用率低以及奖励函数设计不合理所导致的算法收敛慢、收敛性能差及生成轨迹质量不佳的问题，提出了一种基于深度强化学习的机械臂动态避障轨迹规划框架，包括基于神经网络的专家引导三重经验回放机制 NETM 以及一种改进奖励函数 IAPR。其中，NETM 能够结合生成对抗模仿学习，将少量人类演示及算法训练中产生的成功经验扩增为大量专家经验，降低了专家策略的获取难度。NETM 还通过神经网络自主调整成功、失败以及专家经验在算法学习中的比例，提高了经验数据的利用率。另外，IAPR 取消了动态障碍物的斥力作用范围，引入了动态目标的速度信息。使机械臂与目标点运动趋势保持一致的同时，也为机械臂提供了全局感知能力。在不同场景中的实验结果表明，所提出的框架能够加快算法的收敛速度，提高收敛后的性能及生成轨迹的质量。

中国知网 https://www.cnki.net

第5章 总结与展望

本文主要研究了动态环境下的机械臂碰撞检测与轨迹规划问题，在本章中，对本工作进行总结以及对未来研究方向和内容进行展望。

5.1 本文总结

随着社会的进步和技术的发展，机械臂在复杂动态环境中的应用越来越广泛，其重要性也日益凸显。本文以机械臂为研究对象，针对其在动态环境下的避障轨迹规划问题，从碰撞检测与轨迹规划两个层面对算法进行了改进。并通过 Pybullet 仿真软件搭建了四种碰撞检测仿真环境和两种轨迹规划仿真环境，验证了本文所提出算法的有效性。论文主要完成了以下工作：

（1）本文提出了一种基于关系子图神经网络的碰撞检测方法 RSGNet。首先，本文将机械臂和周围障碍物建模为图数据，通过图中节点与边的特征，保存它们的相对位置信息及拓扑信息。其次，通过将机械臂和障碍物整图分割为若干子图对，本文将全局碰撞距离学习问题转化为了子图对间的局部碰撞距离学习问题，降低了碰撞距离函数学习难度的同时，也提高了算法的泛化能力。最后，在估计子图对间的碰撞距离时，本文使用注意力机制寻找含有最大碰撞距离信息的节点以构建关系连通图，并通过关系图上的消息传递，不断聚合机械臂与障碍物子图的碰撞信息，以精确估计碰撞距离。本模型在四种碰撞检测仿真环境中进行了测试，MSE、Accuracy 以及 Safe_FPR 等评估结果表明，仅在一个环境中训练的 RSGNet，在碰撞距离回归误差和碰撞检测准确性上的表现就优于对特定环境单独训练的基线方法。在机械臂轨迹规划任务中的实际应用也进一步验证了设计的合理性。

（2）本文提出了一种基于深度强化学习的机械臂动态避障轨迹规划框架，包括基于神经网络的专家引导三重经验回放机制 NETM 以及一种改进奖励函数 IAPR。首先，NETM 结合生成对抗模仿学习，可以将少量人工示教数据及算法产生的成功经验数据扩增为大量专家经验。得益于 DRL 算法的策略优化能力，所生成专家经验数据的质量也在不断优化。同时，NETM 中的经验采样策略根据 DRL 训练的不同阶段，按不同比例抽取专家经验及算法自身产生的经验进行学习，提高了经验利用率。其次，IAPR 对基于人工势场法思想设计的奖励函数进行了改进，取消了动态障碍物斥力势场的作用范围，并在引力势场中加入了动态目标的速度信息。在轨迹规划仿真环境中的实验表明，本框架生成的专家经验数据质量相对较高，完全能满足 DRL 算法的训练需求，通过结合经验采样策略，本框架能够为 DRL

中国知网 https://www.cnki.net

带来较强的引导效果，从而提高算法的收敛速度及最终收敛性能。此外，本框架中对奖励函数的改进，也提升了生成轨迹的质量，使其更加平滑且自然。

5.2 研究展望

本项工作从碰撞检测和轨迹规划两个方面研究了动态环境下机械臂的避障轨迹规划问题。尽管已经取得了一定的成果，但仍存在一些有待改进的方面：

（1）虽然 RSGNet 的泛化能力在完全由已知（经过充分训练）子图形状组成的环境中得到了验证，但其在含有未知形状的环境中尚未得到充分研究。所以，未来的研究还需提高 RSGNet 在面对未知形状时的泛化能力。例如扩展训练数据集、使用数据增强技术或添加处理未知形状的技术等。

（2）由第三章消融实验可知，RSGNet 中信息节点的数量n_{IE}为最小值 2 时，模型所构建的信息传输通道就已经有足够能力传输两个子图间所有含碰撞距离的信息。所以本文猜想，在不影响性能的前提下，还能继续减少信息传输通道的数量，信息传输通道数量的减少会进一步降低关系连通图的复杂性，减小模型更新的成本，加快模型的推理速度。因此，未来的研究还需寻找一种新的关系图构建方法，以进一步加快模型的推理速度。

（3）尽管本章所提出的奖励函数 IAPR 能够生成较短的轨迹，但 IAPR 并没有考虑机械臂的能量最优问题，即最大惯量关节运动最小的问题，因此，未来的研究还需寻找一种能考虑能量最优问题的轨迹规划方法。

中国知网 https://www.cnki.net

参考文献

[1] 中国电子学会. 中国机器人产业发展报告[R]. 2022.

[2] 孙燕妮,白晓军.《中国制造 2025》——中国特色的强国战略[J].智能制造,2020,(10):43-45.

[3] Barbosa W S, Gioia M M, Natividade V G, et al. Industry 4.0: examples of the use of the robotic arm for digital manufacturing processes[J]. International Journal on Interactive Design and Manufacturing (IJIDeM), 2020, 14: 1569-1575.

[4] Lin H I. Design of an intelligent robotic precise assembly system for rapid teaching and admittance control[J]. Robotics and Computer-Integrated Manufacturing, 2020, 64: 101946.

[5] Alterovitz R, Koenig S, Likhachev M. Robot planning in the real world: Research challenges and opportunities[J]. Ai Magazine, 2016, 37(2): 76-84.

[6] Xian W, Yu K, Han F, et al. Advanced manufacturing in industry 5.0: A survey of key enabling technologies and future trends[J]. IEEE Transactions on Industrial Informatics, 2023, 20(2): 1055-1068.

[7] 张峥.工业机器人的智能化发展探究[J].中国军转民,2022,(18):82-83.

[8] Zhao C, Zhu Y, Du Y, et al. A novel direct trajectory planning approach based on generative adversarial networks and rapidly-exploring random tree[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 17910-17921.

[9] Zhang Q, Liu F, Li B. A heuristic tomato-bunch harvest manipulator path planning method based on a 3D-CNN-based position posture map and rapidly-exploring random tree[J]. Computers and Electronics in Agriculture, 2023, 213: 108183.

[10] Ning YM, Li T, Yao C, et al. HMS-RRT: A novel hybrid multi-strategy rapidly-exploring random tree algorithm for multi-robot collaborative exploration in unknown environments[J]. Expert Systems with Applications, 2024, 247: 123238.

[11] Chen G, Luo N, Liu D, et al. Path planning for manipulators based on an improved probabilistic roadmap method[J]. Robotics and Computer-Integrated Manufacturing, 2021, 72: 102196.

[12] Jang K, Baek J, Park S, et al. Motion planning for closed-chain constraints based on probabilistic roadmap with improved connectivity[J]. IEEE/ASME Transactions on Mechatronics, 2022, 27(4): 2035-2043.

[13] Lambert A, Hou B, Scalise R, et al. Stein variational probabilistic roadmaps[C]//2022

中国知网 https://www.cnki.net

International Conference on Robotics and Automation (ICRA). IEEE, 2022: 11094-11101.

[14] Park S O, Lee M C, Kim J. Trajectory planning with collision avoidance for redundant robots using jacobian and artificial potential field-based real-time inverse kinematics[J]. International Journal of Control, Automation and Systems, 2020, 18(8): 2095-2107.

[15] Xu TY, Zhou H, Tan S, et al. Mechanical arm obstacle avoidance path planning based on improved artificial potential field method[J]. Industrial Robot: the international journal of robotics research and application, 2022, 49(2): 271-279.

[16] Gottardi A, Tortora S, Tosello E, et al. Shared control in robot teleoperation with improved potential fields[J]. IEEE Transactions on Human-Machine Systems, 2022, 52(3): 410-422.

[17] Chen PZ, Pei J, Lu W, et al. A deep reinforcement learning based method for real-time path planning and dynamic obstacle avoidance[J]. Neurocomputing, 2022, 497: 64-75.

[18] Kim J, Park F C. PairwiseNet: Pairwise Collision Distance Learning for High-dof Robot Systems[C]//Conference on Robot Learning. PMLR, 2023: 2863-2877.

[19] Verghese M, Das N, Zhi Y, et al. Configuration space decomposition for scalable proxy collision checking in robot planning and control[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 3811-3818.

[20] Muñoz J, Lehner P, Moreno L E, et al. CollisionGP: gaussian process-based collision checking for robot motion planning[J]. IEEE Robotics and Automation Letters, 2023, 8(7): 4036-4043.

[21] Varghese N V, Mahmoud Q H. Optimization of deep reinforcement learning with hybrid multi-task learning[C]//2021 IEEE International Systems Conference (SysCon). IEEE, 2021: 1-8.

[22] Bing Z, Zhou H, Li R, et al. Solving robotic manipulation with sparse reward reinforcement learning via graph-based diversity and proximity[J]. IEEE Transactions on Industrial Electronics, 2022, 70(3): 2759-2769.

[23] Cheng YH, Chen L, Chen C L P, et al. Off-policy deep reinforcement learning based on Steffensen value iteration[J]. IEEE Transactions on Cognitive and Developmental Systems, 2020, 13(4): 1023-1032.

[24] Zhou DX, Jia R, Yao H, et al. Robotic arm motion planning based on residual reinforcement learning[C]//2021 13th International Conference on Computer and Automation Engineering (ICCAE). IEEE, 2021: 89-94.

中国知网 https://www.cnki.net

[25] Huang ZY, Wu J, Lv C. Efficient deep reinforcement learning with imitative expert priors for autonomous driving[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 34(10): 7391-7403.

[26] Ying FK, Liu H, Jiang R, et al. Trajectory generation for multiprocess robotic tasks based on nested dual-memory deep deterministic policy gradient[J]. IEEE/ASME Transactions on Mechatronics, 2022, 27(6): 4643-4653.

[27] Ruan X, Lin C, Huang J, et al. Obstacle avoidance navigation method for robot based on deep reinforcement learning[C]//2022 IEEE 6th Information Technology and Mechatronics Engineering Conference (ITOEC). IEEE, 2022, 6: 1633-1637.

[28] Han RH, Chen S, Wang S, et al. Reinforcement learned distributed multi-robot navigation with reciprocal velocity obstacle shaped rewards[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 5896-5903.

[29] Tracy K, Howell T A, Manchester Z. Differentiable collision detection for a set of convex primitives[C]//2023 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2023: 3663-3670.

[30] Gilbert E G, Johnson D W, Keerthi S S. A fast procedure for computing the distance between complex objects in three-dimensional space[J]. IEEE Journal on Robotics and Automation, 1988, 4(2): 193-203.

[31] Hubbard P M. Approximating polyhedra with spheres for time-critical collision detection[J]. ACM Transactions on Graphics (TOG), 1996, 15(3): 179-210.

[32] Klosowski J T, Held M, Mitchell J S B, et al. Efficient collision detection using bounding volume hierarchies of k-DOPs[J]. IEEE transactions on Visualization and Computer Graphics, 1998, 4(1): 21-36.

[33] Lauterbach C, Garland M, Sengupta S, et al. Fast BVH construction on GPUs[C]//Computer Graphics Forum. Oxford, UK: Blackwell Publishing Ltd, 2009, 28(2): 375-384.

[34] Zellmann S, Hellmann M, Lang U. A linear time BVH construction algorithm for sparse volumes[C]//2019 IEEE Pacific Visualization Symposium (PacificVis). IEEE, 2019: 222-226.

[35] Pan J, Manocha D. Efficient configuration space construction and optimization for motion planning[J]. Engineering, 2015, 1(1): 046-057.

[36] Pan J, Manocha D. Fast probabilistic collision checking for sampling-based motion planning using locality-sensitive hashing[J]. The International Journal of Robotics Research, 2016, 35(12): 1477-1496.

[37] Huh J, Lee D D. Learning high-dimensional mixture models for fast collision

中国知网 https://www.cnki.net

detection in rapidly-exploring random trees[C]//2016 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2016: 63-69.

[38] Zhi Y, Das N, Yip M. Diffco: Autodifferentiable proxy collision detection with multiclass labels for safety-aware trajectory optimization[J]. IEEE Transactions on Robotics, 2022, 38(5): 2668-2685.

[39] Das N, Yip M C. Stochastic modeling of distance to collision for robot manipulators[J]. IEEE Robotics and Automation Letters, 2020, 6(1): 207-214.

[40] Chase Kew J, Ichter B, Bandari M, et al. Neural collision clearance estimator for batched motion planning[C]//International Workshop on the Algorithmic Foundations of Robotics. Cham: Springer International Publishing, 2020: 73-89.

[41] Cao Y, Zhou J, Cao F, et al. DistFormer: A High-Accuracy Transformer-Based Collision Distance Estimator for Robotic Arms[C]//2023 9th International Conference on Control Science and Systems Engineering (ICCSSE). IEEE, 2023: 178-184.

[42] Wang HN, Liu N, Zhang Y, et al. Deep reinforcement learning: a survey[J]. Frontiers of Information Technology & Electronic Engineering, 2020, 21(12): 1726-1744.

[43] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning[J]. arXiv preprint arXiv:1312.5602, 2013.

[44] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. nature, 2015, 518(7540): 529-533.

[45] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2016, 30(1).

[46] Wang Z, Schaul T, Hessel M, et al. Dueling network architectures for deep reinforcement learning[C]//International conference on machine learning. PMLR, 2016: 1995-2003.

[47] Schaul T, Quan J, Antonoglou I, et al. Prioritized experience replay[J]. arXiv preprint arXiv:1511.05952, 2015.

[48] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:1509.02971, 2015.

[49] Mnih V, Badia A P, Mirza M, et al. Asynchronous methods for deep reinforcement learning[C]//International conference on machine learning. PMLR, 2016: 1928-1937.

[50] Duan J, Guan Y, Li S E, et al. Distributional soft actor-critic: Off-policy reinforcement learning for addressing value estimation errors[J]. IEEE transactions on neural networks and learning systems, 2021, 33(11): 6584-6598.

中国知网 https://www.cnki.net

[51] Zhou X, Zhang X, Zhao H, et al. Constrained soft actor-critic for energy-aware trajectory design in uav-aided iot networks[J]. IEEE Wireless Communications Letters, 2022, 11(7): 1414-1418.

[52] Rashid T, Samvelyan M, De Witt C S, et al. Monotonic value function factorisation for deep multi-agent reinforcement learning[J]. Journal of Machine Learning Research, 2020, 21(178): 1-51.

[53] Lowe R, Wu Y I, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[J]. Advances in neural information processing systems, 2017, 30.

[54] Yu C, Velu A, Vinitsky E, et al. The surprising effectiveness of ppo in cooperative multi-agent games[J]. Advances in Neural Information Processing Systems, 2022, 35: 24611-24624.

[55] Foerster J, Farquhar G, Afouras T, et al. Counterfactual multi-agent policy gradients[C]//Proceedings of the AAAI conference on artificial intelligence. 2018, 32(1).

[56] Han D, Mulyana B, Stankovic V, et al. A survey on deep reinforcement learning algorithms for robotic manipulation[J]. Sensors, 2023, 23(7): 3762.

[57] Gu SX, Lillicrap T, Sutskever I, et al. Continuous deep q-learning with model-based acceleration[C]//International conference on machine learning. PMLR, 2016: 2829-2838.

[58] Mahmood A R, Korenkevych D, Vasan G, et al. Benchmarking reinforcement learning algorithms on real-world robots[C]//Conference on robot learning. PMLR, 2018: 561-591.

[59] Lim J, Ha S, Choi J. Prediction of reward functions for deep reinforcement learning via Gaussian process regression[J]. IEEE/ASME Transactions on Mechatronics, 2020, 25(4): 1739-1746.

[60] Qi GJ, Li Y. Reinforcement learning control for robot arm grasping based on improved DDPG[C]//2021 40th Chinese Control Conference (CCC). IEEE, 2021: 4132-4137.

[61] Li XJ, Liu H, Dong M. A general framework of motion planning for redundant robot manipulator based on deep reinforcement learning[J]. IEEE Transactions on Industrial Informatics, 2021, 18(8): 5253-5263.

[62] Ma RD, Oyekan J. Guiding Deep Reinforcement Learning by Modelling Expert's Planning Behavior[C]//2021 7th International Conference on Control, Automation and Robotics (ICCAR). IEEE, 2021: 321-325.

中国知网 https://www.cnki.net

[63] Ying FK, Liu H, Jiang R, et al. Extensively explored and evaluated actor-critic with expert-guided policy learning and fuzzy feedback reward for robotic trajectory generation[J]. IEEE Transactions on Industrial Informatics, 2022, 18(11): 7749-7760.

[64] Zhou J, Cui G, Hu S, et al. Graph neural networks: A review of methods and applications[J]. AI open, 2020, 1: 57-81.

[65] Waikhom L, Patgiri R. A survey of graph neural networks in various learning paradigms: methods, applications, and challenges[J]. Artificial Intelligence Review, 2023, 56(7): 6295-6364.

[66] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv preprint arXiv:1609.02907, 2016.

[67] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.

[68] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C]//The semantic web: 15th international conference, ESWC 2018, Heraklion, Crete, Greece, June 3–7, 2018, proceedings 15. Springer International Publishing, 2018: 593-607.

[69] Bahdanau D, Brakel P, Xu K, et al. An actor-critic algorithm for sequence prediction[J]. arXiv preprint arXiv:1607.07086, 2016.

[70] Figueroa Fernandez N B, Mirrazavi Salehian S S, Billard A. Multi-Arm Self-Collision Avoidance: A Sparse Solution for a Big Data Problem[C]//Proceedings of the Third Machine Learning in Planning and Control of Robot Motion (MLPC) Workshop. 2018.

[71] Rakita D, Mutlu B, Gleicher M. RelaxedIK: Real-time Synthesis of Accurate and Feasible Robot Arm Motion[C]//Robotics: Science and Systems. 2018, 14: 26-30.

[72] Bhardwaj M, Sundaralingam B, Mousavian A, et al. Storm: An integrated framework for fast joint-space model-predictive control for reactive manipulation[C]//Conference on Robot Learning. PMLR, 2022: 750-759.

[73] Koptev M, Figueroa N, Billard A. Real-time self-collision avoidance in joint space for humanoid robots[J]. IEEE Robotics and Automation Letters, 2021, 6(2): 1240-1247.

[74] Kim Y, Kim J, Park D. GraphDistNet: A graph-based collision-distance estimator for gradient-based trajectory optimization[J]. IEEE Robotics and Automation Letters, 2022, 7(4): 11118-11125.

[75] Serafini M, Guan H. Scalable graph neural network training: The case for sampling[J]. ACM SIGOPS Operating Systems Review, 2021, 55(1): 68-76.

中国知网 https://www.cnki.net

[76] Osa T, Esfahani A M G, Stolkin R, et al. Guiding trajectory optimization by demonstrated distributions[J]. IEEE Robotics and Automation Letters, 2017, 2(2): 819-826.

[77] Ho J, Ermon S. Generative adversarial imitation learning[J]. Advances in neural information processing systems, 2016, 29.

[78] Chen S, Yan D, Zhang Y, et al. Live working manipulator control model based on dppo-dqn combined algorithm[C]//2019 IEEE 4th Advanced Information Technology, Electronic and Automation Control Conference (IAEAC). IEEE, 2019: 2620-2624.

[79] Xiang Y, Wen J, Luo W, et al. Research on collision-free control and simulation of single-agent based on an improved DDPG algorithm[C]//2020 35th Youth Academic Annual Conference of Chinese Association of Automation (YAC). IEEE, 2020: 552-556.

[80] Qi C R, Yi L, Su H, et al. Pointnet++: Deep hierarchical feature learning on point sets in a metric space[J]. Advances in neural information processing systems, 2017, 30.

中国知网 https://www.cnki.net