

北京航空航天大学学报
Journal of Beijing University of Aeronautics and Astronautics
ISSN 1001-5965,CN 11-2625/V

《北京航空航天大学学报》网络首发论文

题目：基于分层深度强化学习的无人机混合路径规划
作者：吕超，李慕宸，欧家骏
DOI：10.13700/j.bh.1001-5965.2023.0550
收稿日期：2023-08-28
网络首发日期：2023-11-01
引用格式：吕超，李慕宸，欧家骏．基于分层深度强化学习的无人机混合路径规划[J/OL]．北京航空航天大学学报．https://doi.org/10.13700/j.bh.1001-5965.2023.0550



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于分层深度强化学习的无人机混合路径规划

吕超[1]，李慕宸[2]，欧家骏[3,✉]

（1. 北京航空航天大学 航空科学与工程学院，北京 100191；2. 战略支援部队航天系统部装备部装备项目管理中心，北京 100193
3. 北京航空航天大学 无人系统研究院，北京 100191）
✉通信作者 E-mail：oujiajun@buaa.edu.cn

摘要 无人机应用中需要在非净空环境中实现自主安全飞行，其中障碍物存在部分已知，部分未知的特点，需在基于已知障碍物进行全局路径规划的同时，开展针对未知障碍物的自主避障。为实现障碍物半已知环境下的安全飞行，提出基于分层深度强化学习的混合路径规划方法。该方法将自主感知避障和全局路径规划后趋向航迹点飞行两个无人机自主飞行中需要执行的子任务，利用分层模型有机结合，实现功能的有效复合。分层深度强化学习模型中，避障和导航两个子任务模型可分别单独训练，并通过两个训练后的模型对系统状态进行抽象，在此基础上训练顶层模型，实现对两个任务输出的有效调度。试验表明，所提出的分层深度强化学习方法，可在全局路径规划后趋向航迹点飞行和自主感知避障的子任务控制器基础上，实现功能扩展完成更为复杂的任务，可在降低模型训练难度的同时，保持了模型任务执行能力。

关键词 无人机；路径规划；自主避障；深度强化学习；分层模型
中图分类号 V219 文献标志码 A DOI: 10.13700/j.bh.1001-5965.2023.0550

UAV hybrid path planning based on hierarchical deep reinforcement learning

LYU Chao[1],LI MuChen[2],OU JiaJun[3,✉]

（1. School of Aeronautic Science and Engineering, Beihang University, Beijing 100191, China；

2. Equipment Project Management Center, Aerospace System Department of Strategic Support Force, Beijing 100193, China

3. Institute of Unmanned System, Beihang University, Beijing 100191, China）
✉E-mail: oujiajun@buaa.edu.cn

Abstract In the application of UAV, it is necessary to realize autonomous and safe flight in the non-clearance environment. For both known and unknown obstacles exist, it is necessary to carry out autonomous obstacle avoidance for unknown obstacles while making global path planning based on known obstacles. In order to realize safe flight in the semi-known environment of obstacles, a hybrid path planning method based on hierarchical deep reinforcement learning is proposed. This method organically combines autonomous perception obstacle avoidance and global path planning, which are two sub-tasks that UAV needs to perform in autonomous flight, to achieve effective combination of functions. In the hierarchical deep reinforcement learning model, the obstacle avoidance and navigation sub-task models can be trained separately, and the system state can be abstracted through the two trained models. On this basis, the top-level model can be trained to achieve effective scheduling of the two sub-task outputs. The experiment shows that the proposed hierarchical deep reinforcement learning method can achieve function expansion to complete more complex tasks based on the sub-task controllers. It can reduce the difficulty of model training while maintaining the ability of model task execution.
Key words UAV; path planning; autonomous obstacle avoidance; deep reinforcement learning; hierarchical model

无人机相对于常规有人驾驶飞行器，具备低成本、机动灵活、可损耗等优点，特别适宜于在危险、重复、枯燥的场景中应用，因此在军民领域发挥出了愈发重要的作用。在无人机技术不断发展的同时，其应用场景不断扩展，无人机需要到城市、森林和山区等存在障碍物的非净空环境中飞行。无

收稿日期：2023-08-28
网络首发时间：2023-11-01 14:10:37 网络首发地址：https://link.cnki.net/urlid/11.2625.V.20231101.1247.003

人机所面临的飞行环境越来越复杂，其中甚至存在大量未知的障碍物。无人机能否有效识别和利用障碍物信息，规划出合理的飞行路线，避免碰撞坠毁，不仅关系到无人机本身的安全和任务执行成败，更关系到周边人员和设施的安全。

无人机在非净空环境条件下实现安全飞行，需获得飞行路线上可能的障碍物信息，根据障碍物信息做出准确的路径规划。在实际应用环境中，受地图测绘和应用场景开发水平等因素限制，无人机飞行环境中的各类障碍物，实际应用场景中的障碍物信息在飞行前一般难以全面掌握，障碍物信息部分已知，部分未知。因此无人机的自主飞行过程包含两方面要素：基于已知障碍物的全局路径规划和针对未知障碍物的自主避障。

针对各类无人平台的路径规划问题，有关学者开展了大量研究工作。文献[1]基于改进的 A*算法实现路径规划。文献[2,3]将改进的 RRT 方法应用于无人机和机器人领域，实现路径规划。文献[4]将 SLAM 方法和人工势场法相结合，提出了一种室内机器人自主导航方法。文献[5]基于 SLAM 方法实现无人平台的自主感知与路径规划。文献[6,7]使用深度神经网络，学习路径规划的方法，实现对近似最优路径的获取。文献[8,9]基于深度强化学习方法，解决全局路径规划问题。

在自主避障方面，文献[10]根据传感器数据，从第一人称视角构建地图，并规划机器人的动作序列实现避障。文献[11]为实现避障能力，其提出了一种深度对抗 Q 神经网络，在从 RGB 图像生成的深度信息存在大量噪音的前提下，该网络机制可以在有效学习如何避障。文献[12]采用分层架构，利用强化学习训练模型获取避障策略，控制无人机动作实现自主飞行。文献[13]提出了一个基于演员-评论家模型的机器人避障导航模型。文献[14]利用全卷积残差网络对障碍物进行识别，得到深度图像并采用深度强化算法规划避障路径，同时构建环境的二维地图。

在前期研究中，有关学者一般将无人机自主飞行，分解为路径规划和自主感知避障两个单独问题进行研究。本文为实现无人机在半已知环境下的安全飞行，提出基于分层深度强化学习的无人机混合路径规划方法，兼顾全局路径规划和自主感知避障能力的实现，实现复合功能。

1 无人机混合路径规划问题描述

本文研究的无人机混合路径规划问题中，设定无人机飞行任务目标点已经预先获得，将飞行任务分解为两个子任务，分别是：基于趋向轨迹规划点飞行子任务和基于传感器数据进行自主避障子任务，两个子任务同时运行，并添加顶层控制器对子任务执行进行控制，完成无人机安全飞行的总任务目标，如图 1 所示。

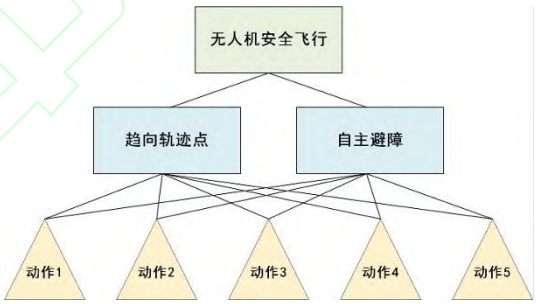


图 1 无人机混合路径规划架构
Fig.1 UAV hybrid path planning architecture

将无人机飞行任务定义为总任务 M，并将其分解为子任务集合 $\{M_0, M_1, M_2\}$。其中 M_0 定义为根（root）任务，其处在任务分层的顶层，即无人机在存在障碍物环境下的安全飞行任务。M_1 和 M_2 为子任务，分别为无人机向全局路径规划航迹点飞行任务，和无人机根据传感器数据自主避障任务，以元组 $\langle T_i, A_i, \overline{R}_i \rangle$ 定义子任务，具体定义如下：

（1）T_i 为子任务 M_i 的终止状态，对某一特定子任务而言，终止状态和活动状态 S_i 共同构成了系

统所有的状态集合 $\mathcal{S}$，当系统当前状态 $s \in S_i$ 时，子任务 M_i 的策略 π_i 执行，当系统状态进入 T_i 时，子任务 M_i 也终止。

（2）A_i 为子任务 M_i 的动作集合，不同子任务间的动作集合可以完全不同、部分相同甚至完全相同，M_i 的策略 π_i 在 A_i 中选取系统动作，用以更新系统状态。

（3）$\bar{R}_i$ 为子任务 M_i 的伪回报函数，表示子任务 M_i 执行动作 $a \in A_i$，子任务系统所获得的回报，由于子任务系统与整体系统存在差异，子任务回报与根任务回报不同，故而称为伪回报。伪回报用于子任务策略的学习过程，根任务的回报可与子任务回报关联，也可完全独立开。

2　混合路径规划模型设计

2.1 设计框架

利用分层深度强化学习，针对无人机在半已知环境下的安全飞行任务建立分层模型，模型设计框架如图 2 所示。无人机的自主安全飞行作为顶层任务，被划分为趋向全局路径规划轨迹点飞行，和根据传感器信息自主避障两个子任务。两个子任务学习得到的策略分别可以控制无人机选取不同的飞行动作进行执行，进而实现对无人机飞行轨迹的调整。无人机安全飞行任务作为顶层任务，其策略控制两个子任务策略的生效与否，实现无人机在趋向轨迹点飞行和开展自主避障两个子任务之间的实时调度。

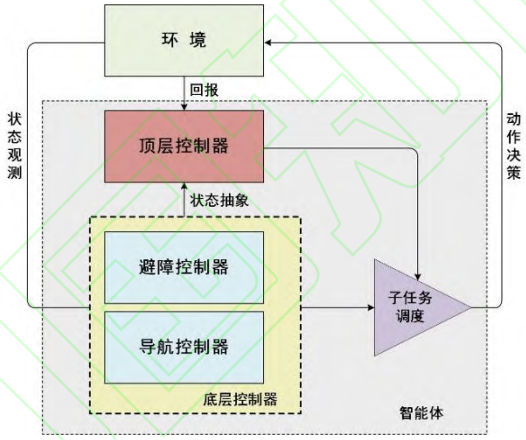


图 2 分层深度强化学习模型设计框架

Fig.2 The design framework of the hierarchical deep reinforcement learning model

无人机分层强化学习模型中包含趋向航迹点和自主避障两个子任务的底层控制器，两个底层控制器分别设计、建模、训练和并行执行。对任意一个子任务 M_i 而言，其决策过程可以看做马尔科夫决策过程，其模型可由一个四元组 $\left\langle \mathcal{S}_i, \mathcal{A}_i, \mathcal{P}_i^{\pi_i}, \mathcal{R}_i \right\rangle$ 表示。系统在子任务内运行，对动作空间内各个动作 $a \in A_i$ 进行评价，获得每个动作对应的 Q 值估计。根任务 M_0 决策过程为半马尔科夫决策过程，其运行根据状态输入，评估当前状态是否为某一子任务的终止状态 T_i，进而决策各子任务平稳状态持续时间。

2.2 控制器设计

混合路径控制器模型基于分层深度强化学习模型设计，包含两个底层控制器，分别为避障控制器和导航控制器，对应于自主避障和趋向航迹点飞行两个子任务的执行，两个子任务共享相同的无人机动作空间。另有一个顶层控制器，负责两个子任务的调度，实现无人机的安全飞行。分层模型中，避障控制器和导航控制器将系统状态信息映射到动作空间中，以此实现子任务抽象，顶层控制器基于抽象后的信息，决策无人机最终飞行动作，如图 3 所示。

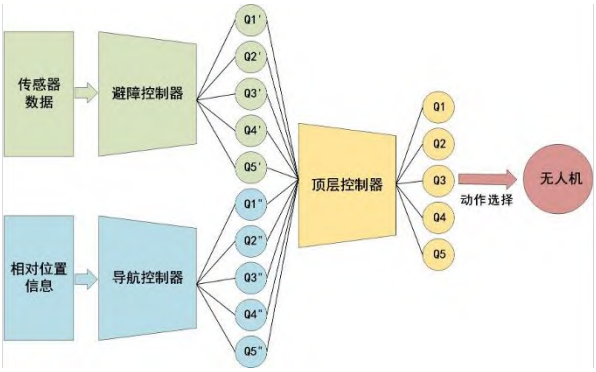


图 3 分层控制器示意图
Fig.3 The diagram of hierarchical controller

2.3 神经网络结构

控制器神经网络结构基于深度竞争循环双 Q 神经网络（D3RQN）设计，其融合了深度循环 Q 神经网络（DRQN）[15]、深度竞争 Q 神经网络（DuelingDQN）[16]和深度双 Q 神经网络（DoubleDQN）[17]的优势。D3RQN 结构如图 4 所示。具体网络结构在深度竞争 Q 神经网络的基础上，将最后一层全连接（FC）层替换为长短期记忆（LSTM）层。

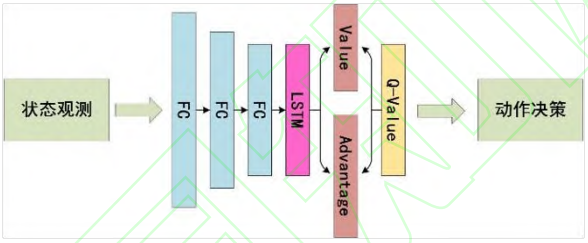


图 4 深度竞争循环双 Q 神经网络示意图
Fig.4 The diagram of the D3RQN

在深度竞争双 Q 循环神经网络中，优势（Advantage）函数和值（Value）函数被分别计算，最后共同构成对 Q 值的估计，可表示为：

$$Q^{\pi}(s,a)=A^{\pi}(s,a)+V^{\pi}(s) \tag{1}$$

式中，π 为控制策略，A 为优势函数，V 为值函数，s 和 a 分别为状态和动作。

针对部分可观马尔科夫决策过程（POMDP），系统状态 s 难以得到，仅能获得对系统状态 s 的观测 o，因此，以观测的集合来近似系统状态，可表示为：

$$\Omega_t=\left(o_0,o_1,o_2,\cdots,o_t\right) \tag{2}$$

式中，Ω_t 为 t 时刻前的观测集合，o_t 为 t 时刻时的观测。同时，结合深度竞争双 Q 循环神经网络中 LSTM 层可以处理序列数据的特点，t 时刻的值函数可表示为：

$$Q^{\pi}\left(\Omega_t,a_t\right)=A^{\pi}\left(\Omega_t,a_t\right)+V^{\pi}\left(\Omega_t\right) \tag{3}$$

深度竞争双 Q 循环神经网络采取与深度双 Q 神经网络相似的学习策略，分别建立当前网络和目标网络。基于这个设计，深度竞争双 Q 循环神经网络下损失函数公式设计如下：

$$\mathcal{L}_t(\theta)=\mathbb{E}_{\Omega_t,a_t,r_t,\Omega_{t+1}}\left[\left(y_t^{D3RQN}-Q\left(\Omega_t,a_t;\theta\right)\right)^2\right] \tag{4}$$

其中，

$$y_t^{D3RQN}=r_t+\gamma\max_{a_{t+1}}Q\left(\Omega_{t+1},a_{t+1};\theta^{-}\right) \tag{5}$$

上式中，θ 和 θ^{-} 分别为当前网络和目标网络参数。神经网络模型可以通过最小化损失函数来学习值函数估计，并基于学习得到的策略进行动作决策的如下：

$$a_t = \pi\left(\Omega_t\right) = \arg\max_a \hat{Q}\left(\Omega_t, a\right) \tag{6}$$

3　混合路径规划决策

3.1 状态空间与动作空间

基于分层深度强化学习的无人机混合路径规划针对二维平面内开展路径规划设计仿真环境，环境场景尺度为 640×480。无人机机载传感器数据、无人机位姿数据和目标航迹点坐标共同构成系统对环境的观测。无人机机载传感器选取前侧视激光雷达，其可直接获取特定方向上无人机与障碍物间的距离。激光雷达与无人机机体固连，采用 32 线束激光雷达，视场角为无人机机体坐标系前向正负 45 度，激光雷达最大探测距离 200，激光雷达示意图如图 5 所示。

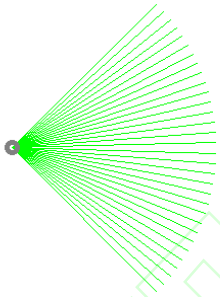


图 5 激光雷达示意图
Fig.5 The diagram of the lidar

无人机在飞行过程中保持恒定速度向前飞行，通过分层强化学习模型控制无人机飞行航向，控制无人机在飞行过程中实现避障并飞抵目标位置，无人机动作空间定义见表 1 所示，其中线速度单位定义为单位时间内无人机在地图图像上移动的图像像素距离。

表 1 无人机动作空间定义
Table 1　The definition of the UAV action space

动作编号	线速度	航向控制量（°）
1	（10，0，0）	0
2	（10，0，0）	+5
3	（10，0，0）	-5
4	（10，0，0）	+10
5	（10，0，0）	-10

3.2 控制器参数

3.2.1 避障控制器参数

避障控制器以 32 线束激光雷达数据为输入，对应避障控制器网络模型第一层输入尺度为 32。同时考虑激光雷达最远探测距离为 200，对传感器数据进行归一化，使得控制器输入在 0-1 之间。避障控制器网络模型主要参数见表 2。

表 2 避障控制器网络模型主要参数
Table 2 The parameters of obstacle avoidance controller

层号	类别	输入尺度	输出尺度	激活函数
1	FC	32	128	Relu
2	FC	128	128	Relu
3	FC	128	128	Relu
4	LSTM	128	128	-
5（A）	FC	128	5	Relu
5（V）	FC	128	1	Relu

3.2.2 导航控制器参数

导航控制器以无人机与目标点的相对位置作为输入，相对位置包含东向（x 轴向右）和北向（y 轴向上）两个分量。考虑到仿真环境的场景最大尺度，将无人机与目标点的相对位置参数除以 500 做近似归一化。导航控制器模型主要参数见表 3。

表 3 导航控制器网络模型主要参数
Table 3 The parameters of navigation controller

层号	类别	输入尺度	输出尺度	激活函数
1	FC	2	32	Relu
2	FC	32	32	Relu
3	FC	32	32	Relu
4	LSTM	32	32	-
5（A）	FC	32	5	Relu
5（V）	FC	32	1	Relu

3.2.3 顶层控制器参数

顶层控制器以两个底层控制器对各动作选项的 Q 值估计作为输入，将其重新映射到无人机的动作空间上，基于两个底层控制器子任务输出，对无人机最终动作进行宏观决策。顶层控制器模型主要参数见表 4 所示。

表 4 顶层控制器网络模型主要参数
Table 4 The parameters of top controller

层号	类别	输入尺度	输出尺度	激活函数
1	FC	10	128	Relu
2	FC	128	128	Relu
3	FC	128	128	Relu
4	LSTM	128	128	-
5（A）	FC	128	5	Relu
5（V）	FC	128	1	Relu

3.3 回报函数设计

3.3.1 避障回报函数

在无人机避障子任务中，系统所获得的回报定义如下：

$$R_{OA}=\begin{cases} d_{\text{nst}}, & \text{安全} \\ -10, & \text{碰撞} \end{cases} \tag{7}$$

其中，d_{nst} 为无人机到最近障碍物的距离，当无人机与最近障碍物的距离大于 20 时，认为无人机处在安全状态，当小于安全距离时，考虑无人机发生碰撞。

3.3.2 导航回报函数

在导航子任务中，无人机位置随着每个动作执行而更新，同时获得相应的回报，回报函数被定义为：

$$R_{Nav}=\begin{cases}10, & \text{到达}\\ K*(d_{curr}-d_{next}-d_{step}), & \text{其他}\end{cases} \tag{8}$$

其中，d_{curr} 是无人机当前位置和目标位置间的距离，d_{next} 是无人机下一步位置和目标位置之间的距离，d_{step} 是无人机动作步长。K 为常数，被定义为 0.1。根据回报函数的设计，无人机在达到目标位置前，所获得的回报总为负值，以避免进行无意义的徘徊。

3.3.3 顶层控制回报函数

顶层控制器混合了自主避障和趋向目标点飞行两种策略，无人机随着飞行动作的执行，获得的回报由避障和趋向目标点飞行两种策略同时组成，定义为：

$$R_{Hybrid}=R_{OA}+R_{Nav} \tag{9}$$

3.4 混合路径规划算法

基于分层深度强化学习的无人机混合路径规划算法实现过程见表 5。本算法以无人机的实时位置、观测数据及目标位置为输入。底层的避障控制器根据观测数据生成作为顶层控制器输入的 Q1 值；导航控制器根据无人机位置和目标位置同样生成作为顶层控制器输入的 Q2 值；顶层控制器根据 Q1、Q2 值选择最优动作，无人机执行该动作后到达下一位置。如此往复，直至到达目标点。

表5 基于分层深度强化学习的无人机混合路径规划算法

Table 5　UAV hybrid path planning based on hierarchical deep reinforcement learning

算法 1 基于分层强化学习的无人机混合路径规划算法（测试阶段）
输入：避障控制器模型、导航控制器模型和顶层控制器模型
输入：当前无人机位置 *L_c* 和目标位置 *L_g*
重设初始状体
路径 P=[L_c]
While *L_c* ≠ *L_g* do
获得当前观测 Ω
避障控制器根据当前观测 Ω 获得 Q1 值
导航控制器根据无人机位置 *L_c* 和目标位置 *L_g* 获得 Q2 值
顶层控制器根据 Q1 和 Q2 值选取最优动作 *a*
更新当前位置 *L_c* 并将其添加到路径中
End while
输出：路径 P

4　仿真验证

无人机混合路径规划仿真场景内可随机生成若干障碍物，障碍物数量、位置、尺寸可定义，无人机初始位姿和目标航迹点位置可随机生成。

4.1 训练设置

混合路径规划模型采用分步训练策略，首先训练两个底层控制器模型，分别实现自主避障和趋向目标点飞行功能，然后在底层模型的基础上训练顶层模型，实现混合路径规划目标。为实现基于分层强化学习的混合路径规划模型训练，针对自主避障、趋向目标点飞行和顶层混合策略三项内容训练分别设置了三个训练场景。三个场景分别对应训练模型避障、导航和顶层控制器能力，控制器训练参数见表 5。

（1）场景一：仿真训练场景要素包括无人机及机载传感器和障碍物，无人机在场景中自由飞行，要求在飞行过程中避开障碍物，并尽可能延长无碰撞飞行时间，旨在训练底层避障控制器性能。

（2）场景二：仿真场景中无障碍物，仅有无人机和目标点，无人机位姿和目标点初始位置在训练过程中不断随机生成，且位姿信息可被控制器获取，以此训练导航控制器，实现引导无人机抵达目标点的能力。

（3）场景三：针对混合路径规划顶层控制器，仿真场景中包含无障碍物、无人机和目标点，训练过程中障碍物固定不变，无人机位姿和目标点初始位置随机生成。利用在场景一和场景二中训练得到的子任务底层控制器，将系统状态信息抽象为对动作的两套 Q 估计值，将底层控制器进行抽象后的 Q 估计值作为顶层控制器的输入数据，训练顶层控制器对底层子任务的协同能力。

表 6 控制器训练参数

Table 6 The parameters of controller training

序号	参数名	场景一	场景二	场景三
1	地图尺度	640*480	640*480	640*480
2	障碍物数量	4	0	4
3	训练批量	64	64	32
4	折扣因子	0.99	0.99	0.99
5	学习率	1e-4	1e-4	1e-4
6	输入数据维度	32	2	34
7	动作时间间隔	0.5s	0.5s	0.5s
8	网络更新频率	400	400	400
9	优化器	Adam	Adam	Adam
10	优化器参数	[0.9,0.999,0]	[0.9,0.999,0]	[0.9,0.999,0]

4.2 训练及测试结果

4.2.1 自主避障

避障控制器训练曲线如图 6 所示。为了测试避障控制器的性能，采用障碍物数量、布置方式和尺寸与训练场景不同的测试场景，对避障控制器能力进行了测试，测试结果如图 7 所示，以红色细线显示无人机避障飞行轨迹，可见无人机飞行轨迹可自主绕开障碍物飞行。开展 1000 次避障飞行测试，设定无人机安全飞行 200 个时间步不发生碰撞，即认为单次飞行测试成功，最终结果为，无人机避障飞行成功率为 96.8%。

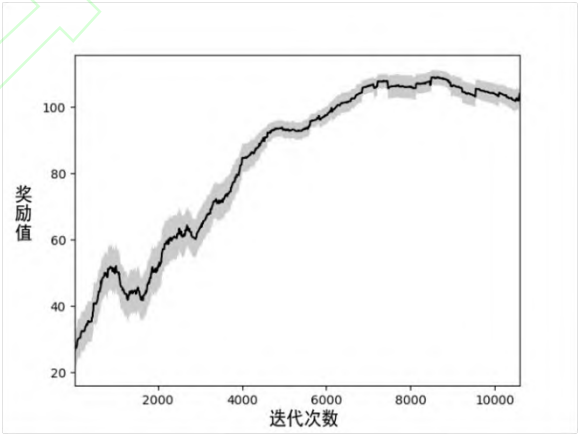


图 6 避障控制器训练曲线图

Fig.6 Training curve of obstacle avoidance controller

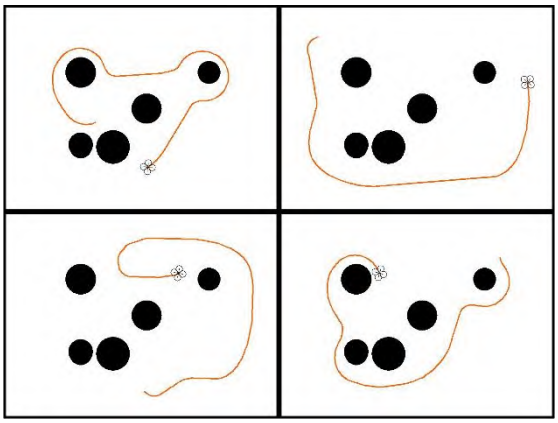


图 7 自主避障测试结果
Fig.7 Autonomous obstacle avoidance test results

4.2.2 导航控制

导航控制器训练曲线如图 8 所示，为了测试控制器引导无人机趋向目标点飞行的能力，测试过程中随机生成无人机位姿和目标点位置，对导航控制器能力进行了测试，测试结果如图 9 所示，无人机可快速飞行目标点。开展 1000 次导航飞行测试，设定当无人机在 200 步动作内飞抵目标点而不飞出地图边界时，即认为单次飞行测试成功，最终结果为，无人机导航飞行成功率为 99.9%。

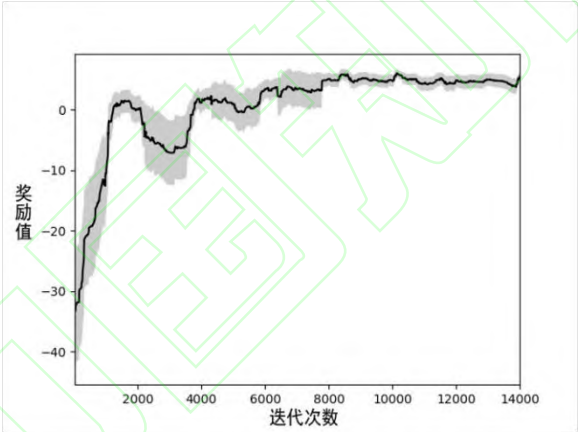


图 8 避障控制器训练曲线图
Fig.8 Training curve of navigation controller

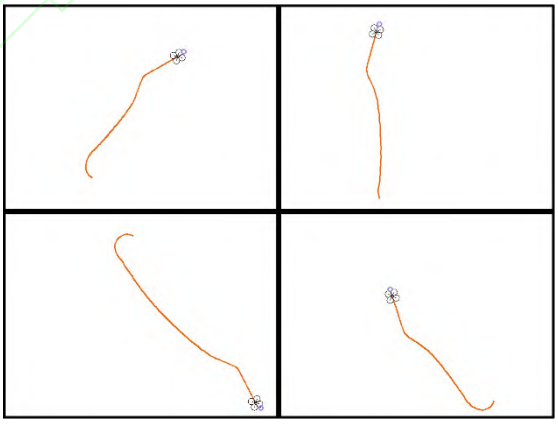


图 9 导航控制测试结果
Fig.9 Navigation test result

4.2.3 顶层控制

顶层控制器训练曲线如图 10 所示，为了测试顶层控制器的性能，采用障碍物数量、布置方式和尺寸与训练场景不同的测试场景，同时随机生成无人机位姿和目标点位置，同步测试无人机避障同时飞行目标点的能力，测试结果如图 11 所示。无人机在避开障碍物飞行的同时，完成路径规划达到目标点。开展 1000 次飞行测试，设定当无人机在 200 步动作内飞抵目标点而不飞出地图边界或与障碍物发生碰撞时，即认为单次飞行测试成功，最终结果为，无人机飞行成功率为 94.7%。

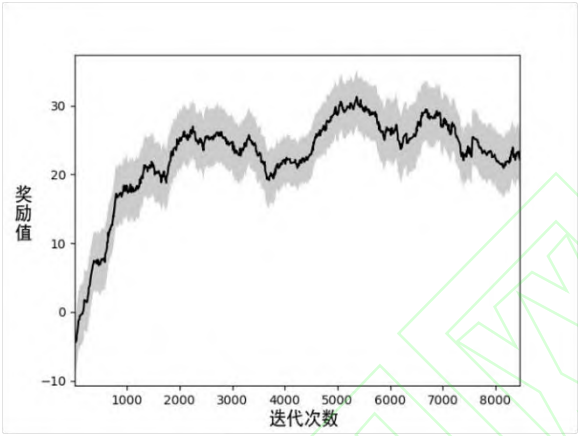


图 10 顶层控制器训练曲线图
Fig.10 Training curve of top controller

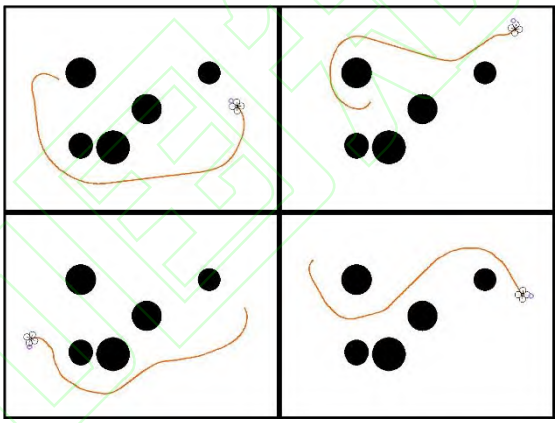
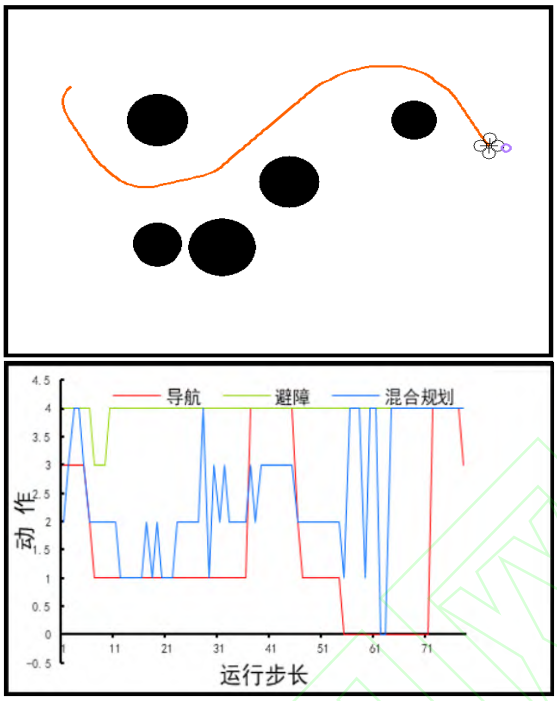


图 11 顶层控制测试结果
Fig.11 Top controller test results

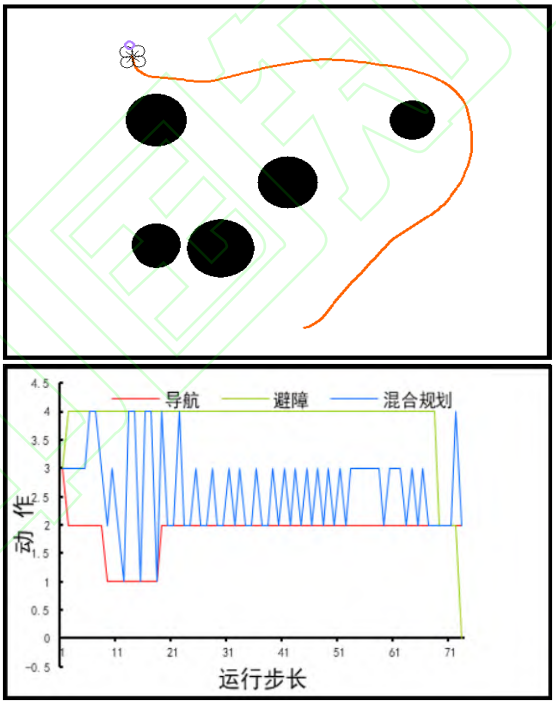
4.3 结果分析

试验结果显示，底层控制器模型可在仿真环境中独立完成避障和导航任务。利用底层控制器模型对系统状态的抽象信息，顶层控制器可调度两个底层模型，最终实现整个分层模型任务的实现。

在路径规划过程中分析各控制器决策，两个底层控制器根据场景情况，分别执行底层控制决策，顶层控制器根据具体情况，在两个底层控制器决策结果冲突时，做出独立判断，并实现最终任务目标，如图 12 所示。图中红色和绿色曲线分别代表底层导航控制器和底层避障控制器的输出，在靠近目标点飞行和避开障碍物飞行两种机制下，两个底层控制器的输出显然不同，甚至可能截然相反。而蓝色曲线代表顶层控制器的动作输出，其综合两个底层控制器的输出，复合后作出决策。顶层控制器在某些时刻可能选择与其中一个底层控制器输出保持一致，也可能与两个底层控制器输出完全相反。



（a）飞行轨迹1及对应动作决策



（b）飞行轨迹2及对应动作决策

图 12 飞行轨迹及各控制器动作决策
Fig.12 The path and action decision of each controller

此外，为了进一步证明所提算法的有效性。将本文所提算法与 RRT 算法进行对比。如图 13 所示，共设置 2 种场景，两种算法均可实现从绿色起点到红色目标点的全局路径规划，在过程中躲避黑色障碍物。与基于 RRT 的算法相比，本文所提算法执行效率更高，不需要大量搜索与试错，适应不同环境能力较强，且规划的路径更平滑。

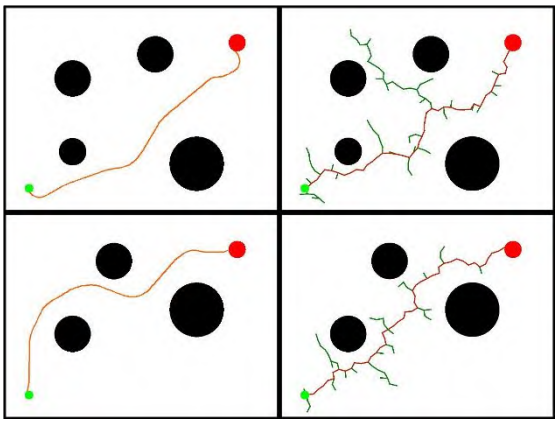


图 13 混合路径规划算法与 RRT 规划算法结果对比（左侧结果为本文所提算法，右侧为 RRT 算法）
Fig.13 Comparison of results of hybrid path planning algorithm and RRT planning algorithm□The results on the left are Hybrid path planning, the others are RRT algorithm□

分层模型体现了以下几点特点：

（1）状态抽象。通过底层控制器对系统状态进行抽象，顶层控制器根据对系统抽象的结果进行决策，系统当前状态下与所解决问题无关的状态将被忽略。

（2）迁移能力。分层模型本质上将问题进行分解，将任务分解为若干个小问题，并分而治之，先构建若干子任务功能模块，并复合这些模块实现最终目标。模块之间可根据任务目标进行灵活组合，或单独运行发挥作用。

（3）策略灵活。普通深度强化学习模型，在每个决策点，均需要根据策略进行决策，而分层强化学习模型可根据场景和任务，实现在不同策略间的自动切换，如避障和飞向目标点的策略切换，进而形成一个可根据场景灵活变化的策略。

5 结论

本文围绕无人机在存在障碍物的非净空环境下安全飞行问题，提出了一种基于分层深度强化学习的混合路径规划方法，使无人机在飞向目标位置的同时可自主避开障碍物，主要结论如下：

1）提了基于分层深度强化学习的混合路径规划方法，其将自主感知避障和全局路径规划后趋向航迹点飞行两个无人机自主飞行中需要执行的子任务，利用分层模型有机结合，实现功能的有效复合。

2）提出的分层深度强化学习模型中，避障和导航两个子任务控制器策略可分别单独训练，并通过两个训练后的控制器模型对系统状态进行抽象，在此基础上训练顶层控制器，实现对两个任务输出的有效调度。

3）本文提出的分层深度强化学习模型，可在子任务控制器基础上，实现功能扩展完成更为复杂的任务，进而在降低模型训练难度的同时，保持了模型任务执行能力。

在进一步的研究工作中，可以将更多的无人机功能扩展到分层模型中，实现更为复杂的无人机功能。

参考文献（References）

[1] 支琛博，张爱军，杜新阳，等．改进 A*算法的移动机器人全局路径规划研究[J]．计算机仿真，2023，40（2）：486-491．
ZHI CHENBO,ZHANG AIJUN,DU XINYANG et al.Research on global Path Planning of Mobile Robot with improved A* Algorithm [J].Computer Simulation,2023,40(2):486-491(in Chinese).

[2] 栾添添，王皓，孙明晓，等．基于动态变采样区域 RRT 的无人车路径规划[J]．控制与决策，2023，38（6）：1721-1729．
LUAN TIAN-TIAN,WANG HAO,SUN MING-XIAO et al.Path planning of unmanned vehicle based on dynamic variable sampling region RRT [J].Control and Decision,2023,38(6):1721-1729. (in Chinese)

[3] 李樾，韩维，陈清阳，等．基于快速扩展随机树算法的多无人机编队重构方法研究[J]．西北工业大学学报，2019，37（3）：601-611．
LI Y,HAN W,CHEN Q Y,et al.Research on Formation Reconfiguration of UAVs Based on RRT Algorithm[J].Journal of Northwestern Polytechnical University,2019,37(3):601-611(in Chinese).

[4] HARIK E H C,KORSAETH A,et al.Combining hector slam and artificial potential field for autonomous navigation inside a

greenhouse[J].Robotics,2018,7(2):1-20.
[5] C. Rhodes, C. Liu and W. -H. Chen. Autonomous Source Term Estimation in Unknown Environments: From a Dual Control Concept to UAV Deployment[J]. IEEE Robotics and Automation Letters,2022,7(2):2274-2281.
[6] YU X,WANG P,ZHANG Z.Learning-Based End-to-End Path Planning for Lunar Rovers with Safety Constraints[J].Sensors,2021,21(3):1-16.
[7] WU K,ESFAHANI M A,YUAN S,et al.TDPP-Net:Achieving three-dimensional path planning via a deep neural network architecture[J].Neurocomputing,2019,357:151–162.
[8] 黄昱洲，王立松，秦小麟．一种基于深度强化学习的无人小车双层路径规划方法[J]．计算机科学，2023，50（1）：194-204．
HUANG Y Z,WANG L S,QIN X L.Bi-level Path Planning Method for Unmanned Vehicle Based on Deep Reinforcement Learning[J].Computer Science,2023,50(1):194-204(in Chinese).
[9] 封硕，舒红，谢步庆．基于改进深度强化学习的三维环境路径规划[J]．计算机应用与软件，2021，38（1）：250-255．
FENG S,SHU H,XIE B Q.3D Environment Path Planning Based on Improved Deep Reinforcement Learning[J].Computer Applications and Software,2021,38(1):250-255(in Chinese).
[10] GUPTA S,DAVIDSON J,LEVINE S,et al.Cognitive mapping and planning for visual navigation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition.2017:2616-2625.
[11] XIE L,WANG S,MARKHAM A,et al.Towards monocular vision based obstacle avoidance through deep reinforcement learning[J].arXiv preprint arXiv:1706.09829,2017.
[12] SINGLA A,PADAKANDLA S,BHATNAGAR S.Memory-based deep reinforcement learning for obstacle avoidance in UAV with limited environment knowledge[J].IEEE transactions on intelligent transportation systems, 2019, 22(1): 107-118.
[13] ZHU Y,MOTTAGHI R, KOLVE E,et al.Target-driven visual navigation in indoor scenes using deep reinforcement learning[C]//2017 IEEE international conference on robotics and automation (ICRA).2017:3357-3364.
[14] WEN S, ZHAO Y, YUAN X, et al. Path planning for active SLAM based on deep reinforcement learning under unknown environments[J].Intelligent Service Robotics,2020:1–10.
[15] HAUSKNECHT M,STONE P.Deep recurrent q-learning for partially observable MDPS[C]//2015 AAAI Fall Symposium Series.2015:29-37.
[16] WANG Z,SCHAUL T,Hessel M,et al.Dueling network architectures for deep reinforcement learning[C]//International conference on machine learning.2016:1995-2003.
[17] VAN H H, GUEZ A,SILVER D.Deep reinforcement learning with double q-learning[C]//Proceedings of the AAAI conference on artificial intelligence. 2016, 30(1):2094-2100.