中图分类号：V249　　论文编号：1028703 23-SZ013
学科分类号：085400

硕士学位论文

基于卷积神经网络的四旋翼无人机视觉避障技术研究

研究生姓名　　梁 永 勋
专 业 类 别　　电 子 信 息
专 业 领 域
指 导 教 师　　龚 华 军　教授

南京航空航天大学
研究生院 自动化学院

二〇二三年六月

中国知网 https://www.cnki.net

Nanjing University of Aeronautics and Astronautics
The Graduate School
College of Automation Engineering

Research on Visual Obstacle Avoidance Technology of Quadrotor UAV Based on CNN

A Thesis in
Electronic Information

by

Liang Yongxun

Advised by

Prof. Gong Huajun

Submitted in Partial Fulfillment

of the Requirements

for the Degree of

Master of Engineering

June, 2023

中国知网 https://www.cnki.net

摘 要

四旋翼无人机由于其结构简单、飞行相对灵活等特点，能够在各种复杂的环境中进行飞行任务，因此被广泛地应用于农林植保、物流配送、航空摄影等领域。四旋翼无人机能够进行自主避障是进行其他飞行任务的前提，但是传统避障方法耗时长、计算负载大，限制了四旋翼无人机快速、安全的飞行，因此本文以卷积神经网络为基础，通过给四旋翼无人机搭载视觉采集设备，对四旋翼无人机避障飞行决策问题进行了探索和研究，主要研究内容如下：

首先，对四旋翼无人机视觉避障系统总体架构进行设计。基于单目相机为四旋翼无人机环境感知设备，设计了图像采集系统和无人机避障控制系统，无人机避障控制系统包括无人机防撞信息预测和无人机避障策略决策两部分；研究了四旋翼无人机自主避障所需的转向数据集和碰撞数据集，并搭建了碰撞帧更丰富的碰撞数据集。

其次，针对复杂环境下的无人机防撞信息预测问题。设计了基于 Swin Transformer 和 ResNet 的四旋翼无人机防撞预测与避障航向预测模型，通过输入图像采集系统预处理的环境图像，输出当前环境下避障所需的转向角度和碰撞概率；分析选择了预测模型的性能评估指标，与其他经典模型做了对比，结果显示本文模型在精度和预测时间上均表现优秀；通过在不同的真实场景中对模型进行测试，验证了模型的有效性。

然后，针对基于预测防撞信息的无人机避障策略决策问题。研究不同的滤波算法，使得预测模型输出结果平滑；结合预测模型输出的碰撞概率和转向角预测信息，研究不同障碍环境下的四旋翼无人机避障策略；在 ROS 操作系统设计了相应的无人机环境感知预测模块和无人机飞行控制模块，并在 Bebop 2 四旋翼无人机上进行实机测试，验证了本文避障方法的有效性。

最后，进行了四旋翼无人机避障系统性能分析与实飞验证。在不同的最大前向飞行速度条件下，进行了无人机防撞预测模型性能分析；对避障控制命令运行时间进行分析，相较于传统避障方法，本文的基于卷积神经网络的视觉避障方法计算时延更短；面对静止障碍物和移动障碍物环境，在 Bebop 2 四旋翼无人机上对本文设计的无人机避障系统进行了实飞验证。

关键词：四旋翼无人机，自主避障，卷积神经网络，Swin Transformer，单目相机

中国知网 https://www.cnki.net

ABSTRACT

Due to its simple structure and relatively flexible flight, quadrotor UAV can carry out flight tasks in various complex environments, so it is widely used in agriculture, forestry plant protection, logistics and distribution, aerial photography and other fields. Autonomous obstacle avoidance is a prerequisite for the quadcopter to accomplish other flight tasks, but the traditional obstacle avoidance method takes a long time and the calculation load is large, which limits the rapid and safe flight of quadcopter UAV, so this paper is based on convolutional neural network, by equipping quadcopter UAV with visual acquisition equipment, the quadcopter UAV obstacle avoidance flight decision-making problem is explored and studied, the main research content is as follows:

Firstly, the overall architecture of the quadrotor UAV visual obstacle avoidance system is designed. Based on the monocular camera as the quadcopter UAV environment perception equipment, the image acquisition system and UAV obstacle avoidance control system are designed, and the UAV obstacle avoidance control system includes two parts: UAV collision avoidance information prediction and UAV obstacle avoidance strategy decision-making. The steering data set and collision data set required for autonomous obstacle avoidance of quadcopter UAV were studied, and a richer collision data set with collision frames was constructed.

Secondly, it aims at the prediction problem of UAV collision avoidance information in complex environments. A quadrotor UAV collision avoidance prediction and obstacle avoidance heading prediction model based on Swin Transformer and ResNet is designed, and the steering angle and collision probability required for obstacle avoidance in the current environment are output by the environmental image preprocessed by the input image acquisition system. The performance evaluation index of the predictive model was selected and compared with other classical models, and the results showed that the proposed model performed well in accuracy and prediction time. By testing the model in different real-world scenarios, the effectiveness of the model is verified.

Then, the UAV obstacle avoidance strategy decision problem based on predictive collision avoidance information is determined. Different filtering algorithms are studied to smooth the output of the predictive model. Combined with the collision probability and steering angle prediction information output by the prediction model, the obstacle avoidance strategy of quadrotor UAV in different obstacle environments is studied. The corresponding UAV environment perception prediction module and UAV flight control module are designed in ROS operating system, and the actual test is carried out on Bebop 2 quadrotor UAV, which verifies the effectiveness of the obstacle

中国知网 https://www.cnki.net

avoidance method in this paper.

Finally, the performance analysis and flight verification of the obstacle avoidance system of the four-rotor UAV are carried out. The performance of UAV anti-collision prediction model is analyzed under different maximum forward flight speeds. The running time of obstacle avoidance control commands is analyzed. Compared with traditional obstacle avoidance methods, the convolutional neural network-based visual obstacle avoidance method in this paper has a shorter computation delay. In the face of sationary obstacles and moving obstacles, the UAV obstacle avoidance system designed in this paper is verified in real flight on a Bebop2 quadrotor UAV.

Keywords: Quadrotor UAV, Autonomous Obstacle Avoidance, Convolutional Neural Network, Swin Transformer, Monocular Camera

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 课题研究的目的和意义.....1
1.2 国内外研究现状.....3
1.2.1 四旋翼无人机研究现状.....3
1.2.2 基于视觉的无人机避障技术研究现状.....4
1.2.3 卷积神经网络研究现状.....6
1.3 本文的主要研究工作.....7
第二章 四旋翼无人机视觉避障系统总体架构.....9
2.1 四旋翼无人机硬件平台.....9
2.2 基于单目视觉的无人机避障系统整体架构.....9
2.3 无人机视觉避障相关理论.....12
2.3.1 四旋翼无人机飞行原理.....12
2.3.2 单目视觉理论.....14
2.3.3 卷积神经网络理论.....17
2.4 相关数据集研究.....20
2.5 本章小结.....21
第三章 无人机防撞预测与避障航向预测网络设计.....22
3.1 基于 Swin Transformer 和 Res Net 的预测模型设计.....22
3.1.1 Swin Transformer 网络.....23
3.1.2 Res Net 网络.....27
3.1.3 整体网络架构.....29
3.1.4 目标损失函数设计.....32
3.2 模型性能评估指标.....33
3.3 模型训练结果及分析.....34
3.3.1 数据预处理.....34
3.3.2 相关参数设置.....34
3.3.3 模型性能评估结果与分析.....34
3.3.4 真实场景测试.....37
3.4 本章小结.....41
第四章 基于碰撞概率和转向预测信息的无人机避障研究.....42
4.1 模型预测结果滤波算法研究.....42
4.1.1 滤波算法选择.....43
4.1.2 滤波算法实验分析.....46
4.2 无人机防撞策略设计.....48

中国知网 https://www.cnki.net

4.2.1 前向速度控制.....49
4.2.2 偏航控制.....50
4.2.3 垂直飞行控制.....52
4.3 基于 ROS 的无人机避障方法软件设计.....53
4.3.1 无人机环境感知模块.....54
4.3.2 无人机避障控制模块.....55
4.4 本章小结.....56
第五章 无人机避障系统性能分析与实飞验证.....58
5.1 防撞预测模型实飞性能分析.....58
5.2 避障控制命令运行时间分析.....61
5.3 四旋翼无人机视觉避障飞行实验.....62
5.3.1 静止障碍物避障实验.....62
5.3.2 移动障碍物避障实验.....67
5.4 本章小结.....69
第六章 总结与展望.....70
6.1 本文的主要工作.....70
6.2 后续研究工作.....71
参考文献.....72

中国知网 https://www.cnki.net

图表清单

图 1.1 四旋翼无人机在各种领域中的应用..... 1
图 1.2 Gyroplane 飞行器实物图.....3
图 1.3 几种国外四旋翼无人机.....4
图 1.4 国内四旋翼无人机.....4
图 1.5 本文整体架构.....8
图 2.1 Bebop 2 无人机实物图..... 9
图 2.2 无人机自主避障系统框架.....10
图 2.3 无人机自主避障控制系统方案流程图..... 11
图 2.4 四旋翼无人机机体坐标系.....12
图 2.5 X 形模式与“十”字形模式.....12
图 2.6 四旋翼无人机基本飞行动作.....14
图 2.7 单目相机成像原理.....14
图 2.8 图像坐标系和像素坐标系.....15
图 2.9 二维互相关运算.....18
图 2.10 最大池化操作示意图.....18
图 2.11 全连接层操作示意图.....18
图 2.12 Dropout 层操作示意图..... 19
图 2.13 Udacity 数据集图像.....20
图 2.14 碰撞帧和非碰撞帧数据示意图.....21
图 2.15 采集到的碰撞帧样本图像.....21
图 3.1 Swin Transformer 网络整体框架..... 22
图 3.2 两个连续的 Swin Transformer Block.....24
图 3.3 Patch Merging 操作..... 24
图 3.4 多头自注意力机制和窗口自注意力机制..... 25
图 3.5 SW-MSA 模块偏移窗口操作.....26
图 3.6 SwinT 层网络结构.....27
图 3.7 ResNet 基础模块.....28
图 3.8 ResNet8 网络结构.....29
图 3.9 预测模型整体架构图.....29

中国知网 https://www.cnki.net

图 3.10 SwinT BLOCK 模块.....30
图 3.11 特征映射模块结构.....31
图 3.12 图像数据预处理操作.....34
图 3.13 预测模型训练损失误差曲线.....35
图 3.14 预测模型碰撞分类的混淆矩阵.....36
图 3.15 转向预测的概率密度函数.....36
图 3.16 室内环境测试.....38
图 3.17 室外环境测试.....38
图 3.18 夜间飞行环境.....39
图 3.19 无人机防撞预测示意图.....39
图 3.20 无人机防撞预测测试环境.....40
图 4.1 预测模型输出结果.....43
图 4.2 一阶低通滤波器传递函数框图.....44
图 4.3 几种滤波算法滤波效果图.....47
图 4.4 四旋翼无人机安全距离示意图.....49
图 4.5 四旋翼无人机偏航角度示意图.....51
图 4.6 四旋翼无人机垂直升高距离示意图.....52
图 4.7 无人机 ROS 避障系统节点图.....54
图 4.8 地面站电脑成功连接到 bebop2 无人机.....54
图 4.9 无人机采集图像成功传送到地面站电脑上.....55
图 4.10 无人机防撞预测模型部分节点图.....55
图 4.11 无人机避障指令生成部分节点图.....56
图 4.12 地面站电脑发送避障指令.....56
图 5.1 无人机防撞预测模型测试环境.....58
图 5.2 无人机成功发送采集图像.....59
图 5.3 无人机接近电线杆.....59
图 5.4 无人机避开电线杆.....60
图 5.5 不同最大前向速度条件下的防撞预测模型输出数据曲线.....60
图 5.6 /bebop2/image_raw 话题发布频率.....61
图 5.7 无人机避障树木障碍物环境.....63
图 5.8 无人机成功绕开树木.....64
图 5.9 无人机避开大树过程中的防撞预测模型输出数据曲线.....64

中国知网 https://www.cnki.net

图 5.10　无人机避开大树过程中的前向速度变化曲线..... 65
图 5.11　无人机避障矮墙障碍物环境.....65
图 5.12　无人机成功越过矮墙.....66
图 5.13　无人机越过矮墙过程中的防撞预测模型输出数据曲线..... 66
图 5.14　无人机越过矮墙过程中的飞行高度变化曲线..... 67
图 5.15　无人机避障移动障碍物环境.....67
图 5.16　移动障碍物避障过程.....68
图 5.17　移动障碍物避障过程中的防撞预测模型输出数据曲线..... 68

表 3.1　预测模型结构参数.....31
表 3.2　不同网络避障预测和转向预测性能结果..... 37
表 3.3　预测模型定量测试.....41
表 4.1　四旋翼无人机偏航角修正系数测试结果..... 51
表 5.1　ROS 避障系统运行时间分析.....62

中国知网　https://www.cnki.net

注释表

f	焦距	M	相机的内参矩阵
K	相机的畸变矩阵	$L_{\mathrm{MSE(X,h)}}$	均方根差损失函数
$\mathrm{h}(x_i)$	转向角预测函数	$L_{\mathrm{BCE(p},z_i)}$	二进制交叉熵损失函数
$\mathrm{p}(x_i)$	碰撞概率预测函数	L_{tot}	总损失函数
X_{RMSE}	均方根误差	X_{EVA}	解释方差比
TP	预测值为碰撞的正样本个数	TN	预测值为未碰撞的负样本个数
FP	预测值为未碰撞的正样本个数	FN	预测值为碰撞的负样本个数
p_t	碰撞概率预测值	s_t	转向角预测值
w_0	截止频率	T	时间常数
α	一阶低通滤波算法滤波系数	$X(n)$	预测模型输出值
$Y(n)$	滤波后的预测模型输出值	n	巴特沃斯低通滤波算法阶数
A	限幅滤波算法最大偏差值	N	平滑滤波算法采样序列长度
P_t	滤波后的碰撞概率预测值	S_t	滤波后的转向角预测值
v_t	当前时刻前向飞行速度	$v_{\max}$	最大前向飞行速度
V_t	前向速度控制指令	α_1	前向速度控制指令滤波系数
φ_t	偏航角度	β	修正系数
Φ_t	偏航角度控制指令	α_2	偏航角度控制指令滤波系数
CH	垂直升高高度控制指令	h	无人机爬升高度

中国知网 https://www.cnki.net

缩略词

缩略词	英文全称	中文全称
UAV	Unmanned Aerial Vehicle	无人机
CNN	Convolutional Neural Network	卷积神经网络
W-MSA	Windows Multi-head Self-Attention	窗口多头自注意力
SW-MSA	Shifted Windows Multi-head Self-Attention	移动窗口多头自注意力
LN	Layer Normlization	层标准化处理
BN	Batch Normlization	批标准化处理
RMSE	Root Mean Square Error	均方根误差
EVA	Mean Absolute Error	解释方差比
PDF	Probability Density Functions	概率密度函数
LPF	Low Pass Filter	低通滤波算法
BLPF	Butterworth Low Pass Filter	巴特沃斯低通滤波算法
ROS	Robot Operating System	机器人操作系统
RPC	Remote Procedure Call Protocol	远程过程调用

中国知网 https://www.cnki.net

第一章 绪论

1.1 课题研究的目的和意义

无人机（Unmanned Aerial Vehicle, UAV）是一种结构简单、造价低、重量轻、飞行相对灵活的无人飞行器，能够在复杂多变的环境里进行各种飞行任务。无人机根据其结构和飞行原理可分为旋翼无人机和固定翼无人机，旋翼无人机的飞行原理是通过一个或多个旋翼，特点是可以悬停和垂直起降，相较于固定翼无人机，旋翼无人机对起飞环境的要求较低，机动性也更好，而且能够搭载各种机载设备拓展更多功能[1]。

本文的研究对象是四旋翼无人机，对比其他多旋翼无人机，其优点在于机架各部件制作简单、技术条件成熟，且在单位体积内具有更大的动力。四旋翼无人机能够搭载视觉识别设备、无线通信设备、GPS 等，能够在狭窄的空间内自主飞行的同时，实现垂直起降、环境感知、智能决策等功能，被广泛的应用于军事侦察、灾后救援、农林植保、电力巡检、航空摄影等众多军用和民用领域[2-4]。



(a)喷洒农药　　(b)电力巡检

图 1.1 四旋翼无人机在各种领域中的应用

在四旋翼无人机的智能应用中，无人机实现安全可靠地自主避障是其他应用的前提，而无人机的自主避障严格要求了其避障系统对于环境感知、障碍物预测、快速生成避障控制指令等条件[5]。而在城市这种结构复杂且实时动态变化的环境中工作时，就对无人机自主避障性能提出了更高的要求。许多无人机制造商为了满足更高精度和反应速度的无人机避障需求，纷纷开始了各自的研究，如大疆公司的 DJI Mini 3 Pro 无人机通过配备前视、后视、下视双目视觉感应系统和 ToF，进一步增大无人机的障碍物感应范围[6]；法国无人机制造商 Parrot 的 Anafi Ai 无人机配备了独特的双眼 3D 摄像头阵列，支持无人机进行 3D 避障[7]。

无人机的自主避障主要由两部分组成，第一部分是通过机载的环境感知设备，探测前方飞

中国知网 https://www.cnki.net

行路径上的障碍物体，并获得障碍物相关信息；第二部分是根据获得的障碍物信息，通过智能决策，规划出无人机下一步的飞行控制指令[8]。目前，用于无人机环境感知的传感器有视觉传感器（单目相机[9]、双目相机[10]等）和非视觉传感器（超声波[11]、红外[12]、激光雷达传感器[13]等），视觉传感器简单可靠，不易受到周围信号及辐射等的干扰[14]。因此以视觉传感器为主、其他传感器为辅的环境感知技术成为了研究的热门，以视觉感知技术与其他环境感知技术相结合，增强了无人机的避障性能，且有助于无人机在目标检测、自主导航等领域的发展。

目前，基于视觉来进行无人机避障的方法主要由两大类组成，一类是传统的避障方法，另一类是基于深度学习的方法。传统的避障方法包括基于优化的避障方法和基于势场的避障方法[15]，基于优化的避障方法包括非线性优化[16]、启发式算法[17]、图论[18]等方法，这类方法的特点是根据建立的无人机模型，设计控制律和约束条件，使无人机避障问题的某一性能指标达到最优；基于势场的避障方法包括人工势场法[19]、流函数法[20]、速度障碍法[21]等，这类方法的特点是在障碍物体和无人机周围构造虚拟势场，生成导航函数，根据物体之间力的作用，规划出无人机的飞行路径。传统的避障方法安全性与可靠性较好，但是过于依赖环境先验信息，且计算量较大，会增大无人机避障系统的时延，使得无人机的飞行速度受到限制。

近年来，随着深度学习技术的发展，以大数据训练模型，快速生成避障控制指令的避障方法，在各种机器视觉任务中表现出非常高的性能[22-23]。基于机器学习的避障方法就是将无人机避障问题转化为一个智能决策问题，通过与飞行环境内信息不断交互，映射给出无人机的飞行动作。由于无人机机载摄像头不断地轻便化，已经能够很好地满足无人机飞行载重的要求，大量通过深度学习进行无人机避障的方法成为了研究的热门，通过预先采集无人机避障时的转向数据，在学习训练后，当无人机在不确定的环境中飞行中遇到类似的障碍场景时，能够快速准确地给与无人机避障指令，有效的节省了飞行决策时间。

随着 Transformer 网络在自然语言处理领域的广泛应用[24-26]，越来越多的研究者注意到了这类方法的光明前景，人们试图将该网络与计算机视觉领域结合起来[27-29]，取得了一系列令人瞩目的成就。与卷积神经网络（Convolutional Neural Networks, CNN）相比[30]，Transformer 网络能够提取更全面的特征，建立起特征图不同区域之间的联系。卷积结构具有最佳的泛化能力，而 Transformer 结构具有最大的模型容量，两者之间并不是对立存在的，通过两种结构的互补，能够实现更高的测试精度[31]。

因此，本文针对四旋翼无人机自主避障问题，使用单目相机作为环境感知设备，采集各种飞行环境下的无人机避障数据，采用 Transformer 网络和 CNN 结合的方法对无人机避障预测展开系统的研究，并在仿真环境和实际室外环境下，对本文提出方法进行实验验证，以期待四旋翼无人机能够在复杂环境下实现准确、安全、迅速地避开障碍物。

中国知网 https://www.cnki.net

1.2 国内外研究现状

1.2.1 四旋翼无人机研究现状

四旋翼无人机具有结构简单、易于控制、成本相对较低等特点，具有广阔的发展前景，近年来不仅吸引了研究人员的注意力，在民用商品市场上也出现了越来越多的无人机种类。四旋翼无人机可以通过改变自身四个旋翼的转速，进行各种灵活的飞行动作，诸如升降运动、俯仰运动、横滚运动、偏航运动等，从 1907 年法国 Breguet 兄弟制造出第一架四旋翼飞行器开始[32]，其发展就吸引了公众的关注。随着最近几十年来微控制器技术、新型材料、微电机系统（MEMS）、微惯导（MIMU）以及飞行控制等技术的发展，四旋翼无人机在灾后救援、地形勘探、快递服务等领域成就颇多。

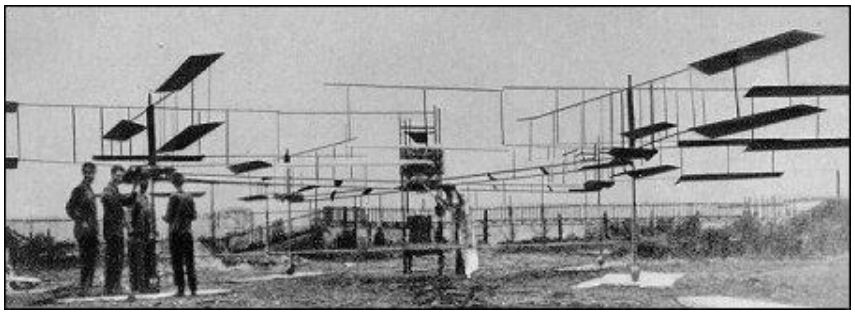


图 1.2 Gyroplane 飞行器实物图

由于四旋翼无人机具有垂直起降和空中悬停等特点，逐渐成为了工程研究和商业应用的热点。如 2002 年，美国宾夕法尼亚大学提出了一种基于 HMX-4 商业模型和视觉反馈控制系统的四旋翼无人机[33]；2004 年，瑞士洛桑联邦理工学院研发了一种直流电机驱动旋翼的小型四旋翼无人机 OS4 II[34]。在商业领域，法国 Parrot 公司在 2017 年发布了一款 Bebop2 Power 无人机[35]，通过优化推进系统，在运动模式下，最高时速可以到达 65km/h；拉脱维亚直升宇航公司在 2020 年发布了一款 AirDog II 无人机，通过一款腕带式的控制装置来控制无人机跟踪用户的位置。



(a)HMX-4 无人机



(b)OS4 II 无人机

中国知网 https://www.cnki.net



(c)bebop 2 无人机



(d)AirDog II 无人机

图 1.3 几种国外四旋翼无人机

国内对于四旋翼无人机的研究起步较晚，最早的研究开始于 2000 年，但由于消费市场需求极大，以大疆创新科技有限公司为首的各个消费级无人机公司发展迅速，通过持续的创新发布了一系列植保、航拍、空中作业规划等类型无人机，为无人机工业、行业用户、专业航拍工作者等提供了性能最强、体验最佳的革命型智能飞行控制产品和解决方案。如大疆公司于 2021 年发布的 T40 农业无人飞机[36]，采用共轴双旋翼设计，搭载源相控阵雷达和双目视觉感知系统，不仅能实现 40 公斤的喷洒和 50 公斤的播撒载重，还能实现飞行防护、航迹预测等功能；臻迪公司于 2016 年推出的首款消费级 PowerEgg 无人机[37]，它基于深度学习训练人脸识别，能够在较远距离识别出不同肤色的人群，甚至还能够进行目标锁定与跟踪。



(a)T40 农业无飞机



(b)PowerEgg 无人机

图 1.4 国内四旋翼无人机

1.2.2 基于视觉的无人机避障技术研究现状

视觉传感器相较于非视觉传感器（雷达、红外、激光传感器等）的不同之处在于，非视觉传感器通过发射声波或光波，在遭遇到阻挡之后反射回来，通过这种交互获得周围环境信息，而视觉传感器是通过相机成像原理获取环境信息，虽然这种方式容易受到光照、天气等因素的干扰，但是其获取的信息如线条、纹理、特征角等信息比红外传感器等要丰富[38]。基于视觉的无人机避障方法分为传统机器视觉方法和基于机器学习的方法。

基于传统机器视觉的无人机避障方法是通过采集前方局部或全局环境图像，通过各种图像处理算法，生成无人机周围的二维或三维地图，再通过合适的路径规划算法，计算出最优的无

中国知网 https://www.cnki.net

人机避障路径，并在避障飞行的过程中，不断更新相关地图，使得避障路径高效可行。在国外，2013 年，Tomoyuki Mori 等研究者采用 SURF 特征匹配和模板匹配相结合的方法[39]，通过比较不同图像间距下的障碍物相对大小，估计碰撞时间并根据碰撞时间大小进行避障，该方法在 Parrot AR 无人机上进行了测试且取得了良好的效果；2017 年，Aguilar Wilbert 等研究者通过单目相机实时获取图像，并于构建的障碍物数据库进行模板匹配，用以控制检测和避开未知环境中的障碍物[40]；2018 年，Massimiliano Iacono 等研究者使用 RGB-D 深度摄像机获取场景的深度信息[41]，首先定义两个三维面的交线为初始路径，然后定义一个以障碍物为中心的径向函数，用以保证障碍物外扩面与路径外扩面交叉点不与障碍物相交来规避碰撞。在国内，对传统机器视觉无人机避障方法也进行了大量的研究，2020 年，马浩森等人提出了一种基于改进 ORB 算法获取障碍物分布范围的障碍物检测方法，基于单目相机不断采集无人机周围环境图像，建立前后两张图像中连续出现的物体之间的联系，筛选出障碍物所对应的特征点[42]；2021 年，许建军等人提出了一种基于双目视觉的避障方法[43]，通过双目定位确定无人机所处位置，再通过 GPS 等传感器建立相机坐标系实现无人机避障。

基于机器学习的无人机避障方法是将无人机避障问题转化为一个智能决策问题，通过视觉传感器不断地采集外界信息，与无人机避障系统不断交互，输出最优或条件最优策略，以实现快速准确地避障防撞目标。常见的机器学习方法有深度学习、强化学习和深度强化学习方法，基于深度学习的方法由于其强大的学习与泛化能力、非线性映射能力以及快速规划能力，在无人机视觉避障领域取得了不错的效果。在国外，2015 年，Ian Lenz 等研究者提出了一种马尔可夫网络的方法[44]，该网络以一张机载拍摄的单一图像作为输入，输出障碍物的种类，并因此决策出一种规避动作，该方法在室外实验中能够准确的避开树木等各种类型的障碍物；2020 年，Joohyun Woo 等研究者提出了一种基于深度强化学习的无人机避障方法[45]，设计了一种神经网络框架和 Semi-Markov 决策模型，当障碍物出现在无人机附近时，该网络被激活以执行避障决策，输出路径跟踪、右侧避让和左侧避让三种行为中的一种。在国内，2017 年，高平海等人提出了一种首先基于深度学习进行障碍物检测，然后通过双目相机左右采集图像之间的特征点差异，通过计算后输出两幅图像之间的视差图，从而获得无人机当前飞行环境的深度图[46]；2020 年，杨兴隆等人提出了一种使用单目相机，设计和实现了基于深度学习的稠密碰撞时间生成算法，通过不断返回的预测碰撞时间生成局部地图，再通过路径规划算法进行避障飞行[47]；2021 年，郑腾龙等人提出了一种基于双目视觉传感器无人机搭建深度学习视觉处理模块，首先提出了一种改进的 Inception-Resnetv2 的网络，用于无人机视觉避障系统的航向预测，通过获取的周围环境深度信息、自身位姿、障碍物检测结果，确定可能会发生碰撞的区域，然后绕开这些区域进行飞行[48]。

总体而言，基于视觉的无人机避障方法依靠 GPS、激光雷达等的获取的位置信息和飞行过

中国知网 https://www.cnki.net

程中视觉传感器捕获的环境图像作为条件输入，或通过传统机器视觉的无人机避障方法获取障碍物的相对信息，然后生成无人机周围的局部或全局地图，最后通过路径规划算法进行避障飞行；或通过机器学习的避障方法，将环境感知与无人机避障控制直接联系起来，通过与环境的不断交互，来优化输出的避障策略，最终实现安全高效地避障决策。

1.2.3 卷积神经网络研究现状

近年来，卷积神经网络发展迅速，由于 CNN 网络相较于其他神经网络具有局部连接、下采样降维、权值共享等优点，其被广泛应用于人们生活的各个角落，基于 CNN 的计算机视觉使人们能够完成过去几个世纪被认为不可能完成的任务，例如人脸识别、自动驾驶汽车、自助超市和智能医疗等[49-50]。

随着 CNN 研究的加深，出现了几种不同类型的卷积结构，如可变性卷积（Deformable Convolution）、组卷积（Group Convolution）、可操控卷积（Steerable Convolution）、图卷积（Graph Convolution）等[51]。可变性卷积是指卷积核在每一个参数上额外增加了一个偏移量向量，且该参数是可以学习改进的，如此就增大了卷积核的感受野，相较于标准卷积的固定几何结构，可变性卷积的卷积核可以根据实际情况调整本身的形状，更好的提取输入的特征，使模型具有更强的泛化性[52]；组卷积是通过将卷积层分为几个滤波器组，再在通道维度上学习稀疏对角块结构中的特征，与标准卷积相比，组卷积网络减少了模型的参数数量，且能有效防止模型过拟合并降低模型的复杂性[53]；可操控卷积是指当输入的图像进行了各种形式的线性变换，经过可操控卷积映射后仍能够准确地识别出正常的图像类别，即可操控卷积网络是等变的而不是不变的，即使具有异常特征的样本，也能够被识别出来[54]；图卷积神经网络是一种在图上应用的网络模型，现实中有很多数据集都是用图的形式存储的，例如社交网络信息、知识图谱、蛋白质网络、万维网等等，这些图网络的形式并不像图像，是排列整齐的矩阵形式，而是非结构化的信息，图卷积神经网络就是这一类进行图特征抽取的图神经网络[55]。

自从 2012 年 Alex Krizhevsky 等人提出 AlexNet 网络以来[56]，CNN 模型就吸引了研究人员的关注，发明了各种更深、更宽、更轻的 CNN 模型，如 VGGNets、ResNet、SENet、ShuffleNets、MobileNets、GhostNet 等，这些 CNN 网络模型为检测、关键点、OCR、文本、语音等其他模型提供了特征层的基础（特征的抽取），对于大多数深度学习相关任务而言，前几层的网络结构都是这些 CNN 的结构。CNN 的发展方向分为两个，一个是向着高精度发展，如 VGGNets、ResNet、SENet 等，这些模型结构复杂、计算量大但是准确率却很高；另一个是向着轻量化发展，如 ShuffleNets、MobileNets、GhostNet 等，这些模型参数量少并降低了网络运行时的计算负荷，能够应用到如无人机、自动驾驶汽车等终端上去。

VGGNets 网络是 Karen Simonyan 等人在 2014 年提出的[57]，可以看做是加深版本的 AlexNet

中国知网 https://www.cnki.net

网络，相较于 AlexNet 的卷积核尺寸（第一个卷积层的卷积核尺寸为 11x11），VGGNets 用到的卷积核尺寸都是 1x1 和 3x3 的卷积核，网络的非线性表达能力更强；ResNet 网络是何凯明等人在 2015 年提出的[58]，模型的层数非常深（ResNet-101 已经超过一百层），并且创新性地引入了残差结构来解决模型退化问题，残差模块的提出让研究者们可以训练更深的网络；SENet 网络是 Hu Jie 等人在 2017 年提出的[59]，通过显式地建模卷积特征通道之间的相互依赖性来提高网络的表示能力，即通过自适应学习的方式获取输入图像各个通道的权重，提升权重大的通道，放弃不太重要的通道，SE 块以微小的计算成本为现有的最先进的深层架构产生了显著的性能改进。

相较于通过堆叠卷积层产生的深度卷积网络，也有很多轻量化的 CNN 模型展现了优秀的性能。ShuffleNets 网络是 Xiangyu Zhang 等人在 2017 年提出的[60]，提出了通道混洗技术来增强分组卷积的全局信息流通，通过深度可分离卷积将提取通道特征和空间特征分为了两步去做，使其的网络结构达到参数少速度快的效果；MobileNets 网络是 Andrew Howard 等人在 2017 年提出的[61]，其的思想也是通过将深度可分离卷积代替传统的卷积，模型由 1x1 和 3x3 的深度可分离的卷积模块堆叠而成，模型参数量较小，不易发生模型过拟合；GhostNet 是何凯明等人 2020 年提出的[62]，该模型利用存在的冗余特征图，通过一系列的线性变换，来生成许多幽灵特征映射，可以充分揭示内在特征背后的信息。

1.3 本文的主要研究工作

本文针对不确定环境下的四旋翼无人机避障问题，以单目相机为环境感知传感器，对基于卷积神经网络的四旋翼无人机视觉避障技术展开了研究。首先，针对传统 CNN 网络无法获得全局感受野使其难以捕获全局上下文信息和图像特征提取计算量大的问题，提出一种基于 Swin Transformer 结合 ResNet 网络模型的无人机感知预测网络，通过单目相机感知四旋翼无人机当前飞行环境并将图像输入预测模型，输出此时环境下的碰撞预测概率和转向角预测信息；然后，进行基于碰撞概率和转向预测信息的无人机避障研究，研究合适的滤波算法，使防撞预测模型输出结果平滑，然后基于这两个防撞预测信息设计了三种避障控制指令，之后基于 ROS 系统进行了避障系统软件设计；最后，对本文提出的无人机避障方法进行性能分析和实飞验证，通过设置各种不同的障碍环境，验证本文方法的可行性。

本文的章节安排和整体架构如下：

第一章是绪论。首先介绍了基于卷积神经网络的四旋翼无人机视觉避障的背景和意义，然后简述了四旋翼无人机、基于视觉的无人机避障技术和卷积神经网络的发展现状，最后对本文的内容和结构进行了简要说明。

第二章对基于单目视觉四旋翼无人机自主避障系统的整体架构进行设计。首先介绍了无人

中国知网 https://www.cnki.net

机自主避障的体系结构，然后介绍了四旋翼无人机的飞行原理、单目视觉理论、卷积神经网络理论、Transformer 理论，最后介绍了本文研究内容选用的数据集并构建了自己的碰撞数据集。

第三章进行基于 Swin Transformer 和残差网络的预测模型设计。首先介绍了 Swin Transformer 模块及其改进方法，然后介绍了本文采用的基准模型 ResNet8 网络，然后设计了基于 Swin Transformer 和 Resnet 的防撞预测模型，对模型进行了性能分析，并在各种障碍物环境中进行了防撞预测测试。

第四章进行基于碰撞概率和转向预测信息的无人机避障方法研究。首先研究合适的滤波算法对防撞预测模型输出结果进行平滑、滤波处理，然后基于碰撞概率预测值和转向角预测值设计了合理的避障控制指令，最后设计了基于 ROS 的无人机自主避障系统软件。

第五章进行无人机避障实验与结果分析。首先对预测网络模型进行性能评估，然后避障控制命令运行时间进行分析，最后基于本文的避障方法进行室外实飞验证，并对结果进行分析。

第六章为全文总结与展望。总结了课题中的主要研究成果，同时也给出了研究中存在不足的地方，对进一步的研究方向做出了展望。

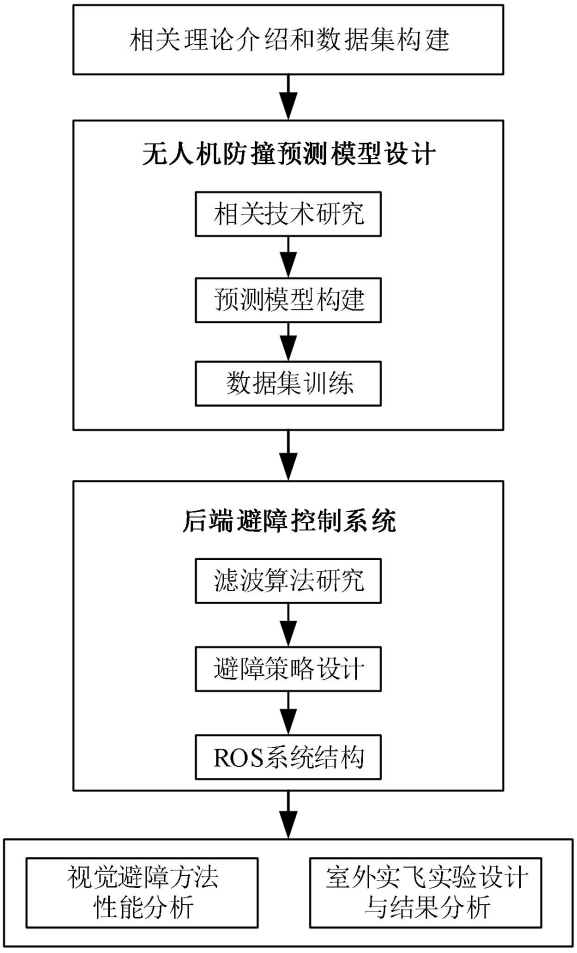


图 1.5 本文整体架构

中国知网 https://www.cnki.net

第二章　四旋翼无人机视觉避障系统总体架构

本章进行对基于单目视觉四旋翼无人机自主避障系统的整体架构进行设计、相关理论分析和碰撞预测数据集搭建。首先介绍了对本文避障方法进行测试的四旋翼无人机硬件实验平台，然后设计了四旋翼无人机自主避障系统的整体架构和避障方案流程，最后对本文涉及的无人机视觉避障相关理论以及相关数据集进行阐述。

2.1 四旋翼无人机硬件平台

本文避障方法的验证设备为法国 Parrot 公司生产的 Bebop 2 四旋翼无人机[63]，是一款重量仅有 500 克的消费级无人机，该无人机供电电池容量为 3100mAh，能够提供 30 分钟续航时间，充足的续航时间让本文可以进行更多类型的无人机避障实验。在运动模式下，Bebop 2 无人机最大水平飞行速度可以达到 65km/h，并且能够在 60km/h 风速的恶劣环境下飞行。这款无人机的环境感知设备为 1400 万像素 CMOS 广角镜头，可以以每秒 30 帧的帧速进行拍摄，拍摄角度接近 170°，可视面积非常广；而且该镜头的视角向下倾斜了 30°，可以让无人机以垂直 90°拍摄地面，这使得这款无人机可以采集到更多的信息。Bebop 2 无人机可以通过 802.11n 的 Wifi 协议与无人机控制设备进行通信，实现精确的远程操控，这保证了进行无人机避障实验的安全性。



图 2.1 Bebop 2 无人机实物图

2.2 基于单目视觉的无人机避障系统整体架构

基于单目视觉的无人机自主避障系统整体架构如图 2.2 所示。系统架构主要包括基于单目相机的图像采集系统和无人机避障控制系统两个部分。图像采集系统通过机载的单目相机采集

中国知网　https://www.cnki.net

包含了无人机当前飞行环境中各种信息的图像，并通过 WiFi 通信将图像无线传输到无人机避障控制系统中进行无人机避障。无人机避障控制系统包括无人机防撞信息预测系统和无人机避障策略决策系统两部分，无人机防撞信息预测系统是将单目相机采集到的图像数据进行预处理后，传入预先训练好的避障信息预测模型，输出无人机当前飞行环境下的碰撞概率和避障转向所需角度预测信息，实现环境感知；无人机避障策略决策系统是基于防撞信息预测系统的预测结果，首先通过研究合适的滤波算法去除掉预测结果中的不平滑点，然后根据不同的碰撞概率和避障转向角度预测信息，设计不同障碍物环境下合理的避障方法，实现四旋翼无人机避障过程中准确、光滑的姿态控制。

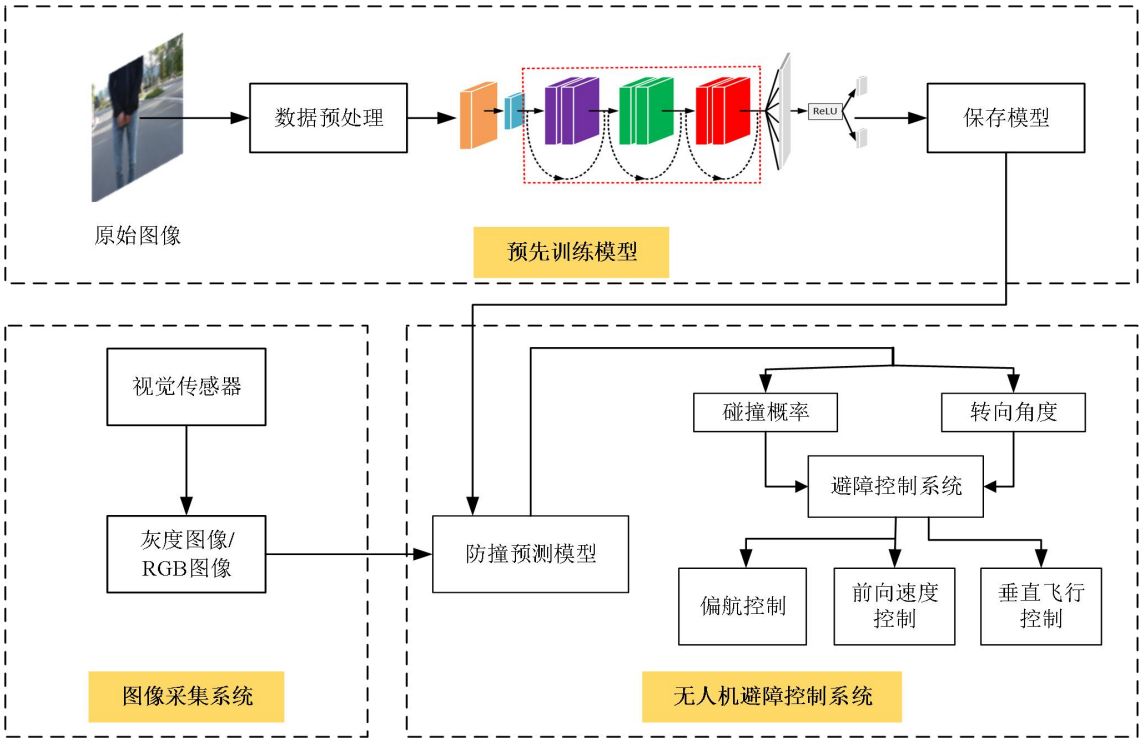


图 2.2 无人机自主避障系统框架

基于单目视觉的无人机避障飞行系统方案流程图如图 2.3 所示。无人机起飞后，启动避障系统，利用单目相机从环境中获取到图像组，采集到的图像经过一系列预处理操作后，传入预先训练好的避障预测模型，模型输出无人机当前飞行环境下的预测碰撞概率和避开障碍物所需的转向角度，将这两个预测结果作为输入传入到无人机避障控制系统中。为了使无人机的避障控制指令光滑稳定，首先采用滤波算法剔除掉预测值中的跳变点和无效值，然后根据这两个输入，制定合理的避障策略，如遇到障碍物时，无人机水平前向速度变慢，四旋翼无人机通过左移、右移、往上等操作绕开障碍物或悬停操作停止向前飞行防止无人机撞上无法避开的障碍物，将这些避障操作转化为控制指令后无线传输到无人机进行避障飞行。重复上述操作，直到无人机到达指定位置，无人机结束飞行，避障系统停止运行。

中国知网 https://www.cnki.net

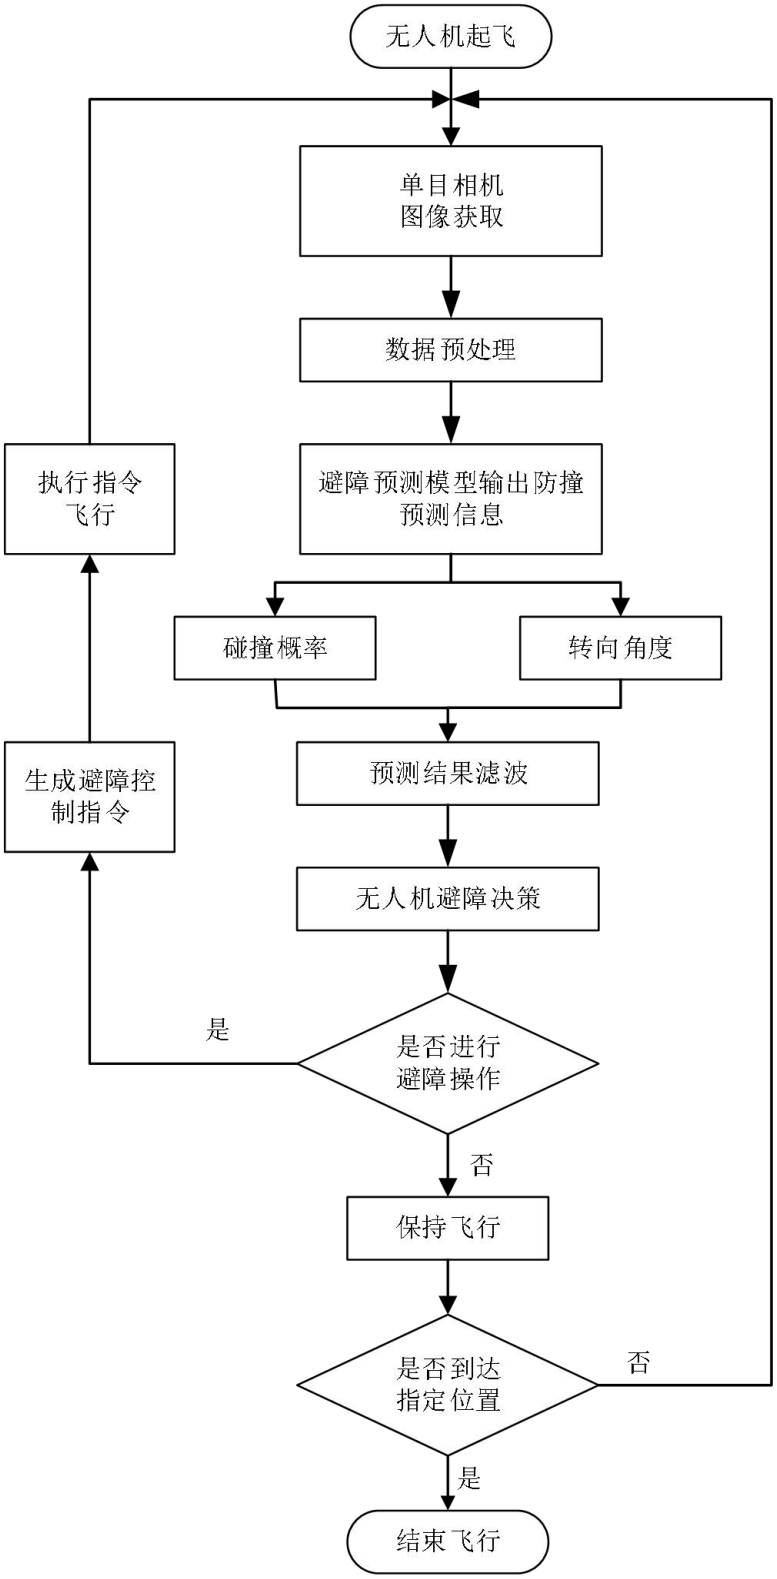


图 2.3 无人机自主避障控制系统方案流程图

中国知网 https://www.cnki.net

2.3 无人机视觉避障相关理论

2.3.1 四旋翼无人机飞行原理

四旋翼无人机通过在四个桨叶上装载电机与旋翼，通过电机转动带动旋翼旋转产生升力，当四个旋翼产生的总升力之和大于无人机自身的重力时，四旋翼无人机就能够实现飞行于空中。将位于对角线的两个旋翼组成一组，这两组旋翼旋转方向相反，彼此抵消旋翼旋转所带来的扭矩。四旋翼无人机所有的姿态和位置变化都是通过改变四个桨叶上的电机转速完成的，本文硬件实验平台的最大上升速度可达 6m/s。图 2.4 展示了四旋翼无人机的机体坐标系 $O_b - x_b y_b z_b$，以四旋翼无人机的质心 O_b 为原点。

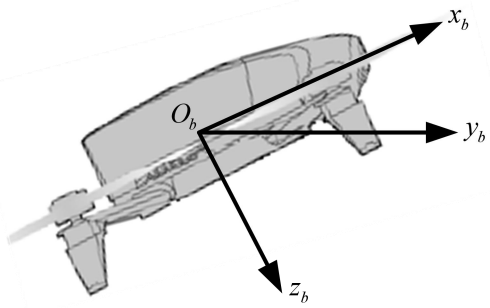


图 2.4 四旋翼无人机机体坐标系

四旋翼无人机一共有 6 个自由度，也就有 6 种基本飞行动作。无人机在 z_b 轴方向上的上下运动称为升降运动，以 x_b 轴为中心轴旋转称为为横滚运动，以 y_b 轴为中心轴旋转称为俯仰运动，以 z_b 轴为中心轴旋转称为偏航运动（自旋）。四旋翼无人机的横滚、俯仰和偏航运动由四个桨叶的转动方向和转速决定。因此，需要定义四旋翼无人机的桨叶序号，研究桨叶的转动方向和转速对其飞行姿态的影响。四旋翼无人机的桨叶布局通常有两种模式，即“十”字形模式和 X 形模式，图 2.5 展示了四旋翼无人机的桨叶结构图。

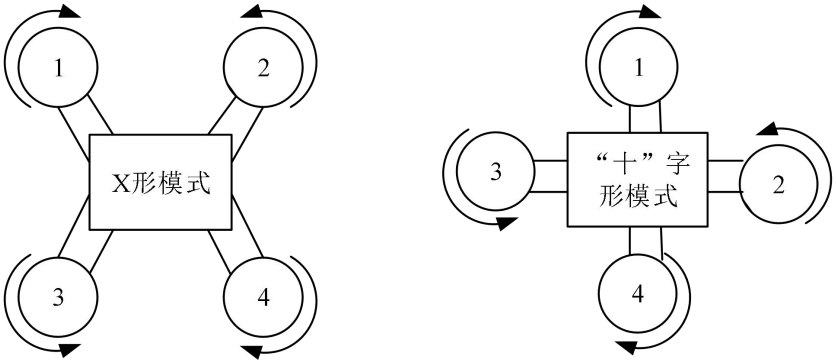


图 2.5 X 形模式与“十”字形模式

中国知网 https://www.cnki.net

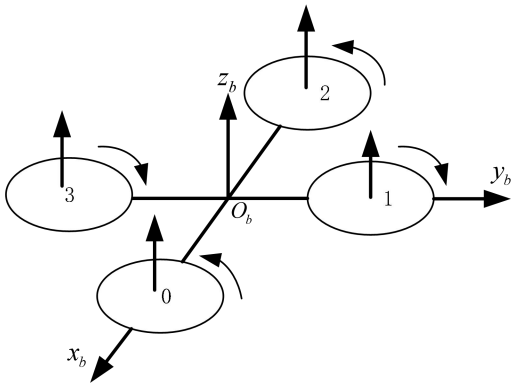
为了抵消旋翼在旋转时产生的反扭距，四旋翼无人机相邻的两个旋翼的转动方向相反，而在对角线上的两个旋翼的转动方向相同，如图 2.4 的 X 形模式所示，当旋翼 1、4 同方向（顺时针方向转动），旋翼 2、3 同方向（逆时针方向转动）的时候，这两个方向产生的反扭距就恰好抵消掉，使得四个机体轴在偏航方向能保持平衡，不至于出现自旋转。

如图 2.6(a)所示，当四旋翼无人机的四个旋翼电机转速保持一致时，无人机处于平稳状态，此时如果同时给四个电机增大相同的转速，则四旋翼无人机会垂直升高；类似的同时给四个电机减小相同的转速，四旋翼无人机会垂直下降。

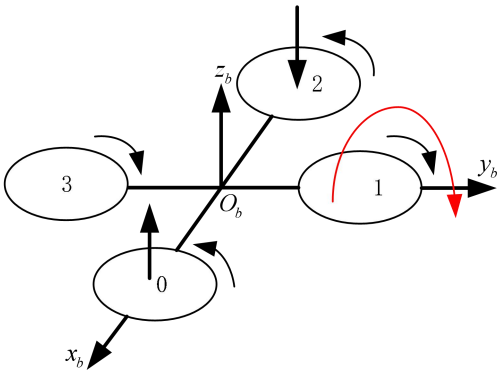
如图 2.6(b)所示，当四旋翼无人机坐标系以无人机飞行正方向为 x_b 轴正方向时，保持 1、3 电机转速不变，此时如果增大电机 0 的转速，减小电机 2 的转速，则四旋翼无人机就会绕着 y_b 轴转动，此时为无人机的仰运动；反之，减小电机 0 的转速，增大电机 2 的转速，此时为无人机的俯运动。俯仰运动实际上还会影响无人机的前进和后退动作。

如图 2.6(c)所示，保持 0、2 电机转速不变的同时，分别改变电机 1、3 的转速，可以使无人机机身绕 x_b 轴转动，此为无人机的横滚运动，横滚运动实际上还会影响无人机的左移和右移动作。

如图 2.6(d)所示，当电机 0、2 的转速增大，同时电机 1、3 的转速减小，此时无人机会绕 z_b 轴以电机 0、2 的旋转方向的反方向旋转；反之，当电机 1、3 的转速增大，同时电机 0、2 的转速减小，此时无人机会绕 z_b 轴以电机 1、3 的旋转方向的反方向旋转，此为无人机的偏航运动。

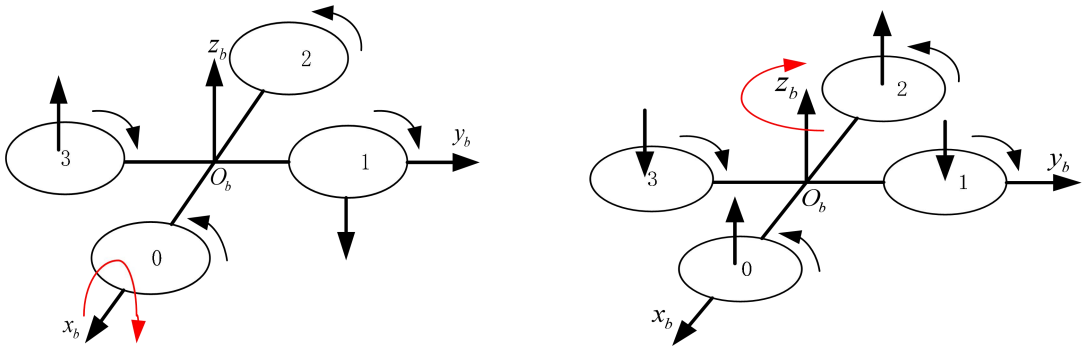


(a)升降运动



(b)俯仰运动

中国知网 https://www.cnki.net



(c)横滚运动　　(d)偏航运动

图 2.6 四旋翼无人机基本飞行动作

2.3.2 单目视觉理论

本文使用的四旋翼无人机硬件实验平台的机载环境感知设备为单目相机，其采集的无人机飞行环境图像是否清晰关系着避障系统能否准确地预测出碰撞危险，因此必须了解单目相机的成像原理，并知道如何解决单目相机拍摄图像发生的畸变。

单目相机图像采集的过程就是将相机前方的实景通过相机的透镜投影到成像平面，完成几何透视变换[64]。如图 2.7 所示，平面 I 是外界环境的物理像平面，平面 $\prod'$ 是单目相机成像的像素平面，平面 $\prod$ 是平行于物理像平面且距离单目相机光心 O_1 焦距 f 长度的一个虚拟归一化像平面，由于像素平面 $\prod'$ 生成的图像受制于单目相机的成像元件，所以通过虚拟的归一化像平面 $\prod$ 将物理像平面 I 按比例缩小，此时该虚拟平面只与外界物体的相机坐标有关，不受相机元件大小限制，而归一化像平面 $\prod$ 与像素平面 $\prod'$ 之间可以通过成像元件的像素恢复成实景图象。

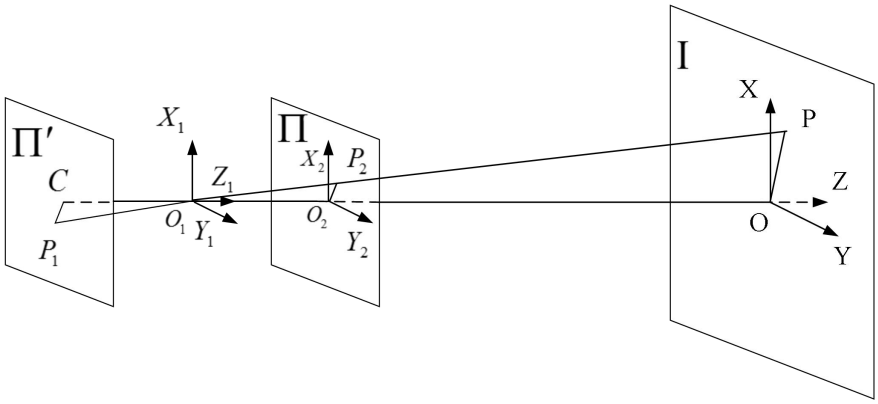


图 2.7 单目相机成像原理

因此，可以将物体空间点 P 的世界坐标系坐标 (x, y, z) 通过公式转化为相机坐标系坐标，相机坐标原点为 O_1，再将相机坐标通过三角相似变换成归一化像平面 $\prod$ 的投影点 P_2，将该点的坐标设为 (x_2, y_2, z_2)，此时由于初始设置归一化像平面 $\prod$ 距离单目相机光心 O_1 的长度 O_1O_2 为相

中国知网 https://www.cnki.net

机的焦距 f，因此可以得到空间点 P 与投影点 P_2 之间的关系：

$$\begin{cases} \dfrac{x}{z}=\dfrac{x_2}{z_2}=\dfrac{x_2}{f} \\ \dfrac{y}{z}=\dfrac{y_2}{z_2}=\dfrac{y_2}{f} \end{cases} \tag{2.1}$$

上式中，这两个坐标点之间的变换就是一个简单的缩放。

当得到物体空间点在归一化像平面 $\prod$ 的相机坐标系坐标之后，就可以通过成像元件的像素将该坐标变换成在像素平面 $\prod'$ 的像素坐标系坐标，但是该像素坐标与最终采集的图像坐标系坐标之间还存在着偏差。如图 2.8 所示，图像坐标系 $O_3-X_3Y_3$ 的坐标原点在成像平面中心，而像素坐标系 O_0-uv 的坐标原点在成像平面的左上角，图像坐标系用于表示像素在图像中的物理位置，图像坐标系和像素坐标系之间存在着一个平移。

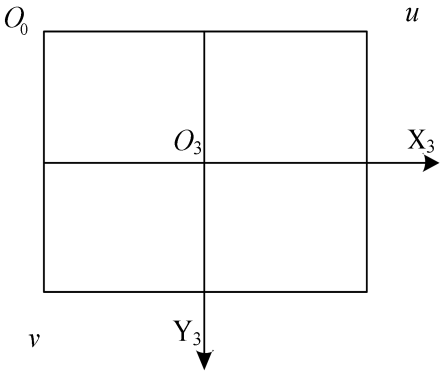


图 2.8 图像坐标系和像素坐标系

为了减少从物体空间点的世界坐标系坐标到最终成像图片中的图像坐标系坐标之间的映射变换计算量，在单目视觉系统中，通过单目相机的内参参数和畸变参数可以使相机准确观测外在环境信息[65]，内参参数反映了环境信息到图像信息之间的映射关系，与相机感光芯片位置、镜头位置等有关系，一个精确的内参系数是通过单目相机进行观测和测量的首要保证；由于设备的局限性和系统连接过程中的各种问题会使单目视觉系统采集到的图像产生各种畸变，为了获取到准确的图像数据，需要求解准确的畸变参数修正单目相机的偏差。

（1）提取相机内参矩阵

已知归一化像平面 $\prod$ 上的投影点 P_2 的相机坐标系坐标为 (x_2,y_2,z_2)，首先需要将其映射转化成像素平面 I 上的点 P_1，由于两者所在的平面是平行的，如图 2.7 所示，因此根据相似性原理，点 P_2 可以通过比例放大或缩小转化为点 P_1 的像素坐标系坐标。而像素坐标系与图像坐标系的关系如图 2.8 所示，因此可以将像素平面 I 上的点 P_1 通过位移得到其在图像坐标系中的对应点坐标，该坐标设为为 (u,v)，则有：

中国知网 https://www.cnki.net

$$\begin{cases} u = a_x x_2 + u_0 \\ v = a_y y_2 + v_0 \end{cases} \tag{2.2}$$

式中 a_x、a_y 分别为归一化像平面 $\prod$ 与成像的像素平面 I 在 x 轴与 y 轴的缩放比例系数（由于镜头制作安装过程中不能保证与相机感光芯片完全平行，而实际应用中归一化像平面 $\prod$ 是与镜头平行的），u_0、v_0 为像素平面的坐标系与图像坐标系原点间的位置偏差。代入式(2.1)可得：

$$\begin{cases} u = \dfrac{a_x x}{z} f + u_0 \\ v = \dfrac{a_y y}{z} f + v_0 \end{cases} \tag{2.3}$$

转化为矩阵形式：

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \begin{bmatrix} f_x & 0 & u_0 \\ 0 & f_y & v_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \dfrac{x}{z} \\ \dfrac{y}{z} \\ 1 \end{bmatrix} = M \begin{bmatrix} \dfrac{x}{z} \\ \dfrac{y}{z} \\ 1 \end{bmatrix} \tag{2.4}$$

式中 $f_x = a_x f$、$f_y = a_y f$ 分别是焦距 f 在 O_0u、O_0v 方向轴上的长度，M 为摄相机的内参矩阵，f_x、f_y、u_0、v_0 为相机内参矩阵系数。

（2）求解相机畸变矩阵

受镜头制造精度的影响，单目视觉系统拍摄的图像会出现不同程度的畸变，这种畸变可以分为径向畸变和切向畸变两种。径向畸变是由透镜形状导致的，是透镜自身形状对光线传播的影响，在理想的情况下，自然界中物体投影到成像平面时，直线仍然保持直线形状，但在实际情况中直线往往会形变成曲线；切向畸变是由透镜与成像平面位置不平行所导致的，这种情况会导致投影在成像平面上点的位置发生改变。为了修正这些畸变带来的影响，会采用几个畸变参数对点的投影坐标进行调整。

假设存在一个点的实际坐标为 (x, y)，对于径向畸变，其畸变后的归一化坐标 $(x_{\text{correct}}, y_{\text{correct}})$ 沿着长度方向发生了改变，可以把畸变看作 $r = \sqrt{(x^2 + y^2)} = 0$ 附近的泰勒奇数展开的前几项来表示，该点的径向位置可以根据以下等式进行调整：

$$\begin{cases} x_{correct} = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \\ y_{correct} = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \end{cases} \tag{2.5}$$

式中，k_1、k_2、k_3 是表达径向畸变的畸变参数。

对于切向畸变，实质是投影点在像素平面上的坐标沿着切线发生了改变，切向畸变可以用以下两个参数和来表示：

中国知网 https://www.cnki.net

$$\begin{cases} x_{correct} = x + 2p_1xy + p_2(r^2 + 2x^2) \\ y_{correct} = y + p_1(r^2 + 2y^2) + 2p_2xy \end{cases} \tag{2.6}$$

综合以上两个式子，可以得到单目相机的综合去畸变公式：

$$\begin{cases} x_{correct} = x(1 + k_1r^2 + k_2r^4 + k_3r^6) + 2p_1xy + p_2(r^2 + 2x^2) \\ y_{correct} = y(1 + k_1r^2 + k_2r^4 + k_3r^6) + p_1(r^2 + 2y^2) + 2p_2xy \end{cases} \tag{2.7}$$

通过求解相机的畸变参数矩阵 $K = [k_1, k_2, k_3, p_1, p_2]$，就可以确定点在像素平面内的正确位置。本文在进行四旋翼无人机避障实飞实验时，都会先对机载单目相机进行畸变矫正，确保采集的飞行环境图像准确真实。

2.3.3 卷积神经网络理论

卷积神经网络是一类包含卷积操作的深度前馈人工神经网络，使用一种变体的多层感知器以减少图像的预处理过程，具有共享权重结构和平移不变性的特征。CNN 基本组成有卷积层、池化层、全连接层、激活函数等，CNN 还经常存在一个过拟合的现象，即训练好的模型只在训练集上表现良好，而在测试集和验证集上表现一般甚至很差，因此 CNN 还会使用正则化、Dropout 层、选择合适的网络结构等操作防止模型过拟合。

（1）卷积层

卷积层通过卷积运算提取输入图像或其他类型数据不同层次的特征，单层卷积层只能够提取很低级的特征，所以往往是多个卷积层一起工作[66]。对于本文无人机避障系统，其输入为有高 H 、宽 W 、通道数 C 三个维度特征的二维图像，因此二维卷积层首先将输入 $\mathrm{X} \in \mathrm{R}^{\mathrm{H}\times\mathrm{W}\times\mathrm{C}}$ 和卷积核 $\mathrm{W} \in \mathrm{R}^{h\times w\times \mathrm{C}\times \mathrm{N}}(h << \mathrm{H}, w << \mathrm{W})$ 做互相关运算（ N 表示经过卷积操作之后的输出特征的通道数），然后加上一个标量偏差 b 来得到输出 $\mathrm{Y} \in \mathrm{R}^{\mathrm{H'}\times\mathrm{W'}\times\mathrm{N}}$ 。对于任意输入特征 X ，给定卷积核 W ，输出特征为 Y ，二维卷积的互相关运算可以表示为：

$$\mathrm{y}_{ij}^{l} = \sum_{u=1}^{h}\sum_{v=1}^{w} w_{uv}^{l,n} \bullet x_{i-u+1,j-v+1}^{l} \tag{2.8}$$

式中，x_{ij}^{l} 和 y_{ij}^{l} 分别表示第 l 层输入特征和输出特征第 i 行和第 j 列的像素值，$w_{uv}^{l,n}$ 表示第 l 层卷积核第 u 行和第 v 列的权值，对应的是第 n 层的输出。

二维卷积层的输出特征还需要经过一个非线性激活函数进行激活后，才能得到输出的特征图 $\mathrm{Y} \in \mathrm{R}^{\mathrm{H'}\times\mathrm{W'}\times\mathrm{N}}$，具体公式表示为：

$$\mathrm{Y} = f(\mathrm{W} \otimes \mathrm{X} + b) = f(\sum_{l=1}^{\mathrm{C}} w^{l,n} \otimes \mathrm{X}^{l} + b) \tag{2.9}$$

式中 $f(\bullet)$ 为激活函数。

二维卷积层的互相关运算过程如图 2.9 所示，绿色区域之间进行卷积操作，具体为输入图像和卷积核相同区域的系数相乘再累积和，最终得到的特征系数放在绿色区域相同位置，以步

中国知网 https://www.cnki.net

长 s 移动卷积核，重复上述操作，直到输入图像所有的区域都完成相关运算。

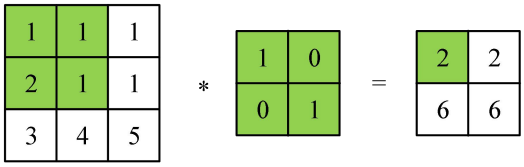


图 2.9 二维互相关运算

（2）池化层

池化层实际上是一种下采样操作，相当于在输入特征 H 和 W 维度上做了维度约减，从而使模型可以抽取更加广范围的特征，池化层分为最大池化和平均池化，其工作方式为将输入图像划分为大小一致的目标区域，在每一个目标区域对像素点大小进行比较或求取这些系数的平均值，将运算后得到的输出值放置在特征图的相同区域，一般池化层之后特征图的大小都会减小，神经元个数也会随之降低[67]。

如图 2.10 所示，最大池化选择局部窗口中的最大值作为池化操作的输出值，池化层一般出现在卷积层之后。

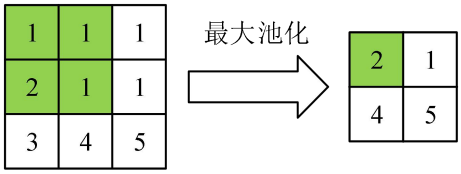


图 2.10 最大池化操作示意图

（3）全连接层

全连接层的作用是将前面卷积层、池化层等提取出来的特征综合起来，其特点是全连接层的每一个神经元都与上一个网络层的所有神经元进行连接，一般每个全连接层的神经元都会用激励函数激活，最后一层全连接层会根据网络模型的输出个数，将所有的输出值传递给所有的输出[68]。全连接层通常可以用于分类以及回归任务中，通常被用于卷积神经网络的最后一层，输出网络的预测结果，全连接层操作示意图如图 2.11 所示。

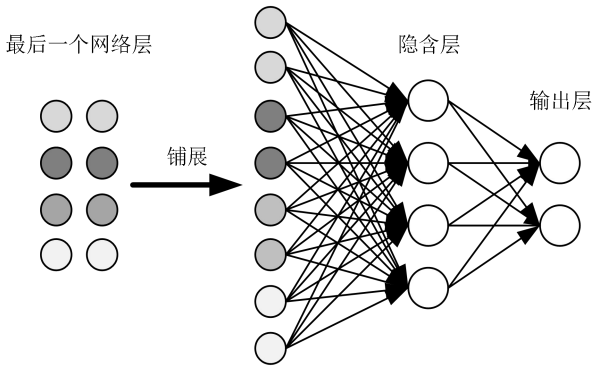


图 2.11 全连接层操作示意图

中国知网 https://www.cnki.net

（4）过拟合

卷积神经网络模型学习样本数据的特点，并追求在陌生图像数据中找出类似的数据，但是在模型拟合数据的过程中，过于追求高拟合度将会导致模型过拟合现象的发生，若模型出现过拟合，当再次抽取样本，模型的预测准确度将大幅降低。为了防止模型出现过拟合现象，可以通过降低模型的复杂度、增加正则化参数、对全连接层神经元进行 dropout 操作等方式，有效地减小过拟合，增加模型的泛化能力。

正则化方法由于由于可以使相关参数尽可能小和无关参数趋于零的特征使得模型的训练变得简化，有效降低了模型的复杂度和计算量，因此能够防止模型过拟合的发生，常见的正则化方法有 L1 正则化、L2 正则化、L1L2 正则化等[69]。L2 正则化由于计算效率高而被经常用于防止模型过拟合，其工作原理是作为一个惩罚项函数加入到损失函数，根据损失函数各个系数的绝对值大小，与之成反比迫使模型最优解的各系数接近 0，这个惩罚项函数表示为 l_2 范数，即权重向量绝对值的平方相加再开方，也称为欧几里得距离，具体公式表示为：

$$\|x\|_2 = \sqrt{\sum_{i=1}^{n} |x_i|^2} \tag{2.10}$$

式中，x_i 为网络层特征输入，将惩罚项函数乘以正则项权重 λ 就是正则项，参数范数惩罚方法实际上就是在模型损失函数后面加上正则项。

Dropout 层是一种可以用于减少卷积神经网络过拟合的结构[70]，其具体实现为在每一个训练批次中，根据设置的删除率，按照一定的概率暂时随机删除掉一些神经元，这样可以使得剩下的神经元的训练不依赖于删除的神经元，在进入下一个批次后，将删除的神经元节点重新插入网络，再随机删除一些神经元，这样特征之间的协同作用被减弱，模型的拟合度也会随之降低，就能够有效地防止模型过拟合了。Dropout 层操作示意图如图 2.12 所示。

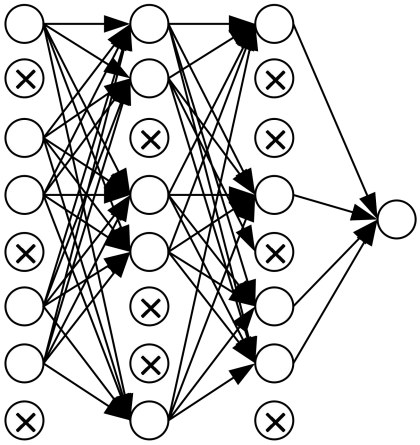


图 2.12 Dropout 层操作示意图

中国知网 https://www.cnki.net

2.4 相关数据集研究

为了研究基于卷积神经网络的四旋翼无人机视觉避障预测网络，需要采集相关可供训练的数据集，四旋翼无人机进行飞行避障，需要知道当前飞行环境下的两个预测数据，一个是碰撞概率，使无人机能够识别危险情况并迅速作出反应；另一个是转向角，使无人机在避开障碍物的同时保持导航[71-72]。因此本文需要使用的图像数据集为：标有碰撞概率标签的碰撞预测数据集和标有无人机偏航角度标签的转向预测数据集。

由于专业的标有无人机偏航角度标签的转向预测数据集非常稀少，因此本文不能直接通过模型预测无人机避障障碍物所需的偏航角，但是通过查阅文献，发现存在着大量关于地面车辆转向角预测任务的文献[73]，若仅考虑通过无人机的偏航运动绕过障碍物，这种避障模式类似于无人驾驶汽车中车辆的转向运动，模型预测的转向角可以通过一个线性变换成无人机避障所需的偏航角度。因此，为了从图像中学习到转向角，本文采用了 Udacity 项目中的一个公开可用数据集，该数据集包含了 39600 多张汽车驾驶图像，分布在 6 个实际场景中，本文拟采用其中的 5 个场景的图像作为训练数据集，1 个作为测试数据集。每个场景的图像数据集都包含着来自 3 个摄像头（左、中、右）的时间戳图像，每张图像都标注有 IMU、GPS 数据、档位、刹车、油门、转向角和速度等信息。基于无人机视觉避障预测网络的研究需求，本文只使用来自前视摄像头的图像及其相关的转向角数据。用于训练学习转向角的 Udacity 图像如 2.13 图所示：



图 2.13 Udacity 数据集图像

本文采用的标有碰撞概率的防撞预测数据集来自于苏黎世大学的 Rpg 碰撞数据集，其通过在自行车把手上安装 GoPro 摄像头来收集碰撞数据，沿着城市的不同区域行驶，保证了障碍物的类型（车辆、行人、植被、建筑工地）和环境的外观多样化，该数据集包含了大约 32000 张图像，分布在 137 个不同障碍物序列上，通过手动标注图像，使远离障碍物的图像帧标记为 0（无碰撞），而非常接近障碍物的图像帧标记为 1（碰撞）。但是通过实际研究发现，Rpg 碰撞数据集的碰撞帧和非碰撞帧数据非常不平衡，碰撞帧数量远远小于非碰撞帧，在训练神经网络时，碰撞帧和非碰撞帧数量之间的不平衡对模型防撞预测的准确率有很大的影响，碰撞帧和非碰撞帧数据如图 2.14 所示。

中国知网 https://www.cnki.net



(a)非碰撞帧　　(b)碰撞帧

图 2.14 碰撞帧和非碰撞帧数据示意图

因此，基于实际的需要，本文收集并标注的自己的碰撞预测数据集（5483 帧），并采集了 Rpg 碰撞数据集中没有的障碍物类型（路灯、支撑柱、告示牌等）。本文收集的碰撞帧数据如图 2.15 所示：



图 2.15 采集到的碰撞帧样本图像

2.5 本章小结

本章对基于卷积神经网络的四旋翼无人机视觉避障方法进行总体架构介绍和相关理论简述。首先，介绍了本文视觉避障方法的无人机硬件平台。然后，对设计的避障系统整体架构进行了介绍，主要包括基于单目相机的图像采集系统和无人机避障控制系统两个部分，并对无人机避障飞行系统整体方案流程进行了介绍。再然后，对相关的无人机视觉避障理论进行介绍，主要介绍了四旋翼无人机的飞行原理、单目视觉理论、卷积神经网络理论等。最后，介绍了本文用于训练和测试的碰撞概率数据集和转向角数据集，并基于实际情况，手动收集了更多实际无人机飞行环境下的碰撞帧数据，解决了模型训练正样本和负样本之间的不平衡问题。

中国知网 https://www.cnki.net

第三章　无人机防撞预测与避障航向预测网络设计

四旋翼无人机进行飞行避障时，需要识别危险情况并迅速作出反应和避开障碍物的同时继续飞行，为了满足上述要求，需要根据无人机机载单目相机采集的图像数据，输出当前无人机飞行环境下的碰撞概率和转向角预测结果。本章进行基于 Swin Transformer 和 CNN 的四旋翼无人机碰撞概率预测和转向角预测模型设计。首先，进行基于 Swin Transformer 和 ResNet 的预测模型设计，分析了 Swin Transformer 网络和 ResNet 网络的原理和结构，然后对设计的预测模型整体结构做了详细的介绍；然后，为了量化本章模型的性能，选择设计了预测网络模型的评估指标；最后，给出了模型的训练结果，并对结果进行了分析。

3.1 基于 Swin Transformer 和 ResNet 的预测模型设计

Swin Transformer 网络是由 Ze Liu 等人在 2021 年提出的一种分层结构网络[74]，通过移动窗口将自关注计算限制在非重叠的局部窗口，同时通过移动窗口连接，让相邻窗口得到了交互，提升了图像不同区域特征之间的关联度，从而实现了近似的全局特征提取，可以实现全局特征信息的有效聚合，从而提高了各种图像任务的准确率。本文无人机防撞预测模型目标是通过采集四旋翼无人机前向飞行方向上的环境图像，综合考虑到所有的障碍物信息后，输出四旋翼无人机可能发生碰撞的碰撞概率和避障所需的转向角度，因此 Swin Transformer 网络提取全局特征的能力非常符合本文防撞预测模型的需要。Swin Transformer 网络的基本架构如图 3.1 所示。

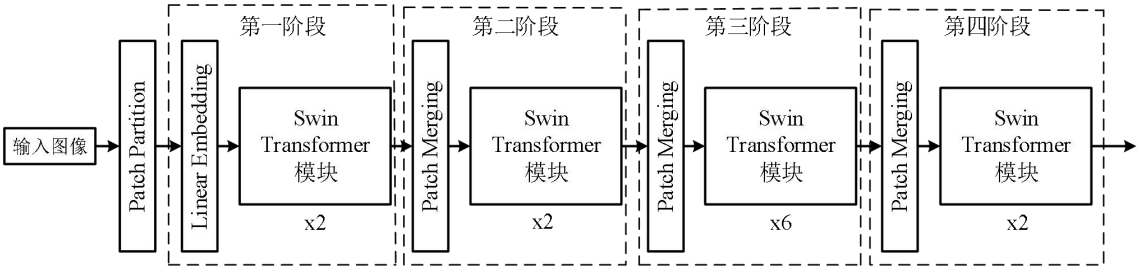


图 3.1 Swin Transformer 网络整体框架

卷积神经网络作为计算机视觉领域的主流深度神经网络，使用卷积层和池化层对输入的图像进行特征提取，卷积核和池化核的大小远远小于图像的大小，因此在滑动窗口内进行图像处理时，更关注局部的感受野，这样的操作减少了模型运算过程中的相关参数量和内存占用，提高了运算速度，但由于无法获得全局的感受野，在面对规模较大的训练集时，CNN 的能力会受到限制。

通过研究发现，Transformer 结构相较于传统 CNN 网络，具有更大的模型容量，即模型在训练数据集上的拟合能力更强；而 CNN 网络结构作为现如今技术最成熟和应用最广泛的网络

中国知网 https://www.cnki.net

结构，具有最强的泛化能力，即模型训练之后，在没训练过的数据上的分类或回归能力最好。基于以上发现，本文提出了一种结合 Swin Transformer 和 CNN 的混合结构，使模型达到模型容量和泛化能力之间的最佳点。

3.1.1 Swin Transformer 网络

Swin Transformer 网络的整体架构如图 3.1 所示，其网络架构使用了类似于卷积神经网络中的多阶段层级式构建方法。首先将原始图像输入到 Patch Partition 模块中进行分块操作，即将每 4x4 个相邻的像素组合成一个 Patch，每个 Patch 有 16 个像素点。然后将所有的 Patch 在通道维度方向展平，若输入的图像是 RGB 图像，则其原始图像有 R、G、B 三个通道，所以展平后每个 Patch 有 48 个像素点，即通过 Patch Partition 模块，原始图像的形状由 [H,W,3] 变为 $[H/4, W/4, 48]$。

然后将特征图输入 Linear Embedding 层，对每个 Patch 的通道数进行线性变换映射，即把向量的维度映射成一个预先设置好的值 C（C 是一个预先设置好的超参数），此时图像的形状由 $[H/4, W/4, 48]$ 变成了 $[H/4, W/4, C]$，然后

再将特征图输入两个连续的 Swin Transformer 模块，其结构如图 3.2 所示。输入的特征先经过 Layer Normalization（LN）层进行归一化（把输入转化为均值为 0、方差为 1 的数据），再经过窗口多头自注意力（Windows Multi-head Self-Attention, W-MSA）模块进行特征学习，然后经过一个残差操作合并特征后，继续进行 LN、MLP（类似全连接层操作）、合并残差操作得到第一个 Swin Transformer Block 的输出特征。第二个 Swin Transformer Block 的操作类似于第一个 Block，但不同的是进行基于移动窗口的多头自注意力（Shifted Windows Multi-head Self-Attention, SW-MSA）特征学习而不是 W-MSA 特征学习，即先进行一次 Shifted window 操作，再进行窗口自注意力的计算。

剩下的三个层级结构都是先通过一个类似于卷积神经网络结构里面池化层的 Patch Merging 层，进行下采样操作，然后进行重复堆叠 Swin Transformer Block 得到多尺度的特征信息，每经过一个层级结构，输出的特征图高和宽两个维度都减半，通道维度都变为原来的两倍。分层结构允许 Swin Transformer 网络模型适配不同尺度的图片，而且模型的计算复杂度与图像大小成线性关系，相较于原始的 Transformer 结构，Swin Transformer 网络将自注意力计算复杂度从平方式增长有效地降低到了线性增长。

中国知网 https://www.cnki.net

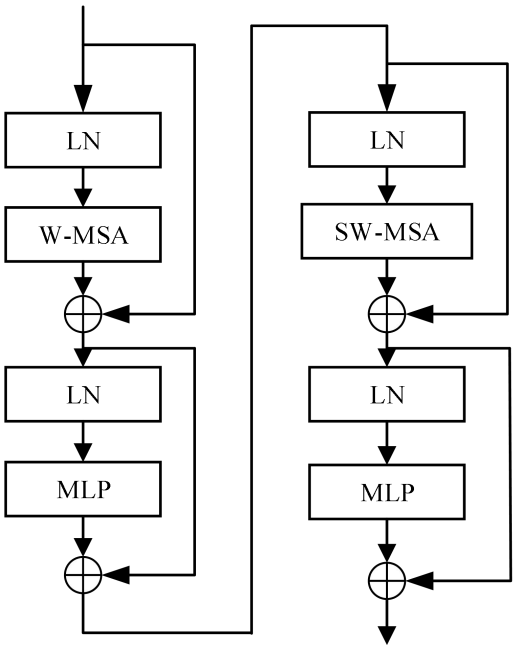


图 3.2 两个连续的 Swin Transformer Block

接下来分别对 Patch Merging、W-MSA、SW-MSA 等部分进行详细介绍。

（1）Patch Merging

Patch Merging 层的具体操作如图 3.3 所示。Patch Merging 层的作用类似于卷积神经网络里面的池化层，通过降采样调整通道数，每次降采样都是两倍。假设输入 Patch Merging 层是一个 [H,W,C] 的特征图，首先在输入特征图的行方向和列方向上间隔选取元素，拼接在一起后形成四个小的特征图。然后将这四个小的特征图在深度方向上进行 concat 拼接（通道数量叠加，实现了多尺度特征的融合），维度由 [H,W,C] 变为 $[H/2,W/2,4C]$ 。之后再通过一个 Layer Normalization 层进行归一化操作，为了满足每次降采样都是两倍的要求，最后通过一个全连接层在特征图的深度方向进行线性变化，将通道数降下来变为 2C，最后的输出为 $[H/2,W/2,2C]$，即通过 Patch Merging 层后，特征图的高和宽都会减半，而深度会翻倍。

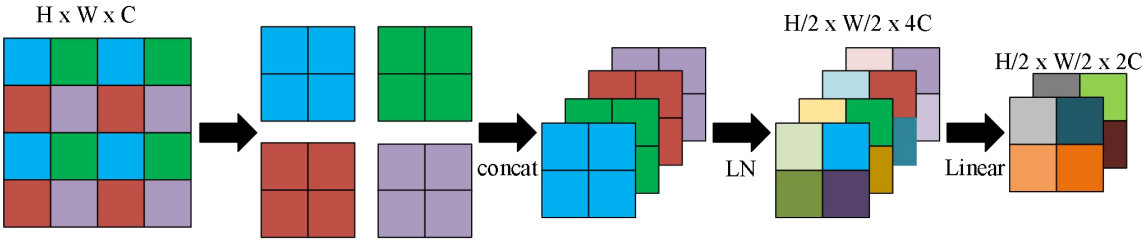


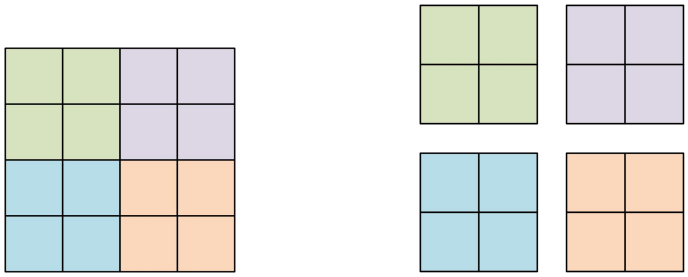
图 3.3 Patch Merging 操作

（2）W-MSA

原始 Transformer 结构中的全局注意力计算会导致计算量成平方倍的增长，而窗口自注意力

中国知网 https://www.cnki.net

W-MSA 提出了一种分块式地自注意力计算机制，首先将输入的特征图按照 $M \times M$ 大小划分成一个个 Windows，然后单独对每一个窗口内部进行自注意力计算，有效地减小了计算量，具体操作如图 3.4 所示（示例中 M=2 ）。



(a)多头自注意力机制　　(b)窗口自注意力机制

图 3.4 多头自注意力机制和窗口自注意力机制

原始多头自注意力（Multi-head Self-Attention， MSA）模块在进行自注意力计算过程中，特征图的每一个像素都需要和所有的像素进行计算，假设特征图的输入为 $X \in R^{h \times w \times C}$ ，其中 h 表示特征图的高度， w 表示特征图的宽度， C 表示特征图的深度，则自注意力计算公式为：

$$\text{Attention}(Q,K,V)=\text{SoftMax}(\frac{QK^T}{\sqrt{d}})V \tag{3.1}$$

式中，$Q^{hw \times C}=X^{hw \times C} \bullet W_Q^{C \times C}$ 是查询向量矩阵、$K^{hw \times C}=X^{hw \times C} \bullet W_K^{C \times C}$ 是键向量矩阵、$V^{hw \times C}=X^{hw \times C} \bullet W_V^{C \times C}$ 是值向量矩阵， W_Q 、 W_K 、 W_V 都是输入特征向量 X 的空间变换矩阵。

多头自注意力计算相较于原始自注意力计算，区别在于要将 concat 拼接后的结果通过融合矩阵 $W_O^{C \times C}$ 进行融合，具体公式为：

$$\text{MultiHead}(Q,K,V)=\text{Concat}(\text{head}_1,\cdots,\text{head}_h)W_O \tag{3.2}$$

式中， head_i 表示第 i 个头的自注意力计算。

如式(3.1)和(3.2)所示，生成 Q 、K 、V 每一个矩阵的计算量为 $hw \times C \times C=hwC^2$ ，同理 QK^T 、乘以 V 的计算量都为 $(hw)^2C$ ，乘以 W_O 的计算量为 hwC^2 。因此，原始多头自注意力模块 MSA 的总计算量为：

$$\Omega(\text{MSA}) = 4hwC^2 + 2(hw)^2C \tag{3.3}$$

而 W-MSA 模块将特征图输入 [h,w,C] 按照 $M \times M$ 大小划分成一个个 Windows，此时每一个 Window 的高和宽都为 M ，一共有 $\frac{h}{M} \times \frac{w}{M}$ 个窗口。

对每一个窗口进行自注意力计算，代入到式(3.3)中，此时 W-MSA 模块的总计算量为：

$$\Omega(\text{W-MSA}) = \frac{h}{M} \times \frac{w}{M} \times (4(MC)^2 + 2M^4C) = 4hwC^2 + 2M^2hwC \tag{3.4}$$

对比式(3.3)和(3.4)，代入具体特征图大小计算可知，W-MSA 模块的计算量相较于原始 MSA 的计算量减少了几十倍。

中国知网 https://www.cnki.net

（3）SW-MSA

相较于 W-MSA 模块只能在每个窗口内进行自注意力计算，无法在窗口与窗口之间进行信息传递，SW-MSA 模块引入了偏移窗口和还原窗口操作，使前一层 W-MSA 模块的 Windows 之间能够进行信息交流，具体操作如图 3.5 所示。

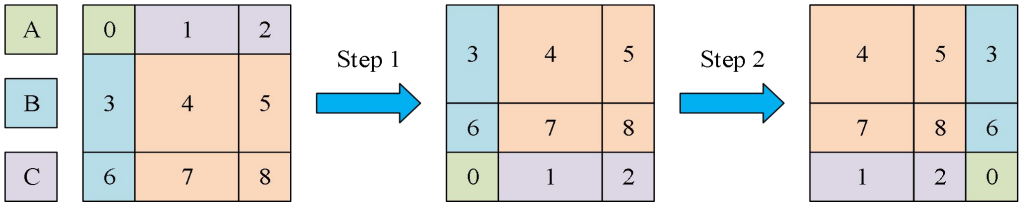


图 3.5 SW-MSA 模块偏移窗口操作

通过偏移窗口操作之后，由 W-MSA 模块输入的 4 个 Windows 变为了 9 个 Windows，首先将区域 A（0 窗口对应的区域）和窗口 C（窗口 1 和窗口 2 对应的区域）移动到最下方，然后再将区域 A 和区域 B（窗口 3 和窗口 6 对应的区域）移动到最右侧。移动完成后，窗口 4 单独作为一个窗口，窗口 3、5 合并成一个窗口，窗口 1、7 合并成一个窗口，窗口 0、2、6、8 合并成一个窗口，此时特征图又恢复到了原来的窗口数，再在这些合并后的窗口内进行自注意力计算，由于并没有增加窗口数，SW-MSA 模块的自注意力计算量与 W-MSA 模块一致，而且此时 W-MSA 模块输入的原始窗口之间就能够进行信息传递了，这使得 Swin Transformer 网络拥有了全局的感受野。为了防止不同区域的特征信息紊乱，在自注意力计算完成后，还需要将窗口还原到原来的位置上。

综上所述，Swin Transformer 网络的优点有：

1）提出了 Patch Merging 层，解决了视觉图像的多尺度问题，提供了各个尺度的维度信息；

2）提出了 Shifted Windows 移动窗口操作，让相邻的窗口之间得到交互，从而实现了近似的全局特征提取；

3）自注意力计算复杂度是线性增长而不是平方式增长，极大地降低了 Transformer 结构的计算复杂度。

因此，本文基于 Swin Transformer 网络构建了一个类似于二维卷积层 Conv2D 的网络层 SwinT 层，该层的结构如图 3.6 所示。为了能够增大 SwinT 层的替代性，类似 Conv2D 的，SwinT 层首先采用一个参数 downsample 决定是否进行降采样操作；然后由于只有 W-MSA 模块和 SW-MSA 模块成对出现时，Swin Transformer 网络才具有移动窗口自注意力机制，因此在 SwinT 层中同时包含了这两个结构；最后用一个 3x3 的卷积层代替 MLP 层进行线性映射操作，将 SwinT 层输出的通道数映射成目标输出通道数。

中国知网 https://www.cnki.net

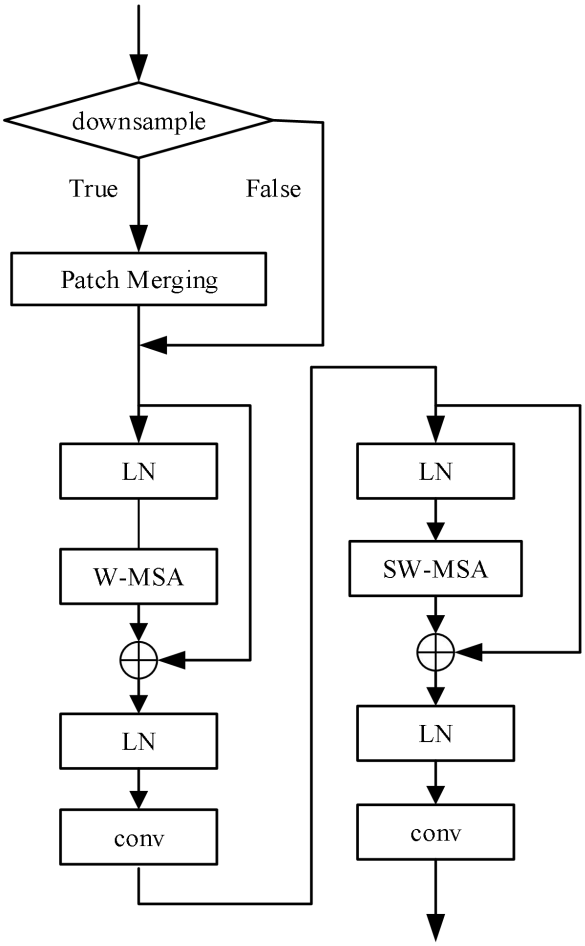


图 3.6 SwinT 层网络结构

3.1.2 ResNet 网络

传统的 CNN 网络采用多阶段层级式构建方式，获得了输入图像的多尺度特征信息和网络学习特征的能力，并且可以通过堆叠卷积层和池化层（增大深度）来丰富特征的“层次”。但是当网络堆叠到一定的深度时，会出现两个问题：

1）梯度消失或梯度爆炸。随着模型深度的进一步加深，根据损失函数计算的误差通过梯度反向传播的方式对深度网络权值进行更新时，得到的梯度值接近 0 或特别大。当梯度接近为 0 时，会导致 CNN 网络模型的参数不再被更新，从而导致模型的训练失败；当梯度由于链式求导规则连续乘积，变得特别大时，模型的学习训练不再变得稳定，容易导致训练失败。

2）退化问题。当 CNN 模型的学习效果达到一定的准确率时，此时网络层数的进一步加深，不仅不会有益于网络的训练性能，反而会增大模型的训练误差和测试误差，从而导致网络层数越深退化现象越严重。

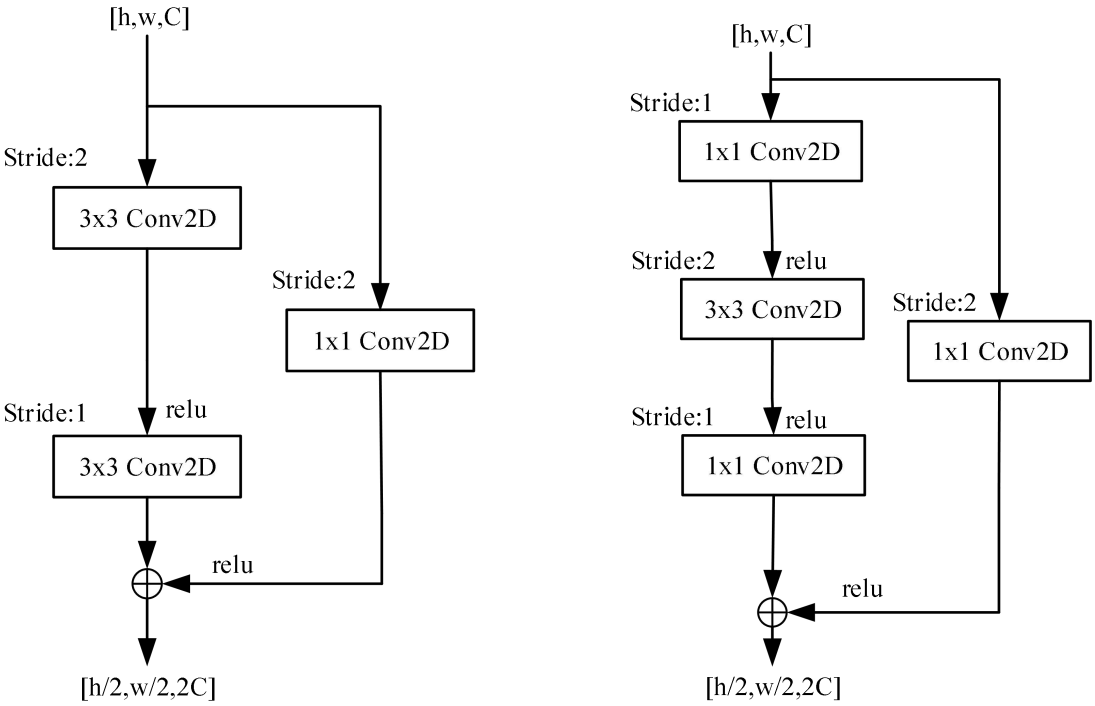
针对上述两个问题，Kaiming He 等人于 2015 年提出 ResNet 网络模型[75]，来解决梯度消失

中国知网 https://www.cnki.net

/爆炸问题和网络模型退化问题：

1）针对梯度消失或梯度爆炸问题，ResNet 网络中通过对数据进行预处理操作和使用 Batch Normalization（BN）层加速训练的形式来解决。

2）针对模型退化问题，ResNet 网络提出了一种 residual 结构（残差结构），该结构采用 Shortcut 连接的模式，具体表现为通过跳层连接，将模块的输入直接连接到模块的输出，使得模型能够表达输入与输出之间的恒等映射，ResNet 的基础模块如图 3.7 所示：



(a)网络层数较少时的残差模块　　(b)网络层数较多时的残差模块

图 3.7 ResNet 基础模块

ResNet 残差模块的特点是，为了使主分支（模块左侧的分支）的输出特征能和 Shortcut 分支（模块右侧的分支）的输出特征相加，必须保证两个分支的输出特征张量拥有相同的形状。为了减少网络运行产生的时延和不增加模型的参数数量，本文采用层数为 8 的残差网络 ResNet8 作为本文的骨干网络，由一个 5x5 的卷积层、3x3 的最大池化层以及三个残差模块 RES BLOCK 组成，ResNet8 网络结构如图 3.8 所示：

中国知网 https://www.cnki.net

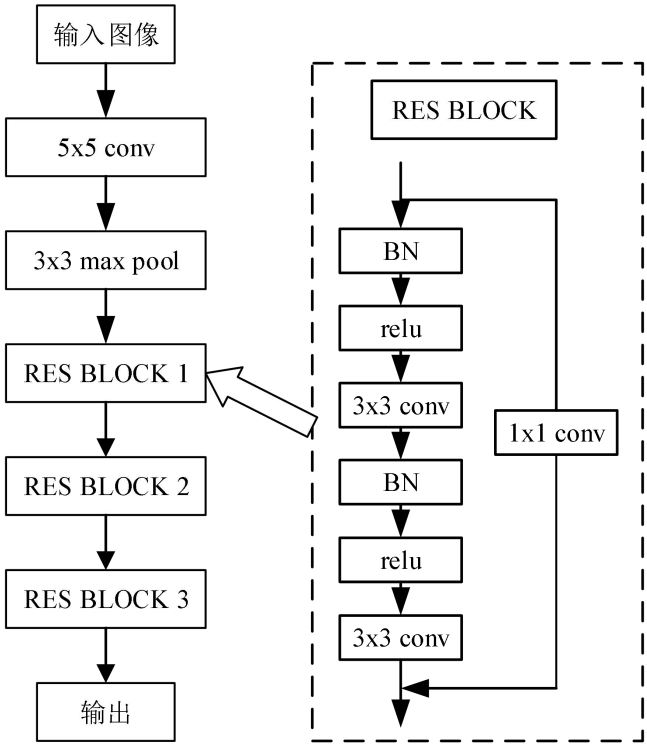


图 3.8 ResNet8 网络结构

3.1.3 整体网络架构

本文提出一种单输入多输出的无人机防撞预测模型，通过输入无人机实时采集的单目图像，输出当前环境下无人机的碰撞概率预测值和绕开障碍物所需的转向角度，预测模型的整体架构如图 3.9 所示：

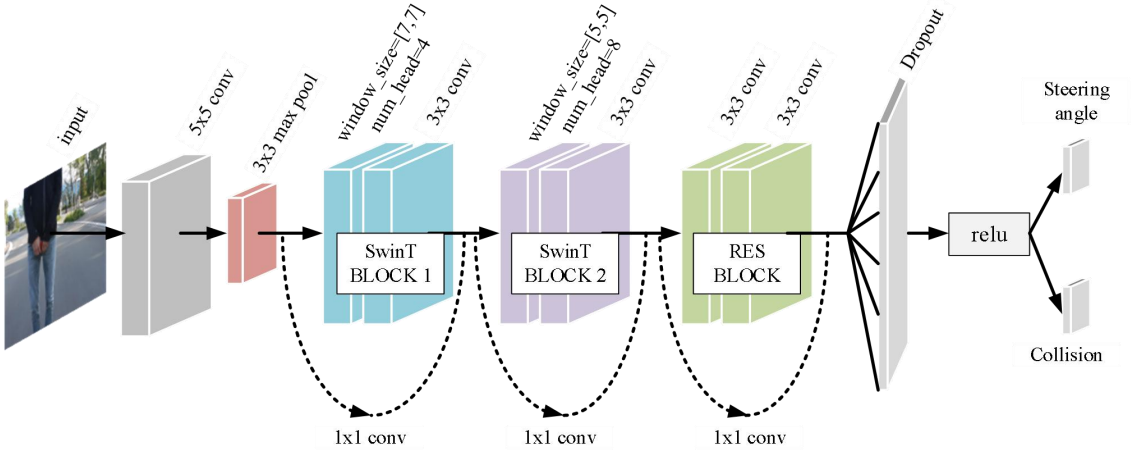


图 3.9 预测模型整体架构图

碰撞概率预测任务是一个图像二分类任务，需要预测模型提取飞行环境图像中的局部障碍

中国知网 https://www.cnki.net

物特征，根据障碍物的空间信息以判断无人机与障碍物之间的距离，输出预测的碰撞概率。而转向角预测任务是一个回归任务，更加关注障碍物周围的无碰撞区域，提取输入图像的全局位置特征信息和多尺度高维语义信息，输出无人机绕过障碍物所需的转向角大小。因此，本文提出一种将 SwinT 层代替 RES BLOCK 模块中进行降采样操作的 3x3 卷积层的特征提取模块 SwinT BLOCK，该模块可以通过 SwinT 层提取输入图像的高级全局特征信息，通过 Shortcut 分支上的二维卷积层 Conv2D 提取局部特征信息，并通过残差结构将两种特征相加。SwinT BLOCK 模块融合了卷积结构泛化能力强和 Swin Transformer 结构模型容量大的优点，该模块的结构如图 3.10 所示：

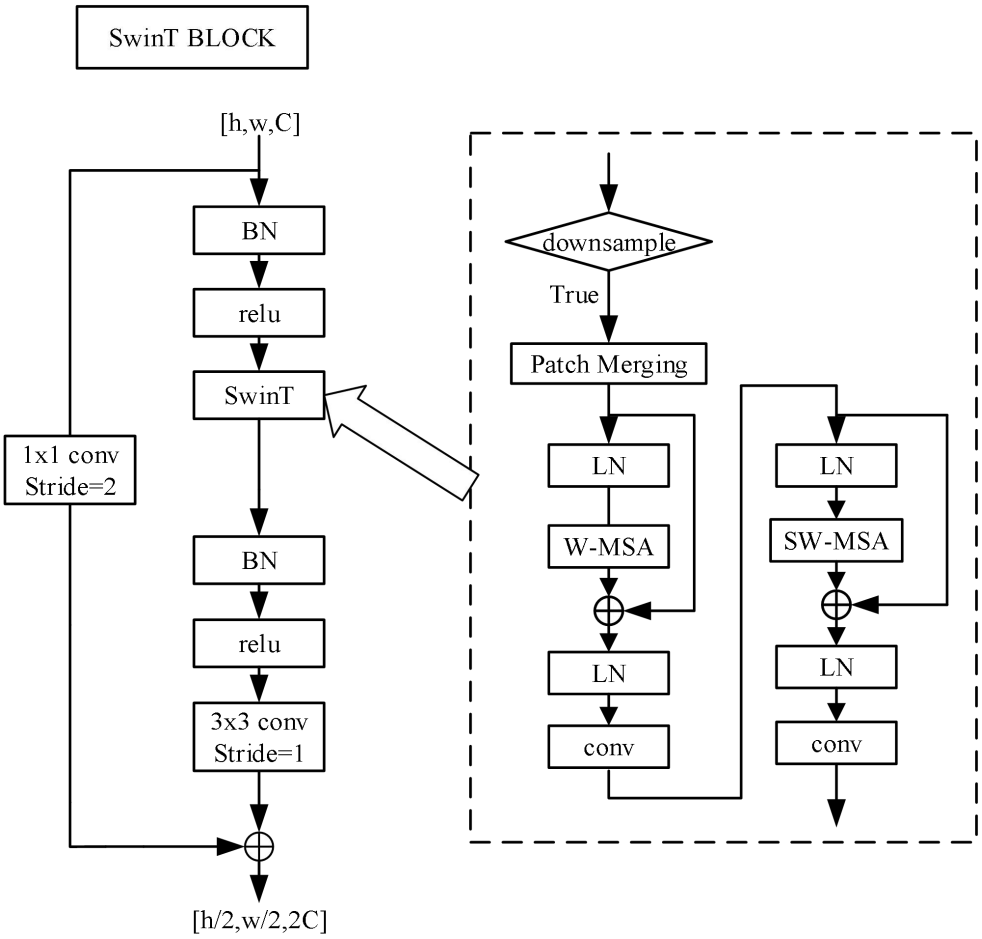


图 3.10 SwinT BLOCK 模块

SwinT BLOCK 模块首先采用批标准化处理（Batch Normlization，BN），对每一个批次的输入特征张量进行归一化操作，这样就把这一个批次中的所有样本关联在了一起，提高了模型的泛化能力；然后将经过 relu 激活函数激活后的数据传入 SwinT 层中进行移动窗口自注意力计算，提取全局特征信息；为了和 Shortcut 分支提取的特征张量拥有相同的形状，主分支的 3x3 卷积层步长为 1，不进行降采样操作，并且为了防止模型过拟合，3x3 的卷积层采用了 L2 正则

中国知网 https://www.cnki.net

化，使相关参数权重加速下降。

SwinT 层中的 W-MSA 模块和 SW-MSA 模块要求划分窗口的高和宽必须能被输入特征图的高和宽整除，因此到第三个特征提取模块时，输入的特征图大小并不能够满足 SwinT BLOCK 模块窗口自注意力计算的要求，因此第三个模块保留 RES BLOCK 模块的设计。如图 3.11 所示，经过三个阶段的特征提取之后，通过 Flatten 全连接层将特征向量展平，然后连接了删除率为 0.5 的 Dropout 层防止模型过拟合，最后将提取的特征映射到碰撞概率预测和转向角预测两个分支。

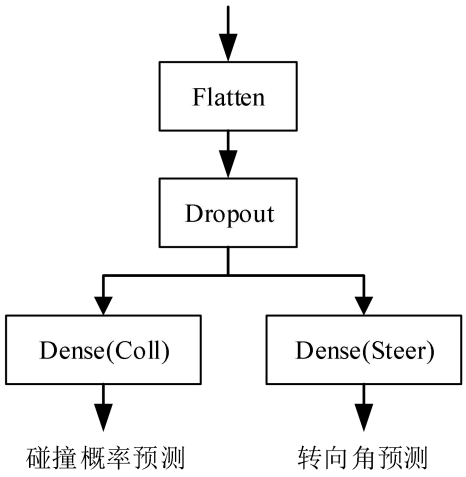


图 3.11 特征映射模块结构

无人机防撞预测和避障航向预测网络模型主要由上文介绍的的 SwinT BLOCK 模块和 RES BLOCK 模块组成，该模型的具体结构参数如表 3.1 所示：

表 3.1 预测模型结构参数

网络层	输出特征向量尺寸	卷积核大小	移动窗口大小	步长
输入图像	(200,200,1)	\	\	\
卷积层	(100,100,32)	5x5	\	2
最大池化层	(49,49,32)	3x3	\	2
BN + relu	(49,49,32)	\	\	\
SwinT 层	(25,25,32)	\	7x7	\
BN + relu	(25,25,32)	\	\	\
卷积层	(25,25,32)	3x3	\	1
BN + relu	(25,25,32)	\	\	\
SwinT 层	(13,13,64)	\	5x5	\
BN + relu	(13,13,64)	\	\	\
卷积层	(13,13,64)	3x3	\	1

中国知网 https://www.cnki.net

(续)接表 3.1

网络层	输出特征向量尺寸	卷积核大小	移动窗口大小	步长
BN + relu	(13,13,64)	\	\	\
卷积层	(7,7,128)	3x3	\	2
BN + relu	(7,7,128)	\	\	\
卷积层	(7,7,128)	3x3	\	1
Flatten 层	1x6272	\	\	\
全连接层(Coll)	1x1	\	\	\
全连接层(Steer)	1x1	\	\	\

3.1.4 目标损失函数设计

由图 3.9 可知，预测模型的特征提取网络由转向预测和避障预测两个任务共享，转向预测是一个回归任务，避障预测是一个二分类任务，分别使用均方根差（MSE）损失函数和二进制交叉熵（BCE）损失函数来训练转向预测和碰撞预测，均方根差损失函数公式如下：

$$L_{\mathrm{MSE(X,h)}}=\sqrt{\frac{1}{m}\sum_{i=1}^{m}(\mathrm{h}(x_i)-y_i)^2} \tag{3.5}$$

式中，X 表示数据集的所有特征，$\mathrm{h}(x_i)$ 是转向角预测函数，m 表示数据集中的图像数量，x_i 和 y_i 表示第 i 张图像及其转向角标签。二进制交叉熵损失函数如下：

$$L_{\mathrm{BCE(p,}z_i\mathrm{)}}=-z_i\log(\mathrm{p}(x_i))+(1-z_i)\log(1-\mathrm{p}(x_i)) \tag{3.6}$$

式中，z_i 表示第 i 张图像的碰撞概率标签（设定碰撞时为 1，无碰撞时为 0），$\mathrm{p}(x_i)$ 是碰撞概率预测函数。

由于回归任务 MSE 梯度的范数与绝对转向误差成比例，因此在训练初始阶段，回归任务的梯度要比二分类任务大得多。两个任务损失所产生的梯度大小非常不同，只是单纯的拟合相加的话会带来模型难以收敛的问题，所以本文通过在模型训练过程中对两个损失之间施加权重来解决这个问题，所以调整损失函数为：

$$L_{\mathrm{tot}}=L_{\mathrm{MSE}}+\max(0,1-\mathrm{e}^{-0.1(B_{epoch}-25)})L_{\mathrm{BCE}} \tag{3.7}$$

式中，L_{tot} 是训练的总损失值，L_{MSE} 和 $L_{BC\mathrm{E}}$ 分别是转向预测和碰撞预测任务损失值，B_{epoch} 表示当前训练批次。如式(3.7)所示，本文设置 MSE 的权重系数始终为 1，而 BCE 的权重系数通过式中的公式动态调整，模型训练结果表示模型能够收敛成功。

中国知网 https://www.cnki.net

3.2 模型性能评估指标

为了量化本文防撞预测模型转向预测和碰撞预测的性能，采用均方根误差（Root Mean Square Error, RMSE）和解释方差比（Mean Absolute Error, EVA）两个指标来评估模型转向预测的性能，采用平均分类精度和 F1 分数来评估碰撞预测的性能。均方根误差（RMSE）是用来衡量预测值与真实值之间的偏差，其计算公式为：

$$X_{\mathrm{RMSE}}=\sqrt{\frac{1}{m}\sum_{i=1}^{m}(y_{pred}-y_{true})^{2}} \tag{3.8}$$

式中，m 表示测试数据集中的图像数量，y_{pred} 和 y_{true} 分别表示第 i 张图像的预测转向角值和真实转向角值。解释方差比（EVA）表示预测值与真实值两组数据的波动情况，其计算公式为：

$$X_{\mathrm{EVA}}=\frac{\mathrm{Var}[y_{true}\text{-}y_{pred}]}{\mathrm{Var}[y_{true}]} \tag{3.9}$$

式中，Var[y] 表示转向角值 y 的方差计算公式。

碰撞预测任务实际上是一个二分类任务，输出为碰撞（标签为 1）或未碰撞（标签为 0），平均分类精度（Accuracy）计算公式为：

$$\mathrm{Accuracy}=\frac{TP+TN}{TP+TN+FP+FN} \tag{3.10}$$

式中，TP 表示预测值和真实值都表示为碰撞的样本个数；TN 表示预测值和真实值都表示为未碰撞的样本个数；FP 表示真实值表示未碰撞而预测值表示为碰撞的样本个数；FN 表示真实值表示为碰撞而预测值表示未碰撞的样本个数。F1 分数是用来衡量二分类模型精确度的一种指标，它同时兼顾了分类模型的精确率（Accuracy）和召回率（recall），召回率的计算公式为：

$$\mathrm{recall}=\frac{TP}{TP+FN} \tag{3.11}$$

F1 分数的计算公式为：

$$\mathrm{F1}=2\frac{\mathrm{Accuracy}\cdot\mathrm{recall}}{\mathrm{Accuracy}+\mathrm{recall}}=\frac{2TP}{2TP+FP+FN} \tag{3.12}$$

本文硬件实验平台和地面站电脑之间的 WIFI 通信频率为 30Hz，则数据传输周期为 33~34ms，如果本文设计的四旋翼无人机防撞预测模型计算耗时大于预测数据传输周期，则本次的无人机避障指令并不能及时提供给四旋翼无人机进行避障操作，这样本文设计的避障方法就不具备实际意义。因此，本文设计的防撞预测模型计算处理时间应小于 33ms。

中国知网 https://www.cnki.net

3.3 模型训练结果及分析

3.3.1 数据预处理

首先对四旋翼无人机机载单目相机进行相机标定，然后通过该相机以 30Hz 的固定频率对无人机飞行方向正前方进行环境采样，将采集图像传递给本文的防撞预测模型进行下一步的图像数据预处理。由表 3.1 可知，模型的输入图像大小要求为(200,200)，而本文使用的 Udacity 转向预测数据集和本文采集的防撞预测数据集中的图像尺寸并不同一，而且图像大小远大于(200,200)，所以在进行模型训练之前，需要对数据集数据进行预处理操作。为了保留飞行环境图像中更多的有效环境特征，本文首先将原始图像进行压缩调整，由于 Udacity 转向数据集和 Rpg 碰撞数据集中图像的长宽比均为 4:3，因此将图像统一压缩调整为(320,240)；然后再裁剪图像使剩余的部分包含大量对无人机避障飞行有用的特征信息，在实际飞行过程中，无人机更关注飞行正前方的障碍物信息，因此本文绕着图像中心裁剪出大小为(200,200)的部分作为模型的输入；为了验证不同类型图像（灰色图像、RGB 图像）对模型性能的影响，本文还可以在训练前调整图像为不同的形式。模型输入图像预处理具体操作如图 3.12 所示：



图 3.12 图像数据预处理操作

3.3.2 相关参数设置

本文中模型训练采用 Adam（Adaptive Moment Estimation）优化器，该优化器适用于数据量较大或模型参数量较多的网络，需要修改的参数较少，且梯度下降速度快，很快就能达到目标最优的网络模型，本文的训练数据集样本个数在 63000 个以上，综合计算效率和内存需求的考虑，选择 Adam 优化器对模型进行优化，设置模型学习率为 0.001，学习率衰减系数为 10^{-5}。

为了防止模型过拟合，本文采用在每一个 3x3 卷积层使用 L2 正则化和在全连接层之后衔接 Dropout 层的操作，提高模型的泛化能力，L2 正则项系数都设置为 10^{-4}，Dropout 层删除率设置为 0.5。此外，网络模型的分批数（Batch）为 32，一共训练 130 个周期（Epoch）。

3.3.3 模型性能评估结果与分析

为了评估本文设计的无人机防撞预测和避障航向预测网络模型在无人机避障任务上的性能

中国知网 https://www.cnki.net

表现，基于 TensorFlow 框架用 python 语言搭建了本章设计的预测网络模型，并分别在 AMD Ryzen 5 3500U CPU、RTX 3090 GPU 上学习训练了该模型。

碰撞预测训练数据集来自 Rpg 数据集和本文自己收集并标注的碰撞预测数据集，拥有 30000 张以上图像，转向预测训练数据集来自 Udacity 数据集，拥有 33000 张以上图像；验证数据集中标有碰撞概率标签和标有转向角标签的数量都在 500 张左右；测试图像集中一共有 6958 张图像，其中标有碰撞概率标签的有 1679 张图像，标有转向角标签的有 5279 张图像，训练集和测试集图像数量比约为 9:1。测试图像集中碰撞帧的数量为 402 张图像，非碰撞帧数量为 1277 张图像，非碰撞帧与碰撞帧数量比约为 4:1。在 CPU 上训练一轮的时间约为 20 分钟，一共训练 130 个周期，训练一次的时间为 45 个小时；在 GPU 上训练一轮的时间约为 9 分钟，训练一次的时间为 20 个小时。

预测模型训练损失误差曲线如图 3.13 所示。预测模型一共进行了 130 个周期的学习，随着训练次数的迭代，预测模型的训练误差不断衰减为 0，而验证误差不断震荡后，最终收敛于模型的训练误差左右，这说明预测模型学习训练状况良好，没有出现模型过拟合或欠拟合现象。模型的训练误差衰减为 0，说明预测模型在训练数据集上的拟合能力强，模型容量大；模型的验证误差衰减为 0，说明预测模型在不参与训练的数据集上拟合能力强，模型泛化能力强。

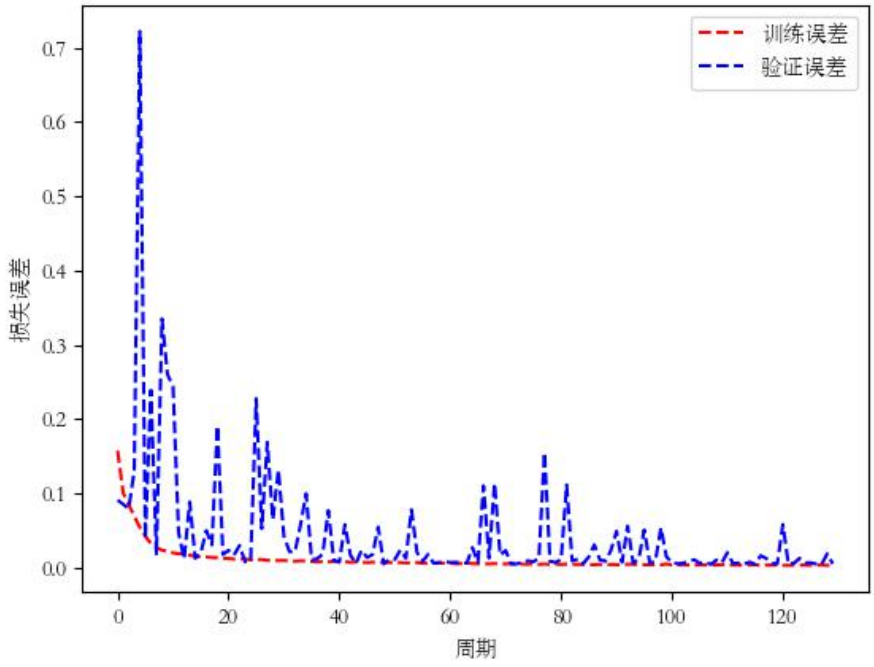


图 3.13 预测模型训练损失误差曲线

撞测试数据集图像来自于 Rpg 数据集和本文采集的数据集，为了清晰直观地展示预测模型碰撞预测任务的结果，图 3.14 展示了在碰撞预测测试数据集上评估碰撞分类的混淆矩阵（Confusion Matrix）。在混淆矩阵中，左上表示 *TN*，右上表示 *FP*，左下表示 *FN*，右下表示

中国知网 https://www.cnki.net

TP。设置当碰撞概率预测值 $p_t \geq 0.5$ 时，输出结果为碰撞；当碰撞概率预测值 $p_t < 0.5$ 时，输出结果为未碰撞。如图 3.14 所示，碰在真实标签值为未碰撞（碰撞概率标注为 0）的图像集上，预测模型的准确率高达 99.3%；在真实标签值为碰撞（碰撞概率标注为 1）的图像集上，预测模型的准确率高达 91.8%。结果表明，预测模型能够准确地预测出无人机当前飞行环境下危险情况。

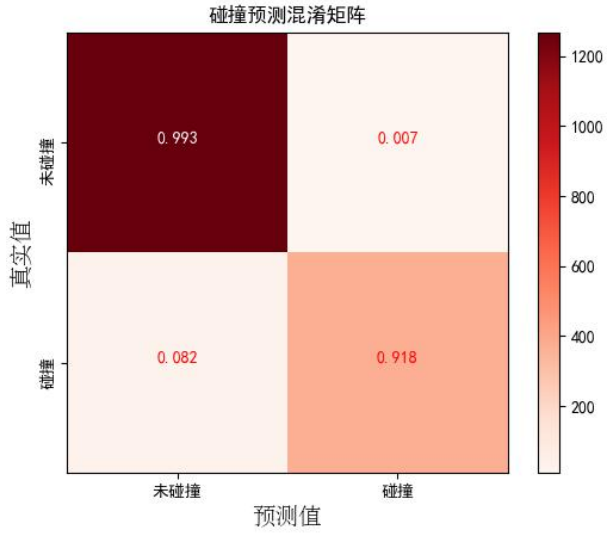


图 3.14 预测模型碰撞分类的混淆矩阵

转向测试数据集图像来自于 Udacity 数据集，为了展示预测模型转向预测任务的结果，图 3.15 展示了在转向预测测试数据集中实际转向与预测转向的概率密度函数（Probability Density Functions, PDF），在概率密度函数中设置当转向角预测值 $s_t > 0$ 时，四旋翼无人机向右偏转；当转向角预测值 $s_k < 0$ 时，四旋翼无人机向右偏转。如图 3.15 所示，预测模型输出的转向角预测值和真实值高度重合，证明当无人机飞行前方出现障碍物时，预测模型能够准确地输出无人机避开障碍物所需的转向角。

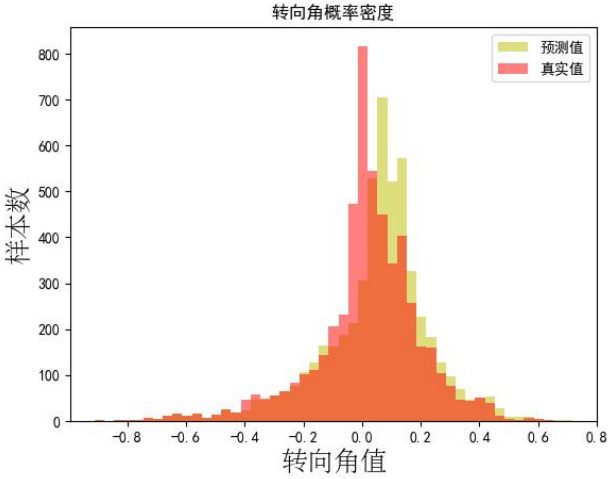


图 3.15 转向预测的概率密度函数

中国知网 https://www.cnki.net

为了进一步评估设计的预测模型在无人机避障任务上的性能结果，选用计算机视觉应用领域中具有较好表现的卷积神经网络网络与本文网络进行对比。这些模型分别是：

（1）DorNet，该网络是 Antonio Loquercio 等人于 2018 年提出的一种卷积神经网络，具有相对较少的层级结构和学习参数量；

（2）ResNet-50，该网络是一种深层卷积神经网络，通过 ResNet 基础单元搭建而成，是对比网络中层级数和参数量最大的网络；

（3）BiSeNet，该网络是一种双分支结构卷积神经网络，一个分支用来提取输入图像的多尺度深度信息，另一个分支用来提取图像的全局空间特征信息，通过全连接层拼接特征后，完成不同的图像处理任务。

所有网络都训练 130 个周期，将每一个网络训练的模型都在测试数据集上进行测试，每个网络模型的最佳性能测试结果如表 3.2 所示，其中模型参数量表示模型的大小程度，参数量越大，模型的训练时间也会越长；每张图像测试时间通过测试图像数据集总体耗费时间取平均值。

表 3.2 不同网络避障预测和转向预测性能结果

模型	RMSE	EVA	Accuracy	F1 分数	模型参数量	每张图像测试时间(CPU)
DorNet	0.111	0.741	95.2%	0.903	$3.2x10^5$	9ms
ResNet-50	0.064	0.875	98.6%	0.969	$2.36x10^7$	41ms
BiSeNet	0.138	0.707	92.5%	0.833	$4.4x10^5$	14.9ms
Our Network	0.074	0.859	97.5%	0.946	$3.6x10^5$	11ms

由表 3.2 可知，在碰撞预测任务上，本文模型的平均分类精度（Accuracy）和 F1 分数分别达到了 97.5%和 0.946；在转向预测任务上，均方根误差（RMSE）和解释方差比（EVA)）分别为 0.074 和 0.859。相较于 DorNet、BiSeNet 两个网络，在测试时间相差不大的情况下，本文模型展现出了更好的避障预测和转向预测性能；而 ResNet-50 网络预测性能虽然优于本文模型，但是处理时间却大于了 33ms，因此不适用于本文设计的无人机避障方法。综上，本文模型在综合预测性能和处理时间考虑上达到了最优。

3.3.4 真实场景测试

选取不同的实验环境对基于 Swin Transformer 和 ResNet 的预测模型进行测试，首先进行室内环境测试，测试结果如图 3.16 所示。在 3.16(a)环境中，无人机的左前方出现了立柱形障碍物，此时预测模型给出的碰撞概率预测值为 0.99，转向角预测值为 0.3，即无人机的飞行方向出现障碍物，若继续飞行将会发生碰撞，如果要避开障碍物应向右偏转，此时模型给出的预测结果符合实际认知情况；而在 3.16(b)环境中，无人机的右前方出现了立柱形障碍物，此时预测模型给出的碰撞概率预测值为 0.99，转向角预测值为-0.24，即无人机前方出现障碍物，应向左偏转，

中国知网 https://www.cnki.net

也符合实际认知。



(a) (b)

图 3.16 室内环境测试

然后进行室外环境的测试，测试结果如图 3.17 所示。图 3.17(a)和(b)分别是无人机飞行前方出现大树和路灯的情况，此时预测模型给出的碰撞概率预测值 p_t 均在 0.5 以上，说明预测模型识别出了障碍物并发出了预警；由于距离大树和路灯太近，如果想要避开障碍物，无人机所需转向角度也应该随之增加，所以预测模型给出的转向角预测值 s_t 均在 0.85 以上（负值表示左转向），室外测试结果满足实际情况。



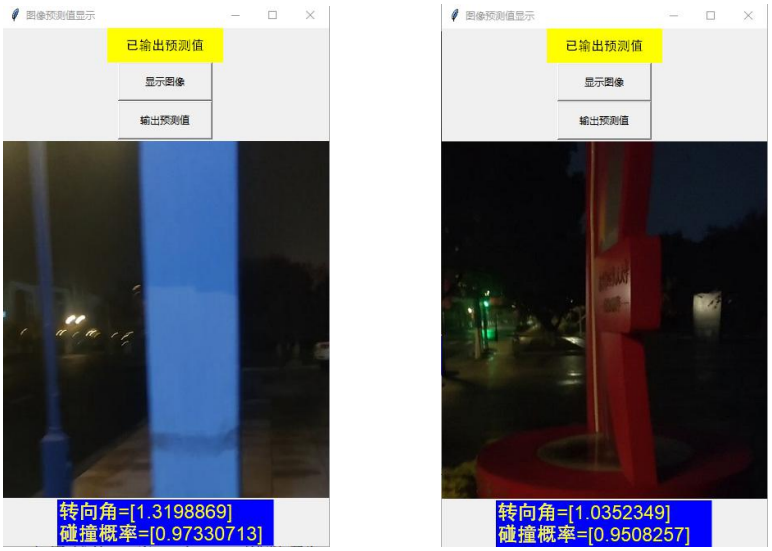
(a) (b)

图 3.17 室外环境测试

为了测试在不同光照情况下，预测模型是否能够满足无人机避障需求，进行了多路段不同时刻测试，图 3.18 是模型在夜间环境下的测试结果。图 3.18(a)和(b)分别是无人机飞行方向上出现立柱式障碍物和不规则立标的情况，此时预测模型给出的碰撞概率预测值 p_t 均在 0.5 以上，

中国知网 https://www.cnki.net

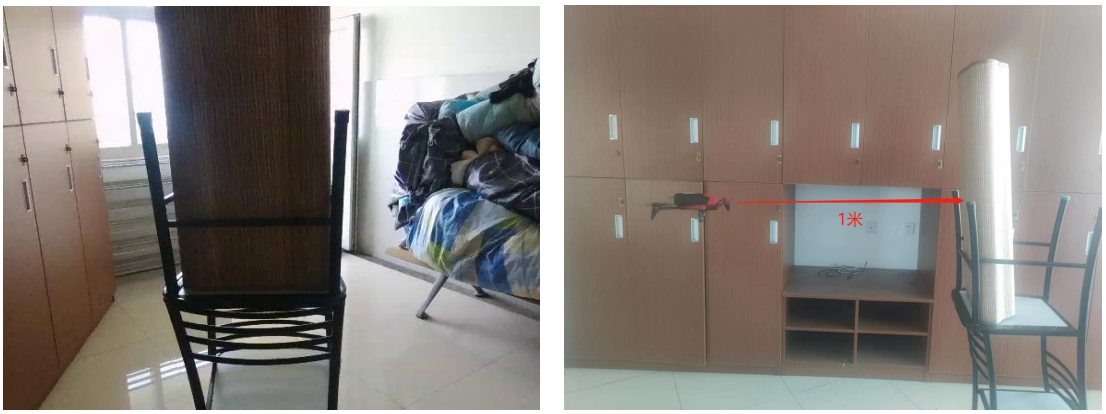
而且转向角预测值 s_t 均在 0.95 以上，结果表明即使在夜间时刻，当无人机前方出现障碍物时，预测模型也能够准确地预测出危险情况给出避开障碍物所需的转向角。



(a) (b)

图 3.18 夜间飞行环境

为了定量评估无人机预测模型的安全性能，分别在无人机距离障碍物固定长度的位置进行测试，测试环境如图 3.19 所示。启动无人机后，将无人机依次悬停在距离障碍物目标固定长度的位置，然后启动基于 Swin Transformer 和 ResNet 的预测模型，等待无人机携带的单目相机采集好环境图像（单目相机固定在无人机飞行方向的前端），经过图像数据预处理后，传入到训练好的预测模型中，输出无人机当前时刻的碰撞概率预测值和转向角预测值。



(a)无人机视角 (b)测试环境侧面图

图 3.19 无人机防撞预测示意图

为了使测试结果更具有普遍性，本文选取了城市环境中路灯、大树、墙壁、自行车、灌木、汽车等典型障碍物作为测试目标，分别距离测试目标 0.8、1、1.5、2、3 米等距离进行重复多次

中国知网 https://www.cnki.net

测试，测试现场如图 3.20 所示。

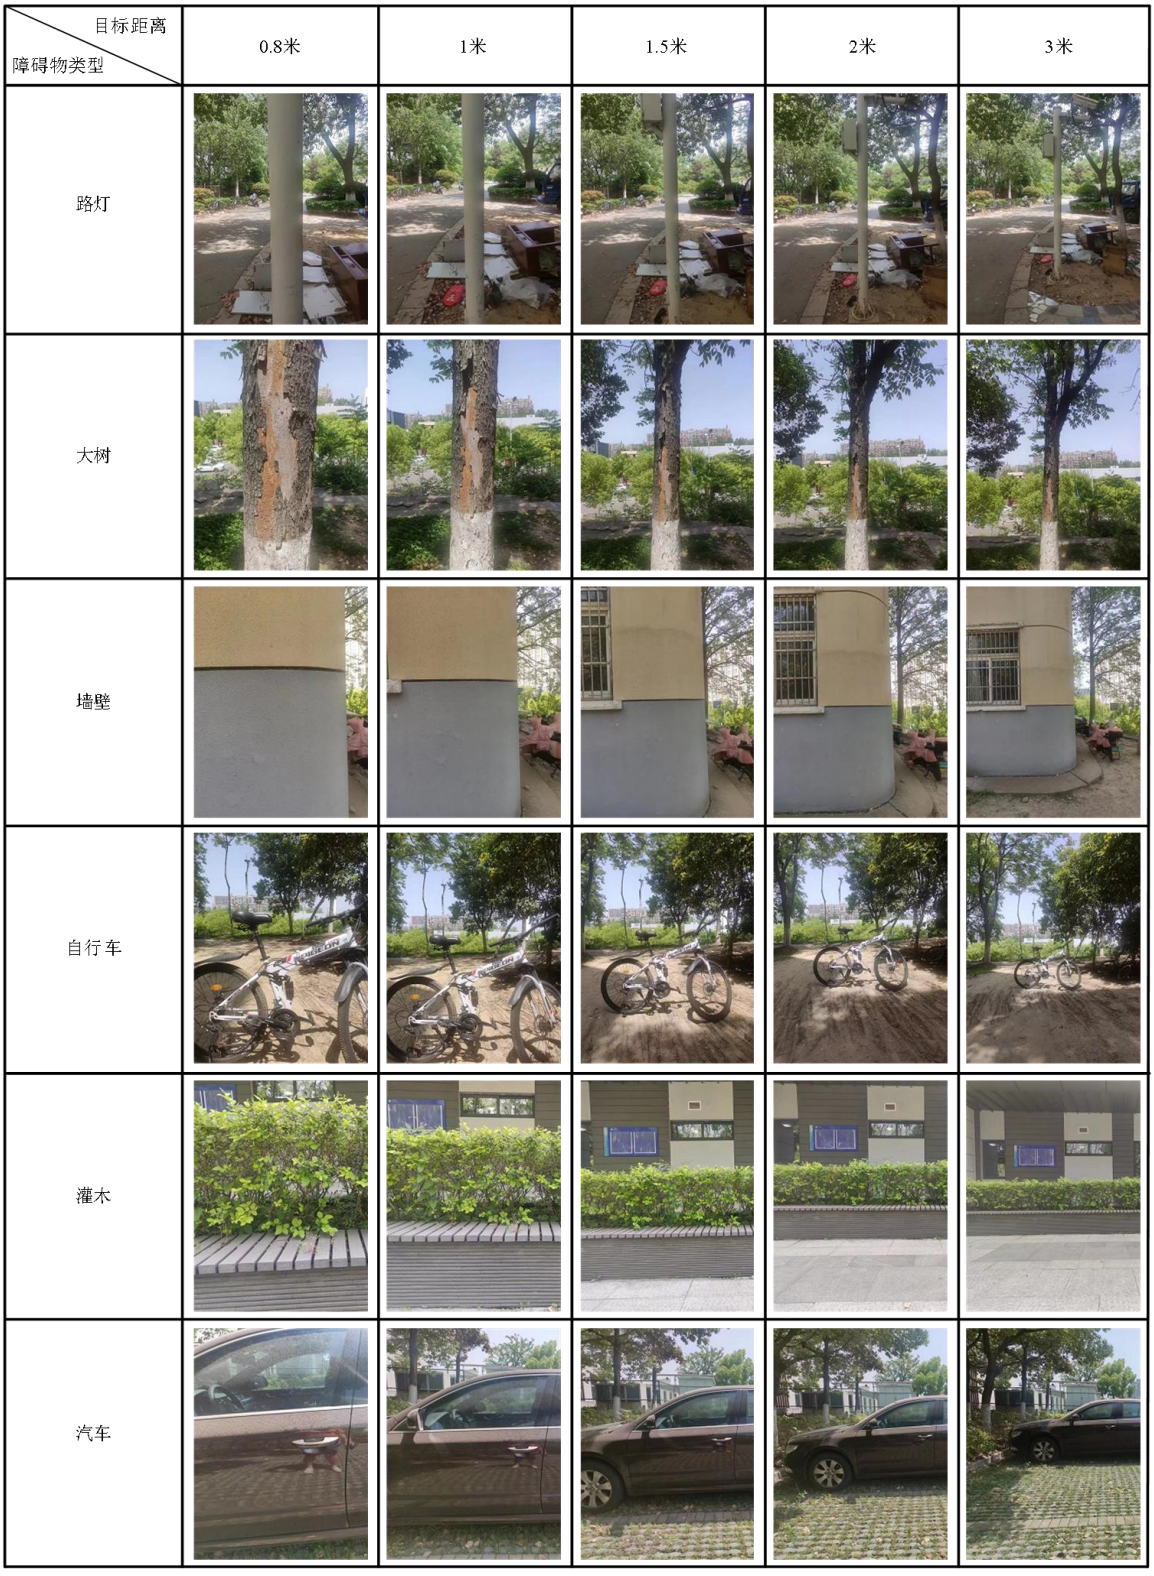


图 3.20 无人机防撞预测测试环境

中国知网 https://www.cnki.net

对基于 Swin Transformer 和 ResNet 的预测模型进行真实场景测试，测试结果如表 3.3 所示（当碰撞概率预测值小于 0.001 时表现为 0）：

表 3.3 预测模型定量测试

平均碰撞概率预测值 / 目标距离 / 障碍物类型	0.8 米	1 米	1.5 米	2 米	3 米
路灯	0.999	0.857	0.888	0.669	0.403
大树	0.966	0.801	0.888	0.034	0.434
墙壁	0.989	0.998	0.947	0.923	0.177
自行车	0.545	0.039	0.121	0.295	0.010
灌木	0.578	0.120	0	0	0.003
汽车	0.697	0.584	0.417	0.144	0.018

由表可以看出，当障碍物出现在无人机一定距离以内，预测模型一定可以识别到障碍物并发出预警，而且随着目标距离的缩短，预测模型给出的碰撞概率预测值也会随之增大。但在现实场景中，障碍物目标并不会单独存在，而是处于一个复杂多变的环境中，如预测模型给出的碰撞概率预测值在无人机距离大树 1 米处并没有 1.5 米处时大，这是因为当无人机处于距大树 1.5 米时，无人机单目相机视角内出现了其他可能发生碰撞的障碍物体。由于四旋翼无人机能够悬空飞行，所以当无人机面对如自行车、灌木、汽车等矮小型障碍物时的碰撞可能远小于面对路灯、大树、墙壁等障碍物。由真实场景测试结果可以看出，基于 Swin Transformer 和 ResNet 的预测模型能够很好的完成碰撞预警，并给出碰撞概率和转向角预测信息。

3.4 本章小结

本章进行无人机防撞预测与避障航向预测网络的设计，首先对 Swin Transformer 网络、ResNet 网络的原理和结构进行了介绍，然后基于 Swin Transformer 和 ResNet 网络设计了无人机避障预测网络；然后介绍了评估预测网络的性能指标，采用均方根误差（RMSE）和解释方差比（EVA）两个指标来评估转向预测的性能，采用平均分类精度和 F1 分数来评估碰撞预测的性能；最后展示了模型的训练结果，并在真实场景中对模型进行了测试，测试结果表明无人机防撞预测与避障航向预测网络模型能够有效地识别危险情况和准确地预测出避开障碍物所需的转向角。

中国知网 https://www.cnki.net

第四章　基于碰撞概率和转向预测信息的无人机避障研究

在已知四旋翼无人机当前飞行环境下碰撞概率预测值和转向角预测值的情况下，需要将这两个信息转化为四旋翼无人机的避障动作指令，才能完整地实现无人机的避障流程。本章首先进行模型预测结果滤波算法研究，将预测模型输入的碰撞概率和转向角值进行平滑处理；然后进行无人机防撞策略研究，研究不同障碍物情况下的无人机避障规则；最后进行基于 ROS 的无人机避障方法软件设计，在 Ubuntu18.04 和 ROS Melodic 环境下实现与四旋翼无人机的实时通信和环境感知，并输出准确、低延时的无人机避障控制指令。

4.1 模型预测结果滤波算法研究

本文通过四旋翼无人机机载单目相机采集前进飞行方向的环境图像，再通过 WiFi 通信将数据传送到装载有 ubuntu 系统的电脑地面站中进行数据分析、计算后，将控制命令发送回四旋翼无人机进行避障飞行。相较于装载有机载图像处理设备的四旋翼无人机，本文的硬件实验平台虽然通过减少机载设备获得了更好的机动性和更长的飞行时间，但是上位机电脑与无人机之间频繁的数据通信使得无人机接收到的预测模型输出结果等信息包含着许多噪声干扰，从而由基于碰撞概率和转向角预测信息计算获得的无人机避障指令波动较大，使得无人机避障飞行不稳定，甚至会影响到无人机防撞结果。为了使无人机避障指令平滑且连续，需要对预测模型输出的预测信息进行滤波处理，消除预测数据中的跳变、异常数据，确保无人机环境感知系统输出的结果安全可靠。

无人机环境感知系统输出的模型预测结果如图 4.1 所示，防撞预测信息曲线有很多不平滑的地方。红色框内显示的是四旋翼无人机遇到障碍物时的碰撞概率预测值变化情况，此时碰撞概率预测值接近为 1，说明无人机环境感知系统发现了障碍物并发出了预警信息。由图 4.1 可以看出，由于采集图像存在噪声、纹理结构模糊等原因使得碰撞概率预测值数据出现了许多跳变，如果预测值数据波动较大，直接将该数据传送给无人机避障策略决策系统后，无人机给出的避障指令可能会使得无人机继续飞行发生碰撞，严重的甚至会发生坠机。因此，针对环境感知系统输出的预测碰撞概率和转向角角度，首先需要进行滤波和平滑处理，消除掉防撞预测信息中的不稳定、不平滑部分，然后再将处理好的预测数据传送给无人机避障策略决策系统，决策出当前环境下四旋翼无人机的前向速度、偏航角、垂直爬升高度等指令。

中国知网　https://www.cnki.net

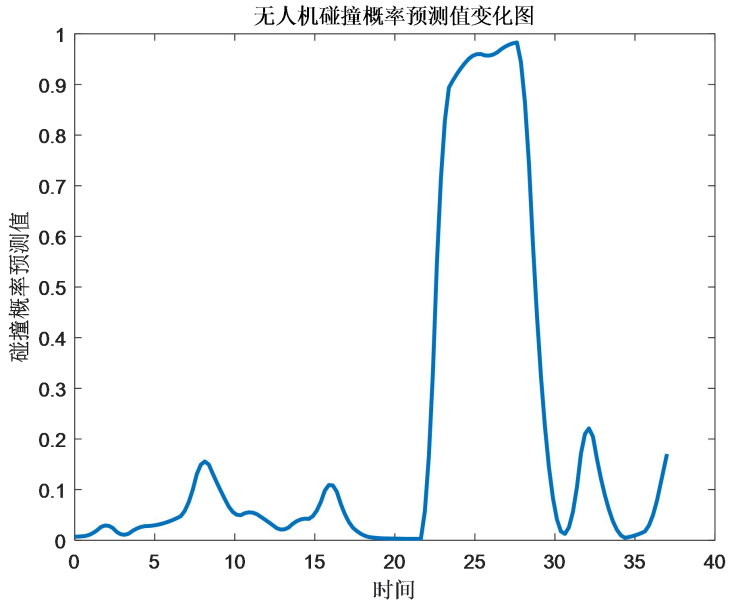


图 4.1 预测模型输出结果

4.1.1 滤波算法选择

常用的数据平滑去噪滤波方法有低通滤波、限幅滤波、平滑滤波、中值滤波等，为了满足四旋翼无人机安全稳定地快速飞行，本文通过分析几种滤波算法的优劣，抉择出最适合本文避障飞行系统的滤波方法。

（1）低通滤波算法

低通滤波算法（Low Pass Filter, LPF）的工作原理为通过设置一个截止频率，当信号频率高于这个截止频率时，将信号数据赋值为 0，即高于截止频率的信号数据不能通过，但低于截止频率的数据保持原样，在这一工作过程中，低频信号数据不变，因此被称之为低频滤波。为了研究快速高效的低频滤波算法，本文选取了一阶低通滤波、巴特沃斯低通滤波两种方法进行分析。

1）一阶低通滤波算法

低通滤波算法适用于防撞预测信息数据处于低频而噪声干扰处于高频的情况，通过滤除预测数据中的干扰部分，低通滤波方法可以使数据中从 0 到低通滤波器截止频率的频率分量保持原状，而高频噪声部分归零。

一阶低通滤波算法又叫做一阶惯性滤波算法[76]，常用的一阶低通滤波滤波器为 RC 滤波电路，通常应用于模拟电路、脉冲数字电路中。通过并联一个电阻 R 和一个电容 C，使得 RC 滤波电路存在一个转折频率 $w_0 = 1/2\pi RC$，当电路输入信号频率低于 w_0 时，RC 滤波电路的总阻抗为电阻 R，当电路输入信号频率高于 w_0 时，RC 滤波电路的总阻抗为电阻 R 并上容抗 C，RC 并联电路这种在高频和低频部分总阻抗差异极大的特性，是其能够衰减高频信号的本质。一阶

中国知网 https://www.cnki.net

低通滤波器的传递函数为：

$$H(s)=\frac{Y(s)}{X(s)}=\frac{w_0K}{w_0+s} \tag{4.1}$$

式中，$X(s)$ 表示输入信号，$Y(s)$ 表示经过一阶低通滤波后的输出信号，K 表示增益，w_0 表示截止频率。一阶低通滤波滤波器传递函数框图如图 4.2 所示。

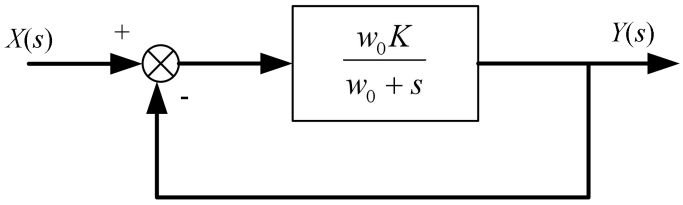


图 4.2 一阶低通滤波器传递函数框图

因为本文硬件实验平台装载的单目相机是以 30Hz 的工作频率采集环境图像，因此无人机防撞信息预测系统的输入是离散的，输出的防撞预测信息数据也是离散不连续的，所以一阶低通滤波滤波器的传递函数也应该进行 z 变换离散化，通过后向差分变换令 $s=(z-1)/zT$ 代入式(4.1)中：

$$H(\mathrm{z})=\frac{Y(z)}{X(z)}=\frac{1}{\frac{1-z^{-1}}{w_0T}+1}=\frac{w_0T}{1-z^{-1}+w_0T} \tag{4.2}$$

式中，T 为离散数据的抽样频率。再将上式转化为时域表示，可以得到：

$$Y(n)=(\frac{T}{\frac{1}{w_0}+T})X(n)+\frac{1}{w_0T+1}Y(n-1) \tag{4.3}$$

式中，$X(n)$ 表示当前采样值，$Y(n)$ 表示本次滤波之后的输出值，$Y(n-1)$ 表示上一次滤波之后的输出值，令 $\alpha=\frac{T}{\frac{1}{w_0}+T}$ 表示滤波系数，因此上式可简化为：

$$Y(n)=\alpha X(n)+(1-\alpha)Y(n-1) \tag{4.4}$$

2）巴特沃斯低通滤波算法

巴特沃斯低通滤波算法（Butterworth Low Pass Filter, BLPF）适用于噪声干扰与预测数据没有重叠的情况下，相较于一阶低通滤波算法，它拥有最大平坦限度的幅频响应特性，且没有滤波器输出大幅度衰减旳振荡的“振铃”现象[77]。由于巴特沃斯低通滤波器结构简单，滤波性能也能够很好地满足设计需要，因此广泛应用在无线电通信领域，其特点是该滤波器是一个全极点滤波器，它的幅频特性和相频特性都随着频率的增加而单调下降，直到频率增加到无穷大时才衰减为零。与一阶低通滤波算法相比，巴特沃斯低通滤波算法能够保证滤除数据和保留数据之间平稳过度，即保证滤波后的预测数据曲线光滑且波动小。巴特沃斯低通滤波器的传递函数

中国知网 https://www.cnki.net

为：

$$H(s)=\frac{Y(s)}{X(s)}=\frac{a_0}{b_n s^n+b_{n-1}s^{n-1}+\cdots+b_1 s+b_0} \tag{4.5}$$

式中，a_0 表示增益，b_0、$b_1\cdots b_n$ 均为实常数，分母多项式的幂次 n 表示滤波器的阶数，n 阶巴特沃斯低通滤波器是一个全极点滤波器，此时传递函数拥有有限个极点而没有有限个零点，阶数 n 越大，滤波器的幅频响应就越接近理想情况。同样对该传递函数进行 z 变换离散化，通过双线性变换令 $s=\frac{2(z-1)}{w_c(z+1)}$ 代入式(4.5)中：

$$H(z)=\frac{Y(z)}{X(z)}=\frac{a_0(z-1)^n}{b_n(\frac{2}{w_c})^n(z+1)^n+b_{n-1}(\frac{2}{w_c})^{n-1}(z+1)^{n-1}(z-1)+\cdots+b_1(\frac{2}{w_c})(z+1)(z-1)^{n-1}+b_0(z-1)^n} \tag{4.6}$$

式中，w_c 表示输入滤波器数据的采样频率。

巴特沃斯低通滤波器实际上就是多个一阶低通滤波器的串联，当两者的截止频率完全一致时，巴特沃斯低通滤波器在截止频率后的衰减明显要比一阶低通滤波器更大，所以在稳态裕度允许的条件下，巴特沃斯低通滤波器的性能要远优于一阶低通滤波器。

通过对一阶低通滤波算法和巴特沃斯低通滤波算法进行分析，总结发现低通滤波算法的优点是对于存在周期性干扰的信号序列，该算法具有较好的滤波效果，特别是当噪声干扰波动频率较高的情况下，它能够很好地完成保留有效信息，滤除高频噪声部分；低通滤波算法的缺点是其幅频特性相位滞后，虽然能够保证滤波后的信号序列光滑连续，但是灵敏度较差。

（2）限幅滤波算法

限幅滤波算法（Limiting Filter）适用于因偶然波动带来的误差干扰[78]，通过设置一个最大偏差值 A，如果当前时刻预测模型输出的预测值 $X(n)$ 与上一次滤波之后的输出值 $Y(n-1)$ 之差的绝对值小于 A 时，保留该数据；但如果本次预测值与上一预测值之差的绝对值大于 A 时，则可能发生了严重的干扰，当前时刻预测值无效，删除该值后直接用上一预测值代替。限幅滤波算法工作时的预测值有效值为：

$$Y(n)=\begin{cases} X(n), |X(n)-Y(n-1)|\le A \\ Y(n-1), |X(n)-Y(n-1)|> A \end{cases} \tag{4.7}$$

限幅滤波算法的优点是工作简单，且能消除随机误差带来的干扰；缺点是需要依靠个人的经验设置最大偏差值，无法直接获得最优值，且无法消除周期性的干扰，滤波后的信号序列也并不光滑。

（3）平滑滤波算法

中国知网 https://www.cnki.net

平滑滤波算法（Smooth Filter）通常应用于图像算法预处理环节，通过对图像进行模糊化操作，可以消除掉图像采集过程中的抖动、噪声等因素带来的干扰，平滑滤波算法的结果影响着图像特征提取、图像复原、模板匹配等一系列任务的准确性，因此合适的平滑滤波算法是对图像进行后续处理的保证，常见的平滑滤波算法有平均值滤波算法、中值滤波算法等。

平均值滤波算法包括算术平均值滤波[79]、滑动算术平均值滤波算法[80]等，都是通过对 N 个预测值数据进行算术平均后，替换掉当前时刻的防撞预测信息，相较于算术平均值滤波只是简单地对本次采集的图像进行 N 次防撞信息预测后求平均值，滑动算术平均值滤波算法是通过建立一个长度为 N 的序列，每次都将当前时刻获得的预测数据替换掉序列末尾的数据，同时删除序列队首的数据，把队列中的 N 个数据进行平均运算后作为平均值平滑滤波的结果，替换掉本次的预测数据。滑动算术平均值滤波算法工作时的预测值有效值为：

$$Y(n)=\frac{(X(n)+\sum_{n-N+1}^{n-1}Y(k))}{N} \tag{4.8}$$

式中，$Y(k)$ 表示第 k 次的防撞预测数据。

中值滤波算法是一种经过排序处理后的滤波方法，包括中位值滤波算法[81]、中位值平均滤波算法[82]等，中位值滤波算法是通过对当前时刻采集图像进行奇数次防撞预测后，将预测数据从小到大进行排列后，取中间值作为本次滤波后的有效预测信息。中位值滤波算法工作时的预测值有效值为：

$$Y(n)=med(X(n),Y(n-1),\cdots,Y(n-N+1)) \tag{4.9}$$

式中，N 是奇数。

中位值平均滤波算法则结合了中值滤波算法和平均值滤波算法两种方法的优点，通过对 N 个连续的预测值序列进行排序后，去除掉最大值和最小值，再将处理好的 $(N-2)$ 个数据进行算术平均运算后，作为中位值平均滤波的结果替换掉当前时刻的预测数据。

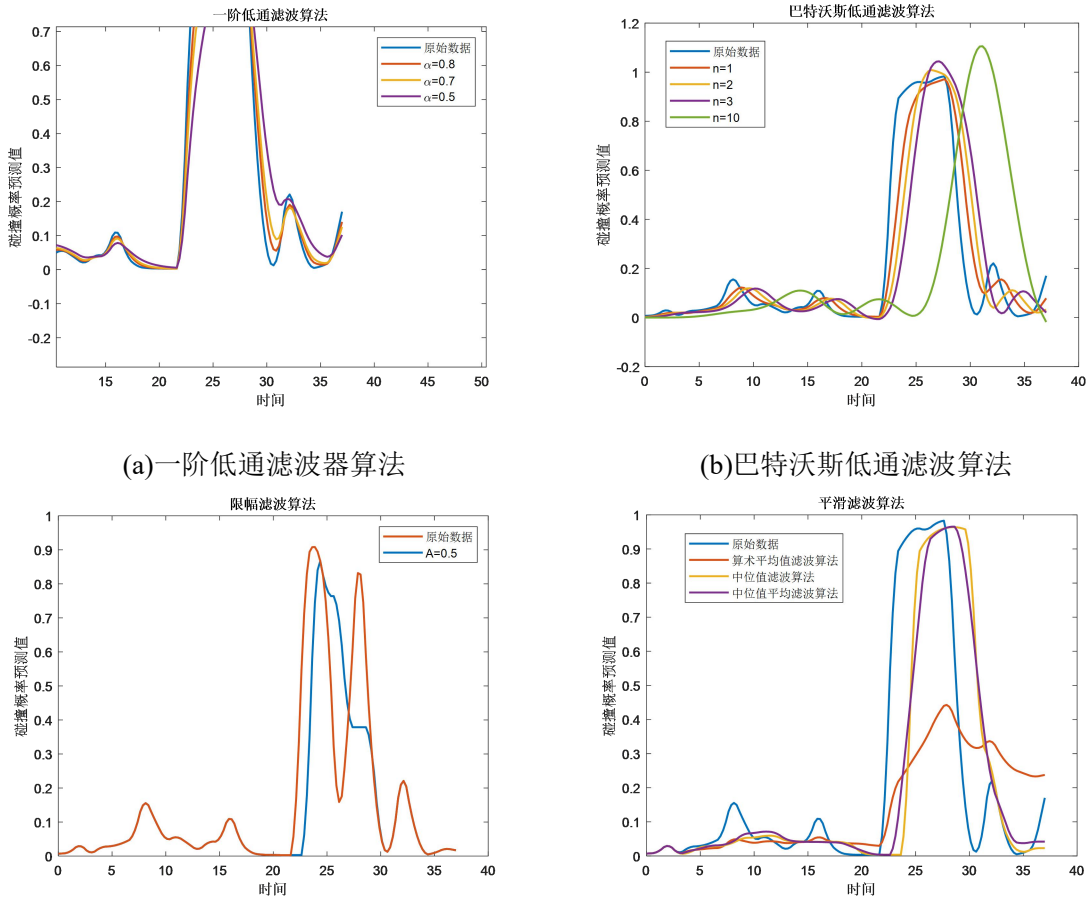
平滑滤波算法的优点是对于周期性干扰和脉冲性干扰都具有良好的抑制性能，平滑度较好，且对低频部分的噪声干扰也能够起到很好的滤波效果；缺点是该方法耗时太久，对于本文这种实时性要求较高的四旋翼无人机避障系统不太适用，且对于序列长度 N，当 N 较大时，平滑滤波算法的滤波结果平滑性较好而灵敏度不高，当 N 较小时，该算法的滤波结果灵敏度高但预测数据曲线波动较大，需要在灵敏性与稳定性方面折中。

4.1.2 滤波算法实验分析

对上文选择研究的滤波算法进行实验分析，为了四旋翼无人机能够安全快速地完成各种飞行任务，这就要求本文设计的防撞系统具有良好的安全性能和反应速度，具体到防撞预测模型的输出结果上，就是需要传送给无人机避障策略决策系统的碰撞概率预测值和转向角预测值数

中国知网 https://www.cnki.net

据具有稳定性强和灵敏度高的特性，而由于无人机机载单目相机采集的图像存在着噪声、细小纹理结构等干扰，导致预测模型输出结果中存在着跳变、异常数据，因此需要对模型预测结果进行滤波处理。选取一段四旋翼无人机平稳飞行、遭遇障碍物、避开障碍物过程中的碰撞概率预测值数据作为测试序列，几种滤波算法的滤波结果如下图所示。



(a)一阶低通滤波器算法　　(b)巴特沃斯低通滤波算法

(c)限幅滤波算法　　(d)平滑滤波算法

图 4.3 几种滤波算法滤波效果图

如图 4.3 所示，4.3(a)展示的是一阶低通滤波算法在不同的滤波系数 α 下的碰撞概率预测值变化曲线，随着滤波系数 α 的减小，滤波后的曲线就越光滑，而且相较于原始数据，经过一节低通滤波后的预测数据在遭遇到障碍物时和躲避障碍物后，也能够及时准确地表达出无人机此刻所处的状态；

4.3(b)展示的是巴特沃斯低通滤波算法在不同的阶数 n 下的碰撞概率预测值变化曲线，为了确保一致性，这几种不同阶巴特沃斯低通滤波算法的截止频率都设置为 50Hz，可以看出随着阶数 n 的增加，碰撞概率预测值曲线都有了不同程度的滞后，但若是随着阶数 n 的减小，当 $n=1$ 时，预测值曲线滞后不多，而且相较于一阶低通滤波算法，曲线的波动性更加平缓，说明一阶巴特沃斯低通滤波算法能够更好地抑制防撞预测数据中的噪声干扰；

中国知网 https://www.cnki.net

4.3(c)展示的是限幅滤波算法在最大偏差值 $A=0.5$ 时的碰撞概率预测值变化曲线，为了更好地展示限幅滤波算法在应对脉冲干扰下的性能，本文人工地在无人机遭遇障碍物时加上了一组跳变数据进行测试，可以看出虽然限幅滤波算法能够消除掉偏差巨大的跳变数据，但是由于在识别到障碍物的一瞬间，预测模型输出的碰撞概率预测值也会跳变为 1，此时经过限幅滤波算法滤波后数据出现了一次滞后，由于四旋翼无人机此时正在快速飞行，这可能会使的无人机发生碰撞；

4.3(d)展示的是几种平滑滤波算法的碰撞概率预测值变化曲线，可以看出，算数平均值滤波算法并不能保证无人机在遭遇障碍物时能够准确地发出预警信息，而中位值滤波算法和中位值平均滤波算法都出现了很大程度的滞后现象，由于无人机在实际飞行过程中输出的防撞预测数据是多变无周期的，且平滑滤波算法的计算耗时很大，因此这几种平滑滤波算法并不适用于本文的避障系统。

综上所述，为提高整体无人机避障飞行系统的稳定性和实时性，本文采用了一阶巴特沃斯低通滤波算法对防撞预测模型的输出结果进行了平滑、滤波处理，在确保了无人机避障飞行灵敏性的同时，消除掉了很多跳变、异常数据。

4.2 无人机防撞策略设计

本文研究四旋翼无人机在进行各种飞行任务时，当无人机飞行方向上出现障碍物时如何决策出合适的防撞策略，总的来说主要分为无人机正常飞行、预测出即将发生碰撞、启动无人机避障策略决策系统输出避障指令、远离障碍物后恢复正常飞行等几个阶段。四旋翼无人机是一个具有六自由度的飞行器，能够通过减速、偏转、升高等各种策略来躲避碰撞物体，在不同的障碍物场景中，能够快速、准确、安全地决策出合适的动作指令是确保四旋翼无人机平稳飞行的前提。

四旋翼无人机的前向飞行速度、偏航角度、垂直升高距离是本文无人机防撞策略的三个研究方向，当四旋翼无人机处于不同的飞行环境中，这三个因素侧重会不同，如当四旋翼无人机预测到柱类障碍物如电线杆、路灯、树干等高度较高但横向面积较窄的物体时，四旋翼无人机可以通过改变其的偏航角，使无人机从柱类障碍物的两侧飞行离开；而当四旋翼无人机预测到悬空类障碍物如电线、桥、横幅等横穿无人机当前视野且纵向高度较小的物体时，无人机从障碍物两侧避障飞行不仅耗时长，而且可以会发生侧面碰撞，此时无人机可以加大电机转速使无人机升高，从而在悬空类障碍物上方飞过。

在已知无人机当前时刻碰撞概率预测值和转向角预测值的情况下，分别将这两个预测值映射到四旋翼无人机的前向速度、偏航角、垂直升高距离三个避障指令，再将避障指令通过 WiFi 发送给无人机飞行控制系统，从而完成躲避障碍物体的目的。

中国知网 https://www.cnki.net

4.2.1 前向速度控制

四旋翼无人机下一时刻的前向速度可以通过预测网络估计的碰撞概率映射得到，碰撞概率越大，说明无人机距离障碍物体的距离越近，根据实际认知可知，此时无人机的前向速度应该随之减小。如图 4.4 所示，当无人机与预测碰撞物体之间的距离缩短到一定长度以内，无人机的前向速度应该变为 0，即悬停在无人机不发生碰撞的安全距离以外。综上所述，无人机下一时刻的前向速度与当前时刻下的碰撞概率预测值之间的映射关系如下式所示：

$$v_t = (1 - P_t)v_{\max} \tag{4.10}$$

式中，v_t 表示 t 时刻的前向速度，P_t 表示 t 时刻经过一阶巴特沃斯低通滤波后的碰撞概率预测值，$v_{\max}$ 是设置的最大前向飞行速度。当滤波后的碰撞概率预测值接近 1 时，无人机的前向速度接近为 0，此时无人机悬停在距预测碰撞物体安全距离之外。

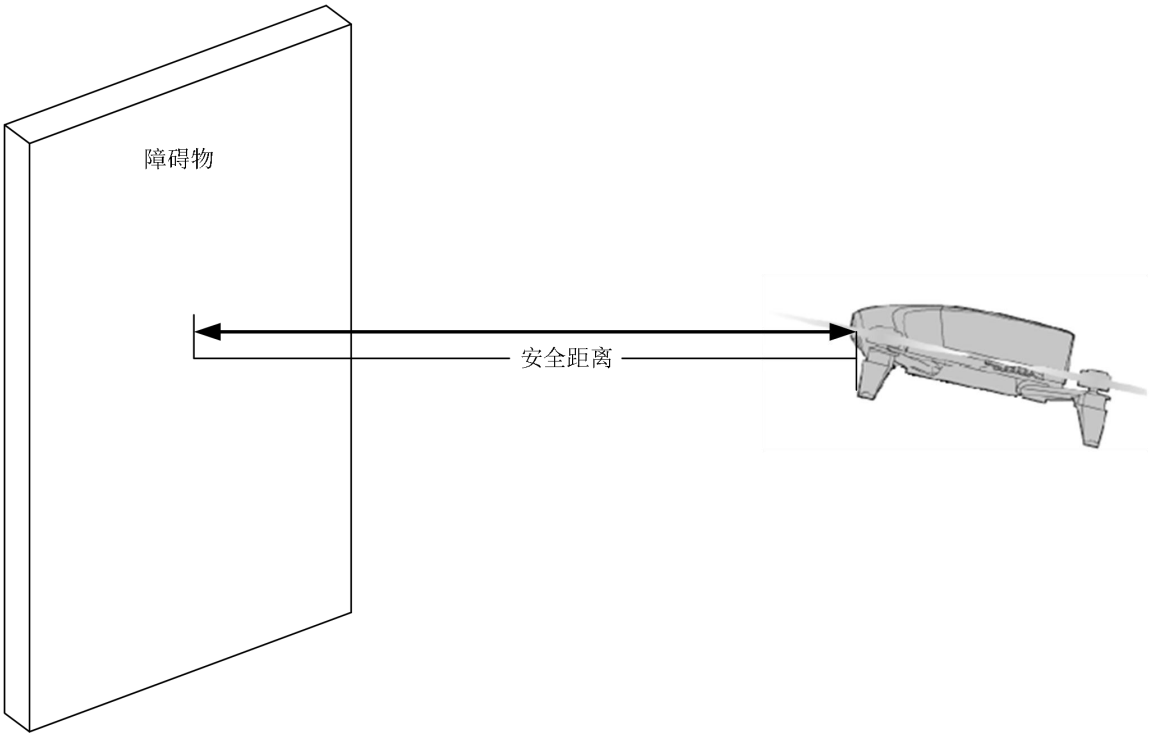


图 4.4 四旋翼无人机安全距离示意图

由于四旋翼无人机的前向速度控制指令在通过 WiFi 传递的过程中，也会携带着噪声干扰，因此本文也需要对该控制指令进行滤波处理，不同于对碰撞概率预测值数据进行一阶巴特沃斯低通滤波处理，前向速度控制指令的实时性要求更高，而且经过对预测数据的滤波处理后，一些异常数据都已被消除，此时综合稳定性和灵敏性的需求，本文使用一阶低通滤波算法对式(4.10)的前向速度输出结果进行滤波处理。因此前向速度控制指令表达为：

$$V_t = \begin{cases} \alpha_1 v_t + (1-\alpha_1)V_{t-1}, V_t < v_t \\ 0, V_t \geq v_t \end{cases} \tag{4.11}$$

中国知网 https://www.cnki.net

式中，α_1表示滤波系数，v_t表示t时刻由碰撞概率预测值P_t映射得到的前向速度，V_{t-1}表示上一时刻的前向速度控制指令，为了防止P_t过大而无人机继续飞行的情况，当v_t大于此刻前向速度控制指令V_t，则向无人机发出停止飞行的命令。

由图 4.3(a)可以看出，随着滤波系数α_1的减小，滤波结果就越平滑，但曲线滞后程度也会随之增加，当$\alpha_1=0.5$时，滤波后的曲线出现了明显的滞后；而当$\alpha_1=0.8$时，滤波后曲线与原始数据曲线一样出现了不平滑性。因此本文设置$\alpha_1=0.7$，以稍微降低无人机飞行的平稳性换取更高的灵敏性。

4.2.2 偏航控制

四旋翼无人机的偏航角度可以通过预测网络估计的转向角映射得到，转向角预测值越大，说明此时预测到的碰撞物体横向长度越宽，无人机从预测碰撞物体两侧避开所需的偏航角度也就越大。如图 4.5 所示，四旋翼无人机从当前位置飞行到障碍物边界处所需的角度φ_t就是无人机所需的偏航角度，本文设置偏航角度φ_t为正值时，无人机向右进行偏航运动；当偏航角度φ_t为负值时，无人机向左进行偏航运动。

由于缺乏专业的无人机视角标有偏航角标签的转向预测数据集，所以本文是通过将无人驾驶汽车中车辆的转向运动数据集作为代替，进行了防撞预测网络模型的训练，因此预测模型输出的转向角预测值与实际的无人机偏航角度还存在着偏差，尤其是本文采用的 Udacity 项目中一个公开可用数据集的转向角范围在$[-25^\circ,25^\circ]$，如果只是简单地将转向角预测值映射到$[-\pi/2,\pi/2]$，四旋翼无人机得到的偏航角控制指令可能并不准确。

因此，首先将经过一阶巴特沃斯低通滤波处理后的转向角预测值数据进行限幅处理，当转向角预测值绝对值大于某个阈值T时，此时无人机的偏航角度φ_t无限接近$\pm\pi/2$，可以近似看作向正左方向或正右方向进行偏转，所以可以将这些转向角预测值绝对值缩小为T，变换公式可表示为：

$$S_t=\begin{cases}-T, S_t\le -T\\ S_t, -T<S_t<T\\ T, S_t\ge T\end{cases} \tag{4.12}$$

式中，S_t表示t时刻经过一阶巴特沃斯低通滤波后的转向角预测值。为了更方便地进行转向角预测值和四旋翼无人机偏航角度之间的映射变换，本文将阈值T设置为 1。

中国知网 https://www.cnki.net

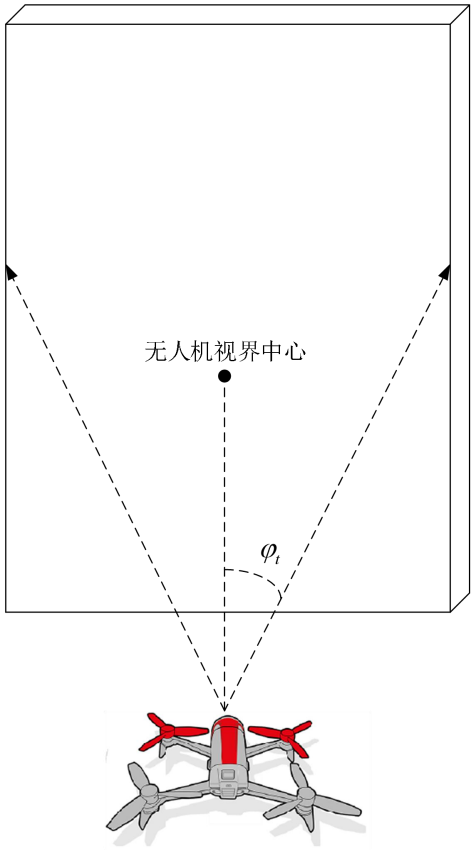


图 4.5 四旋翼无人机偏航角度示意图

再将进行过阈值处理后的转向角预测值映射成$[-\pi/2,\pi/2]$内的四旋翼无人机偏航角度：

$$\varphi_t = \beta \frac{\pi}{2} S_t \tag{4.13}$$

式中，β表示实际无人机偏航角度φ_t和进行过滤波、阈值处理后的转向角预测值S_t之间的修正系数。通过在距离预测碰撞物体一定位置进行无人机偏航角度测试，得到修正系数β的测试结果如下表所示：

表 4.1 四旋翼无人机偏航角修正系数测试结果

参数 / 目标距离	$\frac{\pi}{2}S_t$	实际偏航角度φ_t	修正系数β
0.8 米	0.237	0.245	1.034
1 米	0.202	0.197	0.975
1.5 米	0.140	0.133	0.950
2 米	0.108	0.100	0.923
3 米	0.077	0.067	0.870

中国知网 https://www.cnki.net

为了确保四旋翼无人机能够安全地从预测碰撞物体旁边绕开，修正系数 β 需要确保映射得到的无人机偏航角度足够大，所以通过放大修正系数设置 $\beta=1.2$，确保四旋翼无人机在避开预测碰撞物体时留有余量。与前向速度控制指令相似，也需要对偏航角控制指令进行一阶低通滤波处理，具体的偏航角控制指令如下所示。

$$\Phi_t=\alpha_2\varphi_t+(1-\alpha_2)\Phi_{t-1} \tag{4.14}$$

式中，α_2 表示滤波系数，φ_t 表示 t 时刻由转向角预测值 S_t 映射得到的偏航角度，Φ_{t-1} 表示上一时刻的偏航角控制指令。同前向速度控制指令一样，设置 $\alpha_2=0.7$。

4.2.3 垂直飞行控制

当四旋翼无人机预测到类似横幅、矮墙等障碍物时，滤波后的碰撞概率预测值 P_t 接近 1，而且转向角预测值 S_t 非常大，此时无人机通过向左偏航或向右偏航绕开预测碰撞物体耗时较长且不确定无人机侧面环境情况，在这种状态下，四旋翼无人机通过向上飞行越过预测碰撞物体不仅能够完成避障飞行，同时也能降低无人机的能耗和缩短飞行时间。如图 4.6 所示，四旋翼无人机可以通过加大电机转速使得无人机升高来绕开预测碰撞物体。

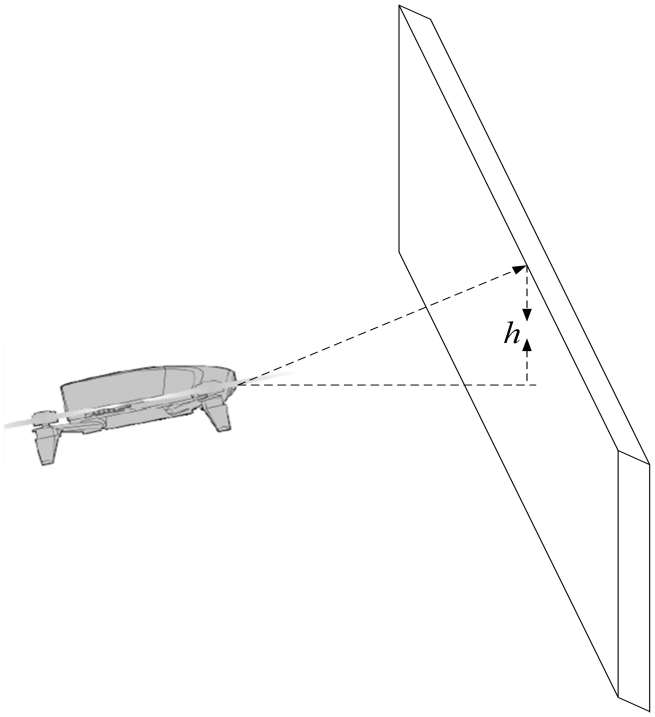


图 4.6 四旋翼无人机垂直升高距离示意图

本文设置当四旋翼无人机当前时刻的碰撞概率预测值 $P_t\geq 0.9$，且此刻的转向角预测值绝对值 $|S_t|\geq 0.9$，才会启动无人机的垂直飞行控制指令，该指令通过控制无人机向上飞行一段固定高度 h 完成避障动作，若无人机在升高之后，防撞预测模型输出的两个预测值仍满足启动无人

中国知网 https://www.cnki.net

机的垂直飞行控制指令的两个前提条件，则无人机继续升高，直到两个前提条件不都符合时，无人机停止爬升。垂直升高高度控制指令 CH 表示为：

$$CH=\begin{cases}h, P_t \geq 0.9 \& \left|S_t\right| \geq 0.9 \\ 0, else\end{cases} \tag{4.15}$$

本文以 Bebop2 四旋翼无人机作为硬件实验平台，考虑到该无人机的高度低于 0.1 米，在考虑到避障裕度的情况下，设置 $h=0.2$ 米。

4.3 基于 ROS 的无人机避障方法软件设计

机器人操作系统（Robot Operating System, ROS）是一种用于编写机器人软件程序的系统级软件架构，可以在 Linux 等系统内核上进行机器人控制、算法和仿真开发，是包括通讯机制、开发工具、应用功能、生态系统等功能在内的一种适用于机器人的开源的元操作系统。ROS 操作系统主要包括以下几个操作概念：

（1）节点（Node）——执行单元。执行具体任务的进程、独立运行的可执行文件，一个系统可以由许多个节点组成，是可执行程序的最小单位。

（2）消息（Message）——话题数据。节点之间通过消息进行通信，消息的数据类型不唯一，可以是标准类型（整型、布尔型、数组等），也可以是用户自定义类型。

（3）话题（Topic）——异步通信机制。节点之间传递数据的重要总线，通过以发布（publish)）/订阅（subscribe）话题的方式传递信息，同一个话题的发布者和订阅者不唯一。

（4）服务（Serve）——同步通信机制。是一种一次性的通信方式，通过客户端/服务器的方式进行同步消息交换，服务器只在有请求（request）的时候才响应（response），而服务客户端会在发送请求后接收响应，完成请求和响应之后，两个连接的节点将断开

（5）节点管理器（ROS Master）——控制中心。通过远程过程调用（Remote Procedure Call Protocol, RPC）为节点提供命名和注册服务，并通过跟踪和记录话题/服务通信，辅助节点相互之间查找、建立连接。

本文在 Ubuntu Melodic 版本操作系统上进行四旋翼无人机避障系统的软件开发，避障系统节点图如图 4.7 所示。首先启动 bebop2 四旋翼无人机后，建立该无人机与装载有 Ubuntu 系统电脑之间的 WiFi 通信，启动/bebop2/bebop_nodelet_manager/bond 等在内的驱动无人机底层节点可订阅的话题；然后通过无人机机载单目相机采集当前飞行环境的图像，并将采集图像发送给/bebop2/image_raw 话题，此时地面站电脑上就可以通过订阅该话题接收到无人机视角的环境图像；之后将这些图像发送给/our_network_perception 节点，防撞预测模型就可以在此节点获得输入图像数据，再将输出的碰撞概率预测值 p_t 和转向角预测值 s_t 发送给/cnn_out/predictions 话题，经过滤波处理后将碰撞概率预测值 P_t 和转向角预测值 S_t 消息发送给/our_network_control 节点，

中国知网 https://www.cnki.net

启动无人机避障策略决策部分软件订阅该话题，发送前向速度控制指令V_t、偏航角度控制指令Φ_t、垂直升高高度控制指令CH等消息到/bebop2/cmd_vel 话题，再通过 WiFi 通信传送无人机硬件平台；bebop2 无人机底层驱动节点/bebop2/bebop_nodelet_manager 通过相关话题将这些控制命令转化为四旋翼无人机的悬停、升降、偏航等基本动作，防止无人机碰撞到障碍物。

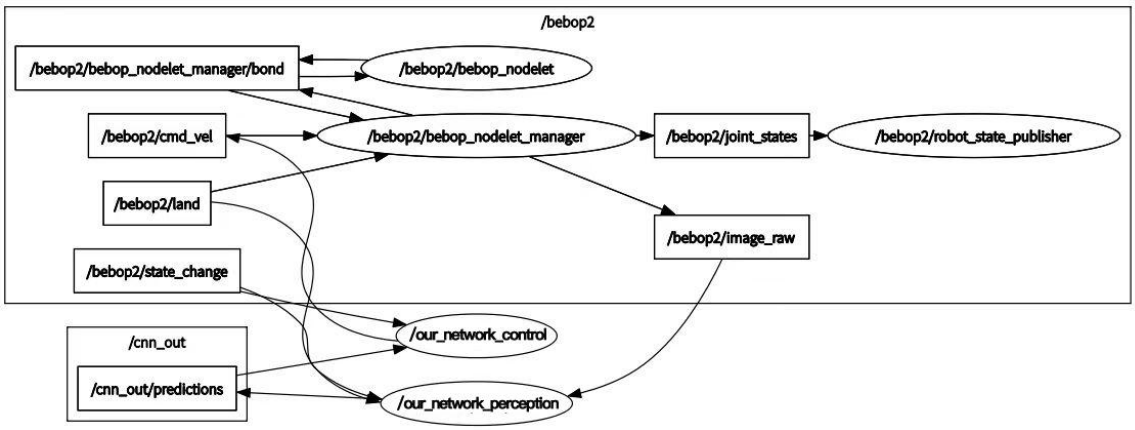


图 4.7 无人机 ROS 避障系统节点图

4.3.1 无人机环境感知模块

无人机环境感知模块主要负责建立地面站电脑与四旋翼无人机之间的 WiFi 通信，为了减少无人机的负载，本文采用的 bebop2 无人机硬件实验平台并没有装载机载图像处理器，而是由地面站电脑处理无人机采集的环境图像，再将无人机避障控制指令发送回无人机进行避障驱动。为了实现 bebop2 无人机的避障飞行，本文进行了无人机环境感知模块的设计，具体步骤如下：

（1）首先在地面站电脑装载了 bebop2 无人机的 ROS 驱动程序 bebop_autonomy 包，该包内的 bebop_nodelet.launch 启动文件可以获取 bebop2 无人机采集的图像信息，通过修改该文件实体机 ip（本文所采用 bebop2 无人机 ip 地址为 192.168.42.1），就可以建立无人机与地面站电脑之间的 WiFi 通信。

（2）打开 bebop2 无人机的电源开关使无人机开机，将地面站电脑的 WiFi 连接到 bebop2 的 WiFi，启动 bebop_nodelet.launch 文件，当地面站电脑上出现如图 4.8 所示终端界面，说明两者之间成功建立了 WiFi 通信。

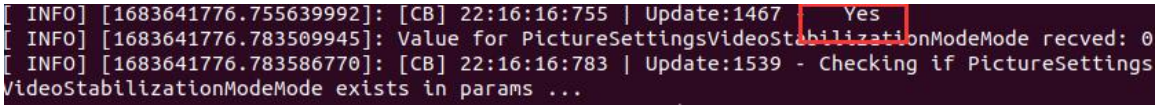


图 4.8 地面站电脑成功连接到 bebop2 无人机

（3）测试地面站电脑是否能够获取 bebop2 无人机实时采集的图像数据，在新建终端中输入 rqt_image_view 命令，当地面站电脑上出现如图 4.9 所示界面，说明 bebop2 无人机采集的图

中国知网 https://www.cnki.net

像能够通过 WiFi 传输到电脑上。

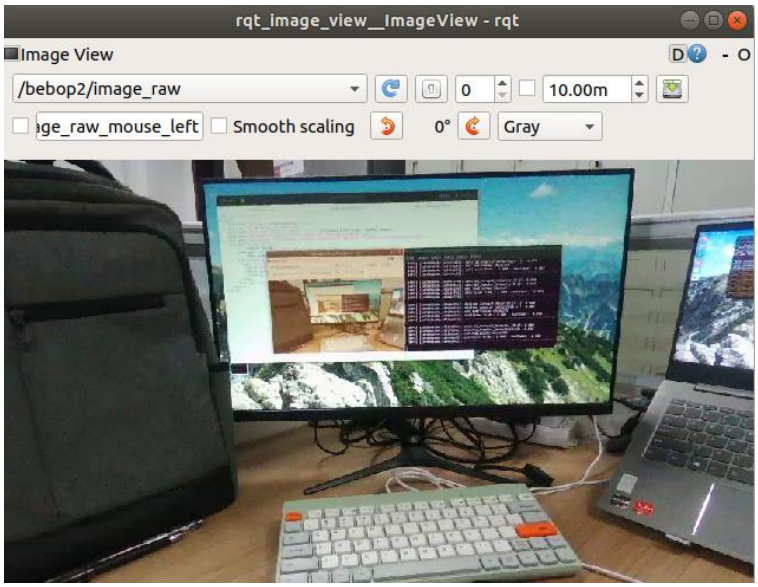


图 4.9 无人机采集图像成功传送到地面站电脑上

（4）测试地面站电脑能否发送控制指令给 bebop2 无人机，在新建终端中输入起飞指令：

rostopic pub --once bebop2/takeoff std_msgs/Empty

其中，bebop_ws 为本文所建无人机避障系统软件给无人机硬件所起的名字。若观测到 bebop2 无人机成功起飞，则说明地面站电脑能够发送避障控制指令给无人机。

4.3.2 无人机避障控制模块

无人机避障控制模块负责将 bebop2 无人机实时采集的图像数据转化为无人机避障指令，主要包括两部分，第一部分负责将采集图像输入预测碰撞模型，输出当前时刻的碰撞概率预测值 p_t 和转向角预测值 s_t，这部分的节点图如图 4.10 所示。

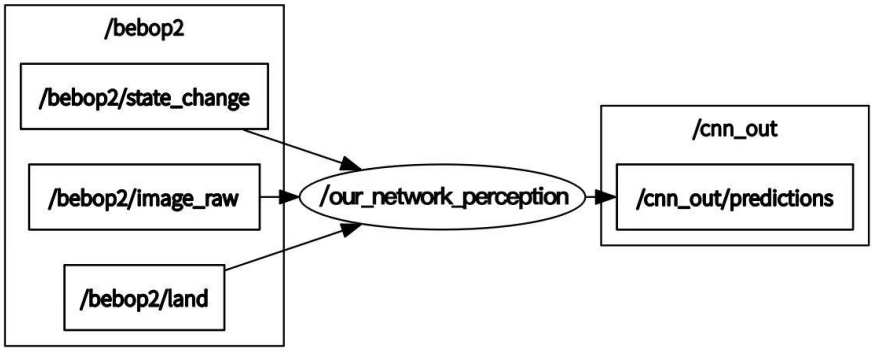


图 4.10 无人机防撞预测模型部分节点图

如图 4.10 所示，通过订阅/bebop2/image_raw 话题，防撞预测模型可以获得无人机采集的飞行环境图像；由于无人机此时未起飞，所以存在/bebop2/land 话题表示此时 bebop2 无人机降落

中国知网 https://www.cnki.net

在地面上；话题/bebop2/state_change 发布启用无人机控制命令，只有当该话题发布的消息为“true”时，无人机避障控制指令才会发送给四旋翼无人机硬件平台。通过加载预训练好的防撞预测模型，输入当前时刻的环境图像，将输出的两个防撞预测值发送到/cnn_out/predictions 话题。

无人机避障控制模块第二部分负责将碰撞概率预测值 p_t 和转向角预测值 s_t 映射成为无人机的避障指令，这部分的节点图如图 4.11 所示。

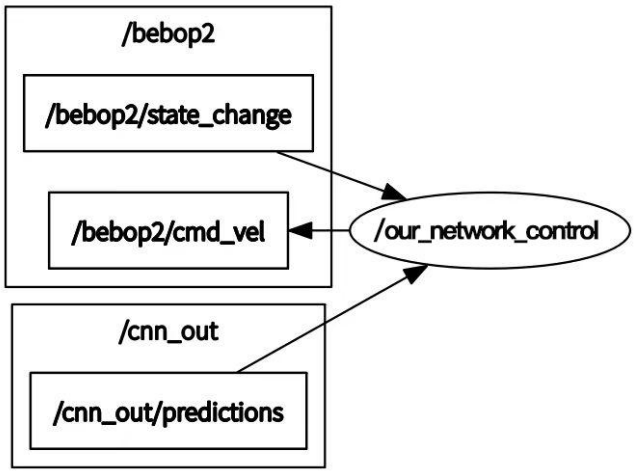


图 4.11 无人机避障指令生成部分节点图

通过订阅/cnn_out/predictions 话题，将碰撞概率预测值 p_t 和转向角预测值 s_t 信息传送到控制指令生成节点，映射成为无人机前向速度控制指令 V_t、偏航角度控制指令 Φ_t 和垂直升高高度控制指令 CH（一般不会发送该消息到/bebop2/cmd_vel 话题，除非两个预测值都在 0.9 以上）。当地面站电脑上出现如图 4.12 所示终端界面，无人机避障控制指令发送成功。

```
[ INFO] [1683641697.313514955]: Desired_Forward_Velocity [0-1]: 1.483
[ INFO] [1683641697.313597088]: Desired Angular Velocity[0-1]: -0.509
[ INFO] [1683641697.313633755]: NOT PUBLISHING VELOCITY
[ INFO] [1683641697.313664764]: Collision Prob.: 0.010 - OutSteer: -0.509
[ INFO] [1683641697.313690326]: ------------------------------------------------
```

图 4.12 地面站电脑发送避障指令

此时设置的最大前向速度为 $v_{\max}=1.5\,\mathrm{m}/s$，可以看到此时预测防撞模型输出的碰撞概率预测值 $p_t=0.010$，转向角预测值 $s_t=-0.509$，所以根据 4.2 节的映射公式，发送无人机前向速度控制指令 $V_t=1.483m/s$，偏航角度控制指令 $\Phi_t=-0.509$（未转化成标准单位），由于碰撞概率预测值 $p_t<0.9$，所以此时不发送垂直升高高度控制指令 CH。

4.4 本章小结

本章进行基于碰撞概率和转向预测信息的无人机避障研究，首先对防撞预测模型输出结果进行滤波处理，分析了低通滤波算法、限幅滤波算法、平滑滤波算法等几类滤波方法的优缺点，

中国知网 https://www.cnki.net

通过对比几种滤波算法的滤波结果曲线，选取了一阶巴特沃斯低通滤波算法对碰撞概率预测值和转向角预测值进行了平滑、滤波处理；然后分析并设计了四旋翼无人机的避障策略，基于碰撞概率预测值和转向角预测值映射出四旋翼无人机的前向飞行速度、偏航角度、垂直升高距离；最后基于 ROS 操作系统，对四旋翼无人机避障系统进行了软件设计，主要包括无人机环境感知模块和无人机避障控制模块，无人机环境感知模块负责建立装载有 Ubuntu 系统的地面站电脑与四旋翼无人机之间的数据通信，无人机避障控制模块负责将无人机避障指令发送给无人机底层驱动实现防撞飞行。

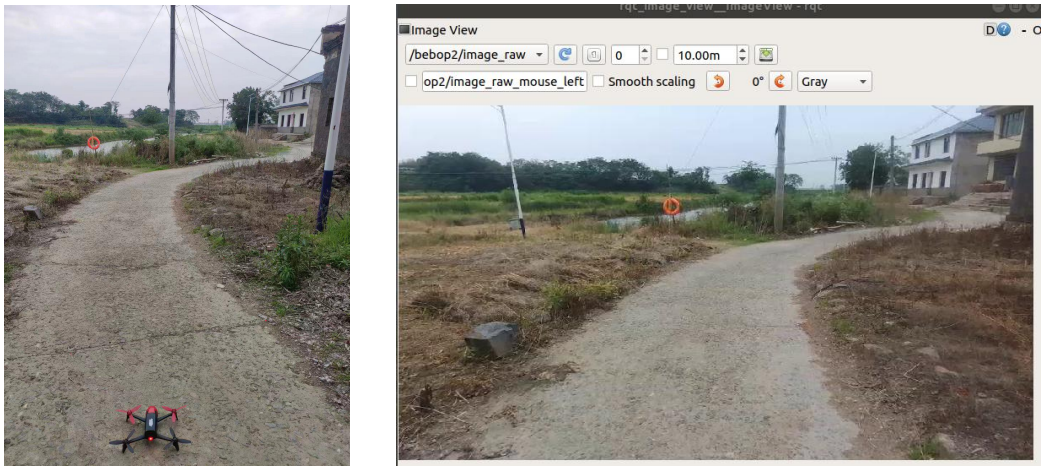
中国知网 https://www.cnki.net

第五章　无人机避障系统性能分析与实飞验证

为验证本文设计的基于卷积神经网络的四旋翼无人机视觉避障方法的良好性能与可行性，对该无人机避障系统各部分进行定量测试。首先进行了无人机防撞预测模型性能分析，在不同的无人机最大前向速度条件下，对比分析了该模型输出的碰撞概率预测值和转向角预测值变化情况，并对不同最大前向速度条件下的无人机避障控制指令执行效果进行分析；然后对避障控制命令运行时间进行分析，通过计算无人机避障环节上各个话题发送数据的频率，就可以获得无人机执行一次避障操作所需要的时间;最后在各种飞行环境中进行了四旋翼无人机实飞实验，验证了本文四旋翼无人机视觉避障方法的有效性。

5.1 防撞预测模型实飞性能分析

本文第三章进行了基于 Swin Transformer 和 ResNet 防撞预测网络模型的性能评估，并且在室内和室外环境下都进行了防撞预测测试，本节主要是测试防撞预测网络在无人机实飞过程中是否能准确预测到障碍物体，以及在不同的最大前向速度下，防撞预测模型是否依然能够快速精准地发送预测碰撞信息给无人机避障控制系统。本文的测试环境如图 5.1 所示：



(a)手持相机拍摄　　(b)无人机视角

图 5.1 无人机防撞预测模型测试环境

bebop2 四旋翼无人机正前方约 20 米处存在着一根电线杆，如果无人机按照预设指令向前飞行，不启动防撞预测模型的情况下，无人机将会和电线杆发生碰撞。按照以下步骤测试实飞时预测防撞模型的性能：

（1）建立 bebop2 四旋翼无人机与地面站电脑的 WiFi 连接，新建终端发送无人机起飞指令，当无人机成功起飞后，输入 rqt_image_view 命令查看无人机采集图像是否成功发送到地面站电

中国知网　https://www.cnki.net

脑，如果出现如图 5.2 界面，说明 bebop2 四旋翼无人机与地面站电脑成功建立了 WiFi 通信。

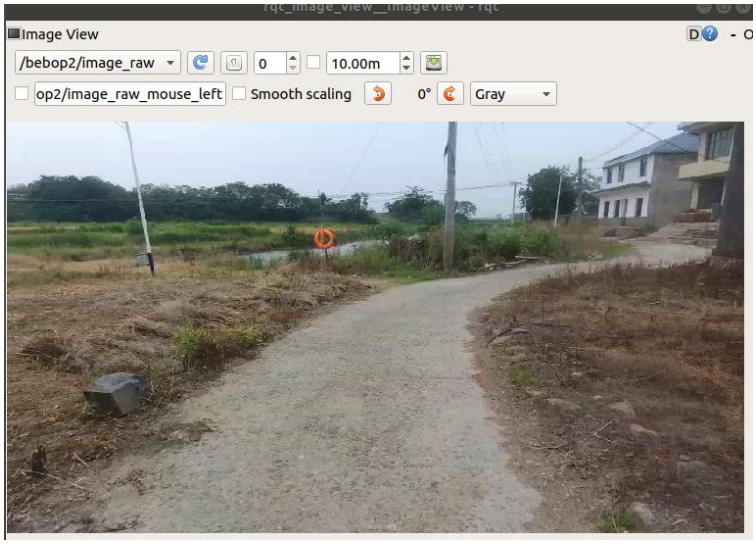


图 5.2 无人机成功发送采集图像

（2）启动无人机感知预测节点，运行本文设计的基于 Swin Transformer 和 ResNet 的防撞预测网络模型，生成当前时刻的 bebop2 四旋翼无人机碰撞概率预测值与转向角预测值。

（3）启动无人机避障控制节点，接收预测防撞模型输出的两个预测值，并将其转化为无人机避障控制指令，此时地面站电脑并不立即将避障控制指令发送给 bebop2 四旋翼无人机，直到在新建终端中输入解锁指令：

rostopic pub --once /bebop2/state_change std_msgs/Bool "data: true"

此时避障控制指令才能成功地发送出去，bebop2 四旋翼无人机开始向前飞行，直到接近电线杆附近开始预测到可能会发生碰撞，执行避障控制指令绕开障碍物，避障相关阶段如图 5.3 和图 5.4 所示。

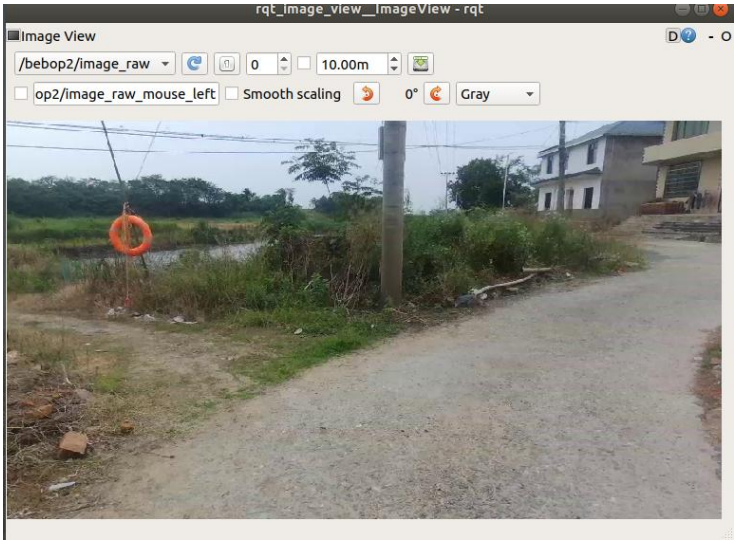


图 5.3 无人机接近电线杆

中国知网 https://www.cnki.net

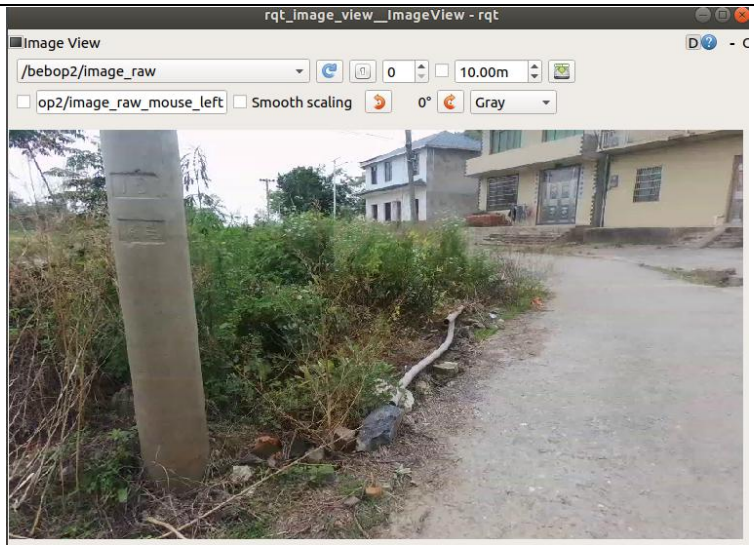
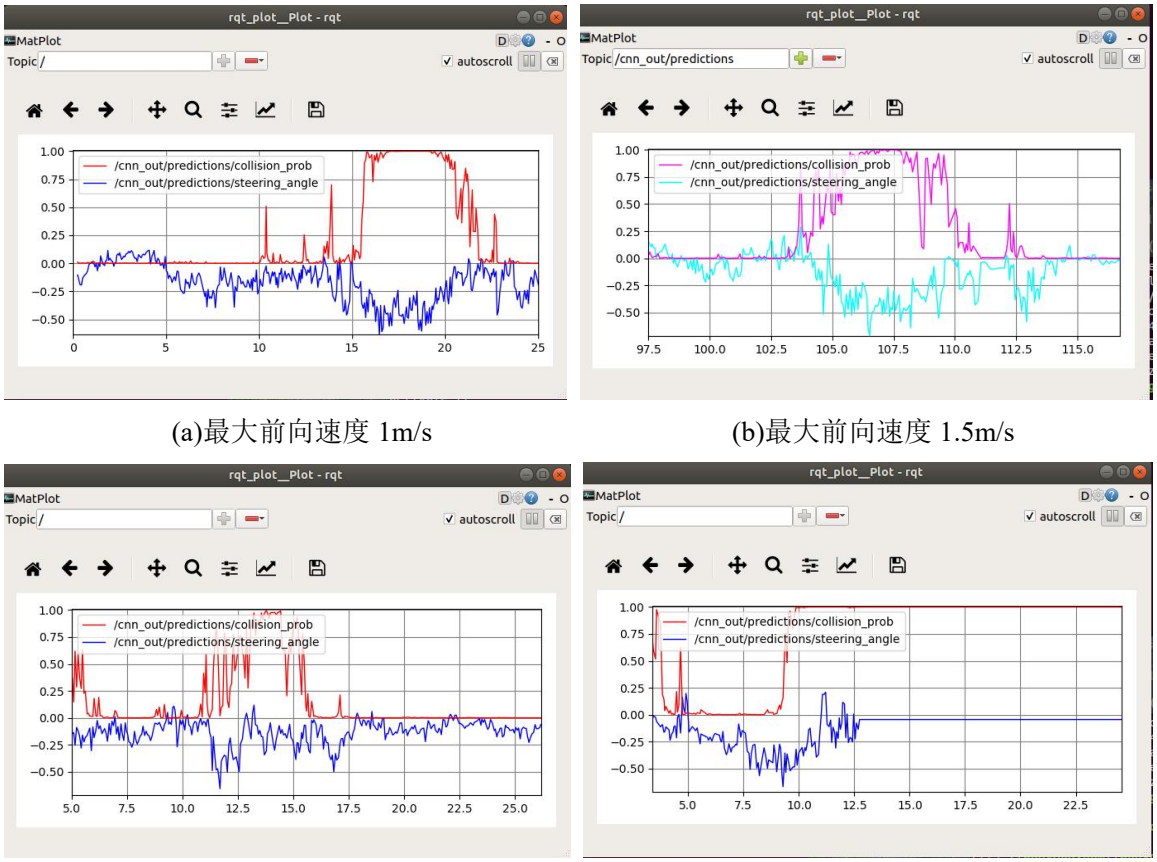


图 5.4 无人机避开电线杆

在不同的最大前向飞行速度条件下，预测防撞模型输出的预测信息变化情况也会不同，分别取 1m/s、1.5m/s、2m/s、3m/s 四种速度对预测防撞模型性能进行测试，模型的输出结果如图 5.5 所示，图中横轴表示时间，纵轴表示预测值大小：



(a)最大前向速度 1m/s　　(b)最大前向速度 1.5m/s

(b)最大前向速度 2m/s　　(d)最大前向速度 3m/s

图 5.5 不同最大前向速度条件下的防撞预测模型输出数据曲线

中国知网 https://www.cnki.net

如图 5.5 所示，当 bebop2 四旋翼无人机的最大前向速度为 1m/s 时，其到达能预测到电线杆处所花时间约为 15 秒，而随着无人机的最大前向速度增大，这段距离所花时间就越短，这是符合实际认知的；而所有的速度下，本文设计的预测碰撞模型都能够准确地发出碰撞预警信息，但不同的是，当 bebop2 四旋翼无人机的最大前向速度为 3m/s 时，虽然预测碰撞模型成功地预测到了电线杆，但是由于无人机前向速度太快，bebop2 四旋翼无人机来不及进行避障绕向，就撞向了障碍物电线杆，所以本文设计的预测碰撞模型还存在四旋翼无人机硬件条件的限制。

5.2 避障控制命令运行时间分析

为了直观的展示本文避障系统运行一次避障操作所需时间，需要对该系统各个部分进行梳理分析。如图 2.3 所示，四旋翼无人机完成一次避障操作主要包括以下步骤：

（1）四旋翼无人机实时采集图像并通过 WiFi 通信传入到地面站电脑；

（2）飞行环境图像传入防撞预测模型输出碰撞概率预测值 p_t 和转向角预测值 s_t；

（3）将防撞预测信息转化成无人机避障指令并发送给四旋翼无人机；

（4）四旋翼无人机底层驱动节点接收指令并将指令分解成基本的飞行避障动作；

（5）执行避障动作结束该次避障操作进入下一循环。

对比图 4.7 所示无人机 ROS 避障系统节点图，可以将上述五个步骤理解成五个相关话题发送数据给执行操作节点，如将四旋翼无人机飞行环境图像传送给地面站电脑，就是/bebop2/image_raw 话题发送图像数据到/our_network_perception 节点启动防撞预测网络，通过在终端中输入显示话题的消息数据发布频率命令，就可以获得/bebop2/image_raw 话题的发布频率和完成传输所需时间：

rostopic hz /bebop2/image_raw

显示结果如图 5.6 所示，/bebop2/image_raw 话题的平均发布频率在 30Hz 左右，数据传输耗时最低为 0.012 秒，最多不超过 0.058 秒。

```
(tf) liangyongxun@liangyongxun-Lenovo-XiaoXinAir-14API-2019:~/bebop_ws
$ rostopic hz /bebop2/image_raw
subscribed to [/bebop2/image_raw]
average rate: 30.197
        min: 0.023s max: 0.042s std dev: 0.00511s window: 28
average rate: 30.081
        min: 0.023s max: 0.044s std dev: 0.00470s window: 58
average rate: 29.988
        min: 0.018s max: 0.047s std dev: 0.00520s window: 88
average rate: 29.912
        min: 0.018s max: 0.047s std dev: 0.00476s window: 118
average rate: 29.862
        min: 0.018s max: 0.047s std dev: 0.00476s window: 147
average rate: 29.917
        min: 0.018s max: 0.048s std dev: 0.00475s window: 178
average rate: 29.862
        min: 0.012s max: 0.058s std dev: 0.00546s window: 207
average rate: 29.836
        min: 0.012s max: 0.058s std dev: 0.00549s window: 237
```

图 5.6 /bebop2/image_raw 话题发布频率

中国知网 https://www.cnki.net

其他步骤与步骤一相似，步骤二就是/cnn_out/predictions 话题发送碰撞概率预测值 p_t 和转向角预测值 s_t 数据，步骤三就是/bebop2/cmd_vel 发送无人机避障控制指令，步骤四就是/bebop2/bebop_nodelet_manager/bond 发送信息数据，步骤五就是/bebop2/joint_states 给四旋翼无人机四个电机发送不同的转速命令。这些话题的发布频率和数据传输耗时如表 5.1 所示：

表 5.1 ROS 避障系统运行时间分析

参数 / 话题	数据发布频率(Hz)	数据传输耗时(秒)
/bebop2/image_raw	30	0.012~0.058
/cnn_out/predictions	20	0.030~0.106
/bebop2/cmd_vel	30	0.033~0.034
/bebop2/bebop_nodelet_manager/bond	2	0.041~0.058
/bebop2/joint_states	5	0.010~0.067

由表 5.1 可知，bebop2 四旋翼无人机与地面站电脑之间始终以 30Hz 的频率进行 WiFi 通信，两者之间的数据传输耗时范围在 0.045~0.092 秒；话题/cnn_out/predictions 以 20Hz 的频率发送着两个防撞预测信息，数据传输耗时仅为 0.030~0.106 秒，从传入当前时刻无人机飞行环境图像，到本文设计的防撞预测网络输出碰撞概率预测值 p_t 和转向角预测值 s_t 仅仅只需 0.1 秒左右的时间，相较于传统避障方法的计算时延，本文基于卷积神经网络的四旋翼无人机避障方法明显更具优势。

5.3 四旋翼无人机视觉避障飞行实验

为了验证本文基于卷积神经网络的视觉避障方法在不同障碍物环境下的有效性和适应性，本节分别进行了静止障碍物避障实验和移动障碍物避障实验。在静止障碍物避障实验中，本文选择了树木和矮墙这两种典型的静止障碍物目标，为了保证飞行试验的安全性，本文将无人机降落指令设为了最高优先级。在移动障碍物避障实验中，本文实验的是当四旋翼无人机正常向前飞行时，面前突然出现移动着的人，验证此时无人机是否能够避障成功。为了确保 bebop2 四旋翼无人机不会失控伤害实验人员，实验中无人机的最大前向速度设置为 1.5m/s，无人机初始起飞高度为 1.5m。

5.3.1 静止障碍物避障实验

静止障碍物避障实验的准备步骤相同，都是先启动 bebop2 四旋翼无人机的电源开关，然后将地面站电脑的 WiFi 连接到无人机的 WiFi，在终端中运行 bebop2 四旋翼无人机 ROS 驱动程序 bebop_autonomy 包里面的 bebop_launch.launch 文件，验证地面站电脑是否成功建立了与无人

中国知网 https://www.cnki.net

机之间的 WiFi 通信，如果成功连接，该终端界面会返回“Yes”指示符。

然后启动无人机碰撞预测系统文件，加载训练好的基于 Swin Transformer 和 ResNet 的防撞预测网络模型，输入 bebop2 四旋翼无人机实时采集的环境图像，然后以 20Hz 的发布频率向/our_network_control 节点发送碰撞概率预测值 p_t 和转向角预测值 s_t。

启动无人机避障控制系统文件，对预测碰撞数据输出的两个预测值信息进行滤波处理后传入避障指令生成文件，输出当前时刻的前向速度控制指令 V_t、偏航角度控制指令 Φ_t 和垂直升高高度控制指令 CH，此时如果没有在终端输入控制指令发送命令，会返回“NOT PUBLISHING VELOCITY”提示。

输入无人机起飞命令，当无人机顺利起飞后，在保证飞行试验环境安全的情况下，输入控制指令发送解锁命令，bebop2 四旋翼无人机向前飞行，开始无人机视觉避障飞行实验。

（1）柱状类大树障碍物

进行无人机避开大树障碍物飞行实验，实验环境如图 5.7 所示。bebop2 四旋翼无人机正前方存在着一颗大树，大树的左侧存在着灌木和汽车等障碍物，右侧是一片空旷的马路。

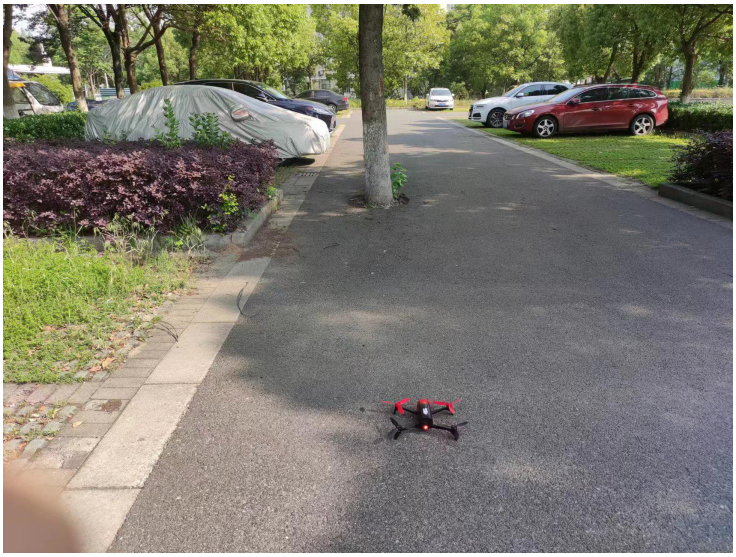
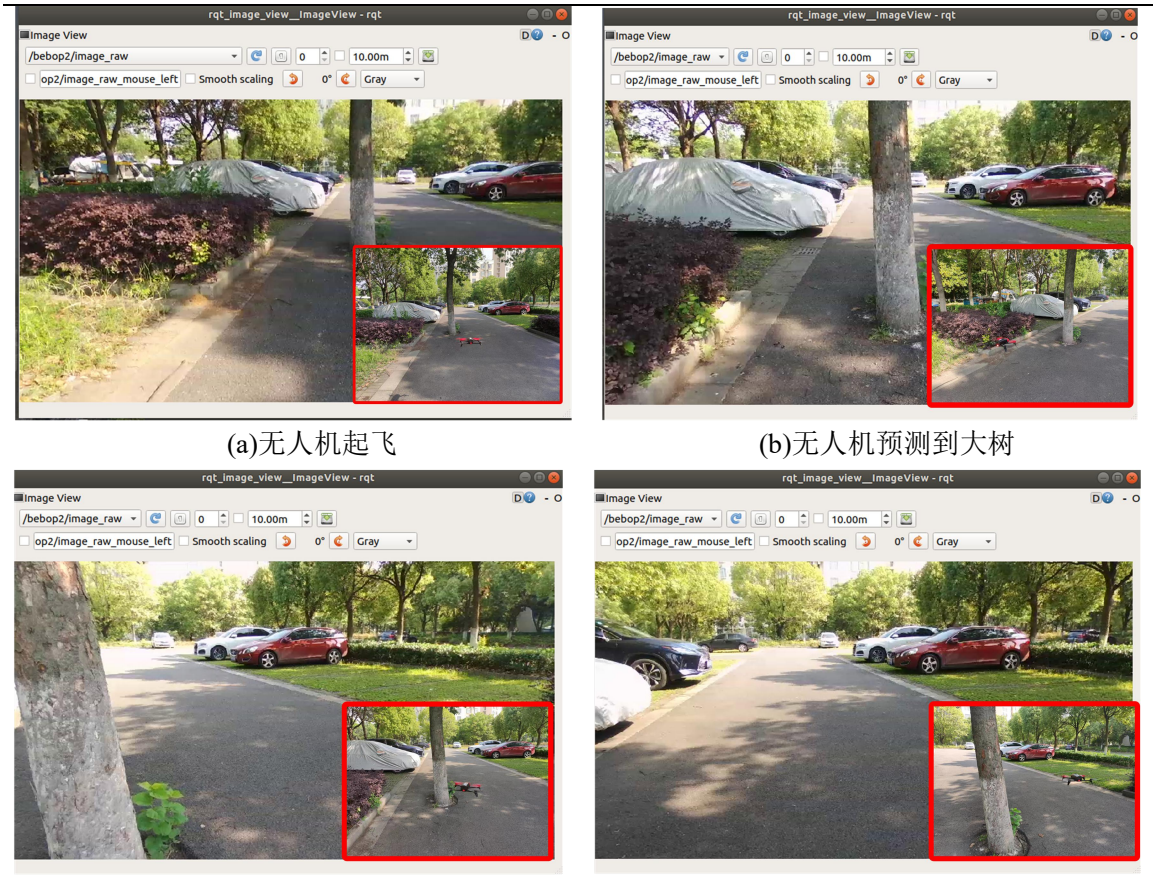


图 5.7 无人机避障树木障碍物环境

打开 bebop2 四旋翼无人机电源，连接到地面站电脑后启动无人机视觉避障系统，实验过程如图 5.8 所示。bebop2 四旋翼无人机向前飞行，直到预测碰撞模型成功预测到大树的存在，发送避障控制指令到无人机，无人机前向速度随之降低，并开始向右偏航以避开大树。

中国知网 https://www.cnki.net



(a)无人机起飞　(b)无人机预测到大树

(c)无人机偏航　(d)避障成功

图 5.8 无人机成功绕开树木

在 bebop2 四旋翼无人机避开大树的过程中，无人机防撞预测模型的输出结果如图 5.9 所示。在第 24 秒左右，防撞预测模型成功预警了大树的存在，并开始向右偏航以绕开大树；在第 25 秒左右，bebop2 四旋翼无人机完成了避障操作。

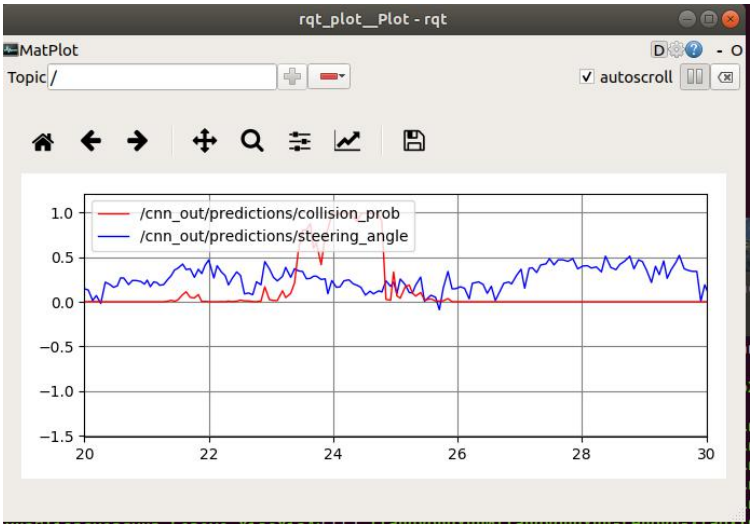


图 5.9 无人机避开大树过程中的防撞预测模型输出数据曲线

中国知网 https://www.cnki.net

bebop2 四旋翼无人机避开大树的过程中的前向速度变化曲线如图 5.10 所示，可知当防撞预测模型输出的碰撞概率预测值越大时，无人机的前向飞行速度越慢；当碰撞概率预测值大于某一阈值时，无人机的前向速度变为 0。

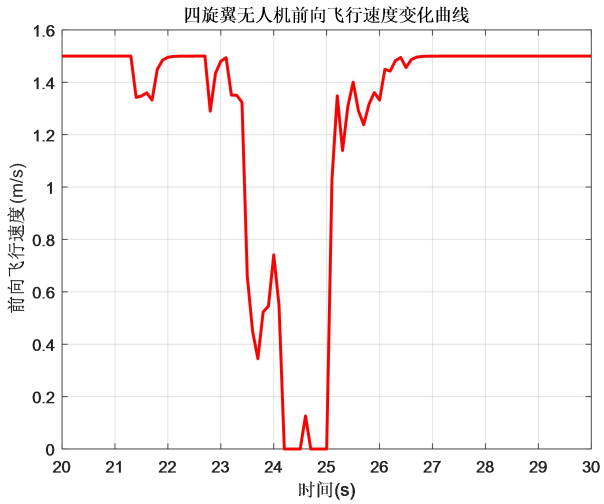


图 5.10 无人机避开大树过程中的前向速度变化曲线

（2）悬空类矮墙障碍物

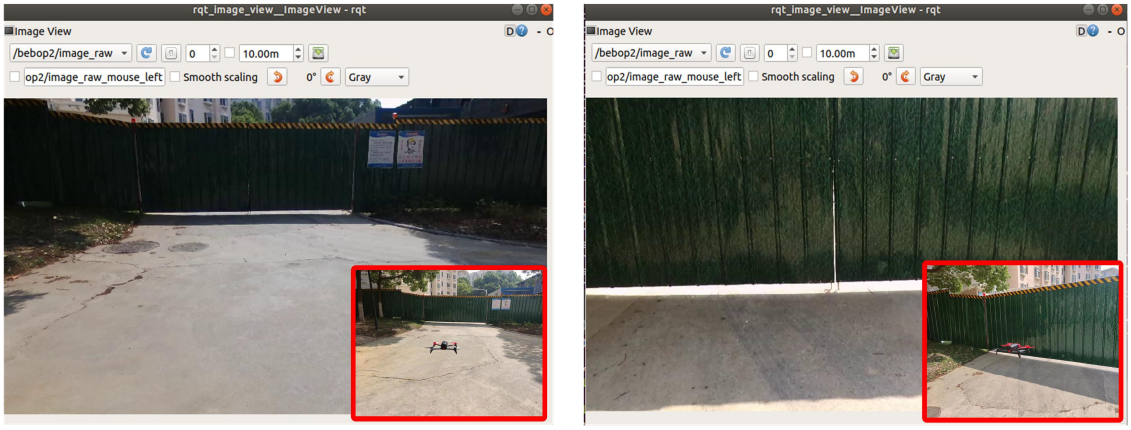
进行无人机避开矮墙障碍物飞行实验，实验环境如图 5.11 所示。bebop2 四旋翼无人机正前方存在着施工用矮墙，矮墙左右两侧长度在 20 米以上，但高度只有 2.5 米左右。



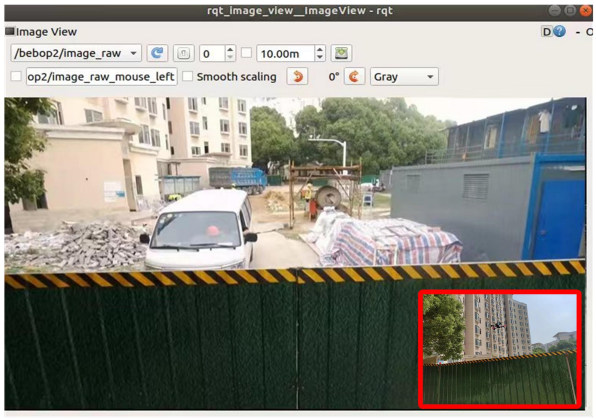
图 5.11 无人机避障矮墙障碍物环境

打开 bebop2 四旋翼无人机电源，使无人机向前飞行，当预测碰撞模型成功预测到矮墙时，开始进行避障，无人机前向速度降低为零，并开始垂直向上飞行越过矮墙，实验过程如图 5.12 所示。

中国知网 https://www.cnki.net



(a)无人机起飞　　(b)无人机接近矮墙



(c)无人机升高以避开障碍物

图 5.12 无人机成功越过矮墙

该实验过程中无人机防撞预测模型的输出结果如图 5.13 所示。当无人机飞行到矮墙一定距离内，防撞预测模型输出的两个预测值都在 0.9 以上，此时地面站电脑发送垂直升高高度控制指令 $CH = 0.2m$ 给 bebop2 四旋翼无人机，无人机开始垂直向上飞行，直到高度超过矮墙。

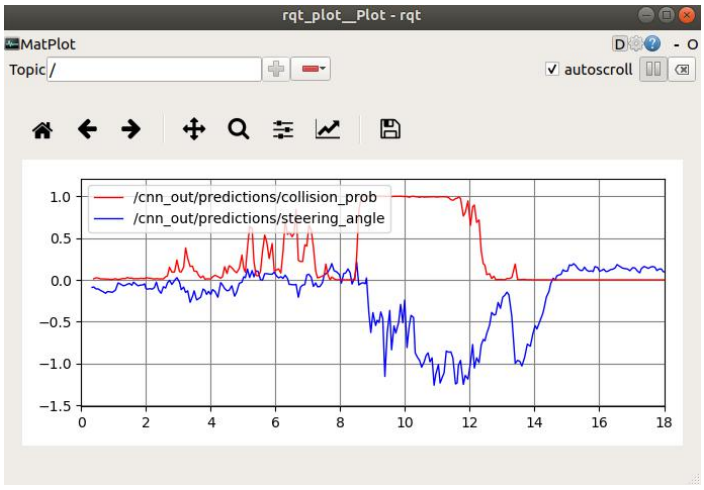


图 5.13 无人机越过矮墙过程中的防撞预测模型输出数据曲线

中国知网 https://www.cnki.net

bebop2 四旋翼无人机越过矮墙过程中的高度变化曲线如图 5.14 所示，从 0 时刻无人机起飞，在 1 米高处向前飞行一段距离后，无人机开始垂直向上飞行，直到越过矮墙。

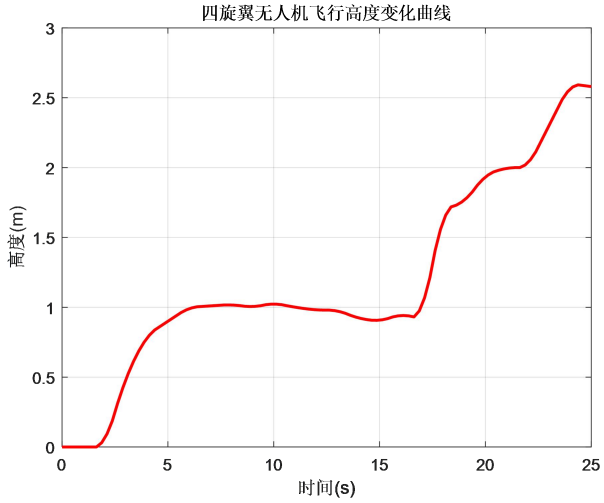


图 5.14 无人机越过矮墙过程中的飞行高度变化曲线

5.3.2 移动障碍物避障实验

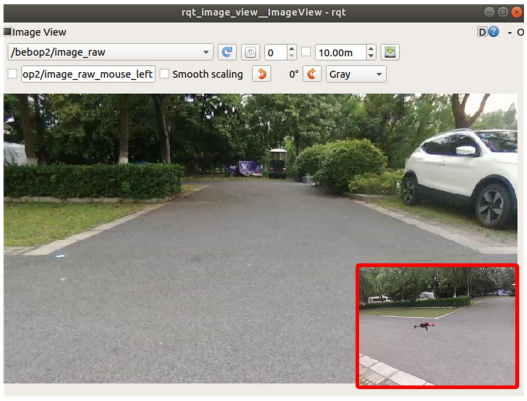
无人机进行移动障碍物避障实验，实验的准备步骤与静止障碍物避障实验相同。本节测试的是当 bebop2 四旋翼无人机正常向前飞行过程中，当移动障碍物突然出现在无人机前向飞行方向上，无人机是否能够及时预测到移动障碍物避免碰撞。实验环境如图 5.15 所示，bebop2 四旋翼无人机飞行方向前方是空旷的马路。



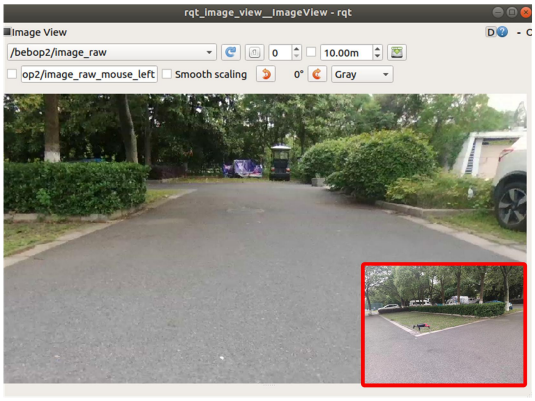
图 5.15 无人机避障移动障碍物环境

打开 bebop2 四旋翼无人机电源，使无人机向前飞行，实验过程如图 5.16 所示。当移动障碍物突然出现时，bebop2 四旋翼无人机前向速度骤降为零，然后开始缓慢地向右侧移动，直到避开移动障碍物。

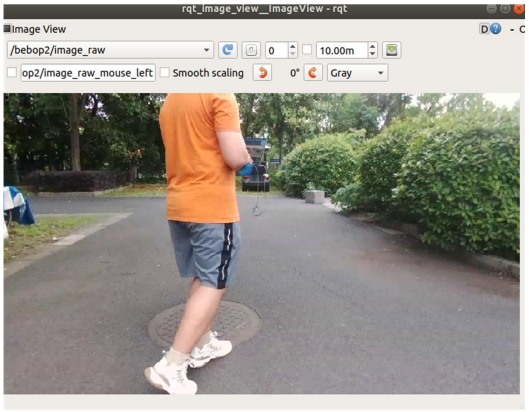
中国知网 https://www.cnki.net



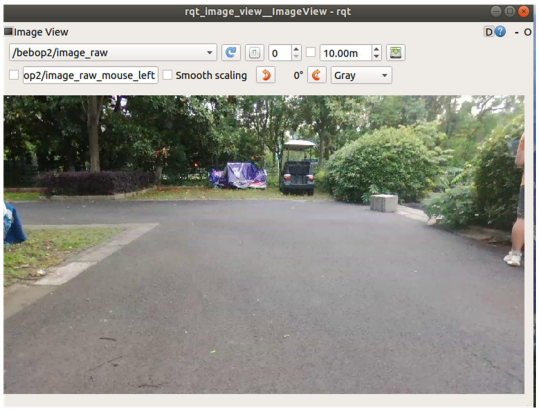
(a)无人机起飞



(b)无人机正常飞行



(c)移动障碍物出现



(d)无人机远离移动障碍物

图 5.16 移动障碍物避障过程

移动障碍物避障实验过程中无人机防撞预测模型的输出结果如图 5.17 所示。当移动障碍物出现在 bebop2 四旋翼无人机视野中时，防撞预测模型快速准确地发出了预警信息，同时指引无人机向右移动以避开移动障碍物，直到离开移动障碍物一段距离后，防撞预测模型输出的碰撞概率预测值降低，bebop2 四旋翼无人机继续向前飞行。

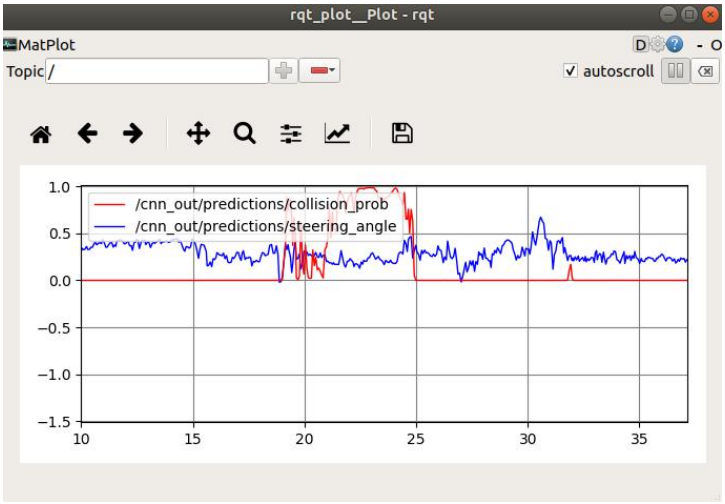


图 5.17 移动障碍物避障过程中的防撞预测模型输出数据曲线

中国知网 https://www.cnki.net

5.4 本章小结

本章实现无人机避障系统性能分析与实飞验证，首先对本文设计的基于 Swin Transformer 和 ResNet 的防撞预测网络模型进行性能分析，在不同的起始前向飞行速度下，对比分析了模型输出的碰撞概率预测值和转向角预测值变化情况，并记录了当四旋翼无人机前向飞行速度减速为零时距预测碰撞目标的距离；然后对避障控制命令运行时间进行分析，总结发现本文基于卷积神经网络的视觉避障系统避障控制指令生成时间远低于传统避障方法，本文避障方法时延更短，且不依赖环境先验信息；最后进行了静止障碍物和移动障碍物环境下的四旋翼无人机避障飞行实飞验证，证明了本文避障方法的可行性。

中国知网 https://www.cnki.net

第六章　总结与展望

6.1 本文的主要工作

四旋翼无人机作为现如今消费市场应用最广、成本相对较低的无人机，具有结构简单、成本低、应用功能广泛等特点，因此被广泛用于现代社会的方方面面。作为四旋翼无人机实现其他应用的前提，无人机自主避障近年来成为了人们研究的热点。本文以四旋翼无人机为研究主体，以卷积神经网络为基础对无人机视觉避障相关技术展开了研究，本文的主要工作如下：

（1）设计了基于卷积神经网络的四旋翼无人机视觉避障系统。对基于单目视觉四旋翼无人机自主避障系统的整体架构进行了设计，包括无人机防撞信息预测系统和无人机避障策略决策系统两部分；由于无人机防撞信息预测系统需要，分析并收集了相关的无人机防撞预测数据集和转向预测数据集，并基于现有防撞预测数据集中碰撞帧与非碰撞帧数量不平衡，增加构建了障碍物场景丰富复杂的碰撞帧数据集。

（2）针对无人机防撞信息预测问题。设计了基于 Swin Transformer 和 ResNet 的四旋翼无人机防撞预测与避障航向预测模型，通过输入四旋翼无人机机载图像采集设备采集的图像，输出无人机当前飞行环境下的预测碰撞概率和转向角信息；为了验证预测网络模型的性能，分析选择了该模型的评估指标，并与其他经典模型做了对比，给出了本文模型在避障预测、转向预测性能、图像处理时间上具有显著的优势；最后，在多种室内室外环境、不同光照条件下对预测网络模型进行了测试，结果表明该模型具有良好的准确性和适用性。

（3）针对无人机避障策略决策问题。首先基于模型预测结果传输过程中的噪声干扰问题，对比研究了多种滤波算法，采用了限幅滤波算法解决了无人机避碰防撞中的信号指令噪声大问题。然后结合预测网络模型给出的碰撞概率和转向角预测信息，结合四旋翼无人机实际避障防撞动作，经过多组实验结果对比，确定了不同情况下的四旋翼无人机前向速度控制、偏航控制、垂直飞行控制指令策略，并结合 ROS 操作系统设计了相应的无人机环境感知预测模块和无人机飞行控制模块，且在法国 Parrot 公司生产的 Bebop 2 四旋翼无人机上进行了实机测试，结果表明设计的无人机避障策略决策系统具有更快的处理时间和更高的避障成功率。

（4）进行了四旋翼无人机避障系统性能分析与实飞验证。首先对本文设计的无人机飞行避障系统整体性能进行了分析，分别进行了避障预测模型性能分析和避障控制命令运行时间分析，结果表明避障预测网络模型相较于单一 CNN 网络结构，本文提出的结合 Swin Transformer 和 CNN 的混合结构，使预测模型在模型容量和泛化能力上都具有较好的结果，而且避障系统的整体运行时间相较于传统避障方法缩短了很多。然后分别进行了静止障碍物和移动障碍物环境下

中国知网　https://www.cnki.net

的实机飞行试验，实验结果证明了本文提出的四旋翼无人机视觉避障方法的有效性。

6.2 后续研究工作

本文针对不确定环境下的四旋翼无人机避障问题进行了研究，取得了一定的工作进展，但还有很多方面值得进一步的研究：

1、相较于简单的四旋翼无人机避障决策问题，需要进一步解决在安全约束、决策时间约束等条件下，无人机在起飞点与目标位置之间建立目标最优的避障路径的问题，结合传统的 A*、D*等启发式算法，仍具有进一步的改善空间。

2、由于试验场地的安全性要求较高，本文四旋翼无人机飞行测试环境虽然具有一定的代表性，但是相对四旋翼无人机实际作业环境仍比较简单，下一步可以尝试如何在人流量大、环境变化复杂的条件下进行避障飞行测试。

3、本文的四旋翼无人机硬件平台搭载的实验设备相对较少，无法模拟四旋翼无人机更多的实际应用，如何将本文提出的视觉避障方法与实际相结合，并且与其它如目标检测、自主降落等功能并用，是下一步的研究重点。

中国知网 https://www.cnki.net

参考文献

[1] 王瑞, 丁晓青. 四旋翼飞行器设计与实现[M]. 北京：清华大学出版社, 2018: 1.

[2] 刘立臣. 基于毫米波雷达和视觉的旋翼植保无人机自主避障研究[D]. 黑龙江：东北林业大学, 2020.

[3] 陈思信. 无人机在应急救援中的应用研究[J]. 科技资讯, 2021, 19(35): 56-58.

[4] Pan Jeng-Shyang, Lv Ji-Xiang, Yan Li-Jun, et al. Golden eagle optimizer with double learning strategies for 3D path planning of UAV in power inspection[J]. Mathematics and Computers in Simulation, 2022, 193(193): 509-532.

[5] D. Gandhi, L. Pinto, A. Gupta. Learning to fly by crashing[C]. 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017: 3948-3955.

[6] Stanković M, Mirza M. M., Karabiyik U. UAV Forensics: DJI Mini 2 Case Study[J]. Drones, 2021, 5(2): 49-57.

[7] Ackerman E. Parrot's new drone reclaims aniche: The Anafi marks the company's return to theconsumerspace - [Resources_Review][J]. IEEE Spectrum, 2018, 55(9): 21-29.

[8] Sonia W. Sense and Avoid in UAS: Research and Applications[J]. The Aeronautical Journal, 2014, 118(1199): 105-115.

[9] S. Saha, A. Natraj and S. Waharte. A real-time monocular vision-based frontal obstacle detection and avoidance for low cost UAVs in GPS denied environment[C]. IEEE International Conference on Aerospace Electronics and Remote Sensing Technology, Indonesia: Yogyakarta, 2014: 189-195.

[10] Zhang Ben, Zhu Denglin. A Stereo SLAM System With Dense Mapping[J]. IEEE ACCESS, 2021, 9: 151888-151896.

[11] Tedeschi A, Calcaterra S, Benedetto F. Ultrasonic RAdar System(URAS): Arduino and Virtual Reality for a Light-Free Mapping of Indoor Environments[J]. IEEE Sensors Journal, 2017: 4595-4604.

[12] Uzkent B, Hoffman M J, Vodacek A, et al. Feature Matching With an Adaptive Optical Sensor in a Ground Target Tracking System[J]. IEEE Sensors Journal, 2015, 15(1): 510-519.

[13] Karthika E, Amutha K, Prabhu S J, et al. Object Detection Using Radar[C]. International Conference on Current Trends towards Converging Technologies, 2018: 773-777.

[14] 李朋月. 基于视觉的旋翼无人机自主避障关键技术研究[D]. 河南：战略支援部队信息工程

中国知网 https://www.cnki.net

大学, 2020.

[15] 张宏宏, 甘旭升, 毛亿, 等. 无人机避障算法综述[J]. 航空兵器, 2021, 28(05): 53-63.

[16] 付其喜, 梁晓龙, 张佳强, 侯岳奇. 双层优化的多无人机合作式冲突探测与解脱[J]. 哈尔滨工业大学学报, 2020, 52(04): 74-83.

[17] Yan Z, Li J, Zou J, et al. A hybrid PSO-WG algorithm for AUV path planning in unknown oceanic environment[C]. 2018 IEEE 8th International Conference on Underwater System Technology: Theory and Applications (USYS), IEEE, 2018: 1-6.

[18] Maini P, Sujit P B. Path planning for a UAV with kinematic constraints in the presence of polygonal obstacles[C]. International Conference on Unmanned Aircraft Systems, IEEE, 2016: 62-67.

[19] Xing Y, Wei Y, Zhang H, et al. A new method for robot path planning based artificial potential field[J]. IEEE, 2016: 1294-1299.

[20] Daily R, Bevly D M. Harmonic potential field path planning for high speed vehicles[C]. IEEE American Control Conference, 2008: 4609-4614.

[21] Durand N. Constant speed optimal reciprocal collision avoidance[J]. Transportation Research Part C: Emerging Technologies, 2018, 96: 366-379.

[22] Zhao W, Chellappa R, Phillips P J, et al. Face recognition: A literature survey[J]. Acm Computer Surveys, 2003, 35(4): 399-458.

[23] 张慧, 王坤峰, 王飞跃. 深度学习在目标视觉检测中的应用进展与展望[J]. 自动化学报, 2017, 43(08): 1289-1305.

[24] A. Qu, J. Niu, S. Mo. Enhancing Transformer with Horizontal and Vertical Guiding Mech-anisms for Neural Language Modeling[C]. In Proceedings of the 2021 IEEE International Conference on Communications (ICC), QC, Canada: Montreal, 2021: 1-6.

[25] N. Camgoz, O. Koller, S. Hadfield, et al. Sign Language Transformers: Joint End-to-End Sign Language Recognition and Translation[C]. In Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), WA, USA: Seattle, 2020: 10020-10030.

[26] V. Shetty, M. Mary. Improving the Performance of Transformer Based Low Resource Speech Recognition for Indian Languages[C]. In Proceedings of the 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Spain: Barcelona, 2020: 8279-8283.

[27] J. Liang, J. Cao, G. Sun, et al. SwinIR: Image Restoration Using Swin Transformer[C]. In Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW), BC, Canada: Montreal, 2021: 1833-1844.

中国知网 https://www.cnki.net

[28] Q. Qin, J. Yan, Q. Wang, et al. ETDNet: An Efficient Transformer Deraining Model[J]. IEEE Access, 2021: 119881-119893.

[29] H. Chen, Y. Wang, T. Guo, et al. Pre-Trained Image Processing Transformer[C]. In Proceedings of the 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition(CVPR), TN, USA: Nashville, 2021: 12294-12305.

[30] Li Zewen, Liu Fan,Yang Wenjie, et al. A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects.[J]. IEEE transactions on neural networks and learning systems, 2021, 33(12): 6999-7019.

[31] Jeng-Shyang Pan, Ji-Xiang Lv, Li-Jun Yan, et al. Golden eagle optimizer with double learning strategies for 3D path planning of UAV in power inspection[J]. Mathematics and Computers in Simulation Acm Computer Surveys. 2022, 193: 509-532.

[32] 丛梦苑. 基于线性二次调节器的四旋翼飞行器控制系统的设计与研究[D]. 黑龙江: 哈尔滨工程大学, 2011.

[33] Rui H, Ping T, Chen B M. Monocular vision-based autonomous navigation system on a toy quadcopter in unknown environments[C]. 2015 International Conference on Unmanned Aircraft Systems (ICUAS), IEEE, 2015: 1260-1269.

[34] 姬江涛, 扈菲菲, 贺智涛, 等. 四旋翼无人机在农田信息获取中的应用[J]. 农机化研究, 2013, 35(02): 1-4.

[35] A. Loquercio, A. I. Maqueda, C. R. del-Blanco, et al. DroNet: Learning to fly by driving[J]. IEEE Robotics and Automation Letters, 2018, 3(2): 1088-1095.

[36] Bergstrom A, Nowatzki J, Witt T, et al. Protecting farm privacy while researching large scale unmanned aircraft systems platforms for agricultural applications[J]. Agronomy Journal, 2022, 114(5): 2700-2714.

[37] PowerVision Robot Corporation. PowerVision Hatching New All-In-One PowerEgg X Autonomous Personal AI Camera at CES 2020[J]. Journal of Robotics & Machine Learning, 2020: 174-179.

[38] 贾宝芝. 视频导航中的地图生成、障碍检测与行人人脸识别[D]. 合肥: 中国科学技术大学, 2015.

[39] Teppei K, Ryoko M, Tomoyuki M, et al. Microtubule-binding sites of the CH domain of EB1 and its autoinhibition revealed by NMR[J]. BBA - Proteins and Proteomics, 2013, 1834(2): 499-507.

[40] Aguilar W, Casaliglla V, J Pólit. Obstacle Avoidance Based-Visual Navigation for Micro Aerial Vehicles[J]. Electronics, 2017, 6(1): 10-18.

中国知网 https://www.cnki.net

[41] M. Iacono, S. Weber, A. Glover, C. Bartolozzi. Towards Event-Driven Object Detection with Off-the-Shelf Deep Learning[C]. 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2018: 1-9.

[42] 马浩森. 基于单目视觉的旋翼无人机避障技术研究[D]. 江苏: 南京邮电大学, 2020.

[43] 许建军. 基于双目 SLAM 技术的无人机避障研究[D]. 北京: 北京邮电大学, 2021.

[44] Ian Lenz, Honglak L, Ashutosh Saxena. Deep Learning for Detecting Robotic Grasps[J]. CoRR, 2015: 705-724.

[45] Joohyun W, Nakwan K. Collision avoidance for an unmanned surface vehicle using deep reinforcement learning[J]. Ocean Engineering, 2020, 199(C): 107001-107001.

[46] 高平海. 基于深度学习的多旋翼无人机双目视觉避障算法[D]. 湖南: 国防科技大学, 2017.

[47] 杨兴隆. 基于碰撞时间的多旋翼无人机视觉避障方法研究[D]. 上海: 上海交通大学, 2020.

[48] 郑腾龙. 基于深度学习的无人机电力巡检障碍物目标检测与避障系统[D]. 天津: 天津工业大学, 2021.

[49] Mohamed A, Samir A. Rawashdeh. A Single-Stream Segmentation and Depth Prediction CNN for Autonomous Driving[J]. IEEE Intelligent Systems, 2020, 36(4): 79-85.

[50] Panganiban E.B., Chung W.-Y., Tai W.-C., et al. Real-Time Intelligent Healthcare Monitoring and Diagnosis System Through Deep Learning and Segmented Analysis[J]. IFMBE Proceedings, 2020, 74: 15-25.

[51] Li Zhiyong, Wen Bo, Luo Yunzhong, et al. Hyperspectral image classification based on octave convolution and multi-scale feature fusion[J]. Precision Engineering, 2022, 75: 80-94.

[52] Dai J, Qi H, Xiong Y, et al. Deformable Convolutional Networks[J]. IEEE, 2017: 764-773.

[53] Huang G, Liu S, Laurens V, et al. CondenseNet: An Efficient DenseNet using Learned Group Convolutions[J]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018: 2752-2761.

[54] Weiler M, Geiger M, Welling M, et al. 3D Steerable CNNs: Learning Rotationally Equivariant Features in Volumetric Data[J]. IEEE, 2018: 10402–10413.

[55] Gori M, Monfardini G, Scarselli F. A new model for learning in graph domains[C]. IEEE International Joint Conference on Neural Networks, IEEE, 2005: 729-734.

[56] A. Krizhevsky, I. Sutskever, G. E. Hinton. ImageNet classificationwith deep convolutional neural networks[J]. Adv. Neural Inf. Process. Syst.(NIPS), 2012, 25: 1097-1105.

[57] Karen S, Andrew Z. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. CoRR, 2014: 1-14.

中国知网 https://www.cnki.net

[58] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. Deep Residual Learning for Image Recognition[J]. IEEE Computer Society, 2016: 770-778.

[59] Hu Jie, Shen Li, Albanie S, et al. Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 42(8): 7132-7141.

[60] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, et al. ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices[J]. CoRR, 2017: 6848-6856.

[61] Andrew H, Mark S, Grace C, et al. Searching for MobileNetV3[J]. CoRR, 2019: 1314-1324.

[62] Han K., Wang Y., Tian Q., et al. GhostNet: More features from cheap operations[J]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2020: 1580-1589.

[63] Suciu G, Dragu M, Hussain I, et al. 3D Modeling Using Parrot Bebop 2 FPV[C]. 2018 IEEE 16th International Conference on Embedded and Ubiquitous Computing (EUC), IEEE, 2018: 61-65.

[64] 周城宇, 甄子洋, 黄一敏, 江驹. 基于视觉引导的无人直升机着舰技术研究[J]. 导航定位与授时, 2018, 5(04): 43-48.

[65] Zhang Z. A Flexible New Technique for Camera Calibration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(11): 1330-1334.

[66] Bouvrie J. Notes on Convolutional Neural Networks[J]. neural nets, 2006: 47-60.

[67] Deng L, Abdel-Hamid O, Yu D. A deep convolutional neural network using heterogeneous pooling for trading acoustic invariance with phonetic confusion[C]. 2013 IEEE International Conference on Acoustics, Speech and Signal Processing, 2013: 6669-6673.

[68] Andersson O, Wzorek M, Rudol P, et al. Model-predictive control with stochastic collision avoidance using Bayesian policy optimization[C]. IEEE International Conference on Robotics & Automation, 2016: 3813-4798.

[69] Selvin P K S, Agees K C, Jemila R R. ERCNN-DRM: an efficient regularized convolutional neural network with a dimensionality reduction module for the classification of brain tumour in magnetic resonance images[J]. Automatika, 2023, 64(1): 79-92.

[70] Ba L J, Frey B. Adaptive dropout for training deep neural networks[J]. Advances in neural information processing systems, 2013: 3084-3092.

[71] 戴熙. 基于卷积神经网络的无人机自主避障方法研究[D]. 四川: 西南交通大学, 2020.

[72] 黄昌鹤. 基于改进 BiSeNet 模型的无人机避障算法研究[D]. 四川: 西南交通大学, 2021.

[73] Kim J, Canny J. Interpretable Learning for Self-Driving Cars by Visualizing Causal Attention[C].

中国知网 https://www.cnki.net

2017 IEEE International Conference on Computer Vision (ICCV), 2017: 2942-2950.

[74] Liu Z, Lin Y, Cao Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[J]. 2021 IEEE International Conference on Computer Vision, 2021: 9992-10002.

[75] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.

[76] Tayebi A, McGilvray S. Attitude stabilization of a VTOL quadrotor aircraft[J]. IEEE Transactions on Control Systems Technology, 2006, 14(3): 562-571.

[77] P. Rusek, J. B. Anderson. M-ary coded modulation by Butterworth filtering[C]. IEEE International Symposium on Information Theory, Proceedings., Yokohama, Japan, 2003: 184-189.

[78] Anon K，Tanriover C, Adebisi B. On the optimization of iterative clipping and filtering for PAPR reduction in OFDM system[J]. IEEE Access, 2017, 5: 12004-12013.

[79] Jiang X. Iterative Truncated Arithmetic Mean Filter and Its Properties[J]. 2012, 21(4): 1537-1547.

[80] 陈姗姗, 杜治君, 李波波. 几种滤波算法性能比较与分析[J]. 现代经济信息, 2009(15): 237-237.

[81] Jayaraj V, Ebenezer D. A New Switching-Based Median Filtering Scheme and Algorithm for Removal of High-Density Salt and Pepper Noise in Images[J]. Eurasip Journal on Advances in Signal Processing, 2010, 2010(1): 1-11.

[82] Zhu Y, Cheng H. An Improved Median Filtering Algorithm Combined with Average Filtering[C]. Measuring Technology and Mechatronics Automation, IEEE, 2011: 420-423.

中国知网 https://www.cnki.net