单位代码：10293 密　级：_____

南京邮电大学

专 业 学 位 硕 士 论 文

论文题目：基于强化学习的机械臂多目标轨迹规划研究

学　　号　1320057811

姓　　名　柳润宁

导　　师　樊春霞

专业学位类别　电子信息硕士

类　　型　非全日制

专业（领域）　电子信息

论文提交日期　2023 年 06 月

中国知网 https://www.cnki.net

Multi-objective trajectory planning of manipulator based on reinforcement learning

Thesis Submitted to Nanjing University of Posts and Telecommunications for the Degree of

Master of Engineering



By

Running Liu

Supervisor: Prof. Chunxia Fan

June 2023

中国知网 https://www.cnki.net

摘要

机械臂轨迹规划是一个重要的研究领域，机械臂轨迹规划的准确性对于实现任务的精确执行至关重要。通过优化轨迹规划，提高生产效率和产品质量。因此，本文以机械臂轨迹规划为研究内容，结合强化学习思想，以时间-动能-冲击为多目标，提出了一种轨迹规划方法。主要的研究内容如下：

1.考虑到机械臂工作的复杂性，针对现有的深度强化学习算法，将其直接应用于机械臂多目标轨迹规划时出现的效果不佳的问题，根据约束条件和优化目标，为每个优化目标确定轨迹规划过程中的奖励函数，从所获得的帕累托前沿集中，随机选择若干组状态-动作对，使用最大熵搜索法来训练每个目标动作网络的参数和梯度下降法训练每个目标评判网络的参数，从而提出了获得满足多种约束条件多个目标的工业机器人轨迹的方法。在仿真实验中，获得了超越 PD 控制算法的性能指标。

2.提出一种基于改进 DDPG 算法（Multi-objective DDPG algorithm）的机械臂多目标轨迹规划方法，简称 MODDPG 算法，通过设计奖励函数，在经验池优先级设计中引入帕累托多目标优化，通过 NSGA 算法求解帕累托前沿，进一步提升了强化学习中的经验样本效率和算法的性能。

3.以 UR5 机械臂为仿真对象，分别用最大熵近端最优算法和改进 MODDPG 算法对其进行仿真验证，其中最大熵近端最优算法效率值相较传统 PD 控制算法提升了 37.5%，改进 MODDPG 算法训练效率相较最大熵近端最优算法提升了 31.25%，执行规划任务时平均效率提升了 15.6%。仿真结果表明两种算法能有效帮助机械臂取得综合最优性能，在复杂任务中有着良好的性能，在提升工业生产效率的同时也能够节约维护成本。

关键词： 机械臂，强化学习，多目标优化，轨迹规划

中国知网 https://www.cnki.net

Abstract

Manipulator trajectory planning is an important research field. The accuracy of manipulator trajectory planning is very important for the accurate execution of tasks. By optimizing trajectory planning, production efficiency and product quality are improved. Therefore, this paper takes the trajectory planning of the manipulator as the research content, combines the idea of reinforcement learning, and proposes a trajectory planning method with time-kinetic energy-impact as the multi-objective. The main research contents are as follows :

A multi-objective trajectory planning method for manipulator based on improved DDPG algorithm (MODDPG algorithm)is proposed.By designing a reward function, Pareto multi-objective optimization is introduced into the priority design of experience pool, and Pareto frontier is solved by NSGA algorithm, which further improves the efficiency of empirical samples in reinforcement learning and the performance of the algorithm.

On the basis of the above maximum entropy proximal strategy optimization algorithm, aiming at the problem that the computational complexity is high in the training process and requires a lot of computing resources, a multi-objective trajectory planning method of manipulator based on improved DDPG algorithm (Multi-objective DDPG algorithm)is proposed, referred to as MODDPG algorithm. By designing the reward function, Pareto optimization is introduced into the priority design of experience pool, which improves the efficiency of empirical samples in reinforcement learning, and the performance of the algorithm is improved.

Taking the UR5 manipulator as the simulation object, the maximum entropy proximal optimal algorithm and the improved MODDPG algorithm are used to simulate and verify it respectively. The efficiency value of the maximum entropy proximal optimal algorithm is 37.5 % higher than that of the traditional PD control algorithm. The training efficiency of the improved MODDPG algorithm is 31.25 % higher than that of the maximum entropy proximal optimal algorithm, and the average efficiency is 15.6 % higher when performing the planning task. The simulation results show that the two algorithms can effectively help the manipulator to achieve comprehensive optimal performance, have good performance in complex tasks, and can save maintenance costs while improving industrial production efficiency.

Key words: Manipulator, Reinforcement learning, Multi-objective optimization, Trajectory planning

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 课题研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 机械臂轨迹规划.....2
1.2.2 目前存在的问题.....3
1.3 本文的主要工作.....4
第二章 相关理论概述.....6
2.1 引言.....6
2.2 机械臂运动模型.....7
2.3 强化学习相关理论.....9
2.3.1 马尔可夫决策过程.....9
2.3.2 Q-learning 算法.....13
2.3.3 DQN 算法.....14
2.3.4 Actor-Critic 算法.....16
2.3.5 DDPG 算法.....17
2.4 机械臂轨迹规划多目标优化.....19
2.4.1 帕累托多目标优化.....19
2.5 本章小结.....21
第三章 基于最大熵近端策略最优的机械臂多目标轨迹规划方法.....23
3.1 引言.....23
3.2 问题描述.....24
3.3 最大熵近端策略最优算法.....25
3.4 实验结果分析.....29
3.5 本章小结.....33
第四章 基于改进 DDPG 算法的机械臂多目标轨迹规划方法.....35
4.1 引言.....35
4.2 问题描述.....36
4.3 基于多目标优化的改进 DDPG 算法.....36
4.4 实验结果分析.....42
4.4.1 实验一.....42
4.4.2 实验二.....43
4.5 本章小结.....46
第五章 总结与展望.....48
5.1 全文总结.....48

中国知网 https://www.cnki.net

5.2 展望未来.....49
参考文献.....50

中国知网 https://www.cnki.net

第一章 绪论

1.1 课题研究背景与意义

机械臂是一种具有多个自由度和可编程的机器设备，能够执行各种任务，如装配、焊接、搬运等。机械臂轨迹规划的背景可以追溯到上世纪的自动化生产和工业机器人应用的发展。随着计算机科学和人工智能的进步，机器学习和优化技术的应用为机械臂轨迹规划带来了新的发展机遇[1]。

随着工业自动化的不断发展，机械臂在工业生产、仓储物流、医疗护理等领域的应用越来越广泛[2]。如图 1.1 所示，机械臂在新能源汽车产业生产线上的工作场景。然而，要实现机械臂在复杂环境中的自主运动和灵活操作，需要解决一个关键问题：轨迹规划。机械臂轨迹规划是指在工业机器人或机械臂执行特定任务时，确定其运动轨迹和姿态的过程。它是工业机器人应用中至关重要的一环，对于实现精确的位置控制、高效的操作和安全性具有重要意义。

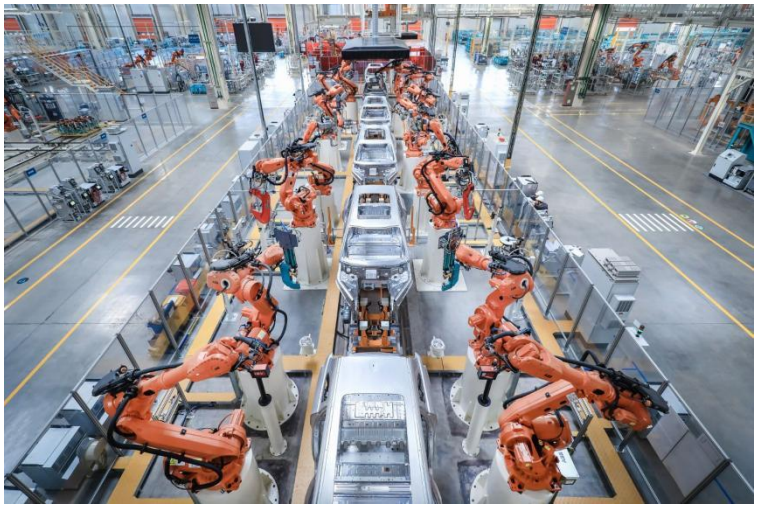


图 1.1 工业机械臂生产线

机械臂轨迹规划的准确性对于实现任务的精确执行至关重要。通过优化轨迹规划，可以最大程度地减小误差，提高生产效率和产品质量。机械臂在复杂环境中工作时，需要规避障碍物、避免碰撞，以确保操作的安全性。轨迹规划可以考虑环境因素和约束条件，通过合理的路径选择避免潜在的碰撞风险。优化的轨迹规划可以减少机械臂的运动时间和能源消耗，提高资源的利用率和能源的效率。通过最小化移动距离、减少不必要的动作，可以降低成本和环境影响。机械臂轨迹规划的研究旨在开发灵活、自适应的方法，使机械臂能够适应不同

中国知网 https://www.cnki.net

任务和环境的需求。这为机械臂的多样化应用提供了更大的潜力和应用空间。

在过去的几十年中，机械臂轨迹规划的研究经历了长足的发展。最早期的机械臂轨迹规划方法主要依靠人工编程，即通过手动设置机械臂的运动路径和关节角度来完成任务。这种方法存在着依赖人力、效率低下和难以适应复杂环境等问题。

随着计算机科学和人工智能的进步，研究者开始探索基于算法的机械臂轨迹规划方法。其中，运动学方法、动力学方法、优化方法和学习方法等不同的技术逐渐被引入。运动学方法通过建立机械臂的几何模型和运动学方程，实现了对机械臂的精确控制；动力学方法考虑机械臂的惯性和力学特性，实现了更加稳定和平滑的轨迹规划；优化方法利用数学优化理论和算法，以最小化特定的目标函数来实现高效的轨迹规划；学习方法则通过机器学习和深度学习技术，让机械臂能够自主学习和改进轨迹规划的策略。综上所述，机械臂轨迹规划在实现精确控制、提高效率、保证安全以及节约资源方面具有重要的背景和作用，对于推动工业自动化和机器人技术的发展具有重要意义。

1.2 国内外研究现状

1.2.1 机械臂轨迹规划

机械臂轨迹规划是指确定机械臂在空间中运动的路径和轨迹，使其能够完成特定的任务。机器人轨迹规划涉及生成一系列路径点，并为每个路径点分配相应的时间信息。其研究目标是在满足机器人的关节角度、角速度、加速度等运动学限制以及能量消耗和动力学约束的前提下，解决机器人时间调度的问题。在规划过程中，时间消耗、能量消耗和冲击等指标被视为评价轨迹质量的重要参数。随着现代化生产作业对效率的日益追求，成本节约和生产效率提升成为当前研究的热门方向。因此，深入研究机器人轨迹规划，以满足工业生产需求，具有重要的实际意义。

轨迹规划可以分为单目标轨迹规划和多目标轨迹规划两个方面。单目标轨迹规划主要关注机械臂完成单一任务的路径规划，通常是指机械臂从一个起始位置到达一个目标位置的规划过程。轨迹优化以时间为优化目标[3]是为了提高机械臂的工作效率。以能量消耗作为轨迹优化目标[4][5]是为了降低能耗，满足长时间工作要求。降低脉动冲击轨迹优化[6]是为了提高机械臂运动过程中轨迹的平滑性，减小冲击，保护机器人本体结构。早期的机械臂轨迹规划研究主要集中在解决点到点的轨迹规划问题，即确定机械臂从一个给定位置移动到另一个给定

中国知网 https://www.cnki.net

位置的最短路径。随着对机械臂应用需求的增加，研究者开始考虑更加复杂的问题。例如，研究者开始研究带有障碍物的路径规划问题，以确保机械臂能够避开障碍物并安全到达目标位置。商德勇等[7]提出了一种基于 RRT*-DR 算法的机械臂避障路径规划方法。随着计算能力的提升和算法的发展，研究者开始采用更复杂的方法进行单目标轨迹规划。例如，引入启发式搜索算法、优化算法和机器学习方法等，以求得更高效和更优的轨迹规划结果。李林生[8]提出了一种基于惩罚函数法的时间最优机械臂规划方法，殷凤健等[9]提出了一种基于时间最优的机械臂关节空间轨迹规划算法。李虎等[10]提出了一种基于改进 PSO 算法的时间最优机械臂轨迹规划方法。

多目标轨迹规划[11]涉及机械臂在多个目标之间进行规划，以完成一系列任务。多目标轨迹规划通常涉及更复杂的任务和约束条件，并且需要考虑不同目标之间的优先级和冲突解决。多目标轨迹规划的早期研究主要关注确定机械臂在多个目标之间的最佳路径。通常使用启发式算法或优化算法来解决多目标优化问题。随着机器学习和人工智能的发展，研究者开始探索将这些技术应用于多目标轨迹规划中。例如，使用强化学习方法来学习机械臂在多目标情况下的最佳策略，或者使用深度学习方法来预测障碍物的位置和姿态，以辅助规划过程。

徐海黎等[12]采用三次多项式曲线连接相邻型值点，通过免疫克隆算法对机械臂时间消耗和能量消耗这两个指标进行综合优化，三次多项式构造的机械臂运动轨迹不够平滑。余阳等[13]采用五次均匀 B 样条插值方法结合混合遗传算法对机械臂进行时间-能量混合最优轨迹规划，这种算法受主观影响较大。施祥玲[14]等采用五次 NURBS 对机械臂进行多个目标轨迹优化，在降低轨迹规划时间的同时，减小了能量消耗和冲击，但无法指定启停时刻加加速度。许哲[15]等提出了一种基于 NSGA-II算法的机械臂多目标轨迹优化方法，实现了多目标综合最优，但忽略了机械臂的自主学习能力和泛化能力。唐润智[16]对面向高载荷低能耗问题的机器人轨迹规划方法进行了研究。以上方法多集中于传统遗传算法对于多目标优化问题的解决，随着人工智能的发展，强化学习为机械臂多目标轨迹规划问题提供了新的方向。

1.2.2 目前存在的问题

尽管关于机械臂多目标轨迹规划的相关研究已经逐渐成熟，但依旧存在许多缺陷与不足。大多数机械臂多目标轨迹规划的研究都是基于传统遗传算法[12]等对于多目标的优化，具有很强的模型确定性，忽略了机械臂的自主学习能力，其主要劣势包含：

1.搜索空间大：机械臂多目标轨迹规划问题通常涉及多个目标和多个约束条件，搜索空间非常庞大。传统遗传算法的搜索过程是通过对候选解进行随机组合和变异来进行搜索[13]，

中国知网 https://www.cnki.net

这种搜索方法在高维空间中容易陷入局部最优解，难以找到全局最优解。

2.适应度评价困难：机械臂多目标轨迹规划问题的适应度评价需要考虑多个目标指标，例如轨迹长度、路径平滑性和碰撞避免等。传统遗传算法通常使用单一的适应度函数来评价解的质量，很难综合考虑多个目标指标，导致无法准确评估解的优劣[14]。

3.缺乏多样性：传统遗传算法中的交叉和变异操作容易导致种群陷入局部最优解，并丧失了种群的多样性。在机械臂多目标轨迹规划中，多样性对于探索搜索空间的全局优化至关重要，但传统遗传算法在这方面的表现相对较差[15]。

1.3 本文的主要工作

机械臂轨迹规划和多目标优化是机器人领域中的重要研究方向。传统的机械臂轨迹规划方法主要基于数学优化技术，如线性规划、非线性规划和遗传算法[16]等。这些方法通常将轨迹规划问题转化为单目标优化问题，通过权衡不同目标之间的权重，得到一个综合考虑多个目标的最优解。然而，这些方法往往忽视了目标之间的相互关系和复杂的约束条件。

本文主要研究机械臂轨迹规划中的多目标优化问题。将优化技术和强化学习算法结合起来以达到提高机械臂轨迹规划的性能的目的。混合方法将传统的数学优化技术与机器学习、强化学习等技术相结合，利用它们各自的优势来解决多目标优化问题。

本文的各章节主要内容安排如下：

第一章介绍了课题的研究背景与意义，对机械臂轨迹规划进行了简要地概括，着重阐明了本文的主要贡献和创新点，并对文章后续章节的内容进行安排。

第二章介绍了机械臂轨迹规划问题相关的部分主流强化学习算法[17]和多目标优化算法，并详细介绍了各种算法的内部原理特性以及迭代流程，引出本文的第一个研究内容：基于强化学习的机械臂多目标轨迹规划。

第三章针对仿真机械臂的多目标轨迹规划，从环境建模出发，构建一个可用于相关实验的仿真环境。并分析了传统方法应用于机械臂轨迹规划[18]问题上存在的缺陷，提出基于强化学习的机械臂多目标轨迹规划方法，针对每个优化目标，构建并行运作的动作网络和评判网络，根据评判网络输出的优势函数对动作网络的策略进行非支配排序而获得帕累托前沿集；根据约束条件和优化目标，为每个优化目标确定轨迹规划过程中的奖励函数，从所获得的帕累托前沿集中，随机选择若干组状态-动作对，使用最大熵搜索法来训练每个目标动作网络的参数和梯度下降法训练每个目标评判网络的参数，从而获得满足多种约束条件多个目标的工业机器人轨迹。最后在数据集上验证了优化方法的有效性，证明了使用该优化方法比传统的

中国知网 https://www.cnki.net

多目标规划方法有更强的稳定性与收敛性。

第四章分为两部分内容，第一部分内容基于前面的研究，提出改进 DDPG 算法的机械臂多目标轨迹规划方法，改进奖励函数以及经验池设计，在仿真中验证了优化方法的有效性，证明了使用该改进方法比传统的多目标规划方法有更强的稳定性与收敛性。第二部分内容搭建了实物仿真平台，与最大熵近端优化算法进行对比分析，在仿真实验中验证了改进 DDPG 算法的有效性，证明了使用该改进方法比传统的方法提升了效率的同时，有着更强的稳定性和收敛性。

第五章总结了本文提出的各种方法，分析并阐述了各个方法间的优点和缺陷，并提出一些不足之处和改进建议。最后提出一些未来在机械臂轨迹规划领域可能的发展方向。

中国知网 https://www.cnki.net

第二章 相关理论概述

2.1 引言

机械臂轨迹规划和多目标优化是机器人领域中的重要研究方向。传统的机械臂轨迹规划方法主要基于数学优化技术，如线性规划、非线性规划和遗传算法等。谢嘉等[19]对改进粒子群优化算法在机械臂轨迹规划中的应用进行了研究。这些方法通常将轨迹规划问题转化为单目标优化问题，通过权衡不同目标之间的权重，得到一个综合考虑多个目标的最优解。然而，这些方法往往忽视了目标之间的相互关系和复杂的约束条件。

近年来，越来越多的研究[20]关注于机械臂轨迹规划中的多目标优化问题。多目标优化方法旨在找到一组解决方案，称为帕累托前沿（Pareto Frontier），其中没有解可以在所有目标上得到改进而不损害其他目标。这些方法可以提供决策者在不同优化目标之间进行权衡和选择的灵活性。进化算法，如遗传算法[21]、粒子群优化[22]和模拟退火[23]等，被广泛应用于机械臂轨迹规划的多目标优化中。这些算法通过模拟自然进化的过程，不断演化出一组解的种群，逐步逼近帕累托前沿。进化算法具有全局搜索能力和对非线性、非凸优化问题的适应性，但其收敛速度较慢。

机器学习和强化学习技术也被应用于机械臂轨迹规划的多目标优化中。这些方法通过训练智能体来学习轨迹规划策略，以最大化预先定义的奖励信号或优化目标。通过学习和优化，智能体可以生成适应不同任务需求和环境条件的多目标优化的轨迹。陈佳盼[24]等人对基于深度强化学习的机器人操作行为进行了研究。周东旭[25]对基于深度强化学习的机械臂运动规划方法展开了研究。刘哲等[26]提出了一种基于指导轨迹加速的机械臂强化学习运动规划方法。最近的研究[27]表明，将不同的优化技术和学习算法结合起来可以提高机械臂轨迹规划的性能。混合方法将传统的数学优化技术与机器学习、强化学习等技术相结合，利用它们各自的优势来解决多目标优化问题。例如，可以使用进化算法来生成一组候选解，然后利用机器学习算法对这些解进行评估和选择，从而得到更好的轨迹规划结果。另一种研究方向是将优化算法[28]和机器学习算法相结合，通过在优化过程中学习和优化模型参数来改进轨迹规划结果。这种方法可以利用机器学习的能力来捕捉问题的复杂性和非线性关系，并通过优化算法[29]进行参数调整和优化，以获得更准确和高效的轨迹规划策略。

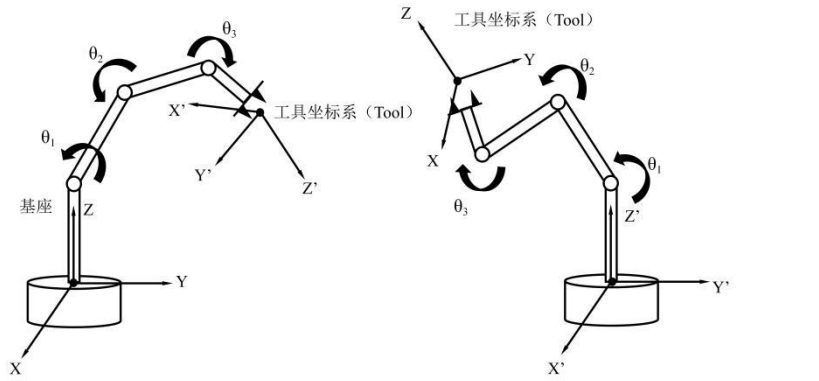
本章节将分为三部分，分别对机械臂、强化学习、多目标优化领域的相关理论和部分主流算法的发展历史进行阐述，目的在于对近年来机器人行业内轨迹规划控制算法领域的发展、

中国知网 https://www.cnki.net

基础理论有一个总体的认知，为后续的研究奠定基础。

2.2 机械臂运动模型

运动学是对物体运动的研究，而不考虑物体的质量，和引起这种运动的力。如图 2.1(a)所示[30]，机器人正运动学[28]是已知或给定一组关节角，计算出末端执行器的坐标系相对于基坐标系的位置和姿态，也就是说，用正运动学来确定机械臂末端执行器的位姿。如图 2.2(b)所示，机器人逆运动学是给定机械臂末端执行器的位置和姿态，计算所有可以到达给定位置和姿态的关节角。也就是说，末端执行器在特定的一个点具有特定的姿态，去计算出它所对应的每一个关节变量的值。机器人运动学的研究方法，首先利用位姿描述、坐标系变换等数学方法确定物体位置、姿态和运动[31]；随后确定不同结构类型的机器人的正逆运动学，这些类型包括直角坐标系、圆柱坐标系和球形坐标系等等；最后根据 Denavit-Hartenberg 参数法去推导机器人的正逆运动学方程。



(a) (b)

图 2.1 机械臂的正运动与逆运动示意图[28]

DH 参数法[32]使用连杆参数来描述机构运动关系。如表 2.1 所示，在标准型 DH 参数法中，描述机械臂中的每一个连杆需要 4 个运动学参数，分别是连杆长度 a_{i-1}、连杆转角 α_{i-1}、连杆偏距 d_i 和关节角 θ_i，它们的定义如下表 2.1 所示。

表 2.1 连杆参数

连杆长度 a_{i-1}	关节轴 $i-1$ 和 i 之间的公垂线的长度
连杆转角 α_{i-1}	第 $i-1$ 个关节轴和第 i 个关节轴之间的夹角
连杆偏距 d_i	沿两个相邻连杆公共轴线方向的距离

中国知网 https://www.cnki.net

关节角θ_i	两相邻连杆绕公共轴线旋转的夹角

用表 2.1 中的 4 个参数对应转动关节和移动关节有两种情况：转动关节中，连杆长度、连杆转角和连杆偏距是固定不变的，关节角θ_i为变量；移动关节中，连杆长度、连杆转角和关节角是固定不变的，连杆偏距d_i为变量。

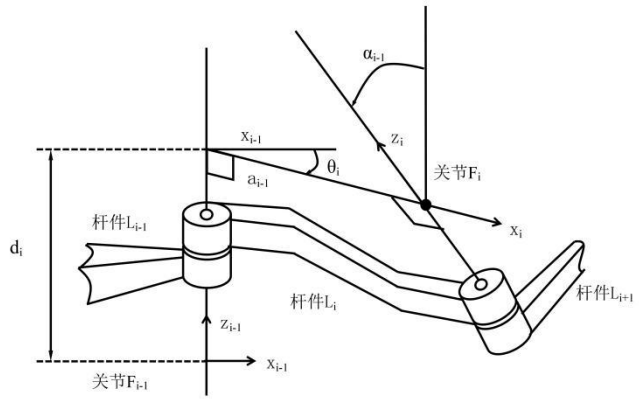


图 2.2 DH 参数法示意图[28]

在机器人的每个关节上 DH 参数中的四个参数分别代表关节连杆不同的特征或在进行不同的变换。如图 2.3 所示[28]，在某时刻，从第$i-1$个关节到第i个关节，经历的变换有：Z 轴旋转（θ_i）、Z 轴平移（d_i）、X 轴平移（a_{i-1}）和 X 轴旋转（α_{i-1}）。

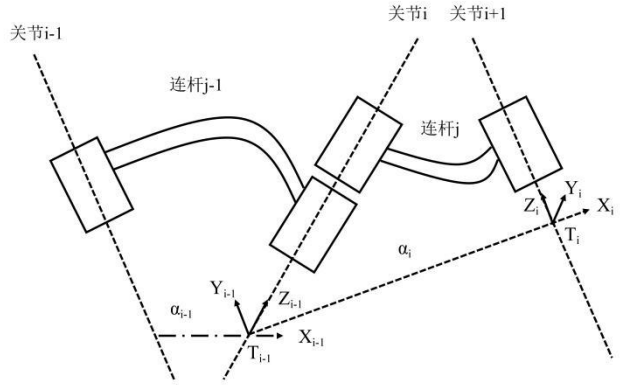


图 2.3 关节连杆示意图[28]

将齐次变换矩阵T和 DH 参数联系起来，即可得到以下公式[28]：

$$ {}^{i}_{i-1}T = R_Z(\theta_i)D_z(d_i)D_X(a_{i-1})R(\alpha_{i-1}) \tag{2.1} $$

中国知网 https://www.cnki.net

上式（2.1）中，a_{i-1}表示连杆长度，即关节轴$i-1$和关节轴i之间公垂线的长度。α_{i-1}表示连杆转角，即第$i-1$个关节轴和第i个关节轴之间的夹角。d_i表示连杆偏距，即沿两个相邻连杆公共轴线方向的距离[33]。θ_i表示关节角，即两相邻连杆绕公共轴线旋转的夹角。

$$ {}^{i}_{i-1}T=\begin{bmatrix} \cos\theta_i & -\sin\theta_i\cos\alpha_{i-1} & \sin\theta_i\sin\alpha_{i-1} & \alpha_{i-1}\cos\theta_i \\ \sin\theta_i & \cos\theta_i\cos\alpha_{i-1} & -\cos\theta_i\sin\alpha_{i-1} & \alpha_{i-1}\sin\theta_i \\ 0 & \sin\alpha_{i-1} & \cos\alpha_{i-1} & d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{2.2} $$

通过将每一个连杆的变换矩阵连乘能够得到坐标$\{N\}$（末端位置）相对于坐标$\{0\}$（基座坐标）的变换矩阵[28]：

$$ {}^{0}_{N}T={}^{0}_{1}T\,{}^{1}_{2}T\cdots{}^{i}_{i+1}T\cdots{}^{N-1}_{N}T \tag{2.3} $$

式（2.3）所示的变换矩阵是N个关节变量的函数。在这里，可以通过各个关节位置传感器得到所需要的值，然后求出每个连杆的变换矩阵，通过式（2.3）就可求出机器人末端[34]的工具坐标系相对于基坐标系的位姿，可表示为：

$$ {}^{0}_{N}T=\begin{bmatrix} r_{11} & r_{12} & r_{13} & p_x \\ r_{21} & r_{22} & r_{23} & p_y \\ r_{31} & r_{32} & r_{33} & p_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{2.4} $$

式（2.4）中，r_{11}到r_{33}代表从基座到末端执行器的旋转矩阵[35]，其中的每列从左到右分别代表末端执行器描述基座中 X 轴、Y 轴和 Z 轴方向上的单位矢量，即可表示末端执行器基于基座坐标系的方向姿态。而式（2.4）p_x、p_y、p_z三行一列从上往下分别代表末端执行器相对于基座坐标系的位置。

2.3 强化学习相关理论

2.3.1 马尔可夫决策过程

马尔可夫决策过程（Markov decision process，MDP）是强化学习的重要概念。如果要用强化学习去解决一个实际问题，第一步要做的是要把这个实际问题抽象为一个马尔可夫决策过程[36]，也就是明确马尔可夫决策过程的各个组成要素。这些要素包含随机过程、马尔可夫性质、马尔科夫奖励过程等。

中国知网 https://www.cnki.net

当且仅当某时刻的状态只取决于上一时刻的状态时，一个随机过程被称为具有马尔可夫性质，可表示为[17]：

$$P(S_{t+1} \mid S_t) = P(S_{t+1} \mid S_1, ..., S_t) \tag{2.5}$$

其中 S_t 表示随机现象在某时刻的取值，$P(S_{t+1} \mid S_1, ..., S_t)$ 表示已知信息（$S_1, ..., S_t$）时下一时刻的状态为 S_{t+1} 的概率。也就是说，当前状态是未来状态的充分统计量，即下一时刻状态只取决于当前状态。

马尔可夫过程是指具有马尔可夫性质的随机过程，也被称为马尔可夫链（Markov chain）。通常我们可以用元组 $\langle S, P \rangle$ 描述一个马尔可夫过程，其中 S 是有限数量的状态集合，P 是状态转移矩阵，它定义了所有状态对之间的转移概率，即：

$$P = \begin{bmatrix} P(s_1 \mid s_1) & \cdots & P(s_n \mid s_1) \\ \vdots & \ddots & \vdots \\ P(s_1 \mid s_n) & \cdots & P(s_n \mid s_n) \end{bmatrix} \tag{2.6}$$

马尔可夫奖励过程即在马尔可夫过程的基础上加入奖励函数 R 和折扣因子 γ。奖励函数 r 表示某个状态转移到另一状态时可以获得的奖励的期望；折扣因子 γ 取值范围为 $[0,1)$，有时候为了尽快获得一些奖励，所以需要对远期利益打一些折扣。即接近 1 的 γ 更关注长期的奖励，接近 0 的 γ 更考虑短期奖励。

在一个马尔可夫奖励过程中，从第 t 时刻状态 S_t 开始，直到终止状态时，所有奖励的衰减之和称为回报，公式如下[17]：

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k} \tag{2.7}$$

其中 R_t 表示时刻 t 获得奖励。一个状态的期望回报被称为这个状态的价值，所有状态的价值就组成了价值函数，价值函数的输入为某一状态，输出则为这个状态的价值。将价值函数记为 $V(s) = E[G_t \mid S_t = s]$，展开为：

$$\begin{aligned} V(s) &= E[G_t \mid S_t = s] \\ &= E[R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots \mid S_t = s] \\ &= E[R_t + \gamma(R_{t+1} + \gamma R_{t+2} + \cdots) \mid S_t = s] \\ &= E[R_t + \gamma G_{t+1} \mid S_t = s] \\ &= E[R_t + \gamma V(S_{t+1}) \mid S_t = s] \end{aligned} \tag{2.8}$$

在式（2.8）的最后一个等式中，一方面，即时奖励的期望正是奖励函数的输出，即 $E[R_t \mid S_t = s] = r(s)$；另一方面，式（2.8）中的其他部分 $E[\gamma V(S_{t+1}) \mid S_t = s]$ 可以根据从状态 s

中国知网 https://www.cnki.net

出发的转移概率得到，即可以得到以下公式：

$$V(s)=r(s)+\gamma\sum_{s'\in S}P(s'|s)V(s') \tag{2.9}$$

式（2.9）即为马尔可夫奖励过程中的贝尔曼方程[17]（Bellman equation），对每一个状态都成立。

马尔可夫过程和马尔可夫奖励过程都是自发改变的随机过程；而当出现一个外界的“刺激”来改变这个随机过程，就有了马尔可夫决策过程。我们将这个来自外界的刺激称为智能体（agent）的动作，在马尔可夫奖励过程的基础上加入动作，就得到了马尔可夫决策过程（MDP）。马尔可夫决策过程由元组$\langle S,A,P,r,\gamma\rangle$构成。

其中：S是状态的集合； A是动作的集合。

马尔可夫决策过程是一个与时间相关的不断进行的过程，在智能体和环境 MDP 之间存在一个不断交互的过程。如下图所示：智能体根据当前的状态S_t选择动作A_t：对于状态S_t和动作A_t，MDP 根据奖励函数和状态转移函数得到S_{t+1}和R_t并反馈给智能体。智能体的目标是最大化得到的累计奖励的期望。智能体根据当前状态从动作的集合A中选择一个动作的函数，成为策略。

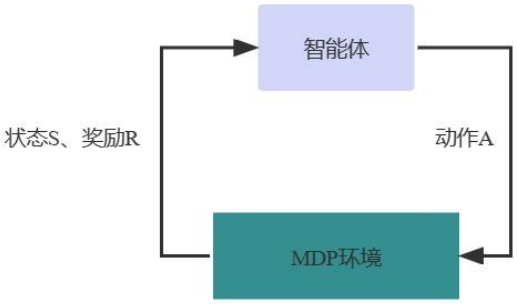


图 2.7 智能体与 MDP 环境的交互示意图[17]

智能体的策略通常用π表示，策略$\pi(a|s)=P(A_t=a|S_t=s)$是一个函数，表示在输入状态为s的情况下采取动作a的概率。当一个策略是确定性策略时，它在每个状态下只输出一个确定性的动作，即只有该动作的概率为 1，其他动作的概率为 0。

状态价值函数是被定义为从状态s出发遵循策略π能获得的期望回报，数学表达式为：

$$V^{\pi}(s)=E_{\pi}[G_t|S_t=s] \tag{2.10}$$

不同于 MRP,在 MDP 中，由于动作的存在，需要定义一个动作价值函数。我们用$Q^{\pi}(s,a)$表示在 MDP 遵循策略π时，对当前状态s执行动作a得到的期望回报：

$$Q^{\pi}(s,a)=E_{\pi}[G_t|S_t=s,A_t=a] \tag{2.11}$$

中国知网 https://www.cnki.net

状态价值函数和动作价值函数二者之间的联系为：当使用策略π时，状态s的价值等于在该状态下基于策略π采取所有动作的概率与相应的价值相乘再求和的结果：

$$V^{\pi}(s)=\sum_{a\in A}\pi(a\mid s)Q^{\pi}(s,a) \tag{2.12}$$

使用策略π时，在状态s下采取动作a的价值等于即时奖励加上经过衰减的所有可能的下一个状态的状态转移概率与相应的价值的乘积：

$$Q^{\pi}(s,a)=r(s,a)+\gamma\sum_{s'\in S}P(s'\mid s,a)V^{\pi}(s') \tag{2.13}$$

综上所述，马尔可夫决策过程（Markov Decision Process，MDP）是强化学习中常用的数学模型，用于描述具有马尔可夫性质的决策过程。下面是马尔可夫决策过程的基本步骤：

1.状态定义：首先，需要定义系统或环境的状态空间。状态是描述系统在某个时间点的特征或特性，可以是离散的或连续的。状态空间包含了系统所有可能的状态。

2.动作定义：在每个状态下，智能体（也称为决策者或代理）可以采取的动作被定义。动作是智能体在某个状态下可以执行的操作或决策，也可以是离散的或连续的。

3.状态转移概率：定义在给定状态和动作下，系统转移到下一个状态的概率。这些转移概率可以用一个转移概率矩阵或函数来表示。

4.奖励函数：为每个状态定义奖励函数，该函数可以根据智能体采取的动作和系统的当前状态给出一个即时奖励。奖励函数可以根据问题的特定目标来设计，可以鼓励或惩罚智能体的行为。

5.折扣因子：引入折扣因子，用于衡量未来奖励的重要性。折扣因子的取值范围在 0 到 1 之间，用于对未来奖励进行折扣，以平衡即时奖励和长期回报之间的权衡。

6.策略定义：定义一个策略，即智能体在给定状态下采取动作的决策规则。策略可以是确定性的，也可以是概率性的。

7.值函数计算：计算值函数，用于衡量在给定策略下的状态或状态动作对的长期价值。值函数可以分为状态值函数（State Value Function）和状态动作值函数（Action Value Function）两种形式。

中国知网 https://www.cnki.net

8.最优策略和最优值函数：通过对值函数进行优化，找到最优策略和最优值函数。最优策略是使期望累积回报最大化的策略。

以上是马尔可夫决策过程的基本步骤，用于描述和解决强化学习中的决策问题。在实际应用中，可以通过迭代算法（如值迭代、策略迭代）或近似算法[37]（如 Q-learning、深度强化学习）来求解最优策略和最优值函数。

2.3.2 Q-learning 算法

除了 Sarsa，还有一种非常著名的基于时序差分算法的强化学习算法——Q-learning[39]。Q-learning 和 Sarsa 的最大区别在于 Q-learning 的时序差分更新方式为：

$$Q(s_t,a_t)\leftarrow Q(s_t,a_t)+\alpha[r_t+\gamma\max Q(s_{t+1},a_{t+1})-Q(s_t,a_t)] \quad (2.15)$$

Q-learning 算法流程图如下表 2.4 所示。

表 2.4 Q-learning 算法

Q-learning 算法的具体流程如下：
初始化 $Q(s,a)$
for 序列 $e=1\rightarrow E$ **do:**
得到初始状态 s
for 时间步 $t=1\rightarrow T$ **do:**
用 $\in-greedy$ 策略根据 Q 选择当前状态 s' 下的动作 a'
得到环境反馈的 r,s'
$Q(s,a)\leftarrow Q(s,a)+\alpha[r+\gamma\max_{a'}Q(s',a')-Q(s,a)]$
$s\leftarrow s'$
end for
end for

可以用价值迭代的思想来理解 Q-learning，即 Q-learning 是直接在估计 Q^*，因为动作价

中国知网 https://www.cnki.net

值函数的贝尔曼最优方程是：

$$Q^*(s,a)=r(s,a)+\gamma\sum_{s'\in S}P(s'\mid s,a)\max_a Q^*(s',a') \tag{2.16}$$

时序差分算法的核心思想是用对未来动作选择的价值估计来更新对当前动作选择的价值估计，这是强化学习中的核心思想之一。Sarsa 和 Q-learning 这两个最具有代表性的时序差分算法。当环境是有限状态集合和有限动作集合时，这两个算法非常好用，可以根据任务是否允许在线策略学习来决定使用哪一个算法。Sarsa 是在线策略（on-policy）算法，称 Q-learning 是离线策略（off-policy）算法。

值得注意的是，尽管离线策略学习可以让智能体基于经验回放池中的样本来学习，但需要保证智能体在学习的过程中可以不断和环境进行交互，将采样得到的最新的经验样本加入经验回放池中，从而使经验回放池中有一定数量的样本和当前智能体策略对应的数据分布保持很近的距离。如果不允许智能体在学习过程中和环境进行持续交互，而是完全基于一个给定的样本集来直接训练一个策略，这样的学习范式被称为离线强化学习。

2.3.3 DQN 算法

2.3.3 节中介绍的 Q-learning 算法中，是以矩阵的方式建立了一张存储每个状态下所有动作值的表格。表格中的每一个动作价值表示在状态下选择动作然后继续遵循某一策略预期能够得到的期望回报。然而，这种用表格存储动作价值的做法只在环境的状态和动作都是离散的，并且空间都比较小的情况下适用。当状态或者动作连续的时候，就有无限个状态动作对，我们更加无法使用这种表格形式来记录各个状态动作对的值。对于这种情况，我们需要用函数拟合的方法来估计值，即将这个复杂的值表格视作数据，使用一个参数化的函数来拟合这些数据。

（1）DQN 算法[40]含有两个重要的模块。

一是经验回放，为维护一个回放缓冲区，将每次从环境中采样得到的四元组数据（状态、动作、奖励、下一状态）存储到回放缓冲区中，训练 Q 网络的时候再从回放缓冲区中随机采样若干数据来进行训练。这样做可以有两个作用。使样本满足独立假设。在 MDP 中交互采样得到的数据本身不满足独立假设，因为这一时刻的状态和上一时刻的状态有关。非独立同分布的数据对训练神经网络有很大的影响，会使神经网络拟合到最近训练的数据上。采用经验回放可以打破样本之间的相关性，让其满足独立假设。提高样本效率。每一个样本可以被使用多次，十分适合深度神经网络的梯度学习。

二是目标网络，训练过程中先将 TD 目标中的 Q 网络固定住，因此需要使用两套 Q 网络：

中国知网 https://www.cnki.net

训练网络$Q_w(s,a)$，用于计算原损失函数$\frac{1}{2}\left[Q_w(s,a)-\left(r+\gamma\max_{a'}Q_{w^-}(s',a')\right)\right]^2$中的$Q_w(s,a)$项，并按照正常梯度下降法来进行更新。

目标网络$Q_{w^-}(s,a)$，用于计算原损失函数$\frac{1}{2}\left[Q_w(s,a)-\left(r+\gamma\max_{a'}Q_{w^-}(s',a')\right)\right]^2$中的$\left[\left(r+\gamma\max_{a'}Q_{w^-}(s',a')\right)\right]$项，其中$w^-$表示目标网络中的参数。DQN 算法流程图如下表 2.5 所示。

表 2.5 DQN 算法

DQN 算法的具体流程图如下：
用随机的网络参数 w 初始化网络$Q_w(s,a)$ 复制相同的参数$w^- \leftarrow w$来初始化目标网络$Q_{w'}$ 初始化经验回放池 R for 序列$e=1\rightarrow E$ **do** 获取环境初始状态s_1 for 时间步$t=1\rightarrow T$ **do** 根据当前网络$Q_w(s,a)$以$\in-$贪婪策略选择动作a_t 执行动作a_t，获得回报r_t，环境状态变为s_{t+1} 将(s_t,a_t,r_t,s_{t+1})存储进回放池中 若 R 中数据足够，从 R 中采样 N 个数据$\{(s_i,a_i,r_i,s_{i+1})\}_{i=1,\cdots,N}$ 对每个数据，用目标网络计算$y_i=r_i+\gamma\max_a Q_{w^-}(s_{i+1},a)$ 最小化目标损失$L=\frac{1}{N}\sum_i\left(y_i-Q_{w^-}(s_i,a_i)\right)^2$，以此更新当前网络$Q_w$ 更新目标网络 end for end for

2.3.4 节以及 2.3.3 节中介绍的 Q-learning、DQN 都是基于价值（value-based）的方法，其中 Q-learning 是处理有限状态的算法，而 DQN 可以用来解决连续状态的问题。在强化学习

中国知网 https://www.cnki.net

中，除了基于值函数的方法，还有一支非常经典的方法，那就是基于策略（policy-based）的方法。对比两者，基于值函数的方法主要是学习值函数，然后根据值函数导出一个策略，学习过程中并不存在一个显式的策略；而基于策略的方法则是直接显式地学习一个目标策略。

基于策略的方法首先需要将策略参数化。假设目标策略是一个随机性策略，并且处处可微，其中是对应的参数。用一个线性模型或者神经网络模型来为这样一个策略函数建模，输入某个状态，然后输出一个动作的概率分布。目标是要寻找一个最优策略并最大化这个策略在环境中的期望回报。将策略学习的目标函数定义为：

$$J(\theta)=E_{s_0}\left[V^{\pi_\theta}(s_0)\right] \tag{2.17}$$

其中，s_0表示初始状态。有了目标函数，将目标函数对策略求导，得到导数后，就可以用梯度上升方法来最大化这个目标函数，从而得到最优策略。

2.3.4 Actor-Critic 算法

Actor-Critic 算法[41]通过拟合一个值函数来指导策略进行学习，用于指导策略的更新。通过引入基线函数（baseline function）来减小方差，采用 Actor-Critic 算法估计一个动作价值函数 Q，代替蒙特卡洛采样得到的回报。通过时序差分残差来指导策略梯度进行学习，用神经网络进行估计的方法可以减小方差、提高鲁棒性。Actor-Critic 分为两个部分：Actor（策略网络）和 Critic（价值网络），Actor 要做的是与环境交互，并在 Critic 价值函数的指导下用策略梯度学习一个更好的策略。Critic 要做的是通过 Actor 与环境交互收集的数据学习一个价值函数，这个价值函数会用于判断在当前状态什么动作是好的，什么动作不是好的，进而帮助 Actor 进行策略更新。

可见 Actor-Critic 算法，它是基于值函数的方法[42]和基于策略的方法的叠加。价值模块 Critic 在策略模块 Actor 采样的数据中学习分辨什么是好的动作，什么不是好的动作，进而指导 Actor 进行策略更新。随着 Actor 的训练的进行，其与环境交互所产生的数据分布也发生改变，这需要 Critic 尽快适应新的数据分布并给出好的判别。

Actor 的更新采用策略梯度的原则，Critic 价值网络更新方式如下，将 Critic 价值网络表示为V_w，对于单个数据定义如下价值函数的损失函数：

$$L(w)=\frac{1}{2}\left(r+\gamma V_w(s_{t+1})-V_w(s_t)\right)^2 \tag{2.18}$$

与 DQN 一样，采取类似目标网络的方法，价值函数的梯度为：

中国知网 https://www.cnki.net

$$\nabla_w L(w) = -(r + V_w(s_{t+1}) - V_w(s_t))\nabla_w V_w(s_t) \quad (2.19)$$

然后使用梯度下降法来更新 Critic 价值网络参数即可。Actor-Critic 算法流程图如下表 2.6 所示。

表 2.6 Actor-Critic 算法

Actor-Critic 算法的具体流程如下：
初始化策略网络参数，价值网络参数
for 序列 $e=1\to E$ **do**：
用当前策略 π_θ 采样轨迹 $\{s_1,a_1,r_1,s_2,a_2,r_2,\ldots\}$
为每一步数据计算：
$\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$
更新价值参数
$w = w + \alpha_w \sum_t \delta_t \nabla_w V_w(s_t)$
更新策略参数
$\theta = \theta + \alpha_\theta \sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t)$
end for

2.3.5 DDPG 算法

DDPG（Deep Deterministic Policy Gradient）算法[43]是一种用于连续动作空间中的深度强化学习的算法，其原理可以概括如下：

1.状态空间和动作空间：首先，定义问题的状态空间和动作空间。状态空间包括描述环境状态的所有信息，而动作空间包括机器学习代理可以执行的所有动作。

2.策略网络和值函数网络：为了实现 DDPG 算法，需要建立一个策略网络和一个值函数网络。策略网络用于输出在给定状态下的动作，而值函数网络用于估计给定状态和动作的累积回报（Q 值）。

3.经验回放缓冲区：为了解决强化学习中的样本相关性问题，DDPG 引入了经验回放缓冲区。在每个时间步，将当前的状态、动作、奖励、下一个状态等经验存储在回放缓冲区中。

4.离线训练和目标网络：DDPG 算法使用离线训练的方式进行学习。具体来说，从经验

中国知网 https://www.cnki.net

回放缓冲区中随机采样一批经验，用于更新策略和值函数网络的参数。此外，为了增加算法的稳定性，引入了目标策略网络和目标值函数网络，用于计算目标 Q 值和目标动作。

5.策略梯度和 Q 值梯度：DDPG 算法使用策略梯度和 Q 值梯度来更新策略和值函数网络的参数。通过最小化策略梯度和 Q 值梯度的损失函数，可以逐步改进策略和值函数的性能。

6.软更新和目标网络更新：为了保持学习的稳定性，DDPG 算法采用软更新的方式更新目标网络的参数。每次迭代，将一部分当前网络的参数与目标网络的参数进行混合，从而使目标网络逐渐接近当前网络。

7.循环迭代：重复执行步骤 3 至步骤 6，通过不断采样、学习和更新，逐渐改进策略和值函数的性能。同时，随着训练的进行，逐渐减小策略探索的程度，使策略网络更加收敛于确定性策略。

DDPG 算法的核心是 Actor-Critic 框架，其中 Actor 网络用于学习策略，即 Actor 要做的是与环境交互，并在 Critic 价值函数的指导下用策略梯度学习一个更好的策略；Critic 网络用于评估策略，即通过 Actor 与环境交互收集的数据学习一个价值函数，价值函数用于判断在当前状态下什么动作是好的，什么动作是不好的，进而帮助 Actor 进行策略更新。DDPG 算法流程图如下表 2.7 所示。

表 2.7 DDPG 算法

DDPG 算法的具体流程如下：

初始化策略网络参数θ和价值网络参数ω

for 序列 $e=1\to E$ **do**:

用当前策略π_θ采样轨迹$\{s_1,a_1,r_1,s_2,a_2,r_2,\ldots\}$

为每一步数据计算$\delta_t=r_t+\gamma V_\omega(s_{t+1})-V_\omega(s)$

更新价值参数$w=w+\alpha_\omega\sum_t\delta_t\nabla_\omega V_\omega(s)$

更新策略参数$\theta=\theta+\alpha_\theta\sum_t\delta_t\nabla_\theta\log\pi_\theta(a\mid s)$

end for

Actor-Critic 与传统的策略梯度方法不同，DDPG 算法使用 Q 值函数作为 Critic 网络的输出，而不是状态值函数，这样可以更好地处理连续动作空间。

下面是 DDPG 算法的主要步骤：

定义 Actor 网络和 Critic 网络，并初始化它们的权重；

定义目标 Actor 网络和目标 Critic 网络，并将它们的权重初始化为与原始网络相同；

定义经验回放缓冲区，并初始化缓冲区；

中国知网 https://www.cnki.net

进入训练循环，每次循环的步骤如下：

a. 根据当前策略和探索噪声选择一个动作，并执行该动作；

b. 观察环境反馈，包括状态、奖励和下一个状态，并将这些信息存储到经验回放缓冲区中；

c. 从经验回放缓冲区中随机采样一批数据，用于训练 Actor 网络和 Critic 网络；

d. 更新 Critic 网络，以最小化当前状态下的 Q 值函数和目标 Q 值函数之间的差异；

e. 更新 Actor 网络，以最大化 Critic 网络对当前状态下的动作的估计值；

f. 更新目标 Actor 网络和目标 Critic 网络的权重；

当训练完成后，使用 Actor 网络进行策略评估和策略执行。

需要注意的是，DDPG 算法中的目标网络是通过软更新（soft update）来更新的，即每次更新目标网络的权重时，将目标网络的权重与原始网络的权重进行加权平均，从而使得目标网络的更新更加平稳。此外，DDPG 算法还使用了一定的探索策略，如添加高斯噪声，以增加算法的收敛性和稳定性。

DDPG 算法的特点[44]主要有以下几点：

1.可以处理连续动作空间的问题。相比于传统的离散动作空间，连续动作空间的搜索空间更加广阔，因此难以使用传统的强化学习算法求解。DDPG 算法通过使用 Actor-Critic 框架，结合 Q 值函数的估计，可以有效地解决这个问题。

2.具有高效的收敛性和稳定性。DDPG 算法通过使用经验回放缓冲区、目标网络以及探索策略等技术，可以提高算法的稳定性和收敛性，使得算法更加容易收敛到最优策略。

3.可以应用于在线学习和离线学习。DDPG 算法可以在实时学习中进行更新，也可以使用离线数据进行批量学习，从而可以更好地适应不同的应用场景。

在机械臂控制中，DDPG 算法的应用非常广泛。机械臂控制通常需要控制连续动作空间，因此 DDPG 算法可以很好地解决这个问题。

2.4 机械臂轨迹规划多目标优化

2.4.1 帕累托多目标优化

帕累托多目标优化（Pareto Multi-Objective Optimization）是一种多目标优化方法，用于解决具有多个冲突目标的问题。它的目标是找到一组解，这些解在多个目标之间没有明显的改进余地，即无法进一步改善某一目标而不损害其他目标。在帕累托多目标优化[45]中，解决方

中国知网 https://www.cnki.net

案被称为帕累托前沿（Pareto Front）或非支配解集（Non-dominated Solution Set）。帕累托前沿是指在所有可能的解空间中，无法找到其他解能够在所有目标上都优于它的解。非支配解集是指帕累托前沿中的解集合。文献[15]提出了一种基于 NSGA-II算法的机械臂多目标轨迹优化方法。

根据帕累托原理，对于多目标优化[46]问题，存在一组解，它们在一个或多个目标上优于其他解，而在其他目标上不如其他解。这些解构成了帕累托前沿。帕累托多目标优化算法的基本原理是通过在解空间中搜索并维护一组非支配解集，逐步逼近帕累托前沿。它通过评估和比较不同解的目标函数值来确定非支配性，并使用一些策略来保持解集的多样性和覆盖性。

NSGA-II（Non-dominated Sorting Genetic Algorithm II）是一种常用的帕累托多目标优化算法。NSGA-II 算法的流程图如下图 2.8 所示。

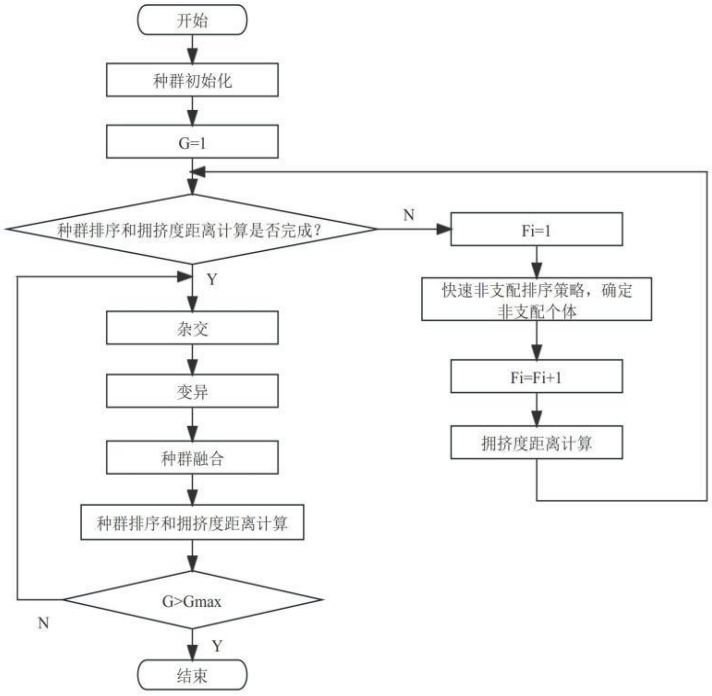


图 2.8 NSGA-II 算法流程图[15]

下面是 NSGA-II 算法的详细步骤：

步骤 1：初始化种群：随机生成一组初始解作为种群，每个解包含问题的决策变量和相应的目标函数值。

步骤 2：计算非支配排序：对种群中的解进行非支配排序，根据解之间的支配关系将解划分为不同的等级。一个解被称为支配另一个解，如果它在所有目标上都优于后者。

步骤 3：计算拥挤度距离：对于每个等级的解，计算每个解的拥挤度距离。拥挤度距离用于衡量解在帕累托前沿中的密度，较大的拥挤度距离表示解在帕累托前沿上的位置更稀疏。

中国知网 https://www.cnki.net

步骤 4：选择操作：根据非支配排序和拥挤度距离，选择下一代种群。通常，选择较高等级的解，并倾向于选择拥挤度距离较大的解，以保持种群的多样性和覆盖性。

步骤 5：交叉操作：对选择的解进行交叉操作，生成新的个体。交叉操作可以通过某种方式在两个解之间进行信息交换，以产生具有多样性的后代个体。

步骤 6：变异操作：对交叉得到的个体进行变异操作，引入一定的随机扰动。变异操作有助于保持种群的多样性，并有可能发现新的非支配解。

步骤 7：更新种群：将选择、交叉和变异得到的个体与原始种群合并，形成下一代种群。

步骤 8：重复步骤 2 至步骤 7：重复执行上述步骤，直到达到指定的停止条件（如迭代次数、收敛条件等）。

最终，NSGA-II 算法将生成一组近似的帕累托前沿解集，这些解在多个目标上都具有一定的优势，形成了问题的最优解选择，

多目标优化问题的解被称为 Pareto 最优解。Pareto 最优解是指无法通过改进一个目标而不损害其他目标的解。因此，多目标轨迹优化的目标是找到一组 Pareto 最优解，形成一个称为 Pareto 前沿（或 Pareto 最优集）的解集。

为了找到 Pareto 前沿，常用的方法是多目标优化算法，例如遗传算法、粒子群算法、多目标优化的进化算法等。这些算法通过在搜索过程中维护一组非支配解来逼近 Pareto 前沿。

综上所述，多目标轨迹优化的数学描述涉及目标函数的定义和约束条件的制定，目标是找到一组 Pareto 最优解，以实现在多个优化目标之间的平衡和权衡。多目标优化算法可应用于求解这类问题，并生成 Pareto 前沿的解集。

因此，本文在传统多目标优化方法的基础上，通过强化学习与帕累托多目标优化相结合的思想，在提高机械臂自主学习能力的同时，改进时间、能耗、冲击等性能指标，提升经验学习效率。

2.5 本章小结

本章介绍了机械臂轨迹规划问题相关的机械臂相关理论、部分主流强化学习算法和多目标优化的现状和未来发展情况，并详细介绍了各种算法的内部原理特性以及迭代流程。首先，我们讨论了机械臂的运动模型，包括正向运动学和逆向运动学。正向运动学通过关节角度计算末端执行器的位置和姿态，逆向运动学则通过末端执行器的期望位置和姿态反向计算关节角度。了解机械臂的运动模型对于控制算法的设计和分析至关重要。

接下来，我们引入了强化学习理论，该理论提供了一种基于智能体与环境交互学习的框

中国知网 https://www.cnki.net

架。我们介绍了强化学习的核心概念，马尔可夫决策过程，包括状态、动作、奖励和价值函数。我们还介绍了基于值函数的方法，如 Q-learning 和深度强化学习，以及基于策略的方法，如策略梯度算法。这些方法可以用于机械臂轨迹规划中，使机械臂能够通过试错和优化来学习执行特定任务。

最后，我们讨论了多目标优化的概念和方法。在机械臂控制中，通常存在多个冲突的优化目标，如时间、冲击和能耗等。我们介绍了多目标优化的常用算法，如遗传算法和粒子群优化算法。这些方法可以帮助我们在平衡多个目标之间进行权衡和决策，从而实现机械臂控制的多目标优化[42]。

综上所述，本章深入探讨了机械臂运动模型、强化学习理论和多目标优化，并讨论了它们在机械臂控制中的应用。通过深入理解和应用这些概念和方法，我们可以为机械臂控制提供更加智能和高效的解决方案，推动机械臂在各个领域的应用和发展。

中国知网 https://www.cnki.net

第三章 基于最大熵近端策略最优的机械臂多目标轨迹规划方法

3.1 引言

强化学习在机械臂控制中的应用[47]非常广泛，它可以帮助机械臂学习如何执行各种复杂任务，例如抓取物体、移动物体、装配等等[48]。强化学习可以让机械臂根据环境的反馈进行学习，逐步优化策略，从而实现高效的任务执行。

传统的机械臂多目标轨迹方法虽取得了一些成就，实现了一定意义上的多目标最优，但传统的机械臂多目标轨迹规划存在一些缺点。传统的机械臂多目标轨迹规划通常是在离线环境下进行的，也就是说，规划是在机械臂执行任务之前完成的。这意味着规划无法适应实时变化的环境和任务需求。如果环境或任务发生变化，机械臂可能无法正确执行规划好的轨迹。与此同时，传统的机械臂多目标轨迹规划通常只考虑了事先定义的目标和约束条件。它们往往缺乏对实际环境和任务的感知和适应能力。例如在复杂环境的情况下，传统规划方法可能无法有效地处理，并且无法根据实时变化的情况进行调整。

综上所述，传统的机械臂多目标轨迹规划方法[12][13]存在离线规划、缺乏适应性等缺点。为了克服这些问题，本章提出了基于最大熵近端最优的机械臂多目标轨迹规划方法，保证实现多目标最优的同时，提升机械臂的自主学习能力以及泛化能力。

最大熵近端策略（Maximum Entropy Proximal Policy Optimization）是一种优化算法，结合了最大熵策略和近端策略优化的思想。它在强化学习中用于学习最优策略。最大熵策略是一种基于最大熵原理[44]的策略选择方法。最大熵原理认为，在缺乏先验知识的情况下，应该选择一个最均匀的策略，即使在面临不确定性的环境中也能有更好的鲁棒性。在强化学习中，最大熵策略通过最大化策略的熵来平衡探索和利用，使得策略更加稳定和灵活。

近端策略优化是一种基于梯度的策略优化方法[49]，它通过在每次更新策略时限制策略的变化范围，以确保策略的更新不会过大，从而保证策略的收敛性和稳定性。这种方法可以有效地控制策略的更新幅度，避免策略更新过大导致性能的不稳定性。

最大熵近端策略最优思想将最大熵策略和近端策略优化结合起来。它通过最大化策略的熵来增加策略的探索性，同时使用近端策略优化来限制策略的变化范围，保证策略的稳定性和收敛性。这种方法可以在保持策略的多样性的同时，有效地优化策略，使得策略能够更好地适应环境的变化。最大熵近端策略最优思想在强化学习任务中有着广泛的应用，特别是在需要平衡探索和利用的任务中。它能够在保持策略的多样性和稳定性的同时，有效地进行策

中国知网 https://www.cnki.net

略优化，提高学习性能和适应性。

本章提出的基于最大熵近端策略最优的机械臂多目标轨迹规划方法，以深度强化学习算法的结构为基础，对本研究针对的机械臂轨迹规划问题进行了系统性的优化，理论上具有更高的稳定性与收敛性。本章节的前半部分将对所提出的方法进行介绍与解析，后半部分将通过对比实验与交叉验证，来考查该方法的可行性与有效性。

3.2 问题描述

多目标轨迹优化是指在机械臂运动规划中考虑多个优化目标的问题。数学上，可以使用多目标优化问题的形式来描述多目标轨迹优化。

假设有一个机械臂运动轨迹的多目标优化问题，可以定义如下：

目标函数：设定多个目标函数来描述问题中的不同优化目标，例如最小化时间、最小化能量消耗、冲击最优等。用 $f(x)$ 表示目标函数的向量形式，其中 x 表示轨迹参数（例如关节角度序列或笛卡尔轨迹参数）。

约束条件：机械臂运动规划通常受到一些约束条件的限制，如关节限位、末端执行器的工作空间限制、碰撞避免等。可以用 $g(x)\le 0$ 表示约束条件的向量形式，其中 $g(x)$ 表示约束函数。

多目标轨迹优化问题可以定义为如下形式的数学优化问题：

最小化公式（3.1）

$$S(x)=[S_1(x),S_2(x),\ldots,S_m(x)]^T \tag{3.1}$$

满足约束条件 $g(x)\le 0$ 其中，m 是目标函数的数量。

机械臂工作空间为基座关节空间周围 850mm 范围内的区域。

参照文献[15]，以机械臂运动时间最短、轨迹最平滑、能耗最小，定义如下的优化目标：

$$S_1=T=\sum_{i=0}^{n-1}\Delta t_i=\sum_{i=0}^{n-1}(t_{i+1}-t_i) \tag{3.2}$$

$$S_2=\sum_{n=1}^{N}\sqrt{\frac{1}{T}\int_0^T a_i^2\,dt} \tag{3.3}$$

$$S_3=\sum_{n=1}^{N}\sqrt{\frac{1}{T}\int_0^T j_i^2\,dt} \tag{3.4}$$

中国知网　https://www.cnki.net

式中：T 为机械臂沿一定的轨迹运动的总时间；t_{i+1}，t_i 分别为第 i 段运动轨迹的时长、运动起始时间、运动结束时间；a_i、j_i 分别为第 i 个关节的运动加速度、加加速度；S_1 为运动时间，用来衡量机械臂运动效率。S_2 为关节平均加速度，用来衡量机械臂能量消耗；S_3 为关节平均加加速度，用来衡量机械臂运动轨迹的平滑度。

构造机械臂运动轨迹时，需要考虑速度、加速度和加加速度等约束，因此机械臂的运动受到以下约束：

关节位移 $|q(t)| \le q_{\max}$；关节速度 $|v(t)| \le v_{\max}$；关节加速度 $|a(t)| \le a_{\max}$；关节加加速度：$|j(t)| \le j_{\max}$。

3.3 最大熵近端策略最优算法

针对传统的机械臂多目标轨迹规划方法存在离线规划、缺乏适应性等缺点。为了克服这些问题，本节提出了基于最大熵近端最优的机械臂多目标轨迹规划方法，保证实现多目标最优的同时，提升机械臂的自主学习能力以及泛化能力。

以工业机器人轨迹的时间最少、动能最优、冲击力最小为优化目标，满足位置、速度、加速度约束，设定奖励函数为如下式（3.5）所示。

$$\begin{aligned} R_{time} &= -\alpha d^2 - \beta\sqrt{d} - \max_i t_i \\ R_{energy} &= -\alpha d^2 - \beta\sqrt{d} - \dot{q}^T M(q)\dot{q} \\ R_{impact} &= -\alpha d^2 - \beta\sqrt{d} - \frac{1}{N}\sum_{i=1}^{N}\left\|\ddot{q}_i(k)\right\| \end{aligned} \tag{3.5}$$

其中 R_{time}、R_{energy}、R_{impact} 分别表示时间最少、动能最小、冲击最小等三个优化目标的奖励函数，$\max_i t_i$、$\dot{q}^T M(q)\dot{q}$、$\frac{1}{N}\sum_{i=1}^{N}\left\|\ddot{q}_i(k)\right\|$ 分别表示时间最少、动能最小、冲击最小这三个优化目标，d 表示工业机器人末端位置与目标位置之间的距离，常数 $\alpha > 0$、常数 $\beta > 0$，调节算法的收敛速度，以防算法陷入局部最优，i 表示第 i 个关节，t_i 表示第 i 个关节运行的时间，$q \in R^n$、$\dot{q} \in R^n$、$\ddot{q} \in R^n$ 分别表示自由度为 n 的机器人的广义关节角位置、广义关节角速度、广义关节角加加速度，$M(q) \in R^{n\times n}$ 表示机器人的惯性矩阵，N 表示机器人运行时间。

为了实现多目标优化，在每个优化目标下，本节构建并行运作的动作网络和评判网络，

中国知网　https://www.cnki.net

并根据评判网络输出的优势函数对动作网络的策略进行非支配排序，从而获得帕累托前沿集。

最大熵近端最优算法流程如下图 3.1 所示。

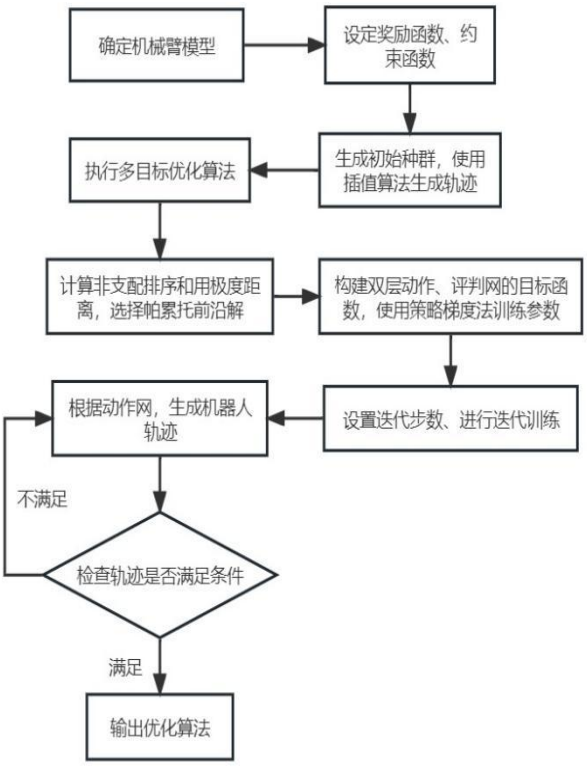


图 3.1　最大熵近端最优算法流程图

最后根据最大熵近端策略优化算法确定每个优化目标对应的动作现实网络和评判现实网络的目标函数，从所获得的帕累托前沿集中，随机选择若干组状态-动作对，使用最大熵搜索法来训练每个目标动作网络的参数和梯度下降法训练每个目标评判网络的参数。每个目标动作现实网络的目标函数如下式（3.6）所示。

$$J_{\lambda_i} = E\left[\min\left(\varphi_i R_i, clip\left(\varphi_i, 1-\varsigma_i, 1+\varsigma_i\right)R_i\right) - \rho\log\pi_i(s_i,a_i) + V(s_i)\right] \tag{3.6}$$

其中，$\varphi_i = \dfrac{\pi_{new}(a_i \mid s_i)}{\pi_{old}(a_i \mid s_i)}$，$clip(\cdot)$ 是常用的剪裁函数，$\varsigma_i > 0$ 是一个适当的常数，$\rho > 0$

按照最大熵搜索算法来更新每个优化目标的动作网中的现实网络权值更新，具体如下式（3.7）所示。

$$f_{action}(\lambda_i) = \begin{cases} \dfrac{\log(\mu+0.5) - \log j}{\sum_{k=1}^{\mu}\left(\log(k+0.5) - \log k\right)} & 0 < j \le \mu \\ 0 & j > \mu \end{cases} \tag{3.7}$$

其中，j 表示当前时刻的值函数在前 μ 次迭代过程中 V 函数从大到小的排序。

每个优化目标的评判网络的优化目标如下式（3.8）所示。

中国知网　https://www.cnki.net

$$J_{critic}(\vartheta_i)=\frac{1}{n}\sum_{k=0}^{n}\left(V_i(s(k))+r_i(k)-\delta_i V_i(s(k+1))\right) \tag{3.8}$$

具体实现步骤如下：

步骤 1：确定机械臂的几何结构和运动学模型，以及位置、速度和加速度的约束条件。根据机械臂类型，确定机械臂的几何结构和运动学模型。在确定位置、速度和加速度的约束条件时，考虑机械臂的物理特性和安全性要求。

步骤 2：定义目标函数和约束函数。对于时间最少、能耗最低和冲击力最小这三个优化目标，需要定义相应的目标函数。此外，还需要定义位置、速度和加速度的约束函数，确保生成的轨迹满足约束条件。

步骤 3：生成初始种群。根据问题的约束条件，使用随机方法生成一组初始解（机器人轨迹）。确保这些解满足位置、速度和加速度约束。可以考虑使用合适的采样方法和运动插值算法来生成平滑的轨迹。

步骤 4：执行多目标优化算法。在 MATLAB 中，使用多目标优化算法对初始种群进行迭代优化，以获得帕累托前沿集。在每次迭代中，算法将使用定义的目标函数和约束函数对种群进行评估，并根据优化算法的策略更新种群中的个体。

步骤 5：进行非支配排序和拥挤度距离计算。根据优势函数的计算结果，对帕累托前沿集进行非支配排序。非支配排序将解分为不同的等级，使得解的优劣关系更明确。

步骤 6：选择帕累托前沿解。根据需求，选择适当数量的帕累托前沿解作为可行解。根据解的非支配等级和拥挤度距离进行选择，以获取一组具有多样性和均衡性的解。

步骤 7：构建双层动作网和双层评判网的目标函数。在双层动作网和双层评判网中，使用策略梯度法来训练参数。首先，需要定义动作网和评判网的网络结构和目标函数。

双层动作网：该网络的目标是生成机械臂的轨迹动作。可以使用深度神经网络作为动作网的结构。输入为机械臂的当前状态，输出为机械臂的下一步动作。目标函数选择使用最大熵近端优化策略来优化。

双层评判网：该网络的目标是评估生成轨迹的质量。使用一个深度神经网络作为评判网的结构。输入为机械臂的轨迹，输出为轨迹的质量评分，如时间、能耗和冲击力。目标函数选择与动作网一致的最大熵近端优化策略。

步骤 8：设置参数和超参数。在训练过程中，需要设置一些参数和超参数，如学习率、批量大小、训练迭代次数等。这些参数的选择会对实验结果产生影响，可以根据具体情况进行调整。

步骤 9：进行策略梯度法训练。使用 MATLAB 中提供的策略梯度法算法，基于双层动作

中国知网　https://www.cnki.net

网和双层评判网的目标函数，对参数进行训练。在训练过程中，通过与评判网进行交互，更新动作网的参数以最大化帕累托前沿集中的轨迹质量。

步骤 10：设置迭代步数并进行迭代训练。根据实验需求，设置训练的迭代步数作为终止条件。在每次迭代中，根据选择的帕累托前沿解生成轨迹，并使用策略梯度法进行参数更新。随着训练的进行，动作网和评判网的性能会逐渐提升。

步骤 11：使用训练得到的动作网，根据初始状态和目标状态生成机器人的轨迹。这可以通过输入初始状态到动作网中，并使用生成的动作来推断机器人的下一步状态，然后迭代生成完整的轨迹。

步骤 12：检查生成的轨迹是否满足位置、速度和加速度的约束条件。如果轨迹不符合约束条件，可以尝试调整优化参数、修改网络结构或增加训练迭代次数，以进一步优化结果。

重复步骤 11 和步骤 12，直到获得满足多重约束优化多个目标的工业机器人轨迹。

综上所述，本节所提出的最大熵近端最优算法的创新点主要有以下几点。传统的多目标规划算法通常采用权衡法或者加权求和的方式来处理多个目标。而本文同时利用了最大熵原理和近端最优算法的优点，将最大熵原理引入机械臂多目标轨迹规划中，可以使得规划算法更加灵活和适应性强。采用近端最优算法、结合强化学习提高了鲁棒性和自适应性。

如下表 3.1 所示，为最大熵近端最优算法伪代码。

表 3.1　最大熵近端最优算法伪代码

最大熵近端最优算法伪代码
1：初始化 Critic 部分的现实神经网络 Q 和 Actor 部分的现实神经网络 μ，参数分别是 λ^{Q} 和 λ^{μ}
2：初始化 Critic 部分和 Actor 部分的目标神经网络 Q' 和 μ'，参数 $\lambda^{Q'}=\lambda^{Q}$，$\lambda^{\mu'}=\lambda^{\mu}$
3：for 回合=1: M do
4：　　while　状态 s 非终止状态 s
6：　　输入状态 s 给 Actor 部分的现实神经网络 μ
7：　　智能体执行动作与环境交互执行动作 a，并且受到即使奖励 r ,环境转移到状态 s'
8：　　将采样经验 (s,a,s',r) 存入经验池中
9：　　对经验池中的数据进行非支配排序和拥挤度距离计算，选择帕累托前沿解集
10：　　if 帕累托前沿集的数据量大于一个训练小组的大小
11：　　从前沿集中采样一个训练小组 (s,a,s',r)
12：　　对每个元组，用目标网络计算，每个目标动作现实网络的目标函数为：

中国知网　https://www.cnki.net

$$J_{\lambda_i} = E\left[\min\left(\varphi_i R_i, clip\left(\varphi_i, 1-\varsigma_i, 1+\varsigma_i\right)R_i\right) - \rho\log\pi_i(s_i,a_i) + V(s_i)\right]$$

13：　　使用梯度法更新 Critic 部分的现实网络，loss 函数为：

$$Loss = \frac{1}{n}\sum\left\{\left[r+\gamma V(s')\right]-V(s)\right\}^2$$

14：　　更新 Actor 模型部分和 Critic 模型部分的现实网络参数到目标网络中

$$\lambda^{Q'} \leftarrow \alpha\lambda^{Q'} + (1-\alpha)\lambda^{Q'}$$

15：　　end if

16：　　end while

17：end for

3.4 实验结果分析

实验设备：一台笔记本电脑、仿真软件 CoppeliaSim Edu、MATLAB。

CoppeliaSim Edu 介绍：CoppeliaSim Edu 是由 Coppelia Robotics 开发的一款强大的 3D 机器人仿真软件。它是 V-REP（Virtual Robot Experimentation Platform）的升级版本[58]。CoppeliaSim Edu 允许用户在虚拟环境中模拟和与各种机器人和机器人系统进行交互。CoppeliaSim Edu 提供了一个全面的仿真平台，用户可以在其中设计、构建和测试机器人系统。它支持各种机器人类型，包括移动机器人、工业机械臂、无人机等，并提供了丰富的传感器和执行器模型。使用 CoppeliaSim Edu，用户可以通过简单而直观的界面创建机器人模型，并定义它们的行为和控制算法。用户可以模拟不同的环境条件，如室内、室外、复杂地形等，并对机器人的运动、感知和决策进行测试和优化。

CoppeliaSim Edu 还提供了强大的物理引擎，可以模拟真实世界中的物理效应，如碰撞、摩擦和重力等。这使得用户能够评估机器人系统的性能和稳定性，并进行虚拟实验和测试，从而节省时间和成本。此外，CoppeliaSim Edu 还支持多种编程语言，如 Python、C++和 Lua，使用户能够自定义机器人的控制和行为，并与其他软件和硬件进行集成。

总之，CoppeliaSim Edu 是一款功能强大的机器人仿真软件，为用户提供了一个实验、学习和开发机器人系统的理想平台。无论是教育、研究还是工业应用，CoppeliaSim Edu（以下简称 V-REP）都可以帮助用户更好地理解和应用机器人技术。

本节将使用 UR5 机械臂进行仿真实验，实验一为轨迹规划，分别使用最大熵近端最优算法以及 MODDPG 算法对其进行规划，记录每次规划任务的完成时间。实验二为模拟 UR5 机械臂传送带码垛任务，同样分别采用最大熵近端最优算法以及 MODDPG 算法对其进行控制，

中国知网　https://www.cnki.net

记录每次任务完成时间。

使用 MATLAB 来实现控制并且与 V-REP 软件通信实现联合仿真的过程如下图所示。

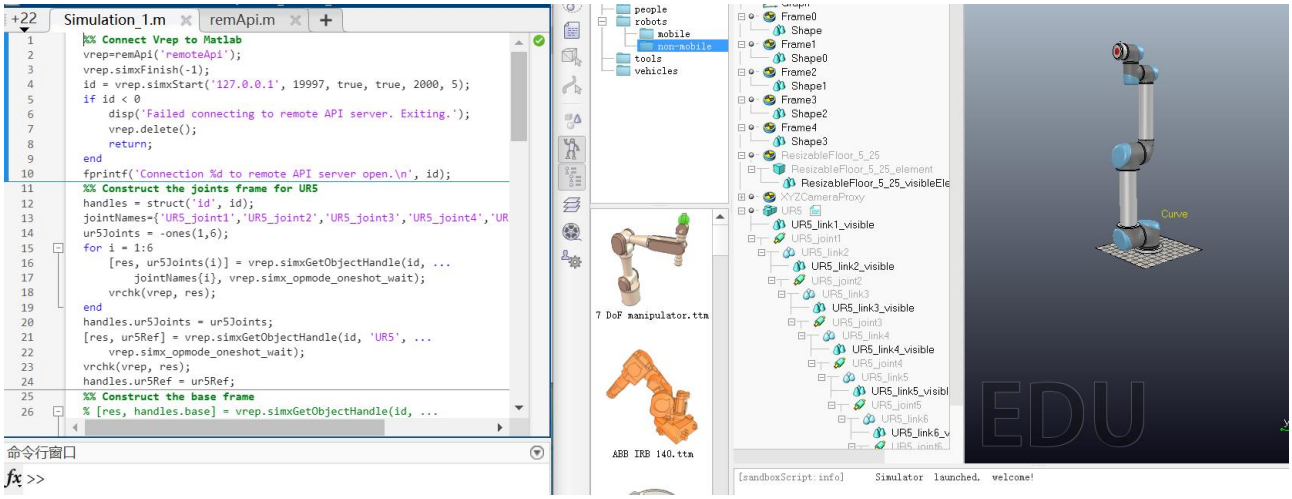


图 3.2　仿真联调界面

UR5 机械臂 DH 参数如下表 3.2 所示。

表 3.2　UR5 机械臂 DH 参数表

序号 i	θ_i / rad	d_i / mm	a_i / mm	α_i / rad
1	θ_1	89.2	0	$\pi/2$
2	θ_2	0	-425	0
3	θ_3	0	-392	0
4	θ_5	109.3	0	$\pi/2$
5	θ_5	94.75	0	$-\pi/2$
6	θ_6	82.5	0	0

在 matlab 和 CoppeliaSim Edu 进行轨迹联合轨迹跟踪仿真轨迹规划实验，可以实现在 matlab 中通过算法控制 VERP 中 UR5 机械臂的运行轨迹，效果图如下：

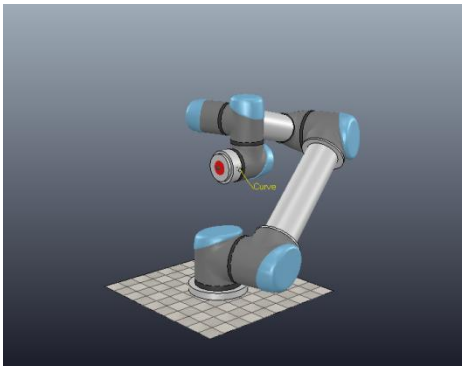


图 3.3　VREP 中 UR5 运行轨迹图

中国知网　https://www.cnki.net

最大熵近端最优算法参数设置：

1.学习率（Learning Rate）：学习率决定了每次更新模型参数时的步长大小。较小的学习率可以使更新更稳定，但可能收敛较慢；较大的学习率可能导致不稳定的更新和不收敛的情况。在 MEPPO 中，通常使用适当的学习率来平衡稳定性和训练速度。

2.迭代次数（Number of Iterations）：迭代次数决定了算法在训练过程中执行的更新步骤的数量。较多的迭代次数可以提供更多的训练机会，但也会增加训练时间。需要根据具体问题和计算资源进行调整。

3.折扣因子（Discount Factor）：折扣因子是用于计算奖励的折现因子，用于平衡当前奖励和未来奖励的重要性。折扣因子在决定模型训练过程中每个时间步的奖励计算中起作用。

4.值函数权衡参数（Value Function Coefficient）：MEPPO 算法中的值函数是一个用于估计状态值的函数，它可以用于辅助策略的优化。值函数权衡参数用于调整值函数在训练中对策略的影响程度。较大的值函数权衡参数可以更注重值函数的估计，而较小的权衡参数可以更注重策略的优化。

表 3.3　最大熵近端最优算法参数表

	学习率	迭代次数（次）	折扣因子	值函数权衡参数
参数大小	0.001	4000	0.96	0.7

最大熵近端最优算法如表 3.3 所示。

如图 3.4 所示，为求解帕累托前沿集的结果。

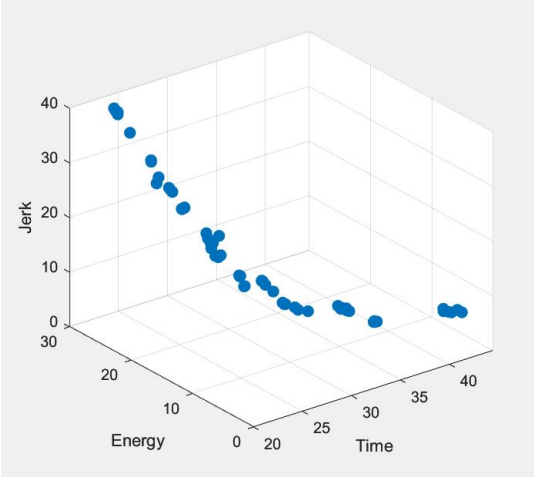


图 3.4 帕累托最优前沿

在强化学习中，训练时的平均奖励值可以反映算法的收敛性：平均奖励值可以用来判断

中国知网　https://www.cnki.net

训练过程是否正在逐渐收敛到一个较高的水平。如果平均奖励值在训练过程中逐渐增加并稳定在一个较高的值，那么可以说智能体的策略正在不断改进并收敛到一个较优的状态。从图 3.5 可知，当训练次数达到 3200 次时，算法逐渐达到收敛，输出带有参数的算法并进行仿真实验。

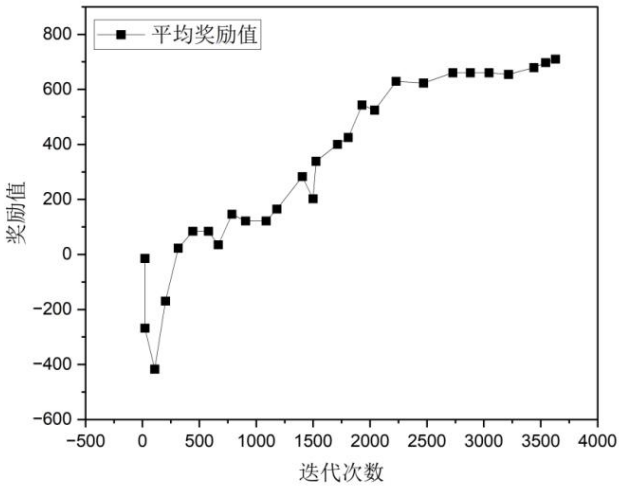


图 3.5　最大熵近端最优算法平均奖励值

在 matlab 中通过控制算法对 UR5 机械臂的运行轨迹进行仿真实验。在空间中指定点的位置，传统方法使用 PD 控制，记录每次任务完成时间，如下表 3.4 所示。

表 3.4　时间记录表

	传统方法	最大熵近端优化算法
平均用时	7.2s	4.5s
最快用时	6.7s	3.6s

通过对比图 3.6 可知，本章提出的算法平均效率相较于传统方法提升了约 37.5%，证明了最大熵近端最优算法的优越性。在实现机械臂多目标轨迹任务的同时，提升了任务的效率，减少了能耗。

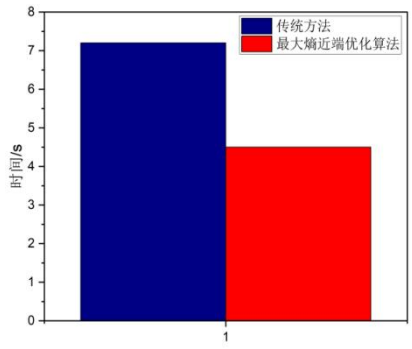


图 3.6　时间对比图

中国知网　https://www.cnki.net

由此可见，最大熵近端最优算法在最大熵建模的基础上，结合了近端最优化的思想，能够更好地处理约束信息，并具有收敛性保证。这使得它在解决实际问题时具有优越性，尤其是在涉及多种约束形式和复杂约束条件的情况下。

综上所述，机械臂轨迹规划是一个复杂的控制问题，需要考虑到多个因素，如避障、动力学约束、轨迹平滑性等。通过以上的仿真实验对比分析，最大熵近端优化算法应用于机械臂轨迹规划的优劣主要有以下几点。

优势：

1.模型无关性：最大熵近端最优算法不需要对系统动力学或环境建模，只需通过专家演示进行学习。这使得算法更具通用性，并能够适应多样的机械臂系统和环境。

2.最大熵原则：最大熵近端最优算法算法通过最大熵原则，在保持与专家演示一致的同时，尽可能考虑到多种可能的轨迹规划策略。这使得生成的规划结果更加多样化，更能适应各种复杂的环境和任务需求。

3.适应性强：最大熵近端最优算法能够从演示中学习到复杂的轨迹规划策略，因此适用于多种机械臂应用场景，包括复杂的操作任务和不确定环境。

劣势：

1.数据需求：最大熵近端最优算法需要大量的专家演示数据来学习奖励函数。如果获取高质量的专家演示数据比较困难或代价较高，算法的性能可能会受到限制。

2.计算复杂度：最大熵近端最优算法通常需要进行迭代优化，这会涉及大规模的优化问题。因此，算法的计算复杂度较高，可能需要较长的训练时间和计算资源。

3.5 本章小结

本章针对仿真机械臂的多目标轨迹规划，从环境建模出发，构建一个可用于相关实验的仿真环境。并分析了传统方法应用于机械臂轨迹规划问题上存在的缺陷，提出了一种基于最大熵近端最优的机械臂多目标轨迹规划方法。

本章提出的基于最大熵近端策略最优的机械臂多目标轨迹规划方法，以深度强化学习算法的结构为基础，对本研究针对的机械臂轨迹规划问题进行了系统性的优化，理论上具有更高的稳定性与收敛性。本章首先以时间最少、能耗最低、冲击力最小等三个目标为优化目标，并且满足位置、速度、加速度的约束，计算每个策略下三个优化目标的优势函数，并对所得到的优势函数进行非支配排序，从而获得帕累托前沿集；其次从所获得的帕累托前沿集中随机选择动作，以最大熵近端优化策略构造双层动作网与双层评判网的目标函数，采用策略梯

中国知网　https://www.cnki.net

度法训练所述动作网与评判网的参数，设置迭代步数为终止条件，最后获得满足多重约束优化多个目标的工业机器人轨迹。

最后在仿真实验中验证了优化方法的有效性，算法平均效率相较于传统方法提升了约37.5%，证明了使用该优化方法比传统的多目标规划方法有更强的稳定性与收敛性。

中国知网　https://www.cnki.net

第四章　基于改进 DDPG 算法的机械臂多目标轨迹规划方法

4.1 引言

第三章提出了基于最大熵近端最优的机械臂多目标轨迹方法，其虽然在轨迹规划上性能指标超越了传统方法，但在实验过程中发现其存在一些问题，例如最大熵近端最优算法需要计算每个状态的分布熵，并在每个时间步骤进行优化。这导致了算法的计算复杂度较高，尤其是在具有大型状态空间和动作空间的问题中，需要大量的计算资源。算法在高维空间中容易陷入维度灾难，导致搜索空间过大而无法找到最优策略。由于算法的非凸性和计算复杂度，需要大量的迭代才能达到收敛。这导致算法在实际问题中的使用受到时间和计算资源的限制。

因此，寻找一种适合连续动作空间、收敛快的强化学习算法[50][51]是一个可行的改进之处。DDPG 算法适用于连续动作空间的问题。通过使用确定性的行为策略，DDPG 算法可以直接输出连续动作值，而不需要进行采样和离散化操作[52]。这使得 DDPG 算法[53]在探索和优化连续动作空间中更具优势。例如，文献[54]提出了一种基于 DDPG-PID 的机器人动态目标跟踪与避障控制研究方法。

然而，原始的 DDPG 算法在探索策略上使用确定性的行为策略，容易陷入局部最优解。改进的 DDPG 算法引入了一些探索策略，如添加噪声或使用随机策略，从而能够更好地探索环境，提高算法的收敛性和性能。

例如，改进的 DDPG 算法引入了经验回放机制，将智能体与环境的交互过程存储在经验回放缓冲区中，并从中随机采样进行训练。这样可以打破数据样本的相关性，提高样本利用效率，同时减少训练过程中的方差，增加算法的稳定性。另外，为了提高神经网络的训练效果和泛化性能，改进的 DDPG 算法可以结合批量归一化（Batch Normalization）技术[55]。批量归一化可以对网络的输入进行归一化处理，减少网络训练过程中的内部协变量偏移，提高训练的收敛速度和稳定性。文献[27]提出了一种基于批量归一化的改进 DDPG 算法，实现了样本数据效率的提高，但没涉及帕累托多目标优化算法对于经验池的设计。

综上所述，本文在第三章研究内容的基础上，针对第三章方法中存在的算法收敛慢、计算度复杂等问题，通过引入改进的 DDPG 算法，对其进行数据标准化[55]、经验池优先级设计[56]在提高算法的稳定性与收敛性同时，提升经验数据的利用率以及算法训练速度。改进部分主要围绕奖励函数设计以及经验池优先级设计部分进行。

中国知网 https://www.cnki.net

4.2 问题描述

机械臂工作空间表示为 $D \in R^3$，工作空间指机械臂末端执行器能够被操作到达或者执行相应任务工作的区域，为机械臂基座关节周围 850mm 的范围内。本章采用的机械臂为 UR5，其各关节的角度范围限制如下表 4.1 所示。参照文献[15]，以机械臂运动时间最短、轨迹最平滑、能耗最小，定义如下的优化目标：

$$S_1 = T = \sum_{i=0}^{n-1} \Delta t_i = \sum_{i=0}^{n-1} \left(t_{i+1} - t_i \right) \tag{4.1}$$

$$S_2 = \sum_{n=1}^{N} \sqrt{\frac{1}{T} \int_0^T a_i^2 dt} \tag{4.2}$$

$$S_3 = \sum_{n=1}^{N} \sqrt{\frac{1}{T} \int_0^T j_i^2 dt} \tag{4.3}$$

式中：T 为机械臂沿一定的轨迹运动的总时间；t_{i+1}，t_i 分别为第 i 段运动轨迹的时长、运动起始时间、运动结束时间；a_i、j_i 分别为第 i 个关节的运动加速度、加加速度；S_1 为运动时间，用来衡量机械臂运动效率。S_2 为关节平均加速度，用来衡量机械臂能量消耗；S_3 为关节平均加加速度，用来衡量机械臂运动轨迹的平滑度。

构造机械臂运动轨迹时，需要考虑速度、加速度和加加速度等约束，因此机械臂的运动受到以下约束：

关节位移 $|q(t)| \le q_{\max}$；关节速度 $|v(t)| \le v_{\max}$；关节加速度 $|a(t)| \le a_{\max}$；关节加加速度：$|j(t)| \le j_{\max}$。

4.3 基于多目标优化的改进 DDPG 算法

针对问题性质特征，第三章通过引入帕累托多目标优化，提升了一定的经验样本效率，但仍存在计算复杂度仍较高的问题，本节利用 DDPG 算法的经验池优先级设计理论对于经验样本的优越性，进一步引入帕累托前沿，提出了基于多目标的改进 DDPG 算法（Multi-objective DDPG algorithm），简称 MODDPG 算法，进而提出改进 DDPG 算法的机械臂多目标轨迹规划方法。

中国知网 https://www.cnki.net

以工业机器人轨迹的时间最少、动能最优、冲击力最小为优化目标，满足位置、速度、加速度约束，设定奖励函数为：

$$\begin{aligned} R_{time} &= -\alpha d^2 - \beta\sqrt{d} - \max_i t_i \\ R_{energy} &= -\alpha d^2 - \beta\sqrt{d} - \dot{q}^T M(q)\dot{q} \\ R_{impact} &= -\alpha d^2 - \beta\sqrt{d} - \frac{1}{N}\sum_{i=1}^{N}\left\|\ddot{q}_i(k)\right\| \end{aligned} \tag{4.4}$$

训练过程评价器策略优化的目标函数为： $R = R_1 + R_2 + R_3$

利用机械臂末端点 g 与目标点 ξ 的距离 $d_{g\xi}$ 来确定 g_t 的值， $d_{g\xi}$ 的计算如下式所示：

$$d_{g\xi} = \sqrt{\left(x_g - x_\xi\right)^2 + \left(y_g - y_\xi\right)^2}$$
$$\begin{cases} g_t = 1 & d_{g\xi} < 10\text{mm} \\ g_t = 0 & \text{其他} \end{cases} \tag{4.5}$$

R_1 与 $d_{g\xi}$ 有关，用于引导机械臂末端点 g 到达目标点范围，按下式计算：

$$R_1 = -0.01 d_{g\xi} + \frac{9.8}{0.02 d_{g\xi} + 1} \tag{4.6}$$

R_2 用于引导机械臂的连杆尽量保持竖直朝向目标物的状态,按下式计算：

$$R_2 = 0.03\left(y_m - y_n\right) \tag{4.7}$$

R_3 用于限制强化学习输出动作的大小，使得机械臂的运动轨迹更加平滑，按下式计算：

$$R_3 = -\|a\|^2 \tag{4.8}$$

上述奖励函数能够根据 $d_{g\xi}$、 y_m、 y_n、输出动作 a 的大小来改变变化趋势，使得模型训练更容易稳定、收敛。

引入参数化权衡器，用来调整 MODDPG 算法中不同目标函数之间的权衡关系。

$$W = \left[w_1 R_{time}, w_2 R_{energy}, w_3 R_{impact}, w_4 R_1, w_5 R_2, w_6 R_3\right] \tag{4.9}$$

w_i 是第 i 个目标函数的权衡参数，在 MODDPG 算法中， w_i 是介于 0 和 1 之间的实数，用于控制各个目标函数在优化中的重要性。当 w_i 趋近于 0 时，表示第 i 个目标函数的重要性较低，算法更倾向于优化其他的目标函数。本文通过以往经验以及实验调整，实验中设置权衡参数系数如下表 4.2 所示。

中国知网 https://www.cnki.net

表 4.2　权衡参数表

	w_1	w_2	w_3	w_4	w_5	w_6
值	0.24	0.18	0.14	0.18	0.16	0.10

为了提高训练效率，学习过程中设置了经验池机制，首先引入多目标优化理论中的帕累托优化，在经验池中通过使用 NSGA 算法求解帕累托前沿集，并在此基础上设计了一种优先抽取高质量经验的方法，对帕累托前沿集中的解进行排序。决策网络定期抽取经验池信息进行训练，设计如下经验案例抽取优先级公式（4.7）。

$$\begin{aligned}\Pr(k) &= \sum_{j=1}^{all}\mu(j)/\mu(k) + 1/\beta + \partial \\ \mu(k) &= 1/\left(\text{rank}\left(\text{rank}\left(J_k(\hat{\theta})\right) + \text{inv_rank}(T_n)\right)\right)\end{aligned} \tag{4.10}$$

上式（4.7）中，一般情况下 $\beta>1$，β 越接近于1时，优先级高的样本越容易被选中；$J_k(\hat{\theta})$ 为经验池中第 k 个案例的最终损失函数；$\mu(\bullet)$ 为排序序位的倒数；rank 为排序函数；$inv_rank(T_n)$ 为抽取次数的递减排序位置。同时∂为惩罚因子项，可以限制经验池中各案例被抽取的次数，$J_k(\hat{\theta})$ 较大的案例随着被使用次数的增加而降低优先级，使得其余案例同样能够得到训练，可以避免训练过程中过拟合现象的产生。

注 4.1 文献[57]中采用 $\Pr(k)=\mu(k)/\sum_{j=1}^{all}\mu(j)+\beta$ 优先级设计公式，虽然也达到了限制经验池中各案例被抽取的次数的目的，但是本章采用的经验池设计公式 $\Pr(k)=\sum_{j=1}^{all}\mu(j)/\mu(k)+1/\beta$ 在 β 的取值范围上更加灵活，在实际应用中，可以直接对 β 取整数，方便实验人员进行参数调节。同时∂为惩罚因子项，对于经验池中奖励值高的案例加以限制，可以有效避免训练过程中的过拟合现象。

网络训练参数：

1.批次大小（Batch size）：指每次从经验回放缓冲区中随机选择的样本数量。较大的批次大小可以增加样本的利用效率，但会增加计算开销。

2.经验回放缓冲区大小（Replay buffer size）：指存储用于训练的经验样本的缓冲区的最大容量。较大的缓冲区大小可以提供更多的样本进行训练，增加样本的多样性，但会增加内存占用。

3.目标网络更新频率（Target network update frequency）：指目标网络参数更新的频率。

中国知网 https://www.cnki.net

在 MODDPG 中，通常使用两个网络：一个是用于选择动作的策略网络（Actor），另一个是用于评估状态-动作对的价值网络（Critic）。目标网络是通过定期从策略网络和价值网络中复制参数来更新的。

4.学习率（Learning rate）：指用于优化算法（如 Adam）的学习率。学习率决定了参数更新的步长。较小的学习率可以增加算法的稳定性，但可能需要更长的训练时间。

5.γ（Discount factor）：指在计算累积奖励时对未来奖励的折扣因子。γ 的取值范围为 0 到 1 之间，较大的γ表示更重视未来奖励，而较小的γ表示更重视即时奖励。

6.ε-greedy 策略参数（ε-greedy exploration parameter）：指在训练过程中探索和利用之间的平衡。ε-greedy 策略用于在一定概率下选择随机动作，以便探索环境。随着训练的进行，可以逐渐减小ε的值，增加对利用的依赖。

具体训练参数设置如下表 4.3 所示：

表 4.3 训练参数表

参数	批次大小（Batch siza）	经验回放缓冲区大小	目标网络更新频率	学习率	折扣因子	策略参数
值	64	10000	500	0.001	0.97	0.02

MODDPG 算法流程图如下图 4.1 所示。

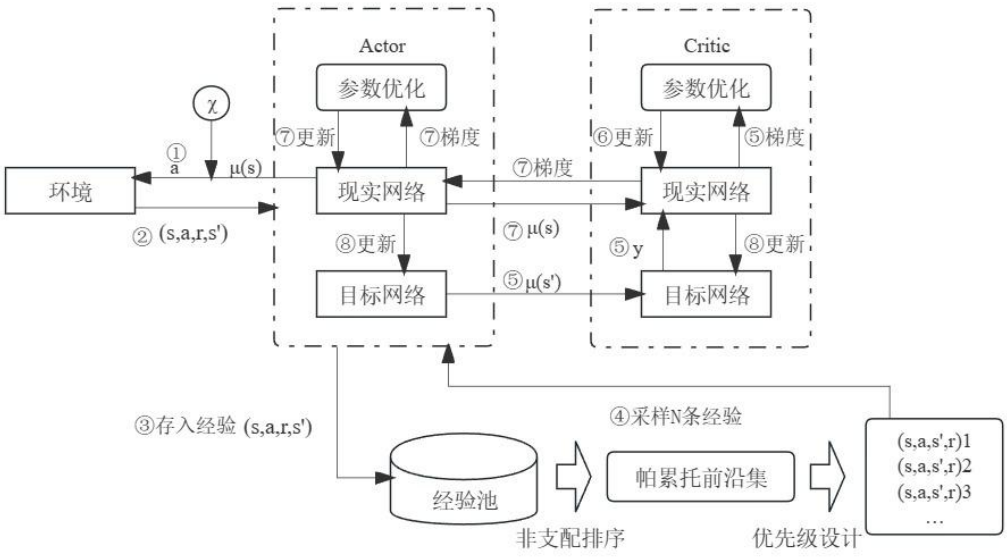


图 4.1　MODDPG 算法流程图

注 4.2 文献[25]虽然在算法流程图上采用了经验池优势函数的设计，但本节中图 4.1 部分经验池设计中，第一步通过在经验池中使用多目标优化算法（NSGA)求解帕累托前沿集，提高了数据质量，在此基础上再进行优先级设计，对帕累托前沿集中的解进行排序，通过为每

中国知网 https://www.cnki.net

个解分配一个优先级，来指导学习算法来进行探索和学习。设计公式如（4.7）所示，本文的设计方法在进一步降低数据集大小的同时，提升了数据集的质量和训练效率，帮助学习算法在多个目标之间进行有效的权衡和决策。

具体训练步骤如下：

1.初始化批量大小（batch size）、训练周期数（number of training cycles）、目标网络更新频率（target network update frequency）等超参数。

2.初始化动作策略网络（actor network）和 Q 值函数网络（critic network），并用随机权重进行初始化。

重复以下步骤直到收敛：

a. 从经验回放缓冲区中随机采样一批数据。

b. 对于每个样本，计算目标 Q 值：

i. 通过目标网络（target network）预测下一个状态的动作。

ii. 计算下一个状态的奖励值。

iii. 计算目标 Q 值，结合奖励值和下一个状态的 Q 值。

c. 更新 Q 值函数网络（critic network）的参数，通过最小化目标 Q 值和当前预测 Q 值之间的均方误差（MSE）。

d. 更新动作策略网络（actor network）的参数，通过沿着梯度上升方向调整动作策略网络的权重。

e. 更新目标网络（target network）的参数，将 Q 值函数网络的权重慢慢地混合到目标网络中。

表 4.1　MODDPG 算法伪代码

MODDPG 算法
1：初始化 Critic 部分的现实神经网络 Q 和 Actor 部分的现实神经网络 μ，参数分别是 λ^{Q} 和 λ^{μ}
2：初始化 Critic 部分和 Actor 部分的目标神经网络 Q' 和 μ'，参数 $\lambda^{Q'}=\lambda^{Q}$，$\lambda^{\mu'}=\lambda^{\mu}$
3：for 回合=1: M do
4：　初始化动作探索的噪声 χ，状态 s
5：　while　状态 s 非终止状态 s
6：　输入状态 s 给 Actor 部分的现实神经网络 μ，选取动作并增加噪声 $a=\mu(s)+\chi$
7：　智能体执行动作与环境交互执行动作 a，并且受到即使奖励 r,通过参数化权衡器

中国知网　https://www.cnki.net

计算得到奖励值，环境转移到状态 s'

8：　将采样经验 (s,a,s',r) 存入经验池中

9：　对经验池中的数据进行非支配排序和拥挤度距离计算，选择帕累托前沿解集，并对帕累托前沿集进行优先级设计

10：　if 帕累托前沿集的数据量大于一个训练小组的大小

11：　从前沿集中采样一个训练小组 (s,a,s',r)

12：　目标函数 $y=r+\gamma Q'(s',\mu'(s'))$ 使用 y 与 $Q(s,a)$ 的均方误差 loss 函数回归来更新 Critic 部分的现实神经网络的参数

13：　通过混合策略网络公式来更新 Actor 部分的目标神经网络参数：

$$\pi(a|s)=\sum_i(\beta_i*\pi_i(a|s))$$

14：　更新 Actor 模型部分和 Critic 模型部分的现实网络参数到目标网络中，σ 是远小于 1 的正数：

$$\lambda^{Q'}\leftarrow\sigma\lambda^{Q'}+(1-\sigma)\lambda^{Q'}$$

$$\lambda^{\mu'}\leftarrow\sigma\lambda^{\mu}+(1-\sigma)\lambda^{\mu'}$$

15：　end if

16：　end while

17：end for

本节在原始的 DDPG 算法基础上进行了创新，以解决多目标优化问题。以下是 MODDPG 算法的创新点：

1.多目标奖励函数：MODDPG 使用多个目标奖励函数来度量不同的目标。传统的 DDPG 算法通常使用单一的奖励函数作为优化目标。而 MODDPG 引入了多个奖励函数，每个奖励函数对应一个特定的目标。这使得算法能够同时优化多个目标，而不仅仅是单一的目标。

2.Pareto 优化：MODDPG 使用 Pareto 优化来解决多目标优化问题。Pareto 优化的目标是找到一组解，这组解在所有目标上都无法被其他解支配。MODDPG 通过在训练过程中保留 Pareto 最优解集合，从而获得多个非支配解。这样可以提供一系列在不同目标之间进行权衡的解。本文通过在经验池优先级设计前引入帕累托前沿，进一步提升了训练数据质量和算法收敛能力。

3.非支配排序经验回放：MODDPG 使用非支配排序经验回放来存储和采样经验。非支配排序经验回放是基于 Pareto 优化的经验回放方法。它将经验按照非支配排序的方式进行排序，

中国知网　https://www.cnki.net

然后按照一定比例选择高质量的经验进行训练。这样可以确保训练样本中包含多样的非支配解，从而更好地优化多个目标。

4.混合策略：MODDPG 使用混合策略来生成不同的动作。传统的 DDPG 算法使用确定性策略，即给定状态直接输出一个具体的动作。而 MODDPG 引入了随机性，采用混合策略生成动作。这样可以使得策略更加多样化，能够适应多个不同的目标。对于算法，可以避免陷入局部最优解，有助于训练过程的稳定，提升收敛速度。

4.4 实验结果分析

实验设备：同第三章相同。

4.4.1 实验一

在 matlab 和 CoppeliaSim Edu 进行轨迹联合轨迹跟踪仿真轨迹规划实验，可以实现在 matlab 中通过算法控制 VERP 中 UR5 机械臂的运行轨迹，效果图如下：

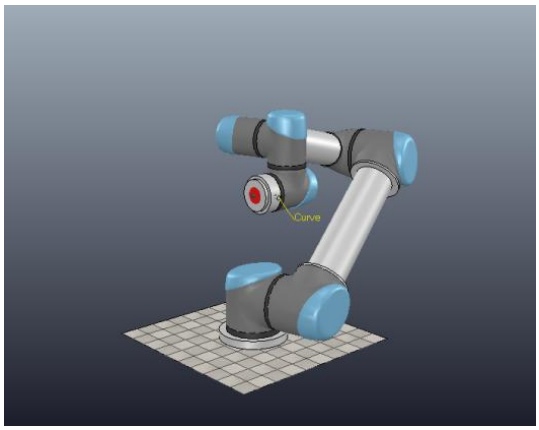


图 3.3　VREP 中 UR5 运行轨迹图

分别用最大熵近端最优算法和 MODDPG 算法对机械臂进行轨迹规划，并记录规划时间。

表 4.3　时间对比表

	最大熵近端最优算法	MODDPG 算法
最快用时	4.8s	3.3s
平均用时	5.4s	3.8s

由上表 4.3 可知，MODDPG 算法和最大熵近端最优算法在轨迹规划任务中平均用时分别为 3.8s、5.4s；最快用时分别为 3.3s、4.8s。

中国知网　https://www.cnki.net

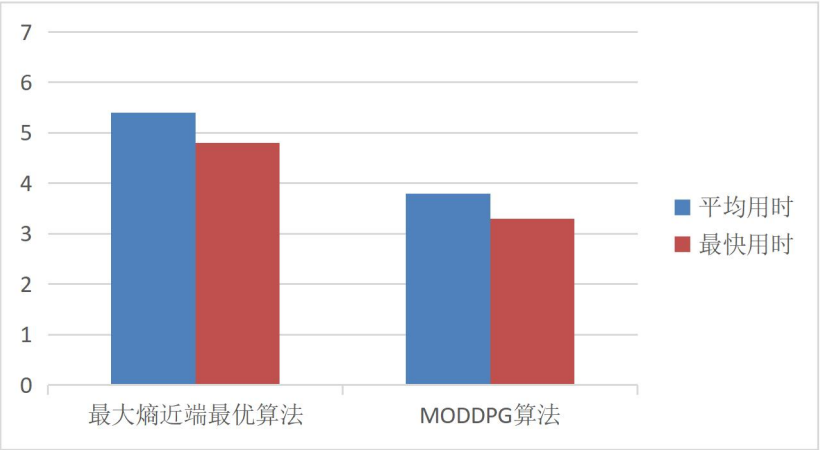


图 4.5　算法时间对比图

通过上图 4.5 可知，MODDPG 算法在轨迹规划任务中平均用时相较最大熵近端最优算法提升了 29.6%，最快用时提升了 31.3%。

4.4.2 实验二

实现码垛任务：实现机械臂码垛任务[59]，将物体按照 3*3 的规格形式摆放到实验平台上，使用本文提出的 MODDPG 算法进行仿真实验，记录码垛任务中每层物体摆放好的时间，如下表 4.4 所示，与最大熵近端最优算法进行对比分析。

表 4.4　算法对比时间记录表

		最大熵近端最优算法			MODDPG 算法		
	实验次数	第一层	第二层	第三层	第一层	第二层	第三层
用时/秒	1	149	552	654	147	347	486
	2	186	519	668	107	296	447
	3	167	530	589	115	329	464
	4	192	507	612	132	317	455
	5	196	577	592	109	316	508
平均用时/秒		178	537	623	122	321	472

1.当码垛任务完成每一层任务时，记录下时间，鉴于码垛任务的复杂性，此实验共进行 5 次，时间取每次实验的平均值，当任务完成第一层时，此时平均用时 122s，实验效果图如下图 4.6 所示。

中国知网　https://www.cnki.net

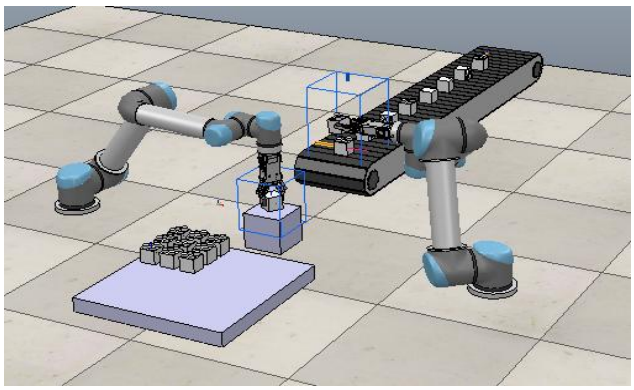


图 4.6　任务第一层

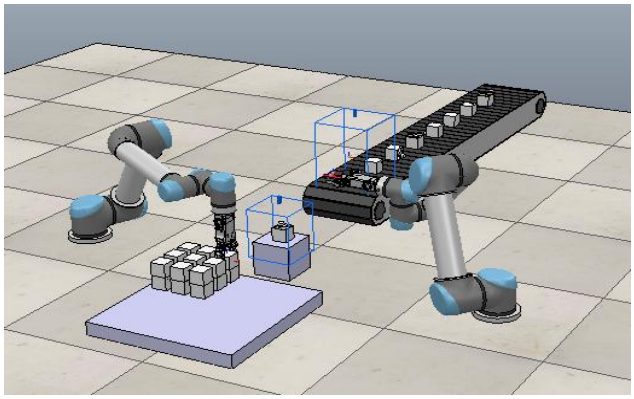


图 4.7　任务第二层

2.当码垛任务进行到完成第二层任务时，如上图 4.7 所示，此时平均用时 321s，

3.当码垛任务进行到第三层时，如下图 4.8 所示，此时平均用时 472s。

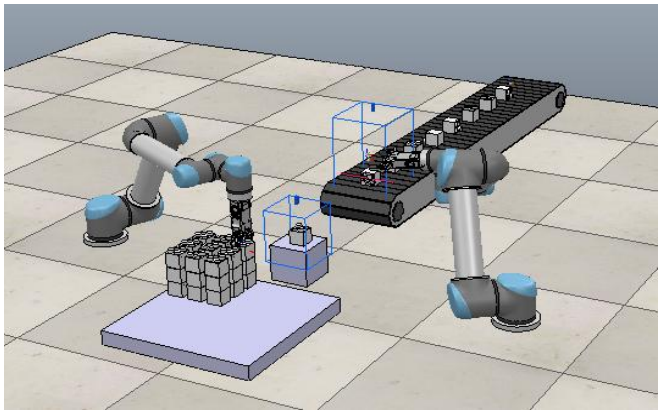


图 4.8　任务第三层

4.重复以上实验，由下表 4.3 可知，最大熵近端最优算法完成码垛任务的平均用时分别是 178s，537s，623s，MODDPG 算法分别为 122s，321s，472s，第一层任务、第二层任务，第三层任务效率值分别提升了 31.4%，40.2%，32%；平均效率值提升了 31.6%。说明了改进的 MODDPG 算法拥有更好收敛性的同时，对于轨迹规划任务的效率、能耗等指标也有了明显提升。

中国知网　https://www.cnki.net

表 4.3　算法时间对比

	最大熵近端最优算法	MODDPG 算法
第一层	178s	122s
第二层	537s	321s
第三层	623s	472s

5.最大熵近端最优算法与 MODDPG 算法完成任务所需时间对比图如下：

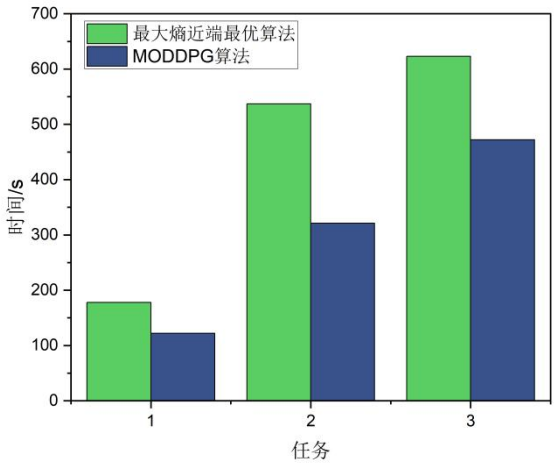


图 4.9　算法时间对比图

通过分析改进算法的效率值变化，说明在第二层任务中改进算法的效率值有了明显的提升，分析其原因可能是在码垛任务中，第二层的任务更加复杂[60]，其对机械臂操作的精度要求更高，对于物体之间的摆放要求也更高，因此说明了改进 MODDPG 算法在面对复杂任务时，相比于最大熵近端最优算法有着更好的效率，改进算法提升的效率值如下图 4.10 所示。

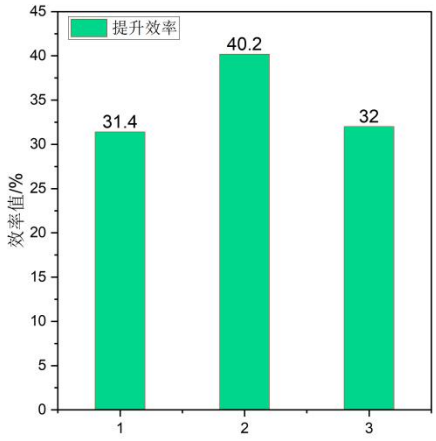


图 4.10　提升效率值

通过以上实验结果分析可知，MODDPG 算法适用于连续动作空间的问题，保留了原始 DDPG 算法的优势，具有较好的探索性能和策略优化能力的同时，结合了 Actor-Critic 结构和经验回放缓冲区，通过奖励函数、帕累托前沿集，经验池设计，提高了算法的训练效率和算

中国知网　https://www.cnki.net

法的稳定性、收敛性。

多目标优化的 DDPG 算法能够处理多目标连续控制问题，使得智能体能够在同一时间优化多个目标。本章提出的 MODDPG 算法基于 Actor-Critic 架构，结合了策略优化和值函数优化的优点，在处理连续动作空间和高维状态空间时表现良好。通过使用经验回放缓冲区进行训练，引入帕累托前沿集，能够提高数据的样本效率和稳定性，提高了收敛性。

仿真实验中算法训练的平均奖励值如下图 4.2 所示，MODDPG 算法在 2200 次时逐渐收敛，相较于最大熵近端最优算法提升了 1000 次左右，算法效率提升了 31.25%。

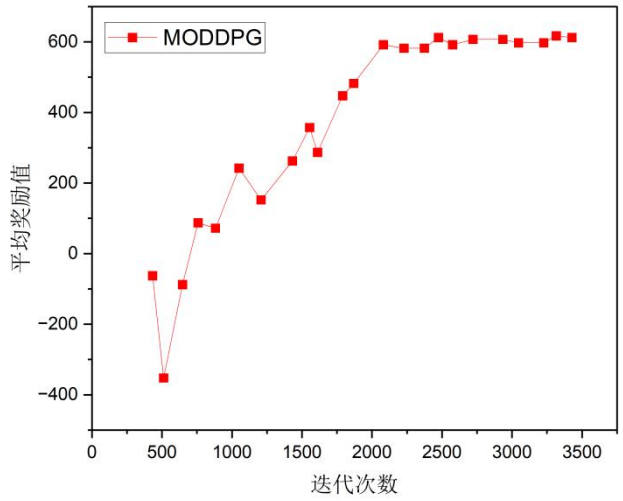


图 4.2　MODDPG 算法平均奖励值

4.5 本章小结

基于前面的研究，本章第一部分提出基于改进的 DDPG 算法的机械臂多目标轨迹规划方法（MODDPG），在仿真实验中验证了该优化方法的有效性，证明了使用该改进方法比最大熵近端最优算法有更强的稳定性与收敛性。第二部分以 UR5 机械臂为仿真对象，采样改进的 MODDPG 算法对其进行仿真验证，其中效率值相较最大熵近端最优算法分别提升了 31.4%，40.2%，32%，平均效率值提升了 31.6%。仿真结果表明该算法能有效帮助机械臂取得综合最优性能，在复杂任务中有着良好的性能，在仿真实验中验证了该优化方法的有效性，证明了使用该改进方法提升了效率，同时有着更强的稳定性和收敛性。综上所述，本章提出的 MODDPG 算法通过使用多个参数化的动作价值函数，优化多个目标的同时，在多目标问题上实现了较好的性能，其优势主要有以下几点。

1.非劣解集：MODDPG 算法能够生成非劣解集，即一组在多个目标函数下都是最优的解。

中国知网　https://www.cnki.net

这使得决策者可以在多个可行解中进行选择，并根据其偏好来确定最终解决方案。非劣解集提供了更多的决策灵活性和多样性。

2.自适应权衡：MODDPG 算法可以根据决策者的偏好自适应地调整不同目标函数之间的权衡关系。通过引入一个参数化的权衡器，可以在不同目标之间进行动态权衡，以满足特定的需求。这使得算法更具灵活性和可调节性，能够适应不同的问题和决策需求。

3.收敛性和稳定性：MODDPG 算法基于 DDPG 算法，使用了深度神经网络来估计动作价值函数，同时利用了策略梯度方法进行优化。这种结合使得 MODDPG 算法在收敛性和稳定性方面表现良好。它可以有效地处理高维、连续动作空间，并且能够通过经验回放和目标网络的更新来提高算法的稳定性。

中国知网 https://www.cnki.net

第五章 总结与展望

5.1 全文总结

本文面向机械臂的轨迹规划问题，首先介绍了该课题的研究背景与意义以及国内外研究现状，了解到近年来深度强化学习领域的发展，极大地促进了机械臂轨迹规划问题与深度学习领域的结合。接着介绍了一部分相关理论，并在此基础上提出了本文的三个研究内容。

第一个提出了基于时间-动能-冲击的强化学习轨迹规划方法，实现了更好的稳定性和收敛性。针对每个优化目标，构建并行运作的动作网络和评判网络，根据评判网络输出的优势函数对动作网络的策略进行非支配排序而获得帕累托前沿集；根据最大熵近端策略优化算法确定动作网络和评判网络的目标函数，从所获得的帕累托前沿集中，随机选择若干组状态-动作对，使用梯度法上升法来训练动作网络和评判网络的参数，从而获得满足多种约束条件多个目标的工业机器人轨迹，通过这种方法，可以在工业机器人的轨迹规划中同时优化多个目标，同时满足位置、速度和加速度的约束。

第二个研究内容是基于改进的 DDPG 算法，通过改进奖励函数设计、经验池优先级设计，训练一个连续动作空间下的策略网络和 Q 值函数网络，实现精细化的轨迹规划。改进的 DDPG 算法的优点在于其对连续动作空间的建模能力和收敛性的同时，可以有效地处理高维、连续动作空间，并且能够通过经验回放和目标网络的更新来提高算法的稳定性和效率。

第三个研究内容搭建了仿真平台，在仿真实验中验证了该优化方法的有效性，改进的 MODDPG 算法效率值完成 1、2、3 任务时相较最大熵近端最优算法分别提升了 31.4%，40.2%，32%，平均效率值提升了 31.6%。证明了使用该改进方法比最大熵近端最优算法提升了效率，同时有着更强的稳定性和收敛性。

综上所述，本文为多目标优化的工业机器人轨迹规划提供了一种多样化的解决方案。通过强化学习的方法，能够处理复杂的问题和多目标优化需求，提供更灵活、智能和适应性强的轨迹规划策略。此外，结合 DDPG 算法的改进，进一步增强了算法的性能和稳定性。

中国知网 https://www.cnki.net

5.2 展望未来

展望未来，机械臂多目标轨迹规划[61]可以在以下方面进行扩展和改进：

算法改进：可以进一步改进 DDPG 算法，提高其效率、稳定性和收敛性。例如，结合其他强化学习算法或深度学习技术，如 Twin Delayed DDPG (TD3)：TD3 是对 DDPG 的改进，通过引入两个 Q 网络和延迟更新的方式来提高算法的性能和稳定性[62]。其中，两个 Q 网络用于减少估计误差，延迟更新则可以减轻过度估计和过拟合的问题。另外，在 DDPG 中应用 HER 可以提高对稀疏奖励环境的学习效率。Distributional DDPG：Distributional DDPG 是一种改进方法，它通过将值函数视为分布而不是单个值来提高算法的性能。这种改进方法可以处理非对称的奖励分布和更好地估计策略的不确定性。

综上所述，本文提出了一种基于最大熵近端最优的机械臂多目标轨迹规划方法，并结合了 DDPG 算法进行改进。这为多目标优化的工业机器人轨迹规划提供了多样化的解决方案，并展现了更好的稳定性和收敛性。未来的研究可以在算法改进方面[63]进行深入探索，以进一步提升工业机器人轨迹规划的性能和应用能力。

中国知网 https://www.cnki.net

参考文献

[1] 龙樟,李显涛,帅涛,温飞娟,冯文荣.工业机器人轨迹规划研究现状综述[J].机械科学与术,2021,40(06):853-862.

[2] 李舒沁,王灏晨,汪寿阳.人工智能背景下工业机器人发展水平综合动态评价研究——以制造业为例[J].系统工程理论与实践,2020,40(11):2958-2967.

[3] Pires E J S,Tenreiro M,Oliveira M.Robot trajectory planning using multi-objective genetic algorithm optimization[J]. Lecture Notes in Computer Science-GECCO,2004,24(5):33-38.

[4] Martin B J,Bobrow J E.Minimum effort motions for open chain manipulators with ask-dependent endeffector constraints[J]. Journal of Robotic Research,1999,8(2):213-224.

[5] ABE AKIRA.Minimum energy trajectory planning method for robot manipulator mounted on flexible base[C]//Proceedings of IEEE Control Conference(ASCC),Istanbul,2013 June23-26.

[6] Kyriakopoulos K J,Saridis G N.Minimum jerk path generation[C]//1988 IEEE International Conference on Robotics and Automation,1988:364-369.

[7] 商德勇,汪俊杰,樊虎,索双富.基于RRT*-DR算法的机械臂避障路径规划[J/OL].计算机集成制造系统,2023.

[8] 李林升.基于惩罚函数法的时间最优机械臂轨迹规划[J].机械设计与研究,2019,35(5):56-58,69.

[9] 殷凤健,梁庆华,程旭,等.基于时间最优的机械臂关节空间轨迹规划算法[J].机械设计与研究,2017,33(5):12-15.

[10] 李虎,刘泓滨.基于改进PSO算法的时间最优机械臂轨迹规划[J].组合机床与自动化加工技术,2023,(01):29-33.

[11] Kang Shin,N. McKay.A dynamic programming approach to trajectory planning of robotic manipulators[J].IEEE Transactions on Automatic Control,1986,31(6):491-500.

[12] 徐海黎,解祥荣,庄健,等.工业机器人的最优时间与最优能量轨迹规划[J].机械工程学报,2010,46(9):19-25.

[13] 余阳,林明,林永才.基于混合遗传算法的工业机器人最优轨迹规划[J].计算机工程与设计,2012,33(4):1574-1580.

[14] 施祥玲,方红根,郭为忠.基于五次NURBS的机械臂时间-能量-平滑性多目标轨迹优化[J].机械设计与研究,2017,33(01):12-16.

[15] 许哲,王庆诚,贾广臣.基于NSGA-II算法的机械臂多目标轨迹优化[J].制造业自动化,2023,45(01):180-184.

[16] 唐润智.面向高载荷低能耗的机器人轨迹规划方法研究[D].硕士学位论文.河北工业大学,2020.

[17] 张伟楠,沈键,俞勇.动手学强化学习[M].北京:人民邮电出版社,2022.

[18] Kamal,Kant,Steven,et al.Toward Efficient Trajectory Planning: The Path-Velocity Decomposition[J].The International Journal of Robotics Research, 1986, 5(3):72-89.

[19] 谢嘉,吴家桢,李永国,梁锦涛.改进粒子群优化算法在机械臂轨迹规划中的应用[J/OL].机械科学与技术,2023.

[20] 王会方,朱世强,吴文祥.基于INSGA-II算法的机械手多目标轨迹规划[J].浙江大学学报(工学版),2012,46(04):622-628.

[21] 周明,孙树栋.遗传算法原理及应用[M].国防工业出版社,1999.

[22] Chi Z , Hai-Bing G , Liang G ,et al.Particle Swarm Optimization(PSO) Algorithm[J].Application Research of Computers, 2003.

[23] Geng X , Chen Z , Yang W ,et al.Solving the traveling salesman problem based on an adaptive simulated annealing algorithm with greedy search[J].Applied Soft Computing, 2011, 11(4):3680-3689.

[24] 陈佳盼,郑敏华.基于深度强化学习的机器人操作行为研究综述[J].机器人,2022,44(02):236-256.

[25] Dongxu Zhou, Mingzuo Xie, Pengcheng Xuan, Ruiqing Jia. A teaching method for the theory and application of robot kinematicsbased on MATLAB and V-REP[J].Computer Applications in Engineering

中国知网 https://www.cnki.net

Education,2020,28(2).
[26] 刘哲,潘爱强,魏本刚,江安烽,张家维,白成超.基于指导轨迹加速的机械臂强化学习运动规划[J].电气自动化,2022,44(05):102-103,107.
[27] 郑钧天.基于深度强化学习的机械臂轨迹规划仿真[D].硕士学位论文.电子科技大学,2020.
[28] 杨辰光,李智军,许杨.机器人仿真与编程技术[M].北京:清华大学出版社,2018.
[29] 赖禹昊,张沙清.考虑动力学约束的机械臂时间最优在线轨迹规划算法研究[J].机械设计与制造工程,2023,52(03):27-33.
[30] 闻了然,张方.机器人运动学模型参数修正[J].数字技术与应用,2023,41(04):1-4,29.
[31] Yankov K .Manipulator Motion Planning[C]//International workshop on Sensorial Integration for Industrial Robots.1989.
[32] 郝建豹,查进艳,谢炼雅.基于DH算法的平面关节机器人的运动学建模与仿真[J].机电工程技术,2018,47(04),99-102.
[33] Yoshikawa T .Quasi-static trajectory tracking control of flexible manipulator bymacro-micro manipulator system[C].1993.
[34] Kelly R ,Victor Santibáez Davila,Julio Antonio Loría Perez.Control of Robot Manipulators in Joint Space[J].Industrial Robot: the international journal of robotics research and application, 2006, 33(6).
[35] Faverjon B .Obstacle avoidance using an octree in the configuration space of a manipulator[C].Proceedings. 1984 IEEE International Conference on Robotics and Automation,1984:504-512.
[36] Iii W , C. C . MARKOV DECISION PROCESSES.[J]. Encyclopedia of Operations Research & Management Science, 2001.
[37] O'Doherty J.Temporal difference learning model accounts for responses in human ventral striatum and orbitofrontal cortex during Pavlovian appetitive learning[J].2003.
[38] Sutton R S , Barto A G . Reinforcement Learning: An Introduction[J]. IEEE Transactions on Neural Networks, 1998, 9(5):1054.
[39] Farahnakian F,Ebrahimi M,Daneshtalab M,et al.Q-learning based congestion-aware routing algorithm for on-chip network[C].Proceedings of the 2nd IEEE International Conference on Networked Embedded Systems for Enterprise Applications,2011:1-7.
[40] Osband I Blundell C, Pritzel A , et al. Deep Exploration via Bootstrapped DQN[J]. CoRR,2016,abs/1602.04621..
[41] Konda V R , Tsitsiklis J N . On Actor-Critic Algorithms[J]. Society for Industrial and Applied Mathematics, 2003,42(4):1143–1166.
[42] Li H , He H . Multi-Agent Trust Region Policy Optimization[J].arXiv Preprint.arXiv.2010.07916,2020.
[43] Fei W , Yu H , Li H , et al. Deterministic Diagnostic Pattern Generation (DDPG) for Compound Defects[C].2008 IEEE International Test Conference, Santa Clara,2008:1-10.
[44] Vecerik M , Hester T , Scholz J ,et al.Leveraging Demonstrations for Deep Reinforcement Learning on Robotics Problems with Sparse Rewards[J].arXiv Preprint arXiv:1707.08817,2017.
[45] Huang C H , Galuski J , Bloebaum C L . Multi-Objective Pareto Concurrent Subspace Optimization for Multidisciplinary Design[J]. AIAA Journal, 2007, 45(8):1894-1906.
[46] Mahapatra G S,Roy T K.Fuzzy multi-objective mathematical programming on reliability optimization model[J].International Journal of Fuzzy Systems, 2006,12(3):259-266.
[47] Fu J , Luo K ,Levine S.Learning robust rewards with adversarial inverse reinforcement learning[J].arXiv preprint arXiv:1710.11248, 2017.
[48] Adam L,Pietra V ,Pietra S . A Maximum Entropy Approach to Natural Language Processing[J]. Computational Linguistics, 2002, 22(1).
[49] Schulman J ,Wolski F ,Dhariwal P , et al. Proximal Policy Optimization Algorithms[J].Advances in Neural Information Processing Systems,2017.
[50] 李鹤宇,赵志龙,顾蕾,郭丽琴,曾贲,林廷宇.基于深度强化学习的机械臂控制方法[J].系统仿真学

中国知网 https://www.cnki.net

报,2019,31(11):2452-2457.
[51] 徐帷,卢山.基于Sarsa(λ)强化学习的空间机械臂路径规划研究[J].宇航学报,2019,40(04):435-443.
[52] Gosavi A . A Reinforcement Learning Algorithm Based on Policy Iteration for Average Reward: Empirical Results with Yield Management and Convergence Analysis[J]. Machine Learning, 2004, 55(1):5-29.
[53] Peng Li,Xiangcheng Ding,Hongfang Sun,Shiquan Zhao,Ricardo Cajo.Research on Dynamic Path Planning of Mobile Robot Based on Improved DDPG Algorithm[J].Mobile Information Systems,VOL.2021.
[54] 刘勇,李祥,蒋沛阳,孙博熙,吴喆.基于DDPG-PID的机器人动态目标跟踪与避障控制研究[J].南京航空航天大学学报,2022,54(01):41-50.
[55] Ioffe S , Szegedy C . Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[J]. JMLR.org, 2015.
[56] Zhang J,Li L ,Hu C .Learning how to drive using DDPG Algorithm with Double Experience Buffer Priority Sampling[C].2020 Chinese Automation Congress (CAC),2020.
[57] 赵毓,管公顺,郭继峰,等.基于多智能体强化学习的空间机械臂轨迹规划[J].航空学报,2021,42(01),266-276.
[58] Mingzuo Xie,Dongxu Zhou,Yong Shi and Ruiqing Jia.Virtual Experiments Design for Robotics Based on V-REP[C].IOP Conf. Series: Materials Science and Engineering,2018(428):012069.
[59] 陈建华.基于深度强化学习的机械臂运动规划研究[D].燕山大学,2019.
[60] 董贯涛.基于深度强化学习的机器人抓取方法研究[D].哈尔滨工业大学,2019.
[61] Yazhou Hu,Wenxue Wang,Hao Liu,Lianqing Liu.Reinforcement Learning Tracking Control for Robotic Manipulator With Kernel-Based Dynamic Model[J].IEEE TRANSACTIONS ON NEURAL NETWORKS AND LEARNING SYSTEMS,2020,31(9):3570-3578.
[62] LeCun Y, Bengio Y, Hinton G.Deep learning[J]. Nature, 2015, 521(7553): 436-444.
[63] Wang X , Hao M , Lei R ,et al.PDE-PEDA: A New Pareto-Based Multi-objective Optimization Algorithm[J].Journal of Universal Computer Science, 2014, 15(4):722-741.

中国知网 https://www.cnki.net