学号： 222050105　　学校代码： 10336

密级：

杭州电子科技大学

硕 士 学 位 论 文

（专业学位）

论文题目： 基于扩散模型和强化学习的机械臂自适应决策与控制方法研究

作 者 姓 名 ： 马晨聪

指 导 教 师 ： 陈德潮 教授

专业学位类别： 电子信息

专 业 领 域 ： 计算机技术

所 在 学 院 ： 计算机学院

完 成 时 间 ： 2025 年 05 月

中国知网 https://www.cnki.net

杭州电子科技大学硕士学位论文

基于扩散模型和强化学习的机械臂自适应决策与控制方法研究

研 究 生：马晨聪

指导教师：陈德潮　教授

2025 年 5 月

中国知网　https://www.cnki.net

Dissertation Submitted to Hangzhou Dianzi University
for the Degree of Master

Research on Adaptive Decision-Making and Control Methods for Robotic Manipulators Based on Diffusion Models and Reinforcement Learning

Candidate: Chencong Ma

Supervisor: Prof. Dechao Chen

May, 2025

中国知网 https://www.cnki.net

摘要

机械臂系统在生活服务和工业场景都有广泛应用，旨在优化流程、减少人力劳动并提升操作精度。传统的决策和控制方法依赖预设规则或单一学习范式，难以适应动态环境与多样化任务需求。本文针对机械臂的智能决策与轨迹跟踪问题，提出了一系列创新方法，提升机械臂在复杂场景、多重任务中的自主决策能力与执行效率。

本文的主要研究成果如下：

（1）在单任务决策方法上，提出了自适应扩散策略（Adaptive Diffusion Policy, ADP）。通过设计的两阶段训练框架，该策略结合了模仿学习和强化学习的优势。在第一阶段，利用模块化设计的扩散策略模仿学习专家演示，学习执行任务所需的行为模式，获得预训练策略；在第二阶段，通过改进的多步强化学习框架以及利用低秩适应技术对预训练策略进行微调训练，通过与环境交互学习的方式进行优化，得到最终的微调策略。在 MetaWorld、Adroit、DexArt 任务上进行的对比、可视化、消融实验证明了该方法的有效性。

（2）在多任务决策方法上，提出了自适应多任务扩散策略（Adaptive Multi-Task Diffusion Policy, AMTDP）。AMTDP 引入混合专家结构改进了 ADP 中的原始模块，又利用视觉语言模型为多样化的任务构建了通用的奖励函数，自动生成密集的奖励指导策略微调优化，将单任务策略 ADP 扩展为多任务策略 AMTDP。在 MetaWorld 多任务上的对比、可视化、消融实验证明了该方法的有效性。

（3）在轨迹跟踪控制方法上，将超螺旋（Super Twisting, ST）滑模控制与雅可比矩阵自适应（Jacobian Matrix Adaption, JMA）方法相结合，提出了一种基于 ST-JMA 方法的新型控制系统，成功解决了机械臂在内部不确定性和外部扰动下的轨迹跟踪控制问题。ST-JMA方法利用时间导数和时间积分信息，将隐式且不可测量的数据转换为显式且可测量的数据，从而克服了传统 JMA 方法中无法同时对抗内部不确定性和外部扰动的缺陷。通过理论分析和实验验证，展现了 ST-JMA 方法的全局稳定性和有限时间收敛性。

关键词：扩散模型，强化学习，任务决策，机械臂控制

中国知网 https://www.cnki.net

ABSTRACT

Robotic Manipulator systems are widely applied in both service and industrial scenes, aiming to optimize processes, reduce manual labor, and enhance operational precision. Traditional decision-making and control methods rely on predefined rules or single learning paradigms, making them inadequate for dynamic environments and diverse task requirements. This thesis addresses the challenges of intelligent decision-making and trajectory tracking control for robotic manipulators by proposing a series of innovative methods to enhance autonomous decision-making capabilities and execution efficiency in complex scenarios and multiple tasks.

The main contributions of this thesis are as follows:

(1) Single-task decision-making approach: This thesis introduces the Adaptive Diffusion Policy (ADP), an innovative policy designed to integrate the advantages of imitation learning and reinforcement learning through a two-stage training framework. In the first stage, a modularly designed diffusion policy is employed to imitate expert demonstrations, enabling the policy to learn the behavioral patterns required for task execution, resulting in a pre-trained policy. In the second stage, an improved multi-step reinforcement learning framework, combined with low-rank adaptation techniques, fine-tunes the pre-trained policy through interactive learning with the environment. Comparative, visualization, and ablation experiments conducted on MetaWorld, Adroit, and DexArt tasks validate the effectiveness of ADP.

(2) Multi-task decision-making approach: This thesis proposes the Adaptive Multi-Task Diffusion Policy (AMTDP), which extends ADP by incorporating mixture of experts structure and utilizing vision-language model to construct a universal reward function for diverse tasks. This approach enables the automatic generation of dense reward signals to guide policy fine-tuning, transforming the single-task ADP into a multi-task policy, AMTDP. Experimental results on MetaWorld multi-task settings, including comparative, visualization, and ablation studies, demonstrate the effectiveness of AMTDP.

(3) Trajectory tracking control approach: This study integrates Super Twisting (ST) sliding mode control with Jacobian Matrix Adaption (JMA) to develop a novel control system based on the ST-JMA method. This approach successfully addresses trajectory

中国知网 https://www.cnki.net

tracking control challenges in robotic manipulators, particularly under internal uncertainties and external disturbances. By leveraging time derivatives and time integral information, the ST-JMA method converts implicit and unmeasurable data into explicit and measurable data, thereby overcoming the shortcomings of the traditional JMA method that cannot simultaneously counteract internal uncertainties and external disturbances. Theoretical analysis and experimental validation confirm the global stability and finite-time convergence of the ST-JMA method.

Keywords: Diffusion Model, Reinforcement Learning, Task Decision-Making, Robotic Manipulator Control

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....3
1.2.1 具身智能中的扩散模型研究现状.....3
1.2.2 结合专家演示的强化学习研究现状.....4
1.2.3 轨迹跟踪控制研究现状.....6
1.3 本文研究内容.....8
1.4 本文组织结构.....9
第二章 相关理论基础.....11
2.1 扩散模型.....11
2.1.1 去噪扩散概率模型.....11
2.1.2 条件控制生成.....13
2.1.3 快速采样方法.....13
2.2 强化学习.....14
2.2.1 基本概念.....14
2.2.2 价值优化方法.....15
2.2.3 策略优化方法.....16
2.3 相关基础模型.....18
2.3.1 低秩适应模型.....18
2.3.2 视觉语言模型.....18
2.3.3 混合专家模型.....20
2.4 机械臂轨迹跟踪控制.....21
2.4.1 正运动学.....21
2.4.2 逆运动学.....22
2.4.3 轨迹跟踪控制.....23
2.5 本章小结.....23
第三章 基于扩散模型与强化学习的单任务策略.....24
3.1 算法设计.....24
3.1.1 扩散策略预训练阶段.....25
3.1.2 强化学习微调阶段.....27
3.2 实验分析.....31
3.2.1 数据集介绍.....31
3.2.2 实验设置.....31
3.2.3 对比实验.....32

中国知网 https://www.cnki.net

3.2.4 可视化实验.....35
3.2.5 消融实验.....36
3.3 本章小结.....40
第四章 基于视觉语言模型与混合专家的多任务策略.....41
4.1 算法设计.....41
4.1.1 混合专家预训练阶段.....42
4.1.2 视觉语言模型奖励函数.....43
4.1.3 混合专家微调阶段.....44
4.2 实验分析.....46
4.2.1 数据集介绍.....46
4.2.2 实验设置.....46
4.2.3 对比实验.....47
4.2.4 可视化实验.....48
4.2.5 消融实验.....51
4.3 本章小结.....52
第五章 基于雅可比矩阵自适应的轨迹跟踪控制.....53
5.1 算法设计.....53
5.2 理论分析.....55
5.2.1 无扰动的全局稳定性证明.....56
5.2.2 无扰动的有限时间收敛性证明.....56
5.2.3 有扰动的全局稳定性证明.....60
5.2.4 有扰动的有限时间收敛性证明.....60
5.3 实验分析.....61
5.3.1 仿真实验.....61
5.3.2 对比实验.....63
5.3.3 消融实验.....64
5.3.4 实物实验.....65
5.4 本章小结.....66
第六章 总结与展望.....67
6.1 本文工作总结.....67
6.2 未来展望.....68
参考文献.....69

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景与意义

机器人技术作为提升人类生产力的关键驱动力，在完成多样化、复杂且密集的任务方面展现出快速、精准和高效的优势，因此在从生活到工业的广泛场景中得到深入应用[1]。理想的智能机器人系统应具备以下特征：能够与工作环境进行有效交互、准确解析传感器信号、适时采取行动以在预期时间内达成目标，并能够通过学习行动结果来自动适应动态变化的工作环境。传统机器人操作模式依赖于预设规则和指令集，这种范式虽然适用于简单任务，但在面对日益复杂和灵活的任务需求时有些无能为力。基于具身智能的方法为解决这一泛化问题提供了新的有效途径[2,3]。

具身智能是一种强调智能体通过与物理环境的交互来获得和展现智能的理论框架，其核心观点是智能的本质源于智能体（如机器人或生物体）在真实环境中的观察和行动等综合能力。尽管对具身智能的研究已持续数十年，但赋予智能体具备人类水平的智能仍面临诸多挑战，包括提升其感知、学习、推理、决策、控制和泛化能力，使其能够在开放、非结构化和动态的环境中执行通用任务。近年来，计算机视觉、自然语言处理和多模态学习领域的突破性进展表明，基础模型在特定任务上已展现出超越人类的能力，表现出卓越的理解、推理、交互和生成能力[4-8]。然而，这些模型目前仍无法直接与物理世界中的实体进行交互，其角色更多是提供辅助信息而非直接参与决策，因此其应用范围主要局限于互联网场景。如何将人工智能模型与机器人系统相集成，使其能够在物理环境中自主决策和行动，是实现具身智能的关键问题和研究重点。

机械臂作为具身智能的典型代表，是一种能够模拟人类手臂功能并操纵环境中物体的机器人系统，已经广泛应用在医疗协作、工业制造、航空航天等领域[9-12]，旨在优化工作流程、减少人力投入并提升操作精度。在医疗领域，机械臂能够协助完成手术操作、康复训练及老年护理等任务，通过承担基础性工作，使医护人员能够专注于更具挑战性的医疗决策。在工业制造场景中，机械臂被用于部件组装、焊接、喷漆和包装等任务，显著提高了生产效率和产品质量。在太空探索中，机械臂则承担着样本采集、结构建造和设备维护等关键任务，能够在深空等对人类而言极端危险或难以到达的环境中可靠运行。机械臂系统通常由视觉传感器（如相机等）、机械臂主体、末端执行器以及协调机械

中国知网 https://www.cnki.net

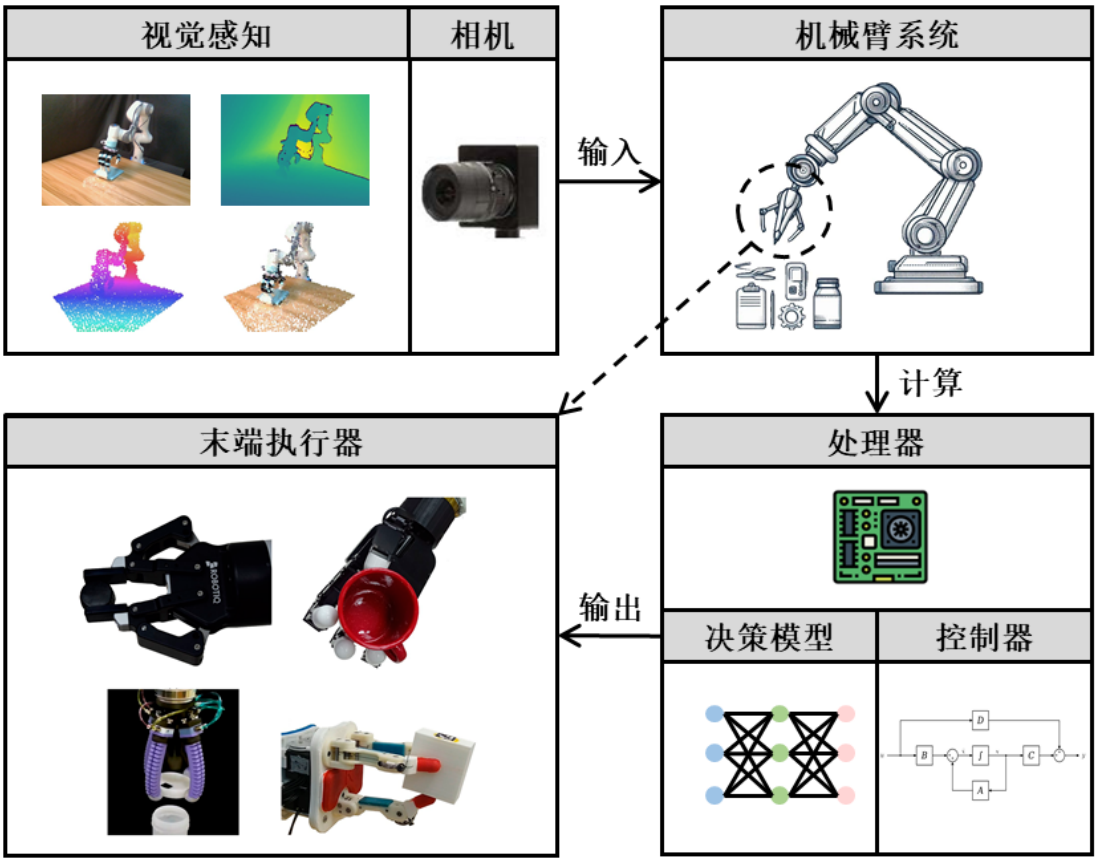


图 1.1 机械臂系统

臂运动的控制系统组成。如图 1.1 所示，机械臂通过相机传感器捕获目标物体及周围环境的视觉信息，并利用这些数据构建对任务场景的理解。随后，处理器对感知信息进行分析和处理，生成最优决策。具体而言，处理器首先基于决策模型规划出机械臂完成任务的动作轨迹，然后通过底层控制器将轨迹转化并执行具体的关节角度控制信号，驱动末端执行器执行相应的操作。人类在复杂任务中展现出的灵巧操作能力是机器人系统亟需实现的关键能力，这不仅决定了机器人能否在动态变化的人类环境中有效工作，也直接影响其替代人力的潜力。早期机械臂依赖于精确编程的固定路径，随后发展为基于运动学和接触分析的建模方法，然而这些方法在处理环境复杂性和不确定性方面存在明显局限，难以提供实用化的解决方案。因此，研究重心逐渐转向基于学习的方法来完成多样化任务[13-18]。

强化学习（Reinforcement Learning, RL）和模仿学习（Imitation Learning, IL）已被证明是智能控制机械臂完成复杂任务的有效方法[19-25]。典型的 RL 算法通过智能体与环境的试错交互来学习最优动作策略，以最大化累积回报，但这种方法通常需要大量采样交互，导致训练效率低下，且在真实环境中存在数据获取成本高、安全风险大等问题。IL 则通过观察专家演示来学习任务策略，但其性能受限于专家数据的质量和规模，且学习到的策略往往难以超越专家水平，泛

中国知网 https://www.cnki.net

化能力有限。

为了克服单一方法的局限性，本文期望引入包括扩散模型（Diffusion Models, DM）、视觉语言模型（Vision Language Models, VLM）、混合专家（Mixture of Experts, MoE）在内的先进基础模型，提升决策模型的表征能力、多模态感知精度及任务理解深度，并整合 IL 与 RL 的互补优势，设计一种自适应决策模型，首先通过专家演示数据快速获取可行的初始策略，随后在任务环境中进行自主探索与优化，从而实现策略性能的突破。此外，本文还开发了一种鲁棒的底层控制器，确保机械臂在存在内部不确定性和外部干扰的情况下仍能精确执行决策模型规划的任务轨迹。通过这一系列创新，本文旨在实现机械臂在复杂、动态环境中的高效、可靠操作，为具身智能的实际应用提供了新的技术路径与解决方案。

1.2 国内外研究现状

1.2.1 具身智能中的扩散模型研究现状

生成模型通过在大规模数据集上的训练，为人工智能的研究和应用开辟了广阔的前景。其中，DM 凭借其对复杂数据分布的高效建模能力和多样化的样本生成能力，已成为该领域的焦点，超越了生成对抗网络[26]和变分自编码器[27]等传统生成模型。

在具身智能领域，DM 同样因其强大的表达能力而备受关注，应用范围广泛，包括但不限于拾取放置操作[28-30]、衣物折叠[31-32]、场景重新排列[33-34]及食物制备[35-36]等。在这些多样化任务中，一个普遍采用的策略是将预训练的 DM 整合到更复杂的系统框架中。具体而言，这些模型通常与感知模块、运动基元、任务与运动规划器或控制器等预定义或学习组件相结合，从而产生协同效应，充分发挥学习组件与预定义组件的各自优势。在这种架构中，DM 主要负责解决传统方法难以建模的问题组件，而预定义元素则处理相对容易定义的方面。

末端执行器的目标位姿（6 自由度变化的位置和姿态）是 DM 生成的最常见元素之一。这些生成的位姿通常被用作场景中目标抓取位姿[28-30]、目标放置位姿[37]，或者直接作为策略的动作输出[38-39]。例如 Weng 等人[29]提出将 DM 与运动规划模块相结合，生成的 6 维位姿被用作运动规划问题中的目标位姿，随后通过基于优化的运动规划器生成机械臂关节空间轨迹。Urain 等人[30]则将学习到 DM 直接集成到运动规划问题中，进一步优化了规划效率。而 Xian 等人[40]提出在一些连续性的任务中，当执行器达到当前目标位姿时，系统会顺序生成新的轨迹，于是利用基于 6 维位姿的 DM 替代传统运动规划器，以实现更高效的轨迹生成。此外，为了满足更高的控制频率需求，Ma 等人[41]提出使用笛卡尔空间

中国知网 https://www.cnki.net

控制器代替运动规划器，通常针对较短的 6 维目标位姿序列进行优化。这些方法不仅提高了系统的实时性，还增强了复杂任务中的控制精度和鲁棒性。位姿生成模型通常能够利用场景与位姿之间的对称性，从而在新场景中表现出更强的泛化能力。

DM 也显示出了生成高维数据的能力[42]，这一进展促使研究界转向探索生成完整轨迹的 DM，而非仅限于单步位姿动作生成。相较于生成单一目标姿态，直接生成整个轨迹具有多重优势。首先，与局限于最终目标的运动规划方法相比，轨迹生成能够实现复杂的动态运动过程，例如将番茄酱涂抹在披萨上[42]或往电池盒中插入电池[36]。其次，与单步生成相比，轨迹生成可能减少协变量偏移误差。由于生成的是整个轨迹，执行长时间任务所需的连续决策步骤减少，从而降低了累积误差[36]。轨迹生成 DM 常见的动作空间是多个连续时间步的末端执行器位姿序列，再结合相机传感器的观察，便能够学习得到在局部环境中高效运作的策略。例如，当相机检测到一个待摘取的苹果时，假设动作由末端执行器生成，只要末端执行器与苹果之间的相对位置保持不变，机器人便可以仅依赖相对信息来调整其行为，从而适应动态环境的变化。这种基于相对信息的策略不仅简化了控制逻辑，还增强了系统对环境变化的鲁棒性[43]。然而，一些研究[43-45]指出，仅依赖最后一次观察的策略可能存在局限性。Shafiullah 等人[45]提出通过使用循环神经网络（Recurrent Neural Network, RNN）等模型，将策略建立在观察历史基础上是卓有成效的，这允许策略对无法从最近观察中提取的相关特征进行编码。

此外，部分研究者也关注到了 DM 与 RL 之间的适配性。例如，基于历史观察，Huang 等人[46]采用视频 DM 提取信息丰富的 RL 奖励。Hu 等人[47]则从历史观察和即时行为中提取视觉条件，再通过 RL 引入任务奖励作为未来指导，进一步增强了模型的时序推理能力。另外，Wang 等人[48]将 Q 学习引导融入 DM，Li 等人[49]将扩散策略梯度作为 RL 学习目标，Ajay 等人[50]采用未来回报监督 DM 的学习过程。这些研究都探索了通过 RL 训练 DM 的新范式。

1.2.2 结合专家演示的强化学习研究现状

作为解决顺序决策问题的流行方法，RL 通过试错机制学习在交互环境中执行一系列动作，以最大化期望奖励。然而，RL 算法通常需要大量的训练样本，导致样本复杂度极高。与从历史标记数据中学习的监督学习范式不同，典型的 RL 算法需要通过在实际环境中运行最新策略来收集交互数据。每当策略更新时，底层数据分布也会随之变化，因此必须重新运行策略以收集新的数据。此外，部署强化学习算法还面临多个耗时且需要领域专业知识的先决条件，例如状态估计、奖励函数设计以及每次交互后反复重置环境等，这些限制显著阻碍了机

中国知网 https://www.cnki.net

器人系统的自我改进能力。

然而，在许多领域，如自动驾驶[51]和机器人[52]，存在大量预先收集的多任务专家演示数据，这些数据可用于促进RL过程。利用演示数据的一个主要优势在于，它允许智能体从专家知识中学习，而无需通过探索来发现最优操作。这在复杂或动态环境中尤为有用，因为在这些环境中，试错学习的成本极高。演示数据可以通过多种方式加以利用，当智能体无法访问环境时（离线学习），可以从演示中学习策略、技能、奖励函数、状态表示甚至学习算法本身。而当智能体被允许与环境交互时（在线学习），演示数据可以作为经验回放、正则化约束、参考轨迹或课程学习的依据。

Kumar 等人[53]提出了保守的 Q 学习，学习策略值的下限，专注于仅使用离线数据学习策略，而不需要任何在线学习或在线微调。但这与标准监督方法相似的方式容易出现过拟合，并且由于演示状态和策略自身状态之间的分布变化，学习的策略也可能不是很强大。常见的改进做法有通过在线学习微调离线学习的策略[54]或者利用预训练的策略在在线规划期间生成潜在的动作候选[55]等。而在某些情况下，演示可能不是期望解决的完全相同的任务，但是这些任务可能共享相同的技能集。例如，制作咖啡和洗杯子都需要技能“拿起并放置杯子”，这里“技能”指的是许多任务之间共享的一些短视距策略。由于样本复杂度高、探索效率低等问题，学习复杂、长视距任务的RL策略非常具有挑战性，因此，一种自然的方法是从演示中学习一组技能，然后在下游任务中使用学习到的技能。Yang 等人[56]主要使用潜在变量模型学习技能，其中潜在变量将经验划分为技能，整个模型通过最大化经验的可能性来学习，在结构上类似于分层贝叶斯建模。Jiang 等人[57]则使用最大似然目标和对技能描述长度的惩罚的组合，这种惩罚从经验中激励技能最大限度地识别和提取公共结构。为了使用学习到的技能来促进在线 RL，Singh 等人[58]首先从多任务演示数据集中学习行为先验，该数据集本质上是一个可逆映射，它将噪声映射到有用的动作。在训练解决新任务时，智能体不是直接在原始马尔可夫过程中执行其动作，而是学习输出的策略，该策略由行为先验作为输入，然后在环境中执行来自行为先验的输出。假如演示数据集不仅包含专家演示轨迹，还包含智能体的整个再学习历史，例如 RL 智能体的整个回放缓冲区，Laskin 等人[59]提出了算法蒸馏的最新方法，能够直接从离线数据集学习 RL 算法。其首先训练 RL 算法的多个实例来解决各种任务并保存它们的学习历史，然后使用这个学习历史数据集，训练一个转换器模型来预测给定先前学习历史的动作。由于策略会随着时间的推移而改进，因此准确预测操作需要转换器对策略改进进行建模。当权重被冻结时，生成的网络可以探索、利用并最大化回报，使其能够学习RL算法本身。除了通过演示进行

中国知网 https://www.cnki.net

离线学习外，还可以在在线学习期间直接使用演示数据，而不需要之前的离线学习阶段。比较直接的一种方法是维护回放缓冲区[60]，并通过对从回放缓冲区样本的经验进行训练来优化策略。在这种方法中，只需将演示轨迹添加到回放缓冲区并照常运行策略，演示数据永远不会在回放缓冲区中被覆盖，确保它在整个训练过程中都可用，使得智能体在探索之前会暴露于更多样化的状态集。虽然这能提高样本效率，但往往存在不稳定性问题[61]。因此， Kang 等人[62]使用专家演示来指导强化学习中的探索，通过强制学习策略与演示之间的占用度量匹配，添加正则化项，激励智能体探索专家策略所演示的域。

另外，获得适合所需的奖励函数对于RL算法来说是非常困难的，构建特定任务的奖励函数可能不适用于难以估计对象状态或难以创建奖励函数的真实世界场景。而在奖励稀疏或不可用的情况下，可以使用演示来计算奖励。其中一种方法是基于演示直接定义奖励，如果只有一个或几个演示轨迹可用，则可以手动设计奖励函数来激励智能体跟踪演示轨迹，这通常是通过将奖励定义为当前状态和演示轨迹之间的某种距离来实现的。例如，Aytar等人[63]从演示轨迹中提取了一系列重要的检查点，如果智能体访问了检查点，则会获得奖励，当到检查点的距离小于阈值时就认为访问了该检查点，并且将距离定义为学习潜在空间中的余弦相似度。类似地，Smith等人[64]演示轨迹划分为多个阶段，并训练分类器来预测某个状态是否属于特定阶段。然后这些分类器可以组合成一个奖励函数。除了基于演示定义奖励外，另一种方法涉及允许智能体与环境交互，并尝试匹配智能体和演示轨迹的分布。在此过程中，智能体和演示轨迹之间的距离或差异可以转化为奖励，并用于改进智能体策略。这种方法构成了大多数逆RL方法的基础。逆RL方法通常涉及在奖励估计和RL之间交替的迭代过程，这可能导致较差的样本效率。Ho 等人[65]提出了对抗模仿学习方法，将奖励函数的学习与智能体的学习过程交织在一起。类似于生成对抗网络，其中一个生成器(策略)被训练来最大限度地混淆鉴别器(奖励)，而鉴别器本身被训练来区分智能体的状态-行动对和专家的状态-行动对。但这样的学习过程会导致不稳定的奖励，容易产生不稳定的训练。为了缓解非平稳奖励问题，Haldar 等人[66]采用了基于最优传输的奖励推理，试图找到一种方法，将一种分布转换为另一种给定成本函数，来计算智能体与专家轨迹之间的相似性，并以此作为奖励。

1.2.3 轨迹跟踪控制研究现状

机器人任务通常涉及机械臂末端执行器的运动轨迹，促使学者设计能够实现预定义轨迹跟踪的控制器。由于计算误差，从正运动学模型导出的雅可比矩阵可能与实际雅可比矩阵不同，此外，对于具有弹性元件的机械臂(例如，由主动刚性关节和可变形连杆组成的机械臂)，计算其准确的模型将是极其复杂和不

中国知网 https://www.cnki.net

准确的。即使对于传统的刚性连杆机械臂，通过标定和参数识别过程，获得系统的精确模型往往是费时费力。这都可能导致从仿真迁移到实际应用中的问题并降低解决方案的准确性。因此，如何在没有已知雅可比矩阵的情况下实现高精度跟踪控制具有重要意义。

单纯利用输入输出数据，模糊系统和神经网络（Neural Networks, NN）作为未知机器人模型的跟踪控制器，已广泛应用于解决由建模复杂性、计算不准确性和自然退化等因素引起的内部不确定性问题。例如，Zhou 等人[67]以及 Van 等人[68]分别探索了自适应模糊反步控制技术。前者将动力学模型划分为两个一阶子系统，而后者将模型内的不确定函数近似为整体避免了对动力学先验知识的需要。Zhao 等人[69]使用模糊系统来解决柔性机械臂中的不确定和连续控制问题。而 Sun 等人[70]提出了一种径向基函数 NN，用于估计未确定的动态函数。此外，Zhu 等人[71]专门为未知的机械臂开发了集成障碍 Lyapunov 函数的 NN 控制器，成功实现了全局稳定性。

近年来，由于 RNN 在处理时变问题和计算效率方面的优势，Zhang 等人[72]对一种创新的功率型变参数 RNN 进行了研究，旨在解决扰动时变问题，特别是在解决机械臂所面临的二次最小化和二次规划方面的问题。Shi 等人[73]采用即时离散化方法引入了离散时间 RNN，并成功应用于平面机器人。而 Zhang 等人[74]则提出了一种名为零化神经网络（Zeroing Neural Network, ZNN）的新型 RNN，专门针对包含多个状态变量的时变问题。而在应对复杂环境时，时间效率与鲁棒性同样至关重要。Jin 等人[75]为 ZNN 开发了一种新型激活函数，旨在实现固定时间收敛，并实际控制双臂机械臂完成跟踪任务。Dai 等人[76]提出了一种基于高阶模糊系统的自适应 ZNN 方法，该方法利用多个输入数据生成自适应因子，实现有限时间收敛。尽管大多数研究聚焦于动力学问题，但从运动学角度出发研究轨迹控制仍然存在一定的潜力。Chen 等人[77]基于 ZNN 首次提出了一种创新的雅可比矩阵自适应（Jacobian Matrix Adaption, JMA）方法。JMA 方法通过利用输入输出数据来估计操作臂的雅可比矩阵，从而实现无模型的运动学控制。在 JMA 方法作为连续模型的背景下，Yang 等人[78]通过离散化和近似公式将 JMA 模型离散化，以提高计算机操作的效率。此外，Tan 等人[79]中利用摄像头作为获取可测量末端执行器位置的方法之一，同时使用低通滤波器解决了不可测速度和加速度的挑战。然而，JMA 方法仍然存在两个不足之处：其一，收敛时间较长；其二，尚未解决对外部扰动的鲁棒性问题。

在控制理论中，超螺旋（Super Twisting, ST）算法是一种基于二阶滑模控制，能够同时提高收敛性和鲁棒性的技术。现有研究表明，ST 算法在应对建模误差及外部扰动时的鲁棒性，且无需事先估计即可有效抑制外部扰动。此外，

中国知网 https://www.cnki.net

ST 算法也能够有效减轻与一阶滑模控制相关的抖振现象[80-82]。Zhai 等人[81]提出一种 ST 观测器，用于实时评估关节的角速度及系统的集体扰动；Saied 等人[82]提出了一种鲁棒的前馈 ST 控制器，以应对不确定性和扰动，在控制并联机械臂方面取得了良好效果。另有 Li 等人[83]提出了一种多变量 ST 控制器，通过时间延迟估计方法确保操作臂的精确轨迹跟踪控制。基于上述研究，ST 算法为实现有限时间收敛和具备对内部不确定性与外部干扰的鲁棒性提供了一种可行的方法，尤其是在依赖模型信息的传统控制方法面临挑战时。

1.3 本文研究内容

基于上述研究，机械臂系统的具身智能实现一方面需要设计一种决策模型规划机械臂在复杂多样化任务中的动作序列或运动轨迹，另一方面又需要开发一种鲁棒的底层运动控制器使得机械臂能够精确不受干扰地执行既定动作序列或任务轨迹。鉴于 IL 和 RL 作为两种主流的策略学习框架各自具有独特的优势与局限性，本文创新性地提出了一种两阶段策略学习框架。该框架充分利用 DM 和参数高效微调技术的最新进展，有效整合了 IL 与 RL 的互补优势，首先通过专家演示数据获取基于 DM 的具有强大表征能力的初始策略，随后在任务环境中进行自主探索以微调优化策略，从而实现快速且安全的性能突破。又得益于 VLM 对任务理解程度的深化以及 MoE 对决策模型容量的扩展，该策略学习框架成功突破了传统方法局限于单任务学习的瓶颈，实现了向多任务学习领域的拓展。在底层控制器设计方面，本文通过将 ST 算法与 JMA 算法相结合，将时间导数和时间积分数据作为反馈信息，并将隐式且不可测量的数据转换为显式且可测量的数据，从而实现了对系统内部不确定性和外部扰动的双重处理。

本文主要贡献可以概括为：

（1）提出了一种两阶段的自适应扩散策略（Adaptive Diffusion Policy, ADP），该策略结合了 IL 和 RL 的优势。在第一阶段，机械臂在 IL 框架下通过历史观察模仿专家演示动作，利用 DM 构建其认知框架，从而学习完成任务所需的行为模式。在第二阶段，机械臂通过改进的多步 RL 进行自主实践以提升性能。在此过程中，通过引入并训练额外的高效参数微调模块，采用轻量化方法增强了对特定任务的适应性。通过系统的实验验证和消融研究，充分证实了所提方法相较于现有方法的显著优势。

（2）提出了自适应多任务扩散策略（Adaptive Multi-Task Diffusion Policy, AMTDP），将 VLM 和 MoE 集成到了 ADP 的两个学习阶段，又利用 VLM 为多样化的任务构建了通用的奖励函数，自动生成密集的奖励指导策略微调优化，将单任务策略 ADP 扩展为多任务策略。通过详实的实验验证和消融研究，充分证明了所提方法在多任务学习场景下的优越性能。

中国知网 https://www.cnki.net

（3）开发了一种基于 ST-JMA 方法的控制系统，成功解决了机械臂受扰跟踪控制问题。所提出的 ST-JMA 方法能够利用时间导数和时间积分数据，同时将隐式且不可测量的数据转换为显式且可测量的数据，从而克服了传统 JMA 方法中无法同时对抗内部不确定性和外部扰动的缺陷。通过对机械臂的全面理论分析和实际应用验证，ST-JMA 控制系统展现了其全局稳定性、有限时间收敛性以及鲁棒性，为相关控制问题提供了高效且可靠的解决方案。

1.4 本文组织结构

本文分为六个章节，各章安排如下：

第一章为绪论，首先阐述了本研究的背景与重要意义，继而系统性地介绍了具身智能中的扩散模型、结合专家演示的强化学习以及轨迹跟踪控制领域的研究现状与发展动态。最后概述了本文研究内容与组织结构。

第二章为相关理论基础，对本文所涉及的关键技术原理进行了系统性阐述，包括扩散模型中的去噪扩散概率模型、条件控制生成和快速采样方法；强化学习的基本概念及其核心方法，包括价值优化方法和策略优化方法；低秩适应模型、视觉语言模型、混合专家模型等基础模型；以及机械臂运动控制中的正运动学、逆运动学和轨迹跟踪控制。

第三章提出了 ADP，首先详细阐述了 ADP 的算法设计框架，该框架包含扩散策略预训练和强化学习微调两个阶段。在第一阶段，为实现过程的系统化建模，ADP 采用了模块化设计，主要由特征提取模块、条件控制模块和动作生成模块三个核心组件构成。在第二阶段，创新性地将参数高效微调模块作为残差组件嵌入到条件控制模块中，并通过设计的多步 RL 框架进行策略优化。通过详实的实验验证和消融研究，充分证实了所提方法相较于现有方法的显著优势。

第四章提出了 AMTDP，在 ADP 的基础上进行了多任务适配的扩展，包括将原有的两阶段训练框架调整为模型结构扩充后的 MoE 预训练阶段和 MoE 微调阶段，以及在多步 RL 框架中利用 VLM 奖励函数替代传统的人工设计奖励函数。通过系统的实验验证和消融研究，证明了所提方法在多任务学习场景下的优越性能。

第五章提出了 ST-JMA 算法，首先介绍了 ST-JMA 算法的整体设计过程，随后针对 ST-JMA 系统在有干扰和无干扰场景下的性能进行了理论证明。通过机械臂系统的仿真实验，验证了 ST-JMA 方法在有效性、鲁棒性以及对多种跟踪路径的适应性方面的突出表现。此外又通过实物机械臂的实际评估进一步证实了该方法的现实可实现性。

第六章为总结和展望，总结了本文研究的工作内容，并对研究中存在的不足之处进行了深入分析，同时提出了未来可能的改进方向和研究思路。

中国知网 https://www.cnki.net

论文结构如图 1.2 所示：

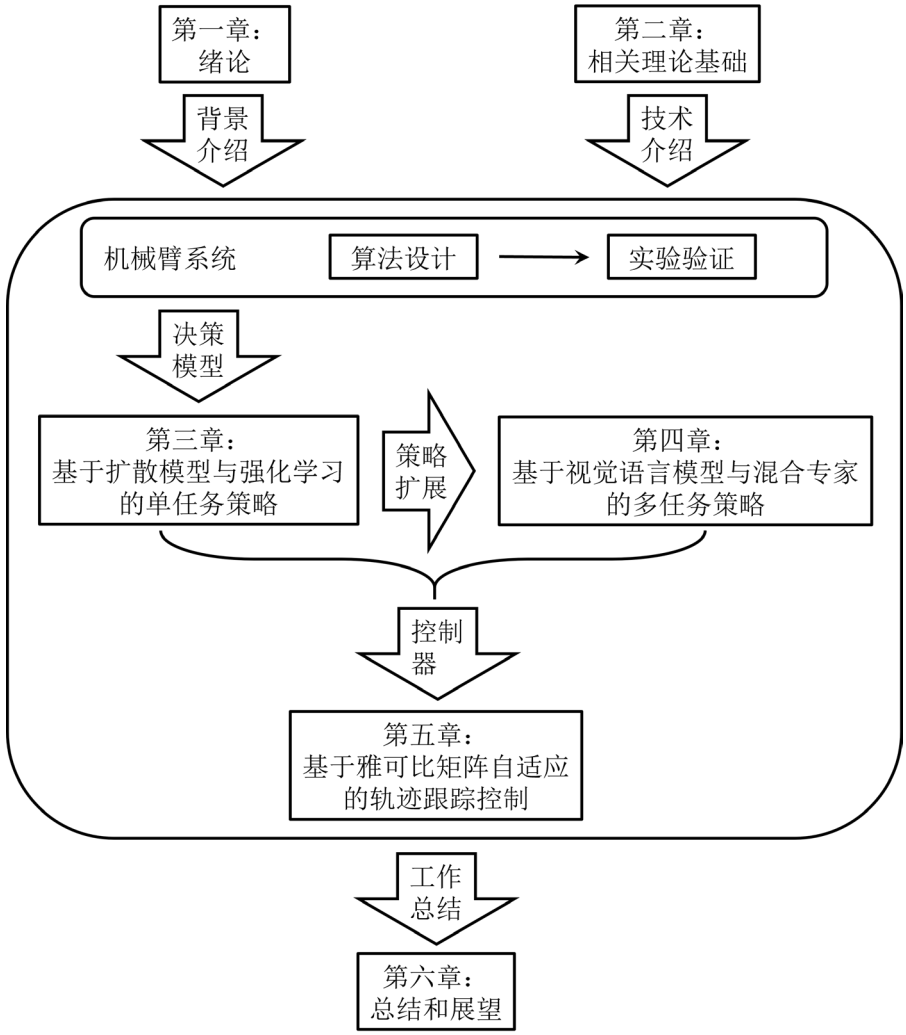


图 1.2 论文结构图

中国知网 https://www.cnki.net

第二章 相关理论基础

本章对本文所涉及的关键技术原理进行了阐述，包括扩散模型中的去噪扩散概率模型、条件控制生成和快速采样方法；强化学习的基本概念及其核心方法，包括价值优化方法和策略优化方法；低秩适应模型、视觉语言模型、混合专家模型等基础模型；以及机械臂运动控制中的正运动学、逆运动学和轨迹跟踪控制。

2.1 扩散模型

2.1.1 去噪扩散概率模型

扩散模型是一类概率生成模型，它通过注入噪声逐步破坏数据，然后学会反转这个过程以生成样本。扩散模型由一个前向过程和反向过程组成。在前向过程中，来自数据分布的干净样本被高斯随机噪声顺序破坏，在无限时间限制中，数据分布被转换为纯噪声。在反向过程中，训练去噪神经网络依次去除数据中添加的噪声分布，恢复新的干净数据分布。目前对扩散模型的研究主要有三个分支:去噪扩散概率模型(Denoising Diffusion Probabilistic Models, DDPM)、基于分数的生成模型和随机微分方程。这里主要介绍 DDPM 方法[84]。

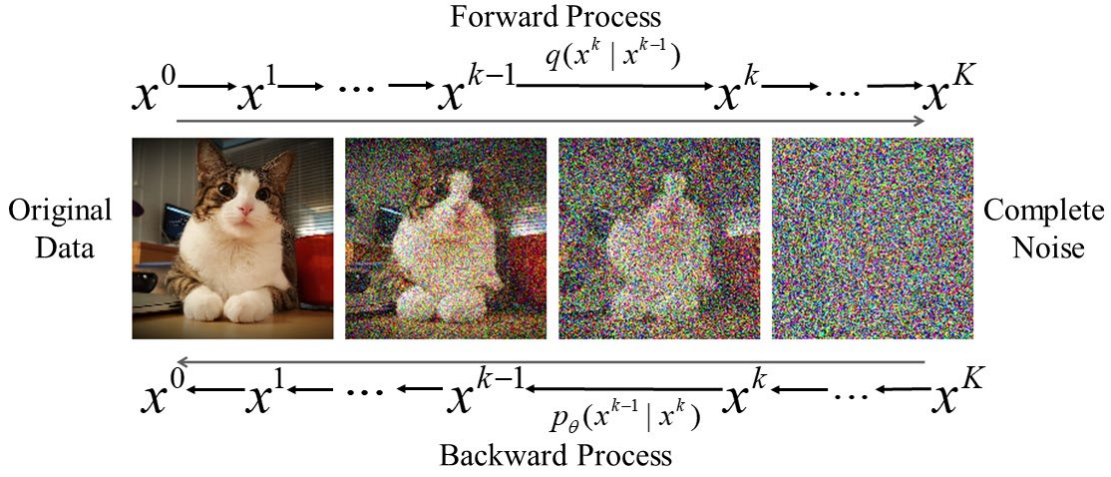


图 2.1 扩散模型的前向和反向过程[84]

如图 2.1 所示，DDPM 利用两个马尔可夫链：将原始数据逐步加噪转换到纯噪声的前向链，以及将噪声逐步去噪转换回数据的反向链。形式上，给定一个数据分布 $x^0 \sim q(x^0)$，通过转移核 $q(x^k \mid x^{k-1})$ 正向链生成一系列随机变量 $x^1, x^2 ... x^K$，利用概率链式法则和马尔可夫性质，可以将在条件 x^0 下的联合分布 $q(x^1, ..., x^K \mid x^0)$ 分解为：

中国知网 https://www.cnki.net

$$q(x^1,...,x^K \mid x^0)=\prod_{k=1}^{K} q(x^k \mid x^{k-1})。 \tag{2.1}$$

DDPM 中常人工设计转移核，以逐步将数据分布转换为可处理的先验分布。转移核的一种典型设计是高斯扰动 $\mathcal{N}(0,\mathbf{I})$ ，而最常见的转移核选择是：

$$q(x^k \mid x^{k-1})=\mathcal{N}(x^k;\sqrt{1-\beta_k}x^{k-1},\beta_k\mathbf{I})， \tag{2.2}$$

其中， $\beta_k \in (0,1)$ 是一个模型训练相关超参数，这种高斯转移核可以边缘化式(2.1)中的联合分布，从而获得 $q(x^k \mid x^0)$ 的解析形式，对于 $k \in \{0,1,...,K\}$ 都适用。具体地，定义:

$$\alpha_k = 1-\beta_k， \tag{2.3}$$

$$\bar{\alpha}_k = \prod_{i=0}^{k} \alpha_i， \tag{2.4}$$

可以得到：

$$q(x^k \mid x^0)=\mathcal{N}(x^k;\sqrt{\bar{\alpha}_k}x^0,(1-\bar{\alpha}_k)\mathbf{I})。 \tag{2.5}$$

给定 x_0，可以采样一个高斯向量 $\epsilon \in \mathcal{N}(0,\mathbf{I})$，并应用以下变换来获得 x_k：

$$x^k=\sqrt{\bar{\alpha}_k}x^0+\sqrt{1-\bar{\alpha}_k}\epsilon， \tag{2.6}$$

当 $\bar{\alpha}_K \approx 0$ 时， x^K 几乎就是高斯分布：

$$q(x^K)\approx\mathcal{N}(x^K;0,\mathbf{I})， \tag{2.7}$$

这一正向过程逐渐向数据注入噪声，直到所有结构信息都丧失。为了生成新的数据样本，DDPM 从先验分布中首先生成一个无结构的噪声向量，然后通过在反向时间方向上运行一个可学习的马尔可夫链，逐步去除其中的噪声。这个反向链由先验分布参数化：

$$p(x^K)=\mathcal{N}(x^K;0,\mathbf{I})， \tag{2.8}$$

并引入一个可学习的转移核 $p_\theta(x^{k-1} \mid x^k)$：

$$p_\theta(x^{k-1} \mid x^k)=\mathcal{N}(x^{k-1};\mu_\theta(x^k,k),\Sigma_\theta(x^k,k))， \tag{2.9}$$

其中， θ 为模型参数，均值 $\mu_\theta(x^k,k)$ 和方差 $\Sigma_\theta(x^k,k)$ 由神经网路参数化，通过这个反向链，可以采样噪声向量 $x^K \sim p(x^K)$，然后继续从学习得到的转移核进行迭代采样 $x^{k-1} \sim p_\theta(x^{k-1} \mid x^k)$ 直到 $k=1$，生成数据样本 x^0：

$$x^{k-1}=\frac{1}{\sqrt{\alpha_k}}\left(x^k-\frac{1-\alpha_k}{\sqrt{1-\bar{\alpha}_k}}\epsilon_\theta(x^k,k)\right)+\sigma_k\mathcal{N}\left(0,\mathbf{I}\right)， \tag{2.10}$$

其中， σ_k 为类似于 β_k 的超参数， ϵ_θ 是输入为 x_k,k 的去噪网络，预测添加到数据样本中的噪声， ϵ_θ 训练目标为：

$$\mathcal{L}=\mathbb{E}_{k,x^0,\epsilon}\left[\left\|\epsilon-\epsilon_\theta(\sqrt{\bar{\alpha}_k}x^0+\sqrt{1-\bar{\alpha}_k}\epsilon,k)\right\|^2\right]。 \tag{2.11}$$

中国知网 https://www.cnki.net

具体地，首先建立一个与 k 相关的噪声调度器来控制超参数 σ_k 和 β_k，随后去噪网络 ϵ_θ 的训练从数据集中随机选择无噪声数据 x^0 开始。对于每个样本，随机选择一个去噪迭代次数 k，然后为该迭代抽取具有适当方差的随机噪声 ϵ^k。ϵ_θ 的任务是预测添加到数据样本中的噪声。利用均方误差（Mean Squared Error, MSE），训练损失 $\mathcal{L}_\theta$ 可以表示为：

$$\mathcal{L}_\theta = \mathrm{MSE}(\epsilon^k, \epsilon_\theta(x^0 + \epsilon^k, k))。 \tag{2.12}$$

2.1.2 条件控制生成

扩散模型中的条件控制生成考虑的是从条件分布 $p(x|y)$ 中采样，其中 y 是生成样本的期望属性，条件控制主要有两类：分类器引导和无分类器引导。

分类器引导依赖于可微分的分类器模型 $p_\phi(y|x)$，具体来说，由于每个去噪步骤都需要执行指导，因此分类器模型 $p_\phi(y|x^k)$ 在噪声样本 x 和相应的属性 y 上进行训练，条件反向过程可以写成：

$$p_{\theta,\phi}(x^{k-1}|x^k, y) = Z p_\theta(x^{k-1}|x^k) p_\phi(y|x^{k-1}), \tag{2.13}$$

其中，Z 是归一化因子，上式可以被近似为:

$$p_{\theta,\phi}(x^{k-1}|x^k, y) = \mathcal{N}\left(\mu_k + \omega \Sigma_k \nabla_{x^k} \log p_\phi(y|x^k)|_{x^k=\mu_k}, \Sigma_k\right), \tag{2.14}$$

其中，ω 是控制条件强度的指导尺度，μ_k 和 Σ_k 分别是式 (2.9)中的均值和方差。

无分类器引导依赖于一个额外的条件噪声模型 $\epsilon_\theta(x^k, y, k)$，在实践中，条件模型和无条件模型共用一组参数，无条件模型通过将 y 设置为一个虚拟值来表示。然后将式 (2.11)中的噪声学习目标设定为 $p(x^k)$ 的一个缩放得分函数，即：

$$\epsilon_\theta(x^k, k) = -\sigma_k \nabla_{x^k} \log p(x^k), \tag{2.15}$$

其中，$\sigma_k = \sqrt{\beta_k}$，然后根据贝叶斯定理可以得到：

$$\nabla_{x^k} \log p(y|x^k) = -\frac{1}{\sigma_k}(\epsilon_\theta(x^k, y, k) - \epsilon_\theta(x^k, k)), \tag{2.16}$$

根据式 (2.14)可以得到条件控制去噪网络：

$$\overline{\epsilon}_\theta(x^k, y, k) = \epsilon_\theta(x^k, k) - \omega\sigma_k \nabla_{x^k} \log p(y|x^k), \tag{2.17}$$

即：

$$\hat{\epsilon}_\omega(x^k, y, k) = \omega\epsilon_\theta(x^k, y, k) + (1-\omega)\epsilon_\theta(x^k, k)。 \tag{2.18}$$

2.1.3 快速采样方法

扩散模型生成过程被认为是反向过程的近似，由于正向过程有 K 步，生成过程也必须进行 K 步采样，因此为了解决长时间迭代采样问题，许多加速采样过程并提高结果样本的质量的方法被提出，可以分为无学习和基于学习的方法。

中国知网 https://www.cnki.net

这里主要采用的是无学习方法。

DDIM(Denoising Diffusion Implicit Model)[85]是加速扩散模型采样最早工作之一。最初的动机是将原始 DDPM 扩展到非马尔可夫情况：

$$q(x^1,...,x^K \mid x^0)=\prod_{k=1}^{K} q(x^k \mid x^{k-1},x^0), \tag{2.19}$$

生成样本的式 (2.10)修改为：

$$x^{k-1}=\sqrt{\bar{\alpha}_{k-1}}\left(\frac{x^k-\sqrt{1-\bar{\alpha}_k}\epsilon_\theta(x^k,k)}{\sqrt{\bar{\alpha}_k}}\right)+\sqrt{1-\bar{\alpha}_{k-1}-{\sigma_k}^2}\epsilon_\theta(x^k,k)+\sigma_k\mathcal{N}(0,\mathbf{I}), \tag{2.20}$$

不同的σ_k值选择会导致不同的生成过程。由于去噪训练目标不依赖于具体的正向过程，因此可以将正向过程定义在部分潜变量$\{x^{\tau_1},...,x^{\tau_K}\}$而非所有潜变量$\{x^1,...,x^K\}$上，其中$\tau$是$[1,...,K]$的一个递增子序列，然后，生成过程可以根据$\tau$的反向序列采样潜变量，称之为采样轨迹。当采样轨迹的长度远小于 K 时，由于采样过程的迭代性质，可以显著提高计算效率。

2.2 强化学习

2.2.1 基本概念

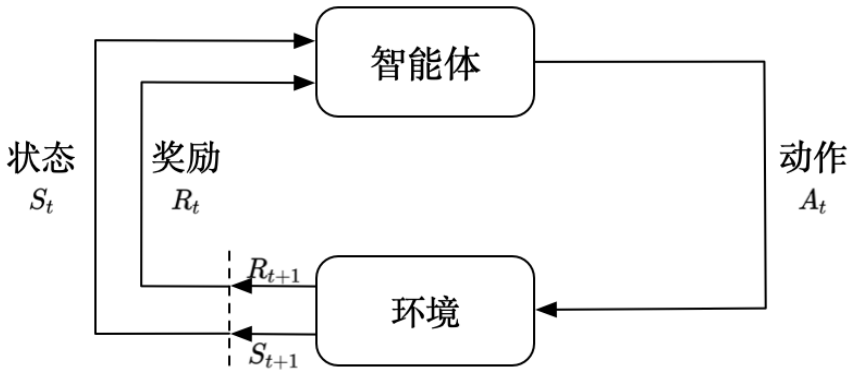


图 2.2 强化学习示意图

如图 2.2 所示，机器人的一个重要问题可以被定义为顺序决策过程，其中决策者被称为智能体，智能体存在的世界成为环境，环境的当前感知称为状态，智能体的策略可以根据状态计算出相应的动作与环境交互，但这些动作不会影响环境的运动学或动力学定律。奖励通常是人为定义的强化信号，当智能体做出的决定有利于任务完成时，获得正向奖励，反之则获得负向奖励。RL 算法的基本目标是确定一个策略以期望获得最大奖励或回报，并通过各种状态下的所有可能动作获得的先前奖励来更新智能体策略。如果随机过程的未来状态的条件概率分布仅取决于当前状态，则其具有马尔可夫性质。顺序决策过程可以形式化为马尔可夫决策过程 （Markov Decision Process, MDP）。MDP 可以用一个

中国知网 https://www.cnki.net

元组表示：

$$\mathrm{MDP}=(S,A,R,P,\gamma)\,, \tag{2.21}$$

其中，S 代表一组环境状态 $s\in S$；A 代表一组智能体根据状态做出的动作 $a(s)\in A$；R 是奖励函数，将每个状态-动作对映射到数字形式的奖励 $r=R(s,a)$；P 是状态转移函数，定义了状态 s 下做出动作 a 转换到下一个状态 s' 的概率 $p=P(s'|s,a)$；γ 是折扣因子，用作计算回报的权重，其中回报 G_t 是当前状态到终止状态的总折扣奖励，如下所示:

$$G_t=\sum_{k=0}^{\infty}\gamma^k r_{t+k}\,。 \tag{2.22}$$

通常RL算法使用估计的状态值函数$V(s)$和动作值函数$Q(s,a)$来确定代理处于特定状态或在该状态下执行动作的优势。价值函数在RL中基于预期的未来回报来估计最优策略。如果代理从状态 s 开始，然后遵循策略 π，则预期回报为 $V^{\pi}(s)$:

$$V^{\pi}(s)=\mathbb{E}_{\pi}[G_t\,|\,s_t=s]=\mathbb{E}_{\pi}[r_t+\gamma V^{\pi}(s_{t+1})\,|\,s_t=s]\,。 \tag{2.23}$$

如果代理从状态 s 开始执行一个动作 a，然后遵循策略 π，则预期回报为 $Q^{\pi}(s,a)$:

$$Q^{\pi}(s,a)=\mathbb{E}_{\pi}[G_t\,|\,s_t=s,a_t=a]=\mathbb{E}_{\pi}[r_t+\gamma Q^{\pi}(s_{t+1},a_{t+1})\,|\,s_t=s,a_t=a], \tag{2.24}$$

$V^{\pi}(s)$ 与 $Q^{\pi}(s,a)$ 之间的关系为：

$$V^{\pi}(s)=\sum_{a\in A}\pi(a\,|\,s)Q^{\pi}(s,a)\,, \tag{2.25}$$

$$Q^{\pi}(s,a)=R(s,a)+\gamma\sum_{s'\in S}P(s'\,|\,s,a)V^{\pi}(s')\,, \tag{2.26}$$

结合式 (2.25)和式 (2.26)可推导出贝尔曼期望方程：

$$V^{\pi}(s)=\sum_{a\in A}\pi(a\,|\,s)[R(s,a)+\gamma\sum_{s'\in S}P(s'\,|\,s,a)V^{\pi}(s')]\,, \tag{2.27}$$

$$Q^{\pi}(s,a)=R(s,a)+\gamma\sum_{s'\in S}P(s'\,|\,s,a)\sum_{a'\in A}\pi(a'\,|\,s')Q^{\pi}(s',a')\,, \tag{2.28}$$

表示当前状态和后续状态的值函数之间的递归关系。

RL 旨在通过与环境交互来确定 MDP 的最优策略$\pi*$，得到贝尔曼最优方程为：

$$V^{*}(s)=\max_{\pi}V^{\pi}(s)=\max_{a\in A}[R(s,a)+\gamma\sum_{s'\in S}P(s'\,|\,s,a)V^{*}(s')]\,, \tag{2.29}$$

$$Q^{*}(s,a)=\max_{\pi}Q^{\pi}(s,a)=R(s,a)+\gamma\sum_{s'\in S}P(s'\,|\,s,a)\max_{a'\in A}Q^{*}(s',a')\,。 \tag{2.30}$$

2.2.2 价值优化方法

求解值函数的方法有：动态规划（Dynamic Programming, DP）法，需要建立一个精确完整的环境模型；蒙特卡洛（Monte-Carlo, MC）法，基于模拟的估

中国知网 https://www.cnki.net

计统计数据，无需环境模型；以及时序差分（Temporal Difference, TD）法，是DP 与 MC 思想的结合，是各种 RL 算法的基础，无需环境模型，通过与环境的逐步交互来进行增量学习。TD 法更新V 值函数的方式为：

$$V(s_t) \leftarrow V(s_t) + \alpha[r_t + \gamma V(s_{t+1}) - V(s_t)], \tag{2.31}$$

其中，α 为学习率，$[r_t + \gamma V(s_{t+1}) - V(s_t)]$ 称为 TD 误差。同样可以用 TD 法估计Q 值函数：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]。 \tag{2.32}$$

Sarsa（State-Action-Reward-State-Action）算法便是基于式 (2.32)来更新 Q 值，并利用ε-贪婪策略：以$1-\varepsilon$概率执行 Q 值最大的当前最优动作，以概率ε执行 A 中的随机动作，$\varepsilon \in (0,1)$ 是一个超参数。另一个经典算法 Q-learning，其区别在于 TD 更新 Q 值函数方式为：

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]。 \tag{2.33}$$

但 Q-learning 需要建立状态动作表来获得$\max_a Q(s_{t+1}, a)$，表的大小随着状态和动作的数量呈指数增长，这使得其对于许多问题是不切实际的。DQN（Deep Q-Network）[86]利用神经网络对Q值进行函数拟合，即对于状态s下的合法动作a的Q值可以估计为$Q(s,a)$，该网络也称为Q网络。然而，使用神经网络来学习 Q 值的一个问题是更新规则取决于网络本身产生的值，这使得收敛变得困难。为此，DQN 引入了重放缓冲区和目标网络。重放缓冲区将过去的交互存储为元组列表，可以对其进行采样以更新值和策略网络。这允许网络多次从单个元组中学习，并减少对当前经验的依赖。目标网络是Q网络的时延副本，Q网络正常更新，而目标网络而是使用Q网络的较旧参数，只有每隔一定步数才与Q网络进行同步。DQN 的一个问题是它倾向于高估真正的奖励，从而导致Q值膨胀。Double DQN[87]将 Q 值估计中的最大操作分解为动作评估和动作选择。而 Dueling DQN[88]将Q值分解为值函数V和优势函数$\mathcal{A}$两个单独的分量来改进，其中$\mathcal{A}$被定义为Q值函数减去V值函数的结果：

$$\mathcal{A}(s,a) = Q(s,a) - V(s), \tag{2.34}$$

反映了采取特定动作 a 与其他动作相比的相对优势。为了实现这种分解，Dueling DQN 引入了具有两个输出的神经网络，一个用于V，一个为$\mathcal{A}$。然后，这些输出被组合以产生最终的Q值。前面介绍的RL算法都为价值优化方法，使用值函数来估计最优策略。

2.2.3 策略优化方法

策略优化方法直接估计最优动作策略，而不用估计值函数。值函数仍可用于优化策略权重参数，但不能用于选择不同的动作。

中国知网 https://www.cnki.net

在策略优化方法中，策略 π_θ 使用参数化函数 $\pi(a|s,\theta)$，并用一些标量性能度量 $J(\theta)$ 用于估计最优策略参数 θ，更新方式为：

$$\theta_{t+1}=\theta_t+\alpha\nabla_\theta J(\theta_t), \tag{2.35}$$

其中，$\nabla_\theta J(\theta_t)$ 是性能度量梯度，策略梯度为策略参数提供了一种分析方法：

$$\nabla_\theta J(\theta)\propto\sum_{s\in S}d^\pi(s)\sum_{a\in A}Q^\pi(s,a)\nabla_\theta\pi(a|s,\theta), \tag{2.36}$$

其中，d^π 为平稳状态分布：

$$d^\pi=\lim_{t\to\infty}P(s_t=s|s_0,\pi_\theta)。 \tag{2.37}$$

在经典 REINFORCE 算法[89]中，利用 MC 法估计 $Q^\pi(s,a)$，得到策略梯度：

$$\nabla_\theta J(\theta)=\mathbb{E}_\pi\left[\sum_{t=0}^{T}\left(\sum_{t'=t}^{T}\gamma^{t'-t}r_{t'}\right)\nabla_\theta\log\pi(a|s,\theta)\right], \tag{2.38}$$

其中，T 是最大交互次数。

但由于 MC 法高方差等问题，REINFORCE 收敛缓慢，因此演员-评论家（Actor-Critic）方法对值函数和策略都进行了近似，其中学习到的近似策略称为策略网络（Actor），学习到的近似值函数称为价值网络（Critic）。另外策略梯度法用梯度下降优化策略目标函数对学习率敏感。较小或较大的学习率可能会导致梯度消失或梯度爆炸问题。TRPO （Trust Region Policy Optimization）[90]算法将策略的优化限制在信任区域，该区域定义为函数的局部逼近是准确的区域，最大步长在其内确定。然后根据新近似策略执行的效果如何迭代地扩展或缩小信任区域，并使用新旧策略之间的 KL（Kullback-Leibler）散度作为变化的度量：

$$\begin{aligned}&\max_\theta\mathbb{E}_{s\sim d^{\pi_{\theta_k}}}\mathbb{E}_{a\sim\pi(\cdot|s,\theta_k)}\left[\frac{\pi(a|s,\theta)}{\pi(a|s,\theta_k)}\mathcal{A}^{\pi_{\theta_k}}(s,a)\right],\\&s.t.\ \mathbb{E}_{s\sim d^{\pi_{\theta_k}}}[D_{KL}(\pi(\cdot|s,\theta_k),\pi(\cdot|s,\theta))]\le\delta,\end{aligned} \tag{2.39}$$

其中，θ_k 表示第 k 次迭代之后的策略，D_{KL} 表示 KL 散度，δ 是一个常数，优势函数 $\mathcal{A}^{\pi_{\theta_k}}$ 可由广义优势估计等方法确定。PPO（Proximal Policy Optimization）[91] 算法旨在通过直接将约束纳入目标函数来解决 TRPO 的计算开销问题，以使用简单的随机梯度下降来优化目标函数。有 PPO 惩罚：

$$\arg\max_\theta\mathbb{E}_{s\sim d^{\pi_{\theta_k}}}\mathbb{E}_{a\sim\pi(\cdot|s,\theta_k)}\left[\frac{\pi(a|s,\theta)}{\pi(a|s,\theta_k)}\mathcal{A}^{\pi_{\theta_k}}(s,a)-\delta D_{KL}(\pi(\cdot|s,\theta_k),\pi(\cdot|s,\theta))\right], \tag{2.40}$$

和 PPO 截断：

$$\arg\max_\theta\mathbb{E}_{s\sim d^{\pi_{\theta_k}}}\mathbb{E}_{a\sim\pi(\cdot|s,\theta_k)}\left[\min\left(\frac{\pi(a|s,\theta)}{\pi(a|s,\theta_k)},\mathrm{clip}\left(\frac{\pi(a|s,\theta)}{\pi(a|s,\theta_k)},\varepsilon\right)\right)\mathcal{A}^{\pi_{\theta_k}}(s,a)\right], \tag{2.41}$$

中国知网 https://www.cnki.net

两种形式，其中 clip 为截断函数：

$$\mathrm{clip}(x,\varepsilon)=\max(\min(x,1+\varepsilon),1-\varepsilon)\text{。} \tag{2.42}$$

上述 TRPO 和 PPO 都是随机性策略，可以表示为 $a\sim\pi(\cdot|s,\theta)$，若策略是确定性的，则可以记为 $a=\pi(s,\theta)$，于是得到 DDPG（Deep Deterministic Policy Gradient）[92]算法：

$$\nabla_\theta J(\theta)=\mathbb{E}_{s\sim d^{\pi_h}}[\nabla_\theta\pi(s,\theta)\nabla_a Q(s,a)|_{a=\pi(s,\theta)}]\text{，} \tag{2.43}$$

其中，π_h 为收集数据的历史策略，此时 $\pi(s,\theta)$ 可视为策略网络，$Q(s,a)$ 可视为价值网络。

2.3 相关基础模型

2.3.1 低秩适应模型

大模型中的许多应用都依赖于将一个大规模、预训练的模型适应多个下游应用程序。这种适应通常是通过微调来完成的，常见的全参数微调更新预训练模型的所有参数，会导致巨大的重训练开销。低秩适应（Low-Rank Adaptation, LoRA）[93]是一种参数高效微调方法，最初是为适应大型语言模型提出的。

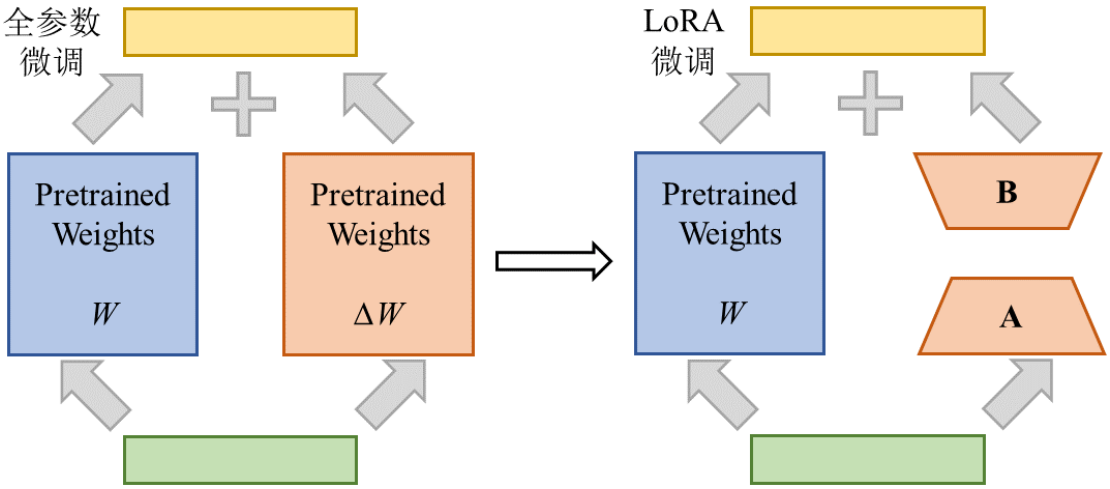


图 2.3 参数微调示意图

如图 2.3 所示，LoRA 将预训练权重 W 的更新限制在一个低秩矩阵 ΔW 内，并将其近似分解为两个较小矩阵 $\mathbf{A}$ 和 $\mathbf{B}$ 的乘积：

$$\widehat{W}=W+\Delta W=W+\mathbf{BA}\text{，} \tag{2.44}$$

其中，$\mathbf{A}\in\mathbb{R}^{\mathrm{rank}\times v}$，$\mathbf{B}\in\mathbb{R}^{u\times\mathrm{rank}}$，rank 为秩且 $\mathrm{rank}\ll\min(u,v)$。此外，$\mathbf{A}$ 以高斯随机噪声初始化，$\mathbf{B}$ 初始化为零。LoRA 使用较少的参数将模型适应到新的任务或领域，从而减少微调过程中计算成本和内存占用。

2.3.2 视觉语言模型

视觉语言模型（Vision Language Models, VLM）旨在预训练 VLM 来学习图

中国知网 https://www.cnki.net

像-文本相关性。给定图像文本对，VLM 首先通过文本编码器和图像编码器提取图像和文本特征，然后通过某些预训练损失函数学习视觉与语言之间的相关性，因此 VLM 可以通过匹配任意给定图像和文本的嵌入，在未见过的数据上以零样本方式进行评估。

VLM 模型在数据集 $\mathcal{D}=\{\mathrm{I}_i,\mathrm{T}_i\}_{i=1}^{\mathrm{N}}$ 中从 N 个图像-文本对中提取图像和文本特征，其中 I_i 和 T_i 分别表示图像样本和其配对的文本样本。VLM 模型包含一个图像编码器 f_{Img} 和一个文本编码器 f_{Txt}，分别将图像和文本编码为图像嵌入 $z_i^{\mathrm{Img}}=f_{\mathrm{Img}}(\mathrm{I}_i)$ 和文本嵌入 $z_i^{\mathrm{Txt}}=f_{\mathrm{Txt}}(\mathrm{T}_i)$。

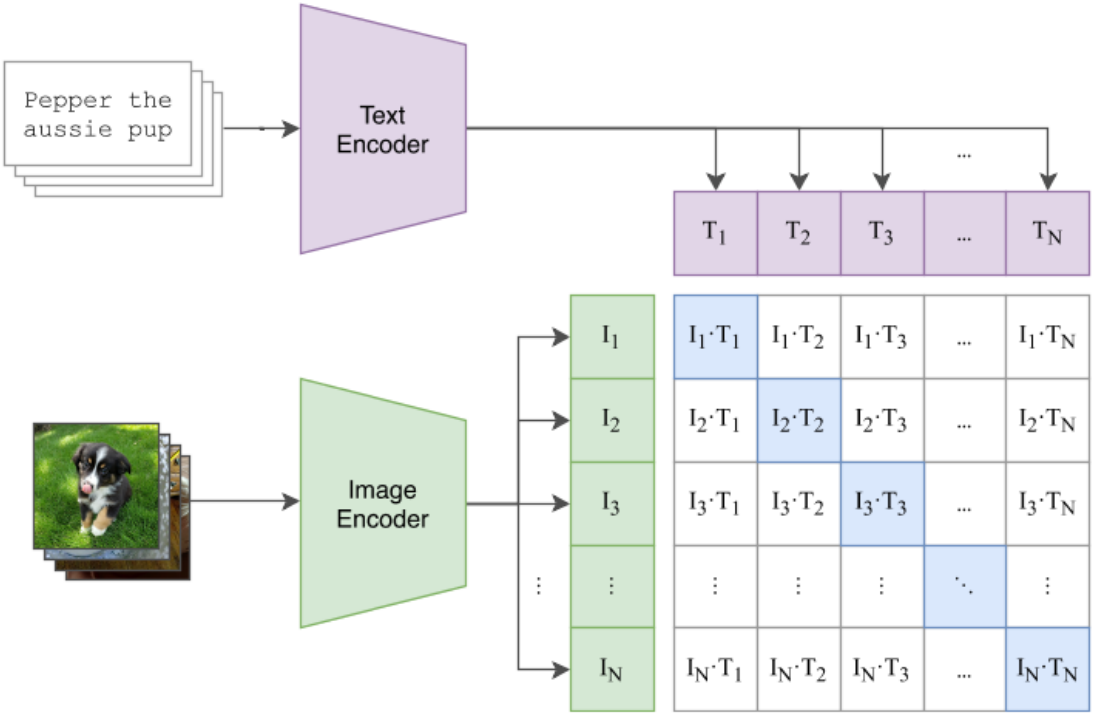


图 2.4 CLIP 模型示意图[94]

以 CLIP[94]为代表的 VLM 模型如图 2.4 所示，设计了对比学习损失函数，通过拉近配对样本、推远其他样本在特征空间中的距离来训练 VLM 学习判别性表示。这通常是通过最小化对称的图像-文本 InfoNCE 损失来实现的：

$$\mathcal{L}_{\mathrm{InfoNCE}}=\mathcal{L}_{\mathrm{Img}\to\mathrm{Txt}}+\mathcal{L}_{\mathrm{Txt}\to\mathrm{Img}}, \tag{2.45}$$

其中 $\mathcal{L}_{\mathrm{Img}\to\mathrm{Txt}}$ 通过将查询图像与文本键进行对比得到，$\mathcal{L}_{\mathrm{Txt}\to\mathrm{Img}}$ 通过将查询文本与图像键进行对比得到。给定一个包含 B 对图像-文本的批次，$\mathcal{L}_{\mathrm{Img}\to\mathrm{Txt}}$ 和 $\mathcal{L}_{\mathrm{Txt}\to\mathrm{Img}}$ 的定义如下：

$$\mathcal{L}_{\mathrm{Img}\to\mathrm{Txt}}=-\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(z_i^{\mathrm{Img}}\bullet z_i^{\mathrm{Txt}}/\tau)}{\sum_{j=1}^{B}\exp(z_i^{\mathrm{Img}}\bullet z_j^{\mathrm{Txt}}/\tau)}, \tag{2.46}$$

$$\mathcal{L}_{\mathrm{Txt}\to\mathrm{Img}}=-\frac{1}{B}\sum_{i=1}^{B}\log\frac{\exp(z_i^{\mathrm{Txt}}\bullet z_i^{\mathrm{Img}}/\tau)}{\sum_{j=1}^{B}\exp(z_i^{\mathrm{Txt}}\bullet z_j^{\mathrm{Img}}/\tau)}, \tag{2.47}$$

中国知网 https://www.cnki.net

其中 exp 为自然指数函数，τ 为温度超参数，用于控制 VLM 对差异的敏感度。

2.3.3 混合专家模型

混合专家（Mixture of Experts, MoE）模型基于一个简单而强大的思想：模型的不同部分，称为专家，专注于数据的不同任务或方面。在这一范式下，只有与给定输入相关的专家会被激活，从而在控制计算成本的同时，依然能利用来自大量专业知识的优势。这种可扩展且灵活的创新为遵循扩展法则提供了一种有效的方法，使得模型容量得以提升，而计算需求则不会相应激增。

每个 MoE 层通常由一组 L 个专家网络 $\{f_1,...,f_L\}$，每个专家网络 f_i 通常是一个具有 ReLU 激活函数的线性网络，和一个门控网络 $\mathcal{G}$ 组成，$\mathcal{G}$ 的作用是通过一个具有 Softmax 激活函数的线性网络，将输入引导到合适的专家网络。MoE 层的布置位置是经过精心设计的，例如在 Transformer 结构的模型中 MoE 通常位于前馈网络（Feedforward Network, FFN），以及位于自注意力层之后[95]。随着模型规模的扩大，前馈网络的计算需求会显著增加。

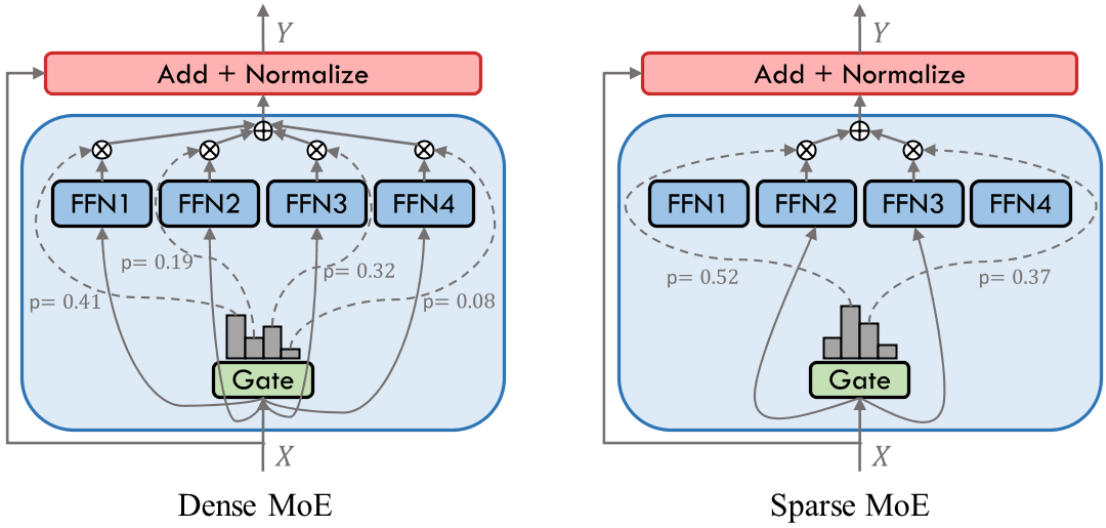


图 2.5 混合专家模型示意图[95]

如图 2.5 所示，根据门控函数的设计，MoE 层可以大致分为密集型 MoE 和稀疏型 MoE 两类。 密集型 MoE 的输出表示为：

$$\mathcal{F}^{\text{MoE}}(x)=\sum_{i=1}^{\text{L}}\mathcal{G}(x)_i f_i(x)\,, \tag{2.48}$$

$$\mathcal{G}(x)_i=\text{Softmax}(g(x))_i=\frac{\exp(g(x)_i)}{\sum_{j=1}^{L}\exp(g(x)_j)}\,, \tag{2.49}$$

其中，x 为输入，$g(x)$ 为 Softmax 操作之前的门控值。虽然专家的密集混合通常会产生更高的预测精度，但它也会导致计算开销显着增加。稀疏型 MoE 旨在在

中国知网 https://www.cnki.net

每次前向传递期间仅激活选定的专家子集。该策略通过计算仅前 K 位专家的输出的加权和来实现稀疏性，而不是聚合所有专家的输出：

$$\mathcal{G}(x)_i = \text{Softmax}(\text{TopK}(g(x)+\mathcal{R}_{\text{noise}},\text{K})_i\,, \tag{2.50}$$

$$\text{TopK}(g(x),\text{K})_i = \begin{cases} g(x)_i, & \text{if } g(x)_i \text{ is TopK of } g(x), \\ -\infty, & \text{otherwise}, \end{cases} \tag{2.51}$$

其中 TopK 函数保留向量中前 K 个元素的原始值，同时将其他所有元素设置为 $-\infty$。在经过 Softmax 操作后，这些被赋值为 $-\infty$ 的元素会近似为零。超参数 K 是根据具体应用选择的。在训练稀疏型 MoE 时，添加噪声项 $\mathcal{R}_{\text{noise}}$ 是一种常见的策略，这有助于促进专家之间的探索，并增强 MoE 训练的稳定性。

2.4 机械臂轨迹跟踪控制

2.4.1 正运动学

机械臂由一系列连接件组成，这些连接件通过旋转或滑动关节依次连接，从基座框架延伸至末端执行器。根据关节变量计算末端执行器的位置和姿态的过程称为正运动学。为了系统地进行机器人机构的正运动学分析，必须采用适当的运动学模型。常用的是 DH（Denavit-Hartenberg）方法，利用四个参数，包括连杆长度 a_{i-1}、连杆扭转角 α_{i-1}、连杆偏矩 d_i 和关节角 θ_i，在该方法中，每个关节都会附加一个坐标系，用以确定 DH 参数。

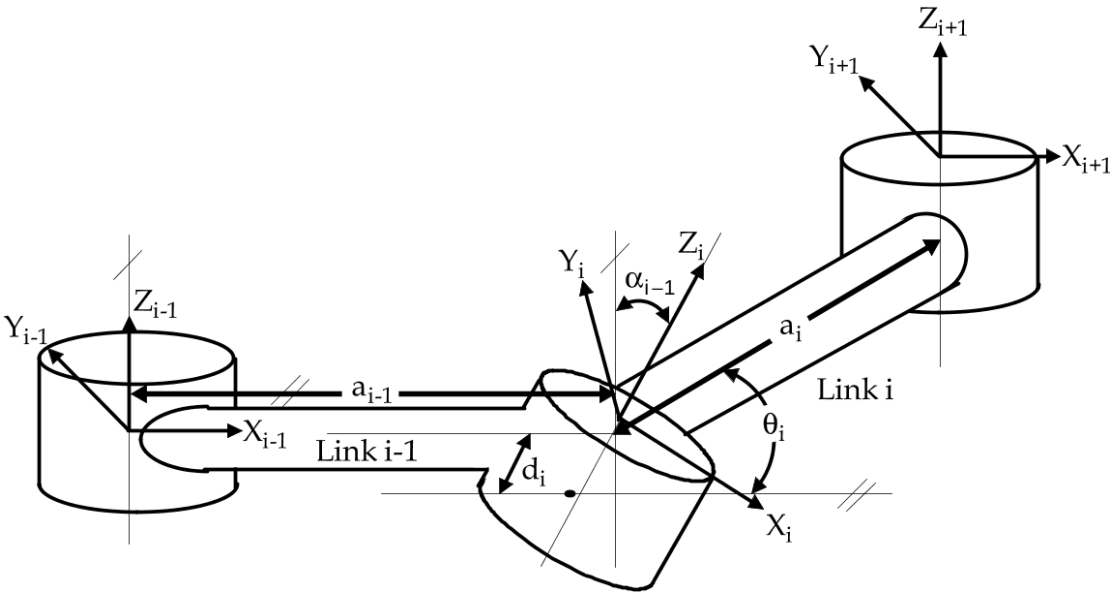


图 2.6 DH 模型坐标系示意图

如图 2.6 所示，坐标系的 Z_i 轴沿着关节的旋转或滑动方向指向，X_i 轴为 Z_{i-1} 和 Z_i 的公垂线，沿着 X_i 轴测量的从 Z_{i-1} 到 Z_i 的距离被定义为 a_{i-1}，沿着 X_i 轴测量的 Z_{i-1} 与 Z_i 之间的角度被定义为 α_{i-1}，沿着 Z_i 轴测量的从 X_{i-1} 到 X_i 的距

中国知网 https://www.cnki.net

离被定义为 d_i，而沿着 Z_i 轴测量的从 X_{i-1} 到 X_i 的角度被定义为 θ_i，单个连杆的一般变换矩阵 ${}^{i-1}_{i}T$ 可以按如下方式获得：

$$
\begin{aligned}
{}^{i-1}_{i}T &= \mathrm{Rot}_x(\alpha_{i-1})\mathrm{Trans}_x(a_{i-1})\mathrm{Rot}_z(\theta_i)\mathrm{Trans}_z(d_i) \\
&= \begin{bmatrix}
\cos\theta_i & -\sin\theta_i & 0 & a_{i-1} \\
\sin\theta_i\cos\alpha_{i-1} & \cos\theta_i\cos\alpha_{i-1} & -\sin\alpha_{i-1} & -\sin\alpha_{i-1}d_i \\
\sin\theta_i\sin\alpha_{i-1} & \cos\theta_i\sin\alpha_{i-1} & \cos\alpha_{i-1} & \cos\alpha_{i-1}d_i \\
0 & 0 & 0 & 1
\end{bmatrix},
\end{aligned} \tag{2.52}
$$

其中，Rot_x 和 Rot_z 表示旋转，Trans_x 和 Trans_z 表示平移，末端执行器相对于基座的正运动学是通过将所有的 ${}^{i-1}_{i}T$ 矩阵相乘来确定的：

$$
{}^{\text{base}}_{\text{end-effector}}T = {}^{\text{base}}_{1}T\,{}^{1}_{2}T\cdots{}^{\text{n-1}}_{\text{end-effector}}T = \begin{bmatrix}
r_{11} & r_{12} & r_{13} & p_x \\
r_{21} & r_{22} & r_{23} & p_y \\
r_{31} & r_{32} & r_{33} & p_z \\
0 & 0 & 0 & 1
\end{bmatrix}, \tag{2.53}
$$

其中，r_{ij}（i 和 j 均取值为 1、2 或 3）表示姿态矩阵的旋转元素，p_x、p_y 和 p_z 表示位置向量的元素。

2.4.2 逆运动学

机械臂执行的任务通常位于笛卡尔空间中，而执行器则在关节空间中工作。笛卡尔空间包括姿态矩阵和位置向量，而关节空间则由关节角表示。将机械臂末端执行器的位姿（位置和姿态）从笛卡尔空间转换到关节空间的过程被称为逆运动学。求解方法通常有两种：解析法和数值法。如果机械臂的运动学模型较为复杂，解析法可能无法提供解或解不唯一，因此常用数值法。数值法中的雅可比矩阵法提供了一种逆向运动学数值求解方法。通过从任意初始猜测开始，操控机械臂或其虚拟副本逐步移动到期望的配置，从而找到问题的唯一解。雅可比矩阵 $J \in \mathbb{R}^{m\times n}$ 是一个 $m\times n$ 的矩阵，其中 m 是末端执行器的自由度，而 n 是机械臂关节的自由度。在这种基于 J 的逆向运动学策略中，可以将执行器的限制条件融入到控制律中，从而确保机械臂轨迹始终是物理上可实现的。其思想是通过 J 描述末端执行器的位置和姿态与各关节角度之间的线性关系，将末端执行器的速度 $\dot{\mathbf{p}}$ 与关节速度 $\dot{\theta}$ 联系起来：

$$
\dot{\mathbf{p}} = J(\theta)\dot{\theta}, \tag{2.54}
$$

然后通过迭代地调整关节角度，使得末端执行器逐渐逼近目标位态：

$$
\theta = \theta + \Delta\theta = \theta + J^{\dagger}(\theta)\Delta\mathbf{p}, \tag{2.55}
$$

$$
J^{\dagger} = J^{\mathrm{T}}(JJ^{\mathrm{T}})^{-1}, \tag{2.56}
$$

其中 $\Delta\mathbf{p}$ 为位姿变化量，$\Delta\mathbf{p}$ 越小，关系越准确，J^{T} 为雅可比矩阵转置，$J^{\dagger}$ 为雅可比矩阵伪逆，确保了即使 J 不是方阵，依然可以进行有效的计算。

中国知网 https://www.cnki.net

2.4.3 轨迹跟踪控制

轨迹跟踪控制关注的是在给定末端执行器位置路径的基础上，寻求关节空间中关节状态向量的实时解。为了进一步说明，考虑下列公式，该公式展示了机械臂的正向运动学：

$$\mathrm{f}(\Theta(t)) = \mathbf{p}_{\mathrm{r}}(t)\,, \tag{2.57}$$

其中 $\mathrm{f}(\bullet):\mathbb{R}^n \to \mathbb{R}^m$ 表示正运动学映射，向量 $\Theta(t) \in \mathbb{R}^n$ 是时刻的关节状态量，$\mathbf{p}_{\mathrm{r}}(t)$ 是末端执行器的实时位置向量，为了确定可行的解，控制信号 $\Theta(t)$ 是通过跟踪预定义路径 $\mathbf{p}_{\mathrm{d}}(t)$ 获得的，因此：

$$\mathrm{f}(\Theta(t)) = \mathbf{p}_{\mathrm{r}}(t) \to \mathbf{p}_{\mathrm{d}}(t)\,。 \tag{2.58}$$

利用雅可比矩阵 J 可以得到：

$$J(\Theta(t))\dot{\Theta}(t) = \dot{\mathbf{p}}_{\mathrm{r}}(t) \to \dot{\mathbf{p}}_{\mathrm{d}}(t)\,, \tag{2.59}$$

$$J(\Theta(t)) = \frac{\partial \mathrm{f}(\Theta(t))}{\partial \Theta(t)}\,。 \tag{2.60}$$

传统控制系统，需要掌握详细的信息，包括机械臂的参数和结构，以计算实时雅可比矩阵。然而，不同机械臂的参数或结构可能存在差异，这导致传统控制系统在实际应用中的可转移性降低。此外，还需要考虑两个因素。首先，由于环境复杂多变，控制系统中普遍存在内部模型的不确定性，包括参数偏差等。此时的跟踪控制问题可表述为：

$$(J(\Theta(t)) + \Delta\varrho)\dot{\Theta}(t) = \dot{\mathbf{p}}_{\mathrm{r}}(t) \to \dot{\mathbf{p}}_{\mathrm{d}}(t)\,, \tag{2.61}$$

其中 $\Delta\varrho \in \mathbb{R}^{m\times n}$ 表示参数偏差，其次，控制系统不可避免地会遇到外部干扰，如偏移误差。更一般地，考虑到内部不确定性和外部干扰，跟踪控制问题可表述为：

$$(J(\Theta(t)) + \Delta\varrho)\dot{\Theta}(t) + \sigma = \dot{\mathbf{p}}_{\mathrm{r}}(t) \to \dot{\mathbf{p}}_{\mathrm{d}}(t)\,, \tag{2.62}$$

其中 $\sigma \in \mathbb{R}^m$ 表示外部扰动。

2.5 本章小结

本章介绍了相关领域的预备知识，包括扩散模型中的 DDPM 过程、条件控制生成原理、DDIM 快速采样方法，强化学习的基本概念以及 DDPG 等经典算法，LoRA 参数高效微调方法，VLM 中的 CLIP 模型，密集和稀疏型 MoE 结构，以及机械臂的正、逆运动学和轨迹跟踪控制原理，为后续章节展开奠定概念和理论基础。

中国知网 https://www.cnki.net

第三章 基于扩散模型与强化学习的单任务策略

RL 和 IL 已被证明是机械臂执行复杂任务时的有前景的智能控制方法，提供了有效的方法来使得机械臂学会广泛的运动技能，例如抓取、放置、按压等模仿人手功能的操作。扩散策略（Diffusion Policy, DP）[42]引入了一种新型的基于扩散模型的 IL 范式，通过基于图像的条件去噪过程在机械臂动作空间中生成动作序列。它不仅成功地扩展了输出维度而不损害模型的表现力，还展示了多模态的动作分布以及稳定的训练过程。尽管 DP 在模型输出阶段取得了显著进展，但在模型输入阶段仍有相当大的改进空间。3D 扩散策略（3D Diffusion Policy, DP3）[96]通过利用点云增强空间信息，从而实现更精确的操作，但仍忽视了对运动感知至关重要的时间信息。直观地说，当人们想要拿起桌上的苹果时依赖的是眼睛观察而非深度相机。借助运动先验信息，可以轻松判断手是否位于苹果的左侧或右侧，是否靠近或远离苹果。同时可以持续观察并将手移动到苹果附近，而不需要精确的距离信息。因此，这里假设图像可以提供足够的空间信息，结合来自视频的时间信息，就能够通过更简单的视觉传感器完成任务。

此外，单一的 IL 算法总是受到 IL 固有局限性的约束。IL 通过模仿专家获取完成特定任务的行为模式，这需要大量的高质量演示。而且，获得的策略只能近似专家策略，而无法超越它，且通常表现出有限的泛化能力。同时单一的 RL 算法通常从零开始并通过反复试验学习策略，这往往需要大量的采样交互，从而导致训练效率低下。同时，在初期阶段可能会出现潜在的安全隐患，例如严重的碰撞。受到残差 RL[97]启发，本章设计一种两阶段的训练框架期望结合 RL 和 IL 各自的优势，首先在 IL 框架中训练模型，随后通过参数高效微调方法在 RL 框架中对预训练策略进行进一步微调优化。

3.1 算法设计

机械臂智能体可以建模为一个将视觉观察 O 映射到末端执行器动作 A 的视觉驱动策略 $\pi: O \rightarrow A$，本章创新地提出了自适应扩散策略（Adaptive Diffusion Policy，ADP），总体结构如图 3.1 所示，中间灰色区域是 ADP 模型的核心，包括：特征提取模块（橙色），条件控制模块（蓝色）和动作生成模块（灰色）。此外，LoRA 模块（红色）在微调阶段集成至条件控制模块。ADP 的学习过程分为两个主要阶段以及一个过渡阶段。第一个主要阶段是扩散策略预训练阶段，在该阶段，机械臂智能体通过观察并模仿预先收集的专家轨迹来学习完成特定任务的行为模式，这些行为模式随后被存储在扩散模型中。基于预训练的扩散

中国知网 https://www.cnki.net

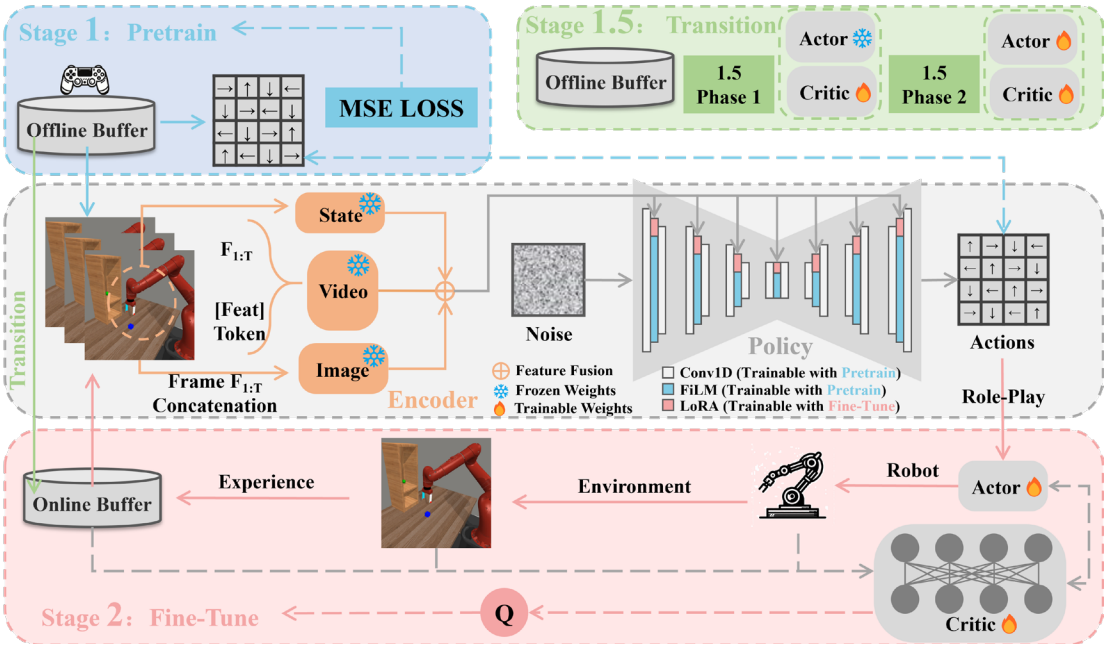


图 3.1 ADP 框架图

策略，机械臂已经能够根据视觉感知生成多样化的动作，以比较可观的成功率完成指定任务。第二个主要阶段是强化学习微调阶段，在该阶段，机械臂与环境进行交互，通过纠正视觉感知来优化策略，同时不改变从第一个阶段学习得到的扩散策略行为模式 。并且由于扩散策略依赖于随机过程，从而赋予其动作的多样性，添加一个固定的残差动作会削弱这种能力，因此创新型地选择将一个 LoRA 模块作为残差组件嵌入到策略中，通过设计的 RL 框架进行策略微调。

3.1.1 扩散策略预训练阶段

给定 t 时刻的观察范围为 T 的观察序列 $\{o_{t-T+1},....,o_{t-1},o_t\}$，其中 $o \in O$，ADP 的目标是预测接下来 N 步机器人的动作 $\{a_t,a_{t+1},....,a_{t+N-1}\}$，其中 $a \in A$。为简便起见，将观察和动作分别堆叠为 $\hat{o}_t$ 和 $\hat{a}_t$。为了建模这一过程，ADP 主要由三个模块组成：特征提取模块 $f_{\mathrm{E}}: O \to \mathcal{F}_O$，该模块从原始观察 O 中提取特征 $\mathcal{F}_O$；条件控制模块 $f_{\mathrm{C}}: \mathcal{F}_O \to \mathcal{F}_A$，该模块将观察特征 $\mathcal{F}_O$ 转换为动作特征 $\mathcal{F}_A$；以及动作生成模块 $f_{\mathrm{G}}: \mathcal{F}_A \to A$，该模块通过在动作特征条件的控制下去噪生成动作。

特征提取模块如图 3.2 所示，包含三种类型的编码器，每种编码器旨在处理不同的输入模态：状态、图像和视频。对于视频输入，考虑到 Mamba 结构在处理长序列时具有线性复杂度的优越性以及其在视觉任务中的成功应用，这里选择 VideoMamba 中的双向 Mamba (Bidirectional Mamba)作为视频编码器，以有效捕捉长时间范围的时序特征[98]。原始的 Mamba 模块设计用于处理一维序列，但在需要空间感知的视觉任务中表现不足。基于此，VisionMamba[99]首次引入了双向 Mamba 模块，该模块针对视觉应用适配了双向序列建模。该模块通过同时

中国知网 https://www.cnki.net

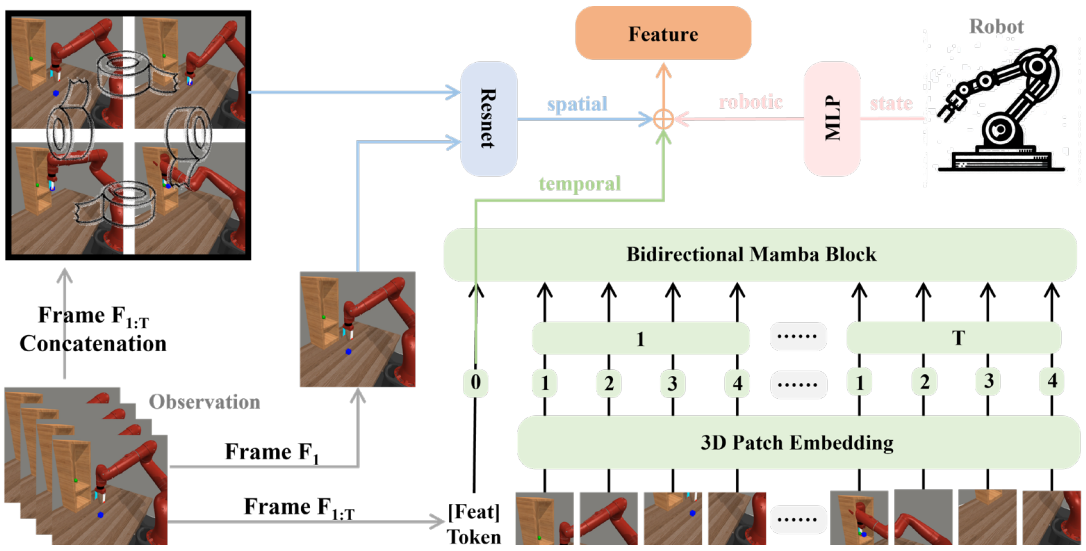


图 3.2 ADP 特征提取模块示意图

进行正向和反向的序列建模，处理展平后的视觉序列，从而增强了其空间感知处理能力。在 VideoMamba 中则将 双向 Mamba 模块扩展到视频理解领域。为了将该模块与 ADP 相适配，考虑一个包含 T 帧的视频片段 $\mathrm{F}_{1:T}$，先将 $\mathrm{F}_{1:T}$ 进行块分割，再使用三维卷积将 $\mathrm{F}_{1:T}$ 投影到非重叠的时空特征标记 X 上。借鉴 Vision Transformer 中的思想[100]，再将一个额外特征标记 X_{Feat} 附加到 X 之前，将 $[X_{\mathrm{Feat}}, X]$ 输入双向 Mamba 模块中输出特征向量，并只保留由 X_{Feat} 部分映射得到的特征向量作为视频特征 $\mathcal{F}_{\mathrm{Video}}$。对于图像输入，同样考虑 T 帧图像 $\mathrm{F}_{1:T}$，但处理包含两部分，一部分，将首帧图像 F_1 直接输入图像编码器 Resnet[101]中，得到图像特征 $\mathcal{F}_{\mathrm{Image1}}$；另一部分，受到上下文学习[102]思想的启发，将一组图像 $\mathrm{F}_{1:T}$ 拼接成一个大图像，可以是上下拼接，或者左右拼接，以及如图 3.2 所示的田字形拼接，同样输入图像编码器 Resnet 中，得到图像特征 $\mathcal{F}_{\mathrm{Image2}}$。对于状态输入，其中状态指的是与机械臂相关的信息向量，包括 T 时间范围内的末端执行器的位姿等，将其输入状态编码器多层感知机（Multilayer Perceptron, MLP）模型中，输出状态特征 $\mathcal{F}_{\mathrm{State}}$。这些特征向量被连接（$\oplus$）在一起以增强时空信息感知：

$$\mathcal{F}_O = \mathcal{F}_{\mathrm{Video}} \oplus \mathcal{F}_{\mathrm{Image1}} \oplus \mathcal{F}_{\mathrm{Image2}} \oplus \mathcal{F}_{\mathrm{State}}, \tag{3.1}$$

上述编码器的参数在初始化后被冻结，确保在训练过程中不会被更新。

在条件控制模块中，则采用特征线性调制（Feature-wise Linear Modulation，FiLM）模型[103]，在动作生成模块的每个卷积层上逐通道应用。具体来说，FiLM 使用 MLP 模型 $f_{i,j}$ 来生成控制系数 $d_{i,j}$ 和 $h_{i,j}$，输入为 $\mathcal{F}_O$：

$$(d_{i,j}, h_{i,j}) = f_{i,j}(\mathcal{F}_O), \tag{3.2}$$

其中，$d_{i,j}$ 和 $h_{i,j}$ 通过仿射变换调节卷积层的动作嵌入 $x_{i,j}$，下标 i 表示第 i 层，下标 j 表示第 j 通道：

$$\mathcal{F}_{A_{i,j}} = \mathrm{FiLM}(x_{i,j} \mid d_{i,j}, h_{i,j}) = d_{i,j} \bullet x_{i,j} + h_{i,j}, \tag{3.3}$$

中国知网 https://www.cnki.net

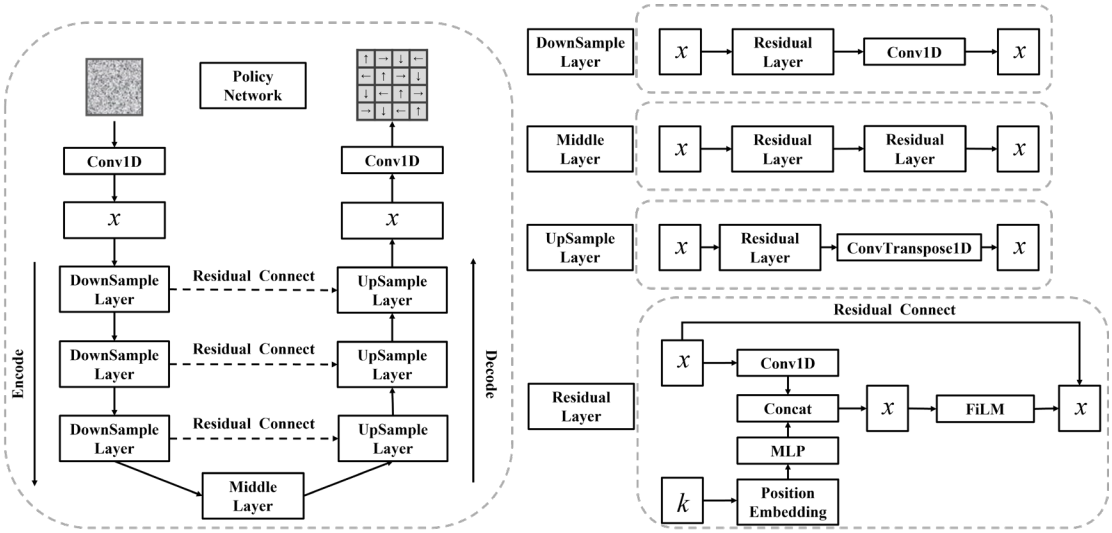


图 3.3 ADP 动作生成模块示意图

动作生成模块如图 3.3 所示，主体是一个编码-解码的 U-Net 结构[104]网络，包含下采样层，由残差层和一维卷积层组成；中间层，由两个残差层组成；上采样层，由残差层和转置一维卷积层组成。条件控制模块 FiLM 结合应用在残差层结构中。与常见的文生图等扩散模型采用二维卷积层不同，由于 ADP 生成是一维的动作向量，因此采用的是一维卷积层。

第一阶段开始训练前，需要先获取所需完成任务的专家演示数据集 B，其是由手动遥控或自动脚本等方法控制机械臂完成指定任务的专家运动轨迹组成，是一系列的状态-动作元组对，定义为 $\{(\hat{o}_t,\hat{a}_t)\}$，其中，观察 $\hat{o}_t$ 包括任务场景的视觉信息：由眼在手外相机拍摄的 RGB 图片; 以及机械臂的本体信息：由末端执行器在三维空间中的位姿组成的一维向量。动作 $\hat{a}_t$ 也是一个一维向量，包括机械臂末端执行器的功能动作以及其在三维空间中的位姿变化。

利用数据集 B，ADP 的预训练过程可以表述为由观察 $\hat{o}_t$ 条件控制的 DDPM 模型，并相应地修改去噪过程式 (2.10)，如下所示：

$$\hat{a}_t^{k-1}=\frac{1}{\sqrt{\alpha_k}}\left(\hat{a}_t^k-\frac{1-\alpha_k}{\sqrt{1-\bar{\alpha}_k}}\epsilon_\theta(\hat{o}_t,\hat{a}_t^k,k)\right)+\sigma_k\mathcal{N}(0,\mathbf{I}), \tag{3.4}$$

相应地，训练的损失函数式 (2.12)修改为：

$$\mathcal{L}_\theta=\mathrm{MSE}(\epsilon^k,\epsilon_\theta(\hat{o}_t,\hat{a}_t^0+\epsilon^k,k)), \tag{3.5}$$

第一阶段训练结束可以得到预训练策略 ADP-I π_θ，并在推理阶段采用 DDIM 算法加快推理速度。

3.1.2 强化学习微调阶段

第二阶段通过设计的 RL 框架在 ADP-I π_θ 的基础上微调得到自适应策略 ADP-II。虽然扩散策略能够生成朝向同一目标的多样化动作序列，但在每次执

中国知网 https://www.cnki.net

行过程中，可以通过 DDIM 快速采样执行一个确定性的动作序列，而不是对学习到的轨迹进行平均。因此，改进了多步 DDPG 算法[105]作为 RL 框架，ADP 作为 Actor 网络，MLP 作为 Critic 网络。在第一阶段模仿专家演示之后，ADP-I 已经学习到了运动先验和行为模式，从而降低了机械臂执行极端或危险动作的可能性。为了确保在安全探索过程中运动先验保持不变，选择将 LoRA 模块ϕ添加到与视觉条件控制相关的 FiLM 层中以增强机械臂的自适应视觉感知能力，同时保持动作生成策略网络不变，使得$\pi_\theta \to \pi_{\theta\cup\phi}$，其中$\phi$参数是可训练的，而$\theta$参数被冻结。

第二阶段开始训练之前，还需要考虑一个问题。由于 ADP-II 是一个建立在初始策略输出基础上残差策略，而像 DDPG 这样的演员-评论家方法不仅包括可以经过预训练得到的 Actor 网络，还包括需要从零训练的 Critic 网络。如果从一个完美的初始 Actor 网络开始，但 Critic 网络是性能较差的随机初始化网络，同样会导致 Actor 网络性能的灾难性退化，因为 Actor 网络是基于 Critic 网络的评估进行训练的。因此，在两个主要阶段之间又增加了一个过渡阶段。

过渡阶段的训练重复利用第一阶段中的专家演示$\{(\hat{o}_t,\hat{a}_t)\}$，结合根据指定任务人工设计的奖励函数 R 得到$r_{t:t+N-1}=R(\hat{o}_t,\hat{a}_t)$，以及经过机械臂 N 步动作$\hat{a}_t$与环境的交互之后获得新的观察$\hat{o}_{t+N}$，于是创建得到一个由当前观察-动作-奖励-下一观察元组$\{(\hat{o}_t,\hat{a}_t,r_{t:t+N-1},\hat{o}_{t+N})\}$组成的离线回放缓冲区$\mathcal{D}_{\text{off}}$。然后开始过渡阶段训练，此阶段也分为两部分，其中第一部分，对于每一步训练步，都从回放缓冲区$\mathcal{D}=\mathcal{D}_{\text{off}}$进行批次大小为 b 的批量数据采样$\tau=\{(\hat{o}_t,\hat{a}_t,r_{t:t+N-1},\hat{o}_{t+N})_i\}_{i=1,\ldots,b}$，用来更新随机初始化的Critic网络且保持Actor网络$\pi_{\theta\cup\phi}$不变。Critic网络更新的损失函数为：

$$\mathcal{L}_{\text{critic}}=\mathbb{E}_{\tau\sim\mathcal{D}}\left[\left(Q(\hat{o}_t,\hat{a}_t)-e\right)^2\right], \tag{3.6}$$

其中Q即是 Critic 网络，输出是一个标量值，e为折扣因子是γ的 N 步时序差分误差：

$$e=\sum_{i=0}^{N-1}\gamma^i r_{t+i}+\gamma^N Q(\hat{o}_{t+N},\pi_{\theta\cup\phi}(\hat{o}_{t+N}))。 \tag{3.7}$$

第二部分则开始更新 Actor 网络$\pi_{\theta\cup\phi}$中的 LoRA 模块ϕ，值得注意的是，由于在扩散模型的去噪过程中已经注入了随机高斯噪声，因此不需要像传统 DDPG 算法那样在策略探索过程中再向策略中添加额外的噪声。此外，受 TD3-BC[106]算法的启发，将行为克隆正则化项融入到传统DDPG的Actor网络损失函数中，使得策略偏向于产生回放缓冲区$\mathcal{D}$中呈现的动作，抑制策略发生剧烈的变化，这对于微调预训练模型的训练效果至关重要，同样采样自$\mathcal{D}=\mathcal{D}_{\text{off}}$，

中国知网 https://www.cnki.net

Actor网络更新的损失函数如下：

$$\mathcal{L}_{\text{actor}} = -\mathbb{E}_{(\hat{o}_t,\hat{a}_t)\sim\mathcal{D}}\left[\rho Q(\hat{o}_t,\pi_{\theta\cup\phi}(\hat{o}_t)) - (\pi_{\theta\cup\phi}(\hat{o}_t)-\hat{a}_t)^2\right], \tag{3.8}$$

其中$(\pi_{\theta\cup\phi}(\hat{o}_t)-\hat{a}_t)^2$即是行为克隆正则项，而$\rho$是一个正则化参数，形式如下所示：

$$\rho = \frac{\eta}{\frac{1}{b}\sum_{(\hat{o}_t,\hat{a}_t)}\left|Q(\hat{o}_t,\hat{a}_t)\right|}, \tag{3.9}$$

其中η是一个调节约束强度的超参数。ρ是一个基于 Q 的平均绝对值的归一化项。实际上，这是通过批量数据 b 来估计这个均值项，而不是使用整个数据集。尽管这个项包含 Q，但它并不需要求导，且仅用于缩放损失。该正则项的一个附加好处是，它能够在不同任务之间归一化学习率，因为 Q 的梯度也将依赖于Q的尺度大小。

经过过渡阶段之后，进入正式的强化学习微调阶段。此阶段仍然保留了离线回放缓冲区$\mathcal{D}_{\text{off}}$，同时设置了一个在线回放缓冲区$\mathcal{D}_{\text{on}}$，并初始化为空。整体训练过程与过渡阶段的第二部分类似，区别在于首先增加了与环境交互的过程，在最大环境交互步数内，每一时间步$\pi_{\theta\cup\phi}$根据$\hat{o}_t$生成动作$\hat{a}_t$，与环境交互后环境状态也发生了改变得到$\hat{o}_{t+N}$，同时可以根据人工设计的奖励函数 R 的得到$r_{t:t+N-1}$。随后将交互得到的新样本$(\hat{o}_t,\hat{a}_t,r_{t:t+N-1},\hat{o}_{t+N})$添加至$\mathcal{D}_{\text{on}}$，此时总的回放缓冲区也得到了更新$\mathcal{D}=\mathcal{D}_{\text{off}}\cup\mathcal{D}_{\text{on}}$，该阶段的 b 批次训练样本τ也采样自$\mathcal{D}$，而不单局限于离线样本。

此外为了促进训练过程的稳定性，还采用了一些RL中常用的技巧。一是，由于 DQN，DDPG 等算法的 Critic 网络都倾向于高估 Q 值，ADP 的 Critic 网络采用了两个独立的 Q 网络Q_1和Q_2，结果取两者间的较小值，即：

$$Q(\hat{o}_t,\hat{a}_t) = \min\left(Q_1(\hat{o}_t,\hat{a}_t),Q_2(\hat{o}_t,\hat{a}_t)\right), \tag{3.10}$$

二是采用了延迟学习，因为 Critic 网络对于 Actor 网络的学习有较大影响，所以设定 Critic 网络的更新频率要高于 Actor 网络，例如每更新两次 Critic 网络，才进行一次 Actor 网络更新。三是在更新 Critic 网络时进行动作平滑正则化，将式(3.7)修改为：

$$e = \sum_{i=0}^{N-1}\gamma^i r_{t+i} + \gamma^N Q\left(\hat{o}_{t+N},\text{clip}\left(\pi_{\theta\cup\phi}(\hat{o}_{t+N})+\varphi,\varepsilon\right)\right), \tag{3.11}$$

其中φ是一个随机值，$\text{clip}(\bullet,\varepsilon)$是式 (2.42)提到的截断函数，使得更新 Critic 网络的策略动作在一定范围内随机，目的是缓解 Q 网络的波动性。四是采用了软更新的参数更新策略，如下所示：

$$\omega = \upsilon\omega' + (1-\upsilon)\omega, \tag{3.12}$$

其中ω是需要更新的模型参数，$\upsilon\in(0,1)$是控制更新幅度的超参数。

中国知网 https://www.cnki.net

完整的 ADP 微调过程如伪代码算法 1 所示：

算法 1：ADP 微调阶段

初始化：

超参数：T, N, b, γ, η

预训练的 Actor 网络 ADP-I π_θ

离线回放缓冲区 $\{(\hat{o}_t, \hat{a}_t, r_{t:t+N-1}, \hat{o}_{t+N})\} \in \mathcal{D}_{\text{off}}$

在线回放缓冲区 $\mathcal{D}_{\text{on}} = \varnothing$

低秩适应矩阵 **A** 和 **B**，LoRA 模块参数 $\phi = \mathbf{BA}$

随机初始化的 Critic 网络 Q

训练阶段：

过渡阶段部分一：

回放缓冲区 $\mathcal{D} = \mathcal{D}_{\text{off}}$，标志 actor_flag=False, online_flag=False

过渡阶段部分二：

回放缓冲区 $\mathcal{D} = \mathcal{D}_{\text{off}}$，标志 actor_flag=True, online_flag=False

强化学习微调阶段:

回放缓冲区 $\mathcal{D} = \mathcal{D}_{\text{off}} \cup \mathcal{D}_{\text{on}}$，标志 actor_flag=True, online_flag=True

训练过程：

for epoch **do**

  任务环境重置

  for environment timestep *t* **do**

    if online_flag == True **then**

      $\hat{a}_t = \pi_{\theta \cup \phi}(\hat{o}_t)$

      $r_{t:t+N-1} = R(\hat{o}_t, \hat{a}_t)$

      $\hat{o}_{t+N} = \text{env.step}(\hat{a}_t)$

      $\mathcal{D}_{\text{on}}.\text{append}((\hat{o}_t, \hat{a}_t, r_{t:t+N-1}, \hat{o}_{t+N}))$

    end if

    $\tau = \left\{(\hat{o}_t, \hat{a}_t, r_{t:t+N-1}, \hat{o}_{t+N})_i\right\}_{i=1,\ldots,b} \sim \mathcal{D}$

    根据更新频率通过式 (3.6)软更新 Critic 网络 Q

    if actor_flag == True **then**

      根据更新频率通过式 (3.8)软更新 Actor 网络 $\phi \rightarrow \pi_{\theta \cup \phi}$

    end if

  end for

end for

中国知网 https://www.cnki.net

3.2 实验分析

3.2.1 数据集介绍

数据集从 3 中不同的仿真环境中收集了 56 个任务，涵盖了各种机械臂技能，任务范围从简单的夹爪夹取操作到具有挑战性的灵巧手操作等。部分任务演示如图 3.4 所示：

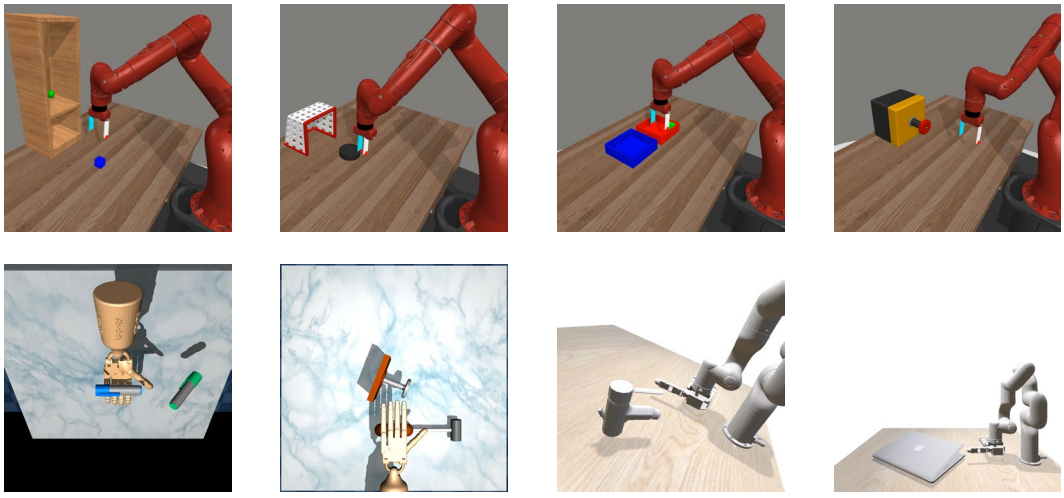


图 3.4 数据集部分任务环境示意图

这些任务分别来自 MetaWorld [107]，Adroit[108]和 DexArt[109]数据集，具体信息如下表所示：

表 3.1 数据集信息

数据集	末端执行器	动作维度	任务数量	演示数量
MetaWorld	夹爪	4	50	10
Adroit	灵巧手	28	3	10
DexArt	灵巧手	22	3	10

3.2.2 实验设置

本章实验的配置环境如下表所示：

表 3.2 实验配置环境

条目	配置
操作系统	Ubuntu 20.04
CPU	Intel i7-7800X
GPU	NVIDIA GeForce RTX 2080 Ti

尽管 ADP 包含较多模块设计，且存在多个训练阶段，引入了较多的超参数，但大部分超参数都是任务无关的，为了体现 ADP 方法应用的灵活性，在 MetaWorld，Adroit 和 DexArt 任务中都采用同一套主要超参数表。主要超参数

中国知网 https://www.cnki.net

如下表所示：

表 3.3 ADP 实验主要超参数表

超参数	设置
T	4
N	8
Image Size	84×84
b	256
γ	0.99
η	2
LoRA rank	16
υ	0.01
Critic Update Frequency	1
Actor Update Frequency	0.5

对于 ADP 训练所需的专家演示，这里与 DP3[96]中的获取方法一致，其中 MetaWorld 环境采用自动脚本收集成功演示，Adroit 环境采用训练好的 VRL3[110] 智能体收集成功演示，DexArt 环境采用训练好的 PPO[91]智能体收集成功演示。且每个任务都只收集 10 条演示。

对于评估指标，每一个实验运行三个种子（0，1，2），训练之后在 100 个随机的测试环境中测试，计算任务成功率，并记录三个种子成功率的平均值（mean）和标准差（standard deviation, std），并以 mean±std 的形式表示结果。

3.2.3 对比实验

首先为了体现基于扩散模型的 IL 算法相较于传统 IL 算法的优越性，选取了 9 个任务，将 ADP 与 IBC[111]和 BCRNN[112]以及对应的 3D 变体算法进行对比评估。结果如表 3.4 所示，可以看出 ADP 显著优于传统 IL 算法。

表 3.4 ADP 与传统 IL 算法对比实验结果

（A 表示 Assembly 任务，DA 表示 Disassemble 任务，S-P 表示 Stick-Push 任务）

Task / Algorithm	MetaWorld			Adroit			DexArt		
	A	DA	S-P	Hammer	Door	Pen	Laptop	Faucet	Toilet
ADP (Ours)	**91**±5	**93**±6	**79**±4	**90**±2	**75**±6	**87**±3	**89**±3	**76**±4	**84**±4
BCRNN	3±4	32±12	45±11	0±0	0±0	9±3	3±3	1±0	5±5
BCRNN (3D)	1±5	11±6	0±0	8±14	0±0	8±1	29±12	26±2	38±10
IBC	0±0	1±1	16±2	0±0	0±0	9±2	3±2	7±1	14±1
IBC (3D)	18±9	3±5	50±6	0±0	0±0	10±1	1±1	7±2	15±1

中国知网 https://www.cnki.net

然后将经过预训练的 ADP-I 以及完整训练的 ADP-II 与 DP[42]以及当前性能最优的 DP3[96]算法相对比，结果如下列表格所示：

表 3.5 在 Adroit 和 DexArt 任务中的对比实验结果

Task / Algorithm	Adroit			DexArt		
	Hammer	Door	Pen	Laptop	Faucet	Toilet
DP	45±5	37±2	13±2	69±4	23±8	58±2
DP3	**100**±0	62±4	43±6	83±1	63±2	82±4
ADP-I	58±9	49±5	52±5	57±4	42±1	71±7
ADP-II	90±2	**75**±6	**87**±3	**89**±3	**76**±4	**84**±4

表 3.6 在 MetaWorld (Easy)任务中的对比实验结果

Task / Algorithm	MetaWorld (Easy)					
	Button Press	Button Press Topdown	Button Press Topdown Wall	Button-Press Wall	Coffee Button	Dial Turn
DP	99±1	98±1	96±3	97±3	99±1	63±10
DP3	**100**±0	**100**±0	99±2	99±1	**100**±0	66±1
ADP-I	**100**±0	**100**±0	**100**±0	**100**±0	**100**±0	71±7
ADP-II	**100**±0	**100**±0	**100**±0	**100**±0	**100**±0	**92**±6
	Door Close	Door Lock	Door Open	Door Unlock	Drawer Close	Drawer Open
DP	**100**±0	86±8	98±3	98±3	**100**±0	93±3
DP3	**100**±0	98±2	99±1	**100**±0	**100**±0	**100**±0
ADP-I	**100**±0	**100**±0	**100**±0	**100**±0	**100**±0	**100**±0
ADP-II	**100**±0	**100**±0	**100**±0	**100**±0	**100**±0	**100**±0
	Faucet Close	Faucet Open	Handle Press	Handle Pull	Handle Press Side	Handle Pull Side
DP	**100**±0	**100**±0	81±4	27±22	**100**±0	23±17
DP3	**100**±0	**100**±0	**100**±0	53±11	**100**±0	**85**±3
ADP-I	**100**±0	**100**±0	**100**±0	43±7	**100**±0	45±4
ADP-II	**100**±0	**100**±0	**100**±0	**64**±10	**100**±0	71±3
	Lever Pull	Plate Slide	Plate Slide Back	Plate Slide Back Side	Plate Slide Side	Reach
DP	49±5	83±4	99±0	**100**±0	**100**±0	18±2
DP3	**79**±8	**100**±0	99±0	**100**±0	**100**±0	24±1
ADP-I	52±6	79±8	**100**±0	**100**±0	**100**±0	54±5
ADP-II	70±4	86±4	**100**±0	**100**±0	**100**±0	**62**±3
	Reach Wall	Window Close	Window Open	Peg Unplug Side		
DP	59±7	**100**±0	**100**±0	74±3		
DP3	68±3	**100**±0	**100**±0	75±5		
ADP-I	58±9	**100**±0	**100**±0	62±5		
ADP-II	**71**±5	**100**±0	**100**±0	84±7		

中国知网 https://www.cnki.net

表 3.7 在 MetaWorld (Medium, Hard, Very Hard)任务中的对比实验结果

Task / Algorithm	MetaWorld (Medium)					
	Basketball	Bin Picking	Box Close	Coffee Pull	Coffee Push	Hammer
DP	85±6	15±4	30±5	34±7	67±4	15±6
DP3	**98**±2	34±30	42±3	**87**±3	**94**±3	76±4
ADP-I	62±8	55±6	34±3	45±4	69±4	73±3
ADP-II	91±4	**83**±4	**62**±6	76±3	85±4	**93**±5
	MetaWorld (Medium)					
	Peg Insert Side	Push Wall	Soccer		Sweep	Sweep Into
DP	34±7	20±3	14±4		18±8	10±4
DP3	**69**±7	49±8	18±3		**96**±3	15±5
ADP-I	46±2	70±3	11±1		32±7	20±1
ADP-II	60±2	**85**±2	**28**±3		74±11	**49**±2
	MetaWorld (Hard)					
	Assembly	Hand Insert	Pick Out of Hole	Pick Place	Push	Push Back
DP	15±1	9±2	0±0	0±0	30±3	0±0
DP3	**99**±1	14±4	14±9	12±4	51±3	0±0
ADP-I	64±2	33±3	17±4	12±2	37±1	0±0
ADP-II	91±5	**64**±4	**42**±5	**37**±5	**54**±2	0±0
	MetaWorld (Very Hard)					
	Shelf Place	Disassemble	Stick Pull		Stick Push	Pick Place Wall
DP	11±3	43±7	11±2		63±3	5±1
DP3	17±10	69±4	27±8		**97**±4	35±8
ADP-I	13±3	80±6	60±6		51±3	45±10
ADP-II	**36**±2	**93**±6	**88**±5		79±4	**64**±4

表 3.8 算法在 Adroit，DexArt 和 MetaWorld (Medium, Hard, Very Hard)任务中的平均成功率

Algorithm	Mean Success Rate (%)
DP	27.6
DP3	57.3
ADP-I (Ours)	44.9
ADP-II (Ours)	**69.1**

遵循 DP3 中的任务设计，这里同样根据难度将 MetaWorld 任务分为 Easy，Medium, Hard, Very Hard 四种类型。在 MetaWorld (Easy)上评测的结果如表 3.6 所示，可以看出 DP，DP3，ADP 方法都可以基本解决简单任务，值得一提的是，比较 ADP-I 和 ADP-II 的结果可以看出，微调的策略不会使得良好的初始策略变

中国知网 https://www.cnki.net

得糟糕，包括在极端情况下，如果初始策略是完美的，那么微调策略也不会产生负面影响。

在另外具有挑战性的任务上进行评测的结果如表 3.5 和表 3.7 所示，且各个算法的平均成功率如表 3.8 所示。首先比较 DP 和 ADP-I 的结果可以看出，通过 ADP 中组合设计的特征提取模块替代 DP 中单一的 Resnet 图像特征编码器，ADP 策略捕获了更多的特征信息，平均成功率相对于 DP 有了 63%幅度的提升。另外，虽然 ADP-I 的平均成功率不如 DP3，但可以发现 ADP-I 在 Disassemble，Bin-Picking， Push-Wall 等任务的成功率上都高于 DP3，一方面是因为 DP3 采用的点云特征编码器相较于图像虽然无序、稀疏、不规则分布，但额外的深度信息使其在部分空间感知要求较高的任务上表现较好，另一方面，ADP 中的视觉特征编码器引入了时间信息，增强了模型的运动理解能力，使其在对连贯动作要求较高的任务上表现较好。然后，对比 ADP-I 和 ADP-II 的结果，可以看出经过微调之后的策略，成功率从 44.9%提升到了 69.1%，相对提升了 54%，并且在几乎所有任务都有较大幅度的提升，体现了 RL 微调训练框架的有效性。将 DP3 和 ADP-II 相对比也可以看出，微调策略在很大程度上弥补了初始策略的不足，通过 LoRA 模块用极小的训练代价，在一定程度上克服了对于计算量较大、获取难度更高的点云深度信息的需求，并将成功率相对提升了 21%，更好地挖掘了模型的潜力。同时，预训练一个优秀的初始策略同样重要，微调策略的最终性能很大程度上依赖于初始策略，例如在 Push-Back 任务这种极端情况下，初始策略的成功率为零，微调策略同样很难取得成功。

3.2.4 可视化实验

为了更直观地表现微调策略的效果，本节展示了经过第一阶段预训练的 ADP-I 策略以及经过完整两阶段训练的 ADP-II 策略执行任务过程的可视化。如图 3.5 所示，总共展示了四组任务，由于 ADP-II 采用的是通过参数高效微调视觉条件控制模块，并同时保持动作生成模块不变，因此总体上来看，ADP-I 与 ADP-II 整体行为模式相似，但 ADP-II 通过 LoRA 模块的参数适应在部分动作的细节上做出了轻微的调整，在防止极端动作的保证下使得策略执行任务从失败到成功。例如在 MetaWorld 的 Disassemble 任务中，目标是提起一个套在柱体上的圆环状工具，但 ADP-I 策略由于圆环与柱体发生碰撞而导致任务失败，而 ADP-II 策略通过调整提起圆环的角度从而避免了碰撞的发生，成功执行任务。在 MetaWorld 的 Stick-Pull 任务中，目标是先抓取一个条状物体，并通过该条状物体拖动水壶，但 ADP-I 策略由于抓取位置太过靠前导致物体掉落，而 ADP-II 策略通过调整抓取位置防止了物体的掉落，成功执行任务。在 Adroit 的 Door 任务中，目标是通过转动门把手打开门，但 ADP-I 策略由于灵巧手过于靠内导致

中国知网 https://www.cnki.net

转动门把手时没有抓稳，而 ADP-II 策略通过向外侧调整了灵巧手位置从而稳定转动门把手，成功执行任务。在 DexArt 的 Toilet 任务中，目标是打开马桶的盖子，但 ADP-I 策略由于灵巧手在抬起盖子后仍然保持竖直往上移动导致盖子掉落，而 ADP-II 策略在抬起盖子之后，将灵巧手指往盖沿内侧移动，成功执行任务。

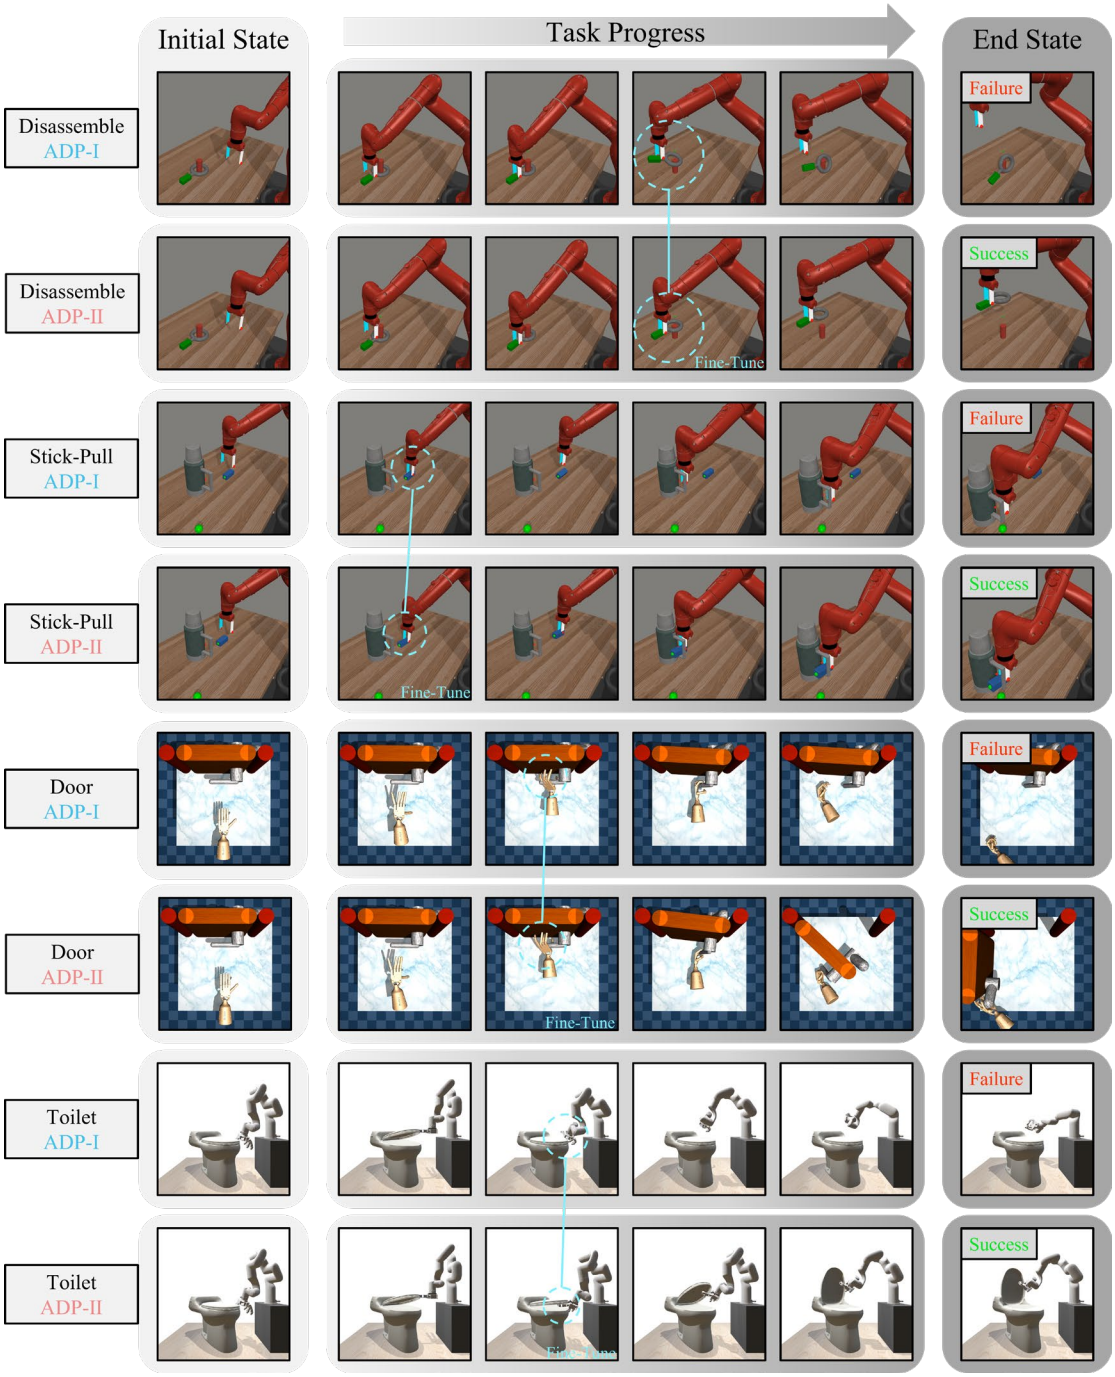


图 3.5 LoRA 微调效果可视化

3.2.5 消融实验

与单步输入映射单步输出的传统策略不同，ADP 是一种多步输入映射多步

中国知网 https://www.cnki.net

输出的策略，且之前已经介绍了多步生成的优势所在。但 DP3 算法受限于对每帧观察的独立处理，使得观察步数增长会导致计算量的巨大增长，使得 DP3 只能使用 2 个时间步的观察，并且 DP3 提到了生成动作步数的增加无法提升策略性能。而在 ADP 中，对多帧观察进行了联合处理，使得策略能扩展到长距离的观察，并且高效提取结合了时间特征和空间特征，使得生成动作步数的增加有效提升了策略性能。因此进行了关于观察范围 T 和生成动作步数 N 的消融实验，其中 DP-S，DP3-S，ADP-S 是在 $T=2, N=3$ 时训练得到的策略，DP-L，DP3-L 是在 $T=2, N=8$ 时训练得到的策略，ADP-L 是在 $T=4, N=8$ 时训练得到的策略。此外 ADP-S 的上下文图像处理采用的是上下拼接，而 ADP-L 采用的是田字形拼接，且 ADP-S-I 和 ADP-S-II 分别是 ADP-S 预训练和完整训练后得到的策略，ADP-L-I 和 ADP-L-II 同理，结果如下表所示。

表 3.9 不同观察范围 T 和生成动作步数 N 对策略性能的影响

Task / Algorithm	Adroit Door	Adroit Pen	Assembly	Disassemble	Stick Push
DP-S	37±2	13±2	15±1	43±7	63±3
DP-L	44±4	16±2	12±3	14±1	44±5
DP3-S	62±4	43±6	99±1	69±4	97±4
DP3-L	64±5	46±3	99±1	75±3	85±14
ADP-S-I	39±2	44±4	53±4	53±2	61±4
ADP-L-I	49±5	52±5	64±2	80±6	51±3
ADP-S-II	64±6	63±9	87±2	68±5	74±5
ADP-L-II	75±6	87±3	91±5	93±6	79±4

根据表 3.9，将 DP-S 与 DP-L，以及 DP3-S 与 DP3-L 相比较，可以发现增大生成动作步数 N 对策略性能提升效果有限，在一些任务上甚至会有负面影响。而将 ADP-S-I 与 ADP-L-I，ADP-S-II 与 ADP-L-II 相比较，可以看出增大观察范围 T 和生成动作步数 N 对于 ADP 策略性能提升效果显著。值得一提，在 Stick-Push 任务中发现，即使 ADP-L-I 成功率要小于 ADP-S-I，但微调后，ADP-L-II 成功率要大于 ADP-S-II，表明微调长距离的多步生成策略更有助于得到性能较优的策略。

随后，ADP-S 和 ADP-L 在更多的任务上进行了测试，并绘制了微调阶段的学习曲线如图 3.6 所示。在得到预训练以及过渡阶段的策略后，每隔 8×10^3 时间步进行一次测试并记录，总共训练了 8×10^4 时间步。根据图 3.6，一方面进一步证明了 ADP 设计的时空特征编码器对于长距离信息提取以及长距动作生成的优势；另一方面，相比于从零开始训练的 RL 算法[107]，ADP 更加高效，极大降低了环境交互成本，同时在训练的初始阶段也更为安全。此外，微调阶段的策略成功率几乎都大于初始策略。

中国知网 https://www.cnki.net

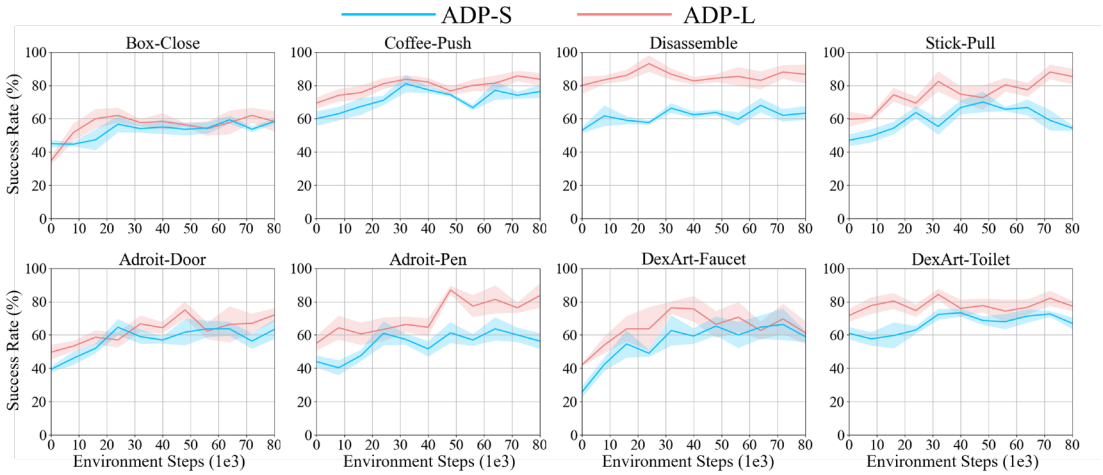


图 3.6 ADP-S 和 ADP-L 在微调阶段的学习曲线

ADP 的高效很大程度是得益于 IL 算法的优势，但传统 IL 算法对于专家演示训练集有很高的要求。一方面，需要足够的专家演示数量， 另一方面又需要保证专家演示的质量。

于是先进行专家演示数量的消融实验。之前部分的实验都只采用了 10 条演示的数据集，便能在大部分任务上取得较好的效果。接下来分别对 1、5、10、20、50 条专家演示情况下，预训练策略 ADP-I 和完整训练策略 ADP-II 的性能进行实验，结果如下所示。

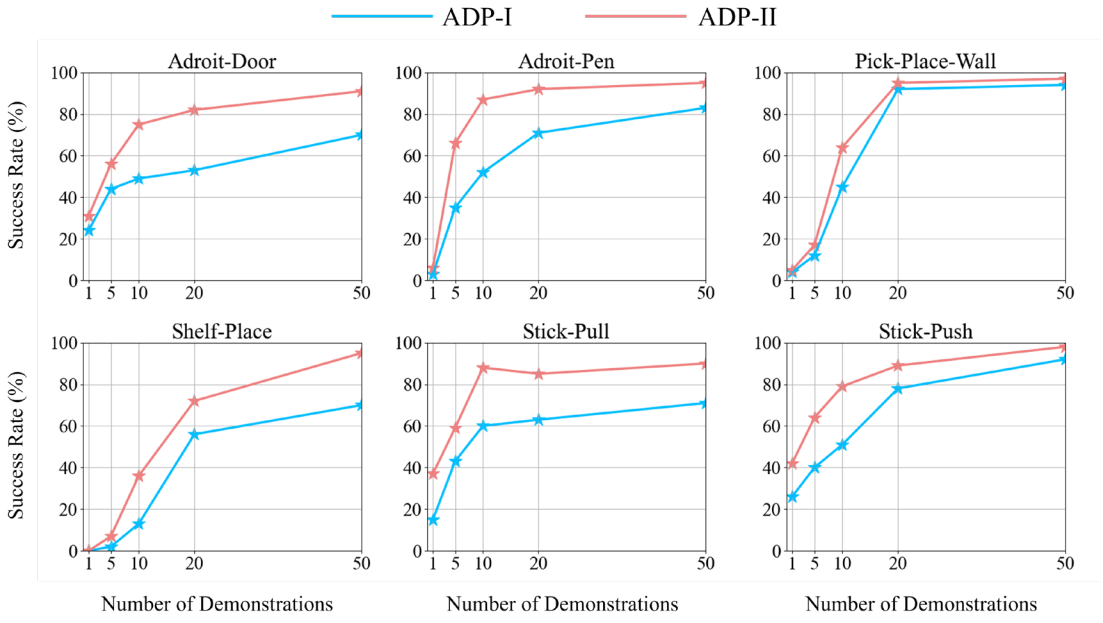


图 3.7 不同数量的专家演示对策略性能影响的实验结果图

根据图 3.7 可以得到，ADP 可以在极少量演示数据集下训练，同时演示数量的提升也能一定程度上改善策略性能，但也存在着边际递减效应。因此，在训练简单任务策略时可以仅采集少量专家演示，而在训练困难任务策略时可以

中国知网 https://www.cnki.net

适当增加专家演示的数量。

然后为了探究专家演示质量对策略性能的影响，使用了两种不同的专家策略采集演示在部分 MetaWorld 任务上进行消融实验。一种是自动脚本（Script）采集，一种是用训练好的 BAC[113]智能体采集。结果如下表所示。

表 3.10 不同类型专家演示对策略性能的影响

Task / Algorithm	Assembly	Coffee Push	Disassemble	Hammer	Stick Pull
DP (Script)	15±1	67±4	43±7	15±6	11±2
DP (BAC)	0±0	13±12	3±4	38±19	0±0
DP3 (Script)	99±1	94±3	69±4	76±4	27±8
DP3 (BAC)	49±5	57±2	46±4	38±7	62±6
ADP-I (Script)	64±2	69±4	80±6	73±3	60±6
ADP-I (BAC)	47±2	77±3	68±9	52±2	91±4
ADP-II (Script)	91±5	85±4	93±6	93±5	88±5
ADP-II (BAC)	83±6	93±2	79±3	65±5	100±0

不同的专家策略代表不同的演示质量，根据表 3.10，将 DP (Script)和 DP (BAC)，以及 DP3 (Script)和 DP3 (BAC)相对比可以看出演示质量会严重影响 DP 和 DP3 的策略性能。而 ADP-I (Script)与 ADP-I (BAC)之间的差距较小，ADP 由于提取了更多维度的时空特征信息，一定程度上缓解了演示质量的影响。此外，结合 ADP-II (Script)和 ADP-II (BAC)，可以看出微调策略进一步缩小了两者间的差距，ADP 降低了对专家演示的质量要求。

最后，研究了不同性能的初始策略对最终微调策略性能的影响。这里采用同一预训练过程中不同训练步数的权重来分别初始化策略，在每个任务上获得五个性能从低到高的初始策略 ADP-I，并分别进行微调得到最终策略 ADP-II，结果如下图所示。

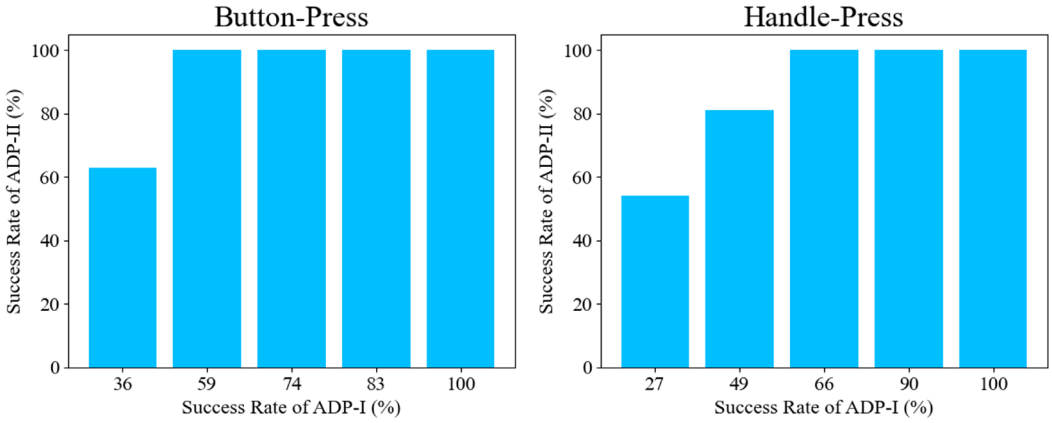


图 3.8 不同性能的初始策略 ADP-I 对最终微调策略 ADP-II 性能的影响

从图 3.8 中可以发现在 Button-Press 任务中，成功率为 59%、74%、83%、100%的初始策略以及在 Handle-Press 任务中，成功率为 66%、90%、100%的初

中国知网 https://www.cnki.net

始策略在经过微调之后最终策略成功率都达到了 100%，一方面说明可以适当放宽对于预训练阶段得到的初始策略性能的要求，另一方面说明性能较差的初始策略仍较好地学习到了专家的行为模式，存在着执行任务的理论潜力，为接下来将 ADP 扩展到多任务策略奠定了基础。

3.3 本章小结

本章主要介绍了 ADP 的算法设计， 包括 ADP 的模型框架，以及扩散策略预训练和强化学习微调阶段两个训练阶段的详细过程。通过与基于二维图像信息的 DP 算法以及三维点云信息的 DP3 算法相对比，体现了结合时空信息以及 IL 和 RL 训练各自优势的 ADP 算法的优越性。并通过可视化结果直观展示了 ADP 中 LoRA 微调策略的效果，可以在保持专家行为模式的情况下，通过参数适应在部分动作的细节上做出了轻微的调整，在防止极端动作的保证下使得策略执行任务从失败到成功。最后通过一系列消融实验体现了 ADP 捕捉长距离信息及生成长距离动作的能力，以及训练效率高，对专家演示要求低等特点。

中国知网 https://www.cnki.net

第四章 基于视觉语言模型与混合专家的多任务策略

通用机器人在学术界和工业界都受到了极大的关注，开发能够从非结构化现实世界环境中的视觉观察中执行不同操作任务，完成多种目标的通用智能体是一个长期存在的问题。能够执行广泛的任务，传统方法通常依赖于所有任务的通用和整体策略，为即使是简单的任务也需激活大型网络中的所有参数。此外，鉴于机器人多种学习任务的不同性质，当遇到新任务时，这些方法通常需要昂贵的微调，这会带来灾难性地忘记先前获得的技能的风险。多任务机器人学习在处理多样化和复杂的场景方面具有重要意义。最近，MoE 模型已被证明在自然语言处理、计算机视觉和多模态领域的大规模应用中是成功的。它根据门控网络有选择地只激活专家的一个子集网络，允许专家跨各种任务和时间使用，并促进集成额外的网络，同时保留现有网络的功能。通过引入专家混合结构，允许更快的推理速度和更高的整个模型容量，从而解决了 RL 参数有限的问题，在控制计算成本的同时提高了多任务学习中的模型性能。

此外，在第三章中，虽然通过结合 IL 和 RL 算法改善了传统 RL 算法中需要大量环境交互的问题，但仍需要手动指定奖励函数，这通常是不可行的，或者从大量人类反馈中学习奖励模型，这通常非常昂贵。使用 RL 框架构建通用智能体的一个关键限制因素是需要大量奖励函数来实现不同的目标。构建一个奖励函数，当期望最大化该函数时，会导致实现特定目标可能具有挑战性、耗时且难以扩展。这在模拟环境和现实世界中都同样适用。在模拟环境中，很难用代码表达代理是否成功实现了诸如操作机械臂画一条蛇这样的抽象目标，而在现实世界中，奖励必须从观察数据中计算得出。这些挑战凸显了自动生成奖励函数的方法在训练通用代理中的重要性。最近出现的一个特别有前途的方向是使用 VLM 在视觉环境中构建奖励函数。在配对图像和文本的大型数据集上训练的 VLM 已被证明在开箱即用的各种视觉检测、分类和问答任务中表现良好，并且可以作为对专业任务或数据集进行微调的良好初始化。因为 VLM 包含大量常识知识，可用于各种下游任务。一个有前景的下游应用程序是使用 VLM 为 RL 任务生成密集的奖励。

4.1 算法设计

为了提升机械臂策略的通用性，在 ADP 框架的基础之上，提出了 MoE-FiLM 层将 MoE 集成到的扩散策略网络的条件控制层中，以将针对单任务设计的 ADP 策略扩展到多任务策略，称为自适应多任务扩散策略（Adaptive Multi-

中国知网 https://www.cnki.net

Task Diffusion Policy，AMTDP）。同时又提出了 MoE-LoRA 层将 MoE 集成到 LoRA 模块，在多步 RL 框架中实现多任务高效微调策略。同时，在微调阶段又引入了 VLM，为多任务构建了通用的奖励函数，自动生成密集的奖励。AMTDP 框架如图 4.1 所示。

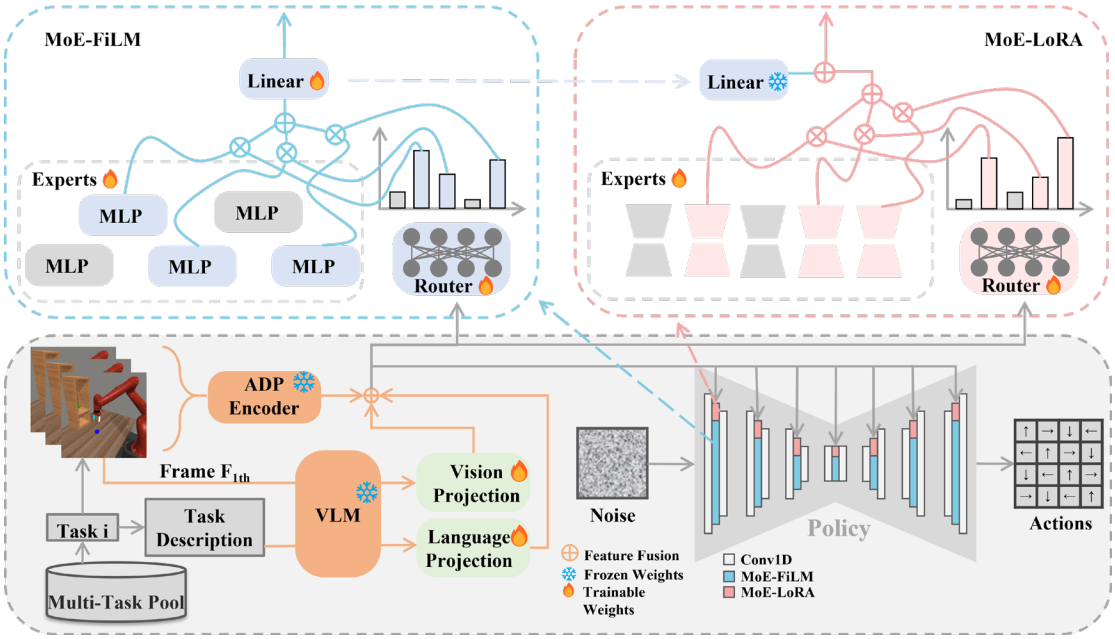


图 4.1 AMTDP 框架图

4.1.1 混合专家预训练阶段

该阶段对应的是 ADP 中的扩散策略预训练阶段，给定 t 时刻的观察范围为 T 的观察序列 $\{o_{t-T+1},....,o_{t-1},o_t\}$，AMTDP 的目标是预测接下来 N 步机器人的动作 $\{a_t,a_{t+1},....,a_{t+N-1}\}$，为简便起见，将观察和动作分别堆叠为 $\hat{o}_t$ 和 $\hat{a}_t$。但与 ADP 考虑的单任务不同，这里考虑用同一个策略解决一组 M 个机械臂任务 $\{\mathcal{T}_m\}_{m=1}^{\mathrm{M}}$。对于任务 $\mathcal{T}_m$，提供一系列的专家演示 $\{(\hat{o}_{tm},\hat{a}_{tm})\}$，以及任务相关的文本描述 o_m^{Txt}，类似于式 (3.5)，可以得到训练损失函数为：

$$\mathcal{L}_m=\mathrm{MSE}(\epsilon^k,\epsilon_\theta(\hat{o}_{tm},o_m^{\mathrm{Txt}},\hat{a}_{tm}^0+\epsilon^k,k)), \tag{4.1}$$

进一步可以多任务训练 AMTDP 的损失函数为：

$$\mathcal{L}_\theta=\sum_{m=1}^{\mathrm{M}}\mathcal{L}_m, \tag{4.2}$$

然后设计了 MoE-FiLM 模型以替换 ADP 条件控制模块中的 FiLM 模型。MoE-FiLM 结构如图 4.1 左上方所示，由一个门控网络 $\mathcal{G}_l$ 和 L_l 个专家网络 $\{f_l\}_{l=1}^{\mathrm{L}_l}$ 组成，门控网络和专家网络都是 MLP 结构，且门控网络采用的是设定超参数 K 的式 (2.50)稀疏门控，同时最后又额外增加了一个线性输出层 Linear，因此

中国知网 https://www.cnki.net

AMTDP 的条件控制结合式 (2.48)将式 (3.2)变为：

$$(d_{i,j},h_{i,j})=\mathrm{Linear}\left(\sum_{l=1}^{\mathrm{L_1}}\mathcal{G}_{\mathrm{l}}(\mathcal{F}_O)f_l(\mathcal{F}_O)\right), \tag{4.3}$$

其中 $\mathcal{F}_O$ 为从原始观察 O 中提取的特征。考虑视觉观察是一个包含 T 帧的图像序列 $\mathrm{F}_{1:T}$，并将第一帧图像记为 o^{Img}，再加上针对每个任务的任务描述文本 o^{Txt}，AMTDP 的特征提取模块在 ADP 基础上，参考式 (3.1)，保持 $\mathcal{F}_{\mathrm{Video}}$，$\mathcal{F}_{\mathrm{Im}age2}$，$\mathcal{F}_{\mathrm{State}}$ 不变，又额外引入了 VLM 中的 CLIP[94]模型，其包含图像编码器 f_{Img} 和文本编码器 f_{Txt}，对 o^{Img} 和 o^{Txt} 进行特征提取。但由于采用的预训练 CLIP 模型，其训练数据与机械臂任务环境视觉输入的数据分布存在很大差异，因此这里又添加了视觉投影层 Ψ_{Img} 和文本投影层 Ψ_{Txt}，以将 CLIP 编码器的输出与任务环境的视觉数据分布相对齐，可以得到新的图像特征 $\mathcal{F}_{\mathrm{Img}}$ 和文本特征 $\mathcal{F}_{\mathrm{Txt}}$：

$$\mathcal{F}_{\mathrm{Img}}=\Psi_{\mathrm{Img}}(f_{\mathrm{Img}}(o^{\mathrm{Img}})), \tag{4.4}$$

$$\mathcal{F}_{\mathrm{Txt}}=\Psi_{\mathrm{Txt}}(f_{\mathrm{Txt}}(o^{\mathrm{Txt}})), \tag{4.5}$$

并且训练过程中只更新 Ψ_{Img} 和 Ψ_{Txt} 编码器的参数，而保持其他编码器参数不变，完整的视觉特征 $\mathcal{F}_O$ 也从式 (3.1)修改为：

$$\mathcal{F}_O=\mathcal{F}_{\mathrm{Video}}\oplus\mathcal{F}_{\mathrm{Image2}}\oplus\mathcal{F}_{\mathrm{State}}\oplus\mathcal{F}_{\mathrm{Img}}\oplus\mathcal{F}_{\mathrm{Txt}}, \tag{4.6}$$

AMTDP 的动作生成模块则与 ADP 相同，该阶段训练细节也与 ADP 的第一阶段类似。

4.1.2 视觉语言模型奖励函数

AMTDP 同样存在 RL 微调阶段，但与 ADP 中单个任务都采用人工设计的奖励函数不同，AMTDP 利用 VLM 来为 $\{\mathcal{T}_m\}_{m=1}^{\mathrm{M}}$ 中的每个任务生成奖励。具体来说，AMTDP 的奖励 r_t 分为两部分，一部分是稀疏的任务奖励 r_t^{task}，另一部分是 VLM 给出的密集奖励 r_t^{VLM}。其中 r_t^{task} 被定义只有在任务成功时才会收到 1 的奖励，否则奖励为 0：

$$r_t^{\mathrm{task}}=\begin{cases}1,\ \text{if success},\\ 0,\ \text{otherwise},\end{cases} \tag{4.7}$$

这是实践中常见的一种奖励设置，但稀疏的奖励使 RL 训练更具挑战性，因此需要加入 r_t^{VLM} 使得奖励变得更密集。r_t^{VLM} 其被定义为目标文本与视觉图像之间 VLM 特征的余弦相似性，这里的 VLM 特征提取采用的是 CLIP 模型中的文本编码器和图像编码器，以及参与 4.1.1 节中预训练的文本投影层和视觉投影层，奖励生成过程如图 4.2 以及下式所示。

$$r_t^{\mathrm{VLM}}=\frac{\left\langle\Psi_{\mathrm{Txt}}(f_{\mathrm{Txt}}(o_t^{\mathrm{Txt}})),\Psi_{\mathrm{Img}}(f_{\mathrm{Img}}(o_t^{\mathrm{Img}}))\right\rangle}{\left\|\Psi_{\mathrm{Txt}}(f_{\mathrm{Txt}}(o_t^{\mathrm{Txt}}))\right\|\bullet\left\|\Psi_{\mathrm{Img}}(f_{\mathrm{Img}}(o_t^{\mathrm{Img}}))\right\|}, \tag{4.8}$$

中国知网 https://www.cnki.net

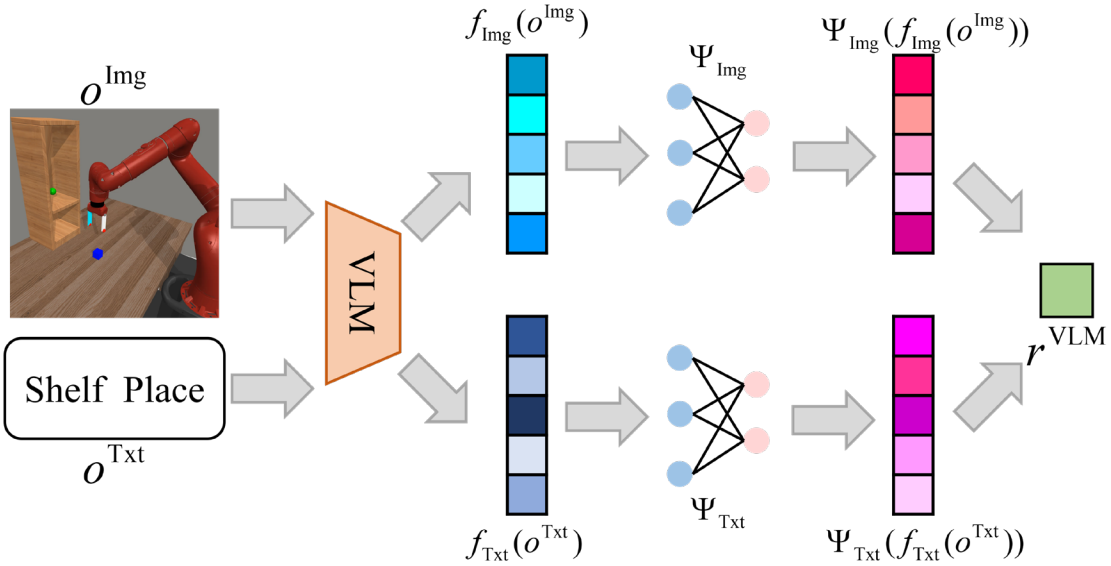


图 4.2 VLM 奖励生成过程

进一步可以得到总的奖励为：

$$r_t = r_t^{\text{task}} + \chi r_t^{\text{VLM}}, \tag{4.9}$$

其中 χ 为调节任务奖励与 VLM 奖励之间的平衡的超参数。

4.1.3 混合专家微调阶段

该阶段对应的是 ADP 中的强化学习微调阶段。现有的 LoRA 参数高效微调策略仅限于微调单个任务，尽管可以很好地单独拟合每个任务，但这种策略很费力，缺乏任务共享的知识。AMTDP 在预训练中通过引入 MoE 结构加入了多任务门控选择机制并扩大了模型容量，旨在微调阶段集成 MoE 结构后同时微调多个任务。在 ADP 的微调阶段，核心是在多步 DDPG 框架中微调添加到条件控制模块中的 LoRA 模块，因此 AMTDP 沿用了该 RL 训练框架，并替换新设计的 MoE-LoRA 模块后进行微调。

MoE-LoRA 模块如图 4.1 的右上方所示，由一个门控网络 $\mathcal{G}_2$ 和 L_2 个 LoRA 专家 $\{\mathbf{B}_l\mathbf{A}_l\}_{l=1}^{\mathrm{L}_2}$ 组成。门控网络是 MLP 结构，且采用的是设定超参数 K 的式 (2.50) 稀疏门控，因此 MoE-LoRA 参数 ϕ 的表达式为：

$$\phi = \sum_{l=1}^{\mathrm{L}_2} \mathcal{G}_2(\mathcal{F}_O)\cdot\mathbf{B}_l\mathbf{A}_l, \tag{4.10}$$

整体上 AMTDP 微调训练与 ADP 微调类似，包含过渡阶段和正式微调阶段，但考虑一组 M 个机械臂任务 $\{\mathcal{T}_m\}_{m=1}^{\mathrm{M}}$，且将回放缓冲区中的数据格式修改为观察-动作-奖励-下一观察-任务描述元组 $\{(\hat{o}_t, \hat{a}_t, r_{t:t+N-1}, \hat{o}_{t+N}, o_t^{\text{Txt}})\}$，其中用 $(\hat{o}_t, o_t^{\text{Txt}})$ 代替 $\hat{o}_t$ 作为策略输入，且 $r_{t:t+N-1}$ 利用 VLM 奖励代替了人工设计奖励：

$$r_{t:t+N-1} = \sum_{i=t}^{t+N-1} r_i = \sum_{i=t}^{t+N-1} r_i^{\text{task}} + \chi r_i^{\text{VLM}}, \tag{4.11}$$

中国知网 https://www.cnki.net

完整的 AMTDP 微调过程如伪代码算法 2 所示：

算法 2：AMTDP 微调阶段

初始化：

超参数：$T, N, b, \gamma, \eta, \mathrm{L}_2, \chi$

预训练模型 f_{Img}、f_{Txt}，Ψ_{Img}、Ψ_{Txt}，Actor 网络 AMTDP-I π_θ

离线回放缓冲区 $\{(\hat{o}_t, \hat{a}_t, r_{t:t+N-1}, \hat{o}_{t+N}, o_t^{\text{Txt}})\} \in \mathcal{D}_{\text{off}}$

在线回放缓冲区 $\mathcal{D}_{\text{on}} = \varnothing$

MoE-LoRA 模块参数 $\phi = \sum_{l=1}^{\mathrm{L}_2} \mathcal{G}_2(\mathcal{F}_O) \cdot \mathbf{B}_l \mathbf{A}_l$

随机初始化的 Critic 网络 Q

训练阶段：

过渡阶段部分一：

回放缓冲区 $\mathcal{D} = \mathcal{D}_{\text{off}}$，标志 actor_flag=False, online_flag=False

过渡阶段部分二：

回放缓冲区 $\mathcal{D} = \mathcal{D}_{\text{off}}$，标志 actor_flag=True, online_flag=False

强化学习微调阶段：

回放缓冲区 $\mathcal{D} = \mathcal{D}_{\text{off}} \cup \mathcal{D}_{\text{on}}$，标志 actor_flag=True, online_flag=True

训练过程：

for epoch **do**

  任务环境重置，从任务池 $\{\mathcal{T}_m\}_{m=1}^{\mathrm{M}}$ 中选择任务 $\mathcal{T}_m$，并得到 o_m^{Txt}

  for environment timestep *t* **do**

    if online_flag == True **then**

      $\hat{a}_t = \pi_{\theta \cup \phi}(\hat{o}_t, o_m^{\text{Txt}})$

      $r_{t:t+N-1} = \sum_{i=t}^{t+N-1} r_i^{\text{task}} + \chi r_i^{\text{VLM}}$

      $\hat{o}_{t+N} = \text{env.step}(\hat{a}_t)$

      $\mathcal{D}_{\text{on}}.\text{append}((\hat{o}_t, \hat{a}_t, r_{t:t+N-1}, \hat{o}_{t+N}, o_m^{\text{Txt}}))$

    end if

    $\tau = \left\{(\hat{o}_t, \hat{a}_t, r_{t:t+N-1}, \hat{o}_{t+N}, o_t^{\text{Txt}})_i\right\}_{i=1,\ldots,b} \sim \mathcal{D}$

    根据更新频率通过式 (3.6)软更新 Critic 网络 Q

    if actor_flag == True **then**

      根据更新频率通过式 (3.8)软更新 Actor 网络 $\phi \to \pi_{\theta \cup \phi}$

    end if

  end for

end for

中国知网 https://www.cnki.net

4.2 实验分析

4.2.1 数据集介绍

AMTDP 在 MetaWorld 数据集的 MT10[107]系列环境中进行测试，由 10 个任务组成了多任务，并遵循 FuRL[114]中的设置给出任务描述，具体信息如图 4.3 所示：

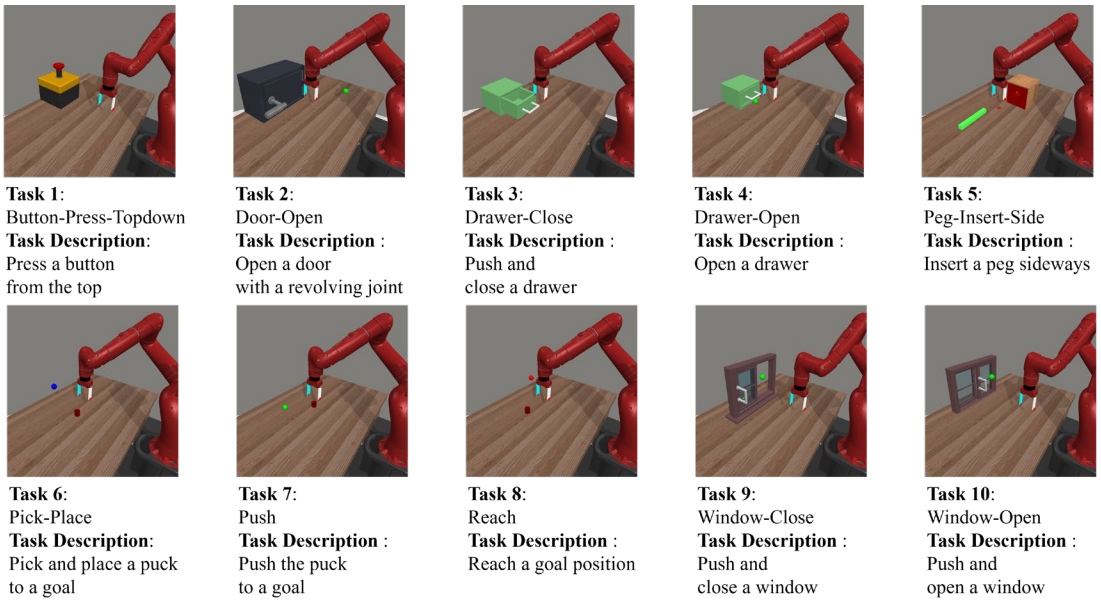


图 4.3 MT10 系列任务及任务描述示意图

4.2.2 实验设置

AMTDP 相对于 ADP 模型参数增加，对显存等要求提高，但仍可以使用单张 GPU 实现训练及推理。本章实验的配置环境如下表所示：

表 4.1 实验配置环境

条目	配置
操作系统	Ubuntu 20.04
CPU	Intel i7-14700
GPU	NVIDIA GeForce RTX 4090 D

对于 AMTDP 训练所需的专家演示，由于使用 MetaWorld 环境，因此仍采用自动脚本收集成功演示，且对 10 个任务中的每个任务都各自采集了 20 条演示，组合形成训练集。

对于评估指标，AMTDP 训练之后在 10 个任务，每个任务 100 个随机的测试环境中测试，计算平均任务成功率。并且实验运行了三个种子（0，1，2），记录它们的平均值。

AMTDP 建立在 ADP 的基础之上，因此大部分超参数也遵循 ADP 中的设置，

中国知网 https://www.cnki.net

同时也引入了更多参数，主要超参数如表 4.2 所示。

表 4.2 AMTDP 实验主要超参数表

超参数	设置
T	4
N	8
Image Size	84×84
L_1	16
L_2	8
χ	0.5
K	2
b	256
γ	0.99
η	2
LoRA rank	16
υ	0.01
Critic Update Frequency	1
Actor Update Frequency	0.5

4.2.3 对比实验

为了体现 AMTDP 算法多维度的优势，从多个角度进行对比分析。选取比较的基线算法包括：MT–SAC[107]，在 SAC[115]算法中增加了共享主干网络后直接应用到多任务测试中；Soft-Mod[116]，作为参数共享方法，软模块化共享参数并使用路由网络来软组合每个任务的所有可能的路由；PCGrad[117]，一种梯度操作方法，将任务的梯度投影到任何其他冲突任务的法线平面上；CARE[118]，作为特征表示共享方法，共享特征表示以学习如何通过利用有关每个任务的附加信息来进行组合；TSAC[119]，在 CARE 的特征表示共享模块基础之上，建立了行为共享模块，并利用面向目标的稀疏奖励；PTSL[120]，提出了投影任务特定层架构，可用于 CARE 等方法之上，协调多任务的编码方法和路由方法。结果分别记录了这些算法在较少训练步数（10^5）和较多训练步数（10^6）下的平均成功率。除了上述依赖人工设计奖励函数的 RL 算法，这里还考虑了同样利用 VLM 作为奖励函数的算法，包括直接将 MT–SAC 与 VLM 奖励结合，以及 Relay[121]和 FuRL[114]算法，但在较少训练步数下这些算法成功率几乎为零，因此仅记录较多训练步数的情况。最后记录了，未扩展前，面向单任务的 ADP 策略，以及扩展后，面向多任务的 AMTDP 策略各自 I、II 两个阶段训练后的结果，另外 ADP 和 AMTDP 微调阶段都只进行10^5训练步数。

中国知网 https://www.cnki.net

表 4.3 MT10 多任务对比实验结果

Algorithm	Steps	Reward	Success (%)
MT-SAC (short)	10^5	Human	19.8
Soft-Mod (short)	10^5	Human	18.0
PCGrad (short)	10^5	Human	27.6
CARE (short)	10^5	Human	26.0
TSAC (short)	10^5	Human	39.0
PTSL (short)	10^5	Human	41.1
MT-SAC (long)	10^6	Human	55.5
Soft-Mod (long)	10^6	Human	56.0
PCGrad (long)	10^6	Human	64.4
CARE (long)	10^6	Human	66.7
TSAC (long)	10^6	Human	72.2
PTSL (long)	10^6	Human	74.2
MT-SAC	10^6	VLM	49.8
Relay	10^6	VLM	57.4
FuRL	10^6	VLM	64.6
ADP-I (Ours)	/	/	21.4
ADP-II (Ours)	10^5	VLM	26.2
AMTDP-I (Ours)	/	/	52.3
AMTDP-II (Ours)	10^5	VLM	70.9

对比结果如表 4.3 所示，首先，AMTDP 的一个优势是保留了 ADP 两阶段训练的特点，即训练效率高，只需10^5环境交互步数即可达到与 TSAC 等单纯 RL 算法在10^6步数下接近的效果，并且可以看出其他 RL 算法在10^5步数下得到的成功率非常低。其次，AMTDP 成功引入了 VLM 奖励，无需再为每个任务特意设计奖励函数，且能达到与使用人工设计奖励函数的 RL 算法接近的成功率，而与 FuRL 等同样使用了 VLM 奖励的 RL 算法相比，优化了训练流程并且策略性能得到了较大的提升。最后，是将 AMTDP 与 ADP 对比，结果表明 ADP 无法应对多任务的情况，而 AMTDP 通过 MoE-FiLM 以及 MoE-LoRA 模块的优化，成功将其扩展为多任务策略。

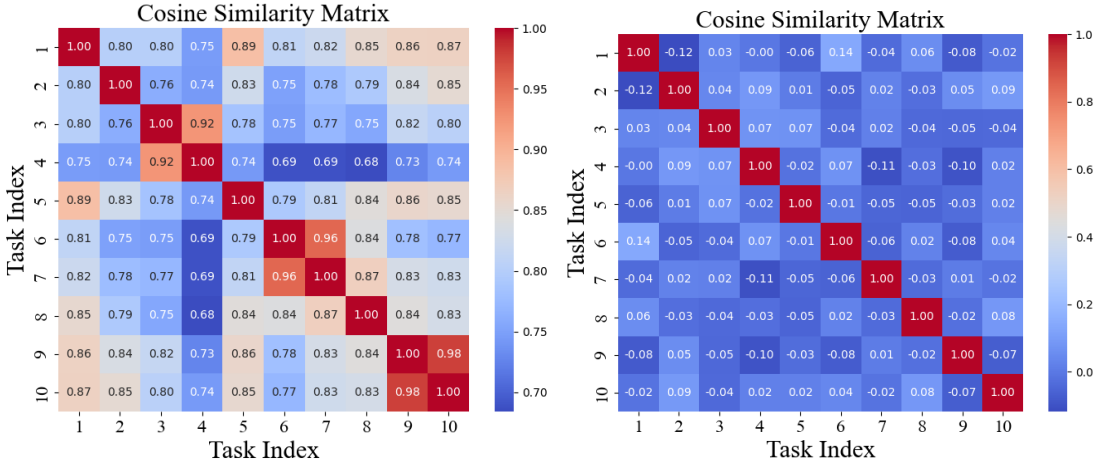
4.2.4 可视化实验

AMTDP 在许多模块都进行了改进，为了更直观地体现这些改进的优势，本节从多个方面进行了可视化实验。

首先，AMTDP 在 CLIP[94]模型的编码器之后额外添加了投影层，这里对投

中国知网 https://www.cnki.net

影层前后 10 个任务的特征向量两两进行了余弦相似度的计算，如下图所示。



(a) 投影前　　(b) 投影后

图 4.4 投影层前后任务特征向量余弦相似度

根据图 4.4 可以得到，在投影之前，各个任务的特征向量之间存在较高的相似性，而投影之后相似性显著降低，作为多任务输入有助于后续模块和奖励函数的处理。

其次，AMTDP 引入了 VLM 奖励 r_t^{VLM}，这里采样了两个任务，分别展示了任务执行过程中的人工设计奖励曲线和 VLM 奖励曲线，如下图所示。

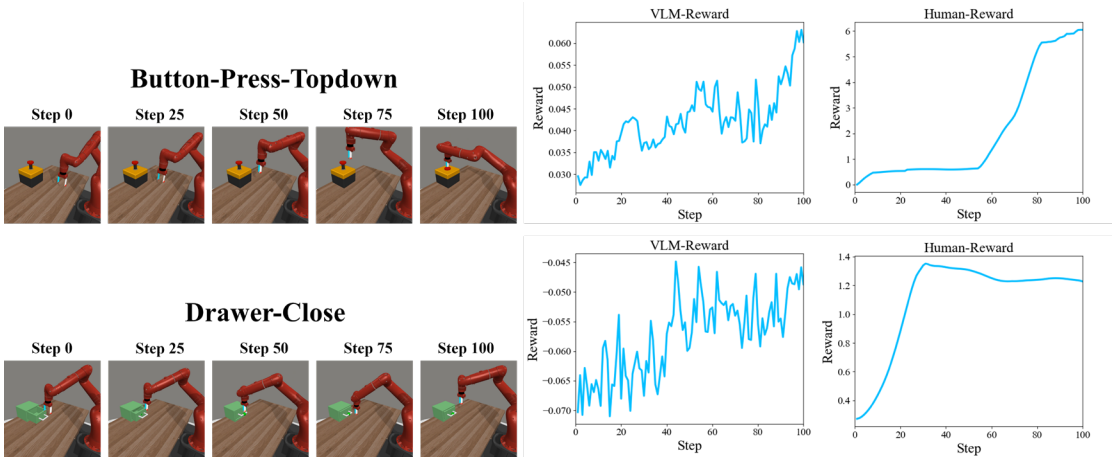


图 4.5 任务执行过程中的人工设计奖励曲线和 VLM 奖励曲线

图 4.5 展示了 Button-Press-Topdown 和 Drawer-Close 两个任务运动轨迹对应的奖励曲线。理想情况下，奖励曲线应该与任务的进展相对齐，即当状态更接近任务完成时，奖励更高，在这一方面人工精心设计的奖励比较贴合整个过程。虽然 VLM 奖励与任务进度没有很好地对齐，但 VLM 曲线走势与人工曲线大致吻合，说明 VLM 奖励仍然可以提供有意义的信息。而且 AMTDP 在经过第一阶段的模仿学习后一定程度上已经具备完成任务的能力，并不依赖于完全精确的奖励，r_t^{VLM} 可以作为一种模糊奖励信号，同时在 r_t^{Task} 的共同指导下帮助 AMTDP 进行微调训练。

中国知网 https://www.cnki.net

然后展示了 MoE-LoRA 微调作用的可视化。

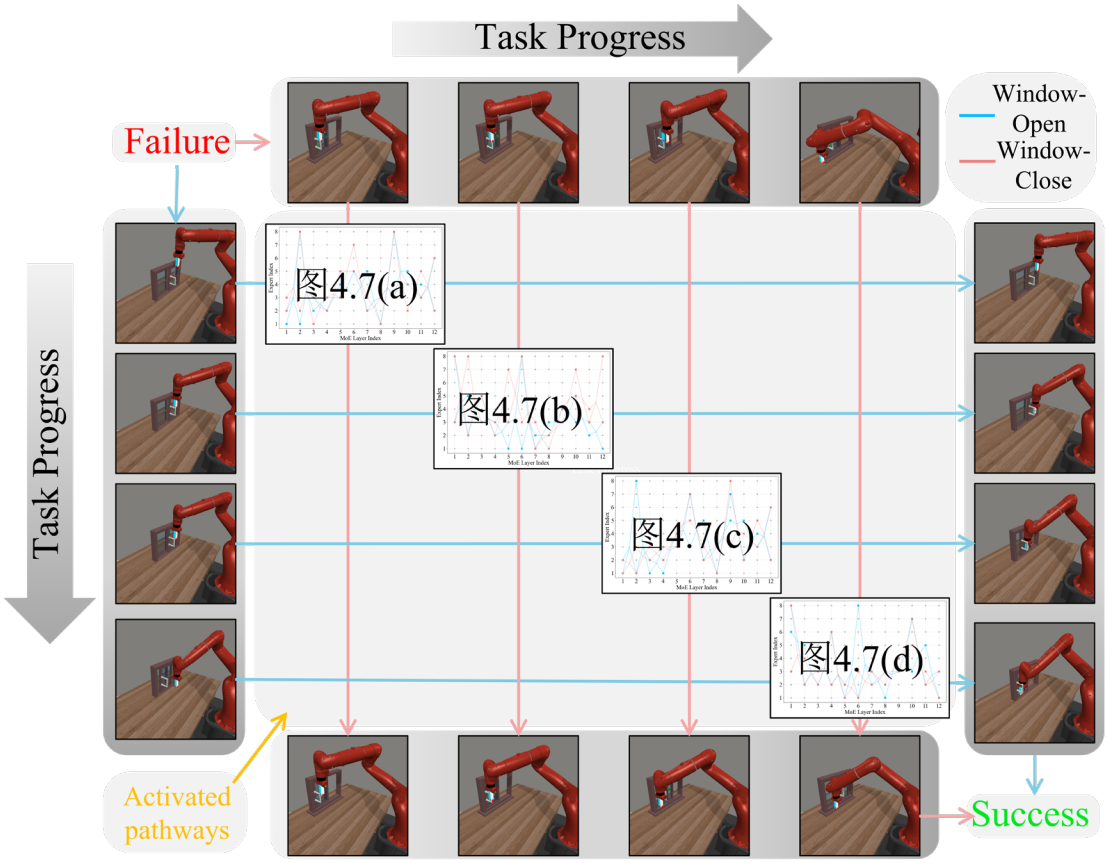


图 4.6 MoE-LoRA 微调效果可视化

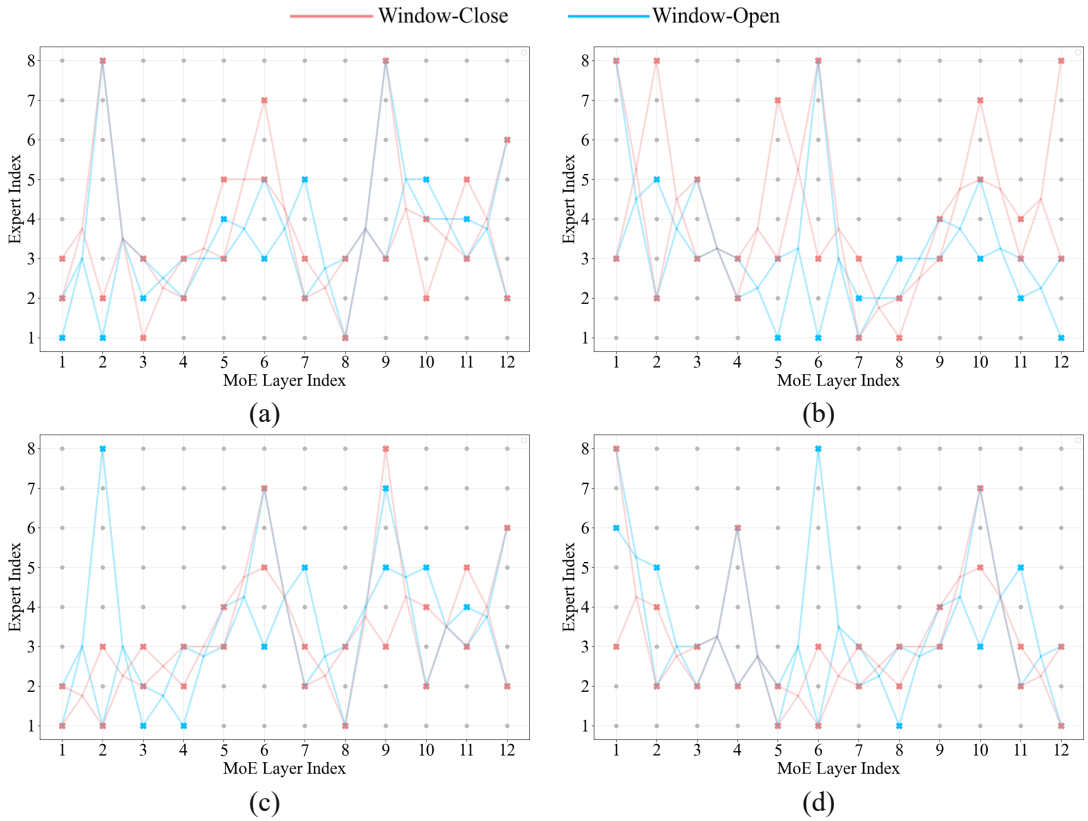
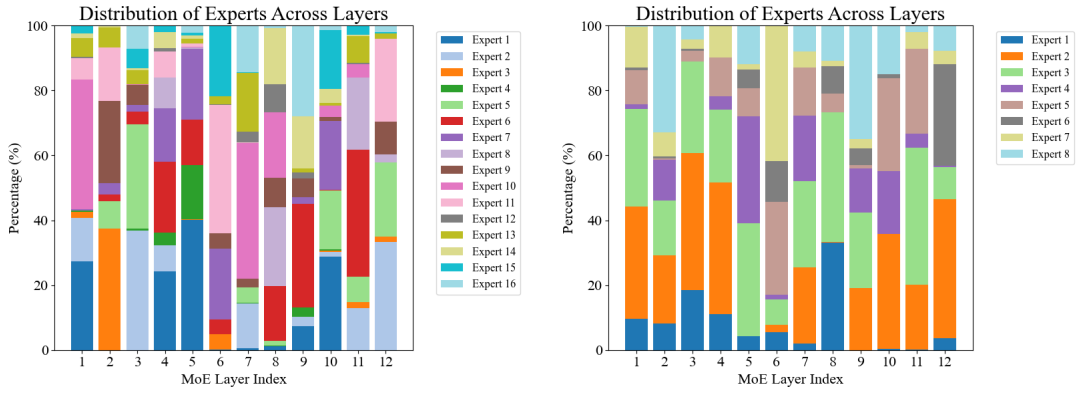


图 4.7 MoE-LoRA 专家激活路径

中国知网 https://www.cnki.net

如图 4.6 和图 4.7 所示，展示了 Window-Close 和 Window-Open 两组实验微调前后任务执行过程的差异。总体上来看，微调前后的行为模式相似，但通过 MoE-LoRA 模块的混合专家参数适应，在部分动作的细节上做出了轻微的调整，在防止极端动作的保证下使得策略执行任务从失败到成功。并且这两个任务动作的微调，都通过同一个 MoE-LoRA 模块自适应地激活不同专家来实现。具体的专家激活路径如图 4.7 所示，因为设置超参数 K 为 2，所以每层 MoE-LoRA 会激活 2 个专家，可以看到不同的任务可以激活相同的专家，展示专家在各种任务中的可重用性。

然后采样了所有 10 个任务，统计了专家的激活情况。



(a) MoE-FiLM 激活情况　　(b) MoE-LoRA 激活情况

图 4.8 各 MoE 层中专家激活率

图 4.8 展示了 MoE-FiLM 和 MoE-LoRA 中每层专家的激活情况，发现各个专家的激活率不同，存在较大的负载偏差，这会在一定程度上影响混合专家及策略学习的效率。

4.2.5 消融实验

AMTDP 通过 MoE-FiLM 和 MoE-LoRA 模块引入了混合专家结构，而模块里的专家数量 L_1 和 L_2 会影响模型参数数量，进而影响策略的性能。但之前的实验发现专家的负载不均衡，同样会对策略性能产生影响，因此对不同的 L_1 和 L_2 进行消融实验。其中 L_2 的消融实验在 $L_1=16$ 的预训练策略基础上进行。

表 4.4 不同 L_1 对预训练策略性能的影响

L_1	Success (%)
4	39.9
8	49.1
16	52.3
24	**53.6**

中国知网 https://www.cnki.net

表 4.5 不同 L_2 对微调策略性能的影响

L_2	Success (%)
4	67.4
8	70.9
16	**71.4**
24	69.3

根据表 4.4 和表 4.5 可以得到，单纯地扩大模型容量在增大显存等资源需求的同时并不能得到相应的性能提升。

最后对调节任务奖励与 VLM 奖励之间平衡的超参数 χ 进行了消融实验。

表 4.6 不同 χ 对微调策略性能的影响

χ	Success (%)
0.005	58.3
0.05	64.6
0.5	**70.9**
5	42.8

根据表 4.6，在 $\chi = 0.5$ 时，奖励组成比较合理。

4.3 本章小结

本章主要介绍了 AMTDP 的算法设计，包括引入 MoE 设计了 MoE-FiLM 以和 MoE-LoRA 模块将 ADP 单任务策略扩展为多任务策略，以及引入 VLM 为微调训练自动生成奖励。通过与 TSAC 等基于人工设计奖励训练的算法以及 FuRL 等基于 VLM 奖励训练的算法相对比，体现了 MoE 结构和 VLM 奖励的有效性。并通过可视化结果直观展示了 AMTDP 中投影层对特征向量的影响，任务进度与 VLM 奖励曲线的对比，以及 MoE-LoRA 微调策略对多任务进行的效果，同样可以在保持专家行为模式的情况下，通过参数适应在部分动作的细节上做出了轻微的调整，在防止极端动作的保证下使得策略执行任务从失败到成功。最后通过消融实验研究了 MoE 中专家数量，及 VLM 奖励函数中超参数 χ 对策略性能的影响。

中国知网 https://www.cnki.net

第五章 基于雅可比矩阵自适应的轨迹跟踪控制

机械臂系统的具身智能实现需要决策模型规划机械臂在复杂多样化任务中的动作序列或是运动轨迹。在第三章和第四章的工作中，分别设计了两阶段的单任务和多任务策略学习框架，但完成任务还需要底层的运动控制器控制机械臂精确地执行既定动作序列或是任务轨迹。

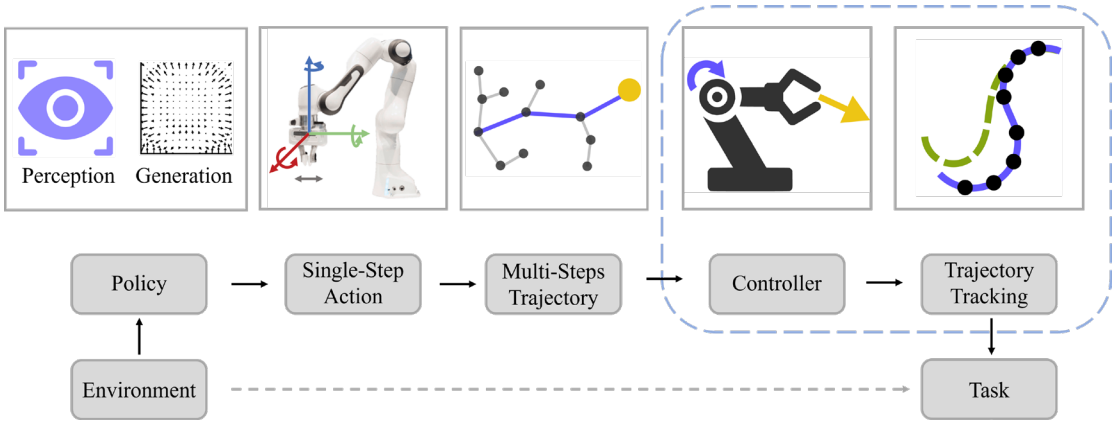


图 5.1 机械臂执行任务流程图

完整的机械臂执行给定任务流程如图 5.1 所示，前述工作得到的 ADP 和 AMTDP 策略，可以根据当前环境的视觉感知输出由多步动作组成的任务轨迹，其中单步动作包含了末端执行器的位姿变化。若暂不考虑末端执行器的具体类型，执行任务的剩余步骤可以视为是轨迹跟踪控制问题。因此，本章结合 ST 和 JMA 算法，开发了 ST-JMA 控制系统实现机械臂的轨迹跟踪控制，并给出了关于系统稳定性和收敛性的理论分析，确保了控制系统在理论层面的可靠性。同时，进行了仿真实验和实物实验，展示了 ST-JMA 系统在内部不确定性和外部扰动的情况下优异的轨迹跟踪性能。

5.1 算法设计

以往的研究已提出 JMA 方法[77]来处理机械臂跟踪控制问题，该方法无需依赖于机器人模型的知识，并克服了位置误差累积现象。受内部不确定性和外部干扰影响的 JMA 控制系统可表述为：

$$\begin{cases} \mathbf{u}(t)=\dot{\Theta}(t)=\hat{J}^{\dagger}(t)(\dot{\mathbf{p}}_{\mathrm{d}}(t)+\mu(\mathbf{p}_{\mathrm{d}}(t)-\mathbf{p}_{\mathrm{r}}(t))), \\ \dot{\hat{J}}(t)=\left(\ddot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\ddot{\Theta}(t)+\lambda(\dot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\dot{\Theta}(t))\right)\dot{\Theta}^{\dagger}(t), \end{cases} \tag{5.1}$$

其中 $\hat{J}(t)\in\mathbb{R}^{m\times n}$ 表示估计的雅可比矩阵，m 是末端执行器的自由度，而 n 是机械臂关节的自由度，$\hat{J}^{\dagger}(t)\in\mathbb{R}^{n\times m}$ 为其伪逆，$\mathbf{p}_{\mathrm{r}}(t)$ 为末端执行器的实时位置向量，

中国知网 https://www.cnki.net

$\mathbf{p}_{\mathrm{d}}(t)$ 为预定义路径，$\Theta(t)$ 为关节角，$\mathbf{u}(t)$ 为控制信号，$\mu \in \mathbb{R}^{+}$ 和 $\lambda \in \mathbb{R}^{+}$ 是两个超参数，然而，由于其指数收敛特性，JMA 方法的解已被证明具有无限长的收敛时间。此外，目前尚缺乏关于 JMA 对干扰的鲁棒性研究。

二阶滑模控制中的 ST 算法能够在不依赖先验估计的情况下，有效地构建一个鲁棒控制器。在控制理论中，通用的 ST 算法可以通过以下方程表示：

$$\begin{cases} \dot{x}_1 = -l_1 \mid x_1 \mid^{q} \operatorname{sign}(x_1) + x_2, \\ \dot{x}_2 = -l_2 \operatorname{sign}(x_1), \end{cases} \tag{5.2}$$

其中 $x_1 \in \mathbb{R}$ 和 $x_2 \in \mathbb{R}$ 是两个变量，l_1、l_2 和 q 为超参数，sign(•) 函数为符号函数，其形式为：

$$\operatorname{sign}(x) = \begin{cases} 1, & if \quad x > 0, \\ 0, & if \quad x = 0, \\ -1, & if \quad x < 0。 \end{cases} \tag{5.3}$$

为了全面捕捉机械臂控制过程中的瞬态和稳态信息，可以构造一个误差函数。该函数量化了预定路径与末端执行器在时刻 t 实际路径之间的差异。该函数的具体形式如下所示：

$$e_i(t) = \mathbf{p}_{\mathrm{d}i}(t) - \mathbf{p}_{\mathrm{r}i}(t)\,, \tag{5.4}$$

其中 $i = 1, 2, ..., m$。随后，基于 ST 算法，可以计算一个中间变量：

$$z_i(t) = -l_2 \int_0^t \operatorname{sign}(e_i(\tau))\mathrm{d}\tau\,, \tag{5.5}$$

根据式 (5.2)，通过代入 $x_1 = e_i(t)$ 和 $x_2 = z_i(t)$，可以得到：

$$\begin{cases} \dot{e}_i(t) = -l_1 \mid e_i(t) \mid^{q} \operatorname{sign}(e_i(t)) + z_i(t), \\ \dot{z}_i(t) = -l_2 \operatorname{sign}(e_i(t))。 \end{cases} \tag{5.6}$$

通过修改后的 ST 方程，设定一个超参数 κ，并使得 $l_1 = 2\kappa$ 和 $l_2 = \kappa^2$，第 i 个分量可以表示为：

$$\dot{e}_i(t) = -2\kappa \mid e_i(t) \mid^{q} \operatorname{sign}(e_i(t)) - \kappa^2 \int_0^t \operatorname{sign}(e_i(\tau))\mathrm{d}\tau\,, \tag{5.7}$$

进一步可以得到：

$$\dot{\mathbf{e}}(t) = -2\kappa \Omega^{q}(\mathbf{e}(t)) - \kappa^2 \int_0^t \operatorname{sign}(\mathbf{e}(\tau))\mathrm{d}\tau\,, \tag{5.8}$$

其中映射函数 $\Omega^{q}(\bullet): \mathbb{R}^{\mathrm{m}} \to \mathbb{R}^{\mathrm{m}}$ 的第 i 个分量描述为：

$$\Omega_i^{q}(e_i(t)) = \begin{cases} \mid e_i(t) \mid^{q}, & \text{if} \quad e_i(t) > 0, \\ 0, & \text{if} \quad e_i(t) = 0, \\ -\mid e_i(t) \mid^{q}, & \text{if} \quad e_i(t) < 0, \end{cases} \tag{5.9}$$

由机械臂的运动学方程式 (2.62)以及上述向量形式的式 (5.8)推导，并考虑到内部不确定性 $\Delta\varrho \in \mathbb{R}^{m \times n}$ 和外部扰动 $\sigma \in \mathbb{R}^{m}$ 的影响，相关的控制方程可以表示为如下形式：

中国知网 https://www.cnki.net

$$\begin{aligned}\dot{\mathbf{p}}_{\mathrm{d}}(t)-(J(\Theta(t))+\Delta\varrho)\dot{\Theta}(t)+\sigma=&-2\kappa\Omega^{q}(\mathbf{p}_{\mathrm{d}}(t)-\mathbf{p}_{\mathrm{r}}(t))\\&-\kappa^{2}\int_{0}^{t}\mathrm{sign}(\mathbf{p}_{\mathrm{d}}(\tau)-\mathbf{p}_{\mathrm{r}}(\tau))\mathrm{d}\tau+\sigma,\end{aligned}\tag{5.10}$$

式 (5.10)可以通过合并输入信号 $\mathbf{u}(t)$ 在速度级别显式重新表述，如下所示：

$$\begin{aligned}\mathbf{u}(t)=\dot{\Theta}(t)=\tilde{J}^{\dagger}(t)\big(&\dot{\mathbf{p}}_{\mathrm{d}}(t)+2\kappa\Omega^{q}(\mathbf{p}_{\mathrm{d}}(t)-\mathbf{p}_{\mathrm{r}}(t))\\&+\kappa^{2}\int_{0}^{t}\mathrm{sign}(\mathbf{p}_{\mathrm{d}}(\tau)-\mathbf{p}_{\mathrm{r}}(\tau))\mathrm{d}\tau\big)。\end{aligned}\tag{5.11}$$

其中 $\tilde{J}(t)=J(\Theta(t))+\Delta\varrho$ 是具有内部不确定性的雅可比矩阵。然后，考虑到未识别的参数和结构，对雅可比矩阵进行实时自适应和更新，这些调整通过利用估计器 $\hat{J}(t)$ 估计 $\tilde{J}(t)$ 来实现，随后，带有未知雅可比矩阵伪逆的控制式 (5.11)可以表示为：

$$\begin{aligned}\mathbf{u}(t)=\dot{\Theta}(t)=\hat{J}^{\dagger}(t)\big(&\dot{\mathbf{p}}_{\mathrm{d}}(t)+2\kappa\Omega^{q}(\mathbf{p}_{\mathrm{d}}(t)-\mathbf{p}_{\mathrm{r}}(t))\\&+\kappa^{2}\int_{0}^{t}\mathrm{sign}(\mathbf{p}_{\mathrm{d}}(\tau)-\mathbf{p}_{\mathrm{r}}(\tau))\mathrm{d}\tau\big)。\end{aligned}\tag{5.12}$$

为了自适应机械臂的雅可比矩阵，包含估计量 $\hat{J}(t)$ 的误差函数由下式给出：

$$\varepsilon(t)=\dot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\dot{\Theta}(t)\,,\tag{5.13}$$

其中 $\varepsilon(t)\in\mathbb{R}^{\mathrm{m}}$。然后通过零化神经网络使得：

$$\dot{\varepsilon}(t)=-\lambda\varepsilon(t)\,,\tag{5.14}$$

其中 $\lambda\in\mathbb{R}^{+}$ 为超参数，用于控制收敛速度，然后可以推导出：

$$\ddot{\mathbf{p}}_{\mathrm{r}}(t)-\dot{\hat{J}}(t)\dot{\Theta}(t)-\hat{J}(t)\ddot{\Theta}(t)=-\lambda(\dot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\dot{\Theta}(t))\,。\tag{5.15}$$

上述方程可以重新表述为：

$$\dot{\hat{J}}(t)=\big(\ddot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\ddot{\Theta}(t)+\lambda(\dot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\dot{\Theta}(t))\big)\dot{\Theta}^{\dagger}(t)。\tag{5.16}$$

式 (5.16)表示整个控制系统的雅可比矩阵自适应方程。需要注意的是在雅可比矩阵自适应过程中，机器人系统始终保持非奇异配置。

根据控制方程 (5.12)和雅可比矩阵自适应方程 (5.16)，可以得到整个 ST-JMA 控制系统如下：

$$\begin{cases}\begin{aligned}\mathbf{u}(t)=\dot{\Theta}(t)=\hat{J}^{\dagger}(t)\big(&\dot{\mathbf{p}}_{\mathrm{d}}(t)+2\kappa\Omega^{q}(\mathbf{p}_{\mathrm{d}}(t)-\mathbf{p}_{\mathrm{r}}(t))\\&+\kappa^{2}\int_{0}^{t}\mathrm{sign}(\mathbf{p}_{\mathrm{d}}(\tau)-\mathbf{p}_{\mathrm{r}}(\tau))\mathrm{d}\tau\big),\end{aligned}\\\dot{\hat{J}}(t)=\big(\ddot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\ddot{\Theta}(t)+\lambda(\dot{\mathbf{p}}_{\mathrm{r}}(t)-\hat{J}(t)\dot{\Theta}(t))\big)\dot{\Theta}^{\dagger}(t)。\end{cases}\tag{5.17}$$

5.2 理论分析

本节详细呈现了完整的理论分析，以研究 ST-JMA 控制系统(5.17)的稳定性和收敛性。

中国知网 https://www.cnki.net

5.2.1 无扰动的全局稳定性证明

定理 1：针对轨迹跟踪控制问题(2.61)，当给定超参数$\kappa>0$以及$q=1/2$，从第 i 个初始位置$\mathbf{p}_{ri}(0)$开始，ST-JMA 控制系统表现出全局稳定性。因此，第 i 个实际路径$\mathbf{p}_{ri}(t)$在没有外部干扰的情况下，依据 Lyapunov 理论，全局收敛到与第 i 个预定义路径$\mathbf{p}_{di}(t)$一致的轨迹。

证明：为了处理控制问题(2.61)，第 i 个子系统在 ST-JMA 系统(5.17)框架下的动态方程可以表示为以下扩展形式：

$$\begin{cases}\dot{e}_i(t)=-2\kappa\,|e_i(t)|^q\,\mathrm{sign}(e_i(t))+z_i(t),\\ \dot{z}_i(t)=-\kappa^2\mathrm{sign}(e_i(t)),\\ \dot{\varepsilon}_i(t)=-\lambda\varepsilon_i(t),\end{cases}\tag{5.18}$$

定义 Lyapunov 候选函数为：

$$\mathcal{V}(t)=\kappa^2\,|e_i(t)|+\frac{z_i^2(t)}{2}+\frac{\varepsilon_i^2(t)}{2}。\tag{5.19}$$

当$e_i(t)=0$以及$\varepsilon_i(t)=0$时，$\mathcal{V}(t)=0$，当$e_i(t)\neq0$或者$\varepsilon_i(t)\neq0$时，$\mathcal{V}(t)>0$，因此$\mathcal{V}(t)$表现出正定性。可以计算$\mathcal{V}(t)$对时间的导数为：

$$\begin{aligned}\dot{\mathcal{V}}(t)&=\kappa^2\mathrm{sign}(e_i(t))\dot{e}_i(t)+z_i(t)\dot{z}_i(t)+\varepsilon_i(t)\dot{\varepsilon}_i(t)\\&=-\kappa^3\,|e_i(t)|^q+\kappa^2\mathrm{sign}(e_i(t))z_i(t)\\&\quad-\kappa^2z_i(t)\mathrm{sign}(e_i(t))-\lambda\varepsilon_i^2(t)\\&=-\kappa^3\,|e_i(t)|^q-\lambda\varepsilon_i^2(t)\\&\le0。\end{aligned}\tag{5.20}$$

可以得到，给定$\kappa>0$以及$q=1/2$，对于时间$t\in[0,+\infty)$，$\dot{\mathcal{V}}(t)$表现出负定性。根据Lyapunov稳定性理论的标准以及不连续系统的LaSalle不变性原理的推广，ST-JMA 系统实现了全局稳定性，并且误差函数$e_i(t)$=$\mathbf{p}_{di}(t)-\mathbf{p}_{ri}(t)$的每个分量全局收敛至 0。因此，第 i 个实际路径$\mathbf{p}_{ri}(t)$全局收敛到第 i 个预定义路径$\mathbf{p}_{di}(t)$。证明完毕。

5.2.2 无扰动的有限时间收敛性证明

定理 2：当给定超参数$\kappa>0$以及$q=1/2$，并且从初始状态出发，时刻$t=0$时误差为$e_i(0)$，由 ST-JMA 控制系统(5.17)生成的第 i 个实际路径$\mathbf{p}_{ri}(t)$会在有限时间T_f内全局收敛到第 i 个预定义路径$\mathbf{p}_{di}(t)$，T_f如下所示：

$$T_\mathrm{f}=\frac{4\sqrt{2\max\{|e_i(0)|\}}}{\kappa},\tag{5.21}$$

其中$\max\{|e_i(0)|\}$表示$|e_i(0)|$的最大值，$i=1,2,...,m$。

中国知网 https://www.cnki.net

证明：考虑一个中间变量：

$$\delta(t)=2\,|e_i(t)|^{q}\ \mathrm{sign}(e_i(t))\,, \tag{5.22}$$

此时 $\mathrm{sign}(\delta(t))=\mathrm{sign}(e_i(t))$ 以及 $|\delta(t)|=2\,|e_i(t)|^{q}$ 仍然有效，然后得到 $\delta(t)$ 对时间的导数：

$$\dot{\delta}(t)=|e_i(t)|^{-q}\ \dot{e}_i(t)=\frac{\dot{e}_i(t)}{|e_i(t)|^{q}}\,, \tag{5.23}$$

通过替换 $\delta(t)$，状态方程(5.6)可以修改为：

$$\begin{aligned}\dot{\delta}(t)&=-l_1\mathrm{sign}(e_i(t))+\frac{z_i(t)}{|e_i(t)|^{q}}\\&=-l_1\mathrm{sign}(\delta(t))+\frac{z_i(t)}{|\delta(t)|}\\&=-l_1\frac{\delta(t)}{|\delta(t)|}+\frac{z_i(t)}{|\delta(t)|},\end{aligned} \tag{5.24}$$

再令 $l_1=2\kappa$ 和 $l_2=\kappa^2$ 得到：

$$\dot{\delta}(t)=-2\kappa\frac{\delta(t)}{|\delta(t)|}+\frac{z_i(t)}{|\delta(t)|}, \tag{5.25}$$

以及

$$\dot{z}_i(t)=-\kappa^2\mathrm{sign}(e_i(t))=-\kappa^2\mathrm{sign}(\delta(t))=-\kappa^2\frac{\delta(t)}{|\delta(t)|}\,, \tag{5.26}$$

选择如下 Lyapunov 候选函数：

$$\mathcal{F}(t)=\frac{1}{2}\left(\delta(t)-\frac{z_i(t)}{\kappa}\right)^{2}+\frac{\delta^2(t)}{2}\,, \tag{5.27}$$

$\mathcal{F}(t)$ 的时间导数为：

$$\begin{aligned}\dot{\mathcal{F}}(t)&=\left(\delta(t)-\frac{z_i(t)}{\kappa}\right)\left(\dot{\delta}(t)-\frac{-\kappa^2\delta(t)}{\kappa\,|\delta(t)|}\right)+\delta(t)\dot{\delta}(t)\\&=\left(\delta(t)-\frac{z_i(t)}{\kappa}\right)\left(\dot{\delta}(t)+\frac{\kappa\delta(t)}{|\delta(t)|}\right)+\delta(t)\dot{\delta}(t),\end{aligned} \tag{5.28}$$

根据式 (5.25)得到：

$$\dot{\delta}(t)+\kappa\frac{\delta(t)}{|\delta(t)|}=-\kappa\frac{\delta(t)}{|\delta(t)|}+\frac{z_i(t)}{|\delta(t)|}\,, \tag{5.29}$$

将式 (5.29)代入式 (5.28)可以得到：

中国知网 https://www.cnki.net

$$\begin{aligned}\dot{\mathcal{F}}(t)&=\left(\delta(t)-\frac{z_i(t)}{\kappa}\right)\left(-\kappa\frac{\delta(t)}{|\delta(t)|}+\frac{z_i(t)}{|\delta(t)|}\right)+\delta(t)\dot{\delta}(t)\\&=-\frac{\kappa}{|\delta(t)|}\left(\delta(t)-\frac{z_i(t)}{\kappa}\right)^2+\frac{\kappa\delta(t)}{|\delta(t)|}\left(-2\delta(t)+\frac{z_i(t)}{\kappa}\right)\\&=\frac{-\kappa}{2|\delta(t)|}\left(\delta(t)-\frac{z_i(t)}{\kappa}+\delta(t)\right)^2\\&\quad+\frac{-\kappa}{2|\delta(t)|}\left(\left(\delta(t)-\frac{z_i(t)}{\kappa}\right)^2+\delta^2(t)\right)\\&=\frac{-\kappa}{|\delta(t)|}\left(\frac{1}{2}\left(2\delta(t)-\frac{z_i(t)}{\kappa}\right)^2+\mathcal{F}(t)\right)\\&\le\frac{-\kappa\mathcal{F}(t)}{|\delta(t)|}。\end{aligned}\tag{5.30}$$

因为：

$$\mathcal{F}(t)=\frac{1}{2}\left(\delta(t)-\frac{z_i(t)}{\kappa}\right)^2+\frac{\delta^2(t)}{2}\ge\frac{\delta^2(t)}{2},\tag{5.31}$$

所以可以得到：

$$\sqrt{2\mathcal{F}(t)}\ge|\delta(t)|,\tag{5.32}$$

因此：

$$\frac{1}{\sqrt{2\mathcal{F}(t)}}\le\frac{1}{|\delta(t)|},\tag{5.33}$$

于是：

$$\frac{-\kappa\mathcal{F}(t)}{\sqrt{2\mathcal{F}(t)}}\ge\frac{-\kappa\mathcal{F}(t)}{|\delta(t)|},\tag{5.34}$$

通过式 (5.30)和式 (5.34)可以进一步推导出：

$$\dot{\mathcal{F}}(t)\le\frac{-\kappa\mathcal{F}(t)}{\sqrt{2\mathcal{F}(t)}}=\frac{-\kappa\sqrt{\mathcal{F}(t)}}{\sqrt{2}},\tag{5.35}$$

因此：

$$\frac{\dot{\mathcal{F}}(t)}{\sqrt{\mathcal{F}(t)}}\le\frac{-\kappa}{\sqrt{2}},\tag{5.36}$$

式 (5.36)也等价于：

$$\frac{2\mathrm{d}\sqrt{\mathcal{F}(t)}}{\mathrm{d}t}\le\frac{-\kappa}{\sqrt{2}},\tag{5.37}$$

中国知网 https://www.cnki.net

通过式 (5.37)两侧积分，可以推导出：

$$\int_0^t \frac{2\mathrm{d}\sqrt{\mathcal{F}(\tau)}}{\mathrm{d}\tau} \le \frac{-\kappa}{\sqrt{2}} t \,, \tag{5.38}$$

以及：

$$2\left(\sqrt{\mathcal{F}(t)} - \sqrt{\mathcal{F}(0)}\right) \le \frac{-\kappa}{\sqrt{2}} t \,, \tag{5.39}$$

因此可以推导出：

$$\mathcal{F}(t) \le \left(\frac{-\kappa t}{2\sqrt{2}} + \sqrt{\mathcal{F}(0)} \right)^2 , \tag{5.40}$$

显然，根据式 (5.40)，当：

$$\begin{aligned} t = T_{\mathrm{fi}} &= \frac{2\sqrt{2\mathcal{F}(0)}}{\kappa} \\ &= \frac{2}{\kappa}\sqrt{\left(\delta(0) - \frac{z_i(0)}{\kappa}\right)^2 + \delta^2(0)} \\ &= \frac{2}{\kappa}\sqrt{\left(2\,|e_i(0)|^q\,\mathrm{sign}(e_i(0)) - \frac{z_i(0)}{\kappa}\right)^2 + \left(2\,|e_i(0)|^q\right)^2} \\ &= \frac{2}{\kappa}\sqrt{8\,|e_i(0)| + \frac{z_i^2(0)}{\kappa^2} - 4\mathrm{sign}(e_i(0))\,|e_i(0)|^q\,\frac{z_i(0)}{\kappa}}, \end{aligned} \tag{5.41}$$

以及 $q = 1/2$ 时，可以得到 $\mathcal{F}(t) = 0$。

同时考虑式 (5.35)可以得到：

$$\dot{\mathcal{F}}(t) \le \frac{-\kappa\sqrt{\mathcal{F}(t)}}{\sqrt{2}} \le 0 \,, \tag{5.42}$$

根据式 (5.41)和式 (5.42)中的结果，可以推导出当 $t \ge T_{\mathrm{fi}}$ 时，$\mathcal{F}(t) = 0$ 仍然成立，因此，可以得出结论：从第 i 个初始位置 $\mathbf{p}_{ri}(0)$ 以及误差 $e_i(0)$ 开始，由 ST-JMA 控制系统(5.17)生成的第 i 个实际路径 $\mathbf{p}_{ri}(t)$ 会在有限时间 T_{fi} 内全局收敛到第 i 个预定义路径 $\mathbf{p}_{\mathrm{d}i}(t)$。此外，值得注意的是：

$$z_i(t) = \int_0^t \mathrm{sign}(e_i(\tau))\mathrm{d}\tau \,, \tag{5.43}$$

因为 $z_i(0) = 0$ 成立，可以推导出：

$$\begin{aligned} T_{\mathrm{fi}} &= \frac{2}{\kappa}\sqrt{8\,|e_i(0)| + \frac{z_i^2(0)}{\kappa^2} - 4\mathrm{sign}(e_i(0))\,|e_i(0)|^q\,\frac{z_i(0)}{\kappa}} \\ &= \frac{4\sqrt{2\,|e_i(0)|}}{\kappa}。 \end{aligned} \tag{5.44}$$

证明完毕。

中国知网 https://www.cnki.net

5.2.3 有扰动的全局稳定性证明

定理 3：针对轨迹跟踪控制问题(2.62)，当考虑到相关模型中存在加性常数干扰σ，并且从第 i 个初始位置$\mathbf{p}_{ri}(0)$开始，ST-JMA 控制系统(5.17)表现出全局稳定性，第 i 个实际路径$\mathbf{p}_{ri}(t)$，全局收敛到与第 i 个预定义路径$\mathbf{p}_{di}(t)$一致的轨迹，与 Lyapunov 理论相一致。

证明：鉴于 ST-JMA 系统(5.17)中存在加性干扰σ，第i个动态子系统的误差函数可以表示为：

$$\begin{cases}\dot{e}_i(t)=-2\kappa\,|e_i(t)|^q\,\mathrm{sign}(e_i(t))-\kappa^2\int_0^t\mathrm{sign}(e_i(\tau))\mathrm{d}\tau+\sigma_i,\\ \dot{\varepsilon}_i(t)=-\lambda\varepsilon_i(t),\end{cases}\tag{5.45}$$

以及$\dot{\sigma}_i=0$，因此可以得到：

$$\begin{cases}\dot{e}_i(t)=-2\kappa\,|e_i(t)|^q\,\mathrm{sign}(e_i(t))+s_i(t),\\ \dot{s}_i(t)=-\kappa^2\mathrm{sign}(e_i(t)),\\ \dot{\varepsilon}_i(t)=-\lambda\varepsilon_i(t),\end{cases}\tag{5.46}$$

与定理 1 的证明步骤类似，选择以下 Lyapunov 候选函数：

$$\mathcal{U}(t)=\kappa^2\,|e_i(t)|+\frac{s_i^2(t)}{2}+\frac{\varepsilon_i^2(t)}{2},\tag{5.47}$$

当$e_i(t)=0$以及$\varepsilon_i(t)=0$时，$\mathcal{U}(t)=0$，当$e_i(t)\neq 0$或者$\varepsilon_i(t)\neq 0$时，$\mathcal{U}(t)>0$，因此$\mathcal{U}(t)$表现出正定性。可以计算$\mathcal{U}(t)$对时间的导数为：

$$\begin{aligned}\dot{\mathcal{U}}(t)&=\kappa^2\mathrm{sign}(e_i(t))\dot{e}_i(t)+s_i(t)\dot{s}_i(t)+\varepsilon_i(t)\dot{\varepsilon}_i(t)\\&=-\kappa^3\,|e_i(t)|^q+\kappa^2\mathrm{sign}(e_i(t))s_i(t)\\&\quad-\kappa^2 s_i(t)\mathrm{sign}(e_i(t))-\lambda\varepsilon_i^2(t)\\&=-\kappa^3\,|e_i(t)|^q-\lambda\varepsilon_i^2(t)\le 0。\end{aligned}\tag{5.48}$$

可以得到，在$\kappa>0$和$q=1/2$的前提下，对于时间$t\in[0,+\infty)$，$\dot{\mathcal{U}}(t)$表现出负定性。根据 Lyapunov 稳定性理论的标准以及不连续系统的 LaSalle 不变性原理的推广，ST-JMA 控制系统(5.17)实现了全局稳定性，误差函数$e_i(t)$=$\mathbf{p}_{di}(t)-\mathbf{p}_{ri}(t)$的每个分量全局收敛至 0。因此，第 i 个实际路径$\mathbf{p}_{ri}(t)$全局收敛到第 i 个预定义路径$\mathbf{p}_{di}(t)$。证明完毕。

5.2.4 有扰动的有限时间收敛性证明

定理 4：当考虑到相关模型中存在加性常数干扰 ，并且给定超参数$\kappa>0$以及$q=1/2$，从初始状态出发，时刻$t=0$时误差为$e_i(0)$，由 ST-JMA 控制系统(5.17)生成的第 i 个实际路径$\mathbf{p}_{ri}(t)$会在有限时间T_f内全局收敛到第 i 个预定义路径$\mathbf{p}_{di}(t)$，T_f如下所示：

中国知网 https://www.cnki.net

$$T_{\mathrm{f}}=\frac{4\sqrt{2\max\{|e_i(0)|\}}}{\kappa}, \tag{5.49}$$

并且，有限收敛时间不受外部干扰σ强度的影响。

证明：ST-JMA 控制系统(5.17)带有加性常数干扰$\sigma\neq 0$的方程与 ST-JMA 控制系统(5.17)在没有外部干扰时的方程是等价的，如式 (5.6)所描述。因此，通过采用与式 (5.25)和式 (5.26)中引入的相同变量替换$\delta(t)$，可以扩展从定理 2 证明过程中推导出的相同结果。证明完毕。

5.3 实验分析

5.3.1 仿真实验

本节以 PUMA560 机械臂作为分析载体，在 Matlab 软件中进行仿真实验，机械臂结构如图 5.2 所示。

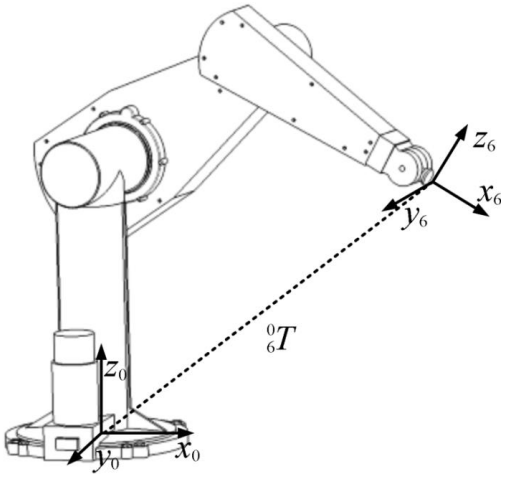


图 5.2 PUMA560 机械臂结构示意图

为了确保通用性，仿真实验中机械臂运动的持续时间标准化为 20 秒。初始关节角度向量$\Theta(0)$为$[-0,-\pi/4,0,-2\pi/3,-\pi/4,0]^{\mathrm{T}}$ rad，关节速度初始化为零向量，可得到初始雅可比矩阵为：

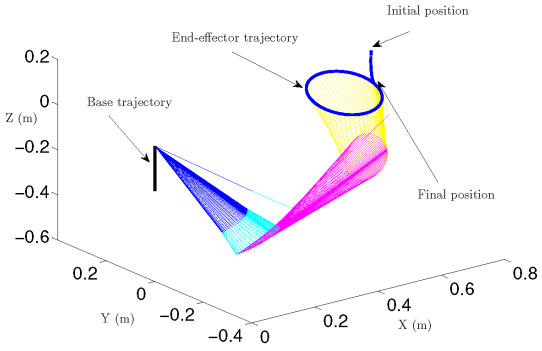
$$\hat{J}=\begin{bmatrix}0.007 & -0.178 & -0.483 & -0.111 & 0.192 & 0\\ 0.689 & 0 & 0 & -0.091 & -0.157 & 0\\ 0 & 0.689 & 0.384 & 0.111 & 0.064 & 0\end{bmatrix}。$$

预定义参数$\kappa=2$和$\lambda=100$，以及控制系统受到$[0.06,0.04,0.05]$的外部扰动。

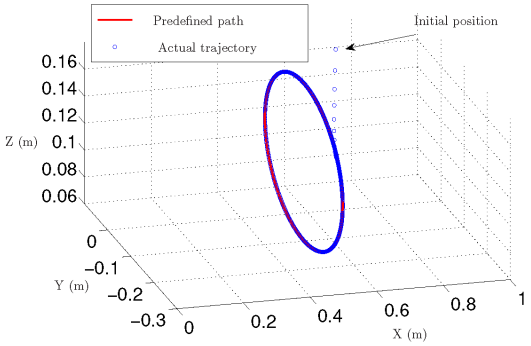
控制系统(5.17)利用 ST-JMA 方法在考虑不确定性和干扰的情况下，跟踪圆形曲线和玫瑰形曲线路径的运动结果分别如图 5.3 和图 5.4 所示。具体来说，图 5.3(a)和 5.4(a)提供了运动过程的三维可视化，展示了末端执行器稳定的圆形曲线和玫瑰形曲线轨迹跟踪。图 5.3(b)和 5.4(b)展示了末端执行器的实际轨迹在瞬态状态下迅速接近预定义路径，并在稳态状态下紧密对齐。从图 5.3(c)和 5.4(c)

中国知网 https://www.cnki.net

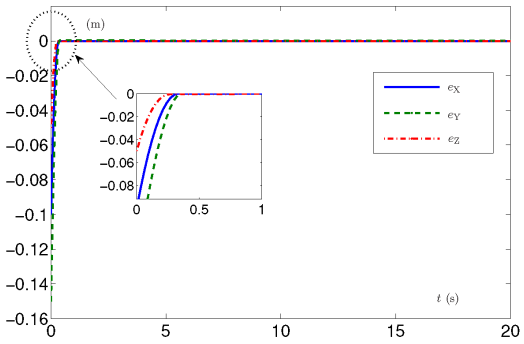
中可以看出误差的每个分量都在有限时间收敛至零，此外图 5.3(d)和 5.4(d)的误差曲线可以得到收敛时间约为 0.4 秒，与定理 4 相符，且进一步展示了 ST-JMA 控制系统快速的收敛速度和高精度的跟踪性能。



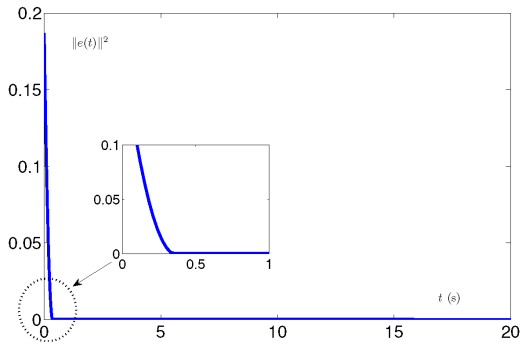
(a) 运动的三维可视化



(b) 预定义路径和实际轨迹

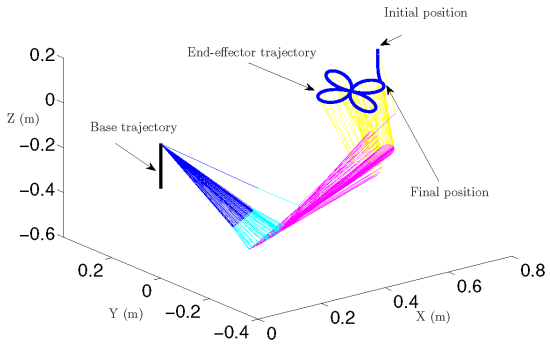


(c) 误差分量曲线

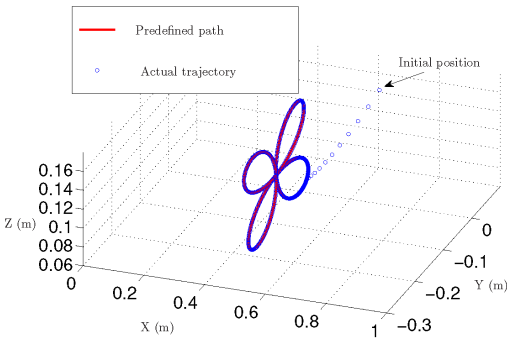


(d) 误差曲线

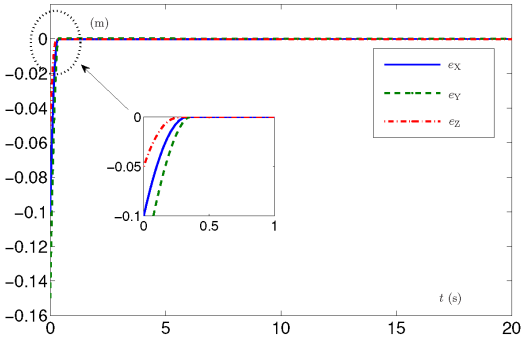
图 5.3 ST-JMA 系统控制末端执行器跟踪圆形轨迹的运动仿真结果



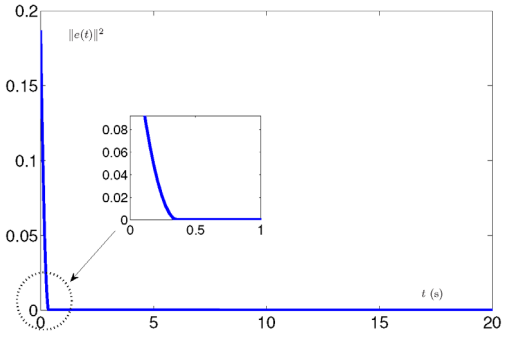
(a) 运动的三维可视化



(b) 预定义路径和实际轨迹



(c) 误差分量曲线

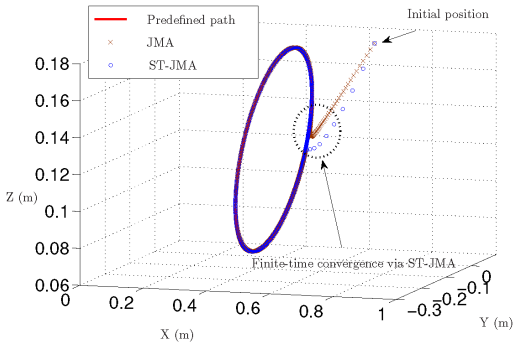


(d) 误差曲线

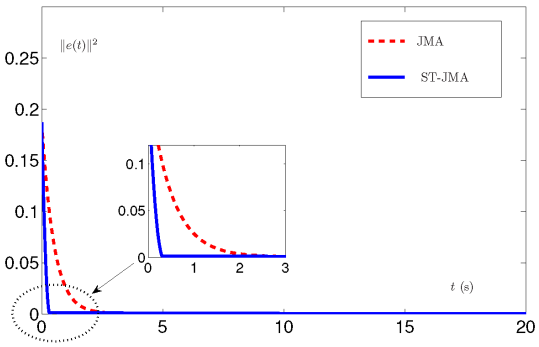
图 5.4 ST-JMA 系统控制末端执行器跟踪玫瑰形轨迹的运动仿真结果

中国知网 https://www.cnki.net

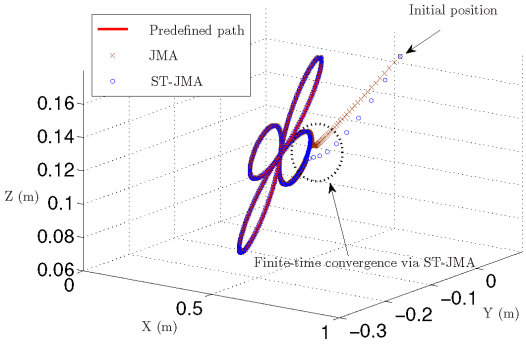
5.3.2 对比实验



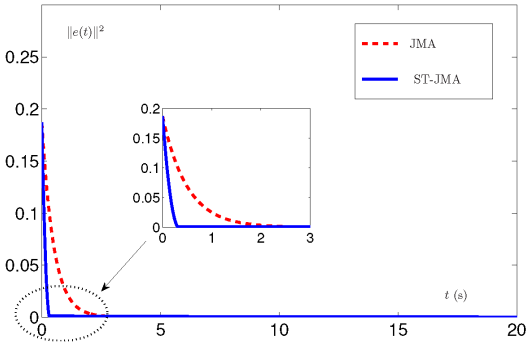
(a) 圆形预定义路径和实际轨迹



(b) 圆形轨迹的误差曲线

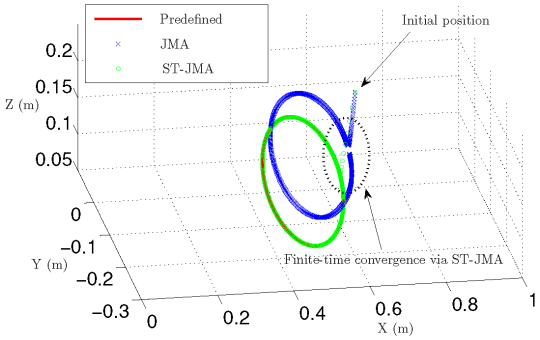


(c) 玫瑰形预定义路径和实际轨迹

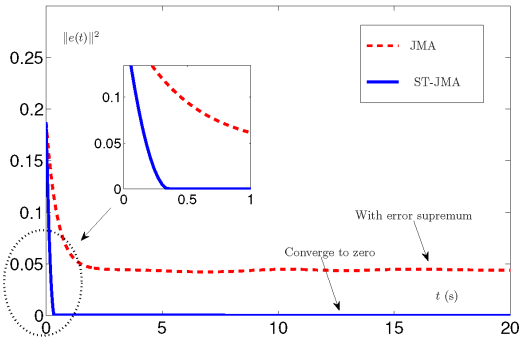


(d) 玫瑰形轨迹的误差曲线

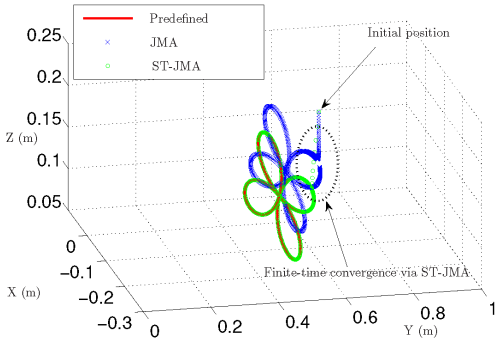
图 5.5 无外部扰动情况下，基于 JMA 方法与基于 ST-JMA 方法对比结果



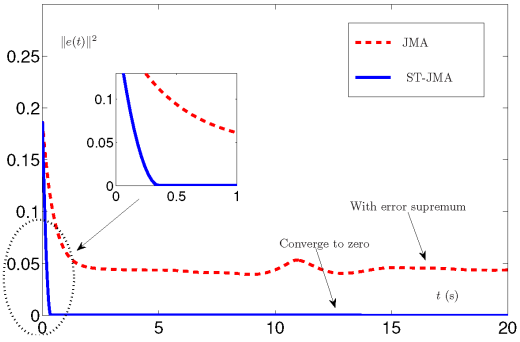
(a) 圆形预定义路径和实际轨迹



(b) 圆形轨迹的误差曲线



(c) 玫瑰形预定义路径和实际轨迹



(d) 玫瑰形轨迹的误差曲线

图 5.6 有外部扰动情况下，基于 JMA 方法与基于 ST-JMA 方法对比结果

中国知网 https://www.cnki.net

为比较两种控制系统的性能差异，分别采用传统 JMA 方法(5.1)和提出的 ST-JMA 方法(5.17)对末端执行器的轨迹跟踪进行了对比实验。实验选取了圆形和玫瑰形两种轨迹作为跟踪目标，以全面评估两种控制方法的跟踪精度和稳定性。

其中没有外部扰动的对比结果如图 5.5 所示。具体地，图 5.5(a)和图 5.5(c)展示了机械臂末端执行器的跟踪过程，通过两种不同方法跟踪预定的圆形和玫瑰形路径，展示了它们不同的收敛特性，可以直观地看出，基于 ST-JMA 的控制使得末端执行器能更快速地收敛至预定义路径。同时，从图 5.5(b)和图 5.5(d)的误差曲线中可以看出基于 ST-JMA 的控制系统收敛时间约为 0.4 秒，而 ST-JMA 的控制系统收敛时间约为 2 秒，表明 ST-JMA 方法在有限时间收敛特性上对 JMA 方法的改进效果。

引入外部扰动的对比结果如图 5.6 所示。可以看出 ST-JMA 控制系统与理论结果一致，继续表现出有限时间收敛。而采用传统 JMA 方法的控制系统则因外部扰动的影响使得实际轨迹存在一个稳态误差。总而言之，ST-JMA 方法在收敛模式和鲁棒性方面优于传统 JMA 方法，表明其在复杂控制应用中的适应性更强。

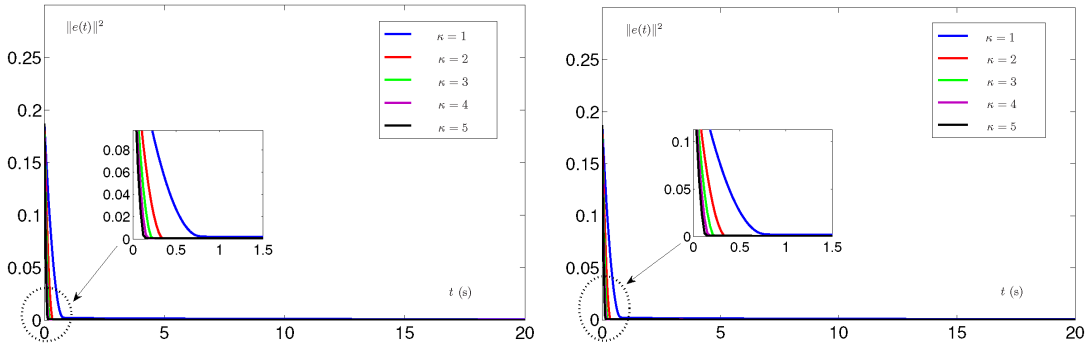
5.3.3 消融实验

然后进行了消融实验，研究了不同超参数 κ，不同的初始位置 $\mathbf{p}_r(0)$，以及不同的外部扰动强度 σ 对 ST-JMA 控制系统的影响。

从图 5.7 中可以看出，随着超参数 κ 的增大，解的收敛速度呈现出更快的加速趋势。

从图 5.8 中可以看出不同的初始状态下系统都能快速收敛，且随着初始误差值的减小，误差的收敛速度加快。

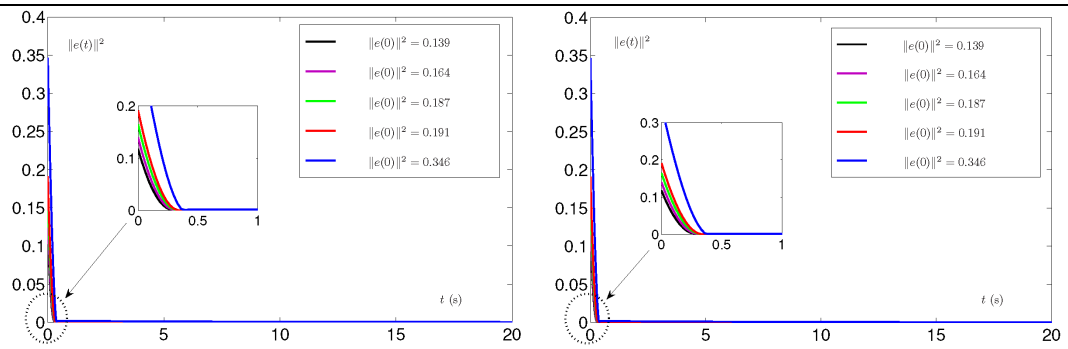
从图 5.9 中可以看出，不同外部扰动 ξ_i（其中 i=1,2,⋯,5）对收敛时间的影响微乎其微。



(a) 圆形轨迹　　(b) 玫瑰形轨迹

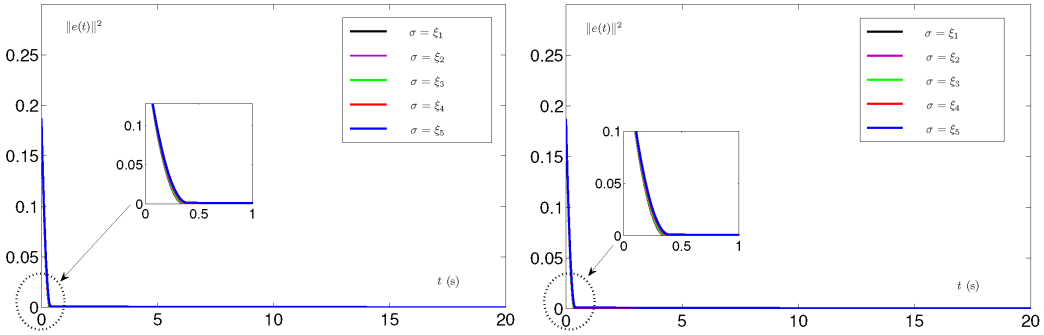
图 5.7 不同超参数 κ 情况下，ST-JMA 系统控制末端执行器跟踪轨迹的误差曲线

中国知网 https://www.cnki.net



(a) 圆形轨迹　　(b) 玫瑰形轨迹

图 5.8 不同初始位置情况下，ST-JMA 系统控制末端执行器跟踪轨迹的误差曲线



(a) 圆形轨迹　　(b) 玫瑰形轨迹

图 5.9 不同外部扰动情况下，ST-JMA 系统控制末端执行器跟踪轨迹的误差曲线

5.3.4 实物实验

最后，ST-JMA 控制方法被应用于一个 6 自由度的 Innfos Gluon 实物机械臂上，以评估其在现实环境中的跟踪控制能力，实验平台如图 5.10 所示。

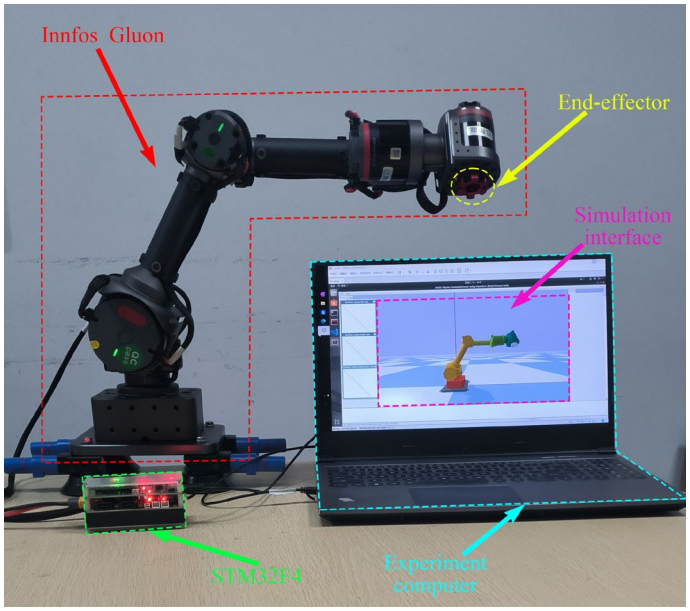


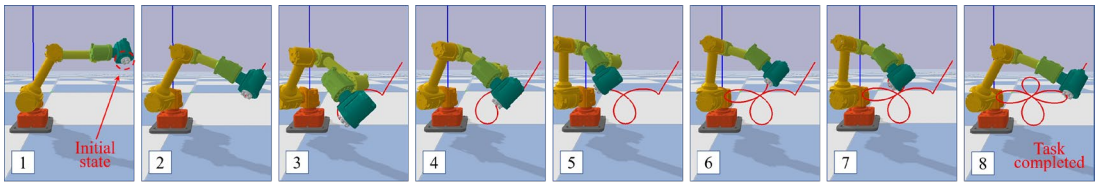
图 5.10 实物实验平台

机械臂的初始关节角度向量 $\Theta(0)$ 为 $[-0,-\pi/3,\pi/3,-\pi/2,-\pi/3,0]^{\mathrm{T}}$ rad，关节速度初始化为零向量，可得到初始雅可比矩阵为：

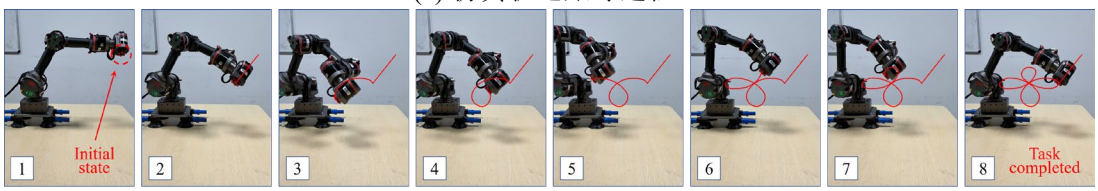
中国知网　https://www.cnki.net

$$\hat{J}=\begin{bmatrix}0.137 & 0.140 & -0.036 & -0.036 & 0 & 0\\ 0.354 & 0 & 0 & 0 & -0.036 & 0\\ 0 & -0.354 & -0.252 & -0.079 & 0.021 & 0\end{bmatrix}。$$

与此同时，Matlab 仿真实验中设定的其他参数直接迁移到该系统中。在执行相关的 Pybullet 仿真测试以初步确保安全性考虑后，进行了控制系统(5.17)的实物测试，以验证 ST-JMA 方法在物理实现上的可行性。结果如图 5.11 所示。



(a) 仿真轨迹跟踪过程



(b) 真实轨迹跟踪过程

图 5.11 Innfos Gluon 机械臂的仿真和实验结果，其末端执行器在瞬态状态下迅速从初始位置过渡到规划的轨迹，并在其空间运动中跟踪预定义的玫瑰形轨迹

5.4 本章小结

本章提出了一种基于 ST-JMA 方法的新型控制系统(5.17)。该方法利用时间导数和时间积分数据作为反馈，有效地将隐式和不可测量的信息转化为显式和可测量的输入输出数据。此外，从理论层面证明了所提出的方法具有全局稳定性、有限时间收敛性等优点。本章还对 ST-JMA 系统进行了实验证明，在无外部扰动和有外部扰动的情况与传统 JMA 方法进行了对比，也进行了超参数κ、初始位置、外部扰动强度的消融实验。从 PUMA560 机械臂获得的仿真结果验证了 ST-JMA 方法在多种跟踪路径上的有效性、收敛性、鲁棒性和适应性。最后，使用 6 自由度 Innfos Gluon 机械臂进行的实物测试也确认了其现实可实现性。

中国知网 https://www.cnki.net

第六章 总结与展望

机械臂系统在协作医疗、工业制造、航空航天等领域的广泛应用，要求其具备在复杂、动态环境中执行多样化任务的能力。传统方法依赖预设规则或单一学习范式，难以应对环境的不确定性与任务的多样性。具身智能通过智能体与环境的交互学习，为解决这一问题提供了新的思路。本文围绕机械臂的智能决策与控制，提出了一系列创新方法，旨在提升机械臂系统在复杂任务中的决策能力与执行效率。

6.1 本文工作总结

本文的贡献主要包括以下几个方面：

（1）在单任务决策方法上，提出了自适应扩散策略（ADP）。在模型架构上进行模块化设计，ADP 由特征提取、条件控制、动作生成三个模块构成。特别是在特征提取模块上，ADP 采用了多元编码器以简易高效地提取时空信息。在策略训练上，设计了扩散策略预训练和强化学习微调两阶段的训练流程，结合了模仿学习训练高效和强化学习能通过与环境交互优化策略等的优势，克服了模仿学习泛化能力不足和强化学习训练采样成本高等的劣势。具体实施上，又采用了低秩适应和行为克隆正则化等微调训练策略，保留了预训练知识并约束了微调更新的幅度，降低了灾难性遗忘的风险，提升了训练的稳定性和环境交互的安全性。通过与其他先进方法对比，体现了 ADP 性能的优越性。随后通过可视化结果直观展示了 ADP 微调策略的效果，可以在保持专家行为模式的情况下，通过参数适应在部分动作的细节上做出了轻微的调整，在防止极端动作的保证下使得策略执行任务从失败到成功。最后通过一系列消融实验体现了 ADP 捕捉长距离信息及生成长距离动作的能力，以及训练效率高，对专家演示要求低等特点。

（2）在多任务决策方法上，提出了自适应多任务扩散策略（AMTDP）。建立在 ADP 的基础上，通过引入混合专家（MoE）结构，设计了 MoE-FiLM 和 MoE-LoRA 模块改进了 ADP 中的原始对应模块，将 ADP 单任务策略扩展为 AMTDP 多任务策略。并引入视觉语言模型（VLM）为微调训练自动生成奖励，在一定程度上改善了强化学习需要为每个任务人工设计奖励函数的难点。通过与其他先进方法对比，体现了 AMTDP 保留了 ADP 高效训练的优势，并证明了 MoE 结构的多任务决策能力，以及 VLM 奖励函数的有效性。

（3）在轨迹跟踪控制方法上，将超螺旋（ST）滑模控制与雅可比矩阵自

中国知网 https://www.cnki.net

适应（JMA）方法相结合，提出了一种基于 ST-JMA 方法的新型控制系统，成功解决了机械臂受扰跟踪控制问题。ST-JMA 方法能够利用时间导数和时间积分信息，同时将隐式且不可测量的数据转换为显式且可测量的数据，从而克服了传统 JMA 方法中无法同时对抗内部不确定性和外部扰动的缺陷。通过对机械臂的全面理论分析和实际应用验证，ST-JMA 控制系统展现了其全局稳定性、有限时间收敛性、鲁棒性以及现实可实现性，为相关控制问题提供了高效且可靠的解决方案。

6.2 未来展望

本文提出的 ADP 单任务决策方法，AMTDP 多任务决策方法以及 ST-JMA 控制方法都具有较好的性能，但在一些方面仍然存在改进空间：

（1）在模型架构上，ADP 的特征编码器在提取多种特征后，对所有的特征只是进行了简单的连接处理，未来的研究中可以尝试结合交叉注意力等的多模态特征融合方法以及更高效的特征提取模型来提高策略性能。另外，ADP 动作生成采用的基于 U-Net 结构的扩散模型，未来可以尝试例如 Diffusion Transformer 等结构的扩散模型。

（2）本文采用的 VLM 是针对计算机视觉任务开发的 CLIP 模型，迁移到机器人任务上会存在先验偏差，而且基于 CLIP 的奖励函数只能提供模糊而非精确的奖励信号。目前，已经有研究提出针对机器人任务的 VLM 或者视觉语言动作模型，未来可以尝试更加强大的大模型为策略训练提供指导。

（3）AMTDP 采用了较为简单的 MoE 结构，可能存在专家负载不均衡等问题，未来可以通过改进的 MoE 结构来提高策略的训练效率和多任务决策能力。

（4）由于存在仿真到现实的差距、现实任务的奖励函数难以设计、现实设备限制等问题，ADP、AMTDP 方法没有在现实应用中得到验证，未来可以通过逐步解决这些问题，将 ADP、AMTDP 与 ST-JMA 共同应用到现实机械臂系统中，以增强这些方法的应用价值。

中国知网 https://www.cnki.net

参考文献

[1] Kang T, Yi J B, Song D, et al. High-Speed Autonomous Robotic Assembly Using in-Hand Manipulation and Re-Grasping[J]. Applied Sciences, 2020, 11(1): 37.

[2] Gupta A, Savarese S, Ganguli S, et al. Embodied Intelligence via Learning and Evolution[J]. Nature Communications, 2021, 12(1): 5721.

[3] Roy N, Posner I, Barfoot T, et al. From Machine Learning to Robotics: Challenges and Opportunities for Embodied Intelligence[J]. ArXiv Preprint ArXiv: 2110.15245, 2021.

[4] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the Association for Computational Linguistics. 2019: 4171-4186.

[5] Brown T, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[J]. Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.

[6] Ramesh A, Pavlov M, Goh G, et al. Zero-Shot Text-to-Image generation[C]// International Conference on Machine Learning. PMLR, 2021: 8821-8831.

[7] Kirillov A, Mintun E, Ravi N, et al. Segment Anything[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 4015-4026.

[8] Li J, Li D, Xiong C, et al. Blip: Bootstrapping Language-Image Pre-Training for Unified Vision-Language Understanding and Generation[C]//International Conference on Machine Learning. PMLR, 2022: 12888-12900.

[9] Mason M T. Toward Robotic Manipulation[J]. Annual Review of Control, Robotics, and Autonomous Systems, 2018, 1(1): 1-28.

[10] Sachan S, Swarnkar P. Intelligent Fractional Order Sliding Mode Based Control for Surgical Robot Manipulator[J]. Electronics, 2023, 12(3): 729.

[11] Arents J, Greitans M. Smart Industrial Robot Control Trends, Challenges and Opportunities Within Manufacturing[J]. Applied Sciences, 2022, 12(2): 937.

[12] Papadopoulos E, Aghili F, Ma O, et al. Robotic Manipulation and Capture in Space: A Survey[J]. Frontiers in Robotics and AI, 2021, 8: 686723.

[13] Fang H S, Wang C, Gou M, et al. Graspnet-1Billion: A Large-Scale Benchmark for General Object Grasping[C]//Proceedings of the IEEE/CVF Conference on Computer Vision And Pattern Recognition. 2020: 11444-11453.

中国知网 https://www.cnki.net

[14] Wada K, James S, Davison A J. Reorientbot: Learning Object Reorientation for Specific-Posed Placement[C]//2022 International Conference on Robotics and Automation. IEEE, 2022: 8252-8258.

[15] Manuelli L, Gao W, Florence P, et al. kpam: Keypoint Affordances for Category-Level Robotic Manipulation[C]//The International Symposium of Robotics Research. Cham: Springer International Publishing, 2019: 132-157.

[16] Team O M, Ghosh D, Walke H, et al. Octo: An Open-Source Generalist Robot Policy[J]. ArXiv Preprint ArXiv:2405.12213, 2024.

[17] O'Neill A, Rehman A, Gupta A, et al. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[J]. ArXiv Preprint ArXiv:2310.08864, 2023.

[18] Zhang X, Liu Y, Chang H, et al. Scaling Manipulation Learning with Visual Kinematic Chain Prediction[J]. ArXiv Preprint ArXiv:2406.07837, 2024.

[19] Ze Y, Hansen N, Chen Y, et al. Visual Reinforcement Learning With Self-Supervised 3D Representations[J]. IEEE Robotics and Automation Letters, 2023, 8(5): 2890-2897.

[20] Zhang X, Jain S, Huang B, et al. Learning Generalizable Pivoting Skills[C]//2023 IEEE International Conference on Robotics and Automation. IEEE, 2023: 5865-5871.

[21] Cao H G, Zeng W, Wu I C. Reinforcement Learning for Picking Cluttered General Objects With Dense Object Descriptors[C]//2022 International Conference on Robotics and Automation. IEEE, 2022: 6358-6364.

[22] Sharma A, Ahmed A M, Ahmad R, et al. Self-Improving Robots: End-to-End Autonomous Visuomotor Reinforcement Learning[J]. ArXiv Preprint arXiv: 2303.01488, 2023.

[23] Qin Y, Huang B, Yin Z H, et al. Dexpoint: Generalizable Point Cloud Reinforcement Learning for Sim-to-Real Dexterous Manipulation[C]//Conference on Robot Learning. PMLR, 2023: 594-605.

[24] Wan W, Zhu Y, Shah R, et al. Lotus: Continual Imitation Learning for Robot Manipulation Through Unsupervised Skill Discovery[C]//2024 IEEE International Conference on Robotics and Automation. IEEE, 2024: 537-544.

[25] Fu L, Huang H, Datta G, et al. In-Context Imitation Learning via Next-Token Prediction[J]. ArXiv Preprint ArXiv:2408.15980, 2024.

[26] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative Adversarial Networks[J]. Communications of the ACM, 2020, 63(11): 139-144.

中国知网 https://www.cnki.net

[27] Kingma D P. Auto-encoding Variational Bayes[J]. ArXiv Preprint ArXiv: 1312.6114, 2013.

[28] Murali A, Mousavian A, Eppner C, et al. 6-DoF Grasping for Target-Driven Object Manipulation in Clutter[C]//2020 IEEE International Conference on Robotics and Automation. IEEE, 2020: 6232-6238.

[29] Weng T, Held D, Meier F, et al. Neural Grasp Distance Fields for Robot Manipulation[C]//2023 IEEE International Conference on Robotics and Automation. IEEE, 2023: 1814-1821.

[30] Urain J, Funk N, Peters J, et al. Se(3)-Diffusionfields: Learning Smooth Cost Functions for Joint Grasp and Motion Optimization Through Diffusion[C]//2023 IEEE International Conference on Robotics and Automation. IEEE, 2023: 5923-5930.

[31] Weng T, Bajracharya S M, Wang Y, et al. Fabricflownet: Bimanual Cloth Manipulation with a Flow-Based Policy[C]//Conference on Robot Learning. PMLR, 2022: 192-202.

[32] Ha H, Song S. Flingbot: The Unreasonable Effectiveness of Dynamic Manipulation for Cloth Unfolding[C]//Conference on Robot Learning. PMLR, 2022: 24-33.

[33] Liu W, Paxton C, Hermans T, et al. Structformer: Learning Spatial Structure for Language-Guided Semantic Rearrangement of Novel Objects[C]//2022 International Conference on Robotics and Automation. IEEE, 2022: 6322-6329.

[34] Liu W, Hermans T, Chernova S, et al. Structdiffusion: Object-Centric Diffusion for Semantic Rearrangement of Novel Objects[C]//Workshop on Language and Robotics at CoRL 2022. 2022.

[35] Zhu Y, Joshi A, Stone P, et al. Viola: Imitation Learning for Vision-Based Manipulation With Object Proposal Priors[C]//Conference on Robot Learning. PMLR, 2023: 1199-1210.

[36] Zhao T Z, Kumar V, Levine S, et al. Learning Fine-Grained Bimanual Manipulation With Low-Cost Hardware[J]. ArXiv Preprint ArXiv:2304.13705, 2023.

[37] Simeonov A, Goyal A, Manuelli L, et al. Shelving, Stacking, Hanging: Relational Pose Diffusion for Multi-Modal Rearrangement[J]. ArXiv Preprint ArXiv: 2307.04751, 2023.

[38] Gervet T, Xian Z, Gkanatsios N, et al. Act3d: Infinite Resolution Action Detection

中国知网 https://www.cnki.net

Transformer for Robotic Manipulation[J]. ArXiv Preprint ArXiv:2306.17817, 2023.

[39] Goyal A, Xu J, Guo Y, et al. Rvt: Robotic View Transformer for 3D Object Manipulation[C]//Conference on Robot Learning. PMLR, 2023: 694-710.

[40] Xian Z, Gkanatsios N, Gervet T, et al. Chaineddiffuser: Unifying Trajectory Diffusion and Keypose Prediction for Robotic Manipulation[C]//7th Annual Conference on Robot Learning. 2023.

[41] Ma X, Patidar S, Haughton I, et al. Hierarchical Diffusion Policy for Kinematics-Aware Multi-Task Robotic Manipulation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 18081-18090.

[42] Chi C, Xu Z, Feng S, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[J]. The International Journal of Robotics Research, 2023: 02783649241273668.

[43] Mees O, Hermann L, Burgard W. What Matters in Language Conditioned Robotic Imitation Learning Over Unstructured Data[J]. IEEE Robotics and Automation Letters, 2022, 7(4): 11205-11212.

[44] Mandlekar A, Xu D, Wong J, et al. What Matters in Learning From Offline Human Demonstrations for Robot Manipulation[J]. ArXiv Preprint ArXiv:2108.03298, 2021.

[45] Shafiullah N M, Cui Z, Altanzaya A A, et al. Behavior Transformers: Cloning k Modes With One Stone[J]. Advances in Neural Information Processing Systems, 2022, 35: 22955-22968.

[46] Huang T, Jiang G, Ze Y, et al. Diffusion Reward: Learning Rewards via Conditional Video Diffusion[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 478-495.

[47] Hu J, Sun Y, Huang S, et al. Instructed Diffuser With Temporal Condition Guidance for Offline Reinforcement Learning[J]. ArXiv Preprint ArXiv: 2306.04875, 2023.

[48] Wang Z, Hunt J J, Zhou M. Diffusion Policies as an Expressive Policy Class for Offline Reinforcement Learning[J]. ArXiv Preprint ArXiv:2208.06193, 2022.

[49] Li Z, Krohn R, Chen T, et al. Learning Multimodal Behaviors from Scratch With Diffusion Policy Gradient[J]. ArXiv Preprint ArXiv:2406.00681, 2024.

[50] Ajay A, Du Y, Gupta A, et al. Is Conditional Generative Modeling all You Need for Decision-Making?[J]. ArXiv Preprint ArXiv:2211.15657, 2022.

中国知网 https://www.cnki.net

[51] Sun P, Kretzschmar H, Dotiwalla X, et al. Scalability in Perception for Autonomous Driving: Waymo Open Dataset[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 2446-2454.

[52] Dasari S, Ebert F, Tian S, et al. Robonet: Large-Scale Multi-Robot Learning[J]. ArXiv Preprint ArXiv:1910.11215, 2019.

[53] Kumar A, Zhou A, Tucker G, et al. Conservative Q-Learning for Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 1179-1191.

[54] Nair A, Gupta A, Dalal M, et al. Awac: Accelerating Online Reinforcement Learning With Offline Datasets[J]. ArXiv Preprint ArXiv:2006.09359, 2020.

[55] Yin Z H, Ye W, Chen Q, et al. Planning for Sample Efficient Imitation Learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 2577-2589.

[56] Yang M, Levine S, Nachum O. Trail: Near-Optimal Imitation Learning With Suboptimal Data[J]. ArXiv Preprint ArXiv:2110.14770, 2021.

[57] Jiang Y, Liu E, Eysenbach B, et al. Learning Options via Compression[J]. Advances in Neural Information Processing Systems, 2022, 35: 21184-21199.

[58] Singh A, Liu H, Zhou G, et al. Parrot: Data-Driven Behavioral Priors for Reinforcement Learning[J]. ArXiv Preprint ArXiv:2011.10024, 2020.

[59] Laskin M, Wang L, Oh J, et al. In-Context Reinforcement Learning With Algorithm Distillation[J]. ArXiv Preprint ArXiv:2210.14215, 2022.

[60] Hester T, Vecerik M, Pietquin O, et al. Deep Q-Learning from Demonstrations[C]// Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).

[61] Henderson P, Islam R, Bachman P, et al. Deep Reinforcement Learning That Matters[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).

[62] Kang B, Jie Z, Feng J. Policy Optimization With Demonstrations[C]//International Conference On Machine Learning. PMLR, 2018: 2469-2478.

[63] Aytar Y, Pfaff T, Budden D, et al. Playing Hard Exploration Games by Watching Youtube[J]. Advances in Neural Information Processing Systems, 2018, 31.

[64] Smith L, Dhawan N, Zhang M, et al. Avid: Learning Multi-Stage Tasks via Pixel-Level Translation of Human Videos[J]. ArXiv Preprint ArXiv:1912.04443, 2019.

[65] Ho J, Ermon S. Generative Adversarial Imitation Learning[J]. Advances in Neural Information Processing Systems, 2016, 29.

[66] Haldar S, Pari J, Rai A, et al. Teach a Robot to Fish: Versatile Imitation From one

中国知网 https://www.cnki.net

Minute of Demonstrations[J]. ArXiv Preprint ArXiv:2303.01497, 2023.

[67] Zhou J, Liu E, Tian X, et al. Adaptive Fuzzy Backstepping Control Based on Dynamic Surface Control for Uncertain Robotic Manipulator[J]. IEEE Access, 2022, 10: 23333-23341.

[68] Van M, Sun Y, Mcllvanna S, et al. Adaptive Fuzzy Fault Tolerant Control for Robot Manipulators With Fixed-Time Convergence[J]. IEEE Transactions on Fuzzy Systems, 2023, 31(9): 3210-3219.

[69] Zhao W, Liu Y, Yao X. Adaptive Fuzzy Containment and Vibration Control for Multiple Flexible Manipulators With Model Uncertainties[J]. IEEE Transactions on Fuzzy Systems, 2022, 31(4): 1315-1326.

[70] Sun Y, Gao Y, Zhao Y, et al. Neural Network-Based Tracking Control of Uncertain Robotic Systems: Predefined-Time Nonsingular Terminal Sliding-Mode Approach[J]. IEEE Transactions on Industrial Electronics, 2022, 69(10): 10510-10520.

[71] Zhu C, Jiang Y, Yang C. Fixed-Time Neural Control of Robot Manipulator With Global Stability and Guaranteed Transient Performance[J]. IEEE Transactions on Industrial Electronics, 2022, 70(1): 803-812.

[72] Zhang Z, Kong L, Zheng L, et al. Robustness Analysis of a Power-Type Varying-Parameter Recurrent Neural Network for Solving Time-Barying QM and QP Problems and Applications[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2018, 50(12): 5106-5118.

[73] Shi Y, Wang J, Li S, et al. Tracking Control of Cable-Driven Planar Robot Based on Discrete-Time Recurrent Neural Network With Immediate Discretization Method[J]. IEEE Transactions on Industrial Informatics, 2022, 19(6): 7414-7423.

[74] Zhang Y, Jiang D, Wang J. A Recurrent Neural Network for Solving Sylvester Equation With Time-Varying Coefficients[J]. IEEE Transactions on Neural Networks, 2002, 13(5): 1053-1063.

[75] Jin J, Chen W, Chen C, et al. A Predefined Fixed-Time Convergence ZNN and its Applications to Time-Varying Quadratic Programming Solving and Dual-Arm Manipulator Cooperative Trajectory Tracking[J]. IEEE Transactions on Industrial Informatics, 2022, 19(8): 8691-8702.

[76] Dai J, Yang X, Xiao L, et al. Design and Analysis of a Self-Adaptive Zeroing Neural Network for Solving Time-Varying Quadratic Programming[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 34(10): 7135-7144.

中国知网 https://www.cnki.net

[77] Chen D, Zhang Y, Li S. Tracking Control of Robot Manipulators With Unknown Models: A Jacobian-Matrix-Adaption Method[J]. IEEE Transactions on Industrial Informatics, 2017, 14(7): 3044-3053.

[78] Yang M, Zhang Y, Zhang Z, et al. Adaptive Discrete ZND Models for Tracking Control of Redundant Manipulator[J]. IEEE Transactions on Industrial Informatics, 2020, 16(12): 7360-7368.

[79] Tan N, Yu P, Ni F. New Varying-Parameter Recursive Neural Networks for Model-Free Kinematic Control of Redundant Manipulators With Limited Measurements[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.

[80] Xi R D, Xiao X, Ma T N, et al. Adaptive Sliding Mode Disturbance Observer Based Robust Control for Robot Manipulators Towards Assembly Assistance[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 6139-6146.

[81] Zhai J, Li Z. Fast-Exponential Sliding Mode Control of Robotic Manipulator With Super-Twisting Method[J]. IEEE Transactions on Circuits and Systems II: Express Briefs, 2021, 69(2): 489-493.

[82] Saied H, Chemori A, Bouri M, et al. Feedforward Super-Twisting Sliding Mode Control for Robotic Manipulators: Application to PKMs[J]. IEEE Transactions on Robotics, 2023, 39(4): 3167-3184.

[83] Li L, Su Y, Kong L, et al. TDE-Based Adaptive Super-Twisting Multivariable Fast Terminal Slide Mode Control for Cable-Driven Manipulators With Safety Constraint of Error[J]. IEEE Access, 2022, 11: 6656-6664.

[84] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models[J]. Advances in Neural Information Processing Systems, 2020, 33: 6840-6851.

[85] Song J, Meng C, Ermon S. Denoising Diffusion Implicit Models[J]. ArXiv Preprint ArXiv:2010.02502, 2020.

[86] Mnih V. Playing Atari With Deep Reinforcement Learning[J]. ArXiv Preprint ArXiv:1312.5602, 2013.

[87] Van Hasselt H, Guez A, Silver D. Deep Reinforcement Learning With Double Q-Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2016, 30(1).

[88] Wang Z, Schaul T, Hessel M, et al. Dueling Network Architectures for Deep Reinforcement Learning[C]//International Conference on Machine Learning. PMLR, 2016: 1995-2003.

中国知网 https://www.cnki.net

[89] Williams R J. Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning[J]. Machine Learning, 1992, 8: 229-256.

[90] Schulman J. Trust Region Policy Optimization[J]. ArXiv Preprint ArXiv: 1502.05477, 2015.

[91] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[J]. ArXiv Preprint ArXiv:1707.06347, 2017.

[92] Lillicrap T P. Continuous Control With Deep Reinforcement Learning[J]. ArXiv Preprint ArXiv:1509.02971, 2015.

[93] Hu E J, Shen Y, Wallis P, et al. Lora: Low-Rank Adaptation of Large Language Models[J]. ArXiv Preprint ArXiv:2106.09685, 2021.

[94] Radford A, Kim J W, Hallacy C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]//International Conference on Machine Learning. PMLR, 2021: 8748-8763.

[95] Cai W, Jiang J, Wang F, et al. A Survey on Mixture of Experts[J]. ArXiv Preprint ArXiv:2407.06204, 2024.

[96] Ze Y, Zhang G, Zhang K, et al. 3D Diffusion Policy: Generalizable Visuomotor Policy Learning via Simple 3D Representations[J]. ArXiv Preprint ArXiv: 2403.03954, 2024.

[97] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C]//2019 International Conference on Robotics and Automation. IEEE, 2019: 6023-6029.

[98] Li K, Li X, Wang Y, et al. Videomamba: State Space Model for Efficient Video Understanding[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 237-255.

[99] Zhu L, Liao B, Zhang Q, et al. Vision Mamba: Efficient Visual Representation Learning With Bidirectional State Space Model[J]. ArXiv Preprint ArXiv: 2401.09417, 2024.

[100] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[J]. ArXiv Preprint ArXiv: 2010.11929, 2020.

[101] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

[102] Huang L, Wang W, Wu Z F, et al. In-Context LoRA for Diffusion Transformers[J].

中国知网 https://www.cnki.net

ArXiv Preprint ArXiv:2410.23775, 2024.

[103]Perez E, Strub F, De Vries H, et al. Film: Visual Reasoning With a General Conditioning Layer[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1).

[104]Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//Medical Image Computing and Computer-Assisted Intervention. 2015: 234-241.

[105]Yarats D, Fergus R, Lazaric A, et al. Mastering Visual Continuous Control: Improved Data-Augmented Reinforcement Learning[J]. ArXiv Preprint ArXiv: 2107.09645, 2021.

[106]Fujimoto S, Gu S S. A Minimalist Approach to Offline Reinforcement Learning[J]. Advances in Neural Information Processing Systems, 2021, 34: 20132-20145.

[107]Yu T, Quillen D, He Z, et al. Meta-World: A Benchmark and Evaluation for Multi-Task and Meta Reinforcement Learning[C]//Conference on Robot Learning. PMLR, 2020: 1094-1100.

[108]Rajeswaran A, Kumar V, Gupta A, et al. Learning Complex Dexterous Manipulation With Deep Reinforcement Learning and Demonstrations[J]. ArXiv Preprint ArXiv:1709.10087, 2017.

[109]Bao C, Xu H, Qin Y, et al. Dexart: Benchmarking Generalizable Dexterous Manipulation With Articulated Objects[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 21190-21200.

[110]Wang C, Luo X, Ross K, et al. VRL3: A Data-Driven Framework for Visual Deep Reinforcement Learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 32974-32988.

[111]Florence P, Lynch C, Zeng A, et al. Implicit Behavioral Cloning[C]//Conference on Robot Learning. PMLR, 2022: 158-168.

[112]Mandlekar A, Xu D, Wong J, et al. What Matters in Learning From Offline Human Demonstrations for Robot Manipulation[J]. ArXiv Preprint ArXiv: 2108.03298, 2021.

[113]Ji T, Luo Y, Sun F, et al. Seizing Serendipity: Exploiting the Value of Past Success in off-Policy Actor-Critic[J]. ArXiv Preprint ArXiv:2306.02865, 2023.

[114]Fu Y, Zhang H, Wu D, et al. FuRL: Visual-Language Models as Fuzzy Rewards for Reinforcement Learning[J]. ArXiv Preprint ArXiv:2406.00645, 2024.

中国知网 https://www.cnki.net

[115]Haarnoja T, Zhou A, Hartikainen K, et al. Soft Actor-Critic Algorithms and Applications[J]. ArXiv Preprint ArXiv:1812.05905, 2018.

[116]Yang R, Xu H, Wu Y, et al. Multi-task Reinforcement Learning With Soft Modularization[J]. Advances in Neural Information Processing Systems, 2020, 33: 4767-4777.

[117]Yu T, Kumar S, Gupta A, et al. Gradient Surgery for Multi-Task Learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 5824-5836.

[118]Sodhani S, Zhang A, Pineau J. Multi-Task Reinforcement Learning With Context-Based Representations[C]//International Conference on Machine Learning. PMLR, 2021: 9767-9779.

[119]Feng J, Chen M, Pu Z, et al. Efficient Multi-Task Reinforcement Learning via Task-Specific Action Correction[J]. IEEE Transactions on Cognitive and Developmental Systems, 2025:1-15.

[120]Roberts J S, Di J. Projected Task-Specific Layers for Multi-Task Reinforcement Learning[C]//2024 IEEE International Conference on Robotics and Automation. IEEE, 2024: 2887-2893.

[121]Lan L C, Zhang H, Hsieh C J. Can Agents Run Relay Race With Strangers? Generalization of RL to Out-of-Distribution Trajectories[J]. ArXiv Preprint ArXiv:2304.13424, 2023.

中国知网 https://www.cnki.net