电 子 科 技 大 学

UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

硕士学位论文

MASTER THESIS



论文题目 基于扩散模型的高效智能体决策研究

学科专业	**计算机科学与技术**
学　　号	**202221080429**
作者姓名	**黄仁明**
指导教师	**杨阳　　教　授**
学　　院	**计算机科学与工程学院 (网络空间安全学院)**

中国知网 https://www.cnki.net

分类号 TP183 密级 公开

UDC 注 1 004.8

学 位 论 文

基于扩散模型的
高效智能体决策研究

（题名和副题名）

黄仁明

（作者姓名）

指导教师 **杨阳 教 授**

电子科技大学 成 都

（姓名、职称、单位名称）

申请学位级别 **硕士** 学科专业 **计算机科学与技术**

提交论文日期 **2025 年 3 月 10 日** 论文答辩日期 **2025 年 5 月 16 日**

学位授予单位和日期 **电子科技大学 2025 年 6 月**

答辩委员会主席 **许春香**

评阅人 许春香, 牛新征, 牛伟纳, 郑旭, 吴洪

注 1：注明《国际十进分类法 UDC》的类号。

中国知网 https://www.cnki.net

Efficient Decision Making Based on Diffusion Models

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline:	**Computer Science and Technology**
Student ID:	**202221080429**
Author:	**Renming Huang**
Supervisor:	**Prof.Yang Yang**
School:	**School of Computer Science and Engineering(School of Cyberspace Security)**

中国知网 https://www.cnki.net

摘 要

智能体作为物理世界与数字空间交互的核心载体，其应用范围已由实验室环境拓展至工业生产、社会服务等关键领域。然而，在复杂动态环境中，智能体的决策能力仍面临根本性挑战，现有决策模型在稳定性和适应性方面亟待突破。为此，强化学习与扩散模型的融合为解决数据采样效率低、策略表征不足以及轨迹规划累积误差等问题提供了新的可能。目前，关于扩散模型与强化学习的结合主要集中在扩散策略表征、轨迹一致性规划以及数据增强三个维度，基本涵盖了智能体策略学习闭环的各个环节。但现有方法多侧重于利用扩散模型提升决策质量，其固有的多步去噪过程却导致决策效率大幅降低，使得基于扩散策略的智能体在实际应用中存在一定困难。为了解决这一挑战，本文提出了一种基于扩散模型的高效智能体决策方法，从全新角度探讨扩散模型与智能体策略学习的结合，重点从策略学习、决策推理和数据增强三个闭环流程展开研究。主要研究内容包括：

（1）为提高扩散策略在轨迹规划中的推理效率并保证规划质量，本文首先通过经验观察将扩散模型的规划过程解耦为轨迹初始化和轨迹优化两个阶段，其中后者仅在去噪后期的少数步骤中进行。基于此，本文提出采用自回归方法进行轨迹初始化，并结合少量扩散模型优化步骤进一步提升轨迹质量。实验结果表明，相较于纯扩散模型，该方法在推理速度上实现了 10 倍提升，同时得益于自回归模型出色的初始化能力，规划质量亦有所提升。

（2）高层策略引导的在线决策学习。直接使用扩散模型进行低层决策往往需要频繁执行去噪过程，从而降低了决策效率。为此，本文充分利用扩散模型的多模态建模能力，将扩散策略作为高级策略，通过从先验数据中提取知识来引导在线策略的高效学习。在稀疏奖励下的导航和操作任务实验中，结果显示该方法通过激励低层策略有效探索，大幅提升了策略学习效率，并在长视距决策任务中表现突出，超越了传统的离线数据预训练加在线微调的方法。详细的消融实验进一步验证了该方法在应对数据覆盖不足、片段化甚至受损轨迹时仍能保持良好鲁棒性。

（3）基于扩散点轨迹的策略学习增强。传统方法通常在图像空间中进行像素级采样，易导致时空不一致和采样效率低下的问题。本文则利用扩散模型学习与策略更紧密相关的点轨迹进行抽象表示，首先利用现有点跟踪技术从视频数据中提取点转移轨迹，从而有效保留策略关键信息并剔除冗余。扩散策略基于当前图像观测和指令生成未来点轨迹，再由策略网络引入该轨迹指导当前决策。实验在 LIBERO 基准测试中针对 100 多种语言条件下的操控任务进行验证，结果显示该

中国知网 https://www.cnki.net

方法整体性能提升达 80%，尤其在长程任务中优势更为明显，这充分证明了扩散模型所学抽象数据表征对增强策略决策能力的重要作用。

关键词：强化学习，扩散模型，智能体决策，高效策略学习

中国知网 https://www.cnki.net

ABSTRACT

As the core medium bridging physical environments and digital spaces, intelligent agents have expanded their applications from laboratory settings to critical domains including industrial production and social services. However, fundamental challenges persist in decision-making capabilities within complex dynamic environments, where existing models require breakthroughs in stability and adaptability. The integration of reinforcement learning with diffusion models presents novel solutions to persistent issues such as low data sampling efficiency, insufficient policy representation, and cumulative trajectory planning errors. Current research primarily focuses on three integration aspects: diffusion-based policy representation, trajectory consistency planning, and data augmentation, collectively addressing key components of agent policy learning. Nevertheless, conventional approaches predominantly emphasize decision quality improvement through diffusion models while neglecting the inherent efficiency degradation caused by multi-step denoising processes, significantly hindering practical deployment of diffusion-based agents. To address this critical challenge, Thesis propose an efficient diffusion-based decision-making framework that innovatively explores policy learning integration through three interconnected processes: strategy learning, decision inference, and data augmentation. Our main contributions include:

(1) Efficient Trajectory Planning via Decoupled Diffusion Process: Through empirical analysis, thesis decouple the diffusion-based planning into trajectory initialization and optimization phases, restricting computationally intensive denoising to later optimization stages. thesis develop an autoregressive trajectory initialization method combined with limited-step diffusion refinement, achieving 10× acceleration over conventional diffusion approaches while maintaining planning quality. Experimental results demonstrate enhanced planning accuracy through effective initialization, particularly in long-horizon tasks.

(2) Hierarchical Policy-Guided Online Learning: To mitigate frequent denoising requirements in low-level decision-making, thesis propose a hierarchical framework leveraging diffusion models' multimodal modeling capacity as high-level policies. This architecture extracts knowledge from prior data to guide efficient online policy learning. Navigation and manipulation experiments under sparse rewards reveal substantial improvements

中国知网 https://www.cnki.net

in exploration efficiency and long-term decision-making performance, outperforming traditional pretraining-finetuning paradigms. Comprehensive ablation studies confirm the method's robustness against data scarcity, fragmentation, and corrupted trajectories.

(3) Diffusion-Enhanced Strategy Learning through Point Trajectories: Addressing spatio-temporal inconsistency in pixel-level sampling, thesis develop a point trajectory abstraction method using diffusion models. By extracting point transfer trajectories from video data through tracking techniques, thesis preserve critical policy information while eliminating redundancies. The diffusion policy generates future point trajectories from visual observations and instructions, subsequently guiding real-time decisions through policy networks. Evaluations on the LIBERO benchmark across 100+ language-conditioned manipulation tasks demonstrate 80% overall performance improvement, with particularly notable advantages in long-horizon scenarios. This validates the crucial role of diffusion-learned abstract representations in enhancing decision-making capabilities. These innovations establish a comprehensive framework that effectively balances decision quality and efficiency, significantly advancing the practical application potential of diffusion-based intelligent agents in complex real-world scenarios.

Keywords: Reinforcement Learning, Diffusion Models, Decision Making, Efficient Policy Learning

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 选题背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 智能体决策研究现状.....3
1.2.2 强化学习研究现状.....4
1.2.3 强化学习中的扩散模型研究现状.....6
1.3 本文主要研究内容.....7
1.4 本文结构安排.....8
第二章 强化学习理论以及扩散模型原理.....10
2.1 引言.....10
2.2 序列决策概念.....10
2.2.1 问题定义.....10
2.2.2 通用模型建模.....11
2.2.3 马尔可夫决策过程.....13
2.2.4 部分观测马尔可夫决策过程.....14
2.3 强化学习理论.....15
2.3.1 基于价值的强化学习.....15
2.3.2 基于策略的强化学习.....19
2.3.3 基于模型的强化学习.....22
2.4 扩散模型基础.....23
2.4.1 扩散概率模型.....23
2.4.2 扩散策略.....25
2.4.3 扩散规划.....25
2.5 本章小结.....25
第三章 扩散模型作为优化器的高效规划.....27
3.1 引言.....27
3.2 轨迹规划问题描述.....28
3.3 经验性观察分析.....29
3.4 基于扩散模型的高效规划.....31
3.4.1 轨迹表示.....31
3.4.2 基于 Transformer 的可行轨迹生成.....32
3.4.3 基于扩散模型的轨迹优化.....33
3.5 实验结果分析与消融实验.....35
3.5.1 实验设置.....35

中国知网 https://www.cnki.net

3.5.2 推理效率评估.....36
3.5.3 性能评估.....38
3.5.4 消融实验.....40
3.6 本章小结.....42
第四章 扩散策略引导的高效策略学习.....43
4.1 引言.....43
4.2 问题描述.....44
4.3 基于先验观测的高效策略学习.....45
4.3.1 子目标生成扩散策略学习.....46
4.3.2 子目标引导的高效在线学习.....49
4.4 实验结果分析与消融实验.....50
4.4.1 实验仿真环境.....50
4.4.2 与现有方法性能对比.....52
4.4.3 消融实验与性质分析.....54
4.5 本章小结.....58
第五章 扩散点轨迹增强的高效策略学习.....59
5.1 引言.....59
5.2 问题描述.....61
5.3 扩散点轨迹引导的策略学习.....61
5.3.1 视频数据集轨迹建模.....62
5.3.2 轨迹引导策略学习.....63
5.4 实验结果分析.....65
5.4.1 与先进方法对比.....65
5.4.2 消融实验分析.....69
5.5 本章小结.....70
第六章 全文总结与展望.....71
6.1 全文总结.....71
6.2 后续工作展望.....72
参考文献.....74

中国知网 https://www.cnki.net

第一章 绪 论

1.1 选题背景及意义

随着人工智能技术的快速演进与产业智能化需求的持续升级，智能体作为物理世界与数字空间交互的核心载体，其应用边界已从实验室场景延伸至工业生产、社会服务等关键领域。在工业 4.0 转型进程中，工业机器人通过自主决策实现了柔性生产线的动态调度；自动驾驶系统依托实时决策能力重塑城市交通运行范式；医疗手术机器人凭借精准决策推动微创手术向亚毫米级精度迈进。据 IDC 最新报告显示，全球智能体市场规模将在 2025 年突破 2000 亿美元，这种爆发式增长既源于社会对智能化服务需求的指数级攀升，也得益于传感器、边缘计算等硬件设备成本的大幅下降。然而，智能体在复杂动态环境中的决策能力仍面临根本性挑战，现有决策模型的稳定性和适应性亟待突破。

强化学习 [1] 是机器学习领域的一个重要组成部分，其强调如何基于环境而行动，以取得最大化的预期利益。其灵感来源于心理学中的行为主义理论，即有机体如何在环境给予的奖励或惩罚的刺激下，逐步形成对刺激的预期，产生能获得最大利益的习惯性行为。强化学习通过最大化累积奖励训练智能体进行序列决策，尽管强化学习在多个领域取得了显著的成功，这里仍然存在长期挑战 [2,3]。具体来说，尽管离线强化学习方法能够可观的解决在线强化学习存在的采样效率低下的问题 [4,5]，但这也使得传统的高斯策略无法拟合具有复杂分布的数据集从而影响决策性能；与此同时，虽然经验回放能够提高采样效率 [6]，在高维状态空间和复杂交互模式下仍然存在数据稀缺性问题；智能体决策可以通过学习动态模型，使用基于模型的强化学习方法进行规划从而完成决策 [7–9]，但是自回归方法存在复合误差问题，这通常导致规划不正确影响最终决策[10]。

扩散模型作为一种强大的生成模型 [11]，近年来得到了广泛的关注。该模型采用了一种去噪框架，通过多步去噪过程生成新的样本。与早期的生成模型相比，例如变分自编码器 [12] 和生产对抗网络 [13]，扩散模型在生成高质量样本方面表现出卓越的能力，并表现出增强的训练稳定性，因此，扩散模型在各个领域取得了显著的进步和成就，包括计算机视觉 [14–16]，自然语言处理 [17,18]，音频生产 [19,20] 以及药物发现 [21,22] 等领域。

相关研究发现扩散模型具有训练稳定，泛化能力强以及优秀的多模态建模能力等特性，使得扩散模型适合应用于智能体决策，能够解决 RL 中长期存在的挑战。图1-1说明了扩散模型与以前的解决方案相比如何发挥不同的作用。目前在智

中国知网 https://www.cnki.net

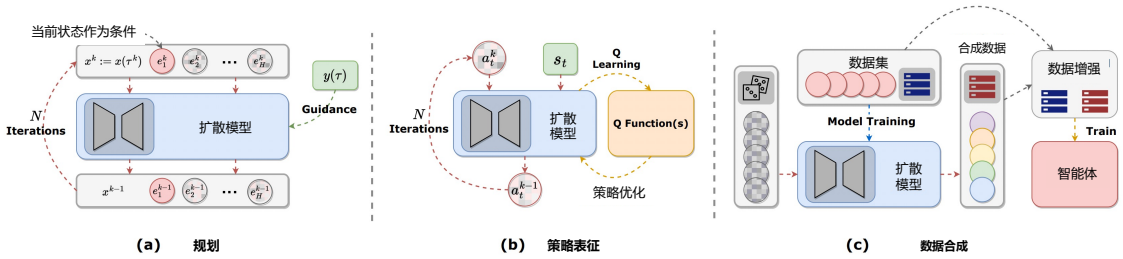


图 1-1 在强化学习中扩散模型扮演着不同的角色: (a) 扩散模型作为规划器。此时采样目标为部分轨迹，其组成成分可能因具体任务而有所不同; (b) 扩散模型作为策略。此时采样目标为以状态为条件的动作，通常通过基于策略梯度的指导或直接将其从训练目标中扣除来实现; (c) 扩散模型作为数据合成器。此时采样目标同样为轨迹，并结合真实数据与合成数据来改进下游策略。

能体决策中应用扩散模型的工作主要有三类: 用于规划[23]，策略表征 [24]，以及数据生成 [25]。规划是指使用动态模型来制定想象的决策和选择适当的行动最大化累积奖励，这个过程通常探索各种行动和状态序列，从而在更长时间内改进决策，扩散模型能够同时生成多步规划序列，从而保证规划的一致性；使用扩散模型进行策略表征的重点是改进现有的无模型 RL 解决方案，扩散模型具有多模态建模能力，能够完美拟合强多模态离线数据集行为策略，更容易使用强化学习的方式对策略进行优化，获得最优策略；扩散模型是智能体决策任务的天然数据合成器，因为数据稀缺性是一个实际问题，扩散模型首先拟合已有数据集的参数化数据分布，利用扩散模型的泛化能力，能够额外的合成更丰富的有效数据，从而对数据集进行扩展。

尽管扩散模型能够解决智能体决策面临的长期挑战，显示出卓越的性能表现，由于扩散模型本身固有的顺序去噪过程，这引入了冗长的推理开销的缺点。传统的扩散模型相对于变分自编码和生成对抗网络的推理时间增加了几个数量级，严重限制了这类方法的实际应用，尤其是对需要实时决策的任务，例如自动驾驶。在计算机视觉领域，为了提高扩散模型的推理时间速度，人们发展了大致两种方法：减少步长 [26] 以及知识蒸馏 [27]，分别是为了减少扩散模型推理中的采样步数以及减少模型参数和大小从而取得更快的推理速度。这些方法在一定程度上减少了推理开销，但牺牲了采样质量和多样性，这些质量下降在图像上是可接受的，但是对于智能体决策与控制任务，这会引起灾难性后果，例如控制人行机器人移动，每一次决策都应该足够准确。

随着机器人领域和具身智能的发展，以及制造业和服务业的需求，对高质量，

中国知网 https://www.cnki.net

高效率决策算法的要求越来越紧迫，如何在保持扩散模型带来的优越性能提升的同时，提高基于扩散模型的智能体决策效率至关重要。单纯的关注于提升扩散模型本身推理效率具有挑战性，重新思考扩散模型在智能体决策中扮演的角色或许会使我们从新的角度理解和提升智能体决策效率。

1.2 国内外研究现状

1.2.1 智能体决策研究现状

随着科学技术的迭代发展，人类社会正经历从机械化、信息化到智能化的深刻转型。在这一进程中，机器的自主决策能力成为技术突破的核心方向。无论是复杂工业场景中的自适应控制，还是社会系统层面的战略推演，智能决策技术不仅能够提升人类生活质量、降低高危作业风险，更预示着机器参与复杂决策的可能性。决策作为人类智能的核心能力，贯穿于国家战略制定、企业运营管理乃至个人生活选择的全过程。人工智能领域自诞生之初便致力于探索机器如何模拟甚至超越人类决策能力，这一探索既推动了技术发展，也重构着人机协同的新范式。

人工智能的演进遵循分层突破的路径：从早期以数据存储和规则运算为核心的计算智能，到突破图像识别、语音处理等感知能力的感知智能，最终迈向以理解、推理和决策为标志的认知智能阶段。认知智能作为技术发展的最高形态，集中体现为智能决策系统的构建——它不仅是各层级技术能力的集成枢纽，更是实现通用人工智能的关键突破口。这一领域的技术突破，既需要模拟人类大脑的抽象逻辑推理，又需具备从海量数据中自主学习的适应能力，更要建立与环境动态交互的行为机制。在此背景下，符号主义、连接主义与行为主义三大理论流派的博弈与融合，构成了智能决策技术发展的底层逻辑。

符号主义学派以知识表示与逻辑推理为核心，其代表性研究如 IBM 的 DeepBlue [28] 和 Watson 系统。DeepBlue 通过穷举搜索与专家规则库击败国际象棋冠军，证明了符号系统在有限状态空间中的决策优势；而 Watson 则进一步整合自然语言处理与知识图谱技术，在海量非结构化医疗文献中实现疾病诊断决策支持。近年来，Cyc 项目尝试构建覆盖常识的符号化知识库，其逻辑推理引擎在反恐风险评估等场景中验证了符号系统的可解释性优势。然而，符号主义的瓶颈在于动态知识的实时更新与不确定性处理。例如，美国国防部 DARPA 的 KAIROS 项目试图通过事件本体建模与因果链推理实现全球事件的预测决策，但在突发地缘政治冲突中仍难以突破预定义逻辑框架的局限性。

连接主义依托深度学习的爆发式发展，在复杂决策任务中取得里程碑式突破。2016 年 DeepMind 的 AlphaGo [29] 首次结合卷积神经网络 [30] 与蒙特卡洛树搜索 [31]，

中国知网 https://www.cnki.net

在围棋决策中击败人类顶尖选手，其核心创新在于通过 13 万局人类棋谱预训练策略网络，再通过 3000 万局自我对弈强化价值网络，实现了从感知到决策的端到端优化。此后，AlphaFold [32] 通过图神经网络预测蛋白质三维结构，将决策精度从传统方法的 30% 提升至 90% 以上，彻底改变结构生物学研究范式。然而，纯数据驱动模型的脆弱性在自动驾驶领域暴露无遗：特斯拉的 Autopilot 系统虽能处理 90% 的常规驾驶决策，但在极端天气或罕见交通场景中仍频发误判，凸显出连接主义在因果推理与长尾问题上的缺陷。

行为主义通过强化学习框架推动智能体在动态环境中的自主决策能力。OpenAI 的 Dactyl [33] 项目通过 780 年模拟训练时长，使机械手完成魔方复原的高精度操作决策，其关键创新在于引入域随机化技术增强环境交互的多样性。更具突破性的是 DeepMind 的 AlphaStar [34]，其在《星际争霸 2》游戏中击败人类职业选手，通过分层强化学习架构实现战略决策、战术决策与微操作决策的协同优化。但行为主义的局限性在现实决策场景中同样显著：波士顿动力的 Atlas 机器人虽能完成复杂地形行走决策，但在救灾场景中仍无法自主判断幸存者生命体征的优先级。

最优控制理论旨在为动态系统寻求最优控制策略，以最小化给定的成本函数。该理论主要建立在变分法与数学优化的基础之上。20 世纪 50 年代中期，理查德·贝尔曼提出了贝尔曼方程，为最优控制问题提供了一种递归求解方法。该方程通过刻画状态、价值函数与回报之间的关系，为动态优化问题奠定了基础。基于贝尔曼方程的动态规划方法被广泛用于求解最优控制问题 [35]。在随机环境下，最优控制问题的离散版本被形式化为马尔可夫决策过程 [36]。马尔可夫决策过程采用顺序决策框架，为每个状态提供最优控制动作的选择策略。1960 年，罗纳德·霍华德提出了策略迭代方法，用于高效求解马尔可夫决策过程问题。这些方法共同构成了现代强化学习理论与算法的核心基础，为自适应决策和智能控制的发展提供了重要支撑。

1.2.2 强化学习研究现状

强化学习的发展历程深刻体现了跨学科研究的创造力。早在 1911 年，心理学家爱德华·桑代克通过 “迷箱实验” 提出 “效果法则”，揭示生物体通过结果反馈形成行为偏好的试错机制，这为后续研究埋下伏笔 [37]。1948 年图灵构想 “Pleasure-Pain System” 时，已尝试用机械逻辑模拟这种反馈机制，而 1952 年香农的机械老鼠迷宫实验则首次在工程层面验证了试错学习的可行性。随着 1960 年代人工神经网络与强化机制的结合，以及明斯基、傅京孙等学者对数学框架的完善，该领域逐渐形成理论雏形 [38,39]。进入 1970 年代，哈里·克洛普夫的突破性研究成

中国知网 https://www.cnki.net

为关键转折点——他通过“享乐主义神经元”假说阐明生物神经系统如何利用局部奖励信号自组织形成复杂行为，不仅澄清了强化学习与监督学习的本质区别[40,41]，更架起了神经科学与计算模型之间的桥梁。这一理论突破直接启发了理查德·萨顿的开创性工作: 他在 1978 年将克洛普夫的神经心理学模型与动物学习理论结合，构建了首个基于预测误差的学习框架，这项奠基性研究催生了时序差分（TD）学习算法。1981 年，萨顿与安德鲁·巴托进一步突破，借鉴巴甫洛夫经典条件反射实验开发的 TD 学习模型，创新性地引入 λ 参数调节机制，实现了即时奖励与未来预期的动态平衡，这种“当前-未来”价值评估框架后来成为 Q-learning 等现代算法的核心组件。时序差分学习不计算整个事件的未来总回报，而是借助访问过的状态和即时回报来预测状态值。时序差分算法利用新信息与旧预测之间的差异来更新预测[1,42]。1959 年，阿瑟-塞缪尔在他的计算机跳棋程序中使用了基于时序差分的学习方法[43,44]，该方法受到克劳德-香农的国际象棋计算机程序的启发。1977 年，伊恩-威滕提出了 $TD(0)$ 的概念，为时序差分学习领域做出了重大贡献[45]。至此，强化学习完成了从行为主义观察到数学形式化表达的蜕变，为后续深度强化学习的崛起奠定了理论基础。

传统强化学习长期受限于马尔可夫决策过程对离散状态-动作空间的严格假设，这种数学框架在复杂连续场景中面临维度灾难。函数逼近技术的突破改变了这一局面——通过将状态价值函数参数化，使得系统能够处理高维甚至连续空间。随着深度学习的爆发式发展[46]，深度神经网络展现出强大的特征抽象能力，在计算机视觉、语音识别等领域验证了其非线性拟合优势。研究者们将深度神经网络与强化学习相结合[47]，催生出深度强化学习这一交叉领域：深度神经网络作为通用函数逼近器，既能编码环境状态的高维信息，又能学习策略函数的复杂映射关系，这使得智能体在原始感知输入层面直接学习成为可能。

深度强化学习的里程碑突破始于 2013 年 DeepMind 团队开发的 DQN 算法[6]，该工作创新性地引入经验回放机制与目标网络架构，首次实现在 Atari 游戏中仅凭像素输入即超越人类水平[48]。这一成就延续了人工智能在博弈领域的进化脉络：从 1992 年 Tesauro 基于 TD 学习的西洋双陆棋程序 TD-Gammon，到 1997 年 IBM 深蓝在国际象棋中击败世界冠军卡斯帕罗夫，直至 2016 年 AlphaGo 结合蒙特卡洛树搜索与深度残差网络，在围棋领域战胜李世石。2020 年升级的 MuZero 算法[8]更是在未知环境动力学的情况下，通过隐式建模状态转移过程实现了跨领域泛化。这些技术进步不仅验证了深度强化学习在策略搜索与长期规划方面的优越性，更揭示了从离散规则系统到数据驱动模型的范式转变，标志着强化学习从理论验证阶段迈入解决现实复杂问题的新纪元。

中国知网 https://www.cnki.net

深度强化学习的通用性优势体现在其应对复杂系统的独特能力。在机器学习范畴中，通用性指算法对未知输入与多样化场景的适应能力，而深度强化学习作为无模型学习范式的代表，通过双重机制突破传统限制：其一，基于深度神经网络的函数逼近能力，可将高维连续状态空间（如视觉感知）和连续动作空间（如机械臂关节力矩）映射为紧凑表征；其二，借助策略梯度[49]与行动者-评论家架构[50]的协同优化，智能体无需系统动力学先验知识，即可通过离线历史数据或在线交互经验自主进化策略。这种特性使得深度强化学习在随机非线性系统中表现出色——例如在机器人动态控制领域，证实深度强化学习智能体通过策略迭代可达成超越人类操作精度的轨迹跟踪；在博弈场景中，DeepMind 的 Alpha 系列智能体通过蒙特卡洛树搜索与深度价值网络耦合，实现了从围棋到星际争霸的跨领域泛化能力。Konda 与 Tsitsiklis 建立的自然梯度框架[51]，以及 Sutton 团队提出的广义优势估计技术，显著提升了策略更新的样本效率与稳定性[52]。这些方法论进步共同构成了深度强化学习的技术支柱，使其既能处理 Atari 游戏中的像素级输入，也能驾驭自动驾驶中的连续决策难题[53]，展现出从虚拟环境到物理世界的通用智能潜力。深度强化学习的跨领域渗透能力正重塑多个学科的研究范式。在机器人领域，深度强化学习已突破传统控制理论的局限性：从工业机械臂的动态抓取[54]到四足机器人的地形自适应[55]，智能体通过端到端学习直接从视觉输入中提取空间特征，实现非结构化环境下的最优控制策略生成。这种无模型学习特性更延伸至智能汽车领域，证实基于深度强化学习的决策系统可在复杂交通场景中实时平衡安全性与通行效率[56]。

1.2.3 强化学习中的扩散模型研究现状

近年来，扩散模型凭借其强大的概率分布建模能力，在强化学习领域引发了一系列创新性探索。传统强化学习算法在离线场景下面临策略表达能力受限的瓶颈，例如基于高斯分布的策略难以拟合复杂多模态数据集，导致策略优化陷入局部最优。针对这一问题，国际研究团队率先提出将扩散模型引入离线强化学习框架。例如，Janner 等人提出的 Diffuser 模型通过扩散过程生成符合数据分布的长时程轨迹，突破了对单步状态转移建模的局限[57]；Wang 团队进一步将扩散策略直接应用于动作序列生成，利用其灵活的生成能力覆盖多样化的行为模式[58]。这类方法通过隐式建模数据分布，避免了传统策略约束算法对数据集多样性的破坏，为离线学习提供了更优的解决方案。

在样本效率提升方面，扩散模型为经验回放机制注入了新的可能性。传统数据增强方法如 RAD[59]采用的图像变换技术虽能提高视觉输入的鲁棒性，但无法生

中国知网 https://www.cnki.net

成具有语义一致性的新样本。2023 年提出扩散驱动的数据增强框架[60]，通过条件生成技术合成符合动态约束的交互轨迹，有效缓解了高维状态空间中的数据稀疏问题。相较于早期基于变分自编码或生成对抗网络的生成方法，扩散模型在长序列生成的保真度上展现出显著优势，其渐进式去噪特性能够更好地保持状态-动作序列的时间一致性，这对时序决策任务至关重要。

基于模型的强化学习长期受困于复合误差累积难题，扩散模型为这一领域带来了范式转换。传统动态模型通过自回归方式逐步预测状态转移，误差会在多步规划中指数级放大[10]。国际前沿工作如 Janner 等人提出的轨迹级扩散规划器[57]，通过联合建模多步状态转移的概率分布，实现了端到端的轨迹优化。这种方法将规划问题转化为分布匹配过程，利用扩散模型的全局生成能力直接产生低误差累积的候选轨迹，在连续控制任务中展现出更稳定的长时程规划性能。2023 年 He 团队进一步将这种规划框架扩展到多任务场景，通过条件扩散机制实现不同任务目标的灵活切换[61]。

面向多任务泛化的研究方向上，扩散模型展现出独特的优势。传统方法如 Transformer 架构的 Gato 模型虽能处理多任务数据，但对任务分布的模式分离能力有限[62]。He 等人通过扩散模型提取可解释的潜在技能空间，使智能体能够动态组合基础技能应对新任务[61]。这种层级式生成架构跨域迁移实验中取得突破，证明扩散模型能有效解耦任务相关特征与通用决策知识，通过解耦表示学习实现了从仿真到真实环境的零样本迁移，为复杂场景下的策略泛化提供了新思路。

当前研究趋势显示，扩散模型正在重塑强化学习的多个核心模块。国际学术界在算法创新层面保持领先，提出了包括轨迹生成、策略参数化、数据增强等系统性解决方案。国内研究团队则在应用落地方面快速跟进，特别是在机器人控制、自动驾驶等垂直领域实现了技术转化。值得注意的是，扩散模型的高计算成本仍是制约其广泛应用的关键瓶颈，如何在保持生成质量的同时提升推理效率，成为国内外学者共同关注的技术攻坚方向。随着模型压缩技术和专用硬件加速架构的发展，这一新兴交叉领域有望推动强化学习在复杂现实场景中的深度应用。

1.3 本文主要研究内容

针对基于扩散模型的高效智能体决策，本文从全新的角度研究扩散模型在智能体决策中的作用，分别从规划，策略学习以及数据生成三个角度，以全新的方法应用扩散模型，充分发挥扩散模型的特性，使得智能体能够达到数据表征高效，策略学习高效以及推理效率高效三方面优势[63,64]。本文的主要研究框架如图1-2所示，主要工作包括以下几个方面：

中国知网 https://www.cnki.net

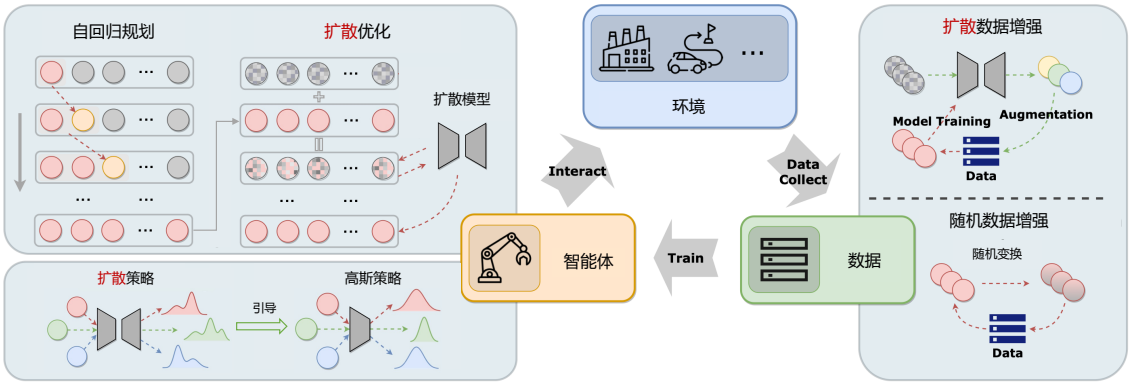


图 1-2 本文主要研究内容的整体框架。

1. 针对扩散模型推理效率低下问题，通过分析扩散模型应用于轨迹规划时推理机制，发现扩散过程可被解耦为两个相对独立过程：轨迹初始化和轨迹优化过程，首先通过设计高效的自回归轨迹规划模型，发挥自回归模型的上下文理解能力以及推理能力，使其能够提供更好的初始化轨迹。其次保留扩散模型少量步骤作为轨迹优化，从而保证轨迹规划质量，通过实验分析，此方法能够显著提升轨迹规划效率，并且同时不牺牲轨迹规划质量。
2. 扩散模型多模态建模能力能很好表征复杂的数据分布，但是扩散模型的多步去噪使得单步决策效率低下，提出使用扩散策略进行高层次决策，以此指导和加速低级策略学习，充分发挥扩散模型表征能力和决策性能，减少扩散策略决策频率。在具有挑战性的稀疏奖励长程决策任务中对该方法进行评估，实验结果表明此方法方法利用了扩散策略的复杂分布建模能力，使其能够提供高质量的高层决策，从而显著提高在线策略学习效率。
3. 针对智能体决策策略学习面临的数据稀疏问题，扩散模型能够拟合已有数据分布并生成额外样本，对数据集进行扩充，然而单纯的数据扩充并不能帮助策略学习，并且在基于图像的数据扩充是非常耗时的，本文首先对已有数据进行抽象化处理，对于机械臂操作任务，使用点跟踪方法获取机械臂操作轨迹，并使用扩散模型学习拟合抽象轨迹表示，这使得扩散模型能够生成表征高效的数据，不仅加快了数据拓展，更高效的数据表征能更好的促进智能体决策策略的学习能力。

1.4 本文结构安排

本文针对基于扩散模型的高效智能体决策问题，首先研究了智能体决策相关技术，包括强化学习，轨迹规划和扩散模型；然后分别在策略学习，数据表征以及高效推理三个方面对扩散模型的应用进行了研究，这三方面的研究形成了智能体

中国知网 https://www.cnki.net

策略学习重要闭环，为扩散模型的应用提供了全新的观点，在策略学习方面，使用扩散模型提供高阶引导，降低了扩散模型的决策频率，加速在线策略学习效率；使用扩散模型学习数据的抽象表示，不仅加速了样本采样效率，并且抽象的数据表征能够更好的帮助策略学习；最后，通过对轨迹规划的扩散过程进行分析，将扩散模型解耦为轨迹初始化和轨迹优化两个步骤，利用自回归模型进行更高效的轨迹初始化，保留扩散模型少量优化步骤从而保证轨迹规划的高效和质量。本文的结构如图 1-2所示，本文的章节安排如下：

第一章，绪论，本章介绍了探索基于扩散模型的高效智能体决策的意义，以及国内外相关研究现状。最后介绍了本文的主要研究内容和章节安排。

第二章，智能体决策基本理论以及扩散模型原理。本章节对智能体决策理论进行了描述，着重介绍了强化学习算法以及扩散模型原理。

第三章，扩散模型作为优化器的高效智能体决策。本章节通过解耦扩散规划过程为轨迹初始化和轨迹优化两部分，使用高效自回归模型进行轨迹规划出初始化，并保留少量扩散步骤进行轨迹优化以获得高质量高效率轨迹规划。最后通过在智能体规划和控制任务实验定量对比验证了提出方法的有效性。

第四章，扩散策略引导的高效智能体策略学习。本章节使用扩散策略作为高阶策略对在线低阶策略学习进行引导，核心思想是通过高阶策略在观测数据集提取先验知识引导在线策略进行高质量探索，以解决智能体在稀疏长程任务中效率低下问题。

第五章，扩散点轨迹增强的高效策略学习。本章节使用扩散模型学习抽象的策略相关数据表征，首先使用点跟踪器提取视频数据中策略相关点轨迹，利用扩散模型生成能力学习基于状态和任务的未来点轨迹，用于增强策略学习能力，这一方法不仅规避了在图像空间像素级生成挑战，点轨迹能更好的提供策略相关信息，提高策略学习效率和决策能力。

第六章，总结和展望。本章总结了论文的研究目的、内容及相关成果，并指出论文有待深入研究的方向。

中国知网 https://www.cnki.net

第二章 强化学习理论以及扩散模型原理

2.1 引言

强化学习方法作为智能体决策的核心技术，通过与扩散模型深度融合，能够显著提升决策策略的质量与鲁棒性。本章将系统性地从以下几个方面展开论述：首先，对智能体决策任务进行严格的数学化建模，明确问题定义、约束条件及优化目标，为后续分析奠定理论基础；其次，深入探讨强化学习在智能体决策中的基本概念与理论框架，涵盖马尔可夫决策过程、贝尔曼方程、价值函数、策略优化等核心内容，并分析其在复杂决策场景中的应用与局限性；随后，详细阐述扩散模型的数学原理及其在生成任务中的工作机制，重点介绍其基于随机微分方程的建模方法，逐步去噪的生成过程以及与强化学习结合的经典方法。

2.2 序列决策概念

强化学习是一类用于解决各种连续决策任务的方法。在这类任务中，要设计一个与外部环境交互的智能体。智能体保持一个内部状态 s_t，并将其传递给它的策略 pi 以选择一个行动 $a_t = \pi(s_t)$。环境会回馈一个观测值 o_t，智能体会使用状态更新函数 $s_{t+1} = U(s_t, a_t, o_{t+1})$ 更新其内部状态。示意图见图2-1。

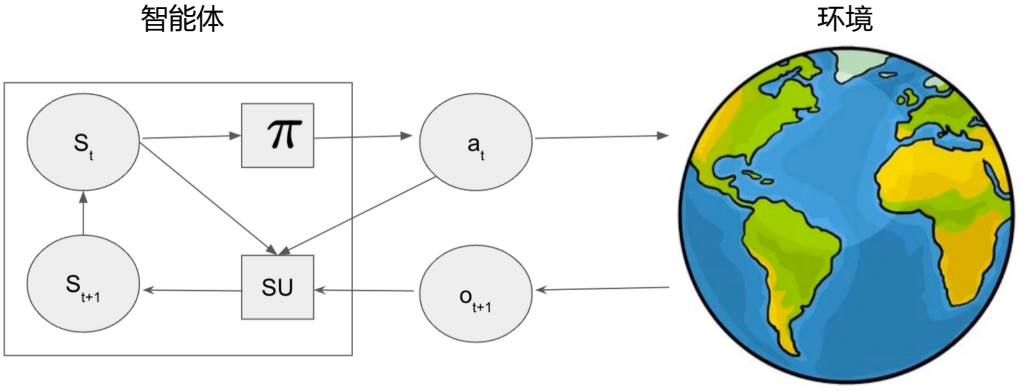


图 2-1 智能体与外部世界互动。

2.2.1 问题定义

智能体的目标是选择一个策略 π，使预期回报之和最大化：

$$V_\pi(s_0) = \mathbb{E}_{p(a_0,s_1,a_1,\ldots,a_T,s_T|s_0,\pi)}\left[\sum_{t=0}^{T} R(s_t,a_t)|s_0\right], \tag{2-1}$$

中国知网 https://www.cnki.net

其中，s_0 是智能体的初始状态，$R(s_t, a_t)$ 是智能体用来衡量在给定状态下执行某一行动的价值的奖励函数，$V_{\pi(s_0)}$ 是在 s_0 处评估的策略 π 的价值函数，期望值如下表示：

$$\begin{aligned} p\left(a_0, s_1, a_1, \ldots, a_T, s_T \mid s_0, \pi\right) = & \pi\left(a_0 \mid s_0\right) p_{\text{env}}\left(o_1 \mid a_0\right) \delta\left(s_1 = U\left(s_0, a_0, o_1\right)\right) \\ & \times \pi\left(a_1 \mid s_1\right) p_{\text{env}}\left(o_2 \mid a_1, o_1\right) \delta\left(s_2 = U\left(s_1, a_1, o_2\right)\right) \\ & \times \pi\left(a_2 \mid s_2\right) p_{\text{env}}\left(o_3 \mid a_{1:2}, o_{1:2}\right) \delta\left(s_3 = U\left(s_2, a_2, o_3\right)\right) \ldots, \end{aligned} \tag{2-2}$$

其中，p_{env} 是环境在观测数据中的分布，这通常是未知的。最优策略通过以下方法定义：

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{p_0(s_0)}\left[V_\pi\left(s_0\right)\right], \tag{2-3}$$

需要注意的是，选择一个能使预期回报之和最大化的策略是最大预期效用原理的一个实例。设计或学习最优策略有多种方法，这取决于对环境和智能体形式的假设。下面将讨论其中的一些方法。

2.2.2 通用模型建模

图2-2 显示了序列决策问题的通用表示法，它是 Warren 等人 [65] 提出的 “通用建模框架” 的扩展版。在这里，假设环境可以用一个受控马尔可夫过程来建模，该过程具有隐藏状态 z_t，每一步都会根据智能体的行动 a_t 进行更新。为了考虑到非确定性动态，将其写成 $z_{t+1} = W(z_t, a_t, \epsilon_t^z)$ ，其中 W 是环境的状态转换函数（通常不为智能体所知），ϵ_t^z 是随机系统噪声, 智能体在每一步都看不到世界状态 z_t，而是看到一个可能有噪声和/或不完整的观测值 $o_{t+1} = O(z_{t+1}\ \epsilon_{t+1}^o$ ，其中 ϵ_{t+1}^o 是随机观测噪声。例如，在迷宫中导航时，机器人可能只能看到前方的景物，而不能同时看到世界上的所有景物；此外，即使是当前景物也可能受到传感器噪声的干扰。任何给定的图像，例如包含一扇门的图像，都可能对应着世界上许多不同的位置（感知别离），而每个位置都可能需要采取不同的行动。因此，智能体需要使用状态更新函数 $s_{t+1} = SU(s_t, a_t, o_{t+1})$，利用这些观察结果来增量更新自己对世界的内部信念状态；这代表了智能体对底层世界状态 z_t 以及未知世界模型 W 本身（或其智能体）的信念。在最简单的情况下，内部 s_t 可以只存储所有过去的观测数据，即 $h_t = (o_{1:t}, a1 : t-1)$，但这种非参数模型会耗费大量的时间和空间，因此通常会考虑参数近似。然后，智能体可以使用 $a_{t+1} = \pi_t(s_{t+1})$，将其状态传递给其策略，以选择行动。

可以将状态更新函数分成两部分来进一步阐述智能体的行为。首先，智能体

中国知网 https://www.cnki.net

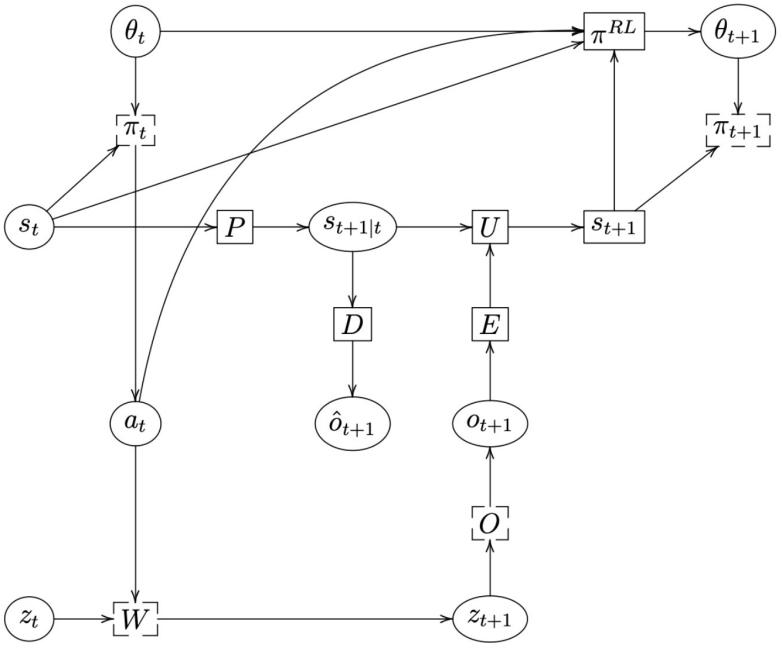


图 2-2 图表展示了智能体与环境之间的交互过程。智能体具有内部状态 s_t，并根据其策略 π_t 选择动作 a_t。随后，智能体通过预测函数 P 预测其下一个内部状态 $s_{t+1|t}$，并可选择通过观测解码器 D 预测相应的观测结果 $\hat{o}_{t+1}$。环境具有（隐藏的）内部状态 z_t，该状态会根据智能体的动作 a_t 通过世界模型 W 更新为新的状态 $z_{t+1} = W(z_t, a_t)$。同时，环境通过观测模型 O 发出观测结果 o_{t+1}。智能体通过其观测编码器 E 将观测结果编码为 e_{t+1}，并使用该编码更新其内部状态，即 $s_{t+1} = U(s_t, a_t, e_{t+1})$。

使用预测函数 P 预测自己的下一个状态，即 $s_{t+1|t} = P(s_t, a_t)$，然后使用更新函数 U 根据观察结果更新预测，得到 $s_{t+1} = U(s_{t+1|t}, o_{t+1})$。因此，$SU$ 函数被定义为预测函数和更新函数的组合：$s_{t+1} = SU(s_t, a_t, o_{t+1}) = U(P(s_t, a_t), o_{t+1})$。如果观察结果是高维的（如图像），智能体可以选择使用编码器将其观察结果编码为低维嵌入 e_{t+1}，$e_{t+1} = E(o_{t+1})$；这可以促使智能体专注于感觉信号的相关部分，这样状态更新就变成了 $s_{t+1} = U(s_{t+1|t}, e_{t+1})$。或者，智能体也可以通过训练解码器来反转这个编码器，使用 $o^{t+1} = D(s_{t+1|t})$ 来预测下一个观测结果；这可能是一个有用的训练信号。最后，智能体需要学习行动策略 π_t。使用 θ_t 将其参数化，因此 $\pi_t(s_t) = \pi(s_t; \theta_t)$。这些参数本身可能需要学习；使用 π^{RL} 来表示强化学习策略，它规定了如何在每一步更新策略参数。参见图2-3。

一般来说，这需要处理三个相互作用的随机过程：环境状态 z_t，通常会受到智能体行动的影响；智能体的内部状态 s_t，根据观察到的数据反映智能体对环境的信念；以及智能体的策略参数 θ_t，根据信念状态中存储的信息进行更新。

中国知网 https://www.cnki.net

如果智能体可以与环境永久交互下去，称其为持续性任务。另一种情况是回合任务，当智能体进入终止状态或中断状态时，交互即告终止——这类状态的特点是只能自我转移且不产生任何奖励。进入终止状态后，可以从新的初始世界状态 $z_0 \sim p_0$ 开始一个全新回合（此时智能体通常也会重置其内部状态 s_0）。回合长度通常是随机不固定的。例如，机器人抵达目标所需的时间可能存在较大波动，这取决于其决策过程以及环境中的随机因素。最后，若回合任务中的轨迹长度 T 是固定且已知的，则称为有限时间问题。将某一状态在 t 时刻的收益定义为未来预期收益的总和，其中每个收益乘以折扣因子 $\gamma \in [0,1]$：

$$\begin{aligned} G_t &\triangleq r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \cdots + \gamma^{T-t-1} r_{T-1} \\ &= \sum_{k=0}^{T-t-1} \gamma^k r_{t+k} = \sum_{j=t}^{T-1} \gamma^{j-t} r_j, \end{aligned} \tag{2-4}$$

其中，$r_t = R(s_t, a_t)$ 是奖赏，G_t 是未来累计奖励。对于在时间 T 终止的回合任务，定义在 $t \geq T$ 时 $G_t = 0$。未来累计奖励满足以下递推关系:

$$G_t = r_t + \gamma \left(r_{t+1} + \gamma r_{t+2} + \cdots \right) = r_t + \gamma G_{t+1}, \tag{2-5}$$

此外，还将价值函数定义为预期未来累计奖励:

$$V_\pi \left(s_t \right) = \mathbb{E} \left[G_t \mid \pi \right], \tag{2-6}$$

折扣因子 γ 有两个作用。首先，它确保了即使 $T = \infty$，收益也是有限的，前提是使用 $\gamma < 1$ 且奖励 r_t 是有界的，它更看重短期奖励，这通常会鼓励智能体人更快地实现目标。但是，如果 γ 太小，智能体人就会变得过于贪婪。在 $\gamma = 0$ 的极端情况下，智能体完全是短视，只试图最大化眼前的回报。一般来说，折扣因子反映了这样一种假设，即互动在下一步结束的概率为 $1-\gamma$。对于已知 T 的有限时间跨度问题，可以设置 $\gamma = 1$，因为事先知道智能体的运行周期。

2.2.3 马尔可夫决策过程

马尔可夫决策过程 [36] 环境状态是可观测的，因此 $zt = ot = st$ 通常用世界模型诱导的状态转换矩阵来定义马尔可夫决策过程：$p_S \left(s_{t+1} \mid s_t, a_t \right) = \mathbb{E}_{\epsilon_t^s} \left[\mathbb{I} \left(s_{t+1} = W \left(s_t, a_t, \epsilon_t^s \right) \right) \right]$ 作为观察模型的替代，假设环境会发出一个奖励信号，从 $p_R(r_t | s_t, a_t, s_{t+1})$ 中采样。因此，期望奖励由以下公式给出:

$$\begin{aligned} R \left(s_t, a_t, s_{t+1} \right) &= \sum_r r p_R \left(r \mid s_t, a_t, s_{t+1} \right) \\ R \left(s_t, a_t \right) &= \sum_{s_{t+1}} p_S \left(s_{t+1} \mid s_t, a_t \right) R \left(s_t, a_t, s_{t+1} \right), \end{aligned} \tag{2-7}$$

中国知网 https://www.cnki.net

给定一个随机策略 $\pi(a_t|s_t)$，智能体可以通过多个步骤与环境互动。每一步称为一个状态转移，由元组 (s_t, a_t, r_t, s_{t+1}) 组成，其中 $a_t \sim \pi(-|s_t)$ $s_{t+1} \sim p_S(s_t, a_t)$ $r_t \sim p_R(s_t, a_t, s_{t+1})$。因此，在策略 π 下，产生长度为 T 的轨迹的概率 $\pi = (s_0, a_0, r_0, s_1, a_1, r_1, s_2, ..., s_T)$, 可表示为：

$$p(\tau) = p_0(s_0) \prod_{t=0}^{T-1} \pi(a_t|s_t) p_S(s_{t+1}|s_t, a_t) p_R(r_t|s_t, a_t, s_{t+1}), \tag{2-8}$$

一般而言，马尔可夫决策过程的状态集和动作集可以是离散的或连续的。当两者均为有限集合时，可以用查找表的形式表示这些函数，这被称为表格化表示。此时，可以将马尔可夫决策过程建模为一个有限状态机，即以节点表示状态、以边表示动作及其对应的转移奖励和下一状态的图结构。图2-3展示了一个包含 3 个状态和 2 个动作的简单马尔可夫决策过程示例。若已知环境模型 p_S（状态转移函数）和 p_R（奖励函数），且状态和动作空间采用表格化表示，则可通过动态规划技术求解最优策略。然而，实际场景中环境模型通常是未知的，且状态和动作的转移可能需用复杂的非线性模型描述。在此类情况下，必须通过强化学习方法学习到一个优良策略。

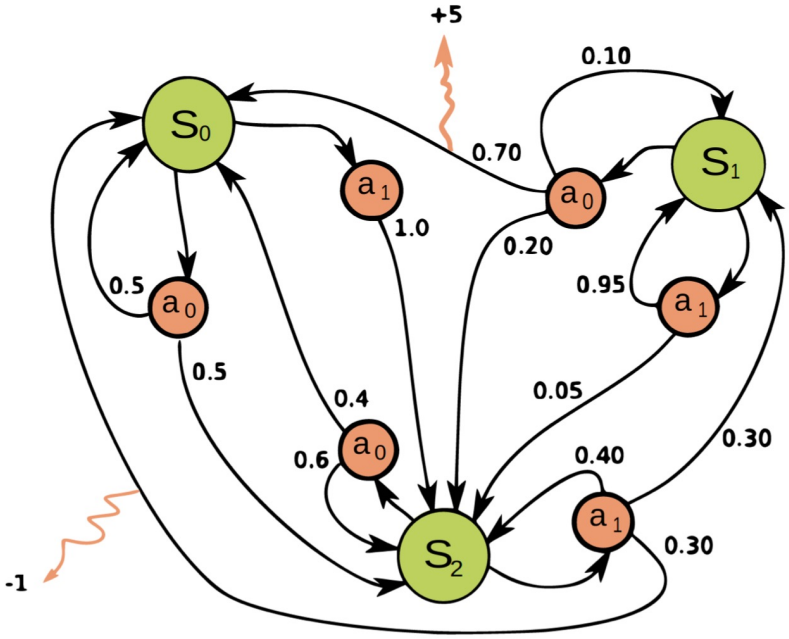


图 2-3 图解将马尔可夫决策过程（MDP）表示为有限状态机。

2.2.4 部分观测马尔可夫决策过程

图 2-2所示的模型被称为部分可观测马尔可夫决策过程 [66]。通常情况下，环境动态模型并非通过带有噪声输入的确定性函数表示，而是由随机转移函数来表征。

中国知网 https://www.cnki.net

可以通过以下方式推导出这一转移函数：

$$p(z_{t+1}|z_t, a_t) = \mathbb{E}_{\epsilon_t^z}\left[\mathbb{I}\left(z_{t+1} = W(z_t, a_t, \epsilon_t^z)\right)\right], \tag{2-9}$$

同样，随机观测函数的公式表示为：

$$p(o_{t+1}|z_{t+1}) = \mathbb{E}_{\epsilon_{t+1}^o}\left[\mathbb{I}\left(o_{t+1} = O(z_{t+1}, \epsilon_{t+1}^o)\right)\right], \tag{2-10}$$

可以将这两个分布结合起来，得出联合世界模型 $p_{WO}(z_{t+1}, o_{t+1}|z_t, a_t)$。此外，还可以利用这些分布推导出环境非马尔可夫观测分布 $p_{env}(o_{t+1}|o_{1:t}, a_{1:t})$，如下所示：

$$\begin{aligned} p_{\text{env}}(o_{t+1}|o_{1:t}, a_{1:t}) &= \sum_{z_{t+1}} p(o_{t+1}|z_{t+1}) p(z_{t+1}|a_{1:t}), \\ p(z_{t+1}|a_{1:t}) &= \sum_{z_1} \cdots \sum_{z_t} p(z_1|a_1) p(z_2|z_1, a_1) \ldots p(z_{t+1}|z_t, a_t), \end{aligned} \tag{2-11}$$

如果已知世界模型（$p(o|z)$ 和 $p(z'|z, a)$），原则上就可以求解最优策略。该方法要求智能体的内部状态对应于信念状态 $s_t = b_t = p(z_t|h_t)$，其中 $h_t = (o_{1:t}, a_{1:t-1})$ 是观测历史。可以使用贝叶斯规则递归更新信念状态，信念状态是最优策略的充分统计量，然而计算信念状态和由此得到的最优策略非常困难。

2.3 强化学习理论

在本节中，将介绍在环境模型未知的情况下如何计算最优策略；这正是强化学习所要解决的核心问题。主要关注马尔可夫决策过程案例。可以从两个主要维度对强化学习方法进行分类：(1) 根据智能体所代表和学习的内容来分类：价值函数、策略、或环境模型；(2) 根据行动的选择方式来分类：同策略或异策略。

2.3.1 基于价值的强化学习

设 π 为给定策略。定义状态价值函数（简称价值函数）如下（其中 $\mathbb{E}_\pi[\cdot]$ 表示动作由策略 π 选择）：

$$V^\pi(s) \triangleq \mathbb{E}_\pi[G_0|s_0 = s] = \mathbb{E}_\pi\left[\sum_{t=0}^{\infty} \gamma^t r_t \middle| s_0 = s\right], \tag{2-12}$$

定义状态-动作价值函数（也称为 Q 函数）如下：

$$Q^\pi(s, a) \triangleq \mathbb{E}_\pi[G_0|s_0 = s, a_0 = a] = \mathbb{E}_\pi\left[\sum_{t=0}^{\infty} \gamma^t r_t \middle| s_0 = s, a_0 = a\right], \tag{2-13}$$

中国知网 https://www.cnki.net

该值表示如果在状态 s 中采取动作 a，然后遵循策略 π 选择动作，所获得的期望回报。最后，定义优势函数如下：

$$A^{\pi}(s,a) \triangleq Q^{\pi}(s,a) - V^{\pi}(s), \tag{2-14}$$

由此可知，在状态 s 中选择动作 a 然后切换到策略 π 的收益，相对于始终遵循策略 π 的基准回报。注意，$A^{\pi}(s,a)$ 可以是正的或负的，并且由于一个有用的等式 $V^{\pi}(s) = \mathbb{E}_{\pi(a|s)}[Q^{\pi}(s,a)]$，有 $\mathbb{E}_{\pi(a|s)}[A^{\pi}(s,a)] = 0$。

假设 π^* 是一个策略，对于所有状态 $s \in S$ 和所有策略 π，都有 $V^{\pi^*} \geq V^{\pi}$，那么 π^* 是一个最优策略。对于同一个马尔可夫决策过程，可能存在多个最优策略，但根据定义，它们的状态价值函数必须相同，分别记为 V^* 和 Q^*。称 V^* 为最优状态价值函数，Q^* 为最优动作价值函数。此外，任何有限马尔可夫决策过程都至少存在一个确定性的最优策略 [36]。

关于最优价值函数的一个基本结果是贝尔曼最优方程：

$$V^*(s) = \max_a \left\{ R(s,a) + \gamma \mathbb{E}_{p_S(s'|s,a)}[V^*(s')] \right\}, \tag{2-15}$$

$$Q^*(s,a) = R(s,a) + \gamma \mathbb{E}_{p_S(s'|s,a)} \left[\max_{a'} Q^*(s',a') \right], \tag{2-16}$$

反之，最优价值函数是唯一满足这些方程的解。换句话说，尽管价值函数被定义为无限多奖励总和的期望，但它可以通过仅涉及马尔可夫决策过程的一步转移和奖励模型的递归方程来表征。这种递归在大量强化学习算法中起着核心作用。

给定一个价值函数（V 或 Q），方程 2-16和 2-15左右两边的差异称为贝尔曼误差或贝尔曼残差。对于给定的马尔可夫决策过程 $M = (R,T)$ 和策略 π，可以定义贝尔曼算子 B 为一个函数，它将一个价值函数 V 转换为另一个价值函数 V'，满足

$$V'(s) = B_M^{\pi} V(s) \triangleq \mathbb{E}_{\pi(a|s)} \left[R(s,a) + \gamma \mathbb{E}_{T(s'|s,a)}[V(s')] \right], \tag{2-17}$$

将贝尔曼算子应用于一个状态称为贝尔曼备份, 这减少了贝尔曼误差。如果迭代这个过程，将收敛到最优价值函数 V^*。

给定最优价值函数，可以通过以下方式推导出最优策略：

$$\begin{aligned} \pi^*(s) &= \arg\max_a Q^*(s,a) \\ &= \arg\max_a \left\{ R(s,a) + \gamma \mathbb{E}_{p_S(s'|s,a)}[V^*(s')] \right\}, \end{aligned} \tag{2-18}$$

遵循这样的最优策略可以确保智能体从任何状态开始都能获得最大期望回报。

求解 V^*、Q^* 或 π^* 的问题称为策略优化。相比之下，对于给定的策略 π，求解 V^{π} 或 Q^{π} 称为策略评估，这构成了强化学习问题的一个重要子类，将在后面的

中国知网 https://www.cnki.net

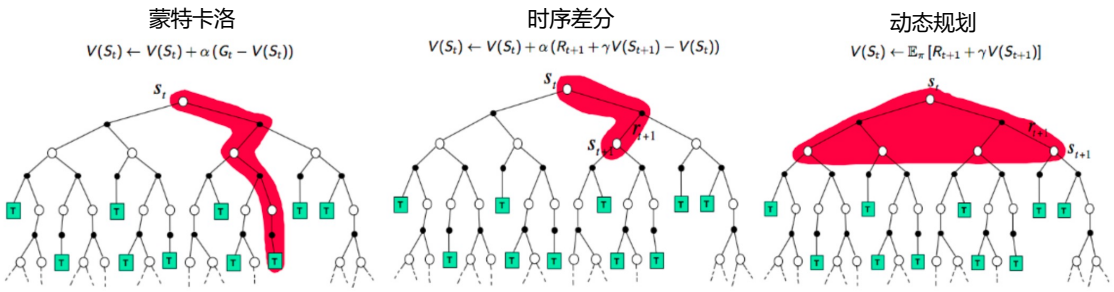


图 2-4 状态价值函数 $V(s_t)$ 的备份图，展示了蒙特卡罗、时序差分和动态规划更新的过程。

章节中讨论。对于策略评估，有类似的贝尔曼方程，只需将方程 2-16和 2-15中的 $\max_a\{\cdot\}$ 替换为 $\mathbb{E}_{\pi(a|s)}[\cdot]$。

与贝尔曼最优方程一样，必须对动作集合 A 中的所有动作取最大值，最大化动作称为关于价值函数 Q^* 或 V^* 的贪心动作。如果 A 是一个小的有限集合，找到贪心动作在计算上是容易的。这里介绍时序差分学习 [1] 方法，图2-4展示了蒙特卡洛、时序差分和动态规划之间的区别。其基本思想是基于状态转移而非完整轨迹，逐步减少采样状态或状态-动作对的贝尔曼误差。更准确地说，假设要学习固定策略 π 的价值函数 V^π。给定一个状态转移 (s_t, a_t, r_t, s_{t+1})，其中 $a_t \sim \pi(s_t)$，调整估计值 $V(s_t)$，使其向目标值 $q_t = r_t + \gamma V(s_{t+1}) \approx G_{t:t+1}$ 靠近：

$$V(s_t) \leftarrow V(s_t) + \eta \left[\underbrace{r_t + \gamma V(s_{t+1}) - V(s_t)}_{\delta_t} \right], \tag{2-19}$$

其中 η 是学习率。$\delta_t = y_t - V(s_t)$ 称为时序差分误差。对于参数化价值函数表示，时序差分更新的更一般形式为:

$$w \leftarrow w + \eta \left[r_t + \gamma V_w(s_{t+1}) - V_w(s_t) \right] \nabla_w V_w(s_t), \tag{2-20}$$

可以看到，方程 2-19是上述公式的一个特例。用于评估 Q^π 的时间查分更新规则类似，只是将状态替换为状态和动作对。

可以证明，在适当条件下，表格情况下的时序差分学习会收敛到正确的价值函数 [67]。然而，当使用非线性函数逼近器时，它可能会发散，原因是该更新是一种 “半梯度”，即仅对价值函数 $\nabla_w V(s_t, w_t)$ 取梯度，而将目标 U_t 视为常数。

时序差分的潜在发散也与以下事实一致：其形式与随机梯度下降非常相似，但它并不对应于任何目标函数的梯度更新。相反，它是一种自举方法，其中估计值 $V_w(s_t)$ 被更新以接近目标值 $r_t + \gamma V_w(s_{t+1})$，而该目标值由价值函数估计本身定义。这种思想与动态规划方法相似，尽管动态规划依赖于完整的马尔可夫决策过

中国知网 https://www.cnki.net

程模型来计算精确的贝尔曼备份。相比之下，时序差分学习可以看作使用采样的转移来近似这种备份。

时序差分和蒙特卡罗之间的一个关键区别在于它们估计回报的方式。给定一个轨迹 $\tau = (s_0, a_0, r_0, s_1, ..., s_T)$，时序差分通过一步前瞻估计状态 s_t 的回报：

$$G_{t:t+1} = r_t + \gamma V(s_{t+1}) \tag{2-21}$$

其中，从时间 $t+1$ 开始的回报被其价值函数估计值所替代。相比之下，蒙特卡罗方法要等到整个回合结束或 T 足够大时，再使用以下估计：

$$G_{t:T} = r_t + \gamma r_{t+1} + \cdots + \gamma^{T-t-1} r_{T-1}, \tag{2-22}$$

可以通过执行 n 步回溯并使用价值函数来近似轨迹剩余部分的回报，在时序查分和蒙特卡洛之间进行插值，类似于启发式搜索。即，可以使用 n 步回报：

$$G_{t:t+n} = r_t + \gamma r_{t+1} + \cdots + \gamma^{n-1} r_{t+n-1} + \gamma^n V(s_{t+n}), \tag{2-23}$$

例如，1 步和 2 步回报分别为：

$$G_{t:t+1} = r_t + \gamma v_{t+1}, \tag{2-24}$$

$$G_{t:t+2} = r_t + \gamma r_{t+1} + \gamma^2 v_{t+2}, \tag{2-25}$$

对应的 n 步时序差分更新形式为：

$$w \leftarrow w + \eta[G_{t:t+n} - V_w(s_t)]\nabla_w V_w(s_t), \tag{2-26}$$

与其选择特定的回溯步数 n，可以对所有可能的 n 取加权平均，并引入一个单一参数 $\lambda \in [0, 1]$：

$$G_t^\lambda \equiv (1-\lambda) \sum_{n=1}^{\infty} \lambda^{n-1} G_{t:t+n}, \tag{2-27}$$

这被称为 lambda 回报（λ-return）。注意，这些系数的和为 1 因为当 $\lambda < 1$ 时：

$$\sum_{t=0}^{\infty} (1-\lambda)\lambda^t = \frac{1-\lambda}{1-\lambda} = 1, \tag{2-28}$$

因此，回报是 n 步回报的凸组合。如图2-5，现在，可以在时序差分更新中使用 G_t^λ 代替 $G_{t:t+n}$，这被称为 TD(λ) 算法。需要注意的是，如果在时间 T 进入终止状态，那么所有后续的 n 步回报都等于标准回报 G_t。因此，可以写成：

$$G_t^\lambda = (1-\lambda) \sum_{n=1}^{T-t-1} \lambda^{n-1} G_{t:t+n} + \lambda^{T-t-1} G_t, \tag{2-29}$$

中国知网 https://www.cnki.net

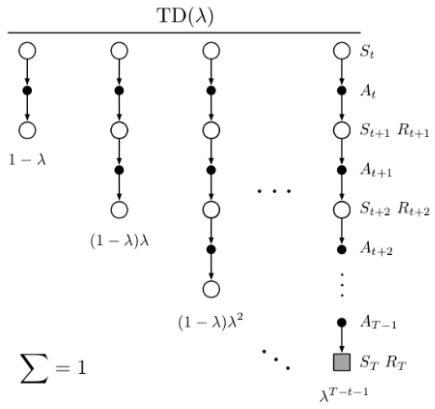


图 2-5 TD(λ) 的备份图。标准时序差分学习对应于 $\lambda = 0$，而标准蒙特卡洛学习对应于 $\lambda = 1$。

由此可见，当 $\lambda = 1$ 时，λ-return 退化为常规蒙特卡洛回报 G_t。当 $\lambda = 0$ 时，λ-return 退化为 1 步回报 $G_{t:t+1}$，因此标准时序差分学习通常被称为 TD(0) 学习。此外，这种回合式形式可以得出以下递归方程：

$$G_t^{\lambda} = r_t + \gamma[(1-\lambda)G_{t+1}^{\lambda} + \lambda V(s_{t+1})], \tag{2-30}$$

其中，终止状态的初始化条件为 $G_T = v_T$。

2.3.2 基于策略的强化学习

在上一节中，考虑了估计行动值函数 $Q\ s\ a$ 的方法，并由此推导出策略。然而，这些方法有几个缺点：(1) 它们很难应用于连续行动空间；(2) 如果使用函数近似，它们可能会发散；(3)Q 的训练通常基于时序查分式更新，与所学策略获得的预期收益没有直接关系；(4) 它们学习的是确定性策略，而在随机和部分观测环境中，随机策略显然更好 [68]。

在本节中，将讨论策略搜索方法，这种方法可以直接优化策略参数，从而使其预期收益最大化。这里主要关注利用损失梯度来引导搜索的策略梯度方法。这些策略方法通常受益于对价值或优势函数的估计，以减少策略搜索过程中的方差。参数策略将以 $\pi_\theta(a|s)$ 表示。对于离散动作，可以采用深度神经网络输出 softmax 结果。对于连续动作，可以使用高斯输出层或扩散策略 [69]。

首先定义策略学习的目标函数，然后推导其梯度。需要最大化的目标函数定

中国知网 https://www.cnki.net

义：

$$\begin{aligned} J(\pi) &\triangleq \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty}\gamma^{t}R_{t+1}\right] \\ &= \sum_{t=0}^{\infty}\gamma^{t}\sum_{s}\left(\sum_{s_0}p_0(s_0)p^{\pi}(s_0\to s,t)\right)\sum_{a}\pi(a|s)R(s,a) \\ &= \sum_{s}\left(\sum_{s_0}\sum_{t=0}^{\infty}\gamma^{t}p_0(s_0)p^{\pi}(s_0\to s,t)\right)\sum_{a}\pi(a|s)R(s,a) \\ &= \sum_{s}\rho^{\pi}(s)\sum_{a}\pi(a|s)R(s,a), \end{aligned} \tag{2-31}$$

定义折扣状态访问分布为：

$$\rho_{\pi}^{\gamma}(s) \triangleq \sum_{t=0}^{\infty}\gamma^{t}\underbrace{\sum_{s_0}p_0(s_0)p^{\pi}(s_0\to s,t)}_{p_t^{\pi}(s)}, \tag{2-32}$$

其中 $p_{\pi^*}(s_0\to s,t)$ 表示在策略 π^* 下，从初始状态 s_0 经过 t 步转移到状态 s 的概率；$p_t^{\pi}(s)$ 是时间步 t 时处于状态 s 的边际概率，$\rho_{\pi}^{\gamma}(s)$ 衡量的是在非终止状态上花费的时间，但它并非概率测度，因为它未经过归一化，即：$\sum_s \rho_{\pi}^{\gamma}(s)\neq 1$，但是仍可将其近似视为概率分布来简化分析，记作：$\mathbb{E}_{\rho_{\pi}^{\gamma}(s)}[f(s)]=\sum_s \rho_{\pi}^{\gamma}(s)f(s)$ 由此可以简化目标函数定义为：

$$J(\pi)=\mathbb{E}_{\rho_{\pi}^{\gamma}(s),\pi(a|s)}\left[R(s,a)\right], \tag{2-33}$$

注意到 $\sum_{t=0}^{\infty}\gamma^{t}=\frac{1}{1-\gamma}$，对所有 $\gamma<1$ 成立，因此可以定义一个标准化的度量 ρ，用于表示归一化则扣状态访问分布:

$$p_{\pi}^{\gamma}(s)=(1-\gamma)\rho_{\pi}^{\gamma}(s)=(1-\gamma)\sum_{t=0}^{\infty}\gamma^{t}p_t(s), \tag{2-34}$$

上述目标的梯度由式给出：

$$\begin{aligned} \nabla_{\theta}J(\theta) &= \sum_{s}\rho_{\pi}^{\gamma}(s)\sum_{a}Q^{\pi}(s,a)\nabla_{\theta}\pi_{\theta}(a|s) \\ &= \sum_{s}\rho_{\pi}^{\gamma}(s)\sum_{a}Q^{\pi_{\theta}}(s,a)\pi_{\theta}(a|s)\nabla_{\theta}\log\pi_{\theta}(a|s) \\ &= \mathbb{E}_{\rho_{\pi}^{\gamma}(s)\pi_{\theta}(a|s)}\left[Q^{\pi_{\theta}}(s,a)\nabla_{\theta}\log\pi_{\theta}(a|s)\right], \end{aligned} \tag{2-35}$$

这被称为策略梯度定理 [49]。其中 $\nabla_{\theta}\log\pi_{\theta}(a|s)]$ 项也称为分数函数。

Soft Actor-Critic(SAC) [70] 算法是基于最大熵强化学习的非策略演员-评论家算法，该算法利用缓冲经验回放对过去经验采样，策略更新使用 actor 自己的概率分布完成，从而消除了使用重要性采样来纠正行为策略和目标策略之间的差异的需

中国知网 https://www.cnki.net

要。首先对强化学习最大化目标函数进行修改：

$$J^{\mathrm{SAC}}(\theta) \triangleq \mathbb{E}_{p^{\gamma}_{\pi_\theta}(s)\pi_\theta(a|s)}\left[R(s,a)+\alpha\mathbb{H}(\pi_\theta(\cdot|s))\right], \tag{2-36}$$

通过引入对策略分布熵项，使目标函数容易被优化，并且鼓励了策略探索。对目标函数的优化通过执行策略评估，然后进行测量提升，策略评估通过重复应用以下修改后的贝尔曼备份操作：

$$\mathcal{T}^{\pi}Q(s_t,a_t) = r(s_t,a_t)+\gamma\mathbb{E}_{s_{t+1}\sim p}\left[V(s_{t+1})\right], \tag{2-37}$$

其中 $V(s_t)=\mathbb{E}_{a_t\sim\pi}\left[Q(s_t,a_t)-\alpha\log\pi(a_t|s_t)\right]$ 是价值函数。通过不断迭代执行贝尔曼备份方程 $Q^{k+1}=\mathcal{T}^{\pi}Q^{k}$，最终会收敛到 Q 函数。

在策略改进步骤中，基于学习到的 Q 函数，通过最大化每个状态最大的可能动作，得到新的优化策略。然后将策略更新约束到策略类中，更新方式如下：

$$\pi_{\mathrm{new}} = \arg\min_{\pi'\in\Pi} D_{\mathbb{KL}}\left(\pi'(\cdot|s_t)\parallel\frac{\exp(\frac{1}{\alpha}Q^{\pi_{\mathrm{old}}}(s_t,\cdot))}{Z^{\pi_{\mathrm{old}}}(s_t)}\right), \tag{2-38}$$

通过求解上述优化问题，能够确保满足 SAC 策略改进定理，即对于所有 s_t 和 a_t，有 $Q^{\pi_{new}}(s_t,a_t)\geq Q^{\pi_{old}}(s_t,a_t)$。在非表格的情况下，上述方法难以处理，所以需要展到使用函数近似的情况。

对于策略评估，保持策略参数 π 固定，并通过最小化贝尔曼差分来优化 Q 函数的参数 w：

$$J_Q(w)=\mathbb{E}_{(s_t,a_t,r_{t+1},s_{t+1})\sim\mathcal{D}}\left[\frac{1}{2}\left(Q_w(s_t,a_t)-q(r_{t+1},s_{t+1})\right)^2\right], \tag{2-39}$$

其中 D 是缓冲回放, $q(r_{t+1},s_{t+1})=r_{t+1}+\gamma V_{\overline{w}}(s_{t+1})$ 是冻结的目标价值，冻结的价值函数 $V_{\overline{w}}$ 计算和 $V(s_t)$ 相同：

$$V_{\overline{w}}(s_t)=\mathbb{E}_{\pi(a_t|s_t)}\left[Q_{\overline{w}}(s_t,a_t)-\alpha\log\pi(a_t|s_t)\right], \tag{2-40}$$

模型参数的采用指数移动平均的方法进行逐步更新。

为了避免 actor-critic 方法可能出现的正高估偏差，Haarnoja 等人[70] 通过优化 $J_Q(w_i)$，分别拟合两个软 Q 函数，对于 $i=1,2$。目标定义为：

$$q(r_{t+1},s_{t+1};\overline{w}_{1:2},\theta)=r_{t+1}+\gamma\left[\min_{i=1,2}Q_{\overline{w}_i}(s_{t+1},\tilde{a}_{t+1})-\alpha\log\pi_\theta(\tilde{a}_{t+1}|s_{t+1})\right], \tag{2-41}$$

对于策略改进，保持值函数参数 w 不变，并通过最小化下面的目标来优化策略参数 θ，其中引入了 KL 项进行约束：

$$J_\pi(\theta)=\mathbb{E}_{s_t\sim\mathcal{D}}\left[\mathbb{E}_{a_t\sim\pi_\theta}\left[\alpha\log\pi_\theta(a_t|s_t)-Q_w(s_t,a_t)\right]\right], \tag{2-42}$$

中国知网 https://www.cnki.net

假设策略分布具有 $\pi_\theta(a_t|s_t) = \mathcal{N}(\mu_\theta(s_t), \sigma^2\mathbf{I})$ 的形式。可以把随机动作写成 $a_t = f_\theta(s_t, \epsilon_t)$，其中 f 是状态和噪声变量 ϵ_t 的确定性函数，因为 $a_t = \mu(s_t) + \sigma^2\epsilon_t$，其中 $\epsilon_t \sim \mathcal{N}(0, \mathbf{I})$，目标函数简化为:

$$J_\pi(\theta) = \mathbb{E}_{s_t\sim\mathcal{D}, \epsilon_t\sim\mathcal{N}}\left[\alpha \log \pi_\theta(f_\theta(s_t, \epsilon_t)|s_t) - Q_w(s_t, f_\theta(s_t, \epsilon_t))\right], \tag{2-43}$$

对于离散动作，可以用 gumbel-softmax 重参数化来代替高斯重参数化，或者可以避开抽样，明确地计算行动的期望，这被称为 SAC-Discrete [71]。J_π 目标可以计算为:

$$J'_\pi(\theta) = \mathbb{E}_{s_t\sim\mathcal{D}}\left[\sum_a \pi_\theta(a|s_t)[\alpha \log \pi_\theta(a|s_t) - Q_w(s_t, a)]\right], \tag{2-44}$$

2.3.3 基于模型的强化学习

无模型强化学习方法通常需要与环境进行大量交互才能获得良好的性能。例如，Atari 基准的最先进的方法，如 rainbow，使用数百万帧，相当于在标准帧率下玩许多天。相比之下，人类可以在几分钟内达到相同的性能 [72]。同样，OpenAI 的机械手控制器 [33] 需要 100 年的模拟数据来学习操作魔方。

一种有希望提高样本效率的方法是基于模型的强化学习（MBRL）。在最简单的基于模型的强化学习方法中，首先学习状态转移或动态模型 $p_S(s'|s, a)$, 也称为世界模型-和奖励函数 $R(s, a)$，然后使用这些模型来计算策略。可以证明，学习动态的样本复杂度小于学习策略的样本复杂度 [73]。然而，上述两阶段方法——首先学习模型，然后用它进行规划可能会遇到离线强化学习中常见的问题，即策略可能在没有收集到数据的状态下查询模型，因此预测可能不可靠，导致策略学习错误。为了获得更好的结果，必须将模型学习和策略学习交织在一起。

执行基于模型的强化学习主要有两种方式。在第一种方法中，称为决策时规划或模型预测控制，使用模型通过搜索可能的未来轨迹来选择下一个动作。然后对每个轨迹进行评分，选择与最佳轨迹相对应的动作，在环境进行执行，然后重复。第二种方法是使用当前的模型和策略来推出想象的轨迹，并使用该数据使用无模型强化学习来改进策略。决策时规划的优势在于，它允许在无奖励数据上训练一个世界模型，然后使用该模型来优化任何奖励函数。如果奖励包含不断变化的约束，或者是基于智能体的知识状态频繁变化的内在奖励，这将特别有用，决策时规划的缺点是它要慢得多。

这里阐述一种称为模型预测控制（Model Predictive Control, MPC）的方法 [74–76]：使用世界模型来预测从当前状态开始可能跟随的每个可能未来动作序列的未来状态和奖励，然后选择看起来最有希望的动作序列中的动作。更准确地说，在每一

中国知网 https://www.cnki.net

步中，计算

$$\begin{aligned} a^*_{t:t+H-1} &= \text{planning}(s_t, M, R, \hat{V}, H) \\ &= \underset{a_{t:t+H-1}}{\text{argmax}}\, \mathbb{E}_{s_{t+1:t+H}\sim M(\cdot|s_t, a_{t:t+H-1})} \left[\sum_{h=0}^{H-1} R(s_{t+h}, a_{t+h}) + \hat{V}(s_{t+H}) \right], \end{aligned} \tag{2-45}$$

$$\pi_{\text{MPC}}(s_t) = a^*_t. \tag{2-46}$$

其中，H 称为规划长度，$\hat{V}(s_{t+H})$ 是对这个 H 步前瞻过程结束时剩余奖励的估计。通常可以通过使用预训练的提议策略 $a_t = \pi(s_t)$ 来加速优化过程，该策略可用于指导搜索过程，如下所述。

需要注意的是，模型预测控制计算一个固定的动作序列 $a_{t:t+H-1}$，也称为规划，给定当前状态 s_t；由于未来动作 $a_{t'}$（$t' > t$）独立于未来状态 $s_{t'}$，因此这被称为开环控制器。这种控制器在确定性环境中可以很好地工作（其中 $s_{t'}$ 可以从 s_t 和动作序列计算得出），但在一般情况下，需要在每一步重新规划，因为实际的下一个状态是观察到的。因此，模型预测控制是一种创建闭环控制器的方法。

可以使用将模型预测控制与模型和策略学习结合起来，其中决策策略 $a_t = \pi_{\text{MPC}}(s_t)$ 由方程 2-46实现。如果想学习提议策略 $a_t = \pi(s_t)$，应该使用离策略（off-policy）方法，因为训练数据（即使是想象的）将由 π_{MPC} 而不是 π 收集。在学习世界模型时，只需要它在当前状态附近局部准确，这意味着在模型预测控制中通常可以使用比背景规划方法更简单的模型。

2.4 扩散模型基础

在本小节主要介绍扩散模型的基础理论，包括两种主流的表示形式和在强化学习任务中特别重要的采样技术。然后介绍了两种应用于智能体决策的主要方法，扩散策略和扩散规划，主要介绍了这两种方法相对于以前方法的原理改进。

2.4.1 扩散概率模型

扩散模型是一类生成模型，他以先验高斯分布 $\mathcal{N}(0, I)$ 中采样的随机噪音图像为输入，对图像进行去噪处理，逐步生成干净的图像。如图2-6所示，扩散模型的训练包括两个过程：前向过程和反向过程。

假设真实数据 x^0 从底层分布 $q(x^0)$ 中采样，DDPM[14] 使用参数化扩散过程来建模从纯高斯噪声 $X^T = (0, \mathbf{I})$ 去噪至真实数据 x^0，表示为 $p_\theta(x^0) = \int p(x^T) \prod_{t=1}^{T} p_\theta(x^{t-1}|x^t) \mathrm{d}x^{1:T}$ 每一个扩散步骤用 x^t 表示，其中 T 表示总步数。序列 $x^{T:0}$ 被定义为高斯转移过程马尔可夫链:$p_\theta(x^{t-1}|x^t) = \mathcal{N}(\mu_\theta(x^t, t), \Sigma(x^t, t))$，

中国知网 https://www.cnki.net

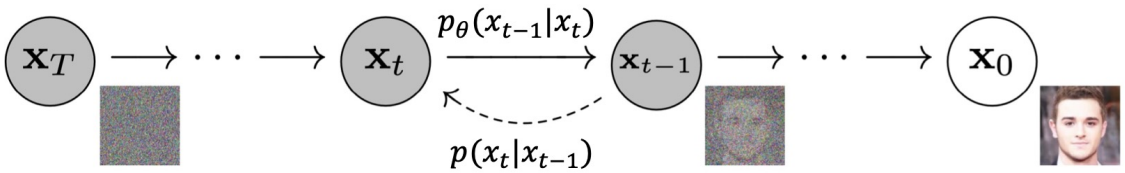


图 2-6 扩散模型前向过程和反向过程示意图。

逆向过程表示为根据方差表 $\beta^{1:T}$ 向真实数据中添加高斯噪声:$x^t = \sqrt{\alpha^t}x^{t-1} + \sqrt{1-\alpha^t}\epsilon^t$，其中 $\alpha^t = 1-\beta^t, \epsilon^t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$，进一步可以直接推倒出从 x^0 到 x^T 的映射:$x^t = \sqrt{\bar{\alpha}^t}x^0 + \sqrt{1-\bar{\alpha}^t}\epsilon(x^t, t), \bar{\alpha}^t = \prod_1^t \alpha^i$，由贝叶斯理论和 x^T 与 x^0 的关系可以推出：

$$q(x^{t-1}|x^t, x^0) = \mathcal{N}(\frac{1}{\sqrt{\alpha^t}}(x^t - \frac{\beta^t}{\sqrt{1-\bar{\alpha}^t}}\epsilon(x^t, t)), \beta^t\mathbf{I}). \tag{2-47}$$

这使得可以从高斯噪声 x^T 采用，逐步去噪声直到 x^0，使用参数化神经网络 ϵ_θ 预测噪声从而获得 $\epsilon(x^t, t)$。Ho 等人 [14] 提出了以下用于学习 ϵ_θ 的简化损失函数，它是证据下界的加权版本：

$$\mathcal{L}(\theta) = \mathbb{E}_{x^0,\epsilon,t}[\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}^t}x^0 + \sqrt{1-\bar{\alpha}^t}\epsilon, t)\|^2]. \tag{2-48}$$

song [77] 将 DDPM 扩展到连续时间扩散过程，使用连续函数 $x^t, t \in [0, T]$ 替换离散序列，前向过程可以用一个随机微分方程来描述：

$$\mathrm{d}x = f(x, t)\mathrm{d}t + g(t)\mathrm{d}w, \tag{2-49}$$

其中 $f(x, t)$ 和 $g(t)$ 是预定义函数，$\mathrm{d}w$ 是布朗运动。根据朗格万动力学，前向过程的逆过程用一个逆时随机微分方程来描述：

$$\mathrm{d}x = \left[f(x, t) - g^2(t)\nabla_x \log p_t(x)\right]\mathrm{d}t + g(t)\mathrm{d}\bar{w}, \tag{2-50}$$

$\bar{w}$ 是逆布朗运动，$p_t(x)$ 是 x^t 的概率密度，$s(x) = \nabla_x \log p_t(x)$ 是 $p_t(x)$ 的分数函数，采用参数化分数模型 s_θ 来估计分数函数，该分数函数可以通过最小化以下目标函数来训练:

$$\mathcal{L}(\theta) = \mathbb{E}_{x^0,t,x^t}\left[\|s_\theta(x^t, t) - \nabla_{x^t} \log p(x^t|x^0)\|_2^2\right]. \tag{2-51}$$

扩散模型的引导采样考虑从条件分布 $p(x|y)$ 中抽样，其中 y 为生成样本的期望属性。无分类器采样依赖于一个额外的条件噪声模型 $\epsilon_\theta(x^t, y, t)$, 在实现时条件模型和无条件模型共享同一组参数，无条件模型通过将 y 设置为虚拟值 $\emptyset$ 来表示。[78] 使用的噪声学习目标是缩放后的 $p(x^t)$ 的分数函数，其中

中国知网 https://www.cnki.net

$\epsilon(x^t,t)=-\sigma^t\nabla_{x^t}\log p(x^t),\sigma^t=\sqrt{\beta_t}$，使用贝叶斯定理可得：

$$\nabla_{x^t}\log p(y|x^t)=-1/\sigma^t(\epsilon(x^t,y,t)-\epsilon(x^t,t)), \tag{2-52}$$

推导出引导噪声预测器为：$\bar{\epsilon}_\theta(x^t,y,t)=\epsilon_\theta(x^t,t)-w\sigma^t\nabla_{x^t}\log p(y|x^t)$，将分数函数替换为噪声模型预测，分类器引导采样中使用的噪声可表示为：

$$\hat{\epsilon}_w(x^t,y,t)=w\epsilon_\theta(x^t,y,t)+(1-w)\epsilon_\theta(x^t,t). \tag{2-53}$$

2.4.2 扩散策略

Diffusion-QL [24] 首先将扩散策略与 Q 学习框架结合起来，发现它可以完美地拟合由强多模态行为策略收集的数据集，而以前基于距离的策略正则化方法则失败。扩散策略的扩散目标就是给定当前状态的动作，假设噪声预测器为 $\epsilon_\theta(a_k,k,s)$，参数化为 θ，导出的动作均值为 $\mu_\theta(a|s)$。结合 $Q(s,a)$ 指导能够产生高回报的模型采样动作，Diffusion-QL 在扩散训练损失中包含一个加权 Q 最大化项：

$$\begin{aligned}\mathcal{L}(\theta)=&\mathbb{E}_{k,\epsilon,(s,a)\sim\mathcal{D}}[\|\epsilon-\epsilon_\theta(a^k,s,k)\|_2^2]\\&-\frac{\eta}{\mathbb{E}_{(s,a)\sim\mathcal{D}}[Q(s,a)]}\cdot\mathbb{E}_{s\sim\mathcal{D},a^0\sim\pi_\theta(\cdot|s)}[Q(s,a^0)],\end{aligned} \tag{2-54}$$

其中 η 为超参数，$\mathcal{D}$ 为离线数据，也可以通过优势加权回归构造策略：

$$\pi_\theta(a|s)\propto\mu_\theta(a|s)\exp(\alpha Q(s,a)). \tag{2-55}$$

2.4.3 扩散规划

使用扩散模型进可以同时生成多步规划序列，在数据有限的条件写能够解决自回归规划存在的复合误差问题。Janner 提出使用扩散模型生成轨迹片段 $\tau=(s_1,a_1,r_1,\ldots,s_H,a_H,r_H)$，记作 $x(\tau)=(e_1,e_2,\ldots,e_H)$,$H$ 是规划长度，e_t 表示从 (s_t,a_t,r_t) 中选择的元素，根据不同的选择规划模型有不同的作用。强化学习数据集通常包含不同质量的轨迹数据。为了使扩散规划器在评估过程中产生高回报的轨迹，引导采样技术被广泛采用。可以在分类器引导采样之后的采样阶段注入条件引导，也可以在无分类器采样之后的训练和采样阶段同时注入指导。

2.5 本章小结

本章首先介绍了智能体决策的核心概念，重点讨论了序列决策问题和马尔可夫决策过程。马尔可夫决策为建模智能体在不确定环境中决策提供了数学框架，包含状态空间、动作空间、转移概率和奖励函数等要素。接着，深入探讨了强化学习的基本原理，介绍了基于价值和基于策略的强化学习算法。其中，Q 学习算

中国知网 https://www.cnki.net

法通过学习状态-动作值函数来指导智能体选择最优动作，而 SAC 算法则采用最大熵强化学习方法，旨在平衡探索与利用，提升策略的鲁棒性和效率。最后，介绍了扩散模型的基本原理及其在智能体决策中的应用方法，扩散策略和扩散规划为智能体在复杂环境中进行高效决策提供了新的思路和方法。为后续展开基于扩散模型的高效智能体决策提供了坚实的理论基础。

中国知网 https://www.cnki.net

第三章 扩散模型作为优化器的高效规划

3.1 引言

离线强化学习是一种数据驱动的强化学习范式，专注于从先前收集的经验的静态数据集中学习[79]。在此设置中，行为策略与环境交互以收集一组经验，稍后可以使用这些经验来学习策略，而无需进一步交互。这种范例在由于数据收集昂贵或不可控而无法实现在线交互的情况下非常有价值。在有限的数据集中学习最优策略提出了重大挑战，策略需要有效地处理分布外数据，并具有推广到离线数据集[79]中没有遇到的新环境的能力。在过去的几年里，扩散模型[80–82]在条件生成建模领域取得了显著的成功[80,83]，展示了其强大的泛化能力。这激发了将扩散模型应用于决策研究的极大兴趣。先前的研究[57,84]涉及在离线数据集上训练生成轨迹模型，并利用它们生成基于条件的轨迹，从而指导决策过程。此外，一些方法[85]侧重于通过生成合成数据和利用奖励信号来改进扩散模型，以提高对已知和未知任务的性能和适应性。

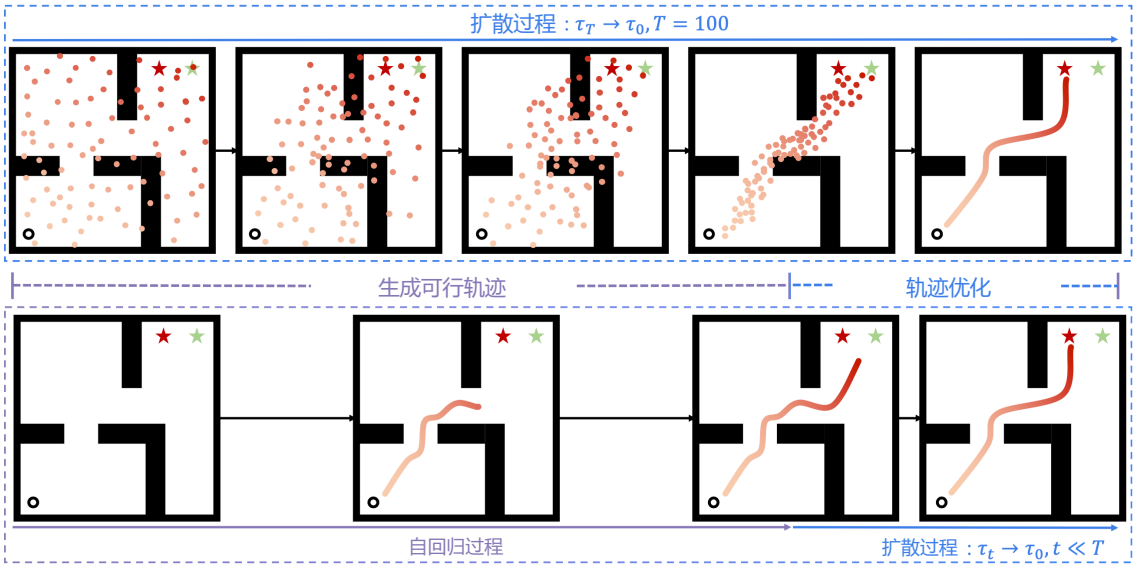


图 3-1 **示例与动机说明**：对迷宫任务中的轨迹规划过程进行可视化，其中智能体需要导航至高奖励的红色目标点。在第一行阐释了去噪过程可以分解为两个阶段，生成可行轨迹和轨迹优化。在第二行展示了如何利用自回归过程加速“生成可行轨迹”阶段的执行。

利用扩散模型进行轨迹规划无疑取得了显著的成功。然而，这些方法[57,84–86]面临着限制其实用性的共同挑战：扩散模型在推理过程中需要漫长的去噪过程，

中国知网 https://www.cnki.net

使得它们不适合快速变化的环境任务，例如自动驾驶。虽然在以前的工作中有解决这个问题的尝试[26,82]，但他们经常牺牲采样的质量。

在深入研究了去噪过程后，发现用于轨迹规划的扩散模型可以有效地分解为两个不同的步骤。首先，生成可行轨迹，智能体根据扩散模型不断优化轨迹。这种初始优化需要大量的计算时间，逐渐将轨迹细化为合理的配置。随后，在扩散过程的最后几个步骤中，模型明确地优化了朝向更高回报目标的轨迹，如图3-1所示。这一观察巩固了本章对扩散模型如何在轨迹生成中运作的理解，并激励本章设计一种更有效的方法来加速去噪过程。本章的目标是减少初始轨迹生成所需的时间，同时提供高质量的轨迹初始化，以保持甚至提高生成轨迹的质量。

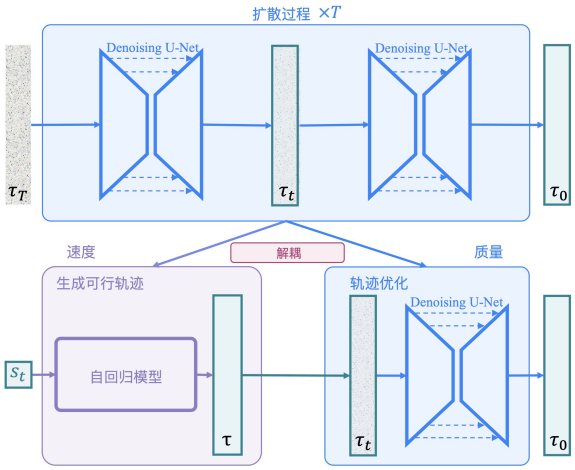


图 3-2 **轨迹生成过程的分解：**去噪过程被划分为两个步骤。为了加速推理过程，本章采用更高效的自回归模型来生成可行轨迹，同时仅保留一小部分去噪过程用于轨迹优化。这样的分解方式能够在提高效率的同时提升性能。

基于上述观察结果，本章提出了一种不牺牲采样质量而加速轨迹生成的方法，称为轨迹扩散（TrajectoryDiffuser），如图3-2所示。为了加快采样速度，本章选择采用一种更快更简单的方法来代替前面提到的过程的第一步。受 decision transformer[87] 的启发，本章利用具有上下文感知的 Transformer[88] 模型以自回归的方式生成高质量的初始轨迹，这与扩散模型相比具有更高的效率。为了保证轨迹质量，保留扩散模型作为轨迹优化器，利用最后十分之一的去噪步骤作为优化过程，并使用条件信息来引导和提高轨迹的质量。

3.2 轨迹规划问题描述

在序列决策领域，智能体决策问题表述为一个由元组定义的折扣马尔可夫决策过程 $\mathcal{M}=\langle\rho_0,\gamma,\mathcal{S},\mathcal{A},\mathcal{T},\mathcal{R}\rangle$, 其中 ρ_0 表示初始状态分布，$\mathcal{S}$ 和 $\mathcal{A}$ 是状态和动作空间，$\mathcal{T}:\mathcal{S}\times\mathcal{A}\to\mathcal{S}$ 是转移方程，$\mathcal{R}:\mathcal{S}\times\mathcal{A}\times\mathcal{S}\to\mathbb{R}$ 为任意状态变化的奖励函

中国知网 https://www.cnki.net

数，$\gamma \in [0,1)$ 是折扣因子。智能体根据随机策略行动 $\pi : \mathcal{S} \to \Delta_{\mathcal{A}}$，这会产生一系列状态-行动-奖励转换，记作轨迹 $\tau = (s_k, a_k, r_k)_{k \geq 0}$，概率为 $p_\pi(\tau)$。轨迹奖励函数定义为该轨迹单步折扣奖励总和:$R(\tau) = \sum_{k \geq 0} \gamma^k r_k$，强化学习的标准目标是找到一个策略 $\pi^* = \arg\max_\pi \mathbb{E}_{\tau \sim p_\pi}[R(\tau)]$ 最大化期望奖励。直接从环境交互中学习通常是效率低下的，离线强化学习提出从离线数据中进行学习，从而避免了采样效率低下的问题，这涉及到从由未知行为策略 μ 收集的固定转移数据集中找到收益最大化策略，使用序列建模解决离线强化学习可以看作是一个轨迹优化问题 [57]，目标是找到一个最佳的行动序列 $a^*_{0:T}$ 能够最大化（或最小化）目标函数 J，这是基于每个时间步奖励（花费）$r(s_t, a_t)$ 计算：

$$a^*_{0:T} = \arg\max_{a_{0:T}} \mathcal{J}(s_0, a_{0:T}) = \arg\max_{a_{0:T}} \sum_{t=0}^{T} r(s_t, a_t), \tag{3-1}$$

3.3 经验性观察分析

本章首先通过一个多臂老虎机（Multi-armed Bandit）案例对扩散模型决策过程进行分析。在多臂老虎机问题中，智能体有多个选项（摇臂），每个选项提供从未知概率分布中提取的奖励。智能体的目标是在一系列试验中使累积奖励最大化。这一任务的挑战在于选择最好的选项，平衡探索不同选项以了解其奖励分布的需求，并选择高奖励的已知手臂以最大化累计回报。假设存在一批离线数据分别由不同策略产生，如图3-3所示，最明显的特点是这些策略分布存在多样性，本章观察到扩散模型捕获了行为策略的所有四种密度模式。BC-MLE [89] 的策略被限制为单一模式，因此表现出很强的模式覆盖行为。它用一个标准差较大的高斯分布拟合四种密度模式，其高密度区域实际上是真实行为策略的低密度区域。CVAE [90] 模型显示出模式覆盖行为，即使它本身是一个具有足够表达能力的隐式模型：看到 CVAE 捕获了四种模式，但在它们之间分配了高密度以覆盖所有模式。注意，这里还观察到 CVAE 模型有时不能捕获具有不同随机种子的所有四种模式。在最大均值差异 (Maximum Mean Discrepancy，MMD) [91] 下优化的 Tanh-Gaussian 策略学习在边界线附近对齐密度，由于其策略表达能力有限，无法捕获真实分布。在这个简单的示例中观察到的行为克隆失败说明了在多模态行为策略的常见情况下，显示出扩散模型具有非常强的多模态建模能力。

随后本章对扩散策略扩散过程进行深入分析，本章发现扩散模型决策过程是由粗到细的过程其中可以发现，真正影响决策效果发生在去噪过程的少量步骤，也就是说，扩散采样过程在最后几个步骤中进行了优化（图3-4（a）），因此这可以用作优化器来改进其他方法的结果。本章使用扩散模型少量优化步骤对 BC-CVAE

中国知网 https://www.cnki.net

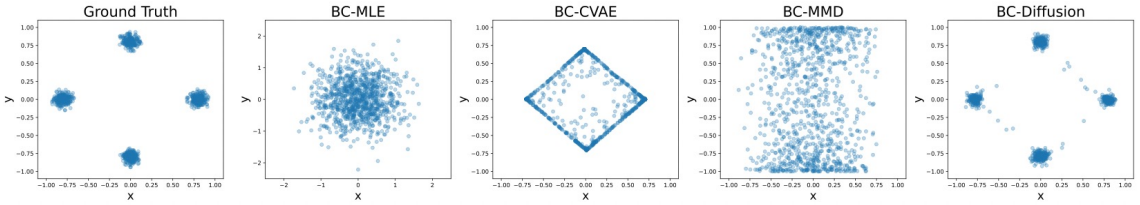


图 3-3 行为克隆方法的对比实验，包括 BC-Diffusion 与现有方法的对比。

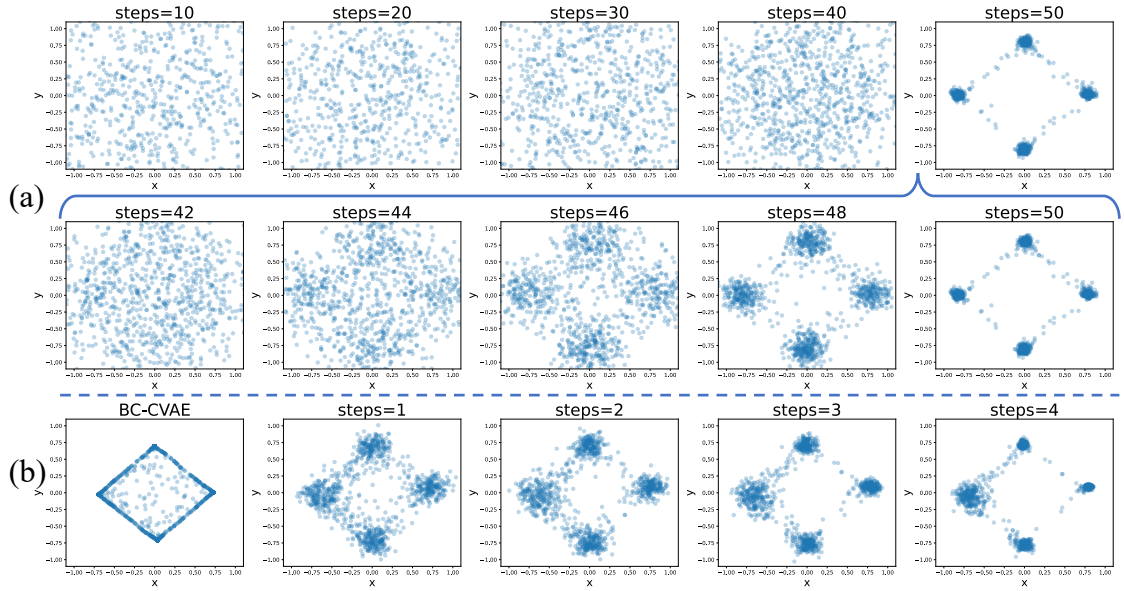


图 3-4（a）扩散过程的展开;（b）扩散模型作为优化器用于提升 BC-CVAE。

方法结果进行优化，实验显示，通过扩散模型少量的优化步骤，其能够捕获 CVAE 方法的数据分布，并对其进行优化，优化结果与直接使用扩散模型结果类似。

基于以上现象，本章考虑扩散模型这一性质能否用于轨迹优化，本章将从频率的角度探索如何实现性能优势。如图3-5所示，本章实验设置在一维轨迹规划任务，转移数据由不同频率轨迹组成，以表示数据的多模态性，本章首先使用基于 Transformer 的自回归方法进行轨迹规划，可以看出，使用自回归的方法生成的轨迹存在频率干扰。随后通过加入少量的扩散步骤对轨迹进行进行优化，优化后的轨迹在保持主频率不变的同时显著降低了干扰频率。可以得出结论，引入扩散模

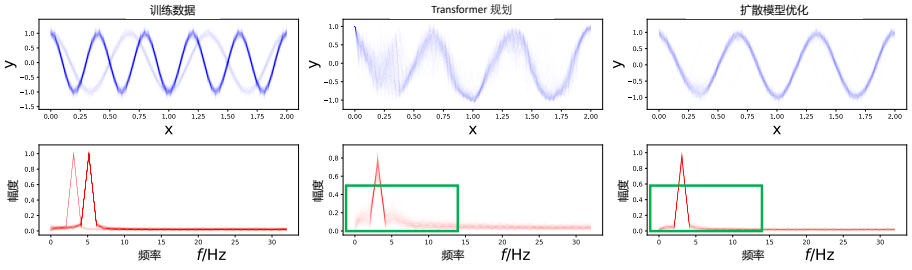


图 3-5 一维轨迹规划的示例实验。

中国知网 https://www.cnki.net

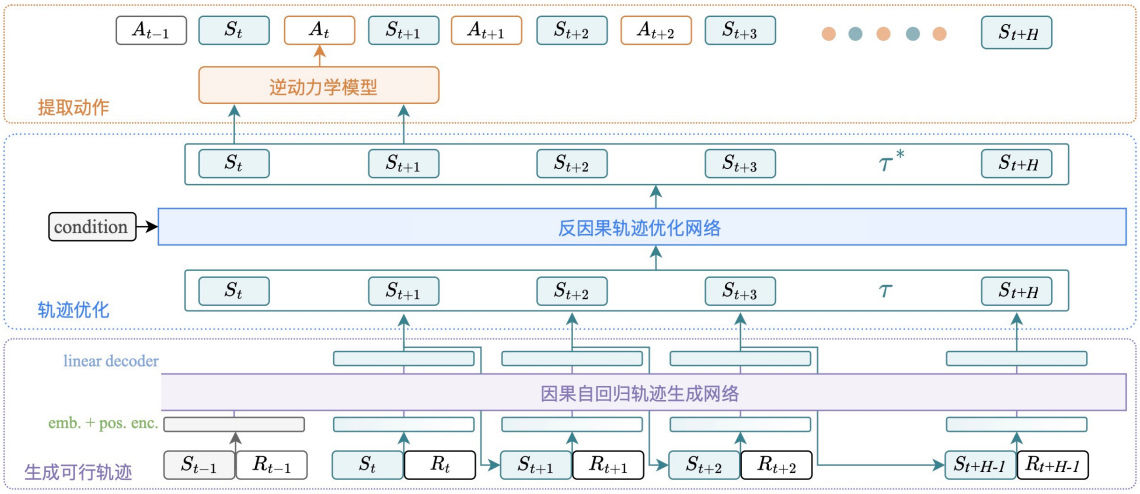


图 3-6 Trajectory Diffuser 采用自回归方式生成未来轨迹 τ，表示为 $\tau = (S_{t+1}, \ldots, S_{t+k})$，其生成过程综合考虑当前状态 S_t、历史状态 $(S_{t-h}, \ldots, S_{t-1})$ 以及回报值 $(\hat{R}_{t-h}, \ldots, \hat{R}_t)$。随后，利用扩散模型对轨迹进行优化 $\tau \rightarrow \tau^*$，并通过逆动力学提取并执行可使智能体到达下一时刻状态 S_{t+1} 的动作 A_t。

型作为优化器并不会改变轨迹的主要分布，而是有助于通过优化获得最优解。这两个实验表明，能够对扩散模型去噪过程进行解耦，使得能够在效率和性能上都保持优异，其中效率的提高来自于采样步骤的显著减少，而性能的提高则是通过引入自回归方法来进行良好的轨迹初始化并将其与扩散模型优化相结合。

3.4 基于扩散模型的高效规划

在本节中，主要介绍轨迹扩散器方法，它将扩散模型的轨迹规划过程分解为生成可行轨迹和轨迹优化两个步骤。这样的设计在兼顾效率和性能的同时，也取得了平衡，因此本章设计了一个由两部分组成的模型。在3.4.2中，本章采用基于 Transformer 的自回归模型来生成可行轨迹，从而提高了推理速度。在3.4.3中，本章保留了用于轨迹优化的扩散模型，以确保轨迹质量。本章的框架概述如图3-6所示。

3.4.1 轨迹表示

选择轨迹表示的主要标准是它是否能够促进 Transformer 模型进行有意义的模式学习，Decision Transformer [87] 为本章提供了一种具有学习能力的轨迹表示方法，以最大化未来期望奖励（returns-to-go）：$\hat{R}_t = \sum_{t'=t}^{T} r_{t'}$，在 Decision Transformer 中，最后 K 个时间步被输入 Decision Transformer，总共有 $3K$ 个令牌（每个模态一个：期望奖励、状态和动作），然而，在强化学习环境下，直接对行为建模会遇

中国知网 https://www.cnki.net

到一些实际问题。首先，在强化学习中，状态通常是连续的，而动作则更加多样化，而且往往是分散的。此外，动作上的序列，通常表示为关节扭矩，往往频率更高，更不平滑，使它们更难预测和建模[84]。因此，本章的轨迹规划模型排除了动作的建模，形成以下轨迹表示 τ，可以进行自回归训练和生成：

$$\tau = \begin{bmatrix} s_1 & s_2 & \dots & s_T \\ \hat{R}_1 & \hat{R}_2 & \dots & \hat{R}_T \end{bmatrix}. \tag{3-2}$$

逆动力学决策。仅仅从扩散模型中采样状态不足以建立一个全面的控制器。逆动力学模型 [92,93] 将两个连续状态作为输入，并输出可能导致从第一种状态过渡到第二种状态的动作。数学上可以表示为：给定两个连续状态 s_t 和 s_{t+1}，具有可学习参数 ϕ 的逆动力学模型 f_ϕ 预测导致从 s_t 到 s_{t+1} 变化的动作：

$$a_t = f_\phi(s_t, s_{t+1}). \tag{3-3}$$

3.4.2 基于 Transformer 的可行轨迹生成

由于轨迹具有自然的顺序模式，通常将符号上的联合概率分解为条件概率的乘积。本章训练了一个自回归 Transformer 模型以 $(s_{t-h:t}, \hat{R}_{t-h:t})$ 形式的令牌序列作为输入来预测下一个状态，包括状态和期望奖励 $(s_{t+1}, \hat{R}_{t+1})$，其中 h 代表历史令牌长度。该模型的训练通过最小化状态和奖励的真值序列的负对数似然:

$$\mathcal{L} = -\sum_{t=1}^{T} \log p(s_{t+1}, \hat{R}_{t+1} | s_{t-h:t}, \hat{R}_{t-h:t}), \tag{3-4}$$

其中 $p(s_{t+1}, \hat{R}_{t+1} | s_{t-h:t}, \hat{R}_{t-h:t})$ 是给定前一状态和奖励的下一状态和期望奖励的条件概率分布。从历史状态 $s_{t-h:t}$ 和期望奖励 $\hat{R}_{t-h:t}$ 开始使用经过训练的 Transformer 模型生成轨迹，从模型生成的分布中重复采样 l 次状态和期望奖励：

$$(s_{t+1}, \hat{R}_{t+1}) \sim p(s_{t+1}, \hat{R}_{t+1} | s_{t-h:t}, \hat{R}_{t-h:t}). \tag{3-5}$$

体系结构方面，本章采用最后 H 个时间步，这些时间步包含两种信息: 状态和到达目标的回报值。与决策转换器方法不同，此方法并不将状态和回报值作为独立的令牌处理，而是将二者视为一个统一的实体，隐式地将回报信息与状态信息结合在一起。

为了获得高质量的令牌嵌入，本章设计了一套专门的训练流程：针对每种模态分别训练独立的线性层，将原始输入转换为所需维度的嵌入表示。接着，本章采用层归一化技术对这些嵌入进行处理，以确保数据分布稳定、特征尺度合理。经过这一系列预处理后，处理好的令牌会被送入 GPT 模型 [94]，该模型通过自回归

中国知网 https://www.cnki.net

建模机制来预测未来的状态。通过这种设计，实现了状态与回报信息的高效融合，进一步提高了模型在复杂任务中预测未来状态的准确性和鲁棒性。

训练过程中，使用一个离线轨迹数据集 $\mathcal{D}$，并从中采样长度为 K 的序列小批量数据。为了防止信息泄露，采用了上三角掩码矩阵，将当前令牌之后的所有信息屏蔽掉。与输入令牌 $[s_t, R_t]$ 对应的预测头被训练用于预测下一个令牌，该令牌由两个部分构成：下一个时间步的状态 s_{t+1} 以及到达目标的回报 R_{t+1}。本章分别使用两个独立的线性层来预测每个时间步的下一个状态和回报，并对各时间步的损失取平均。得益于对状态与回报联合约束的设计，在同时预测状态和回报时，模型表现出显著的性能提升。

3.4.3 基于扩散模型的轨迹优化

符号约定：为了区分本文中涉及的两种时间步，本章采用了特定的符号约定。具体来说，本章使用上标 $k \in \{1, \ldots, K\}$ 来表示与扩散过程相关的时间步，而使用下标 $t \in \{1, \ldots, T\}$ 来表示与强化学习轨迹相关的时间步。这种表示方法不仅使得讨论更为清晰，同时也便于在描述算法细节时准确地区分两类时间步的作用。

扩散模型具有高效建模多模态数据的优势 [58]。为了保留这一优良特性，本章训练扩散模型以学习所有扩散时间步的正向过程。然而，由于数据集包含了一系列次优轨迹，模型可能会受到这些次优行为的影响。为此，此方法在扩散模型中引入了条件引导技术。具体而言，此方法采用了无分类器引导 [78] 来直接训练条件扩散模型。与分类器引导 [11] 相比，该方法避免了动态规划的需求，从而简化了整个训练流程。

算法 3-1 基于扩散模型的轨迹优化

输入： 次优轨迹 τ, 条件 $y(\tau)$, 引导因子 ω, 优化步骤 K, 噪声模型 ϵ_θ 和逆动力学模型 f_ϕ.

输出： 优化轨迹 τ^*.

for $k = K \ldots 1$ **do**

  $x_k(\tau)[0] \leftarrow \tau[0]$;

  $\hat{\epsilon} \leftarrow (1-\omega)\epsilon_\theta(x_k(\tau), k) + \omega\epsilon_\theta(x_k(\tau), y(\tau), k)$;

  $(\mu_{k-1}, \sum_{k-1}) \leftarrow \text{Denoise}(x_k(\tau), \hat{\epsilon})$;

  $x_{k-1} \sim \mathcal{N}(\mu_{k-1}, \sum_{k-1})$;

end

$\tau^* \leftarrow x_0(\tau)$;

中国知网 https://www.cnki.net

在标准的强化学习任务中，目标是设计一个能够最大化奖励的策略。因此，利用从离线数据集中提取的期望奖励指标作为条件变量，记作 $y(\tau)$。值得注意的是，本章的方法与 Diffuser [57] 和 Decision Diffuser [84] 存在差异：本章采用当前时间步 t 之后的累积奖励作为期望奖励，其定义为 $R(\tau)=\sum_{t'\geq t}\gamma^{t'-t}r_{t'}$, 其中 γ 为折扣因子，$r_{t'}$ 表示在时间步 t' 获得的奖励。

这样的设计能够使模型充分利用从当前时刻开始的未来奖励信息，更好地指导策略学习。即使整体奖励较低的轨迹中，仍然可能蕴含局部更优的部分，这样可以确保扩散模型不局限于仅仅利用最优轨迹的信息。形式上，采用监督学习的方式来训练条件生成模型。给定数据集 D 中的一条轨迹 $\tau\in D$，其表示为 $\tau=(s_t,s_{t+1},\ldots,s_T)$, 并以从当前时间步开始计算的期望奖励 $\hat{R}_t$ 作为标签。对于每条轨迹 τ 及其对应的条件 $y(\tau)$，首先从标准正态分布 $\mathcal{N}(0,I)$ 中采样噪声 ϵ，同时从集合 $\{1,\ldots,K\}$ 中均匀采样一个时间步 k。接着，构造状态的带噪数组 $x_k(\tau)$，并利用由噪声模型 θ 参数化的逆扩散过程 p_θ 来预测噪声：

$$\hat{\epsilon}_\theta=\epsilon_\theta(x_k(\tau),y(\tau),k), \tag{3-6}$$

模型的训练采用以下损失函数：

$$\mathcal{L}(\theta)=\mathbb{E}_{k,\tau\in\mathcal{D},\eta\sim\text{Bern}(p)}\left[\left|\epsilon-\epsilon_\theta\left(x_k(\tau),\hat{y}(\tau,\eta),k\right)\right|^2\right], \tag{3-7}$$

其中，$\hat{y}(\tau,\eta)=(1-\eta)\,y(\tau)+\eta\,\emptyset$, $\text{Bern}(p)$ 表示一个以概率 p 取值为 1 的伯努利分布，其定义为:

$$\text{Bern}(p)=\begin{cases}1, & \text{with probability } p,\\ 0, & \text{with probability } 1-p.\end{cases} \tag{3-8}$$

在采样过程中，通过条件扩散模型的反向过程来优化轨迹，其定义为

$$\pi_\theta(x_0(\tau)|y(\tau))=p_\theta(x_{0:k}(\tau)|y(\tau)), \tag{3-9}$$

反向去噪的最终轨迹 $x_0(\tau)$ 表示经过优化后的轨迹。一般来说，$p_\theta(x_{k-1}|x_k,y(\tau))$ 可以建模为高斯分布，其形式为：

$$p_\theta(x_{k-1}|x_k,y(\tau))=\mathcal{N}(x_{k-1};\mu_\theta(x_k,y(\tau),k),\Sigma_\theta(x_k,y(\tau),k)). \tag{3-10}$$

参考 [58] 将 $p_\theta(x_{k-1}(\tau)|x_k(\tau))$ 参数化为噪声预测模型，其中协方差矩阵固定为 $\Sigma_\theta(x_k(\tau),y(\tau),k)=\beta_k I$，而均值则构造为：

$$\mu_\theta(x_k(\tau),y(\tau),k)=\frac{1}{\sqrt{\alpha_k}}\left(x_k(\tau)-\frac{\beta_k}{\sqrt{1-\bar{\alpha}_k}}\hat{\epsilon}_\theta(x_k(\tau),y(\tau),k)\right), \tag{3-11}$$

中国知网 https://www.cnki.net

在公式 3-11中，$\hat{\epsilon}_\theta(x_k(\tau), y(\tau), k)$ 表示扰动噪声，其计算公式为：

$$\begin{aligned}\hat{\epsilon}_\theta(x_k(\tau), y(\tau), k)) =& \epsilon_\theta\left(x_k(\tau), \emptyset, k\right) + \\ & \omega\left(\epsilon_\theta\left(x_k(\tau), y(\tau), k\right) - \epsilon_\theta\left(x_k(\tau), \emptyset, k\right)\right),\end{aligned} \tag{3-12}$$

其中，ω 是一个标量，应用于项 $\epsilon_\theta(x_k(\tau), y(\tau), k) - \epsilon_\theta(x_k(\tau), \emptyset, k)$，旨在增强并提取数据集中表现出 $y(\tau)$ 的轨迹中最有价值的部分。在这些组件的基础上，轨迹优化变得类似于从扩散模型中进行采样。首先，获得一个轨迹 τ，表示为 $x_k(\tau)$，其中 $k \ll K$。接下来，使用条件于 $y(\tau)$ 的扩散过程，从时间步 k 开始采样状态。最后，利用逆动力学模型确定应采取的动作，以到达预测的状态。该过程在常规的前视控制循环中迭代进行，如算法3-1所述。

3.5 实验结果分析与消融实验

3.5.1 实验设置

本章使用 D4RL 数据集 [95] 作为实验基准，该数据集为强化学习提供了标准测试数据。本章选择了 D4RL 中的三个不同任务领域进行实验，如图3-7所示，包括 Gym-locomotion、Adroit 和 Kitchen。本章的研究重点在于回答以下问题：

- 与现有的基于朴素扩散模型的方法相比，Trajectory Diffuser 能带来多大的推理速度提升？
- 采用自回归模型生成可行轨迹是否会影响模型的性能？
- 此方法是否适用于其他回归模型？
- 轨迹优化过程是否必要？
- 如何在效率和性能之间找到平衡点？

首先介绍模型架构和超参数细节，Transformer 模型由 4 层 Transformer 块组成，每层包含 4 个注意力头，嵌入维度设置为 256，激活函数采用修正线性单元（Rectified Linear Unit，ReLU）。噪声模型 θ 采用了一个时间 U-Net 结构，包含 6 个重复的残差块。每个块由两个时间卷积层组成，每个卷积层后跟一个组归一化层（Group Normalization，GN），最后是一个 Mish 非线性激活函数。

时间步和条件嵌入都是 64 维的向量，通过各自的 2 层多层感知机生成，每层包含 128 个隐藏单元和 Mish 激活函数，然后将它们连接在一起，添加到每个块中第一个时间卷积的激活值上。逆向动力学 f_ϕ 由一个包含 256 个隐藏单元和 ReLU 激活函数的 2 层 MLP 表示。在训练过程中，使用 Adam 优化器，批量大小为 32，训练步数为 $2,000,000$。扩散步骤设置为 100，折扣因子为 0.95。条件信息的概率 p 设置为 0.5。

中国知网 https://www.cnki.net

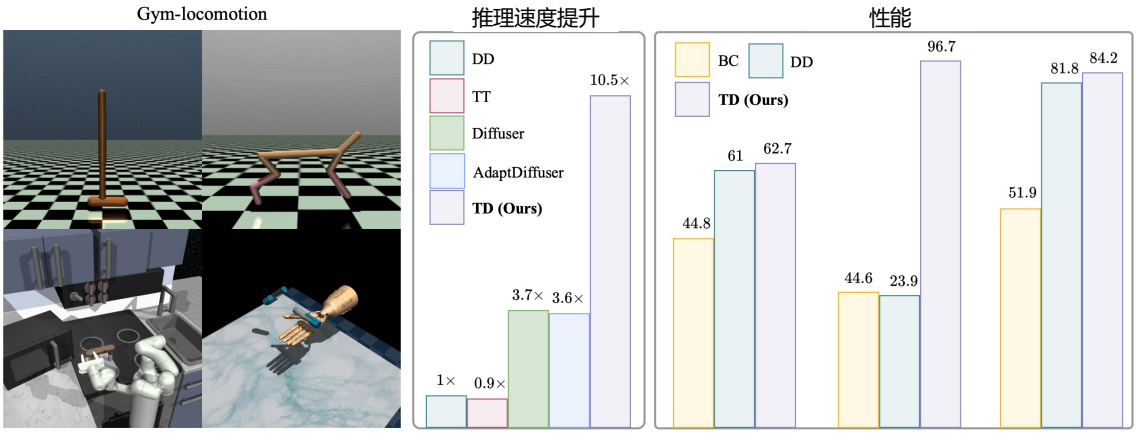


图 3-7 任务与结果概览：(a) 任务：Gym 运动控制、Franka Kitchen 以及 Adroit-Pen; (b) 与传统的基础扩散模型相比，Trajectory Diffuser 在推理速度上取得了显著提升; (c) 性能对比。采用归一化平均回报作为性能评估指标。

表 3-1 所有任务的超参数设置

数据集	环境	学习率	horizon H	improve step k	scalar w	returns-to-go $\hat{R}$
Med-Expert	HalfCheetah	2×10^{-4}	8	5	1.1	11000
Medium	HalfCheetah	2×10^{-4}	8	5	1.1	5300
Med-Replay	HalfCheetah	2×10^{-4}	8	5	1.1	5300
Med-Expert	Hopper	2×10^{-4}	16	5	1.2	3700
Medium	Hopper	2×10^{-4}	16	5	1.2	3100
Med-Replay	Hopper	2×10^{-4}	16	5	1.2	3100
Med-Expert	Walker2d	2×10^{-4}	32	5	1.2	5100
Medium	Walker2d	2×10^{-4}	32	5	1.2	4200
Med-Replay	Walker2d	2×10^{-4}	32	5	1.2	4200
human	pen	1×10^{-4}	16	2	1.3	6000
expert	pen	1×10^{-4}	16	2	1.3	6000
cloned	pen	1×10^{-4}	16	2	1.3	6000
Partial	Kitchen	1×10^{-4}	32	5	1.2	500
Mixed	Kitchen	1×10^{-4}	32	5	1.2	400

3.5.2 推理效率评估

在控制领域中，模型的推理时间是影响其实用性的重要因素之一。尽管基于扩散的序列模型在性能上取得了显著提升，但其推理过程需要执行扩散模型的逆过程，这通常涉及多步迭代计算，从而显著增加推理时间，降低了模型在实际应用中的效率。因此，在本节中，重点评估 Trajectory Diffuser 的推理效率，并分析

中国知网 https://www.cnki.net

其相较于其他方法在推理时间上的改进程度。为确保实验的公平性和可比性，选取了四种具有代表性的轨迹规划模型进行对比分析，包括 Diffuser [57]、Trajectory Transformer (TT) [96]、Decision Diffuser (DD) [84] 和 AdaptDiffuser [85]。

在实验设置方面，严格遵循原始论文中的超参数设定，使各模型的规划长度（Planning Horizon）和扩散步数（Diffusion Step）保持一致，以排除因参数选择不同而导致的影响。实验环境选用了 Gym-locomotion 任务作为测试基准，通过与环境交互采样 1000 组状态转移数据，并计算推理过程中每步推理所需时间（Seconds-Per-Step，SPS），以此衡量模型的推理效率。通过这种方式，可以系统地分析 Trajectory Diffuser 在推理速度上的提升幅度，以及在保证高效推理的同时是否仍能维持良好的轨迹生成质量。

表 3-2 D4RL MuJoCo 环境中的测试时间。所有数据均在单张 NVIDIA A100 GPU 上进行测试。表中的单位为秒（s）。

Dataset	Med-Expert			**Average SPS**
Environment	HalfCheetah	Hopper	Walker2d	
TT	8.43 s	2.68 s	5.17 s	5.43 s
Diffuser	1.17 s	1.26 s	1.28 s	1.24 s
DD	4.26 s	4.47 s	5.11 s	4.61 s
AdaptDiffuser	1.21 s	1.29 s	1.30 s	1.27 s
TD	**0.27** s	**0.42** s	**0.62** s	**0.44** s

实验结果显示，表3-2中详细记录了现有方法与本章提出方法在生成动作时的推理时间对比情况。本章方法以 Decision Diffuser 作为基准模型，通过图3-7的直观展示，清晰地说明了各项技术改进对性能提升的贡献。具体来说，与基于 Transformer 架构的 Trajectory Transformer（TT）模型相比，TT 模型依赖于束搜索来在多个候选轨迹中选取最优解，这一方法虽然有助于提高轨迹选择的准确性，但其计算复杂度较高，导致推理时间显著增加。

本章方法则采用了扩散模型进行轨迹优化，通过迭代地调整和改善生成的轨迹，有效地减少了反向扩散过程中的计算负担，使推理速度提升超过 10 倍。此外，与其他传统扩散模型，包括 DD、Diffuser 和 AdaptDiffuser，相比，本章方法同样展示了明显的优势，在推理速度上实现了 3 至 10 倍的加速。总体而言，这些实验结果不仅验证了本章提出的技术在优化推理效率方面的有效性，同时也为实际控制系统中的实时决策提供了有力的理论与实践支持。

中国知网 https://www.cnki.net

3.5.3 性能评估

本节实验旨在探究 Trajectory Diffuser 是否能在显著提高推理速度的同时保持甚至改善模型性能，或者是否会带来性能上的下降。为此，在 Gym-locomotion、Adroit 和 Kitchen 三个任务上对 Trajectory Diffuser 进行了系统评估，并将其性能与现有的序列建模方法进行了详细比较。其中，Gym-locomotion 的实验结果详见表3-3，而 Adroit 和 Kitchen 任务的实验数据则汇总在表 3-5和表 3-6中。此外，为了获得更全面的性能评估，还将本方法与基于时序差分学习方法以及其他模型基方法进行了对比分析，如表 3-4。

在基线选择上，不仅将 Trajectory Diffuser 与传统的行为克隆（Behavior Cloning，BC）方法进行了对比，还与其他序列建模方法（如 Decision Transformer [87] 和 Trajectory Transformer [96]）进行了比较；同时，还涵盖了扩散模型系列方法，包括 Diffuser [57]、Decision Diffusion [84] 以及 AdaptDiffuser [85]。为进一步全面评估本方法在离线强化学习领域的表现，还对比了多种现有的离线强化学习方法，如 CQL [4]、BRAC [97]、IQL [98]、Diffusion-QL [58] 和 MoReL [99]，以期全面展示 Trajectory Diffuser 在各类任务和不同评价体系下的优势与局限。

本章独立训练了一个基于 Transformer 架构的序列模型，结合了状态扩散过程和逆向动力学模型。训练使用了公开可用的 D4RL 数据集。模型训练了 $200,000$ 次迭代（Adroit 和 Kitchen 任务各训练了 $100,000$ 次），批量大小为 32。实验结果显示，如表 3-4和表 3-5所示，在多种离线强化学习任务中，本章的方法在序列建模模型中达到了最先进的性能，特别是在更具挑战性的 D4RL Adroit 和 Kitchen 任务中，这些任务需要强大的策略正则化来克服外推误差 [100]，并在长时间内进行复

表 3-3 Trajectory Diffuser 与多种序列建模算法在 D4RL 运动基准测试中的性能对比 [95]。Trajectory Diffuser 的结果对应于 20 个随机种子的均值和标准误差。用粗体标注了每个任务中接近最大值 5% 以内的得分 ($\geq 0.95 \cdot \max$)。

Dataset	Environment	BC	DT	TT	Diffuser	DD	AdaptDiffuser	TD
Med-Expert	HalfCheetah	55.2	86.8 ±1.3	**95.0** ±0.2	88.9 ±0.3	**90.6** ±1.3	89.6 ±0.8	**92.2** ±0.8
Med-Expert	Hopper	52.5	107.6 ±1.8	110.0 ±2.7	103.3 ±1.3	**111.8** ±1.8	**111.6** ±2.0	**113.6** ±1.5
Med-Expert	Walker2d	**107.5**	**108.1** ±0.2	101.9 ±6.8	**106.9** ±0.2	**108.8** ±1.7	**108.2** ±0.8	**109.0** ±0.6
Medium	HalfCheetah	42.6	42.6 ±0.1	**46.9** ±0.4	42.8 ±0.3	**49.1** ±1.0	44.2 ±0.6	44.2 ±1.1
Medium	Hopper	52.9	67.6 ±1.0	61.1 ±3.6	74.3 ±1.4	79.3 ±3.6	**96.6** ±2.7	**97.1** ±1.5
Medium	Walker2d	75.3	74.0 ±1.4	79.0 ±2.8	79.6 ±0.5	**82.5** ±1.4	**84.4** ±2.6	**83.5** ±2.2
Med-Replay	HalfCheetah	36.6	36.6 ±0.8	**41.9** ±2.5	37.3 ±0.5	39.3 ±4.1	38.3 ±0.9	**41.3** ±0.8
Med-Replay	Hopper	18.1	82.7 ±7.0	91.5 ±3.6	93.6 ±0.4	**100.0** ±0.7	92.2 ±1.5	94.3 ±3.2
Med-Replay	Walker2d	26.0	66.6 ±3.0	**82.6** ±6.9	70.6 ±1.6	75.0 ±4.3	**84.7** ±3.1	**82.5** ±2.6
Average Returns		51.9	74.7	78.9	77.5	81.8	83.4	**84.2**
Runtime Per Action		-	-	5.43 s	1.24 s	4.61 s	1.27 s	**0.44** s

中国知网 https://www.cnki.net

表 3-4 不同离线强化学习算法与 Trajectory Diffuser 的性能对比。结果按照方法类别进行分类，并对每个类别中表现最优的方法进行了标注。

Dataset	Med-Expert			Medium			Med-Replay			Average	Categorization
Environment	HalfCheetah	Hopper	Walker2d	HalfCheetah	Hopper	Walker2d	HalfCheetah	Hopper	Walker2d		
BC	55.2	52.5	107.5	42.6	52.9	75.3	36.6	18.1	26	51.9	Behavior Cloning
MOReL	53.3	108.7	95.6	42.1	95.4	77.8	40.2	93.6	49.8	72.9	Model-based
BCQ	57.3	87.4	109.1	47.2	40.3	74.2	44.8	76.1	81.6	68.7	Temporal Difference
BRAC	41.9	0.9	81.6	46.3	31.3	81.1	47.7	0.6	0.9	36.9	
CQL	91.6	105.4	108.8	44	58.5	72.5	45.5	95.0	77.2	77.6	
IQL	86.7	91.5	109.6	47.4	66.3	78.3	44.2	94.7	73.9	77.0	
DQL	96.8	111.1	110.1	51.1	90.5	87.0	47.8	101.3	95.5	**88.0**	
DT	86.8	107.6	108.1	42.6	67.6	74.0	36.6	82.7	66.6	74.7	Sequence Modeling
TT	95.0	110.0	101.9	46.9	61.1	79.0	41.9	91.5	82.6	78.9	
Diffuser	88.9	103.3	106.9	42.8	74.3	79.6	37.3	93.6	70.6	77.5	
DD	90.6	111.8	108.8	49.1	79.3	82.5	39.3	100.0	75.0	81.8	
AdaptDiffuser	89.6	111.6	108.2	44.2	96.6	84.4	38.3	92.2	84.7	83.4	
TD	92.2 ±0.8	113.6 ±1.5	109.3 ±0.8	44.3 ±1.1	97.1 ±1.5	83.5 ±2.2	41.3 ±0.8	94.3 ±3.2	82.5 ±2.6	**84.2**	

表 3-5 Kitchen 和灵巧手操作性能对比。

Dataset	**Env**	**BC**	**CQL**	**DD**	**TD**
Human	Pen	25.8	35.2	7.5 ±13.6	**87.9** ±63.1
Expert	Pen	69.7	-	9.0 ±29.8	**116.1** ±54.6
Cloned	Pen	38.3	27.2	55.1 ±66.2	**86.1** ±57.9
Average		44.6	-	23.9	**96.7**
Partial	Kitchen	38.0	49.8	57.0 ±2.8	**71.2** ±11.0
Mixed	Kitchen	51.5	51.0	**65.0** ±2.5	54.2 ±9.3
Average		44.8	50.4	61.0	**62.7**

杂的信用分配。在这些任务中，本章的方法优于 Decision Diffusion，并表现出显著的优势。

在更具挑战性的任务上评估了本章方法的性能，如表 3-6所示，包括 Maze2D 和 Adroit。Maze2D 任务测试策略在长时间跨度内的感知能力，并要求其根据特定条件做出决策。而在 Adroit 任务中，策略需要处理分布外数据，并展现正则化能力，以防观测结果偏离期望区域。在该实验中，在稀疏奖励环境下评估了本章的方法以及多个基线方法的性能。稀疏奖励环境给智能体带来了发现成功轨迹的挑战，尤其是在离线强化学习任务中，智能体无法通过直接交互探索新的经验。实验结果表明，由于稀疏奖励结构的影响，本章的方法能够有效应对需要长时间跨度规划的任务。由于 Adroit 数据集主要由人类行为驱动收集，因此离线数据所覆盖的状态-动作空间通常较为有限。所以，施加稳健的策略正则化至关重要，以确保智能体始终保持在期望的区域内。

中国知网 https://www.cnki.net

表 3-6 Maze2D 和 Adroit 任务性能对比。

Dataset	Environment	BC	AWR	BCQ	CQL	TD
umaze	maze2d	3.8	1.0	12.9	5.7	**118.9**
medium	maze2d	30.0	7.6	8.3	5.0	**56.1**
large	maze2d	5.0	23.7	6.2	12.5	**39.9**
Average		12.9	10.8	9.1	7.7	**71.6**
human	relocate	0.0	0.0	-0.1	**0.2**	0.0
expert	relocate	101.3	91.5	41.6	95.0	**111.1**
cloned	relocate	-0.1	-0.2	0.3	-0.1	**0.2**
human	hammar	1.5	4.4	1.2	0.5	**13.4**
expert	hammar	125.6	39.0	107.2	86.7	**127.6**
cloned	hammar	0.8	0.4	0.4	2.1	**17.8**
human	door	0.5	0.4	0.0	9.9	**12.2**
expert	door	34.9	102.9	99.0	101.5	**105.3**
cloned	door	-0.1	0.0	0.0	0.4	**10.6**
Average		29.4	26.1	27.7	33.3	**44.2**

3.5.4 消融实验

在本研究中，由于本章引入了自回归模型来生成可行的轨迹，本节研究不同自回归模型的影响，如表3-7所示。传统的自回归模型，如 GRU [101]、LSTM [102] 和 Transformer [88]，广泛应用于此领域。此方法能够整合多种自回归模型，建立了框架的强大耦合能力。此外，本节通过实验证明，利用 Transformer 模型进行轨迹初

表 3-7 不同自回归模型消融。

Env	**Transformer**	**GRU**	**LSTM**	**Transformer (-)**	**GRU (-)**	**LSTM (-)**
HalfCheetah	**92.2±0.8**	80.8±1.2	83.1±1.7	**86.2 ±1.2**	75.8±7.1	77.6±9.9
Hopper	**113.6±1.5**	111.9±0.9	109.2±1.0	**103.4 ±4.7**	101.5±11.3	90.1±23.4
Walker2d	**109.0±0.6**	104.8±8.4	107.8±1.4	103.3 ±6.6	99.4±5.2	**105.9±2.7**

始化，在本章的框架中能够获得更优的结果。表 3-8的结果显示，借助擅长建模历史信息的 Transformer 生成的轨迹质量更高。本章方法能够扩展到不同的自回归模型，并且采用扩散模型进行轨迹优化，显著提升了轨迹质量。为进一步证明利用扩

表 3-8 轨迹优化消融，(-) 表示不使用轨迹优化。

Dataset	Med-Expert			Medium			Med-Replay			**Average**
Env	HalfCheetah	Hopper	Walker2d	HalfCheetah	Hopper	Walker2d	HalfCheetah	Hopper	Walker2d	
TD (-)	86.2 ±1.2	103.4 ±4.7	103.3 ±6.6	40.0 ±8.3	**98.8** ±1.5	79.0 ±10.0	38.5 ±2.5	79.1 ±9.1	75.5 ±3.5	79.1
TD	**92.2** ±0.8	**113.6** ±1.5	**109.3** ±0.8	**44.2** ±1.1	97.1 ±1.5	**83.5** ±2.2	**41.3** ±0.8	**94.3** ±3.2	**82.5** ±2.6	**84.2**

散模型对轨迹进行增强能够显著提升模型性能。具体而言，本节设计了一系列消融实验来评估不同优化步骤对最终性能的影响，结果清楚地表明，优化过程主要集中在扩散模型最后十分之一的阶段。在此阶段，模型通过对轨迹进行精细调整，

中国知网 https://www.cnki.net

显著降低了噪声的干扰并提高了生成轨迹的质量。实验结果显示，如表3-9所示，采用扩散模型后，模型不仅在总体性能上有所提升，而且在输出结果的稳定性方面也表现出较低的方差，但随着扩散步骤的延长，性能却出现了下降趋势。这表明，在过多的优化步骤下，对应于 k 步的噪声注入可能会破坏初期已较好初始化的轨迹，导致模型的表现逐渐接近于纯扩散模型的水平。通过合理控制扩散步数，本章方法能够在保持轨迹优化效果的同时，确保模型性能的稳定性和优越性。

表 3-9 扩散优化步骤 k 消融。

Dataset	Med-Expert			**Average**
Env	HalfCheetah	Hopper	Walker2d	
2 steps	**92.2** ±0.8	110.2 ±2.7	108.7 ±1.6	103.7
5 steps	92.1 ±1.0	**113.6** ±1.5	**109.0** ±0.8	**105.0**
10 steps	88.4 ±1.4	111.7 ±1.9	108.9 ±2.1	103.0
20 steps	83.9 ±6.4	103.1 ±2.6	108.3 ±0.3	98.4
50 steps	83.3 ±8.5	100.2 ±2.5	108.4 ±0.3	97.3
100 steps	82.3 ±19.5	106.2 ±1.9	108.3 ±0.4	98.9

超参数调整范围消融。通过消融实验，以验证两个重要超参数——标量 w 和时间跨度 h 的调整范围。实验结果如表 3-10 和表 3-11所示。显然，不同的 w 和 h 值确实会对模型性能产生一定影响。然而，通过实验数据观察到，这些影响所导致的性能变化并不特别显著或明显。

表 3-10 引导缩放 w 消融实验。

Env	$w = 1.0$	$w = 1.1$	$w = 1.2$	$w = 1.3$	$w = 1.4$	$w = 1.5$	$w = 2.0$	$w = 3.0$
Hopper	109.1 ±7.4	112.3 ±2.5	**113.2** ±0.6	112.4 ±0.9	108.5 ±2.7	106.7 ±8.6	109.9 ±7.0	112.2 ±1.2
walker2d	108.3 ±2.7	108.4 ±0.3	**108.9** ±0.2	107.8 ±0.6	107.9 ±0.4	108.2 ±0.3	108.0 ±0.4	108.1 ±0.5
halfcheetah	91.1 ±0.9	**92.1** ±1.5	90.7 ±1.4	90.7 ±1.2	89.7 ±0.7	91.2 ±0.5	87.0 ±7.2	90.0 ±2.6

条件引导消融。评估了目标条件是否能够引导策略的表现。本节通过改变回报累积值（RTG）参数进行消融实验（见表 3-12）。RTG 参数表示模型的最优性能，通过乘以不同的折扣因子来模拟策略需要达到的不同目标。实验结果表明，不同的条件对策略的引导效果不同，这表明本章的方法可以推广到其他基于条件的任务。

表 3-11 长度 H 消融实验。

Env	$H = 8$	$H = 16$	$H = 24$	$H = 32$
Hopper	105.4 ±16.1	**113.6** ±2.3	112.2 ±0.9	112.3 ±0.7
Walker2d	108.7 ±0.4	108.3 ±0.2	108.7 ±0.3	**109.1** ±0.4
Halfcheetah	**92.3** ±0.7	90.9 ±1.5	90.0 ±4.2	82.2 ±20

表 3-12 期望奖励消融实验。

Env	1 * RTG	0.75 * RTG	0.5 * RTG	0.25 * RTG	0 * RTG
Hopper	113.6 ±2.3	103.0 ±20.7	84.9 ±10.3	48.2 ±16.1	13.2 ±0.6
Walker2d	108.7 ±0.4	75.6 ±3.5	76.4 ±2.0	30.3 ±25.4	27.9 ±27.4
Halfcheetah	91.8 ±1.4	90.8 ±0.9	42.7 ±1.0	42.8 ±1.2	42.1 ±0.8

中国知网 https://www.cnki.net

3.6 本章小结

本章提出了一种基于分解思想的扩散模型推理流程，核心目的在于提升基于扩散模型的轨迹规划面临的推理效率低下问题，该流程主要分为两个阶段：首先利用高效的自回归模型生成可行轨迹，然后借助扩散模型对这些轨迹进行细致优化。本章通过自回归模型（如 GRU、LSTM 或 Transformer 等）快速生成初步轨迹，再利用扩散模型强大的优化能力对轨迹进行精细调整，从而在大幅提升推理速度的同时，确保生成结果的高质量。实验结果显示，相较于传统扩散模型，本章的方法在推理速度上实现了显著加速，同时在有效性上也明显优于现有的序列建模方法。由于本方法在效率和精度两方面均取得了显著改善，该方法不仅为在线决策任务提供了一个实用的框架，也为将扩散模型应用于离线强化学习问题提供了一个优秀的设计范例，从而为复杂决策场景下的轨迹规划和策略优化开辟了新的研究方向。本章方法存在一些潜在局限性：它通过专注于离线序列决策来规避探索问题，但可以结合在线微调，利用状态序列模型的熵来实现探索能力。该模型目前仅适用于基于状态的环境，但通过在潜在空间中执行扩散操作，可以将其扩展到基于图像的环境，从而增强其能力。包括 Trajectory Diffuser 在内的扩散模型在数据有限的情况下容易发生过拟合，这可能会限制其在某些应用中的有效性。尽管本章提出了使用扩散模型作为轨迹调控的优化器，但并未对扩散模型的结构进行重新设计。

中国知网 https://www.cnki.net

第四章 扩散策略引导的高效策略学习

4.1 引言

本章提出使用扩散策略引导的多层次强化学习算法，以指导高效在线策略学习，这一方法能够缓解基于高斯表示策略面临的决策多模态挑战，并且显著减少了扩散策略的调用频率，最大化扩散策略单步决策带来的潜在收益。在具有挑战性的基于目标的强化学习任务对本章的方法进行验证，实验结果显示本章的方法从新的角度发挥扩散模型的作用，能够指导在线策略高效学习。

基于稀疏奖励的目标达成策略展现出巨大潜力，其核心优势在于能够激励智能体实现多样化目标，进而获得具有较强泛化能力的策略，同时避免了为每个任务精心设计奖励函数的繁琐过程[103,104]。这种方法使得系统在面对未知环境时，不再依赖于预先设定的精细奖励机制，而是通过奖励信号的稀疏反馈来自主探索和学习。然而，正因为环境缺乏足够的指示性线索，策略学习面临着极大的挑战。在线学习方法通常依赖于对所有可能出现的新状态进行广泛探索，以便覆盖那些潜在的高奖励区域[105–108]。这种策略在任务时长较长的场景中容易导致探索过程效率低下，因为智能体可能需要经历大量无关或低奖励的状态才能最终找到有效的策略路径[109]。为此，研究者们也提出了另一类方法：通过对外部专家数据进行行为克隆，或利用大量离线数据进行预训练，借助离线强化学习生成初始策略，再以此作为在线微调的起点[4,98,110,111]。这种方法在一定程度上缩短了智能体的探索时间，提高了策略学习的起始质量。然而，这些依赖全标注数据的方法也存在明显的局限性。一方面，获取全面且高质量的标注数据往往成本高昂且在实际应用中难以实现；另一方面，在在线微调阶段[112]，由于数据分布可能与离线数据存在偏差，模型容易遭遇分布转移（Distribution Shift）问题，这可能导致预训练策略在实际环境中的表现不尽如人意[79]。因此，在设计和优化基于稀疏奖励的目标达成策略时，如何平衡探索效率与数据标注成本，以及如何缓解分布转移问题，成为亟待解决的关键课题。

本章从全新的视角出发，探讨了长时域目标达成策略的学习问题，即通过利用非专家、无动作标记的观测数据来实现策略学习。尽管这类数据缺乏逐步动作信息，且其轨迹质量并不总能得到保证，但其中蕴含了丰富的关键信息：不仅包括那些可能引导智能体达到最终目标的状态，还包括各状态之间潜在的联系。通过提取和利用这些信息，能够更有效地指导智能体的探索和状态转移过程，从而在学习效率上显著优于传统的纯在线学习方法。此外，由于此类数据易于获取，不

中国知网 https://www.cnki.net

需要昂贵的标注工作，其来源也更为广泛，这使得本章的方法在实际应用中更具可行性和经济性。

然而，这一设定也带来了不少挑战。首先，由于缺乏动作标签，直接学习低层次、逐步执行的策略变得十分困难；其次，若仅以最终目标作为奖励信号，可能会在长时域任务中导致指引信号逐渐衰减，从而影响学习效果。为了解决这些问题，本章提出了基于先验观测数据的高效目标达成策略学习方法（Efficient Goal-Reaching policy learning with Prior Observations, EGR-PO）。该方法采用层次化的策略设计，通过从无动作标记的观测数据中提取合理的子目标和探索指引，来辅助在线策略的微调和改进。总的来说，EGR-PO 方法不仅降低了对精细标注数据的依赖，拓宽了数据采集的途径，还为解决长时域任务中策略学习的困难提供了一种全新的思路。未来，期待在更复杂的环境中进一步验证该方法的鲁棒性和泛化能力，同时探索结合其他辅助信号，如环境上下文或领域知识，以提升整体系统性能的可能性。

本章的方法通过学习基于扩散模型的高层次策略来生成合理的子目标，这些子目标作为到达最终目标的中间点。此外，本章还学习了一个状态-目标价值函数，用于计算探索奖励，从而鼓励有效地实现子目标，最终达到最终目标。在预训练阶段，状态-目标价值函数 [113] 协助高层次策略从非专家观察数据中生成最优子目标 [104]，作为更接近的目标，解决了状态-目标价值函数在处理长时间跨度的最终目标时遇到的引导衰减和预测不准确性问题。此外，本章的方法无缝地集成到离策略演员-评论家框架中 [114]。高层次策略生成子目标，作为低层次策略的引导，而状态-目标价值函数为每个过渡计算有意义的探索奖励，促进有效的探索。

总的来说，本章的方法通过利用非专家、无动作的数据，减少了对昂贵数据标注的需求，使得策略学习更具实用性。本章引入了 EGR-PO，这是一种层次化策略学习方法，包括子目标生成和状态-目标价值函数学习。这些组件协同工作，促进了有效和高效的探索。通过广泛的实证评估，在具有挑战性的机器人导航和操作任务上，展示了本章的方法优于现有的目标导向强化学习方法。消融研究进一步突显了本章方法的优点，包括更清晰的引导和对轨迹损坏的鲁棒性。本章的研究为机器人在复杂任务中的自主学习和执行提供了新的思路，特别是在缺乏专家示范的情况下，利用非专家数据进行有效的策略学习。

4.2 问题描述

在传统的强化学习中，智能体只需依据奖励函数完成单一、特定的任务；而目标条件强化学习（GCRL）则面向更加通用和复杂的情境。目标条件强化学习中

中国知网 https://www.cnki.net

的智能体不仅需要同时掌握多项任务，还需具备将那些长期且难以直接实现的目标拆解成一系列易于达成的中间子目标的能力，并通过一个统一的策略逐步实现这些目标。换句话说，智能体可以选择直接解决多个任务，或先将复杂目标细化为若干子目标，再逐一攻克，甚至两种策略兼而有之。例如，在机器人导航或物体操控任务中，目标往往定义为需要到达的具体位置，但实际情况中，这一过程可能涉及路径规划、障碍物避让以及环境适应等多个环节。目标条件强化学习通过对目标的层次化和模块化设计，使得智能体在面对复杂、多变的环境时，能够更灵活地调整策略，提高整体执行效率和成功率。

为了解决这一挑战，目标条件强化学习的理论框架在传统的马尔可夫决策过程）基础上，引入了额外的元组 $\langle \mathcal{G}, p_g, \phi \rangle$ [115]，从而构建出目标增强型马尔可夫决策过程。其中，$\mathcal{G}$ 表示任务目标的空间，涵盖了描述任务所需达成状态的各种目标；p_g 则定义了环境中期望实现的目标分布，反映了任务在不同情境下的要求；而映射函数 $\phi : \mathcal{S} \to \mathcal{G}$ 则用于将状态空间 $\mathcal{S}$ 中的每个状态映射到一个具体的目标。在许多实际应用中，状态空间 $\mathcal{S}$ 与目标空间 $\mathcal{G}$ 可以相同，此时 ϕ 就退化为一个恒等映射函数，即状态本身就代表目标。在此框架下，奖励函数 $r : \mathcal{S} \times \mathcal{A} \times \mathcal{G} \to \mathbb{R}$ 根据目标进行定义，其设计旨在引导智能体根据所处状态和预设目标选择合适的动作。因而，目标条件强化学习的核心目标在于通过构建一个目标条件策略 $\pi : \mathcal{S} \times \mathcal{G} \times \mathcal{A} \to [0, 1]$ 来实现目标状态的达成，该策略的优化目标是使在目标分布 p_g 下累计回报的期望最大化。这种方法不仅能够同时应对多任务场景，还可以将复杂且长期的目标分解为一系列更易实现的子目标，从而通过统一的策略逐步完成整个任务。具体而言，在诸如机器人导航或物体操控等应用中，目标可能涉及到特定位置、姿态或者路径规划等多种维度的信息。通过引入目标分布和映射函数，智能体不仅能够明确任务目标，还能根据当前状态智能地调整策略，以应对环境中的不确定性和动态变化。

4.3 基于先验观测的高效策略学习

本章方法概述如图4-1所示。在4.3.1中，模型学习从观察中提取指导信息，包括训练状态-目标值函数 $V(s, g)$，以促进信息丰富的探索，以及学习高层策略 $\pi_h(g_h|s, g)$，该高层策略使用扩散策略为基础，以应对状态之间转移的复杂分布问题，从而学习生成合理的子目标。在4.3.2中，描述了这些学习到的部件如何协同工作，增强在线低层策略 $\pi_l(a_t|s_t, g_h)$ 的学习效果。具体而言，$V(s, g)$ 通过评估状态和目标的价值，指导智能体在探索过程中关注有价值的区域，从而提高学习效率。高层策略 $\pi_h(g_h|s, g)$ 则根据当前状态和目标生成子目标 g_h，引导智能体在复

中国知网 https://www.cnki.net

杂任务中分解问题，逐步逼近最终目标。低层策略 $\pi_l(a_t|s_t, g_h)$ 在接收到子目标 g_h 后，专注于实现该子目标的具体动作，从而在子任务层面上优化行为。通过这种层次化的协同机制，本章的方法能够有效地处理复杂任务，实现高效的学习和决策。算法4-0展示了本章方法的伪代码。

算法 4-1 基于先验观测的高效策略学习

输入：观测数据集 $\mathcal{D}_{\mathcal{O}}$
while 未收敛 **do**
  采样批次 $(s, s', g) \sim \mathcal{D}_{\mathcal{O}}$;
  使用公式 4-2更新状态目标价值网络 $V(s, g)$;
  采样批次 $(s, g_{sub}, g) \sim \mathcal{D}_{\mathcal{O}}$;
  使用公式 4-8更新高阶扩散策略 $\pi_{\phi}^{h}(g_{sub}|s, g)$;
end
for 每环境步骤 **do**
  基于 $g_{sub}^{h} \sim \pi^{h}(g_{sub}^{h}|s, g)$ 执行动作 $a \sim \pi^{l}(a|s, g_{sub}^{h})$;
  计算探索奖励 r_g，保存转移至缓冲回放 $\mathcal{D}$;
  # Actor-Critic 更新
  通过后验重标签采样小批量转移数据 $\mathcal{B} = \{(s, a, s', r, r_g, g_{sub})\} \sim \mathcal{D}$;
  更新 Q 网络和 Q_g 网络;
  更新在线策略 π^{l};
end

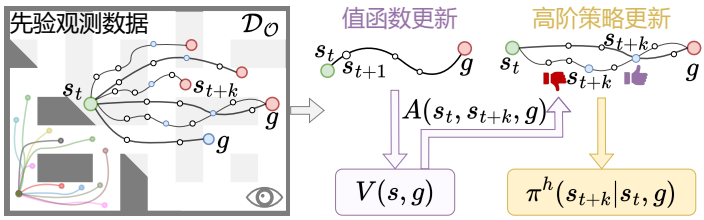
4.3.1 子目标生成扩散策略学习

首先学习用于激励探索的状态-目标价值函数 [4]，直接从先验数据中学习价值函数通常面临价值函数高估问题，这是由于数据分布无法完全覆盖所有行为空间和观测空间，从而导致了错误的估计。Kostrikov 等人 [98] 提出了隐式 Q 学习（Implicit Q-Learning，IQL）方法，旨在通过将贝尔曼最优方程中的最大操作转换为期望回归，避免查询分布外的动作。具体而言，IQL 训练一个动作值函数 $Q_{\theta_Q}(s, a)$ 和一个状态值函数 $V_{\theta_V}(s)$，损失函数为：

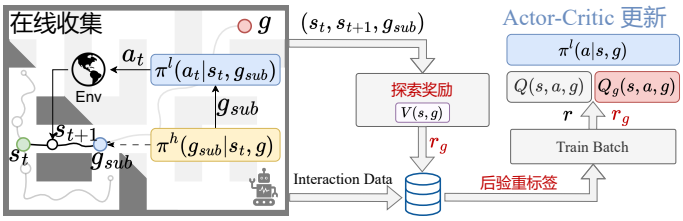
$$\begin{aligned} \mathcal{L}_V(\theta_V) &= \mathbb{E}_{(s,a)\sim\mathcal{D}}[L_2^{\tau}(Q_{\bar{\theta}_Q}(s, a) - V_{\theta_V}(s))], \\ \mathcal{L}_Q(\theta_Q) &= \mathbb{E}_{(s,a,s')\sim\mathcal{D}}[(r_{\text{task}}(s, a) + \gamma V_{\theta_V}(s') - Q_{\theta_Q}(s, a))^2], \end{aligned} \tag{4-1}$$

其中 $r_{task}(s, a)$ 表示任务价值函数，$\bar{\theta}_Q$ 为目标 Q 网络参数 [6]，L_2^{τ} 是带参数

中国知网 https://www.cnki.net



(a) 从观测数据中学习引导信息



(b) 基于引导信息加速在线策略学习

图 4-1 EGR-PO 方法概览：（a）本章的方法由两个关键学习组件构成: 一个用于提供信息性探索的状态-目标价值函数，以及一个用于生成合理子目标的高层策略；（b）将这两个组件集成到 Actor-Critic 方法中，其中学习到的状态-目标价值函数提供探索奖励，以促进有意义的探索，而合理的子目标则提供清晰的引导信号。

$\tau \in [0.5, 1)$ 的期望损失函数：$L_2^\tau(x) = |\tau - \mathbb{1}(x < 0)|x^2$，直观地，期望回归可以解释为一种不对称的平方损失函数，对正值的惩罚大于对负值的惩罚。因此，当 τ 趋近于 1 时，$V_{\theta_V}(s)$ 接近于 $\max_a Q_{\bar{\theta}_Q}(s,a)$，这使得可以使用值函数来估计时序差分目标 $r_{\text{task}}(s,a) + \gamma \max_{a'} Q_{\bar{\theta}_Q}(s',a')$ 为 $r_{\text{task}}(s,a) + \gamma V_{\theta_V}(s')$，而无需对动作 a' 进行采样，通过这种方式，IQL 能够在不直接评估分布外动作的情况下，学习到有效的策略。

原始的 IQL 方法要求离线数据中同时包含奖励和动作标签，以便通过公式4-1来训练值函数。然而，在现实场景中，离线数据可能并不包含任务信息或动作标签，例如在任务无关的示范或视频中。基于此，本章关注于离线目标条件强化学习的设置，这种设置不依赖任务奖励，同时为本章提供了一种将仅包含状态的轨迹融入值函数学习的方法。本章采用以下 IQL 的无动作变体 [116,117] 来学习离线目标条件的值函数 $V_{\theta_V}(s,g)$：

$$\mathcal{L}_V(\theta_V) = \mathbb{E}_{(s,s')\sim\mathcal{D}_S, g\sim p(g|\tau)}[L_2^\tau(r(s,g) + \gamma V_{\bar{\theta}_V}(s',g) - V_{\theta_V}(s,g))]. \tag{4-2}$$

随着距离的增加，学习到的状态-目标值函数的可靠性降低。仅仅依赖于它来处理长时间跨度的任务是无效的，甚至可能有害。为了解决这个问题，本章学习了高级策略，用于生成附近且合理的子目标，这些子目标提高了预测值的准确性，

中国知网 https://www.cnki.net

并提供了更清晰的指导信号。本章采用扩散概率模型来执行行为克隆，以生成子目标。先前的研究已证明，扩散概率模型在策略回归中具有鲁棒性。本章方法通过条件扩散模型的反向过程来表示扩散策略，如下所示：

$$\pi_\phi^h(g_{sub}^h|s,g) = p_\phi(g_{sub}^{0:N}|s,g) = \mathcal{N}(g_{sub}^N;\mathbf{0},I)\prod_{i=1}^{N} p_\phi(g_{sub}^{i-1} \mid g_{sub}^i, s, g), \tag{4-3}$$

本章方法遵循去噪扩散概率模型的方法[14,58,118]，通过优化以下目标函数来训练 ϵ 条件模型：

$$J_{BC}(\phi) = \mathbb{E}_{i\sim\mathcal{U},\epsilon\sim\mathcal{N}(\mathbf{0},I),(s,g_{sub},g)\sim\mathcal{D}_\mathcal{O}}\left[||\epsilon - \epsilon_\phi(\sqrt{\bar{\alpha}_i}g_{sub} + \sqrt{1-\bar{\alpha}_i}\epsilon, s, g, i)||^2\right], \tag{4-4}$$

其中，ϵ 是服从高斯分布的噪声，U 是离散集合 $\{1,...,N\}$ 上的均匀分布。参考 HIQL[113] 本章方法从同一轨迹中的未来状态或数据集中的随机状态中采样目标 g。类似地，本章方法从同一轨迹中的未来 k 步状态 s_k 中采样子目标 g_{sub}。

由于先前的数据并非来自专家，通过行为克隆生成的子目标可能并非最优。通过利用公式4-2学习到的状态-目标值函数，本章方法可以使用以下优势加权回归算法[119]的变体来改进策略：

$$J_I(\phi) = \mathbb{E}_{(s,g_{sub},g)\sim\mathcal{D}_\mathcal{O}}[\exp(\beta\cdot\tilde{A}(s,g_{sub},g))\cdot\log\pi_\phi^h(g_{sub} \mid s,g)], \tag{4-5}$$

其中，优势函数 $\tilde{A}(s,g_{sub},g)$ 近似为 $V_\theta(g_{sub},g) - V_\theta(s,g)$，这有助于提取具有更高优势的子目标，同时避免偏离数据分布。按照[119]的方法，优势估计可表示为：

$$\tilde{A}(s_t, s_{t+\tilde{k}}, g) = \gamma^{\tilde{k}}V_\theta(s_{t+\tilde{k}},g) + \sum_{t'=t}^{t+\tilde{k}-1} r(s_{t'},g) - V_\theta(s_t,g), \tag{4-6}$$

其中，本章方法使用符号 $\tilde{k}$ 和 $\tilde{s}_{t+k}$ 来处理前一段讨论的特殊情况（即，当从未来状态中采样 g 时，$\tilde{k} = \min(k, t_g - t)$；当从随机状态中采样 g 时，$\tilde{k} = \min(k, T-t)$；同时定义 $\tilde{s}_{t+k} = s_{\min(t+k,T)}$。

这里，$s_{t'} \neq g$ 以及 $s_t \neq \tilde{s}_{t+k}$ 始终成立，除了这些特殊情况。因此，在奖励项在大多数情况下是常数（在奖励函数当 $s=g$ 时 $r(s,g)=0$，否则 $r(s,g)=-1$），同样第三项关于策略输入的部分也是常数。因此，在实际应用中忽略这些项以简化计算，而这种简化进一步使得第一项中的折扣因子可以合并到温度超参数 β 中。

本章方法使用以下简化的优势估计公式[112,120,121]，该公式在实验中被证明可以实现几乎相同的性能：

$$\tilde{A}(s, g_{\text{sub}}, g) = V_\theta(g_{\text{sub}}, g) - V_\theta(s,g), \tag{4-7}$$

中国知网 https://www.cnki.net

其中，本章方法使用 g_{sub} 来表示在各种条件下的 $s_{t+\tilde{k}}$ 。最终的目标函数是行为克隆和策略改进的线性组合：

$$\pi_\phi^h = \arg\min_\phi J(\phi) = \arg\min_\phi (J_{BC}(\phi) - \alpha \cdot J_I(\phi)), \tag{4-8}$$

其中 α 是用于控制子目标多样性的超参数。

在具体实现中，本章方法的扩散策略通过条件扩散模型的逆过程表示为方程4-4。然而，逆向采样需要迭代计算 ε_ϕ 网络 N 次，这可能成为运行时间的瓶颈。为了将 N 限制在一个相对较小的值，本章方法设定 $\beta_{\min} = 0.1$ 和 $\beta_{\max} = 10.0$，并参考 [122] 定义：

$$\beta = 1 - \alpha = 1 - e^{-\beta_{\min}(1) - 0.5(\beta_{\max} - \beta_{\min})\frac{2i-1}{N^2}}, \tag{4-9}$$

其中，该噪声调度是在 [24] 提出的方差保持随机微分方程（SDE）下获得的。

本章方法分别使用方程4-2和4-4训练状态-目标值函数和高层策略，并采用不同的目标采样分布。对于状态-目标值函数，本章方法按照 [116] 的方法，以 0.3、0.5 和 0.2 的概率分别从随机状态、未来状态或当前状态中采样目标。未来状态的分布使用 Geom$(1-\gamma)$，而随机状态则从离线数据集的均匀分布中采样。对于高层策略，本章方法主要遵循 [123] 的采样策略。首先，从数据集 $\mathcal{D}_O$ 中采样一个轨迹 $(s_0, s_1, ..., s_t, ..., s_T)$ 并选取轨迹中的某个状态 s_t 。然后，本章方法采取以下两种方式之一来采样目标子目标 g_{sub} : 从轨迹中的未来状态 $s_{t_g}(t_g > t)$ 进行均匀采样，并将目标子目标设定为 $s_{\min(t+k, t_g)}$；从数据集中均匀采样 g，并将目标子目标设定为 $s_{\min(t+k,T)}$。

4.3.2 子目标引导的高效在线学习

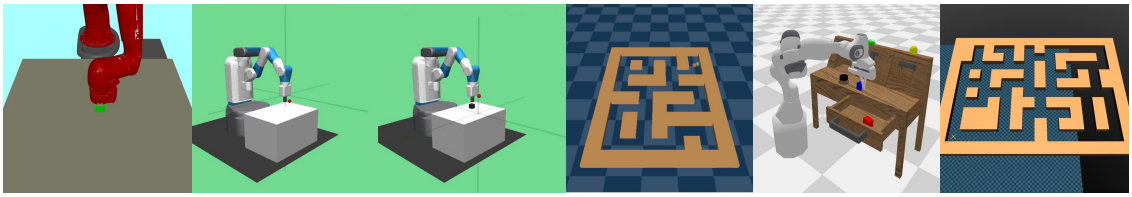
策略学习的目标是根据当前状态输出合适的动作，因此本章方法使用子目标引导在线策略学习，上一节学习到的高阶策略和状态-目标价值函数可以自然的整合到离线 Actor-Critic 的范式中 [47,70,89,114,124]。Actor-Critic 框架同时学习动作价值值函数 Q [48] 和策略网络 π_{θ_l} [49]。动作价值网络 Q 则采用时序差分 [1] 进行训练:

$$\mathcal{L}_Q = \mathbb{E}_{(s,a,s',g,r)\sim\mathcal{D}, a'\sim\pi_\theta^l(s',g)} \left[\left\| r + \gamma \cdot \bar{Q}(s', a', g) - Q(s, a, g) \right\|^2 \right], \tag{4-10}$$

其中 $\bar{Q}$ 为目标网络，r 表示环境奖励，为鼓励在线策略进行正确的探索行为，本章方法引入了额外的探索奖励 r_g 来鼓励有价值的探索，探索奖励函数的设计基于所学习的状态-目标值函数：

$$R_g(s, s', g) = \tanh(\eta \cdot (V_\theta(s', g) - V_\theta(s, g))), \tag{4-11}$$

中国知网 https://www.cnki.net



(a) SawyerReach (b) Reach (c) PickAndPlace (d) Maze2d (e) CALVIN (f) AntMaze

图 4-2 实验环境: 具有稀疏奖励的机器人导航和操作任务。

在此，η 是一个缩放因子。在强化学习中，探索奖励用于鼓励智能体探索环境。传统方法通常将探索奖励直接添加到环境奖励中[106,125–128]。然而，考虑到未来状态的影响，本章方法引入了一个额外的引导 Q 函数 $Q_g(s,a,g)$，与之前的方法不同，本章方法不直接将 r_g 添加到环境奖励 r，因为探索奖励已考虑到未来，因此，本章方法直接通过监督学习的方式让 $Q_g(s,a,g)$ 拟合探索奖励：

$$\mathcal{L}_{Q_g} = \mathbb{E}_{(s,a,r_g,g^h_{sub})\sim\mathcal{D}}\left[\left\|Q_g(s,a,g^h_{sub}) - r_g\right\|^2\right], \tag{4-12}$$

在线低级策略参数更新通过同时最大化 Q 函数和引导 Q_g 函数：

$$\pi^l_\theta = \arg\max_\theta \mathbb{E}_{(s,g^h_{sub})\sim\mathcal{D},a\sim\pi^l_\theta(\cdot|s,g^h_{sub})}[Q(s,a,g^h_{sub}) + \beta\cdot Q_g(s,a,g^h_{sub})]. \tag{4-13}$$

4.4 实验结果分析与消融实验

本节的实验深入探讨了利用非专家观察数据来加速目标达成任务中的在线学习，特别是聚焦于解决与长时间跨度目标相关的挑战。评估了本章方法在具有稀疏奖励的挑战性任务中的效果，如图4-2所示。这些任务包括操作任务，如 SawyerReach [129] 和 FetchReach [130]，以及长时间跨度任务，如 FetchPickAndPlace [130]、CALVIN [131]，以及两项难度各异的导航任务 [95]。本节的实验旨在为以下问题提供具体的答案：（1）与其他在线方法相比，本章的方法是否更高效，能否与从完全标注数据中学习的离线-在线方法相竞争？（2）方法的高效性是否源自信息丰富的探索？（3）合理的子目标是否使得本章方法中的引导更加清晰？（4）本章的方法是否对不足、低质量和高度多样化的观察数据具有鲁棒性？

4.4.1 实验仿真环境

SawyerReach 环境源自 Multi-World，其任务要求 Sawyer 机器人通过末端执行器到达目标位置。该环境的观察空间和目标空间均为三维笛卡尔坐标，用于表示位置；状态到目标的映射是一个简单的恒等函数，即 $\phi(s) = s$，动作为三维空间，用以确定下一步末端执行器的位置。

OpenAI Gym 中的 FetchReach 和 FetchPickAndPlace 环境均采用一台具有 7 自

中国知网 https://www.cnki.net

由度的机械臂，配备双指夹具。在 FetchReach 中，目标是触及指定的位置；而 FetchPickAndPlace 则要求先拾取一个盒子，再将其移动到预定位置。此环境的状态空间由 10 个维度构成，表示夹具的位置和速度；动作空间为四维，用于描述夹具的运动及开合状态。目标则以目标位置的三维向量形式给出。

Maze2D 是一个目标条件规划任务，其任务是引导一个具有 2 自由度的球，该球可以在 x 和 y 方向上受到力的驱动。给定起始位置和目标位置后，策略需找到一条可行的路径，使球从起点出发避开所有障碍物直达目标。

AntMaze 属于一类具有挑战性的长时域导航任务，其目标是将一个具有 8 自由度的蚂蚁机器人从初始位置引导到指定的目标位置。在四种不同难度设置下评估其表现，包括原始 D4RL 基准中的 “umaze”、“medium” 及 “large” 迷宫数据集。虽然大型迷宫已对长时域规划构成重大挑战，但还引入了 [132] 提出的更大迷宫 “ultra”，其尺寸为原 D4RL 数据集中最大迷宫的两倍。每个数据集包含 999 条长度为 1000 的轨迹，其中蚂蚁智能体从任意起始位置导航至另一目标位置（该目标不一定与评估目标一致）。在测试阶段，为了为策略指定目标 g，将前两个状态维度（对应 x-y 坐标）设为环境给定的目标位置，其余本体感受状态维度则取自数据集中第一条观察记录。在评估时，智能体每到达一次目标即可获得 1 分奖励。

CALVIN 是另一种长时域操作任务环境，包含四个目标子任务。采用了 [133] 提供的离线数据集，该数据集基于 [131] 的远程操控示范，共包含 1204 条长度为 499 的轨迹。在每条轨迹中，智能体以任意顺序完成 34 个子任务中的若干个，从而使数据集具有高度的任务无关性 [133]。在测试阶段，为了为策略指定目标 g，将本体感受状态维度设置为数据集中第一条观察记录，而其他维度则设为目标配置；在评估时，智能体每完成一个子任务，即可获得 1 分奖励。

模型参数设置：本节在表4-1中列出了实验中使用的超参数，大部分网络架构和超参数遵循 [113,116] 的设置。对于所有 MLP 层，本章方法使用层归一化（Layer Normalization） [134]。此外，本章方法对状态-目标值函数的目标编码器采用归一化的 10 维输出特征，以便高层策略能够更容易地预测这些目标。

对于子目标步长 k，本节在不同任务中使用不同的值：AntMaze-Ultra 任务中 $k = 50$，FetchReach、FetchPickAndPlace 和 SawyerReach 任务中 $k = 15$，其他任务中 $k = 25$。高层和低层策略的目标采样方式如下：从同一轨迹中的未来状态采样的概率为 0.7，从数据集中的随机状态采样的概率为 0.3。在训练过程中，本节每 20 个 episode 进行一次性能评估，并使用 50 次 rollouts 来评估学习到的策略表现。

中国知网 https://www.cnki.net

表 4-1 超参数设置

超参数	值
Batch Size	1024
High-level Policy MLP Dimensions	(256, 256)
State-Goal Value MLP Dimensions	(512,512,512)
Representation MLP Dimensions	(512,512,512)
Nonlinearity	GELU [135]
Optimizer	Adam [136]
Learning Rate	0.0003
Target Network Smoothing Coefficient	0.005
AWR Temperature Parameter	1.0
IQL Expectile τ	0.7
Discount Factor γ	0.99
Diversity of Subgoals α	0.5

4.4.2 与现有方法性能对比

基准方法。将本章的方法与多种在线学习方法进行了比较，包括演员-评论员方法 Online [70]、基于探索的方法如 RND [106] 和 ExPLORe [108]，以及数据高效方法如 HER [137]、GCSL [138] 和 RIS [139]。此外，本节还与离线-在线方法进行了比较，涵盖了朴素的在线微调方法 [79]，例如 AWAC [112] 和 IQL [98]，悲观方法 CQL [4] 和 Cal-QL [111]，策略约束方法 SPOT [140]，以及策略扩展方法 PEX [110]。为了确保公平的策略更新，本节将更新数据比率（UTD） [141] 设置为 1。学习曲线结果如图4-3和图4-4所示。

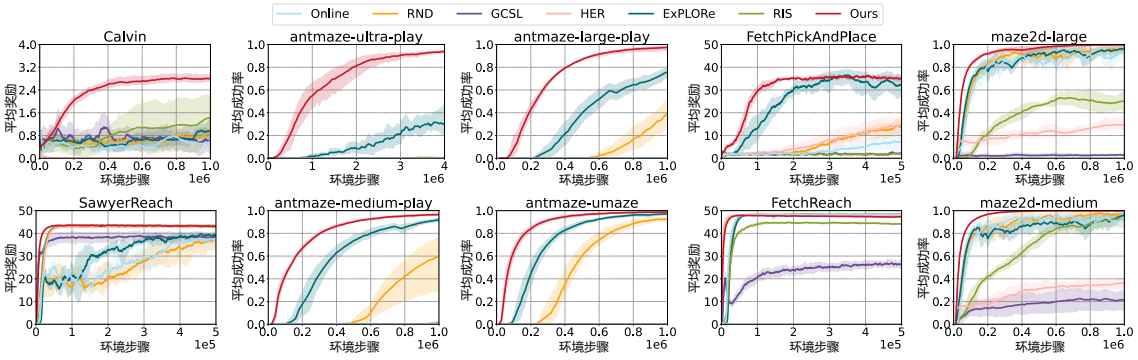


图 4-3 机器人操作和导航任务在线学习方法的比较。阴影区域表示 5 个随机种子的 95% 置信区间。

Online 是一种标准的异策略 actor-critic 算法 [70]，它从零开始同时训练 actor 网络和 critic 网络，完全不利用先验数据。RND 在 Online 方法的基础上，引入随机网络蒸馏 [106] 作为探索的奖励增益。对于一个在线转换 (s, a, r, s') 和 RND 特征网

中国知网 https://www.cnki.net

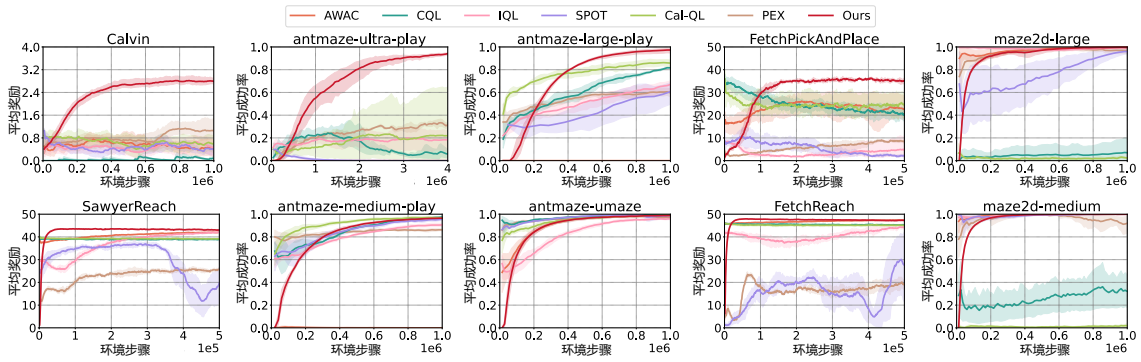


图 4-4 与离线预训练和在线微调方法的比较，阴影区域表示 5 个随机种子的 95% 置信区间。

络 $f_\phi(s,a)$ 以及 $\bar{f}(s,a)$，其中：

$$\hat{r}(s,a) \leftarrow r + L||f_\phi(s,a) - \bar{f}(s,a)||^2, \tag{4-14}$$

并在在线更新时使用转换 $(s,a,\hat{r},s')$。RND 训练方式与本章的方法相同，每次收集新转换数据时都会进行一次梯度更新。HER：将 Online 方法与后验经验回放 (HER) [137] 结合，通过使用不同目标重新标记过去的数据，提高数据利用率。GCSL 通过监督学习训练策略，保证学习过程的稳定性。RIS 方法 [139] 引入了一个单独的高层策略，预测目标的一半路程处的中间状态。通过使子目标到达策略与最终策略对齐，RIS 有效地正则化了学习过程，并在复杂任务中提升了性能。ExPLORe 方法从在线经验中学习奖励模型，并为未标记的先验数据 [108] 赋予乐观奖励，然后，它将这些数据与在线数据同时用于下游的策略优化和 critic 优化。

CQL 在学习到的 Q 函数上引入了额外的正则项，对超出分布范围的动作进行惩罚，同时在训练数据集中出现的动作上补偿这种保守性。假设值函数由 Q_θ 表示，其训练目标如下：

$$\begin{aligned}\min_\theta \quad & \alpha \underbrace{\left(\mathbb{E}_{s\sim\mathcal{D},a\sim\pi}\left[Q_\theta(s,a)\right] - \mathbb{E}_{s,a\sim\mathcal{D}}\left[Q_\theta(s,a)\right]\right)}_{\text{Conservative regularizer } \mathcal{R}(\theta)} \\ & + \frac{1}{2}\mathbb{E}_{s,a,s'\sim\mathcal{D}}\left[\left(Q_\theta(s,a) - \mathcal{B}^\pi\bar{Q}(s,a)\right)^2\right],\end{aligned} \tag{4-15}$$

其中，$\mathcal{B}^\pi Q(s,a)$ 是作用于延迟目标 Q 网络 Q 的备份算子：

$$\mathcal{B}^\pi Q(s,a) := r(s,a) + \gamma\mathbb{E}_{a'\sim\pi(a'|s')}[Q(s',a')], \tag{4-16}$$

第二项是标准的时序差分误差。第一项 $R(\theta)$ 是一个保守正则项，旨在通过最小化策略 $\pi(a|s)$ 下的 Q 值来防止对 OOD 动作的 Q 值过高估计，并通过最大化行为策略 π_β 数据集中的动作 Q 值来平衡这种保守性。Cal-QL 方法通过学习保守的值函

中国知网 https://www.cnki.net

数初始化，加速在线微调，同时利用离线数据的优势，通过低估学习到的策略值来确保校准性。具体而言，Cal-QL 约束学习到的 Q 函数 Q_π^θ 大于值函数 V，通过对 CQL 训练目标进行如下简单修改来实现：

$$\mathbb{E}_{s\sim D,a\sim\pi}[\max(Q_\theta(s,a),V(s))]-\mathbb{E}_{s,a\sim D}[Q_\theta(s,a)]. \tag{4-17}$$

SPOT 方法约束离线强化学习中的策略网络，使其不仅位于支持集内，还能有效避免分布外动作，与标准的行为策略相比，更加注重行为正则化。PEX 方法引入了一种策略扩展方案。在学习离线策略后，将其作为候选策略加入策略集合，从而进一步促进在线策略的学习。该方法避免直接对离线策略进行微调（这可能会破坏已学习的策略），而是允许离线策略自适应地参与在线探索。

图4-3展示了本章的方法与其他在线学习方法在导航和操作任务中的性能对比曲线。从图中可以看出，本章的方法在学习效率和策略性能上都有显著的提升，特别是在一些具有长时域挑战的任务中，如 FetchPickAndPlace、AntMaze-Ultra 和 CALVIN。在这些任务中，智能体需要通过智能探索来获得有效的信息，而不是对所有状态进行穷举搜索，这样的探索方式不仅高效，而且节省时间。传统方法可能需要对每个可能的状态进行过度的探索，这在长时域任务中极为耗时，效果也不一定理想。值得注意的是，本章方法能够迅速收敛，并且在保证稳定性的同时，超越了现有方法的表现，展示了出色的效率。

图4-4则展示了本章的方法与离线-在线方法的比较。从对比结果来看，本章的方法在短时间内便能够达到与现有方法相当的性能，并且在处理长时域任务时展现出了明显的优势，尤其在如 AntMaze-Ultra 和 CALVIN 等具有较大挑战性的任务中，本章的方法在表现上超越了传统的离线-在线混合方法。这表明，在这些任务中，本章的方法不仅具备了快速收敛的能力，而且在策略的稳定性和长期表现上也展现出了更高的效率和可靠性。

4.4.3 消融实验与性质分析

本节首先评估了本章的方法对 AntMaze 领域中智能体状态覆盖率的影响[108]，以探讨其有效性是否主要源自信息丰富的探索。这一评估使能够确定在加速在线学习过程中，纳入非专家的无动作观察数据的有效性。在 AntMaze 任务中，本节评估了各种方法的状态覆盖率，特别关注它们在迷宫导航中的探索效果。图4-5直观地展示了在 antmaze-large 任务中的状态访问情况。值得注意的是，本章的方法引导智能体进行探索，优先考虑那些可能导致最终目标的状态。更进一步，本节对 FetchReach 任务中的末端执行器轨迹进行了可视化。为了增强可视化效果，将目标位置固定在距离起始点更远的位置，从而增加任务难度。在图4-6中，黑点表

中国知网 https://www.cnki.net

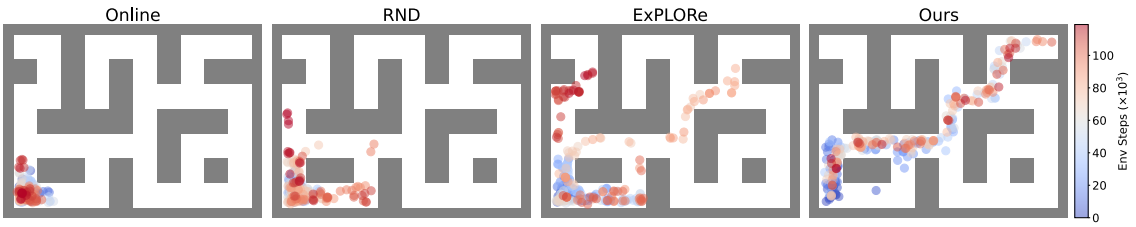


图 4-5 AntMaze-Large 上智能体探索行为的可视化：散点均匀采样自在线重放缓冲区，并根据训练环境步数进行着色，可视化结果通过从最多 $120K$ 个环境步中采样 512 个点获得。

示起始点，绿色点表示最终目标。可视化结果显示，其他方法从起始点向外均匀探索。尽管它们包含了主动探索机制，但由于状态空间过大，仍难以成功到达目标点。而本章的方法则避免了无目标的探索，能够高效地到达目标点，这与本章的结论一致。

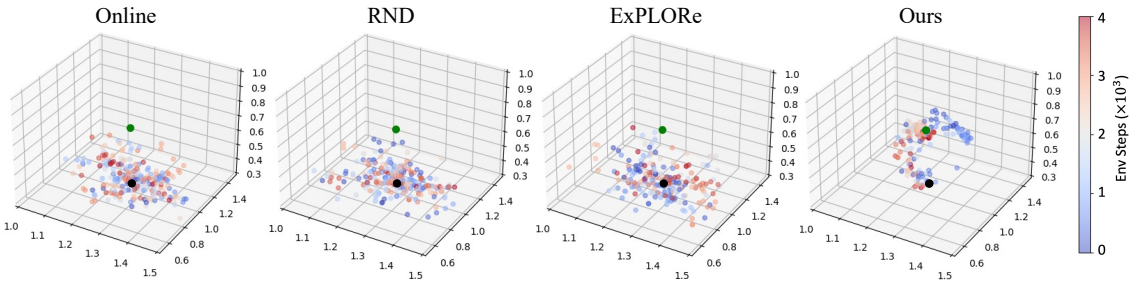


图 4-6 FetchReach 任务中末端执行器轨迹的可视化：这些点是从在线重放缓冲区中均匀采样的，并根据训练环境的步数进行着色。

为了提供更量化的评估，本节采用了“加权状态覆盖率”指标。将地图划分为网格，并根据每个状态到目标的距离分配重要性值，如图4-7所示。加权覆盖率指标反映了每 1000 步所遇到的状态的平均重要性。较高的加权覆盖率表示更强调探索重要状态。与 RND [106] 和 ExPLORe [108] 等方法相比，这些方法虽然优先进行广泛的探索，但可能未必专注于任务完成所需的关键状态。相反，本章的方法将探索集中在更可能导致目标的状态上。通过这些评估，本章的方法在引导智能体有效探索关键状态方面表现出色，从而加速了在线学习过程。这表明，纳入非专家的无动作观察数据，并使用扩散策略学习子目标引导对于提升探索效率和学习效果具有重要意义。

然而，学习到的状态-目标值函数并不完美，存在以下问题：1. 长期目标估计引入噪声：在强化学习中，估计长期目标可能会引入较高的噪声，影响学习的稳定性和效率；2. 梯度衰减：随着距离目标的增加，状态-目标值函数中的梯度逐渐减弱，导致对远距离目标的学习信号变得微弱。在图4-8（a）中可视化了这些错误，

中国知网 https://www.cnki.net

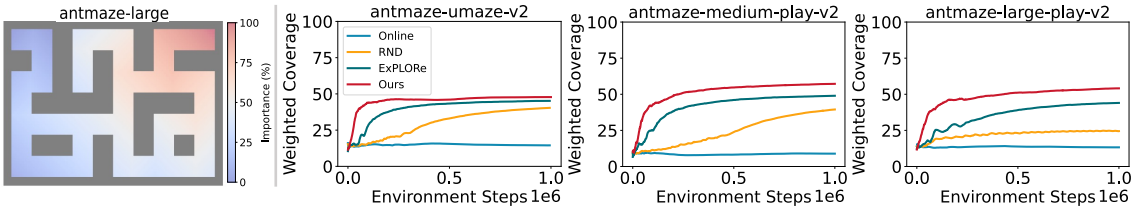


图 4-7 **左图：**状态重要性的可视化，其重要性由到目标的距离决定；**右图：**三个 AntMaze 任务的加权覆盖度。加权覆盖度表示每 $1K$ 步的平均重要性。更高的加权覆盖度表明探索更有价值。

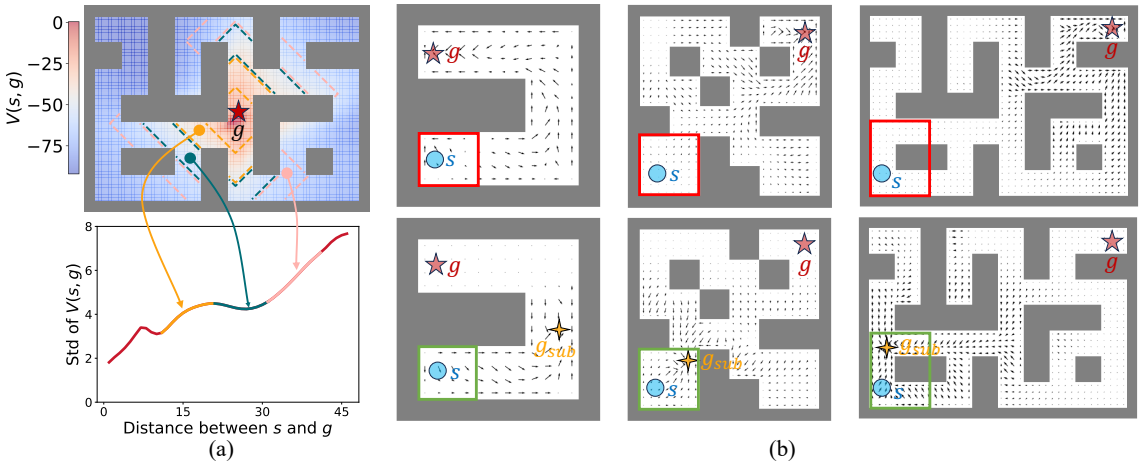


图 4-8 （a）价值函数 $V(\cdot, g)$ 标准差的可视化：当状态与目标之间的距离增加时，学习到的价值函数会变得更加噪声化; （b）顶部：仅依赖远距离目标会导致指导不清晰且容易出错; 底部：通过子目标可以提供清晰的指导。箭头表示 $V(\cdot, g)$ 的梯度，反映了对策略探索的引导作用。

突出显示了仅依赖值函数所提供的有限引导。通过设置提供当前状态附近目标的子目标，本章方法可以有效地缓解上述问题，特别是在长时域任务中。在图4-8（b）中，来自子目标的探索奖励显示出显著的差异和更高的精度，使学习信号更加明显和易于辨识。

为了展示子目标和探索引导如何促进目标达成任务中高效策略的学习，本章进行了消融实验，逐一移除每个组件。实验结果如图4-9所示，突显了子目标设置的重要性，在没有子目标的情况下，长时域任务的解决能力受到显著限制。此外，结合探索引导可以帮助策略更高效地达到子目标，从而进一步提高学习效率，结合子目标设置和探索引导，能够充分发挥两者的优势，从而实现高效的学习过程。为了探究子目标步长值 k 对性能的影响，本节在 AntMaze 任务上对方法进行了评估，并选取了六个不同的 k 值 $\{1, 5, 15, 25, 50, 100\}$。如图4-10所示，评估结果揭示了 k 值与性能之间的关系。值得注意的是，当 k 值处于 25 至 50 的区间内时，本

中国知网 https://www.cnki.net

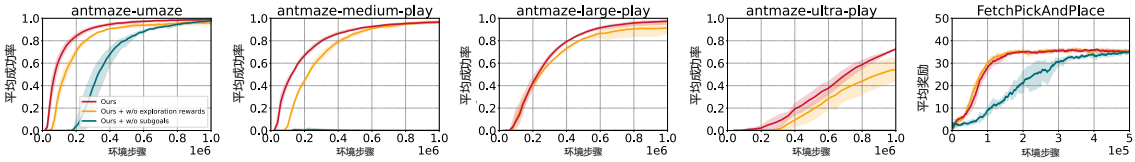


图 4-9 子目标与探索引导的消融研究显示子目标设定对学习过程至关重要，此外，融合探索引导可以帮助策略更高效地到达子目标，从而进一步提升学习效率。阴影区域表示在 5 个随机种子下的 95% 置信区间。

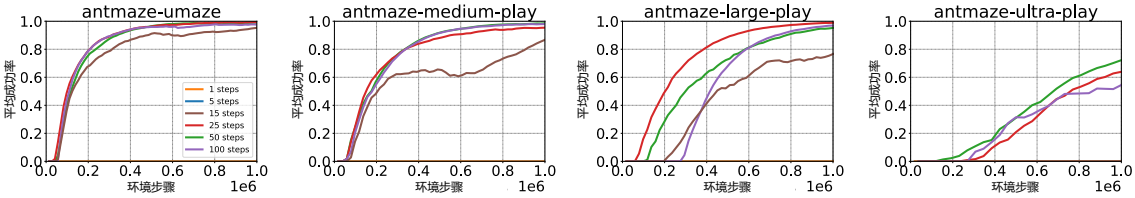


图 4-10 子目标步长 k 的消融研究。本章方法在 k 取值为 25 到 50 之间时通常能达到最佳性能。即使 k 不在此范围内，大多数情况下仍能保持较好的性能。

章的方法始终展现出最佳性能，该区间可视为最优取值范围。即使在 k 值偏离该范围时，本章的方法依然表现良好，仅在 k 值过小的情况下性能会显著下降，体现了本章方法在各子目标步长值下的鲁棒性和高效性。

为了进一步评估本章的方法在利用先验数据方面的能力，本章对 antmaze-large-play-v2 数据集进行了修改，以在不同数据损坏情景下测试本章的方法。具体而言，本章主要考虑以下几种情况，实验结果如图4-11所示：

- 多样性：本章考察了方法对离线轨迹多样性的敏感性。实验中使用了两种 antmaze-large 数据集变体：antmaze-large-play：智能体从固定的起点导航到固定的终点；antmaze-large-diverse：智能体从随机起点导航到随机终点。
- 数据量有限：本章通过移除不同比例的离线轨迹来检验数据数量对性能的影响，其中 10% 表示仅保留 100 条轨迹。
- 覆盖不足：评估了方法对离线数据覆盖范围的依赖性。具体做法是从 antmaze-large-play 数据集中保留部分轨迹，并将其划分为三个区域：起始区、中间区和目标区。随后，通过分别移除各区域数据来进行消融实验。
- 不完整轨迹：通过将每条离线轨迹按不同长度分割，验证了方法对不完整轨迹的鲁棒性。实验中采用了三种分割级别：2 段、3 段和 4 段。各轨迹的长度分布在图4-11（d）中进行详细说明。

本章的方法在处理多样化数据集时表现出强大的鲁棒性，即使在数据有限的情况下也能保持有效性和稳定性。即使数据极为稀缺，它仍然能够有效运行。当覆盖

中国知网 https://www.cnki.net

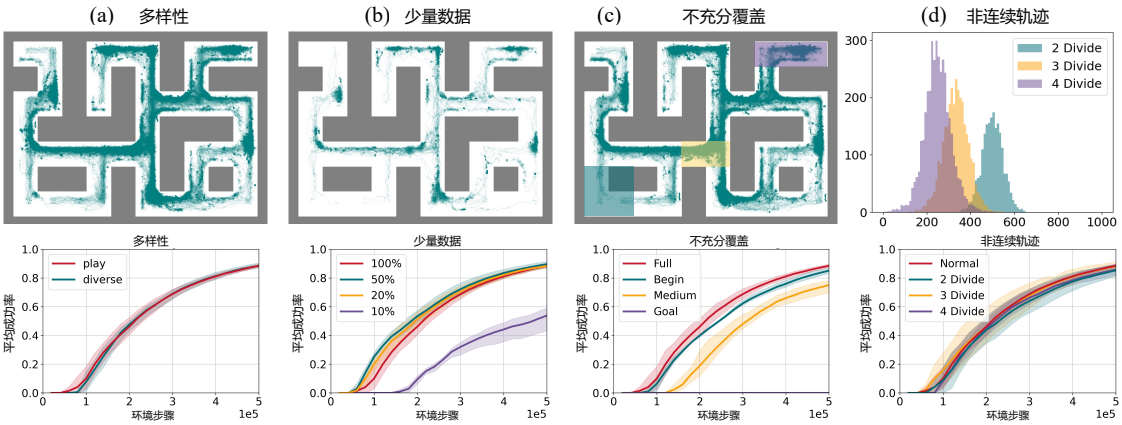


图 4-11 对四种不同类型的先验观测数据的可视化及其评估结果。顶部：数据特征的可视化；底部：评估结果；（a）复杂性与多样性；（b）受限数据集模式；（c）覆盖不足；（d）轨迹不完整。

不足时，缺少起始区和中间区数据对本章方法策略的学习影响不大。然而，当目标区的数据覆盖不足时，在线学习会面临挑战，这突显了目标覆盖的重要性。在处理由轨迹段组成的数据时，本章的方法表现优异，得益于其强大的轨迹拼接能力。上述比较强调了本章方法在不同数据集上的鲁棒性，包括多样化的先验数据和具有不同程度损坏的低质量数据。

4.5 本章小结

本章提出的方法 EGR-PO 解决了长时域目标达成策略学习中的挑战，通过利用非专家的无动作观察数据来提高学习效率。首先学习一个高层次的扩散策略来生成合理的子目标，并通过状态-目标值函数来促进信息丰富的探索。子目标作为途中的关键点，为智能体提供了明确的引导，并提高了预测探索奖励的准确性。这两个组件自然地融入到演员-评论员框架中，使得应用现有算法变得更加简单。本章的实验结果表明，本章的方法在现有的目标达成方法上取得了显著的提升，并且对各种损坏的数据集表现出良好的鲁棒性，增强了本章方法的实用性和应用性。

中国知网 https://www.cnki.net

第五章 扩散点轨迹增强的高效策略学习

5.1 引言

在以上两章中，讨论了扩散模型在智能体决策以及策略学习中的作用，本章关注于扩散模型在数据表征的研究，与前两章围绕基于扩散模型的智能体高效决策形成闭环。在环境中直接使用强化学习方法进行策略学习通常是效率低下的，现有的方法更关注于使用专家演示数据来指导智能体高效策略学习，这类方法需要收集大量数据以支撑和提高策略学习性能，但数据收集往往需要花费更多的资源。扩散模型作为生成模型能够通过拟合已有数据，从样本中学习数据分布，并通过在该分布中进行采样，生成更多的有效数据，这通常用于解决数据稀缺性问题。在基于图像观测的任务上，使用扩散模型进行数据扩充需要在图像空间进行视频生成，使用扩散模型进行视频生成成本过高，现有的方法很难生成高质量且时空一致性的内容，从而导致生成的数据无法有助于策略学习。为解决这一问题，本章使用扩散模型直接学习策略相关的数据表征，通过避免对图像像素级的生成，主要关注于决策相关的信息，不仅能够增强扩散模型推理效率，并且学习到的抽象数据表示能够更好的有助于策略学习，具体来说，对于机械臂操作任务，首先使用点跟踪模型，对机械臂操作专家演示行为进行轨迹表示，扩散模型通过学习轨迹表示，对智能体决策基于轨迹表示作为引导，从而更高效的进行策略学习。

视频包含有关行为、物理和语义的知识，提供了另一种数据源。然而，缺乏行动标签使得视频数据在策略学习中的利用变得困难。先前的工作已经解决了这个问题，通过使用视频预训练的自监督目标来学习用于策略学习的观察的特征表示[142–144]。然而，特征表示只描述当前时间步长的状态，在很大程度上忽略了预测未来状态的转换动态。为了明确建模过渡动态，先前的工作已经开发了视频预测模型，从当前的图像帧预测未来的图像帧[145]，以指导策略学习[145–147]。然而，学习用于控制的视频预测模型会带来两个挑战。首先，视频预测任务通过对每个像素的变化建模，将物理运动与视觉外观（如纹理和照明）相结合，避免了任何抽象。这种耦合使得建模变得困难，常常导致幻觉和不切实际的未来预测。其次，这些模型在训练和推理方面都需要大量的计算量。在计算资源有限的情况下，性能会显著下降。此外，较高的推理成本迫使这些模型采用开环执行[145,148]，这往往导致策略的鲁棒性较差。先前的研究探索了用于机器人操作的结构化表示[62,149,150]，如点云[151,152]和关键点[153,154]，但这些方法主要局限于结构化的桌面场景。其中，一些基于流表示预测动作的方法[155–157]依赖于 3D 机器人交互数据（通常来自仿真环

中国知网 https://www.cnki.net

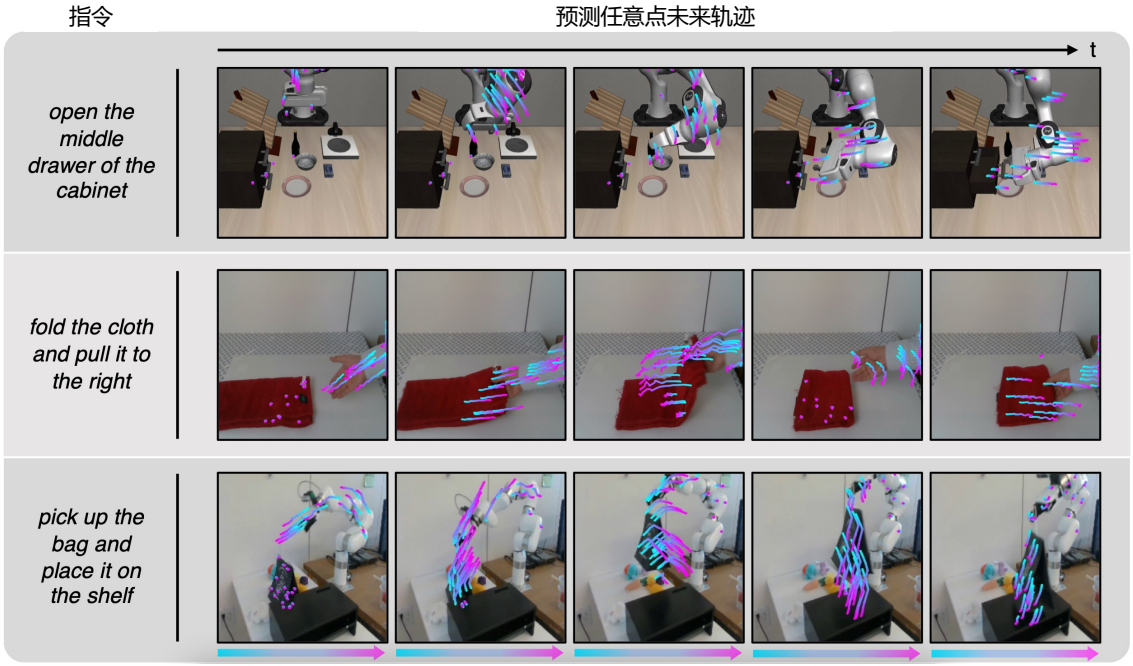


图 5-1 给定任务指令和图像帧中任意一组点的初始位置，本章的扩散点轨迹模型可以在任务条件下预测这些点的未来轨迹。在无动作视频数据集上训练该模型后，预测的轨迹可作为有效的引导，用于学习一组基于语言指令的视觉运动控制任务。

境），因此难以推广到真实世界的应用。最近，Vecerik 等人[158] 利用点跟踪进行视觉伺服控制，但该方法需要对任务进行结构化的多阶段定义，并且在测试时仅能处理与训练数据略有不同的变化。同时，相关研究通过预测当前图像中点的未来轨迹改进了，使其能够结合领域内的人类视频和机器人视频学习策略。然而，该框架无法直接利用网页视频数据，因为其策略依赖于逐步的图像观测来进行轨迹预测。本章的方法是独立开发的，它能够在仅提供初始图像和目标图像的情况下，从网页视频中学习任意点的轨迹预测。本章进一步展示了如何利用这些预测的轨迹来推断物体的刚体变换，以进行开环执行，并通过对动作预测残差进行优化，实现闭环部署，从而提升执行效果。

本章提出了一种新颖的结构化表示来连接视频预训练和策略学习，首先将每个状态表示为视频帧中的一组点。为了对视频中的时间结构建模，本文学习了一个基于扩散模型的轨迹点模型，它以当前观测和任务为条件输入，自主拟合关键点位置，并输出它们未来的轨迹。本章在相机坐标系中预测这些轨迹，这些二维点轨迹对应于三维空间中的粒子轨迹，是运动的通用表示，可以转移到不同的领域和任务。与跟踪像素强度变化的视频预测方法相比，基于粒子的轨迹建模提供了对物理动力学的抽象，自然地包含了物体永续性和连续运动等归纳偏差。本章

中国知网 https://www.cnki.net

方法首先在无动作视频数据集上预训练轨迹模型。预训练后，预测轨迹可以作为信息增强来指导控制策略，本章方法仅使用最少量的动作标记演示数据来训练轨迹引导策略。

5.2 问题描述

在本章中，本章方法的目标是从一小组带有动作标记的演示轨迹中学习鲁棒的控制策略。为此，希望利用更具可扩展性的未标记视频作为预训练的数据源。本章的核心思路是借助扩散模型，从视频数据中学习与策略相关的抽象轨迹表示，以减少扩散模型的参数规模，并为策略学习提供清晰的指引。

首先，将无动作标签视频数据集表示为 $\mathcal{T}_o = \{(\tau_o^{(i)}, \ell^{(i)})\}_{i=1}^{N_o}$，其中 $\ell^{(i)}$ 是第 i 个片段的语言指令，$\tau_o^{(i)} = \{o_t^{(i)}\}_{t=1}^{T}$ 表示在相机观测下的仅由图像组成的轨迹，类似地，将演示数据集表示为 $T_a = \{(\tau_a^i, l^i)\}_{i=1}^{N_a}$，$\tau_a = \{o_t, a_t\}_{t=1}^{T}$ 是带有动作标记的轨迹。在模仿学习过程中，本章的目标是通过以下行为克隆目标，学习由参数 θ 表示的策略 π_θ，以模仿专家行为：

$$\pi_\theta^* = \arg\min_\theta E_{(o_t, a_t, \ell)\sim\mathcal{T}_a} \left[\mathcal{L}(\pi_\theta(o_t, \ell), a_t)\right], \tag{5-1}$$

其中，$\mathcal{L}$ 是损失函数，可以是均方误差（MSE）或交叉熵损失。

视频跟踪技术的最新进展 [159–163] 使得能够在无需外部监督的情况下跟踪视频帧中每个点的轨迹。在本章中，采用了 [164] 提出的现成跟踪器。正式来说，给定来自视频的一系列图像 $o_1, \ldots, o_T$，任意时间步 $\bar{t} \in [1, T]$，以及该帧中的一组点 $\{\bar{p}_{t,k}\}_{k=1}^{K}$，其中 $\bar{p}_{t,k} = (x, y)$ 表示在相机坐标系中的点坐标，跟踪任务的目标是预测这些点在每一帧中的 2D 相机坐标 $p_{t,k}$，其中 $t = 1, \ldots, T$。在本章中，将使用轨迹来表示任意点的 2D 坐标序列，记作 $(p_1, \ldots, p_T)$。本章方法仅对相机坐标系中的 2D 轨迹进行建模，以避免对多视角相机或深度信息的可用性做额外假设，从而便于未来扩展到更丰富的视频数据集。此外，跟踪器还会预测一个二值可见性变量 $v_{t,k}$，用于指示该点在时间步 t 是否被遮挡。

5.3 扩散点轨迹引导的策略学习

视频蕴含了大量关于世界的先验信息，捕捉了物理动态、人类行为和语义，这些信息对于策略学习至关重要。相比于仅从视频中学习表征 [142,143,165]，本章的目标是从视频中学习一个模型，用于预测未来状态，从而指导控制策略。通过这种方式，可以将视觉-运动策略学习的挑战本质上分解为两个部分。第一部分是学习“下一步该做什么”，即通过生成未来状态作为具体的子目标，这一过程完全基于

中国知网 https://www.cnki.net

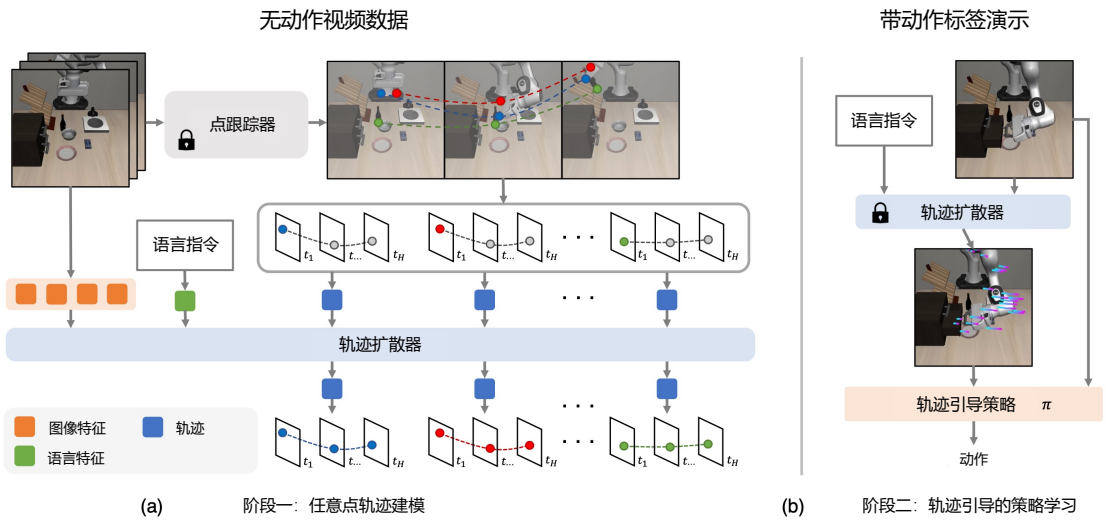


图 5-2 **框架概述：**（a）在第一阶段，针对一个无动作视频数据集，本章方法首先在某一帧视频上采样 2D 点，并使用预训练的跟踪器在整个视频中跟踪它们的轨迹。然后，本章训练一个轨迹 Diffuser，使其能够在给定当前图像观测、语言指令情况下定位并预测未来的点轨迹；（b）在第二阶段，本章方法学习一个基于轨迹引导的策略来预测控制动作。通过预测轨迹提供的引导，本章方法可以仅通过少量带有动作标注的示例学习出稳健的策略。

视频学习。第二部分是学习如何预测控制动作以跟随子目标，与端到端策略学习相比，这一过程所需的数据量大大减少。借助充分的视频预训练，即使仅依赖少量带有动作标注的轨迹，本章方法仍然能够学习具有泛化能力的策略。先前的研究[145, 148, 166]主要依赖像素级的未来帧预测作为视频预训练方法。然而，视频预测在训练和推理阶段都非常消耗计算资源，并且其主要关注的是重建像素级细节，而这些细节往往与策略学习无关，可能会降低后续策略学习的效率。本章提出了一种基于扩散模型的任意点轨迹建模方法。如图5-2所示，DPT 是一个两阶段框架：首先，在大规模无动作标注的视频数据上进行预训练，学习如何预测视频帧中点的未来轨迹；然后，利用预测的轨迹来指导策略学习，以少量带有动作标注的演示数据完成学习。本节将对本章提出的方法进行详细介绍，本节首先描述如何从无动作标注的视频数据集 $\mathcal{T}_0$ 中学习点轨迹预测模型。随后介绍如何利用预训练的轨迹预测模型，从有限的带动作标注轨迹数据集 $\mathcal{T}_a$ 中学习基于轨迹引导的策略。

5.3.1 视频数据集轨迹建模

本章的目标是预训练一个模型，使其能够从视频中预测视频帧内点的未来轨迹。更具体地说，给定时间步 t 的图像观测 o_t、图像帧上的任意一组 2D 查询点 $\mathbf{p}_t = \{\mathbf{p}_{t,k}\}_{k=1}^{K}$ 以及语言指令 $\mathcal{L}$，本章方法学习一个模型 τ_θ，使其能够预测查询点

中国知网 https://www.cnki.net

在未来 H 个时间步内的坐标，即 $\mathbf{p}_{t:t+H} = \tau_\theta(o_t, \mathbf{p}_t, \mathcal{L})$，其中，$\mathbf{p}_{t:t+H} \in \mathbb{R}^{H\times K\times 2}$ 表示相机坐标系中查询点的未来轨迹。为了对轨迹进行建模，本章方法提出了一种轨迹扩散策略，图5-2（a）展示了其架构。

首先进行自监督轨迹标注，本章方法从无动作标注的视频中生成点轨迹，以进行轨迹建模的预训练。本章方法使用视觉跟踪器对视频进行预处理，并生成一个跟踪数据集。对于每个视频，随机采样一个时间步 $\bar{t}$，然后在该帧上随机选取一些点，并运行跟踪器生成它们的轨迹。然而，在静态摄像机的情况下，随机采样的大多数点可能位于背景中，这些点在训练轨迹扩散策略时提供的信息较少。为了解决这一问题，采用了一种启发式方法来过滤这些静态点：首先，在时间步 $\bar{t}$ 处的帧上采样一个 $n \times n$ 的网格，并在整个视频中跟踪这些网格点，以获得初始轨迹集 $\tau \in \mathbb{R}^{n^2\times T\times 2}$。接着，通过计算点随时间变化的位置方差，筛除那些在整个视频中几乎没有移动的点。最后，在筛选后的点附近重新采样新的点，并利用跟踪器生成它们的位置。

在多模态轨迹建模中，本章将未来轨迹预测问题转化为一个生成任务。具体来说，该任务的目标是根据当前的图像观测和任务语言指令，自主生成合理的轨迹，不仅回归当前关键点的位置，还预测这些关键点在未来的运动变化。为实现这一目标，本章方法将语言描述和图像观测作为条件信息输入到轨迹扩散模型中。具体流程如下：首先，利用预训练的 BERT [167] 编码器对语言指令进行编码，并使用 ResNet 提取图像特征后进行编码，从而获得统一的条件表示。然后，从高斯分布 $N \sim \mathcal{N}(0, I)$ 中随机采样 $N \times T \times 2$ 个点，作为初始轨迹 τ^T。在此基础上，扩散模型对噪声进行预测，并通过前向扩散过程逐步去噪，最终生成符合条件的轨迹。

5.3.2 轨迹引导策略学习

训练好的轨迹扩散策略基于当前观测预测未来轨迹，基于此可以学习由轨迹引导的控制策略，轨迹引导策略 $\pi(a_t \mid o_t, p_{t:t+H})$ 以当前观测 o_t 和预测轨迹 $p_{t:t+H}$ 作为输入，并预测相应的动作。图5-2（b）展示了本章方法策略架构的简化示意图。本章方法借鉴了先前工作 [168,169] 的设计，以 Transformer 为策略架构，尽管单独的预测轨迹已经为动作预测提供了丰富的信息，本章方法仍将上下文图像观测融入策略中，以确保不会丢失任何信息。在图像令牌融合的前后都引入了轨迹令牌，以确保能够有效整合轨迹中传递的指导信息。由于轨迹本身已经提供了细粒度的子目标，此时策略不再需要语言指令作为任务规范，实际上，这些轨迹将原本复杂的策略学习问题简化为更易解决的子目标跟随问题，从而将策略降解为一个逆向动力学模型。轨迹引导策略采用均方误差损失进行训练。在图5-3中展示了

中国知网 https://www.cnki.net

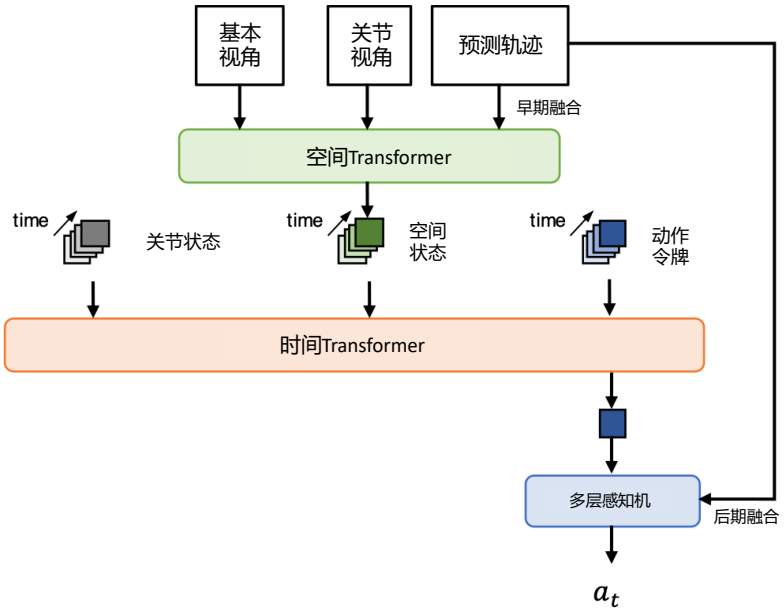


图 5-3 **空间信息：**本章方法对包含所有视角轨迹、图像 patch 以及 CLS 标记的序列执行自注意力机制；**时间信息：**本章方法在每个时间步的空间 CLS 标记、本体感知信息和动作 CLS 标记之间执行因果自注意力机制；**动作回归：**本章方法将每个时间步的动作 CLS 标记与提议的轨迹进行拼接。

实验中所采用的 ViT-T [168,169] 策略的更详细示意图。该策略的输入包括多个视角下时间堆叠的图像 $o_t \in \mathbb{R}^{V\times T\times C\times H\times W}$ 以及本体感知数据 $p_t \in \mathbb{R}^{D_p}$。为处理这些输入，ViT-T 主要由以下三个阶段构成:

在空间编码阶段，本章方法首先对每个时间步的所有模态信息进行整合和编码。通过利用冻结的轨迹 Transformer 对输入图像 o_t 中所有视角下的帧进行处理，提出一组轨迹信息，然后通过各自专门设计的模态编码器将图像、轨迹等不同模态数据投影到共享嵌入空间 $\mathbb{R}^D$ 中。每种模态的令牌都会先经过一个共享的模态令牌以及对应的模态特定位置嵌入进行编码，以捕捉各自的特征和空间位置信息。随后，将来自各模态和各视角的令牌进行级联，并在前端添加一个学习得到的空间 CLS 令牌，通过自注意力机制对整个令牌序列进行处理，实现多模态信息的有效融合，提取出的空间 CLS 令牌作为全局空间特征的表示，为后续的时间解码和动作预测阶段提供了坚实的特征基础。

在时间解码阶段，首先将每个时间步的本体感知数据投影到共享嵌入空间中，以确保各个时间步的本体感知信息具有一致的特征表示。将编码后的本体感知令牌、在空间编码阶段得到的全局空间 CLS 令牌以及一个专门学习得到的动作 CLS 令牌按照时间顺序交替排列成一个序列。这个序列随后通过因果屏蔽的自注意力机制进行处理，确保每个时间步的输出仅依赖于当前及之前的时间步，从而捕捉

中国知网 https://www.cnki.net

表 5-1 策略学习超参数。

Hyperparameters	Policy
epoch	100
batch size	512
optimizer	AdamW
learning rate	5e-4
weight decay	1e-4
lr scheduler	Cosine
lr warm up	0
clip grad	100
point sampling	grid
number of points	32
track length	16
frame stack	10
augmentation	ColorJitter,RandomShift

到动态变化的时序特征，使得时间解码模块不仅有效地整合了来自多个时间步的本体感知信息和空间特征，还为后续的动作预测提供了丰富而连贯的时序上下文。

在动作头部分，对每个时间步的输出结果进行独立处理，并通过多层感知器对动作进行参数化预测。对于每个时间步，首先从时间解码器中提取出对应的动作 CLS 令牌，然后将令牌前时间步重构的轨迹信息进行融合。这一过程加强了时序输出中的关键信息，而且有效整合了轨迹预测中提取到的细粒度子目标信息，确保每个时间步生成的特征既反映了环境状态的动态变化，充分捕捉任务执行的指导细节，融合后的特征经过多层感知机转换为具体的动作指令，作为智能体决策指令。

5.4 实验结果分析

本节通过实验说明，使用扩散模型学习抽象的数据表征能够使策略学习更高效，从而使得学到的策略性能更高，本节主要通过对比与最先进的视频预训练和行为克隆基线，其次，在模拟环境中进行了一系列消融实验，以展示各项设计选择的影响。这些实验内容包括：策略学习所需的带动作标记轨迹数量、轨迹预测时间范围的效果以及轨迹融合的影响。

5.4.1 与先进方法对比

本节在 LIBERO 基准测试 [168] 上的 100 多个语言条件下的操控任务中，与基线方法进行比较。该基准测试分为五个子套件：LIBERO-Spatial、LIBERO-Object、LIBERO-Goal、LIBERO-Long 以及 LIBERO-90，如图5-4提供了简要实例。其中，

中国知网 https://www.cnki.net

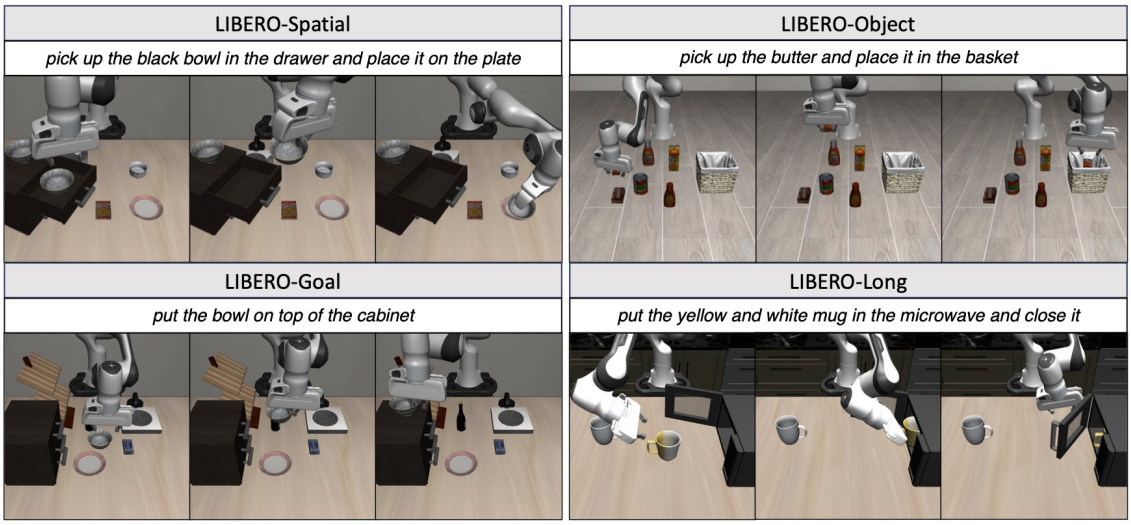


图 5-4 LIBERO 基准测试中任务的可视化。

除 LIBERO-90 包含 90 个任务外，其余每个子套件均包含 10 个任务。每个任务都附有专家级的人类演示数据。具体来说，LIBERO-Spatial 包含使用相同物体但布局不同的任务；LIBERO-Object 则是布局相同但物体不同的任务；LIBERO-Goal 中任务的物体类别和空间布局相同，但目标不同；LIBERO-Long 包含物体类别和布局多样化且任务目标时间跨度较长的任务；而 LIBERO-90 则涵盖了极其多样化的物体类别、布局和任务目标。本节在每个子套件上分别与基线方法进行比较。所有方法均在每个任务中使用 10 条带动作标记的演示轨迹和 50 条无动作视频演示轨迹进行训练，对于每个包含 10 个任务的子套件，总共使用 500 个视频。演示数据集包含来自第三人称摄像机和手腕摄像机的 RGB 图像，同时还包含夹爪状态和关节状态作为观测信息。由于每个任务均由一条语言指令来指定，本章方法采用预训练的 BERT 网络来获取任务嵌入表示 [167]。图像分辨率为 128×128，动作空间为 7 维，分别对应末端执行器的平移、旋转和抓取开合状态。 本节与以下基线方法进行比较：

表 5-2 LIBERO 基准测试的平均成功率。本章的方法在所有任务集合中均稳定优于所有基线方法。UniPi-Replan 仅在单个种子上进行了评估。

方法	Libero-Spatial	Libero-Object	Libero-Goal	Libero-Long	Libero-90
BC-Full-Trainset (Oracle)	71.83 ± 3.70	71.00 ± 7.97	76.33 ± 1.31	24.17 ± 2.59	-
BC	39.00 ± 8.20	51.83 ± 13.54	42.50 ± 4.95	16.67 ± 3.66	29.78 ± 1.14
R3M-finetune [143]	49.17 ± 3.79	52.83 ± 2.25	5.33 ± 1.43	9.17 ± 2.66	9.59 ± 0.27
VPT [170]	37.83 ± 4.29	19.50 ± 0.82	3.33 ± 2.36	3.83 ± 1.65	-
UniPi [145, 166]	69.17 ± 3.75	59.83 ± 3.01	11.83 ± 2.02	5.83 ± 2.08	-
UniPi-Replan [148]	-	31.00	3.00	-	-
DPT	$\mathbf{71.80 \pm 1.28}$	$\mathbf{94.30 \pm 2.18}$	$\mathbf{80.57 \pm 0.76}$	$\mathbf{47.26 \pm 13.80}$	$\mathbf{62.34 \pm 2.29}$

中国知网 https://www.cnki.net

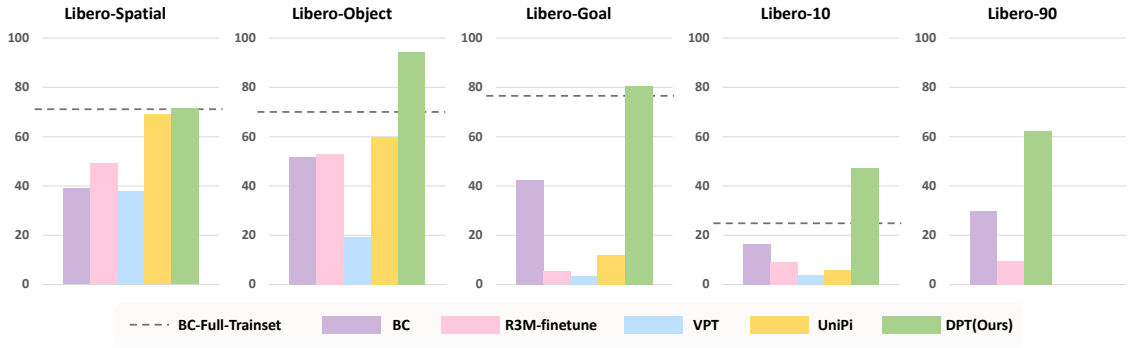


图 5-5 不同任务的定量对比。在 LIBERO 基准测试中，对比了当前最先进的视频预训练方法在语言条件操控任务上的表现。并进一步在包含 90 个任务的任务集（即 LIBERO-90）上，DPT 在所有任务中均优于基线方法，并在 LIBERO-Goal 和 LIBERO-Long 任务上表现尤为突出。

- Behavior Clone (BC) 表示最基本的行为克隆方法，该方法仅使用有限的带动作标记的专家演示数据来训练策略，而不利用视频数据集。BC 使用的策略架构与 DPT 完全相同，唯一的区别在于其将粒子轨迹部分置零，并以语言嵌入作为任务规范。可以将 BC 基线视为在不使用无动作视频数据的情况下进行策略学习的消融实验。需要注意的是，训练 BC 策略时的具体架构和损失函数可能会有所不同。
- R3M-finetune [143] 采用对比学习目标，通过结合时序对比损失、L1 正则化和语言一致性损失，实现视频与语言表征的对齐。本节使用公开发布的 Ego4D 预训练权重，并在领域内的视频数据集 T_o 上进行微调，以初始化行为克隆策略的视觉编码器，在策略训练过程中，还进一步利用行为克隆损失对 R3M 主干网络进行微调。虽然这种方法通过表征学习从无动作视频中捕获了先验知识，但其视觉表征缺乏对决策至关重要的转移动力学信息。
- VPT [170] 首先利用带动作标记的轨迹 T_a 训练一个逆向动力学模型，然后使用该模型为视频数据集预测伪动作标签，接着，通过这些伪标签采用行为克隆方法训练策略。该方法要求逆向动力学模型对输入观测的广泛分布具有较强的鲁棒性，而从有限的演示数据中学习这一特性是相当具有挑战性的。
- UniPi [145, 148, 166] 利用文本条件的视频扩散模型，从初始帧和语言指令中生成时间上细粒度的视频规划。在策略学习过程中，UniPi 则使用带动作标记的数据训练逆向动力学模型，并基于 Ko 等人[166] 中的 UniPi 实现。虽然 UniPi 和 DPT 都依赖于基于未来子目标条件的策略，但轨迹表征将运动信息与其他像素信息解耦，从而使得策略学习变得更为容易。

实验结果：本节在图5-5中展示了主要实验结果。可以看出，通过利用点轨迹

中国知网 https://www.cnki.net

这一结构化表征来衔接视频数据与策略学习，本章的方法显著超越了多种强基线的视频预训练方法。

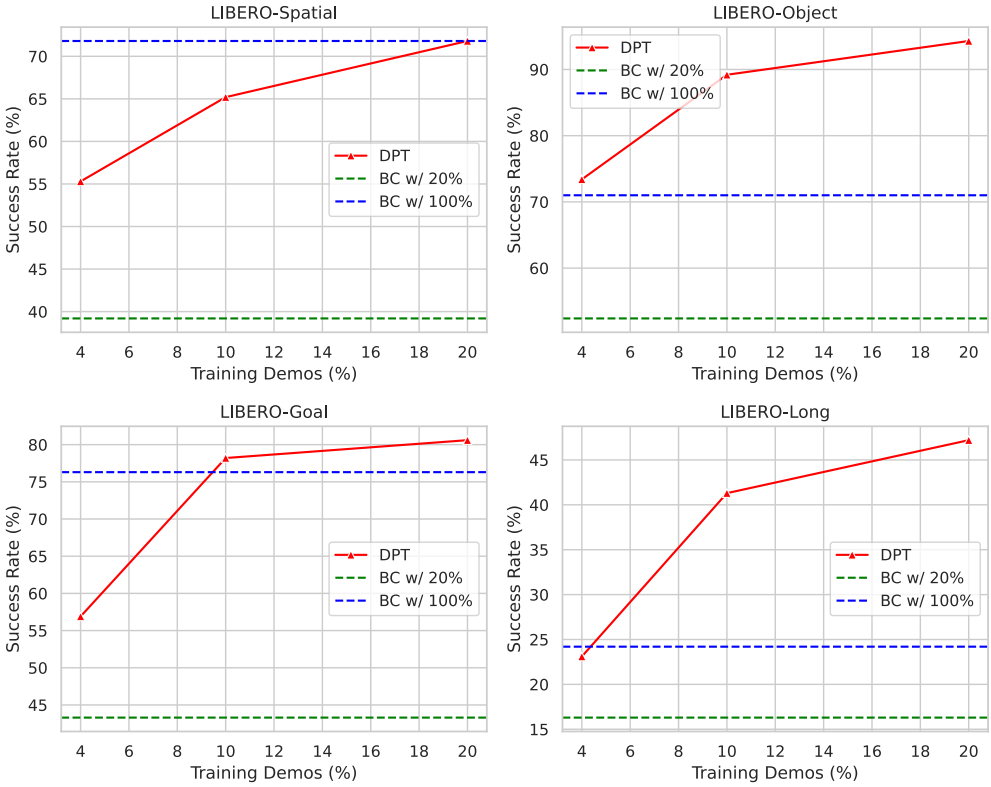


图 5-6 本章的方法在使用 4%、10% 和 20% 动作标注示例训练时的成功率表现。本章的方法在仅使用 4% 示例训练时，在 LIBERO-Spatial、LIBERO-Object 和 LIBERO-Goal 上的表现与使用 20% 示例训练的行为克隆（BC）基线相当，甚至在 LIBERO-Spatial 上表现更优。当使用 20% 示例训练时，本章的方法的性能接近使用全部训练数据的行为克隆方法。

BC 与 DPT 的对比表明，利用额外的视频数据能为策略学习提供有用的信息。实验证明，VPT 表现较差，因为其预测的伪动作标签在视频数据集上通常存在较大误差；而 UniPi 在处理更复杂的任务时也失败了，因为视频预测模型缺乏物理约束，常常生成不符合物理规律的未来帧，例如机器人在图像中消失的情况。令人惊讶的是，DPT 在长时程任务以及需要理解目标的任务上表现尤为出色，这种性能提升得益于 DPT 的设计：它利用明确的未来粒子轨迹作为子目标，在每个时间步，DPT 都会基于当前观测预测一个未来轨迹目标，与其他方法使用的整个任务过程中不变的静态自然语言指令相比，DPT 的闭环未来轨迹为策略接下来的行动提供了清晰的指导。

中国知网 https://www.cnki.net

5.4.2 消融实验分析

动作标记轨迹数量的影响：通过训练策略时使用不同长度（4、8、16、32 和 64 步）的预测轨迹，来研究轨迹长度对策略输入的影响。如图5-7所示，平均而言，16 步的轨迹长度能够获得最佳性能。较短的轨迹长度会显著降低性能，而轨迹长度为 0 则相当于将 DPT 简化为纯粹的行为克隆基线，完全失去了预训练的优势。另一方面，过长的轨迹长度也会对性能产生负面影响，尤其是在处理更具挑战性的任务（如 LIBERO-Long 和 LIBERO-Goal）时，因为较长的轨迹预测更容易受到噪声干扰，并且对于实现短时程子目标的指导意义较弱。

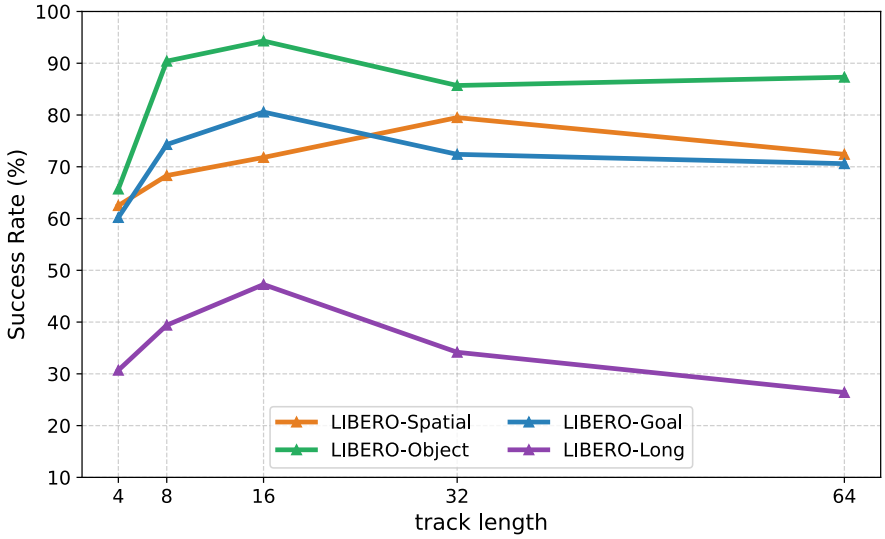


图 5-7 绘制了使用不同长度的预测轨迹训练的策略的成功率。总体而言，较长的轨迹长度可以提升性能，在长度超过 16 后，这种收益趋于平稳。

轨迹长度的影响：预训练的点轨迹扩散策略的轨迹长度为 16，默认情况下将每条轨迹的所有 16 个点作为策略输入。在本实验中，通过将预测轨迹截断为 4、8 和 16 步来训练策略，从而探究策略输入中轨迹长度的影响。图5-7的结果表明，通常情况下较长的轨迹能带来更高的成功率，但在 LIBERO-Object 任务中，轨迹长度为 8 时表现最佳。尤其是在 LIBERO-Goal 和 LIBERO-Long 任务中，缩短轨迹长度会导致显著的性能下降，因为这些任务需要对任务目标有全面深入的理解，而较长的轨迹能够为每个任务提供更详细、具体的子目标，这对指导智能体在后续阶段的运动和行动至关重要。相反，对于强调精确操作而非任务目标理解的 LIBERO-Object 任务，轨迹长度为 16 的策略表现略逊于轨迹长度为 8 的模型。推测较长的轨迹可能由于噪声干扰了逆向动力学的学习，这也支持了采用轨迹既作为子目标条件，又利用逆向动力学特性的策略。

中国知网 https://www.cnki.net

早期融合和晚期融合的影响：如图5-3所示，将预测轨迹在策略中的输入分为两部分：在 Transformer 架构之前的早期融合和之后的晚期融合。通过消融实验分别移除这两部分轨迹输入，结果如表5-3所示。从实验结果可以看出，去除晚期融合会导致最显著的性能下降；在 LIBERO-Goal 任务中，仅保留早期融合时的表现与其他基线方法相当，而仅保留晚期融合的表现仅略逊于完整方法。这表明，预测轨迹的晚期融合充当了有用的子目标，能帮助策略在多任务学习环境下更好地理解任务，并且由于子目标预测是在更大规模的视频数据集上进行训练的，因此其鲁棒性更高。

表 5-3 策略架构的消融研究。研究输入轨迹在策略中的两种融合方式对模型的影响：Transformer 输入（早期融合）和 MLP 头部（晚期融合）。

早期融合	晚期融合	Spatial	Object	Goal	Long
✔	✗	57.32 ± 1.84	56.67 ± 3.09	35.33 ± 2.37	42.53 ± 5.94
✗	✔	65.50 ± 3.89	74.36 ± 1.37	72.83 ± 4.73	42.76 ± 14.62
✔	✔	71.80 ± 1.28	94.30 ± 2.18	80.57 ± 0.76	47.26 ± 13.80

5.5 本章小结

在本章工作中提出了一种基于扩散模型的任意点轨迹建模框架，作为视频预训练方法，有效地从无动作视频数据集中学习行为和动态。相较于传统的使用扩散模型在图像像素级建模相比，对策略相关的轨迹建模不仅具有推理高效的优点，基于点轨迹的抽象表征方式更有助于策略学习。通过学习轨迹引导策略，本章工作相较于之前的最先进方法取得了显著改进，并展示了从分布外的人类视频中进行有效学习的能力。本章工作证明了基于点的表征不仅具有可解释性和结构性，还能自然地融合诸如物体持久性等物理归纳偏置。一个局限在于，本章的方法仍然依赖于一组带动作标记的演示轨迹来映射到具体动作，这在一定程度上限制了所学习策略的泛化能力。未来的工作可以考虑利用强化学习来训练轨迹跟随策略，从而不再需要额外的演示数据。另一个局限在于，本论文中使用的视频数据集仅包含较小的领域差异，而从野外视频数据中进行学习则面临额外的挑战，如多模态分布、多样的摄像机运动以及次优的动作表现。

中国知网 https://www.cnki.net

第六章 全文总结与展望

6.1 全文总结

扩散模型和强化学习结合有望解决智能体决策策略学习问题，使用强化学习进行智能体决策策略学习通常面临策略表征困难，时空不一致以及数据采样效率低下等问题，现有的方法直接使用扩散模型替换传统模型，在性能上去的了显著的性能提升，然而，扩散模型的固有的多步去噪过程反而限制了这类方法的使用，因为现实中的智能体决策通常需要应对实时的环境变化，否则低频的决策在实际部署时或许不如传统的决策方法。本文研究的主要内容是基于扩散模型的高效智能体决策，围绕解决扩散模型的引入引起的智能体决策效率低下问题进行研究，主要的研究思路是重新思考扩散模型在智能体决策中的结合方式，分别从策略学习，决策推理和数据表征三个维度进行研究，涵盖了扩散模型与智能体决策结合的主要三大方向，在策略学习方向，虽然扩散策略计算开销大，但具备高质量决策能力，使用扩散策略作为高级策略进行顶层规划，不仅减少扩散模型调用频率，还能对在线策略学习进行引导，使其策略学习高效；在决策推理方面，尤其解决使用扩散模型进行规划低效问题，发挥扩散模型的精细优化能力与快速自回归方式初始化结合，同时保证了规划的质量和推理高效；在数据表征方面，避免了传统的对图像像素级生成方法，使用扩散模型学习策略相关的抽象表示，显著减少扩散模型参数，并且抽象的数据表征有助于策略高效学习和推理。本文的工作总结如下：

1. 基本调研。本文首先阐述了智能体决策的研究背景与应用价值，并概括了该领域的发展流派：符号主义、连接主义与行为主义。本文重点调研了行为主义的发展历程，特别是近年来依托深度学习取得显著成效的强化学习方法，系统阐明了强化学习的核心思想和基本理论。同时，还介绍了扩散概率模型的快速发展历程，并展示了其与强化学习相结合的应用前景。上述论述为后文提出基于扩散模型的高效智能体决策方法提供了理论铺垫，突显了该方法的必要性和重要性。
2. 扩散模型的作为优化器以进行高效规划。首先研究扩散模型在智能体轨迹规划任务中的应用，通过一系列实验观察分析发现扩散模型应用于决策和规划时，可以被解耦为两部分，分别是初始化和优化，其中扩散模型的优化步骤可以被单独与其他方法结合，因此本文提出使用自回归方法进行轨迹初始化并结合扩散模型少量优化步骤对轨迹进行提升，从而保证了轨迹规划效率和质量。通过在 D4RL 和 Kitchen，Adroit 等环境进行实验，本章的方法在推理

中国知网 https://www.cnki.net

效率上与纯扩散模型相比高达 10 倍效率提升，与此同时，本章的方法通过引入自回归方法提供更好的初始化轨迹，使得优化后的轨迹质量提升。

3. 基于扩散策略引导高效策略学习。扩散策略具有多模态表征能力，能够更好的适应离线数据存在的策略多样性带来的挑战，然而，直接应用扩散模型进行低层规划会导致频繁的执行去噪过程，致使决策效率低下。本章利用扩散策略作为高级策略，利用其多分布建模能力从非专家无动作观测数据中学习先验知识，并引导低层策略学习。通过在稀疏奖励任务下的导航和操作环境进行实验，结果显示本章的方法通过鼓励低层策略进行有效探索，显著提升了策略学习效率，相比于其他在线学习方法，本章方法在长视距决策任务上表现突出，并且超越了使用完整离线数据学习并进行在线微调的方法。本章通过详细的消融实验分析了方法的特有性质，以及发现本章的方法对少量，覆盖不充分以及大量轨迹片段等受损数据上仍然具有良好的鲁棒性。
4. 扩散点轨迹增强的高效策略学习方法。本文探索了使用扩散模型进行数据增强的应用，传统的方法通过学习图像空间数据分布并直接在图像空间进行像素级采样，使得采样结果存在时空不一致以及采样效率底下问题，本文使用扩散模型学习与策略相关性更高的抽象表示，具体实现为点轨迹，首先使用现有的点跟踪方法从视频数据中提取点转移轨迹，这种数据抽象更能够保持与策略相关信息，摒弃掉冗余信息。扩散策略基于当前图像观测和指令生成未来点轨迹，策略网络通过引入未来点轨迹指导当前决策，由于该轨迹具有强策略相关，显著提升了决策能力。在 LIBERO 基准测试的 100 多个语言条件下的操控任务中，与基线方法进行比较。实验结果显示本章的方法取得了 80% 性能提升，尤其是在长程任务表现更为明显，反应出扩散模型学到的抽象数据表征方式能够显著增强策略决策。

6.2 后续工作展望

扩散模型与智能体决策的融合展现出巨大的潜力，吸引了广泛的研究关注。现有方法多侧重于提升决策质量，而在实际应用中，决策效率同样不可忽视。尽管本文基于扩散模型在策略学习、决策推理和数据表征三个层面提出了新的应用方案，但该领域仍存在诸多亟待改进的问题。未来的研究可从以下几个方向展开更深入的探索和优化：

1. 面向图像观测的扩散规划。目前智能体决策任务中，环境状态往往通过图像获得，这种观测方式具有一定的偏差且难以直接映射为精确状态信息。现有的扩散规划方法在处理图像观测时难以实现有效分解，未来研究应致力于开

中国知网 https://www.cnki.net

发针对图像数据的专门模型，如通过设计特定的图像到潜在空间的映射机制，或结合视觉注意力机制，以提升规划过程中的状态估计精度和实时响应能力。

2. 域外知识迁移。当前基于扩散策略的策略引导方法主要依赖于域内数据，导致在不同环境下均需重新采集数据进行训练。未来的研究可充分发挥扩散模型的多模态建模能力，探索跨域知识迁移技术。通过构建共享表示或利用无监督领域适应方法，使得模型能够有效提取并利用域外知识，从而降低数据采集成本，增强系统的泛化能力和适应性。
3. 更全面的数据表征方式。本文提出的基于点轨迹的数据抽象方法虽能提取策略相关信息，但在实际应用中容易忽略如机械臂几何结构等关键环境信息，导致只能实现较为粗略的控制。未来研究可考虑将数据表征拓展至包含更丰富几何信息的光流表示，甚至结合点轨迹、光流与图像多种数据形式，构建更为全面的环境描述模型。这样的多维数据融合不仅有助于捕捉精细的运动特征，还能为策略学习提供更高质量的输入，从而进一步提高决策的精度和效率。

中国知网 https://www.cnki.net

参考文献

[1] Sutton R S. Learning to predict by the methods of temporal differences[J]. Machine learning, 1988, 3: 9-44.

[2] Kober J, Bagnell J A, Peters J. Reinforcement learning in robotics: A survey[J]. The International Journal of Robotics Research, 2013, 32(11): 1238-1274.

[3] Kiran B R, Sobh I, Talpaert V, et al. Deep reinforcement learning for autonomous driving: A survey[J]. IEEE transactions on intelligent transportation systems, 2021, 23(6): 4909-4926.

[4] Kumar A, Zhou A, Tucker G, et al. Conservative q-learning for offline reinforcement learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 1179-1191.

[5] Fujimoto S, Gu S S. A minimalist approach to offline reinforcement learning[J]. Advances in neural information processing systems, 2021, 34: 20132-20145.

[6] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning[J]. arXiv preprint arXiv:1312.5602, 2013.

[7] Nagabandi A, Kahn G, Fearing R S, et al. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning[C]. 2018 IEEE international conference on robotics and automation (ICRA), 2018: 7559-7566.

[8] Schrittwieser J, Antonoglou I, Hubert T, et al. Mastering atari, go, chess and shogi by planning with a learned model[J]. Nature, 2020, 588(7839): 604-609.

[9] Zhu M, Liu M, Shen J, et al. Mapgo: Model-assisted policy optimization for goal-oriented tasks[J]. arXiv preprint arXiv:2105.06350, 2021.

[10] Xiao C, Wu Y, Ma C, et al. Learning to combat compounding-error in model-based reinforcement learning[J]. arXiv preprint arXiv:1912.11206, 2019.

[11] Dhariwal P, Nichol A. Diffusion models beat gans on image synthesis[J]. Advances in neural information processing systems, 2021, 34: 8780-8794.

[12] Kingma D P, Welling M. Auto-encoding variational bayes[J]. arXiv preprint arXiv:1312.6114, 2013.

[13] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.

[14] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[J]. Advances in neural information processing systems, 2020, 33: 6840-6851.

中国知网 https://www.cnki.net

[15] Lugmayr A, Danelljan M, Romero A, et al. Repaint: Inpainting using denoising diffusion probabilistic models[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 11461-11471.

[16] Luo S, Hu W. Diffusion probabilistic models for 3d point cloud generation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 2837-2845.

[17] Austin J, Johnson D D, Ho J, et al. Structured denoising diffusion models in discrete state-spaces[J]. Advances in Neural Information Processing Systems, 2021, 34: 17981-17993.

[18] Li X, Thickstun J, Gulrajani I, et al. Diffusion-lm improves controllable text generation[J]. Advances in Neural Information Processing Systems, 2022, 35: 4328-4343.

[19] Lee J, Han S. Nu-wave: A diffusion probabilistic model for neural audio upsampling[J]. arXiv preprint arXiv:2104.02321, 2021.

[20] Kong Z, Ping W, Huang J, et al. Diffwave: A versatile diffusion model for audio synthesis[J]. arXiv preprint arXiv:2009.09761, 2020.

[21] Xu M, Yu L, Song Y, et al. Geodiff: A geometric diffusion model for molecular conformation generation[J]. arXiv preprint arXiv:2203.02923, 2022.

[22] Schneuing A, Du Y, Harris C, et al. Structure-based drug design with dvariant diffusion models[J]. arXiv preprint arXiv:2210.13695, 2022.

[23] Janner M, Du Y, Tenenbaum J B, et al. Planning with diffusion for flexible behavior synthesis[C]. International Conference on Machine Learning, 2022.

[24] Wang Z, Hunt J J, Zhou M. Diffusion policies as an expressive policy class for offline reinforcement learning[C]. The Eleventh International Conference on Learning Representations, 2023.

[25] Lu C, Ball P J, Parker-Holder J. Synthetic experience replay[C]. Workshop on Reincarnating Reinforcement Learning at ICLR 2023, 2023.

[26] Song J, Meng C, Ermon S. Denoising diffusion implicit models[J]. arXiv preprint arXiv:2010.02502, 2020.

[27] Luo W. A comprehensive survey on knowledge distillation of diffusion models[J]. arXiv preprint arXiv:2304.04262, 2023.

[28] Newborn M, Newborn M. Deep blue: an artificial intelligence milestone[M]. Springer Science & Business Media, 2003.

[29] Silver D, Huang A, Maddison C J, et al. Mastering the game of go with deep neural networks and tree search[J]. nature, 2016, 529(7587): 484-489.

中国知网 https://www.cnki.net

[30] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.

[31] Browne C B, Powley E, Whitehouse D, et al. A survey of monte carlo tree search methods[J]. IEEE Transactions on Computational Intelligence and AI in games, 2012, 4(1): 1-43.

[32] Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with alphafold[J]. nature, 2021, 596(7873): 583-589.

[33] Andrychowicz O M, Baker B, Chociej M, et al. Learning dexterous in-hand manipulation[J]. The International Journal of Robotics Research, 2020, 39(1): 3-20.

[34] Vinyals O, Babuschkin I, Czarnecki W M, et al. Grandmaster level in starcraft ii using multi-agent reinforcement learning[J]. nature, 2019, 575(7782): 350-354.

[35] Bellman R. Dynamic programming[J]. science, 1966, 153(3731): 34-37.

[36] Puterman M L. Markov decision processes: discrete stochastic dynamic programming[M]. John Wiley & Sons, 2014.

[37] Thorndike E L. Animal intelligence: An experimental study of the associative processes in animals[J]. The Psychological Review: Monograph Supplements, 1898, 2(4): 1.

[38] Minsky M. Steps toward artificial intelligence[J]. Proceedings of the IRE, 1961, 49(1): 8-30.

[39] Fu K. Sequential methods in pattern recognition and machine learning[M]. Academic press, 1968.

[40] Klopf A H. A drive-reinforcement model of single neuron function: An alternative to the hebbian neuronal model[C]. AIP Conference Proceedings, 1986: 265-270.

[41] Klopf A H. Brain function and adaptive systems: a heterostatic theory[M]. Air Force Cambridge Research Laboratories, Air Force Systems Command, United States Air Force, 1972.

[42] Sutton R S, Barto A G. Toward a modern theory of adaptive networks: expectation and prediction[J]. Psychological review, 1981, 88(2): 135.

[43] Samuel A L. Some studies in machine learning using the game of checkers[J]. IBM Journal of research and development, 1959, 3(3): 210-229.

[44] Adel'son-Vel'skii G M, Arlazarov V L, Bitman A, et al. Programming a computer to play chess[J]. Russian Mathematical Surveys, 1970, 25(2): 221.

[45] Witten I H. An adaptive optimal controller for discrete-time markov environments[J]. Information and control, 1977, 34(4): 286-295.

[46] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.

中国知网 https://www.cnki.net

[47] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:1509.02971, 2015.

[48] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. nature, 2015, 518(7540): 529-533.

[49] Sutton R S, McAllester D, Singh S, et al. Policy gradient methods for reinforcement learning with function approximation[J]. Advances in neural information processing systems, 1999, 12.

[50] Crites R, Barto A. Improving elevator performance using reinforcement learning[J]. Advances in neural information processing systems, 1995, 8.

[51] Kakade S M. A natural policy gradient[J]. Advances in neural information processing systems, 2001, 14.

[52] Schulman J, Moritz P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[J]. arXiv preprint arXiv:1506.02438, 2015.

[53] Sun P, Kretzschmar H, Dotiwalla X, et al. Scalability in perception for autonomous driving: Waymo open dataset[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2020: 2446-2454.

[54] Gu S, Holly E, Lillicrap T, et al. Deep reinforcement learning for robotic manipulation with asynchronous off-policy updates[C]. 2017 IEEE international conference on robotics and automation (ICRA), 2017: 3389-3396.

[55] Lee J, Hwangbo J, Wellhausen L, et al. Learning quadrupedal locomotion over challenging terrain[J]. Science robotics, 2020, 5(47): eabc5986.

[56] Cai P, Hsu D. Closing the planning learning loop with application to autonomous driving[J]. IEEE Transactions on Robotics, 2022, 39(2): 998-1011.

[57] Janner M, Du Y, Tenenbaum J B, et al. Planning with diffusion for flexible behavior synthesis[J]. arXiv preprint arXiv:2205.09991, 2022.

[58] Wang Z, Hunt J J, Zhou M. Diffusion policies as an expressive policy class for offline reinforcement learning[J]. arXiv preprint arXiv:2208.06193, 2022.

[59] Laskin M, Lee K, Stooke A, et al. Reinforcement learning with augmented data[J]. Advances in neural information processing systems, 2020, 33: 19884-19895.

[60] Trabucco B, Doherty K, Gurinas M, et al. Effective data augmentation with diffusion models[J]. arXiv preprint arXiv:2302.07944, 2023.

中国知网 https://www.cnki.net

[61] He H, Bai C, Xu K, et al. Diffusion model is an effective planner and data synthesizer for multi-task reinforcement learning[J]. Advances in neural information processing systems, 2023, 36: 64896-64917.

[62] Reed S, Zolna K, Parisotto E, et al. A generalist agent[J]. arXiv preprint arXiv:2205.06175, 2022.

[63] Huang R, Pei Y, Wang G, et al. Diffusion models as optimizers for efficient planning in offline rl[C]. European Conference on Computer Vision, 2024: 1-17.

[64] Huang R, Liu S, Pei Y, et al. Goal-reaching policy learning from non-expert observations via effective subgoal guidance[C]. 8th Annual Conference on Robot Learning, 2024.

[65] Warren B Powell W, Hardback. Reinforcement learning and stochastic optimization: A unified framework for sequential decisions[M]. Taylor & Francis, 2022.

[66] Kaelbling L P, Littman M L, Cassandra A R. Planning and acting in partially observable stochastic domains[J]. Artificial intelligence, 1998, 101(1-2): 99-134.

[67] Bertsekas D. Reinforcement learning and optimal control[M]. Athena Scientific, 2019.

[68] Jaakkola T, Singh S, Jordan M. Reinforcement learning algorithm for partially observable markov decision problems[J]. Advances in neural information processing systems, 1994, 7.

[69] Ren A Z, Lidard J, Ankile L L, et al. Diffusion policy policy optimization[J]. arXiv preprint arXiv:2409.00588, 2024.

[70] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]. International conference on machine learning, 2018: 1861-1870.

[71] Christodoulou P. Soft actor-critic for discrete action settings[J]. arXiv preprint arXiv:1910.07207, 2019.

[72] Tsividis P, Pouncy T, Xu J L, et al. Human learning in atari[C]. AAAI Spring Symposia, 2017.

[73] Zhu H, Huang B, Russell S. On representation complexity of model-based and model-free reinforcement learning[J]. arXiv preprint arXiv:2310.01706, 2023.

[74] Rawlings J B, Mayne D Q, Diehl M, et al. Model predictive control: theory, computation, and design[M]. Nob Hill Publishing Madison, WI, 2017.

[75] Kouvaritakis B, Cannon M. Model predictive control[J]. Switzerland: Springer International Publishing, 2016, 38(13-56): 7.

[76] Mayne D Q, Michalska H. Receding horizon control of nonlinear systems[C]. Proceedings of the 27th IEEE Conference on Decision and Control, 1988: 464-465.

中国知网 https://www.cnki.net

[77] Song Y, Sohl-Dickstein J, Kingma D P, et al. Score-based generative modeling through stochastic differential equations[C]. International Conference on Learning Representations, 2020.

[78] Ho J, Salimans T. Classifier-free diffusion guidance[J]. arXiv preprint arXiv:2207.12598, 2022.

[79] Levine S, Kumar A, Tucker G, et al. Offline reinforcement learning: Tutorial, review[J]. and Perspectives on Open Problems, 2020, 5.

[80] Saharia C, Chan W, Saxena S, et al. Photorealistic text-to-image diffusion models with deep language understanding[J]. Advances in Neural Information Processing Systems, 2022, 35: 36479-36494.

[81] Nichol A, Dhariwal P, Ramesh A, et al. Glide: Towards photorealistic image generation and editing with text-guided diffusion models[J]. arXiv preprint arXiv:2112.10741, 2021.

[82] Nichol A Q, Dhariwal P. Improved denoising diffusion probabilistic models[C]. International Conference on Machine Learning, 2021: 8162-8171.

[83] Ramesh A, Dhariwal P, Nichol A, et al. Hierarchical text-conditional image generation with clip latents[J]. arXiv preprint arXiv:2204.06125, 2022, 1(2): 3.

[84] Ajay A, Du Y, Gupta A, et al. Is conditional generative modeling all you need for decision-making?[J]. arXiv preprint arXiv:2211.15657, 2022.

[85] Liang Z, Mu Y, Ding M, et al. Adaptdiffuser: Diffusion models as adaptive self-evolving planners[J]. arXiv preprint arXiv:2302.01877, 2023.

[86] Ni F, Hao J, Mu Y, et al. Metadiffuser: Diffusion model as conditional planner for offline meta-rl[J]. arXiv preprint arXiv:2305.19923, 2023.

[87] Chen L, Lu K, Rajeswaran A, et al. Decision transformer: Reinforcement learning via sequence modeling[J]. Advances in neural information processing systems, 2021, 34: 15084-15097.

[88] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[89] Fujimoto S, Hoof H, Meger D. Addressing function approximation error in actor-critic methods[C]. International conference on machine learning, 2018: 1587-1596.

[90] Sohn K, Lee H, Yan X. Learning structured output representation using deep conditional generative models[J]. Advances in neural information processing systems, 2015, 28.

[91] Kumar A, Fu J, Soh M, et al. Stabilizing off-policy q-learning via bootstrapping error reduction[J]. Advances in Neural Information Processing Systems, 2019, 32.

[92] Agrawal P, Nair A V, Abbeel P, et al. Learning to poke by poking: Experiential learning of intuitive physics[J]. Advances in neural information processing systems, 2016, 29.

中国知网 https://www.cnki.net

[93] Pathak D, Mahmoudieh P, Luo G, et al. Zero-shot visual imitation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition workshops, 2018: 2050-2053.

[94] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners[J]. OpenAI blog, 2019, 1(8): 9.

[95] Fu J, Kumar A, Nachum O, et al. D4rl: Datasets for deep data-driven reinforcement learning[J]. arXiv preprint arXiv:2004.07219, 2020.

[96] Janner M, Li Q, Levine S. Offline reinforcement learning as one big sequence modeling problem[J]. Advances in neural information processing systems, 2021, 34: 1273-1286.

[97] Wu Y, Tucker G, Nachum O. Behavior regularized offline reinforcement learning[J]. arXiv preprint arXiv:1911.11361, 2019.

[98] Kostrikov I, Fergus R, Tompson J, et al. Offline reinforcement learning with fisher divergence critic regularization[C]. International Conference on Machine Learning, 2021: 5774-5783.

[99] Kidambi R, Rajeswaran A, Netrapalli P, et al. Morel: Model-based offline reinforcement learning[J]. Advances in neural information processing systems, 2020, 33: 21810-21823.

[100] Fujimoto S, Meger D, Precup D. Off-policy deep reinforcement learning without exploration[C]. International conference on machine learning, 2019: 2052-2062.

[101] Chung J, Gulcehre C, Cho K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[J]. arXiv preprint arXiv:1412.3555, 2014.

[102] Shi X, Chen Z, Wang H, et al. Convolutional lstm network: A machine learning approach for precipitation nowcasting[J]. Advances in neural information processing systems, 2015, 28.

[103] Kaelbling L P. Learning to achieve goals[C]. IJCAI, 1993: 1094-1098.

[104] Schaul T, Horgan D, Gregor K, et al. Universal value function approximators[C]. International conference on machine learning, 2015: 1312-1320.

[105] Pathak D, Agrawal P, Efros A A, et al. Curiosity-driven exploration by self-supervised prediction[C]. International conference on machine learning, 2017: 2778-2787.

[106] Burda Y, Edwards H, Storkey A, et al. Exploration by random network distillation[C]. Seventh International Conference on Learning Representations, 2019: 1-17.

[107] Lin T, Jabri A. Mimex: Intrinsic rewards from masked input modeling[J]. Advances in Neural Information Processing Systems, 2024, 36.

[108] Li Q, Zhang J, Ghosh D, et al. Accelerating exploration with unlabeled prior data[J]. Advances in Neural Information Processing Systems, 2024, 36.

中国知网 https://www.cnki.net

[109] Pertsch K, Rybkin O, Ebert F, et al. Long-horizon visual planning with goal-conditioned hierarchical predictors[J]. Advances in Neural Information Processing Systems, 2020, 33: 17321-17333.

[110] Zhang H, Xu W, Yu H. Policy expansion for bridging offline-to-online reinforcement learning[C]. The Eleventh International Conference on Learning Representations, 2022.

[111] Nakamoto M, Zhai S, Singh A, et al. Cal-ql: Calibrated offline rl pre-training for efficient online fine-tuning[J]. Advances in Neural Information Processing Systems, 2024, 36.

[112] Nair A, Gupta A, Dalal M, et al. Awac: Accelerating online reinforcement learning with offline datasets[J]. arXiv preprint arXiv:2006.09359, 2020.

[113] Park S, Ghosh D, Eysenbach B, et al. Hiql: Offline goal-conditioned rl with latent states as actions[J]. Advances in Neural Information Processing Systems, 2024, 36.

[114] Konda V, Tsitsiklis J. Actor-critic algorithms[J]. Advances in neural information processing systems, 1999, 12.

[115] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. MIT press, 2018.

[116] Ghosh D, Bhateja C A, Levine S. Reinforcement learning from passive data via latent intentions[C]. International Conference on Machine Learning, 2023: 11321-11339.

[117] Xu H, Jiang L, Jianxiong L, et al. A policy-guided imitation approach for offline reinforcement learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 4085-4098.

[118] Chi C, Feng S, Du Y, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[C]. arXiv preprint arXiv:2303.04137, Daegu, Republic of Korea, 2023.

[119] Peng X B, Kumar A, Zhang G, et al. Advantage-weighted regression: Simple and scalable off-policy reinforcement learning[J]. arXiv preprint arXiv:1910.00177, 2019.

[120] Neumann G, Peters J. Fitted q-iteration by advantage weighted regression[J]. Advances in neural information processing systems, 2008, 21.

[121] Yang R, Lu Y, Li W, et al. Rethinking goal-conditioned supervised learning and its connection to offline rl[C]. ICLR 2022-10th International Conference on Learning Representations, 2022.

[122] Xiao Z, Kreis K, Vahdat A. Tackling the generative learning trilemma with denoising diffusion gans[C]. International Conference on Learning Representations, 2021.

[123] Gupta A, Kumar V, Lynch C, et al. Relay policy learning: Solving long-horizon tasks via imitation and reinforcement learning[C]. Conference on Robot Learning, 2020: 1025-1037.

[124] Mnih V, Badia A P, Mirza M, et al. Asynchronous methods for deep reinforcement learning[C]. International conference on machine learning, 2016: 1928-1937.

中国知网 https://www.cnki.net

[125] Kim D, Shin J, Abbeel P, et al. Accelerating reinforcement learning with value-conditional state entropy exploration[J]. Advances in Neural Information Processing Systems, 2024, 36.

[126] Wu Z, Lu H, Xing J, et al. Pae: Reinforcement learning from external knowledge for efficient exploration[C]. The Twelfth International Conference on Learning Representations, 2023.

[127] Bruce J, Anand A, Mazoure B, et al. Learning about progress from experts[C]. The Eleventh International Conference on Learning Representations, 2022.

[128] Mazoure B, Bruce J, Precup D, et al. Accelerating exploration and representation learning with offline pre-training[J]. arXiv preprint arXiv:2304.00046, 2023.

[129] Yang R, Lu Y, Li W, et al. Rethinking goal-conditioned supervised learning and its connection to offline rl[C]. International Conference on Learning Representations, 2021.

[130] Plappert M, Andrychowicz M, Ray A, et al. Multi-goal reinforcement learning: Challenging robotics environments and request for research[J]. arXiv preprint arXiv:1802.09464, 2018.

[131] Mees O, Hermann L, Rosete-Beas E, et al. Calvin: A benchmark for language-conditioned policy learning for long-horizon robot manipulation tasks[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334.

[132] Zhang T, Janner M, Li Y, et al. Efficient planning in a compact latent action space[C]. The Eleventh International Conference on Learning Representations, 2022.

[133] Shi L X, Lim J J, Lee Y. Skill-based model-based reinforcement learning[C]. Conference on Robot Learning, 2023: 2262-2272.

[134] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.

[135] Hendrycks D, Gimpel K. Gaussian error linear units (gelus)[J]. arXiv preprint arXiv:1606.08415, 2016.

[136] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.

[137] Andrychowicz M, Wolski F, Ray A, et al. Hindsight experience replay[J]. Advances in neural information processing systems, 2017, 30.

[138] Ghosh D, Gupta A, Reddy A, et al. Learning to reach goals via iterated supervised learning[C]. 9th International Conference on Learning Representations, ICLR 2021, 2021.

[139] Chane-Sane E, Schmid C, Laptev I. Goal-conditioned reinforcement learning with imagined subgoals[C]. International Conference on Machine Learning, 2021: 1430-1440.

[140] Wu J, Wu H, Qiu Z, et al. Supported policy optimization for offline reinforcement learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 31278-31291.

中国知网 https://www.cnki.net

[141] Ball P J, Smith L, Kostrikov I, et al. Efficient online reinforcement learning with offline data[C]. International Conference on Machine Learning, 2023: 1577-1594.

[142] Sermanet P, Lynch C, Chebotar Y, et al. Time-contrastive networks: Self-supervised learning from video[C]. 2018 IEEE international conference on robotics and automation (ICRA), 2018: 1134-1141.

[143] Nair S, Rajeswaran A, Kumar V, et al. R3m: A universal visual representation for robot manipulation[C]. Conference on Robot Learning, 2023: 892-909.

[144] Seo Y, Lee K, James S L, et al. Reinforcement learning with action-free pre-training from videos[C]. International Conference on Machine Learning, 2022: 19561-19579.

[145] Du Y, Yang S, Dai B, et al. Learning universal policies via text-guided video generation[C]. Thirty-seventh Conference on Neural Information Processing Systems, 2023.

[146] Yang M, Du Y, Ghasemipour K, et al. Learning interactive real-world simulators[J]. arXiv preprint arXiv:2310.06114, 2023.

[147] Escontrela A, Adeniji A, Yan W, et al. Video prediction models as rewards for reinforcement learning[J]. Advances in Neural Information Processing Systems, 2023, 36: 68760-68783.

[148] Black K, Nakamoto M, Atreya P, et al. Zero-shot robotic manipulation with pretrained image-editing diffusion models[J]. arXiv preprint arXiv:2310.10639, 2023.

[149] Brohan A, Brown N, Carbajal J, et al. Rt-1: Robotics transformer for real-world control at scale[J]. arXiv preprint arXiv:2212.06817, 2022.

[150] Walke H R, Black K, Zhao T Z, et al. Bridgedata v2: A dataset for robot learning at scale[C]. Conference on Robot Learning, 2023: 1723-1736.

[151] Li Y, Li S, Sitzmann V, et al. 3d neural scene representations for visuomotor control[J]. arXiv preprint arXiv:2107.04004, 2021.

[152] Rashid A, Sharma S, Kim C M, et al. Language embedded radiance fields for zero-shot task-oriented grasping[C]. Conference on Robot Learning, 2023: 178-200.

[153] Qin Z, Fang K, Zhu Y, et al. Keto: Learning keypoint representations for tool manipulation[C]. 2020 IEEE International Conference on Robotics and Automation (ICRA), 2020: 7278-7285.

[154] Manuelli L, Li Y, Florence P, et al. Keypoints into the future: Self-supervised correspondence in model-based reinforcement learning[J]. arXiv preprint arXiv:2009.05085, 2020.

[155] Goyal A, Mousavian A, Paxton C, et al. Ifor: Iterative flow minimization for robotic object rearrangement[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022: 14787-14797.

中国知网 https://www.cnki.net

[156] Seita D, Wang Y, Shetty S J, et al. Toolflownet: Robotic manipulation with tools via predicting tool flow from point clouds[C]. Conference on Robot Learning, 2023: 1038-1049.

[157] Gu J, Kirmani S, Wohlhart P, et al. Rt-trajectory: Robotic task generalization via hindsight trajectory sketches[J]. arXiv preprint arXiv:2311.01977, 2023.

[158] Vecerik M, Doersch C, Yang Y, et al. Robotap: Tracking arbitrary points for few-shot visual imitation[J]. arXiv, 2023.

[159] Harley A W, Fang Z, Fragkiadaki K. Particle video revisited: Tracking through occlusions using point trajectories[C]. European Conference on Computer Vision, 2022: 59-75.

[160] Doersch C, Gupta A, Markeeva L, et al. Tap-vid: A benchmark for tracking any point in a video[J]. Advances in Neural Information Processing Systems, 2022, 35: 13610-13626.

[161] Doersch C, Yang Y, Vecerik M, et al. Tapir: Tracking any point with per-frame initialization and temporal refinement[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 10061-10072.

[162] Wang Q, Chang Y Y, Cai R, et al. Tracking everything everywhere all at once[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 19795-19806.

[163] Zheng Y, Harley A W, Shen B, et al. Pointodyssey: A large-scale synthetic dataset for long-term point tracking[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, 2023: 19855-19865.

[164] Karaev N, Rocco I, Graham B, et al. Cotracker: It is better to track together[J]. arXiv:2307.07635, 2023.

[165] Ma Y J, Sodhani S, Jayaraman D, et al. VIP: Towards universal visual reward and representation via value-implicit pre-training[C]. The Eleventh International Conference on Learning Representations, 2023.

[166] Ko P C, Mao J, Du Y, et al. Learning to Act from Actionless Video through Dense Correspondences[J]. arXiv:2310.08576, 2023.

[167] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), Minneapolis, Minnesota, 2019: 4171-4186.

[168] Liu B, Zhu Y, Gao C, et al. Libero: Benchmarking knowledge transfer for lifelong robot learning[C]. Thirty-seventh Conference on Neural Information Processing Systems Datasets and Benchmarks Track, 2023.

中国知网 https://www.cnki.net

[169] Kim W, Son B, Kim I. Vilt: Vision-and-language transformer without convolution or region supervision[C]. International conference on machine learning, 2021: 5583-5594.

[170] Baker B, Akkaya I, Zhokov P, et al. Video pretraining (vpt): Learning to act by watching unlabeled online videos[J]. Advances in Neural Information Processing Systems, 2022, 35: 24639-24654.

中国知网 https://www.cnki.net