分类号：TP391　　密　　级：公开
U D C：　　单位代码：10142

沈阳工业大学

硕士学位论文

基于改进深度强化学习的机械臂轨迹规划

学　　号：202010661
作　　者：经翔宇
论 文 类 型：控制科学与工程

2023 年 06 月 12 日

中国知网　https://www.cnki.net

沈阳工业大学硕士学位论文

基于改进深度强化学习的机械臂轨迹规划

Trajectory Planning of Manipulator based on Improved Reinforcement Learning

作　　者：经翔宇　　单位：人工智能学院

指 导 教 师：臧传治 教授　　单位：沈阳工业大学

协助指导教师：邹菲 讲师　　单位：沈阳工业大学

论文答辩日期：2023 年 05 月 29 日

学位授予单位：沈 阳 工 业 大 学

中国知网 https://www.cnki.net

摘要

机械臂工作的环境复杂多变，如何在其工作的空间内快速、高效、可靠地规划出一条避障轨迹，是机械臂轨迹规划的关键点。传统的机械臂轨迹规划方法需先根据物理学原理建立机械臂、障碍物和目标物之间的轨迹方程，然后通过数值方法确定运行轨迹，模型效率低。针对此问题，本文研究了基于改进深度强化学习的机械臂轨迹规划方法，此方法无需建立复杂的轨迹方程，通过与环境的交互来处理传统方法无法解决的复杂关系。具体研究内容如下：

针对静态障碍物，研究了基于传统二值奖励函数、距离引导奖励函数和静态避障奖励函数相结合的深度确定性策略梯度算法的机械臂轨迹规划方法。针对机械臂仅在传统二值奖励函数下因盲目探索而无法快速到达目标物位置的问题，设计了距离引导奖励函数，包括负距离奖励、分区奖励、距离对比奖励；针对机械臂在传统二值奖励函数和距离引导奖励函数下不能适应静态障碍物环境的问题，设计了静态避障奖励函数。仿真结果表明在传统二值奖励函数的基础上增加距离引导奖励函数能加快奖励值的收敛速度，进而加快了机械臂到达目标物位置的速度，并且机械臂成功地避开了静态障碍物。

考虑到机械臂在实际的工作环境中有突发障碍物的风险，研究了基于动态避障奖励函数、动态分区奖励函数相结合的深度确定性策略梯度算法的机械臂轨迹规划方法。针对机械臂仅在静态障碍物的奖励函数下不能适应动态障碍物环境的问题，设计了动态避障奖励函数；针对机械臂在动态障碍物场景下因盲目探索而无法快速避开动态障碍物的问题，设计了动态分区奖励函数。仿真结果表明在动态避障奖励函数的基础上增加动态分区奖励函数能加快奖励值的收敛速度，进而加快了机械臂避开动态障碍物的速度，并且机械臂成功地避开了静态障碍物和动态障碍物。

关键词：机械臂轨迹规划，深度强化学习，距离引导奖励函数，动态分区奖励函数

中国知网 https://www.cnki.net

Abstract

The working environment of the manipulator is complex and changeable, and the method of planning the trajectory to avoid the obstacle within its working space quickly, efficiently, and reliably is the key point of the trajectory planning of the manipulator. The traditional method of planning the trajectory of the manipulator requires establishing equations for the trajectory between the manipulator, the obstacle, and the target based on physical principles and then determining the operating trajectory through numerical methods. The model has low efficiency. In response to this issue, this thesis researches the trajectory planning method of the manipulator based on improved deep reinforcement learning. This method does not require the establishment of complex equations for the trajectory and handles complex relationships that cannot be solved by traditional methods through the interaction with the environment. The specific research contents are as follows:

For the static object, the trajectory planning method of the manipulator based on the deep deterministic policy gradient algorithm is researched, which combines the traditional binary reward function, the distance-guided reward function, and the reward function to avoid static obstacles. The distance-guided reward function is designed to solve the problem of the manipulator being unable to quickly reach the target position due to blind exploration under the traditional binary reward function, including the negative-distance reward, the zone reward, and the distance-comparison reward; the reward function to avoid static obstacles is designed to solve the problem of the manipulator being unable to adapt to the environment of static obstacles under both the traditional binary reward function and the distance-guided reward function. The simulation results show that adding the distance-guided reward function to the traditional binary reward function can accelerate the convergence speed of the reward value, thereby accelerating the speed of the manipulator reaching the target position, and the manipulator successfully avoids static obstacles.

Considering the risk of the sudden obstacle in the actual working environment of the manipulator, the trajectory planning method of the manipulator based on the deep deterministic policy gradient algorithm is researched, which combines the reward function to avoid the dynamic obstacle with the dynamic-partition reward function. The reward function to avoid the dynamic obstacle is designed to solve the problem of the manipulator being unable to adapt to the environment of the dynamic obstacle with the reward function in the environment of static

中国知网 https://www.cnki.net

object; the dynamic-partition reward function is designed to solve the problem of the manipulator being unable to quickly avoid the dynamic obstacle due to blind exploration in the scene of the dynamic obstacle . The simulation results show that adding the dynamic-partition reward function based on the reward function to avoid the dynamic obstacle can accelerate the convergence speed of the reward value, thereby accelerating the speed of the manipulator avoiding the dynamic obstacle, and the manipulator successfully avoids static obstacles and the dynamic obstacle.

Key Words: Trajectory Planning of the Manipulator, Deep Reinforcement Learning, Distance-guided Reward Function, Dynamic-partition Reward Function

中国知网 https://www.cnki.net

目 录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 机械臂的研究现状.....2
1.2.2 传统算法的研究现状.....3
1.2.3 强化学习算法的研究现状.....5
1.3 本文主要工作.....5
1.4 本文结构安排.....6
第 2 章 相关理论概述.....8
2.1 机械臂模型.....8
2.1.1 机械臂的运动学模型.....8
2.1.2 机械臂的动力学模型.....9
2.2 深度强化学习简述.....10
2.3 深度强化学习算法.....13
2.4 本章小结.....17
第 3 章 静态障碍物场景下的机械臂轨迹规划.....18
3.1 机械臂轨迹规划概述.....18
3.2 静态障碍物场景下的奖励函数改进.....18
3.3 静态障碍物场景.....20
3.4 静态障碍物场景下的实验设计.....22
3.4.1 实验方案.....22
3.4.2 实验结果.....23
3.5 静态障碍物场景下的机械臂轨迹.....26
3.6 本章小结.....28
第 4 章 动态障碍物场景下的机械臂轨迹规划.....30
4.1 动态障碍物场景下的奖励函数改进.....30
4.2 动态障碍物场景.....31
4.3 动态障碍物场景下的实验设计.....32
4.3.1 实验方案.....32
4.3.2 实验结果.....32
4.4 动态障碍物场景下的机械臂轨迹.....36
4.5 本章小结.....39
第 5 章 总结与展望.....41
5.1 总结.....41

中国知网 https://www.cnki.net

5.2 展望.....42
参考文献.....43

中国知网 https://www.cnki.net

第 1 章 绪论

1.1 研究背景及意义

伴随着机器人技术的快速发展，从 1959 年第一个机器人诞生开始，机器人就得到了很好的发展，它已成为集控制技术、计算机技术等多种技术于一体的高新技术设备[1,2]。在人工智能飞速发展的大背景下，机器人已具备感知、记忆、决策等能力。由于机器人需求量逐年增加，用机器人代替人类处理重复性、危险性的工作已成为一种趋势，人工智能时代的生存模式也使服务型机器人有着巨大的发展。而机械臂在机器人当中，具有灵敏度高、工作空间大等优势，它不仅能够代替人们处理核武器等各种危险的物体，还可以减少完成工作的耗时，大大提高工作效率。在 2013 年的汉诺威工业博览会上，德国企业正式推出了“工业 4.0”[3]。2015 年 5 月，《中国制造 2025》正式发布，是中国由制造大国迈向制造强国的重要里程碑。在此大环境下，对机械臂的需求量将会越来越多，由此会带来两方面的问题：一方面机械臂的工作环境越来越复杂，另一方面对机械臂高效率完成任务提出了更高的要求。

由于机械臂工作的环境复杂多变，所以特别需要对机械臂进行轨迹规划，以应对多变的环境[4,5]。以 2011 年的日本核泄漏事故为例，需要通过机械臂轨迹规划，对事故现场进行快速搜救，由于搜救现场的环境非常复杂，所以对机器人搜救的实时性要求非常高，要求机器人在运动过程中既要避开障碍物，又要与复杂环境中的物体进行交互，此时，通过机械臂轨迹规划，规划出一条避障轨迹，就显得十分重要[6]。

在机械臂轨迹规划中，算法的选择对轨迹规划的效率有着一定的影响。传统的轨迹规划算法需要在获得机械臂参数的前提下，通过运动学方程和动力学方程对机械臂进行建模，将机械臂轨迹规划从惯性空间映射到构型空间后，在构型空间求解机械臂最优轨迹[7]。但是在实际生活中，机械臂及周围环境的数学模型不能被精确地建立，当环境中的目标物和障碍物位置变化时，需要重新计算构型空间的映射，所以传统的轨迹规划算法十分复杂，难以实现实时动态轨迹规划的目的。

当作业条件发生变化时，要求机械臂针对所处条件适时调整避障措施。随着深度强化学习的兴起，使机械臂更有机会具备这种学习功能，并且深度强化学习为机械臂轨迹规划开辟了全新的开发领域。深度强化学习是深度学习和强化学习的结合，它不仅具备了深度学习的图像网络处理功能，还具备了强化学习的策略自主学习功能，机械臂根据输入的图像和学到的策略进行训练，是一种更接近人类决策的机械臂训练算法，并且机械臂可通过深度强化学习算法完成相对复杂的训练任务。

中国知网 https://www.cnki.net

本文针对传统的机械臂轨迹规划算法需要建立复杂的轨迹方程的问题，采用深度强化学习算法进行机械臂轨迹规划，因为深度强化学习算法与传统的轨迹规划算法相比，无需建立复杂的轨迹方程，提高了轨迹规划的效率。

1.2 国内外研究现状

1.2.1 机械臂的研究现状

在国外，美国在 1980 年进行了一项名为 FTS（Flight Telerobotic Servicer）的空间机械臂的研究，FTS 空间机器人具有双臂结构，可以完成精细化的操作，可以帮助宇航员安装仪器，对航天器进行检测和维护[8]。欧洲航天局研制的七自由度机械臂被部署在国际空间站的俄罗斯舱段，是一款对称的放入式机械臂，用于太空装配和其它舱外服务，如图 1.1 所示[9]。



图 1.1 欧洲七自由度机械臂

Fig. 1.1 European manipulator with 7-DOF

日本以及欧洲几个国家目前在工业机器人方面掌握着较为先进的理论和制造技术，其中，以日本安川公司为首的企业，研发出了全自动化机械臂，用于搬运、切割、电焊等多个场景下，在此基础上，一直引领着全球的机器人市场。图 1.2 为日本安川公司研发的 GP7 机械臂。GP7 机械臂整体外形紧凑，具有快速、高效的特点。



图 1.2 GP7 机械臂

Fig. 1.2 GP7 manipulator

中国知网 https://www.cnki.net

在国内，关于工业机器人制造的相关企业也陆续诞生，其中包括新松机器人自动化有限公司，可以被称为国内机器人行业的龙头企业，研发出来的机械臂如图 1.3 所示：



图 1.3 新松 SCR5 协作机械臂
Fig. 1.3 Siasun SCR5 manipulator

然而，工业机器人的发展仍存在不足之处。对于工业机器人的使用，我国国内大多数都是汽车、船舶等大型企业在使用，一些小型企业仍是人工操作居多，因此导致了工业机器人在国内的使用率低，说明我国的工业自动化程度有待提高[10]。

1.2.2 传统算法的研究现状

人工势场法最早是由 Kathib O[11]在 1986 年提出的，其基本原理是将机械臂的工作环境模拟为人造力场，机械臂在到达目标物位置的过程中受到障碍物的斥力和目标物的引力，这两种力的合力就会确定机械臂的运动路线，但是该算法存在不足之处：①规划的轨迹可能不是全局最优轨迹，只是某一轮的局部最优轨迹，在实际测试中的成本很高；②当机械臂与目标物的距离较远时，机械臂受到的目标物的引力较大，受到的障碍物的斥力较小，因此容易与障碍物或边界发生碰撞；③当目标物靠近障碍物或在仿真环境的边界，机械臂移动到目标物附近时，由于其受到的目标物的引力较小，受到的障碍物的斥力较大，所以机械臂会在一定范围内徘徊，无法到达目标物位置；④当机械臂受到相同的引力和斥力，也就是合力为 0 时，机械臂轨迹规划很有可能陷入局部最优的困境[12,13]。因此，学者们对此算法展开了改进，取得了一定的成果：邱博[14]引入变增益函数，较好地改善了引力和斥力，通过同时规划起始点和目标点，自动控制扩展步长的大小，有效地避免了人工势场法陷入局部极小值；Fang Z 等[15]将遗传算法与强化学习相结合，并将其应用于改进人工势场法，减小了规划后的轨迹的长度和节点数，提高了轨迹规划的效率。

中国知网 https://www.cnki.net

A*算法是一种启发式搜索算法，在探索中根据环境的启发性信息，引导机械臂向目标物移动，并通过优化的方式，得到机械臂的最优轨迹[16]。Xu Z 等[17]在引入可操纵性概念的前提下，基于 A*算法对机械臂的运动性能进行定量分析和优化，使得到的轨迹与参考轨迹高度一致；张许有等[18]针对复杂的环境，提出了位置代价 A*算法，通过计算位置代价来判断节点，大大提高了 A*算法的轨迹规划效率。然而，在复杂的环境下，A*算法需要多次进行安全移动空间的计算，这会造成机械臂的输出轨迹出现一定的延迟。

快速扩展随机树（Rapidly-exploring Random Tree，RRT）算法是由 Lavalle S M[19]1998 年提出的，它的基本原理是以机械臂末端的初始位置作为根节点，在其工作空间中用随机采样的方式对叶子节点进行扩展，当叶子节点包含目标物的点时，即可生成从起点到目标物的一条轨迹。但是此算法需要在路径存在、规划时间足够长的前提下，才能找到一条路径解，效率较低，控制效果不稳定，并且规划的轨迹比较粗糙，往往不是最优轨迹[20,21]。因此，学者将 RRT 算法进行了改进，取得了一定的成果：Yuan C 等[22]提出了 PBG-RRT（Probability Bias-goal Rapidly-exploring Random Tree）算法，它虽然能加快收敛速度，避免陷入局部极小值，但是不能完全避免，在经过多次尝试后，会在附近采样，并陷入局部极小值，而且节点过于密集；Yi J 等[23]针对 RRT 算法搜索效率低的问题，提出了改进的 P_RRT*（Potential Function-based Rapidly-exploring Random Tree Star）算法，基于势函数进行随机采样，在新节点的扩展中采用两次扩展方法加快了算法的搜索效率，结果表明了改进后的算法有良好的效果。

在采用多项式进行机械臂轨迹规划的研究中，刘驰等[24]在构建机械臂模型，并求解机械臂正逆运动学解的基础上，采用七次多项式插值曲线进行机械臂轨迹规划，并规划出了平滑的机械臂轨迹曲线；Gao M 等[25]在 4-3-4 多项式插值轨迹规划算法的基础上，通过粒子群优化算法对轨迹进行优化，弥补了多项式插值法的不足；孙颙琰等[26]为了实现对水下机械臂的精准控制，提出了基于五次多项式的曲线插值算法，结果表明了机械臂能更加平稳地运动。

在采用 B 样条进行机械臂轨迹规划的研究中，李国洪等[27]结合了改进遗传算法和七次 B 样条曲线，降低了机械臂轨迹运行的时间；王青等[28]采用 5 次非均匀 B 样条曲线对机械臂的关节空间进行轨迹规划研究，通过弦长参数法和平均值法选取节点，将离散路径点作为弦值点反解出 B 样条控制点，结果验证了轨迹的平稳性；Nie L 等[29]通过结合五次多项式插值和五次非均匀有理 B 样条曲线，使得机械臂运动轨迹误差最小，提高了曲线的平滑度。

中国知网 https://www.cnki.net

1.2.3 强化学习算法的研究现状

强化学习算法主要通过让智能体进行“试错”训练，并进行最终的测试来规划轨迹，在训练的过程中，智能体每次做出动作之后，系统给出奖励值，智能体根据奖励值的大小决定下一回合的动作，直至达到规定的训练回合次数。国内外学者对此进行了深入研究，取得了一定的成果：Xie S 等[30]利用深度强化学习中的 A3C（Asynchronous Advantage Actor-Critic）进行了避障算法的设计；Ou J 等[31]将 DQN（Deep Q-learning Network）算法进行了改进，提出了 D3RQN（Dueling Double Deep Recurrent Q-learning Network）算法，对四旋翼避障进行训练和测试，结果表明在 D3RQN 算法下，四旋翼的避障效果比 DQN 算法更好；Huang R 等[32]对 DQN 算法进行了改进，减少了机器人由于与动态障碍物发生相对运动而造成的奖励值异常，从而造成碰撞的可能性，但是依旧存在收敛速度慢的问题；Yan C 等[33]将 DQN 算法改进，提出了 D3QN（Dueling Double Deep Q-learning networks）算法，结果表明 D3QN 算法可在避开动态障碍物（敌方）的情况下，让无人机顺利抵达目标点，并且奖励值比 DQN 更高；Kim H 等[34]将 Q-learning 算法与搜索策略相结合，解决了 Q-learning 算法在环境数量多的前提下不能储存所有训练数据的缺陷，并成功地在地图变化和动态障碍物场景对机器人进行避障路径规划；李辉等[35]通过设计四层神经网络代替 Q 价值函数，解决了 Q-learning 算法产生维数灾难的问题，并通过估计网络、现实网络的双网络模型和经验回放机制，提高了算法的收敛性，最终得到了比传统算法效率更高的轨迹；霍志会[36]将传统的 A*算法和深度强化学习中的 DQN 算法相结合，克服了 A*算法只依赖于栅格地图计算节点权值的缺点；Xu X 等[37]对于水面无人舰艇的控制问题，采用 DDPG 算法，实现了推力和舵角的连续输出；Cimurs R 等[38]提出了一种基于深度强化学习的目标导向避障导航系统，在面向目标的避障模型中进行端到端的训练，无需进行人工调整。

上述深度强化学习算法都是 off-policy 类算法，虽然它们能解决 on-policy 类算法（例如 TRPO 算法）的学习效率低的问题，但是也容易造成结果不收敛的问题，例如基于值的 Q-learning 算法，它更适合处理离散动作，因此在求解机械臂轨迹规划等连续动作空间的问题时，很难保证系统的稳定性与收敛性[39]。

1.3 本文主要工作

本文针对传统的机械臂轨迹规划算法需要建立复杂的轨迹方程、效率低的问题，提出了基于改进深度强化学习的机械臂轨迹规划方法，通过对机械臂进行避障训练，并进行最终的测试的方式规划其避障轨迹。在深度强化学习算法中，采用适合于规划连续的机械臂轨迹的算法，并对深度强化学习算法中的奖励函数进行了改进，并分别在静态障碍物和动

中国知网 https://www.cnki.net

态障碍物场景中进行三组实验，所做的具体内容如下：

(1) 针对机械臂仅在二值奖励函数下因盲目探索而无法快速到达目标物位置，进而无法快速地规划机械臂与目标物相交的轨迹的问题，设计了与机械臂和目标物的距离相关的距离引导奖励函数，包括负距离奖励、分区奖励、距离对比奖励，旨在让机械臂更快地到达目标物位置，并规划满足要求的机械臂轨迹；

(2) 在静态障碍物场景中，针对机械臂在传统二值奖励函数和距离引导奖励函数下不能适应静态障碍物环境的问题，设计了静态避障奖励函数，旨在让机械臂的各个连杆和各个关节避开所有的静态障碍物；

(3) 在动态障碍物场景中，针对机械臂在仅有静态障碍物场景的所有奖励函数的前提下不能适应动态障碍物环境的问题，设计了动态避障奖励函数；针对机械臂在动态障碍物场景下因盲目探索而无法快速避开动态障碍物的问题，设计了动态分区奖励函数，旨在让机械臂更快地避开动态障碍物；

(4) 为了满足规划连续的机械臂轨迹的要求，将适合于连续动作空间的深度确定性策略梯度（DDPG）算法应用于机械臂轨迹规划，并将其与异步优势行动者-评论家（A3C）算法进行了对比，目的是验证 DDPG 算法收敛速度更快，并且选择此算法进行机械臂轨迹规划；

(5) 规划机械臂在避障并到达目标物位置的前提下的步数最少的轨迹。

1.4 本文结构安排

本文的各章节内容安排如下：

第 1 章介绍了本研究的背景与意义，包括机械臂、传统算法和强化学习算法的国内外研究现状，并对本文的后续内容进行了安排。

第 2 章介绍了本研究的相关理论，包括机械臂模型和深度强化学习，其中，机械臂模型包括机械臂的运动学模型和动力学模型，它们的作用分别是为机械臂轨迹规划提供了相应的机械臂坐标、为后续的机械臂控制打下基础；深度强化学习包括对深度强化学习的具体介绍，以及适合于连续动作的三个深度强化学习算法及它们在机械臂轨迹规划中的应用，具体包括 Actor-Critic 算法和以此算法为框架的 DDPG 算法与 A3C 算法，目的是引出后文对这两个算法的奖励值收敛效果对比，并选择 DDPG 算法进行机械臂轨迹规划。

第 3 章针对静态障碍物场景进行机械臂轨迹规划，首先简要地介绍了机械臂轨迹规划；然后介绍了针对静态障碍物场景设计的奖励函数，包括传统二值奖励函数、距离引导比奖励函数、静态避障奖励函数；然后介绍了静态障碍物的二维仿真环境，包括场景示意图和正方形坐标；然后介绍了奖励值收敛效果对比的具体方案，并通过各种情况的对比，验证

中国知网 https://www.cnki.net

了 DDPG 算法比 A3C 算法的收敛速度更快，以及增加距离引导奖励函数能使机械臂更快到达目标物位置；最后规划了静态障碍物场景的机械臂轨迹，并选择步数最少的机械臂轨迹，在确保机械臂碰不到静态障碍物的前提下，将此轨迹作为最终规划的机械臂轨迹。

第 4 章针对动态障碍物场景进行机械臂轨迹规划，首先介绍了针对动态障碍物场景设计的奖励函数，包括动态避障奖励函数、动态分区奖励函数；然后介绍了动态障碍物的二维仿真环境，即场景示意图；然后介绍了奖励值收敛效果对比的具体方案，并通过各种情况的对比，验证了 DDPG 算法比 A3C 算法的收敛速度更快，以及增加动态分区奖励函数能使机械臂更快避开动态障碍物；最后规划了动态障碍物场景的机械臂轨迹，并选择步数最少的机械臂轨迹，在确保机械臂碰不到静态障碍物的前提下，将此轨迹作为最终规划的机械臂轨迹。为了验证机械臂在测试过程中避开了动态障碍物，还规划了机械臂中间过程图，结果表明机械臂成功地避开了动态障碍物。

第 5 章总结了本文所做的内容，并提出了可供后续研究者尝试的一些改进建议。

中国知网 https://www.cnki.net

第 2 章 相关理论概述

2.1 机械臂模型

2.1.1 机械臂的运动学模型

研究机械臂，首先要建立运动学模型。机械臂的基本物理结构是由多个关节和连接各个关节的连杆构成的，并且每个关节都有一定的可平移或旋转的自由度。在建立机械臂模型的过程中，为了便于对连杆的参数进行描述，需要对机械臂设置坐标系，来描述关节和连杆的对应位置关系。对于位置关系的描述，应用最广泛的方法是 Denavit 和 Hartenberg 在 1955 年提出的一种方法，也就是 D-H 法，它描述的机械臂关节的主要参数有四个：关节角度θ、偏置长度 d、连杆长度 l、旋转角度α[40]。

本研究选取三关节、二连杆的机械臂作为仿真的机械臂模型，其运动学模型的参数如表 2.1 所示：

表 2.1 机械臂的 D-H 参数

Tab. 2.1 The D-H parameters of manipulator

连杆	θ	d	l	α	转角范围
连杆 1	θ_1	0	100	$\pi/2$	$(-2\pi,2\pi)$
连杆 2	θ_2	0	100	0	$(-2\pi,2\pi)$

根据模型参数，可建立一个二自由度机械臂，其二维平面结构如图 2.1 所示：

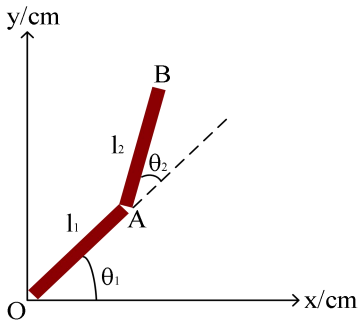


图 2.1 机械臂二维平面结构图

Fig. 2.1 The two-dimensional plane structure diagram of manipulator

图中，点 O 是机械臂的固定点，点 A、B 是机械臂的两个运动点，l_1和l_2是机械臂两个连杆的长度，均为 100cm，θ_1是机械臂连杆 OA 相对 x 轴的旋转角度，θ_2是机械臂连杆

中国知网 https://www.cnki.net

AB 相对于机械臂连杆 OA 的旋转角度。设点 A、点 B 的坐标分别为(x_1, y_1)、(x_2, y_2)，则有：

$$\begin{cases} x_1 = l_1 \cos\theta_1 \\ y_1 = l_1 \sin\theta_1 \end{cases} \tag{2.1}$$

$$\begin{cases} x_2 = l_1 \cos\theta_1 + l_2 \cos(\theta_1 + \theta_2) \\ y_2 = l_1 \sin\theta_1 + l_2 \sin(\theta_1 + \theta_2) \end{cases} \tag{2.2}$$

在仿真时，需要根据点 A、点 B 的坐标计算后续介绍的奖励函数的奖励值，并进行机械臂的避障轨迹规划。

2.1.2 机械臂的动力学模型

为了更充分地定义机械臂轨迹规划问题，还需要介绍机械臂的动力学模型。机械臂动力学是当前研究的一个热门课题，其建模方法很多，理论也很成熟，而且它的建模准确性决定了轨迹规划后续的机械臂控制效果优劣。

在本研究的二自由度机械臂中，对于连杆 OA，对公式（2.1）进行求导，可得到:

$$\begin{cases} x_1^{'} = -l_1\theta_1^{'} \sin\theta_1 \\ y_1^{'} = l_1\theta_1^{'} \cos\theta_1 \end{cases} \tag{2.3}$$

由此可得到连杆 OA 线速度平方

$$v_1^2 = (x_1')^2 + (y_1')^2 = l_1^2(\theta_1')^2 \tag{2.4}$$

因此对于连杆 OA，其动能和重力势能分别为:

$$\begin{cases} K_1 = \dfrac{1}{2} m_1 l_1^2 (\theta_1')^2 \\ P_1 = m_1 g l_1 \sin\theta_1 \end{cases} \tag{2.5}$$

由于连杆 OA 和连杆 AB 是串联状态，所以当连杆 OA 转动时，连杆 AB 也会跟着转动，因此对于连杆 AB 的线速度，对公式（2.2）进行求导，可得到:

$$\begin{cases} x_2' = -l_1\theta_1' \sin\theta_1 - l_2(\theta_1' + \theta_2')\sin(\theta_1 + \theta_2) \\ y_2' = l_1\theta_1' \cos\theta_1 + l_2(\theta_1' + \theta_2')\cos(\theta_1 + \theta_2) \end{cases} \tag{2.6}$$

由此可得连杆 AB 末端线速度平方

$$v_2^2 = (x_2')^2 + (y_2')^2 = (l_1\theta_1')^2 + l_2^2(\theta_1' + \theta_2')^2 + 2l_1l_2\theta_1'(\theta_1' + \theta_2')\cos\theta \tag{2.7}$$

因此对于连杆 AB，其动能和重力势能分别为:

中国知网 https://www.cnki.net

$$\begin{cases} K_2 = \frac{1}{2} m_2[(l_1\theta_1')^2 + l_2^2(\theta_1' + \theta_2')^2 + 2l_1l_2\theta_1'(\theta_1' + \theta_2')\cos\theta_2] \\ P_2 = m_2 g[l_1\sin\theta_1 + l_2\sin(\theta_1 + \theta_2)] \end{cases} \tag{2.8}$$

机械臂动力学方程的拉格朗日算子是机械臂的动能和重力势能之差，可表示为

$$\begin{aligned} L = K - P = K_1 + K_2 - P_1 - P_2 = \frac{1}{2} m_2[l_2^2(\theta_1' + \theta_2')^2 + 2l_1l_2\theta_1'(\theta_1' + \theta_2')\cos\theta_2] \\ + \frac{1}{2}(m_1 + m_2)(l_1\theta_1')^2 - (m_1 + m_2)gl_1\sin\theta_1 - m_2gl_2\sin(\theta_1 + \theta_2) \end{aligned} \tag{2.9}$$

之后对拉格朗日算子进行求导，求得二自由度机械臂的力矩

$$\begin{cases} \tau_1 = \frac{d}{dt}\frac{\partial L}{\partial \theta_1'} - \frac{\partial L}{\partial \theta_1} = [(m_1+m_2)l_1^2 + m_2l_2^2 + 2m_2l_1l_2\cos\theta_2]\,\theta_1'' \\ + (m_2l_2^2 + m_2l_1l_2\cos\theta_2)\,\theta_2'' - m_2l_1l_2(2\theta_1' + \theta_2')\,\theta_2'\sin\theta_2 + (m_1+m_2)gl_1\cos\theta_1 \\ + m_2gl_2\cos(\theta_1 + \theta_2) \\ \tau_2 = \frac{d}{dt}\frac{\partial L}{\partial \theta_2'} - \frac{\partial L}{\partial \theta_2} = (m_2l_2^2 + m_2l_1l_2\cos\theta_2)\,\theta_1'' + m_2l_2^2\theta_2'' + m_2l_1l_2(\theta_1')^2\sin\theta_2 \\ + m_2gl_2\cos(\theta_1 + \theta_2) \end{cases} \tag{2.10}$$

将其整理成机械臂动力学模型通用的动力学方程形式，可得：

$$M(\theta)\begin{bmatrix}\theta_1'' \\ \theta_2''\end{bmatrix} + C(\theta,\theta')\begin{bmatrix}\theta_1' \\ \theta_2'\end{bmatrix} + G(\theta) = \begin{bmatrix}\tau_1 \\ \tau_2\end{bmatrix} \tag{2.11}$$

其中，$M(\theta)$ 是惯性矩阵，$C(\theta,\theta')$ 是向心力矩阵，$G(\theta)$ 是惯性矩阵，并且

$$\begin{cases} M(\theta) = \begin{bmatrix} (m_1+m_2)l_1^2 + m_2l_2^2 + 2m_2l_1l_2\cos\theta_2 & m_2l_2^2 + m_2l_1l_2\cos\theta_2 \\ m_2l_2^2 + m_2l_1l_2\cos\theta_2 & m_2l_2^2 \end{bmatrix} \\ C(\theta,\theta') = \begin{bmatrix} -2m_2l_1l_2\theta_2'\sin\theta_2 & -m_2l_1l_2\theta_2'\sin\theta_2 \\ m_2l_1l_2\theta_1'\sin\theta_2 & 0 \end{bmatrix} \\ G(\theta) = \begin{bmatrix} (m_1+m_2)gl_1\cos\theta_1 + m_2gl_2\cos(\theta_1+\theta_2) \\ m_2gl_2\cos(\theta_1+\theta_2) \end{bmatrix} \end{cases} \tag{2.12}$$

2.2 深度强化学习简述

强化学习由五个要素组成：智能体、环境、状态、动作、奖励，其目标是如何根据情况采取行动，使奖励值最大化。如图 2.2 所示，在每个时间步 t，Agent 可以观察到环境的当前状态 $s_t \in \boldsymbol{S}$。基于观察到的状态，Agent 决定要采取的动作 $a_t \in \boldsymbol{A}$。在动作 a_t 的作用下，环境的状态改变为 s_{t+1}，并产生此动作的奖励 $r(s_t, a_t)$。有了这些新信息，Agent 可

中国知网 https://www.cnki.net

以确定该动作是有用的，应该重复执行，还是无用的，应该避免执行。观察、动作、奖励的循环将持续到学习完成为止。每个时间步骤的目标是确定如何采取动作，使未来奖励的贴现和最大化，即 $\sum_{T=t}^{\infty}\gamma^{T-t}r(s_T,a_T)$，其中 $\gamma\in[0,1]$ 是优先考虑近期奖励的贴现因子，T 是采样时间。强化学习的优势是在每次训练之前，无需提供样本数据，从而使人们摆脱了复杂的优化问题。近年来，强化学习已被用于机器人控制、投资分析、棋类博弈等领域。虽然强化学习能使智能体很好地掌握动作策略，但是类似 Q-learning 这样的传统强化学习仅能处理在离散动作下的动作空间或状态空间较小的问题，无法规划实际的在连续动作空间下的机械臂轨迹，例如以机械臂图像作为状态时，维度非常高，计算机需要很大的内存来存储每个状态的动作、奖励值等变量。由此可见，传统的强化学习虽然效率比传统的轨迹规划算法高，但在高维情况下仍存在效率低的缺陷，此时就需要加上深度学习。

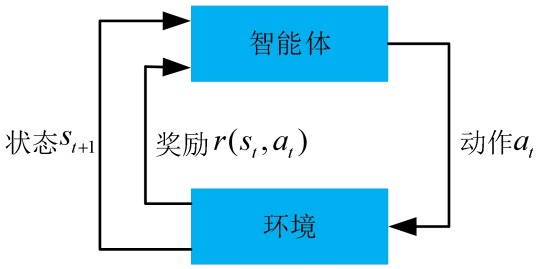


图 2.2 强化学习的五大元素

Fig. 2.2 Five elements of reinforcement learning

深度学习是一种对样本数据内在规律进行学习的机器学习方法，按其表现形式可分为监督学习、半监督学习和无监督学习，在 2006 年由多伦多大学的 Hinton G E 等[41]首次提出，采用了无监督预训练方法，对网络中的权重初值进行优化，并对权重进行精细调整，从而拉开了深度学习的序幕[42,43]。与传统的机器学习相比，深度学习的最明显的特征就是适使用了多层非线性处理单元，来对特征进行提取和转换，实现了多层级的特征表示和抽象概念的学习，进而实现了端对端的训练，并且在大数据下表现出了优势[44-46]。由于它在图像和语言的识别方面具有强大的性能，目前已经在许多领域中得到了应用，比如自然语言处理、计算机视觉等，并且效果比传统的机器学习更好。近年来，深度学习在国内外的应用领域广泛：在国内，百度推出的“飞桨”以深度学习为核心框架，目前已成为功能完善的深度学习平台[47]；在国外，谷歌的 TensorFlow 和脸书的 PyTorch 已经在开源社区产生了广泛的影响[48]。

深度学习中的“深度”与提升方法、支持向量机等“浅层学习”方法相比，其模型存在更多的非线性运算层面[49]。浅层学习是利用人工经验来抽取样本，在所学到的网络模型中，只能得到一个单一层次的特征，而没有一个层级的特征[50,51]。深度学习是指对原始信号展开逐层特征变换，将原空间的样本特征变换到一个新的空间，并利用自动学习获得新的层

中国知网 https://www.cnki.net

次化的特征表示，从而更有利于进行特征可视化或分类[52]。深度学习的过程如图 2.3 所示：



图 2.3 深度学习的过程

Fig. 2.3 The process of deep learning

深度学习是机器学习的更深层次，将支持向量机、聚类等传统方法使用的浅层次特征提取进行更深层次的加工，模仿神经元之间的传导关系，通过含有多个隐藏层的神经元来建立网络架构，根据人类大脑的原理解释数据，进而通过前向传播和反向传播，计算从输入的数据到输出的结果之间的一系列变换过程，因此，深度学习可用于进行数据处理、数据修复、提取内部特征等操作。其过程可总结为：①输入大量信息，并对其进行预处理，进而得到高质量的待处理数据；②进行一层一层的正向传播、特征提取、张量变形等操作，目的是将低层次、抽象度低的数据转换为高层次、抽象度高的数据，进而简化了原有的复杂运算，仅需简单的模型就能进行相应的操作；③用优化器，通过反向传播来进行参数的调整，目的是降低损失；④计算这个参数下的模型运算结果的损失，目的是衡量这个模型的好坏。包含多个隐藏层的深度学习模型如图 2.4 所示：

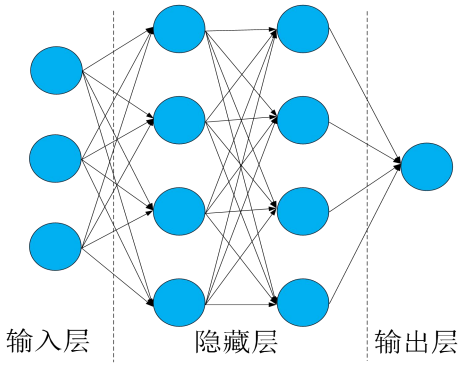


图 2.4 深度学习的模型

Fig. 2.4 The model of deep learning

深度强化学习结合了深度学习与强化学习，在本研究中，它使用深度神经网络来解决机械臂执行动作的策略和价值函数的表示问题，使用强化学习来对机械臂避障和到达目标物位置的问题进行定义，之后通过梯度反向传播进行轨迹规划的优化[53]。随着深度学习理论的发展，深度神经网络通过在训练过程中改变系统节点的权重与偏置的方式，来达到对系统中输入的任意机械臂动作进行表示的效果。这种泛化能力可克服传统的强化学习面对连续动作空间产生的问题，解决了传统的强化学习在离散动作下无法规划连续的机械臂轨迹的缺陷，使强化学习应用在更多的领域，因此，深度强化学习算法在现实生活中具有广泛的应用前景。

中国知网 https://www.cnki.net

2.3 深度强化学习算法

本小节将介绍适合于连续性动作的三个深度强化学习算法在本研究中的应用，具体包括 Actor-Critic 算法，和以此算法为框架的两个深度强化学习算法：DDPG 算法和 A3C 算法，并在后文中需要将 DDPG 算法和 A3C 算法的收敛性进行对比，目的是选择恰当的深度强化学习算法进行机械臂轨迹规划。

（1）Actor-Critic 算法

Actor-Critic 算法是一种结合以值函数为基础（例如 Q-learning 算法）和以策略函数为基础（例如 Policy Gradients 算法）的深度强化学习算法，结合了 Policy Gradients 算法的可以应用在连续动作空间中规划机械臂的连续轨迹和 Q-learning 算法的可以通过值函数评价此轨迹是否为最优轨迹的优势，神经网络分为 Actor 网络和 Critic 网络两部分，其中：Actor 网络以策略函数为基础，它输入的是机械臂当前的状态 s_t，输出每个可能的动作被执行的概率 $\pi_\theta(s_t,a_t)$，并基于该概率来选择合适的动作 a_t，然后得到 s_{t+1}、r_t；Critic 网络以值函数为基础，它输入的是 Actor 网络的机械臂状态 s_t、s_{t+1}，获得机械臂状态的 V 值 $V_w(s_t)$、$V_w(s_{t+1})$。每训练完一组样本数据，将各个网络的参数更新一次，直至达到设置的最大回合次数[54]。Actor-Critic 算法的网络结构如图 2.5 所示：

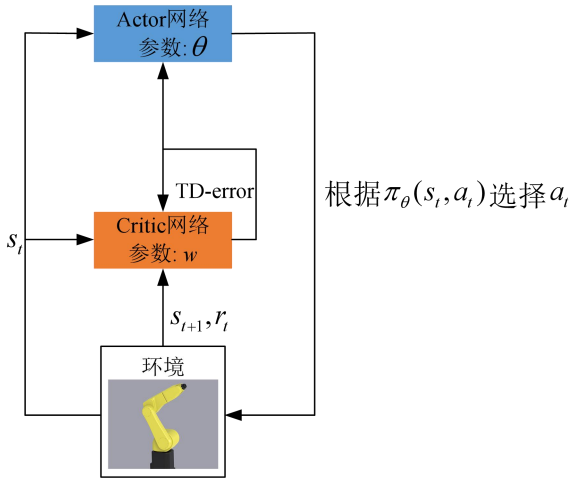


图 2.5 Actor-Critic 算法的网络结构

Fig. 2.5 The network structure of Actor-Critic Algorithm

Actor-Critic 算法在本研究的伪代码如表 2.2 所示：

表 2.2 Actor-Critic 算法伪代码

Tab. 2.2 The pseudocode of Actor-Critic algorithm

Actor-Critic 算法伪代码
1.初始化 Actor 网络参数θ、Critic 网络参数 w
2. For episode=1：
1)获取机械臂的初始状态 s_t
2) For step=1：
a) 利用策略 π 获取当前状态下的动作 a_t

中国知网 https://www.cnki.net

续表 2.2

b) 机械臂执行动作 a_t 并返回奖励值 r_t 和新的状态 s_{t+1},并执行下一个动作 a_{t+1}

c) 计算 TD-Error: $\delta_t = r_t + \gamma V_w(s_{t+1}) - V_w(s_t)$

d) 更新 Actor 网络参数θ: $\theta = \theta + \alpha \nabla_\theta \log \pi_\theta(s_t, a_t)(r_t + \gamma V_w(s_{t+1}) - V_w(s_t))$

e) 更新 Critic 网络参数 w: $w = w + \beta \delta_t \nabla_w (r_t + \gamma V_w(s_{t+1}) - V_w(s_t))$

直至达到设置的最大步数（step），循环结束

直至达到设置的最大回合次数（episode），循环结束

然而，Actor-Critic 算法牵扯到了两个连续状态中更新的网络，它不能破坏参数在更新之前和更新之后的相互关系，容易使机械臂输出的动作陷入局部最优的困境中，进而使得规划的机械臂轨迹不是全局最优轨迹。

（2）DDPG 算法

本文基于 Deep Deterministic Policy Gradient（DDPG）算法进行机械臂轨迹规划，它是一种 Actor-Critic 类算法，它是在 DQN 这种只能应对离散动作的算法的基础上，使用深度神经网络对状态-动作值函数 $Q(s,a)$和确定性策略 $\mu_\theta(s)$ 进行近似，可以解决无法在连续动作空间内规划机械臂轨迹的问题，用两个神经网络来拟合 Q 值函数和策略函数，同时使用回放缓冲区储存机械臂训练过的样本数据[55]。DDPG 算法在本研究中的网络结构如图 2.6 所示，其中，Actor 网络输入的是机械臂当前的状态 s_t，并根据该状态对当前动作 a_t 进行选择，然后得到 s_{t+1}、r；Critic 网络输入的是 Actor 网络输出的机械臂的状态-动作对 s_t、a_t，并迭代 Critic 网络的权重 θ^Q，求解机械臂状态-动作对的 Q 值 $Q(s_t, a_t|\theta^Q)$；目标 Actor 网络输入的是机械臂的基于回放缓冲区的下一个状态 s_{t+1}，并基于该状态对下一个动作 a_{t+1} 进行选择；目标 Critic 网络输入的是目标 Actor 网络输出的机械臂状态-动作对 (s_{t+1}, a_{t+1})，并迭代目标 Critic 网络的权重 $\theta^{Q'}$，求解机械臂状态-动作对的 Q 值 $Q(s_t, a_t|\theta^{Q'})$。每训练完一组样本数据，将各个网络的参数更新一次，直至达到设置的最大回合次数。

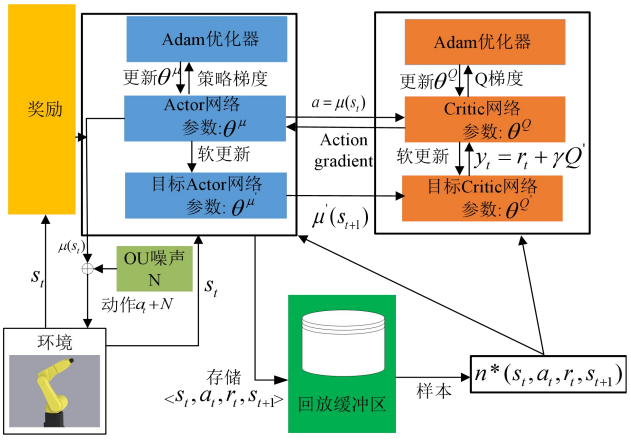


图 2.6 DDPG 算法的网络结构

Fig. 2.6 The network structure of DDPG algorithm

中国知网 https://www.cnki.net

由于本研究涉及的状态信息基本上都是机械臂、目标物和障碍物的状态信息，所以整个网络结构只包含全连接层，除了 Actor 网络的输出层的激活函数是用来将动作值映射到[-1,1]的双曲正切函数（Tanh），其余各层的激活函数均为线性修正单元（ReLU），具体内容如表 2.3 所示。

表 2.3 Actor 网络和 Critic 网络的结构

Tab. 2.3 The structure of Actor network and Critic network

网络	层的名称	形状	激活函数
Actor 网络	输入层	（状态和动作维度之和，256）	ReLU
Actor 网络	隐藏层 1	（256，256）	ReLU
Actor 网络	隐藏层 2	（256，256）	ReLU
Actor 网络	输出层	（256，动作维度）	Tanh
Critic 网络	输入层	（状态、目标和动作维度之和，256）	ReLU
Critic 网络	隐藏层 1	（256，256）	ReLU
Critic 网络	隐藏层 2	（256，256）	ReLU
Critic 网络	输出层	（256，1）	无

DDPG 算法的在本研究中的伪代码如表 2.4 所示：

表 2.4 DDPG 算法伪代码

Tab. 2.4 The pseudocode of DDPG algorithm

DDPG 算法伪代码

1. 随机初始化 Critic 网络 $Q(s,a|\theta^Q)$ 和 Actor 网络 $\mu(s|\theta^\mu)$，对应的权重分别为 θ^Q、θ^μ
2. 初始化目标网络 Q' 和 μ'，权重 $\theta^{Q'} \leftarrow \theta^Q$、$\theta^{\mu'} \leftarrow \theta^\mu$
3. 初始化回放缓冲区 Replay buffer
4. For episode=1：
   1)获取机械臂的初始状态 s_t
   2) For step=1：
      a) 利用当前给定策略，并与随机噪声叠加得到动作：$a_t = \mu\left(s_t|\theta^\mu\right) + N$
      b) 机械臂执行一个动作 a_t 并返回一个奖励值 r_t 和一个新的状态 s_{t+1}
      c) 将状态转换过程 $\langle s_t, a_t, r_{t+1}, s_{t+1}\rangle$ 保存到一个回放存储单元 Replay buffer 中，并把它用作训练网络的一个数据集
      d) 从 Replay buffer 中随机提取小批量训练数据 $\langle s_t, a_t, r_{t+1}, s_{t+1}\rangle$
      e) 计算 TD-Error：$y_t = r_t + \gamma Q'\left(s_{t+1}, \mu'\left(s_{t+1}|\theta^{\mu'}\right)\middle|\theta^{Q'}\right)$
      f) 通过最小化损失函数更新 Critic 网络，定义该损失函数为均方误差：
      $L = \frac{1}{N}\sum_t \left(y_t - Q(s_t, a_t|\theta^Q)\right)^2$
      g) 对样本使用策略梯度更新 Actor 网络：
      $\nabla_{\theta_\mu}\mu|s_t \approx \frac{1}{N}\sum_t \nabla_a Q\left(s,a|\theta^Q\right)\Big|_{s=s_t,a=\mu(s_t)} * \nabla_{\theta_\mu}\mu\left(s|\theta^\mu\right)\Big|_{s_t}$

中国知网 https://www.cnki.net

续表 2.4

h) 目标网络参数更新，其中 $\tau(0<\tau<1)$ 为参数更新速率:

$$\theta^{Q'} \leftarrow \tau\theta^{Q}+(1-\tau)\theta^{Q'}$$
$$\theta^{\mu'} \leftarrow \tau\theta^{\mu}+(1-\tau)\theta^{\mu'}$$

直至达到设置的最大步数（step），循环结束
直至达到设置的最大回合次数（episode），循环结束

（3）A3C 算法

为了验证 DDPG 算法收敛速度更快，需要将其与 Asynchronous Advantage Actor-Critic（A3C）算法进行对比。A3C 算法也是一种 Actor-Critic 类算法，它将 Actor-Critic 放到多个子线程中，并对其进行同步训练，提高了智能体的训练效率[56]。在本研究中，A3C 算法创建了多个并行的环境，可以让多个机械臂在一个并行的环境下对主结构的参数进行更新，并行的机械臂之间不会发生任何的干扰，因此减少了更新的相关性；服务器中的每一个核都是一个线程，可以在多个线程中并行运行程序，可提高运行效率。每训练一段时间后，需要将每个机械臂（Worker1~Worker5)）的梯度传给中央大脑（Global Network）进行分析，并将参数 θ、θ_v 传给各个机械臂进行下一次的训练，直至达到设置的最大回合次数。在该算法中，每个机械臂的 Actor 网络和 Critic 网络的激活函数与 DDPG 算法相同。本研究选用 5 个并行的机械臂，相应的网络结构如图 2.7 所示：

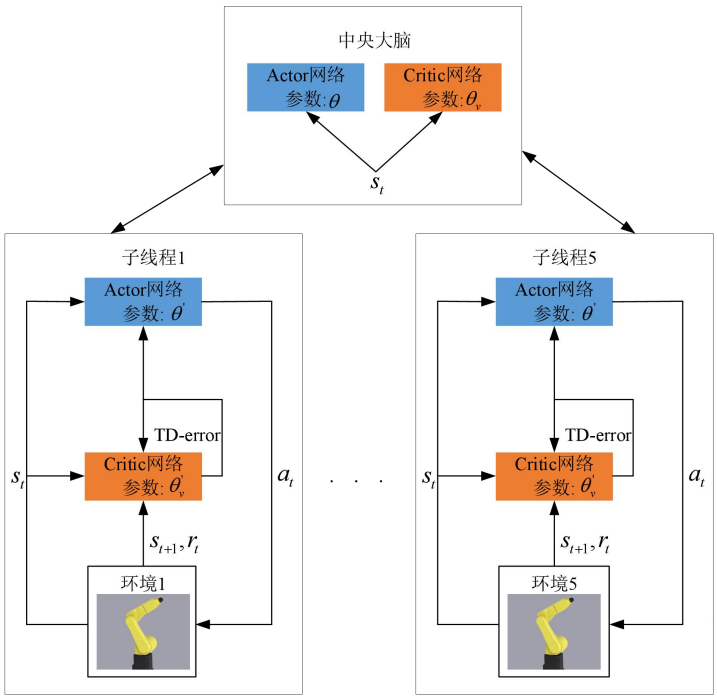


图 2.7 A3C 算法的网络结构

Fig. 2.7 The network structure of A3C algorithm

中国知网 https://www.cnki.net

A3C 算法在本研究中的伪代码如表 2.5 所示：

表 2.5 A3C 算法伪代码

Tab. 2.5 The pseudocode of A3C algorithm

A3C 算法伪代码
初始化全局共享网络参数 θ 、 θ_v 和全局共享迭代次数 $T=0$
初始化子线程网络参数 θ' 、 θ_v'
初始化线程步进计数器 $t=0$
repeat
重置梯度 $d\theta \leftarrow 0, d\theta_v \leftarrow 0$
同步两个网络的参数 $\theta' = \theta, \theta_v' = \theta_v$
$t_{start} = t$
获取机械臂的初始状态 s_t
repeat
根据策略 $\pi(a_t \mid s_t; \theta')$ 执行动作 a_t ，并获取奖励值 r_t 和下一个状态 s_{t+1}
$t \leftarrow t+1$
$T \leftarrow T+1$
直至 s_t 是终止状态或 $t - t_{start} == t_{\max}$
$R = \begin{cases} 0 & s_t\text{是终止状态} \\ V(s_t, \theta_v') & s_t\text{不是终止状态} \end{cases}$
repeat
$R \leftarrow r_i + \gamma R(i \in \{t-1, ..., t_{start}\})$
计算 θ' : $d\theta \leftarrow d\theta + \nabla_{\theta'} \log \pi(a_i \mid s_i; \theta')(R - V(s_i; \theta_v'))$
计算 θ_v' : $d\theta_v \leftarrow d\theta_v + \partial (R - V(s_i; \theta_v'))^2 / \partial \theta_v'$
$t = t-1$
直至 $t = t_{start}$ ，分别使用 $d\theta$、$d\theta_v$ 更新 θ、θ_v
直至 $T > T_{\max}$

2.4 本章小结

本章首先对机械臂的运动学模型和动力学模型进行了详细的描述，其中，运动学模型主要包括机械臂的 D-H 参数和坐标公式，可为机械臂轨迹规划提供相应的坐标，为本文的结构完整性奠定了基础，动力学模型为轨迹规划后续的机械臂控制打下了基础，更充分地定义了机械臂轨迹规划；然后对强化学习和深度学习的基本内容、结合了强化学习与深度学习的深度强化学习进行了简单地介绍，并对其相对于传统强化学习相比的优点进行了分析；最后详细地介绍了适合于连续性动作的三个深度强化学习算法在机械臂轨迹规划中的应用，具体包括 Actor-Critic 算法，以及以此算法为框架的 DDPG 算法和 A3C 算法，为本文的 DDPG 算法和 A3C 算法的对比打下了基础，后续根据对比效果，将收敛速度更快的 DDPG 算法作为最终的机械臂轨迹规划算法。

中国知网 https://www.cnki.net

第 3 章 静态障碍物场景下的机械臂轨迹规划

3.1 机械臂轨迹规划概述

机械臂轨迹规划是指在符合某种约束的情况下，规划出一条将起点和终点相连的机械臂轨迹，并且在有障碍物的场景下，要求规划的机械臂轨迹必须与目标物相交，并且不能与障碍物相交[57]。然而，传统的根据物理学原理建立机械臂、目标物和障碍物的位置对应关系的方程进行机械臂轨迹规划的方法十分复杂，因此，本研究基于深度强化学习算法进行机械臂轨迹规划。在此类算法中，重点在于如何设计恰当的奖励函数，使机械臂学会如何避开障碍物，并到达目标物位置，因为奖励函数是机械臂轨迹规划中影响很大的一个环节，通常被视为一个映射，当机械臂从某个状态转向下一个状态时，环境会以奖励函数为基础，评估当前的状态-动作对，并将奖励值反馈到机械臂，让机械臂能够从环境给予的反馈中感知这个“世界”，进而逐步掌握到其中的“规律”，在下一次回合根据奖励值对行为进行改进，逐步学到最优的策略，在进行深度强化学习的测试后可规划机械臂避障轨迹。不同的奖励函数对仿真结果的影响很大，有着很强的引导作用，整个机械臂轨迹规划中至关重要，因此，本文对深度强化学习算法中的奖励函数进行了改进。

3.2 静态障碍物场景下的奖励函数改进

机械臂轨迹规划首先要求规划的机械臂轨迹与绿色目标物（以下简称目标物）相交，因此需要设计机械臂到达目标物位置的奖励函数，以确保机械臂到达目标物位置时，获得正的奖励值，即传统的二值奖励函数，设目标物中心点坐标为(x_{goal}, y_{goal})，当机械臂末端保持在目标物内时，奖励值加 1，反之奖励值为 0，具体形式如公式（3.1）所示，其中，(x_2, y_2)是机械臂端点的坐标，对应机械臂二维平面结构图的点 B：

$$r_1 = \begin{cases} 1 & \left(x_{goal} - 20 < x_2 < x_{goal} + 20\right) and \\ & \left(y_{goal} - 20 < y_2 < y_{goal} + 20\right) \\ 0 & otherwise \end{cases} \tag{3.1}$$

然而，机械臂仅在传统二值奖励下会因长时间进行盲目探索而无法到达目标物位置，因此，本文对深度强化学习中的奖励函数进行了改进，以确保机械臂能更快到达目标物位置，具体内容如下：

中国知网 https://www.cnki.net

为了达到机械臂距离目标物越近，奖励函数越大，将奖励函数逐步导向最大决策空间的效果，增加了负距离奖励函数，设机械臂末端与目标物的距离为d_{goal}，则负距离奖励函数如公式（3.2）所示：

$$r_2 = -d_{goal} = -\sqrt{\left(x_2 - x_{goal}\right)^2 + \left(y_2 - y_{goal}\right)^2} \tag{3.2}$$

因为分区奖励函数与传统的二值奖励函数相比较，它不仅与任务的最终目标联系起来，还与一些有价值的环境信息相结合，使机械臂在没有达到目标时，还能感知到周围环境中传来的反馈信息，从而引导机械臂进行正确的探索，防止因为接不到正向反馈而导致的过多的无效探索，所以人为地增设分区奖励，即当机械臂端点与目标物边缘的距离很短（本文以 20cm~30cm 作为机械臂端点与目标物边缘的短距离）时，奖励值为 0.1，当距离大于 30cm 时，奖励值为-1，具体形式如公式（3.3）所示：

$$r_3 = \begin{cases} 0.1 & 20 < d_{goal} \le 30 \\ -1 & d_{goal} > 30 \end{cases} \tag{3.3}$$

为了正确引导机械臂到达目标物位置，即当机械臂在本次回合与目标物的距离比上一回合更远时，设置负奖励值，当机械臂与目标物的距离比上一回合更近时，设置正奖励值，因此增加了机械臂与目标物距离对比的奖励函数，如公式（3.4）所示：

$$r_4 = \begin{cases} 0.5 & d_{goal}' < d_{goal} \\ 0 & d_{goal}' = d_{goal} \\ -0.5 & d_{goal}' > d_{goal} \end{cases} \tag{3.4}$$

这里的d_{goal}'表示机械臂末端在下一回合与目标物的距离，具体含义为：下一回合两者的距离小于本次回合的距离，奖励值为0.5；当两者相等时，没有奖励值；下一回合两者的距离大于本次回合的距离，奖励值为-0.5。

$r_2 + r_3 + r_4$统称为距离引导奖励函数，其作用是使机械臂更快地到达目标物位置。

机械臂轨迹规划还要求规划的机械臂轨迹不能与静态障碍物相交，即机械臂的各个关节和各个连杆都需要避开静态障碍物，因此需要对机械臂的关节和连杆到达静态障碍物位置的行为设计奖励函数。由于机械臂的关节和连杆在到达静态障碍物的位置时，总的奖励值必须小于 0，所以$|r|$必须大于正的总奖励值 1.6，因此，当机械臂的关节和连杆到达任意一个静态障碍物的位置时，r=-2。设置的机械臂避障节点如图 3.1 所示：

中国知网 https://www.cnki.net

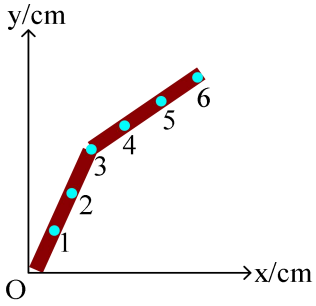


图 3.1 机械臂避障节点图

Fig. 3.1 The node diagrams of manipulator to avoid obstacles

设置这 6 个节点的原因如下：

要想使机械臂的两个运动关节都避开静态障碍物，就需要对机械臂两个运动关节接触静态障碍物的行为设计奖励函数，即当机械臂关节到达静态障碍物的位置时，奖励值为-2，反之奖励值为 0。图中，点 3 和点 6 分别为机械臂二维平面结构图的点 A 和点 B，坐标分别为(x_1,y_1)、(x_2,y_2)。设任意一个静态障碍物的中心坐标为(x_{obs},y_{obs})，则机械臂关节的避障奖励函数如公式（3.5）所示：

$$r_5=\begin{cases}-2 & (x_{obs}-20<x_i<x_{obs}+20)\,and\\ & (y_{obs}-20<y_i<y_{obs}+20)(i=1、2)\\ 0 & otherwise\end{cases} \tag{3.5}$$

要想使机械臂的两个连杆避开静态障碍物，就需要对机械臂两个连杆接触静态障碍物的行为设计奖励函数，即当机械臂连杆到达静态障碍物的位置时，奖励值为-2，反之奖励值为 0，然而，对连杆的每处设计奖励函数，显得过于繁琐，因此采取将连杆分段的措施，并且需要确保每段连杆的长度小于静态障碍物内最短的线段长度（在本研究中为正方形的边长），设分的段数为 n，则 100/n<40，所以在本研究中，将机械臂的每个连杆都分成 3 段，以确保连杆在接触静态障碍物时，奖励值为负。设点 1、2、4、5 的坐标分别为(x_3,y_3)、(x_4,y_4)、(x_5,y_5)、(x_6,y_6)，则机械臂连杆的避障奖励函数如公式（3.6）所示：

$$r_6=\begin{cases}-2 & (x_{obs}-20<x_i<x_{obs}+20)\,and\\ & (y_{obs}-20<y_i<y_{obs}+20)(i=3、4、5、6)\\ 0 & otherwise\end{cases} \tag{3.6}$$

r_5+r_6 统称为静态避障奖励函数。

3.3 静态障碍物场景

本文在二维仿真环境中进行静态障碍物场景下的机械臂轨迹规划研究，并且目标物和障碍物均为边长是 40cm 的正方形。场景中的机械臂移动速度为 200 步/秒。为了进一步验

中国知网 https://www.cnki.net

证深度强化学习算法的更新和奖励函数的更新能加快机械臂到达目标物位置和避开动态障碍物的速度，针对静态障碍物场景进行三组实验：第一组，设置绿色目标物、橙色障碍物和紫色障碍物；第二组在第一组的基础上，增加红色障碍物；第三组在第二组的基础上，移动紫色障碍物的位置。三组的目标均是通过避障的方式到达绿色正方形的位置。机械臂固定点的坐标为（200,200）。静态障碍物的三组场景示意图如图 3.2~3.4 所示：

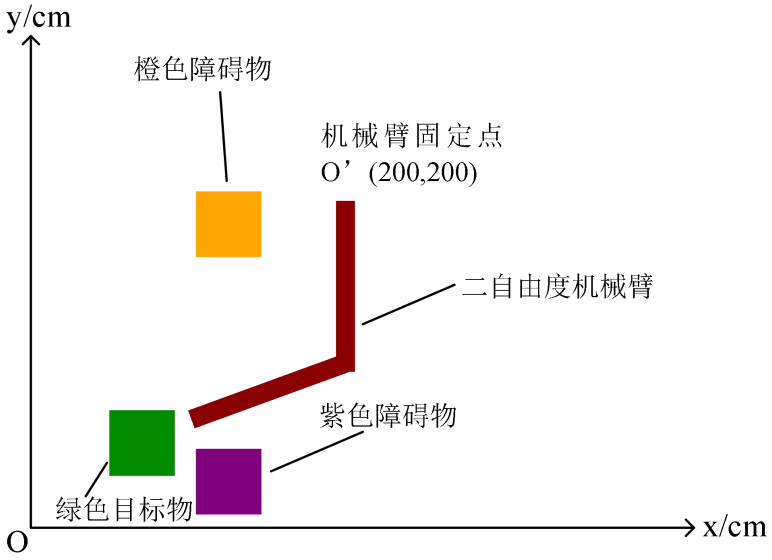


图 3.2 静态障碍物场景 1

Fig. 3.2 The NO.1 scene of static obstacles

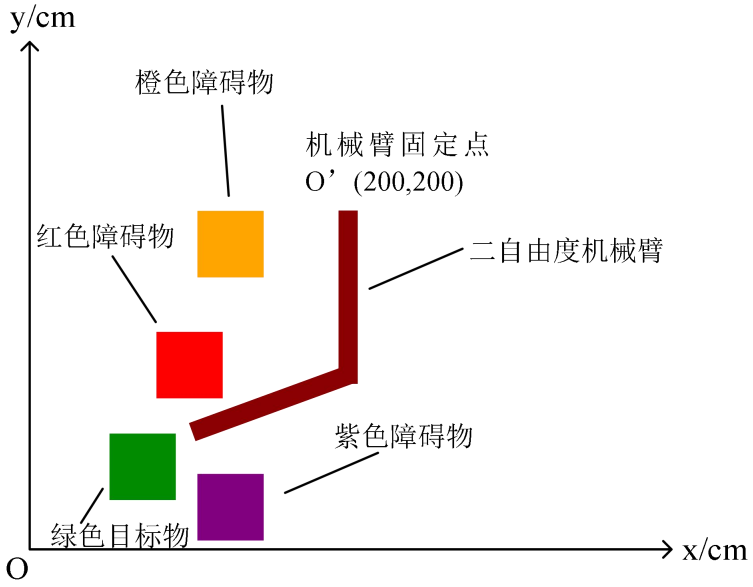


图 3.3 静态障碍物场景 2

Fig. 3.3 The NO.2 scene of static obstacles

中国知网 https://www.cnki.net

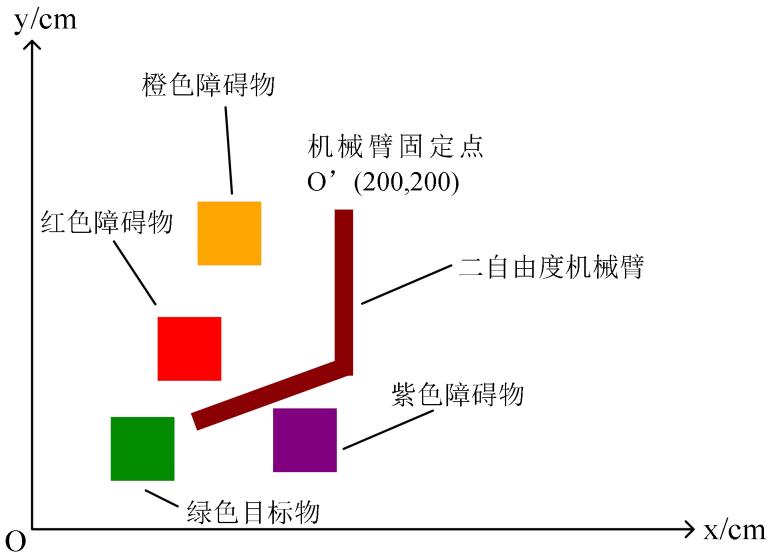


图 3.4 静态障碍物场景 3

Fig. 3.4 The NO.3 scene of static obstacles

静态障碍物场景的障碍物和目标物的中心点坐标如表 3.1 所示：

表 3.1 静态障碍物场景的正方形坐标

Tab. 3.1 The coordinates of squares in scenes of static obstacles

静态障碍物场景	1		2		3	
	x	y	x	y	x	y
绿色目标物	70cm	50cm	70cm	50cm	70cm	50cm
红色障碍物			100cm	115cm	100cm	115cm
橙色障碍物	125cm	190cm	125cm	190cm	125cm	190cm
紫色障碍物	125cm	25cm	125cm	25cm	175cm	55cm

3.4 静态障碍物场景下的实验设计

3.4.1 实验方案

在机械臂轨迹规划中，需要设计高效的深度强化学习算法和奖励函数，以规划高效可靠的机械臂避障轨迹，因此，为了验证设计的深度强化学习算法和奖励函数的高效性，本文将深度强化学习算法和奖励函数进行对比，具体做法如下：①在传统的二值奖励函数的基础上，将基于 DDPG 算法的避障奖励函数、基于 DDPG 算法的避障奖励函数和距离引导奖励函数进行对比，以验证距离引导奖励函数能使机械臂更快到达目标物位置；③在静态障碍物场景的奖励函数相同的前提下，将 DDPG 算法与 A3C 算法进行对比，以验证

中国知网 https://www.cnki.net

DDPG 算法比 A3C 算法的收敛速度更快。

在进行深度强化学习算法和奖励函数的对比后，为了规划相对高效的机械臂轨迹，还需要将轨迹“行走”的步数进行对比，选择步数最少的轨迹，并且当此轨迹在多个场景中均碰不到静态障碍物时，可将此轨迹作为最终规划的机械臂轨迹。

3.4.2 实验结果

图 3.5~3.13 为静态障碍物的三个场景分别在三种情况下的仿真结果，其中，DDPG 算法设置 1000 次回合，A3C 算法设置 4000 次回合（5 个并行的机械臂，平均每个机械臂设置 800 次回合），每次回合的最大步数均为 400 步。图中，ep_r 表示每次回合的奖励值，average_r 表示平均奖励值，设回合次数为 i，则具体计算方式如公式（3.7）所示：

$$average_r=\begin{cases} ep_r & i=1 \\ 0.995\times average_r+0.005\times ep_r & otherwise \end{cases} \tag{3.7}$$

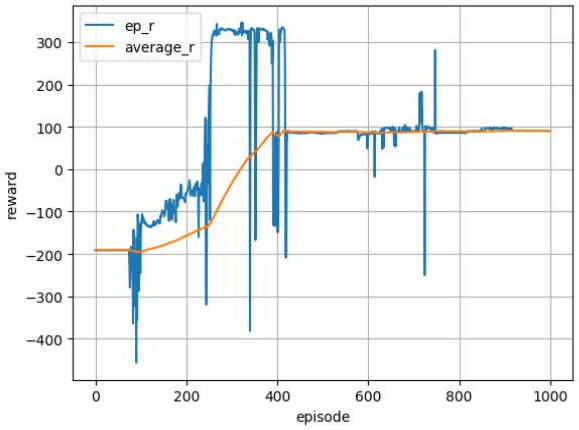


图 3.5 静态障碍物场景 1 基于 DDPG 算法的避障奖励图

Fig. 3.5 The graph of obstacle-avoidance reward based on DDPG algorithm in NO.1 scene of static obstacles

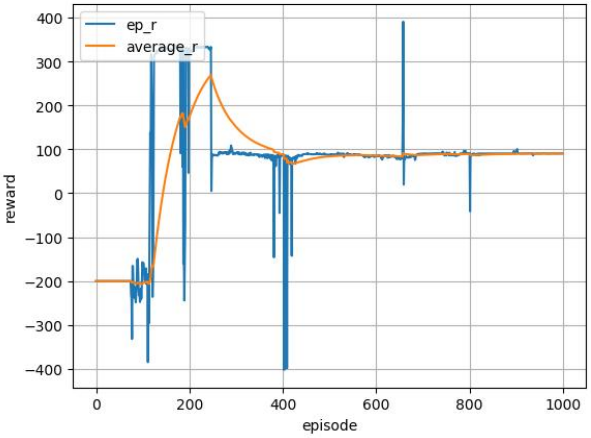


图 3.6 静态障碍物场景 2 基于 DDPG 算法的避障奖励图

Fig. 3.6 The graph of obstacle-avoidance reward based on DDPG algorithm in NO.2 scene of static obstacles

中国知网 https://www.cnki.net

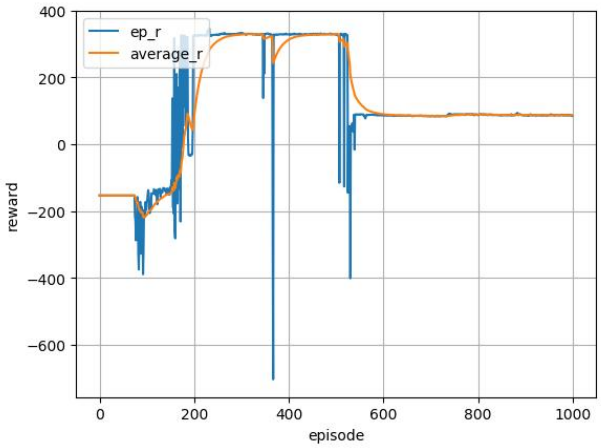


图 3.7 静态障碍物场景 3 基于 DDPG 算法的避障奖励图

Fig. 3.7 The graph of obstacle-avoidance reward based on DDPG algorithm in NO.3 scene of static obstacles

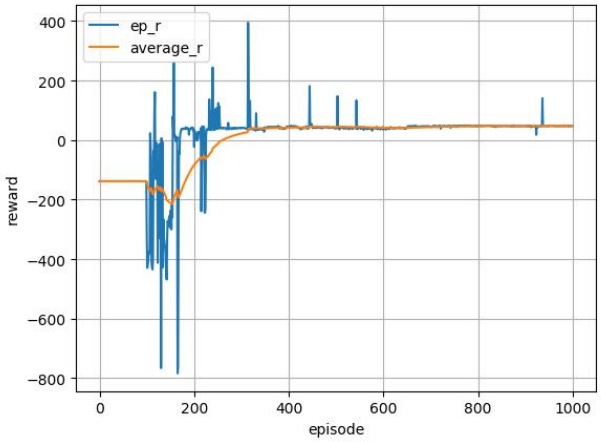


图 3.8 静态障碍物场景 1 基于 DDPG 算法的避障奖励和距离引导奖励图

Fig. 3.8 The graph of obstacle-avoidance reward and distance-guided reward based on DDPG algorithm in NO.1 scene of static obstacles

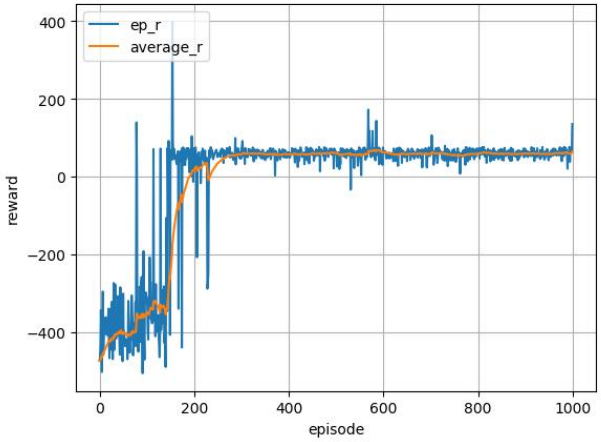


图 3.9 静态障碍物场景 2 基于 DDPG 算法的避障奖励和距离引导奖励图

Fig. 3.9 The graph of obstacle-avoidance reward and distance-guided reward based on DDPG algorithm in NO.2 scene of static obstacles

中国知网 https://www.cnki.net

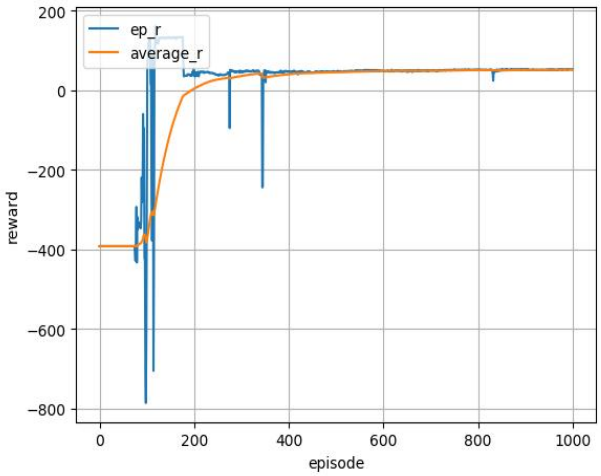


图 3.10 静态障碍物场景 3 基于 DDPG 算法的避障奖励和距离引导奖励图

Fig. 3.10 The graph of obstacle-avoidance reward and distance-guided reward based on DDPG algorithm in NO.3 scene of static obstacles

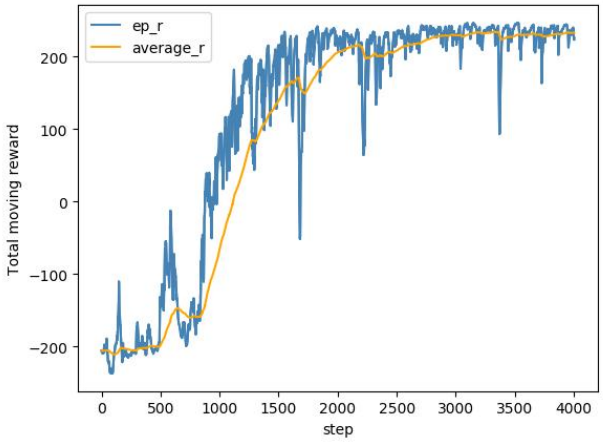


图 3.11 静态障碍物场景 1 基于 A3C 算法的避障奖励和距离引导奖励图

Fig. 3.11 The graph of obstacle-avoidance reward and distance-guided reward based on A3C algorithm in NO.1 scene of static obstacles

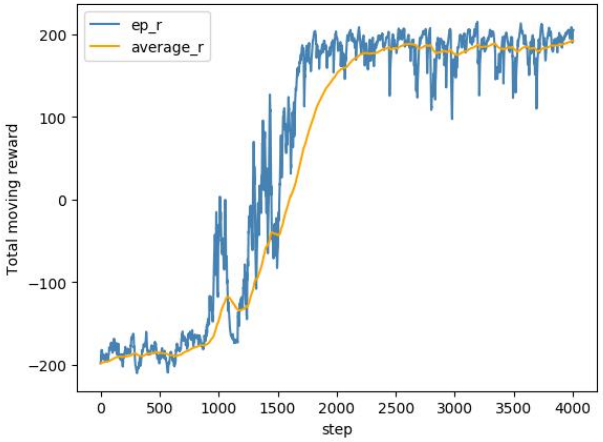


图 3.12 静态障碍物场景 2 基于 A3C 算法的避障奖励和距离引导奖励图

Fig. 3.12 The graph of obstacle-avoidance reward and distance-guided reward based on A3C algorithm in NO.2 scene of static obstacles

中国知网 https://www.cnki.net

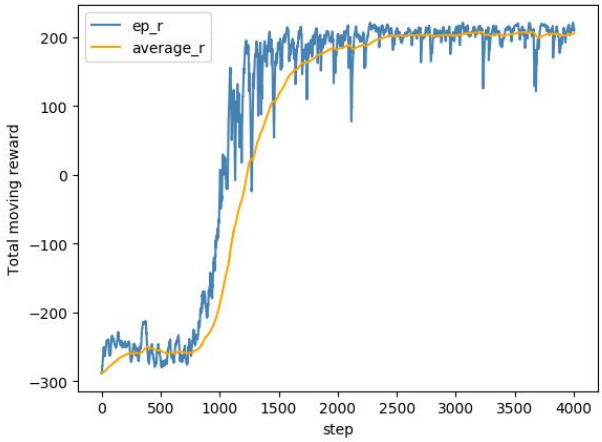


图 3.13 静态障碍物场景 3 基于 A3C 算法的避障奖励和距离引导奖励图

Fig. 3.13 The graph of obstacle-avoidance reward and distance-guided reward based on A3C algorithm in NO.3 scene of static obstacles

由仿真结果图的对比情况可看出，在场景相同且均选用 DDPG 算法的前提下，增加避障奖励和距离引导奖励后，三个场景分别在大约第 350、300、400 次回合收敛，而仅增加避障奖励后，三个场景分别在大约第 400、500、600 次回合收敛，说明增加距离引导奖励之后，机械臂能更快地到达目标物位置；在场景和奖励函数都相同的前提下，A3C 算法分别在大约第 3000、2500、2500 次回合收敛，即平均每个机械臂在大约第 600、500、500 次回合收敛，说明 DDPG 算法比 A3C 算法的收敛速度更快。从仿真结果图还可看出，DDPG 算法的收敛效果比 A3C 算法更好、更稳定。因此，在静态障碍物场景中，选用基于 DDPG 算法的增加避障奖励和距离引导奖励作为下一小节的机械臂轨迹规划的方法。

3.5 静态障碍物场景下的机械臂轨迹

图 3.14~3.16 为机械臂在静态障碍物场景下经过 1000 次训练后，进行测试的轨迹，其中，虚线部分为机械臂中间点的轨迹，实线部分为机械臂端点的轨迹，两条棕色线为机械臂结束测试时的状态：

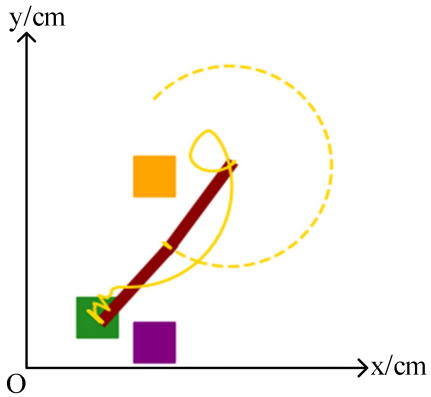


图 3.14 静态障碍物场景 1 的机械臂轨迹

Fig. 3.14 The trajectory of manipulator in NO.1 scene of static obstacles

中国知网 https://www.cnki.net

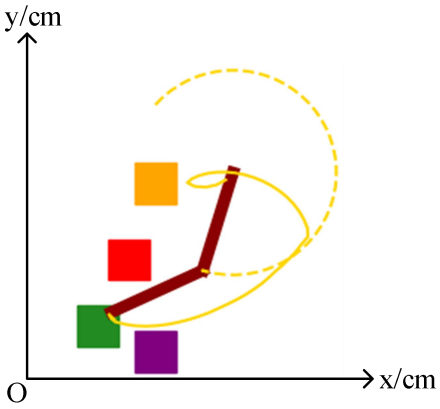


图 3.15 静态障碍物场景 2 的机械臂轨迹

Fig. 3.15 The trajectory of manipulator in NO.2 scene of static obstacles

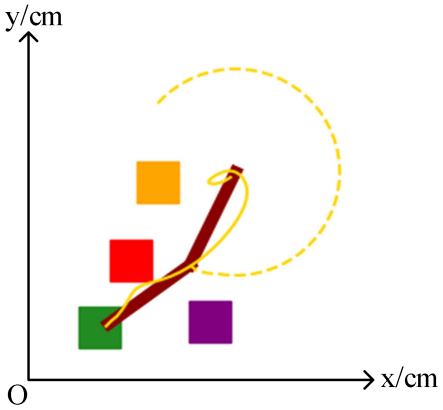


图 3.16 静态障碍物场景 3 的机械臂轨迹

Fig. 3.16 The trajectory of manipulator in NO.3 scene of static obstacles

为了使规划的机械臂轨迹是相对高效的，还需要将三个场景的机械臂轨迹的步数进行对比，选择步数最少的轨迹，并且当此轨迹在三个场景中均碰不到障碍物时，可将此轨迹作为最终规划的机械臂轨迹。对比结果如图 3.17 所示：

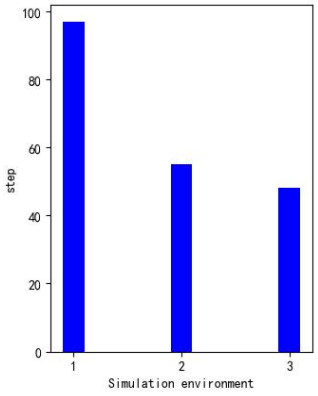


图 3.17 静态障碍物场景的机械臂轨迹步数

Fig. 3.17 The number of steps of trajectory of the manipulator in scenes of static obstacles

由对比结果可看出，场景 3 的步数最少，因此，将场景 3 的机械臂轨迹迁移到场景 1 和场景 2 中，效果如图 3.18、3.19 所示：

中国知网 https://www.cnki.net

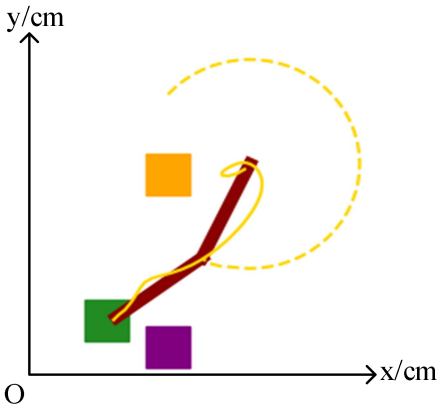


图 3.18 静态障碍物场景 1 修改后的机械臂轨迹

Fig. 3.18 The modified trajectory of manipulator in NO.1 scene of static obstacles

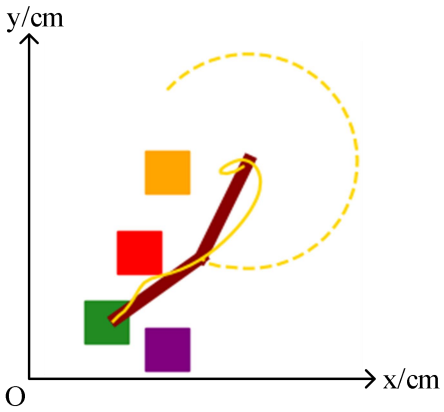


图 3.19 静态障碍物场景 2 修改后的机械臂轨迹

Fig. 3.19 The modified trajectory of manipulator in NO.2 scene of static obstacles

由于修改后的机械臂轨迹没有与障碍物相交，所以此轨迹可作为最终在静态障碍物场景规划的机械臂轨迹。

3.6 本章小结

本章首先对机械臂轨迹规划进行了概述，包括基于深度强化学习算法代替传统算法进行轨迹规划的原因，以及深度强化学习算法中的奖励函数在机械臂轨迹规划中的重要性，并引出了后文针对机械臂轨迹规划的具体内容；然后介绍了静态障碍物场景中的奖励函数，包括传统二值奖励函数、距离引导奖励函数、静态避障奖励函数，其中，距离引导奖励函数的作用是使机械臂更快到达目标物位置，静态避障奖励函数的作用是使机械臂避开静态障碍物；然后介绍了静态障碍物的二维仿真环境，包括静态障碍物场景图和各个正方形的坐标；之后介绍了在静态障碍物场景进行机械臂轨迹规划的整体实验方案，并针对三个场景在各种条件下的收敛情况进行了具体分析，将 DDPG 算法与 A3C 算法进行对比、在静

中国知网 https://www.cnki.net

态障碍物场景增加距离引导奖励函数，其结果验证了 DDPG 算法比 A3C 算法的收敛速度更快，增加距离引导奖励函数能加快奖励值的收敛速度，使机械臂更快到达目标物位置；最后规划了机械臂在静态障碍物的三个场景训练后，进行测试的避障轨迹，并选择了步数最少的轨迹，在确保机械臂在三个场景都能避开静态障碍物的前提下，将此轨迹作为最终规划的机械臂轨迹。

中国知网 https://www.cnki.net

第 4 章 动态障碍物场景下的机械臂轨迹规划

4.1 动态障碍物场景下的奖励函数改进

考虑到机械臂在实际的工作环境中有突发障碍物的风险，所以需要在静态障碍物场景的基础上，对动态障碍物场景进行机械臂轨迹规划，并且要求机械臂避开静态障碍物和动态障碍物，因此需要在静态障碍物场景的奖励函数的基础上，增加了动态避障奖励函数，即当机械臂的关节和连杆到达动态障碍物的位置时，奖励值为-2，反之奖励值为 0。设动态障碍物的任意两个不相邻的顶点坐标为(x_7,y_7)、(x_8,y_8)，如图 4.1 所示：

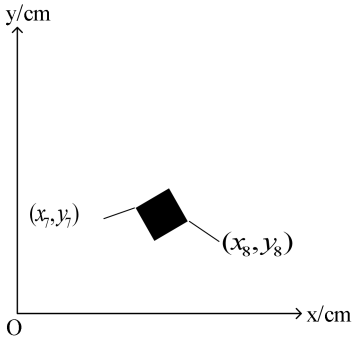


图 4.1 动态障碍物坐标

Fig. 4.1 The coordinates of dynamic obstacle

则奖励函数如公式（4.1）所示：

$$r_7=\begin{cases}-2 & \left(x_7<x_i<x_8\right)and \\ & \left(y_7<y_i<y_8\right)\ \left(i=1、2、3、4、5、6\right) \\ 0 & otherwise\end{cases} \tag{4.1}$$

由于动态障碍物场景比静态障碍物场景更加复杂，所以为了使机械臂更快地避开动态障碍物，并绘制相应的机械臂轨迹，需要引导机械臂对避开动态障碍物进行正确地探索，避免由于得不到负反馈而无法及时避开动态障碍物，增加了机械臂端点(x_2,y_2)与动态障碍物的任意一个顶点$\left((x_7,y_7)或(x_8,y_8)\right)$的距离相关的动态分区奖励函数，即当机械臂的端点与动态障碍物距离很近时（本文以 0cm~5cm 作为机械臂的端点与动态障碍物顶点的近距离），奖励值为-0.5，反之奖励值为 0，设机械臂的端点与障碍物的顶点距离为d_{obs}，则$d_{obs}=\sqrt{(x_6-x_j)^2+(y_6-y_j)^2}(j=7、8)$，因此，动态障碍物分区奖励函数（以下简称动态分区奖励函数）如公式（4.2）所示：

中国知网 https://www.cnki.net

$$r_8 = \begin{cases} -0.5 & 0 \le d_{obs} \le 5 \\ 0 & otherwise \end{cases} \tag{4.2}$$

$r_7 + r_8$ 统称为动态奖励函数。

4.2 动态障碍物场景

本文在二维仿真环境中进行动态障碍物场景下的机械臂轨迹规划研究，并且目标物和障碍物均为边长是 40cm 的正方形。场景中的机械臂和动态障碍物的移动速度均为 200 步/秒。动态障碍物的三组场景均在静态障碍物场景的基础上，增加一个黑色动态障碍物。三组的目标均是通过避障的方式到达绿色正方形的位置。动态障碍物的三组场景示意图如图 4.2~4.4 所示：

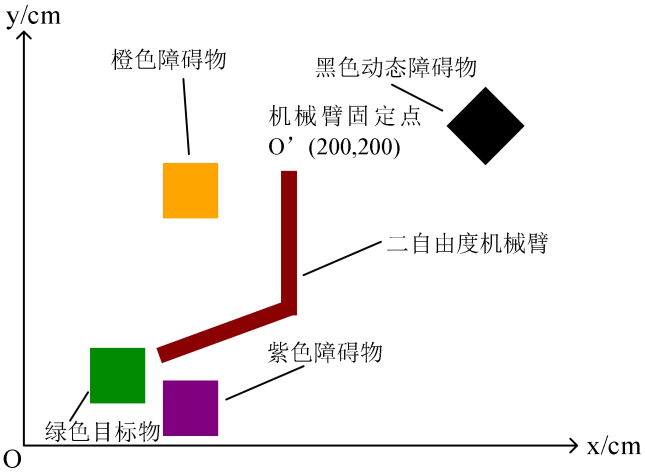


图 4.2 动态障碍物场景 1

Fig. 4.2 The NO.1 scene of dynamic obstacle

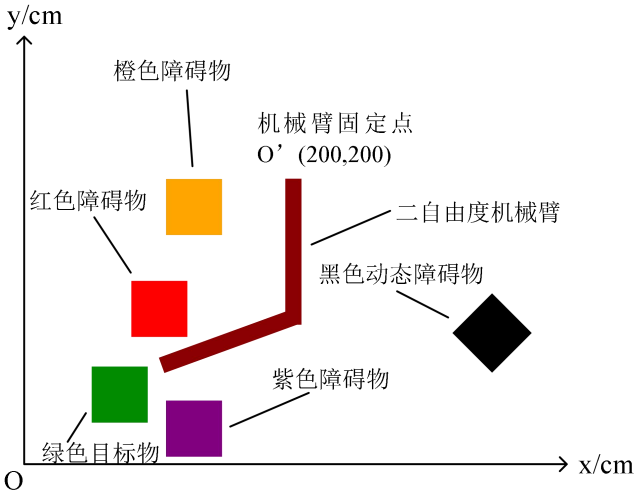


图 4.3 动态障碍物场景 2

Fig. 4.3 The NO.2 scene of dynamic obstacle

中国知网 https://www.cnki.net

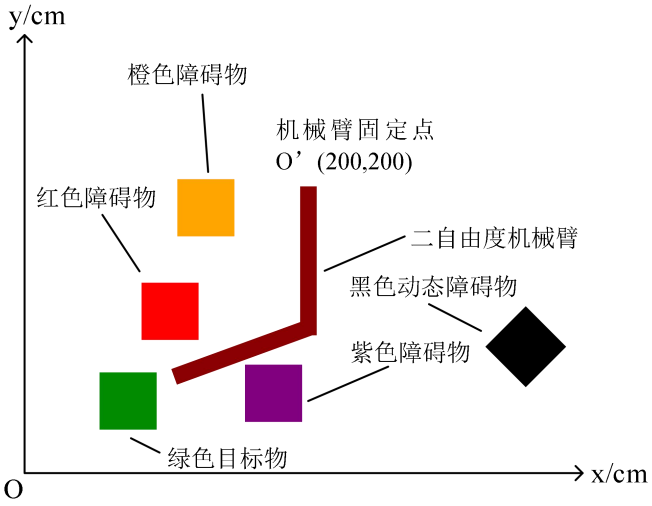


图 4.4 动态障碍物场景 3

Fig. 4.4 The NO.3 scene of dynamic obstacle

4.3 动态障碍物场景下的实验设计

4.3.1 实验方案

在动态障碍物场景的机械臂轨迹规划中，同样需要设计高效的深度强化学习算法和奖励函数，以规划高效可靠的机械臂避障轨迹，因此，为了验证设计的深度强化学习算法和奖励函数的高效性，本文将深度强化学习算法和奖励函数进行对比，具体做法如下：①在静态障碍物场景的所有奖励函数的基础上，将基于 DDPG 算法的动态避障奖励函数、基于 DDPG 算法的动态避障奖励函数和动态分区奖励函数进行对比，以验证动态分区奖励函数能使机械臂更快避开动态障碍物；②在动态障碍物场景的奖励函数相同的前提下，将 DDPG 算法与 A3C 算法进行对比，以验证 DDPG 算法比 A3C 算法的收敛速度更快。

在进行深度强化学习算法和奖励函数的对比后，为了规划相对高效的机械臂轨迹，还需要将轨迹“行走”的步数进行对比，选择步数最少的轨迹，并且当此轨迹在三个场景中均碰不到静态障碍物和动态障碍物时，可将此轨迹作为最终规划的机械臂轨迹。

4.3.2 实验结果

图 4.5~4.13 为动态障碍物的三个场景分别在三种情况下的仿真结果，回合次数、每次回合的最大步数、平均奖励计算方式与静态障碍物场景相同。

中国知网 https://www.cnki.net

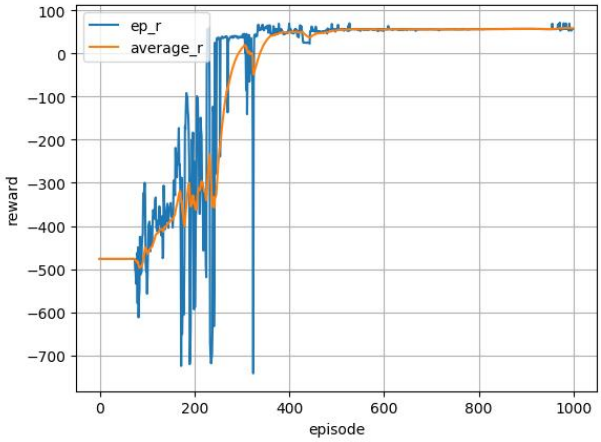


图 4.5 动态障碍物场景 1 基于 DDPG 算法的动态避障奖励图

Fig. 4.5 The graph of dynamic obstacle-avoidance reward based on DDPG algorithm in NO.1 scene of dynamic obstacle

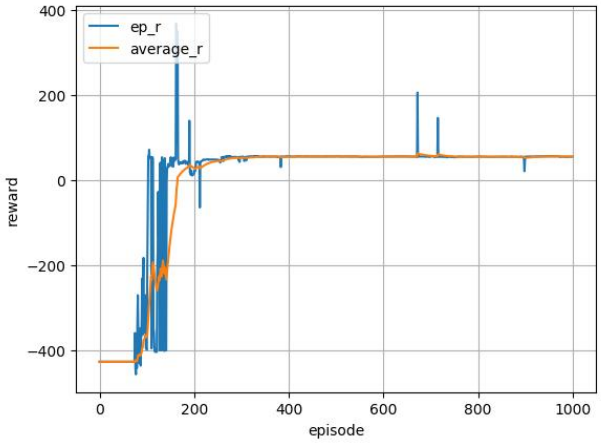


图 4.6 动态障碍物场景 2 基于 DDPG 算法的动态避障奖励图

Fig. 4.6 The graph of dynamic obstacle-avoidance reward based on DDPG algorithm in NO.2 scene of dynamic obstacle

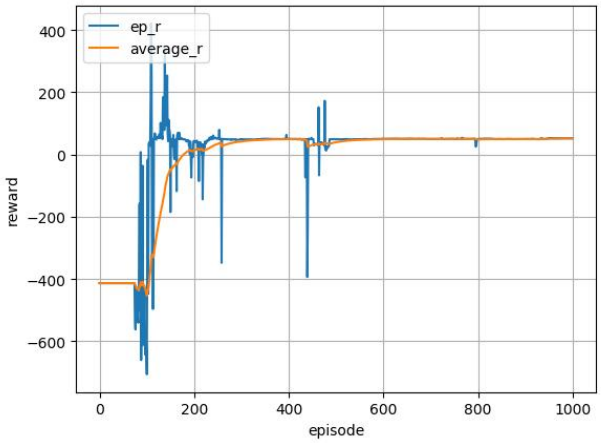


图 4.7 动态障碍物场景 3 基于 DDPG 算法的动态避障奖励图

Fig. 4.7 The graph of dynamic obstacle-avoidance reward based on DDPG algorithm in NO.3 scene of dynamic obstacle

中国知网 https://www.cnki.net

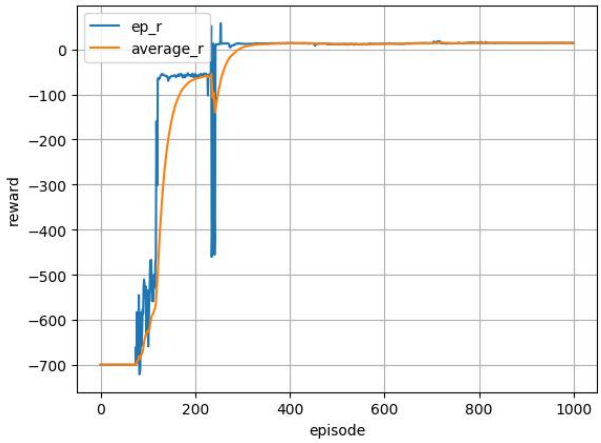


图 4.8 动态障碍物场景 1 基于 DDPG 算法的动态避障奖励和动态分区奖励图

Fig. 4.8 The graph of dynamic obstacle-avoidance reward and dynamic-partition reward based on DDPG algorithm in NO.1 scene of dynamic obstacle

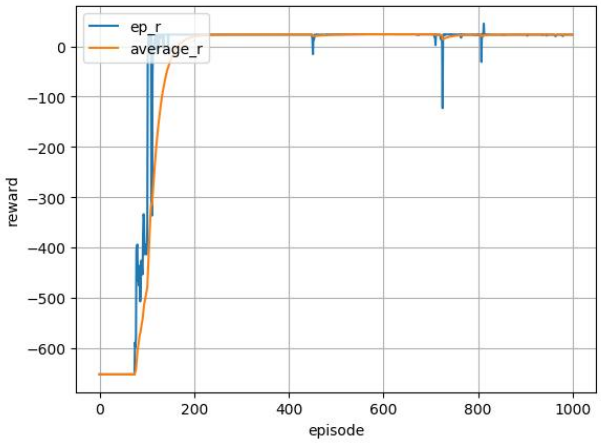


图 4.9 动态障碍物场景 2 基于 DDPG 算法的动态避障奖励和动态分区奖励图

Fig. 4.9 The graph of dynamic obstacle-avoidance reward and dynamic-partition reward based on DDPG algorithm in NO.2 scene of dynamic obstacle

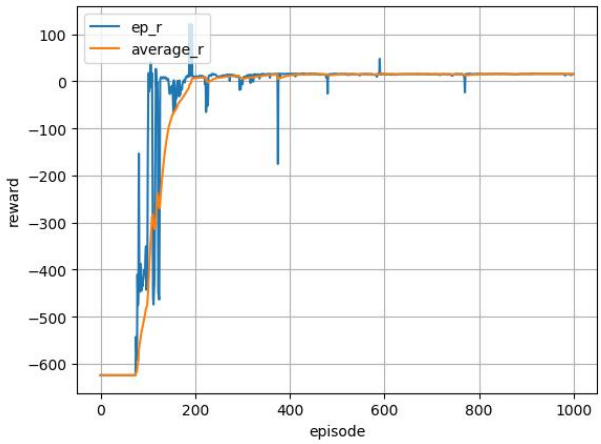


图 4.10 动态障碍物场景 3 基于 DDPG 算法的动态避障奖励和动态分区奖励图

Fig. 4.10 The graph of dynamic obstacle-avoidance reward and dynamic-partition reward graph based on DDPG algorithm in NO.3 scene of dynamic obstacle

中国知网 https://www.cnki.net

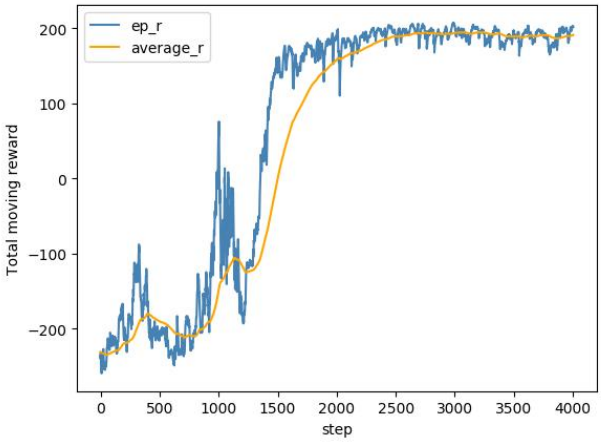


图 4.11 动态障碍物场景 1 基于 A3C 算法的动态避障奖励和动态分区奖励图

Fig. 4.11 The graph of dynamic obstacle-avoidance reward and dynamic-partition reward graph based on A3C algorithm in NO.1 scene of dynamic obstacle

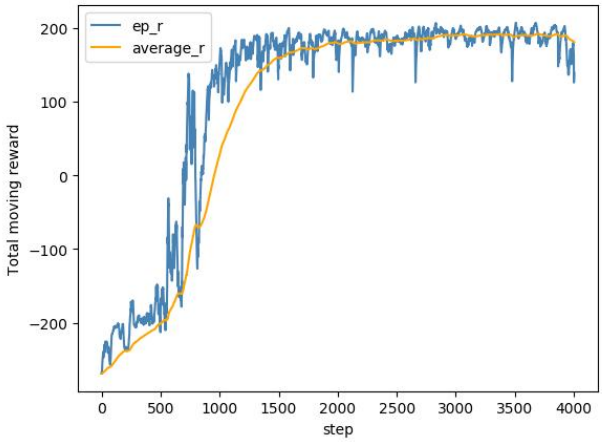


图 4.12 动态障碍物场景 2 基于 A3C 算法的动态避障奖励和动态分区奖励图

Fig. 4.12 The graph of dynamic obstacle-avoidance reward and dynamic-partition reward graph based on A3C algorithm in NO.2 scene of dynamic obstacle

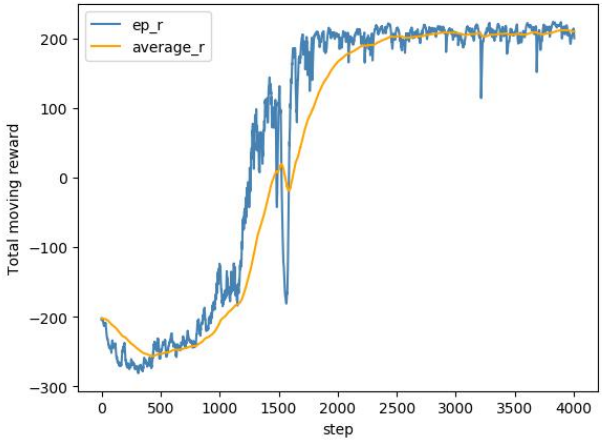


图 4.13 动态障碍物场景 3 基于 A3C 算法的动态避障奖励和动态分区奖励图

Fig. 4.13 The graph of dynamic obstacle-avoidance reward and dynamic-partition reward graph based on A3C algorithm in NO.3 scene of dynamic obstacle

中国知网 https://www.cnki.net

由仿真结果图的对比情况可看出，在场景相同且均选用 DDPG 算法的前提下，增加动态避障奖励和动态分区奖励后，三个场景分别在大约第 300、200、400 次回合收敛，而仅增加动态避障奖励后，三个场景分别在大约第 500、300、500 次回合收敛，说明增加动态分区奖励后，机械臂能更快地避开动态障碍物；在场景和奖励函数都相同的前提下，A3C 算法分别在大约第 2500、2000、2500 次回合收敛，即平均在大约第 500、400、500 次回合收敛，说明在动态障碍物场景中，DDPG 算法同样比 A3C 算法的收敛速度更快。从仿真结果图还可看出，DDPG 算法的收敛效果比 A3C 算法更好、更稳定。因此，在动态障碍物场景中，选用基于 DDPG 算法的增加动态避障奖励和动态分区奖励作为下一小节的机械臂轨迹规划的方法。

4.4 动态障碍物场景下的机械臂轨迹

图 4.14~4.16 为机械臂在动态障碍物场景下的测试的轨迹，其中，虚线部分为机械臂中间点的轨迹，实线部分为机械臂端点的轨迹，冒号部分为动态障碍物的轨迹，两条棕色线为机械臂结束测试时的状态：

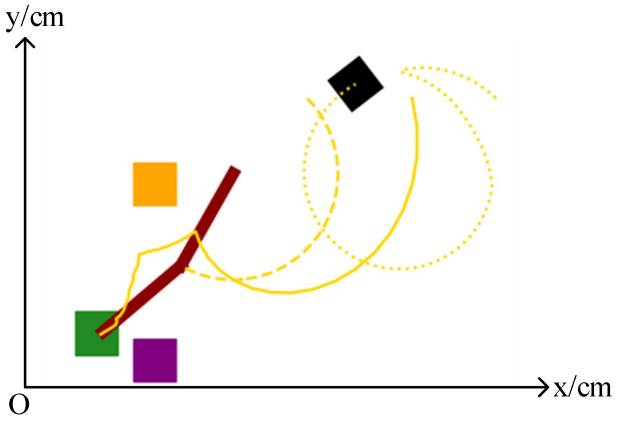


图 4.14 动态障碍物场景 1 的机械臂轨迹

Fig. 4.14 The trajectory of manipulator in NO.1 scene of dynamic obstacle

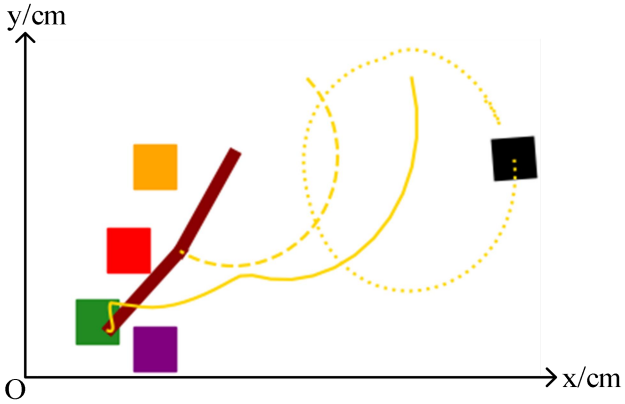


图 4.15 动态障碍物场景 2 的机械臂轨迹

Fig. 4.15 The trajectory of manipulator in NO.2 scene of dynamic obstacle

中国知网 https://www.cnki.net

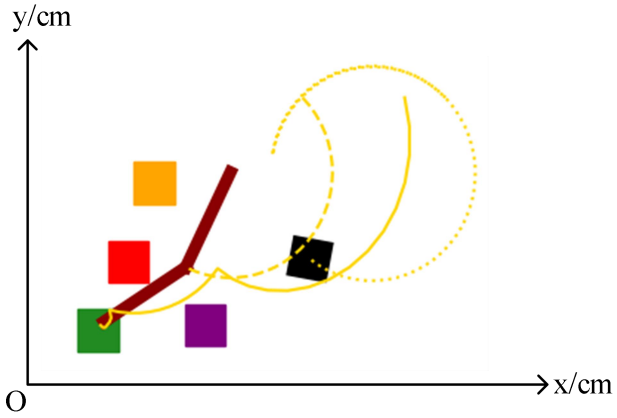


图 4.16 动态障碍物场景 3 的机械臂轨迹

Fig. 4.16 The trajectory of manipulator in NO.3 scene of dynamic obstacle

将三个场景的机械臂轨迹的步数进行对比，结果如图 4.17 所示：

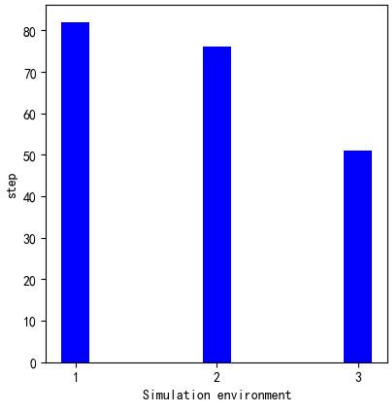


图 4.17 动态障碍物场景的机械臂轨迹步数

Fig. 4.17 The number of steps of trajectory of manipulator in scene of dynamic obstacle

由对比结果可看出，场景 3 的步数最少，因此，将场景 3 的机械臂轨迹迁移到场景 1 和场景 2 中，并在动态障碍物的轨迹步数与机械臂的轨迹步数相同的前提下规划动态障碍物的轨迹，效果如图 4.18、4.19 所示：

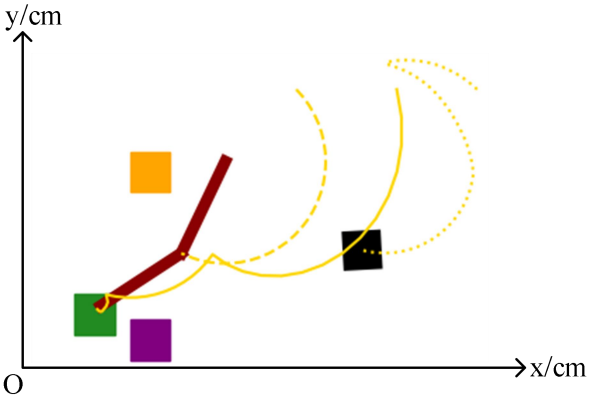


图 4.18 动态障碍物场景 1 修改后的机械臂轨迹

Fig. 4.18 The modified trajectory of manipulator in NO.1 scene of dynamic obstacle

中国知网 https://www.cnki.net

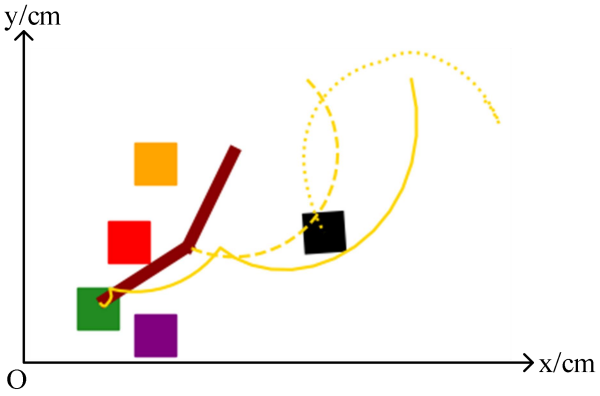


图 4.19 动态障碍物场景 2 修改后的机械臂轨迹

Fig. 4.19 The modified trajectory of manipulator in NO.2 scene of dynamic obstacle

由修改后的机械臂轨迹可看出，机械臂避开了静态障碍物。为了验证机械臂在测试过程中避开了动态障碍物，还需要规划动态障碍物经过虚线部分与冒号部分的交点时的机械臂轨迹图（即机械臂中间过程图），如图 4.21~4.23 所示；由于动态障碍物场景 1 的机械臂轨迹仅与动态障碍物相交，而没有与动态障碍物的轨迹相交，所以针对此场景，规划了机械臂和动态障碍物“行走”了整个轨迹的一半时的相应轨迹，如图 4.20 所示：

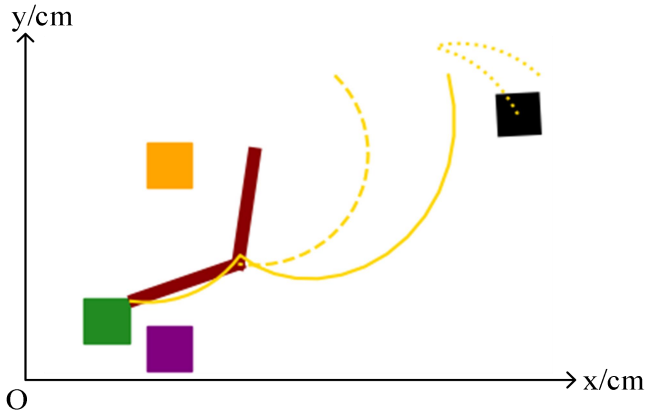


图 4.20 动态障碍物场景 1 的机械臂中间过程图

Fig. 4.20 The intermediate process of manipulator in No.1 scene of dynamic obstacle

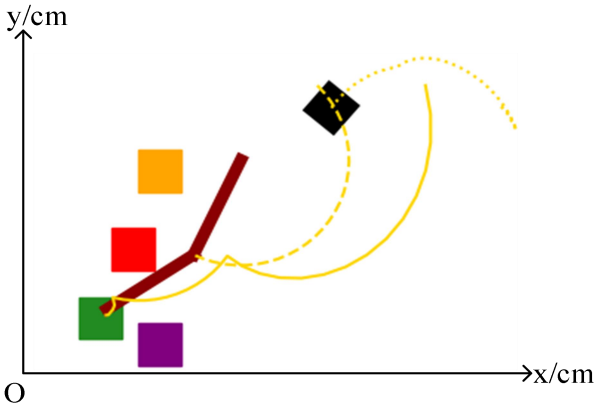


图 4.21 动态障碍物场景 2 的机械臂中间过程图

Fig. 4.21 The intermediate process of manipulator in No.2 scene of dynamic obstacle

中国知网 https://www.cnki.net

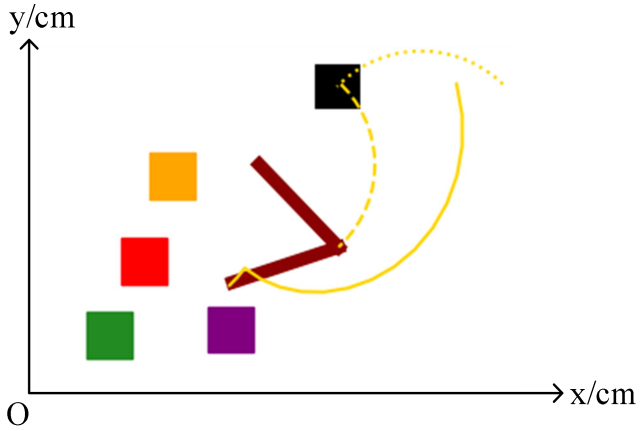


图 4.22 动态障碍物场景 3 的机械臂中间过程图 1

Fig. 4.22 The first intermediate process of manipulator in No.3 scene of dynamic obstacle

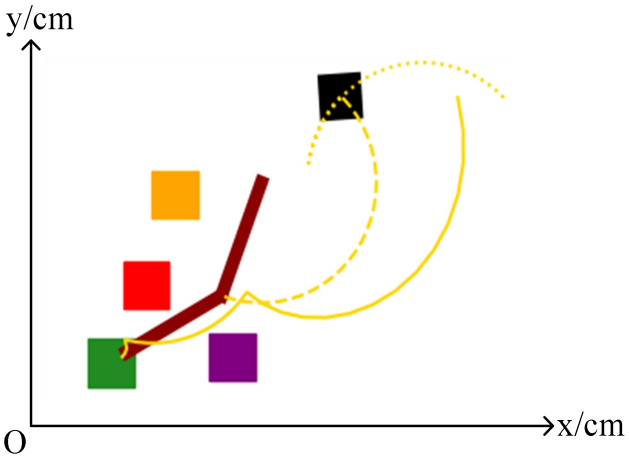


图 4.23 动态障碍物场景 3 的机械臂中间过程图 2

Fig. 4.23 The second intermediate process of manipulator in No.3 scene of dynamic obstacle

由图可看出，当动态障碍物与机械臂的轨迹交点时，机械臂均已接近或到达绿色目标物的位置（图 4.20、4.21、4.23），并且由图 4.22 可看出，动态障碍物场景 3 的机械臂已走完整个轨迹的一半以上，说明在测试过程中，机械臂成功地避开了动态障碍物。

4.5 本章小结

本章首先介绍了在动态障碍物场景下设计的奖励函数，包括动态避障奖励函数、动态分区奖励函数，其作用是使机械臂更快地避开动态障碍物；然后介绍了动态障碍物的二维仿真环境，即动态障碍物场景图；然后介绍了在动态障碍物场景进行机械臂轨迹规划的整体实验方案，并针对三个场景在各种条件下的收敛情况进行了具体分析，将 DDPG 算法与 A3C 算法进行对比、在动态障碍物场景增加动态分区奖励函数，其结果验证了 DDPG 算法比 A3C 算法的收敛速度更快，增加动态分区奖励函数能加快奖励值的收敛速度，使机械臂更快避开动态障碍物；最后规划了机械臂在动态障碍物的三个场景训练后，进行测试的避障轨迹，并选择了步数最少的轨迹，在确保机械臂在三个场景都能避开静态障碍物

中国知网 https://www.cnki.net

和动态障碍物的前提下，将此轨迹作为最终规划的机械臂轨迹。为了验证机械臂在测试过程中避开了动态障碍物，还规划了机械臂中间过程图，结果表明机械臂成功地避开了动态障碍物。

中国知网 https://www.cnki.net

第 5 章 总结与展望

5.1 总结

本文研究了基于改进深度强化学习的机械臂轨迹规划。深度强化学习算法是通过让机械臂在有障碍物的情况下，进行反复的尝试，并得到奖励，来学习如何正确地避开障碍物并到达目标物位置，进而规划相应的机械臂轨迹。本次研究完成的主要内容如下：

(1) 为了引出本文所使用的 DDPG 算法，本文首先介绍了强化学习、深度学习，以及结合二者的深度强化学习，其中，强化学习介绍了它的五大元素，深度学习介绍了它的学习过程和模型，并对深度强化学习进行了简单地介绍，然后基于深度强化学习中的 Actor-Critic 算法框架，介绍了三个适合于连续性动作的三个深度强化学习算法，具体包括 Actor-Critic 算法本身、结合 Actor-Critic 和 DQN 的 DDPG 算法、将 Actor-Critic 放到多个线程进行训练的 A3C 算法，包括各个算法的网络结构和伪代码。最终将 DDPG 算法与 A3C 算法进行对比，验证了 DDPG 算法比 A3C 算法的收敛速度更快；

(2) 针对静态障碍物场景，在传统二值奖励函数的基础上对奖励函数进行更新设计，具体内容如下：为了引导机械臂更快到达目标物位置，设计了距离引导奖励函数，包括负距离奖励、分区奖励、距离对比奖励，即机械臂距离目标物越近，奖励值越大；为了规划机械臂不与静态障碍物相交的轨迹，设计静态避障奖励函数，即在机械臂的连杆和关节到达静态障碍物位置的前提下，奖励值为负。仿真结果表明在传统二值奖励函数的基础上增加距离引导奖励函数能加快奖励值的收敛速度，进而加快了机械臂到达目标物位置的速度；

(3) 针对动态障碍物场景，在静态障碍物场景的奖励函数的基础上对奖励函数进行更新设计，具体内容如下：为了引导机械臂对避开动态障碍物进行正确地探索，设计动态分区奖励函数，即在机械臂距离动态障碍物较近的前提下，奖励值为负；为了使机械臂避开动态障碍物，设计动态避障奖励函数，即在机械臂的连杆和关节到达动态障碍物位置的前提下，奖励值为负。仿真结果表明在动态避障奖励函数的基础上增加动态分区奖励函数能加快奖励值的收敛速度，进而加快了机械臂避开动态障碍物的速度；

(4) 分别针对静态障碍物场景和动态障碍物场景规划了机械臂避障并到达目标物位置的轨迹。为了使规划的轨迹是相对高效的，将静态障碍物和动态障碍物的三个场景的机械臂步数分别进行对比，选择步数最少的轨迹，在确保机械臂避开静态障碍物的前提下，将此轨迹作为最终规划的机械臂轨迹。在动态障碍物场景下，还规划了机械臂中间过程图，其结果验证了机械臂避开了动态障碍物。

中国知网 https://www.cnki.net

5.2 展望

目前使用 DDPG 算法进行机械臂轨迹规划虽然取得了很好的效果，但是机械臂轨迹规划的方法仍在不断地创新中，在项目研究的过程中，又出现了 SAC 等更加新颖的深度强化学习算法，它们的奖励值收敛速度是否比 DDPG 算法更快，以及是否能规划出更优的机械臂避障轨迹，还需要进行更加深入地研究。因此，未来的工作应当更加深入地进行机械臂轨迹规划方法的研究，并选择更优的深度强化学习算法作为机械臂避障轨迹规划的算法。

中国知网 https://www.cnki.net

参考文献

[1] Nakai H, Yamataka M, Kuga T, et al. Development of dual-arm robot with multi-fingered hands[C]. IEEE International Symposium on Robot and Human Interactive Communication. IEEE, 2006:208-213.

[2] 王田苗, 陶永. 我国工业机器人技术现状与产业化发展战略[J]. 机械工程学报, 2014, 50(09): 1-13.

[3] 谢琳灿, 吴沁沁. 美德工业互联网发展经验及借鉴[J]. 宏观经济管理，2022 (03): 83-90.

[4] Le Q D, Kang H J. Finite-time fault-tolerant control for a robot manipulator based on synchronous terminal sliding mode control[J]. Applied Sciences, 2020, 10(9): 2998.

[5] Li T, Zheng S, Shu X, et al. Self-recognition grasping operation with a vision-based redundant manipulator system[J]. Applied Sciences, 2019, 9(23): 5172.

[6] Ruan X, Li J, Feng X, et al. The motion control of mobile self-balancing robot based on vision-teleoperation[C]. Intelligent Control and Automation (WCICA), 2012 10th World Congress on. IEEE, 2012.

[7] 王婴, 胡立生. 基于深度 Q 学习的工业机械臂路径规划方法[J]. 化工自动化及仪表, 2018, 45(2): 141-145; 171.

[8] 唐智浩. 空间机械臂动力学预测与控制方法研究[D]. 哈尔滨：哈尔滨工业大学, 2021.

[9] 李岚普. 关节故障突发下空间机械臂停机策略研究[D]. 北京：北京邮电大学, 2021.

[10] 宋启良, 梁秀兵, 胡振峰等. 现代工业机器人的发展,应用及其绿色修复再制造研究现状[J]. 材料保护, 2020, 53(12): 95-100.

[11] Kathib O. Real-time Obstacle-avoidance for manipulators and mobile robots[C]. IEEE International Conference on Robotics and Automation. 1985: 500-505.

[12] 袁朝春, 翁烁丰, 何友国等. 基于改进人工势场法的路径规划决策一体化算法研究[J]. 农业机械学报, 2019, 50(9): 394-403.

[13] 徐晓苏, 袁杰. 基于改进强化学习的移动机器人路径规划方法[J]. 中国惯性技术学报, 2019, 27(3): 314-320.

[14] 邱博, 单梁, 常路等. 基于改进人工势场法双向规划的双机械臂避碰路径规划[J]. 江苏科技大学学报（自然科学版）, 2021, 35(5): 72-79.

[15] Fang Z, Liang X. Intelligent obstacle avoidance path planning method for picking manipulator combined with artificial potential field method[J]. Industrial Robot, 2022, 1: 1-16.

中国知网 https://www.cnki.net

[16] 赵真明, 孟正大. 基于加权 A*算法的服务型机器人路径规划[J]. 华中科技大学学报：自然科学版, 2008(S1): 196-198.

[17] Xu Z, Guo S, Zhang L. A path planning method of 6-DOF robot for mirror therapy based on A* algorithm[J]. Technology and health care: official journal of the European Society for Engineering and Medicine, 2022, 30(1): 105-116.

[18] 张许有. 机械臂平滑避障路径规划及轨迹跟踪研究[D]. 安徽：安徽工程大学, 2021.

[19] Lavalle S M. Rapidly-exploring random trees : a new tool for path planning[J]. Algorithmic & Computational Robotics New Directions, 1999, 1(1): 293-308.

[20] 王滨, 金明河, 谢宗武等. 基于启发式的快速扩展随机树路径规划算法[J]. 机械制造, 2007, 45(012):1-4.

[21] Lindemann S R, Lavalle S M. Current issues in sampling-based motion planning[C]. Robotics Research, The Eleventh International Symposium, ISRR, October 19-22, 2003, Siena, Italy. DBLP, 2003.

[22] Yuan C, Zhang W, Liu G, et al. A heuristic rapidly-exploring random trees method for manipulator motion planning[J]. IEEE Access, 2020, 8: 900-910.

[23] Yi J, Yuan Q, Sun R, et al. Path planning of a manipulator based on an improved P_RRT* algorithm[J]. Complex & Intelligent Systems, 2022, 8(3): 2227-2245.

[24] 刘驰, 田成军, 史俊等. 四自由度机械臂目标抓取轨迹规划的研究[J]. 长春理工大学学报（自然科学版）, 2022, 45(1): 65-71.

[25] Gao M, Ding P, Yang Y. Time-optimal trajectory planning of industrial robots based on particle swarm optimization[C]. Fifth International Conference on Instrumentation and Measurement. IEEE, 2021: 1934-1939.

[26] 孙颙琰, 郭文勇, 孙云岭等.基于改进 NURBS 曲线的水下机械臂轨迹规划[J]. 舰船电子工程, 2023, 43(1): 47-52.

[27] 李国洪, 王远亮. 基于 B 样条和改进遗传算法的机器人时间最优轨迹规划[J]. 计算机应用与软件, 2020, 37(11): 215-223、279.

[28] 王青, 叶明露, 贾秀海. 基于 5 次非均匀 B 样条曲线的 4 自由度机器人轨迹规划[J]. 轻工机械, 2022, 40(6): 7-13.

[29] Nie L, Yang Y, Wang X, et al. Trajectory planning algorithm of manipulator based on NURBS[J]. International Journal of Frontiers in Engineering Technology, 2023, 5(3): 49-56.

中国知网 https://www.cnki.net

[30] Xie S, Chu X, Zheng M, et al. A composite learning method for multi-ship collision avoidance based on reinforcement learning and inverse control[J]. Neurocomputing, 2020, 411: 375-392.

[31] Ou J, Guo X, Zhu M, et al. Autonomous quadrotor obstacle avoidance based on dueling double deep recurrent Q-learning with monocular vision[J]. Neurocomputing, 2021, 441: 300-310.

[32] Huang R, Qin C, Li J L, et al. Path planning of mobile robot in unknown dynamic continuous environment using reward-modified deep Q-network[J]. Optimal Control Applications and Methods, 2021, 21(7): 1-18.

[33] Yan C, Xiang X, Wang C. Towards real-time path planning through deep reinforcement learning for a UAV in dynamic environments[J]. Journal of Intelligent & Robotic Systems: Theory & Application, 2020, 98(2): 297-309.

[34] Kim H, Lee W. Dynamic obstacle avoidance of mobile robots using real-time Q-learning[C]. 2022 International Conference on Electronics, Information, and Communication. ICEIC, 2022: 1-2.

[35] 李辉, 祁宇明. 一种复杂环境下基于深度强化学习的机器人路径规划方法[J]. 计算机应用研究, 2020, 37(1):129-131.

[36] 霍志会. 基于强化学习的 UGV 在复杂环境下的路径探索关键技术研究[D]. 浙江：浙江科技学院, 2022.

[37] Xu X, Lu Y, Liu X, et al. Intelligent collision avoidance algorithms for USVs via deep reinforcement learning under COLREGs[J]. Ocean Engineering, 2020, 217(3) : 107704.

[38] Cimurs R, Jin H L, Suh I H. Goal-oriented obstacle avoidance with deep reinforcement learning in continuous action space[J]. Electronics, 2020, 9(3) :411.

[39] Volodymyr M , Koray K , David S, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[40] Denavit J , Hartenberg R S . A kinematic notation for lower-pair mechanisms based on matrices[J]. Journal of Applied Mechanics, 1955, 22: 215-221.

[41] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.

[42] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.

[43] 尹宝才, 王文通, 王立春. 深度学习研究综述[J]. 北京工业大学学报, 2015, 41(1): 48-59.

[44] Deng L, Yu D. Deep learning: methods and applications[J]. Foundations & Trends in Signal Processing, 2014, 7(3): 197-387.

中国知网 https://www.cnki.net

[45] Mane D T, Kulkarni U V. Visualizing and understanding customized convolutional neural network for recognition of handwritten marathi numerals[J]. Procedia Computer Science, 2018, 132: 1123-1137.

[46] Sun Y, Wang X, Tang X, et al. Deep learning face representation by joint identification-verification[C]. Advances in neural information processing systems, 2014: 1988-1996.

[47] Yanjun Ma, Dianhai Yu, Tian Wu, et al. Paddle: an open-source deep learning platform from industrial practice[J]. Frontiers of Data and Computing, 2019, 1(1): 105-115.

[48] Abadi M, Barham P, Chen J, et al. Tensorflow: a system for large-scale machine learning[C]. USENIX Association, 2016: 265-283.

[49] Bengio Y. Learning deep architectures for AI[J]. Foundations & Trends in Machine Learning, 2009, 2(1): 1-127.

[50] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.

[51] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]. IEEE Computer Society Conference on Computer Vision & Pattern Recognition. IEEE, 2005.

[52] Chenguang Liu, Li Tao, Yeong-Taeg Kim. VLW-net: a very light-weight convolutional neural network (CNN) for single image dehazing[C]. Proc of International Conference on Advanced Concepts for Intelligent Vision Systems. Cham: Springer, 2020: 433-442.

[53] 赵冬斌, 邵坤, 朱圆恒等. 深度强化学习综述:兼论计算机围棋的发展[J]. 控制理论与应用, 2016, 33(6): 701-717.

[54] Konda V R, Tsitsiklis J N. On Actor-Critic algorithms[J]. Society for Industrial and Applied Mathematics, 2003, 42(4): 1143-1166.

[55] 刘朝辉. 基于深度强化学习的智能驾驶路径规划[D]. 西安：西安石油大学，2021.

[56] Mnih V, Badia A P, Mirza M, et al. Asynchronous methods for deep reinforcement learning[C]. International Conference on Machine Learning. Berlin: Springer, 2016: 2850-2869.

[57] Gasparetto A, Boscariol P, Lanzutti A, et al. Path planning and trajectory planning algorithms: a general overview[J]. Motion and Operation Planning of Robotic Systems, 2015, 29(3): 3-27.

中国知网 https://www.cnki.net