DOI: 10.3969/j.issn.1673-095X.2024.06.011

# 基于深度强化学习的单机械臂智能控制算法

邵艳朋[1,2],周海波[1,2],樊肖艳[1,2],徐琦媛[1,2],刘楠[1,2*]

(1.天津理工大学 机电工程国家级实验教学示范中心,天津 300384;
2.天津理工大学 天津市先进机电系统设计与智能控制重点实验室,天津 300384)

**摘要:** 机械臂的运动控制问题一直是当下的研究热点,而传统控制算法存在环境适应性差、效率低等不足,已经难以满足当今工业复杂环境等对机械臂的需求,近几年新兴的智能控制算法逐步应用到机械臂的控制上,提高了机械臂的智能性和工作效率。深度强化学习(deep reinforcement learning,DRL)作为人工智能算法之一,已经形成适用于离散和连续状态空间的智能控制方法,目前用于机械臂运动控制的深度强化学习算法大多属于连续状态空间控制方法,并且取得了较好的实验效果。文中阐述了几种单机械臂深度强化学习运动控制算法,从优缺点、适用性等方面进行分析对比,为单机械臂的智能控制提供参考。

**关键词:** 机械臂;智能控制;综述;深度强化学习;运动控制

**中图分类号:** TP202.6 **文献标识码:** A **文章编号:** 1673-095X(2024)06-0070-08

# A survey of intelligent control methods for single robot arm based on deep reinforcement learning

SHAO Yanpeng[1,2],ZHOU Haibo[1,2],FAN Xiaoyan[1,2],XU Qiyuan[1,2],LIU Nan[1,2*]

(1. National Demonstration Center for Experimental Mechanical and Electrical Engineering Education, Tianjin University of Technology, Tianjin 300384, China;
2. Tianjin Key Laboratory for Advanced Mechatronic System Design and Intelligent Control, Tianjin University of Technology, Tianjin 300384, China)

**Abstract:** The motion control of robotic arms has always been a research hotspot at the moment. However, traditional control algorithms have shortcomings such as poor environmental adaptability and low efficiency, which make it difficult to meet the demands of today's complex industrial environments for robotic arms. In recent years, emerging intelligent control algorithms are gradually emerging. Applied to the control of the robotic arm, the intelligence and work efficiency of the robotic arm are improved. As one of the artificial intelligence algorithms, Deep Reinforcement Learning has formed as an intelligent control method suitable for discrete and continuous state spaces. At present, most of the Deep Reinforcement Learning algorithms used for robotic arm motion control belong to continuous state space control methods, and have achieved good results in experiment. In this paper, several Deep Reinforcement Learning motion control algorithms for single manipulators are expounded, and the advantages, disadvantages, applicability and other aspects are analyzed and compared which provide a reference for the intelligent control of single manipulators.

**Key words:** robot arm; intelligent control; review; deep reinforcement learning; motion control

**收稿日期:** 2022-09-20; **修订日期:** 2023-03-21

**基金项目:** 天津市多元投入基金项目重点项目(21JCZDJC00870);天津市自然科学基金重点项目(17JCZDJC30400);天津市大学生创新创业训练计划项目(202210060030)

中国知网 https://www.cnki.net

随着机器人技术的高速发展，机械臂在工业、医疗、航天航空以及军事等领域发挥着重要作用，可以实现繁重的甚至人工难以完成的作业[1]。传统控制方法不仅效率低下，而且其优化方法对机械臂的环境适应性提升甚微[2]。然而随着工作环境变得越来越复杂，机械臂的智能控制水平以及工作效率亟待提升。近几年随着人工智能的兴起，机器学习的不断升级和创新，深度强化学习（deep reinforcement learning，DRL）在游戏、金融、自动驾驶等领域取得了优秀的成果[3]。在机器人的研究方向上，DRL 与机械臂技术相结合，经过训练，机械臂可以准确高效地处理更复杂的作业。不仅单机械臂，多臂机器人也可以通过 DRL 算法的训练而成功协同抓取目标物[4]，只是成功率有待提升。

文中从单机械臂的智能控制角度，介绍深度强化学习模型和分类，阐明了智能运动控制的工作原理，然后总结了现有深度强化学习对单机械臂的智能控制方法并进行性能的对比分析。

## 1　模型与分类

DRL 是强化学习（reinforcement learning，RL）和深度学习（deep learning，DL）的结合。RL 是以马尔可夫决策过程（Markov decision processes，MDPs）为数学模型，即智能体的下一个状态取决于目前的观测状态和动作，和之前的观测状态与动作没有关系[5]。在强化学习模型中，主要是智能体与环境的交互，如图 1。其基本原理可以看为智能体根据当前的状态和奖励去执行动作，从而出现下一个状态和奖励，智能体不以目前的最高奖励为目的，而是以获得一次训练后最高的回报（全部奖励的和）为最终目的[6]。因此智能体会减少执行获得奖励低的动作，更倾向于高奖励的动作，从而获得最高的回报。

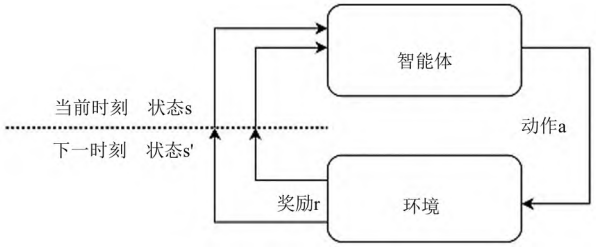



图 1　强化学习模型

Fig. 1　Reinforcement learning model

传统的强化学习算法，例如 Q-learning 算法和 Sarsa 算法，都是在离散状态空间下训练的，如果把算法中的表格升级为深度神经网络，借助神经网络强大的表征能力去拟合表格或者直接拟合策略来解决维度过大或空间连续的问题，那么强化学习将升级为深度强化学习。在训练机械臂时，算法将不断更新神经网络的参数，达成最终的目标。

深度强化学习的分类如图 2 所示，主要分为基于模型（model-based）和无模型（model-free）两大类，基于模型的方法是智能体与环境交互获得样本后，利用样本进行环境建模，当模型与实际环境很相似的时候，智能体已经掌握任意状态下发出的任意动作所获得的全部回报，可以直接通过算法选择最优的策略，从而输出相应的动作[7-9]，其中比较基础的算法有动态规划[10]等。2015 年，DeepMind 研发的 AlphaGo 击败人类围棋冠军足以证明基于模型的强化学习算法的先进性[11]。

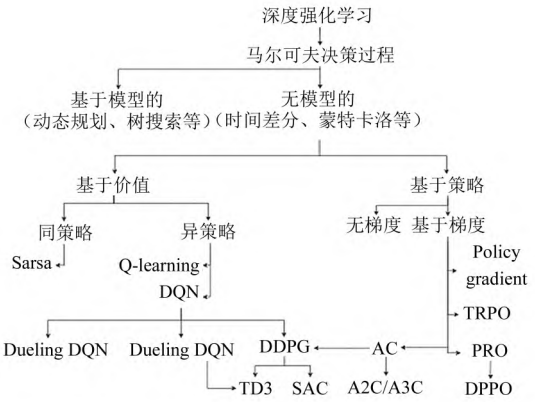



图 2　深度强化学习分类

Fig. 2　Classification of deep reinforcement learning

目前更多的研究方向集中于无模型的方法，此方法同样是先令智能体与环境交互获得样本，但在获得样本之后直接根据样本进行序列决策，不需要环境建模[12]，因此相比较基于模型的方法来讲，它更简单。其中时间差分（temporal difference，TD）[13]和蒙特卡洛（Monte Carlo，MC）[14]是无模型方法的基础算法。在无模型的方法下，又分为基于价值的学习（value-based learning）和基于策略的学习（policy-based learning）。

基于价值的学习是学习价值函数（动作价值函数或状态价值函数），让智能体通过训练取得最高的价

中国知网　https://www.cnki.net

值而获取最优解。Sarsa 和 Q 学习算法（Q-learning）算法都属于时间差分算法，Sarsa 算法属于同策略（on-policy）算法，即它的行为策略和目标策略是一致的；Q-learning 算法则属于异策略（off-policy）算法，其行为策略是进行样本采集，然后通过不断训练得到目标策略。深度 Q 网络算法（deep Q-network，DQN）[15] 通过引入神经网络，使 Q-Learning 算法可以控制连续状态空间下的智能体。传统的 DQN 存在一些不足，它的一些高级算法进行了性能提升，双深度 Q 网络算法（double deep Q network，Double DQN）[16] 将 TD 目标的计算分别使用 DQN 和目标网络进行，大大降低了高估造成的危害；对决深度 Q 网络算法（dueling deep Q network，dueling DQN）[17] 将神经网络升级为对决网络，把最优动作价值分解为最优状态价值与最优优势，训练的效率明显高于传统 DQN。

基于策略的学习是学习策略函数，根据训练所取得的最终回报多少来评价不同策略的适用性。基于策略的算法可以称为策略梯度优化算法（policy gradient，PG），置信域策略优化算法（trust region policy optimization，TRPO）[18] 和近端策略优化算法（proximal policy optimization，PPO）[19] 是典型的代表。TRPO 算法是将置信域方法应用在策略学习中，可以用很少的经验就能得到较好策略。而 TRPO 的计算量巨大且实现较为复杂，PPO 则对 TRPO 的信任域计算过程进行简化，效果更好。PPO 的升级算法是分布式近端策略优化算法（distributed proximal policy optimization，DPPO）[20]，可以显著提升样本训练效率。

演员－评论家算法（actor-critic，AC）[21] 是一个既基于价值又基于策略的方法，同时拥有价值网络（Critic）和策略网络（Actor），Critic 给 Actor 做出的动作进行评分，帮助 Actor 不断改进，Actor 就能训练出分数更高的策略。同步优势 AC 算法（synchronous advantage actor-critic，A2C）[22] 和异步优势 AC 算法（asynchronous advantage actor-critic，A3C）[23] 都是 AC 算法的升级版，A2C 是在 AC 算法的基础上增加了并行计算的框架，A3C 则是 A2C 的异步版本。将 DQN 和 AC 算法相结合，就衍生出了深度确定性策略梯度算法（deep deterministic policy gradient，DDPG）[24]，即在 AC 算法框架下，增加了 DQN 的经验回放和目标网络的方法，使 DDPG 可以用于连续动作空间上。DDPG 算法的升级版本有双延迟深度确定性策略算法（twin delayed deep deterministic policy gradient，TD3）[25] 和柔性 AC 算法（soft actor-critic，SAC）[26] 等。

## 2 算法分析

不同的深度强化学习算法可以分别应用在离散空间和连续空间中，机械臂的运动属于连续控制问题，大多研究人员对它的研究都是采用连续空间上的深度强化学习算法及其改进版本，当然前期在尝试把强化学习应用到机械臂上时，有少数研究人员将机械臂的动作空间离散化之后进行实验，也有一定成效，不过局限性较大。

1）Sarsa 算法目的是学习动作价值函数，不同的行为策略所对应的动作价值函数不同，动作价值函数表示成表格形式如表 1 所示。徐帷等[27] 把有效迹加入 Sarsa 算法的值函数增量式更新部分，获得收敛更快的 Sarsa（$\lambda$）算法[28]。实验将机械臂的连续动作空间离散化，训练后可以根据策略进行路径规划，虽然不会像传统控制算法一样出现奇异问题，但其智能性与鲁棒性有待提高。

表 1 表格形式的动作价值函数

Tab. 1 Action value function in tabular form

| | 动作 1 | 动作 2 | … | 动作 $n$ |
|---|---|---|---|---|
| 状态 1 | $Q_{11}$ | $Q_{12}$ | … | $Q_{1n}$ |
| 状态 2 | $Q_{21}$ | $Q_{22}$ | … | $Q_{2n}$ |
| ⋮ | ⋮ | ⋮ | ⋮ | ⋮ |
| 状态 $n$ | $Q_{n1}$ | $Q_{n2}$ | … | $Q_{nn}$ |

2）Q-learning 算法目的是学习最优动作价值函数，从而做出回报最大的决策。因为 Q-learning 算法是异策略的强化学习算法，可以使用经验回放的方法更新表格。DQN 是把 Q-learning 的表格升级为神经网络，同样经过经验回放来更新神经网络的参数。DQN 的神经网络结构如图 3 所示。目前腹腔镜手臂在医疗手术中经常被使用，从方便手术和节省时间的角度出发，YU 等[29] 提出了一种基于视觉和深度强化学习的腹腔镜自动调整方法，在仿真环境中用视觉图像作为 DQN 的输入，经过大量训练，最后可以实现在不同场景中根据手术器械的状态自动调整姿态。实验中只

中国知网 https://www.cnki.net

是注意到了医疗器械的状态，实际中还需要观察人体状态，因此后续需要验证在实际手术中的表现。TSAI 等[30]在研究工业中织物鞋舌制造的自动化技术时，研发了一条基于计算机物理系统人工智能（CPS-AI）架构的自动生产线，产线中的机械臂通过 DQN 算法反复训练学习产品定位和路径规划，成功实现机械臂抓取和缝制织物鞋舌，且测试收敛精度高达 95.9%。

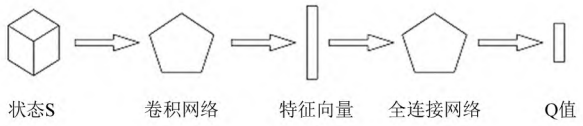



图 3　DQN 的神经网络结构

Fig. 3　Neural network structure of DQN

在控制工业中的焊接机械臂时，李广创等[31]在原始 DQN 中加入一个目标网络来降低高估带来的缺陷，机械臂训练后虽然可以成功避障，但其动作空间的不连续使其在作业时具有一定局限性。谢文显等[32]在同样的问题上，采用更先进的 Double DQN 算法，最终机械臂的路径规划成功率可以高达 90%。

3）PPO 算法是目前非常流行的一种强化学习算法，适用性很广。PPO 算法使用多步 TD 目标来进行更新以平衡方差和偏差，并采用重要性采样，将 AC 算法的同策略改为异策略从而提升采样效率。NAUGHTON 等[33]在仿真环境中，采用 TRPO，PPO，DDPG，TD3 和 SAC 算法均实现了对软体机器人的柔顺控制，其中 PPO 的稳定性最好。但仿真环境中的软体机器人形状和各方面性能过于理想，后续应制作机器人实体模型，逐步将在真实环境中验证算法。李鹤宇等[34]用 PPO 优化机械臂的调试时间和稳定性，使机械臂可以准确地达到目标点，其系统结构图如图 4 所示。将 PPO 与 DDPG 进行对比实验，PPO 更有效地抑制了机械臂的抖动，控制更加稳定。

在研究移动机器人时，WANG 等[35]提出将 PPO 算法与视觉感知结合的方法，用于控制移动基座上的机械臂。视觉检测系统先获取目标物的位置并计算相对姿态，机器人通过深度强化学习算法生成的策略来规划机械臂向前抓取，虽然现实实验的成功率低于仿真实验的成功率，但是都可以顺利抓取目标物。同样在研究移动机器人手臂时，WANG 等[36]提出了一种改进的 PPO 控制方法，通过扩展经验池，减少对无用环境的探索，提高了训练效率和控制的稳定性。

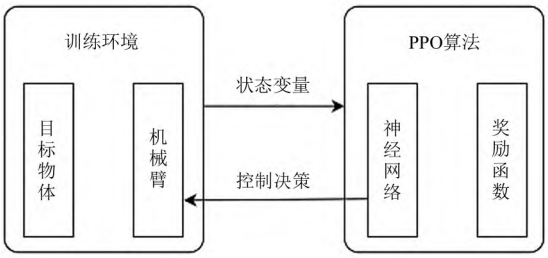



图 4　系统结构图

Fig. 4　Diagram of system structure

EGLI 等[37]根据 PPO2 算法训练高度非线性液压挖掘机臂的末端执行器轨迹跟踪控制器，训练完成后，由控制器直接发出指令，控制 12 t（1 t = $10^3$ kg）液压挖掘机分别在有土壤和无土壤的环境下进行测试，表明此算法训练后得到的控制策略可以高精度控制液压挖掘机臂，所获得的性能足以投入到施工现场进行使用。该方法有潜力提高装备智能化水平。

在实现机械臂自主装配销钉销孔时，WANG 等[38]提出了改进的 PPO 算法，使用 LSTM 网络重构 Critic 网络来丰富状态信息，并且将示教机制加入到算法中为其提供知识库，此算法显著地提升了机械臂的自主学习的收敛效果，实验表明该算法在 3 mm 精度下可以达到 80% 的成功率，且具有良好的鲁棒性。

4）DPPO 就是 PPO 算法的分布式实现，相比 PPO 算法而言可以合理利用样本，提高训练速度。DPPO 多线程框架如图 5 所示。靳栋银等[39]为提高机械臂的轨迹规划学习效率以及规划策略鲁棒性，设计了一个基于语音的奖励函数，为 DPPO 提供有引导性的奖励值，降低轨迹规划过程中的盲目性，使收敛更快。

熊俊涛等[40]用 DPPO 算法训练采摘机械臂，设计了一种类似于人工势场法的奖励函数来缓解稀疏奖励的问题，实现机械臂在野外随机环境中迅速轨迹规划避障，且机械臂完成采摘的成功率将近 97%，突出了此方法具有良好的鲁棒性和更好的适应性。

5）DDPG 算法是目前在单机械臂中应用最多的算法之一，它是一种集 DQN 和 AC 算法的优点于一

中国知网　https://www.cnki.net

身的离线策略，不仅采样效率高，而且在离散动作空间和连续动作空间均适用。DDPG 的算法流程如图 6 所示。LIU 等[41] 在采用自适应/鲁棒控制器控制四旋翼飞行器时，选择 DDPG 算法训练其机械臂，成功降低机械臂对飞行器的影响，保证了飞行器在空间中的稳定性和跟踪性能。SEKKAT 等[42] 在有视觉加持的机械臂上，使用 YOLOv5 检测到目标物的位置，然后计算机械臂的运动学逆解，使机械臂的末端执行器达到目标物的所在位置后进行抓取，DDPG 算法被训练成为一个逆运动学解算器，可以更快地计算出机械臂的关节角度，其算法精度达到 95.5%，具有良好的适用性。

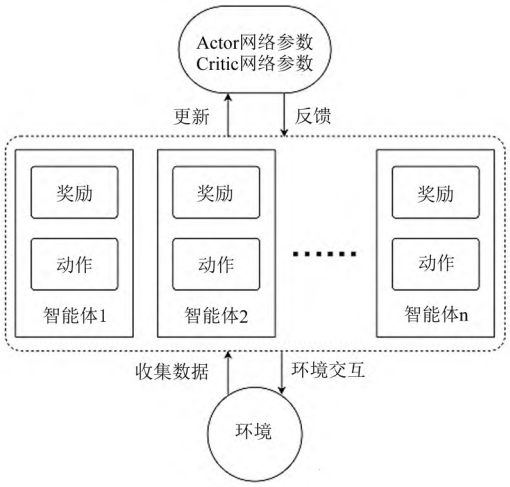



图 5 DPPO 多线程框架

Fig. 5 Multithreaded framework for DPPO

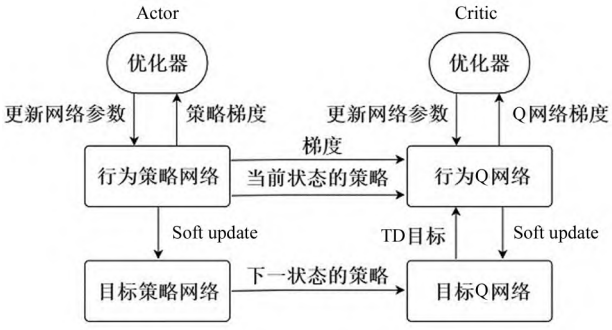



图 6 DDPG 算法流程

Fig. 6 Algorithm flow of DDPG

IRIONDO 等[43] 在控制移动机械臂抓取目标物体时，令 DDPG 和 PPO 算法进行同等条件下的训练，DDPG 收敛得更快，且可以更迅速地接近目标，生成平滑的路径，而 PPO 的探索时间要更长，甚至在复杂的环境中 PPO 不能正确完成任务。但这两种算法，因为超参数的调节难度大，以至于它们都需要大量的学习时间，因此，未来需要从降低训练时间的角度继续优化算法。

LINDNER 等[44] 将事后经验回放（hindsight experience replay，HER）算法分别与 DDPG，TD3 和 SAC 算法进行结合，分别在仿真环境和现实环境中对机械臂进行位置控制，从定位精度、运动轨迹和到达目标所走步数等几个指标进行比较，结果表明，这几种深度强化学习算法均可以成功控制机械臂，其中 DDPG 与 HER 结合使用时明显控制精度更高。后续 LINDNER 等[45] 又将 DDPG 与 HER 结合的方法用来解决机械臂避障问题，六自由度机械臂可以成功避开各种形状的障碍物后到达目标位置。同样使用 DDPG 与 HER 结合的方法，YANG 等[46] 先通过用 VICON 光学运动捕捉系统来收集人体手臂的动作特征，然后使用此方法对机械臂进行运动规划的训练。训练后机械臂的动作特征与人体真实动作高度相似，更加证明了此方法的有效性。

6）SAC 算法是面向最大熵强化学习的一种异策略算法，具有更强的鲁棒性和更高的探索性，且训练速度快。与 DDPG 相比较而言，SAC 使用的是随机策略，比确定性策略具有一定优势。SAC 算法网络架构如图 7 所示。

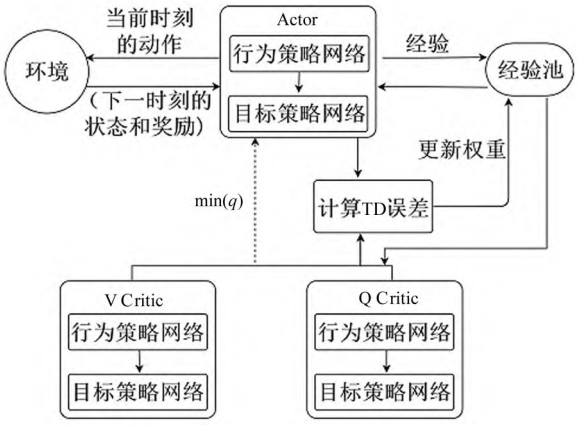



图 7 SAC 算法网络架构

Fig. 7 Network architecture of SAC algorithm

王骏超[47] 提出将 SAC 算法作为机械臂的控制策略来进行轨迹规划，且分别与 RRTstar 算法和 DDPG

中国知网 https://www.cnki.net

算法进行同等条件下的比较，实验表明 SAC 算法比 DDPG 算法收敛更快、更稳定；比 RRTstar 规划的轨迹更平缓，规划时间更短，而且成功率更高。这表明 SAC 算法可以弥补传统算法的缺陷，具有较好的应用价值。

7）TD3 算法是将 Double DQN 的思想结合到 DDPG 算法中，用以截断双 Q 学习，还在目标策略网络中加入噪声，且降低策略网络和三个目标网络的更新频率，可以缓解 DDPG 算法的高估问题，更有效地解决连续控制问题。截断双 Q 学习中的六个神经网络之间的关系如图 8 所示。

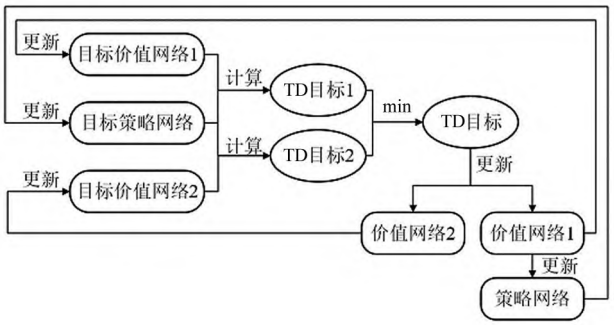



图 8　截断双 Q 学习的六个神经网络之间的关系

Fig. 8　Relationship between six neural networks truncating double Q learning

范振等[48]在训练机械臂倒立摆时，采用 TD3 算法与 DDPG 算法的对比实验，由于 TD3 比 DDPG 多两个神经网络，所以 TD3 的算法训练起来更慢，但前期 TD3 比 DDPG 的训练周期要少一半，因此训练前期 TD3 有更好的学习能力和约束适应性。在施加干扰力的情况下，TD3 相比 DDPG 的精度要高，鲁棒性更好。综合来看，TD3 算法可以在短时间内收敛，倒立摆消耗能量少，稳定性较强。

张强等[49]提出一种改进的 TD3 算法控制四自由度机械臂的轨迹规划及避障，实验分为两个阶段进行训练：预训练阶段用目标位置引导机械臂进行点到点的训练，以减少前期训练的盲目性；第二个阶段训练机械臂对示教的参考轨迹进行模仿，实现避障。实验结果表明，机械臂训练后可以规划出一条和参考路径相似的安全路径，但是精度有待提高。

以上针对单机械臂控制问题具体介绍了几种算法，表 2 为各个算法的性能对比。

表 2　深度强化学习算法性能对比

Tab. 2　Comparison of deep reinforcement learning algorithm performance

| 算法名称 | 适用场景 | 开始收敛时训练次数 | 优点 | 缺点 |
|---|---|---|---|---|
| Sarsa | 离散动作空间 | 500 回合[27] | 可以在线训练模型 | 存在自举问题 |
| DQN | 离散动作空间 | 6 300 回合[31] | 算法通用性高 | 存在高估问题 |
| PPO | 连续动作空间 | 800 回合[34] | 训练稳定，易于调参 | — |
| DPPO | 连续动作空间 | 60 000 步[40] | 多线程并行，采样效率提高 | — |
| DDPG | 连续动作空间 | 400 回合[42] | 样本效率高 | 对超参数敏感 |
| SAC | 连续动作空间 | 12 500 步[48] | 探索更加均匀，训练更快 | 易陷入次优策略 |
| TD3 | 连续动作空间 | 2 877 回合[49] | 可以更好地缓解高估问题 | 超参数过多 |

## 3　结　论

文中列举了控制单机械臂的深度强化学习算法的研究现状，对其原理进行简述，并结合不同应用场景进行了性能的对比分析，表明了当前几种主流算法的优缺点，为单机械臂的智能控制提供参考。对于未来的研究工作，提出以下几点进行展望：

1）目前所研究的目标物体都是规则的形状且处于静止状态下，但是现实中目标物体更多是不规则的形状甚至相对机械臂是运动的，因此如何合理抓取目标物需要加入到后续研究中，提高算法的泛化能力。

2）如今的深度强化学习算法都需要在范围巨大的探索空间下采集大量样本进行训练，时间成本较高，后续可在机械臂上加持力觉传感器、声音传感器、视觉传感器等多种传感器，通过传感器的融合信息，缩小探索空间，从而提高效率。

3）目前算法对机械臂的控制多数都是在仿真空间下进行的，但在实际应用中，机械臂所面对的环境更加复杂，后续需要进一步对深度强化学习算法进行改进和创新，提高其适应性。

## 参　考　文　献

[1]　吴万欣，田军委，丁良华，等. 六自由度机械臂运动学分析与仿真 [J]. 天津理工大学学报，2022，38（1）：

中国知网　https://www.cnki.net

8 – 12.

[2] 开航，陈炜，赵新华. 基于粒子群的欠驱动平面机械臂PID控制算法研究 [J]. 天津理工大学学报，2013，29(3)：16 – 19.

[3] 王寅. 基于深度强化学习的机械臂路径规划研究 [D]. 广州：广东工业大学，2022.

[4] 周顺. 三机械臂深度强化学习协调控制算法研究 [D]. 天津：天津理工大学，2021.

[5] SUTTON R S，BARTO A G. Reinforcement learning：an introduction [M]. Massachusetts：MIT Press，2018.

[6] 董豪，丁子涵，仉尚航. 深度强化学习：基础、研究与应用 [M]. 北京：电子工业出版社，2020.

[7] VOOT T，JUN M，MASASHI S. Model-based reinforcement learning with dimension reduction [J]. Neural Networks，2016，84：1 – 16.

[8] KALWEIT G，BOEDECKER J. Uncertainty-driven imagination for continuous deep reinforcement learning [J]. Proceedings of Machine Learning Research，2017，78：195 – 206.

[9] KAMALAPURKAR R，WALTERS P，DIXON W E. Model-based reinforcement learning for approximate optimal regulation [J]. Control of Complex Systems，2016，64：247 – 273.

[10] BELLMAN R. Dynamic programming and lagrange multipliers [J]. Proceedings of the National Academy of Sciences，1956，42(10)：767 – 769.

[11] SILVER D，HUANG A，MADDISON C J，et al. Mastering the game of go with deep neural networks and tree search [J]. Nature，2016，529(7587)：484 – 489.

[12] 王超. 基于深度强化学习的机械臂卷积神经网络控制策略研究 [D]. 哈尔滨：哈尔滨工业大学，2018.

[13] MICHIE D，CHAMBERS R A. BOXES：an experiment in adaptive control [J]. Machine Intelligence，1968，2：137 – 152.

[14] SUTTON R S. Learning to predict by the methods of temporal differences [J]. Machine Learning，1988，3(1)：9 – 44.

[15] MNIH V，KAVUKCUOGLU K，SILVER D，et al. Human-level control through deep reinforcement learning [J]. Nature，2015，518(7540)：529 – 533.

[16] VAN HASSELT，GUEZ A，SILVER D. Deep reinforcement learning with double Q-learning [C] //Proceedings of the AAAI Conference on Articial Intelligence. Palo Alto：AAAI Press，2016：2094 – 2100.

[17] WANG Z，SCHAUL T，HESSEL M，et al. Dueling network architectures for deep reinforcement learning [J]. Proceedings of Machine Learning Research，2016，48：1995 – 2003.

[18] SCHULMAN J，LEVINE S，ABBEEL P，et al. Trust region policy optimization [J]. Proceedings of Machine Learning Research，2015，37：1889 – 1897.

[19] 陈佳盼，郑敏华. 基于深度强化学习的机器人操作行为研究综述 [J]. 机器人，2022，44(2)：236 – 256.

[20] LIN J，ZHANG P，LI C，et al. APF-DPPO：an automatic driving policy learning method based on the artificial potential field method to optimize the reward function [J]. Machines，2022，10(7)：533 – 557.

[21] KONDA V，TSITSIKLIS J. Actor-critic algorithms [C] // Advances in Neural Information Processing Systems. Cambridge：MIT Press，1999：1008 – 1014.

[22] MNIH V，BADIA A P，MIRZA M，et al. Asynchronous methods for deep reinforcement learning [C] // Proceedings of the 33rd International Conference on Machine Learning. New York：PMLR，2016：1928 – 1937.

[23] MNIH V，BADIA A P，MIRZA M，et al. Asynchronous methods for deep reinforcement learning [J]. Proceedings of Machine Learning Research，2016，48：1928 – 1937.

[24] LILLICRAP T P，HUNT J J，PRITZEL A，et al. Continuous control with deep reinforcement learning [J]. Computer Science，2015，1：1 – 14.

[25] FUJIMOTO S，HOOF H V，MEGER D. Addressing function approximation error in actor-critic methods [C] // Proceedings of the 35th International Conference on Machine Learning. New York：PMLR，2018：1587 – 1596.

[26] HAARNOJA T，ZHOU A，ABBEEL P，et al. Soft actor-critic：off-policy maximum entropy deep reinforcement learning with a stochastic actor [C] //Proceedings of the 35th International Conference on Machine Learning. New York：PMLR，2018：1861 – 1870.

[27] 徐帷，卢山. 基于Sarsa(λ)强化学习的空间机械臂路径规划研究 [J]. 宇航学报，2019，40(4)：435 – 443.

[28] SINGH S P，SUTTON R S. Reinforcement learning with replacing eligibility traces [J]. Machine Learning，1996，22：123 – 158.

[29] YU L T，XIA Y Q，WANG P C，et al. Automatic adjustment of laparoscopic pose using deep reinforcement learning [J]. Mechanical Sciences，2022，13(1)：593 – 602.

中国知网 https://www.cnki.net

[30] TSAI Y T，LEE C H，LIU T Y，et al. Utilization of a reinforcement learning algorithm for the accurate alignment of a robotic arm in a complete soft fabric shoe tongues automation process [J]. Journal of Manufacturing Systems，2020，56：501－513.

[31] 李广创，程良伦. 基于深度强化学习的机械臂避障路径规划研究 [J]. 软件工程，2019，22（3）：12－15.

[32] 谢文显，孙文磊，刘国良，等. 基于强化学习的机器人智能路径规划 [J]. 组合机床与自动化加工技术，2022（7）：13－17.

[33] NAUGHTON N，SUN J，TEKINALP A，et al. Elastica：a compliant mechanics environment for soft robotic control [J]. IEEE Robotics and Automation Letters，2021，6（2）：3389－3396.

[34] 李鹤宇，林廷宇，曾贲，等. 基于强化学习的空间机械臂控制方法 [J]. 航天控制，2020，38（6）：38－43.

[35] WANG C，ZHANG Q，TIAN Q，et al. Learning mobile manipulation through deep reinforcement learning [J]. Sensors，2020，20（3）：939－956.

[36] WANG Y，WANG L，ZHAO Y. Research on door opening operation of mobile robotic arm based on reinforcement learning [J]. Applied Sciences，2022，12（10）：5204－5222.

[37] EGLI P，HUTTER M. A general approach for the automation of hydraulic excavator arms using reinforcement learning [J]. IEEE Robotics and Automation Letters，2022，7（2）：5679－5686.

[38] WANG F，CUI B，LIU Y，et al. Deep reinforcement learning for peg-in-hole assembly task via information utilization method [J]. Journal of Intelligent & Robotic Systems，2022，106：16－30.

[39] 靳栋银，李跃，邵振洲，等. 面向机械臂轨迹规划的强化学习奖励函数设计 [J]. 计算机工程与应用，2022，58（19）：302－308.

[40] 熊俊涛，李中行，陈淑绵，等. 基于深度强化学习的虚拟机器人采摘路径避障规划 [J]. 农业机械学报，2020，51（S2）：1－10.

[41] LIU Y C，HUANG C Y. DDPG-based adaptive robust tracking control for aerial manipulators with decoupling approach [J]. IEEE Transactions on Cybernetics，2022，52（8）：8258－8271.

[42] SEKKAT H，TIGANI S，SAADANE R，et al. Vision-based robotic arm control algorithm using deep reinforcement learning for autonomous objects grasping [J]. Applied Sciences，2021，11（17）：1－14.

[43] IRIONDO A，LAZKANO E，SUSPERREGI L，et al. Pick and place operations in logistics using a mobile manipulator controlled with deep reinforcement learning [J]. Applied Sciences，2019，9（2）：1－19.

[44] LINDNER T，MILECKI A，WYRWAL D. Positioning of the robotic arm using different reinforcement learning algorithms [J]. International Journal of Control，Automation and Systems，2021，19：1661－1676.

[45] LINDNER T，MILECKI A. Reinforcement learning-based algorithm to avoid obstacles by the anthropomorphic robotic arm [J]. Applied Sciences，2022，12（13）：6629－6652.

[46] YANG A L，CHEN Y L，WASIF N，et al. Humanoid motion planning of robotic arm based on human arm action feature and reinforcement learning [J]. Mechatronics，2021，78：1－12.

[47] 王骏超. 基于 SAC 算法的机械臂控制方法与分析 [J]. 赤峰学院学报（自然科学版），2020，36（10）：33－39.

[48] 范振，陈乃建，董春超，等. 基于深度强化学习的单臂机器人末端姿态控制 [J]. 济南大学学报（自然科学版），2022，36（5）：616－625.

[49] 张强，文闻，周晓东，等. 基于改进 TD3 算法的机械臂智能规划方法研究 [J]. 智能科学与技术学报，2022，4（2）：223－232.

作者简介：邵艳朋（1997—），男，硕士研究生，研究方向：机械臂的运动控制等。E-mail：13363167547@163.com

刘楠（通信作者）（1986—），男，高级实验师，硕士，研究方向：机电控制及自动化。E-mail：tjutnan@163.com

中国知网　https://www.cnki.net