

中国矿业大学（北京）

CHINA UNIVERSITY OF MINING & TECHNOLOGY-BEIJING

博士学位论文

基于深度强化学习的机械臂运动规划方法研究

作　　者：周东旭

学　　院：机电与信息工程学院

学　　号：BQT1700401020

学科专业：机械工程

导　　师：贾瑞清

2021 年 6 月

中国知网 https://www.cnki.net

中图分类号：TP242　　单位代码：11413

UDC 分类号：621　　密　　级：公开

博 士 学 位 论 文

中文题目：基于深度强化学习的机械臂运动规划方法研究

英文题目：Research on Motion Planning Method of Robotic Arm Based on Deep Reinforcement Learning

作　　者：周东旭　　学　　号：BQT1700401020

学科专业：机械工程　　研究方向：机器人技术

导　　师：贾瑞清　　职　　称：教授

论文提交日期：2021 年 3 月 18 日　论文答辩日期：2021 年 5 月 24 日

学位授予日期：2021 年 6 月 17 日

中国矿业大学（北京）

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

摘　要

随着机器人技术的快速发展，机械臂得到了越来越广泛的应用。与此同时，机械臂的运动规划功能发挥着越来越重要的作用。机械臂在复杂环境中进行抓取、搬运以及协作等运动时，需要对机械臂的运动路径进行相应的规划。在传统的机械臂控制方法中，人工示教是实现机械臂运动规划的常用方法。但是示教方法依赖于人工手动进行操作，过程繁琐且缺少自适应性。随着时代的发展，传统的示教方法已经越来越难以满足机械臂智能化控制的需要。机械臂的运动规划问题成为了机器人控制领域研究的热点问题。

运动规划问题在移动机器人领域也被称为路径规划问题，移动机器人领域的路径规划是在 2 维或者 3 维构形空间当中进行，而机械臂运动规划则是在高维构形空间进行，构形空间的维度取决于机械臂的自由度数。这种特点使一些适用于移动机器人的运动规划算法无法应用于机械臂。

随着各国学者不断地在人工智能领域取得新突破，将深度强化学习算法应用于运动规划问题是近年来出现的新趋势。相比于传统算法，基于机器学习的方法有很强的泛化能力以及鲁棒性，更适用于机械臂在复杂环境中的运动规划问题。然而将深度强化学习算法应用于机械臂的运动规划仍然存在训练困难的问题。强化学习的训练过程是智能体与环境不断进行交互试错的过程。对于一些复杂的任务，强化学习智能体从头开始训练到收敛状态是很困难的，这导致了实际训练中效率低下等问题。

基于上述背景，本文开展了基于深度强化学习的机械臂运动规划方法研究，主要研究内容与创新点如下：

（1）对传统运动规划算法、深度强化学习算法以及其在机械臂控制领域应用的国内外研究现状进行了系统地梳理。在此基础上，指出了将深度强化学习算法应用于机械臂运动规划问题时存在的一些问题，针对这些问题，明确了本论文的研究意义与研究方向。

（2）分析了能够用于机械臂控制的深度强化学习算法需要具备的特点，对 3 种能够应用于机械臂运动规划任务的典型深度强化学习算法在相同运动规划任务中进行了比较，分析了它们在机械臂控制问题上的性能。采用机器人虚拟仿真平台 V-REP 在计算机上构建用于研究机械臂深度强化学习训练的实验平台。在 V-REP 软件中设置无障碍物环境下的 6 自由度机械臂运动规划任务，分别将深度 Q 网络归一化优势函数(DQN-NAF)、深度确定性策略梯度(DDPG)和近端策略优化(PPO)

中国知网 https://www.cnki.net

算法应用于该虚拟任务，比较了这 3 种算法在相同运动规划任务当中的性能。实验结果表明 DQN-NAF 算法在简单任务中表现良好，但是在复杂任务中表现出强烈的性能局限性；DDPG 算法表现出了最大的不稳定性；PPO 算法表现出了最为稳健的性能。

（3）针对强化学习算法训练效率低和训练困难的问题，提出了一种基于残差强化学习的机械臂运动规划方法。该方法将智能体进行运动规划的策略分为初始策略和残差策略。初始策略由 BP 神经网络构成，负责引导由强化学习算法构成残差策略的训练方向。残差策略由改进 PPO 算法构成，在初始策略的引导下，残差策略能够快速收敛。残差策略部分则补充完善了初始策略的自适应性和泛化能力。

针对所提出的残差强化学习运动规划方法中的初始策略部分，采用了一种基于 BP 神经网络的运动规划方法。该方法利用神经网络的非线性拟合能力，采用传统的 RRT*运动规划算法生成供神经网络训练用的规划轨迹数据。将障碍物抽象为其内切球体，使所构建的神经网络可以根据当前构形、目标构形，以及障碍物位置半径特征值预测输出机械臂下一个可能的构形。针对残差策略部分，对原始 PPO 算法进行了多项改进，提出了一种改进 PPO 算法。改进 PPO 算法针对原始 PPO 算法采样利用率低、优势函数估计随机性大的问题，引入了小型经验池以及基于 SumTree 的优先经验回放机制。

在仿真环境下进行了运动规划实验，结果表明残差强化学习运动规划方法能够成功进行运动规划。将该方法与单纯使用原始 PPO 算法进行对比，结果表明使用残差强化学习运动规划方法可以有效地引导强化学习智能体的训练，极大地提高算法的收敛速度。

（4）针对残差强化学习运动规划方法中初始策略部分将障碍物抽象为其内切球体时可能出现的外形尺寸相差过大问题，提出了一种基于课程强化学习的障碍物自适应训练方法。该方法采用障碍物有效球体概念来简化环境中的障碍物，根据强化学习智能体的即时运动规划能力来自适应调整障碍物有效球体半径的大小，从而使智能体在与之能力相匹配的环境中进行训练。智能体先在简单的环境中进行训练，然后逐步过渡到完整的障碍物环境。虚拟环境中的实验表明，该方法能够成功进行运动规划。将采用基于课程强化学习的障碍物自适应训练方法与不采用该方法直接进行训练所得到的运动规划成功率进行对比，在经历相同 5000 回合次数的训练后，该方法的成功率达到了 95%，而不使用该方法进行训练的成功率为 70%。

（5）为了将运动规划得到的离散构形序列应用于真实的机械臂控制，提出了一种基于前瞻算法的机械臂关节空间轨迹规划方法。针对按照时间序列发送给运

中国知网 https://www.cnki.net

动控制系统的离散角度指令，设计了运动块环形队列机制，并将速度前瞻算法引入其中。通过对运动块速度的前瞻规划，保证了机械臂底层运动控制系统在接收连续动态指令时运动的连续性以及平稳性。

最后使用虚拟环境当中训练完成的机械臂智能体实现了对真实环境中 Mirobot 机械臂的控制。采用 ArUco 标签获取实际环境中物体的位置，对采用的摄像头进行了相机标定和手眼标定。提出了一种基于 V-REP 的机械臂虚实同步控制方法，使用 V-REP 中的虚拟 Mirobot 机械臂智能体同步控制真实环境中的机械臂完成了实际环境中的运动规划实验任务。

关键词：机器人，运动规划，深度强化学习，残差强化学习，前瞻算法

中国知网 https://www.cnki.net

Abstract

With the rapid development of robotics technology, robotic arms have been used more and more widely. Simultaneously, the motion planning function of the robotic arm is playing an increasingly important role. When the robotic arm performs grasping, handling, and collaboration movements in a complex environment, it is necessary to plan the robotic arm's movement path accordingly. In the traditional robotic arm control method, manual demonstration is a standard method to realize the robotic arm's motion planning. However, the demonstration method relies on manual operation. The process is cumbersome and lacks adaptability. With the development of the times, the traditional demonstration method has become increasingly challenging to meet intelligent control of robotic arms. The motion planning of the robotic arm has become a research hotspot in the field of robot control.

The problem of motion planning is also called path planning in the field of mobile robots. Path planning in the field of mobile robots is carried out in a two-dimensional or three-dimensional configuration space. In contrast, motion planning of a robotic arm is carried out in high-dimensional configuration space. The dimension of the configuration space depends on the degree of freedom of the robotic arm. This feature makes some motion planning algorithms suitable for mobile robots unable to be applied to robotic arms.

As scholars from various countries continue to make breakthroughs in the field of artificial intelligence, the application of deep reinforcement learning algorithms to motion planning problems is a new trend that has emerged in recent years. Compared with traditional algorithms, the method based on machine learning has strong generalization ability and robustness, so it is more suitable for robotic arms' motion planning in complex environments. However, the application of deep reinforcement learning algorithms to robotic arms' motion planning still has difficulty in training. The training process of reinforcement learning is a process of trial-and-error interaction between the agent and the environment. For some complex tasks, it is difficult for reinforcement learning agents to train from scratch to a convergent state, and it takes a long time, which leads to problems such as low efficiency in actual training.

This paper has researched the robotic arm motion planning method based on deep reinforcement learning. The main research content and innovation are as follows:

(1) First, it systematically sorts out the research status of traditional motion planning

中国知网 https://www.cnki.net

algorithms, deep reinforcement learning algorithms, and their applications in the field of robotic arm control. On this basis, some problems in applying the deep reinforcement learning algorithm to the robotic arm motion planning problem are pointed out. Aiming at these problems, the research significance and research direction of this thesis are clarified.

(2) The characteristics of deep reinforcement learning algorithms that can be used for robotic arm control are analyzed. Three kinds of typical deep reinforcement learning algorithms that meet the conditions are compared in the same motion planning task. Their performance on the robotic arm control problem is analyzed. The robot virtual simulation platform V-REP is used to build an experimental platform for studying the robotic arm's deep reinforcement learning training on the computer. Set up a 6-DOF robot motion planning task in an obstacle-free environment in the V-REP software. The Deep Q Network-Normalized Advantage Functions (DQN-NAF), Deep Deterministic Policy Gradient (DDPG), and Proximal Policy Optimization (PPO) are applied to the virtual task, respectively. The performance of these three algorithms in the same motion planning task is compared. Experimental results show that the DQN-NAF algorithm performs well in simple tasks but shows substantial performance limitations in complex tasks; the DDPG algorithm shows the most significant instability; the PPO algorithm shows the most robust performance.

(3) Aiming at the problem of low training efficiency and difficulty of reinforcement learning algorithm, a robotic arm motion planning method based on residual policy theory is proposed. This method divides the agent's policy of motion planning into initial policy and residual policy. The initial policy is composed of a BP neural network responsible for guiding the residual policy's training direction composed of the reinforcement learning algorithm. The residual policy is composed of reinforcement learning improved PPO algorithm. Under the guidance of the initial policy, the residual policy can quickly converge. The residual policy part complements and perfects the adaptability and generalization ability of the initial policy.

A method based on BP neural network is applied to the proposed residual policy method's initial policy. This method utilizes the nonlinear fitting ability of neural networks. The obstacle is abstracted as an inscribed sphere. The constructed neural network can predict and output the robotic arm's following possible configuration based on the current configuration, the target configuration, and the obstacle position radius's characteristic value. For the residual policy part, a series of improvements are made to

中国知网 https://www.cnki.net

the original PPO algorithm, and an improved PPO algorithm is proposed. Aiming at the problems of low sampling utilization of the original PPO algorithm and large randomness of the advantage function estimation, the improved PPO algorithm introduces a small experience pool and a priority experience playback mechanism based on SumTree.

A motion planning experiment is carried out in a simulation environment, and the results show that the residual policy motion planning method can successfully perform motion planning. Comparing this method with purely using the original PPO algorithm shows that the residual policy motion planning method can effectively guide the reinforcement learning agent's training and significantly improve the algorithm's convergence speed.

(4) Aiming at the problem that the initial strategy part of the residual strategy motion planning method abstracts the obstacle as an inscribed sphere, the possible size difference is too significant. An adaptive obstacle motion planning method based on curriculum reinforcement learning is proposed. This method uses the concept of obstacle effective sphere to simplify obstacles in the environment. According to the reinforcement learning agent's real-time motion planning ability, the size of the effective sphere radius of the obstacle is adaptively adjusted so that the agent can train in an environment that matches its ability. The agent first trains in an uncomplicated environment and then gradually transitions to a complete obstacle environment. Experiments in a virtual environment show that this method can successfully perform motion planning. The success rate of motion planning obtained by adopting the adaptive obstacle training method and directly training without this method is compared. After experiencing the same 5000 episodes of training, this method's success rate reaches about 95%, and the success rate of training without this method is about 70%.

(5) A space trajectory planning method for robotic arm joints based on a look-ahead algorithm is proposed to apply the discrete configuration sequence from motion planning to real robotic arm control. For the discrete angle commands sent to the motion control system in time series, a circular queue mechanism of motion blocks is designed. The speed look-ahead algorithm is introduced into it. The robotic arm motion control system's continuity and stability when receiving continuous dynamic commands are ensured through the look-ahead planning of the moving block's speed.

(6) Finally, the robot agent trained in the virtual environment is used to control the Mirobot robot in the real environment. The ArUco tag is used to obtain the object's position in the actual environment, and the camera calibration and hand-eye calibration are performed on the adopted camera. A V-REP-based virtual-real synchronization

中国知网 https://www.cnki.net

control method of a robotic arm is proposed. The virtual Mirobot robotic arm agent in V-REP synchronously controls the robotic arm in the real environment to complete the actual environment's motion planning experiment task.

Key Words: robot, motion planning, deep reinforcement learning, residual reinforcement learning, look-ahead algorithm

中国知网 https://www.cnki.net

目 录

1 绪论.....1

1.1 研究背景.....1

1.2 国内外研究现状.....2

1.2.1 经典运动规划算法综述.....2

1.2.2 高维构形空间中运动规划算法综述.....6

1.2.3 深度强化学习综述.....8

1.2.4 基于深度强化学习的机械臂控制方法综述.....14

1.3 问题的提出及研究意义.....16

1.3.1 研究问题的提出.....16

1.3.2 研究意义.....17

1.4 本论文的主要研究内容.....18

1.5 技术路线.....19

1.6 本章小结.....19

2 基于典型深度强化学习算法的机械臂运动规划方法.....21

2.1 马尔可夫决策过程与强化学习算法模型.....21

2.1.1 马尔可夫决策过程.....22

2.1.2 从马尔可夫决策过程到强化学习算法.....23

2.1.3 基于价值函数的强化学习算法.....24

2.1.4 基于策略梯度(PG)的强化学习算法.....26

2.1.5 价值函数与策略梯度结合的方法 Actor-Critic(AC).....28

2.2 适用于机械臂高维连续动作空间的强化学习算法.....29

2.2.1 深度 Q 网络归一化优势函数算法(DQN-NAF).....29

2.2.2 深度确定性策略梯度算法(DDPG).....34

2.2.3 近端策略优化算法(PPO).....37

2.3 仿真实验环境.....42

2.3.1 V-REP 机器人仿真平台.....43

中国知网 https://www.cnki.net

2.3.2 深度强化学习训练环境搭建 45
2.4 无障碍环境下基于 3 种典型强化学习算法的运动规划 47
2.4.1 运动规划任务设计 47
2.4.2 机械臂的动作、状态空间与奖励函数设置 49
2.4.3 算法的神经网络构建 52
2.4.4 神经网络训练的优化 55
2.4.5 3 种典型算法在无障碍环境下的性能 59
2.5 本章小结 64
3 基于残差强化学习的机械臂运动规划方法研究 65
3.1 残差强化学习理论 66
3.1.1 残差强化学习 66
3.1.2 基于残差强化学习的运动规划方法理论 67
3.2 基于 BP 神经网络与球体障碍物抽象的初始策略 69
3.2.1 机械臂运动规划问题的数学描述 69
3.2.2 机械臂神经网络运动规划方法 71
3.2.3 障碍物抽象特征 73
3.2.4 用于生成训练神经网络用构形序列的传统运动规划算法 74
3.2.5 神经网络模型构建与训练 82
3.3 基于改进 PPO 算法的残差策略 86
3.3.1 Critic 部分优势函数的随机性问题 86
3.3.2 引入经验池机制 88
3.3.3 引入优先经验回放机制 88
3.3.4 针对残差策略的修改 91
3.3.5 最终的改进 PPO 算法 92
3.4 有障碍物环境下的运动规划虚拟实验 95
3.4.1 奖励函数设置 95
3.4.2 训练过程 97
3.4.3 实验结果 99

中国知网 https://www.cnki.net

3.5 本章小结 102

4 基于课程强化学习的障碍物自适应训练方法研究 103

4.1 初始策略与残差策略的互补性以及障碍物球体抽象存在的问题 103

4.2 课程学习理论 104

4.3 基于课程学习的障碍物简化训练与有效球体概念 105

4.3.1 障碍物有效球体概念 106

4.3.2 自适应障碍物大小调整方法 107

4.3.3 障碍物是否需要简化的判断条件 108

4.3.4 课程强化学习方法的 5 个阶段 109

4.4 残差强化学习运动规划方法与课程强化学习训练方法的结合 110

4.5 V-REP 当中的实际训练方法 111

4.5.1 建立多个 V-REP 场景用于交替训练 111

4.5.2 关闭 V-REP 的图形化界面用于加速训练 112

4.6 实验结果 113

4.7 本章小结 118

5 基于前瞻算法的机械臂底层运动控制系统设计 121

5.1 机械臂的运动学分析 121

5.1.1 Denavit-Hartenberg 模型 121

5.1.2 机械臂的正运动学 122

5.1.3 机械臂的逆运动学 123

5.2 机械臂的运动规划与轨迹规划之间的关系 128

5.3 基于前瞻算法的机械臂关节轨迹规划方法 129

5.3.1 与抛物线拟合的线性函数轨迹规划 129

5.3.2 运动块环形队列原理 131

5.3.3 前瞻控制算法 133

5.3.4 速度轮廓曲线 137

5.3.5 基于 Leib Ramp 算法的脉冲输出 139

5.4 机械臂运动控制系统整体运行原理与测试 140

中国知网 https://www.cnki.net

5.5 本章小结 142

6 机械臂的实物控制实验 143

6.1 基于 ArUco 标签的物体位姿估计方法 143

6.2 相机标定 146

6.2.1 像素坐标系与图像坐标系的关系 146

6.2.2 图像坐标系与相机坐标系的关系 147

6.2.3 世界坐标系与相机坐标系的关系 149

6.2.4 相机的内参与外参 149

6.3 手眼标定 151

6.4 基于 V-REP 的机械臂虚实同步控制方法 152

6.4.1 虚实同步控制方法 152

6.4.2 虚实控制实验 154

6.5 本章小结 157

7 结论与展望 159

7.1 结论 159

7.2 创新点 161

7.3 展望 161

参考文献 163

致　谢 173

作者简介 175

中国知网 https://www.cnki.net

1 绪论

随着机器人技术的快速发展与普及，机械臂的运动规划功能发挥着越来越重要的作用。传统的机械臂示教运动规划方法存在诸多缺陷。使用强化学习算法来解决运动规划问题是近年来出现的新研究趋势。然而强化学习算法在一些复杂的任务中很难快速地收敛。这导致了实际训练当中的效率低下以及训练困难问题。本文针对基于深度强化学习的机械臂运动规划方法进行了研究。本章主要介绍研究的背景、国内外研究现状、研究意义和研究内容。

1.1 研究背景

自上世纪 50 年代第一台能够用于工业生产的机械臂 Unimate 出现后，在全世界范围内机械臂逐渐成为了广泛应用的自动化机械设备。机械臂相关科研领域成为了各国学者们关注的热点，其相关的理论与技术获得了快速地发展，并且在实际的工业生产当中得到了广泛地应用。

我国的机器人产业发展迅速。2018 年我国工业机器人销量为 15.4 万台，2019 年我国的工业机器人销量为 14.05 万台，虽然比 2018 年有所减少，但是仍然稳居全球第一[1]。近年来，美国和欧洲一些国家提出了工业物联网以及第四次工业革命的概念，我国在 2015 年提出了“中国制造 2025”[2]，该发展战略的核心为实现制造业智能化，实施制造强国战略。因此，机械臂在工业生产当中将发挥更重要的作用。

目前工业机械臂的应用主要是在传统行业，如汽车行业。传统行业的生产特点是生产环境单一并且生产工艺长时间不变。在相应的机械臂操作方法上，以示教方式为主。示教方法包括示教器示教和拖动示教。但是示教方法往往需要耗费操作者大量时间进行机械臂逐个位置的示教记录，该方法效率比较低且依赖人工操作[3]。

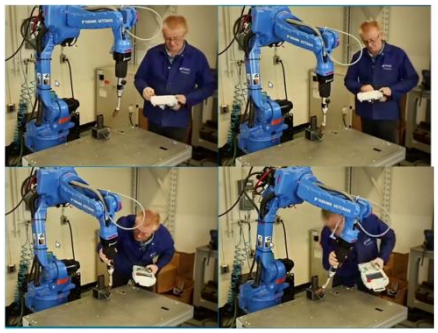


图 1.1 操作者通过示教器示教与拖动示教方式进行机械臂的运动规划

Fig. 1.1 The operator uses the teaching device to teach and drag the teaching method to plan the motion of the robotic arm

中国知网 https://www.cnki.net

随着汽车等传统行业的饱和，机械臂逐渐被应用于新兴的 3C 产业(Computer、Communication、 Consumer Electronics)，这些 3C 产业如手机组装等行业的生产特点与传统行业不同，3C 产品的产品线更新周期短、样式与种类繁多并且单件利润低，需要大批量生产。传统的机械臂人工示教方法难以根据工艺灵活地进行运动规划。

此外，随着技术的发展与机器人生产成本的降低，服务型机器人[4]与桌面型机器人[5, 6]逐步地进入了人们的生活当中。与传统的大型工业机械臂相比，这种类型的机械臂在保证相当性能的前提下，降低了生产成本，减小了体积并且更加注重人机交互的安全性。它们能够更好地应用于高校的机器人教学、科研以及人们的日常生活当中。这一类的机械臂与工业机器人最大的区别就在于，工业机械臂周围的环境往往是长期不变的，而这一类机械臂则需要根据工作场景当中的障碍物，实时而灵活地进行路径的规划。在这种情况下，传统的人工示教方法则更显不足。

机械臂的运动规划问题研究的就是能够代替人工示教自动地规划出一条从起点到终点且避开所有障碍物路径的方法。而示教方法相当于一种手动的运动规划方法。近年来，运动规划问题已经成为了机器人控制领域研究的热点问题。

1.2 国内外研究现状

本小节从经典的运动规划算法、高维空间运动规划算法、深度强化学习以及深度强化学习方法在机械臂控制领域的应用四个方面阐述了研究现状。

1.2.1 经典运动规划算法综述

运动规划问题研究的内容是：在一定的约束环境中，机器人根据所指定的起点与终点位置自动规划出一条避开所有障碍物保证无碰撞并且完全处于机器人可达工作空间之内的轨迹[7]。

在学术上，运动规划(Motion Planning)和路径规划(Path Planning)是针对关节式机械臂和移动机器人两大类不同机器人研究对象的相同研究问题。之所以认为运动规划和路径规划是相同的研究问题，是因为从数学算法的角度上来看，它们实际上共用相同或者相似的求解算法，两个领域问题的本质是相同的，属于同一问题在不同领域的不同表现。移动机器人领域的路径规划(Path Planning)问题是近年来各个国家相关科研人员研究的热点问题。移动机器人的路径规划问题主要解决机器人在 2 维或者 3 维空间中，从给定的起点到终点规划出一条无碰撞运动路径的问题。但是机械臂的运动规划问题又不同于移动机器人的路径规划问题，由于机械臂的每一个关节都属于一个维度，因此 3 自由度以上机械臂的运动规划问题都是在高维且非欧式空间进行，机械臂的运动规划问题比移动机器人的路径规划问题要

中国知网 https://www.cnki.net

更复杂。

传统的运动规划算法包括 Bug 算法、基于人工势场函数的算法、基于路图的算法和基于随机采样的算法。

（1）Bug 算法

Bug 算法是最基本的运动规划算法。Bug 算法分为 Bug1[8]算法和 Bug2[9]算法。在 Bug1 算法中，机器人首先沿着直线向着目标前进，碰到障碍物以后沿着障碍物边缘运动，它需要运动一整圈直到重新回到最初碰到障碍物的点，再找出沿着整个障碍物环绕轨迹上距离目标点最近的点，然后重新沿着障碍物边缘运动到该点，从该点脱离障碍物边缘继续沿直线向目标前进，直到抵达目标。Bug2 算法的基本原理是直接连接所指定的运动起点与终点构成一条直线段 m-line，然后机器人直接沿着最短的直线段向着目标前进，当碰到障碍物时，沿着障碍物的边缘运动，直到运动到与最短直线 m-line 相交的地方，脱离障碍物边缘继续沿着 m-line 向着目标前进直到抵达目标位置。显然，Bug2 算法要比 Bug1 算法效率高，图 1.2 是 Bug1 和 Bug2 算法的原理示意图。

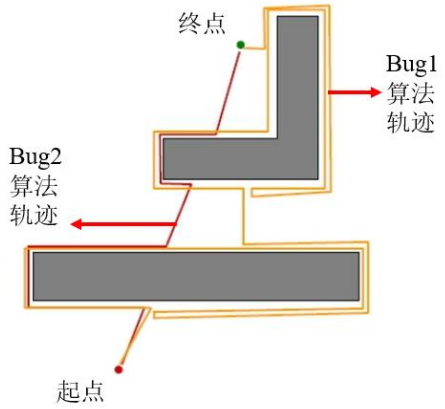


图 1.2 Bug1 和 Bug2 算法的原理

Fig. 1.2 Principles of Bug1 and Bug2 algorithms

（2）基于人工势场函数的算法

基于势场函数的算法又被称为人工势场法[10,11]。如图 1.3 所示，这种方法的基本思想是在规划空间的障碍物周围人工设置排斥势场，而在目标点周围人工设置吸引势场。势场由包含距离参数的函数构成。机器人在吸引势场和排斥势场的共同作用下将会自发地沿着一条路径从起点运动到达终点。人工势场法的优点是容易实现，势场函数的构造简单并且实践证明其规划效果较好。但是它很容易出现局部极小值从而使机器人陷入局部极小值处导致规划失败。人工势场法是一种不完备也不最优的运动规划方法。人工势场法当中的函数设置与强化学习中稠密类型奖励函数的设置有异曲同工之处，都是为了引导机器人向目标前进，都可能会遇到局

中国知网 https://www.cnki.net

部极小值，但又都是比较快速有效的方法。

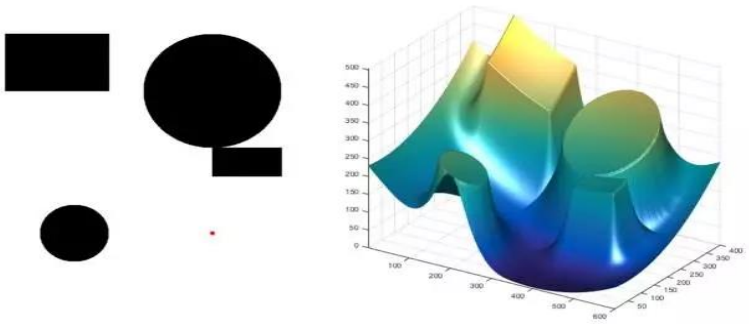


图 1.3 人工势场法

Fig. 1.3 Artificial Potential Field Method

（3）基于路图的算法

基于路图(Road Map)的算法是在移动机器人领域应用最广泛的路径规划方法。其核心思想是在规划空间当中首先按照一定的方法构造路图，然后利用图搜索算法搜索出一条连接起点与终点的路径。构造路图的方法主要包括可视图法(Visibility Graph)[12]和栅格化法(Cell Decomposition)[13, 14]。

可视图法将障碍物抽象成封闭凸多边形几何体，然后将其所有顶点、起点和终点互相连接成线段并且删去其中与几何体相交的线段，从而得到一个环绕所有障碍物且包含起点与终点的图。

栅格化法又称为空间离散法。首先按照一定的分辨率将规划空间离散划分成网格，凡是网格中存在障碍物的都属于不可通过的网格区域。然后在网格周围采用四连通或者八连通的规则即可得到一张图。栅格方法的主要问题在于其分辨率的设置。分辨率过大，则规划结果不精确，分辨率过小，则计算量会急剧增大，从而导致维度灾难[15]问题。

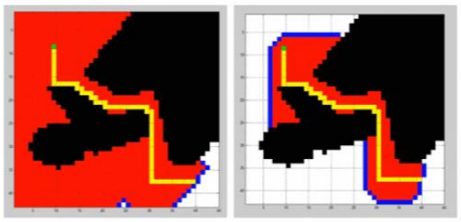
构建好路图之后，就可以使用典型的图搜索算法进行运动规划。典型的图搜索算法包括 Dijkstra[16, 17]和 A*[18]。

Dijkstra 算法由计算机科学家 Dijkstra 最早在 1959 年提出。其核心思想是设置一个优先级队列，初始化路图中每个节点 n 的距离函数为 g(n)，g(n)存储了从起点到该节点 n 的最短距离。最初起点的 g(n)等于 0，其他所有节点都为无穷大。然后从起点开始向外探索，探索它周围的所有邻居节点，按照使 g(n)最小的原则更新它们的 g(n)函数值并把它们放入优先级队列，然后优先级队列按照贪心原则弹出其中 g(n)值最小的节点，继续循环进行探索，直到到达终点为止。Dijkstra 算法是完备且最优的。它的主要缺点是算法从起始点向周围盲目的扩展搜索，它均匀穷举探索所有可达空间直到遇到终点或者探索完所有节点为止，因此它的效率不高。

A*算法可以认为是 Dijkstra 算法的一种升级版本。它的算法流程与 Dijkstra 算法基本一致，唯一的区别就是引入了启发函数 h(n)，h(n)用于估计从节点 n 到终点

中国知网 https://www.cnki.net

的最短距离。估计距离可以采用欧式距离或者曼哈顿距离[19]。将 Dijkstra 算法路图中每个节点的 g(n)函数变为 f(n) = g(n) + h(n)，探索时优先级队列按照贪心原则弹出 f(n)最小的节点。其他算法步骤与 Dijkstra 完全一样。A*算法是完备的。但是 A*算法是否最优与所采用的启发函数 h(n)有关系，只有当所估计的当前节点到目标距离小于等于真实的当前节点到目标的距离时，A*算法才是最优的，因此 A*算法的启发函数设计是至关重要的，也是学者们研究的一个重点问题。



(1) Dijkstra　　(2)A*

图 1.4 Dijkstra 算法与 A*算法

Fig. 1.4 Dijkstra algorithm and A* algorithm

（4）基于随机采样的算法

基于采样的算法主要包括概率路线图(Probabilistic Road Maps，PRM)[20]和快速搜索随机树法(Randomly Exploring Randomized Trees, RRT)[21, 22]。

PRM 算法随机地在规划空间采样点，然后再将所有的采样点、起点与终点用线段连接起来，删去所有与障碍物相交的线段，剩下互相连通的线段就组成了一张图，再使用图搜索算法找到一条从起点到终点的最短路径即可。PRM 算法规划出的路径如图 1.5(1)所示。

RRT 算法将起点作为树的根节点，然后随机向规划空间放置点，连接树上和所放置点最近的叶子节点，如果这条线段不与障碍物相交，则在这条线段方向上前进一步，并将得到的新的点增加为树的叶子节点，不断重复这个过程，就能够得到一个随机扩展树。当树的叶子节点到达终点时，树的生长过程结束，然后就可以得到一条从根节点也就是起点到终点的路径。RRT 算法规划出的路径如图 1.5(2)所示。

PRM 算法和 RRT 算法都是概率完备且不最优的。这意味着只要采样点的数量足够多，算法一定可以找到一个解，但是由于采样点是随机的，生成的路径一定不是最优的。并且在相同的约束环境下每一次重新执行算法都会得到一条不同的路径。

中国知网 https://www.cnki.net

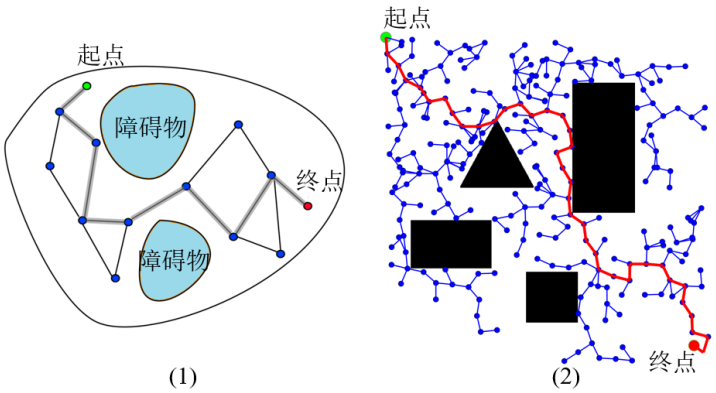


图 1.5 PRM 算法与 RRT 算法

Fig. 1.5 PRM algorithm and RRT algorithm

1.2.2 高维构形空间中运动规划算法综述

前述的所有运动规划算法都可以应用于 2 维或者 3 维空间的移动机器人，但是这些路径规划算法在研究问题时都是将机器人看作一个点，实际当中机器人有体积有形状，这时就需要在构形空间(Configuration Space)中对机器人做规划。构形空间[23]是考虑障碍物以及机器人的体积形状之后，将机器人抽象成点从而方便进行运动规划的一种规划空间。

移动机器人采用闵科夫斯基和(Minkowski Sum)[24]的拓扑学方法对障碍物进行膨胀处理从而得到对应的构形空间。机械臂的运动规划方法与移动机器人有很大区别。区别主要体现在两个方面：

第一个方面是机械臂运动规划的构形空间与移动机器人不同。移动机器人的构形空间是 2 维或者 3 维的欧式空间。而机械臂的构形空间则是一个高维的圆环空间[25]。图 1.6 是一个 2 自由度机械臂的构形空间，这是一个 2 维的圆环空间，其形状类似于一个“甜甜圈”。机械臂两个关节角所对应的维度已经标示在图 1.6 中。所有大于 3 自由度的机械臂将无法用可视的形式展现其构形空间，比如一个 6 自由度机械臂的构形空间应该是一个位于 6 维超空间的圆环。机械臂的任意一组角度构形抽象为其圆环构形空间表面的一个点。

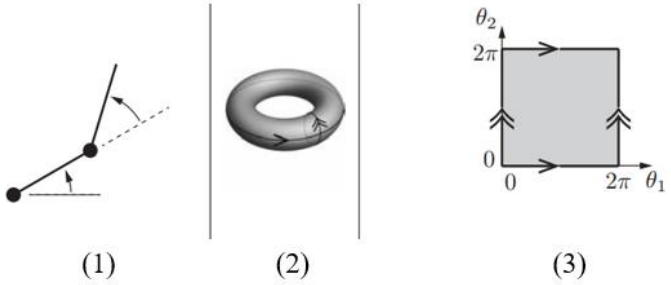


图 1.6 2 自由度机械臂与它的圆环构形空间[25]

Fig. 1.6 2 degrees of freedom robotic arm and its circular configuration space

中国知网 https://www.cnki.net

传统的运动规划算法都可以应用于 2 维或者 3 维的欧式空间中。但是它们是否可以直接应用于高维并且非欧式空间的圆环表面就成为了一个问题。针对这一问题，有学者使用拓扑学原理[26]证明了虽然 n 维圆环空间本身与 n 维欧式空间并不同胚，但是如果限定圆环空间每个维度的参数在一定范围内，就可以保证所得到的圆环空间的一个局部表面与 n 维的欧式空间是局部微分同胚[7]的。这一结论意味着所有传统的运动规划算法或者移动机器人的路径规划算法都能够在限定机械臂关节角度在一定范围内时应用于机械臂的运动规划问题，这一理论为经典的低维构形空间运动规划算法向高维空间推广提供了理论依据。如图 1.6 (1)中的 2 自由度机械臂，其构形空间实际上是图 1.6 (2)所示的圆环空间，但是当限定了它的两个关节角度范围为 0 到 2π 时，圆环构形空间的运动规划就等效于图 1.6 (3)所示的欧式空间 2 维平面中的运动规划。该结论可以向 6 自由度机械臂等高维空间推广。

机械臂的运动规划方法与移动机器人的第二个区别在于其维度更高。根据局部微分同胚的概念，6 自由度机械臂的运动规划相当于在一个 6 维空间的表面进行。这个区别使一些在移动机器人中可以很好运用的规划算法无法应用于机械臂。

基于路图方法中的可视图法在高维空间不成立。栅格方法理论上虽然可行，但是高维空间的栅格离散化以及障碍物在栅格中的映射都会带来十分巨大的运算量。例如 6 自由度机械臂，如果把每个关节所对应的维度按照 10° 分辨率来划分栅格，一共需要生成 36^6 个网格，此时的图搜索算法如 A*算法或者 Dijkstra 算法的运算量十分巨大。此外，在构形空间映射全部的工作空间障碍物也是一项困难的工作。因此基于路图的方法无法应用于自由度大于 3 的高维空间机械臂的运动规划问题中。

对于人工势场法，在高维的构形空间中构建势场函数同样比较困难。有学者采用直接在机械臂工作空间设置势场函数的方法[27]。这种方法直接在机械臂工作空间的障碍物以及机械臂自身的个别控制点上放置排斥势场，在目标点位置上放置吸引势场，也取得了一定的效果，该方法不能保证机械臂运动一定成功，因此这种方法不完备也不最优，但是易于操作。

目前已经应用于机械臂运动规划的算法主要是基于随机采样的算法。PRM 和 RRT 算法可以应用于高维空间的规划中。基于随机采样的运动规划算法在高维空间中的运算速度很快，这种算法不需要在构形空间映射工作空间的障碍物，而仅在采样点处检测是否发生碰撞即可。机器人操作系统 ROS[28, 29]中的运动规划功能包 MoveIt[30]内置的 OMPL(The Open Motion Planning Library)[31]库主要使用了 PRM 和 RRT 算法。但是原始的 PRM 和 RRT 算法仍然存在着一些问题，近年来国内外学者对 PRM 和 RRT 算法进行了一系列的改进。

2000 年，Kuffner 等学者在文献[32]中提出了双向 RRT(RRT-Connect)算法，通过在起点与终点同时设置搜索树的方法来较大程度减少算法的计算量。

中国知网 https://www.cnki.net

2008 年，Jaillet 等学者在文献[33]中提出了 Transition-based RRT 算法。针对经典 RRT 方法随机采样导致效率低的问题，该算法在构形空间构建成本地图(Cost Spaces)，通过成本地图来引导经典 RRT 当中随机的采样过程，从而大大提高了算法的效率。

2011 年，Karaman 等学者在文献[34]中提出了 RRT*算法，该算法在新生成叶子节点的同时对其周围相邻叶子节点进行扩展搜索，从而重新选择路径代价更低的父节点，通过重新布线的方法减少路径代价。该方法对于高维空间的机械臂运动规划具有重要意义。RRT*算法是渐进最优的，即只要算法进行搜索的时间足够长，RRT*算法就可以收敛到最优解。

2014 年，Gammell 等学者在文献[35]中提出了 Informed RRT*算法，针对经典算法随机采样效率不高且无法得到最优解的问题，该方法引入数学中关于椭圆的先验知识，将搜索限制在一个椭圆区域之内，构建新的路径之后，更新椭圆，再次搜索，直到算法收敛到最优解。该算法是渐进最优的。

传统的 RRT 算法对每一个采样点都进行一次碰撞检测，对于那些本身距离障碍物很远的采样点，这种做法会耗费额外的检测时间。针对碰撞检测效率问题，2019 年 Yavari 等学者在文献[36]中提出了 Lazy RRT 算法，按照所提出的原则只对接近障碍物的采样点有选择性地进行碰撞检测，从而减少了大部分的额外碰撞检测计算。

由于基于采样的运动规划方法是机械臂运动规划的主流方法，目前各国学者仍然在对相关的一系列算法进行改进。

1.2.3 深度强化学习综述

（1）机器学习

人工智能是自 20 世纪 50 年代以来学者们研究的热点领域。机器学习是实现人工智能的一种具体的算法手段。20 世纪 90 年代学者 Michie 在其著作[37]中首先提出了机器学习的定义。“假设用 P 来评估计算机程序在某任务类 T 上的性能，若一个程序通过利用经验 E 在 T 中任务上获得了性能改善，则我们就说关于 T 和 P，该程序对 E 进行了学习[38]”。机器学习首先获得数据并通过统计学中的方法来对人类大量的行为或者先验知识进行学习，训练所得到的机器学习模型可以独立工作。

机器学习按照其具体算法和应用领域的不同可以分为 3 类：监督学习、无监督学习和强化学习[39]。监督学习(Supervised Learning)的目标是根据输入给模型的大量带有标签的数据（自变量），得到带有预测性质的输出结果（因变量），并使该结果最优。监督学习根据输出的不同又可以分为两大类：回归问题和分类问题。回归问题解决的是函数拟合问题，根据以往数据拟合出一个函数，并且通过该函数可

中国知网 https://www.cnki.net

以对未来的数据进行预测。分类问题根据输入的不同数据，输出该数据的分类类别，机器学习在目标检测当中的应用就是一种分类问题。监督学习根据所采用的模型不同，又可以分为深度学习、支持向量机、决策树等不同类型。无监督学习输入给模型大量没有标签的数据，用于对数据进行聚类分析或降维操作。强化学习与上述两种机器学习方法的显著区别在于它不需要向模型提供大量的训练数据。强化学习在不断与环境进行交互的过程中进行采样得到需要学习的样本数据。

（2）强化学习研究现状

强化学习是一种机器学习方法。强化学习的训练过程就是找到能够使智能体(Agent)期望总收益最大的状态-行为映射函数。在学习之初，智能体并不清楚在某一个状态下采取何种行为策略能获得最大的总收益，而是通过不断地尝试，智能体不断地与环境进行交互，从而在实际交互过程当中自发地发现哪些行为是好的（获得丰厚收益），哪些行为是不好的（收益小甚至收益变为负值的惩罚）[40]。强化学习还强调智能体的最终目标是通过改变自己的状态-行为映射函数（行为策略）而使得总收益最大化。智能体的目标是最大化总收益而不是单步收益，如果智能体只考虑最大化单步收益，智能体就是短视的并且很难得到很好的最终效果。例如象棋比赛中，吃对方的棋子往往获得收益，而被对方吃棋子往往获得负收益，但是我们完全有可能为了赢得最终棋局的胜利而在最初阶段故意让对方吃掉自己的棋子，因为赢得整局棋的胜利代表着最大化期望总收益而非单步收益，暂时的负收益换来的可能是未来更大的正收益。综上所述，智能体在与环境交互过程当中不断进行试错和延迟收益是强化学习两个最重要的特点。

强化学习与目前已经得到广泛应用的监督学习有很大区别[41]。监督学习通过人类根据先验知识而提前进行了标记的大量训练数据来进行训练，这个过程相当于有“老师”指导智能体的行为。何种行为是正确的，何种行为是错误的已经被人为地标记出来。但是在强化学习中，整个训练过程并不需要人类的先验知识直接告诉智能体何种行为是正确的何种行为是错误的，而是通过间接地设置奖励函数的方式来引导智能体与环境进行交互。强化学习智能体在与环境的交互中，在不断进行试错中逐渐学习到正确的行为策略。从本质上讲，强化学习的方式与人类自己的学习方式很相似，少年时期在学校接受教育，有老师的引导，这一过程可以看做监督学习，但是在人类长大成人以后，要学习更复杂的知识，比如如何在社会上自己独立生活工作，大多数时候都是没有“老师”指导的，在多元价值观的影响下人类的很多行为无法用绝对的对与错来衡量，偶尔的吃亏或者辛苦可能带来长远的成功或者幸福，人需要不断地自我总结经验，从失败当中学习，从而找到最佳的人生行为策略。

强化学习与无监督学习同样有很大区别。无监督学习主要是通过训练让智能

中国知网 https://www.cnki.net

体自己找到数据内在的统计学关系。虽然无监督学习和强化学习都没有人类的先验知识作为直接输入，但是无监督学习侧重于寻找输入数据当中人类无法直接察觉到的高维度隐藏信息，而强化学习的目的是找到最佳的行为策略。强化学习的输出为对应于具体状态所采取的行为，因此强化学习在控制机器人行为策略的问题上应用广泛，是与监督学习和无监督学习并列的机器学习方法。

强化学习的另一个重要的特点就是需要在“探索”和“利用”之间折中权衡它们各自在训练过程中所占的比例[42]。“利用”指的是智能体在某个状态下采取已经通过强化学习算法学习过的行为。在与环境交互试错一段时间以后，智能体已经明确知道在某状态下执行该行为能够得到较好的收益。按照强化学习的最大化总收益目标，智能体应该更倾向于执行已知能够得到较大收益的行为，这就是“利用”行为。但是如果智能体仅仅由于希望得到最大收益而只表现出“利用”行为，那么智能体就无法尝试其他可能得到更高收益的行为，这样智能体就会局限于当前的行为策略而无法进步。因此智能体在“利用”已知好的行为的同时，还必须按照一定的概率去执行一些试探性的行为，哪怕这些试探行为导致更低的收益。智能体需要在整个强化学习的训练过程中去平衡“试探”与“利用”行为的比例，从而不断获得进步，才能最终收敛到最优策略。

强化学习可以分为基于模型(Model-Based)和不基于模型(Model-Free)两大类。模型是指与智能体进行交互的环境模型。具体而言，环境模型指当智能体执行了某个动作以后，环境会按照何种概率转移到何种状态。基于模型的强化学习算法目前主要应用于棋类任务中。在机器人控制等任务中，由于无法或者很难建立准确的环境模型，广泛采用了不基于模型的强化学习(Model-Free RL) 算法。因此，本文主要对能够应用于机器人控制的不基于模型强化学习方法进行研究。

不基于模型的强化学习又可以分为 3 种：基于价值函数的方法、基于策略梯度的方法和将价值函数与策略梯度结合起来的方法。基于价值函数的方法又被称为仅评论家(Critic-only)方法，该方法给智能体可以进行的每个行为赋予一个价值函数，智能体根据 ε-贪心算法[43]在每次行为决策中都选择价值函数最大的行为。因此基于价值函数的强化学习算法本质就是在不断学习和更新准确的行为价值函数，只有准确的价值函数才能得到准确的最优行为策略。基于策略梯度的方法则是另外一种与基于价值函数不同的方法，它又被称为仅演员(Actor-only)方法。它不引入价值函数参与行为策略的选择，而是使用一些方法直接更新优化行为策略。将基于价值函数的方法与策略梯度方法联合起来使用，就构成了演员-评论家(Actor-Critic)方法。

基于价值函数的方法是强化学习领域的传统方法。其中的动态规划法(Dynamic Programming, DP)[44]、蒙特卡洛法(Monte Carlo, MC)[45]以及时序差分法

中国知网 https://www.cnki.net

(Temporal Difference, TD)[46]是经典的强化学习算法，更具体来说，它们都是用来估计价值函数的方法。其中的动态规划方法是后两种方法的基础，但是动态规划方法和蒙特卡洛方法不易于实现。时序差分方法是最简单可行也是最常用的估计价值函数的方法，因此在后续被各国学者提出的强化学习算法中，当需要估计价值函数时，几乎都采用了时序差分方法。

基于价值函数并且采用时序差分算法估计价值函数的经典强化学习算法主要包括 SARSA[47, 48]和 Q 学习[49]。

SARSA 算法与 Q 学习算法非常相似，在与环境交互时它们都使用 ε-贪心算法来选择动作，并且在更新价值函数时它们都采用时序差分的方法。它们之间唯一的区别是 SARSA 算法是在轨策略(On-Policy)而 Q 学习是离轨策略(Off-Policy)。在轨策略指的是智能体与环境交互采样时所采取的行为策略和智能体使用采样更新价值函数时所对应的策略是同一个，也就是说一个智能体的策略用自己去采样，然后更新自己。离轨策略指的是智能体与环境交互采样时所采取的行为策略和智能体使用采样更新价值函数时所对应的策略不是同一个。在轨策略和离轨策略的区别贯穿所有的强化学习算法，它们是强化学习的另一个重要特征。一般而言，采用离轨策略的算法由于用来采样的策略和更新的策略可以不同，其算法效率比在轨策略要高，所有基于 Q 学习所衍生出的深度强化学习算法都可以采用离轨策略，同时设置经验池，把过去所有策略更新过程中的采样数据保存下来，不断地用这些数据来学习出更优化的策略。

传统的强化学习算法没有神经网络参与其中，其性能与使用受到很大的局限。2013 年，神经网络被引入强化学习算法当中，出现了深度强化学习算法。

（3）深度强化学习研究现状

深度学习属于机器学习的一种，是自 2006 年以后人工智能领域的研究热点。人工神经网络是深度学习的前身。人工神经网络技术在上世纪 50 年代开始兴起，1958 年感知机被提出[50]；1969 年麻省理工大学学者指出感知机的局限性；八十年代多层感知机被提出[51]，此时的人工神经网络实际上与今天所广泛研究的深度神经网络(DNN)已经非常相似；而后反向传播(Backpropagation, BP)算法[52]被提出，BP 算法是一种能够让神经网络参数更简单更快速进行梯度下降的方法。当时的学者发现超过 3 层的神经网络难以获得更好的训练效果，至此深度神经网络的功能与作用受到很大质疑。这一情况一直延续到了 2006 年，有学者提出深度学习的概念。

深度学习首先由 Hinton 在 2006 年的论文[53]中首次提出。而后采用计算机显卡(GPU)来加速神经网络训练的方法[54]被提出。学者 Krizhevsky 等人在 2012 年的图像识别比赛 ImageNet 中采用深度学习的方法获得了远超过传统方法的成绩[55]。

中国知网 https://www.cnki.net

在此之后，深度学习研究领域表现出井喷式的快速发展。

在将深度学习引入强化学习之前，传统的强化学习算法采用基于表格的方法来记录价值函数。例如，Q 学习使用时序差分算法估计在每一个状态能够采取的所有动作的价值函数值（Q 值），当训练完成以后，就得到一张 Q 表。这张 Q 表的行对应所有的状态，列对应所有的动作，高度对应 Q 值。一个典型的 Q 表如图 1.7 所示。在使用该策略时，智能体不断地根据目前所处的状态去查 Q 表，找到同一状态对应动作中价值函数最大的去执行。

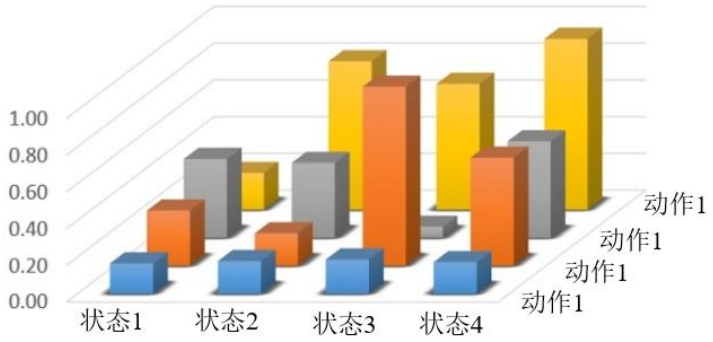


图 1.7 一个典型的 Q 表

Fig. 1.7 A typical Q table

由于单纯的强化学习使用基于表格的方法，当处理任务的状态或者动作非常多而无法穷举的时候，就会发生维度灾难问题[56]。基于表格的强化学习仅仅适用于智能体状态数量有限且不多的情况下。如果不是上述的情况，即使能够采用一定的分辨率离散化智能体的状态或者动作空间，其所构建的 Q 表也会非常巨大，每次遍历以及更新 Q 表都将会是很大的问题。机械臂的控制就属于这种情况，如果仅仅只把机械臂每一个关节维度离散成 100 个状态，对于 6 自由度机械臂就有 100^6 个状态，这是一个非常巨大的数字，后续对于表格的处理和计算将无法进行。

为了解决状态空间的维度灾难问题，2013 年谷歌公司的 DeepMind 团队首次提出将深度学习引入强化学习当中的深度 Q 网络(Deep Q Network, DQN)[57, 58]算法。DQN 算法将深度学习中的卷积神经网络(CNN)与强化学习中经典的 Q 学习相结合，并在雅达利小游戏上进行了训练与测试，结果表明训练后的智能体进行游戏所得到的分数远远高于人类玩家。DQN 的输入是一个高维的游戏图像画面(状态)，输出则是离散的游戏手柄动作。与传统的 Q 学习相同，DQN 也选择一副画面所对应所有可执行动作当中 Q 值最大的来执行。二者的区别在于传统 Q 学习用 Q 表这种表格形式来记录所估计的 Q 值，这时就会遇到维度灾难问题，而 DQN 则采用卷积神经网络来非线性拟合状态-动作对的 Q 值。但是 DQN 的输出动作是离散的，对于机械臂关节控制的问题，关节转动角度是连续变化的，因此 DQN 算法无法直接应用于机械臂的控制问题。

中国知网 https://www.cnki.net

DQN 提出之后，学者们不断地对其进行改进。针对 DQN 中 Q 值总是被过高估计的问题，Van Hasselt 等学者提出了双 Q 网络(Double DQN)[59]，该方法采用两个估计 Q 值的神经网络，在按照时序差分方法更新 Q 值时两个神经网络相互制约，从而使得 Q 值不被过高的估计。

DeepMind 研究团队提出了 Dueling DQN 算法[60]。这种算法针对原来 DQN 每次使用时序差分算法只能更新一个动作的 Q 值，算法收敛速度不够快的问题，修改了神经网络的结构，在原有直接输出 Q 值的基础上修改为输出 V(s)函数值和 A(s, a)函数值，此时 Q 值= V(s)+ A(s, a)。V 值相当于状态 s 下所有 Q 值的平均数。这样提高了使用时序差分算法更新网络进行训练的效率，从而使算法更快地收敛。

2016 年 DeepMind 研究团队提出了优先经验回放(Prioritized Experience Replay)[61]。DQN 算法是一种离轨策略算法，因此它可以采用之前策略采样得到的样本进行现在神经网络的更新，并设置经验库，存储原来的采样数据。DQN 算法随机选取经验库中的采样数据来进行训练。但是这样无差别地选取采样数据将使一些质量好的数据很难在巨量的经验库中被选择到，从而影响了算法收敛的速度。优先经验回放，引入了每条采样数据的优先级，优先级按照时序差分时的 TD-error 大小进行排序，优先选择优先级高的数据进行训练。

DQN 属于基于价值函数的强化学习算法，另一种类型的强化学习方法是基于策略梯度的方法。基于价值函数的方法首先评估 Q 值，然后按照贪心原则选取 Q 值最大的行为执行，评估 Q 值的网络可以看作一个评价行为好坏的评论家(Critic)。而基于策略梯度的方法则更加直接，给智能体输入一个当前状态，智能体直接输出所选择的动作，这个过程并不依赖 Q 值的估计。策略梯度的一般架构就是训练一个神经网络，该网络的输入是状态，输出是动作。决策的网络可以看作一个演员(Actor)，演员直接对所处状态做出动作决策而不依赖于评论家对该行为的评价。

学者 Sutton 首先提出了策略梯度方法(Policy Gradient, PG)[62]。相比于 DQN 这种基于价值函数的方法，PG 方法最大的优势在于它可以输出一个连续的动作值。而所有基于价值函数的方法得到的都是离散值，这些方法对于机械臂这种需要连续动作控制的任务并不适用。但是 PG 方法也有 3 个明显缺点：一是 PG 方法实际上是一种随机策略梯度方法，所谓随机是指对于同一个状态 s，它所输出的动作值是在一个概率分布当中随机选取的，因此，每一次决策时即使输入相同的状态，智能体都可能采取不同的动作。二是策略梯度算法比较不稳定，容易受到超参数设置的影响，在实际应用时很容易不收敛。三是采样利用率低，PG 方法属于在轨策略方法，每回合采样数据只能用于训练一次。

2014 年学者 Silver 等人首次提出了确定性策略梯度(Deterministic Policy Gradient, DPG)[63]。在此之前学术界普遍认为策略梯度算法得到的结果只能是随机

中国知网 https://www.cnki.net

的而不可能是确定的。Silver 的论文首先对之前的策略梯度方法进行回顾，然后从数学上推导得到了确定性策略梯度的结论。他的结论认为确定性策略梯度实际上是随机策略梯度的特殊形式，即策略的方差值趋于 0。

针对传统 PG 方法采样利用率低，且很不容易收敛的问题。2015 年美国加州大学伯克利分校学者 Schuulman 等人提出了信任域策略优化(Trust Region Policy Optimization, TRPO)[64]。该算法将重要性采样引入 PG 方法中，在满足散度 KL 约束的条件下，智能体可以多次利用之前策略进行采样得到的数据来进行训练，并且更加易于收敛。

学者 Bahdanau 等人提出了演员-评论家(Actor-Critic)[65]方法。该方法将基于价值函数的方法（称为 Critic）与策略梯度方法（称为 Actor）相结合。算法中的 Actor 部分负责根据状态生成行为，而 Critic 部分负责评估所选出行为的优良程度，然后 Actor 部分依据所得到的评估结果来改进自己，使得自己逐渐达到最优。

学者 Silver 等人提出了深度确定性策略梯度方法(Deep Deterministic Policy Gradient, DDPG)[66]。DDPG 算法基于 Actor-Critic 框架采用了 4 个神经网络，Actor 部分两个神经网络，Critic 部分两个神经网络，并且借鉴了 DQN，大幅度提高了算法的性能。DDPG 算法能够解决连续动作空间类型的任务。

2017 年谷歌 Deepmind 团队和 OpenAI 团队在同一时间分别发表论文，提出了针对 TRPO 算法的改进版本近端策略优化(Proximal Policy Optimization, PPO)算法[67, 68]。该算法将 TRPO 中的散度 KL 约束条件直接加入到优化表达式中，使其实现更加简单，同时算法收敛更快。

1.2.4 基于深度强化学习的机械臂控制方法综述

将深度强化学习应用于机械臂控制是近年来随着强化学习算法的不断发展而出现的一个新的研究热点。使用强化学习的方式进行机械臂的运动规划是一种仿人的思路，因为人类使用自己的手臂规划动作路径时从来不需要示教或者各种运动规划算法的参与。人类是根据自己从婴儿时期逐渐学习到的经验来与环境互动，而这些经验来自于与环境的交互和试错，父母老师的指导等。这使得基于强化学习的运动规划具有比传统运动规划算法更好的泛化能力以及更快的速度，尤其是在处理一些复杂任务时具有一定的鲁棒性和自适应性。

然而相比于强化学习可以解决的其他领域的智能控制问题而言，机械臂的控制又有其特殊性，这导致很多强化学习算法无法应用于机械臂控制问题。输入状态空间连续、输出动作空间连续、状态与动作空间维度高是机器人领域强化学习任务的 3 大特点[69]。因此，机器人控制问题相比于深度强化学习领域其他任务类型的难度要更高。

中国知网 https://www.cnki.net

基于价值函数的强化学习算法的原理都是评估行为的 Q 值，而 Q 值对应于每一个状态-行为对，它是离散的。也就是说 DQN 以及其改进算法只能够处理状态空间高维度而动作空间是离散低维度的问题。如果将机械臂每个关节进行离散化处理，又将面临运动控制的精度问题以及维度灾难问题。基于策略梯度的 PG 方法很难在训练过程中快速收敛。因此在学者对 PG 方法进行进一步演化提出 PPO 以及 DDPG 算法之前，机械臂的控制问题是强化学习不容易解决的。

2016 年顾世翔等学者提出了深度 Q 网络归一化优势函数(DQN-Normalized Advantage Functions, DQN-NAF)方法[70]。该方法通过修改传统 DQN 中的神经网络输出，使 DQN 这种基于价值函数的方法也能够输出连续动作值并且可以应用于机械臂控制问题。

Sangiovanni 等学者在文献[71]中应用 DQN-NAF 算法控制虚拟环境 V-REP 中的工业机械臂模型。通过设置合理的稠密奖励函数，训练机械臂自动地避开了环境中的障碍物。

Mahmood 等学者在文献[72]中采用 TRPO 算法成功控制一台 UR5 机械臂完成了到达目标点的任务。文献研究了强化学习算法在控制一台真实机械臂时出现的一些控制问题。

陈建华在文献[73]中对采用 DDPG 算法进行机械臂运动规划问题进行研究，并且研究了无障碍物环境下和有障碍物环境下的运动规划。提出了对 DDPG 算法进行改进的方法，并且将迁移学习[74]引入到机械臂运动规划任务中，加快了算法的收敛速度。

董贯涛在文献[75]中对采用 DDPG 算法控制机械臂进行抓取的方法进行了研究，提出了 DDPG 的改进方法，并提出了针对密集物体的推抓结合抓取方法。

闫冬等学者在文献[76]中采用 PPO 算法联合 DDPG 来进行电力机器人带电作业任务的运动规划研究。针对作业环境设置了一种稠密奖励函数，提出先用 PPO 算法进行避障，然后再用 DDPG 算法进行导航的组合运动规划方法。

李鹤宁等学者在文献[77]中采用 DDPG 算法控制虚拟仿真环境中的机械臂移动到特定区域。

郑均天在文献[78]中研究采用 DQN 方法控制机械臂轨迹，但是 DQN 方法只能输出离散动作，该文献将机械臂在笛卡尔空间上的动作离散成上下左右 6 种动作，然后提出了动态改变 DQN 离散控制输出步长的方法，当距离目标较远时，采用大步长输出，当距离目标较近时采用小步长。总体而言这种将机械臂连续动作离散的控制方法会影响控制的精度。

张子扬在文献[79]中采用 PPO 算法控制水下液压机械臂完成了对目标物体的抓取操作。

中国知网 https://www.cnki.net

黄伟伟在文献[80]中采用 PPO 算法控制机械臂抓捕飞行物体。提出了基于比例导引的机械臂抓捕运动规划方法。

1.3 问题的提出及研究意义

本小节提出了研究问题，然后阐述了课题的研究意义。

1.3.1 研究问题的提出

机械臂的运动规划方法能够找到一条从当前构形起点运动到目标构形终点且避开所有障碍物的轨迹。在传统的机械臂控制当中，人工示教是实现机械臂运动规划的常用方法。但是示教方法严重依赖于人工手动进行操作。随着时代的发展，传统的示教方法已经越来越难以满足机械臂智能化控制的需要。

在移动机器人领域，运动规划是在 2 维或者 3 维构形空间进行的。经典的运动规划算法 A*和 Dijkstra 等都可以应用于移动机器人运动规划任务中。但是机械臂的运动规划则是在高维构形空间中进行。构形空间的维度取决于机械臂的自由度数。这种特点使能够在低维构形空间中使用的运动规划算法难以在高维空间继续使用。对于运动规划的可视图法，在高维构形空间中并不成立。对于栅格类的运动规划方法，在高维空间中理论上可行，但是面临着运算量巨大的问题。并且该类方法需要构建从工作空间到构形空间的障碍物映射，目前没有很好的方法精确地进行这种映射，一般的做法是将构形空间离散化，然后在每个离散的网格中判断是否存在工作空间的障碍物。对于人工势场法，如果在高维构形空间当中构建势场，同样面临着运算量巨大的问题，如果直接在工作空间中添加控制点构建势场，则同样会面临局部极小值问题。

运动规划的构形空间维度越高，难度就越大。一般的算法都面临着计算量巨大的问题，在这种情况下，基于随机采样的运动规划方法成为了目前在机械臂高维构形空间中进行规划的主要算法。这一类算法无需构建从工作空间到构形空间的障碍物映射，而仅仅需要对在构形空间中随机采样得到的点进行工作空间的碰撞检测。但是这一类算法需要在构形空间中随机地进行大量的采样选点，并且所生成的路径轨迹具有相当的随机性。

随着各国学者不断在人工智能领域取得新的突破，将深度强化学习应用于运动规划问题求解是近几年来出现的新趋势。相比于传统算法，基于机器学习的方法有很强的泛化能力以及鲁棒性，比较适合应用于机械臂在复杂环境中的运动规划问题。但是深度强化学习算法作为一种解决机械臂运动规划问题的新方法，在应用的过程中仍然存在着诸多问题有待解决：

（1）虽然已经有部分学者将强化学习应用于机械臂的运动规划问题，但是不

中国知网 https://www.cnki.net

同的学者往往是分别采用 DQN-NAF、PPO 和 DDPG 等算法中的一种加以分析并应用于机械臂运动规划任务。对于不同强化学习算法性能的比较，虽然国外已经有部分学者进行研究，但是这些研究往往不是针对机械臂运动规划问题。那么这些强化学习算法在机械臂运动规划问题中的表现如何，在相同任务中的性能区别如何，哪一种最适合解决机械臂运动规划任务。这些强化学习算法在机械臂特定领域应用的问题，目前研究还比较少。

（2）强化学习的训练过程是智能体与环境不断交互试错的过程。受制于强化学习算法的这种特点，强化学习算法在一些复杂的任务中需要进行大量的随机探索动作，因而很难快速地收敛。这导致了在实际训练中效率低下以及训练困难等问题。对于一些复杂的任务，强化学习智能体从头开始训练到收敛状态是很困难的，并且需要很长时间。

（3）区别于一般的控制方法，强化学习并不直接指示被控对象的具体做法以及需要完成任务的具体目标，而是间接地给出融入了人类先验知识的奖励函数。通过奖励函数来间接引导强化学习智能体自发地找到最优策略。奖励函数分为稠密奖励函数与稀疏奖励函数。稠密奖励函数存在局部极小值问题，并且加入过多的先验知识可能反而不利于找到最优策略。稀疏奖励函数则面临着智能体由于获得的奖励过于稀疏导致训练效率低下的问题。如何更有效率地引导强化学习智能体训练是目前强化学习领域的热点研究问题。

（4）如果强化学习智能体需要解决的运动规划任务难度过大，那么很有可能无论经过多长时间，多少回合的训练，强化学习算法都无法收敛，根本无法完成任务。对于人类而言，对复杂知识的学习可以被划分为从易到难，从简单到复杂的学科课程。那么对于强化学习智能体而言，同样需要找到一种能够解决大难度任务训练的方法。

综上所述，本文采用深度强化学习方法对机械臂的运动规划问题进行求解，并针对上述存在的问题进行了深入研究。

1.3.2 研究意义

（1）随着机械臂在新兴 3C 产品制造业中的应用，对区别于传统示教方式的运动规划方法进行研究，在推动行业发展，推动机械臂在 3C 行业中的普及，提高生产效率等方面具有重要意义。

（2）新兴的服务机器人以及桌面机器人在家庭应用、个人生活以及高校的科研教学中发挥着越来越重要的作用。其中的运动规划技术是关键技术之一，配合更加先进的视觉算法，能够实现更加复杂的应用。推动更加智能的机械臂走进人们的生活中，使机械臂真正地从单纯的工业应用走进普通人的生活。

中国知网 https://www.cnki.net

（3）强化学习的方法源于仿生学和心理学。仿生学对于机器人的研究具有重要意义[81]。传统的机械臂控制方法准确而“呆板”，将人工智能领域的深度强化学习方法引入到机械臂控制中，能够使机械臂的动作更加的拟人化，更加具有泛化能力以及鲁棒性。

1.4 本论文的主要研究内容

（1）研究基于 3 种典型深度强化学习算法的机械臂运动规划方法

对用于机械臂运动规划任务求解的深度强化学习算法理论进行了研究，分别分析了 DQN-NAF、DDPG 和 PPO 算法，这 3 种算法均能够处理连续动作空间任务。采用机器人虚拟仿真平台 V-REP 在计算机上构建用于研究机械臂深度强化学习训练的虚拟实验平台。在 V-REP 软件中设置无障碍物环境下的 6 自由度机械臂运动规划任务，分别将 DQN-NAF、DDPG 和 PPO 算法应用于完成该虚拟任务，比较这 3 种算法在相同的运动规划任务当中的性能。

（2）研究基于残差强化学习的有障碍物环境运动规划方法

针对强化学习算法需要与环境进行大量试错交互，在训练中效率低下以及训练困难的问题，提出一种基于残差强化学习的运动规划方法。该方法将运动规划过程中智能体的行为策略划分为初始策略与残差策略，初始策略由 BP 神经网络构成，残差策略由深度强化学习算法构成。在提出的方法中，初始策略用于引导强化学习算法向着正确的方向训练。强化学习算法的训练过程从原本的随机试错过程变为由初始策略引导的有方向训练过程，从而大大减小训练的难度并提高训练的效率。

（3）研究基于 BP 神经网络的初始策略以及基于改进 PPO 算法的残差策略

在构建残差强化学习运动规划方法的初始策略时，采用基于 BP 神经网络以及球体障碍物抽象的机械臂运动规划方法。该方法利用神经网络的非线性拟合能力，采用传统的 RRT*运动规划算法生成供神经网络训练用的规划轨迹数据。使所构建的神经网络可以根据当前构形、目标构形，以及障碍物位置半径特征值预测输出机械臂下一个可能的构形。该方法作为初始策略引导作为残差策略的强化学习 PPO 算法进行训练。

在构建残差强化学习运动规划方法的残差策略时，提出一种改进 PPO 算法。传统 PPO 算法属于在轨策略，每次采样一定数量的样本，然后在保证 KL 散度约束的条件下，对行为策略神经网络进行一定次数的训练更新，然后重新采样，再次继续上述的过程，采样数据利用率比较低。将 DDPG 等离轨策略方法中广泛采用的经验池机制重新引入到传统 PPO 算法中，同样在必须满足重要性采样原理中 KL 散度约束条件的前提下，设置小型经验池，然后从小型经验池中采样一个小组，用

中国知网 https://www.cnki.net

于策略网络的训练。并且在小型经验池数据的选择中引入基于 SumTree 数据结构的优先经验回放方法，将优先级大的样本数据优先提供给智能体训练。

（4）研究基于课程学习的环境难度动态变化训练方法

针对残差强化学习运动规划理论提出的球体障碍物抽象方法，当障碍物实际形状与所抽象出障碍物球体相差很大时，将会出现智能体训练难度过大的问题。提出一种基于课程学习的简化障碍物强化学习训练方法。该方法的核心思想是通过改变环境中障碍物在实际训练时的体积大小来动态调整训练的难度。对于机械臂的运动规划任务，障碍物越小，训练也就越容易进行。在训练的初期，障碍物从原始大小缓慢的减小，直到其体积缩小到障碍物的内切球体大小。此时的训练环境达到最简单，然后再逐步增大障碍物的体积，继续进行训练，直到障碍物恢复其原本的形状。

（5）研究基于前瞻算法的机械臂轨迹规划方法

分析机械臂运动规划与轨迹规划之间的关系。运动规划先于轨迹规划进行，运动规划得到的是与时间函数无关的离散机械臂构形序列，而轨迹规划则进一步用时间函数将构形序列进行衔接。为了将运动规划得到的离散构形序列应用于真实的机械臂控制，提出一种基于前瞻算法的机械臂关节空间轨迹规划方法，该方法将机械臂运动控制系统中需要按照先后顺序执行的运动规划构形位置进行速度的前瞻规划，保证了机械臂运动的平稳性。

1.5 技术路线

本论文的技术路线如图 1.8 所示。

1.6 本章小结

本章阐述了机械臂运动规划方法的研究背景。从经典运动规划算法、高维构形空间的运动规划算法、深度强化学习算法以及其在机械臂控制中的应用等方面阐述了该领域的国内外研究现状。同时提出了本文的研究问题、研究意义和研究内容。

中国知网 https://www.cnki.net

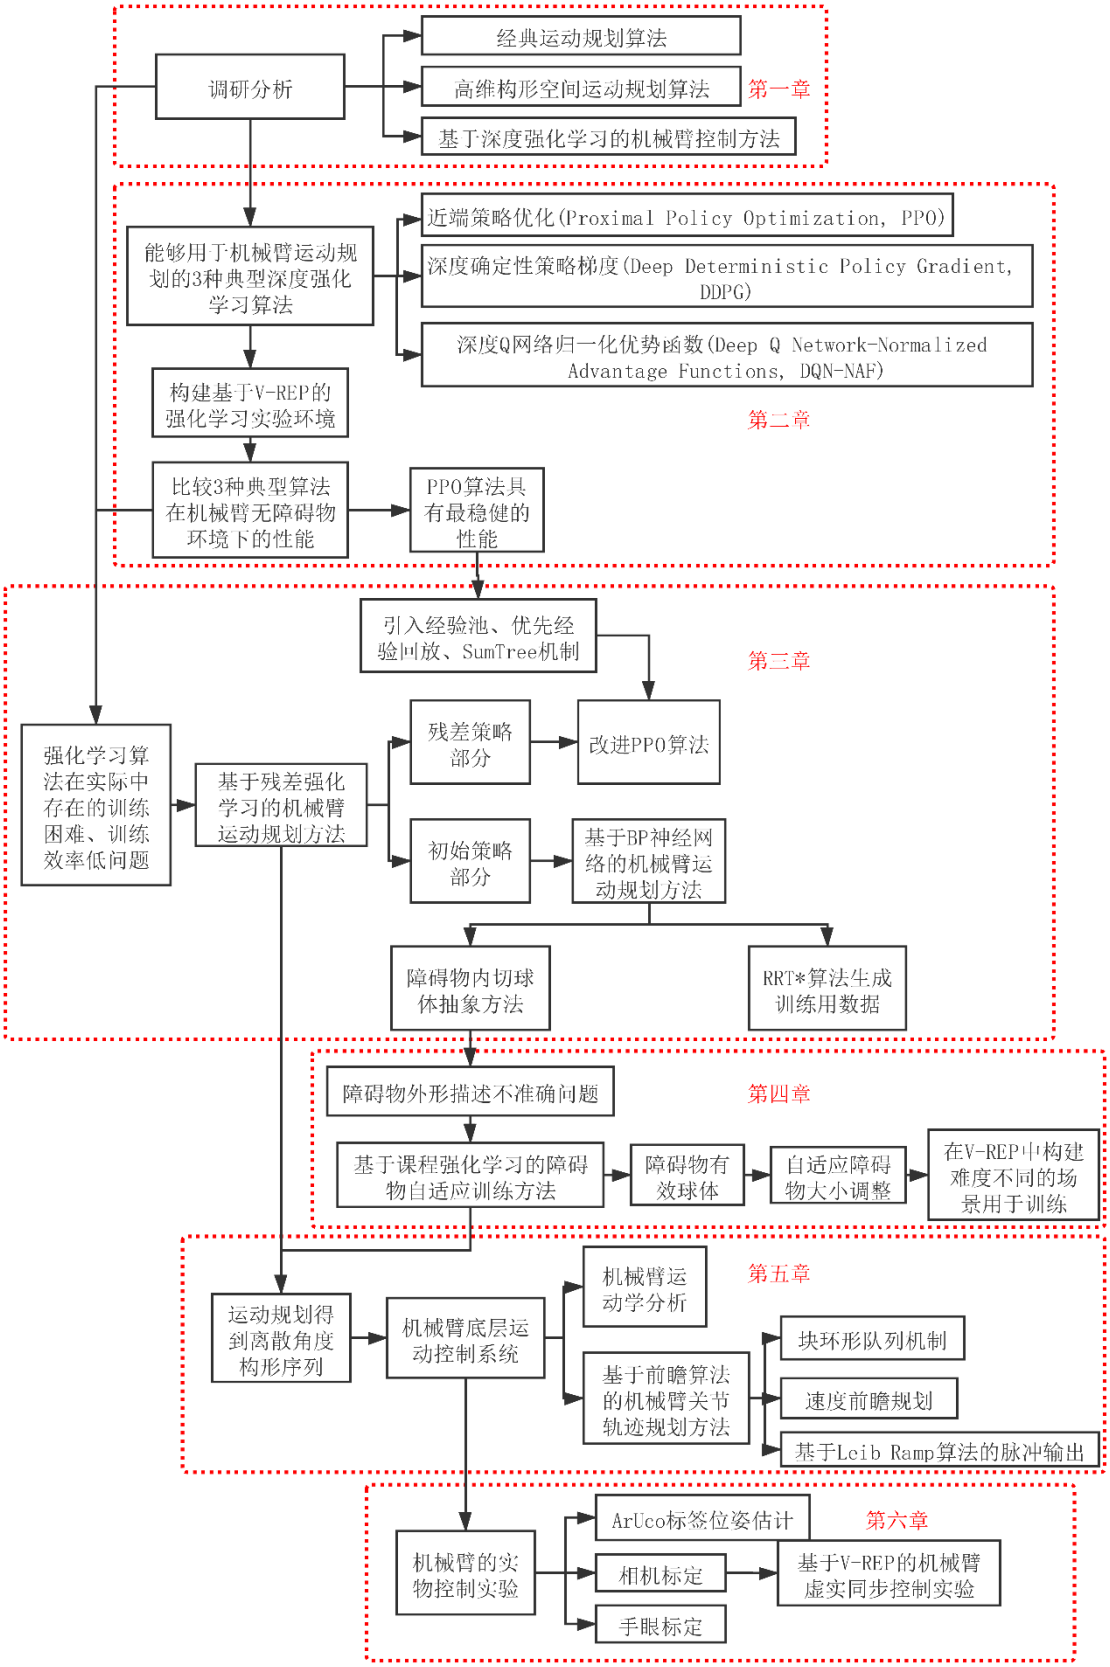


图 1.8 技术路线图

Fig. 1.8 Technology roadmap

中国知网 https://www.cnki.net

2 基于典型深度强化学习算法的机械臂运动规划方法

将深度强化学习算法应用于机械臂的运动规划是近年来机器人控制领域的研究热点，但是相比于强化学习在其他领域的应用，机械臂控制有其特殊性，并非所有的强化学习算法都能够直接应用于机械臂控制。传统基于价值函数的表格型强化学习方法面临着“维度爆炸”问题。因此 DQN 算法将深度神经网络引入了强化学习中，但是以 DQN 为代表的基于价值函数的深度强化学习方法输出仍然是离散且不连续的。能够应用于解决机械臂运动规划问题的深度强化学习算法必须满足两个条件：算法的状态空间高维且连续，算法的输出连续。基于策略梯度的强化学习算法是满足上述条件的，因此策略梯度方法是可以用来实现机械臂运动规划的。基于策略梯度的强化学习算法主要是包括近端策略优化(Proximal Policy Optimization, PPO)算法和深度确定性策略梯度(Deep Deterministic Policy Gradient, DDPG)算法。此外，有学者对基于价值函数的 DQN 算法神经网络末端进行改进，得到了深度 Q 网络归一化优势函数(Deep Q Network-Normalized Advantage Functions, DQN-NAF)算法，将传统 DQN 算法的离散输出部分进行修改后，该算法也支持连续动作输出，同样可以应用于机械臂控制。已经有一些学者分别使用了上述的 3 种算法来解决机械臂的控制问题。但是对于上述 3 种算法在解决机械臂控制问题时在性能方面的具体区别，讨论还比较少。

本章第 1 小节首先介绍强化学习的理论基础，介绍了马尔可夫决策过程(Markov Decision Processes, MDP)，具体阐述了 MDP 的一些概念和性质，说明了 MDP 作为强化学习理论基础的原因。然后介绍了基于 MDP 所构建的强化学习理论当中的重要参数，算法的基本模型以及算法的基本原理。第 2 小节依次介绍了目前能够用于解决机械臂运动规划问题的 3 种深度强化学习算法：DQN-NAF、PPO 和 DDPG。第 3 小节介绍了后续进行算法训练与验证的虚拟仿真环境 V-REP。第 4 小节使用第 2 小节所介绍的 3 种深度强化学习算法在虚拟仿真环境 V-REP 中进行了无障碍物环境下机械臂的运动规划实验，并对比了 3 种算法在机械臂运动规划任务上的性能。

2.1 马尔可夫决策过程与强化学习算法模型

本节阐述了马尔可夫决策过程以及强化学习的算法模型，介绍了相关的概念以及数学原理。

中国知网 https://www.cnki.net

2.1.1 马尔可夫决策过程

马尔可夫决策过程是强化学习算法的数学模型。在强化学习算法当中，与环境进行交互并且进行一系列决策的主体被称为智能体(Agent)。与智能体发生交互的事物被称为环境(Environment)[40]。如图 2.1 所示为智能体与环境的交互过程原理。在每个离散时刻 t=0，1，2，3…，智能体根据所观察到的环境状态 S_t 来进行决策，选择动作 a_t 执行，执行动作后，智能体接收到一个数值化的即时奖励 R_{t+1},同时环境由于受到智能体行为的影响，从而进入下一个新的状态 S_{t+1}。

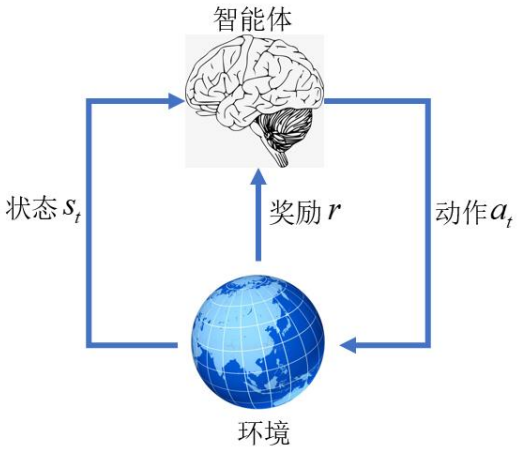


图 2.1 强化学习的基本框架

Fig. 2.1 Basic framework of reinforcement learning

马尔可夫性质指的是交互序列的下一个状态 S_{t+1} 只与当前状态 S_t 和当前决策的动作 a_t 有关，而与早前的状态和动作完全无关。用状态转换的数学公式来描述为：

$$P\{s_{t+1} \mid s_t, a_t\} = P\{s_{t+1} \mid s_t, a_t; s_{t-1}, a_{t-1}; \ldots; s_0, a_0\} \tag{2.1}$$

式(2.1)表示在一个任意状态 S 下，状态的转换概率为 P，智能体在采取决策动作 a_t 之后得到的奖励与环境转换得到的下一个状态 S_{t+1} 与智能体之前经历的所有状态无关。本质上说明了强化学习算法仅关心当前智能体所处的环境状态，这个状态已经包含了过去智能体与环境进行交互的各种信息。马尔可夫决策的动态过程可以表示为一个如图 2.2 所示的序列。智能体观察到初始环境状态 S_0，然后决策选择一个动作 a_0 执行，环境根据转移概率 $P(s_1,r_1|s_0,a_0)$转换到下一个状态 S_1，并且得到奖励 r_1，然后智能体与环境不断循环进行上述过程。最终得到一个序列 $(s_0,a_0,r_1,s_1,a_1,r_2,s_2,a_2,r_3\ldots)$。所有能够用强化学习算法解决的问题都可以被抽象为一个这样的马尔可夫决策过程序列。

中国知网 https://www.cnki.net

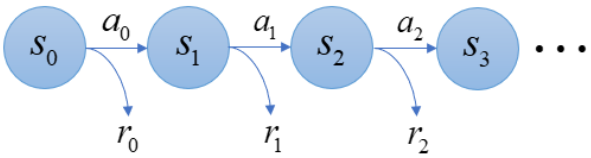


图 2.2 马尔可夫动态过程

Fig. 2.2 Markov dynamic process

2.1.2 从马尔可夫决策过程到强化学习算法

当一个任务可以被抽象成一个 MDP 动态过程时，强化学习算法就可以应用其中。强化学习算法的最终目标就是寻找一个最优的策略，智能体按照这个策略来根据所处的状态选择所要执行的行为从而使得累计的期望总收益最大化。智能体执行的策略可以数学地表示为：

$$\pi(a|s)=P[a_t=a|s_t=s] \tag{2.2}$$

用 π 来表示一个策略，当给定策略 π 时，整个 MDP 动态过程的累计收益被定义为：

$$R_t=r_{t+1}+r_{t+2}+r_{t+3}+... \tag{2.3}$$

如果一个任务中智能体-环境交互的 MDP 动态过程不是回合式而是一直不断持续进行下去的，式(2.3)所表示的期望累计收益将会很容易趋于无穷大。为了避免这个现象发生，引入折扣系数 γ 后的累计总收益表示为：

$$R_t=r_{t+1}+\gamma r_{t+2}+\gamma^2 r_{t+3}+...=\sum_{k=0}^{\infty}\gamma^k r_{t+k-1} \tag{2.4}$$

在实际的智能体-环境交互过程中，智能体每次获得的奖励值是随机的，但是累计奖励的期望值是一个确定的值，该值就是状态价值函数：

$$V^{\pi}(s)=E_{\pi}\left[\sum_{k=0}^{\infty}\gamma^k r_k\right] \tag{2.5}$$

状态价值函数表示从当前智能体所处状态向未来方向看，最终智能体能获得的累计收益的期望值。显然状态价值函数可以反映当前智能体所采用的策略 π 的优劣。本质上，一个马尔可夫决策过程的最优策略 π*由下式表示：

$$\pi^*=\arg\max V^{\pi}(s) \tag{2.6}$$

智能体在处于状态 s 并且采取动作 a 情况下，最终累计收益的期望值就是状态-行为价值函数：

中国知网 https://www.cnki.net

$$Q^{\pi}(s,a)=E\left[\sum_{k=0}^{\infty}\gamma^{k}r_{k}|s_{0}=s,a_{0}=a\right] \tag{2.7}$$

2.1.3 基于价值函数的强化学习算法

从强化学习的算法原理来划分，强化学习算法可以被分为基于价值函数的算法和基于策略梯度的算法。基于价值函数的算法原理示意如图 2.3 所示。它包含两个迭代中的过程，首先算法按照一定的方法来估计当前策略 π 所对应的各个状态的价值函数，这个过程被称为策略估计；然后算法根据当前估计好的价值函数值贪心的更新策略 π，由于算法按照价值函数贪心的更新策略，该策略一定比原来的策略要好，这个过程被称为策略改进。两个过程循环往复的进行下去，它们需要持续更新智能体所遇到的所有状态，最终的结果就是策略收敛到能够使得价值函数值最大(V^*)的最优策略(π^*)。

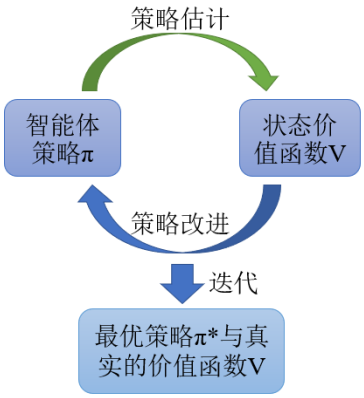


图 2.3 强化学习算法的策略估计与策略改进过程

Fig. 2.3 Policy estimation and policy improvement process of reinforcement learning algorithm

基于价值函数的强化学习算法的核心在于估计价值函数值，也就是进行策略估计，围绕着策略估计方法的不同，强化学习衍生出不同的基本方法：动态规划方法、蒙特卡洛方法以及时序差分方法。由于动态规划方法是基于环境模型的方法，它需要首先确定环境的状态转移概率，这在一般的智能体与环境的交互中是不容易实现的，所以它在实际当中较少使用。但是，蒙特卡洛方法和时序差分方法实际上都是对动态规划方法的简化，其核心思想仍然蕴含其中。

蒙特卡洛方法和时序差分方法都属于不基于环境状态转移概率模型的方法。由于缺少环境状态的转换概率，它们都通过智能体与环境交互进行采样的方法来估计价值函数的真实值。蒙特卡洛方法与环境交互并且一直采样到回合结束，因此它只能够用于回合制的任务中。由于蒙特卡洛方法是基于采样的，且需要多次采样到一个回合结束，该方法所估计值的偏差会很大。如图 2.4 所示，取蒙特卡洛方法得到的多个采样序列的收益平均值来估计真实价值，只有当采样回合数足够多时

中国知网 https://www.cnki.net

算法所估计的价值函数值才能够比较接近真实值。

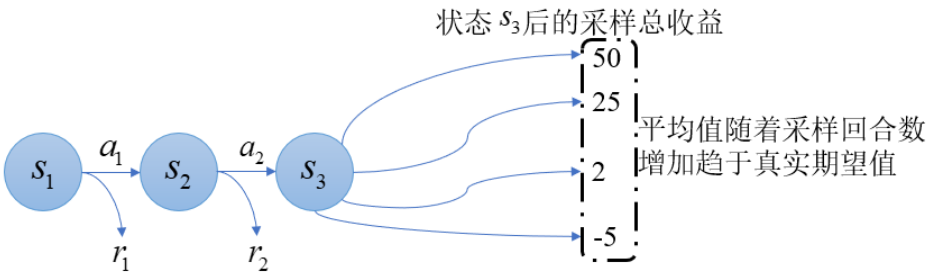


图 2.4 蒙特卡洛方法采样对总收益估计的随机性

Fig. 2.4 The randomness of Monte Carlo sampling on total revenue estimation

时序差分算法只对决策过程进行单步采样，它采用单步采样得到的即时收益 r 以及下一次状态所对应的价值函数 $V(S_{t+1})$来更新本次状态的价值函数 $V(S_t)$，如式(2.8)所示：

$$V(s_t)\leftarrow V(s_t)+\alpha\left[r_{t+1}+\gamma V(s_{t+1})-V(s_t)\right] \tag{2.8}$$

式(2.8)中，参数 α 表示学习率，参数 γ 表示奖励折扣率。数学上可以证明经过多次迭代，时序差分方法的价值函数可以收敛到真实值[82]。如果将时序差分的单步采样过程一直进行直到一个回合结束，时序差分方法就变成了蒙特卡洛方法。如果将单步采样过程进行介于单步和结束之间的 N 步，就得到了 TD(N)算法，并且时序差分作为一种特例可以被称为 TD(0)。

基于时序差分方法的值函数估计算法包括 Q 学习和 SARSA 算法，两种算法的区别在于 Q 学习属于离轨策略而 SARSA 属于在轨策略。2013 年出现的深度强化学习算法 DQN 同样使用时序差分的方法更新值函数。因此，时序差分方法是强化学习中最重要的一种方法。

Q 学习和 SARSA 算法均是使用动作价值函数也就是 Q 值来贪心的选择离散动作进行输出。两种算法的本质是估计任务可能出现的所有状态对应的 Q 值，并将它们保存在 Q 表里边，其求解过程就是不断根据时序差分方法迭代更新出现状态的 Q 值。算法开始时 Q 值是不准确的，随着时序差分方法对 Q 值更新的进行，Q 表中各个状态对应的 Q 值将逐渐收敛到真实值。显然，此时如果按照贪心策略根据智能体当前的状态选择 Q 表中对应 Q 值最大的动作执行就可以达到最优策略。

Q 学习更新 Q 值的时序差分公式如下：

$$Q(s_{step},a_{step})'=Q(s_{step},a_{step})+\sigma\left[r_{step+1}+\gamma\max_a Q(s_{step+1},a)-Q(s_{step},a_{step})\right] \tag{2.9}$$

SARSA 算法更新 Q 值的时序差分公式如下：

$$Q(s_{step},a_{step})'=Q(s_{step},a_{step})+\sigma\left[r_{step+1}+\gamma Q(s_{step+1},a_{step+1})-Q(s_{step},a_{step})\right] \tag{2.10}$$

中国知网 https://www.cnki.net

式(2.9)和(2.10)中的 σ 为学习率，γ 为奖励的折扣系数。从 Q 学习和 SARSA 算法时序差分更新 Q 值的公式上可以看出二者的区别。Q 学习属于离轨策略方法，也就是智能体与环境交互进行采样时所采取的策略与式(2.9)实际更新 Q 值时所采取的策略不同，实际更新时使用的是贪心策略。SARSA 算法属于在轨策略，也就是智能体与环境交互采样时所采取的策略与式(2.10)实际更新 Q 值时所采取的策略相同。由于二者的上述区别，Q 学习在学习过程当中所采取的动作更为“激进”和“大胆”，而 SARSA 算法则更为“稳健”和“保守”。Q 学习具体的算法过程如表 2.1 所示。

表 2.1 Q 学习与 SARSA 算法伪代码

Table 2.1 Q learning and SARSA algorithm pseudo code

Q learning 和 SARSA 算法
1：输入参数：学习率 $\sigma \in (0,1]$， $\varepsilon > 0$，对所有状态 s，动作 a 任意初始化 Q 表中的 $Q(s,a)$
2: for 回合=1:M do
3: 重置环境，初始化状态 s
4: while 状态 s 非终止状态 do
5: 使用 ε 贪心算法在 Q 表中的状态 s 中选择出动作 a
6: 智能体执行动作与环境交互执行动作 a，受到即时奖励 r，环境转移到状态 s'
7: if Q 学习
8: 执行公式(2.9)所示的时序差分更新
9: else
10: 执行公式(2.10)所示的时序差分更新
11: end if
12: 将新得到的状态 s' 赋值给 s
13: end while
14: end for

2.1.4 基于策略梯度(PG)的强化学习算法

基于策略梯度的强化学习算法不需要估计价值函数，而是直接根据状态输出动作。其算法原理如图 2.5 所示。

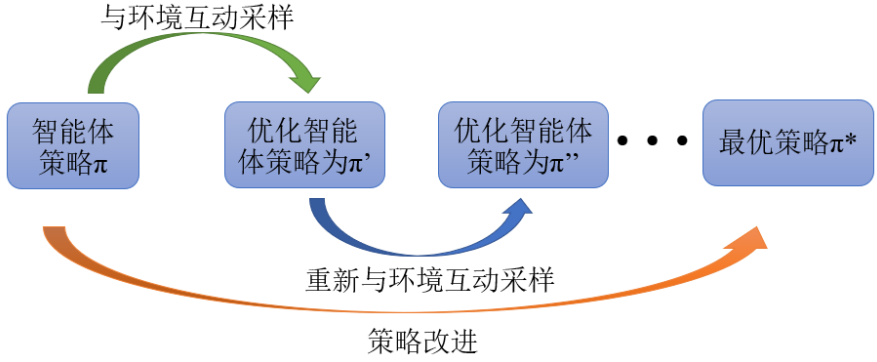


图 2.5 基于策略梯度的强化学习算法原理

Fig. 2.5 The principle of reinforcement learning algorithm based on policy gradient

中国知网 https://www.cnki.net

在策略梯度类型的强化学习算法中，首先智能体使用策略 π 与环境直接互动，进行采样，然后使用采样得到的经验序列对策略进行改进，再使用新的策略 π'继续采样。采样过程和策略的改进过程循环往复，直到算法收敛得到最优策略。基于价值函数的方法需要通过价值函数值的大小来贪心地选择动作，而策略梯度方法可以直接输出决策的动作，因此策略梯度可以输出连续的动作。

策略梯度方法的目标同样是最大化期望总收益。单个回合采样后的总收益为：

$$R_\lambda = \sum_{step=1}^{N} r_{step} \tag{2.11}$$

式(2.11)中，r_{step} 代表每一个时间步的即时收益，λ 表示此时智能体所采取的策略 $\pi_\lambda(s)$ 中的参数。期望总收益为：

$$\overline{R}_\lambda = \sum_{\alpha} R(\alpha) P(\alpha \mid \lambda) \approx \frac{1}{M} \sum_{m=1}^{M} R(\alpha^m) \tag{2.12}$$

式 (2.12) 中 α 表示智能体通过采样得到的马尔可夫过程序列 $\{s_1, a_1, r_1, s_2, a_2, r_2, \cdots, s_N, a_N, r_N\}$，$P(\alpha \mid \lambda)$ 表示在策略 $\pi_\lambda(s)$ 下采样序列 α 出现的概率。总收益的期望值又可以通过采样 M 次然后取每个序列总收益的平均值方法来近似得到。策略梯度方法的执行过程就变成了找出使得期望总收益最大的参数 λ^* 的过程:

$$\lambda^* = \arg\max_{\lambda} \overline{R}_\lambda \tag{2.13}$$

采用梯度上升的方式更新策略 $\pi_\lambda(s)$ 中的参数 λ 来使期望总收益最大化:

$$\lambda' = \lambda + \sigma \nabla \overline{R}_\lambda \tag{2.14}$$

参数 σ 表示学习率。

式(2.14)中:

$$\begin{aligned} \nabla \overline{R}_\lambda &= \sum_{\alpha} R(\alpha) \nabla P(\alpha \mid \lambda) \\ &= \sum_{\alpha} R(\alpha) P(\alpha \mid \lambda) \frac{\nabla P(\alpha \mid \lambda)}{P(\alpha \mid \lambda)} \\ &= \sum_{\alpha} R(\alpha) P(\alpha \mid \lambda) \nabla \log P(\alpha \mid \lambda) \\ &\approx \frac{1}{M} \sum_{m=1}^{M} R(\alpha^m) \nabla \log P(\alpha^m \mid \lambda) \end{aligned} \tag{2.15}$$

式(2.15)中:

$$P(\alpha \mid \lambda) = p(s_1) \prod_{step=1}^{N} p(a_{step} \mid s_{step}, \lambda) p(r_{step}, s_{step+1} \mid s_{step}, a_{step}) \tag{2.16}$$

中国知网 https://www.cnki.net

式(2.16)中的项 $p(s_1)$ 和 $p(r_{step}, s_{step+1} \mid s_{step}, a_{step})$ 是由环境决定的状态转移概率，它们与智能体的策略完全无关，因此对策略参数的梯度为 0。

$$\nabla \log P(\alpha^m \mid \lambda) = \sum_{step=1}^{N} \nabla \log p(a_{step} \mid s_{step}, \lambda) \tag{2.17}$$

最终 $\nabla \overline{R}(\lambda)$ 化简为:

$$\nabla \overline{R}_{\lambda} \approx \frac{1}{M} \sum_{m=1}^{M} \sum_{step=1}^{N} R(\alpha^m) \nabla \log p(a_{step}^m \mid s_{step}^m, \lambda) \tag{2.18}$$

2.1.5 价值函数与策略梯度结合的方法 Actor-Critic(AC)

将基于价值函数的方法与基于策略梯度的方法进行结合就得到了演员-评论家(Actor-Critic, AC)算法框架。目前主流的深度强化学习算法广泛使用了 AC 算法框架。如图 2.6 所示，顾名思义 AC 算法包含一个演员(Actor)模型和一个评论家(Critic)模型。

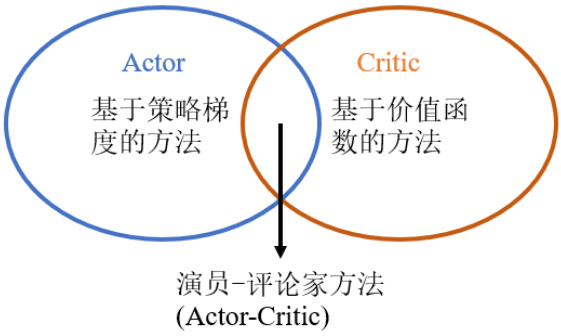


图 2.6 演员-评论家算法框架模型

Fig. 2.6 Actor-Critic algorithm framework model

Actor 模型是一个策略梯度模型，输入状态给模型后直接输出动作。Critic 模型是一个基于值的估计器专门负责估计状态价值函数的值。Actor 负责选择一个动作，而 Critic 通过准确的评估执行该动作的 Q 值来评价 Actor 选择出动作的优劣程度，这个优劣程度反过来作为一个状态-动作对的加权值参与到 Actor 的训练中。定性来讲，状态-动作对的加权值越大，则训练时 Actor 的参数向着增加当前状态-动作对概率发生的方向移动。加权值越小，则训练时 Actor 的参数向着减小当前状态-动作对概率发生的方向移动。单一的策略梯度方法用所评价的状态-动作对发生后的采样总收益 $R(\alpha^m)$ 作为训练 Actor 的权值(式 2.18)。

中国知网 https://www.cnki.net

2.2 适用于机械臂高维连续动作空间的强化学习算法

Q 学习、SARSA 和 DQN 等传统的强化学习算法只能够输出离散的动作而不能直接用于解决机械臂的连续动作控制问题。DQN-NAF 是一种在 DQN 的基础之上，修改神经网络输出结构从而可以输出连续动作的方法。基于策略梯度的强化学习方法也能够输出连续动作空间，其中最常用的就是近年来被提出的 PPO 和 DDPG 算法。针对将强化学习应用于机械臂的控制问题，近年来不同的学者分别尝试采用上述的 3 种算法来解决机械臂运动规划等控制问题[71, 73]。但是对于上述 3 种算法在解决机械臂控制问题时性能上有何具体区别，讨论还比较少。本章的后续部分针对无障碍物环境下的机械臂运动规划控制任务，采用 DQN-NAF、PPO 和 DDPG 3 种不同的深度强化学习算法进行控制尝试，然后比较了它们在不同类型任务当中的性能。

2.2.1 深度 Q 网络归一化优势函数算法(DQN-NAF)

（1）深度 Q 网络(DQN)算法

谷歌公司的 DeepMind 团队于 2013 年首次提出了深度 Q 网络(DQN)算法。该算法第一次将深度学习引入强化学习算法，成功地在 49 款雅达利 2600 电子游戏中取得了比人类高水平玩家高得多的分数。DQN 算法的核心原理与 Q 学习类似，它们都采用时序差分的方法估计各个状态的 Q 值。所不同的是，DQN 的输入是每一帧游戏图像，然后采用卷积神经网络自动地提取图像特征作为强化学习的输入状态 *S*。然后连接前馈神经网络，利用神经网络的非线性拟合能力去训练这个前馈网络拟合任意输入状态 *S* 所对应的 Q 值。这种方法相比于基于表格型的强化学习方法有了巨大的改进，最重要的优势在于表格型的方法一旦状态空间的数量过多就会出现“维度爆炸”问题。而 DQN 用前馈神经网络代替了传统的表格，仅仅用有限个数的神经元就可以拟合数量趋于无穷大的 Q 值表格。并且由于神经网络具有泛化能力，即使在估计 Q 值时出现了某个从未在训练中出现过的状态 *S*，也能由神经网络拟合出一个比较接近真实值的动作价值函数值。

图 2.7 所示为 DQN 的神经网络结构示意图。图像经过两个卷积层的卷积与池化操作，再连接到全连接层。每层由 ReLU 激活函数处理，最后一层输出的是一个包含了各个离散动作 Q 值的向量。

中国知网 https://www.cnki.net

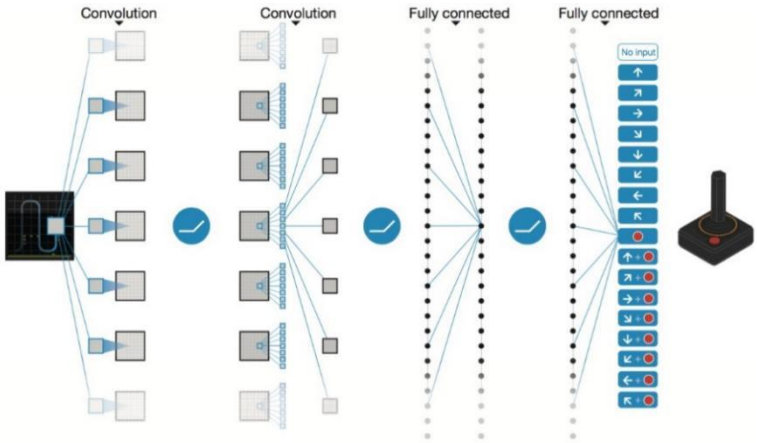


图 2.7 DQN 算法的神经网络结构示意图[57]

Fig. 2.7 The schematic diagram of neural network structure of DQN algorithm

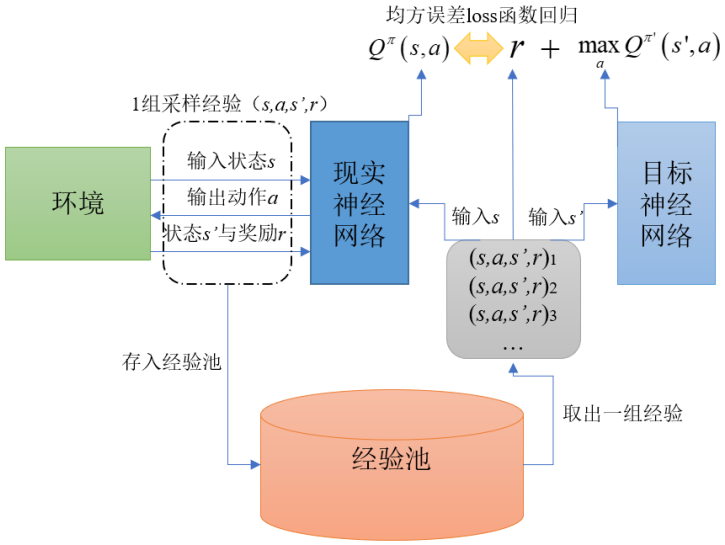


图 2.8 DQN 算法的训练过程

Fig. 2.8 The training process of DQN algorithm

DQN 算法的训练过程如图 2.8 所示。包含两个神经网络：现实神经网络和目标神经网络。现实神经网络是要进行训练的神经网络，目标神经网络用于辅助训练，最初目标神经与现实神经网络的参数完全相同，目标神经网络训练过程中参数保持不变，每次经过若干回合后将新的现实神经网络参数值完全复制给目标神经网络。现实神经网络与环境进行互动并获得 1 条经验(s,a,s',r)，然后将获得的经验存入经验池中，这里体现了 DQN 与 Q 学习相同的离轨策略属性。采用不同策略与环境互动所得到的经验可以在后续的训练过程中一直使用，直到经验池容量爆满再将最早的经验覆盖掉。经验池的设置有利于切断采样数据之间的相关性。训练时，

中国知网 https://www.cnki.net

每次从经验池中随机抽取一个组数量（50 个或者 100 个经验的小组）来进行训练，以小组为单位训练是因为神经网络可以通过并行运算加速，同时处理一个小组的数据可以加速训练。但是小组的大小要适当，其大小与训练平台的 GPU 显卡性能相关[83]。然后将现实神经网络估计出的 Q 值与目标神经网络估计的下一个状态的 Q 值加上本次即时奖励 r 的和求均方误差作为训练现实神经网络进行梯度下降的损失函数，对现实神经网络的参数进行训练。DQN 算法的流程如表 2.2 所示。

表 2.2 DQN 算法伪代码

Table 2.2 DQN algorithm pseudo code

DQN 算法
1: 初始化现实神经网络 Q^{π} 和目标神经网络 $Q^{\pi'}$， $Q^{\pi'}=Q^{\pi}$
2: for 回合=1:M do
3: 重置环境，初始化状态 s
4: while 状态 s 非终止状态 do
5: 输入状态 s 给现实神经网络 Q^{π}，按照 ε 贪心原则决策得到输出动作 a
6: 智能体执行动作 a 与环境交互，并且得到即时奖励 r，环境转移到状态 s'
7: 将 1 条采样经验 (s,a,s',r) 存入 DQN 算法的经验池中
8: if 经验池中的数据量大于一个训练小组的大小
9: 从经验池中采样一个训练小组 (s,a,s',r)
10: 目标函数 $y=r+\max_{a} Q^{\pi'}(s',a)$
11: 使用 y 与 $Q^{\pi}(s,a)$ 的均方误差 loss 函数回归方法来更新现实神经网络的参数
12: 每经过 C 个时间步，将现实神经网络的参数复制给目标神经网络 $Q^{\pi'}=Q^{\pi}$
13: end if
14: end while
15: end for

（2）能够输出连续动作的 DQN 算法—DQN-NAF

典型的 DQN 算法无法解决输出为连续动作空间的控制问题。但是可以将动作空间按照一定的分辨率进行离散化。对于机械臂控制而言，就是将机械臂各个关节角度进行离散化。可以将每个关节离散成：向前 1 步，向后 1 步和停止不动，这种离散方法对于自由度比较少的机械臂是一种可行的方法。例如 3 自由度机械臂离散化以后所对应的 DQN 动作空间输出为 3^3=27 个，如果再加入末端夹具的状态共计 28 个动作输出。而对于 6 自由度机械臂而言，DQN 的动作空间输出为 3^6=729 个，理论上可行，但是此时的网络不容易收敛。此外由于角度进行了离散，机械臂运动控制的精度下降，且每次 DQN 算法都只输出某几个关节的一个小步运动，运动的效率非常低下，综合来看运算量很大。

在无障碍物环境空间中，对一个 3 自由度机械臂采用角度离散的 DQN 方式进

中国知网 https://www.cnki.net

行了测试，如图 2.9 所示，角度分辨率为 0.5 度，经过一段时间训练后，3 自由度机械臂也能顺利运动到前方圆柱体目标物体位置。

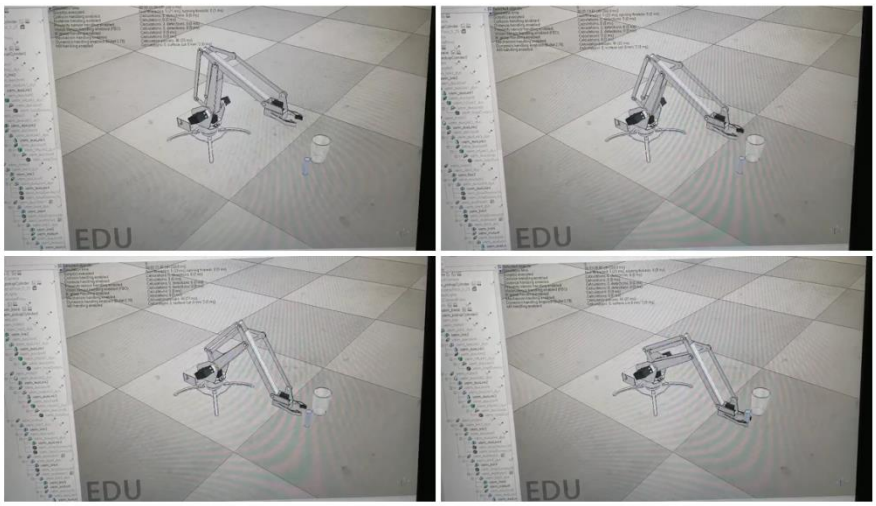


图 2.9 3 自由度机械臂采用角度离散的 DQN 算法抓取圆柱体

Fig. 2.9 DQN algorithm with discrete angles is used to train the 3-DOF robotic arm to grasp the cylinder

综上所述，如果想在 DQN 方法的大框架下实现输出连续动作，必须能够找到一种方法，向神经网络输入一个状态后，神经网络能够直接输出 Q 值最大的动作。针对这一问题，2016 年剑桥大学学者顾世翔与谷歌公司 DeepMind 团队共同提出了深度 Q 网络归一化优势函数(DQN-NAF)算法。该算法能够同时输出 Q 值和能够使得 Q 值最大的连续动作值。

DQN-NAF 首先定义 Q 值为：

$$Q(s,a)=V(s)+A(s,a) \tag{2.19}$$

式(2.19)中$V(s)$表示状态 s 所对应的状态价值函数值，它只与所处状态有关。$A(s,a)$表示动作 a 相对于其他动作在状态 s 下的优势。即不同的动作在同一个状态 s 下的优势函数$A(s,a)$越大，它的 Q 值也就越大，问题就转换成了求解在状态 s 下最大的优势函数$A(s,a)$所对应动作的问题。构建优势函数$A(s,a)\le 0$，定义$A(s,a)$为一个负值的二次正定矩阵：

$$A(s,a)=-\frac{1}{2}\left(a-\varphi(s)\right)^{T} M(s)\left(a-\varphi(s)\right) \tag{2.20}$$

式(2.20)中，需要$M(s)$是一个关于状态 s 的正定矩阵，为了满足这一条件，对该矩阵进行 Cholesky 分解[84]:

$$M(s)=I(s)I(s)^{T} \tag{2.21}$$

中国知网 https://www.cnki.net

根据 Cholesky 分解的性质，只要下三角矩阵$I(s)$为对角线正值矩阵，所构造得到的矩阵$M(s)$就一定是一个正定矩阵。因此只要可以构造出$I(s)$形式的矩阵，就可以得到$M(s)$进而得到优势函数$A(s,a)$。而当动作$a=\varphi(s)$时，优势函数$A(s,a)=0$得到最大值，此时$Q_{\max}(s,a)=V(s)$。

DQN-NAF 的算法原理如图 2.10 所示。与 DQN 类似，它也有现实神经网络和目标神经网络两个网络，与 DQN 不同的是，它的网络输出是下三角矩阵$I(s)$、动作向量$\varphi(s)$以及估计得到的状态价值函数$V(s)$三个输出。在训练时，同样利用时序差分的方法，将现实神经网络估计得到的$Q(s,a)=V(s)+A(s,a)$与目标神经网络估计得到的下一次最大的 Q 值即$V(s)$与即时奖励 r 和的均方差作为 loss 函数。与 DQN 类似，它也包含一个用于存储与环境交互得到采样数据的经验池。

训练结束以后，现实神经网络输出的$a=\varphi(s)$就是智能体策略所选择的行为。在 DQN 当中，为了保证智能体行为中存在足够的探索，需要按照一定的概率不选择最大 Q 值所对应的动作。而 DQN-NAF 算法直接输入智能体状态，输出的是对应 Q 值最大的动作，同样为了保证探索，必须在所选择的动作中加入一定的随机噪声信号χ来增加智能体的探索行为，如式(2.22)所示。

$$a=\varphi(s)+\chi \tag{2.22}$$

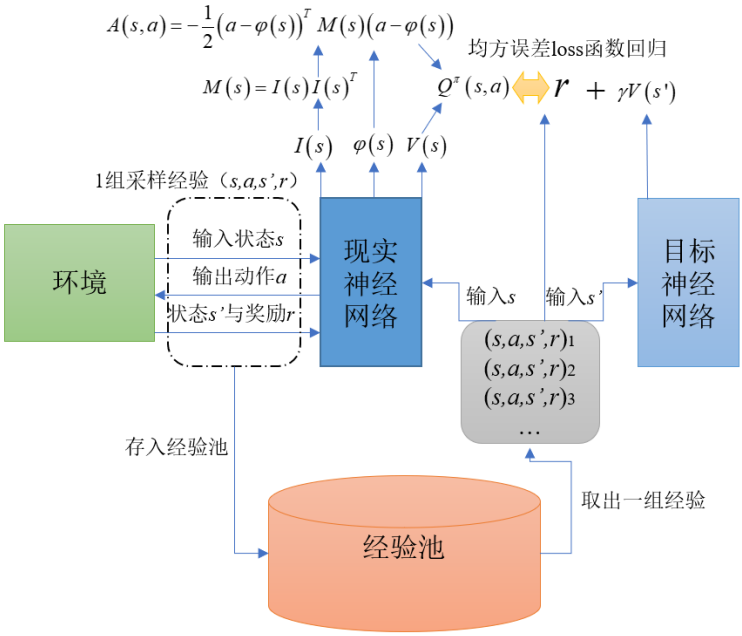


图 2.10 DQN-NAF 算法的原理

Fig. 2.10 The principle of DQN-NAF algorithm

中国知网 https://www.cnki.net

表 2.3 DQN-NAF 算法伪代码

Table 2.3 DQN-NAF algorithm pseudo code

DQN-NAF 算法
1: 初始化现实神经网络Q^{π}和目标神经网络$Q^{\pi'}$，$Q^{\pi'}=Q^{\pi}$
2: for 回合=1:M do
3: 初始化动作探索的噪声χ
4: while 状态 *s* 非终止状态 do
5: 输入状态 *s* 给现实神经网络Q^{π}，选取动作$a=\varphi(s)+\chi$
6: 智能体执行动作 *a*，并且得到即时奖励 *r*，环境转移到状态 *s'*
7: 将采样经验(s,a,s',r)存入经验池中
8: if 经验池中的数据量大于一个训练小组的大小
9: 从经验池中采样一个训练小组(s,a,s',r)
10: 将状态 *s* 和 *a* 输入现实神经网络Q^{π}，得到对角线为正值的下三角矩阵$I(s)$，动作向量$\varphi(s)$，状态价值函数$V(s)$，然后得到$M(s)=I(s)I(s)^{T}$，$A(s,a)=-\frac{1}{2}(a-\varphi(s))^{T}M(s)(a-\varphi(s))$，$Q^{\pi}(s,a)=V(s)+A(s,a)$
11: 输入状态 *s'*给目标网络$Q^{\pi'}$得到状态价值函数$V(s')$，目标函数 $y=r+\gamma V(s')$
12: 使用y与$Q^{\pi}(s,a)$的均方误差 loss 函数回归方法来更新现实神经网络的参数
13: 逐步软更新现实网络参数到目标网络中，σ 是远小于 1 的正数: $Q^{\pi'}\leftarrow\sigma Q^{\pi}+(1-\sigma)Q^{\pi'}$
14: end if
15: end while
16: end for

2.2.2 深度确定性策略梯度算法(DDPG)

深度确定性策略梯度(Deep Deterministic Policy Gradient)算法是谷歌 DeepMind 团队于 2016 年提出的一种深度强化学习算法。该方法是一种基于 Actor-Critic 算法框架并且将 DQN 算法的思想与确定性策略梯度(Deterministic Policy Gradient, DPG)方法相结合提出的一种用于解决连续动作空间问题的方法。从策略梯度类型的强化学习算法演化上来看，最初的策略梯度(PG)方法发展到确定性策略梯度(DPG)方法，最后再发展到深度确定性策略梯度(DDPG)方法。

（1）确定性策略梯度(DPG)

DPG 方法是相对于最先被提出的策略梯度(PG)方法而言的。PG 方法是一种随机策略梯度方法，具体而言就是对于一个固定的输入状态 *s*，同一个策略输出的动作为一个满足高斯分布的概率分布。也就是说，即使输入给智能体的状态是相同的，输出的动作仍然是随机的。

中国知网 https://www.cnki.net

对于随机策略梯度，其目标函数对于参数的梯度为：

$$\nabla \bar{R}_\lambda = \mathrm{E}_{s\sim\rho^\pi, a\sim\pi_\lambda}\left[R^\lambda(s,a)\nabla \log p(a|s)\right] = \mathrm{E}_{s\sim\rho^\pi, a\sim\pi_\lambda}\left[Q^\lambda(s,a)\nabla \log p(a|s)\right] \quad (2.23)$$

式(2.23)表明，随机策略梯度的公式是关于状态 s 和动作 a 的期望，为了求解该期望值，需要对状态空间和动作空间都进行广泛地采样，对于机械臂这种动作空间维度较高的任务而言，随机策略梯度方法的采样效率会很低下。

相比于随机策略梯度，确定性策略梯度 DPG 对于一个确定的状态 s，仅输出一个确定性的动作 a。其梯度公式为：

$$\nabla \bar{R}_\lambda = \mathrm{E}_{s\sim\rho^\lambda}\left[\nabla \mu_\lambda(s)\nabla Q^\lambda(s,a)|_{a=\mu_\lambda(s)}\right] \quad (2.24)$$

DPG 不需要采样动作空间，因此它比随机策略梯度在训练时所需要的样本数量小很多。尤其适用于机械臂控制这种关节动作空间维度较大的任务类型，其算法效率比随机策略梯度高很多。但是由于 DPG 对于状态输出唯一的动作，如果在训练时一直这样输出，智能体就不会进行必要的“探索”，自然也就不会进步。因此必须要在训练时给动作加入一些“噪音”。

（2）深度确定性策略梯度（DDPG）

深度确定性策略梯度 DDPG 算法按照 Actor-Critic 的框架设计了两个模型，参照 DQN 的思想，每个模型都包括现实网络和目标网络两个网络，因此实际上 DDPG 有 4 个神经网络。Actor 部分负责根据输入状态生成确定动作，然后 Critic 部分负责评估 Actor 部分生成动作的 Q 值，Actor 部分和 Critic 部分相互配合。经过训练后，Critic 部分的神经网络收敛到能够准确估计 Q 值，而 Actor 部分的神经网络则能够准确输出 Q 值最大的动作。

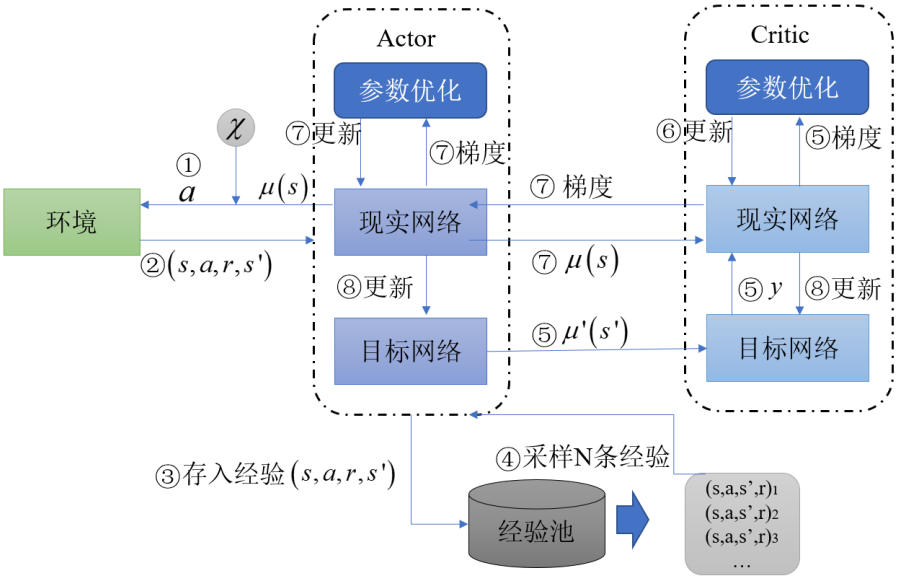


图 2.11 DDPG 算法的原理

Fig. 2.11 The principle of DDPG algorithm

中国知网 https://www.cnki.net

图 2.11 所示为 DDPG 算法的原理图。图中序号表示算法的执行过程。其中，s 表示一条采样经验中的当前状态，a 表示动作，r 表示本次的即时收益，s' 表示下一个状态，μ 表示 Actor 部分的现实网络，μ' 表示 Actor 部分的目标网络，Q 表示 Critic 部分的现实网络，Q' 表示 Critic 部分的目标网络。

①Actor 模型部分的现实网络负责接受输入的状态 s 并输出一个确定的动作 a，为了增加“探索”，使智能体能够尝试一些没有进行过但有可能估值更高的动作，将高斯分布“噪音”α 信号加入到输出的动作中。

②智能体执行动作，环境反馈即时收益 r，以及下一个状态 s'。

③将本次采样经验 (s,a,r,s') 存储到经验库中。

④从经验库中采样一个小组的数据。

⑤将状态 s' 输入给 Actor 模型的目标网络，目标网络输出一个动作 $\mu'(s')$，然后这个值被送给 Critic 模型部分的目标网络，目标网络使用输入的下一个状态 s'，以及从 Actor 部分选择出的动作 $\mu'(s')$ 估计得到 $y=r+\gamma Q'(s',\mu'(s'))$。

⑥将 Critic 模型部分的现实网络估计出的当前状态值 $Q(s,a)$ 与 $y=r+\gamma Q'(s',\mu'(s'))$ 的均方误差作为 loss 函数，训练 Critic 模型部分的现实网络使得 loss 函数最小，并更新其网络参数。

⑦将状态 s 传入 Actor 模型部分的现实网络得到动作 $\mu(s)$，然后输入给 Critic 模型部分的现实网络，得到 $Q(s,\mu(s))$，将 $-\frac{1}{N}\sum_i Q(s_i,\mu(s_i))$ 作为 loss 函数，训练 Actor 模型部分的现实网络，让 loss 函数最小，并更新其网络参数。此处 $-\frac{1}{N}\sum_i Q(s_i,\mu(s_i))$ 最小，也就是 $\frac{1}{N}\sum_i Q(s_i,\mu(s_i))$ 最大。进行梯度反向更新，让 Actor 模型部分的现实网络 $\mu(s)$ 部分向着让 $\frac{1}{N}\sum_i Q(s_i,\mu(s_i))$ 变大的方向更新参数。

⑧逐步更新 Actor 模型部分和 Critic 模型部分的现实网络参数到目标网络中。

DDPG 算法的伪代码如表 2.4 所示。

中国知网 https://www.cnki.net

表 2.4 DDPG 算法伪代码

Table 2.4 DDPG algorithm pseudo code

DDPG 算法

初始化 Critic 部分的现实神经网络 Q 和 Actor 部分的现实神经网络 μ，参数分别是 λ^{Q} 和 λ^{μ}

初始化 Critic 部分和 Actor 部分的目标神经网络 Q' 和 μ'，参数 $\lambda^{Q'}=\lambda^{Q},\lambda^{\mu'}=\lambda^{\mu}$

for 回合=1:M do

  初始化动作探索的噪声 χ,状态 s

  while 状态 s 非终止状态 do

    输入状态 s 给 Actor 部分的现实神经网络 μ，选取动作并增加噪声 $a=\mu(s)+\chi$

    智能体执行动作与环境交互执行动作 a，并且受到即时奖励 r，环境转移到状态 s'

    将采样经验 (s,a,s',r) 存入经验池中

    if 经验池中的数据量大于一个训练小组的大小

      从经验池中采样一个训练小组 (s,a,s',r)

      目标函数 $y=r+\gamma Q'(s',\mu'(s'))$ 使用 y 与 $Q(s,a)$ 的均方误差 loss 函数回归方法来更新 Critic 部分的现实神经网络的参数

      通过策略梯度公式来更新 Actor 部分的目标神经网络参数：

$$\nabla J=\frac{1}{N}\sum_{i}\nabla\mu(s_i)\nabla Q(s_i,a)|_{a=\mu(s_i)}$$

      更新 Actor 模型部分和 Critic 模型部分的现实网络参数到目标网络中，σ 是远小于 1 的正数：

$$\lambda^{Q'}\leftarrow\sigma\lambda^{Q}+(1-\sigma)\lambda^{Q'}$$

$$\lambda^{\mu'}\leftarrow\sigma\lambda^{\mu}+(1-\sigma)\lambda^{\mu'}$$

    end if

  end while

end for

2.2.3 近端策略优化算法(PPO)

近端策略优化(Proximal Policy Optimization, PPO)算法是由策略梯度 PG 算法发展而来的算法。它主要解决了 PG 算法采样效率低且对超参数敏感不容易收敛的问题。传统的 PG 方法是一种在轨策略(On-Policy)，如图 2.5 和式(2.18)所示，智能体首先使用策略 π 与环境互动采样，然后使用采样得到的序列对策略进行改进提升。由于采样序列 α 是从一个由策略 π 决定的概率分布中采样得到的，当得到新的策略 π' 时，需要重新从新的策略 π' 所决定的概率分布中采样新的序列，而之前用策略 π 采样所得到的序列则全部丢弃无法继续使用。用新策略重新与环境互动进行采样，重复上述的训练过程。上述 PG 算法的采样利用效率很低，训练过程很费时间。

中国知网 https://www.cnki.net

$$\nabla \overline{R}_{\lambda} = \mathrm{E}_{\alpha \sim P_{\lambda}(\alpha)}[R(\alpha)\nabla \log P(\alpha)] \tag{2.25}$$

PPO 算法就是为了解决 PG 算法的上述问题而出现的，它的前身是信任域策略优化(Trust Region Policy Optimization，TRPO)算法。为了解决采样效率低和 PG 对超参数敏感不容易收敛的问题，TRPO 算法中引入重要性采样原理，并通过限制散度约束条件来限制新旧策略之间的差别程度。但是 TRPO 算法单独把约束条件列出，这种做法不利于实际的操作。PPO 算法对 TRPO 的 KL 散度约束进行了更有益于实际实施的改进。

（1）重要性采样原理

若有两个概率分布$m(x)$和$n(x)$，自变量x从概率分布$m(x)$中采样得到，则关于x的函数$p(x)$的期望值为：

$$\mathrm{E}_{x\sim m}\left[p(x)\right] \approx \frac{1}{N}\sum_{i=1}^{N} p(x_i) \tag{2.26}$$

式(2.26)表示可以通过多次采样取平均值的方式估计一个函数的近似期望值。如果自变量x无法从概率分布$m(x)$中采样，而只能从另一个概率分布$n(x)$当中进行采样。则有：

$$\mathrm{E}_{x\sim m}\left[p(x)\right] = \int p(x)m(x)dx = \int p(x)\frac{m(x)}{n(x)}n(x)dx = \mathrm{E}_{x\sim n}\left[p(x)\frac{m(x)}{n(x)}\right] \tag{2.27}$$

式(2.27)说明如果求一个函数$p(x)$的期望，自变量x本来应该从概率分布$m(x)$中采样，但如果转而从另一个概率分布$n(x)$中进行采样，那么原函数期望的表达式需要增加一项权值，也就是两个概率分布的商$\frac{m(x)}{n(x)}$，这样从$n(x)$采样后计算得到的函数期望值与原来采样$m(x)$所得到函数$p(x)$的期望值相等。

它们的期望值相等，再考虑方差：

$$Var_{x\sim m}\left[p(x)\right] = \mathrm{E}_{x\sim m}\left[\left(p(x)\right)^2\right] - \left(\mathrm{E}_{x\sim m}\left[p(x)\right]\right)^2 \tag{2.28}$$

$$\begin{aligned} Var_{x\sim n}\left[p(x)\frac{m(x)}{n(x)}\right] &= \mathrm{E}_{x\sim n}\left[\left(p(x)\frac{m(x)}{n(x)}\right)^2\right] - \left(\mathrm{E}_{x\sim n}\left[p(x)\frac{m(x)}{n(x)}\right]\right)^2 \\ &= \mathrm{E}_{x\sim m}\left[\left(p(x)\right)^2\frac{m(x)}{n(x)}\right] - \left(\mathrm{E}_{x\sim m}\left[p(x)\right]\right)^2 \end{aligned} \tag{2.29}$$

比较式(2.28)和式(2.29)，显然它们的方差并不相等。$m(x)$和$n(x)$两个概率分

中国知网 https://www.cnki.net

布越不相同，通过采样所得到的函数 $p(x)$ 和 $p(x)\frac{m(x)}{n(x)}$ 的方差差距也就越大。受到这种方差关系的影响，如图 2.12 所示，如果 $m(x)$ 和 $n(x)$ 两个概率分布差距过大，通过采样来估计出的函数 $p(x)$ 的值就会不准确。在图 2.12 中，如果采样次数较少，通过在概率分布 $m(x)$ 采样估计得到的函数 $p(x)$ 值显然是一个正值，但是通过在概率分布 $n(x)$ 中采样估计得到的函数 $p(x)\frac{m(x)}{n(x)}$ 值显然是一个负值，此时显然无法用 $p(x)\frac{m(x)}{n(x)}$ 来近似 $p(x)$ 的值，除非采样次数非常多，这两个函数的期望值最终仍然会相等，但是过多的采样使得效率变低。

综上所述，如果希望能够得到 $\mathrm{E}_{x\sim m}\left[p(x)\right]=\mathrm{E}_{x\sim n}\left[p(x)\frac{m(x)}{n(x)}\right]$ 的结果，必须要保证两个函数 $m(x)$ 和 $n(x)$ 的概率分布相差不大。PPO 算法应用了该原理。

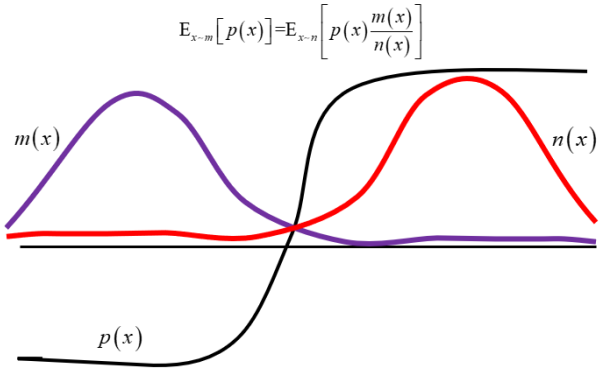


图 2.12 期望相等的两个函数相差很大的方差

Fig. 2.12 The variance of two functions which are expected to be equal is very different

（2）近端策略优化(PPO)算法

将重要性采样原理应用于策略梯度 PG 的梯度公式当中得到：

$$\nabla\bar{R}_{\lambda}=\mathrm{E}_{\alpha\sim P_{\lambda}(\alpha)}[R(\alpha)\nabla\log P(\alpha)]=\mathrm{E}_{\alpha\sim P_{\lambda'}(\alpha)}[\frac{P_{\lambda}(\alpha)}{P_{\lambda'}(\alpha)}R(\alpha)\nabla\log P(\alpha)] \quad (2.30)$$

式(2.30)将本来从概率分布 $P_{\lambda}(\alpha)$ 中采样序列改为从概率分布 $P_{\lambda'}(\alpha)$ 中采样序列，在保证期望值不变的前提下，增加了两个概率分布的商 $\frac{P_{\lambda}(\alpha)}{P_{\lambda'}(\alpha)}$ 作为权值。此时 PG 方法从原来的在轨策略变为局部的离轨策略，但是必须要满足采样的策略和训练的策略相差不能太大的条件，否则就会出现方差过大而导致采样估计的误差很

中国知网 https://www.cnki.net

大的问题。

序列 α 为采样得到的马尔可夫过程序列 $\{s_1,a_1,r_1,s_2,a_2,r_2,\cdots,s_N,a_N,r_N\}$，式(2.30)可以进一步写为：

$$\begin{aligned}\nabla\overline{R}_\lambda &= \mathrm{E}_{\left(s_{step},a_{step}\right)\sim\lambda}[R^\lambda\left(s_{step},a_{step}\right)\nabla\log p\left(a_{step}\mid s_{step}\right)]\\ &= \mathrm{E}_{\left(s_{step},a_{step}\right)\sim\lambda'}[\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)}R^{\lambda'}\left(s_{step},a_{step}\right)\nabla\log P\left(a_{step}\mid s_{step}\right)]\end{aligned} \tag{2.31}$$

此时需要最大化的目标函数为：

$$\overline{R}_\lambda = \mathrm{E}_{\left(s_{step},a_{step}\right)\sim\lambda'}[\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)}R^{\lambda'}\left(s_{step},a_{step}\right)]\approx\sum_{\left(s_{step},a_{step}\right)}\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)}R^{\lambda'}\left(s_{step},a_{step}\right) \tag{2.32}$$

式(2.32)需要满足的条件是两个概率分布 $P_\lambda(\alpha)$ 和 $P_{\lambda'}(\alpha)$ 不能相差过远，在具体做法上，TRPO 算法设置了一个约束两个策略相差程度的 Kullback-Leibler(KL)散度[85]约束条件：

$$KL\left(\lambda,\lambda'\right)<\varepsilon \tag{2.32}$$

在满足 KL 散度约束的情况下，找到使目标函数最大化的参数。

TRPO 算法把散度约束条件放置在目标函数的公式之外单独列出，对于实际训练而言，比较难操作。PPO 算法针对这一训练难点进行了进一步的改进，直接将梯度上升的目标函数修改为：

$$M\left(\lambda\right)=\overline{R}_\lambda-\sigma KL\left(\lambda,\lambda'\right) \tag{2.33}$$

在散度前加入一个系数 σ，整体最大化目标函数 $M\left(\lambda\right)$。并且动态调整系数 σ，设散度 KL 的最大值和最小值范围：$KL_{\max}$ 和 $KL_{\min}$。如果通过梯度上升最大化目标函数 $M\left(\lambda\right)$ 后，$KL\left(\lambda,\lambda'\right)>KL_{\max}$，那么需要增大系数 σ。如果通过梯度上升最大化目标函数 $M\left(\lambda\right)$ 后，$KL\left(\lambda,\lambda'\right)<KL_{\min}$，那么需要减小系数 σ。

PPO 算法存在另一种变化形式 PPO2，其目标函数变为：

$$\begin{aligned}&\overline{R}_\lambda\\ &= \mathrm{E}_{\left(s_{step},a_{step}\right)\sim\lambda'}[\min\left(\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)}R^{\lambda'}\left(s_{step},a_{step}\right),clip\left(\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)},1-\sigma,1+\sigma\right)R^{\lambda'}\left(s_{step},a_{step}\right)\right)]\\ &\approx\sum_{\left(s_{step},a_{step}\right)}\min\left(\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)}R^{\lambda'}\left(s_{step},a_{step}\right),clip\left(\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)},1-\sigma,1+\sigma\right)R^{\lambda'}\left(s_{step},a_{step}\right)\right)\end{aligned} \tag{2.34}$$

中国知网 https://www.cnki.net

clip 函数对两个策略概率分布的差异程度 $\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)}$ 进行了裁剪限制，如果差异超过区间 $(1-\sigma,1+\sigma)$ 则截取这个区间之内的值。差异程度 $\frac{P_\lambda\left(a_{step}\mid s_{step}\right)}{P_{\lambda'}\left(a_{step}\mid s_{step}\right)}$ 的图像如图 2.13 所示。

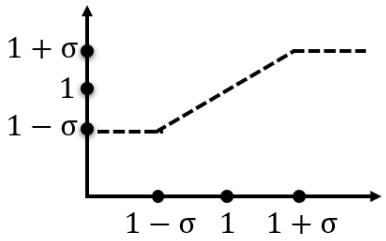


图 2.13 PPO2 算法对散度的约束

Fig. 2.13 Constraint of ppo2 algorithm on divergence

目标函数的图像按照 $R^{\lambda'}\left(s_{step},a_{step}\right)$ 的正负分为两种：

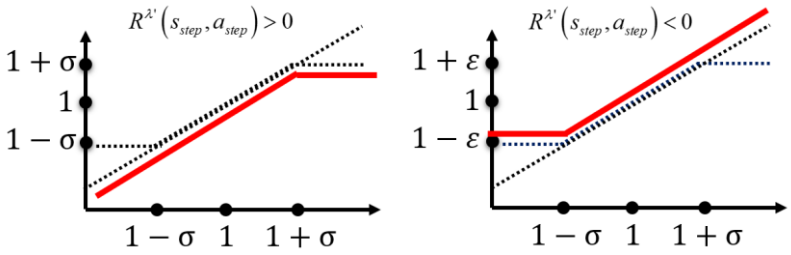


图 2.14 PPO2 算法对目标函数的约束

Fig. 2.14 Constraint of ppo2 algorithm on objective function

PPO2 算法可以保证在通过梯度上升最大化目标函数 $\overline{R}_\lambda$ 的过程中，限制策略 λ 和 λ' 的差异程度不过大，如果差异过大，则目标函数值被限制不再继续增大。

（2）PPO 算法的 Actor-Critic 架构

PPO 算法目标函数中的 $R^{\lambda'}\left(s_{step},a_{step}\right)$ 项表示对于一个序列，在状态 s_{step} 执行动作 a_{step} 之后所获得的总收益，它用来衡量在特定状态下智能体选择执行动作 a_{step} 后的优劣程度，实际上可以将这一项替换为优势函数，优势函数表示在状态 s_{step} 下执行特定动作相对于其他动作的优势大小。并且根据折扣奖励有：

$$\begin{aligned} R^{\lambda'}\left(s_{step},a_{step}\right) &= A^{\lambda'}\left(s_{step},a_{step}\right) \\ &= \sum_{step'>step}\gamma^{step'-step}\mathrm{r}_{step'}-V\left(s_{step}\right) \end{aligned} \tag{2.35}$$

$\sum_{step'>step}\gamma^{step'-step}\mathrm{r}_{step'}$ 项表示从当前时间步之后所有的奖励在考虑折扣率情况

中国知网 https://www.cnki.net

下的加和。PPO 算法中的 Critic 部分神经网络负责估计当前状态的状态价值函数值$V\left(s_{step}\right)$。Actor 部分的神经网络负责根据输入状态输出动作的概率分布。对于连续动作的概率分布，认为它是高斯分布，因此神经网络的输出估计值实际上是高斯分布所对应的平均值和方差。

PPO 算法的原理如图 2.15 所示。

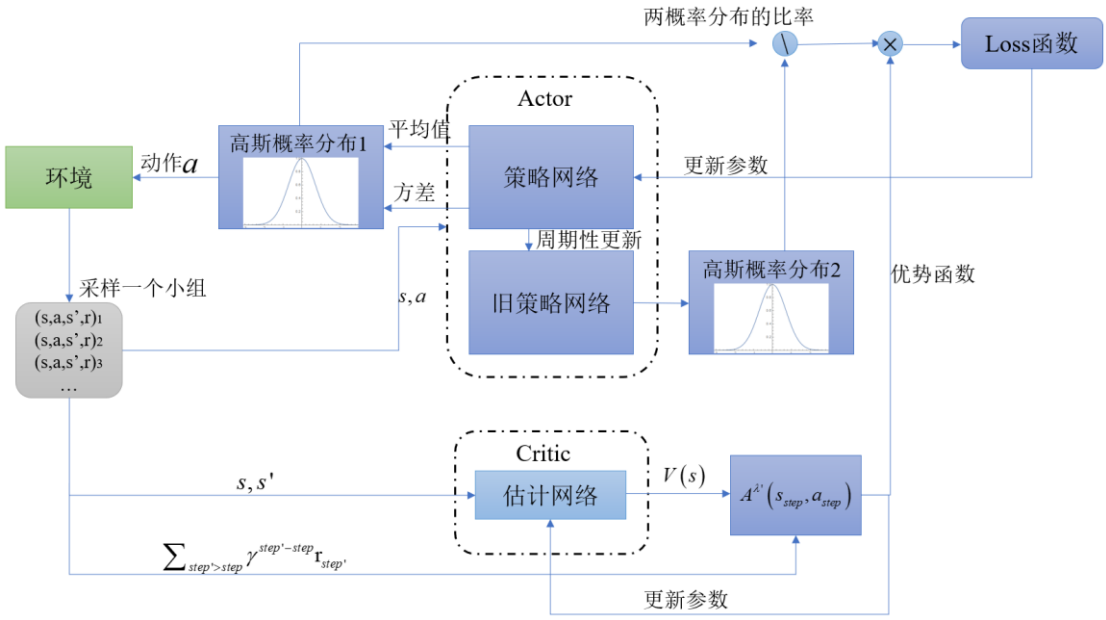


图 2.15 PPO 算法的原理

Fig. 2.15 The principle of PPO algorithm

2.3 仿真实验环境

强化学习是解决机器人领域传统人工设计算法难以解决的复杂控制问题的一种很好的方法。但是将强化学习应用于机器人控制面临着的一个难点就是算法的训练问题。任何一种强化学习算法都是通过智能体与环境的不断交互并且试错来进行采样学习的，这种交互试错并且采样学习的过程就是强化学习的训练过程，对于强化学习方法而言，这是最重要的一个过程。但是这种训练过程却很难直接在真实机器人上实现。主要的原因在于，强化学习智能体需要经过成千上万次的训练，在实际当中很难对一个真实的机器人进行如此多次数的重复训练，这需要花费很长的时间，并且需要承受不断试错的过程给机器人带来的损伤，其成本是很大的。

由于强化学习的固有特点，使用仿真环境来对机器人进行强化学习训练已经被广泛应用。将所提出的强化学习算法框架放在虚拟仿真环境下进行训练与验证的设想，最早由强化学习理论创立者之一的 Sutton 于 1991 年提出，他提出了一种 Dyna 框架，构建一个虚拟现实(Simulated Reality)架构用于算法验证[86]。根据真实

中国知网 https://www.cnki.net

环境在虚拟环境中创建模型，然后在仿真环境下对机器人完成一系列的训练，再将已经训练好的强化学习智能体迁移到真实机器人，最终实现控制。

2.3.1 V-REP 机器人仿真平台

能够应用于深度强化学习算法机器人训练的虚拟仿真平台包括 Bullet、MuJoCo[87]、Gazebo[88]和 V-REP[89]等。本文采用的是 V-REP 平台来进行机械臂的仿真训练。V-REP（软件最新版本改名为 CoppeliaSim）是一款功能十分强大的机器人虚拟仿真平台。它内置了 4 种不同的动力学物理引擎，可以在动力学环境下对机器人进行实验仿真。V-REP 提供了与机器人操作系统 ROS(Robot Operation System)的通信接口，与数值计算软件 Matlab 或者 Octave 也可以直接连通使用，同时提供 Python、Lua、C/C++编程语言的控制功能[90]。

通过外部的 API(Application Programming Interface)函数接口，V-REP 软件可以方便的完成外部算法对于虚拟机器人地控制。本文采用 Python 语言实现所述的深度强化学习算法，并且通过 V-REP 提供的 Python 函数接口实现算法与虚拟环境的交互[91]。

Python 语言广泛应用于数据分析和人工智能领域，最主要的原因就是它包括功能强大的各种软件包，尤其是广泛应用于深度学习神经网络框架搭建以及快速展开训练的 Python 工具：Pytorch[92]和 Tensorflow[93]。借助这样的软件工具可以很快速的搭建并且完成算法当中的神经网络计算部分。此外，Python 中常用的工具包还包括 Numpy[94]、Pandas[95]等数值计算工具包。使用 Python 来实现深度强化学习算法并且与 V-REP 软件通信实现联合仿真的过程如图 2.16 所示。

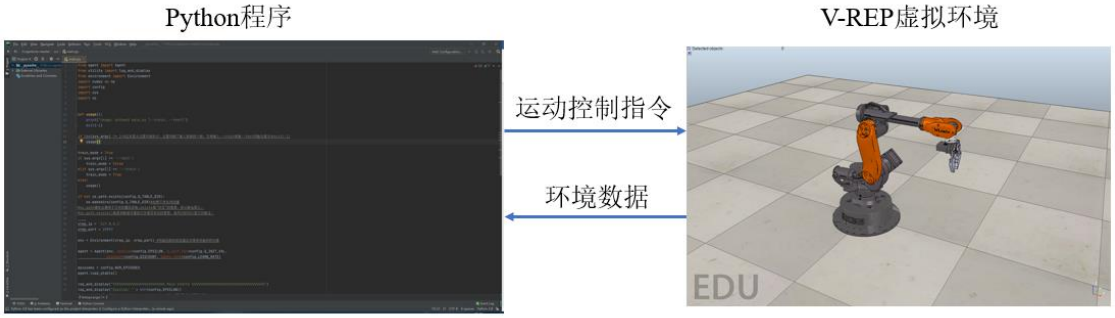


图 2.16 强化学习算法与 V-REP 软件通信实现联合仿真的过程

Fig. 2.16 The process of communication between reinforcement learning algorithm and V-REP software to realize simulation

V-REP 与外界的通信是通过网络协议实现的。外界的 Python 作为客户端，V-REP 软件作为服务器端，通过套接字模式来进行双向通信。客户端向服务器端发出请求，然后等待服务器端对请求进行处理并回复。一个典型的 V-REP 服务器端

中国知网 https://www.cnki.net

与客户端通信过程如图 2.17 所示。

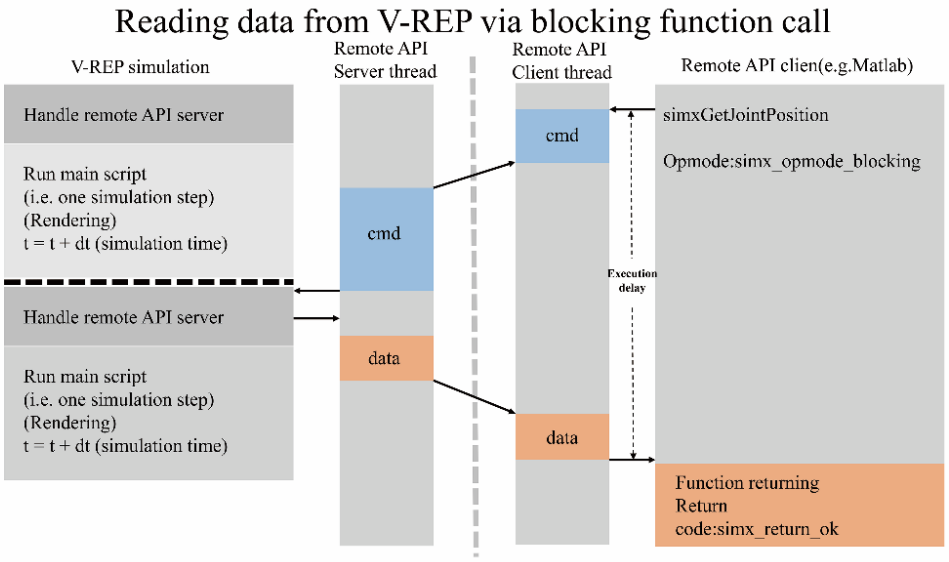


图 2.17 典型的 V-REP 服务器端与客户端通信过程

Fig. 2.17 Typical V-REP server and client communication process

V-REP 端通过 API 函数接口向客户端发送包括障碍物状态、关节状态、仿真中各种传感器信息等虚拟仿真环境信息。Python 控制的客户端则以同样的方式通过 API 函数接口向服务器端发送相应的机器人控制指令，这些指令包括设置机器人关节角度位置，设置关节运动速度，获取传感器数据等，并等待 V-REP 端返回成功或者异常的标志信号。

在 Python 端与 V-REP 联合仿真过程中，Python 端负责搭建并实现所测试的强化学习算法，V-REP 则负责提供类似于真实世界的机器人模型与物理交互环境。按照功能层级，Python 端的强化学习算法可以被划分为策略控制层与指令中继层两大部分。其中，策略控制层最为重要，这一层位于机器人控制的策略顶层，用于使用 Python 语言实现深度强化学习算法。在实现算法过程中，使用 Pytorch 和 Tensorflow 等构建深度神经网络的工具包，并且需要配合计算机显卡设备对进行的训练过程进行加速。Python 端的指令中继层则负责使用标准的 API 函数接口与 V-REP 环境进行交互，将高层算法得到的控制指令值经过封装发送给 V-REP，或者将 V-REP 发来的信息进行解析然后传递给高层算法进行下一步操作。完整的 Python 端策略控制层和指令中继层与 V-REP 交互过程如图 2.18 所示。

中国知网 https://www.cnki.net

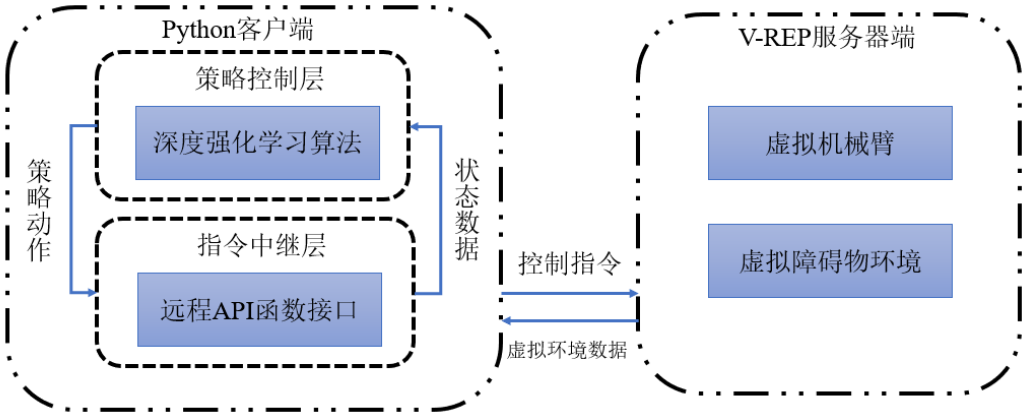


图 2.18 Python 端策略控制层与指令中继层以及 V-REP 交互过程

Fig. 2.18 Python-side policy control layer and instruction relay layer and V-REP interaction process

2.3.2 深度强化学习训练环境搭建

在 Python 与 V-REP 联合仿真的过程中，Python 的策略控制层需要实现相关的控制算法。其中神经网络的搭建需要借助于 Tensorflow 和 Pytorch 等工具软件包，这些神经网络工具包可以方便地构建神经网络，并且对网络当中成百上千的参数使用反向传播算法进行梯度下降操作。为了提高算法的运行速度，采用计算机的 GPU 显卡硬件来进行训练加速。本文的计算机仿真实验硬件系统 CPU 型号为 Intel 酷睿 i7-10700，运行频率为 3.8GHz，显卡型号为 RTX2080。搭建实验环境所用到的主要工具为：

（1）Ubuntu

Ubuntu 是一个开源的 Linux 操作系统发行版。Ubuntu 由于其开源特性而拥有庞大的用户社区。基本的机器学习软件包如 Tensorflow 等都较好地支持运行于 Ubuntu 上。尽管这些软件包目前也提供对 Windows 操作系统的支持，但是为了避免各种问题，在 Linux 系统上进行人工智能的开发工作仍然是目前的主流趋势。

（2）CUDA(Compute Unified Device Architecture)

CUDA 是显卡生产商英伟达官方推出的用于支持显卡并行运算架构的软件工具。如果需要使用英伟达显卡来进行机器学习相关运算，都必须采用英伟达的 CUDA 软件来进行辅助。

（3）Cudnn

Cudnn 是英伟达公司推出的用于深度神经网络加速的 GPU 加速库，通常与 CUDA 计算架构配合使用，实现对于神经网络运算的加速。

（4）Docker

Docker 是一个开源的虚拟机容器。它可以让开发者将应用以及该应用的依赖

中国知网 https://www.cnki.net

项打包成镜像，任意移植到其他机器上。

（5）Nvidia-Docker

由于 Docker 本身并不支持在镜像容器中调用英伟达 GPU 驱动程序，因此英伟达公司针对 Docker 应用推出了 Nvidia-Docker，用以在镜像容器中提供对 GPU 驱动程序的支持。

（6）Pycharm

Pycharm 是一款功能强大的 Python 编译器。能够实现 Python 程序的高效编辑以及断点调试。

（7）Anaconda

Anaconda 是一种高效的 Python 包管理器，它包含了绝大部分的 Python 工具包，并且可以方便的建立、切换和管理不同版本的 Python 环境。

如图 2.19 所示，本文采用 Docker 来进行学习环境的搭建。Docker 镜像包含了与显卡版本相匹配的 CUDA、Cudnn 等软件包，Docker 镜像容器通过 Nvidia-Docker 来调用底层的显卡 GPU 驱动实现对并行计算的加速。使用 Docker 可以大大简化环境的搭建过程，并且方便搭建好的环境快速移植到其他电脑。

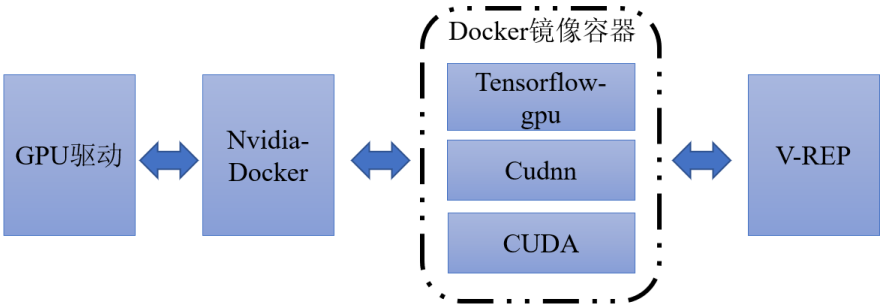


图 2.19 使用 Docker 搭建的强化学习训练环境

Fig. 2.19 Reinforcement learning training environment built using Docker

运行于 Docker 镜像容器内的 Python 算法程序通过网络 API 函数与 V-REP 进行通信与控制。实际操作中必须注意的是，普通的深度学习训练所使用的 Docker 不需要与外部进行网络通信，而基于深度强化学习的训练必须要不断的与外部的 V-REP 进行交互通信。V-REP 是无法运行于 Docker 镜像容器内部的，这是因为 Docker 容器没有图形化引擎。Docker 容器的外部网络模式默认运行于桥接模式，此时的每个容器不能直接与外界进行通信，而是通过 NAT(Network Address Translation)网络地址转换协议转接到外部网络。Host 模式则是容器直接与外界通信，不通过 NAT 转换。因此在从 Docker 镜像创建容器时必须指定该容器的网络运行于 host 模式，这样 Docker 容器中的程序才可以与外部的 V-REP 软件进行通信。

中国知网 https://www.cnki.net

2.4 无障碍环境下基于 3 种典型强化学习算法的运动规划

能够被应用于机械臂运动规划的深度强化学习算法主要有 DQN-NAF、PPO 和 DDPG 3 种。本节尝试将 3 种不同方法应用于无障碍物环境下的机械臂运动规划任务并对其控制效果进行比较，具体对 3 种算法在机械臂控制上的性能进行分析，从而选择一种更适合应用于有障碍物复杂环境中机械臂运动规划任务的深度强化学习算法。

2.4.1 运动规划任务设计

本文采用 Mirobot 机械臂作为机械臂运动规划算法实验的对象。Mirobot 是一款桌面级别的 6 自由度机械臂[96]。它是课题组针对高校机器人工程新工科建设、机器人学教学需要，并且面向日常生活当中机械臂的应用场景研发的一种消费级的机器人。其外观结构以及各个关节位置如图 2.20 所示。

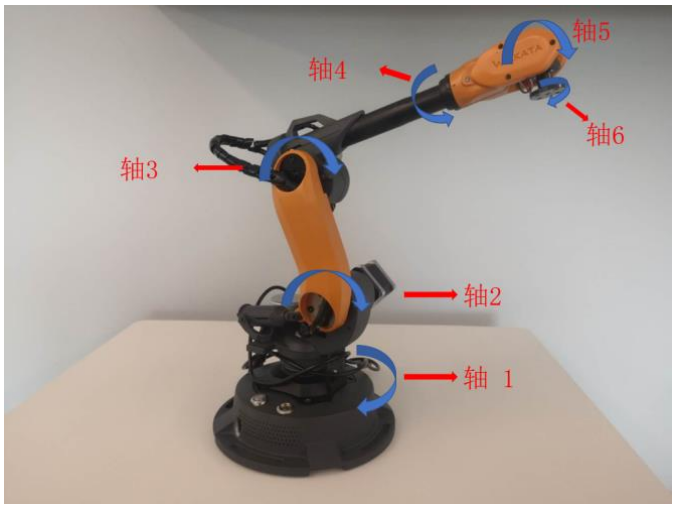


图 2.20 Mirobot 机械臂以及其各个关节位置

Fig. 2.20 Mirobot robotic arm and its joint position

（1）机械臂的到达任务

在机械臂到达任务中，强化学习智能体控制 6 自由度机械臂 Mirobot 的末端去到达一个球形的目标区域。到达任务如图 2.21 所示。

中国知网 https://www.cnki.net

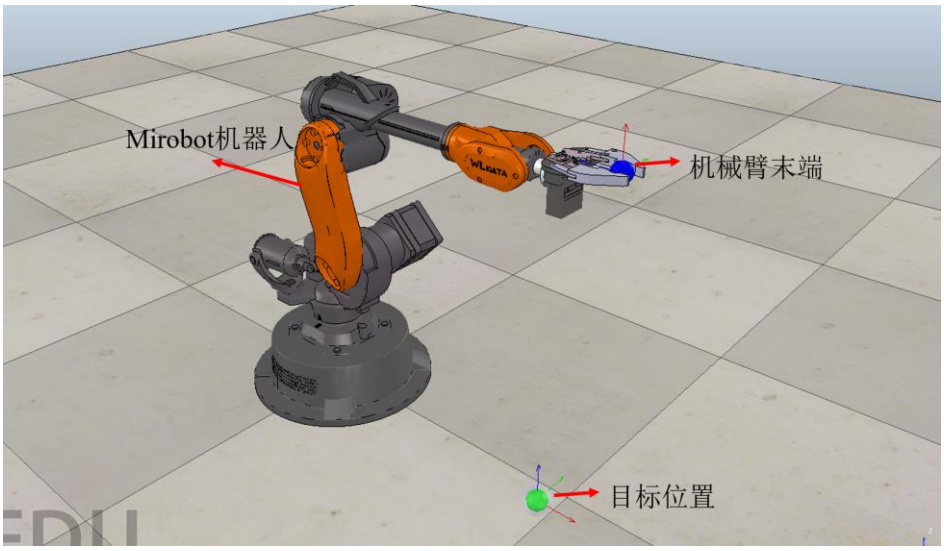


图 2.21 机械臂的到达任务

Fig. 2.21 The arrival task of the robotic arm

机械臂末端处的蓝色球体需要到达环境中绿色小球表示的目标位置，规定到达目标位置中心半径 3CM 之内属于任务成功。机械臂的初始构形为图 2.21 中所示的各轴初始位置。

（2）机械臂抓取到达任务

机械臂需要用夹爪将位于下方地面上的圆柱体夹住，并且将其向上方移动至位于绿色目标点位置中心半径 3CM 之内。机械臂的抓取到达任务仿真环境如图 2.22 所示。机械臂的初始构形为图 2.22 中所示的各轴初始位置。

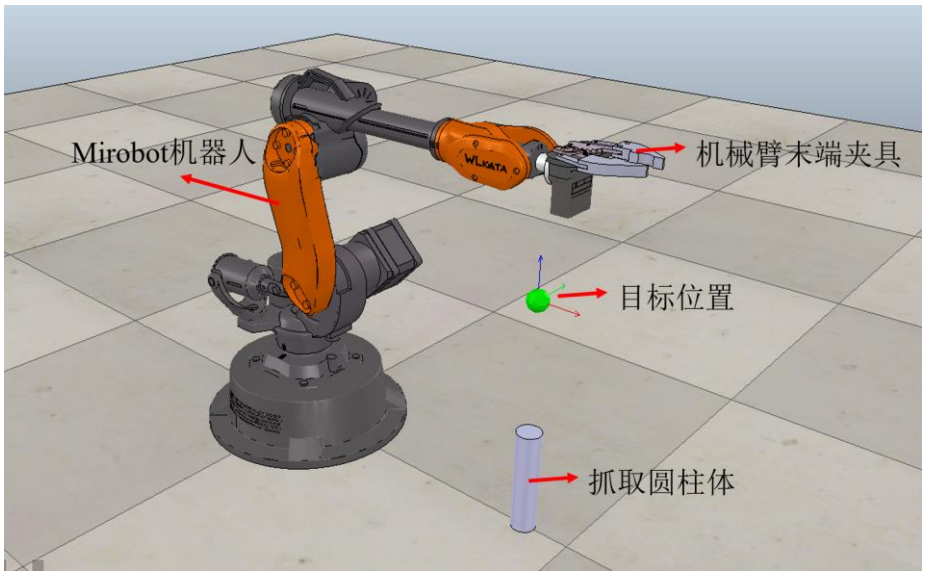


图 2.22 机械臂的抓取到达任务

Fig. 2.22 The grasp and reach task of robotic arm

中国知网 https://www.cnki.net

2.4.2 机械臂的动作、状态空间与奖励函数设置

（1）稠密奖励与稀疏奖励

强化学习所控制的智能体完全是由奖励函数来引导的，因此奖励函数的设置至关重要。如果智能体得到了积极的奖励，那么当智能体再次遇到相同状态，就会倾向于选择重复上次获得积极奖励的行为，类似地，如果智能体得到的是惩罚性的奖励，那么智能体下一次就会在相同状态下避免出现该动作。因此奖励函数的设计直接关系到任务能否顺利完成以及算法训练时的收敛速度。

按照奖励函数的类型来划分，可以将奖励函数划分为稠密奖励函数和稀疏奖励函数两大类。

稠密奖励函数以一个连续的函数形式给予智能体奖励，该奖励函数一般与任务当中的距离信息相关。一个典型的稠密奖励函数如下：

$$r = -\lambda d \tag{2.36}$$

式(2.36)中，与目标的距离为 d，该任务所有的奖励都是负值，距离目标越远，则负的惩罚就越大，而距离目标越近，惩罚就越小。参数 λ 为调整惩罚剧烈程度的系数。

稀疏奖励函数只在智能体完成任务的关键节点上给予离散形式的惩罚或者奖励。例如当智能体成功完成任务时给予+R 的奖励，当智能体失败时，给予-R 的惩罚，而平时状态则奖励值为 0。

相比于稀疏奖励，稠密奖励加入了更多人类的先验知识，算法设计者显然知道智能体如何操作才能够完成任务，设计一个稠密奖励函数的过程就变为如何精密地通过连续奖励的形式引导智能体完成设计者所需要任务的过程，因此稠密奖励函数往往能够更加快速地引导智能体的训练。而稀疏奖励函数由于只在某些成功或者失败的关键节点才对智能体的行为进行好坏评价，其所引入的人类先验知识显然少于稠密奖励，这将导致单一由稀疏奖励所引导的智能体在训练的初期需要进行大量杂乱无章的试错，其训练的回合数比采用稠密奖励要多。

但是在强化学习训练中，引入过多的人类先验知识未必是一件正确的事情，如果要解决的任务复杂程度很低，算法设计者可以马上观察出最优的行为策略，那么引入人类先验知识就可以快速帮助智能体学会如何去做。如果任务很复杂，智能体反而会受到人类所提供先验知识的干扰，可能陷入局部极小值中无法自发地找到解决任务的行为策略。稀疏奖励函数相对于稠密奖励函数的优势就在于只告诉智能体所需要的最终结果（成功则奖励，失败则惩罚），给算法最大的自由度，让算法自己去探索到最优的（最大化期望总收益）结果。

对于机械臂的运动规划任务而言，从引入人类先验知识数量的角度，将传统的示教方法、稠密奖励函数与稀疏奖励函数进行对比，如图 2.23 所示。

中国知网 https://www.cnki.net



图 2.23 示教方法、稠密奖励函数与稀疏奖励函数引入先验知识数量的对比

Fig. 2.23 Comparison of teaching method, dense reward function and sparse reward function introducing prior knowledge

（2）机械臂的到达任务

如式(2.37)所示，本文设计输入强化学习算法的状态为 6 个关节的角度位置、目标位置的 3 个坐标值和机械臂末端的 3 个坐标值，即输入状态为一个维度为 12 的状态向量：

$$s=\left\{\theta_1,\theta_2,\theta_3,\theta_4,\theta_5,\theta_6,x_{goal},y_{goal},z_{goal},x_{tip},y_{tip},z_{tip}\right\} \tag{2.37}$$

到达任务的动作空间为下一个时间步机械臂 6 个关节的期望角度变化值：

$$a=\left\{q_1,q_2,q_3,q_4,q_5,q_6\right\},q_i\in\left[-5^\circ\sim 5^\circ\right] \tag{2.38}$$

为了防止单步角度变化过大，设置一个角度限制，把最大变化的角度值限制到$\left[-5^\circ\sim 5^\circ\right]$。如果机械臂在执行该时间步前的初始角度值为$\left\{\theta_1,\theta_2,\theta_3,\theta_4,\theta_5,\theta_6\right\}$，则该时间步输出后关节角度值将变为$\left\{\theta_1+q_1,\theta_2+q_2,\theta_3+q_3,\theta_4+q_4,\theta_5+q_5,\theta_6+q_6\right\}$。

对于到达任务奖励函数采用与目标距离相关的稠密奖励函数：

$$r=-\sqrt{\left(x_{goal}-x_{tip}\right)^2+\left(y_{goal}-y_{tip}\right)^2+\left(z_{goal}-z_{tip}\right)^2}-\lambda\|a\| \tag{2.39}$$

在式(2.39)所示的奖励函数引导下，机械臂末端距离目标位置越近则获得的奖励越大。$-\lambda\|a\|$项限制输出的动作幅度不过大，λ为系数，取值范围是$\left[0\sim 100\right]$。

训练回合的结束条件为：

$$\sqrt{\left(x_{goal}-x_{tip}\right)^2+\left(y_{goal}-y_{tip}\right)^2+\left(z_{goal}-z_{tip}\right)^2}\le 3CM \text{ 或者} \ge\left(d_{init}+5\right)CM \tag{2.40}$$

当蓝色小球中心与绿色小球中心的距离小于 3CM 时，认为该回合成功，回合结束，或者该距离大于训练开始时它们之间的距离加 5CM，认为它们之间距离过远，为了避免不必要的探索，判定回合失败，直接结束回合。

（3）机械臂抓取到达任务

对于抓取到达任务，设置输入状态为机械臂的 6 个关节角度值，末端夹爪中心坐标值，目标圆柱体中心坐标值和最终需要到达的目标位置坐标值。

中国知网 https://www.cnki.net

$$s=\left\{\theta_1,\theta_2,\theta_3,\theta_4,\theta_5,\theta_6,x_{cy},y_{cy},z_{cy},x_{tip},y_{tip},z_{tip},x_{goal},y_{goal},z_{goal}\right\} \tag{2.41}$$

式(2.41)中，x_{cy},y_{cy},z_{cy} 表示目标圆柱体中心的坐标，x_{tip},y_{tip},z_{tip} 表示夹爪中心的坐标，$x_{goal},y_{goal},z_{goal}$ 表示目标区中心的坐标。

该任务的动作空间比到达任务的动作多了一个维度 clip，该维度表示夹爪的开闭状态：

$$a=\left\{q_1,q_2,q_3,q_4,q_5,q_6,clip\right\},q_i\in\left[-5^\circ\sim 5^\circ\right] \tag{2.42}$$

维度 *clip* 是一个离散的动作，由于所采用算法 DQN-NAF、PPO 和 DDPG 均输出连续动作，本文采用先将 *clip* 当作各个算法输出的连续动作值处理，然后单独将 *clip* 项输入给一个 Sigmod 激活函数，得到一个 0 到 1 之间的值，作为夹爪闭合的概率，即如果该值大于 0.5 则夹爪闭合。

抓取到达任务的奖励函数采用稠密奖励函数与稀疏奖励函数相结合的方式。对于稠密奖励函数部分，首先是机械臂末端与抓取目标圆柱体中心位置距离相关的项：

$$r_1=\sqrt{\left(x_{cy}\text{-}x_{tip}\right)^2+\left(y_{cy}\text{-}y_{tip}\right)^2+\left(z_{cy}\text{-}z_{tip}\right)^2} \tag{2.43}$$

目标圆柱体与抓取后需要举高到达的蓝色目标球中心之间的距离的项：

$$r_2=\sqrt{\left(x_{cy}\text{-}x_{tip}\right)^2+\left(y_{cy}\text{-}y_{tip}\right)^2+\left(z_{cy}\text{-}z_{tip}\right)^2} \tag{2.44}$$

机械臂末端 2 指夹爪与目标圆柱体中心位置距离的项：

$$r_3=\sqrt{\left(x_{cy}\text{-}x_{clip1}\right)^2+\left(y_{cy}\text{-}y_{clip1}\right)^2+\left(z_{cy}\text{-}z_{clip1}\right)^2}+\sqrt{\left(x_{cy}\text{-}x_{clip2}\right)^2+\left(y_{cy}\text{-}y_{clip2}\right)^2+\left(z_{cy}\text{-}z_{clip2}\right)^2}-d_{cy} \tag{2.45}$$

式(2.45)中，$\left(x_{clip1},y_{clip1},z_{clip1}\right)$ 和 $\left(x_{clip2},y_{clip2},z_{clip2}\right)$ 表示 2 指夹爪的两个指内表面中心的位置坐标。d_{cy} 表示目标圆柱体的半径。

对于稀疏奖励部分：

$$r_4=\begin{cases}-1,\text{夹爪在没有夹到目标物体时发生闭合}\\-2,\text{撞倒了目标圆柱体}\\-2,\text{夹爪抓住了目标圆柱体后又松开了圆柱体}\\3,\text{第一次成功抓住目标圆柱体}\\5,\text{成功完成任务}\end{cases} \tag{2.46}$$

该任务的总奖励函数如下：

$$r=\frac{100}{10+r1+r2+r3}+r_4-\lambda\|a\| \tag{2.47}$$

中国知网 https://www.cnki.net

$-\lambda\|a\|$ 项用于防止输出的动作幅度过大，常数用于防止分母出现 0 而导致奖励函数无穷大或者出现很大的奖励函数值。

回合的结束条件为：

①目标圆柱体被撞倒。

$$②\sqrt{\left(x_{goal}-x_{cy}\right)^2+\left(y_{goal}-y_{cy}\right)^2+\left(z_{goal}-z_{cy}\right)^2}\le 3CM\text{或}\ge\left(d_{init}+10\right)CM \tag{2.48}$$

当圆柱体与表示目标区域的绿色小球中心位置距离小于等于 3CM 可以认为任务已经完成，回合结束，当该距离大于它们之间的初始距离加 10CM，认为探索过程偏离过多，结束该回合。

$$③\sqrt{\left(x_{tip}-x_{cy}\right)^2+\left(y_{tip}-y_{cy}\right)^2+\left(z_{tip}-z_{cy}\right)^2}\ge\left(d_{init}+5\right)CM \tag{2.49}$$

当机械臂夹爪中心位置偏离圆柱体中心位置多于初始距离加 5CM，认为探索过程偏离过多，结束该回合。

2.4.3 算法的神经网络构建

为了对 3 种主要算法进行比较，尽量选择相近或者完全相同的网络结构来进行上述的机械臂控制任务。

（1）DQN-NAF 算法

DQN-NAF 算法由结构相同的现实神经网络和目标神经网络组成。DQN-NAF 算法需要输出 3 个关键的向量：状态价值函数值、动作向量、用于构建下三角矩阵的列向量。神经网络的输入量是智能体的状态 s。算法的神经网络结构采用前馈神经网络[97]，其结构为输入层、2 个隐含层、输出层。对于 DQN-NAF 算法输出的 3 个关键张量，它们共用输出层之前的神经网络部分。网络的结构如图 2.24 所示。

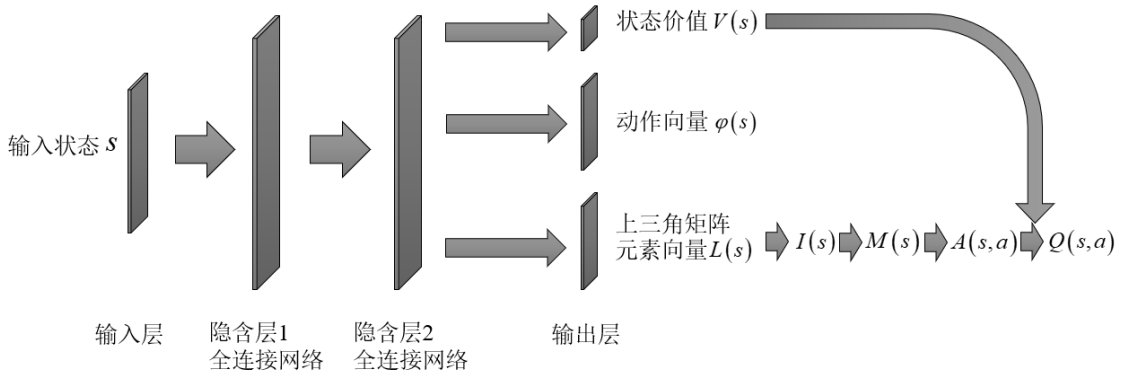


图 2.24 DQN-NAF 算法的神经网络结构

Fig. 2.24 Neural network structure of DQN-NAF algorithm

图 2.24 中，输入状态的维度决定了神经网络输入层的神经元个数，2 个隐含

中国知网 https://www.cnki.net

层神经元个数均为 128，输出层分为 3 个部分，对应于状态价值函数$V(s)$，动作向量$\varphi(s)$，上三角矩阵构造向量$L(s)$。输出层之前采用的激活函数为 ReLU 函数，输出层的状态价值输出部分和上三角元素向量部分的激活函数为线性输出，动作向量部分采用 tanh 激活函数输出。输出层状态价值部分神经元个数为 1，动作向量部分神经元个数为动作的维度值$\dim_{action}$，上三角矩阵元素向量部分神经元个数为动作维度的函数$\frac{\dim_{action}\times(\dim_{action}+1)}{2}$，这个值对应于所构建下三角矩阵中的非零元素个数。DQN-NAF 算法的现实神经网络与目标神经网络均采用上述的网络结构，但是目标神经网络只需要输出状态价值函数项。

（2） PPO 算法

PPO 算法在策略梯度 PG 的基础上发展而来，相对于确定性策略梯度 DPG 而言，PPO 实际上属于一种随机策略梯度算法，PPO 算法的 Actor 部分神经网络输出动作概率分布，一般认为该动作概率分布是一个高斯概率分布。具体构建神经网络时，Actor 网络需要能够估计高斯概率分布所对应的期望值u和方差σ。PPO 算法采用了 Actor-Critic 算法架构，因此算法中需要有 Actor 和 Critic 两个神经网络。Actor 神经网络的输入为智能体的状态，根据状态估计出智能体需要执行动作的概率分布，实际当中则是估计概率分布的两个参数：期望值u和方差σ。Critic 网络专门根据输入的状态来估计所对应的状态价值函数。

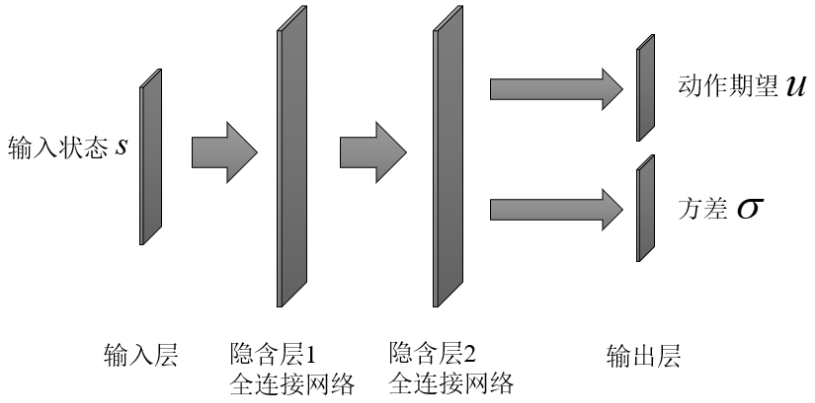


图 2.25 PPO 算法 Actor 部分的神经网络

Fig. 2.25 Neural network of the Actor part of the PPO algorithm

Actor 部分的神经网络如图 2.25 所示，神经网络的输入是智能体的状态，前馈神经网络的结构为输入层、2 个隐含层、输出层。输入层神经元个数与输入状态的维度相等，2 个隐含层神经元个数均为 128 个。输出层之前采用的激活函数为 ReLU 函数，对于期望和方差输出层采用 tanh 激活函数。

中国知网 https://www.cnki.net

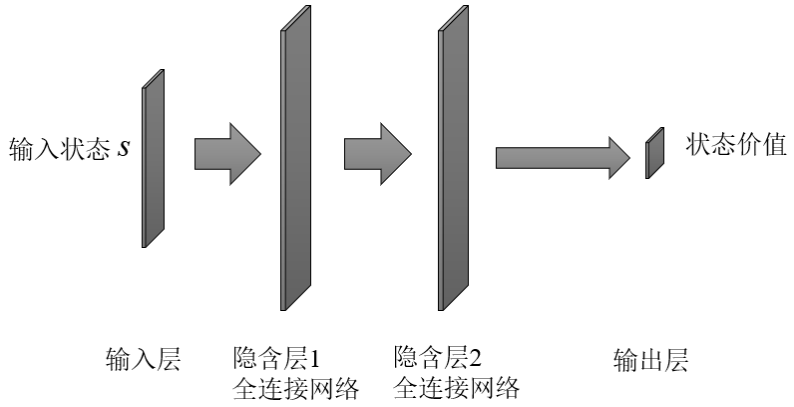


图 2.26 PPO 算法 Critic 部分的神经网络

Fig. 2.26 Neural network of the Critic part of the PPO algorithm

Critic 部分的神经网络如图 2.26 所示，2 个隐含层的神经元个数均为 128 个，输出层输出当前状态所对应的状态价值函数值。隐含层与输出层均采用 ReLU 激活函数。

（3） DDPG 算法

DDPG 算法同样由现实神经网络和目标神经网络构成。它的 Actor 部分包含 2 个结构相同的神经网络，Critic 同样包含 2 个结构相同的神经网络。

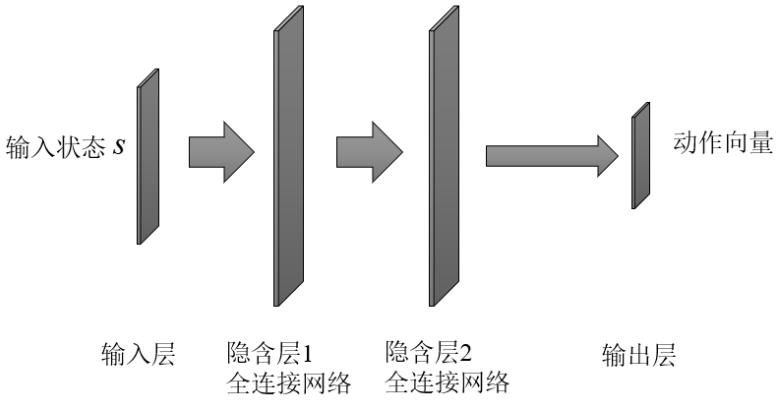


图 2.27 DDPG 算法 Actor 部分的神经网络

Fig. 2.27 Neural network of the Actor part of the DDPG algorithm

如图 2.27 所示，DDPG 算法的 Actor 部分输入状态，输出确定的动作向量，输出层之前的层采用 ReLU 激活函数，输出层采用 tanh 激活函数，隐含层神经元个数均为 128 个。

中国知网 https://www.cnki.net

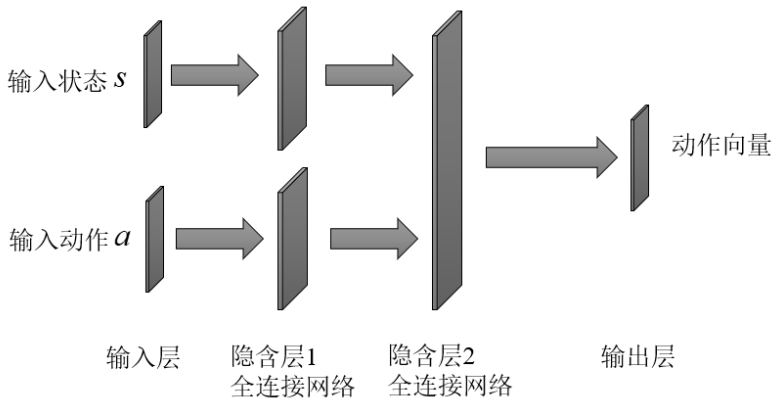


图 2.28 DDPG 算法 Critic 部分的神经网络

Fig. 2.28 Neural network of the Critic part of the DDPG algorithm

DDPG 算法的 Critic 部分如图 2.28 所示，智能体的状态与动作分别输入到 Critic 网络当中，它们的第一个隐含层也是分开的，然后在共同合并输入到第二个隐含层中，最后输出动作。输入状态和动作的第一个隐含层神经元个数为 64 个，第二个隐含层为 128 个。激活函数采用与 Actor 相同的配置，输出层之前为 ReLU，输出层为 tanh。

2.4.4 神经网络训练的优化

（1）激活函数

在进行神经网络训练时，单层的前馈神经网络结构如图 2.29 所示。

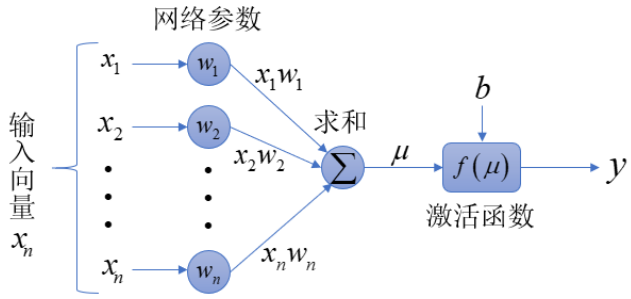


图 2.29 单层的前馈神经网络的结构

Fig. 2.29 Single-layer feedforward neural network structure

单层神经网络输入向量与输出变量的函数关系为：

$$y = f\left(\sum_{i=1}^{n} w_i x_i + b\right) \tag{2.50}$$

函数 $f(\mu)$ 表示所采用的非线性激活函数，本文采用的是 ReLu、tanh 函数和 sigmod 函数。

中国知网 https://www.cnki.net

在神经网络中使用激活函数的作用是使神经网络非线性化。tanh 函数是一种双曲正切激活函数，它能够将输出压缩到-1 到 1 之间的范围。

$$\tanh(x)=\frac{\sinh(x)}{\cosh(x)}=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}} \tag{2.51}$$

但是如果在整个网络使用 tanh 函数会导致梯度消失问题[98]。这是因为 tanh 函数会把很大的输入变化量转换为很小的输出变化量，这种转换会导致靠近输入的神经元的参数梯度很小，导致这部分参数无法得到有效训练。因此一般只在输出层采用 tanh 函数限制输出量的范围，而在之前的隐含层采用 ReLU 函数。

ReLU 函数当输入大于 0 时，是一种线性输出，可以有效地避免梯度消失问题。并且线性关系的输入与输出使神经网络正向传播时的参数计算速度更快。

$$\mathrm{Re}\,LU(x)=\max(0,x) \tag{2.52}$$

sigmod 激活函数的表达式：

$$\sigma(x)=\frac{1}{1+e^{-x}} \tag{2.53}$$

sigmod 激活函数可以把输出控制在 0 到 1 之间。它是神经网络领域较早被用于将神经网络非线性化的激活函数，但是 sigmod 函数与 tanh 函数类似，都会对输出值进行压缩，从而使反向传播时出现梯度消失现象。

（2）梯度下降方法

梯度下降是训练神经网络最常用的算法，神经网络中的参数按照梯度进行更新，适当的梯度下降优化方法可以增加训练的速度同时避免算法陷入局部极小值或者发散情况。本文采用按照小组的梯度下降方法以及 Adam 方法，每个梯度下降训练小组的大小选择为 128，算法的学习率设置为 0.002。

梯度下降方法按照每次训练时采用样本数量多少可以分为 3 类：全部样本梯度下降、小组样本梯度下降和随机梯度下降。全部样本梯度下降是在每次训练更新参数梯度时，采用所有样本的值进行梯度更新。小组样本梯度下降则是选取全部样本中一定数量的一个小组作为本次梯度更新的训练样本。随机梯度下降则每次只选用样本中的一个数据进行梯度更新，这种方法梯度更新的随机性会很大。

随着 GPU 加速神经网络训练技术的应用，采用小组样本梯度下降来进行训练能够显著提高算法的性能。小组样本大小的选择与计算机硬件的性能密切相关，如果样本数量选择的过小，则不能充分发挥 GPU 并行加速的能力，梯度下降的过程变为与随机梯度下降类似的过程。如果小组样本的数量过大，则会超过 GPU 所能达到的最大性能极限，速度反而会降低，并且过大的小组样本个数使梯度下降的路径缺少随机性，更加容易陷入局部极小值中。如图 2.30 所示，图中黑

中国知网 https://www.cnki.net

色线圈代表训练所对应 loss 函数的等高线，蓝色路径表示每次训练时小组样本数量很大甚至是全部样本的情况，它的路径平稳，但是由于缺少随机性，很容易陷入到 loss 函数的某个局部极小值。红色路径代表小组样本适中的梯度下降过程，梯度下降过程会出现一些波动，这些波动增加了路径的随机性，有利于跳出可能出现的局部极小值点，但是过小的小组样本数量，就会变成随机梯度下降，下降路径过于不稳定，反而影响算法的效率。

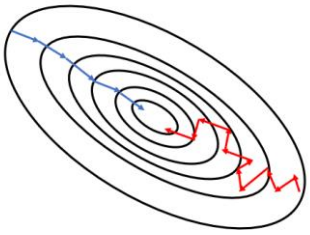


图 2.30 不同小组样本个数对应的梯度下降过程

Fig. 2.30 Gradient descent process corresponding to the number of samples in different groups

梯度下降当中的学习率是另一个重要的参数。

如果神经网络的参数是$\{\lambda_1,\lambda_2\}$

梯度下降开始时初始参数为：

$$\lambda^0=\begin{bmatrix}\lambda_1^0\\ \lambda_2^0\end{bmatrix} \tag{2.54}$$

则计算梯度为：

$$\nabla loss(\lambda)=\begin{bmatrix}\dfrac{\partial loss(\lambda)}{\partial\lambda_1}\\ \dfrac{\partial loss(\lambda)}{\partial\lambda_2}\end{bmatrix} \tag{2.55}$$

梯度下降为：

$$\begin{aligned}\lambda_1^1&=\lambda_1^0-\alpha\frac{\partial loss(\lambda_1)}{\partial\lambda_1}\\ \lambda_2^1&=\lambda_2^0-\alpha\frac{\partial loss(\lambda_2)}{\partial\lambda_2}\end{aligned} \tag{2.56}$$

式(2.56)中的参数α为学习率，学习率决定了神经网络的参数沿着梯度方向移动的剧烈程度。如图 2.31 所示，单个参数梯度下降时的 loss 函数，黑色的线代表 loss 函数的表面，梯度下降的目的就是找到黑色曲线的最低点，也就是 loss 函数的最小值。图中带箭头的线段代表梯度下降的过程，红色线段代表学习率设置很小时的梯度下降过程，蓝色线段代表学习率设置适中时的梯度下降过程，绿色线

中国知网 https://www.cnki.net

代表学习率设置较大时，紫色线则代表学习率设置过大的情况。从图中可以看出，红色线段需要经过非常多次的梯度下降才能够到达最小值处，因此如果学习率过小，则会导致训练过程过于缓慢，算法效率下降。蓝色线段代表学习率适中时算法快速稳定的下降到最小值处。绿色线段由于过大的学习率，导致无法下降到最小值处，算法最终会在最小值之上的某一位置来回波动。紫色线段代表学习率过大，算法直接跑飞。

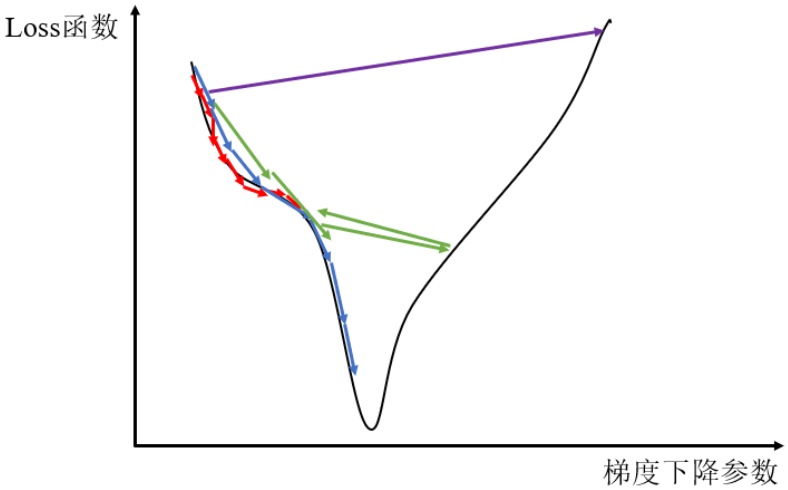


图 2.31 不同学习率对应的梯度下降过程

Fig. 2.31 Gradient descent process corresponding to different learning rates

综上所述，合适的学习率在梯度下降过程中起到了关键的作用。本文所采用的 Adam 方法是 RMSprop 方法[99]与 Momentum 方法[100]的结合体。

RMSProp 是一种根据每个参数梯度变化的不同而动态调整学习率的算法。它在计算每个参数对应的学习率时引入了过去所有时刻该参数的梯度值平方和，使得学习率能够根据 loss 函数的形状不断动态调整到合适的值。RMSProp 算法的梯度更新、学习率计算公式如下：

$$\begin{aligned}
&\lambda_1 \leftarrow \lambda_0 - \frac{\alpha}{\rho^0}\nabla loss^0, \rho^0 = \nabla loss^0 \\
&\lambda_2 \leftarrow \lambda_1 - \frac{\alpha}{\rho^1}\nabla loss^1, \rho^1 = \sqrt{\sigma\left(\rho^0\right)^2 + (1-\sigma)\left(\nabla loss^1\right)^2} \\
&\cdots \\
&\lambda_{n+1} \leftarrow \lambda_n - \frac{\alpha}{\rho^n}\nabla loss^n, \rho^n = \sqrt{\sigma\left(\rho^{n-1}\right)^2 + (1-\sigma)\left(\nabla loss^n\right)^2}
\end{aligned} \tag{2.57}$$

式(2.57)中，$\frac{\alpha}{\rho^n}$ 代表动态变化的学习率，参数 σ 的大小衡量了学习率对于过去的梯度和当前梯度的置信度。

Momentum 方法是一种受物理学惯性概念启发而出现的方法。参数梯度下降

中国知网 https://www.cnki.net

的过程很可能会卡在极小值点出不来，给梯度下降的参数在原有按照梯度进行变化的基础上增加一项，也就是惯性项，惯性项可以在参数位于极小值点时产生推动作用，从而将参数从极小值点推出去，避免参数陷入局部极小值。

Adam 将 RMSProp 与 Momentum 方法相结合，既能够根据以往的梯度平方和来动态更新参数的学习率，也能够根据以往的梯度来计算“惯性”，使本次的梯度下降增加了原有梯度的“惯性”影响，从而更不容易陷入局部极小值。Adam 算法的主要过程如下：

①初始化惯性项$M_0=0$,初始化梯度平方和为$G_0=0$，时间步$step=0$。

②计算当前参数时间步的梯度$\nabla loss\left(\lambda_{step}\right)$。

③根据上一个时间步的惯性项和当前梯度计算本次时间步所对应的惯性项：

$$M_{step}=\sigma_1 M_{step-1}+\left(1-\sigma_1\right)\nabla loss\left(\lambda_{step}\right) \tag{2.58}$$

式(2.58)中的参数σ_1用于衡量过去梯度和当前梯度对于惯性项的影响程度。

④根据上一个时间步的梯度平方和与当前梯度计算本次时间步所对应的梯度平方和项：

$$G_{step}=\sigma_2 G_{step-1}+\left(1-\sigma_2\right)\left[\nabla loss\left(\lambda_{step}\right)\right]^2 \tag{2.59}$$

⑤Adam 梯度的更新公式为:

$$\lambda_{step}=\lambda_{step-1}-\frac{\alpha M_{step}}{\sqrt{G_{step}}+\varepsilon} \tag{2.60}$$

2.4.5 3 种典型算法在无障碍环境下的性能

（1）机械臂的到达任务

该任务中，采用 3 种典型深度强化学习算法对机械臂进行训练后均取得了很好的效果。当训练回合数超过 4000 以后，3 种算法对于到达任务的成功率都趋于 96%以上。

中国知网 https://www.cnki.net

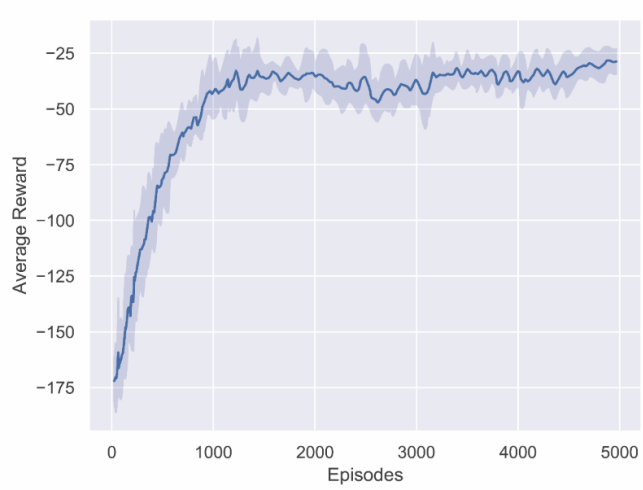


图 2.32 DQN-NAF 算法的平均收益

Fig. 2.32 Average return of DQN-NAF algorithm

如图 2.32 所示为采用 DQN-NAF 算法时的每回合平均收益与回合数之间的折线关系图。从图中可以看出 DQN-NAF 算法在解决机械臂到达任务时，在训练回合超过 1000 时就已经收敛到比较好的效果。

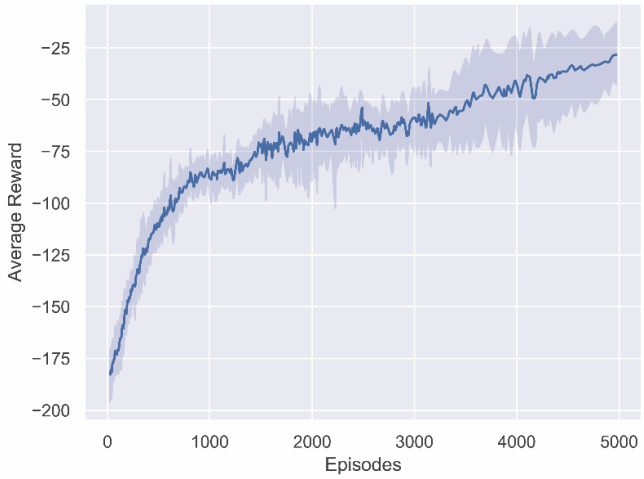


图 2.33 PPO 算法的平均收益

Fig. 2.33 Average return of PPO algorithm

图 2.33 所示为采用 PPO 算法时的回合平均收益与回合数之间的折线图。可以看出 PPO 算法同样能够比较好的解决到达任务，但是它在训练过程中收益会出现小幅度的波动，总体稳健上升，并最终收敛，但是收敛速度没有 DQN-NAF 快。

中国知网 https://www.cnki.net

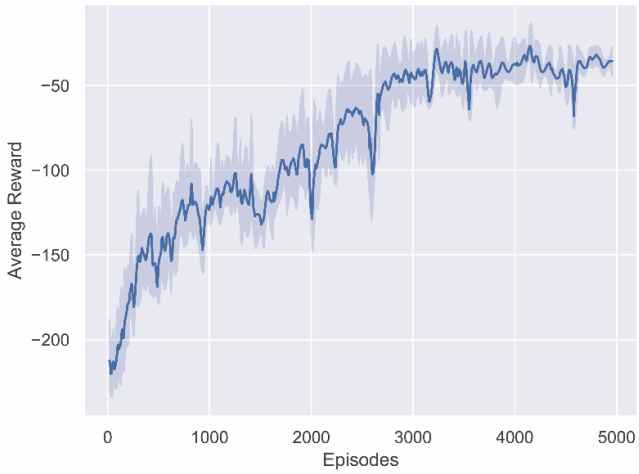


图 2.34 DDPG 算法的平均收益

Fig. 2.34 Average return of DDPG algorithm

图 2.34 所示为 DDPG 算法的回合平均收益与回合数之间的折线图。DDPG 算法表现出了很强的不稳定性，它需要经过多次剧烈的来回反复才能够最终收敛到比较好的结果。

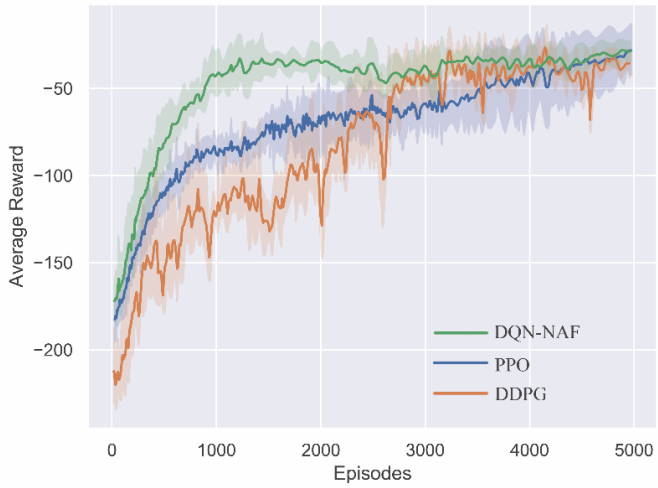


图 2.35 3 种典型算法同时比较

Fig. 2.35 Simultaneous comparison of 3 typical algorithms

图 2.35 所示为 3 种典型算法同时比较的结果图。可以看出在机械臂到达任务时，表现出最好性能的是 DQN-NAF 算法，DDPG 算法最为不稳定，在训练过程中表现出很大的波动，PPO 算法则最为稳健。

（2）机械臂抓取到达任务

在机械臂的抓取到达任务中，在经过 5000 回合最长时间训练过后，只有 PPO 算法能够成功的完成任务，而 DQN-NAF 和 DDPG 都很难顺利完成任务。

中国知网 https://www.cnki.net

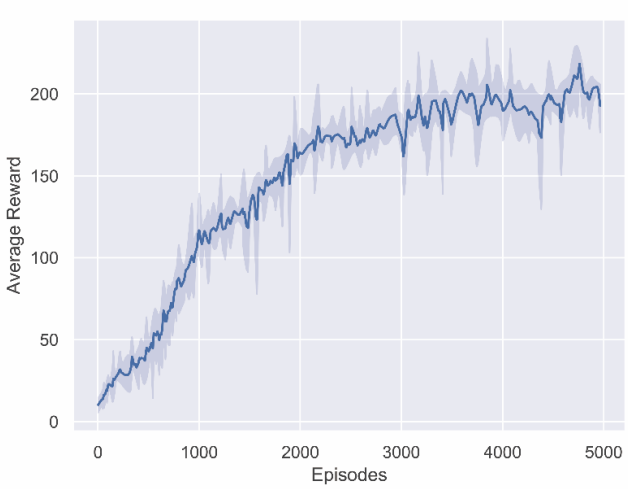


图 2.36 DQN-NAF 算法的平均收益

Fig. 2.36 Average return of DQN-NAF algorithm

图 2.36 所示为 DQN-NAF 算法的每回合平均收益与回合数之间的折线关系图。DQN-NAF 算法的性能大概在训练 2000 回合以后就无法继续上升了。



图 2.37 PPO 算法的平均收益

Fig. 2.37 Average return of PPO algorithm

图 2.37 所示为 PPO 算法的每回合平均收益与回合数之间的折线关系图。PPO 算法在抓取到达任务当中体现出良好的性能，其性能曲线波动但是总趋势一直上升，如果继续增加训练回合数 PPO 算法性能有可能进一步提升。

中国知网 https://www.cnki.net



图 2.38 DDPG 算法的平均收益

Fig. 2.38 Average return of DDPG algorithm

在图 2.38 中，DDPG 算法仍然表现出最大的不稳定性，直到 5000 回合结束仍然有一定的上升趋势，如果继续增加训练回合数，DDPG 算法的性能可能会进一步提高。



图 2.39 3 种典型算法同时比较

Fig. 2.39 Simultaneous comparison of 3 typical algorithms

如图 2.39 所示为 3 种算法的平均总收益与回合数的折线图。相对于 DQN-NAF 和 DDPG，PPO 算法体现出很稳定的性能，随着训练回合数的增加，其收益折线虽然有一定的波动，但是一直稳健提升，直到能够顺利完成抓取到达任务。

通过机械臂的到达任务和抓取到达任务中 3 种算法的性能表现可以看出，在简单的任务中（到达任务），DQN-NAF 这种基于价值函数的算法体现出了快速且优良的性能。但是在增加一定复杂度的任务中（抓取到达任务），DQN-NAF 这种基于价值函数的算法表现出了强烈的局限性，其总收益折线上升到某一个阶段后

中国知网 https://www.cnki.net

就无法继续提高，而基于策略梯度方法的 PPO 算法体现出了比 DQN-NAF 更好的性能，随着训练回合数的增加，它的总收益折线能够在曲折中上升，因此 PPO 这种基于策略梯度的方法更加适合复杂的机械臂控制任务。进一步可以看出 DDPG 算法相对于其他两种算法表现出了最大的不稳定性，这种不稳定性是由策略梯度本身的算法特性所决定的，PPO 算法由于利用重要性采样原理限制住了新策略相对旧策略变化更新的幅度而使得整个训练过程更加平稳。因此在本文后续的研究中采用 PPO 算法作为标准的强化学习算法来进行机械臂运动规划研究。

2.5 本章小结

（1）本章首先详细阐述了深度强化学习算法的数学模型与基本原理。

（2）研究了能够应用于机械臂运动规划问题的 3 种强化学习算法：DQN-NAF、PPO 和 DDPG。

（3）阐述了本文所使用的深度强化学习训练环境以及通过 GPU 加速训练的方法。

（4）在机器人虚拟仿真软件中构建无障碍物环境下的运动规划任务，对 3 种强化学习算法在同样任务上所表现出的性能进行了测试和比较，PPO 算法表现出了稳健的性能。最终确定将 PPO 算法作为解决机械臂运动规划问题的标准强化学习算法，对其进行进一步研究。

中国知网 https://www.cnki.net

3 基于残差强化学习的机械臂运动规划方法研究

本文的第 2 章将 DQN-NAF、PPO 和 DDPG 这 3 种能够用于解决高维空间运动规划问题的深度强化学习算法应用于无障碍物环境下的机械臂控制任务中，设计了相应的奖励函数和实验仿真方法，最后比较了它们在相同任务中的不同性能。结果表明，相比于另外两种算法，PPO 算法在解决机械臂控制任务时具有比较稳健的性能。

单纯的深度强化学习算法在解决机械臂运动规划问题时，尤其是在解决复杂任务时面临着训练时间过长、算法收敛困难的问题。这是由强化学习的算法特性所决定的，强化学习的核心思想是智能体不断与环境进行交互试错。设计者给予算法的先验知识仅通过所设计的奖励函数来引导智能体，智能体通过不断的尝试、失败、再尝试、再失败的反复试错过程对环境进行探索，从而自发地找到解决问题的最佳策略。这显然是一个类似于“盲人摸象”的过程，盲人在最终能够在内心中得到大象真实而完整的样貌之前，只能通过大量的随机触摸来感知，这个随机触摸的过程相当漫长。对于简单的任务，强化学习算法只需要经过相对少量的尝试就能够得到比较好的结果，但是对于复杂的任务，强化学习智能体需要进行的随机试错次数往往会无法避免的多。如何提高强化学习算法的训练效率避免训练困难问题已经成为了强化学习领域的研究热点。为了提高强化学习的训练效果，大部分学者着眼于对奖励函数进行改进[101, 102]，尤其是采用稠密奖励函数能够将更多的先验知识引入到强化学习智能体的训练中。但是引入了过多设计者先验知识的稠密类型奖励函数也存在固有缺陷，2.4.2 小节对稠密奖励函数与稀疏奖励函数的优缺点进行了分析。

针对采用单一深度强化学习算法在复杂任务中面临的训练时间过长，训练困难问题，本章提出了一种将运动规划过程的最终行为策略分解为初始策略与残差策略相叠加的方法。首先分析了该方法的思想来源以及理论框架。然后针对方法中的初始策略进行设计，采用了一种基于 BP 神经网络的运动规划方法，并提出了球体障碍物抽象方法。针对方法中的残差策略部分，则使用了在前期实验中表现平稳的 PPO 算法，并针对 PPO 算法采样利用率低的问题，提出了一种在 PPO 算法局部采用离轨策略思想并引入样本优先级经验池进行训练的改进 PPO 算法。最后设计了有障碍物环境仿真实验任务，在虚拟仿真环境中对采用单纯 PPO 算法与所提出残差强化学习方法的训练效果进行了比较。

中国知网 https://www.cnki.net

3.1 残差强化学习理论

本节提出了基于残差强化学习的机械臂运动规划方法理论，并阐述了该方法的思想来源以及原理。

3.1.1 残差强化学习

加州大学伯克利分校与西门子公司的学者 Johannink 等人在 2019 年的 IEEE 机器人技术和自动化国际会议(ICRA)中提出了机器人控制的残差强化学习方法[103]。在其研究中，一台机械臂将一个立方体木块放置在另外两个相同的立方体木块的夹缝中间部分，并且保证在放置过程中另外两个立方体木块不能被碰倒。

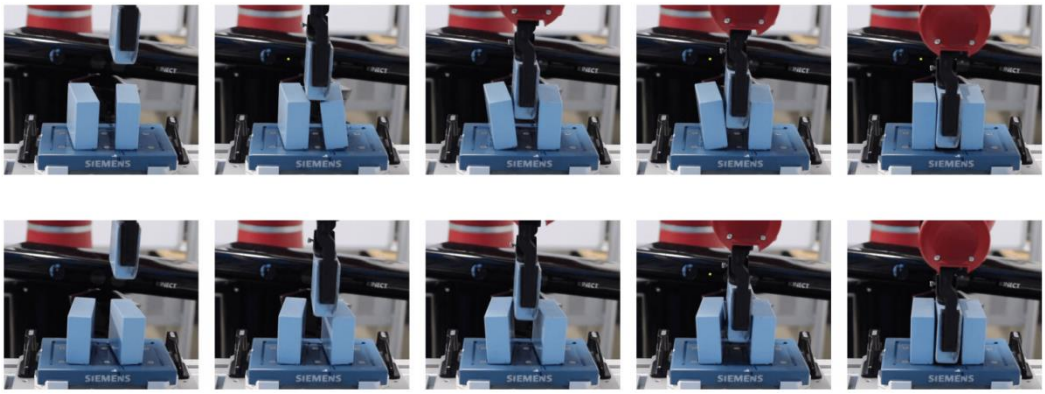


图 3.1 残差强化学习算法用于控制机械臂将物块放入狭小的夹缝当中[103]

Fig. 3.1 The residual reinforcement learning algorithm is used to control the robotic arm to put the block into the narrow gap

如图 3.1 所示为该任务的执行过程。对于传统的机器人控制而言，将物体平稳而准确的放置到机械臂工作空间的任意位置是没有任何难度的任务。但是要将物体放置在本来无法容纳其体积的夹缝当中，就需要机械臂不能直接进行放置的动作，而是首先进行一些轻微的刮蹭，将两边物块的距离刮蹭到能够容纳中间物块，并且在轻微刮蹭旁边两个物块的同时，不能将其碰倒。对于传统的机器人控制器而言，操作者很难编写一套固定的动作完成如此复杂而精密的任务，该任务属于难以手动建立精确控制模型的任务。

Johannink 等学者认为传统的控制方法鲜有自适应行为，并且缺少有效的行为泛化。上述任务中所必须的刮蹭物块过程很难建立控制模型，对于人类而言，执行这样的任务反而是比较容易的，这是因为人类操作者完全可以进行一系列的试探动作，尝试去触碰宽度狭窄的两块立方体，找到最佳的放置“技巧”。人类完成该任务的过程类似于强化学习的训练过程，因此采用强化学习算法来尝试解决该任务是恰当的。但是如果从强化学习智能体的最初始状态让机械臂随机试错，一直训

中国知网 https://www.cnki.net

练到机械臂第一次出现能够成功完成该任务的动作，所经历的随机试错次数显然会难以接受的多。

最终，Johannink 等学者利用手动建模设计的动力学控制器作为移动小立方体物块到目标位置的初始策略，然后利用强化学习算法与另外两个物块交互过程中所学习到的行为策略作为残差策略，控制器最终输出的行为动作为初始策略与残差策略的叠加动作。

3.1.2 基于残差强化学习的运动规划方法理论

Johannink 等学者提出的残差强化学习方法解决了无法手动建立准确控制模型的小方块插入放置任务。受其理论中将初始策略与残差策略两种策略叠加输出从而使总策略同时兼具两种策略特性这一思想的启发，本文将机械臂的运动规划问题分解为初始运动规划策略的动作输出和深度强化学习策略动作输出的叠加，该方法被称为残差强化学习运动规划。将初始策略与强化学习策略叠加输出的思想作为本章所提出的解决机械臂运动规划问题方法的核心思想。

如果初始策略为π_0，对于输入状态s，初始策略的输出动作为：

$$a_0 = \pi_0(s) \tag{3.1}$$

如果残差策略为π_R，对于同样的输入状态s，残差策略的输出动作为：

$$a_R = \pi_R(s) \tag{3.2}$$

那么最终的行为策略输出动作为：

$$a = a_0 + a_R = \pi_0(s) + \pi_R(s) \tag{3.3}$$

在这种初始策略-残差策略的方法框架中，初始策略能够在最初引导由强化学习算法构成的残差策略训练，使得曾经随意的“试错”变为有方向性的探索过程，从而使强化学习的训练过程大大缩短。而强化学习部分的策略能够为初始策略部分提供必要的行为策略补充，初始策略往往缺乏自适应能力和泛化能力，而这正是强化学习算法所擅长的。

如果一个初始策略本身已经接近完美，那么所叠加的残差策略输出可以被训练为接近于 0 输出的修正动作。反之，如果初始策略与最优控制策略相差甚远，训练后的残差策略将对其产生强烈的修正作用，初始策略仅为残差策略部分的强化学习智能体提供训练方向的指引，降低强化学习算法收敛的难度，避免从头开始训练强化学习智能体所出现的训练困难问题。

中国知网 https://www.cnki.net

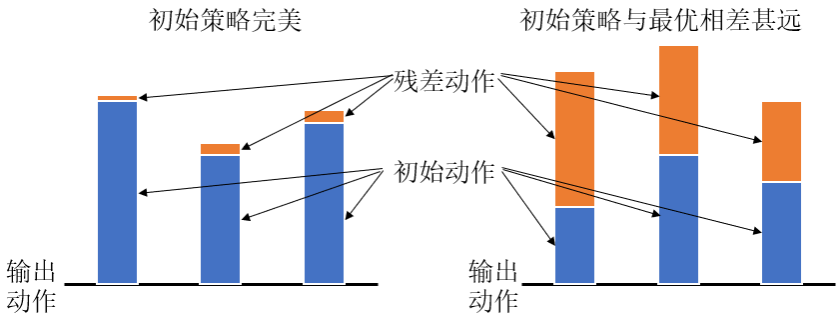


图 3.2 残差策略在初始策略完美和与最优相差很多情况下的不同作用

Fig. 3.2 Different effects of residual policy when the initial policy is perfect and when it is much different from the optimal

图 3.2 所示为初始策略完美时，初始策略与最优策略相差甚远时两种情况下训练过后的残差动作与初始动作在最终输出动作中所发挥作用的示意图，图中假设有 3 个动作输出。

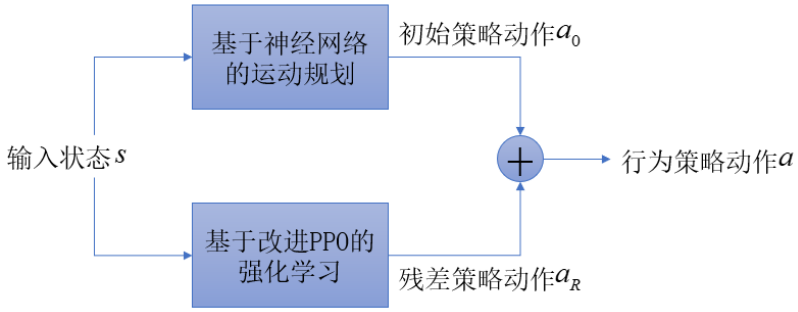


图 3.3 基于残差强化学习的机械臂运动规划原理框图

Fig. 3.3 The principle block diagram of robotic arm motion planning based on residual policy

如图 3.3 所示，为基于残差强化学习的机械臂运动规划理论原理框图。对于所提出的残差强化学习运动规划方法的初始策略部分，本文采用了一种基于 BP 神经网络的运动规划方法并将其作为智能体的初始策略，该初始策略能够引导残差策略部分强化学习智能体的训练方向。对于残差策略部分，使用强化学习 PPO 算法。此外，由于传统的 PPO 算法属于在轨策略，其采样利用效率比较低，本文借鉴了 DDPG 算法作为离轨策略所使用的经验池回放机制和优先经验回放(Prioritized Experience Replay)的方法，提出了一种性能更好的改进 PPO 算法。最终用于机械臂运动规划的策略动作为上述的初始策略动作与残差策略动作的叠加。

表 3.1 所示为基于残差强化学习的运动规划算法的伪代码，其中的神经网络运动规划方法以及改进 PPO 算法在本章后续部分详细阐述。

中国知网 https://www.cnki.net

表 3.1 基于残差强化学习的运动规划算法伪代码

Table 3.1 Motion planning based on residual policy algorithm pseudo code

基于残差强化学习的运动规划算法
1: 初始化初始策略：BP 神经网络运动规划策略 π_0。初始化残差策略：改进 PPO 算法策略 π_R
2: for 回合=1:M do
3: 重置环境，初始化状态 s
4: while 状态 s 非终止状态 do
5: 根据智能体状态 s 获得初始策略的动作：$a_0=\pi_0(s)$
6: 根据智能体状态 s 获得残差策略的动作：$a_R=\pi_R(s)$
7: 得到智能体的执行动作：$a=a_0+a_R$
8: 智能体执行动作与环境交互执行动作 a，并且受到即时奖励 r，环境状态转移到状态 s'
9: 将采样数据 (s,a_R,s',r) 传递给改进 PPO 算法的小型经验池
10: 改进 PPO 算法根据采样经验进行参数优化训练
11: end while
12: end for

3.2 基于 BP 神经网络与球体障碍物抽象的初始策略

初始策略与残差策略共同引导机械臂进行运动规划。残差策略部分采用改进 PPO 深度强化学习算法，而初始策略部分则需要一种能够向正确方向引导强化学习部分智能体训练的运动规划策略。能够应用于高维空间机械臂运动规划的传统方法主要是 RRT 算法以及 RRT 的一些改进算法，但是这些算法在高维构形空间中需要随机采样，算法的性能随着机械臂自由度数的增加而降低。

传统运动规划算法的规划过程本质上是从输入给算法的当前机械臂构形与障碍物空间的描述得到连接起点到终点一系列构形的非线性映射过程，而神经网络非常适合进行这种非线性拟合。本小节采用 BP 神经网络来拟合机械臂运动规划时每一个时间步的输出构形，并将其作为残差强化学习运动规划方法的初始策略部分。

3.2.1 机械臂运动规划问题的数学描述

机械臂的工作空间表示为 $D\in R^3$，工作空间指机械臂末端执行器能够被操作到达或者执行相应任务工作的区域。机械臂的构形空间(Configuration Space)简称为 C 空间，是将机械臂的每个关节角度作为坐标系的一个坐标轴，再将机械臂的每一个构形（各个关节的一组角度位置）表示为构形空间中的一个点。如图 3.4 所示为一个简单的 2 自由度关节型机械臂的工作空间与所对应的构形空间，假设每个关

中国知网 https://www.cnki.net

节都可以旋转$0^{\circ}\sim360^{\circ}$，图中的三角形物体为机械臂工作空间的障碍物。图 3.4 中的右侧图则表示了这个 2 自由度机械臂和工作空间障碍物所对应的构形空间，横轴与纵轴表示机械臂的 2 个关节角度值，图中的不规则阴影部分为工作空间障碍物在构形空间当中的映射。图中展示了工作空间的机械臂从开始位置避开所有障碍物运动到目标位置的运动规划过程以及该过程所对应的构形空间中点的移动过程。

实际上该 2 自由度机械臂的构形空间并非平面，而是一个圆环构形空间，由于拓扑学原理，圆环空间的一个局部表面与同维度欧式空间是局部微分同胚的，因此其构形空间可以简化为欧式空间的平面，并且在平面中推导得到的规则与结论仍然可以适用于圆环空间。这个结论实际上是所有传统机械臂运动规划算法的理论前提，关于构形空间的概念本文在绪论的小节 1.2.2 进行了详细阐述。

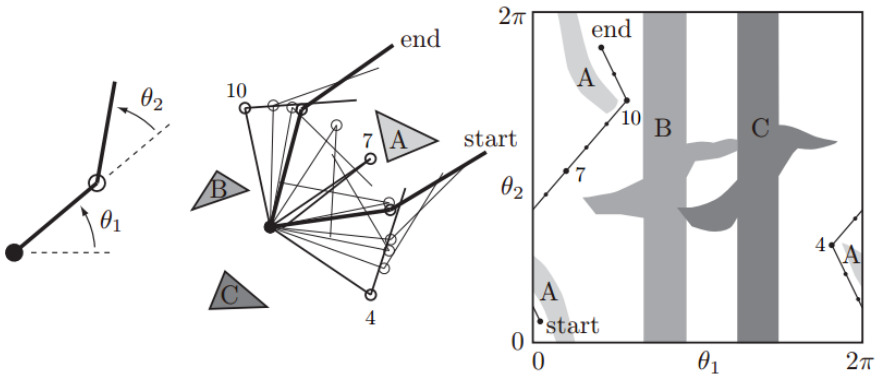


图 3.4 二自由度机械臂的工作空间与构形空间

Fig. 3.4 The work space and configuration space of a two-degree-of-freedom robotic arm

构形空间中所有障碍物点构成的集合表示为C_{obs}。构形空间中无障碍物的点构成的集合表示为C_{free}。有障碍物空间和无障碍物空间共同构成了全部的机械臂构形空间$C=C_{free}\cup C_{obs}$。将构形空间中一个具体的机械臂构形表示为$q\in C$，在构形空间中给定一个初始的机械臂构形$q_{start}\in C$和一个目标构形$q_{end}\in C$，构形q_{start}和q_{end}通过机械臂的运动学关系与工作空间中给定的末端执行器起始与目标工作位置$d_{start},d_{end}\in D$相对应。机械臂的运动规划问题可以描述为：从构形q_{start}到q_{end}，按照时间步$t\in[0,T]$在无障碍构形空间C_{free}中找到一条由构形组成的时间步序列$\{q(0),q(1),q(2)\cdots q(T)\}$，使得$q(0)=q_{start}$，$q(T)=q_{end}$。对于 6 自由度机械臂，每一个构形$q(t)$表示一组 6 个关节角度值$(\theta_1,\theta_2,\theta_3,\theta_4,\theta_5,\theta_6)_t$。

中国知网 https://www.cnki.net

3.2.2 机械臂神经网络运动规划方法

机械臂的运动规划算法能够在构形空间中找到一条由构形角度值所构成的序列$\{q(0),q(1),q(2)\cdots q(T)\}$。RRT 等传统运动规划算法进行运动规划的过程如图 3.5 所示。其本质过程是输入给运动规划算法起始构形位置、目标构形位置和障碍物的信息，然后 RRT 等运动规划算法经过随机采样计算后得到一条连通起始与目标构形且无碰撞的构形轨迹序列，最后再下发给机械臂的运动控制系统进行进一步的轨迹规划进而控制机械臂执行具体的运动。



图 3.5 传统机械臂运动规划算法的规划过程示意图

Fig. 3.5 Schematic diagram of the planning process of the traditional robotic arm motion planning algorithm

使用神经网络进行运动规划的基本原理就是借助反向传播(BP)神经网络[104]的非线性拟合能力来拟合传统运动规划算法，给神经网络输入一系列特征，然后输出运动规划结果。如图 3.6 所示为将传统运动规划算法拟合为 BP 神经网络的示意过程，输入相同的特征值给传统算法和神经网络，传统算法经过计算得到构形序列，神经网络经过拟合同样得到构形序列，将传统算法计算得到的序列与神经网络得到的序列之间数值的均方差作为训练神经网络梯度下降的 loss 函数，然后就可以使用梯度下降法对 BP 神经网络进行训练。

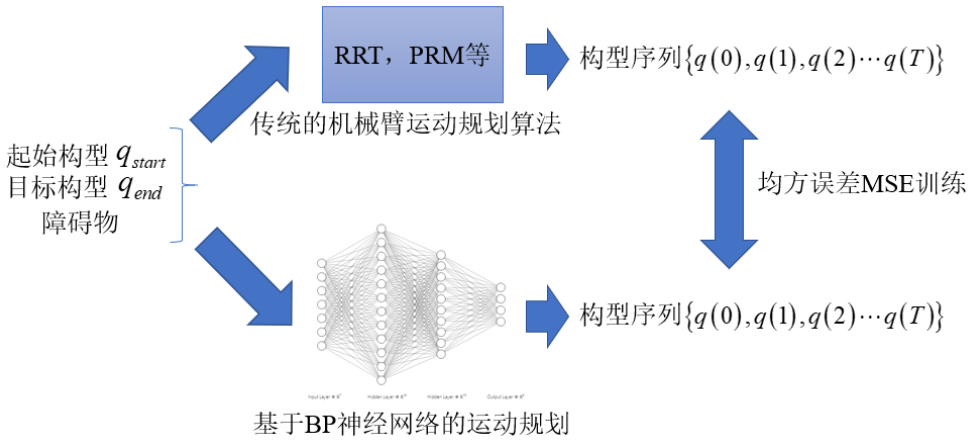


图 3.6 将传统运动规划算法拟合为 BP 神经网络的示意图

Fig. 3.6 Schematic diagram of fitting traditional motion planning algorithm to BP neural network

上述方式设计的神经网络输入输出对于构形序列较短且机械臂自由度数较少的情况适用。对于 6 自由度机械臂而言，一个构形点包括 6 个关节角度数值，如果

中国知网 https://www.cnki.net

构形序列中包含 100 个构形节点，那么神经网络的输出层就需要有 600 个输出量，过多的网络输出量显然使网络的设计与训练难以进行。

因此，需要对上述 BP 神经网络的输入与输出进行适当的调整。针对这一问题，加州大学圣地亚哥分校学者 Ahmed H. Qureshi 等在 2019 年的 ICRA 会议当中提出了一种使用神经网络进行运动规划的有效方法 MPNet[105]。MPNet 采用两个神经网络，第一个神经网络用来编码降低障碍物数据的维度，第二个神经网络接收第一个神经网络输出的障碍物数据以及当前构形、目标构形，输出预测得到的下一个构形。

MPNet 方法使用 RRT 算法来生成训练其神经网络用的数据，它本质属于模仿学习[106]方法。由于被模仿的传统运动规划算法很难生成非常靠近障碍物边缘的训练用轨迹，这将导致模仿学习的智能体在障碍物边缘处的数据稀疏问题[107]。此外，该方法需要同时训练 2 个神经网络，网络训练的难度较大。针对上述问题，本文对 MPNet 中使用的神经网络方法进行了修改并将其作为所提出残差强化学习运动规划方法的初始策略。针对模仿学习遇到的数据稀疏问题，本文所提出的残差强化学习运动规划方法当中的残差策略部分能够有效的利用强化学习的试错特性，充分试探靠近障碍物边缘的部分，从而避免智能体在障碍物边缘处的数据稀疏问题。针对障碍物的特征描述问题，本文提出了一种球体障碍物抽象方法。

如图 3.7 所示,将输入特征值设置为当前构形 q_{curr} 、目标构形 q_{end} 和障碍物特征，将神经网络输出设置为与当前构形相邻的下一个可达的构形 q_{next} 。

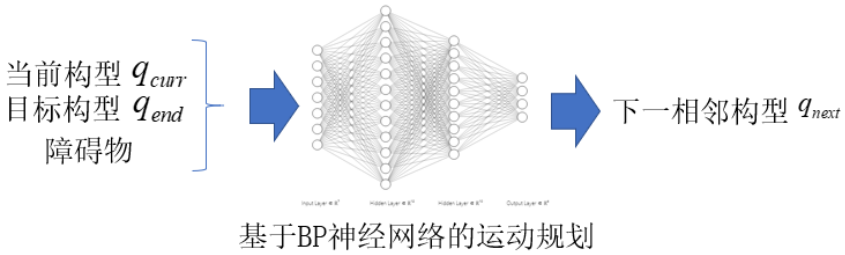


图 3.7 基于 BP 神经网络的机械臂运动规划

Fig. 3.7 Motion planning of robotic arm based on BP neural network

如图 3.8 所示为用于机械臂运动规划的 BP 神经网络训练过程示意。在训练时，先使用传统运动规划算法生成可行的构形序列，然后按照序列的时间步顺序，从前向后，依次将前后相邻的两个构形节点用于对神经网络的回归训练。前边的构形节点作为神经网络输入的当前构形，后边的构形节点作为目标构形，与神经网络预测输出的相邻构形做均方误差 MSE，然后让均方误差最小，对神经网络的参数使用反向传播算法进行梯度下降。

中国知网 https://www.cnki.net

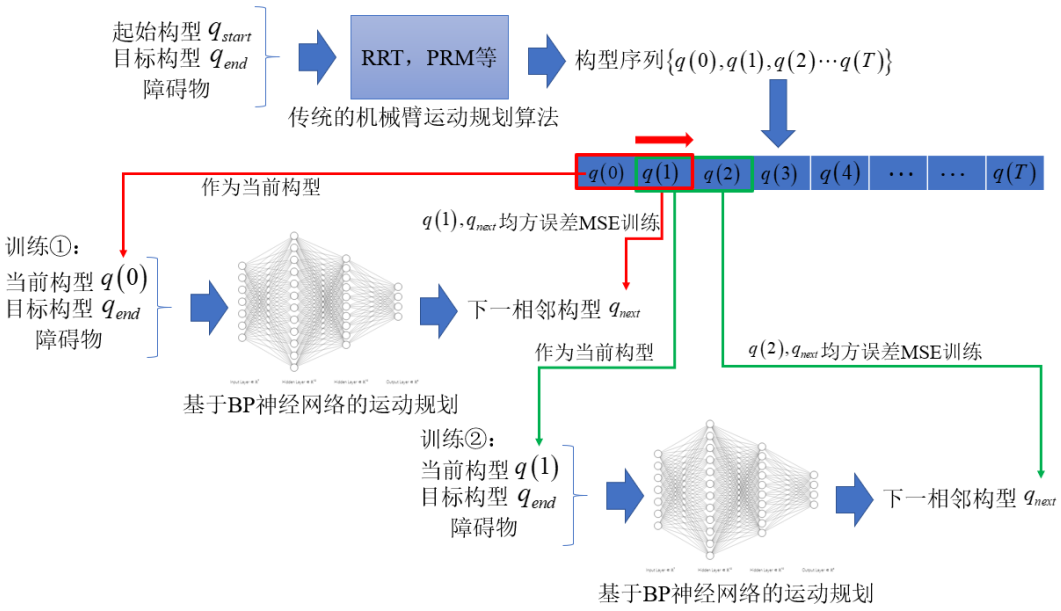


图 3.8 用于机械臂运动规划的 BP 神经网络训练过程

Fig. 3.8 Training process of BP neural network for robotic arm motion planning

3.2.3 障碍物抽象特征

工作空间的障碍物是输入规划算法的重要特征。在 6 自由度机械臂的 6 维构形空间构建从工作空间到构形空间的映射需要消耗非常大的计算能力。在 PRM 和 RRT 等基于采样的运动规划算法中一个重要优点就是不需要构建这种复杂的映射关系。它们在构形空间做规划，当需要检测是否在工作空间发生碰撞时，只需要将构形空间的点通过机械臂正运动学转换到工作空间然后进行碰撞检测。

对于输入到 BP 神经网络的障碍物特征，本文提出了一种将障碍物简化抽象为球体的特征简化方法。将球体的 3 个位置坐标值和半径作为障碍物的特征值输入到神经网络中。如图 3.9 所示为将一个易拉罐障碍物抽象为球体障碍物的过程。

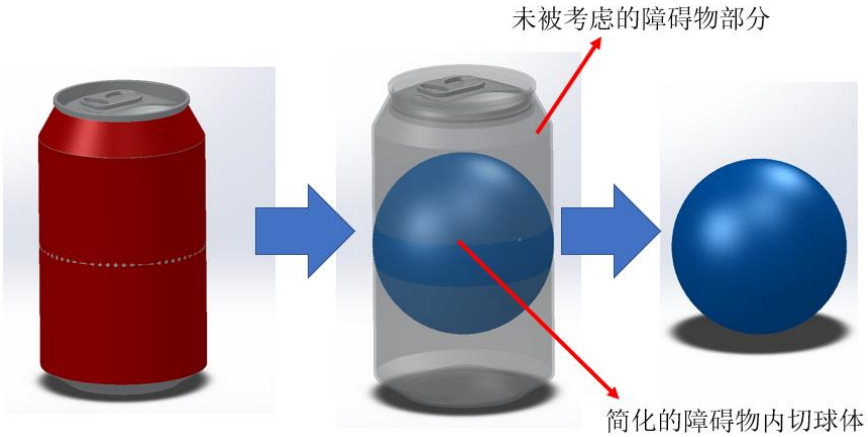


图 3.9 将一个易拉罐障碍物抽象为球体障碍物的过程

Fig. 3.9 The process of abstracting a can obstacle into a spherical obstacle

中国知网 https://www.cnki.net

所抽象出的障碍物球体并非实际障碍物的外接球体，而是全部位于障碍物内部的内切球体。显然这样的障碍物抽象近似方法会导致球体外部的一部分障碍物实际上没有被考虑，但是这种简化机械臂运动规划障碍物的方法能够非常方便地将障碍物特征快速数值化，然后输入给神经网络进行训练。

本文所提出的残差强化学习运动规划方法让 BP 神经网络构成的初始策略来引导由改进 PPO 强化学习算法构成的残差策略向正确的方向训练。因此，如果在神经网络运动规划初始策略部分所简化的障碍物模型存在着未被考虑的部分，则可以由强化学习部分的残差策略在其训练的“试错”过程中予以补充。综上所述，虽然在初始策略所采用的障碍物简化方法存在对障碍物实际形体描述的误差，但是这些误差会在与强化学习部分的残差策略联合训练时被予以考虑和补充，从而保证最终的总策略输出能够解决机械臂的运动规划任务。

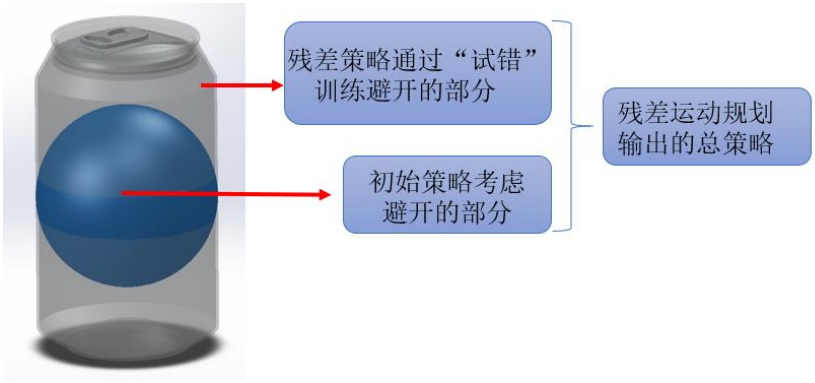


图 3.10 初始策略与残差策略对于障碍物不同部分的作用

Fig. 3.10 The effect of initial policy and residual policy on different parts of obstacles

如果实际障碍物与所简化出的球体障碍物相差很大，则需要强化学习部分进行试错和探索从而避开的障碍物部分就会很大。这种情况下，强化学习部分的残差策略仍然可能会出现前述的训练困难问题。针对实际障碍物与所简化出的球体障碍物相差很大的情况，本文在第 4 章当中提出了一种基于课程强化学习的障碍物自适应训练方法。

3.2.4 用于生成训练神经网络用构形序列的传统运动规划算法

针对 BP 神经网络运动规划初始策略方法，需要一种传统运动规划算法来生成训练数据，用于训练神经网络。基于采样的算法是在近年来用于解决机械臂高维空间运动规划问题的最常用方法。这种类型的运动规划算法只需要从机械臂的构形空间随机采样，并且无需在构形空间耗费大量的运算量来构建工作空间中障碍物的映射。

快速搜索随机树(Rapidly-exploring random tree, RRT)算法是一种基于随机采样

中国知网 https://www.cnki.net

的运动规划算法。RRT 算法通过随机在构形空间选点并按照算法原则向外逐渐扩展路径从而最终找到构形空间中连接起点到终点的一条路径。对于障碍物的处理，RRT 算法将构形空间中规划得到的点通过正运动学映射到机械臂的工作空间并检测是否发生碰撞，从而避免了在构形空间建立障碍物模型的大量运算过程。

原始的 RRT 算法也有一些缺点。RRT 算法是完备的，但是其规划出的路径具有随机性，每次规划所得到的路径都不相同且无法保证最优。围绕着 RRT 算法，近年来出现了很多改进算法，RRT*算法就极大提高了 RRT 算法的性能。在 RRT*算法中，随着采样点数的增加同时修整原有的路径节点。如果采样点数量足够多，则能够收敛到最优解，因此 RRT*算法是渐进最优的。本文采用 RRT*算法来生成神经网络训练时的规划演示数据。

（1） RRT 算法

RRT 算法按照下述的过程进行：

①初始化一个随机树结构 T。

②在机械臂的构形空间随机采样一个点a

机械臂构形空间中的一个点代表了一组关节角度值构成的向量，向量的维度与机械臂自由度数目相等。如图 3.11 所示为 2 自由度机械臂的工作空间和构形空间，其构形空间的坐标轴对应于机械臂的每一个自由度，机械臂的每一组关节角度值都对应于构形空间的一个点。图 3.11 右图中构形空间的阴影部分代表左图中工作空间的障碍物在其中的映射。对于 6 自由度机械臂，在构形空间采样得到的是 6 维空间当中的点$a\left(\theta_1,\theta_2,\theta_3,\theta_4,\theta_5,\theta_6\right)$。

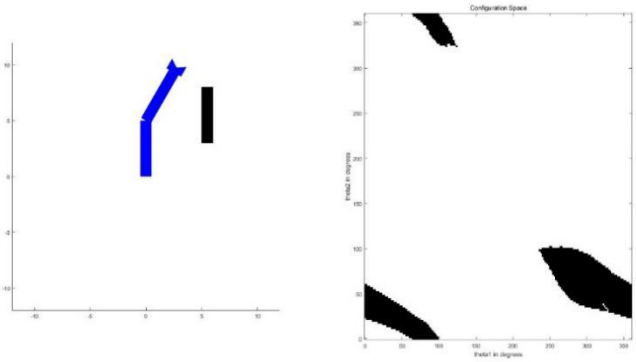


图 3.11 2 自由度机械臂的工作空间和构形空间

Fig. 3.11 The working space and configuration space of the 2 degree of freedom robotic arm

③搜索构形空间中与随机采样节点a最近的节点

在已知的搜索树 T 的所有节点中，搜索与采样所得到节点距离最近的节点，所依据的距离为两个节点在高维空间中的欧氏距离。如图 3.12 所示，搜索树上最近节点为a_{nearest}。

中国知网 https://www.cnki.net

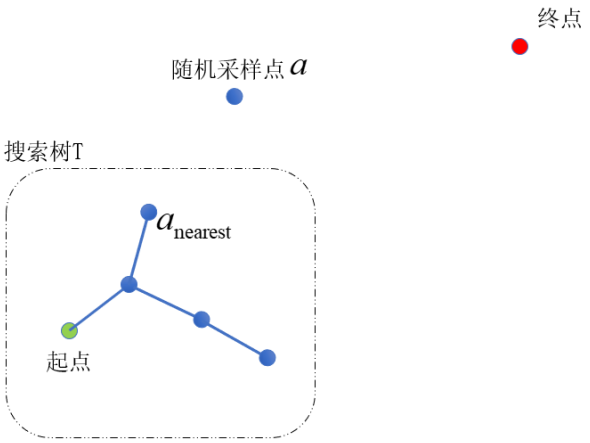


图 3.12 构形空间中与随机采样节点 a 最近的节点

Fig. 3.12 The node closest to the randomly sampled node in the configuration space

④生成新的树节点

连接随机采样得到的节点 a 和树上的节点 a_{nearest}，从搜索树上的节点 a_{nearest} 沿着连接两个节点的直线段向节点 a 方向向前按照固定步长 step 移动一步，得到新的节点 a_{new}。该过程如图 3.13 所示。

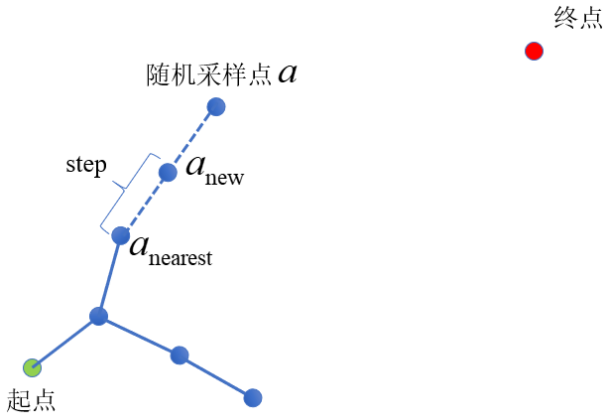


图 3.13 连接随机采样得到的节点和找到的搜索树上的节点

Fig. 3.13 Connect randomly sampled nodes and found nodes on the search tree

⑤检测碰撞

检测从节点 a_{nearest} 到节点 a_{new} 之间的路径是否与工作空间当中的障碍物发生碰撞。对于机械臂而言，检测的是机械臂从关节角度 $a_{\text{nearest}}\left(\theta_1,\theta_2,\theta_3,\theta_4,\theta_5,\theta_6\right)$ 运动到 $a_{\text{new}}\left(\theta_1,\theta_2,\theta_3,\theta_4,\theta_5,\theta_6\right)$ 的过程中与障碍物是否发生碰撞。在直线段 $\overline{a_{\text{nearest}}a_{\text{new}}}$ 上均匀等间距采样若干个点，分别对这些关节角度值应用机械臂的正运动学，把它们映射到工作空间，然后判断各个点在工作空间与障碍物是否发生碰撞，如果其中有一个点发生碰撞，判断为从节点 a_{nearest} 到节点 a_{new} 之间发生碰撞，则需要重新进行之前的步骤重新采样。

中国知网 https://www.cnki.net

⑥将新的边加入到树结构中

如图 3.14 所示，将新的节点 a_{new} 和连接节点 $a_{nearest}$ 到节点 a_{new} 之间的线段 $\overline{a_{nearest}a_{new}}$ 加入到搜索树 T 的机构中。

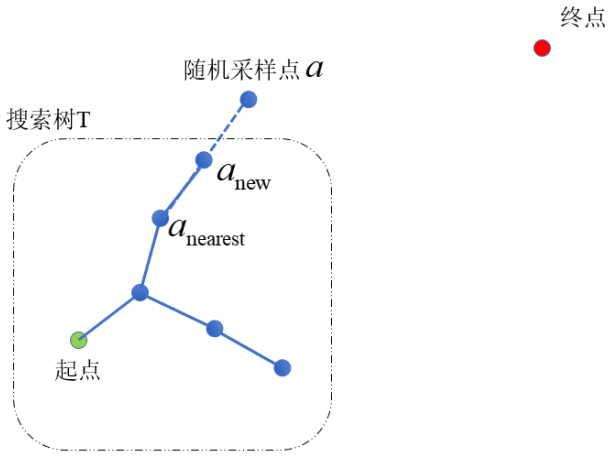


图 3.14 将连接节点得到的新线段加入到搜索树 T 中

Fig. 3.14 Add the new line segment obtained by connecting the nodes to the search tree T

⑦重复上述过程

重复不断的进行上述过程，不断扩展搜索树 T 的节点和边。如果新得到的节点 a_{new} 与终点 a_{goal} 之间的距离小于阈值 ε，即 $\|a_{new}-a_{goal}\|\le\varepsilon$，则认为已经成功找到一条从起点到终点的路径。如图 3.15 所示，搜索树 T 上的红色边组成的就是找到的规划路径。

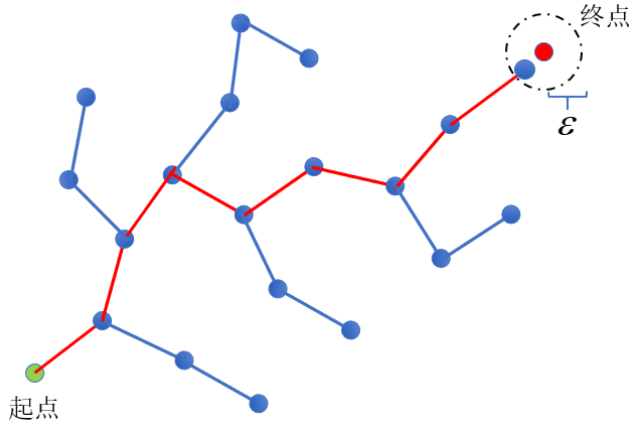


图 3.15 搜索树 T 上的红色边组成的就是所找到的规划路径

Fig. 3.15 The red edges on the search tree T consist of the planned path found

RRT 算法的总体流程如图 3.16 所示。

中国知网 https://www.cnki.net

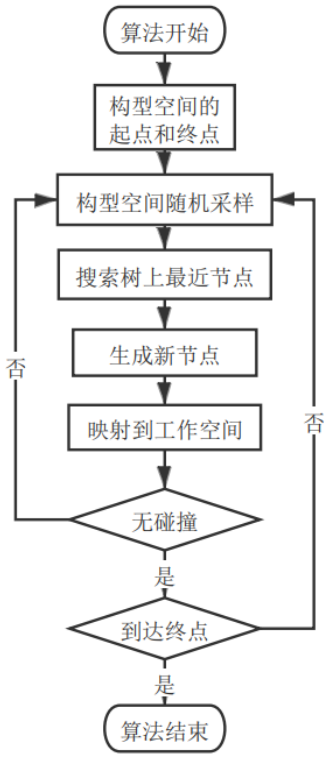


图 3.16 RRT 算法的总体流程图

Fig. 3.16 Overall flow chart of RRT algorithm

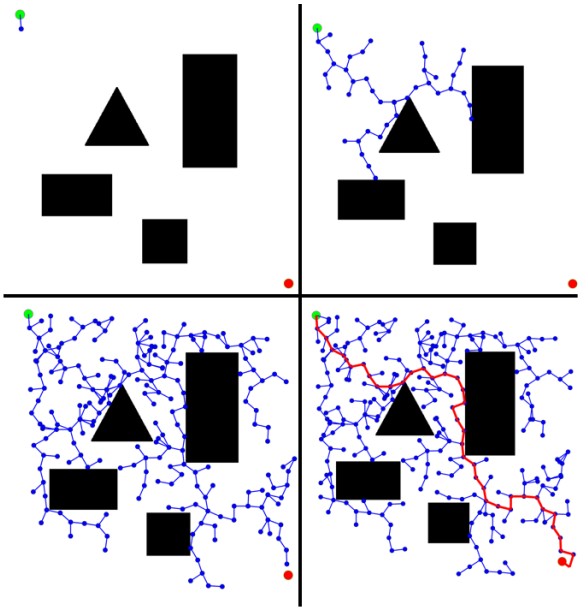


图 3.17 RRT 算法在 2 维构形空间中的应用效果

Fig. 3.17 The application effect of RRT algorithm in 2-dimensional configuration space

图 3.17 所示为 RRT 算法在 2 维构形空间中的应用效果，图中的黑色物体表示构形空间的障碍物，可以看出 RRT 算法生长的搜索树随着采样点数的增加而不断增长，最终得到一条由起点经过搜索树边和节点到达目标点的路径。

中国知网 https://www.cnki.net

（2） RRT*算法

RRT*算法对 RRT 算法进行了改进。在保证算法完备性的同时，RRT*算法是一种渐进最优的算法。

RRT*算法的流程与 RRT 基本一致，但是增加了几个额外的算法过程：

①在 RRT 算法的步骤 4 处，通过随机采样得到节点 a，并找到搜索树上距离 a 最近的节点 a_{nearest}，连接它们并从 a_{nearest} 节点向着 a 节点运动一个 *step* 步长，得到 a_{new} 节点并检测从 a_{nearest} 到 a_{new} 之间无碰撞之后，以节点 a_{new} 为中心，r 为半径做圆形搜索范围，找到所有包含在其中搜索树上已有的节点集合 a_{near}，$\left\{a_i \in a_{near} \,|\, \|a_{\text{new}} - a_i\| \le r\right\}$。如图 3.18 所示，图中的节点 $a_1a_2a_3$ 为搜索到的树上节点。

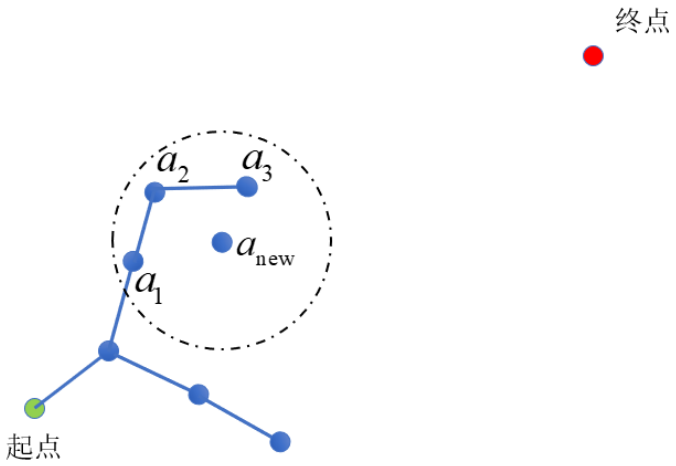


图 3.18 虚线内节点为搜索到的树上节点

Fig. 3.18 The nodes in the dotted line are the nodes on the searched tree

②将从起点 a_{start} 到某节点 a_i 的代价记作 $C(a_i)$，那么搜索树上的每一个节点都有一个对应的代价值。再将搜索树上从节点 a_i 到节点 a_j 的路径代价记作 $c(a_i, a_j)$，如果 a_i 自 a_j 生长而来，则节点 a_i 的代价为 $C(a_i) = C(a_j) + c(a_i, a_j)$。在实际计算中，对于机械臂而言，从其构形空间的节点 a_i 到节点 a_j 的代价可以定量的表示为从关节角度 $a_i(\theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6)$ 运动到 $a_j(\theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6)$ 的过程中，各个关节运动角度的总和，即 $c(a_i, a_j) = \sum_{k=1}^{6} \Delta\theta_k$。

③对于搜索到的点集 $\left\{a_i \in a_{near} \,|\, \|a_{\text{new}} - a_i\| \le r\right\}$ 中的每一个节点，计算节点 a_{new} 分别以它们为父节点并连通到起始节点的代价值 $C(a_{new}) = C(a_i) + c(a_i, a_{new})$，然后选择其中代价值最小的节点，作为 a_{new} 真正的父节点，并连通它们。如图 3.19 所示，节点 a_1 被选择为新生成节点 a_{new} 的父节点，并连通 a_1 和 a_{new}。

中国知网 https://www.cnki.net

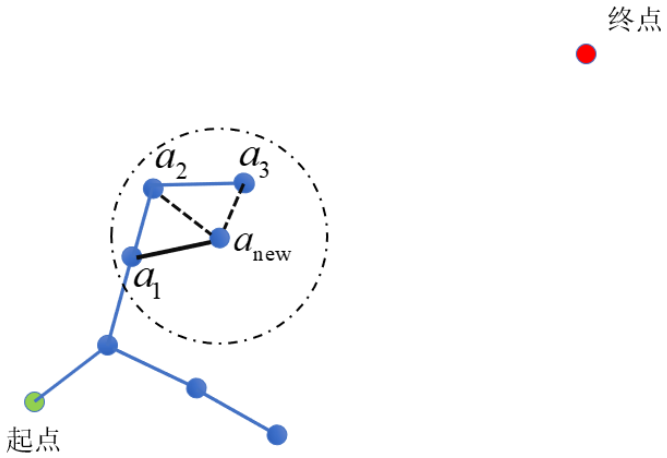


图 3.19 选取出新的父节点

Fig. 3.19 Select a new parent node

④遍历搜索到的点集$\{a_i \in a_{near} \mid \|a_{\text{new}} - a_i\| \le r\}$中每一个节点，如果它们与新加入的节点$a_{\text{new}}$之间可以连通，且$a_{\text{new}}$的代价$C(a_{new})$加上$a_i$和$a_{\text{new}}$之间的代价$c(a_i, a_{new})$小于原来$a_i$的代价$C(a_i)$，则断开原来与$a_i$的父节点，以新的$a_{\text{new}}$作为父节点。这一操作相当于在采样得到新的搜索树节点后对原有路径进行修改，从而保证局部最优。如图 3.20 所示，原有的连接节点a_2a_3的边被从搜索树上删去，然后连接a_{new}和a_3构造新的搜索树边，保证了节点a_3代价最小。

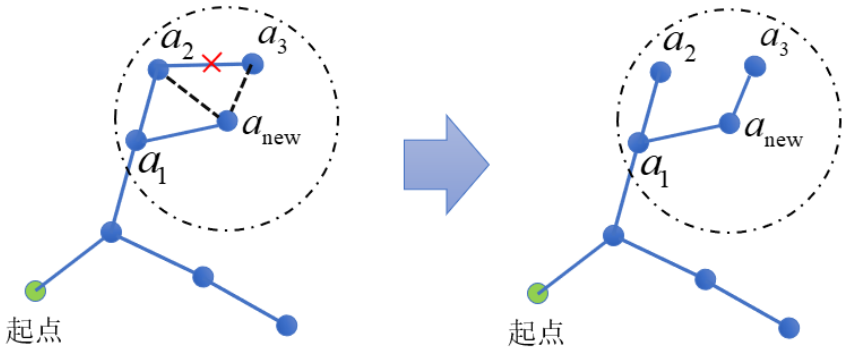


图 3.20 RRT*算法构造新的最短路径过程

Fig. 3.20 RRT* algorithm constructs a new shortest path process

RRT*算法通过给采样得到的新节点依据代价选择父节点，以及按照代价重新构建搜索树的边，这两个主要的算法机制，使该算法具有渐进最优性质。如图 3.21 所示为 RRT*算法的流程图。

中国知网 https://www.cnki.net

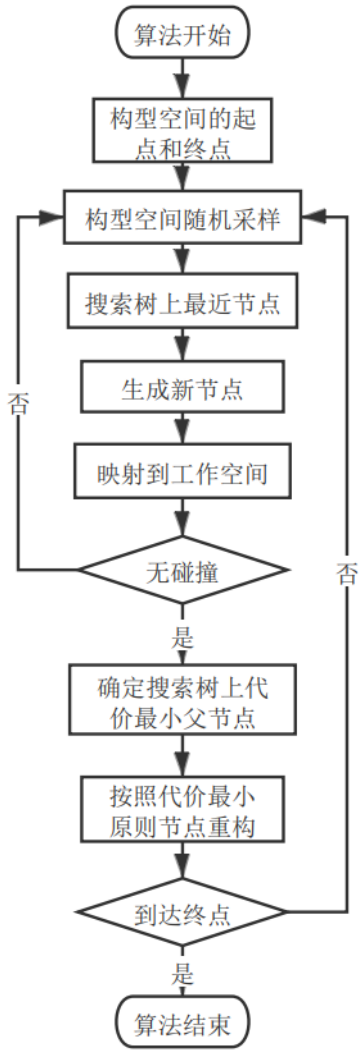


图 3.21 RRT*算法的流程图

Fig. 3.21 Flow chart of RRT* algorithm

在 2 维构形空间应用 RRT*算法的效果如图 3.22 所示，图中蓝色边为第一次生成的搜索树结构，绿色边为后续优化过程中节点重构后的搜索树结构，并且在最初第一次搜索到一条路径以后，随着算法的继续，路径被不停的修改并且趋于最优。

中国知网 https://www.cnki.net

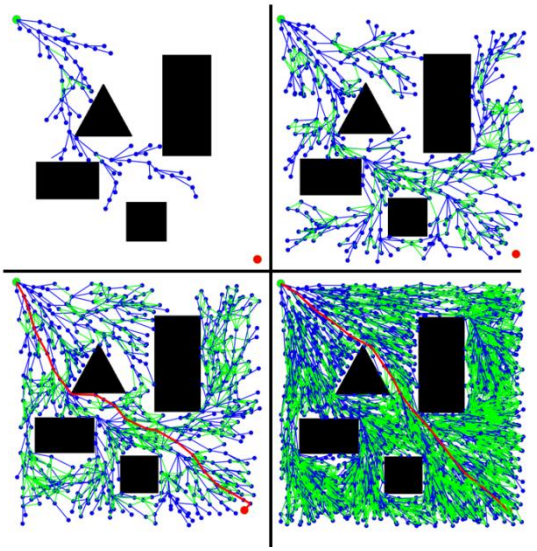


图 3.22 在 2 维构形空间应用 RRT*算法的效果

Fig. 3.22 The effect of applying RRT* algorithm in 2D configuration space

图 3.23 所示为在 3 维构形空间当中应用 RRT*算法，图中 3 维空间中的圆球体表示构形空间的障碍物。

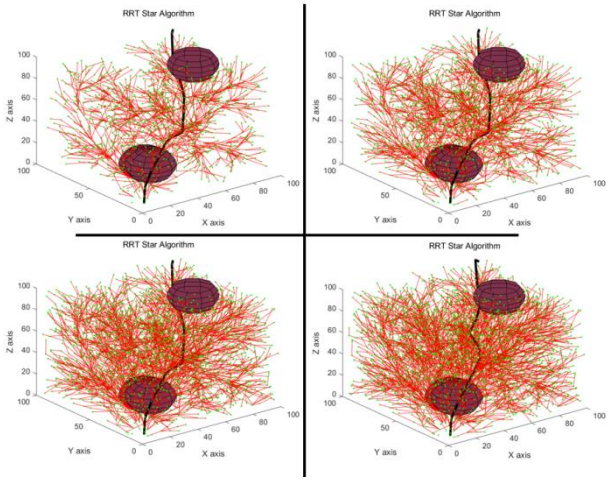


图 3.23 在 3 维的构形空间当中应用 RRT*算法

Fig. 3.23 Apply RRT* algorithm in 3D configuration space

本文采用 RRT*算法生成用于训练 BP 神经网络所需的构形序列数据。

3.2.5 神经网络模型构建与训练

（1）神经网络模型构建

初始策略所采用的 BP 神经网络结构如图 3.24 所示，通常情况下神经网络采用 2 个隐含层就能够达到比较好的训练效果，但是考虑到运动规划拟合的复杂性，为了增大网络的非线性拟合能力，本文采用了 3 个隐含层的神经网络。在本文的

中国知网 https://www.cnki.net

实验环境中，设置了 3 个障碍物抽象球体，因此障碍物部分输入网络的特征值个数为 12 个，再加上输入的当前构形与目标构形，总共输入的特征值个数为 24 个。如果所抽象的障碍物球体数量增大，则应当相应增加用于训练的神经网络的复杂程度，包括增加隐含层数与增加隐含层包含的神经元个数。

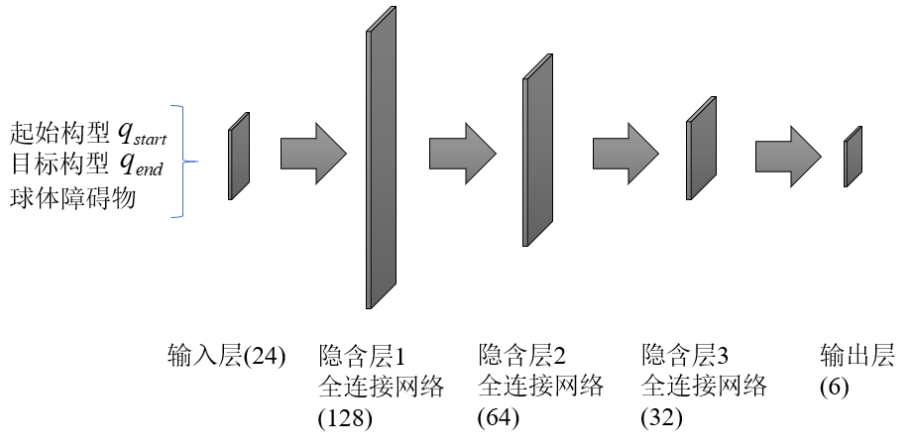


图 3.24 所采用的 BP 神经网络结构

Fig. 3.24 BP neural network structure used

隐含层 1 包含 128 个神经元，隐含层 2 包含 64 个神经元，隐含层 3 包含 32 个神经元。

输出层之前的层全部采用 ReLu 激活函数，输出层采用线性激活函数 pureline 输出。训练所采用的 loss 误差函数为均方误差 MSE 函数：

$$Loss = \frac{1}{m}\frac{1}{n}\sum_{i=1}^{m}\sum_{k=1}^{n}\left(q_i^k - q_i^k\right)^2 \tag{3.4}$$

式(3.4)中，m 为神经网络的输出值数目，n 为训练样本的数目，q_i^k 为神经网络所输出的下一个构形值，q_i^k 为 RRT*算法生成的序列中对应的实际当中下一个构形值。

（2）防止过拟合

当神经网络的层数与神经元个数增加时，神经网络的非线性拟合能力将得到增强，但是随之而来的副作用就是实际参与训练的网络参数个数的增加，参数个数的增加有可能会导致过拟合(Overfitting)[108, 109]现象。

中国知网 https://www.cnki.net

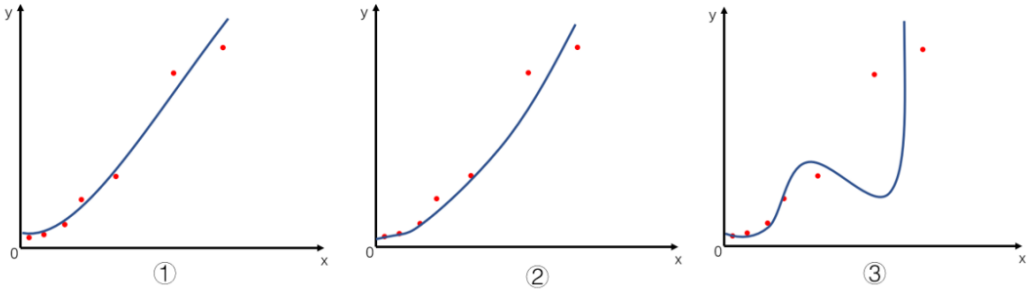


图 3.25 多项式曲线对离散坐标点的拟合

Fig. 3.25 The fitting of polynomial curve to discrete coordinate points

如图 3.25 所示，用多项式曲线拟合离散点的过程来说明过拟合现象发生的原因。使用一个高次多项式来拟合这些离散的坐标点。

图 3.25 中①用 2 次多项式拟合：

$$y = a + w_1 x + w_2 x^2 \tag{3.5}$$

图 3.25 中②用 3 次多项式拟合：

$$y = a + w_1 x + w_2 x^2 + w_3 x^3 \tag{3.6}$$

图 3.25 中③用 5 次多项式拟合：

$$y = a + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + w_5 x^5 \tag{3.7}$$

可以看出②在增加多项式的次数时，即增加用于拟合多项式的参数之后，拟合得到的曲线更为贴切。但是③由于引入了过多的多项式参数，虽然拟合能力比①和②强，但是很容易产生过度的拟合，反而使得最终得到的拟合曲线与真实的数据变化趋势相差甚远。给神经网络引入比较多的神经元和层数以后容易出现类似于上述多项式引入更多参数后容易发生过拟合的现象。一旦发生过拟合现象，神经网络在训练数据集上表现良好，但是真实使用后，将出现非常大的误差。

为了防止神经网络在训练中出现过拟合现象，本文在神经网络的隐含层采用 Dropout 方法[108]。Dropout 方法是学者 Hinton 等在 2012 年提出的一种在训练复杂前馈神经网络时防止过拟合发生的方法。具体的做法就是在每次进行神经网络训练时，隐含层中的神经元都有一定的概率 p 发生消失，原本完整的神经网络将变成一个丢失了一部分神经元的不完整网络，然后直接用这个不完整网络进行正常的训练。如图 3.26 所示，一个 3 层的神经网络中间的 1 个隐含层所有的神经元按照某个固定的概率 p 发生失效。

在使用 Dropout 方法训练防止神经网络过拟合的发生时，需要将训练所需要使用的数据分成小组，然后将每个小组用于训练不同 Dropout 结果后的神经网络。在使用神经网络进行测试时，则需要使用不进行 Dropout 时的全部神经元，并且需要

中国知网 https://www.cnki.net

将所有已经训练完成的权值乘以系数$1-p$。

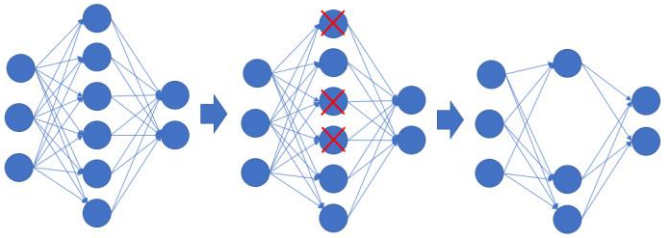


图 3.26 3 层的神经网络中间的 1 个隐含层所有的神经元按照某个固定的概率发生失效

Fig. 3.26 All neurons in a hidden layer in the middle of the 3-layer neural network fail according to a fixed probability

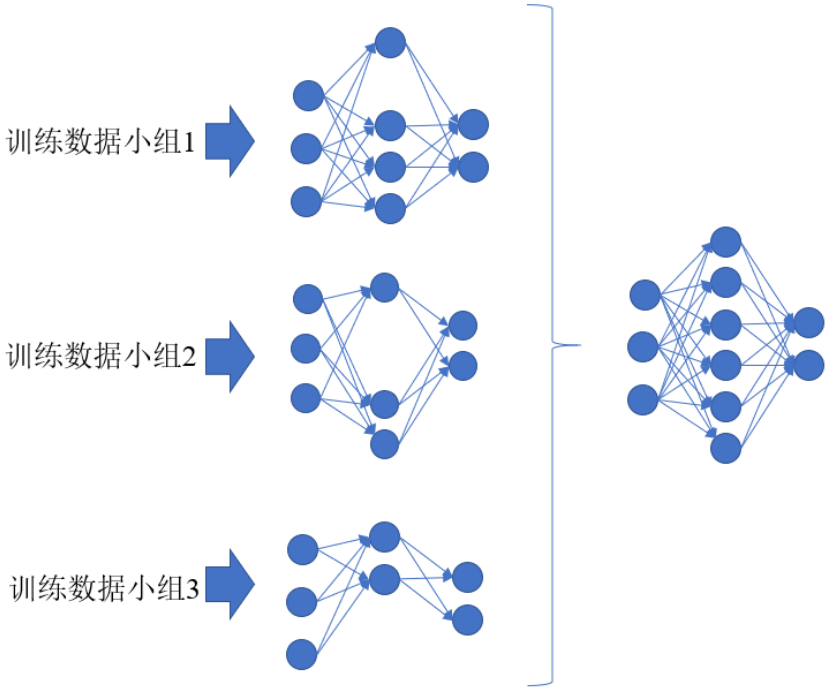


图 3.27 分小组训练 Dropout 神经网络

Fig. 3.27 Train the Dropout neural network in small groups

Dropout 方法相当于将一个神经网络分成多种不同结构的网络，然后用同样的方式去训练，得到几个不同输出，然后将输出做了平均效果，不同的网络产生了不同的过拟合程度，将它们平均的结果就是过拟合相互抵消。

（3）切断数据间相关性

除了过拟合问题之外，训练神经网络时还应当注意切断训练数据之间的相关性问题。最终训练的神经网络需要根据当前的构形、目标构形和抽象障碍物特征来输出与当前构形相邻的下一个预测构形。如果每次训练输入给神经网络的数据都是同一个轨迹当中相邻顺序的构形，这些构形之间就会有相关性与连续性，用这样的数据训练神经网络会影响网络的泛化能力。因此，应当在采集足够的 RRT*算法生成构形轨迹后，将这些轨迹当中的相邻构形，目标构形，以及障碍物特征，按照

中国知网 https://www.cnki.net

如下的结构构成训练用向量数组：

[当前构形，目标构形，障碍物特征，下一个构形]

将所有这些数据构成的数组打乱顺序，再分成训练用数据小组，每次对网络进行训练都使用一个训练小组的数据。本文取训练小组大小为 30。

（4）归一化处理

数据的数值较大，因此需要对输入 BP 神经网络的数据进行 Min-max 归一化处理，将数据数值限制到[0,1]范围内。

3.3 基于改进 PPO 算法的残差策略

近端策略优化算法(PPO)属于在轨策略算法，每次采样一定数量的样本，然后在保证 KL 散度约束的条件下，对行为策略神经网络进行一定次数的训练更新，然后丢弃本次采样数据重新采样，再次继续上述的过程。算法的采样数据利用率比较低，并且 PPO 算法的 Critic 网络仅估计当前的状态价值函数，然后依靠从当前时刻到最终时刻的折扣总收益来估计优势函数值，这种方法估计出的优势函数值随机性很大。

针对传统 PPO 算法的采样效率问题，并且为了使 PPO 算法能够作为本章所提出残差强化学习运动规划方法中的残差策略，本节对 PPO 算法进行了一些改进，提出了改进 PPO 算法。

3.3.1 Critic 部分优势函数的随机性问题

PPO 算法采用了强化学习中经典的 Actor-Critic 算法架构。其中的 Critic 神经网络部分负责估计优势函数：

$$\begin{aligned} &R^{\lambda'}\left(s_{step},a_{step}\right)=A^{\lambda'}\left(s_{step},a_{step}\right)\\ &=\sum\nolimits_{step'>step}\gamma^{step'-step}\mathrm{r}_{step'}-V\left(s_{step}\right)\end{aligned} \tag{3.8}$$

式(3.8)中的 $\sum_{step'>step}\gamma^{step'-step}\mathrm{r}_{step'}$ 项表示从当前时间步之后所有的奖励在考虑折扣率情况下的总和。

$\sum_{step'>step}\gamma^{step'-step}\mathrm{r}_{step'}$ 项必须在一个回合结束以后才能够得到，并且多次采样最终得到的总收益值会受采样过程中方差的影响而产生一定的随机性。在这种情况下，需要采样的数量足够多，$\sum_{step'>step}\gamma^{step'-step}\mathrm{r}_{step'}$ 才能够收敛到准确期望值附近。

采样的随机性导致最终得到的优势函数无法很好的估计真实值，针对这一问题，本文将泛化优势估计方法(Generalized Advantage Estimation)[110]引入到优势函

中国知网 https://www.cnki.net

数的估计中。把 $R^{\lambda'}\left(s_{step},a_{step}\right)$ 部分抽象为用行为价值函数表示的优势函数：

$$\begin{aligned} R^{\lambda'}\left(s_{step},a_{step}\right)&=A^{\lambda'}\left(s_{step},a_{step}\right)\\ &=Q\left(s_{step},a_{step}\right)-V\left(s_{step}\right)\end{aligned} \tag{3.9}$$

Critic 部分的神经网络负责估计 $\mathrm{Q}\left(s_{step},a_{step}\right)$ 和 $V\left(s_{step}\right)$。此时需要估计两种价值函数，不易操作，因此进一步修改优势函数为：

$$R\left(\alpha\right)=\mathrm{r}_{step}+\gamma V\left(s_{step+1}\right)-V\left(s_{step}\right) \tag{3.10}$$

此时 Critic 部分只需要负责估计当前状态所对应的状态价值 $V\left(s_{step}\right)$ 和下一个状态所对应的状态价值 $V\left(s_{step+1}\right)$。改进后的优势函数估计方法实际上进行了单步采样，把当前的动作状态价值函数 $\mathrm{Q}\left(s_{step},a_{step}\right)$ 通过单次采样更新为 $\mathrm{r}_{step}+\gamma V\left(s_{step+1}\right)$，其中参数 γ 为奖励折扣系数。虽然单次采样依旧会产生一定的随机性，但是相比于 $\sum_{step'>step}\gamma^{step'-step}\mathrm{r}_{step'}$ 多次采样的随机性，单次采样随机性要小得多。

改写优势函数之后，Critic 网络的作用与训练过程就与 DQN 算法完全类似，需要令时序差分误差(TD-error)最小化，即让估计的当前状态价值函数值 $V\left(s_{step}\right)$ 与预测的当前状态价值函数值 $\mathrm{r}_{step}+V\left(s_{step+1}\right)$ 之间的均方误差最小化。与 DQN 方法中需要引入另一个目标网络来估计下一个状态 Q 值的原因类似，如果仅使用一个 Critic 网络将导致估计的下一个状态的 $V\left(s_{step+1}\right)$ 值一直处于变化中，对训练产生很大干扰，算法不易收敛。因此需要仿照 DQN 算法的机制为 PPO 算法引入两个 Critic 网络，一个网络是现实 Critic 网络，用于估计当前状态所对应的状态价值函数值，另一个网络是目标 Critic 网络，用于估计下一个状态所对应的状态价值函数值，目标 Critic 网络先在训练中保持不变，经过若干次训练后，再逐步将现实网络中的参数更新到目标网络中。该过程如图 3.28 所示。

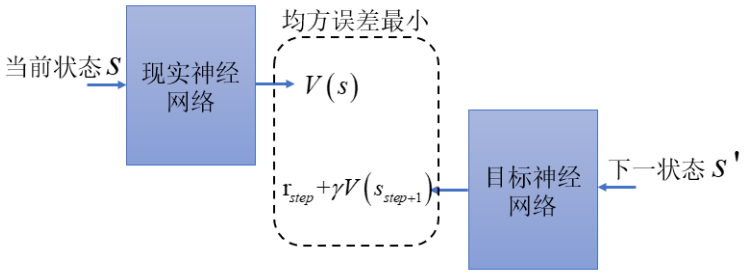


图 3.28 现实神经网络与目标神经网络的训练过程

Fig. 3.28 The training process of realistic neural network and target neural network

中国知网 https://www.cnki.net

3.3.2 引入经验池机制

在 DDPG 算法与 DQN 算法中都有经验池机制参与训练，智能体每次与环境进行互动所得到的一条经验(s,a,r,s')都保存到经验池中，在进行训练时，随机的从经验池中抽取一个小组大小的经验条目来对网络进行优化训练。该方式实际上模仿了人类在处理任务时往往会把原来脑海中保存下来的完成相同任务的经验再次利用的过程。这种方式对采样的利用效率很高，并且由于每次训练都是从经验池中随机采样，从而切断了连续采样过程中相邻采样条目之间的相关性。

DDPG 算法与 DQN 算法能够采用经验池机制的本质原因在于它们都属于离轨策略(Off-Policy)，也就是说它们进行采样的策略与使用采样样本进行更新的策略是不同的。对于策略梯度(PG)算法而言，由于它本质属于在轨策略(On-Policy)，无法使用这种离轨策略机制，因此 PG 算法是采样利用效率最低的，每次采样都只能够用于训练一次，然后这些采样就完全失效，需要重新采样进行后续的训练。而对于 PPO 算法，它在单纯的 PG 算法基础上引入了重要性采样机制，使得从旧的策略进行采样所得到的经验能够在保证散度 KL 约束的前提下被用于更新原有策略多次。但是其样本利用效率仍然不高。

本文将经验池机制引入到原始 PPO 算法，同样在必须满足重要性采样原理当中 KL 散度约束条件的前提下，设置一个比 DDPG 当中经验池要小的小型经验池，然后从小型经验池中采样小组数据用于 Actor 策略网络的训练。

本文提出增加小型经验池机制后的 PPO 算法同样需要引入两个 Actor 网络，一个现实 Actor 网络用于最新的策略训练以及估计最新的行为概率分布，另一个目标 Actor 网络则在一个阶段的训练过程中保持不变，目标 Actor 网络用于保存旧策略以及估计旧采样策略的行为概率分布。用两个 Actor 网络在每次采样后的行为概率分布之商来计算 PPO 算法中的重要性采样值。当采集到的一个小型经验池训练使用完毕后，更新现实 Actor 网络的参数值给目标 Actor 网络。

3.3.3 引入优先经验回放机制

从小型经验池抽取训练用小组数据时，一般采用随机抽取的方式，这种采样方式对于经验池中所有的数据都一视同仁，它们有相等的被抽取概率，这将导致重要的经验条目和不重要的经验条目在训练时没有优先级区别。经验池机制来源于人类的经验记忆，但是对于人类而言，记忆是有重要性等级的，有些记忆经验是非常重要的，有些则并不是那么重要。同样的原理，在经验池中抽取训练用数据时，也可以引入优先级，对于重要的经验条目，需要增大它被抽取到的概率，而对于不重要的经验条目，则减小它被抽取到的概率。例如，在机械臂的强化学习智能体训练时，机械臂能够成功完成任务的经验条目数量是比较少的，而大多数经验条目都是

中国知网 https://www.cnki.net

在进行试错时采集到的，如果采用均匀概率来进行随机抽取，那么数量较少的成功样本就很难被采集到。在实际训练时，这些数量较少的成功经验条目对于机械臂的强化学习训练起到了非常重要的引导性作用。

针对上述的经验条目随机抽取问题，本文将优先级采样方法引入到改进 PPO 算法的小型经验池中。目的是将经验池中的条目按照优先级进行区分，让重要的经验被抽取的概率比较大，通过这种方法来加快 PPO 算法收敛过程。本文用每个经验条目的时序差分误差值来表示其优先级。改进 PPO 算法的 Critic 部分现实网络和目标网络进行训练时所获得的 $r_{step}+\gamma V\left(s_{step+1}\right)-V\left(s_{step}\right)$ 即为时序差分误差值，这个误差值越大表示所训练的 Critic 部分神经网络预测准确性还有较多的提高空间，相应经验条目就更加需要被尽量多“学习”。因此，将经验条目样本的时序差分误差作为优先权值，误差越大对应的优先权值也越大，该经验条目被抽取到的概率也就越大。

样本的优先级权值与其被抽取到的概率之间的关系公式为：

$$P_i=\frac{p_i^{\lambda}}{\sum_{j=1}^{n}p_j^{\lambda}} \tag{3.11}$$

式(3.11)中，P_i 表示经验池中第 i 条经验被抽样到的概率，p_i^{λ} 表示第 i 条经验的优先级权值，$\sum_{j=1}^{n}p_j^{\lambda}$ 表示经验池中所有条目优先级权值的和，n 表示经验池中经验条目的总数目，λ 是一个调整优先经验回放机制对于样本抽取影响程度大小的参数，当 λ 为 0 时，完全不采用优先经验回放机制，各个样本等概率被抽取，λ 参数越大在抽取过程中优先经验回放机制起到的作用就越大。

在引入优先经验回放之前，经验池中所存储的一条采样经验为：(s,a,r,s')，引入优先经验回放机制需要给每一条采样经验加入优先级权值项：(s,a,r,s',p)，然后在每次从经验池中抽取训练用经验条目时按照与优先级权值呈正相关的概率来进行抽取。在实际优先经验回放的操作过程中，如何按照经验池中每条样本的优先级权值对应不同概率进行抽取同样是一个问题。

本文利用 SumTree[111]数据结构来进行经验条目的优先级权值排序和抽取。SumTree 是一种树型结构的数据存储方式。树的最底层叶子节点保存的是经验池中的所有条目，每一个最底层叶子节点都对应一个条目的数据。从最底层向上，每两个叶子节点的数值加和得到它们的父节点，按照这种两两子节点数值加和的方式持续进行下去，直到树结构的最顶层只有一个父节点。此时最顶层的父节点数值为最底层所有叶子节点条目数值之和。

中国知网 https://www.cnki.net

将每条经验条目作为 SumTree 树结构最底层叶子节点，然后向上计算两两经验条目优先级数值之和从而构建整个树的数据结构。此时，按照优先级权值所决定的概率抽取样本的过程就变为：在树结构最顶层父节点数值的一个范围内，采用均匀采样的方法随机选择一个数值 p_1，然后从顶层父节点依次按照从上到下且从左到右的顺序将数值 p_1 与下级的叶子节点数值进行搜索比较。如果 p_1 小于等于所搜索的左侧子节点数值，则保持 p_1 的值不变，继续向下遍历左侧子节点；如果 p_1 大于所搜索的左侧子节点数值，则将 p_1 减去左侧子节点数值后的值赋值给 p_1，并且向右侧子节点方向继续遍历，直到遍历过程持续到树结构的最底层，最后所选择的最底层叶子节点就是选出的经验条目。

举例来说明上述的 SumTree 树结构原理。如图 3.29 所示，是一个有 8 个最底层叶子节点的树结构，每一个最底层叶子节点都代表了经验池中的一个条目，而其中的数值代表了它们各自的优先级权值，权值越大该叶节点所代表的经验条目被选中的概率也就越大。

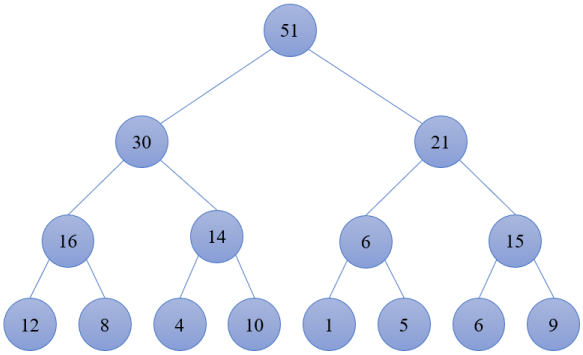


图 3.29 一个最底层有 8 个叶子节点的树结构

Fig. 3.29 A tree structure with 8 leaf nodes at the bottom

抽样时，将树顶层的数值，即所有优先级权值的和，按照需要采样出的条目数量来划分区段。例如要采样 3 个样本，则将树最顶端数值 51 划分为 3 个区段：

$$[0\sim17],[17\sim34],[34\sim51]$$

然后按照均匀随机采样的原则在所划分的每一个区段内随机选择一个数值，例如从 $[17\sim34]$ 区段中选择了数值 $p_1=20$，则从数值为 51 的父节点向下，先遍历它的左侧子节点，数值为 30 的节点，由于 $20<30$，因此在数值为 30 和 21 的两个子节点中选择数值为 30 的子节点路径，继续向数值为 16 的子节点遍历，由于 $20>16$，因此选择数值为 14 的子节点路径，且此时的数值需要减去 16 对应的子节点的数值，即 $p_1=24-16=8$，然后继续重复上述过程，由于节点 14 的左侧子节点数值为 4，而 $8>4$。因此选择节点 14 的右侧子节点 10 作为最终选出的条目。

中国知网 https://www.cnki.net

该过程如图 3.30 所示。

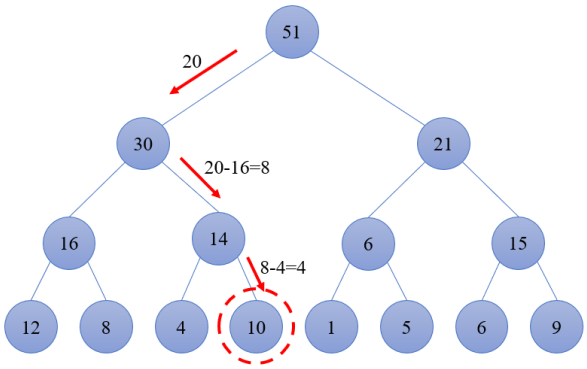


图 3.30 SumTree 的采样一次采样过程

Fig. 3.30 The sampling process of SumTree

图 3.31 显示了选择$[0\sim17]$分段中数值 6 的树遍历路径。

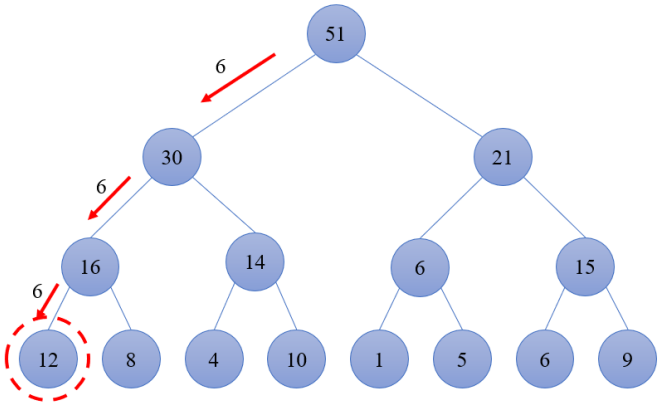


图 3.31 选择数值为 6 的后的树节点遍历过程

Fig. 3.31 The tree node traversal process after selecting the value of 6

利用 SumTree 树结构就可以在数量众多的经验条目中按照优先级权值概率大小来快速进行采样，且如果最底层叶节点的权值发生变化，只需要将对应节点所发生变化的值向上传递到它所有的父节点上，就可以完成树结构的更新。

3.3.4 针对残差策略的修改

为了使改进 PPO 算法输出的动作能够与神经网络运动规划构成的初始策略输出动作共同叠加输出，需要对 PPO 算法做一些针对残差策略应用的修改。

（1）初始化 Actor 网络的输出层参数为 0

根据 3.1.2 小节的内容，如果初始策略本身就是完美的，那么与之叠加输出的 PPO 算法策略必须保证不能让本身完美的初始策略在叠加残差策略后变差。考虑最为极端的情况就是初始策略完美，此时的 PPO 残差策略输出动作应该为 0 输出。为了在残差策略部分开始训练时保证这一点，需要将 PPO 算法当中 Actor 网络的

中国知网 https://www.cnki.net

最后一层，也就是输出层的参数初始化为 0。

（2）预训练 Critic 部分的神经网络

在本文所提出的残差强化学习运动规划理论中，初始策略部分在与残差策略部分共同训练时并不是杂乱的输出动作，而是已经比较接近最终能够完成任务的策略，它能够在作为残差策略的 PPO 算法还未收敛之前指导训练向着能够完成任务的有利方向前进。但是，最开始训练时的残差策略 PPO 算法部分的 Critic 神经网络参数却完全是初始化后的随机值，而 Critic 部分主要用于估计状态价值函数 V，进而估计优势函数 A。这意味着，在最初即使智能体在初始策略的引导下表现出相对良好的行为，PPO 算法中的 Critic 部分也难以给出正确的“评价”。这将导致整体策略性能在训练的初期无法快速上升，甚至出现最初动作表现良好而训练后却表现糟糕的现象。

为了解决这一问题，需要在完整训练之前，对 PPO 算法当中的 Critic 部分神经网络进行预训练。具体做法是，让智能体在完整的初始策略与残差策略下进行训练，但是固定住 Actor 部分的网络参数不变，由于 PPO 算法中 Actor 网络的最后一层初始化为 0，那么此时的 PPO 算法残差策略部分的输出就是 0，整个策略的输出等于初始策略的输出。此时，仅训练 PPO 算法中的 Critic 部分神经网络，然后监测 Critic 部分神经网络的 loss 函数，即时序差分误差的大小，设置阈值 φ，当 Critic 部分估计得到价值函数的时序差分误差小于阈值 φ 时说明 Critic 部分已经具备一定的准确估计状态价值函数 V 的能力，此时停止预训练。在预训练结束后，将得到的 Critic 部分的神经网络参数保留，然后再进行完整的训练。如图 3.32 所示，为 Critic 预训练原理说明。

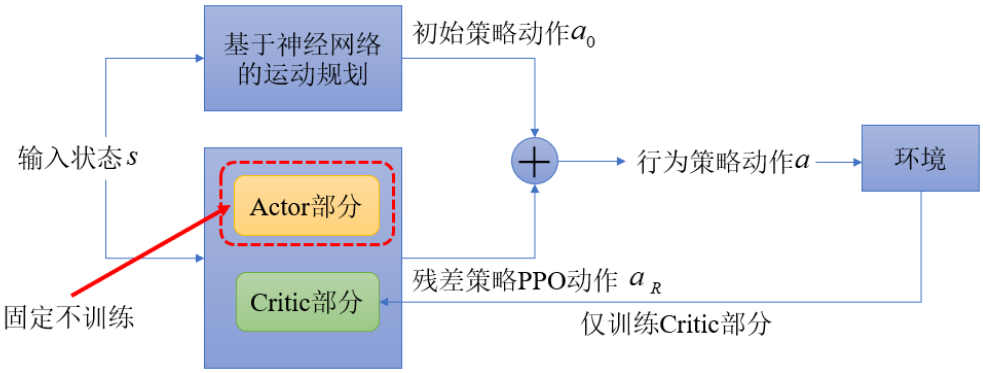


图 3.32 改进 PPO 算法 Critic 部分预训练原理

Fig. 3.32 Improved Critic pre-training principle of PPO algorithm

3.3.5 最终的改进 PPO 算法

图 3.33 所示为改进 PPO 算法原理框图。与第 2 章当中阐述的原始 PPO 算法

中国知网 https://www.cnki.net

原理图 2.15 相比，本文提出的改进 PPO 算法主要对原始 PPO 算法在以下几个方面进行改进：

①将泛化优势估计方法引入到优势函数值的估计过程，减小大量采样导致的估计误差。

②将 DDPG 和 DQN 算法中广泛采用的经验池机制引入到 PPO 算法中，在满足 KL 散度约束的前提下，从小型经验池采样进行局部的离轨策略训练。

③在小型经验池中引入优先经验回放机制，按照样本的优先级大小从经验池进行抽取。在具体实施上，采用 SumTree 数据结构进行快速采样。

④针对所提出的残差强化学习运动规划方法，对 PPO 算法的输出层进行修改，并增加对 PPO 算法 Critic 部分的预训练。

⑤算法的 Actor 部分和 Critic 部分均修改为现实网络与目标网络两个。

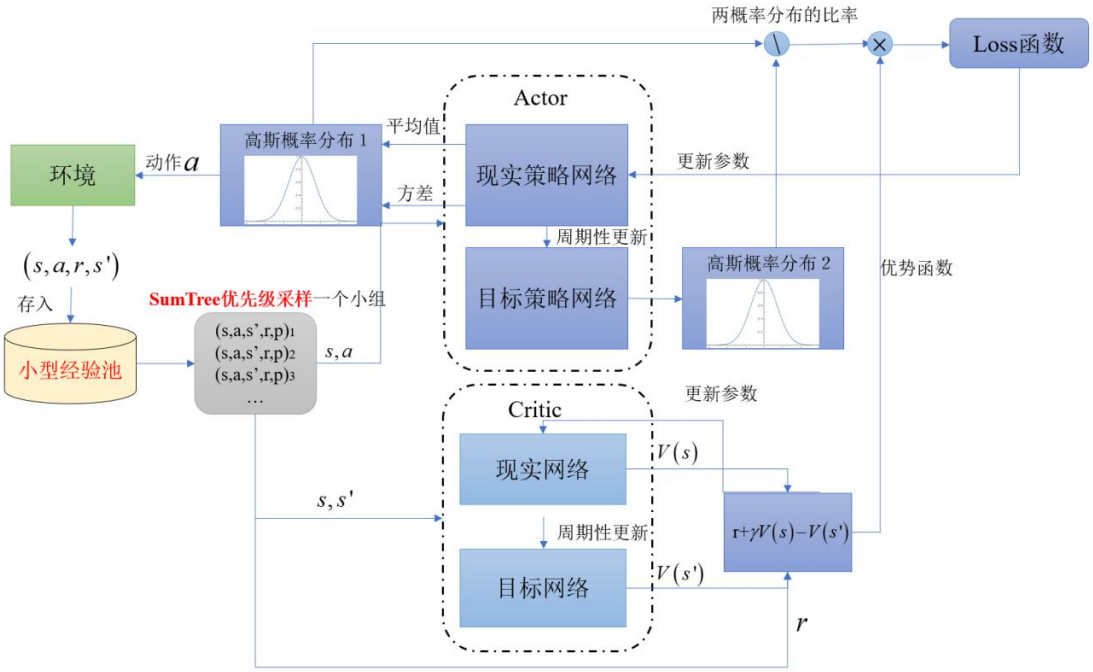


图 3.33 改进 PPO 算法原理

Fig. 3.33 Improved PPO algorithm principle

表 3.2 所示为经过上述方法改进后的 PPO 算法伪代码。p 为每条采样经验的初始优先级权值，$p_{\max}$ 为经验池已有条目中优先级的最大值。

中国知网 https://www.cnki.net

表 3.2 改进 PPO 算法伪代码

Table 3.2 Improved PPO algorithm pseudo code

改进 PPO 算法
1: 初始化 Critic 部分的现实神经网络 Q 和 Actor 部分的现实神经网络 μ，它们的参数分别是 λ^Q 和 λ^μ，参数 λ^Q 通过 Critic 的预训练得到
2: 初始化 Critic 部分和 Actor 部分的目标神经网络 Q' 和 μ'，参数 $\lambda^{Q'}=\lambda^Q, \lambda^{\mu'}=\lambda^\mu$
3: 初始化小型经验池 M，初始化 SumTree 结构，所有节点优先级权值 $p=0$
4: for 回合=1:M do
5: 重置环境，初始化状态 s
6: while 状态 s 非终止状态 do
7: 输入状态 s 给 Actor 部分的现实神经网络 μ，输出动作概率分布，然后从中采样得到具体的动作 a
8: 智能体执行动作与环境交互执行动作 a，并且受到即时奖励 r，环境转移到状态 s'
9: 将采样经验 (s,a,s',r,p) 存入经验池中，$p=\begin{cases}p_{\max}, p_{\max}\neq 0\\ 1, p_{\max}=0\end{cases}$
10: if 采样经验条目填满小型经验池 M
11: 将 Actor 部分的现实神经网络参数更新到 Actor 部分的目标神经网络参 数：$\lambda^{\mu'}\leftarrow\lambda^\mu$
12: for 训练次数=1:20 do
13: 从经验池中采样一个大小为 n 的训练小组 (s,a,s',r,p)
14: 用 Critic 部分的目标网络估计：$V(s')$
15: 用 Critic 部分的现实网络估计：$V(s)$
16: 得到优势函数 $A=\left[r+\gamma V(s')\right]-V(s)$
17: 用 Actor 部分的目标网络得到旧的行为概率分布：$\pi_{old}(a\mid s)$
18: 用 Actor 部分的现实网络得到新的行为概率分布：$\pi_{new}(a\mid s)$
19: 使用梯度上升方法更新 Actor 部分的现实网络参数 λ^μ，目标函数为：$J_{\lambda^\mu}=\sum\frac{\pi_{new}(a\mid s)}{\pi_{old}(a\mid s)}A-\sigma KL\left[\pi_{old}(a\mid s)\mid\pi_{new}(a\mid s)\right]$
20: 使用梯度下降方法更新 Critic 部分的现实网络，loss 函数为：$Loss=\frac{1}{n}\sum\left\{\left[r+\gamma V(s')\right]-V(s)\right\}^2$
21: 清空小型经验池 M
22: 软更新 Critic 的现实网络参数到目标网络：$\lambda^{Q'}\leftarrow\varepsilon\lambda^Q+(1-\varepsilon)\lambda^{Q'}$
23: end for
24: end if
25: end while
26: end for

中国知网 https://www.cnki.net

3.4 有障碍物环境下的运动规划虚拟实验

为了验证所提出的残差强化学习运动规划方法，在 V-REP 虚拟环境中建立有障碍物环境的运动规划任务。如图 3.34 所示，本文设置了 3 个日常生活中的物品作为机械臂 Mirobot 需要避开的障碍物：2 个易拉罐和 1 个药瓶。在 V-REP 平台中建立与实物尺寸大小相同的 3 个物品障碍物模型以及它们抽象出的障碍物内切球体。图中机械臂 Mirobot 末端当前所处的位置红色小球处为该任务的起始位置，绿色小球处为该任务的目标位置，中间有障碍物物体。

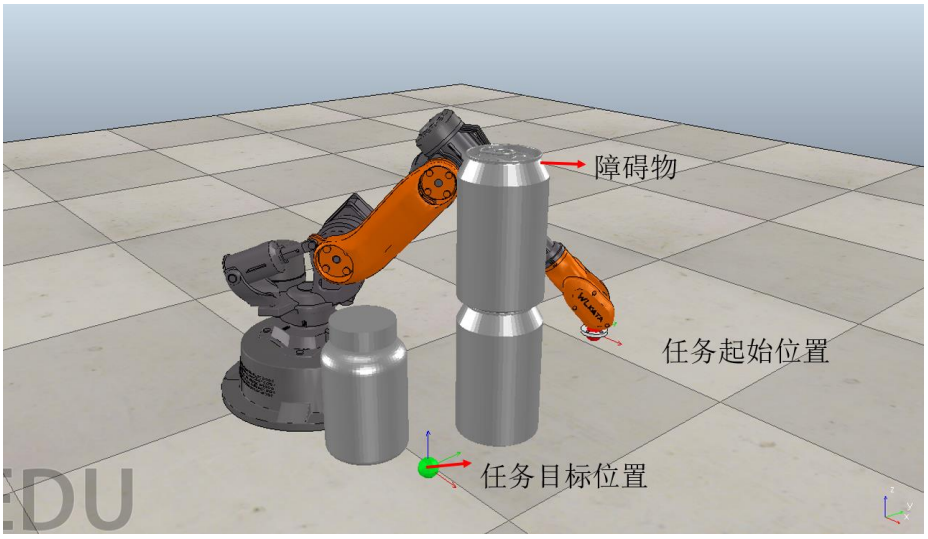


图 3.34 V-REP 虚拟环境当的有障碍物环境的运动规划任务

Fig. 3.34 V-REP virtual environment for motion planning tasks with obstacles

3.4.1 奖励函数设置

对于有障碍物环境下的运动规划任务而言，除了引导机械臂到达目标位置之外，还需要引导机械臂以指定的姿态到达目标位置。本文采用文献[73]所提出的对于机械臂姿态引导的奖励函数设计。

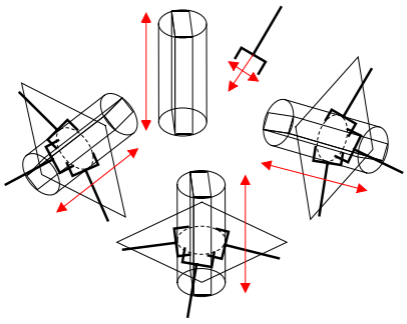


图 3.35 机械臂的姿态向量[73]

Fig. 3.35 Posture vector of the robotic arm

如图 3.35 所示，将机械臂末端执行器平面的法向量作为机械臂末端的姿态，

中国知网 https://www.cnki.net

而末端目标的姿态如图中圆柱体箭头所示，当机械臂末端的姿态向量与物体的姿态向量平行表明它们的姿态相同，对于机械臂末端的姿态规划完成。

因此该任务的奖励函数设计既需要引导位置也需要引导姿态，奖励函数设置为：

$$r=\begin{cases}-\left\|(x,y,z)_{tip}-(x,y,z)_{goal}\right\|, \text{if } \left\|(x,y,z)_{tip}-(x,y,z)_{goal}\right\|>10 \\ -\left\|(x,y,z)_{tip}-(x,y,z)_{goal}\right\|+\left|(\vec{x},\vec{y},\vec{z})_{tip}\bullet(\vec{x},\vec{y},\vec{z})_{goal}\right|, \text{if } \left\|(x,y,z)_{tip}-(x,y,z)_{goal}\right\|\le 10\end{cases} \tag{3.12}$$

式(3.12)中，$(x,y,z)_{tip}$ 为机械臂末端执行器位置，$(x,y,z)_{goal}$ 为运动规划目标的位置，$(\vec{x},\vec{y},\vec{z})_{tip}$ 为机械臂末端执行器的单位姿态向量，$(\vec{x},\vec{y},\vec{z})_{goal}$ 为运动规划目标的单位姿态向量。当机械臂末端距离目标比较远时，暂时不考虑与姿态有关的奖励项，当机械臂末端距离目标足够近的时候，考虑姿态影响下的奖励项。

但是，上述的稠密奖励函数存在一个很大的问题。本文在 2.4.2 小节中论述了稠密奖励函数的优点与缺点，稠密奖励函数引入设计者的大量先验知识，这种先验知识在一定程度上有助于训练，但是也会带来不利影响。对于上式中的稠密奖励函数，机械臂末端与目标的位置越近，距离惩罚就越小，即奖励函数就越大，显然如果机械臂末端以直线形式直达目标时的奖励函数是最大的。因此其他任何为了避开障碍物得到的路径在该稠密奖励函数下得到的奖励值都小于直线到达时的奖励值。这意味着，最终得到能够解决任务的运动规划路径在该稠密奖励函数下的奖励值都一定比机械臂末端沿着直线到达目标位置时的奖励值小。因此，在有复杂环境的障碍物运动规划任务中，上述式中的稠密奖励函数不利于智能体的训练，它容易将智能体的训练引入错误的方向。如图 3.36 所示，红色线段表示直线到达的路径，该路径获得最大稠密奖励。

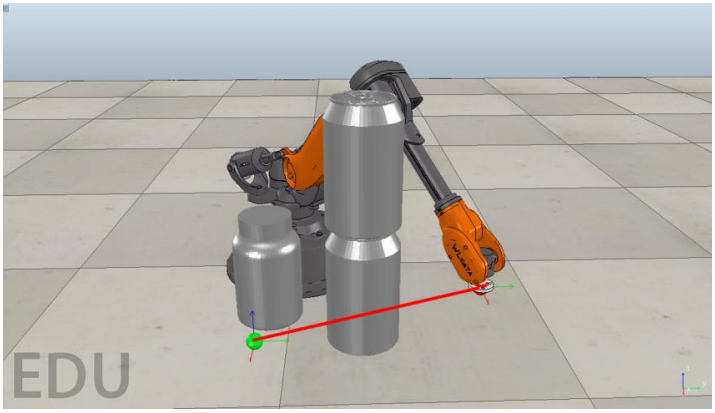


图 3.36 工作空间中起点到终点的最短直线路径

Fig. 3.36 The shortest straight path from the start point to the end point in the workspace

中国知网 https://www.cnki.net

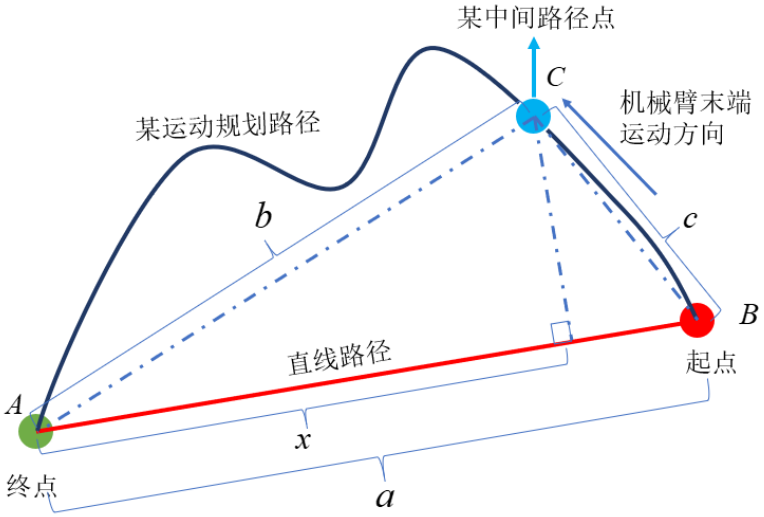


图 3.37 等效直线路径折算方法

Fig. 3.37 Equivalent straight path conversion method

如图 3.37 所示，该图为将机械臂起点、终点以及运动规划路径绘制到平面上的示意图。如果按照传统的与终点目标距离相关稠密奖励函数，则对于运动规划路径上的某一路径点，计算奖励时所使用的距离为图中距离 b。为了避免出现只有直线路径最短从而导致的奖励引导问题，将距离 b 在起点与终点连线上的投影点到终点的距离 x 作为稠密奖励函数中距离相关的参数。参数距离 a、b、c 是与三点坐标相关的距离。

$$x=\frac{a^2+b^2-c^2}{2a} \tag{3.13}$$

综上所述，本文重新设计了关于执行器末端与目标位置距离远近的稠密奖励函数项。此外增加稀疏奖励函数项，机械臂如果触碰障碍物，则予以惩罚，如果最终能够完成任务，则予以奖励。最终设计的奖励函数如下：

$$r_1=\begin{cases}-x, \text{if } \left\|(x,y,z)_{tip}-(x,y,z)_{goal}\right\|>10\\ -x+\left|(\vec{x},\vec{y},\vec{z})_{tip}\bullet(\vec{x},\vec{y},\vec{z})_{goal}\right|, \text{if } \left\|(x,y,z)_{tip}-(x,y,z)_{goal}\right\|\le 10\end{cases} \tag{3.14}$$

$$r_2=-5，\text{触碰障碍物} \tag{3.15}$$

$$r=r_1+r_2 \tag{3.16}$$

3.4.2 训练过程

（1）初始策略的训练

初始策略采用基于 BP 神经网络的运动规划方法，将障碍物抽象为球体，然后

中国知网 https://www.cnki.net

将位置和半径特征值输入给神经网络，用传统的运动规划算法 RRT*来生成训练用数据。按照小节 3.2.2 中的过程进行 BP 神经网络的训练。如图 3.38 所示为进行 BP 神经网络初始策略训练时障碍物抽象球体环境。在工作空间中随机设定 500 组不同的起点与终点位置对，然后调用 V-REP 中自带的运动规划库 OMPL(The Open Motion Planning Library)，并指定算法为 RRT*，生成对应的运动规划关节构形序列。然后再取其中的 400 条序列用于神经网络的训练，剩余 100 条序列用于测试训练效果。

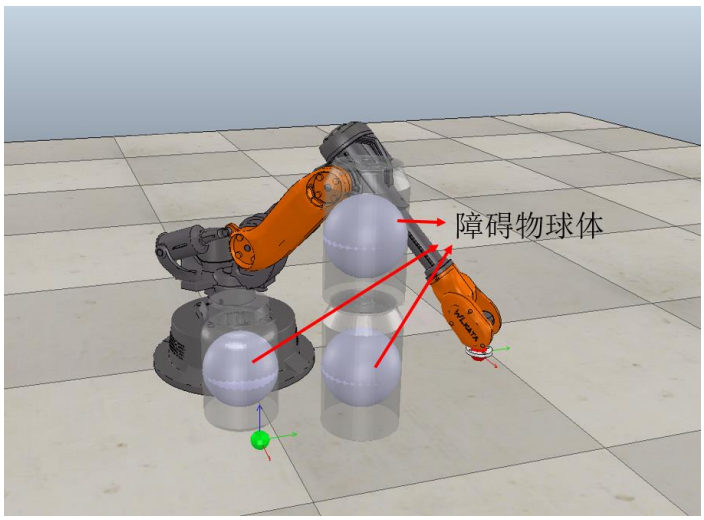


图 3.38 虚拟实验中的球体障碍物抽象

Fig. 3.38 Spherical obstacle abstraction in virtual experiment

（2）改进 PPO 深度强化学习算法部分

改进 PPO 算法部分的网络结构与输入特征与本文第 2 章中设置的结构基本相同，但是需要按照 3.3.4 小节进行部分修改。在 PPO 部分的 Actor 网络初始化参数时，需要将最后输出层的网络参数初始化为 0。预训练 Critic 部分的神经网络，只训练 PPO 算法中的 Critic 部分神经网络，然后监测 Critic 部分神经网络的 loss 函数，也就是时序差分误差的大小，当时序差分误差小于阈值φ时，预训练结束，算法进入正式训练过程。本文的阈值φ设置为 10。

中国知网 https://www.cnki.net

3.4.3 实验结果

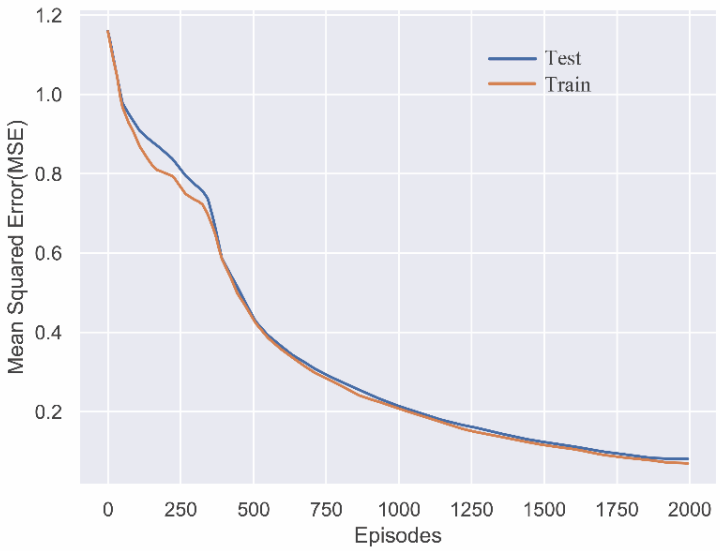


图 3.39 BP 神经网络训练结果

Fig. 3.39 BP neural network training results

初始策略中 BP 神经网络的训练效果如图 3.39 所示，图中的横坐标表示训练回合数，纵坐标表示训练时的均方误差 MSE 数值，该数值越趋近于 0 说明训练的效果越好。所构建的神经网络进行了 2000 次迭代训练，最终误差趋于 0。图中包括两条曲线，Train 曲线表示使用训练数据集训练神经网络时的均方误差曲线，Test 曲线表示训练过后神经网络在测试数据上的效果。实验结果表明经过训练后初始策略中的 BP 神经网络具有引导残差策略进行运动规划训练的能力。

在初始策略训练完成后，采用所提出的残差强化学习运动规划方法在虚拟实验环境中进行强化学习部分的试错训练，与单纯使用 PPO 算法直接进行强化学习的训练效果进行比较。如图 3.40 所示，为采用所提出方法与单纯 PPO 算法在相同的虚拟实验环境下进行训练时的平均收益与训练回合数之间的关系。

中国知网 https://www.cnki.net

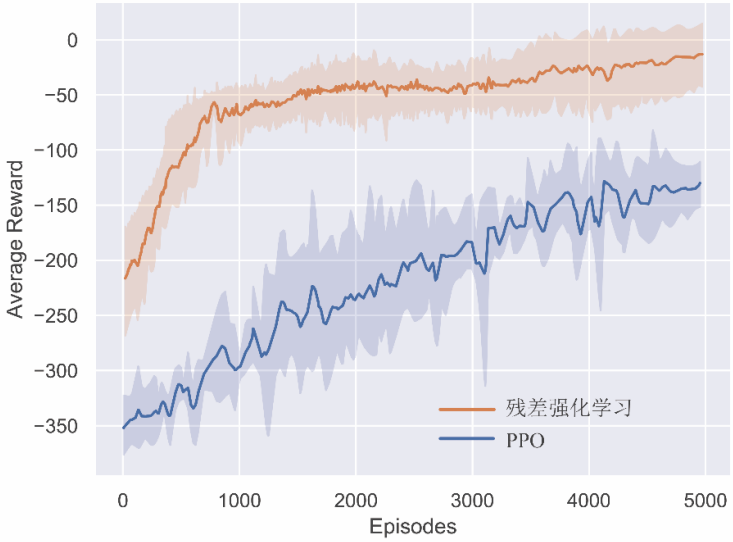


图 3.40 残差强化学习运动规划方法与单纯 PPO 算法的平均收益与回合数之间的关系

Fig. 3.40 The relationship between the average return and the number of episodes between the residual reinforcement learning method and the pure PPO algorithm

从图 3.40 中可以看出，所提出的残差强化学习运动规划方法比单纯使用 PPO 算法的收敛速度更快，算法在初始策略的有效引导下，在大约 1000 回合训练之后就已经趋于收敛，而 PPO 算法则在总计 5000 回合的训练中始终处于缓慢的上升过程，其训练过程比较缓慢且出现了一定地震荡。

统计所提出残差强化学习运动规划方法与单纯采用 PPO 算法进行强化学习训练的成功率，每隔 10 个回合对当前训练的智能体策略在实验环境中的成功率进行 50 次评估测试，并计算当前成功率。如图 3.41 所示为成功率评估结果。蓝色曲线为所提出残差强化学习运动规划方法的成功率，红色曲线为单纯采用 PPO 算法进行强化学习时的成功率。实验结果显示所提出的残差强化学习方法在训练 1000 步以后成功率就已经达到了 60%以上，而此时的 PPO 算法的成功率接近于 0。在继续训练以后，2000 回合以后残差强化学习运动规划方法的成功率基本稳定在 80%以上，在 5000 回合训练结束时基本稳定在 90%以上。而 PPO 算法的成功率随着训练的进行在缓慢地上升，5000 回合时成功率接近 60%。通过该实验可以发现所提出的残差强化学习运动规划方法比单一采用 PPO 算法进行强化学习训练快很多并且效果明显。

中国知网 https://www.cnki.net

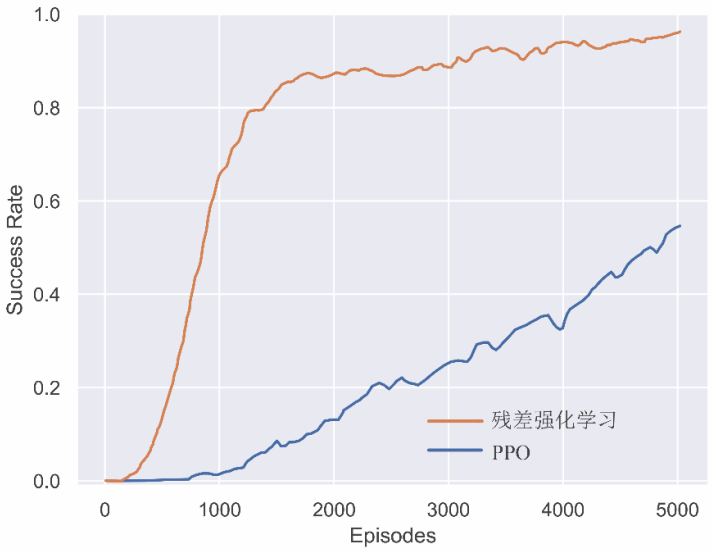


图 3.41 残差强化学习运动规划方法与单纯 PPO 方法的成功率

Fig. 3.41 The success rate of residual strategy motion planning method and pure PPO algorithm

图 3.42 所示为残差强化学习运动规划虚拟实验过程中机械臂运动规划过程。机械臂的末端位置最初位于红色球体标识的起始位置，目标位置位于绿色球体标识的位置，机械臂的末端在残差强化学习运动规划方法的规划下，各个关节逐步运动，接近目标位置且避开了虚拟环境当中的障碍物，最终到达了目标位置。图 3.43 所示为该规划过程中机械臂的各个关节角度变化曲线。

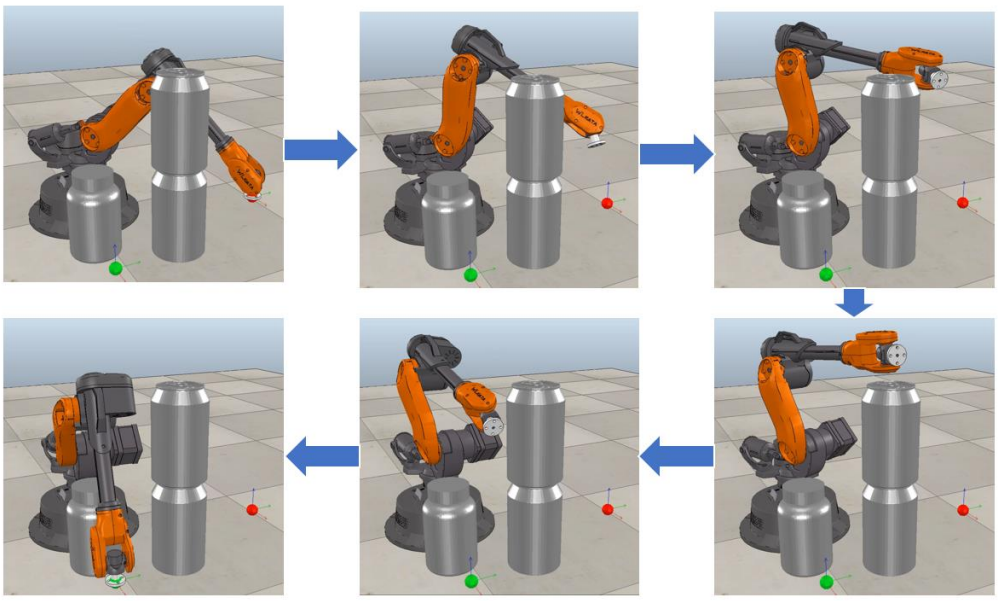


图 3.42 机械臂从起始位置到目标位置的运动规划过程

Fig. 3.42 The motion planning process of the robotic arm from the starting position to the target position

中国知网 https://www.cnki.net

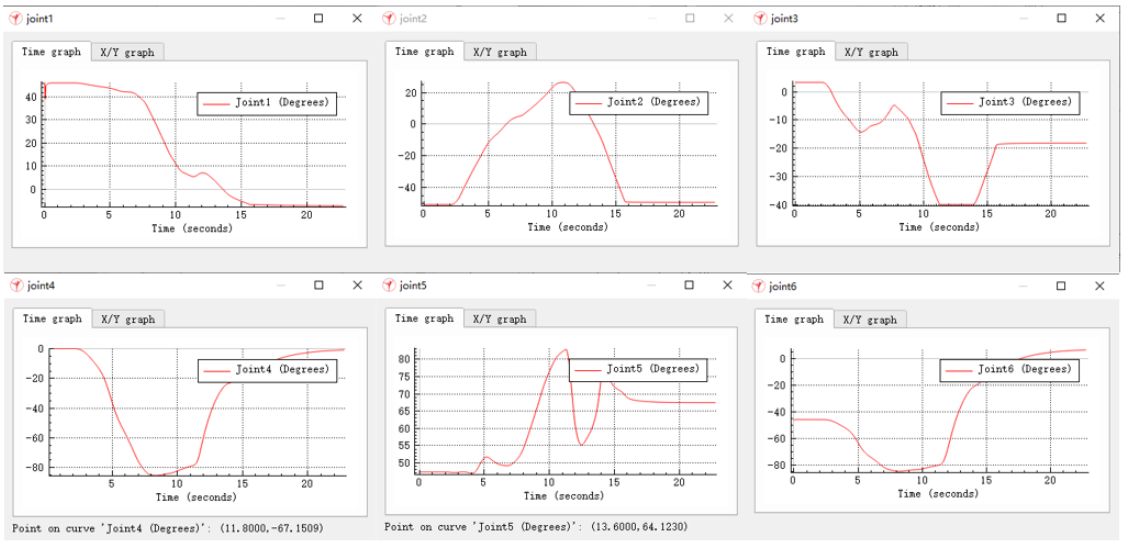


图 3.43 运动规划过程中机械臂关节角度的变化曲线

Fig. 3.43 Change curve of robotic arm joint angle during motion planning

3.5 本章小结

（1）针对强化学习算法训练效率低和训练困难的问题，本章提出了一种基于残差强化学习的机械臂运动规划方法。该方法将智能体进行运动规划的策略分为初始策略和残差策略。初始策略由 BP 神经网络构成，负责引导由强化学习算法构成残差策略的训练方向。残差策略由强化学习算法中的 PPO 构成。在初始策略的引导下，残差策略能够快速收敛。残差策略部分则补充完善了初始策略的自适应性和泛化能力。

（2）针对所提出残差强化学习运动规划方法中的初始策略部分，本章采用了一种基于 BP 神经网络的运动规划方法，并提出了一种球体障碍物抽象方法。

（3）针对所提出残差强化学习运动规划方法中的残差策略部分，本章对原始 PPO 算法进行了一系列改进，提出了一种改进 PPO 算法。

（4）在仿真环境下进行实验，结果表明残差强化学习运动规划方法能够成功地进行运动规划。将该算法与单纯使用 PPO 算法进行对比，实验结果表明残差强化学习运动规划方法能够有效提高强化学习智能体训练的效率。

中国知网 https://www.cnki.net

4 基于课程强化学习的障碍物自适应训练方法研究

本文第 3 章提出了基于残差强化学习的机械臂运动规划方法，其中的初始策略 BP 神经网络运动规划方法向正确的方向引导作为残差策略的改进 PPO 算法训练。在基于 BP 神经网络的运动规划初始策略中，需要向网络输入环境障碍物特征值，本文提出将障碍物按照内切球体来进行抽象，将每个障碍物抽象为一个内切于障碍物表面的球体。该障碍物抽象方法能够将环境障碍物有效简化，并将其关键特征参数输入神经网络用于训练。

对于障碍物的球体抽象方法，所抽象的球体与实际障碍物存在描述差距，尤其对于某些长高尺寸相差较大的障碍物，这种差距非常明显且会对后续训练产生影响。针对这一问题，本章提出了一种基于课程强化学习的障碍物自适应训练方法。首先分析了球体障碍物抽象所面临的描述问题，然后引入课程强化学习方法，进而将课程强化学习的思想应用于机械臂的运动规划问题。

4.1 初始策略与残差策略的互补性以及障碍物球体抽象存在的问题

本文第 3 章所提出的内切球体障碍物抽象方法对于障碍物的描述与实际障碍物形状之间存在差距。当球体与实际障碍物之间形状的差距不是很大时，该抽象方法仍然适用于第 3 章所提出的残差强化学习运动规划方法，这是由初始策略与残差策略的互补性原理决定的。

如果使用单一的强化学习算法来解决复杂环境下的运动规划问题，如本文 3.4 小节的对比实验，强化学习算法通过奖励函数的引导，不停的对环境进行试错。由于环境的复杂性，仅依靠强化学习固有的奖励引导以及试错来找到解决运动规划任务的有效方法将经历非常多回合的训练，遭遇训练困难问题。本文通过引入初始策略，通过初始策略来引导强化学习训练的方向，使得原本随机的试错过程从训练一开始就变为有一定方向性的探索行为。在这个过程中，初始策略与残差策略互为补充互相协调，初始策略能够引导残差策略（改进 PPO 算法）的训练，残差策略通过强化学习算法所固有的特点，即奖励引导下的试错行为，补充解决初始策略中障碍物外形描述不精确的问题。图 4.1 描述了初始策略与残差策略的互补性原理。

中国知网 https://www.cnki.net

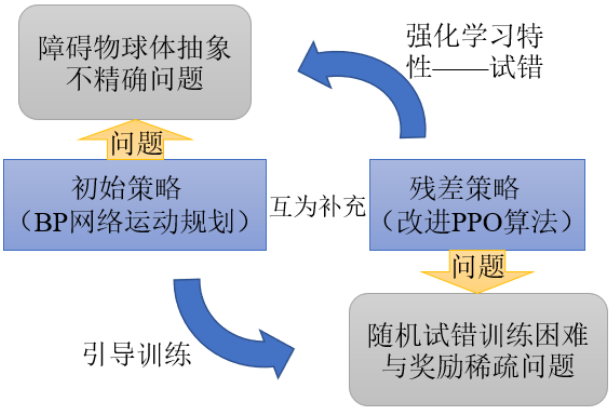


图 4.1 初始策略与残差策略的互补性

Fig. 4.1 Complementarity of initial policy and residual policy

虽然依靠初始策略与残差策略的互补性原理能够克服初始策略中使用的球体障碍物抽象方法不准确问题，但是如果障碍物形状的长宽高比例相差比较大，那么所抽象出的球体与实际障碍物的外形差距将十分大，这时，残差策略当中的强化学习算法需要进行试错的空间就会很大，从而仍然有可能出现训练困难的问题。



图 4.2 抽象球体与障碍物实际形状相差很大的情况

Fig. 4.2 The abstract sphere is very different from the actual shape of the obstacle

如图 4.2 所示为抽象出的障碍物球体与实际障碍物形状相差很大的情况，左侧为水杯障碍物抽象，右侧为牛奶盒障碍物抽象。这一类障碍物的特点是其长宽高尺寸比例相差很大，从而导致抽象出的内切障碍物球体比实际障碍物小得多。本章的后续内容引入课程强化学习方法，对这种情况下可能出现的训练困难问题进行解决。

4.2 课程学习理论

课程学习(Curriculum Learning)[112]的概念最初由学者 Bengio 在 2009 年的机器学习会议 ICML(International Conference on Machine Learning)提出。这一概念的提

中国知网 https://www.cnki.net

出对于与机器学习相关各种算法的发展起到了重要的作用，以课程学习思想为启发而衍生出的算法在深度学习以及强化学习的各个研究领域广泛出现[113, 114]。

课程学习方法的思想根源来自于人类与动物的学习行为。人类与动物的学习行为往往按照由易到难的过程进行。例如，如果要教会 3 岁孩子微积分高等数学的相关知识，这是不可能完成的任务，但是如果先让小孩上幼儿园，然后小学，中学，大学，那么自然而然的在大学当中他就能够学会微积分高等数学的知识了。这一过程的本质就是教育，教育提供了一种系统化的方法来将原本复杂的知识进行分解，并且按照学习的难易程度以及知识的逻辑关系设计成不同阶段的课程。合理的课程设计使人类对于困难事物的学习更加容易上手。

2018 年，Kerzel 等学者提出了一种用于训练机械臂到达目标位置的课程强化学习方法[115]。该方法从生物学文献[116]的研究结论中受到启发，即抓握经验较少的婴儿更倾向于用手来探索体积较大的物体，并且一旦婴儿的抓握能力得到提高，它们就会转而去尝试抓握体积更小的物体。基于此结论，Kerzel 等对到达任务的目标精度进行简化，在训练的过程中，首先将目标区域的半径从最小按照训练的成功率逐步调整到最大，然后再从最大逐步调整到最小，从而实现了对训练对象目标难度的动态调整。如图 4.3 所示为 2 自由度机械臂到达任务目标的简化过程，将目标的直径增大即可简化到达任务的难度，从而大大减小强化学习智能体在该任务中的训练难度。

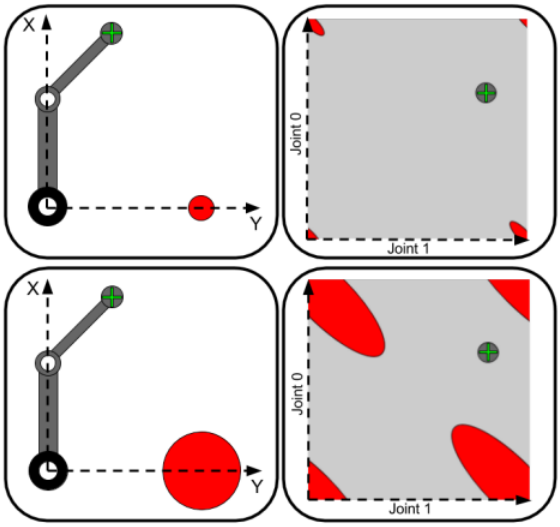


图 4.3 2 自由度机械臂到达任务的简化[115]

Fig. 4.3 Simplification of DOF robotic arm to reach task

4.3 基于课程学习的障碍物简化训练与有效球体概念

本文受课程学习思想以及 Kerzel 等学者所提出方法的启发，提出了一种基于

中国知网 https://www.cnki.net

课程强化学习的障碍物自适应训练方法。该方法的核心思想是通过改变环境中障碍物在实际训练时的体积大小来动态调整训练的难度。对于图 4.3 所示的达到任务，目标范围越大，任务就越容易完成，因此训练也就越容易进行。类似的，对于机械臂的运动规划任务，障碍物越小就越容易被机械臂避开，训练的难度也就越小，强化学习算法就越容易收敛。

基于上述思想对需要解决的机械臂运动规划任务中的障碍物进行简化。在训练初期，从原始大小开始缓慢地减小障碍物与强化学习智能体进行交互的实际体积大小，直到体积缩小到在初始策略中所抽象的障碍物球体大小，此时对应的训练环境最简单，即初始策略训练时将障碍物抽象为球体时的环境。然后再逐步增大障碍物的体积，继续进行训练，直到障碍物恢复其原本的形状。下面详细阐述该方法的训练过程。

4.3.1 障碍物有效球体概念

为了能够动态描述和调整障碍物的大小，本文提出障碍物有效球体的概念。首先将按照障碍物内切表面抽象出的球体称为最小有效球体 $O_{\min}$ 其半径记为 $r_{\min}$，按照某一固定步长 Δr 增大最小有效球体的半径，直到新增大的球体刚刚能够完全包裹住该障碍物的所有部分，该球体称为最大有效球体 $O_{\max}$ 其半径记为 $r_{\max}$。那么位于最小有效球体 $O_{\min}$ 和最大有效球体 $O_{\max}$ 之间所夹的实际障碍物部分就是可以动态调整进行增大或者减小的障碍物体积部分。

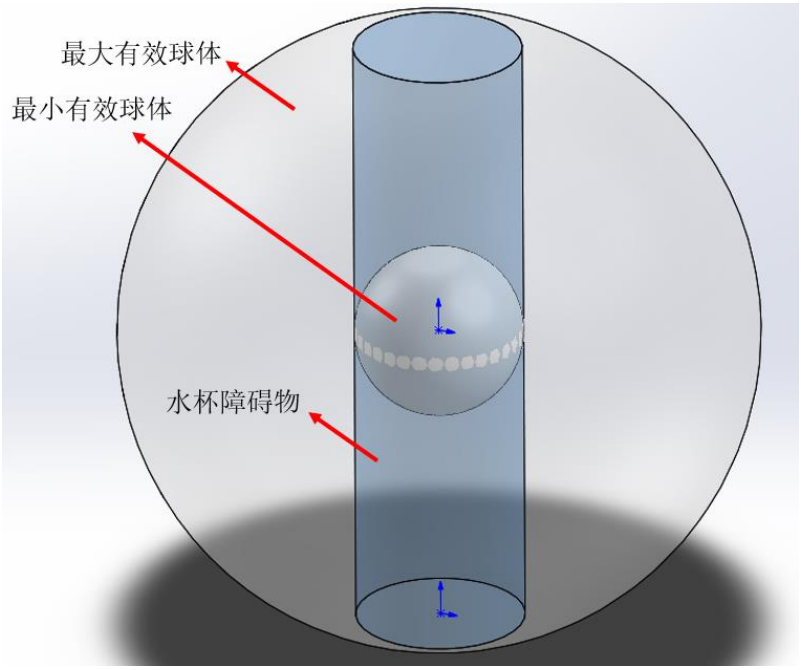


图 4.4 水杯障碍物的最大与最小有效球体

Fig. 4.4 The largest and smallest effective sphere of the obstruction of the water glass

中国知网 https://www.cnki.net

如图 4.4 所示为一个水杯障碍物的最小有效球体部分、最大有效球体部分以及夹在它们之间的障碍物可变体积部分。

在引入障碍物有效球体概念之后，就可以很容易的在最小有效球体与最大有效球体范围之内调整实际用于训练的障碍物大小，从而调整训练的难易程度，实现本文所提出的课程学习训练方法。如图 4.5 所示，根据有效球体的半径步长逐步增大有效球体，截割原始障碍物后得到几个不同体积大小的简化障碍物，从左到右依次从最初的内切球体障碍物抽象过度到完整形状的障碍物。



图 4.5 有效障碍物体积从小到大变化过程

Fig. 4.5 The effective obstacle volume changes from small to large

4.3.2 自适应障碍物大小调整方法

将障碍物有效球体从最小的内切球体逐步增大半径，本文在实际操作中按照每次 20mm 的半径变化量进行有效球体大小的改变。显然，有效球体截割原始障碍物得到的简化障碍物体积越大，训练的难度就越大。因此应当按照所训练智能体的运动规划能力大小自适应地动态调整简化障碍物的大小，在智能体能力较弱时，缩小简化障碍物的大小，在其能力变强时，增大简化障碍物的大小。

采用一定回合次数后的运动规划成功率衡量此时的智能体运动规划能力大小：

$$\begin{aligned} ASR(\alpha) &= \frac{1}{\alpha}\sum_{N'=N-\alpha}^{N} S_{N'} \\ S_{N'} &= \begin{cases} 1, \text{回合成功} \\ 0, \text{回合失败} \end{cases} \end{aligned} \tag{4.1}$$

中国知网 https://www.cnki.net

式(4.1)中 N 表示训练回合的计数，α 参数表示计算平均成功率 $ASR(\alpha)$ 时所取的回合数。从当前回合计数 N 向前取 α 回合到 $N-\alpha$ 回合， $ASR(\alpha)$ 计算的就是从回合计数 $N-\alpha$ 到回合 N 之间智能体运动规划的成功率，本文的 α 参数取 50。

同时，障碍物的体积按照当前时刻智能体运动规划成功率 $ASR(\alpha)$ 大小进行自适应增大或者减小：

$$r_{obs}=\begin{cases} r_{\max}, N<N_{init} \\ \max\left(r_{obs}-\Delta r, r_{\min}\right), ASR(\alpha)<P_1 \text{且} N\geq N_{init} \\ \min\left(r_{obs}+\Delta r, r_{\max}\right), ASR(\alpha)\geq P_2 \text{且} N\geq N_{init} \end{cases} \tag{4.2}$$

式(4.2)中，r_{obs} 代表着当前的障碍物有效球体半径，它的值介于 $r_{\min}$ 与 $r_{\max}$ 之间。在开始训练后的一定回合 N_{init} 之内，采用完整的障碍物 $r_{\max}$ 评估智能体的运动规划性能，取 N_{init} 的值大于回合计数参数 α，本文取 $N_{init}=250$，$\alpha=50$。在经过最初的 N_{init} 个回合之后，根据评估的当前成功率 $ASR(\alpha)$ 判断智能体是否能力不足，如果能力不足则需要按照半径变化步长 Δr 减小障碍物有效球体的半径且不小于最小有效球体半径，此时的训练环境最简单，完全简化为残差强化学习运动规划方法中初始策略训练时使用的障碍物环境。

随着训练不断地进行，成功率 $ASR(\alpha)$ 会逐渐提高，此时障碍物有效球体的半径将转入增大过程，最大增大到能够得到原始障碍物。 设置参数 P_1 和 P_2 为成功率的概率阈值，P_1 为障碍物球体半径缩小阶段的成功率判断阈值，本文设置 P_1 为 0.2，即在半径缩小训练阶段，如果智能体在某一简化障碍物环境下训练 ΔN 回合后，运动规划的成功率未能达到阈值 20%，则缩小有效球体的半径，切换到难度更低的障碍物环境当中。设置 P_2 为 0.8，即在半径增大训练阶段，达到 80%的运动规划成功率则认为智能体在该环境下的运动规划能力已经足够高，可以切换到下一个更难的障碍物环境中继续训练。

4.3.3 障碍物是否需要简化的判断条件

并非所有的障碍物都需要经过有效球体的简化，对于尺寸长宽高相差不大的障碍物可以直接用于训练，只有自身在各个方向尺寸相差较大的障碍物才会与障碍物内切球体相差非常大而影响训练。对于环境中的障碍物是否需要进行课程学习方法的有效球体简化，需要制定一个定量的判断标准。

本文将一个障碍物所对应的最大有效球体半径 $r_{\max}$ 与最小有效球体半径 $r_{\min}$ 的比值与阈值 ε 作比较：

中国知网 https://www.cnki.net

$$\begin{cases} \text{如果}\dfrac{r_{\max}}{r_{\min}} > \varepsilon, \text{判定为需要采用课程学习方法简化的障碍物} \\ \text{如果}\dfrac{r_{\max}}{r_{\min}} \le \varepsilon, \text{判定为不需要采用课程学习方法简化的障碍物} \end{cases} \tag{4.3}$$

本文的阈值参数ε选定为 3，在所设计的任务中，障碍物为典型的生活用品：水杯、药瓶和易拉罐。经过计算，它们的障碍物球体半径大小以及比值如表 4.1 所示。易拉罐和药瓶障碍物是不需要进行简化的，但是需要对水杯进行简化。

表 4.1 几种桌面障碍物的有效球体半径参数

Table 4.1 Effective sphere radius parameters of several desktop obstacles

障碍物名称	$r_{\max}$ (mm)	$r_{\min}$ (mm)	$\frac{r_{\max}}{r_{\min}}$ (2 位小数)	是否需要简化操作
水杯	114	30	3.80	是
药瓶	66.46	32.5	2.04	否
易拉罐	65	33	1.97	否

4.3.4 课程强化学习方法的 5 个阶段

如图 4.6 所示，按照本章所提出的课程学习方法训练过程的障碍物有效球体半径大小来划分，可以把训练过程分为 5 个阶段。训练开始时，进入初始评估阶段，此时的障碍物完全不进行简化，障碍物有效球体半径为$r_{\max}$，然后进行训练N_{init}回合并评估当前的智能体运动规划能力，如果此时智能体运动规划能力即成功率无法达到阈值P_1，训练将进入障碍物缩小阶段，该阶段障碍物按照指定的半径变化步长Δr，一边缩小一边进行训练，直到障碍物有效球体半径缩小到最小的$r_{\min}$。在缩小阶段的每一个有效球体半径环境中至少训练ΔN回合，由阈值P_1判断是否继续进行缩小。继续进行训练一段时间，智能体的运动规划能力将在简单环境中得到迅速地提高。当检测到运动规划能力大于阈值P_2，则进入障碍物变大阶段，一边增大障碍物有效球体半径，一边继续进行训练，直到障碍物有效球体半径达到最大值$r_{\max}$。然后进入调整阶段，在该阶段让智能体在完整的障碍物环境下继续训练一段时间使已经收敛的算法更加的稳定，此时设定调整阶段继续进行训练的最大回合数为$N_{ft\max}$。

中国知网 https://www.cnki.net

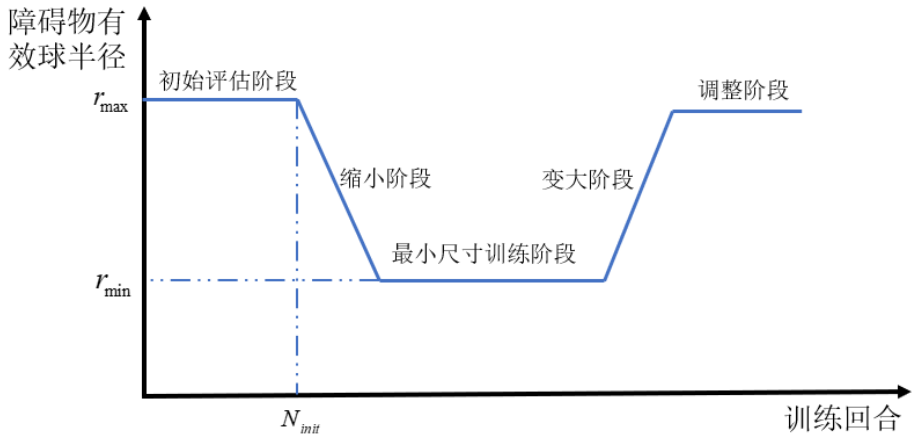


图 4.6 所提出的课程强化学习方法的 5 个阶段

Fig. 4.6 The 5 stages of the proposed curriculum reinforcement learning method

4.4 残差强化学习运动规划方法与课程强化学习训练方法的结合

如图 4.7 所示为将本章基于课程学习的训练方法与第 3 章残差强化学习运动规划方法结合的示意图。

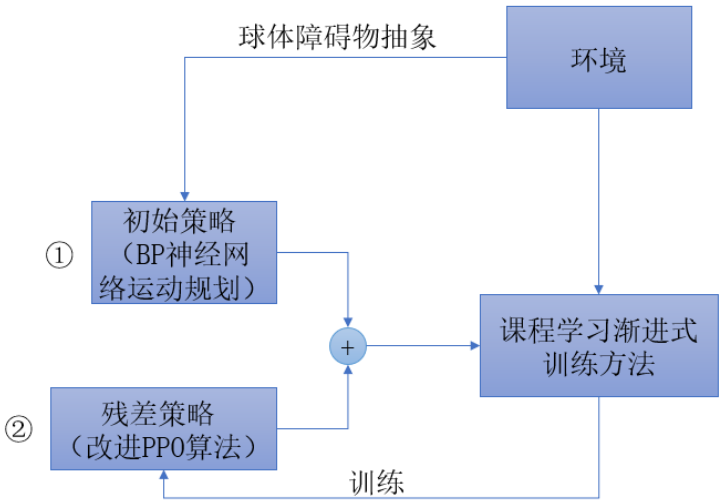


图 4.7 残差强化学习运动规划与课程学习训练方法的结合

Fig. 4.7 Combination of residual policy motion planning and curriculum learning method

首先，作为初始策略(IP)的 BP 神经网络按照第 3 章图 3.8 所示的方法在内切球体障碍物环境中进行训练，此时输入给 BP 神经网络的障碍物球体半径为内切于障碍物的最小球体半径；然后再按照第 3 章图 3.32 所示的方法对残差策略(RP)中改进 PPO 算法的 Critic 网络进行预训练；Critic 网络经过预训练收敛后，再按照图 4.7 所示的方法，将初始策略 *IP* 、残差策略 *RP* 的联合输出与按照课程强化学习方法简化后的障碍物环境进行互动，从而完整地训练残差策略。表 4.2 所示为基于课

中国知网 https://www.cnki.net

程强化学习的自适应障碍物运动规划方法的伪代码。

表 4.2 基于课程强化学习的障碍物自适应训练方法伪代码

Table 4.2 Pseudo-code for adaptive obstacle motion planning based on curriculum reinforcement learning

基于课程强化学习的障碍物自适应训练方法

输入已经训练好的初始策略 IP，初始化调整阶段训练回合数 $N_{ft}=0$，训练回合计数 $N=0$，是否进入调整阶段标志位 $Flag_{ft}=False$，是否处于障碍物增大阶段标志位 $Flag_{up}=False$

while $N_{ft}<N_{ft\max}$ do：

  if $N<N_{init}$ 或者 $Flag_{ft}==True$

    $r_{obs}=r_{\max}$

  else if $N>N_{init}$

    if $ASR(\alpha)<P_1$ 且 $Flag_{up}==False$

      $r_{obs}=\max\left(r_{obs}-\Delta r,r_{\min}\right)$

    else if $ASR(\alpha)\geq P_2$

      $Flag_{up}=True$

      $r_{obs}=\min\left(r_{obs}+\Delta r,r_{\max}\right)$

    end if

  end if

  执行残差策略运动规划的训练 ΔN 回合：$RP\leftarrow train\left(IP,RP,r_{obs}\right)$

  $N+=\Delta N$

  if $r_{obs}=r_{\max}$ 并且 $N>N_{init}$

    $Flag_{ft}=True$

  end if

  if $Flag_{ft}==True$

    $N_{ft}+=\Delta N$

  end if

4.5 V-REP 当中的实际训练方法

本节对如何在机器人虚拟仿真软件 V-REP 中实现本章所提出方法的具体操作过程进行阐述。

4.5.1 建立多个 V-REP 场景用于交替训练

在课程强化学习方法的实际操作中，需要根据障碍物有效球体的大小逐步的改变 V-REP 软件中障碍物的可碰撞部分大小。但是机器人虚拟仿真软件 V-REP 尚不支持部分的改变其中物体的可碰撞属性。为了能够在 V-REP 中实现课程学习的

中国知网 https://www.cnki.net

障碍物大小变化机制，对需要改变大小的障碍物建立多个 V-REP 仿真场景，在每次障碍物有效球体变化到对应场景中的障碍物时，加载对应的 V-REP 场景，在该场景中进行训练，然后再切换到下一场景继续训练。如图 4.8 所示为将水杯障碍物用于课程学习逐步训练时的 5 个 V-REP 场景。在障碍物缩小阶段，依次切换 V-REP 场景(5)、(4)、(3)、(2)、(1)，如图 4.8 中红色剪头所示。在障碍物增大阶段，依次切换切换 V-REP 场景(1)、(2)、(3)、(4)、(5)，如图 4.8 中蓝色剪头所示。

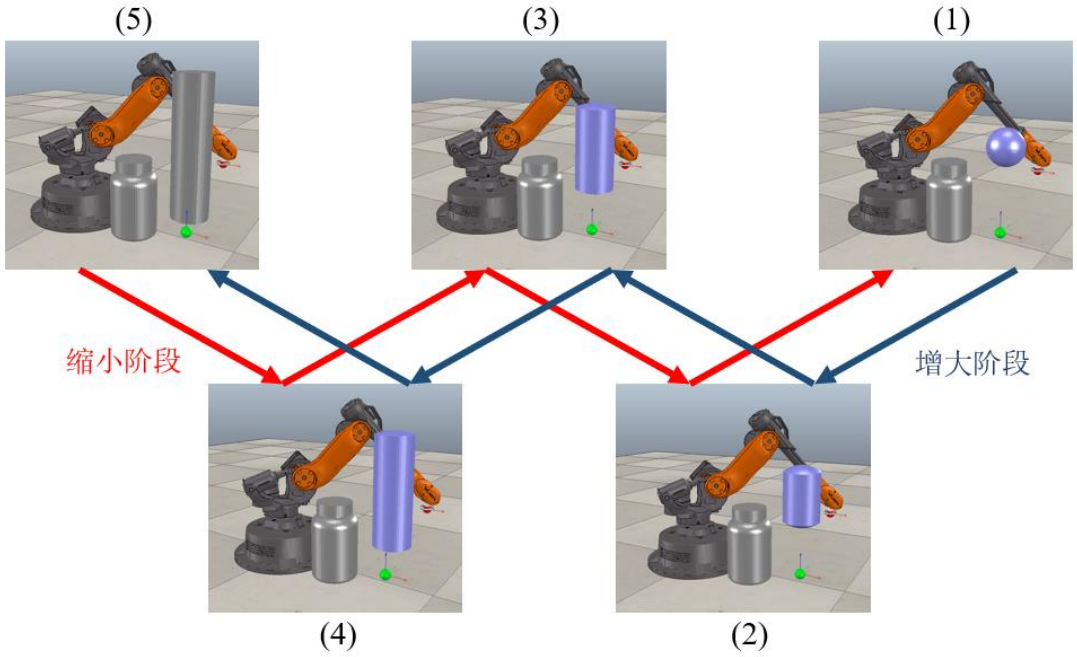


图 4.8 用于课程强化学习的 5 个水杯障碍物 V-REP 场景

Fig. 4.8 5 water cup obstacle V-REP scenes for curriculum reinforcement learning

4.5.2 关闭 V-REP 的图形化界面用于加速训练

V-REP 作为一款机器人虚拟仿真软件，包含用于机器人虚拟仿真的图形化界面引擎，该图形化界面用于显示虚拟仿真过程中机器人实体的动作和状态等，使虚拟仿真过程对于使用者而言更加的形象直观。但是对于深度强化学习训练过程而言，机器人仿真环境的图形化界面显示仅对观察者有意义，观察者可以查看机器人与环境的实时状态，但是对于实际的训练而言图形化界面并无意义。图形化界面当中机器人的所有状态与反应本质上都是一个数值计算过程。V-REP 等虚拟仿真软件的基本运行原理如图 4.9 所示，前台系统负责图形化界面显示，后台系统负责数值计算。

中国知网 https://www.cnki.net

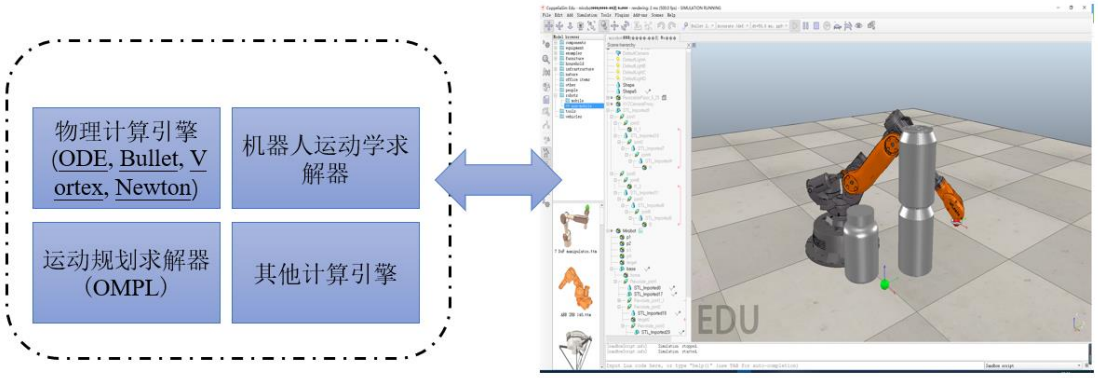


图 4.9 V-REP 虚拟仿真软件的基本原理

Fig. 4.9 The basic principle of V-REP virtual simulation software

V-REP 图形化界面消耗了计算机大量的系统资源，因此，在实际的训练过程中，可以关闭仿真软件的图形化界面显示，让数值计算的后台系统继续运行直到最终得到结果。V-REP 软件提供了这种关闭图形化界面而单独让后台系统运行数值计算的功能[117]。在实际训练过程中，通过关闭 V-REP 软件的图形化界面可以节约系统的资源，从而提高训练过程的速度。

4.6 实验结果

首先，将第 3 章当中的残差强化学习运动规划方法直接应用于障碍物抽象球体与障碍物本身相差很大的虚拟训练环境中，该虚拟环境如图 4.8(5)，环境中的主要障碍物为小节 4.3.1 中所描述的圆柱体水杯形状障碍物。评估后的运动规划任务成功率如图 4.10 所示，可以看出，在初始策略的引导下，算法趋于收敛，并且在 5000 回合训练结束时，成功率达到了 70%左右，如果继续进行训练，成功率会继续上升。但是由于初始策略中的障碍物抽象球体与实际环境中的障碍物水杯存在较大的描述区别，如图 4.8 中的(5)和(1)，从而导致了实际训练过程中残差策略部分的改进 PPO 算法仍然需要对实际的障碍物形状进行大量探索与试错，从而使算法收敛比较慢。在训练进行的前 1000 个回合，算法的成功率非常缓慢地上升。

中国知网 https://www.cnki.net

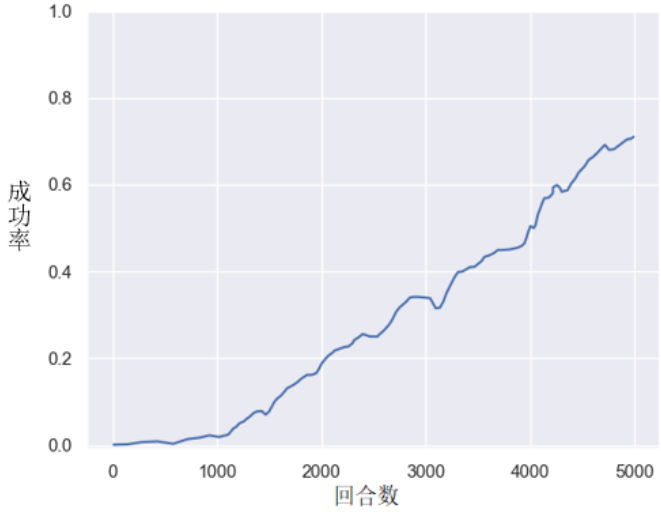


图 4.10 不使用课程学习方法时的成功率

Fig. 4.10 Success rate when not using the curriculum learning method

然后，加入所提出的课程强化学习障碍物自适应训练方法，对智能体进行训练。本文针对图 4.8(5)的运动规划任务场景，设置课程学习中的障碍物球体半径变化参数 Δr 为 20mm。从而进一步在 V-REP 虚拟实验环境中创建了如图 4.5 所示的 5 个半径连续变化的水杯障碍物，进而创建了如图 4.8 所示的 5 个不同难度的运动规划任务场景。

设置每个场景的最小训练回合数 ΔN 为 250 回合，缩小阶段的成功率阈值为 20%。障碍物有效球体半径缩小阶段的成功率曲线如图 4.11 所示。最初使用 V-REP 场景中的⑤，也就是图 4.8(5)进行训练，此时障碍物为原始大小，在 250 回合训练后，成功率为 0。然后切换到如图 4.8(4)所示的场景④继续训练，在这个场景训练 250 回合后，成功率仍然为 0，表明该场景的训练难度对于智能体来说仍然很大。再次减小障碍物球体半径，切换到图 4.8(3)所示的场景③，此时成功率开始从 0 缓慢的上升，但是在 250 回合结束时依旧无法达到所设置的阈值 20%。再次切换到图 4.8(2)所示的场景②，成功率继续缓慢上升。最后切换到图 4.8(1)所示的场景①，该场景的水杯障碍物完全抽象为最简单的球体障碍物，对于智能体而言，这是最简单的训练场景。整个训练过程进入障碍物最小尺寸训练阶段。

中国知网 https://www.cnki.net

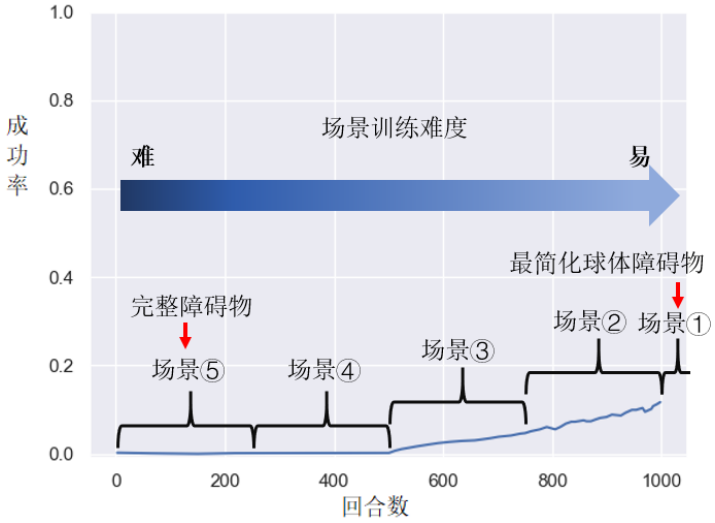


图 4.11 所提出课程学习训练方法的障碍物有效球体半径缩小阶段

Fig. 4.11 The reduction stage of the obstacle sphere radius of the proposed curriculum learning training method

接着设置障碍物有效球体半径最小阶段以及增大阶段的成功率阈值为 80%，则智能体在这个阶段的每一个场景中都将一直训练直到在该场景下的成功率达到80%为止，然后切换到下一个半径更大难度更高的训练场景继续训练。该过程如图4.12 所示，承接之前的半径缩小阶段，在最简单的球体障碍物抽象场景图 4.8(1)中继续训练，该场景对于智能体比较简单，因此成功率比较快速的上升至 80%的阈值。然后切换到场景②，由于突然更换了训练场景，增大了难度，从而导致成功率下降，然后在该场景下成功率继续上升至阈值。继续提高训练场景的难度，依次切换到场景③和场景④，可以看出每次切换都带来了难度的瞬间提高，从而导致成功率瞬间下降。当智能体在场景④中能够达到 80%成功率时，切换到最终的完整障碍物场景⑤。智能体已经在前边几个难度逐渐变化的场景中逐步积累学习经验，在完整场景⑤中能够快速的收敛，成功率提高到 80%以后，继续训练一段时间，直到5000 回合停止训练，最终的成功率达到了 95%左右。

中国知网 https://www.cnki.net

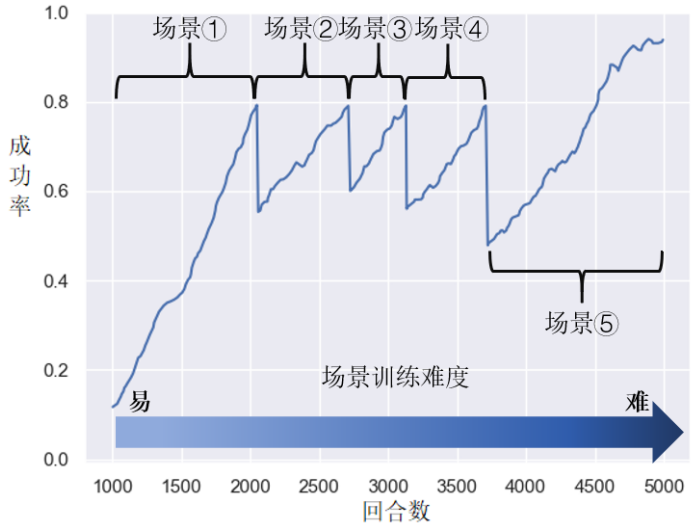


图 4.12 所提出课程学习训练方法的障碍物有效球体半径增大阶段

Fig. 4.12 The radius of the obstacle sphere of the proposed curriculum learning and training method is the smallest in the enlarged stage

各个场景当中训练得到的运动规划过程如图 4.13 到图 4.17 所示。

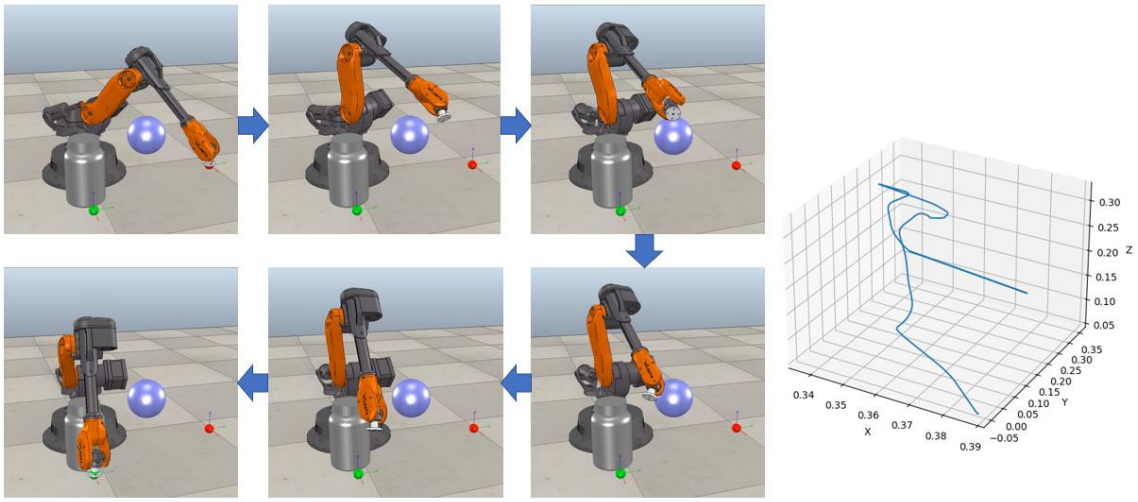


图 4.13 场景(1)中的运动规划以及末端轨迹

Fig. 4.13 Motion planning and end trajectory in scene (1)

中国知网 https://www.cnki.net

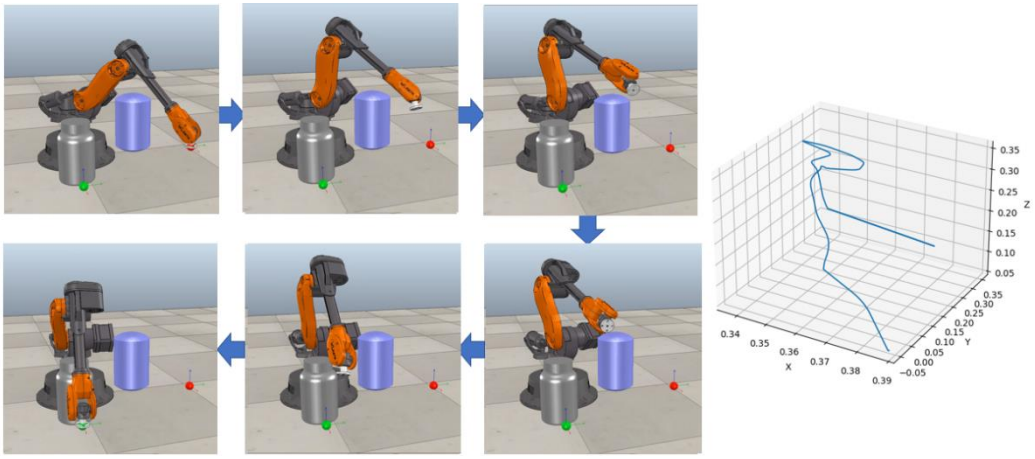


图 4.14 场景(2)中的运动规划以及末端轨迹

Fig. 4.14 Motion planning and end trajectory in scene (2)

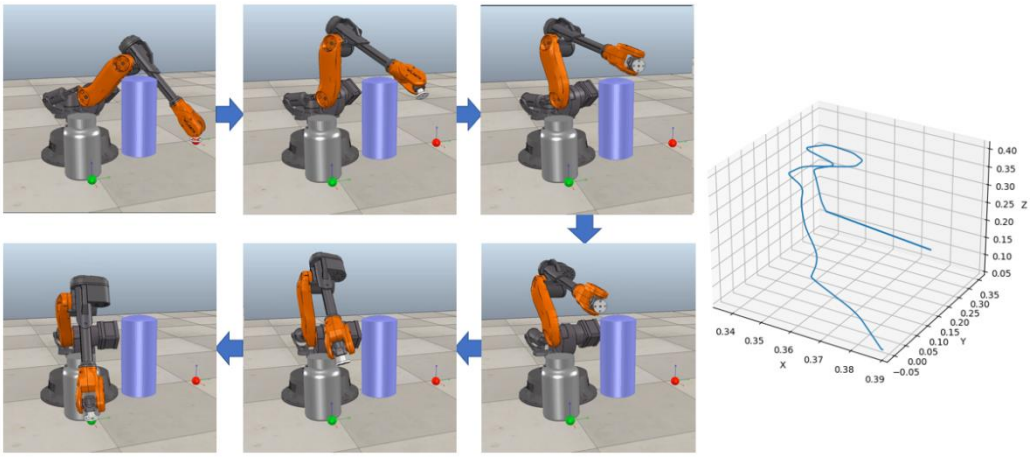


图 4.15 场景(3)中的运动规划以及末端轨迹

Fig. 4.15 Motion planning and end trajectory in scene (3)

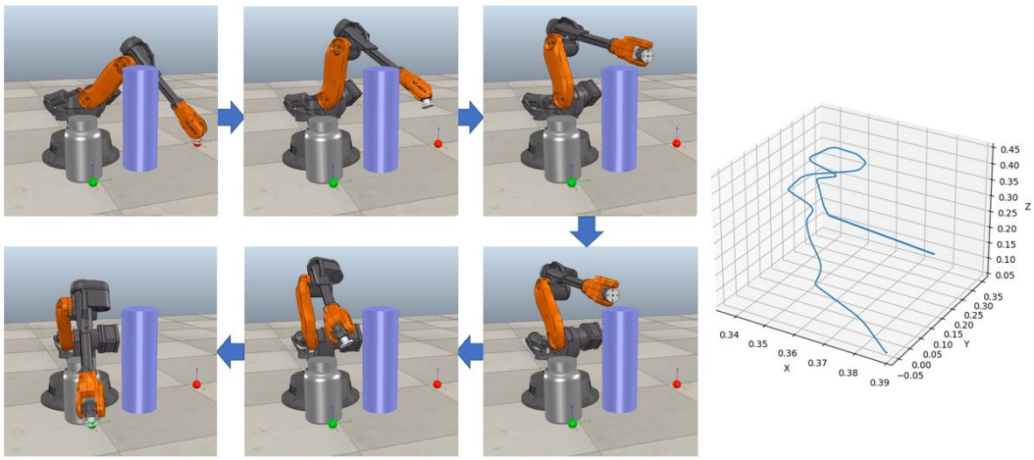


图 4.16 场景(4)中的运动规划以及末端轨迹

Fig. 4.16 Motion planning and end trajectory in scene (4)

中国知网 https://www.cnki.net

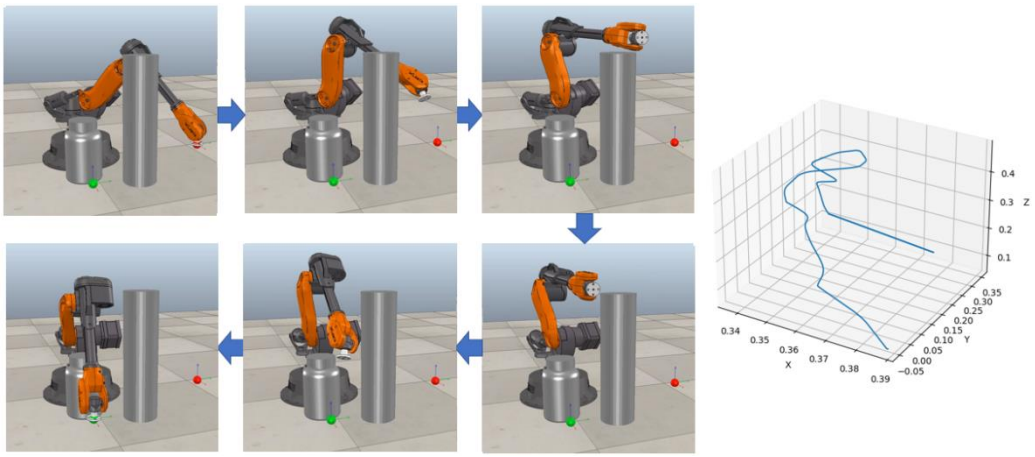


图 4.17 场景(5)中的运动规划以及末端轨迹

Fig. 4.17 Motion planning and end trajectory in scene (5)

如图 4.18 所示，将采用本文所提出的基于课程强化学习的障碍物自适应训练方法与不采用该方法直接进行训练所得到的运动规划成功率曲线放在一起进行对比。采用课程学习方法后，智能体的强化学习训练效率比不采用课程学习时要高，智能体在难度逐步变化着的训练环境当中逐渐学习，虽然在训练当中切换不同难度场景时成功率会突然下降，但是该方法到 5000 回合训练实验结束时，取得了更好的效果。

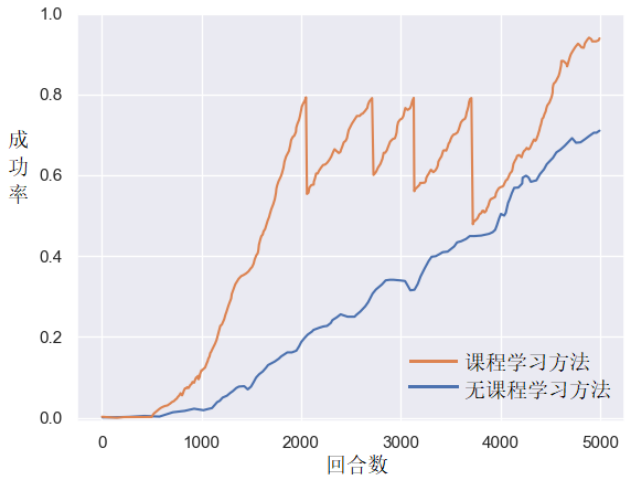


图 4.18 采用所提出课程学习方法与不采用课程学习方法时的成功率曲线

Fig. 4.18 The success rate curve when using the proposed curriculum learning method and not using the curriculum learning method

4.7 本章小结

（1）本章首先分析了第 3 章提出的残差强化学习运动规划方法当中初始策略

中国知网 https://www.cnki.net

与残差策略的互补性原理以及当障碍物抽象球体与障碍物本身存在较大差别时可能出现的问题。

（2）根据已有的课程学习思想提出了一种基于课程强化学习的障碍物自适应训练方法，该方法通过自适应修改障碍物有效球体半径来改变训练场景对于智能体完成运动规划任务的难度大小，从而在训练过程中动态调整任务难度，从难到易再从易到难。

（3）设计了在机器人虚拟仿真软件 V-REP 中实现本章所提出方法的具体操作过程。提出建立多个 V-REP 场景交替训练以及关闭 V-REP 软件图形化界面加速训练的方法。

（4）实验结果表明，所提出的方法能够有效地提高强化学习训练的效率，降低在障碍物抽象球体与实际障碍物差别很大时强化学习智能体训练的难度。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

5 基于前瞻算法的机械臂底层运动控制系统设计

机械臂的运动规划算法生成的是其构形空间的离散角度序列，进一步还需要下发给机械臂的底层运动控制系统，底层运动控制系统根据这些离散角度序列进行轨迹规划后才能完成对机械臂的控制。在前述章节中，本文提出的机械臂运动规划方法在虚拟机械臂上进行了训练和实验，再进一步将算法从虚拟环境迁移到真实机械臂之前，本章阐述了机械臂的底层运动控制系统设计。

本章首先对 Mirobot 机械臂的运动学进行了建模与求解分析，然后阐述了机械臂运动规划与轨迹规划之间的关系。为了能够动态地执行机械臂运动规划得到的离散关节角度序列，使强化学习算法在迁移到机械臂实物控制时保持良好的运动平稳性，本章将速度前瞻控制算法引入机械臂的底层控制系统中，设计了基于前瞻算法的关节轨迹规划方法。

5.1 机械臂的运动学分析

机械臂的运动学分析可以分为正向运动学分析和逆向运动学分析。正向运动学解决从机械臂各个关节角度到其末端执行机构位置与姿态的映射求解问题，逆向运动学解决从机械臂末端执行机构的位置与姿态到各个关节角度的映射求解问题。为了能够使用数学工具精确描述上述的运动学求解过程，需要将机械臂的结构抽象为由关节连接的连杆机构，并且建立连杆之间定量的位姿关系。

5.1.1 Denavit-Hartenberg 模型

机械臂的运动学数学建模方法主要有 Denavit-Hartenberg 方法和旋量法[118]。本文采用 Denavit-Hartenberg(D-H)方法，该建模方法由 Denavit 和 Hartenberg 在 1955 年的论文[119]中提出，该方法在机械臂的每个连杆上都放置一个直角坐标系，然后找到相邻两个坐标系之间的位姿关系，该关系可以用齐次变换矩阵 T 来表示，再将相邻坐标系的齐次变换矩阵相乘，最终就可以得到最后一个坐标系相对于基坐标系的位姿关系。

Mirobot 机械臂的结构如第 2 章图 2.20 所示，机械臂的前三个关节控制其末端位置，而后三个关节控制其末端姿态，后三个关节轴线相交于一点，该交点称为腕点。本文采用改进型 D-H 方法来构建机械臂的 D-H 模型，按照改进型 D-H 方法所构建的 D-H 坐标系模型如图 5.1 所示。机械臂的 4 个 D-H 参数如表 5.1 所示。

中国知网 https://www.cnki.net

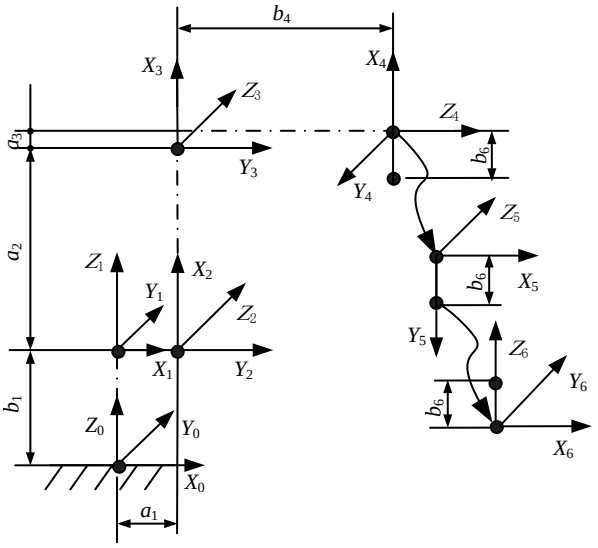


图 5.1 Mirobot 机械臂 D-H 模型

Fig. 5.1 DH model of Mirobot robotic arm

表 5.1 D-H 参数

Table 5.1 D-H parameters

	α_{i-1}	a_{i-1}	b_i	θ_i
1	0	0	b_1	0
2	-π/2	a_1	0	-π/2
3	0	a_2	0	0
4	-π/2	a_3	b_4	0
5	π/2	0	0	π/2
6	π/2	0	b_6	0

5.1.2 机械臂的正运动学

机械臂的正运动学解决的是给定 6 个关节角度然后求解此时末端杆件上的坐标系相对于基坐标系位置与姿态的问题。空间坐标系位置与姿态的数学描述是齐次变换矩阵。对于改进型 D-H 方法，两个相邻连杆坐标系之间的齐次变换矩阵 ${}_{i}^{i-1}T$ 可以表示为：

$$ {}_{i}^{i-1}T=\begin{bmatrix} c\theta_i & -s\theta_i & 0 & a_{i-1} \\ s\theta_i c\alpha_{i-1} & c\theta_i c\alpha_{i-1} & -s\alpha_{i-1} & -s\alpha_{i-1}d_i \\ s\theta_i s\alpha_{i-1} & c\theta_i s\alpha_{i-1} & c\alpha_{i-1} & c\alpha_{i-1}d_i \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{5.1} $$

式(5.1)中包含了改进型 DH 方法的 4 个 DH 参数：关节转角 θ_i，连杆的偏距 b_i，连杆的杆长 a_{i-1} 与连杆的扭角 α_{i-1}。式(5.1)中，c 表示余弦，s 表示正弦。

将表 5.1 中每个连杆的 DH 参数带入 ${}_{i}^{i-1}T$ 中，可得每两个相邻连杆之间的齐次

中国知网 https://www.cnki.net

变换矩阵：

$$
{}^{0}_{1}T=\begin{bmatrix} c\theta_1 & -s\theta_1 & 0 & 0 \\ s\theta_1 & c\theta_1 & 0 & 0 \\ 0 & 0 & 1 & 80 \\ 0 & 0 & 0 & 1 \end{bmatrix}
{}^{1}_{2}T=\begin{bmatrix} c\theta_2 & -s\theta_2 & 0 & 32 \\ 0 & 0 & 1 & 0 \\ -s\theta_2 & -c\theta_2 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}
{}^{2}_{3}T=\begin{bmatrix} c\theta_3 & -s\theta_3 & 0 & 108 \\ s\theta_3 & c\theta_3 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}
$$

$$
{}^{3}_{4}T=\begin{bmatrix} c\theta_4 & -s\theta_4 & 0 & 20 \\ 0 & 0 & 1 & 128 \\ -s\theta_4 & -c\theta_4 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}
{}^{4}_{5}T=\begin{bmatrix} c\theta_5 & -s\theta_5 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ s\theta_5 & c\theta_5 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}
{}^{5}_{6}T=\begin{bmatrix} c\theta_6 & -s\theta_6 & 0 & 0 \\ 0 & 0 & -1 & 20 \\ s\theta_6 & c\theta_6 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{5.2}
$$

根据齐次变换矩阵的链乘法则，将相邻连杆的各个变换矩阵相乘可以得到机械臂的正运动学方程：

$$
{}^{0}_{6}T={}^{0}_{1}T\,{}^{1}_{2}T\,{}^{2}_{3}T\,{}^{3}_{4}T\,{}^{4}_{5}T\,{}^{5}_{6}T \tag{5.3}
$$

所得到的齐次变换矩阵 ${}^{0}_{6}T$ 表示的是机械臂最后一个连杆的坐标系{6}相对于基座坐标系{0}之间的位置与姿态。将机械臂位于初始位置的各个关节角度值代入求得的齐次变换矩阵 ${}^{0}_{6}T$：

$$
{}^{0}_{6}T=\begin{bmatrix} 1 & 0 & 0 & 160 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 188 \\ 0 & 0 & 0 & 1 \end{bmatrix} \tag{5.4}
$$

5.1.3 机械臂的逆运动学

针对在机械臂底层微处理器中快速求逆解的问题，本文采用在前三轴采用几何方法求解，后三轴采用 Z-Y-Z 欧拉角反变换方法求解的方法[120]。对于机械臂逆解的多解问题，根据各个关节角度的限位范围筛选一组位于适合区间的逆解。

（1）几何法求解机械臂的前 3 轴角度

机械臂的末端位姿由末端的坐标 $(x_{tip}, y_{tip}, z_{tip})$ 位置以及相对于基坐标系的RPY角姿态共同构成。RPY 角即绕着 X-Y-Z 固定坐标轴依次旋转 α 角度，β 角度和 γ 角度。将其欧拉角形式的姿态转换为旋转矩阵：

$$
R_x=\begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos\alpha & -\sin\alpha \\ 0 & \sin\alpha & \cos\alpha \end{bmatrix}
R_y=\begin{bmatrix} \cos\beta & 0 & \sin\beta \\ 0 & 1 & 0 \\ -\sin\beta & 0 & \cos\beta \end{bmatrix}
R_z=\begin{bmatrix} \cos\gamma & -\sin\gamma & 0 \\ \sin\gamma & \cos\gamma & 0 \\ 0 & 0 & 1 \end{bmatrix} \tag{5.5}
$$

将绕单个轴的旋转矩阵相乘得到总的姿态旋转矩阵：

中国知网 https://www.cnki.net

$$R_{xyz}=R_zR_yR_x=\begin{bmatrix} c\beta c\gamma & c\gamma s\alpha s\beta-c\alpha s\gamma & s\alpha s\gamma+c\alpha c\gamma s\beta \\ c\beta s\gamma & c\alpha c\gamma+s\alpha s\beta s\gamma & c\alpha s\beta s\gamma-c\gamma s\alpha \\ -s\beta & c\beta s\alpha & c\alpha c\beta \end{bmatrix} \tag{5.6}$$

式(5.6)中的R_{xyz}表示机械臂末端相对于基坐标系的姿态。为了方便后续的算法描述，将该旋转矩阵描述为：

$$R_{xyz}={}^{0}_{E}R=\begin{bmatrix} n_x & o_x & a_x \\ n_y & o_y & a_y \\ n_z & o_z & a_z \end{bmatrix} \tag{5.7}$$

进一步求解出机械臂的腕点坐标位置。因为已知的末端位置为$(x_{tip},y_{tip},z_{tip})$，并且已知其到腕点的长度为图 5.1 中的$b_6$。${}^{0}_{E}R$矩阵中的第 3 列$\left[a_x,a_y,a_z\right]$表示机械臂末端坐标系的 Z 坐标轴在基坐标系中的 3 个坐标轴方向上的方向余弦值。因此根据三角函数几何关系可以求得腕点的坐标位置$\left(P_x,P_y,P_z\right)$：

$$\begin{aligned} P_x &= X_{tip}+b_6\,a_x \\ P_y &= Y_{tip}+b_6\,a_y \\ P_z &= Z_{tip}+b_6\,a_z \end{aligned} \tag{5.8}$$

然后继续求解前 3 轴的角度值。根据反三角函数关系有：

$$\theta_1=atan\left(P_y,P_x\right) \tag{5.9}$$

相应的另一个解为：

$$\theta_1'=\theta_1+\pi \tag{5.10}$$

所得到的θ_1和θ_1'为第 1 关节角度的两个解。

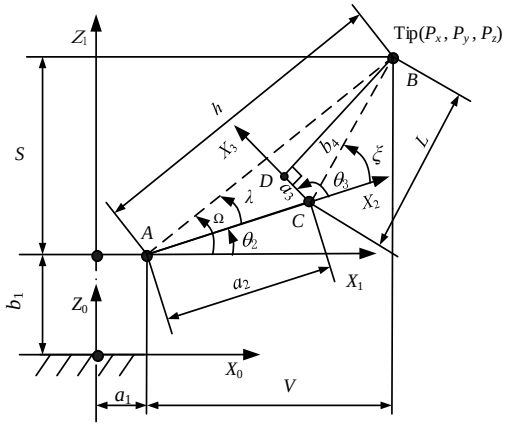


图 5.2 机械臂 XOY 平面几何结构

Fig. 5.2 Plane geometry of robot XOY

中国知网 https://www.cnki.net

然后根据图 5.2 所示几何关系求解第 3 轴角度值。

由余弦定理，在$\triangle ABC$当中：

$$h^2 = a_2^2 + L^2 - 2a_2 L\cos(\pi - \xi) \tag{5.11}$$

$$L = \sqrt{b_4^2 + a_3^2} \tag{5.12}$$

$$h^2 = S^2 + V^2 \tag{5.13}$$

$$S^2 + V^2 = a_2^2 + b_4^2 + a_3^2 + 2a_2\sqrt{b_4^2 + a_3^2}\cos\xi \tag{5.14}$$

求得：

$$\cos\xi = \frac{S^2 + V^2 - a_2^2 - (b_4^2 + a_3^2)}{2a_2\sqrt{b_4^2 + a_3^2}} \tag{5.15}$$

式(5.15)中的 S 和 V 可以计算为：

$$S = P_z - b_1 \tag{5.16}$$

$$V = \pm\sqrt{\left(P_x - a_1\cos\theta_1\right)^2 + \left(P_y - a_1\sin\theta_1\right)^2} \tag{5.17}$$

$$\sin\xi = \pm\sqrt{1 - \left(\cos\xi\right)^2} \tag{5.18}$$

进一步可得：

$$\xi = a\tan 2\left(\sin\xi, \cos\xi\right) \tag{5.19}$$

$$\theta_3 = -\left[\xi + a\tan 2\left(b_4, a_3\right)\right] \tag{5.20}$$

由于$\sin\xi$为正负 2 个值，所以求得的第 3 轴角度也为两个值，记为θ_3和θ_3'。

然后求解第 2 轴角度值。仍然由图 5.2 中的几何关系可得：

$$\theta_2 = \Omega - \lambda \tag{5.21}$$

$$\Omega = \text{atan2}\left(S, V\right) \tag{5.22}$$

$$\lambda = atan2\left(L\sin\xi, a_2 + L\cos\xi\right) \tag{5.23}$$

显然 DH 方法中第 2 轴所转动的正方向与根据几何关系所求得θ_2角度方向相反，因此需要增加一个负号：

$$\theta_2 = -\left(\Omega - \lambda\right) \tag{5.24}$$

在求解过程中的中间量V有正负 2 个值，因此第 2 轴角度值也存在两个解，可以记为θ_2和θ_2'。

中国知网 https://www.cnki.net

（2）Z-Y-Z 欧拉角反变化法求解机械臂后 3 轴角度

首先将机械臂的后 3 个关节角度运动到 D-H 模型中角度值为 0 的位置。计算机械臂位于当前角度位置时的末端坐标系{6}相对于中间坐标系{3}的姿态，也就是旋转矩阵 ${}^{3}_{6}R$：

$$ {}^{3}_{6}R|_{\theta_4=\theta_5=\theta_6=0}=\begin{bmatrix}1 & 0 & 0\\ 0 & 0 & -1\\ 0 & 1 & 0\end{bmatrix} \tag{5.25}$$

式(5.25)中的 ${}^{3}_{6}R|_{\theta_4=\theta_5=\theta_6=0}$ 表示机械臂后 3 个关节运动到 D-H 模型中角度值为 0 的位置时末端坐标系{6}相对于中间坐标系{3}的姿态。

将一个坐标系{E}固定在机械臂的末端，并且该坐标系的姿态与已知的末端姿态 R_{xyz} 相同。根据之前求得的前 3 轴角度值可以求得中间坐标系{3}相对于基坐标系{0}的姿态：

$$ {}^{0}_{3}R=\begin{bmatrix}c_1c_{23} & -c_1s_{23} & -s_1\\ s_1c_{23} & -s_1s_{23} & c_1\\ -s_{23} & -c_{23} & 0\end{bmatrix} \tag{5.26}$$

式(5.26)中的 s 表示正弦，c 表示余弦。

机械臂末端固定坐标系{E}相对于坐标系{6}的姿态矩阵为 ${}^{6}_{E}R$，则有姿态关系：

$$ {}^{0}_{E}R={}^{0}_{3}R\,{}^{3}_{6}R|_{\theta_4=\theta_5=\theta_6=0}\ {}^{6}_{E}R \tag{5.27}$$

可以求得旋转矩阵 ${}^{6}_{E}R$：

$$ {}^{6}_{E}R=\left({}^{3}_{6}R|_{\theta_4=\theta_5=\theta_6=0}\right)^{-1}\left({}^{0}_{3}R\right)^{-1}\ {}^{0}_{E}R \tag{5.28}$$

需要求解的后 3 轴角度值相当于将它们从角度为 0 的位置旋转到使得坐标系{6}与附加坐标系{E}重合时 3 轴所对应的角度值。观察图 5.1 可以看出当机械臂处于后 3 个关节角度为 0 位置时，第 4 轴关节轴线 Z_4 与坐标系{6}的 Z_6 坐标轴重合，方向相反；第 5 轴的关节轴线 Z_5 与坐标系{6}的 Y_6 坐标轴重合，方向相同；第 6 轴的关节轴线 Z_6 与坐标系{6}的 Z_6 坐标轴重合，方向相同。

综上所述，需要求解的后 3 轴角度值大小与将姿态矩阵 ${}^{6}_{E}R$ 进行 Z-Y-Z 欧拉角反变换后的欧拉角对应相等，但是第 4 轴的角度值相差一个负号。若 ${}^{6}_{E}R$ 反变换出的欧拉角为 α,β,γ，则后 3 轴角度值为：

$$ \theta_4=-\alpha,\ \ \theta_5=\beta,\ \ \theta_6=\gamma \tag{5.29}$$

将旋转矩阵 ${}^{6}_{E}R$ 反变换出欧拉角 α,β,γ 的过程为：

中国知网 https://www.cnki.net

$$R_{zyz}=R_z(\partial)R_y(\beta)R_z(\gamma)=\begin{bmatrix} c\alpha c\beta c\gamma-s\alpha s\gamma & -c\gamma s\alpha-c\alpha c\beta s\gamma & c\alpha s\beta \\ c\alpha s\gamma+c\beta c\gamma s\alpha & c\alpha c\gamma-c\beta s\alpha s\gamma & s\beta s\alpha \\ -s\beta c\gamma & s\beta s\gamma & c\beta \end{bmatrix} \tag{5.30}$$

定义一般形式的 ${}^{6}_{E}R$：

$${}^{6}_{E}R=\begin{bmatrix} g_{11} & g_{12} & g_{13} \\ g_{21} & g_{22} & g_{23} \\ g_{31} & g_{32} & g_{33} \end{bmatrix} \tag{5.31}$$

可以求得后 3 轴的角度值为：

$$\theta_5=a\tan 2\left(\sqrt{g_{31}^2+g_{32}^2},g_{33}\right) \tag{5.32}$$

$$\theta_4=-a\tan 2\left(\frac{g_{23}}{\sin\theta_5},\frac{g_{13}}{\sin\theta_5}\right) \tag{5.33}$$

$$\theta_6=a\tan 2\left(\frac{g_{32}}{\sin\theta_5},-\frac{g_{31}}{\sin\theta_5}\right) \tag{5.34}$$

另一组解：

$$\theta_5'=a\tan 2\left(-\sqrt{g_{31}^2+g_{32}^2},g_{33}\right) \tag{5.35}$$

$$\theta_4'=-a\tan 2\left(\frac{g_{23}}{\sin\theta_5'},\frac{g_{13}}{\sin\theta_5'}\right) \tag{5.36}$$

$$\theta_6'=a\tan 2\left(\frac{g_{32}}{\sin\theta_5'},-\frac{g_{31}}{\sin\theta_5'}\right) \tag{5.37}$$

当第 5 轴角度为 0 时，表达式存在退化情况，只能够求得 2 个角度的和或者差值，此时取第 4 轴角度为 0。

当第 5 轴为 0 时：

$$\theta_4=0 \tag{5.38}$$

$$\theta_6=a\tan 2\left(-g_{12},g_{11}\right) \tag{5.39}$$

当第 5 轴为 180 时：

$$\theta_4=0 \tag{5.40}$$

$$\theta_6=a\tan 2\left(g_{12},-g_{11}\right) \tag{5.41}$$

中国知网 https://www.cnki.net

5.2 机械臂的运动规划与轨迹规划之间的关系

机械臂的运动规划和轨迹规划是机械臂两个层次的控制。它们彼此关联而又有所区别。如果从定义上来看：

运动规划在移动机器人领域也称为路径规划，用于找到将对象物体从起始位置移动到目标位置的有效配置序列[121]。这是非常宽泛的定义，如果就机械臂控制而言，运动规划指给定机械臂运动的起始构形与目标构形，规划出连接起始构形和目标构形且有效避开障碍物的离散构形序列[122]。

轨迹规划得到的是一个动点的位置随时间而连续变化的轨迹曲线，对于机械臂关节空间的轨迹规划，它所规划出的是机械臂关节角度随着时间而发生改变的函数关系[123]。

运动规划得到的是能够完成机械臂控制任务的关节位置的离散序列，机械臂按照这些角度位置来逐个运动，能够从给定的起点运动到目标点而不发生碰撞。但是运动规划得到的是离散的角度序列，如果需要真实控制机械臂，还需要轨迹规划算法来将这些离散的角度序列按照以时间为自变量的轨迹函数进行连接，这个过程就是关节空间的轨迹规划。因此，机械臂的运动规划与轨迹规划是上下层级的关系。针对一个具体的机械臂控制任务，应当先进行机械臂的运动规划得到能够完成该任务的有效构形角度序列，然后再将得到的角度序列下发给机械臂的底层运动控制系统，由运动控制系统进行下一层次的轨迹规划，最终由机械臂执行轨迹规划后的运动轨迹[124]。该过程如图 5.3 所示。

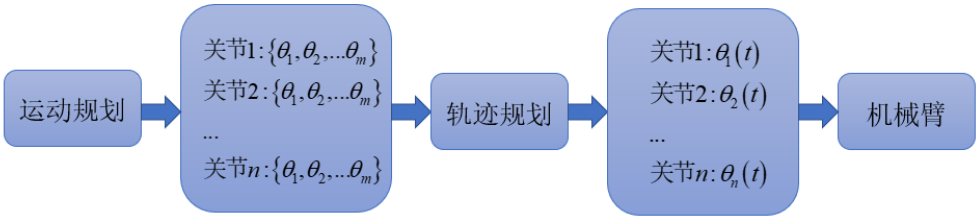


图 5.3 机械臂的运动规划与轨迹规划

Fig. 5.3 Motion planning and trajectory planning of robotic arm

传统的机械臂控制器一般不提供运动规划功能而仅仅提供轨迹规划功能。在传统的机械臂使用场景中，一般都是通过使用者的示教来实现机械臂运动规划的。机械臂的使用者根据需要，通过拖动机械臂或者用机械臂示教器来控制机械臂到达合适的任务位置，并且记录该位置的各轴角度值，然后再由记录了这些离散序列的机器人控制器来进行轨迹规划从而进行机械臂的控制。一个典型的示教操作过程如绪论部分的图 1.1 所示，该使用者拖动机械臂的末端达到所需要完成的零件焊接轨迹中间点，将所有需要焊接的点位完全的手动示教一次。

中国知网 https://www.cnki.net

综上所述，运动规划是找出轨迹规划时所途径中间路径点的过程，而示教是传统机器人控制中最常用的由操作者手动进行运动规划的方法。

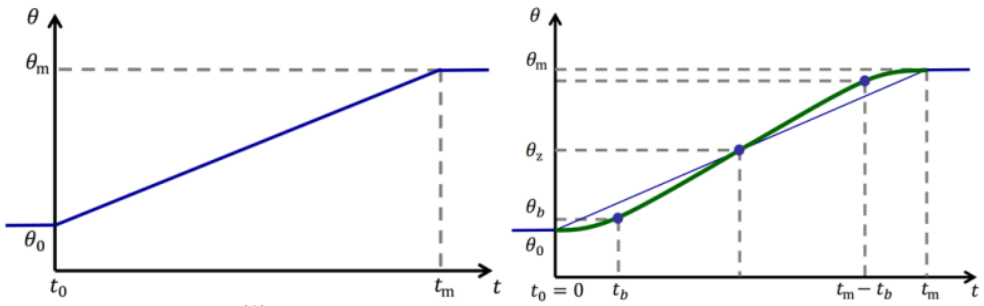
5.3 基于前瞻算法的机械臂关节轨迹规划方法

机械臂关节空间的轨迹规划是在关节空间规划角度值的轨迹。给定机械臂运动过程中各个轴的中间角度值，然后针对每个关节角度变量规划出一条平滑的关于时间的函数。关节空间的轨迹规划方法包括三次多项式方法和五次多项式方法[125]，这些规划方法通过平滑的高次多项式曲线连接各个路径点。Mirobot 机械臂采用了另一种与抛物线拟合的线性函数轨迹规划方法。该方法的关节路径轨迹为一条直线，在轨迹的开始与结束位置采用平滑的抛物线函数进行连接过渡。其关节速度曲线为梯形，也可将该方法称为梯形加减速方法。

传统的关节轨迹规划方法需要提前已知关节角度所有的路径点，然后通过数学约束关系求解出连接它们的光滑轨迹曲线。但是在机械臂的实际应用中它所接收到的角度指令并不是同时得到的，而是按照时间顺序一个一个得到的。后得到的指令需要与先前的指令之间光滑连接起来，速度不能出现突变。这一问题实际上是运动控制系统解决的问题，本文将数控设备中广泛采用的前瞻算法引入到机械臂关节空间的轨迹规划方法中。

5.3.1 与抛物线拟合的线性函数轨迹规划

如图 5.4(1)所示为用直线段连接起始位置与目标位置的轨迹规划。



(1) (2)

图 5.4 直线段连接起始位置与目标位置的轨迹规划

Fig. 5.4 Trajectory planning of line segment connecting starting position and target position

在直线段的起始位置与终止位置出现了不平滑，这将导致速度曲线的突变与加速度的冲击。图 5.4(2)所示为在直线的开始与终止位置用抛物线进行平滑连接后的规划曲线。

如果这一段的初始速度与终止速度均为 0：

中国知网 https://www.cnki.net

$$\dot{\theta}_0 = \dot{\theta}_m = 0 \tag{5.42}$$

对于直线运动段：

$$\dot{\theta} = \frac{\theta_z - \theta_b}{t_z - t_b} \tag{5.43}$$

对于二次多项式段：

$$\theta(t) = \frac{1}{2}\ddot{\theta}t^2 + \dot{\theta}_0 t + \theta_0 \tag{5.44}$$

$$\dot{\theta}(t) = \dot{\theta}_0 + \ddot{\theta}t \tag{5.45}$$

$$\dot{\theta}(t_b) = \ddot{\theta}t_b \tag{5.46}$$

在连接点处直线段与二次多项式段速度相等：

$$\ddot{\theta}t_b = \frac{\theta_z - \theta_b}{t_z - t_b} = \frac{\frac{\theta_m - \theta_b}{2} - \left(\frac{1}{2}\ddot{\theta}t_b^{\,2} + \theta_0\right)}{\frac{t_m}{2} - t_b} \tag{5.47}$$

整理得：

$$\ddot{\theta}t_b^{\,2} - \ddot{\theta}t_m t_b + (\theta_m - \theta_0) = 0 \tag{5.48}$$

解得：

$$t_b = \frac{\ddot{\theta}t_m - \sqrt{\ddot{\theta}^2 t_m^{\,2} - 4\ddot{\theta}(\theta_m - \theta_0)}}{2\ddot{\theta}} \tag{5.49}$$

并且根号下判别式需要非负：

$$\ddot{\theta} \geq \frac{4(\theta_m - \theta_0)}{t_m^{\,2}} \tag{5.50}$$

从上式可以看出二次项过渡段的过度时间大小与角加速度相关，如果取最小的角加速度：

$$t_b = \frac{t_m}{2} = t_z \tag{5.51}$$

这意味着规划出的轨迹没有直线段，只有两个彼此平滑连接的二次项曲线。如果加速度变大，那么二次项过渡段的长度将越来越小，当处于极限状态时，路径变为完全的直线连接。

中国知网 https://www.cnki.net

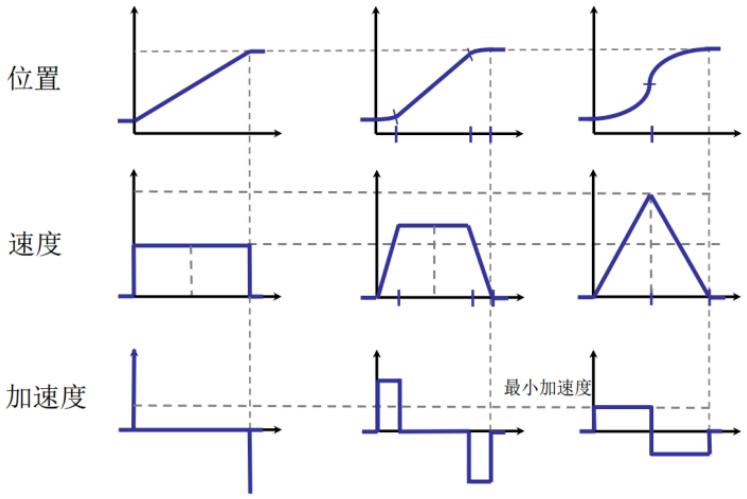


图 5.5 不同情况的过渡规划轮廓曲线

Fig. 5.5 Transition planning contour curves in different situations

图 5.5 所示为直线段运动轨迹无二次项过渡、有二次项过渡以及有二次项过渡且使用最大加速度时的位置、速度以及加速度示意图。标准的速度轮廓曲线是一个梯形，如果加速度比较大，则变为一个三角形。

5.3.2 运动块环形队列原理

发送给机械臂的每一条指令最终都可以转化为机械臂 6 个关节位置的变化量。定义关节每次根据指令需要运动的距离为一个结构体类型，称之为“运动块”。每一个运动块实际上都对应着一个在首尾部分由二次曲线与相邻的前后运动块进行平滑过渡的轨迹。如图 5.6 所示为一个运动块所对应的梯形速度轮廓曲线，速度轮廓曲线与时间轴所包围部分的面积就是该轨迹所对应的移动距离。

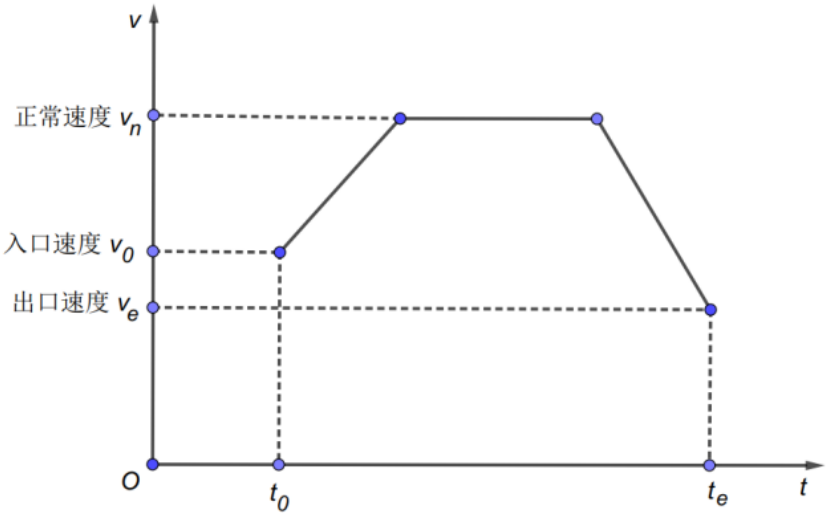


图 5.6 一个运动块的梯形速度轮廓曲线

Fig. 5.6 Trapezoidal velocity profile curve of a moving block

中国知网 https://www.cnki.net

一般情况下，每个运动块都包括 3 个速度：梯形轮廓的入口速度、出口速度和正常运动速度。显然，一个运动块的入口速度需要与它前边相邻运动块的出口速度相等，它的出口速度需要与它后边相邻运动块的入口速度相等，这样块与块之间才能够实现运动过程中速度的平滑连接。每个运动块还包括 3 个运动阶段：加速阶段、匀速阶段以及减速阶段。但是并不是每一个运动块都会包含完整的 3 个运动阶段，它可能只包含 3 个阶段中的一个或者两个。

如图 5.7 所示，发送给机械臂进行执行的指令是按照时间顺序一个一个发来的，它是一个动态的过程。本文采用计算机数据结构当中的环形队列数据结构[126]来储存需要按照时间顺序逐个执行的运动块结构。

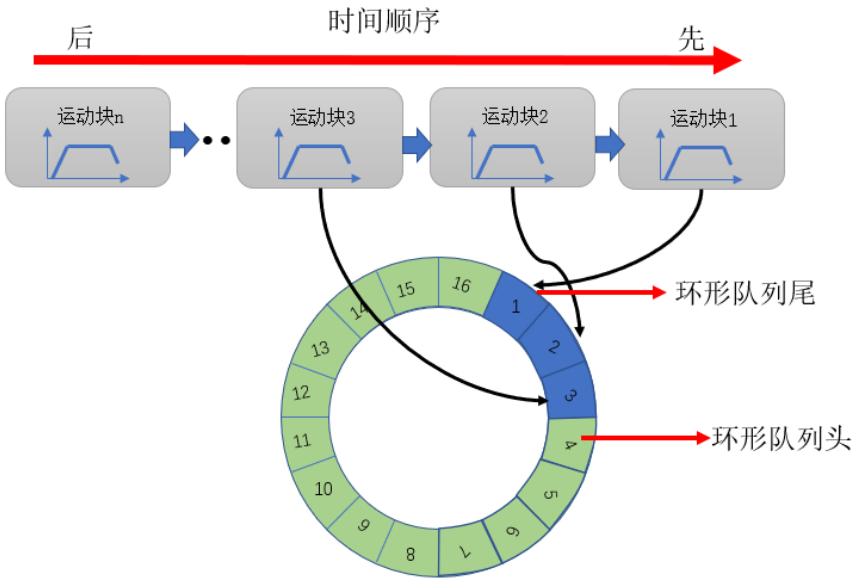


图 5.7 按照时间顺序放入环形队列中的运动块

Fig. 5.7 Motion blocks placed in the circular queue in chronological order

环形队列是一种遵循先进先出(FIFO)原则的首尾相连数据结构。图 5.7 中按照时间先后顺序有 3 个运动块被放入了环形队列当中。下一个运动块将要放入的位置被称为环形队列头，最先被放入运动块的位置称为环形队列尾。

中国知网 https://www.cnki.net

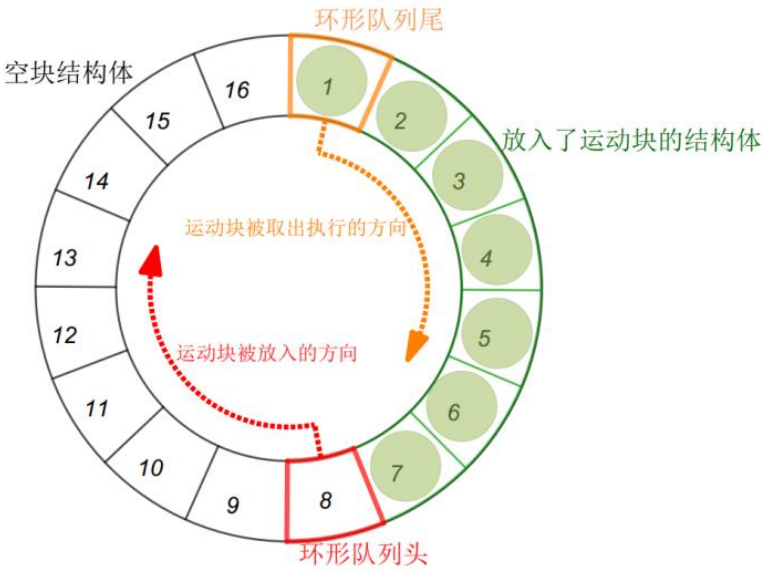


图 5.8 环形队列的动态运行过程

Fig. 5.8 Dynamic running process of circular queue

在运动块被机械臂执行时，按照先入先出的原则，先执行队列尾部的运动块，然后从队列尾部向队列头部继续依次执行队列中的运动块。在此过程中，新发送给控制系统的运动块将继续按照顺序被放入环形队列的头部。环形队列当中的运动块数据处于一种不断从头部填充，同时不断从尾部被取走执行的动态过程当中。如果队列尾部追到与队列头部重合，表明此时环形队列为空，所有运动块都已经被执行完毕。如果队列头部追到了队列尾部，表明环形队列被放满，需要暂时停止向队列头放入新的运动块，等待队列尾部的运动块被取出执行一部分后再继续放入运动块。上述过程在实际的编程操作中通过建立运动块的结构体数组并且循环数组的序号来实现。环形队列的动态运行过程如图 5.8 所示。

5.3.3 前瞻控制算法

前瞻控制算法[127]在运动控制系统中起着非常重要的作用。它主要应用于高端 CNC 数控加工设备的运动控制系统中，先进的前瞻控制技术是各个运动控制器厂家的核心技术之一。

前瞻控制就是在运动控制系统接收到运动块但还未进行运动之前，对所接收运动块的速度轮廓曲线进行提前规划，使得相邻运动块之间的入口与出口速度能够首尾相接，从而使运动过程光滑平稳。对于保存在环形队列当中的运动块，前瞻控制算法使已经进入其中但还未执行运动块之间的速度相互衔接。并且当有新的运动块进入环形队列中时，需要将新进入的运动块纳入速度前瞻重新规划整体的运动速度。因此，在环形队列中进行前瞻速度规划的过程同样是一个随着新进入的运动块而不断进行的动态过程。

中国知网 https://www.cnki.net

本文所设计的针对环形队列中运动块的前瞻控制速度规划过程按照下述过程进行：

（1）将运动块打包成结构体放入环形队列

如果放入的运动块是放入的第一个块，则该运动块的入口速度设置为 0。如果运动块是最后一个被放入的块，则该运动块的出口速度为 0。对于其他运动块，比较要放入运动块的正常速度 v_{nomal} 与前一个运动块的正常速度 v_{nomal_pri}，如果 v_{nomal} 与 v_{nomal_pri} 方向相反，设置当前块的入口速度为 0，否则设置当前运动块的入口速度为 v_{nomal} 与 v_{nomal_pri} 中的较小值。经过上述的初步速度约束规划，每一个运动块都有一个初步的入口速度值，记为 v_{entry}。

（2）反向动态规划过程

当放入一个新的运动块时按照（1）中的原则初步设置运动块的速度限制。然后进行反向动态规划过程，反向规划是为了在满足最大加速度约束的条件下，保证环形队列中的最后一个块一定可以减速到 0。因此需要从环形队列头部的运动块向环形队列尾部反向进行速度规划。图 5.9 表示了反向规划开始的最后一个块位置，以及反向规划进行的方向。

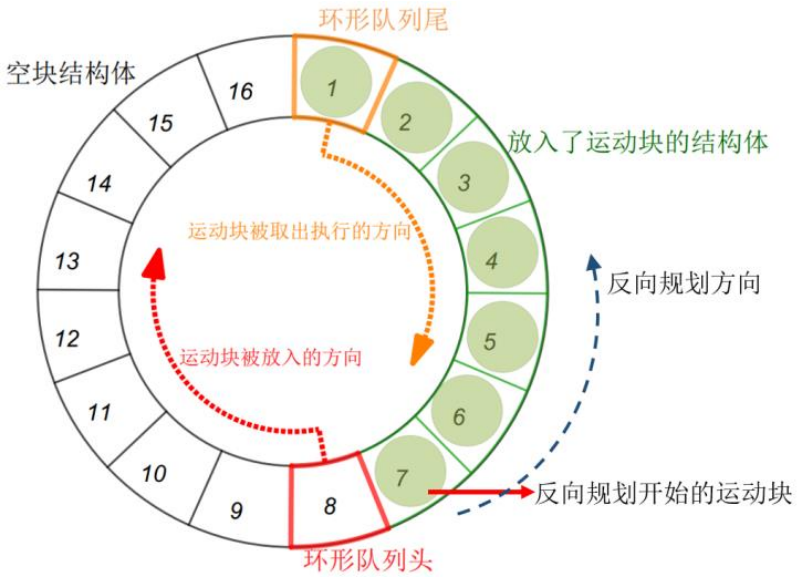


图 5.9 反向规划开始的运动块以及规划方向

Fig. 5.9 The movement block at the beginning of the reverse planning and the planning direction

A、首先规划队列头部最后一个运动块的入口速度：

$$v_{entry}' = \min\left(v_{entry}, 2a_{\max}s\right) \tag{5.52}$$

式(5.52)中 v_{entry} 表示该运动块初步规划的入口速度，$a_{\max}$ 表示最大加速度，s 表示该运动块要移动的距离，对于关节而言表示该关节需要运动的角度值。式(5.52)

中国知网 https://www.cnki.net

中的速度限制是为了保证执行的运动最后一定可以停止，即最后一个运动块的出口速度一定要下降到 0。按照最大加速度反推该块的入口速度，如果即使按照最大加速度从入口处就开始减速，保持全程减速，都无法保证最终能够减速到 0，那么就必须减小原先初步规划的入口速度到$2a_{\max}s$。

B、继续向前规划，如果环形队列只有 2 个运动块，则无需继续进行反向规划。

C、如果环形队列中存在 3 个以上的运动块。如图 5.10 所示，将要进行规划的运动块指针从已经完成规划的最后一个块向前移动一个块，指向倒数第二个块。

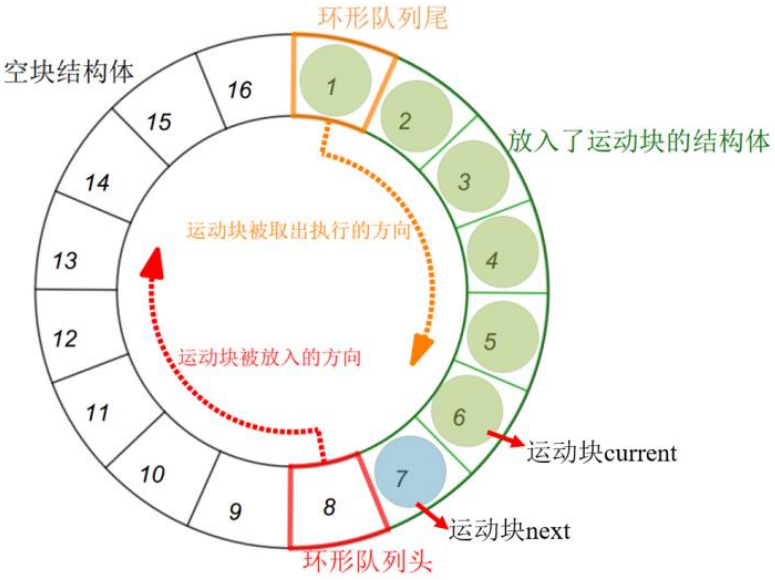


图 5.10 当前运动块与下一个已经规划好的运动块

Fig. 5.10 The current motion block and the next planned motion block

将当前要进行规划的运动块称为 current 运动块，将之前刚刚规划好的运动块称为 next 运动块。规划当前 current 块的入口速度为：

$$v_{entry_current}' = \min\left(v_{entry_current}, v_{entry_next} + 2a_{\max_current}s_{current}\right) \tag{5.53}$$

式(5.53)中$v_{entry_current}$表示当前块初步规划时的入口速度，v_{entry_next}表示 next 块的入口速度，它是上一步已经进行过规划的速度，$a_{\max_current}$表示当前块的最大加速度，$s_{current}$表示当前块的移动距离。式(5.53)的速度约束条件保证最后执行的块速度能够减小到 0。如果按照当前块的最大加速度进行从入口处就开始减速，仍然无法在出口处减小到下一个块的入口速度v_{entry_next}，则需要减小当前块的入口速度到$v_{entry_next} + 2a_{\max_current}s_{current}$。

D、如图 5.11 所示，继续将运动块指针向前移动一个块，继续按照 C 步骤中的方法进行速度规划，直到规划完环形队列中所有的运动块。

中国知网 https://www.cnki.net

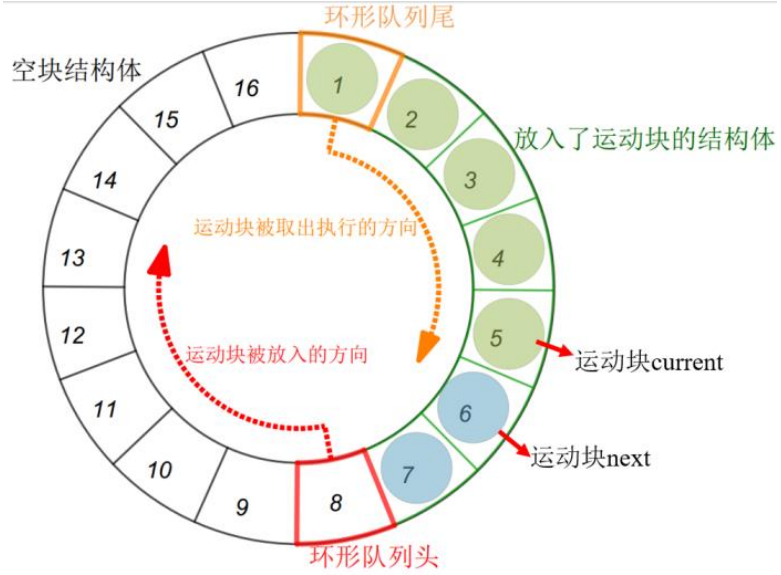


图 5.11 反向规划过程

Fig. 5.11 Reverse planning process

（3）正向动态规划过程

反向规划按照保证最后一个运动块的速度能够减速到 0 的原则从后向前规划环形队列中所有运动块的速度，它判断的是每个运动块的减速能力。正向规划则是从环形队列的尾部，按照块执行顺序从前向后判断运动块的加速能力。

如图 5.12 所示，将当前要进行正向规划的运动块称为 current 块，将与之相邻的下一个块称为 next 块。

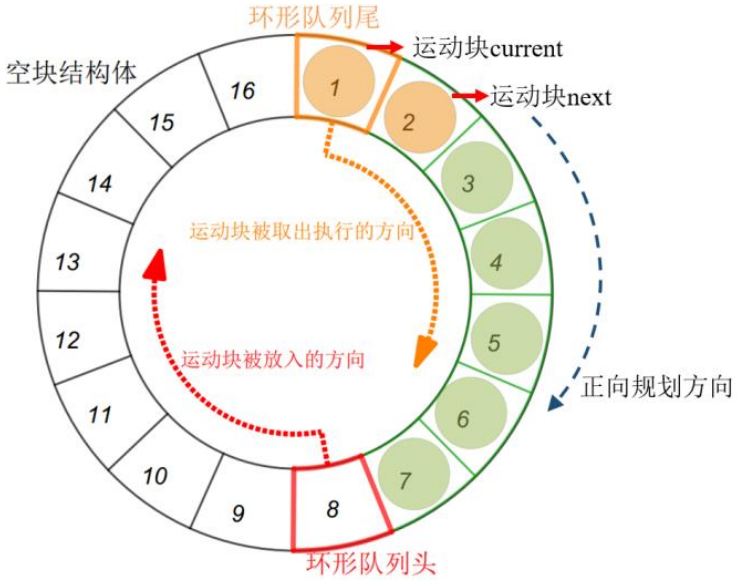


图 5.12 正向规划过程中的相邻块与方向

Fig. 5.12 Neighboring blocks and directions in the forward planning process

首先判断如果：

中国知网 https://www.cnki.net

$$v_{entry_current} < v_{entry_next} \tag{5.54}$$

即判断当前块是加速过程还是减速过程，如果是需要减速的过程，则该块不需要考虑重新规划，因为在反向规划中已经考虑了减速能力。如果是加速过程则继续进行规划。规划当前块的出口速度，也就是下一个块的入口速度为：

$$v_{entry_next}' = \min\left(v_{entry_next}, v_{entry_current} + 2a_{\max_current}s_{current}\right) \tag{5.55}$$

式(5.55)中，v_{entry_next} 表示下一个块先前规划好的入口速度，$v_{entry_current}$ 表示当前块先前规划好的入口速度，$a_{\max_current}$ 表示当前块的最大加速度，$s_{current}$ 表示当前块的移动距离。式(5.55)表示如果当前块是一个需要加速的块，那么从当前块的入口速度开始一直加速到块结束所得到的速度必须大于下一个相邻块先前规划好的入口速度，否则应该减小下一个块的入口速度到 $v_{entry_current} + 2a_{\max_current}s_{current}$ 。

然后继续移动运动块指针，按照上述的正向规划方法进行正向动态规划，直到环形队列头部位置。

（4）重规划

当环形队列中已有的运动块进行完毕上述的反向与正向规划，当再有新的运动块被放入环形队列中时，需要重新按照上述的反向与正向过程规划速度，保证新加入的运动块融入原来的速度体系中，它们的速度轮廓曲线始终都在上述动态的规划过程中保持连续。

5.3.4 速度轮廓曲线

对环形队列中的每一个运动块按照一定原则进行速度前瞻规划并得到其入口速度后，可以进一步根据每一个运动块的速度与加速度来计算具体的速度轮廓曲线。

如图 5.13 所示为一个完整的梯形速度轮廓曲线示意图，整个过程可以分为加速过程、减速过程和匀速过程，但是实际运动块的速度轮廓曲线可能并不完全包含完整的 3 个过程，可能是一直加速，一直减速或者加速后匀速，匀速后减速等过程。具体确定一个运动块速度轮廓曲线形状的过程如下：

（1）计算运动块速度轮廓加速段与减速段可能存在的交点与运动块结束位置的距离

图 5.13 中的 s_2 为运动块速度轮廓加速段与减速段可能存在的交点与运动块结束位置的距离。

中国知网 https://www.cnki.net

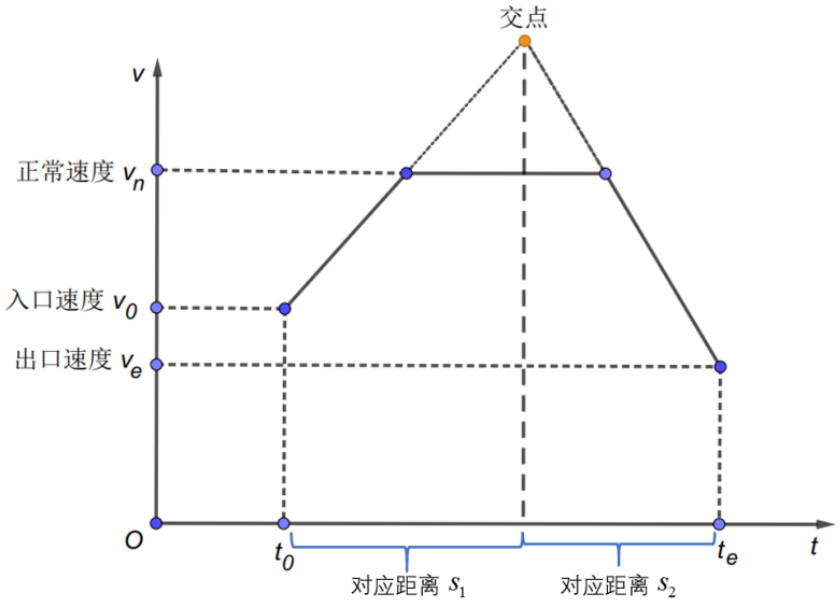


图 5.13 加速段与减速段可能存在的交点距离运动块结束位置的距离

Fig. 5.13 The distance between the possible intersection of the acceleration section and the deceleration section from the end position of the moving block

交点处速度记为v_m，运动块的总移动距离记为s，交点左侧移动距离记为s_1，所求距离为s_2。

$$\begin{cases} v_m^2 - v_0^2 = 2as_1 \\ v_m^2 - v_e^2 = 2as_2 \\ s_1 + s_2 = s \end{cases} \tag{5.56}$$

解得：

$$s_2 = \frac{1}{2}\left[s + \frac{1}{2a}\left(v_0^2 - v_t^2 \right) \right] \tag{5.57}$$

首先判断距离s_2的正负，如果s_2小于等于 0，说明该运动块没有减速部分，全程为加速状态，且它的出口速度就是该块的最大速度，如图 5.14(a)所示。

如果s_2大于 0，再进一步判断s_2与块全程距离s之间的关系。如果s_2大于等于s，说明该运动块全程减速，且它的入口速度就是该块最大速度，如图 5.14(b)所示。

如果s_2小于s，说明该运动块的速度轮廓为梯形或者三角形。进一步计算该运动块的减速距离s_d：

$$s_d = \frac{1}{2a}\left(v_n^2 - v_e^2 \right) \tag{5.58}$$

式(5.58)中，v_n表示块的匀速速度，v_e表示块的出口速度。如果s_2小于等于s_d，说明该块的速度轮廓是三角形，如图 5.14(c)所示，块最大速度为三角形尖端速度：

中国知网 https://www.cnki.net

$$\sqrt{2as_2+v_e^2} \tag{5.59}$$

如果s_2大于s_d，该块速度轮廓为梯形，最大速度为匀速速度。进一步判断如果该块的入口速度等于匀速速度，则该梯形形状为匀速以及减速段结合，如图 5.14(d)。如果该块的入口速度不等于匀速速度，则该梯形形状为完整的 3 阶段梯形或者加速后匀速段结合的梯形，如图 5.24(e)(f)。

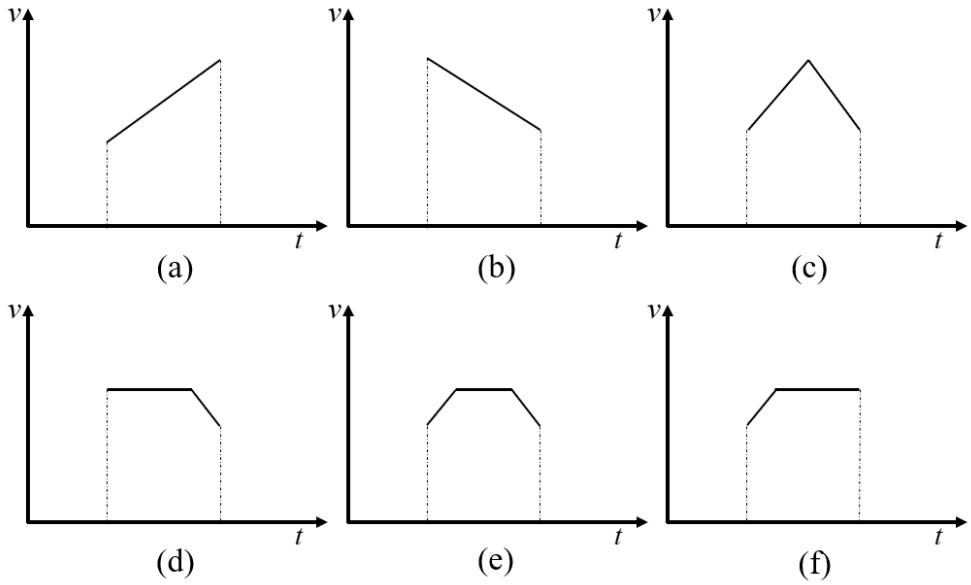


图 5.14 不同类型的速度轮廓曲线

Fig. 5.14 Different types of speed profile curves

5.3.5 基于 Leib Ramp 算法的脉冲输出

Leib Ramp 算法[128]，最初由美国国际商业机器公司(IBM)工程师 Aryeh Eiderman 于 1994 年提出，并于 2004 年第一次被移植到嵌入式平台。该算法最初设计的目的是为了使 IBM 所生产的电脑能够通过并行接口同时控制 4 个基于脉冲控制的电机联动。Leib Ramp 算法的原理是将控制器中规划好的速度轮廓曲线与嵌入式单片机的计数器脉冲中断响应频率关联起来，通过控制单片机的中断响应频率或者计数器的计数次数来控制其输出脉冲的频率。

该算法的具体做法为：将规划好速度的每个运动块按照时间片 *dt* 拆分成段，根据要移动的速度计算脉冲时间间隔，然后换算成单片机中断响应定时器的定时设置值。将每个段对应的定时器设置值放入中断响应的定时器中，就可以精确控制每个段对应脉冲的频率，即运动块的速度轮廓曲线所对应的速度值。

中国知网 https://www.cnki.net

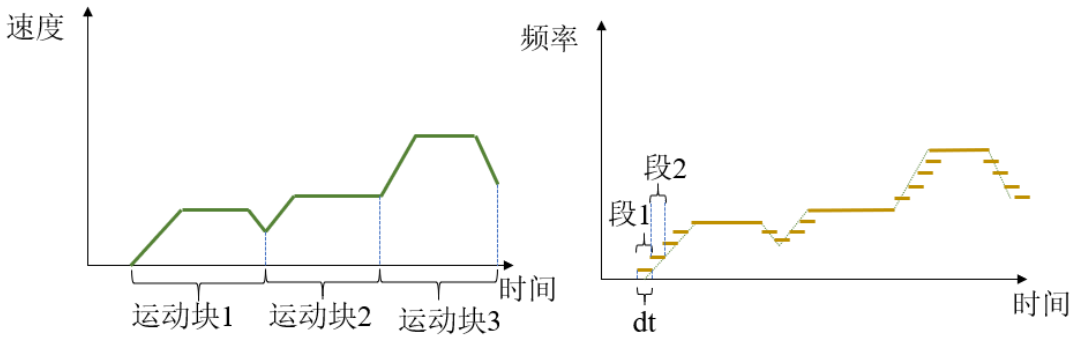


图 5.15 速度轮廓曲线的运动块与段的转换关系示意图

Fig. 5.15 Schematic diagram of the conversion relationship between the moving block and the segment of the velocity profile curve

如图 5.15 所示为运动块与段的转换示意图，这种转化相当于近似在短暂时间片 *dt* 内运动块的速度不变，即微控制器发送脉冲的频率不变。每个段对应的单片机定时器的定时值都不相同，按照段的顺序依次修改定时器的定时值。

5.4 机械臂运动控制系统整体运行原理与测试

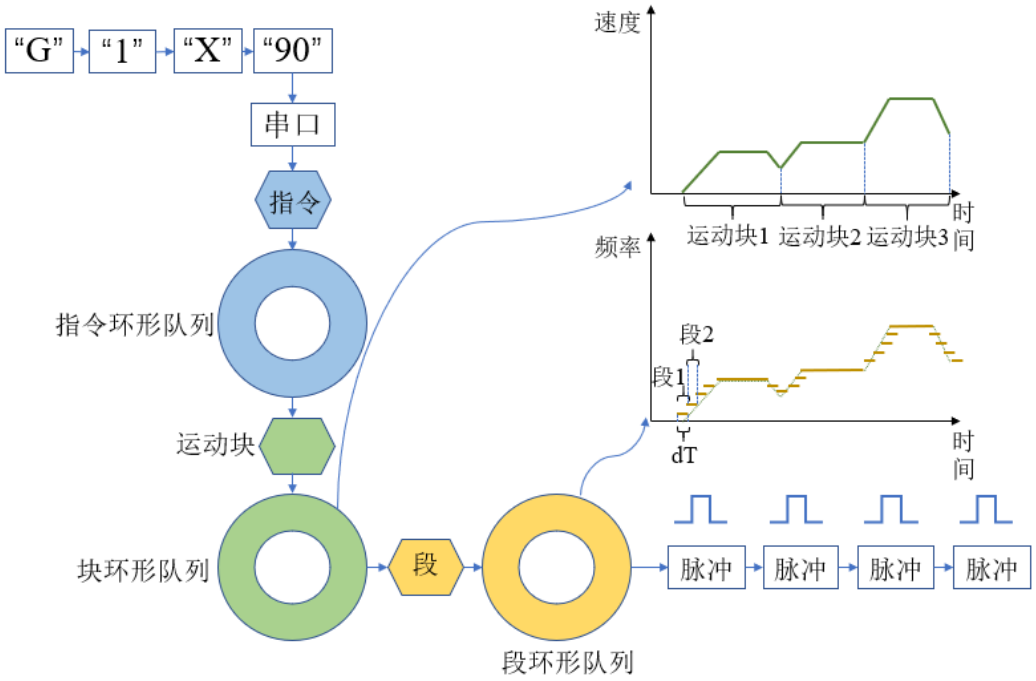


图 5.16 机械臂运动控制系统整体运行原理

Fig. 5.16 The overall operating principle of the robotic arm motion control system

图 5.16 所示为本文设计的机械臂运动控制系统整体运行原理。采用传统数控加工中最常使用的 G 代码作为其指令系统，由于收到的指令可能很多，因此同样

中国知网 https://www.cnki.net

按照运动块环形队列的机制设置指令环形队列。串口发来的指令经过初步的解析后，被送入指令环形队列中，如果收到的指令是角度转动指令，则直接构建每条运动指令为运动块并依次放入块环形队列中，进行前瞻速度规划，规划出能够将块与块之间相互平滑连接的梯形速度轮廓曲线。然后构建段环形队列，将速度轮廓曲线转换为单片机实际执行发出脉冲所使用的定时器装载定时值，最终由单片机的中断响应向外发出供机械臂各个轴电机驱动器运动的脉冲信号，驱动机械臂的关节运动。

为了测试基于前瞻算法的机械臂运动控制系统的实际效果，课题组开发了 Mirobot 机械臂的上位机软件。该软件能够对输入的图形曲线进行离散处理，并通过运动学逆解转换笛卡尔空间点到关节构形角度值。然后按照时间顺序将离散的关节构形序列下发给机械臂。机械臂的运动控制系统通过本章设计的基于前瞻算法的关节空间轨迹规划方法实现运动块的速度前瞻控制，最终控制各个电机运动。

实际实验时，在上位机软件中输入汉字“永”，如图 5.17 所示。然后将离散化的关节构形序列下发给 Mirobot 机械臂执行。机械臂末端适当位置通过夹具安装了一支笔，下方为画板。

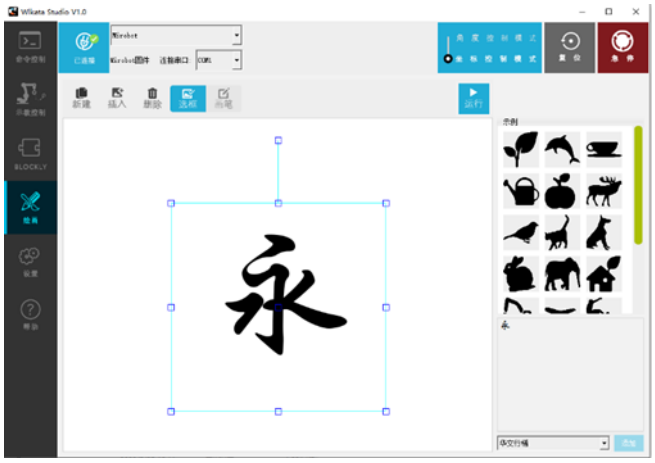


图 5.17 上位机软件中输入的汉字“永”

Fig. 5.17 The Chinese character "Yong" entered in the upper computer software.

如图 5.18 所示，为 Mirobot 机械臂书写汉字“永”的最终效果。可以看出书写过程平滑，位置准确。

中国知网 https://www.cnki.net

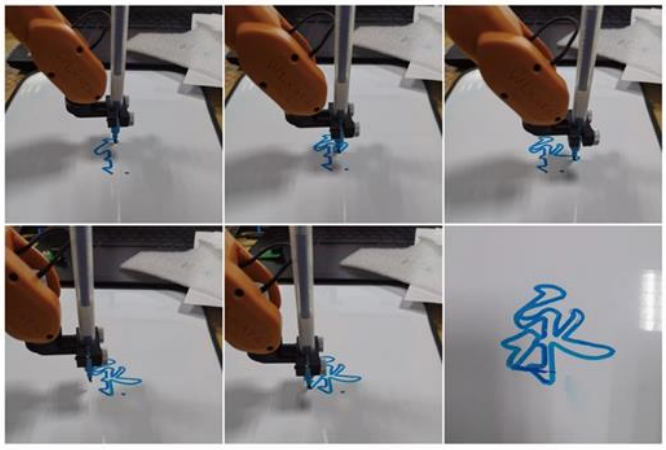


图 5.18 Mirobot 机械臂书写汉字“永”

Fig. 5.18 The Chinese character "Yong" is written by Mirobot robotic arm.

5.5 本章小结

（1）本章首先对 Mirobot 机械臂的运动学进行建模分析。

（2）阐述了机械臂运动规划与轨迹规划之间的关系，先进行运动规划得到离散的关节角度序列，然后进行轨迹规划，将离散的角度序列用关于时间的函数平滑连接。

（3）针对按照时间序列发送给运动控制系统的离散角度指令，设计了运动块环形队列机制，并将速度前瞻算法引入其中，通过对运动块速度的前瞻规划，保证了机械臂底层运动控制系统在接收连续动态指令时运动的连续性以及平稳性。

（4）对基于前瞻算法的机械臂运动控制系统进行了测试，为进一步将使用前述章节提出方法进行训练得到的机械臂智能体应用于真实环境中的机械臂实物控制做好准备。

中国知网 https://www.cnki.net

6 机械臂的实物控制实验

本章进行了强化学习智能体对于机械臂实物的控制实验。真实环境实验与 V-REP 中的虚拟实验有很大区别，主要区别在于虚拟仿真环境可以随意的获取任何物体的位姿并且可以任意的转换其位姿相对关系，但是实际控制中需要采用视觉等其他辅助传感手段获取物体的位姿。

在进行实物控制实验时，首先在虚拟环境中构建与实际物体相同大小尺寸的虚拟物体模型，然后采用视觉方法获取真实环境中障碍物与目标物体的实际位姿，从而在虚拟环境中确定障碍物与目标物体的准确位姿。接着采用前文提出的残差强化学习运动规划方法与课程强化学习训练方法在有障碍物的虚拟环境当中完成对强化学习智能体的训练，最后使用在虚拟环境中训练完成的强化学习智能体控制实际环境中的机械臂完成控制实验。

针对实际控制实验中物体位姿的获取问题，本章首先引入了基于二维码标签的视觉位姿获取方法，并将其应用于本文的机械臂实物控制实验当中；然后介绍了相机的内参与外参标定方法，机械臂的手眼标定方法；随后提出了一种基于 V-REP 虚拟仿真平台的虚实机械臂同步控制方法并进行了实物控制实验。

6.1 基于 ArUco 标签的物体位姿估计方法

许多文献采用在虚拟环境中进行强化学习相关算法的大量试错训练，再将训练好的强化学习智能体应用于真实机械臂控制的方法。在实际操作中，为了获取实际的物体位姿，文献[73, 75]采用深度摄像机配合相应的模板匹配[129]和 YoLo[130]视觉方法来估计实际物体的位姿，这一类方法需要采用 Kinect 等深度摄像头并针对 3 维视觉估计与点云建模进行专门的课题研究。另外一些文献则在进行深度强化学习训练时直接将摄像头的图片输入给增加了神经网络卷积层的强化学习算法进行端到端的训练[131]，这一类方法能够将输入给智能体的图像与其策略动作直接关联，但是图像与卷积层的加入使算法的训练变得缓慢并且不易收敛。

本文采用了一种在计算机视觉领域得到广泛应用的二维码 ArUco 标签来进行物体位姿估计的方法。ArUco 标签的形式如图 6.1 所示，最初由学者 Jurado [132]提出。它是一种包含了黑色和白色正方形方块的二维码标签，主要应用于计算机视觉领域的位姿估计，其优点是能够使用普通单目摄像头而不依赖于深度摄像头来进行物体的位姿估计，鲁棒性很强，检测速度快并且实现起来非常简单。在实际使用中，仅需要设计标签的尺寸以及每个标签所对应的唯一 ID 号码进而生成对应的 ArUco 标签[133]，然后将该标签打印并粘贴于需要估计位姿的物体表面再用一枚经

中国知网 https://www.cnki.net

过参数矫正的摄像头对标签进行拍摄即可。

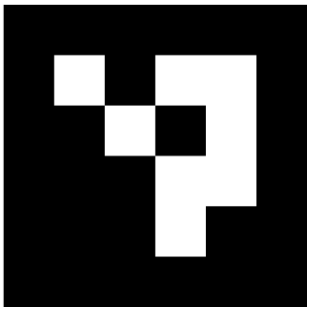


图 6.1 ArUco 标签

Fig. 6.1 ArUco tag

ArUco 标签的最外部一圈为黑色的边界，黑色边界的内部方格表示的是一组二进制的矩阵数据，矩阵的大小称为该 ArUco 标签的大小，矩阵的内容包括奇偶校验信息以及数据信息。图 6.1 所示为内部大小为5×5方格的 ArUco 标签，该标签表示的有效方格需要除去外部一圈的黑色边界方格，其内部的方格中，黑色的方格表示数值 0 而白色的方格表示数值 1。内部方格的第 1、3 和第 5 列表示该标签的奇偶校验位，第 2 和第 4 列表示该标签实际包含的数据，该标签的数据位为 10 位，能够表示的数据大小为2^{10}。

ArUco 标签项目依赖于开源的机器视觉库 OpenCV(Open Source Computer Vision Library)。OpenCV 项目是由英特尔公司于 1999 年发起，能够用于图像处理、计算机视觉以及模式识别的跨平台计算机视觉库[134]。OpenCV 支持 Python, Java 和 MATLAB/OCTAVE 接口，相比于 Halcon[135]等广泛使用的商业视觉软件，采用 OpenCV 库能够大幅度降低计算机视觉项目的开发成本。

使用相机拍摄 ArUco 标签，而后经过一系列的计算能够转换得到标签坐标系相对于相机坐标系的齐次变换矩阵，该过程如图 6.2 所示：

中国知网 https://www.cnki.net

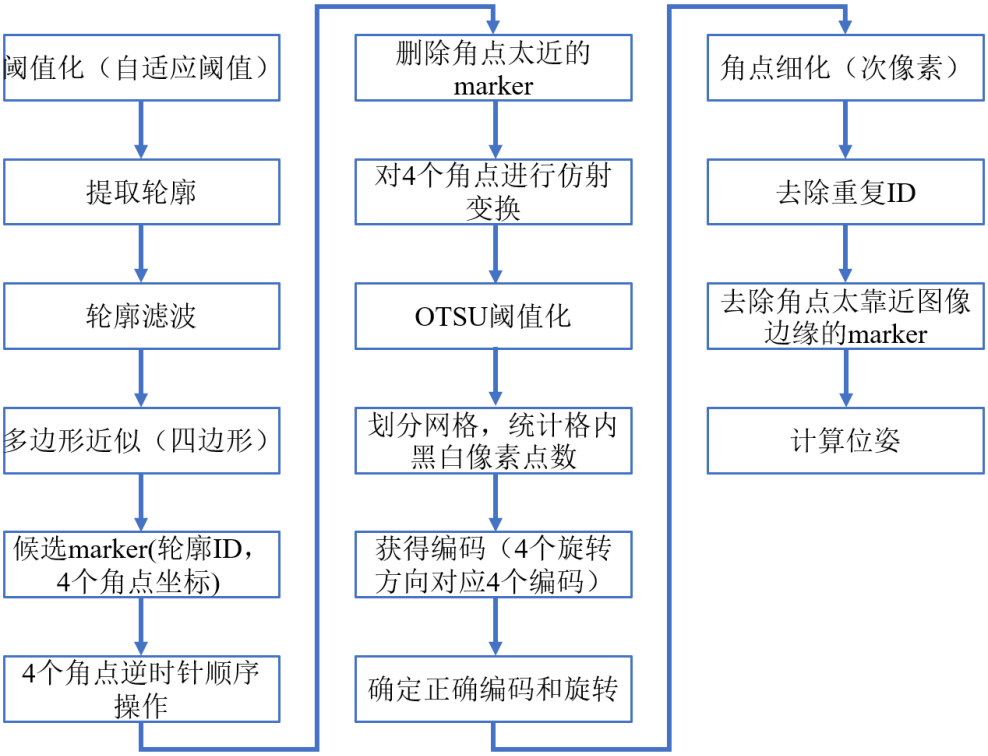


图 6.2 ArUco 标签的计算处理过程

Fig. 6.2 ArUco label calculation process

如图 6.3 所示为采用 OpenCV 对拍摄到的 ArUco 标签进行解析，进而得到标签中心处的位姿。其中的蓝色坐标轴为 Z 轴，垂直于标签所在平面向外，红色坐标轴为 X 轴，绿色坐标轴为 Y 轴。坐标原点位于 ArUco 标签的中心位置。

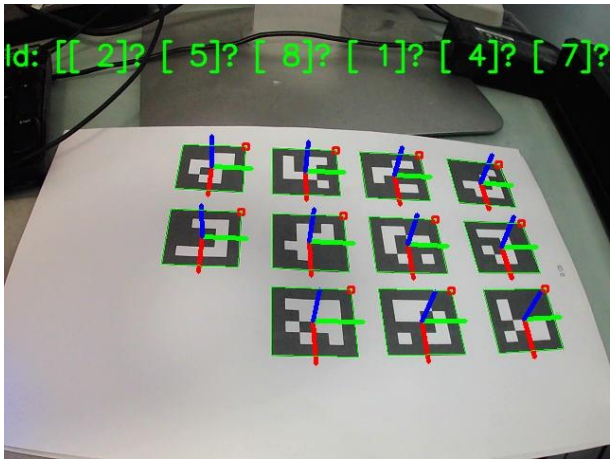


图 6.3 ArUco 标签所确定的位姿坐标系

Fig. 6.3 Pose coordinate system determined by ArUco tag

本文采用 OpenCV 解析 ArUco 标签。在每个环境物体的中心位置粘贴一枚 ArUco 标签，如图 6.4 所示，用普通的单目 USB 摄像头拍摄这些物体，便能够得到每个物体中间位置的位姿，进而得到第 3 章所提出障碍物抽象球体的球心所在

中国知网 https://www.cnki.net

的位置。

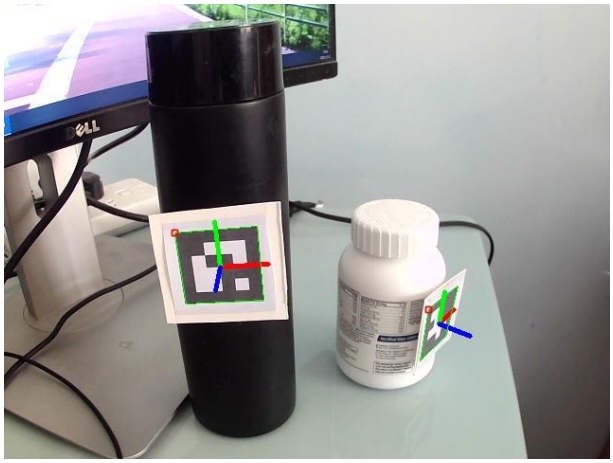


图 6.4 用 ArUco 标签确定实际障碍物球体位置

Fig. 6.4 Use ArUco tags to determine the actual obstacle sphere position

6.2 相机标定

在使用相机对拍摄的 ArUco 标签进行位姿估计之前需要对相机进行参数标定。通过相机标定来确定所使用相机的内参、外参以及镜头畸变系数。通过建立相机成像过程的模型来推导相机图像中的像素点与所拍摄工作空间中对应点的坐标关系。

6.2.1 像素坐标系与图像坐标系的关系

相机拍摄到的图像由大量的像素点构成，而图像左上角位置的像素点为像素位置$(0,0)$，如图 6.5 中的O_{pixel}点，该处的坐标系称为像素坐标系。像素坐标系所描述的图像点位置不利于坐标变换进行，因此定义使用物理长度尺寸（毫米）表示位置的图像坐标系，图 6.5 中该坐标系的原点为O_{image}，它是相机镜头光轴与成像平面的交点，即图像的中心点。显然像素坐标系与图像坐标系是平移关系。

中国知网 https://www.cnki.net

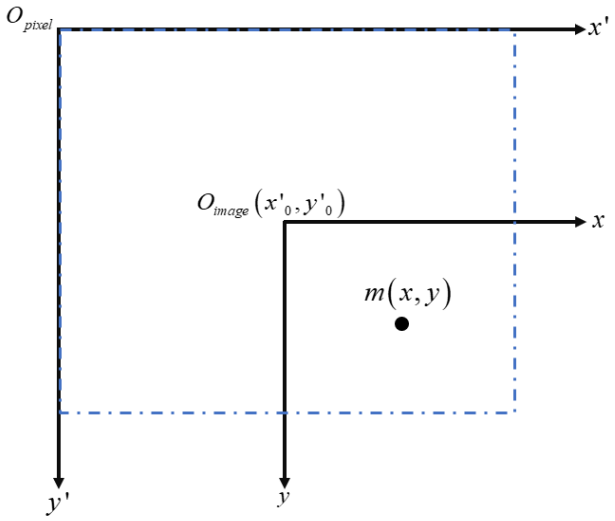


图 6.5 像素坐标系与图像坐标系之间的位置关系

Fig. 6.5 The positional relationship between the pixel coordinate system and the image coordinate system

如图 6.5 所示，在图像坐标系 $xO_{image}y$ 中点 m 的坐标为 (x,y)，则根据像素与相机传感器芯片物理距离之间的比例关系以及坐标的平移关系可得：

$$\begin{cases} x' = \dfrac{x}{dx} + x'_0 \\ y' = \dfrac{y}{dy} + y'_0 \end{cases} \tag{6.1}$$

式(6.1)中的 dx 和 dy 表示像素与相机传感器芯片的物理距离之间的比值。进一步将上述的关系公式改写为矩阵形式：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \dfrac{1}{dx} & 0 & x'_0 \\ 0 & \dfrac{1}{dy} & y'_0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \tag{6.2}$$

6.2.2 图像坐标系与相机坐标系的关系

如图 6.6 所示为图像坐标系中任意一点与其空间中实际点之间的几何关系。图像坐标系当中的点 $m(x,y)$ 映射到相机坐标系当中的点 $M(x'',y'',z'')$，距离 $\overline{O_{camera}O_{image}}$ 为镜头的焦距 f。

中国知网 https://www.cnki.net

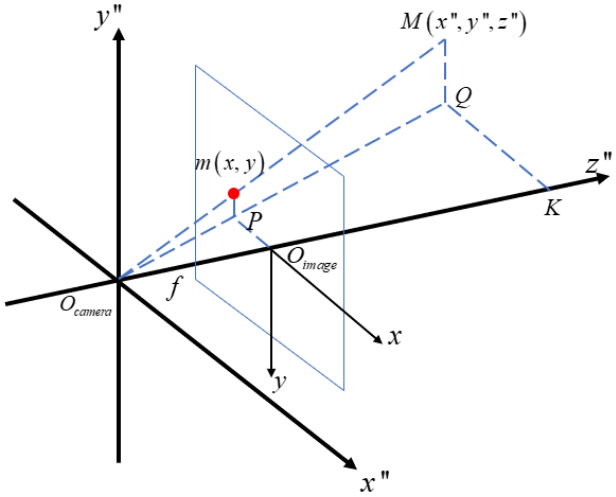


图 6.6 图像坐标系中任意一点与其空间中实际的点之间的几何关系

Fig. 6.6 The geometric relationship between any point in the image coordinate system and its actual point in space

由相似三角形判定定理可知：

$$\begin{aligned} &\triangle KQO_{camera} \sim \triangle O_{image}PO_{camera} \\ &\triangle QMO_{camera} \sim \triangle PmO_{camera} \end{aligned} \tag{6.3}$$

则在两个相似三角形中存在比例关系：

$$\frac{KQ}{O_{image}P}=\frac{KO_{camera}}{O_{image}O_{camera}}=\frac{MQ}{mP}=\frac{x''}{x}=\frac{z''}{f}=\frac{y''}{y} \tag{6.4}$$

因此：

$$x=f\frac{x''}{z''},y=f\frac{y''}{z''} \tag{6.5}$$

将上述代数关系改写为矩阵表示：

$$z''\begin{bmatrix}x\\y\\1\end{bmatrix}=\begin{bmatrix}f&0&0&0\\0&f&0&0\\0&0&1&0\end{bmatrix}\begin{bmatrix}x''\\y''\\z''\\1\end{bmatrix} \tag{6.6}$$

中国知网 https://www.cnki.net

6.2.3 世界坐标系与相机坐标系的关系

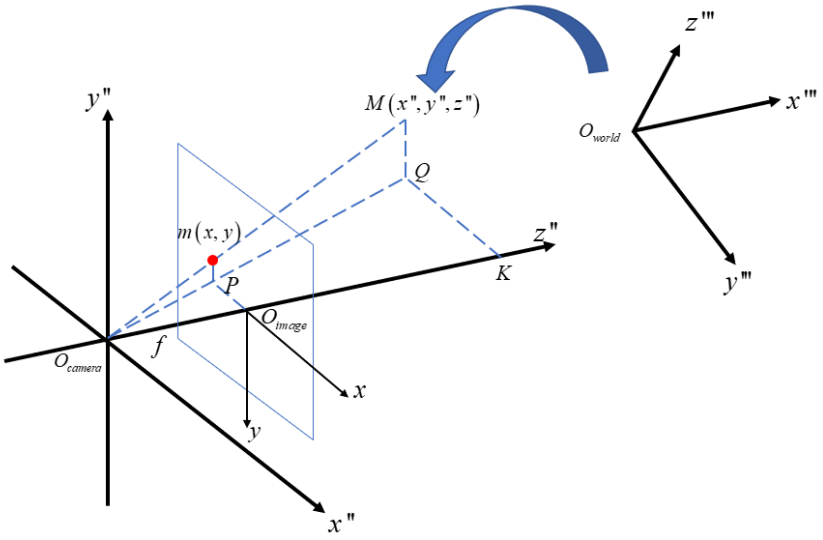


图 6.7 世界坐标系与相机坐标系的位姿关系

Fig. 6.7 The pose relationship between the world coordinate system and the camera coordinate system

如图 6.7 所示为世界坐标系O_{world}与相机坐标系O_{camera}之间的关系，该关系包括平移与旋转：

$$\begin{bmatrix} x" \\ y" \\ z" \end{bmatrix} = R \begin{bmatrix} x''' \\ y''' \\ z''' \end{bmatrix} + Tran \tag{6.7}$$

式(6.7)中坐标(x''', y''', z''')表示空间任意一点 M 在世界坐标系中的位置，坐标$(x", y", z")$则是 M 点在相机坐标系中的位置，矩阵R表示世界坐标系在相机坐标系中的旋转矩阵，它是一个 3*3 的矩阵，$Tran$表示从相机坐标系原点O_{camera}到世界坐标系原点O_{world}之间的平移距离，它是一个维度为 3 的列向量。

进一步将该位姿关系写为齐次变换矩阵形式：

$$\begin{bmatrix} x" \\ y" \\ z" \\ 1 \end{bmatrix} = \begin{bmatrix} R & Tran \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x''' \\ y''' \\ z''' \\ 1 \end{bmatrix} \tag{6.8}$$

6.2.4 相机的内参与外参

将式(6.2)、式(6.6)与式(6.8)联立可得：

中国知网 https://www.cnki.net

$$z''\begin{bmatrix}x'\\y'\\1\end{bmatrix}=\begin{bmatrix}\frac{1}{dx}&0&x'_0\\0&\frac{1}{dy}&y'_0\\0&0&1\end{bmatrix}\begin{bmatrix}f&0&0&0\\0&f&0&0\\0&0&1&0\end{bmatrix}\begin{bmatrix}R&Tran\\0&1\end{bmatrix}\begin{bmatrix}x'''\\y'''\\z'''\\1\end{bmatrix}$$
$$=\begin{bmatrix}\frac{f}{dx}&0&x'_0&0\\0&\frac{f}{dy}&y'_0&0\\0&0&1&0\end{bmatrix}\begin{bmatrix}R&Tran\\0&1\end{bmatrix}\begin{bmatrix}x'''\\y'''\\z'''\\1\end{bmatrix} \tag{6.9}$$

式(6.9)中的矩阵$\begin{bmatrix}\frac{f}{dx}&0&x'_0&0\\0&\frac{f}{dy}&y'_0&0\\0&0&1&0\end{bmatrix}$是相机的内参矩阵，$\begin{bmatrix}R&Tran\\0&1\end{bmatrix}$是相机的外参矩阵。

上式中的内参和外参在实际操作中采用张正友标定法[136, 137]可以得到。通过张正友标定法仅需要一个打印好的棋盘格就可以对相机进行内外参数标定。本文采用了普通的 USB 高清摄像头，如图 6.8 所示。



图 6.8 USB 高清摄像头

Fig. 6.8 USB HD camera

在标定过程中用摄像头不断变换不同的拍摄角度拍摄棋盘格，从而获得 30 张标定用棋盘格图片，然后直接调用 OpenCV 视觉库当中的 cv2.calibrateCamera()函数即可对摄像头进行标定。该函数同时可以返回包含 5 个畸变系数的向量，包括径向畸变系数和切向畸变系数。如图 6.9 所示为标定函数在标定过程中进行角点检测。

中国知网 https://www.cnki.net

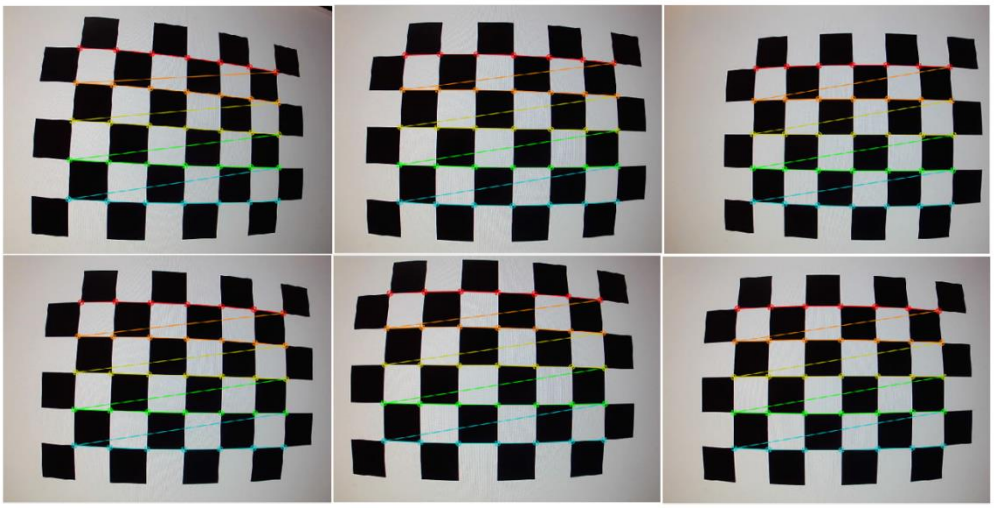


图 6.9 标定棋盘格图片

Fig. 6.9 Calibration checkerboard picture

6.3 手眼标定

在障碍物与目标物体上粘贴 ArUco 标签，从而可以使用经过标定的摄像头获取 ArUco 标签中心位置处的位姿数据。但是该位姿数据是相对于拍摄它的相机坐标系的，机械臂的一切操作都必须依照相对于机械臂基座坐标系的物体位姿来进行，此时需要将相机拍摄并计算得到的相对于相机坐标系的位姿转换为相对于机械臂坐标系的位姿，这是一个将相机坐标系中的位姿左乘齐次变换矩阵的变换过程，通过标定获得这个齐次变换矩阵的过程就是机械臂手眼标定的过程。

机械臂手眼标定方法按照相机与机械臂的相对位置不同可以划分为 2 种类型。如图 6.10 左所示为将摄像头安装在机械臂末端，它与机械臂同时运动，这种类型称为眼在手上(Eye in Hand)类型。另一种类型如图 6.10 右所示，将摄像头独立固定在机械臂周围的某个便于拍摄物体的位置，它不随机械臂一起运动，这种类型称为眼在手外(Eye to Hand)。

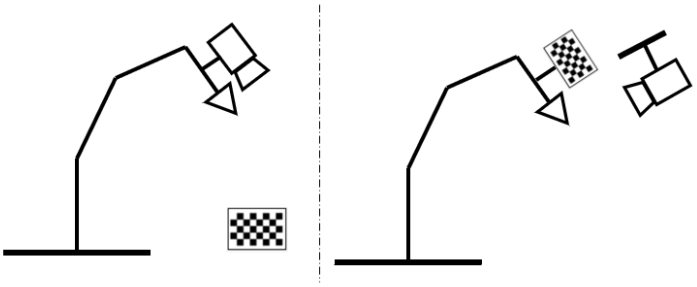


图 6.10 2 种不同的机械臂手眼标定类型

Fig. 6.10 2 different manipulator hand-eye calibration types

中国知网 https://www.cnki.net

本文采用的方式为眼在手外方式，将摄像头用三脚架固定于 Mirobot 机械臂的旁边。对于机械臂任意的两个不同的构形，有如下的齐次变换矩阵关系存在：

$$ {}^{end}_{base1}T\ {}^{base1}_{camera1}T\ {}^{camera1}_{object}T = {}^{end}_{base2}T\ {}^{base2}_{camera2}T\ {}^{camera2}_{object}T \tag{6.10} $$

进行变换后得：

$$ {}^{end}_{base2}T^{-1}\ {}^{end}_{base1}T\ {}^{base1}_{camera1}T = {}^{end}_{base2}T\ {}^{base2}_{camera2}T\ {}^{camera2}_{object}T\ {}^{camera1}_{object}T^{-1} \tag{6.11} $$

式(6.11)当中的齐次变换矩阵 ${}^{end}_{base1}T$ 和 ${}^{end}_{base2}T$ 可以由机械臂的正运动学求解得到，矩阵 ${}^{camera1}_{object}T$ 与 ${}^{camera2}_{object}T$ 可以由摄像头拍摄标定板得到，而矩阵 ${}^{base1}_{camera1}T$ 与矩阵 ${}^{base2}_{camera2}T$ 相等，表示从相机坐标系到机械臂基坐标系的位姿变换矩阵，是需要通过标定求出的手眼标定矩阵。式(6.11)相当于方程：

$$ AX = XB \tag{6.12} $$

针对该方程的求解，可以采用文献[138, 139]的求解方法。

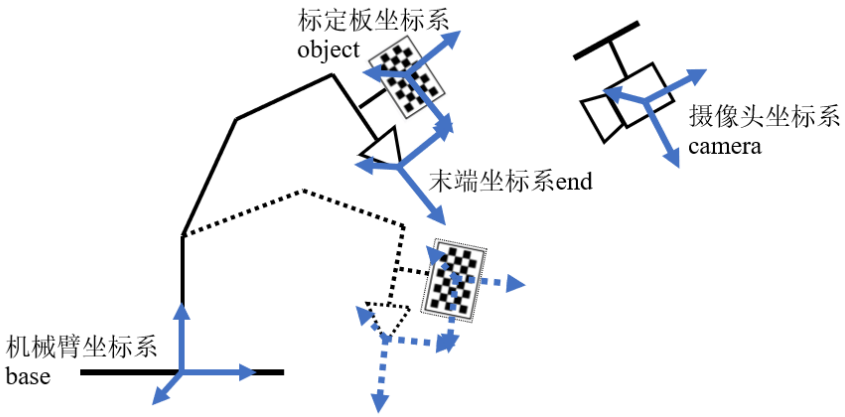


图 6.11 眼在手外标定方式的两个姿态与各个坐标系

Fig. 6.11 Two postures and various coordinate systems of the eye-out-of-hand calibration method

6.4 基于 V-REP 的机械臂虚实同步控制方法

本文通过 ArUco 标签估计实际环境中的物体位姿，然后进行了相机的内外参数标定、机械臂与相机的手眼标定。本小节进一步提出了一种基于 V-REP 的虚实同步控制方法，使用 V-REP 中的虚拟机械臂同步控制真实环境中的机械臂。

6.4.1 虚实同步控制方法

由于所使用的强化学习算法需要对机械臂进行反复的“试错”训练，在真实机械臂上进行这种反复的试错容易损坏机械臂且训练过程十分漫长，所以一般采用在虚拟环境中进行机械臂智能体的训练而后将训练好的智能体迁移到实物机械臂

中国知网 https://www.cnki.net

进行控制的方法。

本章利用 V-REP 虚拟实验平台软件的特性，将虚拟 Mirobot 机械臂的各个关节角度信息实时采集，然后进行协议转换，最后通过串口发送给第 5 章设计的机械臂底层运动控制系统，从而实现了 Mirobot 机械臂的虚实同步控制。实验具体操作过程如下：

（1）V-REP 中虚拟物体的构建

在 V-REP 虚拟环境中构建与实际环境中物体大小尺寸相同的虚拟物体模型。

（2）基于 ArUco 标签的物体位姿估计

按照本章前几小节内容，对摄像头参数进行标定，对摄像头与真实机械臂的相对位姿关系进行手眼标定。然后通过拍摄实际环境中带有 ArUco 标签的物体可以确定它们相对于机械臂的实际位姿，再将得到的障碍物与目标的实际位姿发送给 V-REP 虚拟环境，从而确定虚拟环境中物体相对于机械臂的位姿，构建与实物位姿相同的虚拟环境。

（3）在 V-REP 虚拟环境中进行智能体的训练

在 V-REP 虚拟环境中，采用前文所提出的残差强化学习运动规划方法与课程强化学习训练方法对强化学习智能体进行运动规划训练，得到能够在虚拟环境中成功进行运动规划的虚拟机械臂智能体。

（4）角度信息采集

利用训练好的虚拟机械臂智能体在 V-REP 虚拟环境中进行运动规划。同时在 V-REP 中增加虚拟机械臂关节信息采集线程脚本，利用 API 函数采集虚拟机械臂在进行运动规划时各个关节的状态信息。

（5）角度信息下发机械臂实体

将采集到的机械臂各个关节状态信息按照 Mirobot 机械臂的指令协议格式进行指令构建，然后再通过串口将指令发送给机械臂的底层运动控制系统，从而实现虚拟环境中的机械臂智能体对于实物机械臂的虚实同步控制。

Mirobot 机械臂的指令解析系统内置了各种机械臂控制指令，这些指令基于数控加工设备中的G代码[140]指令设置，其中令机械臂工作于角度控制模式的指令为：

$$M21\,G90\,X\{1\}\ Y\{2\}\ Z\{3\}\ A\{4\}\ B\{5\}\ C\{6\}\ F\{7\}$$

指令中 M21 与 M20 相对应，M20 表示机械臂工作于笛卡尔坐标模式，M21 表示机械臂工作于角度控制模式；G90 与 G91 相对应，G90 表示机械臂工作于绝对位置模式，后边连接的指令数值为相对于机械臂各关节初始位置的绝对角度值，G91 表示机械臂工作于相对位置模式，后边连接的指令数值为对应关节角度的增量值；XYZABC 分别对应机械臂的第 1 到 6 轴，后接角度值；F 对应该条指令的

中国知网 https://www.cnki.net

速度。

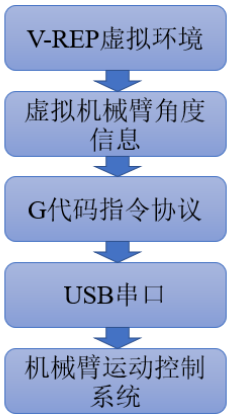


图 6.12 虚实控制中下发指令流程

Fig. 6.12 The process of issuing instructions in virtual and real control

（6）实体机械臂针对每条指令回文

Mirobot 机械臂在正确接收并处理每一条指令后都会返回正常回文，V-REP 当中的脚本程序需要确认收到此回文，以确定指令执行正常。

6.4.2 虚实控制实验

设计了如图 6.13 所示的虚实控制实物实验场景。为了能够同时应用前文所提出的残差强化学习运动规划方法以及课程强化学习训练方法，该实验场景当中放置了药瓶和宽高尺寸差距较大的水杯两个障碍物，目标抓取物体被放置在图中水杯的一侧，机械臂需要进行运动规划将目标物体放置在图中用 ArUco 标签标识出的目标位置上。

中国知网 https://www.cnki.net



图 6.13 虚实控制实物实验场景

Fig. 6.13 Virtual reality control physical experiment scene

为了抓取目标物体，Mirobot 机械臂末端安装了一个用于吸取目标物体的吸盘执行机构，并配合相应的吸盘气泵和 Mirobot 机械臂扩展控制盒来使用，将扩展控制盒连接气泵，再连接至 Mirobot 机械臂后端的扩展 IO 接口上即可使用。外部气泵与吸盘设备的连接如图 6.14 所示。



图 6.14 Mirobot 机械臂与吸盘气泵的连接

Fig. 6.14 Connection of Mirobot robotic arm and suction cup air pump

中国知网 https://www.cnki.net

虚实控制实验装置如图 6.15 所示。



图 6.15 机械臂虚实控制实验装置

Fig. 6.15 Virtual and actual control experimental device for robotic arm

实验结果如图 6.16 和图 6.17 所示，可以看出虚拟机械臂与实物机械臂完全同步。实物机械臂的动作与虚拟机械臂同步运动并且成功的将目标小物块吸起并运动到目标位置。

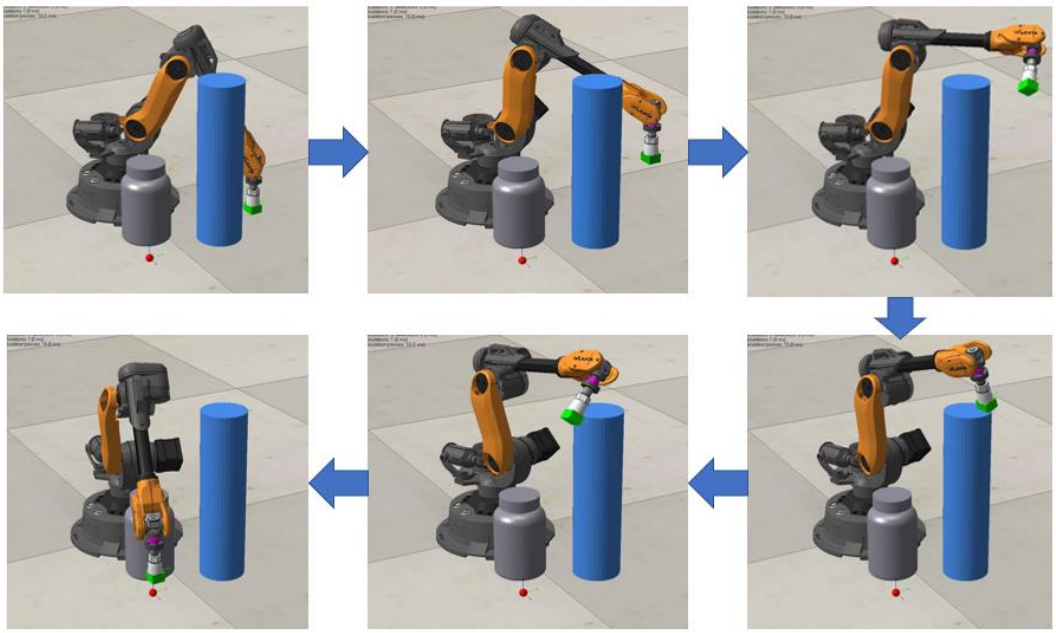


图 6.16 V-REP 中的运动规划过程

Fig. 6.16 Motion planning process in V-REP

中国知网 https://www.cnki.net

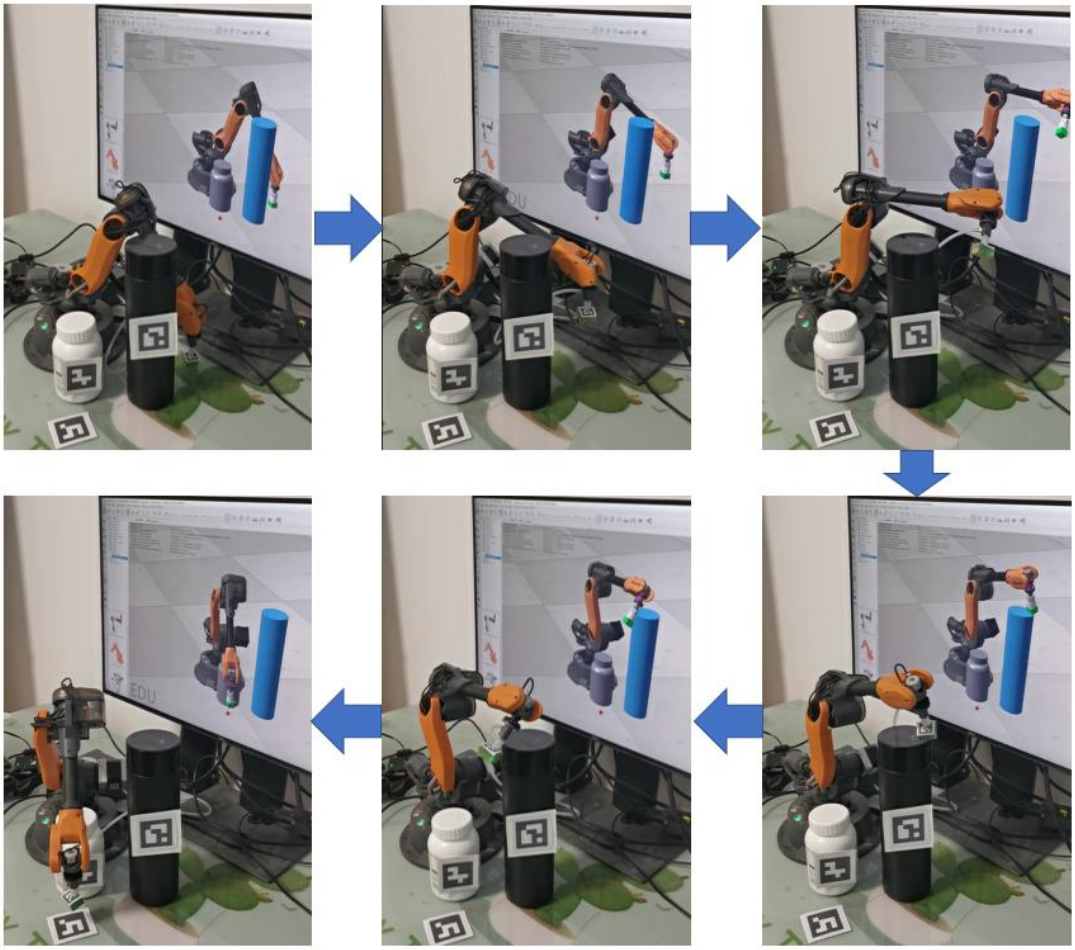


图 6.17 基于 V-REP 的机械臂虚实控制实验

Fig. 6.17 Virtual and real control experiment of manipulator based on V-REP

6.5 本章小结

（1）本章将 ArUco 标签引入实物控制实验中，使用 USB 摄像头来检测实际环境中物体的位姿。

（2）研究了相机的参数标定方法，并使用 OpenCV 开源机器视觉库实现了对所使用的 USB 摄像头参数的标定。

（3）研究了机械臂与摄像头之间的手眼标定方法，采用眼在手外的方法对机械臂与 USB 摄像头进行了位姿关系标定。

（4）提出了一种基于 V-REP 机器人虚拟仿真平台的虚实同步的机械臂控制方法，采用 V-REP 中的虚拟 Mirobot 机械臂智能体通过指令协议转换同步控制实物环境中的 Mirobot 机械臂实体，并完成运动规划过程。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

7 结论与展望

本章总结了课题的研究结论，列出了课题研究的创新点，最后对研究课题进行了展望。

7.1 结论

本论文对基于深度强化学习的机械臂运动规划方法进行了研究。传统的机械臂运动规划方法为手动示教，示教方法耗时长，操作繁琐。随着人工智能领域的不断发展，将机器学习中的强化学习方法应用于机械臂运动规划问题的求解成为了近年来的研究热点。相比于传统的运动规划算法，基于强化学习的方法具有较高的泛化能力以及鲁棒性，该方法最接近于人类自己运动规划的行为模式。但是强化学习算法在实际应用中存在着随机试错过程缓慢，训练效率低以及训练困难等问题。针对这些问题，本文进行了深入研究。主要研究结论包括：

（1）研究了目前已有的深度强化学习算法，重点对能够应用于机械臂控制的深度强化学习算法特点进行了分析。得出的结论是只有能够输出高维连续动作的深度强化学习算法才能够应用于机械臂的运动规划问题。进一步研究分析了 3 种能够应用于机械臂运动规划问题的深度强化学习算法：近端策略优化(PPO)算法、深度确定性策略梯度(DDPG)算法和深度 Q 网络归一化优势函数(DQN-NAF)算法。构建了基于 V-REP 虚拟仿真软件的强化学习实验训练平台，将这 3 种算法应用于无障碍物环境下的运动规划任务，并进行了性能的对比。对比结果发现在简单的机械臂到达任务当中，DQN-NAF 算法表现出最好的性能，仅在约 1000 回合之后就已经收敛到比较好的结果。DDPG 算法则表现出强烈的不稳定性。在增加了复杂程度的机械臂抓取到达任务当中，经过最长 5000 回合训练后，只有 PPO 算法能够顺利完成任务，DQN-NAF 算法表现出很强烈的局限性，其性能上升到一定阶段后便很难继续提高。DDPG 算法表现出了极大的不稳定性，但是在训练结束时其性能仍然有上升趋势。本文得出的结论是在简单任务中 DQN-NAF 算法能够快速稳定收敛，但是对于复杂任务则效果不佳。DDPG 算法具有最大的不稳定性。在机械臂控制中综合表现最好，性能最稳健的算法是 PPO。因此在后续研究中采用 PPO 算法作为强化学习部分的基本算法。

（2）针对采用单纯的深度强化学习算法从头训练智能体时面临的训练困难，训练过程中收敛慢等问题，提出了一种基于残差强化学习的运动规划方法。它将智能体进行运动规划的策略分为初始策略和残差策略两部分。初始策略负责引导由强化学习算法构成的残差策略的训练方向。残差策略部分则补充了初始策略所不

中国知网 https://www.cnki.net

具备的自适应性和泛化能力。针对所提出残差强化学习运动规划方法中的初始策略部分，采用了一种基于 BP 神经网络与障碍物内切球体抽象的运动规划方法。采用 PPO 算法作为所提出残差强化学习运动规划方法中的残差策略部分，针对原始 PPO 算法采样使用率比较低且估计优势函数时随机性比较大的问题，提出了改进 PPO 算法，引入了小型经验池以及基于 SumTree 的优先经验回放机制。最终在仿真环境下进行了运动规划实验，结果表明残差强化学习运动规划方法能够成功进行运动规划。将该方法与单纯使用 PPO 算法进行对比，结果表明使用残差强化学习运动规划方法可以有效地引导强化学习智能体的训练，极大地提高了算法的收敛速度。

（3）在所提出的残差强化学习运动规划方法中初始策略部分采用了障碍物内切球体简化的方法。在障碍物形状长宽高比例相差比较大的情况下，该障碍物简化方法所抽象出的内切球体与实际障碍物形状的差距比较大，这种情况下，残差策略当中的强化学习算法需要进行试错的空间很大，从而有可能出现训练困难的问题。针对上述问题，提出了一种基于课程强化学习的障碍物自适应训练方法。该方法采用障碍物有效球体概念来简化环境中的障碍物，根据强化学习智能体的即时运动规划能力来自适应的调整障碍物有效球体半径的大小，从而使得智能体在与之能力相匹配的环境中进行训练。智能体先在简单的环境中进行训练，然后逐步过渡到完整的障碍物环境。虚拟环境中的实验表明，该方法能够成功的进行运动规划。将采用基于课程强化学习的障碍物自适应训练方法与不采用该方法直接进行训练所得到的运动规划成功率进行对比，在经历相同 5000 回合次数的训练后，该方法的成功率达到了 95%，而不使用该方法进行训练的成功率为 70%。

（4）机械臂的运动规划算法生成的是其构形空间的离散角度序列，进一步还需要下发给机械臂的底层运动控制系统，底层运动控制系统根据这些离散角度序列进行轨迹规划后才能完成对一台真实机械臂的控制。本文设计了机械臂的底层运动控制系统，分析了研究对象 Mirobot 机械臂的运动学，提出了一种基于前瞻算法的机械臂关节空间轨迹规划方法，该方法能够将运动规划得到的离散关节角度进行动态的速度规划，使所提出的强化学习算法在迁移到机械臂实物控制时保持良好的运动平稳性。

（5）进行了强化学习智能体对于 Mirobot 机械臂实物的控制实验。对于实际环境中的障碍物以及目标位置获取问题，采用 ArUco 标签。对所采用的摄像头进行了相机标定和手眼标定。提出了一种基于 V-REP 的机械臂虚实同步控制方法，使用 V-REP 当中的虚拟机械臂智能体同步控制真实环境当中的机械臂完成了实际环境当中的运动规划实验任务。

中国知网 https://www.cnki.net

7.2 创新点

本文的主要创新点如下：

（1）提出了基于残差强化学习的运动规划方法。该方法将控制策略分解为初始策略与残差策略，初始策略用于引导残差策略的训练方向，残差策略对初始策略提供必要的策略补充和行为泛化。该方法有效提高了强化学习算法在机械臂运动规划问题上的训练效率与收敛速度。

（2）研究了残差强化学习运动规划方法中的初始策略与残差策略。针对初始策略部分，采用了 BP 神经网络运动规划方法。针对残差策略部分，对原始 PPO 算法进行改进，引入了小型经验池以及基于 SumTree 的优先经验回放机制，提出了一种改进 PPO 算法。

（3）根据课程学习思想提出了一种基于课程强化学习的障碍物自适应训练方法。该方法通过自适应修改障碍物有效球体半径来改变训练场景对于智能体完成运动规划任务的难度大小，从而在训练过程中动态调整任务难度。

（4）提出了一种基于前瞻算法的机械臂关节空间轨迹规划方法，针对按照时间序列发送给运动控制系统的离散角度指令，设计了运动块环形队列机制，并将速度前瞻算法引入其中，通过对运动块速度的前瞻规划，保证了机械臂底层运动控制系统在接收连续动态指令时运动的连续性以及平稳性。

7.3 展望

由于将深度强化学习算法应用于机械臂控制方面的研究刚刚起步，本文的工作存在一些不足之处，在现有的研究基础上，可以继续开展以下几个方面的研究工作：

（1）深度强化学习领域算法的发展与进步是日新月异的，本文分析了 DQN-NAF、DDGP 和 PPO 这 3 种典型的能够应用于机械臂运动规划任务的深度强化学习算法，目前涌现出了更多能够输出连续动作的强化学习算法，这些算法在解决机械臂控制问题时是否具有比本文最终采用的 PPO 算法更好的性能，有待于进一步研究。

（2）在强化学习使用的神经网络前端加入用于处理图像的卷积神经网络层可以使输入强化学习算法的特征为图像。这样的方法能够让强化学习智能体自主地找到输入图像中的特征，而不是人工选择特征输入给算法。这种基于端到端的强化学习对机械臂运动规划控制方法有更高的实用性，但是这种方法在训练时所面临的难度和不收敛的风险会很高。有待于进一步研究。

（3）本文在 Mirobot 桌面机械臂进行了实物实验，进一步可以在工业机械臂

中国知网 https://www.cnki.net

以及协作机械臂上进行控制实验。对于自由度数大于或者小于 6 的机械臂也可以采用同样的方法进行控制实验。

中国知网 https://www.cnki.net

参考文献

[1] 梁文莉. 全球机器人市场统计数据分析[J]. 机器人技术与应用, 2020(03): 47-48.

[2] 孙燕妮, 白晓军. 《中国制造2025》——中国特色的强国战略[J]. 智能制造, 2020(10): 43-45.

[3] ALTEROVITZ R, KOENIG S, LIKHACHEV M. Robot planning in the real world: research challenges and opportunities[J]. Ai Magazine, 2016,37(2): 76-84.

[4] 陈志贤. 面向复杂环境的服务机器人自主规划方法研究[D]. 中国科学院大学(中国科学院深圳先进技术研究院), 2019.

[5] 罗东峰. 桌面式上肢康复机器人控制研究[D]. 中国科学院研究生院(西安光学精密机械研究所), 2012.

[6] 李梦然. 五自由度桌面机械臂运动学及控制系统研究[D]. 吉林大学, 2018.

[7] CHOSET H M, LYNCH K M, HUTCHINSON S, et al. Principles of robot motion: theory, algorithms, and implementation[M]. MIT press, 2005.

[8] TAYLOR K, LAVALLE S M. I-Bug: An intensity-based bug algorithm: 2009 IEEE International Conference on Robotics and Automation[C]. IEEE, 2009.

[9] YANG S, WANG X, WEN Y, et al. A New Intelligent Trajectory Planning Algorithm Based on Bug2 Algorithm: Bridge Algorithm: 2019 IEEE International Conference on Robotics and Biomimetics (ROBIO)[C]. IEEE, 2019.

[10] CHEN Y, LUO G, MEI Y, et al. UAV path planning using artificial potential field method updated by optimal control theory[J]. International Journal of Systems Science, 2016,47(6): 1407-1420.

[11] GOMEZ E J, SANTA F M M, SARMIENTO F H M. A comparative study of geometric path planning methods for a mobile robot: potential field and voronoi diagrams: 2013 II international congress of engineering mechatronics and automation (CIIMA)[C]. IEEE, 2013.

[12] HUANG H, CHUNG S. Dynamic visibility graph for path planning: 2004 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)(IEEE Cat. No. 04CH37566)[C]. IEEE, 2004.

[13] LINGELBACH F. Path planning using probabilistic cell decomposition: IEEE International Conference on Robotics and Automation, 2004. Proceedings. ICRA'04. 2004[C]. IEEE, 2004.

[14] 马兆青, 袁曾任. 基于栅格方法的移动机器人实时导航和避障[J]. 机器人, 1996(06): 25-29.

中国知网 https://www.cnki.net

[15] AREMU O O, HYLAND-WOOD D, MCAREE P R. A machine learning approach to circumventing the curse of dimensionality in discontinuous time series machine data[J]. Reliability Engineering & System Safety, 2020,195: 106706.

[16] DIJKSTRA E W. A note on two problems in connexion with graphs[J]. Numerische mathematik, 1959,1(1): 269-271.

[17] 谢建平, 陈治亚, 邓连波, 等. 改进Dijkstra算法在大型城市轨道交通网计价系统中的应用[J]. 国防科技大学学报, 2021,43(01): 109-116.

[18] HART P E, NILSSON N J, RAPHAEL B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE transactions on Systems Science and Cybernetics, 1968,4(2): 100-107.

[19] AGGARWAL C C, HINNEBURG A, KEIM D A. On the surprising behavior of distance metrics in high dimensional space: International conference on database theory[C]. Springer, 2001.

[20] KAVRAKI L E, SVESTKA P, LATOMBE J, et al. Probabilistic roadmaps for path planning in high-dimensional configuration spaces[J]. IEEE transactions on Robotics and Automation, 1996,12(4): 566-580.

[21] LAVALLE S M. Rapidly-exploring random trees: A new tool for path planning[J]. Computer ence Dept. Oct, 1998,6: 16-18.

[22] RODRIGUEZ S, TANG X, LIEN J, et al. An obstacle-based rapidly-exploring random tree: Proceedings 2006 IEEE International Conference on Robotics and Automation, 2006. ICRA 2006[C]. IEEE, 2006.

[23] LOZANO-PEREZ T. Spatial planning: A configuration space approach[M]//Autonomous robot vehicles. Springer, 1990:259-271.

[24] VARADHAN G, MANOCHA D. Accurate Minkowski sum approximation of polyhedral models: 12th Pacific Conference on Computer Graphics and Applications, 2004. PG 2004. Proceedings[C]. IEEE, 2004.

[25] LYNCH K M, PARK F C. Modern Robotics[M]. Cambridge University Press, 2017.

[26] KELLEY J L. General topology[M]. Courier Dover Publications, 2017.

[27] 谢龙, 刘山. 基于改进势场法的机械臂动态避障规划[J]. 控制理论与应用, 2018,35(09): 1239-1249.

[28] CASHMORE M, FOX M, LONG D, et al. Rosplan: Planning in the robot operating system: Proceedings of the International Conference on Automated Planning and Scheduling[C]. 2015.

[29] QUIGLEY M, CONLEY K, GERKEY B, et al. ROS: an open-source Robot

中国知网 https://www.cnki.net

Operating System: ICRA workshop on open source software[C]. Kobe, Japan, 2009.

[30] CHITTA S, SUCAN I, COUSINS S. Moveit![ros topics][J]. IEEE Robotics & Automation Magazine, 2012,19(1): 18-19.

[31] SUCAN I A, MOLL M, KAVRAKI L E. The open motion planning library[J]. IEEE Robotics & Automation Magazine, 2012,19(4): 72-82.

[32] KUFFNER J J, LAVALLE S M. RRT-connect: An efficient approach to single-query path planning: Proceedings 2000 ICRA. Millennium Conference. IEEE International Conference on Robotics and Automation. Symposia Proceedings (Cat. No. 00CH37065)[C]. IEEE, 2000.

[33] JAILLET L, CORTÉS J, SIMÉON T. Transition-based RRT for path planning in continuous cost spaces: 2008 IEEE/RSJ International Conference on Intelligent Robots and Systems[C]. IEEE, 2008.

[34] KARAMAN S, FRAZZOLI E. Sampling-based algorithms for optimal motion planning[J]. The international journal of robotics research, 2011,30(7): 846-894.

[35] GAMMELL J D, SRINIVASA S S, BARFOOT T D. Informed RRT*: Optimal sampling-based path planning focused via direct sampling of an admissible ellipsoidal heuristic: 2014 IEEE/RSJ International Conference on Intelligent Robots and Systems[C]. IEEE, 2014.

[36] YAVARI M, GUPTA K, MEHRANDEZH M. Lazy steering rrt*: an optimal constrained kinodynamic neural network based planner with no in-exploration steering: 2019 19th International Conference on Advanced Robotics (ICAR)[C]. IEEE, 2019.

[37] MICHIE D, SPIEGELHALTER D J, TAYLOR C C. Machine learning, neural and statistical classification[M]. Ellis Horwood, 1994.

[38] 周志华. 机器学习[M]. 清华大学出版社, 2016.

[39] LEE J H, SHIN J, REALFF M J. Machine learning: Overview of the recent progresses and implications for the process systems engineering field[J]. Computers & Chemical Engineering, 2018,114: 111-121.

[40] SUTTON R S, BARTO A G. Reinforcement learning: An introduction[M]. MIT press, 2018.

[41] DENG Y, BAO F, KONG Y, et al. Deep direct reinforcement learning for financial signal representation and trading[J]. IEEE transactions on neural networks and learning systems, 2016,28(3): 653-664.

[42] DOMINGOS P. A few useful things to know about machine learning[J].

中国知网 https://www.cnki.net

Communications of the ACM, 2012,55(10): 78-87.

[43] TOKIC M. Adaptive ε-greedy exploration in reinforcement learning based on value differences: Annual Conference on Artificial Intelligence[C]. Springer, 2010.

[44] BELLMAN R. Dynamic programming and Lagrange multipliers[J]. Proceedings of the National Academy of Sciences of the United States of America, 1956,42(10): 767.

[45] MICHIE D, CHAMBERS R A. BOXES: An experiment in adaptive control[J]. Machine intelligence, 1968,2(2): 137-152.

[46] SUTTON R S. Learning to predict by the methods of temporal differences[J]. Machine learning, 1988,3(1): 9-44.

[47] RUMMERY G A, NIRANJAN M. On-line Q-learning using connectionist systems[M]. University of Cambridge, Department of Engineering Cambridge, UK, 1994.

[48] SUTTON R S. Generalization in reinforcement learning: Successful examples using sparse coarse coding[J]. Advances in neural information processing systems, 1996,8: 1038-1044.

[49] WATKINS C J, DAYAN P. Q-learning[J]. Machine learning, 1992,8(3-4): 279-292.

[50] ROSENBLATT F. The perceptron: a probabilistic model for information storage and organization in the brain[J]. Psychological review, 1958,65(6): 386.

[51] GARDNER M W, DORLING S R. Artificial neural networks (the multilayer perceptron) a review of applications in the atmospheric sciences[J]. Atmospheric environment, 1998,32(14-15): 2627-2636.

[52] LECUN Y, TOURESKY D, HINTON G, et al. A theoretical framework for back-propagation: Proceedings of the 1988 connectionist models summer school[C]. 1988.

[53] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks[J]. science, 2006,313(5786): 504-507.

[54] STRIGL D, KOFLER K, PODLIPNIG S. Performance and scalability of GPU-based convolutional neural networks: 2010 18th Euromicro Conference on Parallel, Distributed and Network-based Processing[C]. IEEE, 2010.

[55] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012,25: 1097-1105.

[56] KOBER J, BAGNELL J A, PETERS J. Reinforcement learning in robotics: A

中国知网 https://www.cnki.net

survey[J]. The International Journal of Robotics Research, 2013,32(11): 1238-1274.

[57] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Playing atari with deep reinforcement learning[J]. arXiv preprint arXiv:1312.5602, 2013.

[58] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. nature, 2015,518(7540): 529-533.

[59] Van HASSELT H, GUEZ A, SILVER D. Deep reinforcement learning with double q-learning: Proceedings of the AAAI Conference on Artificial Intelligence[C]. 2016.

[60] WANG Z, SCHAUL T, HESSEL M, et al. Dueling network architectures for deep reinforcement learning: International conference on machine learning[C]. PMLR, 2016.

[61] SCHAUL T, QUAN J, ANTONOGLOU I, et al. Prioritized experience replay[J]. arXiv preprint arXiv:1511.05952, 2015.

[62] SUTTON R S, MCALLESTER D A, SINGH S P, et al. Policy gradient methods for reinforcement learning with function approximation.: NIPs[C]. Citeseer, 1999.

[63] SILVER D, LEVER G, HEESS N, et al. Deterministic policy gradient algorithms: International conference on machine learning[C]. PMLR, 2014.

[64] SCHULMAN J, LEVINE S, ABBEEL P, et al. Trust region policy optimization: International conference on machine learning[C]. PMLR, 2015.

[65] BAHDANAU D, BRAKEL P, XU K, et al. An actor-critic algorithm for sequence prediction[J]. arXiv preprint arXiv:1607.07086, 2016.

[66] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:1509.02971, 2015.

[67] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.

[68] HEESS N, TB D, SRIRAM S, et al. Emergence of locomotion behaviours in rich environments[J]. arXiv preprint arXiv:1707.02286, 2017.

[69] 多南讯, 吕强, 林辉灿, 等. 迈进高维连续空间:深度强化学习在机器人领域中的应用[J]. 机器人, 2019,41(02): 276-288.

[70] GU S, LILLICRAP T, SUTSKEVER I, et al. Continuous deep q-learning with model-based acceleration: International Conference on Machine Learning[C]. PMLR, 2016.

[71] SANGIOVANNI B, RENDINIELLO A, INCREMONA G P, et al. Deep reinforcement learning for collision avoidance of robotic manipulators: 2018 European Control Conference (ECC)[C]. IEEE, 2018.

中国知网 https://www.cnki.net

[72] MAHMOOD A R, KORENKEVYCH D, KOMER B J, et al. Setting up a reinforcement learning task with a real-world robot: 2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)[C]. IEEE, 2018.

[73] 陈建华. 基于深度强化学习的机械臂运动规划研究[D]. 燕山大学, 2019.

[74] PAN S J, YANG Q. A survey on transfer learning[J]. IEEE Transactions on knowledge and data engineering, 2009,22(10): 1345-1359.

[75] 董贯涛. 基于深度强化学习的机器人抓取方法研究[D]. 哈尔滨工业大学, 2019.

[76] 闫冬, 陈盛, 彭国政, 等. 基于层次深度强化学习的带电作业机械臂控制技术[J]. 高电压技术, 2020,46(02): 459-471.

[77] 李鹤宇, 赵志龙, 顾蕾, 等. 基于深度强化学习的机械臂控制方法[J]. 系统仿真学报, 2019,31(11): 2452-2457.

[78] 郑钧天. 基于深度强化学习的机械臂轨迹规划仿真[D]. 电子科技大学, 2020.

[79] 张子扬. 基于深度强化学习的水下机械臂抓取研究[D]. 中国科学技术大学, 2020.

[80] 黄伟伟. 基于深度强化学习的机械臂抓捕控制研究[D]. 哈尔滨工业大学, 2020.

[81] DARIO P, SANDINI G, AEBISCHER P. Robots and Biological Systems: Towards a New Bionics: Proceedings of the NATO Advanced Workshop on Robots and Biological Systems, held at II Ciocco, Toscana, Italy, June 26-30, 1989[M]. Springer Science & Business Media, 2012.

[82] TESAURO G. Temporal difference learning and TD-Gammon[J]. Communications of the ACM, 1995,38(3): 58-68.

[83] GARG A, GUPTA D, SAHADEV P P, et al. Comprehensive analysis of the uses of GPU and CUDA in soft-computing techniques: 2019 6th International Conference on Signal Processing and Integrated Networks (SPIN)[C]. IEEE, 2019.

[84] DERENIOWSKI D, KUBALE M. Cholesky factorization of matrices in parallel and ranking of graphs: International Conference on Parallel Processing and Applied Mathematics[C]. Springer, 2003.

[85] HERSHEY J R, OLSEN P A. Approximating the Kullback Leibler divergence between Gaussian mixture models: 2007 IEEE International Conference on Acoustics, Speech and Signal Processing-ICASSP'07[C]. IEEE, 2007.

[86] SUTTON R S. Dyna, an integrated architecture for learning, planning, and reacting[J]. ACM Sigart Bulletin, 1991,2(4): 160-163.

中国知网 https://www.cnki.net

[87] EREZ T, TASSA Y, TODOROV E. Simulation tools for model-based robotics: Comparison of bullet, havok, mujoco, ode and physx: 2015 IEEE international conference on robotics and automation (ICRA)[C]. IEEE, 2015.

[88] BINGHAM B, AGÜERO C, MCCARRIN M, et al. Toward maritime robotic simulation in gazebo: OCEANS 2019 MTS/IEEE SEATTLE[C]. IEEE, 2019.

[89] ROHMER E, SINGH S P, FREESE M. V-REP: A versatile and scalable robot simulation framework: 2013 IEEE/RSJ International Conference on Intelligent Robots and Systems[C]. IEEE, 2013.

[90] ZHOU D, XIE M, XUAN P, et al. A teaching method for the theory and application of robot kinematics based on MATLAB and V-REP[J]. Computer Applications in Engineering Education, 2020,28(2): 239-253.

[91] XIE M, ZHOU D, SHI Y, et al. Virtual Experiments Design for Robotics Based on V-REP[J]. IOP Conference Series Materials Science and Engineering, 2018,428(1): 12069.

[92] PASZKE A, GROSS S, MASSA F, et al. Pytorch: An imperative style, high-performance deep learning library[J]. arXiv preprint arXiv:1912.01703, 2019.

[93] ABADI M, BARHAM P, CHEN J, et al. Tensorflow: A system for large-scale machine learning: 12th symposium on operating systems design and implementation[C]. 2016.

[94] BAUER M, GARLAND M. Legate NumPy: Accelerated and distributed array computing: Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis[C]. 2019.

[95] MCKINNEY W. pandas: a foundational Python library for data analysis and statistics[J]. Python for High Performance and Scientific Computing, 2011,14(9): 1-9.

[96] KICKSTARTER. Mirobot, 6-axis Mini Industrial Robot Arm[EB/OL]. [2021-03-07]. https://www.kickstarter.com/projects/mirobot/mirobot-6-axis-mini-industrial-robot-arm?lang=zh.

[97] FARIS H, ALJARAH I, MIRJALILI S. Training feedforward neural networks using multi-verse optimizer for binary classification problems[J]. Applied Intelligence, 2016,45(2): 322-332.

[98] SQUARTINI S, HUSSAIN A, PIAZZA F. Preprocessing based solution for the vanishing gradient problem in recurrent neural networks: Proceedings of the 2003 International Symposium on Circuits and Systems, 2003. ISCAS'03[C]. IEEE, 2003.

中国知网 https://www.cnki.net

[99] HUK M. Stochastic Optimization of Contextual Neural Networks with RMSprop: Asian Conference on Intelligent Information and Database Systems[C]. Springer, 2020.

[100] ZHANG N. An online gradient method with momentum for two-layer feedforward neural networks[J]. Applied Mathematics and Computation, 2009,212(2): 488-498.

[101] 李鹤宇, 林廷宇, 曾贲, 等. 基于强化学习的空间机械臂控制方法[J]. 航天控制, 2020,38(06): 38-43.

[102] 丁鹏超. 基于强化学习的机械臂轴孔装配策略研究[D]. 哈尔滨工业大学, 2020.

[103] JOHANNINK T, BAHL S, NAIR A, et al. Residual reinforcement learning for robot control: 2019 International Conference on Robotics and Automation (ICRA)[C]. IEEE, 2019.

[104] LI J, CHENG J, SHI J, et al. Brief introduction of back propagation (BP) neural network algorithm and its improvement[M]//Advances in computer science and information engineering. Springer, 2012:553-558.

[105] Qureshi A H, Simeonov A, Bency M J, et al. Motion planning networks: 2019 International Conference on Robotics and Automation (ICRA), 2019[C]. IEEE, 2019

[106] Hussein A, Gaber M M, Elyan E, et al. Imitation learning: A survey of learning methods[J]. ACM Computing Surveys (CSUR), 2017,50(2):1-35.

[107] Jurgenson T, Tamar A. Harnessing reinforcement learning for neural motion planning[J]. arXiv preprint arXiv:1906.00214, 2019.

[108] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The journal of machine learning research, 2014,15(1): 1929-1958.

[109] HAWKINS D M. The problem of overfitting[J]. Journal of chemical information and computer sciences, 2004,44(1): 1-12.

[110] SCHULMAN J, MORITZ P, LEVINE S, et al. High-Dimensional Continuous Control Using Generalized Advantage Estimation[J]. Computer Science, 2015,6:15-18.

[111] GAO H, ZHI-QUN H U, LU-HAN Y U, et al. Intelligent Traffic Signal Control Algorithm Based on Sumtree DDPG[J]. Journal of Beijing University of Posts and Telecommunications, 2020,8:55-58.

[112] BENGIO Y, LOURADOUR J, COLLOBERT R, et al. Curriculum learning:

中国知网 https://www.cnki.net

Proceedings of the 26th annual international conference on machine learning[C]. 2009.

[113] LUO S, KASAEI H, SCHOMAKER L. Accelerating reinforcement learning for reaching using continuous curriculum learning: 2020 International Joint Conference on Neural Networks (IJCNN)[C]. IEEE, 2020.

[114] FLORENSA C, HELD D, WULFMEIER M, et al. Reverse curriculum generation for reinforcement learning: Conference on robot learning[C]. PMLR, 2017.

[115] KERZEL M, MOHAMMADI H B, ZAMANI M A, et al. Accelerating deep continuous reinforcement learning through task simplification: 2018 International Joint Conference on Neural Networks (IJCNN)[C]. IEEE, 2018.

[116] LIBERTUS K, GIBSON J, HIDAYATALLAH N Z, et al. Size matters: How age and reaching experiences shape infants' preferences for different sized objects[J]. Infant Behavior and Development, 2013,36(2): 189-198.

[117] FORUM C. Execute V-REP without GUI via ssh[EB/OL]. [2021-03-07]. https://forum.coppeliarobotics.com/viewtopic.php?f=5&t=1319.

[118] 张小俊, 孙凌宇, 张明路, 等. 基于旋量法的连续体搜救机器人运动学分析[J]. 华中科技大学学报(自然科学版), 2013,41(12): 90-95.

[119] DENAVIT J, HARTENBERG R S, MOORING B W, et al. 54 KINEMATIC PARAMETER[J]. Journal of applied mechanics, 1955,77(2): 215-221.

[120] 周东旭, 谢明佐, 宣鹏程, 等. 煤矿轻型协作机械臂逆运动学解算与验证[J]. 煤炭学报, 2019,44: 791-799.

[121] LAVALLE S M. Planning algorithms[M]. Cambridge university press, 2006.

[122] LATOMBE J. Robot motion planning[M]. Springer Science & Business Media, 2012.

[123] BIAGIOTTI L, MELCHIORRI C. Trajectory planning for automatic machines and robots[M]. Springer Science & Business Media, 2008.

[124] GASPARETTO A, BOSCARIOL P, LANZUTTI A, et al. Path planning and trajectory planning algorithms: A general overview[J]. Motion and operation planning of robotic systems, 2015,6: 3-27.

[125] 贾瑞清, 周东旭, 谢明佐. 机器人学——规划、控制及应用[M]. 1. 北京: 清华大学出版社, 2020: 213.

[126] 刘勇, 李俊, 王其斌. Modbus通讯中的环形FIFO队列算法[J]. 仪表技术与传感器, 2017(06): 161-164.

[127] WANG L, CAO J. A look-ahead and adaptive speed control algorithm for high-

中国知网 https://www.cnki.net

speed CNC equipment[J]. The International Journal of Advanced Manufacturing Technology, 2012,63(5): 705-717.

[128] EIDERMAN A. Real Time Stepper Motor Linear Ramping Just by Addition and Multiplication[EB/OL]. [2021-03-07]. http://www.hwml.com/LeibRamp.htm.

[129] BERG A C, MALIK J. Geometric blur for template matching: Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001[C]. IEEE, 2001.

[130] HUANG R, PEDOEEM J, CHEN C. YOLO-LITE: a real-time object detection algorithm optimized for non-GPU computers: 2018 IEEE International Conference on Big Data (Big Data)[C]. IEEE, 2018.

[131] 王超. 基于深度强化学习的机械臂卷积神经网络控制策略研究[D]. 哈尔滨工业大学, 2018.

[132] GARRIDO-JURADO S, MUÑOZ-SALINAS R, MADRID-CUEVAS F J, et al. Automatic generation and detection of highly reliable fiducial markers under occlusion[J]. Pattern Recognition, 2014,47(6): 2280-2292.

[133] KALACHEV O. ArUco markers generator[EB/OL]. [2021-03-07]. https://chev.me/arucogen/.

[134] BRADSKI G, KAEHLER A, PISAREVSKY V. Learning-based computer vision with intel's open source computer vision library[J]. Intel technology journal, 2005,9(2): 68-70.

[135] 罗湘喜. 基于视觉的Delta机械手抓取定位技术应用研究[D]. 南华大学, 2017.

[136] SALVI J, ARMANGUÉ X, BATLLE J. A comparative review of camera calibrating methods with accuracy evaluation[J]. Pattern recognition, 2002,35(7): 1617-1635.

[137] CHEN S Y, ZHANG J, ZHANG H, et al. Intelligent lighting control for vision-based robotic manipulation[J]. IEEE Transactions on Industrial Electronics, 2011,59(8): 3254-3263.

[138] DANIILIDIS K. Hand-eye calibration using dual quaternions[J]. The International Journal of Robotics Research, 1999,18(3): 286-298.

[139] PARK F C, MARTIN B J. Robot sensor calibration: solving AX= XB on the Euclidean group[J]. IEEE Transactions on Robotics and Automation, 1994,10(5): 717-721.

[140] 蒋通. 基于LinuxCNC的六轴工业机器人控制系统及图形化编程研究[D]. 华南理工大学, 2020.

中国知网 https://www.cnki.net

致　谢

博士生涯即将结束，回忆起自大学至今生活学习和科研的点点滴滴，历历在目，我心中百感交集。这一路的前行，这一路的磨练，这一路的进步，有过惊喜，有过失落，也有过彷徨，但是对工程技术以及未知世界探索的兴趣始终不变！人生短短数十载，能够终生从事自己所热爱的事业，无比幸福。

学业的进步、论文的完成得益于良师益友的指导与帮助，关怀与鼓励，在此向我的老师、亲人和朋友们表达由衷的感谢与诚挚的祝福！

首先非常非常感谢我的导师贾瑞清教授。读博以来贾老师对我的学业和生活关怀备至，对我的选题以及学位论文的撰写给予了重要的建设性指导。贾老师和蔼可亲、学识渊博、治学严谨，读博以来我每每遇到困难或者问题，贾老师都给予了我最大的帮助和完全的支持，正是贾老师一直以来对我的指导、支持、理解和鼓励使得我能够最终完成博士学业。贾老师儒雅的人格魅力、简单朴素的工作作风、丰富的科研经验以及积极乐观的生活态度深深影响了我，我将受益终身！

感谢孟国营教授、林福严教授、郑晓雯教授、赵四海教授、朱红秀副教授、卢继霞副教授在科研和生活中给予我的大力帮助和支持！

感谢实验室我的同窗们，感谢王乾博士、贾敏博士、李健博士、马飞博士、张富臣博士、邹华东博士、孙稚媛博士、罗虎博士生、刘欢博士生、陈浩博士生、谢明佐硕士、高鹏硕士、宣鹏程硕士、高任志硕士、宋致强硕士、黄琳琳硕士等在研究项目中对我的大力帮助！感谢张均嘉师兄、赵明辉师兄、董会师兄对于工程项目的大力支持！感谢我的室友姚海峰博士，关于科研与生活我们交流很多，海峰给予了我很多人生的建议！从他身上我学习到了很多经验与知识。感谢好友赵奇在生活中给予我的帮助和鼓励。感谢我的本科挚友燕山大学的徐浩然博士，海内存知己，天涯若比邻！

感谢我的父亲周维和母亲魏凤霞，感谢父母对我的养育之恩！感谢他们在我读博过程中对我的理解与支持！感谢我的妻子兰利亚，我们在大学时代相识、相知、相恋，每每到了人生道路中的彷徨时刻，她都给予我最大的理解与支持。感谢我已经故去的爷爷奶奶，奶奶从小非常疼爱我，并且从小教育我要认真读书，知识是人生最大的财富。

最后，要特别感谢在百忙之中参加本论文指导、评阅以及答辩的各位专家老师！

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net