廣東工業大學
GUANGDONG UNIVERSITY OF TECHNOLOGY

硕士学位论文

（专业学位）

复杂环境下基于强化学习的无人机规划与控制研究

作　　者　　姓　　名：范春晖

导　　师　　姓　　名：鲁仁全

学科（专业）或领域名称：控制工程

论　文　答　辩　年　月：二〇二五年五月



中国知网 https://www.cnki.net

中图分类号：　　学校代号：11845
UDC：　　密级：　　学　　号：2112204387

广东工业大学硕士学位论文

（电子信息硕士）

复杂环境下基于强化学习的无人机规划与控制研究

范春晖

指导教师姓名、职称：鲁仁全　教授
校外指导教师姓名、职称：刘露　高级工程师
学科（专业）或领域名称：控制工程
学生所属学院：自动化学院
答辩委员会主席：熊建斌　教授
论文答辩日期：2025 年 5 月 22 日

中国知网　https://www.cnki.net

A Dissertation Submitted to Guangdong University of Technology
in Partial Fulfillment of the Requirement
for the Degree of Master of Electronic Information

Reinforcement Learning-Based Quadrotor Trajectory Planning and Control in Complex Environments

Candidate: FAN Chunhui

Supervisor: LU Renquan

May 22, 2025
School of School of Automation
Guangdong University of Technology
Guangzhou 510006, Guangdong, P. R. China

中国知网 https://www.cnki.net

摘要

随着四旋翼无人机在复杂动态场景中的应用需求日益增长，传统轨迹规划与控制方法在实时性、环境适应性及能效优化方面面临显著挑战。本研究旨在提出一种融合深度强化学习的分层自主决策框架，解决复杂环境下四旋翼无人机轨迹规划与控制的多目标协同优化问题，突破现有方法在动态障碍物避碰、不确定动力学响应及长期能耗约束等方面的局限性。针对上述问题，本文提出一种基于分层元强化学习的系统架构，其核心创新包括：

（1）设计规划层与控制层的双层深度强化学习（DRL）结构，分别采用多专家软演员-评论家（Mixture-of-Experts Soft Actor-Critic，MoE-SAC）算法与元学习增强的 SAC 控制器，实现任务解耦与协同优化；

（2）构建跨层反馈机制，通过经验缓存池传递控制器跟踪误差、能耗特征等量化指标，动态修正规划层的时间分配策略与轨迹参数化约束；

（3）提出能耗-耗时预测与时间分配算法，结合多专家算法优化无人机规划结果的能耗特性。

在规划层算法设计中，通过微分平坦理论改进四旋翼无人机动力学模型，构建了包含轨迹稳定性评估专家、飞行走廊规划专家及能耗预测专家的多专家网络，实现动态环境下的安全轨迹生成。在控制器算法设计中，采用一阶模型无关元学习（MAML）预训练策略增强 SAC 算法的快速适应能力，并通过层间异步训练机制解决规划与控制频率失配问题。进一步地，在跨层反馈中基于李雅普诺夫稳定性理论进行控制器性能评估，并利用回放池缓冲双层网络的频率冲突。

为验证系统性能，本文搭建了包含 Isaac GYM 仿真平台与实物无人机实验平台，设计实时避碰撞实验。实验表明，在轨迹规划层面，所提 MoE-SAC 算法相较于传统 QP 和 MINCO 求解方法，规划成功率达 98%，求解稳定性更好，算法同时使得轨迹运动的平均能量消耗降低 6%，能耗约束下运行速度平均提高 30%，规划求解速度提高 40%；在控制层面，元学习增强的 SAC 控制器跟踪误差较 ADRC 方法减少 47%；此外，得益于层间反馈机制，本研究的分层强化学习算法相较于传统规划控制架构的运动误差低 50%。

本研究通过分层强化学习框架实现了规划与控制的深度耦合，其反馈机制与能耗

中国知网 https://www.cnki.net

优化策略显著提升了四旋翼无人机在复杂环境下的自主性。理论分析与实验结果表明，所提方法在动态避障、抗干扰能力及能效比方面均优于现有基准算法，为四旋翼无人机在物流配送、灾害救援等实际场景的应用提供了新的技术路径。

关键词：四旋翼无人机；深度强化学习；轨迹规划；运动控制

中国知网 https://www.cnki.net

ABSTRACT

With the increasing demand for quadrotor applications in complex dynamic scenarios, traditional trajectory planning and control methods face significant challenges in real-time performance, environmental adaptability, and energy efficiency optimization. This study aims to develop a hierarchical decision-making framework integrating deep reinforcement learning (DRL) to address the multi-objective collaborative optimization of quadrotor trajectory planning and control in complex environments, overcoming limitations of existing approaches in dynamic obstacle avoidance, uncertain dynamic response, and long-term energy constraints.

To tackle these challenges, this thesis proposes a hierarchical meta-reinforcement learning architecture with three key innovations:

(1) A dual-layer DRL structure separating planning and control layers, implemented through a Mixture-of-Experts Soft Actor-Critic (MoE-SAC) planner and a meta-learning enhanced SAC controller; (2) An inter-layer feedback mechanism utilizing experience replay buffers to propagate controller tracking errors and energy consumption patterns, enabling dynamic adjustment of temporal allocation strategies and trajectory parametrization constraints; (3) energy-time-consumption prediction and temporal allocation algorithm, combined with a multi-expert network, to optimize the energy characteristics of UAV planning results.

For the planning layer, we improve quadrotor dynamic modeling through differential flatness theory, constructing a multi-expert network containing trajectory stability evaluators, flight corridor planners, and energy prediction specialists to ensure safe trajectory generation. The control layer employs first-order Model-Agnostic Meta-Learning (MAML) for SAC pre-training to enhance rapid adaptation, with an asynchronous training mechanism resolving frequency mismatch between planning (10Hz) and control (100Hz) layers. Theoretical guarantees include Lyapunov stability-based trajectory reachability proofs and Monte Carlo sampling verification for flight corridor robustness.

To validate the system performance, this thesis establishes an experimental framework comprising the Isaac GYM simulation platform and a physical UAV testbed, with real-time collision avoidance experiments designed. Experimental results demonstrate that at the trajec-

中国知网 https://www.cnki.net

tory planning level, the proposed MoE-SAC algorithm achieves a 9% planning success rate, outperforming conventional QP and MINCO solvers in solution stability. The algorithm simultaneously reduces the average energy consumption of trajectory motion by 6%, achieves 30% higher average operating speed under energy consumption constraints, and improves planning computation speed by 40%. At the control level, the meta-learning-enhanced SAC controller reduces tracking errors by 47% compared with ADRC methods. Furthermore, benefiting from the inter-layer feedback mechanism, the hierarchical reinforcement learning algorithm proposed in this study exhibits 50% lower motion errors compared to traditional planning-control architectures.

This research establishes a hierarchical DRL framework that deeply couples planning and control through bio-inspired feedback mechanisms. Both theoretical analyses and empirical results confirm the proposed method's superiority in dynamic obstacle avoidance, disturbance rejection, and energy efficiency over state-of-the-art baselines, providing new technical pathways for quadrotor applications in logistics and emergency response.

Key words: Quadcopter; Deep Reinforcement Learning; Trajectory Planning; Motion control

中国知网 https://www.cnki.net

物理量名称及符号表

符号	含义
q	四元数姿态
ω	角速度
$\mathcal{R}$	无人机轨迹可行域
$u(t)$	无人机的轨迹规划结果
Q	无人机规划约束
$\mathcal{R}_c$	无人机状态空间
s	无人机状态
π	强化学习策略
$\mathcal{A}_c$	无人机控制器动作空间
r	无人机动作奖励
r_c	无人机控制器动作奖励
Ω	无人机旋翼转速
r_c	无人机规划动作奖励
V	李雅普诺夫复合能力函数
$\mathcal{L}$	损失函数或目标优化函数
$\mathcal{B}$	数据缓存
$\mathcal{D}$	经验回放池
η	强化学习折扣因子
$\mathbb{E}$	数学期望
r_{expert}	专家算法计算得到的动作奖励
Q_{sac}	强化学习的 Q 值预测函数
$\mathcal{H}(\pi)$	强化学习策略的熵
Hu	Huber 函数
ReLU	ReLU 函数

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 本课题研究背景及研究意义.....1
1.2 国内外相关研究现状.....2
1.2.1 无人机自主系统架构技术.....2
1.2.2 多旋翼无人机的轨迹规划.....3
1.2.3 多旋翼无人机先进控制策略.....4
1.2.4 深度强化学习在机器人领域应用.....5
1.3 当前研究面临的挑战和本文创新点.....6
1.4 论文结构安排.....7
第二章 系统建模与理论基础.....8
2.1 无人机动力学模型.....8
2.1.1 理想推力-重力耦合模型.....8
2.1.2 微分平坦参数化理论及其改进.....10
2.1.3 理想推力-重力耦合模型的求解方法.....12
2.1.4 真实物理条件下的动力学模型修正.....12
2.2 轨迹规划算法与可达性分析.....13
2.2.1 安全飞行走廊的最小控制量轨迹问题构造.....13
2.2.2 高阶多项式轨迹参数化方法.....16
2.2.3 基于动力学模型的轨迹可达性证明.....18
2.3 强化学习问题建模.....19
2.3.1 控制器的强化学习 MDP 模型构造.....19
2.3.2 规划算法的强化学习 MDP 模型构造.....20
2.4 本章小结.....22
第三章 分层元强化学习框架设计.....23
3.1 整体系统架构概览.....23
3.1.1 分层强化学习算法和层间反馈设计.....23
3.1.2 元学习算法.....25
3.2 层间反馈机制设计.....25
3.2.1 控制器性能量化评估.....26
3.2.2 反馈信息的收集.....27
3.3 基于多专家算法的 SAC 轨迹规划方法.....28
3.3.1 MoE-SAC 规划算法的架构概述.....28
3.3.2 轨迹稳定性评估专家设计.....31
3.3.3 飞行走廊规划专家设计.....33

中国知网 https://www.cnki.net

3.3.4 概率密度梯度场避障专家算法.....34
3.4 创新方法：能耗预测与时间分配优化专家设计.....35
3.4.1 带有能量约束的轨迹规划问题构造.....35
3.4.2 基于深度学习的能量消耗预测方法.....37
3.4.3 基于动态规划的时间分配优化.....42
3.5 基于 SAC 算法的无人机控制器设计.....43
3.5.1 网络架构设计.....44
3.5.2 损失函数设计与优化策略.....46
3.5.3 基于 MAML 算法的模型预训练.....46
3.6 本章小结.....47
第四章 模型训练稳定性与收敛性分析.....49
4.1 训练流程设计.....49
4.2 模型训练结果.....51
4.2.1 控制器层深度神经网络网络预训练.....51
4.2.2 能量预测专家网络训练.....52
4.2.3 轨迹稳定性估计专家网络训练.....54
4.2.4 规划算法和控制器网络的实物平台在线训练.....54
4.3 模型训练改进的有效性验证.....57
4.3.1 控制器反馈机制下轨迹稳定性估计网络的训练流程验证..57
4.3.2 一阶 MAML 算法对控制器模型收敛的提升验证.....57
4.4 本章小节.....58
第五章 实验设计与结果分析.....60
5.1 实验环境与基准算法.....60
5.1.1 仿真测试平台.....60
5.1.2 实物实验平台.....62
5.2 规划层性能评估.....64
5.2.1 能量预测和时间分配算法性能分析.....64
5.2.2 MoE-SAC 算法的能效和规划成功率对比.....66
5.2.3 计算效率对比.....70
5.3 控制层跟踪性能.....72
5.3.1 静态轨迹跟踪.....72
5.3.2 抗干扰能力测试.....73
5.4 消融和对比实验分析.....74
5.4.1 能量预测网络的架构合理性消融实验.....74
5.4.2 层间反馈机制消融实验.....75
5.4.3 网络模型算力需求分析.....76
5.4.4 MoE 框架对规划算法的性能改进验证.....77
5.5 系统集成：多机协同实验下的规划控制与动态避障.....77

中国知网 https://www.cnki.net

5.6 本章小结.....78
第六章 结论与展望.....79
6.1 研究总结.....79
6.2 研究局限性和未来工作展望.....79
参考文献.....81

中国知网 https://www.cnki.net

第一章　绪论

1.1 本课题研究背景及研究意义

随着自动控制和电子信息技术的迅猛发展，多旋翼无人机在过去十余年来已经从理论验证发展到产业快速应用阶段。其凭借着机动性好、环境适应性强和低空作业经济性的技术优势，在消费电子、工业巡检、农业植保和军事等领域得到了广泛应用[1]，市场规模逐年提升。其中自主无人机系统作为工业应用和智能化的核心技术，相关领域已经成为产学研界共同关注的技术焦点[2]。

在工业应用场景中，自主无人机系统通过集成环境感知、智能规划与实时控制技术，可显著提升作业自动化程度与安全性。以浙江某地变电站自动化巡检为例（图1-1(a)），搭载包括 3D 激光雷达在内的多传感器自主无人机可替代人工完成配电房内高压设备的读数观测、热成像检测与故障定位，使巡检效率大幅提高，同时避免人员接触高电压。同时在船只等封闭空间的三维建图任务中（图1-1(b)），自主无人机通过同时定位与地图构建（Simultaneous Localization and Mapping，SLAM）算法实现 GPS 拒止环境下的高精度建图，其避障能力可确保在复杂钢结构内部安全执行检测任务。这类应用体现了无人机自主系统在提升作业效能、降低人力成本、保证安全性方面的技术优势。



(a) 浙江某地变电站采用自主无人机进行巡检



(b) 无人机在无 GPS 信号的船舱环境内建图巡查

图 1-1 自主无人机的应用

Figure 1-1 Autonomous quadrotor applications

未来自主无人机将向全场景适应性与群体协同化方向发展，这对轨迹规划与控制

中国知网　https://www.cnki.net

（Planning and Control, PnC）算法提出更严苛的要求。在动态的复杂环境中，无人机的规划与控制算法需要有能力处理无人机运动学或动力学约束下的实时轨迹优化生成、动态障碍物的实时避让以及复杂工况下的高精度控制[3]。传统基于几何规则或 PID 的控制方法在应对此类问题时存在建模不够精细、环境适应性差等局限。近年来，深度强化学习（Deep Reinforcement Learning, DRL）在机器人的应用中崭露头角，其作为自主决策领域的前沿方向，正逐渐引发新一轮技术变革[4]。深度强化学习通过构建” 感知-决策-执行” 的闭环学习框架，在机械臂柔性抓取、足式机器人动态步态控制等任务中取得突破性进展。在无人机的规划与控制算法研究中，利用深度强化学习对大量的经验数据的学习和搜索能力，也可实现对具有自适应能力的规控算法[5]。综上所述，利用深度强化学习技术发展新型智能规划与控制算法对突破自主无人机应用场景和基础性能具有关键推动作用。

本研究聚焦于基于深度强化学习的无人机规划和控制方法，旨在解决单机在复杂场景下的建图后规划、实时避让与精确控制问题。通过设计分阶段奖励机制引导深度强化学习网络学习和收敛，并构建仿真训练环境和实物平台，最终实现无人机在 GPS 拒止、障碍物环境下的无人机自主规划飞行。研究成果有望为工业巡检、灾害救援等关键领域提供理论支持与技术储备，具有实际的工程意义。

1.2 国内外相关研究现状

1.2.1 无人机自主系统架构技术

随着无人机在军事侦察、灾害救援、精准农业等领域的广泛应用，其自主系统架构技术已成为学术界与工业界的研究焦点。自主系统架构作为无人机智能化的核心载体，直接影响着环境感知、决策规划与运动控制的整体性能。当前主流架构主要呈现分层式、耦合式与端到端式三种技术路线，国内外学者针对不同应用场景开展了深入探索。

通过模块化分层设计实现功能解耦，其” 感知 - 规划 - 执行” 的经典范式受到广泛认可。MIT 的 ACFR 实验室提出了四层架构[6]，包含环境感知层、任务规划层、运动控制层和硬件驱动层，该框架被成功应用于 NASA 火星无人机原型系统。国内方面，北京航空航天大学团队[7] 通过改进分层接口协议，将规划层响应速度提升了 37%。

耦合式架构（Coupled architecture）强调模块间的紧耦合交互，尤其适用于动态环

中国知网 https://www.cnki.net

境下的实时响应。苏黎世联邦理工学院 (ETH) 开发的 Robotic Operating System (ROS) 框架[8] 通过发布-订阅机制实现多模块并行协作，其无人机避障延迟低于 50ms。国内研究中，国防科技大学提出的 BVC（Behavior-Based Virtual Controller）架构[9] 将 SLAM 与路径规划模块深度耦合，在军事侦察任务中表现出色。

端到端架构（End-to-end architecture）借助深度学习技术实现感知到控制的直接映射，近年来取得突破性进展。Google Brain 团队[10] 采用深度强化学习框架，使无人机在未建模环境中自主飞行成功率提升至 92%。值得关注的是，南京大学[11] 将数字孪生技术与端到端架构结合，构建了虚实联动的自主训练系统。但这类架构存在可解释性不足的缺陷，清华大学团队[12] 通过引入语义中间层的方法，在保持端到端优势的同时提高了决策透明度。

当前研究趋势呈现三大特征：架构融合化（如分层 - 端到端混合架构）[13] 、计算边缘化（架构部署向机载设备迁移）[14] 、验证标准化（建立无人机架构评估基准平台）[15]。未来研究需在动态环境适应性、多机协同架构优化、能耗效率平衡等方面实现突破，特别是需要建立符合中国空域特点的自主系统架构标准体系。

1.2.2 多旋翼无人机的轨迹规划

多旋翼无人机轨迹规划技术是自主飞行的核心环节，其目标是在复杂动态环境中生成满足动力学约束、避障要求及任务目标的最优路径。近年来，随着无人机在物流、巡检、救援等领域的广泛应用，轨迹规划方法的研究呈现多元化发展趋势，主要可归纳为基于采样的规划、基于优化的规划及数据驱动的规划三类方法，各类方法在实时性、最优性和环境适应性上具有独特优势与局限性。

基于采样的规划方法通过随机搜索构建可行路径，以概率完备性和计算效率著称。国外研究中，Kuffner 等提出的 RRT（快速扩展随机树）算法及其改进版本 RRT*、Informed RRT 被广泛用于无人机三维路径搜索[16]。Karaman 团队进一步引入动态约束自适应采样策略，显著提升复杂空域下的规划成功率[17]。国内学者针对实时性瓶颈取得突破，如清华大学王磊团队提出 GPU 并行化 RRT-Connect 算法，将规划耗时降低 40%[18]，哈尔滨工业大学张强等人开发动态障碍物预测模块与 RRT 融合框架，增强动态场景适应性[19]。然而，该类方法生成的轨迹通常需后处理平滑，且全局最优性难以保证。

中国知网 https://www.cnki.net

基于优化的规划方法通过构建目标函数与约束条件求解最优轨迹，在轨迹平滑性与动力学合规性方面表现突出。国际研究前沿中，MIT 的 Deits 等人采用半定规划（SDP）解决非凸避障约束问题[20]，苏黎世联邦理工学院（ETH）的 Zhou 等将微分平坦理论与模型预测控制（MPC）结合，实现高速无人机实时轨迹生成[21]。国内研究聚焦于约束处理优化，如北京航空航天大学陈浩团队提出分层优化架构，通过稀疏化约束提升求解效率[22]，浙江大学刘洋课题组开发基于 B 样条参数化的时空联合优化方法，有效协调避障与能耗间的矛盾[23]。此类方法虽能获得高质量轨迹，但面临非凸优化求解耗时、对初值敏感等挑战。

数据驱动方法利用机器学习从历史数据或仿真环境中学习规划策略，为未知环境下的在线决策提供新范式。国际学术界中，加州大学伯克利分校的 Pinto 团队采用深度强化学习（DRL）实现无人机在密集动态障碍物中的端到端避障[24]，斯坦福大学 Gupta 等人设计模仿学习框架，从专家演示中提取复杂机动策略[25]。国内研究注重算法轻量化与迁移能力，如中科院自动化所李航课题组提出基于元学习的规划模型，可在少样本条件下适应新场景[26]。尽管此类方法展现出强大的环境适应潜力，但其可解释性不足与数据获取成本仍是实际部署的主要障碍。

当前研究趋势表明，融合采样、优化与数据驱动的混合规划架构逐渐成为主流。然而，如何实现异构方法的高效协同、平衡计算效率与轨迹质量、提升复杂干扰下的鲁棒性，仍是亟待突破的关键科学问题。本文后续章节将围绕上述挑战展开深入研究。

1.2.3 多旋翼无人机先进控制策略

多旋翼无人机的高性能控制策略是实现精准轨迹跟踪、抗扰稳定及安全机动的关键保障。随着飞行任务复杂度与动态环境不确定性的加剧，传统控制方法面临模型失配、实时性不足等挑战，催生了模型驱动控制、数据驱动控制及混合控制等先进策略的快速发展。本节从方法原理、技术突破与应用局限三个维度综述国内外研究进展。

模型驱动控制基于精确动力学建模设计控制器，具有理论严谨、稳定性可证的特点。国际上，苏黎世联邦理工学院（ETH）的 Faessler 团队通过非线性模型预测控制（NMPC）实现无人机高速飞行下的厘米级轨迹跟踪，其扰动观测器设计将风扰补偿误差降低至 0.3m/s 以下[27]。麻省理工学院（MIT）Tedrake 课题组提出微分平坦性理论驱动的分层控制框架，通过状态约束凸化提升抗突风能力[28]。国内研究中，团队开发了

中国知网 https://www.cnki.net

哈尔滨工业大学高会军自适应滑模控制器，结合李雅普诺夫稳定性分析，将姿态控制精度提升至 ±0.05 弧度[29]。然而，此类方法高度依赖模型精度，在强非线性与未建模动态场景中易出现性能退化。

数据驱动控制通过机器学习直接从数据中提取控制律，突破了对先验模型的依赖。国际前沿中，剑桥大学 Kormushev 课题组采用深度确定性策略梯度（DDPG）实现无模型姿态控制，响应速度较传统 PID 提升 30%[30]。国内研究聚焦轻量化与安全性，如清华大学孙富春团队提出联邦强化学习框架，通过分布式训练降低 90% 的数据传输量[31]；浙江大学熊蓉团队设计基于时空注意力机制的 LSTM 控制器，在传感器噪声下将位置均方误差降低至 0.1m[32]。尽管此类方法在复杂场景中表现优异，但其黑箱特性导致的稳定性风险与数据采集成本仍是实际部署的主要障碍。

混合控制通过融合模型驱动与数据驱动优势，兼顾鲁棒性与环境适应性。国际研究方面，佐治亚理工学院 Egerstedt 课题组开发基于贝叶斯更新的混合控制框架，通过实时数据融合动态调整模型参数[33]。国内创新成果中，上海交通大学张卫东团队设计模型-数据双回路控制结构，前馈通道采用 LSTM 预测扰动，反馈通道基于滑模控制保证稳定性，实验表明抗扰能力提升 60%[34]。当前研究难点在于动态权重分配策略的设计与实时性保障，需进一步解决异构模块的协同优化问题。

现有研究表明，先进控制策略正朝着“模型-数据协同化”与“计算-通信轻量化”方向发展。然而，如何实现不确定干扰下的全域稳定、平衡模型依赖性与数据效率、构建可解释的混合控制理论体系，仍是制约技术落地的核心挑战。本文后续工作将针对上述问题提出新型混合控制架构，并通过仿真与实飞实验验证其有效性。

1.2.4 深度强化学习在机器人领域应用

深度强化学习（DRL）凭借其端到端决策与复杂环境自适应的优势，已成为机器人智能控制的研究热点。然而，仿真训练与物理部署的差异、高维动作空间下的收敛效率、以及安全约束的严格保障，仍是 DRL 技术落地的核心挑战。本节从仿真到现实迁移、训练加速与安全约束三个关键技术方向综述国内外研究进展。

仿真到现实迁移旨在缩小虚拟训练与物理执行间的“现实鸿沟”。国际研究中，OpenAI 的 Rajeswaran 团队提出层级域随机化（HDR）方法，通过动态调整物理参数分布，使机械臂抓取任务迁移成功率提升至 79%（ICRA 2023）[35]。加州大学伯克利分校

中国知网 https://www.cnki.net

Levine 课题组开发基于系统辨识的逆动力学模型，将四足机器人运动策略迁移误差降低 62%[36]. 国内创新方面，清华大学孙富春团队提出自适应域随机化框架，结合在线环境参数估计，实现无人机避障任务 85% 以上的跨平台迁移成功率[37]。当前瓶颈在于复杂接触动力学建模不足与多模态扰动泛化能力有限。

DRL 训练加速技术聚焦于提升样本效率与计算资源利用率。DeepMind 的 Espeholt 等人提出分布式优先经验回放（DPER），在机械臂操控任务中实现 10 倍以上的训练速度提升[38]。Meta AI 团队（原 FAIR）的 Rajeswaran 通过课程学习与课程学习结合，将四旋翼敏捷飞行训练周期从 200 小时压缩至 50 小时[39]。国内进展中，中科院自动化所刘成林团队开发基于迁移学习的多任务共享网络，通过知识蒸馏使机械臂新任务训练时间缩短至 2 小时（IROS 2022)[40]；哈尔滨工业大学洪炳熔团队提出分层经验回放缓冲机制，在无人机导航任务中达到 89% 的样本复用率[41]。然而，现有方法在长周期稀疏奖励任务中仍面临探索效率低下与局部最优陷阱问题。

安全约束实现通过形式化方法确保 DRL 策略满足物理限制与操作规范。国际前沿中，加州大学伯克利分校 Ames 团队提出安全屏障函数与 DRL 融合框架，在足式机器人运动中实现碰撞率低于 2%（RSS 2023)[42]。国内突破包括北京大学王龙团队设计的约束感知策略优化（CAPO）算法，通过李雅普诺夫函数约束保证无人机姿态稳定，实验违规率低于 1%[43]。现有挑战集中于高维约束的实时验证与不确定干扰下的鲁棒性保障。

当前技术发展呈现“虚实协同化”“训练高效化”与“安全可证化”趋势，但跨模态迁移的普适性、复杂任务的计算可扩展性、以及开放环境下的终身安全学习仍是亟待突破的难题。本文后续将提出基于元强化学习的安全约束迁移框架，通过分层奖励塑形与物理引导策略优化，系统提升 DRL 在实际机器人系统中的可靠性。

1.3 当前研究面临的挑战和本文创新点

自主无人机涉及多个研究领域，其中在规划控制算方面依然存在大量的技术困难。首先在规划算法层面，尽管使用基于样条和优凸化的方法可以保证飞行轨迹的合法和平滑性，但是对于需要兼顾能耗和速度、考虑控制器控制效果，在障碍物密集的场景依然存在计算效率与动力学可行性无法兼顾的困境。其次在控制算法方面，自抗扰控制、模型预测控制等基于反馈或模型的控制方法被大量应用在多旋翼无人机上，虽然改善

中国知网 https://www.cnki.net

了无人机的控制器性能，但是无法有效应对模型失配或未建模动态干扰，在时变参数的自适应上也存在不足。更加值得注意的是，现有的规划控制框架因使用”规划-控制”的解耦设计，缺乏控制器对规划算法的闭环反馈，这导致现有的算法存在运行误差，尤其在高速多弯场景中，对飞行轨迹的安全性构成了巨大威胁。

针对上述挑战，本研究提出基于深度强化学习的规划控制反馈框架，设计了融合模型预测控制和元强化学习的跟踪控制算法，通过预训练控制模型和实时快速学习提高控制器的环境适应能力。同时，构建基于深度强化学习的轨迹规划算法，价值网络学习安全飞行走廊的几何特征预测飞行轨迹的能量开销；搭建了基于多专家模型的强化学习算法进行轨迹参数优化。最终，研究提出了规划控制反馈机制，将跟踪控制算法的状态评估反馈给轨迹生成网络，抑制高速机动场景下无人机的运动控制误差。本文提出的方法为复杂环境下的无人机自主飞行提供了新的技术思路，提高了自主无人机实际应用中的运行表现。

1.4 论文结构安排

本文的结构安排如下：第一章是绪论，给出本研究的背景、研究现状和研究内容的必要性；第二章介绍了无人机的动力学建模、规划算法的理论基础、深度强化学习的相关算法基础和规划控制问题的马尔可夫模型；第三章介绍了算法的总体设计，包括反馈机制的定义、控制规划算法的设计及各个专家网络的结构；第四章进行了算法的稳定性证明、分析和实验，证明了强化学习方法的有效性，分析了分层算法在异步条件下的稳定性同时给出了控制的稳定边界；第五章进行了本研究的仿真、真机实验，验证了上述二、三、四章算法的有效性；第六章是本研究的总结，介绍了研究内容的实用价值和未来可以继续改进和研究的方向。

中国知网 https://www.cnki.net

第二章　系统建模与理论基础

本研究面向动态障碍物场景下的四旋翼无人机自主规划控制问题，旨在建立基于深度强化学习的规划控制解决方案。为引入深度强化学习所需的基础理论和建模分析，本章节首先引入无人机的推力-重力耦合动力学建模，建立了基于无人机动力学模型的运动模型，给出了理想模型的求解过程，构造了新的微分平坦表达；然后引入了基于多项式轨迹的生成算法，并严格证明高阶多项式轨迹在耦合模型下的可达性；最后进行了基于上述两个无人机模型和轨迹模型的强化学习问题建模。

2.1 无人机动力学模型

2.1.1 理想推力-重力耦合模型

根据微分平坦性理论[44]，四旋翼无人机的完整状态可由轨迹 $P(t)$ 及其高阶导数唯一确定。考虑无风扰动条件下的刚体运动，其动力学方程为：

$$M_{\text{drone}}\ddot{P} = F_t + G \tag{2.1}$$

其中 $P(t) \in \mathbb{R}^3$ 为规划轨迹（位置坐标 $[x(t), y(t), z(t)]^T$）；$Q = [0, 0, -M_{\text{drone}}g]^T$ 为重力向量，方向与惯性系 Z 轴相反；g 为重力加速度数值；F_t 为旋翼推力在惯性系下的投影；M_{drone} 为无人机总质量（含负载）。

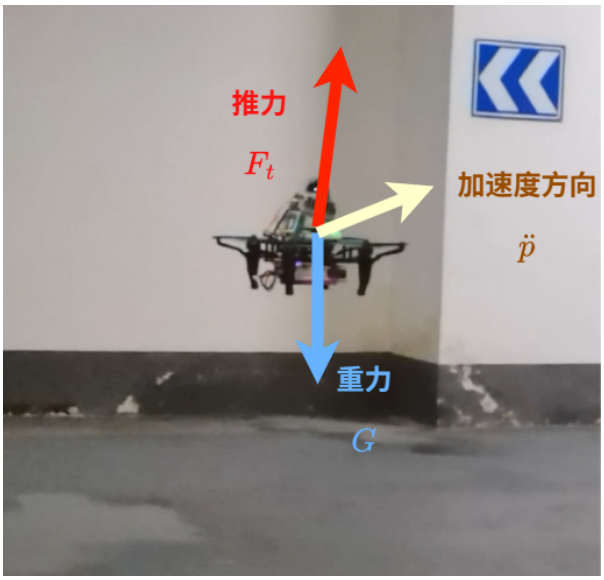


图 2-1 无人机的动力学模型

Figure 2-1 Quadrotor dynamic model

中国知网　https://www.cnki.net

如图2-1所示，通过调整无人机的 Z 轴拉力向量，就可实现无人机的 SE(3) 空间位移。然而图2-1同样表明无人机的姿态决定了 Z 轴的推力方向，其物理模型含有约束。约束中的四旋翼无人机的姿态通常可以使用四元数来表示，即:

$$q = [q_0, q_1, q_2, q_3]^T = [q_0, q_v]^T \tag{2.2}$$

并且四元数表示满足归一化约束:

$$\|q\|^2 = q_0^2 + q_1^2 + q_2^2 + q_3^2 = 1 \tag{2.3}$$

同时，机体角速度 $\omega = [p, q, r]^T$ 与四元数导数的关系可由微分方程描述:

$$\dot{q} = \frac{1}{2} q \otimes \begin{bmatrix} 0 \\ \boldsymbol{\omega} \end{bmatrix} = \frac{1}{2} \begin{bmatrix} -q_1 & -q_2 & -q_3 \\ q_0 & -q_3 & q_2 \\ q_3 & q_0 & -q_1 \\ -q_2 & q_1 & q_0 \end{bmatrix} \begin{bmatrix} p \\ q \\ r \end{bmatrix} \tag{2.4}$$

其中 $\otimes$ 表示四元数乘法运算；$\boldsymbol{\omega}$ 表示无人机刚体的角速度。

基于上述无人机的四元数表示，惯性系下的推力向量 $\boldsymbol{F_t}$ 和机体坐标系 Z 轴方向 $e_z^b = [0, 0, 1]^T$ 是同向的:

$$\boldsymbol{F_t} \times (\boldsymbol{R}(q) e_z^b) = \boldsymbol{0} \tag{2.5}$$

其中旋转矩阵 $\boldsymbol{R}(q)$ 的四元数表示为:

$$\boldsymbol{R}(q) = \begin{bmatrix} 1 - 2(q_2^2 + q_3^2) & 2(q_1 q_2 - q_0 q_3) & 2(q_1 q_3 + q_0 q_2) \\ 2(q_1 q_2 + q_0 q_3) & 1 - 2(q_1^2 + q_3^2) & 2(q_2 q_3 - q_0 q_1) \\ 2(q_1 q_3 - q_0 q_2) & 2(q_2 q_3 + q_0 q_1) & 1 - 2(q_1^2 + q_2^2) \end{bmatrix} \tag{2.6}$$

基于上述的四旋翼无人机的刚体动力学模型和模型中的姿态约束，可以构建理想情况下的推力-重力耦合模型:

$$\begin{cases} \boldsymbol{M}_{\text{drone}} \ddot{\boldsymbol{P}} = \boldsymbol{F_t} - \boldsymbol{Q} \\ \boldsymbol{F_t} = \boldsymbol{R}(q) \cdot (\boldsymbol{T} e_z^b) \\ \dot{q} = \frac{1}{2} q \otimes \begin{bmatrix} 0 \\ \boldsymbol{\omega} \end{bmatrix} \\ \boldsymbol{J}\dot{\boldsymbol{\omega}} + \boldsymbol{\omega} \times \boldsymbol{J}\boldsymbol{\omega} = \boldsymbol{\tau} \end{cases} \tag{2.7}$$

其中 $\boldsymbol{T}$ 是推力 $\boldsymbol{F_t}$ 的模长，实际物理模型中表示旋翼推力的数值大小。显然在理想的物理模型中，通过对机体角速度 $\boldsymbol{\omega}$ 和旋翼拉力数值 $\boldsymbol{T}$ 的控制，就可以使无人机按照物理模型进行运动。

中国知网　https://www.cnki.net

2.1.2 微分平坦参数化理论及其改进

四旋翼无人机在进行跟踪控制时，因为微分平坦性理论[44]为无人机的规划控制提供了极大的便利，所以通常会将目标设定为具有微分平坦性质的轨迹。该理论将系统的全状态和控制输入描述为由一组平坦输出及其有限阶导数显式表达的形式，使得控制规划过程不需要关注全部状态，而是只需要关注平坦输出状态。

目前常用的平坦输出状态会选取位置坐标与偏航角，即 (x, y, z, ψ)，其中姿态参数采用欧拉角描述，然而由于欧拉角存在万向锁和奇点，在全姿态的状态空间中有较大的限制。本研究提出位置-四元数参数化方法，将偏航角 ψ 扩展为完整四元数 $\boldsymbol{q}$，同时保持平坦输出维度不变。

四元数也支持无人机倾斜角和偏航角的分离，不同于欧拉角和旋转矩阵，这种分离不受旋转顺序的影响：

定义 2-1 （倾斜四元数）： 称 $\boldsymbol{q}_{\text{tilt}} \in \mathbb{S}^3$ 为纯倾斜四元数，当且仅当满足：

$$\boldsymbol{q}_{\text{tilt}} = [q_0, q_1, q_2, 0]^T / \sqrt{q_0^2 + q_1^2 + q_2^2} \tag{2.8}$$

其对应的欧拉角 ϕ, θ 满足横滚角 $\phi \in (-\pi/2, \pi/2)$，俯仰角 $\theta \in (-\pi/2, \pi/2)$

命题 2-1 （四元数的分解）： 四旋翼姿态四元数 $\boldsymbol{q} \in \mathbb{S}^3$ 可唯一分解为倾斜分量 $\boldsymbol{q}_{\text{tilt}} \in \mathbb{S}^3$ 与偏航分量 $\boldsymbol{q}_{\psi} \in \mathbb{S}^3$ 的合成：

$$\boldsymbol{q} = \boldsymbol{q}_{\text{tilt}} \otimes \boldsymbol{q}_{\psi} \tag{2.9}$$

其中：$\boldsymbol{q}_{\text{tilt}}$ 描述俯仰 (pitch) 与横滚 (roll) 运动，满足 $\boldsymbol{q}_{\text{tilt}} = [q_0, q_1, q_2, 0]^T / \|\cdot\|$；$\boldsymbol{q}_{\psi} = [\cos\frac{\psi}{2}, 0, 0, \sin\frac{\psi}{2}]^T$ 表示纯偏航旋转。

该分解保持了平坦输出空间的四维特性：

$$\boldsymbol{z} = (x, y, z, \boldsymbol{q}_{\psi}) \in \mathbb{R}^3 \times \mathbb{S}^3 \tag{2.10}$$

证明： 通过四元数乘法结合律可得：

$$R(\boldsymbol{q}) = R(\boldsymbol{q}_{\text{tilt}}) R(\boldsymbol{q}_{\psi})$$
$$\boldsymbol{\omega} = \boldsymbol{\omega}_{\text{tilt}} + R(\boldsymbol{q}_{\text{tilt}}) \boldsymbol{\omega}_{\psi}$$

其中 $\boldsymbol{\omega}_{\text{tilt}} \in \mathbb{R}^3$ 与 $\boldsymbol{\omega}_{\psi} \in \mathbb{R}^3$ 分别对应倾斜与偏航角速度。由此，系统状态 $\{\boldsymbol{P}, \boldsymbol{q}, \boldsymbol{\omega}\}$ 可由 $\boldsymbol{z}$ 及其一、二阶导数唯一确定。由此命题证毕。 □

中国知网 https://www.cnki.net

根据四元数姿态分解特性，纯偏航旋转对应的四元数仅包含两个非零分量：

$$\boldsymbol{q}_\psi = \begin{bmatrix} \cos\frac{\psi}{2} \\ 0 \\ 0 \\ \sin\frac{\psi}{2} \end{bmatrix} = \begin{bmatrix} \sqrt{1-\zeta^2} \\ 0 \\ 0 \\ \zeta \end{bmatrix}, \quad \zeta \in [-1, 1] \tag{2.11}$$

其中 $\zeta = \sin\frac{\psi}{2}$ 为归一化参数，满足：

$$\|\boldsymbol{q}_\psi\|^2 = \left(\sqrt{1-\zeta^2}\right)^2 + \zeta^2 = 1 \tag{2.12}$$

命题 2-2（偏航角单参数化）：在姿态分解 $\boldsymbol{q} = \boldsymbol{q}_{\text{tilt}} \otimes \boldsymbol{q}_\psi$ 下，偏航角 ψ 可唯一由 ζ 参数化：

$$\psi = 2\arcsin(\zeta) = 2\arctan\left(\frac{\zeta}{\sqrt{1-\zeta^2}}\right) \tag{2.13}$$

其中 $\zeta \in [-1, 1]$ 作为新的平坦输出分量。

命题 2-3（偏航角单参数化的微分平坦性）：对于动力学系统(2.7)，存在平坦输出：

$$\boldsymbol{z} = (x, y, z, \zeta) \in \mathbb{R}^3 \times [-1, 1] \tag{2.14}$$

使得系统状态 $\boldsymbol{x} = (\boldsymbol{P}, \boldsymbol{q}, \boldsymbol{\omega})$ 与控制输入 $\boldsymbol{u} = (T, \boldsymbol{\tau})$ 均可由 $\boldsymbol{z}$ 及其至三阶导数唯一确定。

证明：由四元数指数映射关系：

$$\begin{aligned} \boldsymbol{q}_\psi &= e^{\frac{\psi}{2}\boldsymbol{e}_z} \\ &= \cos\frac{\psi}{2} + \boldsymbol{e}_z \sin\frac{\psi}{2} \\ &\Rightarrow \zeta = \sin\frac{\psi}{2} \end{aligned}$$

结合四元数约束 $\|\boldsymbol{q}_\psi\| = 1$，可得 ζ 与 ψ 的双射关系。命题证毕。 □

由此，可将全状态重新参数化为四元数微分平坦空间：

$$\boldsymbol{z}_{\mathbf{q}} = (x, y, z, \zeta) \in \mathbb{R}^3 \times [-1, 1] \tag{2.15}$$

该参数化将偏航角投影到三角函数值域，优化后的参数化方案具有如下的优势：1. 彻底消除对欧拉角参数的依赖；2. 旋转角度 ϕ 可无限增长而不引发奇异性；3. 参数 ζ 在 $(-1, 1)$ 内保持单射性，保持了四维平坦输出的特性。

中国知网　https://www.cnki.net

2.1.3 理想推力-重力耦合模型的求解方法

为了求解上述四元数微分平坦空间构成的四旋翼无人机轨迹，本研究参考了先前提出的理想推理-重力耦合模型(2.7)。基于前述理论，本研究提出一种自上而下的方法，先计算推力向量的正确方向，在反推求解姿态变化。

假设无人机精确跟踪轨迹 $P(t)$，则推力向量可通过式(2.1)反推：

$$F_t = M_{\text{drone}}(\ddot{P} + ge_z) \tag{2.16}$$

其中 $e_z = [0, 0, 1]^T$ 为惯性系 Z 轴单位向量。

在机体坐标系 $\mathcal{B}$ 中，推力方向与无人机 Z 轴对齐：

$$F_t = R(q) \cdot \begin{bmatrix} 0 \\ 0 \\ T \end{bmatrix} \tag{2.17}$$

其中 $R(q) \in \text{SO}(3)$ 为由四元数 q 描述的旋转矩阵，T 为总推力标量。

联立式(2.16)和(2.17)，可得推力大小与姿态的关系：

$$T = \|F_t\| = M_{\text{drone}}\|\ddot{P} + ge_z\| \tag{2.18}$$

基于微分平坦性，定义无人机的平坦期望姿态四元数 q_{des} 的计算流程为：

$$z_b^{\text{des}} = \frac{\ddot{P} + ge_z}{\|\ddot{P} + ge_z\|} \tag{2.19}$$

$$y_b^{\text{des}} = \frac{z_b^{\text{des}} \times \dot{P}}{\|z_b^{\text{des}} \times \dot{P}\|} \tag{2.20}$$

$$x_b^{\text{des}} = y_b^{\text{des}} \times z_b^{\text{des}} \tag{2.21}$$

$$R_{\text{des}} = [x_b^{\text{des}}\ y_b^{\text{des}}\ z_b^{\text{des}}] \tag{2.22}$$

$$q_{\text{des}} = R_q^{-1}(R_{\text{des}}) \tag{2.23}$$

其中 R_{des} 表示目标姿态的旋转矩阵；z_b^{des}、y_b^{des}、x_b^{des} 分别表示姿态在惯性坐标系下的投影；R_q^{-1} 是求解旋转矩阵对应四元数的映射函数。

通过计算(2.18)至(2.23)，即可得控制器所需的无人机目标姿态和推力。

2.1.4 真实物理条件下的动力学模型修正

在真实物理条件下，因无人机的动力学模型受其他作用力干扰，理想模型不能直接使用。其中，风阻和户外风力干扰对无人机的干扰较为显著，考虑空气阻力与无人机相对风速的二次关系：

$$F_w = -\frac{1}{2}\rho_{\text{air}} C_d A \|v_{\text{rel}}\| v_{\text{rel}} \tag{2.24}$$

中国知网 https://www.cnki.net

其中 ρ_{air} 为空气密度，单位为千克每立方米 (kg/m^3)，C_d 为阻力系数，A 为迎风面积；$v_{\text{rel}} = v - v_{\text{wind}}$ 为无人机相对于气流的速度；$v_{\text{wind}} = v_{\text{const}} + v_{\text{gust}}$ 为总风速，包含定常分量 v_{const} 和阵风分量 $v_{\text{gust}} \sim \mathcal{N}(0, \Sigma)$

由此得到修正后的无人机牛顿-欧拉方程：

$$M_{\text{drone}}\ddot{P} = F_t + G + F_w + F_d \tag{2.25}$$

$$J\dot{\omega} + \omega \times J\omega = \tau - \tau_w + \tau_d \tag{2.26}$$

其中 τ_w 为风阻引起的力矩扰动，可由 F_w 作用点偏移计算；F_d 为其他建模并未考虑的力扰动；τ_d 为建模未考虑的力矩扰动。

在工程实践环节，未建模的扰动通常包括：电池随电压变化产生的电机特性变化、海拔高度或环境气压造成的多旋翼机性能变化、无人机本身的运动学参数变化等等。由于无人机时变参数（如直流无刷电机的 Kv 特性曲线随电池消耗变化）和未建模动态的广泛存在，基于精确模型的前馈补偿方法面临显著的工程局限性。因此使用强化学习等基于无模型学习的方法并减少扰动对控制的影响具有一定的工程价值。本研究将会在 2.3 节和第三章利用强化学习对真实物理模型下的无人机控制问题进行讨论。

2.2 轨迹规划算法与可达性分析

2.2.1 安全飞行走廊的最小控制量轨迹问题构造

四旋翼无人机的轨迹规划层面，一个典型的规划任务可以描述为：在控制输出 $u(t)$ 的作用下，从初始时刻 t_s 开始，至最终时刻 t_f 结束，无人机状态从 p_s 变化至 p_f，任务中的 p_s 和 p_f 通常包含了位置、速度、加速度或者更高阶的状态。通常，无人机存在多种可能的控制输出序列来完成飞行任务，即存在一个集合，其包含了所有可行的控制序列：

$$\mathcal{R} = \left\{ u(t) \;\middle|\; \begin{array}{l} z^{(s)}(t) = u(t), \\ z^{(s-i)}(t_s) = {p_s}^{(s-i)}(t_s), \\ z^{(s-i)}(t_f) = {p_f}^{(s-i)}(t_f), \\ z^{(d_j-i)}(t) = p_j^{(d_j-i)}(t), \\ G(z(t)) \\ i = 1, 2, \ldots, s, \\ t \in [t_s, t_f], \\ s \in \mathbb{N}^+ \end{array} \right\} \tag{2.27}$$

中国知网　https://www.cnki.net

式中 $\mathcal{R}$ 是所有满足给定约束的可行控制序列 $u(t)$ 的集合；$z(t)$ 是在控制序列 $u(t)$ 作用下状态变量，通常代表无人机的位置或其他基本状态；$z^{(s)}(t)$ 表示状态 $z(t)$ 的 s 阶导数；s 是一个正整数，表示状态序列（包括 p_s 和 p_f）中考虑的最高阶数；$G(z(t))$ 表述状态序列 $z(t)$ 必须满足的约束条件，包括运动学约束和飞行走廊的空间限制，这些约束保证了飞行轨迹的合理性和安全性；$u(t)$ 是集合 $\mathcal{R}$ 中的元素，代表无人机用以完成飞行任务的控制序列。

无人机在进行轨迹规划时，通常需要在飞行走廊限制的区域内进行轨迹生成，并且还需要遵守无人机动力学约束，这构成了无人机的约束 Q，其分为两个部分：

$$Q = \{Q_{\mathrm{p}}, Q_{\mathrm{kn}}\} \tag{2.28}$$

式中 Q 表示无人机在规划过程中的所有约束，Q_{p} 表示无人机飞行过程中的飞行走廊的约束；Q_{kn} 表示无人机飞行过程中的运动学约束。由于飞行走廊可由不同的凸包组合形成，因此也可以将这种飞行走廊的约束写为：

$$Q_{\mathrm{p}} = \{\mathrm{p}_1, \mathrm{p}_2, \ldots, \mathrm{p}_{\mathrm{n}}\} \tag{2.29}$$

式中假设了规划算法已经将可行的空间分为 n 个存在交集的凸包空间子集，在这之后飞行器可以得到一条符合运动学约束，并且通过这些凸包的轨迹，即凸包之间存在如下的关系:

$$\mathrm{p}_i \cap \mathrm{p}_{i+1} \neq \varnothing, i = 1, 2, \ldots, n-1 \tag{2.30}$$

对于凸包 $\mathrm{p}_i, i = 1, 2, \ldots, n$，通常使用半空间描述法，使用不等式约束对每个凸包的平面进行描述，因此当一个凸包存在 k_i 个面，则可以将凸包 p_i 中的 k_i 个平面描述为：

$$\mathrm{p}_i = \{H_{1,i}, H_{2,i}, \ldots, H_{k_i,i}\}, i = 0, 1, \ldots, n \tag{2.31}$$

式中 $H_{j,i}$ 表示了第 i 个凸包的第 j 个平面的空间不等式描述。在使用神经网络对无人机飞行任务的最低能量消耗进行预测时，这些凸包描述可以作为外部环境信息进行利用，进而提高网络的预测精度。

最终，每个飞行走廊的轨迹规划约束写为 Q_i，包含了空间的约束 p_i 和飞行动力学约束 Q_{kn}：

$$Q_i = \{p_i, Q_{\mathrm{kn}}\}, i = 0, 1, \ldots, n \tag{2.32}$$

对于一个合法的飞行轨迹，其需要使其位置等状态始终在飞行走廊 Q_{p} 中，同时需

中国知网 https://www.cnki.net

要满足其高阶导数存在，即：

$$Q_{\text{kn}}：\forall k \in \mathbb{N}, 0 \leq k \leq s, \exists f^{(k)}(x), \forall x \in [t_s, t_f] \tag{2.33}$$

式中 s 是一个正整数，表示状态序列（包括 p_s 和 p_f）中考虑的最高阶数。

在实际应用场景中，飞行器在起飞时携带的能量 E_r 是固定的，这限制了其在整个飞行过程中的总能量消耗。因此，对于任何给定的控制输出 $u(t)$，总能量消耗不得超过这一能量限制 E_r。相应地，在进行轨迹规划时，必须考虑能量消耗的上限约束。为了更清晰的表述无人机的能量消耗，本文定义了无人机在控制输出 $u(t)$ 作用下的总体能量消耗模型：

$$E(u(t)) = \int_{t_s}^{t_f} u(t)^T W u(t) dt \tag{2.34}$$

式中 $E(u(t))$ 表示在控制序列 $u(t)$ 作用下完成飞行器完成飞行任务所消耗的总能量；$u(t)$ 表示无人机的控制输出序列；t_s 和 t_f 分别代表无人机的起始和结束时间点；W 是一个正定的权重矩阵，用于量化不同控制输出对能量消耗的贡献。

在实际工程场景中，无人机不仅要面对携带能量的限制，还需要在确保安全的前提下尽可能快速地完成飞行任务。为了使无人机在满足能量消耗约束的同时，尽可能快速且安全地完成任务，我们定义了如下优化问题：

$$\begin{aligned} \min \quad & T(u(t)) \\ \text{s.t.} \quad & u(t) \in \mathcal{R}(Q, p_s, p_f) \\ & E(u(t)) \leq E_r \end{aligned} \tag{2.35}$$

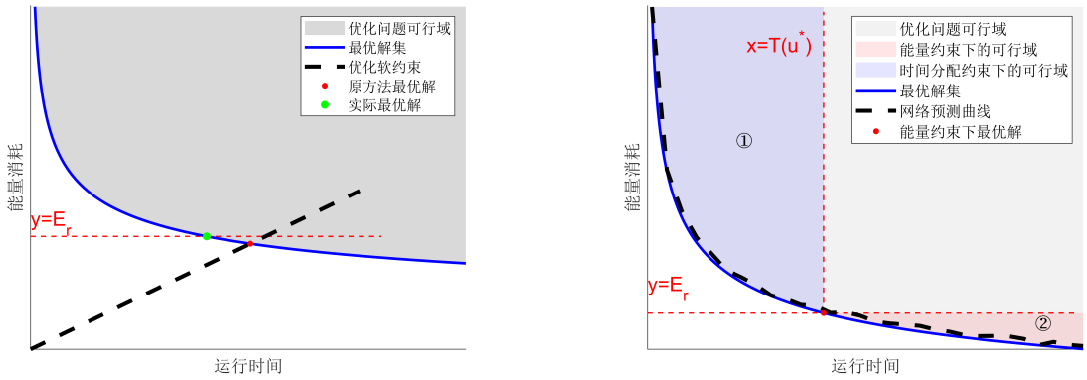
在上述优化问题中 $\mathcal{R}$ 是基于约束 Q，初始状态 p_s 和最终状态 p_f 定义的所有可行解的集合；$u(t)$ 代表该集合中的一个具体轨迹；$T(u(t))$ 代表轨迹 $u(t)$ 的执行时间；E_r 代表飞行任务的能量消耗上限。该优化问题旨在寻找一条既满足能量约束又具最短执行时间的轨迹，这是本研究的核心问题。

尽管式(2.35)中的优化问题旨在寻找既满足能量约束又具有最短执行时间的轨迹，但在实际求解过程中，由于优化问题的权重往往是固定的，而参数调整不仅烦琐且需要消耗较多的运算资源，因此现有方法很难对整个可行空间进行完整的搜索。为了深入理解这些挑战以及优化问题的求解空间，我们收集了飞行任务数据来进行详细的说明，如图2-2所示。

图2-2展示了在约束条件和飞行任务固定的情况下，无人机飞行轨迹的运行时间与能量消耗之间存在明显的反比关系。具体而言，飞行任务的耗时越短，相应的最小能

中国知网　https://www.cnki.net

量消耗越高。这种描述最小能量消耗与飞行时间关系的边界称为帕累托最优边界，它代表了在给定的能量约束下，无人机能够实现的最短飞行时间的理想值。



(a) 原方法很难找到最优解　　(b) 通过网络推理帕累托最优边界构造优化问题

图 2-2 能量约束下轨迹规划问题的求解原理

Figure 2-2 Solution Methodology for Energy-Constrained Trajectory Planning Problems

然而，现有的轨迹生成方法很难按照能量消耗的约束找到对应的最小能量和相应轨迹，一些诸如最小控制量轨迹的优化方法尝试用软约束的方式进行探索，然而其最终的求解结果通常会落在如图2-2(a)所示的红色交点附近，而非能量约束 E_r 所对应的绿色最优解位置。另外，通过软约束的形式求解式(2.35)存在一些缺陷，首先是能量约束 E_r 对应的最短末端时间难以求解，搜索需要花费较大的时间和性能开销；其次，软约束在权重过大，即图2-2(a)中约束斜率过高时，会造成生成的轨迹质量不稳定。

如图2-2(b)所示，为了求解式(2.35)中描述的主要问题，本研究在第三章提出了基于几何特征的能耗预测和时间分配的专家算法，通过神经网络预测飞行任务中时间消耗和能量的帕累托最优边界，并且求解出了合理的时间分配方案。这一方法大大提高了优化算法对规划问题的求解速度，解除了现有算法无法对帕累托最优边界全局进行搜索的局限，改善了无人机的能耗效率。

2.2.2 高阶多项式轨迹参数化方法

目前，四旋翼无人机的轨迹规划算法最为常用的轨迹形式是多项式轨迹及多段多项式轨迹构成的样条轨迹。多项式样条轨迹很容易进行多阶微分来得到积分链上的状态；同时，多项式也更容易根据始始末约束进行曲线拟合。

对于本研究，根据式(2.7)的无人机动力学描述和微分平坦的性质，四旋翼无人机

中国知网 https://www.cnki.net

的推力和姿态会唯一确定最终的轨迹；而本研究 2.1.3 节也可以根据目标轨迹的多重微分来唯一确定推力和姿态的状态曲线。综上所述，本研究的轨迹使用多段高阶多项式样条轨迹来满足动力学约束。

由于现实的物理约束，四旋翼无人机的推力是无法瞬间改变的，同时根据根据式(2.4)，无人机的姿态是根据辛积分计算的，这意味其只能根据角速度逐步变化，不会产生突变，而四旋翼无人机的刚体运动中，角速度也是无法突变的。因此，为保证控制输入 $\dot{\boldsymbol{\omega}}$ 的连续性，轨迹需满足 4 阶导数连续（即 C^4 连续性）。

命题 2-4： 设 $\gamma(t) = \big(x(t), y(t), z(t)\big)$ 为三维空间中的 n 次多项式曲线, 则唯一确定该曲线需要 $3(n+1)$ 个独立的约束条件。

证明： 三维多项式曲线可分解为三个独立分量：

$$x(t) = \sum_{k=0}^{n} a_k t^k, \quad y(t) = \sum_{k=0}^{n} b_k t^k, \quad z(t) = \sum_{k=0}^{n} c_k t^k,$$

其中 a_k, b_k, c_k 为待定系数。每个分量包含 $n+1$ 个系数，因此总自由度为 $3(n+1)$。

每个约束条件（如特定点 t_i 处的函数值、一阶导数 $\gamma'(t_i)$、二阶导数 $\gamma''(t_i)$ 等）对应一个线性方程。例如：

$$x^{(m)}(t_i) = \frac{d^m x}{dt^m}\Big|_{t=t_i} = \sum_{k=m}^{n} \frac{k!}{(k-m)!} a_k t_i^{k-m},$$

$$y^{(m)}(t_i) = \sum_{k=m}^{n} \frac{k!}{(k-m)!} b_k t_i^{k-m}, \quad \text{同理对 } z(t) \text{ 成立.}$$

当约束条件分布于不同点或涉及不同阶导数时, 可保证方程组的独立性。当提供 $3(n+1)$ 个独立约束时，对应的线性方程组系数矩阵满秩，从而保证存在唯一解 (a_k, b_k, c_k)。因此，唯一确定曲线需恰好 $3(n+1)$ 个约束。命题证毕。 □

由于多项式函数天然无限可导，因此必定满足 4 阶导数连续。同时，无人机的轨迹规划过程中含有下面的无人机的始末点状态：

$$\boldsymbol{P}^{\text{start}} = (\boldsymbol{P}_x^{\text{start}}, \dot{\boldsymbol{p}}_x^{\text{start}}, \ddot{\boldsymbol{P}}_x^{\text{start}}, \boldsymbol{P}_y^{\text{start}}, \dot{\boldsymbol{P}}_y^{\text{start}}, \ddot{\boldsymbol{P}}_y^{\text{start}}, \boldsymbol{P}_z^{\text{start}}, \dot{\boldsymbol{P}}_z^{\text{start}}, \ddot{\boldsymbol{P}}_z^{\text{start}}) \tag{2.36}$$

$$\boldsymbol{P}^{\text{end}} = (\boldsymbol{P}^{\text{end}}, \dot{\boldsymbol{P}}^{\text{end}}, \ddot{\boldsymbol{P}}^{\text{end}}, \boldsymbol{P}^{\text{end}}, \dot{\boldsymbol{P}}^{\text{end}}, \ddot{\boldsymbol{P}}^{\text{end}}, \boldsymbol{P}^{\text{end}}, \dot{\boldsymbol{P}}^{\text{end}}, \ddot{\boldsymbol{P}}^{\text{end}}) \tag{2.37}$$

式中 $\boldsymbol{P}^{\text{start}}$ 为开始位置的状态信息，包括 x、y、z 轴的开始位置状态 $\boldsymbol{P}_x^{\text{start}}$、$\boldsymbol{P}_y^{\text{start}}$、$\boldsymbol{P}_z^{\text{start}}$ 以及其导数；$\boldsymbol{P}^{\text{end}}$ 为结束位置的状态信息，包括 x、y、z 轴的结束位置状态 $\boldsymbol{P}_x^{\text{end}}$、$\boldsymbol{P}_y^{\text{end}}$、$\boldsymbol{P}_z^{\text{end}}$ 以及其导数

上述的 18 个状态将作为约束条件，不难得到此时的多项式轨迹次数为 5。此外，为

中国知网　https://www.cnki.net

了更好地躲避动态障碍物，需要在始末两点之间添加一些位置状态进行避障，综上所述，本研究使用的高阶多项式轨迹的形式为：

$$\gamma(t) = \left(\sum_{k=0}^{n} a_k t^k \quad \sum_{k=0}^{n} b_k t^k \quad \sum_{k=0}^{n} c_k t^k \right), \quad \text{with } n \geq 5 \tag{2.38}$$

subject to:

$$\left| \gamma''(t) - \begin{bmatrix} 0 & 0 & g \end{bmatrix}^{\mathsf{T}} \right| \leq a_{\text{limit}} \qquad \left| \gamma^{(4)}(t) \right| \leq \tau_{\text{limit}} \tag{2.39}$$

式中，a_k、a_k、a_k 分别表示多项式在 x、y、z 轴上的多项式参数；n 表示多项式阶数；g 表示重力加速度；T_{limit} 表示四旋翼无人机的旋翼最大加速度；τ_{limit} 表示四旋翼无人机的最大角加速度。

2.2.3 基于动力学模型的轨迹可达性证明

相较于现有常用的多项式轨迹，上述的轨迹约束为了在复杂环境下大角度机动，将姿态约束进行了省略，但这可能造成轨迹不可行，因此下面将严格证明所设计的高阶多项式轨迹在动力学模型(2.7)下可进行求解并全局可达。

命题 2-5 （高阶多项式的全局可达性）： 对任意满足 C^4 连续性的轨迹 $\gamma(t) \in C^4([t_0, t_f], \mathbb{R}^3)$，若其满足推力约束：

$$\|\ddot{\gamma}(t) + g\boldsymbol{e}_z\| \leq \frac{T_{\max}}{M_{\text{drone}}}, \quad \forall t \in [t_0, t_f] \tag{2.40}$$

则存在连续的控制输入 $(T(t), \boldsymbol{\omega}(t))$ 使得无人机精确跟踪该轨迹。

证明： 证明分为三步：

1. 微分平坦性保证控制律存在性

根据 2.1.2 节定义的微分平坦输出 $\boldsymbol{z}_q = (x, y, z, \zeta)$，由命题 2.1 可知：对任意 $\gamma(t) = (x(t), y(t), z(t))$，存在唯一的平坦输出扩展：

$$\zeta(t) = \sin\frac{\psi(t)}{2} = \frac{\boldsymbol{q}_\psi(t)_4}{\sqrt{1 - \boldsymbol{q}_\psi(t)_1^2}} \tag{2.41}$$

通过式(2.19)-(2.23)可计算期望姿态 $\boldsymbol{q}_{\text{des}}(t)$ 与推力 $T(t)$：

$$T(t) = M_{\text{drone}}\|\ddot{\gamma}(t) + g\boldsymbol{e}_z\| \tag{2.42}$$

$$\boldsymbol{q}_{\text{des}}(t) = R_q^{-1}\left(\frac{\ddot{\gamma}(t) + g\boldsymbol{e}_z}{T(t)/M_{\text{drone}}} \right) \tag{2.43}$$

2. 四元数参数化消除奇异性

传统欧拉角参数化在俯仰角 $\theta \to \pm\pi/2$ 时存在万向锁问题。而本研究采用的四元数

中国知网 https://www.cnki.net

分解：

$$\boldsymbol{q} = \boldsymbol{q}_{\text{tilt}} \otimes \boldsymbol{q}_{\psi} \tag{2.44}$$

通过约束 $\boldsymbol{q}_{\text{tilt}} \in \mathbb{S}^3_{\text{tilt}}$（定义 2.1），确保：倾斜分量 $\boldsymbol{q}_{\text{tilt}}$ 始终位于无奇点子流形，同时偏航角 ψ 通过 $\zeta \in [-1, 1]$ 实现全局参数化因此，即使在大角度机动（如 $\phi > \pi/2$）时，姿态空间仍保持良好定义。

3. 高阶多项式保证控制输入连续性

对于 $n \geq 9$ 次多项式轨迹 $\gamma(t)$，其四阶导数 $\gamma^{(4)}(t)$ 连续。根据角速度动力学：

$$\boldsymbol{\omega}(t) = 2\boldsymbol{q}^{-1} \otimes \dot{\boldsymbol{q}} \tag{2.45}$$

姿态四元数 $\boldsymbol{q}(t)$ 的二阶可导性（由 $\gamma(t) \in C^4$ 保证）意味着 $\boldsymbol{\omega}(t) \in C^2$，进而推力变化率 $\dot{T}(t)$ 有界。因此控制输入 $(T(t), \boldsymbol{\omega}(t))$ 满足实际执行器动态约束。

综上，在满足式(2.40)的条件下，存在连续控制律实现轨迹精确跟踪。命题证毕。 □

推论 2-1 （无障碍物场景下高次多项式曲线的充分可达性）：当不考虑障碍物约束时，对任意初始状态 $\boldsymbol{P}^{\text{start}}$ 和目标状态 $\boldsymbol{P}^{\text{end}}$，存在 9 次多项式轨迹 $\gamma(t)$ 满足：

$$\gamma(t_0) = \boldsymbol{P}^{\text{start}}, \quad \gamma(t_f) = \boldsymbol{P}^{\text{end}}, \quad \gamma^{(k)}(t_0) = \boldsymbol{P}^{\text{start},k}, \quad \gamma^{(k)}(t_f) = \boldsymbol{P}^{\text{end},k} \quad (k = 1, 2) \tag{2.46}$$

且该轨迹可通过定理 4.1 所述控制律实现。

2.3 强化学习问题建模

基于前文对无人机动力学模型和轨迹规划形式化描述，本研究的强化学习问题可构造为分层马尔可夫决策过程（Hierarchical Markov Decision Process, HMDP）。根据分层强化学习（Hierarchical Reinforcement Learning, HRL）框架，将四旋翼无人机轨迹规划与控制分解为两层独立决策模块：轨迹规划层（高层）与控制器层（底层）。本节将分别定义两层的 MDP 核心要素。

2.3.1 控制器的强化学习 MDP 模型构造

控制器层的状态空间 $\boldsymbol{S}_c$ 包含历史-当前-未来轨迹序列信息及无人机实时状态：

$$\mathbf{s}_c^t = \left[\mathbf{p}_{t-k:t}, \mathbf{v}_{t-k:t}, \mathbf{R}_{t-k:t}, \omega_{t-k:t}, \mathbf{p}_{ref}^{t:t+\Delta T}, \mathbf{v}_{ref}^{t:t+\Delta T}\right] \tag{2.47}$$

其中 $\mathbf{p}_{t-k:t}, \mathbf{v}_{t-k:t}$ 表示无人机在时间窗口 $[t-k, t]$ 内的位置与速度历史序列（k 为回溯步长，根据无人机惯性时间常数设定为 $k = 5$）；$\mathbf{R}_{t-k:t}, \omega_{t-k:t}$ 表示姿态矩阵与角速度序列，可依据无人机的微分平坦模型直接微分求解；$\mathbf{p}_{ref}^{t:t+\Delta T}, \mathbf{v}_{ref}^{t:t+\Delta T}$ 表示规划层提供的

中国知网　https://www.cnki.net

未来 ΔT 时间内的参考轨迹位置与速度序列（ΔT 与控制器频率匹配）。

控制器层的动作空间 $\mathcal{A}_c$ 定义为旋翼转速变化率序列：

$$\mathbf{a}_c^t = \left[\dot{\Omega}_1^{t:t+\delta t}, \dot{\Omega}_2^{t:t+\delta t}, \dot{\Omega}_3^{t:t+\delta t}, \dot{\Omega}_4^{t:t+\delta t}\right] \tag{2.48}$$

其中 $\dot{\Omega}_i$ 为第 i 个旋翼的转速导数，δt 为单步控制时长。该设计避免直接输出绝对转速值（易导致电机饱和），符合实际电调驱动特性。

控制器层奖励函数 r_c^t 需平衡跟踪精度与物理约束：

$$r_c^t = w_1 r_{track}^t + w_2 r_{smooth}^t + w_3 r_{penalty}^t + r_{success}^t \tag{2.49}$$

式中的 w_1、w_2、w_3 表示奖励的权重参数，而各个分量及其含义如下：

（1）跟踪误差奖励 r_{track}^t：采用窗口内归一化误差的指数衰减形式：

$$r_{track}^t = \exp\left(-\frac{1}{k+1}\sum_{\tau=t-k}^{t}\|\mathbf{p}_\tau - \mathbf{p}_{ref}^\tau\|_2\right) \tag{2.50}$$

（2）平滑性奖励 r_{smooth}^t：鼓励误差持续下降，定义滑动窗口平均误差的差分：

$$r_{smooth}^t = \tanh\left(\frac{1}{k}\sum_{\tau=t-k}^{t-1}\|\mathbf{e}_\tau\| - \frac{1}{k}\sum_{\tau=t-k+1}^{t}\|\mathbf{e}_\tau\|\right) \tag{2.51}$$

其中 $\mathbf{e}_\tau = \mathbf{p}_\tau - \mathbf{p}_{ref}^\tau$。

（3）物理约束惩罚 $r_{penalty}^t$：包含两项：

$$r_{penalty}^t = -\lambda_1 \sum_{i=1}^{4}\max(0, \Omega_i^t - \Omega_{max})^2 \quad \text{(超速惩罚)} \tag{2.52}$$

$$-\lambda_2 \sum_{i=1}^{4}\mathbb{I}_{\Omega_i^t<0} \quad \text{(反转惩罚)} \tag{2.53}$$

其中 Ω_{max} 由电机数据手册给出，$\mathbb{I}$ 为示性函数。

（4）在空时长奖励 $r_{success}^t$：当跟踪误差连续 N 步低于阈值 ϵ 时触发：

$$r_{success}^t = \begin{cases}\eta, & \text{if } \|\mathbf{e}_\tau\|_2 < \epsilon, \forall\tau \in [t-N+1, t] \\ 0, & \text{otherwise}\end{cases} \tag{2.54}$$

该奖励项解决稀疏奖励问题，N 需大于无人机动态响应时间（实验取 $N = 10$）。

2.3.2 规划算法的强化学习 MDP 模型构造

规划层的状态空间 $\mathcal{S}_p$ 需编码全局环境信息与任务约束：

$$\mathbf{s}_p^t = \left[\mathcal{O}_t, \mathcal{C}_t^{sfc}, \mathbf{q}_{start}, \mathbf{q}_{goal}, E_{budget}, T_{budget}, \mathbf{x}_t^{UAV}\right] \tag{2.55}$$

中国知网 https://www.cnki.net

其中 $\mathcal{O}_t$ 表示动态障碍物的空间概率密度场，通过 SLAM 算法对点云中的非已知部分进行切分得到，本研究主要讨论无人机的规划控制问题，不进一步探讨相关技术；C_t^{sfc} 为安全飞行走廊（Safe Flight Corridor, SFC）约束，包含当前时段 t 和下一时段 $t+1$ 的凸多面体描述：

$$C_t^{sfc} = \{\mathbf{p} \in \mathbb{R}^3 | \mathbf{A}_t \mathbf{p} \leq \mathbf{b}_t\} \tag{2.56}$$

其生成方法参考文献[45] 的快速凸分解算法；E_{budget}, T_{budget} 表示任务允许的最大能耗与时间预算，根据电池容量和任务紧急程度设定；$\mathbf{x}_t^{UAV} = [\mathbf{p}_t, \mathbf{v}_t, \mathbf{a}_t, \psi_t]$ 表示无人机当前状态（位置、速度、加速度、偏航角）。

规划层动作空间 $\mathcal{A}_p$ 定义为三个必经的航路点：

$$\mathbf{a}_p^t = [\mathbf{w}_1^{t+\Delta_1}, \mathbf{w}_2^{t+\Delta_2}, \mathbf{w}_3^{t+\Delta_3}] \tag{2.57}$$

其中 Δ_i 为相对于当前时刻的采样时间间隔（$\Delta_1 < \Delta_2 < \Delta_3$），$\mathbf{w}_1, \mathbf{w}_2$ 中仅包含位置坐标 (x, y, z)；而 $\mathbf{w}_3$ 包含位置、速度、加速度 $(x, y, z, v_x, v_y, v_z, a_x, a_y, a_z)$。

该设计使得高次多项式轨迹的可通过拉格朗日或牛顿插值快速求解，具体轨迹生成公式为：

$$\mathbf{p}(t) = \sum_{i=0}^{5} \mathbf{c}_i t^i \quad \text{s.t.} \quad \mathbf{p}(t_j) = \mathbf{w}_j,\ j = 1, 2, 3 \tag{2.58}$$

系数 $\mathbf{c}_i$ 通过插值算法求得，保证轨迹连续性。需要注意，根据命题 (2-4)，当轨迹包含 4 个点，其中 2 个点为全状态，另外 2 个点包含位置信息时，则轨迹存在 24 条约束，满足要求的轨迹为 7 阶多项式，天然满足 C^4 连续性（位置、速度、加速度、姿态、角速度连续），无需额外通过奖励项对轨迹的平滑性进行约束。

规划层奖励函数 r_p^t 需综合安全性、可行性与效率：

$$r_p^t = \alpha_1 r_{feas}^t + \alpha_2 r_{safe}^t + \alpha_3 r_{collision}^t + \alpha_4 r_{efficiency}^t + \alpha_5 r_{velocity}^t \tag{2.59}$$

各分量定义如下：

（1）轨迹可行性奖励 r_{feas}^t：评估生成轨迹是否可被控制器跟踪。通过预训练的专家网络 $\mathcal{N}_{expert}$（见第 3 章）预测跟踪误差：

$$r_{feas}^t = -\frac{1}{L} \sum_{i=1}^{L} \| \mathcal{N}_{expert}(\mathbf{p}_{ref}^i) - \mathbf{p}_{ref}^i \|_2 \tag{2.60}$$

其中 L 为预测步长，$\mathbf{p}_{ref}^i$ 为插值轨迹点。

中国知网　https://www.cnki.net

（2）SFC 安全奖励 r^t_{safe}：惩罚轨迹点脱离安全走廊：

$$r^t_{safe} = -\sum_{i=1}^{3} \mathbb{I}_{\mathbf{w}_i \notin C_t^{sfc} \cup C_{t+1}^{sfc}} \tag{2.61}$$

（3）碰撞概率惩罚 $r^t_{collision}$：积分轨迹经过区域的障碍物概率密度：

$$r^t_{collision} = -\int_{\mathbf{p}(t)}^{\mathbf{p}(t+\Delta T)} \mathcal{O}_t(x, y, z)\, d\mathbf{p} \tag{2.62}$$

数值实现采用蒙特卡洛路径采样近似。

（4）能效奖励 $r^t_{efficiency}$：对比实际能耗与预算：

$$r^t_{efficiency} = \exp\left(-\left|\frac{E_{pred}}{T_{pred}} - \frac{E_{budget}}{T_{budget}}\right|\right) \tag{2.63}$$

其中 E_{pred}, T_{pred} 为预测总能耗与时间，由动力学模型仿真得到。

（5）速度一致性奖励 $r^t_{velocity}$：确保局部速度与全局平均速度匹配：

$$r^t_{velocity} = -\left|\frac{\|\mathbf{v}_t\|}{\|\mathbf{v}_{global}\|} - 1\right|, \quad \mathbf{v}_{global} = \frac{\mathbf{q}_{goal} - \mathbf{q}_{start}}{T_{budget}} \tag{2.64}$$

由于安全走廊 C_t^{sfc} 为凸集且无内部障碍，轨迹任意两点间直线距离不大于实际路径长度，故局部速度与全局速度的偏差可通过凸性约束上界估计，避免奖励函数设计冲突。

2.4 本章小结

本章建立了四旋翼无人机轨迹规划与控制的完整数学模型框架，为后续分层强化学习算法设计奠定基础。具体内容包括：

1. 基于牛顿-欧拉方程介绍了无人机的刚体动力学方程，建立了无人机动力学模型，为后续控制器的强化学习模型设计提供了便利；

2. 基于轨迹规划的基本概念，介绍了无人机规划过程中存在的能耗-耗时帕累托最优边界，为第三章的专家网络设计提供了基础；

3. 基于无人机的动力学特征，引入了多项式样条轨迹，并证明了轨迹通过动力学进行无人机姿态求解时的可达性，为后续轨迹层强化学习模型的设计提供了依据；

4. 构建双层马尔可夫决策过程，给出了模型的基本要素和强化学习需要解决的问题。

本章建立的模型为后续章节的展开提供了基础，下一章节将详细介绍如何对本章节的模型进行实现，并对相关规划和控制问题进行求解。

中国知网 https://www.cnki.net

第三章　分层元强化学习框架设计

针对第二章提出的无人机分层强化学习建模的实现，本章节基于分层强化学习算法进行了一系列改进。为了改善规划层的探索性能和多模态的适应能力，本章节提出了基于多专家算法的 SAC 轨迹规划方法；为了提高控制器在不同环境、不同物理参数四旋翼无人机上的适应能力，本章节提出了基于元强化学习的四旋翼无人机跟踪控制算法；为了使无人机动态选择能耗和耗时，提高轨迹的灵活性，本章节提出了一种能耗-耗时帕累托边界的估计算法和动态时间分配算法；此外，本章节还提出了分层强化学习的层间反馈机制，用以增强上层网络对下层网络的感知力。本章将分四个小节，详细介绍研究中算法的具体构建、运行机制和模型结构。

3.1 整体系统架构概览

3.1.1 分层强化学习算法和层间反馈设计

本研究的工程应用目标是在复杂环境中完成自主无人机的轨迹规划和探索任务，现有的无人机的规划控制工程应用存在一些困难和挑战。首先，无人机的控制效果受到未建模的参数影响，想要在各类工况中保持一致性存在挑战；其次，无人机的规划和控制算法往往是分层解耦的，规划算法对下层控制算法的感知能力有限，无法根据控制器性能实时调整规划；最后，无人机的规划算法往往无法做到最佳的能耗表现，而针对能耗的规划方案也存在搜索范围有限的问题。

表 3-1 规控架构对比分析

Table 3-1 Comparative Analysis of Guidance and Control Architectures

对比维度	分层强化学习	端到端模型	传统控制器
学习效率	高	低	无
资源占用	中等	高	低
可解释性	高	低	高
迁移与重用性	高	低	高

针对上述前两点挑战，使用强化学习的无模型学习算法既可以更好地进行无人机控制，也可以根据控制器的预期效果进行规划调整。如表3-1所示，带有学习的算法可以使得规划控制功能获得性能和迁移性上的提高，相较于传统方法具有显著的优势。然

中国知网　https://www.cnki.net

而无人机在实际运行时算力有限，传统的深度强化学习模型在使用过程中必然会受到性能限制，此外在传统深度强化学习模型的训练过程中，很容易因为策略搜索空间复杂度过高而导致最终算法效果不佳，而分层强化学习的架构通过划分功能降低了搜索难度，降低了实际工程应用的算力需求，因此针对无人机规划控制问题选择分层强化学习算法是符合实际工程要求的。

针对无人机规划过程中能耗优化存在的困难，本研究设计了一种基于深度神经网络的能耗-耗时帕累托边界估计方法，配合动态规划算法，可以快速为无人机求解指定能耗下的时间分配方案，同时可以根据能耗情况实时进行时间分配调整。

此外，为了减少层间传递导致的误差，本研究提出了跨层进行反馈的机制，增加规划层对控制效果的掌握程度，从而为模型训练过程提供帮助。综上所述，本研究的算法架构算法整体框架如图3-1所示。

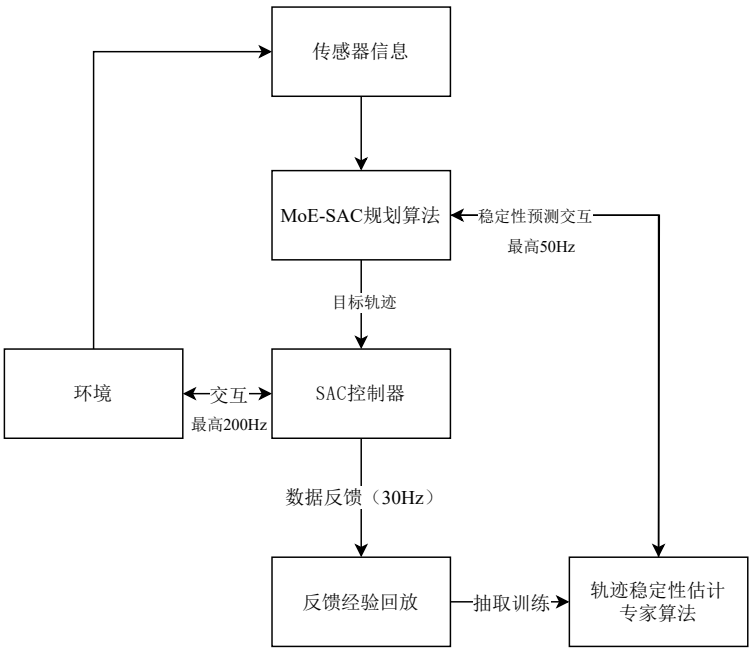


图 3-1 本研究提出算法的整体框架

Figure 3-1 The integrated framework of the proposed algorithm is presented in this study

首先，无人机通过传感器、SLAM 算法、路径规划和飞行走廊生成，得到无人机规划控制需要的基础输入数据；然后规划层的基于多专家的 SAC 规划算法（简称 MoE-SAC 算法）会将数据分类传输向各个专家网络，统筹考虑控制器反馈信号、规划问题

中国知网 https://www.cnki.net

约束、无人机动力学模型约束和能耗-耗时预测的时间分配约束，并配合 SAC 算法进行轨迹点规划，然后规划层利用插值算法在线性时间复杂度下求解出符合动力学要求的四旋翼无人机轨迹。规划层的计算开销较高，同时对计算频率的要求往往没有控制器严格，因此其规划频率设定在 10 至 50Hz；控制器层利用四旋翼无人机动力学模型进行推力和姿态曲线求解，然后采用 SAC 算法搜索无人机在实际物理环境中的最佳动作，完成推力和姿态的跟踪控制，控制层的控制输出频率较高，通常需要 50 至 200Hz 的控制频率，该频率需根据传感器回报频率进行调整。控制过程中，运动控制误差和控制器的稳定性指标将作为控制器度量指标反馈向规划层的控制稳定性专家数据池。

针对前述的系统整体架构，本章的 3.2 节将介绍控制器反馈信号的发送、接收；3.3 节将介绍规划层的大部分专家网络结构、SAC 深度模型设计；3.4 节将单独介绍介绍能耗-耗时预测算法和动态规划算法的相关细节，其作为 SAC 规划算法的专家算法参与到整个规划过程中；3.5 节将介绍控制层 SAC 算法的深度模型设计和一阶 MAML 算法的设计。

3.1.2 元学习算法

此外，在第二章系统建模阶段，本研究已经指出无人机在实际应用中存在大量未纳入建模的参数，诸如海拔高度、电机特性、电池放电能力变化、场地的风扰等等，这些时变和空间参数会影响控制器实际控制效果。为了解决这一挑战，本研究提出使用元学习方法进行跟踪控制算法模型预训练，再依据实际环境特征在线对模型进行小幅快速迭代。在本章的 3.5 节，将详细介绍控制器训练过程中的元学习算法设计。

3.2 层间反馈机制设计

传统分层式架构中，规划层与控制层间的开环协作模式存在误差累积效应。本研究提出图3-1所示的层间反馈机制来进行闭环优化，其方法执行存在三个阶段：

（1）性能量化评估；

（2）数据收集和汇入经验池；

（3）专家网络学习训练。

本节将介绍前两个阶段的技术细节，第三阶段的专家网络在规划算法设计中将独立介绍。

中国知网　https://www.cnki.net

3.2.1 控制器性能量化评估

控制器通常要保证控制效果的稳定、快速和准确，控制器的性能量化指标需要体现这些设计目标。判断无人机的控制器的稳定性通常使用李雅普诺夫稳定性指标来表示，考虑无人机动力学模型的非线性特性，首先构建包含位置误差 e_p 与速度误差 e_v 的复合能量函数：

$$V(e_t) = \frac{1}{2} e_p^\top K_p e_p + \frac{1}{2} e_v^\top K_v e_v \tag{3.1}$$

其中 $K_p \in \mathbb{R}^{3\times3}$ 和 $K_v \in \mathbb{R}^{3\times3}$ 分别为位置与速度误差的加权矩阵，其对角元素表征各自由度上的控制增益。对 $V(e_t)$ 求导可得：

$$\dot{V}(e_t) = e_p^\top K_p e_v + e_v^\top K_v (u_t - g) \tag{3.2}$$

式中 $g \in \mathbb{R}^3$ 为重力加速度向量，u_t 为控制输入。当 $\dot{V} < -\epsilon$（$\epsilon > 0$ 为预设阈值）时满足渐进稳定性条件。

当控制器不稳定时，存在发散的过程，这个过程需要在滑动时间窗口进行判断，为量化时间窗口的稳定特性，定义滑动窗口稳定性指标：

$$R_{stable} = \frac{1}{k} \sum_{i=0}^{k-1} \mathbb{I}(\dot{V}_{t-i} < -\epsilon) \tag{3.3}$$

该指标通过统计窗口期 $[t-k+1, t]$ 内满足稳定性条件的样本比例，反映控制系统的动态稳定性演变趋势。

除了稳定性，无人机控制器的跟踪误差指标也是非常重要的综合性能指标，反映了控制器的准确性。在稳定性保障基础上，需同步评估轨迹跟踪精度。定义复合跟踪误差度量：

$$e_{track} = \sqrt{\frac{1}{N} \sum_{i=1}^{N} \| w_i^{ref} - w_i^{actual} \|^2 + \lambda \max_i \| w_i^{ref} - w_i^{actual} \|} \tag{3.4}$$

式中第一项 $\frac{1}{N} \sum \| w_i^{ref} - w_i^{actual} \|^2$ 表征均方根误差 (RMSE)，反映整体跟踪精度；第二项 $\max \| w_i^{ref} - w_i^{actual} \|$ 捕捉最大瞬时偏差，用于识别突发扰动下的控制失效风险。超参数 $\lambda \in [0, 1]$ 调节两项指标的权重平衡，该参数需经过经网格搜索确定最优值。

3.2.1.1 多指标正则化处理 稳定率 R_{stable} 与跟踪误差 e_{track} 具有不同量纲和数值范围，加法或简单运算会造成优化过程偏置。为此研究引入了动态加权评分机制：

$$\Psi_t = \alpha_t R_{stable} - (1 - \alpha_t) e_{track}, \quad \alpha_t = \sigma(W_\alpha \xi_{t-k:t}) \tag{3.5}$$

中国知网 https://www.cnki.net

其中 $\sigma(\cdot)$ 为 Sigmoid 函数，$W_\alpha \in \mathbb{R}^{2k}$ 为可学习权重向量，b_α 为偏置项，$\xi_{t-k:t} \in \mathbb{R}^{2k}$ 为过去 k 步的标准化指标拼接向量。该处理通过 $\alpha_t \in (0,1)$ 将两指标映射到同一数量级，同时 W_α 可以学习历史窗口 $[t-k,t]$ 内指标变化的权重分配模式。

权重向量 W_α 的训练采用交替方向优化：当更新策略网络时固定 W_α，更新 W_α 时则冻结策略网络参数。优化目标函数为：

$$\mathcal{L}_{W_\alpha} = \mathbb{E}_t[-\Psi_t] + \lambda \|W_\alpha\|_2^2 \tag{3.6}$$

其中 λ 为正则化系数，抑制历史观测中的噪声干扰；$\mathbb{E}_t[-\Psi_t]$ 表示当前评分的期望值，这里使用有限时域内评分的平均值来代替。

3.2.2 反馈信息的收集

无人机在飞行过程中会采集多维时序数据 $\xi_t = (s_t^{\text{imu}}, a_t^{\text{ctrl}}, e_t^{\text{track}})$，其中 s_t^{imu} 为无人机的目标飞行状态，a_t^{ctrl} 为控制指令，e_t^{track} 为轨迹跟踪误差。研究设计了数据的 FIFO 数据缓冲区：

$$\mathcal{B}_t = \{\xi_i | t-K < i \le t\} \tag{3.7}$$

其中的 $\mathcal{B}_t$ 是数据缓冲区，其收集并容纳最近的 K 组采样数据。当这些数据计划发送时，会构造出一组数据序列：

$$B_t = \{\xi_i | i = t-K, t-K+1, \ldots, t\} \tag{3.8}$$

其中的 B_t 是待发送数据，其包括最近的 K 组采样数据，数据构造为一组经验数据并汇入控制稳定性专家经验池，用于轨迹规划算法中轨迹稳定性专家网络的训练。

时序数据 B_t 具有显著的时间相关性与非平稳分布特性，直接随机抽取经验池数据会导致专家经验池样本分布偏差，为此使用双层经验池结构：

$$\mathcal{D}_{\text{ctr}ctr} = \{\mathcal{D}_{stable}, \mathcal{D}_{unstable}\}, \quad \text{where} \begin{cases} \mathcal{D}_{stable} = \{B_t | R_{stable} \ge \gamma_{th}\} \\ \mathcal{D}_{unstable} = \{B_t | R_{stable} < \gamma_{th}\} \end{cases} \tag{3.9}$$

其中 γ_{th} 为稳定性阈值，筛选出前 35% 的稳定性评分；R_{stable} 为稳定性评分，其计算了序列 B_t 内李雅普诺夫导数为负定的序列内元素个数。

训练时，从专家经验池采样需按照概率进行分层抽样：

$$B_t \sim \mathcal{D}_{\text{ctr}ctr} \Rightarrow B_t = \begin{cases} \text{从}\mathcal{D}_{stable}\text{按时间逆序采样}, & p = 0.3 \\ \text{从}\mathcal{D}_{unstable}\text{均匀采样}, & p = 0.7 \end{cases} \tag{3.10}$$

该策略保留时间局部性特征的同时，保证了不稳定样本的利用率。

中国知网　https://www.cnki.net

3.3 基于多专家算法的 SAC 轨迹规划方法

传统的深度强化学习方法在处理多维度约束时存在局限性，其单一策略网络难以处理建模动力学稳定性、安全走廊与能耗优化等多模态信息；部分强化学习算法会使用硬约束，其导致策略探索效率低下；此外普通 AC 框架缺乏熵最大化机制，探索能力较差易陷入局部最优。针对无人机轨迹规划中复杂的障碍所带来的飞行走廊约束、动态障碍物规避、电池续航有限带来的飞行时间和能耗约束以及控制器误差、干扰等复杂条件，本节提出一种多专家算法的改进型 SAC 方法（简称 MoE-SAC）。该算法通过构建多个专家深度神经网络，实现传感器数据、环境约束和运动目标多模态数据处理，可提高 SAC 算法在处理轨迹规划问题时的整体效率。

3.3.1 MoE-SAC 规划算法的架构概述

传统 SAC 算法采用单一网络处理多维状态，难以有效提取各模态特征的深层关联，往往存在模型潜力不足、因奖励冲突导致训练不稳定以及性能需求过高的问题。本研究的处理思路基于选取架构各异的专家网络和相应的优化算法，对不同特征的数据进行有效推理。算法的架构设计如图3-2所示。

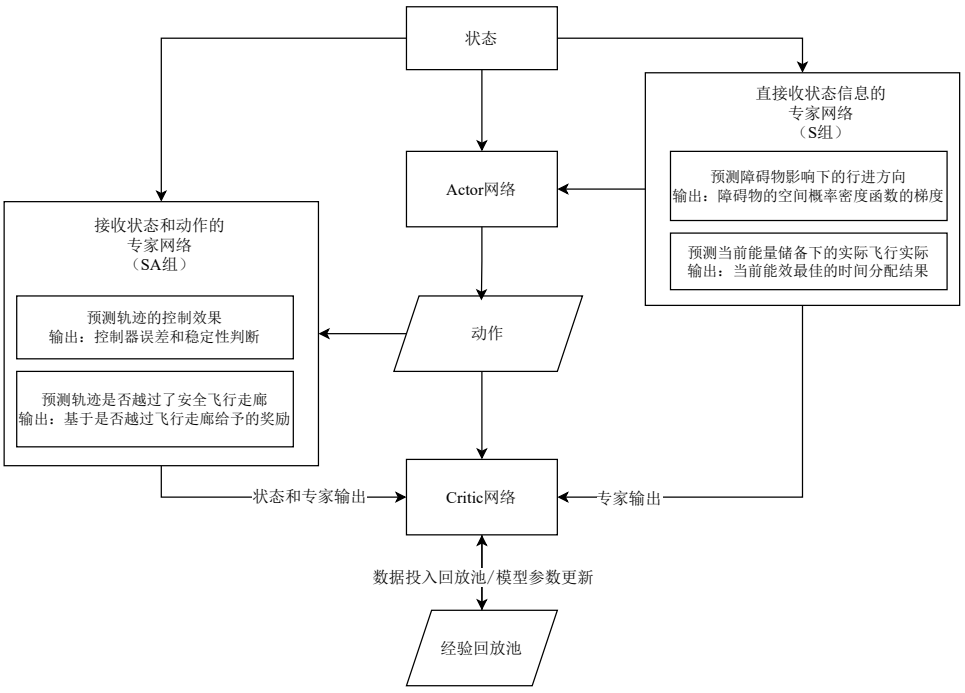


图 3-2 基于混合专家的 SAC 规划算法架构

Figure 3-2 The SAC planning algorithm architecture based on Mixture of Experts (MoE)

中国知网 https://www.cnki.net

规划算法的整体架构包含了专家模型集合、Critic 网络和 Actor 网络。在运行过程中，专家网络根据是否需要决策作为输入分为 S 组和 SA 组。S 组内的网络由：当无人机根据上一步决策完成环境互动，得到状态 s_t 后，S 组专家网络将输出针对当前状态 s 的评价；Actor 网络将采纳这一组专家网络的结果，并根据状态 s_t 得到决策结果 a_t；SA 组专家网络将基于状态 s_t 和决策 a_t 输出评价；上述的所有专家网络评价通过设置动态的门控权重编码，然后和状态 s_t 和决策 a_t 通过注意力机制 Critic 网络得到输出价值期望。得到奖励 r_t 和新状态 s_t 之后将数据放入经验回放池：

$$\mathcal{D} = \{(s_t, a_t, r_t, s_t') | t \in \mathbb{N}_0\} \tag{3.11}$$

式中 $\mathcal{D}$ 为经验回放池，(s_t, a_t, r_t, s_t') 为回放经验池的元素，包含了回放过程中需要的数据。在训练过程中，则通过从经验回放池中取出数据进行训练。值得注意的是，算法中的神经网络训练按照首先训练稳定性估计网络，然后训练其他专家网络，最后固定专家网络训练 SAC 算法的顺序进行，在本文第四章将会对训练顺序进行详细说明。

本研究提出将 MoE 模块集成到 SAC 框架中，将专家的平均结论通过动态权重进行输出，根据第二章式(2.59)中对规划层强化学习奖励的定义，可以计算专家算法计算的各类数据的奖励：

$$r_t^{\text{expert}}(s_t, a_t) = w_1 r_{feas} + w_2 r_{safe} + w_3 r_{collision} + w_4 r_{efficiency} + w_5 r_{velocity} \tag{3.12}$$

其中 $w_i = g_i(s, a_{\text{raw}})$ 表示门控网络对第 i 个专家的激活权重；r_{feas} 表示飞行轨迹可行性奖励，由轨迹稳定性估计专家算法进行计算；r_{safe} 表示飞行走廊安全性奖励，由飞行走廊可行性专家算法进行计算；$r_{collision}$ 表示飞行碰撞惩罚，基于概率密度梯度的避障专家算法进行计算；$r_{efficiency}$ 表示对比实际能耗与预算的奖励，由能耗预测与时间分配优化专家算法计算后计算得到；$r_{velocity}$ 表示局部速度与全局平均速度匹配奖励，由能耗预测与时间分配优化专家算法计算后计算得到；$r_t^{\text{expert}}(s_t, a_t)$ 为对专家算法对当前状态和动作的奖励计算结果。专家算法协助 Critic 网络完成了大量传感器数据的解析工作和奖励预测计算工作，减小了价值网络的训练难度。

在完成上述奖励后，需将状态、Actor 网络输出的动作一起作为一组数据保存至经验回放池。

除专家网络之外，规划期的 SAC 算法还包含 Actor 网络和 Critic 网络。模型的参数如表3-2所示。

中国知网　https://www.cnki.net

表 3-2 MoE-SAC 规划算法的超参数设置

Table 3-2 Comparative Analysis of Guidance and Control Architectures

参数	值	说明
Actor 学习率	3e-4	使用 Adam 优化器
Critic 学习率	规划：1e-3，约束：1e-4	使用 Adam 优化器
折扣因子 η	0.99	无
目标网络更新率	5e-3	软更新保持稳定性
自动熵调整	True	初始 α=0.2
每轮训练数据条数	400	无

Actor 和 Critic 网络的结构细节如图3-3所示。

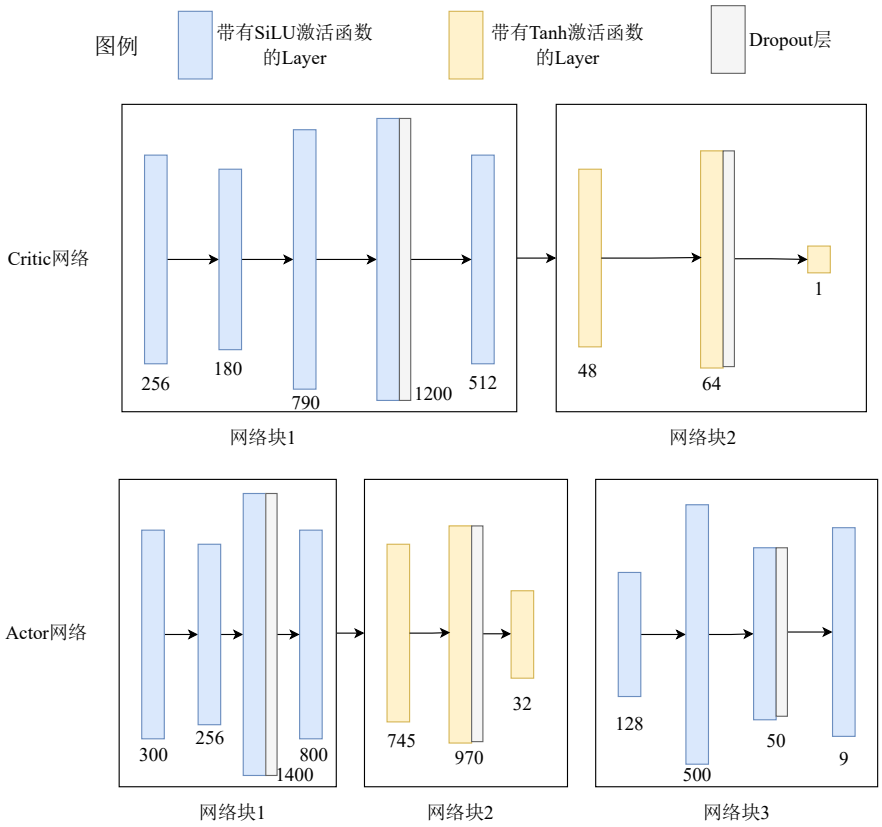


图 3-3 Actor 和 Critic 网络的架构

Figure 3-3 The SAC planning algorithm architecture based on Mixture of Experts (MoE)

Actor 网络即策略网络，通过多层线性层进行组合而成，将当前无人机的状态、经

中国知网 https://www.cnki.net

过专家算法处理的传感器数据和时间分配结果作为输入，最终得到轨迹的约束点作为动作，本研究使用 3 个网络块组成该网络，通过多层线性网络组成每个网络块；Critic 网络将状态和动作作为输入，预测和环境如此交互可以获得的奖励，使用了 2 个网络块构成了模型的主体。

算法训练过程中的总损失函数由三部分构成：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{critic}} + \mathcal{L}_{\text{actor}} + \mathcal{L}_{\text{entropy}} \tag{3.13}$$

对于价值网络，采用双 Q 学习降低过估计：

$$\mathcal{L}_{\text{critic}} = \mathbb{E}_{(s,a,r,s')\sim\mathcal{D}}\left[(Q_{\text{sac}} - r_{\text{target}})^2\right] \tag{3.14}$$

其中 r_{target} 表示规划轨迹的奖励，计算方式为：

$$r_{\text{target}} = r_{\text{expert}} + \gamma(\min_{i=1,2} Q_{\text{sac},i}(s', \tilde{a}')) \tag{3.15}$$

策略网络的损失表示为：

$$\mathcal{L}_{\text{actor}} = \mathbb{E}_{s\sim\mathcal{D}}\left[\alpha \log \pi(a|s) - Q_{\text{sac}}(s,a) + \beta\|\Delta a\|^2\right] \tag{3.16}$$

为了保证探索能力，算法引入了自适应温度系数调节，其损失表示为：

$$\mathcal{L}_{\text{entropy}} = \alpha\left(\bar{\mathcal{H}} - \mathbb{E}[\mathcal{H}(\pi)]\right) \tag{3.17}$$

综上所述，本研究对构建了基于 MoE 算法的 SAC 轨迹规划方法。MoE 模块提供可验证的轨迹安全修正，同时建立了两个独立的价值网络进行估计。这些方法使得无人机规划算法可以通过多模态数据进行准确规划，提升了规划算法的安全性、准确性。接下来本章节将对算法中的专家进行详细设计和介绍。

3.3.2 轨迹稳定性评估专家设计

针对无人机轨迹的稳定性判定问题，本文设计了基于长短期记忆网络（Long Short-Term Memory，LSTM）的评估网络。

算法使用轨迹序列作为输入，让 Actor 生成的未来 N 步控制指令：

$$\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, ..., \mathbf{x}_T]^\top \in \mathbb{R}^{T\times 10} \tag{3.18}$$

其中单步数据 $\mathbf{x}_t$ 包含：

$$\mathbf{x}_t = [\underbrace{x, y, z, q_z}_{\text{微分平坦状态}}, \underbrace{v_x, v_y, v_z}_{\text{速度}}] \tag{3.19}$$

中国知网　https://www.cnki.net

根据 3.2 节对反馈信号的设计，网络需要输出控制结果的预期，包括平均误差和李雅普诺夫稳定性的判据，根据上述两个参数的特点，网络需要执行平均误差的回归任务和李雅普诺夫的分类任务，其中分类任务的定义为：

$$\mathcal{L}_{\text{stab}} = \begin{cases} 1, & \text{若} \dot{V}(\mathbf{e}_t) \leq -\gamma \|\mathbf{e}_t\|^2 \ (\forall t) \\ 0, & \text{否则} \end{cases} \tag{3.20}$$

最终形成的算法架构如图3-4所示。

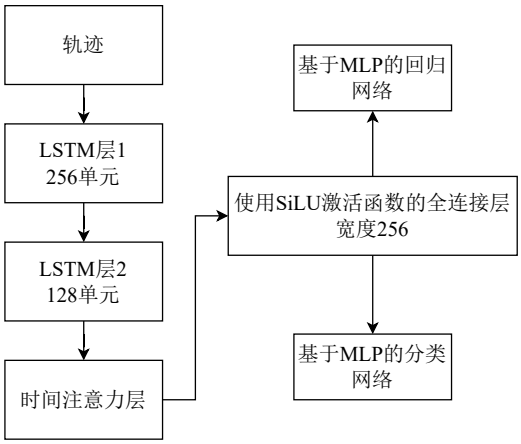


图 3-4 轨迹稳定性评估专家算法架构

Figure 3-4 The SAC planning algorithm architecture based on Mixture of Experts (MoE)

如图3-4所示，为了能够准确估计，轨迹稳定性预测算法使用了 LSTM 和注意力机制进行优化。具体而言，双层 LSTM 的第 k 层 LSTM 的标准隐藏状态更新过程为：

$$\mathbf{f}_t^{(k)} = \sigma(\mathbf{W}_f^{(k)}[\mathbf{h}_{t-1}^{(k)}, \mathbf{x}_t^{(k)}] + \mathbf{b}_f^{(k)}) \tag{3.21}$$

$$\mathbf{i}_t^{(k)} = \sigma(\mathbf{W}_i^{(k)}[\mathbf{h}_{t-1}^{(k)}, \mathbf{x}_t^{(k)}] + \mathbf{b}_i^{(k)}) \tag{3.22}$$

$$\mathbf{o}_t^{(k)} = \sigma(\mathbf{W}_o^{(k)}[\mathbf{h}_{t-1}^{(k)}, \mathbf{x}_t^{(k)}] + \mathbf{b}_o^{(k)}) \tag{3.23}$$

$$\tilde{\mathbf{c}}_t^{(k)} = \tanh(\mathbf{W}_c^{(k)}[\mathbf{h}_{t-1}^{(k)}, \mathbf{x}_t^{(k)}] + \mathbf{b}_c^{(k)}) \tag{3.24}$$

$$\mathbf{c}_t^{(k)} = \mathbf{f}_t^{(k)} \odot \mathbf{c}_{t-1}^{(k)} + \mathbf{i}_t^{(k)} \odot \tilde{\mathbf{c}}_t^{(k)} \tag{3.25}$$

$$\mathbf{h}_t^{(k)} = \mathbf{o}_t^{(k)} \odot \tanh(\mathbf{c}_t^{(k)}) \tag{3.26}$$

其中 σ 为 sigmoid 函数，$\odot$ 为 Hadamard 积。

而注意力机制的计算过程分为两步，首先计算各时间步权重：

$$\alpha_t = \frac{\exp(\mathbf{v}^\top \tanh(\mathbf{W}_h \mathbf{h}_t^{(2)} + \mathbf{b}_h))}{\sum_{t'=1}^{T} \exp(\mathbf{v}^\top \tanh(\mathbf{W}_h \mathbf{h}_{t'}^{(2)} + \mathbf{b}_h))} \tag{3.27}$$

中国知网 https://www.cnki.net

然后计算上下文向量：

$$\mathbf{c} = \sum_{t=1}^{T} \alpha_t \mathbf{h}_t^{(2)} \tag{3.28}$$

模型的损失函数定义为复合损失，这样可以处理上述的两个任务：

$$\mathcal{L} = \lambda_1 \mathcal{L}_{\text{MSE}} + \lambda_2 \mathcal{L}_{\text{BCE}} + \lambda_3 \mathcal{L}_{\text{Lyap}} \tag{3.29}$$

式中的 λ_1、λ_2、λ_3 表示损失的权重，损失函数分为三个分量，在统计窗口宽度为 n，这三个分量可以表示为：

1. 回归损失，包含控制器误差的回归计算损失：

$$\mathcal{L}_{\text{MSE}} = \frac{1}{n} \sum_{i=1}^{n} (\bar{e}_i - \hat{\bar{e}}_i)^2 \tag{3.30}$$

2. 分类损失，用于处理李雅普诺夫稳定性判断损失：

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{n} \sum_{i=1}^{n} [y_i \log p_i + (1 - y_i) \log(1 - p_i)] \tag{3.31}$$

3. 李雅普诺夫正则项：

$$\mathcal{L}_{\text{Lyap}} = \frac{1}{n} \sum_{i=1}^{n} \max\left(0, \dot{V}_i + \gamma \|\mathbf{e}_i\|^2\right) \tag{3.32}$$

其中 $\dot{V}$ 由下式给出：

$$\dot{V}(\mathbf{e}_t) = \mathbf{e}_t^{\top} \mathbf{P} (\mathbf{p}_{\text{desired},t} - f_{\text{dyn}}(\mathbf{p}_{\text{real},t}, \mathbf{u}_t)) \tag{3.33}$$

$\mathbf{P}$ 为正定矩阵，f_{dyn} 为无人机动力学模型。

该网络的迭代过程需要使用专用的经验回放池 $\mathcal{D}_{\text{ctr}ctr}$，其迭代过程依然遵守神经网络的基本规则。

3.3.3 飞行走廊规划专家设计

为了对轨迹是否违反安全飞行走廊的约束进行检查，本研究设计了一套基于深度神经网络的飞行走廊轨迹合法性预测网络，其通过计算每个面约束和轨迹参数，实时进行检测。网络通过离线学习大量轨迹和凸包的关系，建立轨迹参数到安全指标的映射关系，其神经网络的结构设计如图3-5所示。每次预测时，网络接受一组约束面参数和轨迹参数，并对是否越过约束面进行判定，在得到预测结果后，该约束的奖励通过交叉熵进行获取。相较于传统几何检测方法，本设计通过神经网络进行快速判定，其通过数据驱动自动学习复杂走廊形状的隐式约束的能力为能量-能耗预测网络打下了基础。

中国知网　https://www.cnki.net

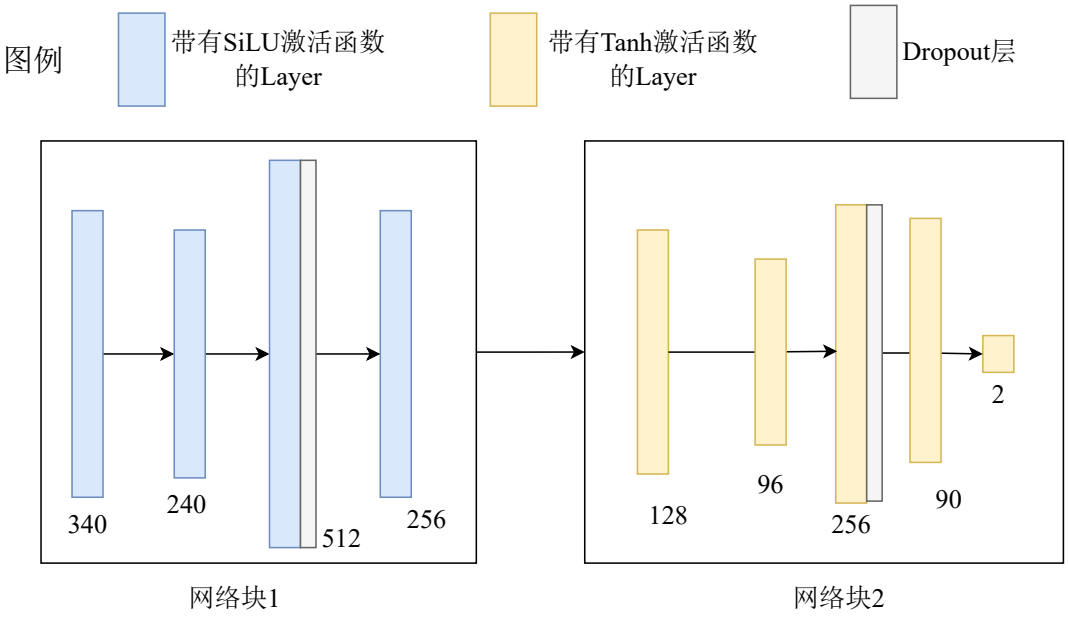


图 3-5 飞行走廊规划专家模型架构

Figure 3-5 Expert Model Architecture for Flight Corridor Planning

该网络在训练过程中，将多项式参数、约束面和约束面周围临近的面作为输入传入网络，网络限制约束面数量上限为 35 片，而数据集的标签为布尔值，表示是否出现多项式违规的情形，由于这话问题本质是分类问题，因此网络设置最终输出的是 1*2 的矩阵。

3.3.4 概率密度梯度场避障专家算法

设障碍物在三维空间中的概率密度分布函数为 $p(\mathbf{x})：\mathbb{R}^3 \to \mathbb{R}^+$，其中 $\mathbf{x} = (x, y, z)$ 表示无人机当前位置。避障专家算法通过实时计算该密度场的负梯度方向生成导航建议：

$$\mathbf{v}_{adv} = -\nabla p(\mathbf{x}) = -\left(\frac{\partial p}{\partial x}, \frac{\partial p}{\partial y}, \frac{\partial p}{\partial z}\right) \tag{3.34}$$

式中 $\mathbf{v}_{adv} \in \mathbb{R}^3$ 表示建议避障方向向量。该向量的物理意义为：无人机应当沿概率密度下降最快的方向运动，从而远离障碍物聚集区域。

该算法不涉及神经网络，单次梯度求解仅需 6 次密度查询和 3 次减法运算，消耗的算力极低；同时通过向规划层传递建议的梯度方向，减小了碰撞概率。

中国知网 https://www.cnki.net

3.4 创新方法：能耗预测与时间分配优化专家设计

在当前的轨迹规划研究领域，已经存在类似 MINCO 轨迹类的成熟方案。MINCO 轨迹类是一类使用高阶多项式轨迹的轨迹生成方案，其主要优势在于低能耗。但是其软约束的权重并不能自适应挑战，容易因时间分配不合理导致控制器跟踪状态不佳。

本研究将 MINCO 轨迹类及其优化方法作为基准算法进行开发，提出了基于神经网络进行能量预，然后进行时间优化分配的方法。主要贡献在于：1. 使得规划阶段的时间分配更为合理，并且可以通过能量剩余情况动态分配，相较于现有算法更为灵活；2. 通过合理的时间分结果，算法加快了轨迹的优化收敛速度。

3.4.1 带有能量约束的轨迹规划问题构造

在求解式(2.35)时，算法需要在可行域中寻找到能量消耗不大于 E_r 且消耗时间最少的可行解。结合图2-2(b)不难发现，若存在耗时为 t^* 的最快轨迹 $u^*(t)$，则，这条轨迹具有所有可行解中最多的能量消耗，即 E_r：

$$E(u^*(t)) = E_r \tag{3.35}$$

因此，速度更快的轨迹会消耗超过能量约束 E_r 的能量，这意味着通过构造最小能量消耗的优化问题也可以接近最优解：

$$\begin{aligned} \min \quad & E(u(t)) \\ \text{s.t.} \quad & u(t) \in \mathcal{R}(G, p_s, p_f) \\ & T(u(t)) < t^* \end{aligned} \tag{3.36}$$

式中，$u(t)$ 表示轨迹集合 $\mathcal{R}(G, p_s, p_f)$ 内的可行轨迹；$T(u(t))$ 表示轨迹 $u(t)$ 的运行时间。

式(3.36)的最优解和式(2.35)是一致的，其搜索区域也变为了图2-2(b)中的区域 ①。MINCO 轨迹类的优化问题可以表述为：

$$\begin{aligned} \min \quad & E(u(t)) + \rho T(u(t)) \\ \text{s.t.} \quad & u(t) \in \mathcal{R}(G, p_s, p_f) \end{aligned} \tag{3.37}$$

式中，ρ 为飞行轨迹耗时的软约束权重。其他符号的含义和式(3.36)相同。基于 MINCO 轨迹类的优化方法可以在构造之后对问题(3.36)进行优化。

然而，求解式(3.36)仍然面临一些挑战，首先，的 t^* 是一个未知的量，因此该优化问题只有计算出图2-2(a) 中帕累托最优边界在能量消耗为 E_r 时的时间消耗 t^*，才能顺利进行优化求解；同时，规划算法的时间分配策略存在不足，t^* 是无人机在飞行时通

中国知网　https://www.cnki.net

过多个飞行走廊后的时间总和，无法体现飞行走廊之间的时间消耗关系，优化算法若只重视耗时总和，往往容易陷入局部最优解。针对这些问题，可以将式(2.35)中的优化问题分段，从而得到下面的优化问题：

$$\begin{aligned} \min \quad & \sum_{i=1}^{m} T(u_i(t)) \\ \text{s.t.} \quad & u(t) = \left\{u_i(t)\right\}, u(t) \in \mathcal{R}(G, p_s, p_f) \\ & u_i(t) \in \mathcal{R}(G_i, p_{s,i}, p_{f,i}) \\ & \sum_{i=1}^{m} (E(u_i(t))) < E_r \\ & i = 1, 2, \ldots, m; m \in \mathbb{N}^+ \end{aligned} \tag{3.38}$$

式中，m 表示当前飞行任务的安全飞行走廊个数；$u_i(t)$ 表示第 i 个飞行走廊内的控制序列；$\mathcal{R}(G_i, p_{s,i}, p_{f,i})$ 表示在第 i 个飞行走廊内的约束 G_i 和条件 $p_{s,i}$、$p_{f,i}$ 的可行解的集合；$T(u_i(t))$ 表示序列 $u_i(t)$ 的运行时长。该优化问题在式(2.35)的基础上将序列进行分段，添加了数个冗余的约束。显然，式(3.38)是一个组合问题，通过搜索可以得到每个飞行走廊之间的时间关系和最短时间，考虑到了时间分配，可以解决式(3.36)中存在的问题。

为了求解式(3.38)，需要计算每个飞行走廊中能量消耗和时间的关系。本方法引入了深度神经网络，通过学习大量的数据样本，有效地识别轨迹规划过程中能量消耗与时间分配之间的内在关系，这种方法不仅显著降低了计算成本，还提高了求解的效率和精度。

$$\begin{aligned} Net(G, p_s, p_f) &= \left\{Opt_1, Opt_2, \ldots, Opt_{segs}\right\} \\ Opt_i &\ni \left\{f_{opt,i} : Opt_{e,i} \leftrightarrow Opt_{t,i}\right\} \\ i &= 1, 2, \ldots, \text{segs}; \quad \text{segs} \in \mathbb{N}^+ \end{aligned} \tag{3.39}$$

式中，$Net(G, p_s, p_f)$ 表示神经网络的运算函数；G 表示飞行任务的约束；p_s 表示飞行任务的初始状态；p_f 表示飞行任务的结束状态；$segs$ 表示神经网络预测的可行解数目；Opt_i 表示网络预测的帕累托最优边界上第 i 个可行解，其包含了一组双映射关系 $f_{opt,i}$，即可行解的能量消耗 $Opt_{e,i}$ 和可行解的任务耗时 $Opt_{t,i}$。对于拥有约束 G 和条件 p_s、p_f 的飞行任务，在将能量消耗 $Opt_{e,i}$ 或任务耗时 $Opt_{t,i}$ 作为约束时，都可以利用双映射关系得到预估对应的任务耗时和能量消耗。

使用神经网络对每片飞行走廊进行估计，即可通过插值等方法估计无人机消耗能

中国知网 https://www.cnki.net

量为 E_{ep} 时的最短飞行时间 t_{ep}：

$$t_{ep} \approx \sum_{i=0}^{s_{acu}} c_i E_{ep}^i \tag{3.40}$$

式中，s_{acu} 表示插值阶数；c_i 表示多项式系数。在对每个飞行走廊进行上述估计，并求解式(3.38)进行求解，之后，我们得到：

$$t^* = \sum_{i=1}^{m} t_i \tag{3.41}$$

式中，t^* 表示帕累托最优边界上能量消耗为 E_r 时的最小时间消耗；m 表示规划问题的飞行走廊个数；t_i 表示第 i 个飞行走廊的时间分配目标。由此即可得到 t^* 和每个飞行走廊的时间分配目标结果。据此我们可以基于式(3.36)构造下面的优化问题：

$$\begin{aligned} \min \quad & \begin{cases} E(u(t)) + Q(u(t)) & \text{if } T(u(t)) < t^* \\ E(u(t)) & \text{if } T(u(t)) \geq t^* \end{cases} \\ \text{s.t.} \quad & u(t) \in \mathcal{R}(G, p_s, p_f) \end{aligned} \tag{3.42}$$

式中，$Q(u(t))$ 表示控制序列 $u(t)$ 在搜索域外时的附加代价，其计算方式为：

$$Q(u(t)) = \beta \sum_{i=1}^{m} \sum_{j=1}^{m} \left(\frac{t_j T_{\text{ep},i}}{t_i} - T_{\text{ep},j} \right)^2 \tag{3.43}$$

式中，m 表示当前规划问题的飞行走廊数目；t_i 表示第 i 个飞行走廊的时间消耗计算结果；$T_{\text{ep},i}$ 表示第 i 个飞行走廊的期望时间分配结果；β 是损失函数的权重参数。

通过对不处于式(3.36)优化区域内的可行解施加附加的时间分配代价 $D(u(t))$，可以在不影响原优化问题的条件下，进行时间分配，进而得到本文主要问题的解。

3.4.2 基于深度学习的能量消耗预测方法

为了实现前文的网络预测功能，本方法共设计了 3 组网络，其中 2 组网络分别进行运动学和空间约束的能量消耗估计，最后 1 组汇总前 2 组网络的预测输出，得到最终的预测结果。其计算式写为：

$$Net(G, p_s, p_f) = \left\{ Net_{\text{mix}}(L(t)) \leftrightarrow t | t \in T \right\} \tag{3.44}$$

$$L(t) = \begin{bmatrix} Net_{\text{kn}}(p_s, p_f, t) \\ Net_{\text{p}}(G, p_s, p_f, t) \end{bmatrix} \tag{3.45}$$

上式中，$Net(G, p_s, p_f)$ 表示整个能量消耗预测网络，在已知约束 G、无人机的开始状态 p_s 和结束状态 p_f 时可以计算进行轨迹规划时，能量消耗和时间消耗的关系；T 表示飞行任务可能的时间消耗集合，t 表示集合 T 中的元素；$L(t)$ 表示能量消耗组合向量，向量中的元素分别表示运动学和空间约束的能量消耗预测，其中 Net_{kn} 为运动学预测网络，预测了无人机运动的动力学能量消耗，Net_{p} 为空间约束预测网络，预测了

中国知网　https://www.cnki.net

飞行走廊对无人机运行增加的能量消耗；Net_{mix} 为混合网络，将 $L(t)$ 作为输入，综合考虑无人机飞行过程中运动学和飞行走廊带来的能量消耗总和。能量消耗预测网络的架构如下图3-6所示：

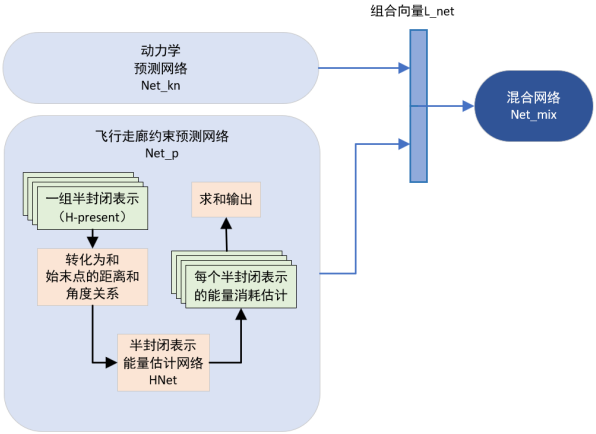


图 3-6 能耗估计深度网络框架

Figure 3-6 Energy Consumption Estimation Deep Neural Network Framework

图3-7所示的网络中，运动学预测网络 Net_{kn} 将无人机的开始状态 p_s、结束状态 p_f 和期望的运行时间 t 构造为宽度为 9 的矩阵并作为网络输入，网络输出为预测的能量消耗。图3-8 展示了这一网络的详细结构。

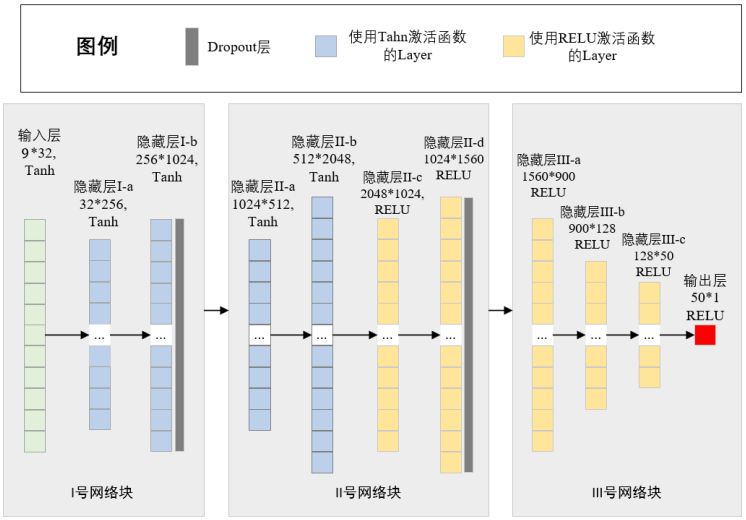


图 3-7 运动学预测网络框架

Figure 3-7 The Kinematic Prediction Network Framework

中国知网 https://www.cnki.net

在图3-7所示的运动学预测网络中，共使用了 3 个网络块，其中 I 号网络块进行特征提取工作，II 号网络块进行简单预测，II 号块网络进行复杂预测。在 I 号网络块中共计有 3 层具有 Tanh 激活函数的隐藏层和 1 层 DropOut 层；在 II 号网络块中，共计有 2 层使用 Tanh 激活函数的隐藏层和 2 层使用 RELU 激活函数的隐藏层，并在 II 号网络块最后添加了 1 层 DropOut 层；在 III 号网络块中 3 层使用 RELU 激活函数的隐藏层完成最后的能量预测任务。同时，通过下式可以对运动学预测网络进行损失计算：

$$Loss_{kn} = \mathrm{Hu}(\ln(E_{real}), Net_{\mathrm{kn}}(p_s, p_f, t)) \tag{3.46}$$

式中，$Loss_{kn}$ 表示动力学预测网络的损失函数值；Hu() 为 Huber 函数的简写，是一种常用的损失函数形式；E_{real} 表示实际求解的能量消耗，由图2-2(a)可知无人机的能量消耗和时间消耗的曲线并不是一条直线，选择对数函数对实际结果进行预处理可以使网络的数据集分布均匀、网络准确率更好。

此外，图3-6中的空间约束预测网络 Net_{p} 对飞行走廊的信息进行了处理。

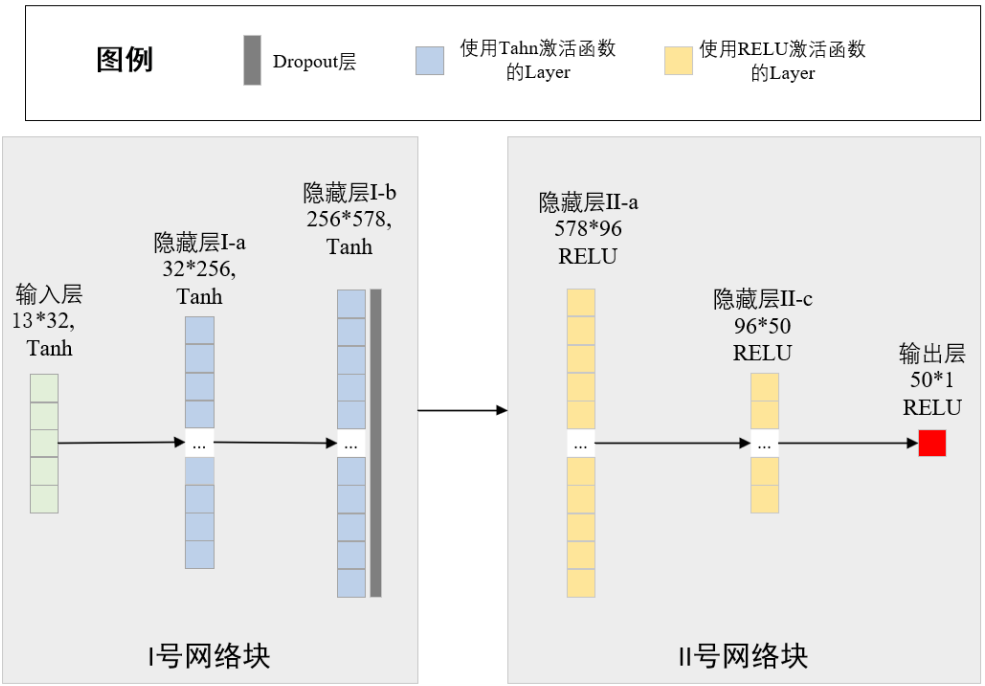


图 3-8 面约束预测网络

Figure 3-8 The Surface-Constrained Prediction Network Architecture

空间约束预测网络将无人机的开始状态 p_s、结束状态 p_f、运行的时间约束 t_n、飞行走廊的几何信息 p 和预计的飞行时间 t 作为输入，网络输出为几何约束附加的能量

中国知网　https://www.cnki.net

消耗。因为飞行走廊的几何信息通常使用的是半空间表示方法，通过数个平面约束来表示一个多边形凸包，是一个宽度随凸包面数变化的矩阵，输入到网络存在困难，所以本方法首先计算每个面附带的能量消耗预测，然后再进行求和，预测一个完整凸包对飞行任务附加的能量消耗。因此空间约束预测网络 $Net_{\mathrm{p}}(G_i, p_s, p_f)$ 的计算式表示为：

$$Net_{\mathrm{p}}(G_i, p_s, p_f, t) = \sum_{j=1}^{n_{\mathrm{p}}} Net_H \left(\begin{bmatrix} \mathrm{prep}(H_{i,j}, p_s, p_f) \\ p_s \\ p_f \\ t \end{bmatrix} \right) \tag{3.47}$$

上式中，G_i 表示第 i 个飞行走廊的约束，其存在 n_{p} 个面；网络 Net_H 称为面约束预测网络，用于估计 p_i 的面 $H_{i,j}$ 对能量消耗的影响，由于需要约束面的角度和距离信息，因此函数 $\mathrm{prep}(H_{i,j}, p_s, p_f)$ 将数据转为宽度为 13 的向量。

图3-9展示了面约束预测网络的结构，网络使用了 2 个网络块，在 I 号网络块中共计有 3 层具有 Tanh 激活函数的隐藏层和 1 层用于正则化的 DropOut 层。在 II 号网络块中，共计有 3 层使用 RELU 激活函数的隐藏层。

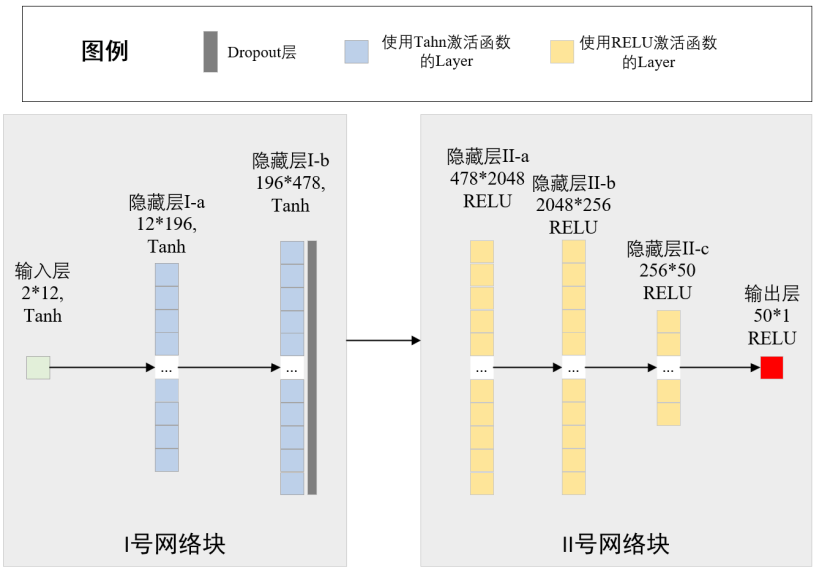


图 3-9 能耗混合网络框架

Figure 3-9 The Energy Consumption Hybrid Network Framework

飞行走廊一般通过多个平面进行描述，本方法通过预处理将这些平面和运动的开始和结束点进行了关联，并将关联结果作为网络输入。这一转化关系的过程，可通过

中国知网 https://www.cnki.net

函数 prep$(H_{i,j}, p_s, p_f)$ 表达为:

$$\text{prep}(H_{i,j}, p_s, p_f) = \begin{bmatrix} \frac{h_{i,j} \cdot \dot{p_s}}{|h_{i,j}||\dot{p_s}|} \\ \frac{h_{i,j} \cdot \dot{p_f}}{|h_{i,j}||\dot{p_f}|} \\ \frac{h_{i,j} \cdot \dot{p_s} + H_{i,j,4}}{|H_{i,j}|} \\ \frac{h_{i,j} \cdot \dot{p_f} + H_{i,j,4}}{|H_{i,j}|} \\ t \end{bmatrix} \tag{3.48}$$

$$h_{i,j} = \begin{bmatrix} H_{i,j,1} & H_{i,j,2} & H_{i,j,3} \end{bmatrix} \tag{3.49}$$

上式中，$H_{i,j}$ 表示第 i 个飞行走廊的第 j 片平面约束；$H_{i,j,k}$ 表示第 i 个飞行走廊的第 j 片平面约束中，第 k 个元素的数值；函数 prep$(H_{i,j}, p_s, p_f)$ 的第一、二个元素分别计算了开始和结束运动位置点的速度和平面法线的夹角，第三、四个元素计算了开始和结束运动的位置点和平面的距离，最后一个元素是预期的运动时间。

在网络的训练过程中，我们通过下面的损失函数对网络的准确性进行评估，考虑到数据集里的大量数据都是较小且精度高，因此使用对数函数对数据进行了变换：

$$Loss_p = \text{Hu}(\log_{10}(E_{real}), Net_{\text{p}}(G, p_s, p_f, t)) \tag{3.50}$$

在完成上述的飞行走廊约束预测网络和运动学预测网络的求解之后，我们可以得到两个网络预测的运动学能量消耗和空间中飞行走廊约束附加的能量消耗，将两个 1*1 的预测结果组合为一个 2*1 的向量，即可形成形如式(3.45)中的混合网络输入向量，同时混合网络的如图 5 所示，混合网络框架使用了 2 个网络块。在 I 号网络块中共计有 2 层具有 Tanh 激活函数的隐藏层和 1 层 DropOut 层；在 II 号网络块中，共计有 2 层使用 RELU 激活函数的隐藏层。上述的三组网络按照图3-6进行组合之后，可以共同完成相应的能量预测任务。

在训练过程中，混合网络通过下面的损失函数评估准确性：

$$\begin{aligned} Loss_{\text{mix}} = \text{Hu}\Big(& \log_{10}(E_{\text{real}}), \\ & \text{Net}_{\text{mix}}\left(\begin{bmatrix} \text{Net}_{\text{kn}}(p_s, p_f, t) \\ \text{Net}_{\text{p}}(G, p_s, p_f, t) \end{bmatrix}\right)\Big) \end{aligned} \tag{3.51}$$

由此，通过神经网络即可预测轨迹规划任务中，无人机能量消耗和时间消耗之间的关系。

中国知网　https://www.cnki.net

3.4.3 基于动态规划的时间分配优化

通过深度神经网络对无人机的能量消耗和时间消耗进行估计之后，研究使用动态规划对式(3.38)进行求解。

对于式(3.38)中的优化问题，定义函数 $D(\mathrm{p}, \mathrm{Part})$，此函数表示在能量上限为 E_r 时，无人机花费占比为 $\frac{Part}{N}$ 的能量，穿越飞行走廊 p_i 所花费的最小时间、最小累计时间和最小累计时间对应的能量大小，即：

$$D(\mathrm{p}_i, \mathrm{Part}) = \begin{pmatrix} T^{\mathrm{sum}}_{i,Part} \\ T_{i,Part} \\ E^{\mathrm{seg}}_{i,Part} \end{pmatrix}, i = 1, 2, \ldots, n_{\mathrm{p}} \tag{3.52}$$

式中 N 表示能量被均匀切分的份数在实际应用中，N 值的选择需要综合考虑飞行任务的复杂度、计算资源和精度要求等因素；$T^{\mathrm{sum}}_{i,Part}$ 表示从飞行走廊 i 花费占能量上限 $\frac{Part}{N}$ 的能量时，最短的总时间消耗，$T_{i,Part}$ 表示当前第 i 个飞行走廊的分配时间，而 $E^{\mathrm{seg}}_{i,Part}$ 表示这个最优时间分配方案中当前第 i 个飞行走廊的能量消耗。很显然，通过函数 D 的结果会以迭代的形式记录所有可行解，因此可以对式(3.38)中的组合问题进行求解，同时这种迭代的结构也可以进行回溯。

通过二维动态规划的思想，很容易发现函数 $D(\mathrm{p}_i, j)$ 可以通过下面的形式进行推导：

$$F_{\mathrm{bk}} = F_e^{-1}(\mathrm{p}_i, p_{s,i}, p_{f,i}, \frac{E_r k}{N}) \tag{3.53}$$

$$D(\mathrm{p}_i, j) = \begin{pmatrix} D_1(\mathrm{p}_{i+1}, k) + F_{\mathrm{bk}} \\ F_{\mathrm{bk}} \\ \frac{E_r k}{N} \end{pmatrix} \tag{3.54}$$

$$D(\mathrm{p}_m, j) = \begin{pmatrix} F_e^{-1}(\mathrm{p}_m, p_{f-1}, p_f, \frac{E_r k}{N}) \\ F_e^{-1}(\mathrm{p}_m, p_{f-1}, p_f, \frac{E_r k}{N}) \\ \frac{E_r k}{N} \end{pmatrix} \tag{3.55}$$

式中，F_{bk} 表示在飞行走廊 $\mathrm{p}i$ 中，从初始状态 ps, i 到结束状态 $p_{f,i}$，当花费的能量为 $\frac{E_r k}{N}$ 时，控制序列花费的最小时间对应的当前飞行走廊时间分配结果；N 表示能量被切分的份数；D_j 表示函数 D 计算结果的第 j 个元素；i 表示凸包序列，范围为：$i = 1, 2, \ldots, m-1$；m 是规划问题中的飞行走廊个数；k 表示能量消耗占总能量的百分比数，可以通过下面的方式进行求解：

$$k = \arg \min_{h=j}^{f} D_1(\mathrm{p}_{i+1}, h) \tag{3.56}$$

上式(3.55)中的函数 $F_e^{-1}(\mathrm{p}_i, p_{s,i}, p_{f,i}, \frac{E_r k}{N})$ 是一个插值函数，用于计算飞行走廊 p_i

中国知网 https://www.cnki.net

中，从初始状态 $p_{s,i}$ 到结束状态 $p_{s,i}$，当花费的能量为 $\frac{E_r k}{N}$ 时，控制序列花费的最小时间。基于前文的神经网络的计算和插值计算，可以较为容易地得到这个函数值的结果。

在使用式(3.55)对飞行过程中全部的可行解完成搜索之后，即可得到最优的时间分配结果。具体而言，当飞行器运行到 p_h 区域的开始位置，此时剩余的能量为 E_h，此时对于空间约束区域 p_h 最佳的飞行器时间分配方案为 $t_h = D(\mathrm{p}_h, \left\lfloor \frac{100E_h}{E_r} \right\rfloor)$，此时剩余能量变为 $E_h - F_e^{-1}(\mathrm{p}_h, E_h)$，如此继续对可行域 p_{h+1} 进行时间分配，即可获得最佳的时间分配策略，这个迭代过程可以表示为：

$$t_h = D_2(\mathrm{p}_h, \left\lfloor \frac{100E_h}{E_r} \right\rfloor) \tag{3.57}$$

$$E_h \leftarrow E_h - F_e^{-1}(\mathrm{p}_h, E_h) \tag{3.58}$$

$$h \leftarrow h + 1 \tag{3.59}$$

上式中，h 表示当前迭代所在的飞行走廊位置；t_h 表示每次迭代过程中，当前飞行走廊最优的时间分配结果；D_j 表示函数 D 计算结果的第 j 个元素。通过上述的迭代过程，即可计算最优的时间分配结果。基于 MINCO 轨迹类的优化方法，对式(3.42)求解，即可得到一条基于 E_r 能量的最大值约束条件下，速度最快的无人机运动轨迹曲线。其在能量消耗发生偏离或误差时，依然可通过式(3.57)至式(3.59)，在不重新搜索的前提下再次进行时间分配。

3.5 基于 SAC 算法的无人机控制器设计

针对四旋翼轨迹跟踪任务中存在的多模态状态空间（历史轨迹、实时姿态、未来参考轨迹）与高维连续动作空间（旋翼转速导数）耦合问题，传统 Actor-Critic（AC）框架存在策略探索不足与 Q 值过估计缺陷。本研究提出基于 Soft Actor-Critic（SAC）的控制器架构，该算法的优势在于使用最大熵策略优化，在标准 AC 框架中引入策略熵最大化目标，解决多模态状态空间下的探索-利用困境。其策略目标函数通常定义为：

$$J(\pi) = \sum_{t=0}^{T} \mathbb{E}_{(s_t,a_t)\sim\rho_\pi}[r(s_t, a_t) + \alpha\mathcal{H}(\pi(\cdot|s_t))] \tag{3.60}$$

其中 $\alpha > 0$ 为温度系数，$\mathcal{H}$ 表示策略熵，ρ_π 为状态-动作对的分布。相较于普通 AC 模型，该机制可提升策略在复杂状态空间中的鲁棒性。同时 SAC 算法默认使用双 Q 网络架构，解决了传统 AC 中 Q 值过估计问题，其采用的解耦的 Critic 网络结构，目标 Q

中国知网　https://www.cnki.net

值计算为：

$$Q_{target} = r + \gamma \min_{i=1,2} Q_{\theta_i'}(s', \tilde{a}') - \alpha \log \pi(\tilde{a}'|s') \tag{3.61}$$

其中 $\tilde{a}' \sim \pi(\cdot|s')$，$\gamma$ 为折扣因子，θ_i' 为目标网络参数。该设计可有效抑制 Q 值估计偏差的累积。

四旋翼无人机对转速连续性的要求与 SAC 基于高斯分布采样的动作输出机制天然匹配。相比于离散动作算法（如 DQN），避免了动作量化带来的控制精度损失；相较于 PPO，其重要性采样机制在样本效率上更具优势。此外根据式(2.49)中的奖励设计，其包含跟踪误差、平滑性、物理约束等多目标项。SAC 的双 Q 网络结构与自适应温度系数可动态平衡稀疏奖励与密集奖励的耦合关系，缓解多目标优化中的策略震荡问题。

最后，SAC 采用离线策略（off-policy）训练与在线轻量化推理相结合的模式，其 Actor 网络仅需单次前向传播即可生成动作。在第五章的实验中将说明其轻量化的模型能够实现 <5ms 的单步推理延迟，满足最高 200Hz 控制频率需求。本节将介绍本研究基于 SAC 算法的无人机控制器设计细节。

3.5.1 网络架构设计

本研究设计了如下图3-10所示的网络架构用以处理无人机的控制任务。

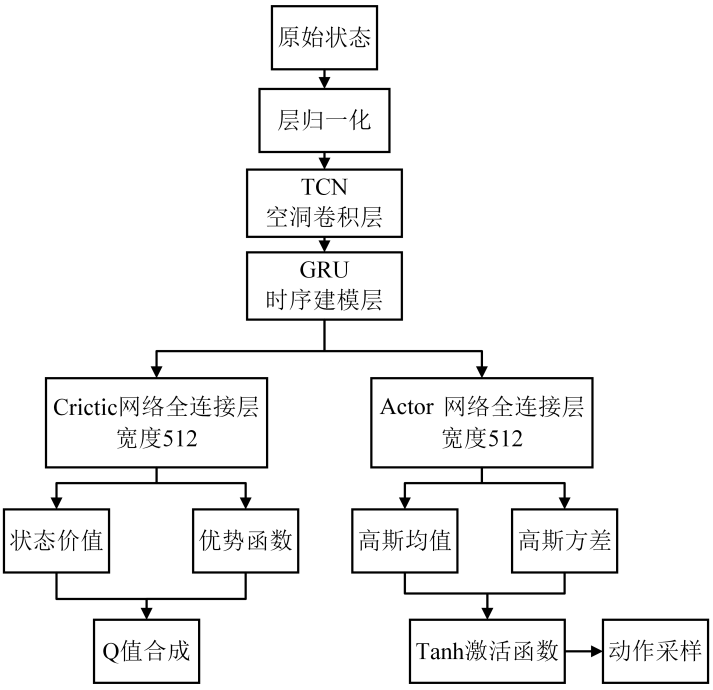


图 3-10 运动学预测网络框架

Figure 3-10 The Kinematic Prediction Network Framework

中国知网 https://www.cnki.net

本研究的控制器算法网络包含以下核心组件：

（1）时间卷积网络（TCN）：采用空洞因果卷积（dilated causal convolution），模型采用 4 层膨胀卷积（dilation factors=1,2,4,8），每层 64 个滤波器，卷积核大小 $k=3$，有效感受野覆盖历史窗口 $k=5$：

$$\mathbf{h}_{tcn} = \mathrm{ReLU}(\mathbf{W}_d *_d \mathbf{s}_c^{t-k:t} + \mathbf{b}_d) \tag{3.62}$$

其中 $*_d$ 表示膨胀率为 d 的卷积操作，$\mathbf{W}_d \in \mathbb{R}^{64\times 3}$ 为可学习参数。

（2）门控循环单元（GRU）：模型隐藏单元数 128，计算过程为：

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]) \tag{3.63}$$
$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]) \tag{3.64}$$
$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]) \tag{3.65}$$
$$\mathbf{h}_t = (1-\mathbf{z}_t)\odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \tag{3.66}$$

其中 $\odot$ 表示 Hadamard 积，$\mathbf{z}_t$ 和 $\mathbf{r}_t$ 分别为更新门与重置门。

（3）Actor 网络采用 3 层全连接（256-128-64），输出旋翼转速变化率的均值 $\mu \in \mathbb{R}^4$ 与对数标准差 $\log\sigma$，通过重参数化技巧采样动作。

$$\mathbf{a}_t = \tanh(\mu_t + \sigma_t \odot \epsilon), \quad \epsilon \sim \mathcal{N}(0, \mathbf{I}) \tag{3.67}$$

（4）Critic 网络采用双 Q 网络结构（Q1,Q2），各含 3 层全连接（256-128-64），输出状态-动作价值估计。

$$Q_\phi(\mathbf{s}_t, \mathbf{a}_t) = \mathbf{W}_q \cdot \mathrm{ReLU}(\mathbf{W}_2 \cdot \mathrm{ReLU}(\mathbf{W}_1 \cdot [\mathbf{h}_t, \mathbf{a}_t])) \tag{3.68}$$

表3-3展示了网络的参数配置细节。

表 3-3 网络超参数设置

Table 3-3 Network hyperparameterization

参数项	取值
TCN 空洞因子	[1,2,4,8,16]
GRU 隐藏单元数	128
全连接层维度	512
目标网络更新率 (τ)	0.005
初始温度系数 (α)	0.2

在网络执行推理任务时，输入数据首先进行正则化消除传感器量纲差异，然后采

中国知网　https://www.cnki.net

用时间卷积网络（TCN）捕获历史状态的长程依赖，使用 GRU 层建模时序动态特性，这些数据最终汇集到 Actor 和 Critic 网络的输入，并通过 MLP 网络计算实际的动作序列和动作对应的 Q 值。

3.5.2 损失函数设计与优化策略

SAC 算法的优化目标包含策略熵最大化与 Q 值误差最小化，其损失函数的构造和前文相同，这部不作赘述。

在计算 Q 函数损失时，采用 Clipped Double Q-learning 形式抑制过估计：

$$\mathcal{L}_Q(\phi_i) = \mathbb{E}_{(\mathbf{s}_t,\mathbf{a}_t,r_t,\mathbf{s}_{t+1})\sim\mathcal{D}}\left[\left(Q_\phi(\mathbf{s}_t,\mathbf{a}_t) - y_t\right)^2\right], \quad i = 1,2 \tag{3.69}$$

其中目标值 y_t 计算为：

$$y_t = r_t + \gamma\left(\min_{i=1,2} Q_{\phi_i'}(\mathbf{s}_{t+1},\tilde{\mathbf{a}}_{t+1}) - \alpha\log\pi_\theta(\tilde{\mathbf{a}}_{t+1}|\mathbf{s}_{t+1})\right) \tag{3.70}$$

$\tilde{\mathbf{a}}_{t+1}\sim\pi_\theta(\cdot|\mathbf{s}_{t+1})$，$\phi_i'$ 为目标网络参数。控制器的 SAC 算法同样使用自适应的温度系数条件，通过优化下式动态调节 α：

$$\mathcal{L}(\alpha) = \mathbb{E}_{\mathbf{s}_t\sim\mathcal{D}}\left[-\alpha\left(\log\pi_\theta(\mathbf{a}_t|\mathbf{s}_t) + \mathcal{H}_0\right)\right] \tag{3.71}$$

其中 $\mathcal{H}_0$ 为目标熵，设为动作维度（本实验 $\mathcal{H}_0 = -4$）。

相较于标准 AC 框架，通过策略熵最大化的正则化项，增强对多模态状态空间（历史轨迹序列、未来参考轨迹）的表征能力；同时双 Q 网络结构与目标网络延迟更新机制共同抑制价值函数过估计；此外控制器算法通过自适应温度系数实现探索强度与任务需求的动态平衡。

3.5.3 基于 MAML 算法的模型预训练

为了保证无人机在实物飞行阶段的训练质量，本研究引入了 MAML 算法。首先研究构建了如式(3.72)所示的，包含 9 个维度的动态参数空间 $\mathcal{P}$。这些参数将在模型训练过程中作为干扰项，增加模型的鲁棒性。

中国知网 https://www.cnki.net

$$p \sim \mathcal{P} = \begin{cases} d \in \{220, 250, 330, 350, 450\} \text{ (轴距/mm)} \\ k_m \sim \mathcal{U}[0.85, 1.15] \text{ (电机力矩系数)} \\ V_{bat} \sim \mathcal{U}[14.8, 25.2] \text{ (电池电压/V)} \\ C_d \sim \mathcal{U}[0.6, 1.2] \text{ (风阻系数)} \\ \Delta z \sim \mathcal{U}[-0.08, 0.08] \text{ (重心偏移/m)} \\ m \sim \mathcal{U}[0.8m_0, 1.2m_0] \text{ (质量变异)} \\ J \sim \mathcal{U}[0.9J_0, 1.1J_0] \text{ (惯性矩扰动)} \\ \tau \sim \mathcal{U}[0.02, 0.05] \text{ (电机响应延迟/s)} \\ \eta_p \sim \mathcal{U}[0.7, 1.0] \text{ (螺旋桨效率系数)} \end{cases} \tag{3.72}$$

式中的 m_0 和 J_0 为无人机标称质量与惯性矩。

由于在迭代过程中，MAML 会使用二阶导数，这会导致训练所需的步骤更加繁琐，算力需求也更高，因此本研究采用了一阶 MAML 算法进行元学习，其核心流程如算法3.1所示：

初始化元策略参数 θ

初始化元学习率 α, β

for $m = 1$ ***to*** M *(元迭代次数)* **do**

采样任务批次 $\{\mathcal{T}_i\} \sim p(\mathcal{T})$

foreach 任务 $\mathcal{T}_i \in \{\mathcal{T}_i\}$ **do**

从 $\mathcal{T}_i$ 采集训练数据 $\mathcal{D}_i^{train}$

计算自适应梯度：$g_i \leftarrow \nabla_\theta \mathcal{L}_{\mathcal{T}_i}(\pi_\theta)$

更新内部参数：$\theta_i' \leftarrow \theta - \alpha g_i$

评估 $\pi_{\theta_i'}$ 生成验证数据 $\mathcal{D}_i^{val}$

end

聚合元梯度：$g \leftarrow \nabla_\theta \sum_{\mathcal{T}_i} \mathcal{L}_{\mathcal{T}_i}(\pi_{\theta_i'})$

更新元参数：$\theta \leftarrow \theta - \beta g$

end

Algorithm 3.1: 一阶 MAML 元训练流程（FOMAML）

3.6 本章小结

本章节介绍了研究中的大部分算法细节。首先本章对反馈机制的数据流程进行了介绍，然后介绍了 MoE-SAC 规划算法，对相关的专家算法进行了详细介绍的同时，对

中国知网　https://www.cnki.net

规划层的神经网络也进行了讨论，最后本章介绍了基于 SAC 算法的控制器结构及其一阶 MAML 算法的实施过程。

由于强化学习在某个应用中的稳定性严格证明是困难的，经典控制论的大量工具无法使用。因此下一章节中，将对本研究的神经网络进行训练稳定性和收敛性的实验和验证，侧面验证强化学习算法在处理无人机规划控制问题上的可行性。

中国知网 https://www.cnki.net

第四章　模型训练稳定性与收敛性分析

本章节对第三章的分层深度强化学习算法和各专家算法的神经网络模型进行了训练方案制定、训练稳定性和收敛性分析。本章节首先介绍了各个网络模型的训练策略，然后验证了各个子层级算法的收敛情况，对模型的稳定性和训练方法的合理性进行了说明；接下来验证了各个神经网络的训练顺序和交替训练策略的有效性，最后展示验证了元学习算法、反馈机制对训练和收敛效果的影响。本章节证明了本研究方法的稳定性和收敛性。

4.1 训练流程设计

对于多个网络组合构成的复杂系统，同步开展模型训练往往对数据集的质量和规模有较高要求，并且需要较强的硬件性能，工程难度较大。因此本研究为模型训练过程设计了训练顺序，通过分阶段、交替训练等方式处理系统中模型的训练需求。模型的具体训练顺序如图4-1所示，算法的训练首先在服务器的模拟环境中进行离线学习，然后在实物平台进行在线学习。

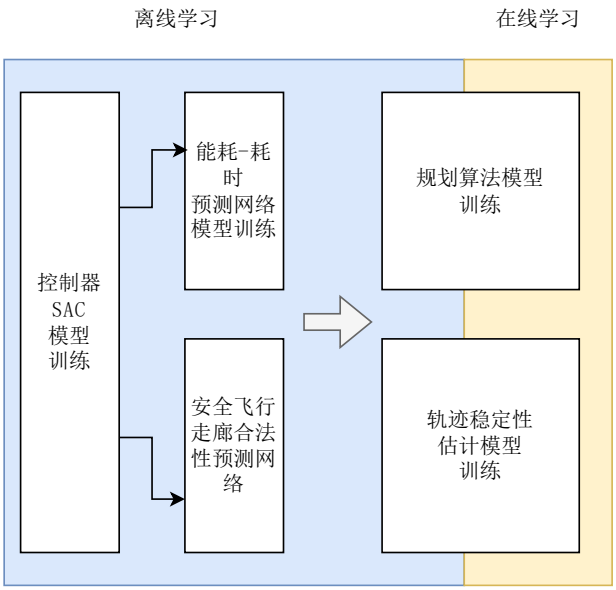


图 4-1 本研究中网络模型的训练顺序

Figure 4-1 The Training Protocol of the Proposed Network Model

中国知网　https://www.cnki.net

本研究的模型训练流程基本遵守自下而上的顺序，控制器层的 SAC 网络规划层网络首先通过一阶 MAML 算法进行预训练，然后对规划层的专家算法网络进行训练和固定。

在完成上述模型训练后，无人机系统需在仿真环境中进行实时训练，首先对规划算法的 SAC 网络进行训练和控制器 SAC 算法进行交替训练。分层强化学习中常采用“高层慢更新、底层快更新”的设计，其理论依据可追溯至两时间尺度随机逼近理论（Two-Timescale Stochastic Approximation），其在应用效果上得到了广泛验证。在本研究在每完成单个样条轨迹飞行时进行训练，每次训练通过上下两级网络的损失函数下降比例动态进行训练对象选择，这个过程可以描述为：

$$P_{\text{control}} = \min(1, P_{\text{control}}^{\text{base}} + \frac{\text{Pn}_{\text{loss}}^{\text{control}}}{\text{Pn}_{\text{loss}}^{\text{plan}}}) \tag{4.1}$$

式中，P_{control} 表示控制层网络被选中的概率，每次进行的训练选择时包含一定概率；$P_{\text{control}}^{\text{base}}$ 表示控制层网络被选中的基础概率，通过设置更大的基础概率可使高层网络训练次数更多；$\text{Pn}_{\text{loss}}^{\text{control}}$ 表示控制器网络的损失函数下降比例；$\text{Pn}_{\text{loss}}^{\text{plan}}$ 表示规划层网络的损失函数下降比例。损失函数下降比例的计算方式为：

$$\text{Pn}_{\text{loss}} = \frac{\log(Loss_{\text{init}})}{\log(Loss_{\text{now}})} \tag{4.2}$$

式中，Pn_{loss} 表示模型的损失下降比例，$Loss_{\text{init}}$ 表示第一次迭代时的损失函数值，$Loss_{\text{now}}$ 表示最近一次迭代时的损失函数值。

表 4-1 模型训练的数据来源和训练类型

Table 4-1 Model Training Data Sources and Training Methodologies

模型功能	架构	数据来源	训练类型
控制器	TCN+MLP	环境交互	离线预训练和在线训练
轨迹稳定性预测	LSTM	控制器缓存数据	在线训练
安全飞行走廊约束	MLP	计算机自动生成	离线训练
能耗-耗时预测	MLP	计算机自动生成和环境交互	离线预训练和在线训练
规划算法	MLP	环境交互	在线训练

在无人机实时运行过程中，专家模型的按照需求可在线训练，能耗预测专家网络会统计近 N_{etbuffer} 组能耗估计结果，若存在 10% 的误差则需要重新进行迭代，能耗预

中国知网 https://www.cnki.net

测专家网络对算力的需求较低，可以在线完成网络模型的迭代；轨迹稳定性估计专家网络在无人机系统完成 N_{tsbuffer} 次多项式轨迹片段的运动后，会进行经验回放池的数据抽取和模型训练，并对控制器迭代前的数据进行清理。

表4-1展示了不同功能模型数据的来源和在线或离线的训练类型，通过合理设置时序，可以保证所有网络获得相应的训练数据。

训练过程中，轨迹稳定性预测专家网络需要从经验回放池中抽取数据，规划层 SAC 算法等模型也需要缓存进行经验数据的暂存，而每次取出的数据也需要根据训练情况进行调整。综上所述，训练过程中存在大量的超参数，表4-2展示了模型训练过程中的超参数。

表 4-2 训练超参数表

Table 4-2 Training hyperparameter table

参数符号	参数名称	参数值
Size_{ts}	轨迹稳定性估计数据缓存条数	5000
Smp_{ts}	轨迹稳定性估计数据每批次训练数据条数	1000
N_{tsbuffer}	轨迹稳定性估计网络每轮迭代需要等待的无人机规划轮数	30
Size_{et}	能耗预测网络数据缓存条数	10000
Smp_{et}	能耗预测网络每批次训练数据条数	1000
N_{etbuffer}	能耗预测网络每轮迭代需要等待的无人机规划轮数	80
Size_{ctr}	控制器 SAC 算法数据缓存条数	20000
Smp_{ctr}	控制器 SAC 算法每批次训练数据条数	500
$\text{Size}_{\text{plan}}$	规划层 SAC 算法数据缓存条数	5000
Smp_{plan}	规划层 SAC 算法每批次训练数据条数	100

4.2 模型训练结果

4.2.1 控制器层深度神经网络网络预训练

为保证无人机控制网络在实物训练阶段的安全性，减少翻机风险，需要加入预训练流程，使得无人机的参数可以保证无人机的基本运动和快速收敛。MAML 是一类广泛使用的元学习算法，但是其需要计算二阶导数，会给整个训练过程带来较大的性能开销，因此本研究首先使用一阶段 MAML 进行模型预训练。训练过程中使用 200 台无人机在仿真环境进行并行训练，同时采取异策略措施，通过无人机经验池进行模型训练。为了保证模型良好的泛化性能，训练过程中使用随机参数生成轨迹，并且逐步添

中国知网　https://www.cnki.net

加干扰。模型训练分为以下三个阶段：（1）粗调阶段，固定电池电压和轴距参数，随机化其余参数，不添加干扰，学习基础动力学响应；（2）精调阶段，引入随机电池电压，随机在 220mm、250mm、330mm、350mm、450mm、550mm 中选择轴距，并添加遵守正态分布的传感器噪声，增加模型泛化能力；（3）鲁棒性训练阶段: 注入脉冲干扰，提升抗扰动能力。

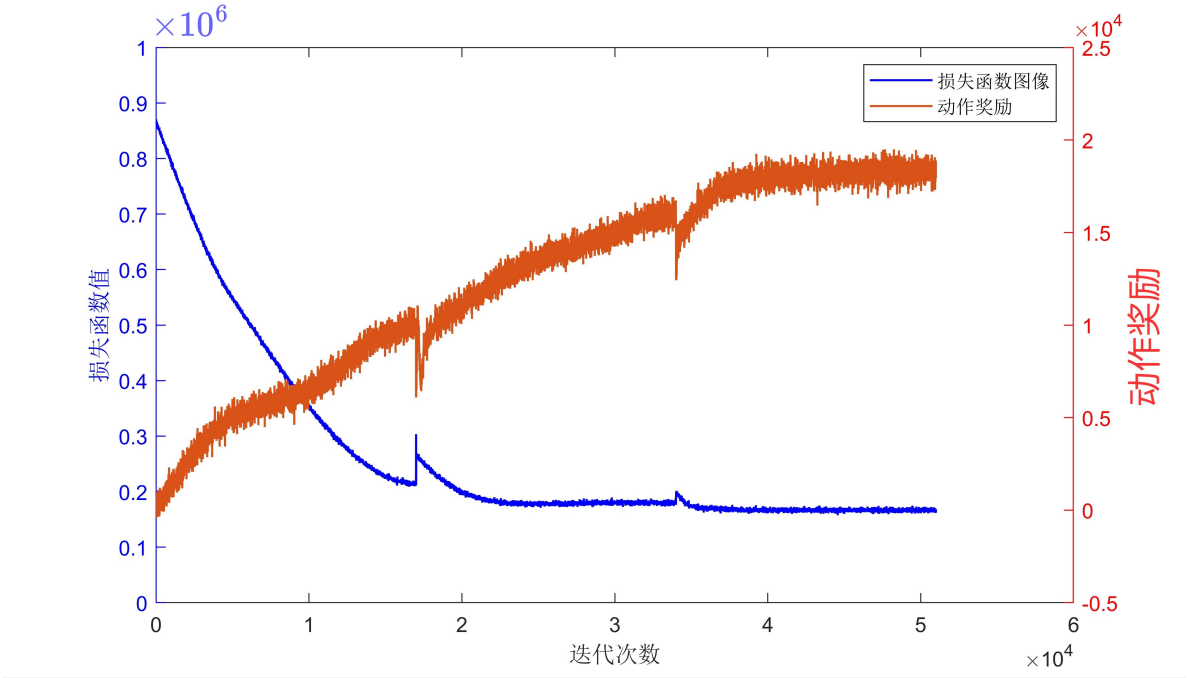


图 4-2 元学习算法训练阶段的训练损失和决策网络奖励

Figure 4-2 Training Losses, and Decision Network Rewards in the Training Phase of Meta-Learning Algorithms

如图4-2所示，元学习算法通过三个阶段的学习过程，逐步降低了元学习过程中的训练损失，随着学习训练损失降低，价值网络模型的误差得到降低，决策网络的网络奖励得到了提高。注意到图中的两次损失函数值和奖励数值异常，这些异常来自每个阶段新的无人机和环境参数的导入。训练结果的稳定从侧面证明了神经网络对无人机进行控制的可行性，使用强化学习方法也可以保证对无人机系统的稳定控制。

4.2.2 能量预测专家网络训练

作为无人机规划过程中约束的一环，无人机需预测飞行过程中能量与飞行时间的关系，通过预先使用计算机随机生成数据集，使用最小控制量轨迹算法来表征当前最优的能量控制算法，则可以收集到足量数据进行离线训练。

中国知网 https://www.cnki.net

训练前，本研究随机生成了不同形状的、尺寸不大于 25 米 *25 米 *1 米的 900 万组随机凸包，并使用了随机的内部点作为出发和终止点，并进行了轨迹生成，然后统计了其中控制消耗的能量，最后将这些数据按照每 10000 组作为一个训练数据批次进行了网络训练和测试。网络的训练结果如图 6 所示，网络在训练了 5000 轮后将能量估计的误差降低至不高于 10%。

在训练阶段，网络首先对 Net_{kn} 进行训练，使网络具有一定的初步预测能力，然后固定网络 Net_{kn} 参数，再对网络 Net_{p} 和 Net_{mix} 进行训练。

在推理阶段，将出发和终止的状态信息和时间约束等信息作为运动学网络 Net_{kn} 的输入，并将上述凸多边形的约束同出发和终止点的角度、距离信息作为空间约束网络 Net_{p} 的输入，并将上述两个网络的输出作为输入汇总到混合网络 Net_{mix} 以得到最终的结果。如图4-3所示，网络的测试集误差已经几乎为 0，这表明了深度神经网络对于能耗-耗时预测的有效性。

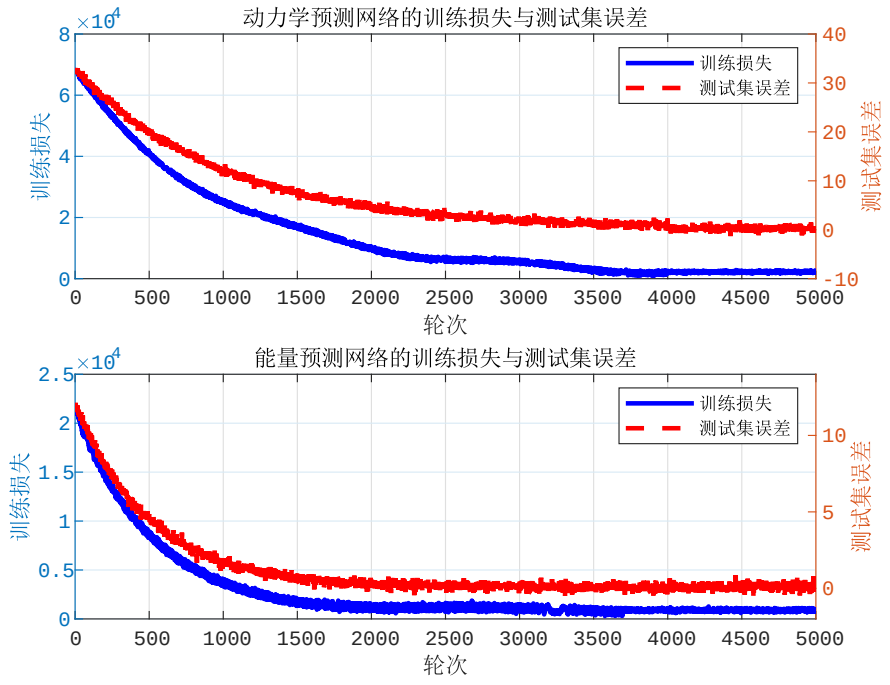


图 4-3 能量预测专家网络训练时的损失和平均误差

Figure 4-3 Losses and average errors during training of energy prediction expert networks

中国知网　https://www.cnki.net

4.2.3 轨迹稳定性估计专家网络训练

本研究使用 LSTM 模型为基础的神经网络来判断无人机的目标控制序列是否合理并对规划层算法的轨迹进行约束，其网络输出是预计的控制误差和稳定性指标。为了进行模型训练，该网络的模型获取和训练分为两步：（1）离线学习，使用无人机预训练数据，对无人机轨迹的合理性进行学习；（2）在线学习，控制器层会实时采样控制效果并送入经验回放池，其回放和训练的超参数遵守表4-2 的参数设置。

图4-4展示了上述两个阶段的模型在训练后的损失函数值和控制器平均误差、稳定性指标的误差。可以发现网络的损失呈现逐步下降趋势，其估计的误差也逐步降低。在切换训练模式后可在图中看见预测效果短暂变差，但是依然快速收敛。这证明了深度神经网络对于控制器模型控制边界的预测能力。

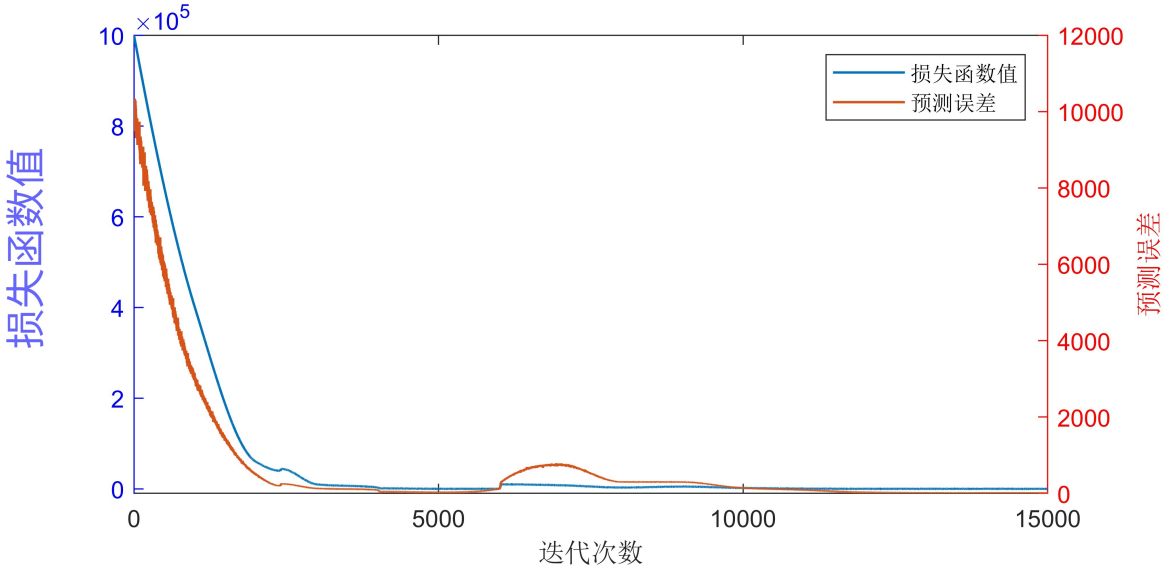


图 4-4 轨迹稳定性估计专家网络训练时的损失和平均误差

Figure 4-4 Trajectory Stability Estimation of Losses and Mean Errors in Expert Network Training

4.2.4 规划算法和控制器网络的实物平台在线训练

规划算法和控制器的分层 SAC 算法训练分为两个部分：（1）首先进行仿真环境下的规划算法迭代，使得规划算法学习基础的轨迹点选择。（2）在实物平台上，通过三个步骤完成规划器的训练任务：首先进行空旷无遮挡场地的规划任务训练，然后搭建带有障碍的场景进行规划，最后通过上位机随机添加动态目标，完成规划器的训练。

在仿真阶段，规划算法的训练效果如图4-5所示，随着迭代，SAC 规划算法在多专

中国知网 https://www.cnki.net

家算法的辅助下其损失逐步下降，而奖励逐步上述，这表示相关算法结构在规划问题求解的有效性。

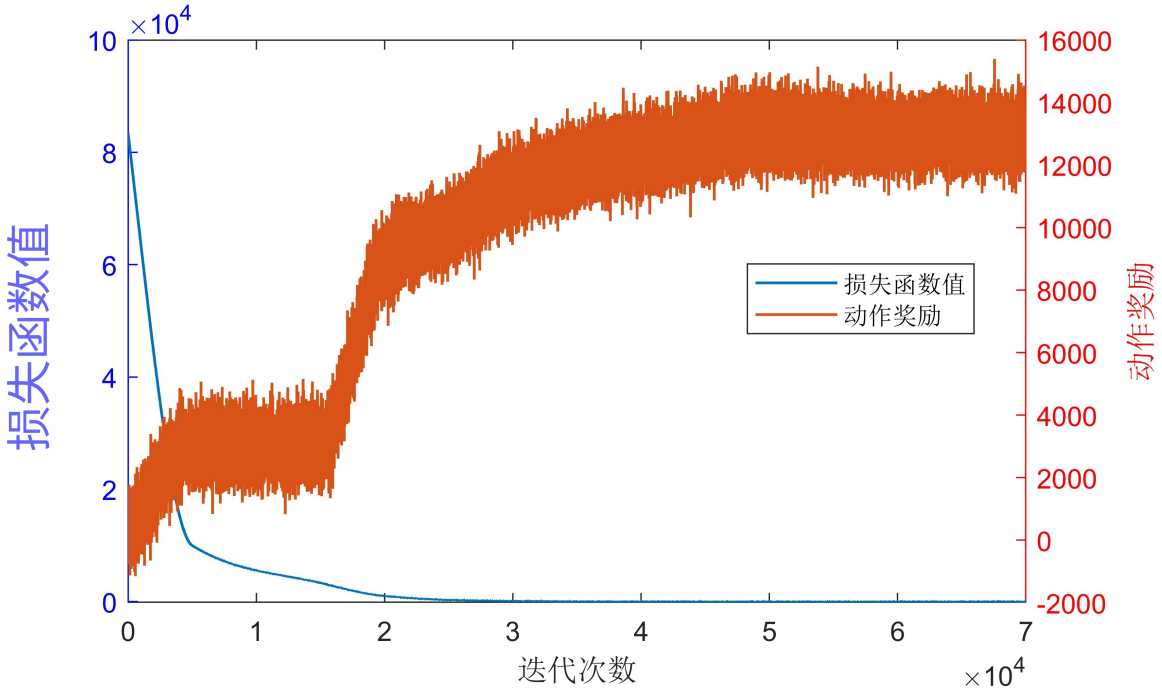


图 4-5 SAC 规划算法仿真训练时的损失和奖励

Figure 4-5 Losses and rewards in simulated training of SAC planning algorithms

表 4-3 在线训练实验配置

Table 4-3 Online Training Experiment Configuration

实验配置	实验配置信息或规格
无人机平台	带有 Nvidia Jetson Orin 系列机载电脑的实物无人机平台
无人机轴距	250mm
无人机电池	6 串联 21700 电池（25.2V）
无人机通信方式与时延	WIFI 通信/ROS2 传递信息,20ms
上位机	Ubuntu20.04 PC 机
超参数 $P_{\text{control}}^{\text{base}}$	仿真:-0.7，实物：0.6

在实物实验阶段，实验配置如表4-3所示。实物训练过程中的价值估计误差和奖励值迭代过程如图4-6所示，在仿真训练阶段，模型的误差缓慢、逐步下降而奖励逐步上升，规划网络通过仿真环境可以学习到初步的规划策略。在实物训练阶段，模型的误差

中国知网　https://www.cnki.net

出现了初期陡升，奖励也出现下降，这是因为专家网络在实物环境的估计误差，控制器的模型存在差异，同时仿真到实物存在一定的物理参数变化，但随着模型学习，模型的估计误差逐步下降，决策奖励同步逐步上升，这表明网络可以学习现实物理特征并进行正确决策。

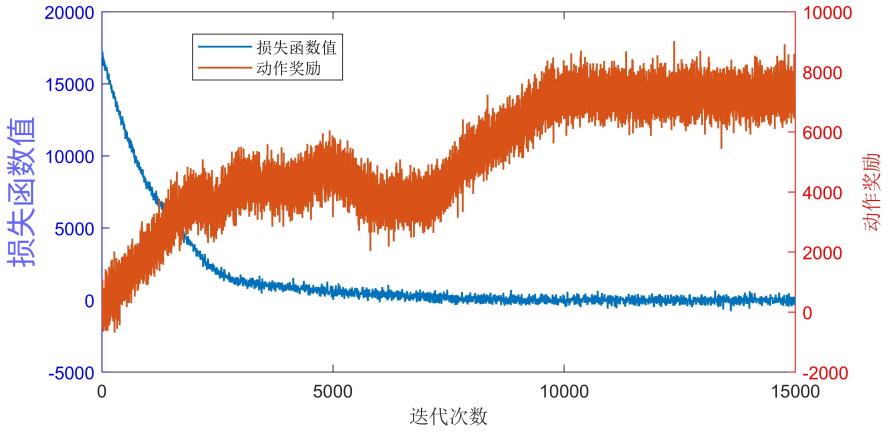


图 4-6 实物训练时的训练时的规划算法损失和动作奖励

Figure 4-6 Planning Algorithm Losses and Action Rewards during Training in Real Life Training

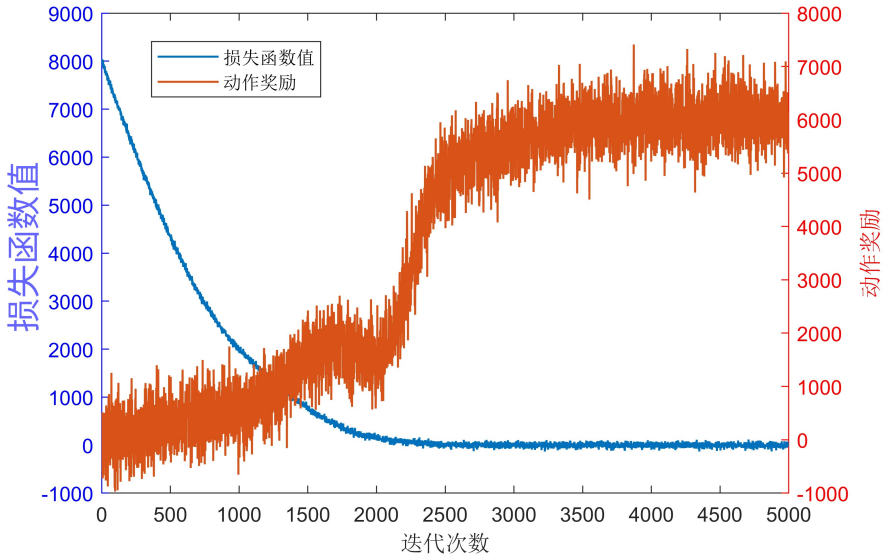


图 4-7 实物训练时的训练时的控制器模型损失和动作奖励

Figure 4-7 Controller Model Losses and Action Rewards during Training in the Real World

中国知网 https://www.cnki.net

4.3 模型训练改进的有效性验证

4.3.1 控制器反馈机制下轨迹稳定性估计网络的训练流程验证

本小节验证了控制器的反馈机制数据作为轨迹稳定性估计网络的数据集，其在网络训练过程中的作用分析。在完成前述无人机控制器的训练之后，可使用随机轨迹来使得无人机进行跟踪飞行，在飞行过程中轨迹稳定性相关的数据进入到经验回放池，并通过双层回放池的机制提取经验数据进行训练。根据图4-8的迭代曲线显示，即便这种数据收集和训练的频率不同，但估计网络依然可以学习到轨迹稳定需要的特征。

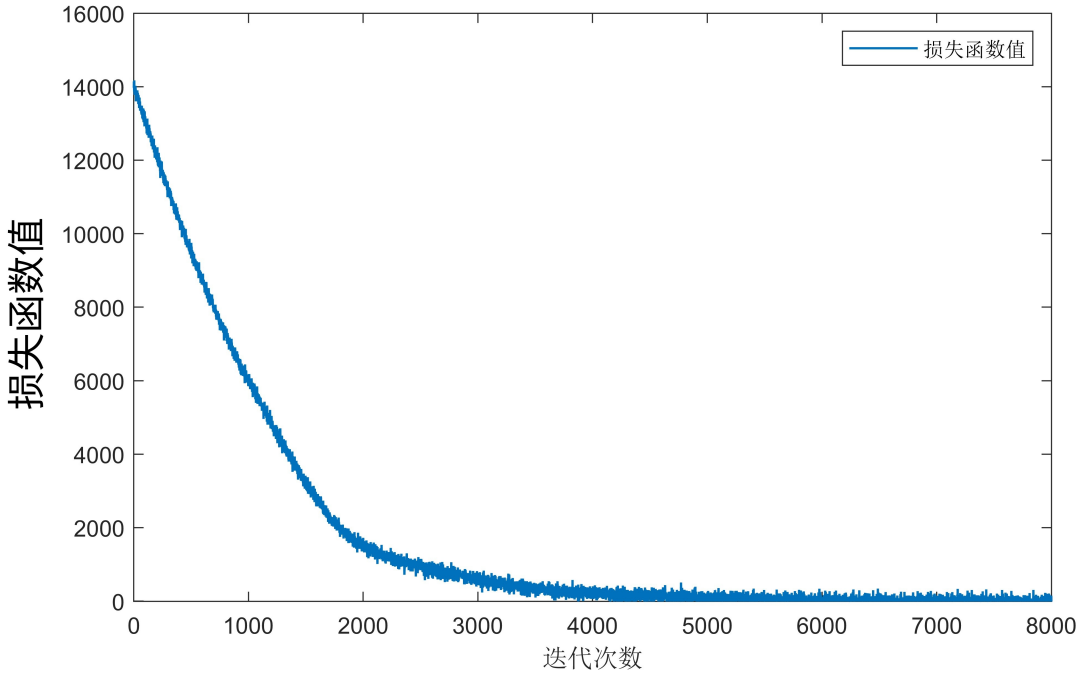


图 4-8 无人机在反馈机制下的损失函数值变化

Figure 4-8 Errors in UAV trajectory tracking without feedback mechanism

4.3.2 一阶 MAML 算法对控制器模型收敛的提升验证

为了验证元学习算法对控制器模型收敛过程的提升，实验在仿真平台上对比了不使用 MAML 的多组随机模型和预训练模型的最终训练结果。实验结果如图4-9所示，预训练模型使用了更短的迭代次数完成收敛的同时，也更容易探索到问题的最优解，图中不使用 MAML 的模型在训练上万轮之后依然无法优于使用 MAML 进行预训练的模型训练后的结果。图4-10展示了使用 MAML 预训练网络在进行部署训练时的快速迭代过程，其损失函数在初始时更低，也能更快完成训练过程。

中国知网　https://www.cnki.net

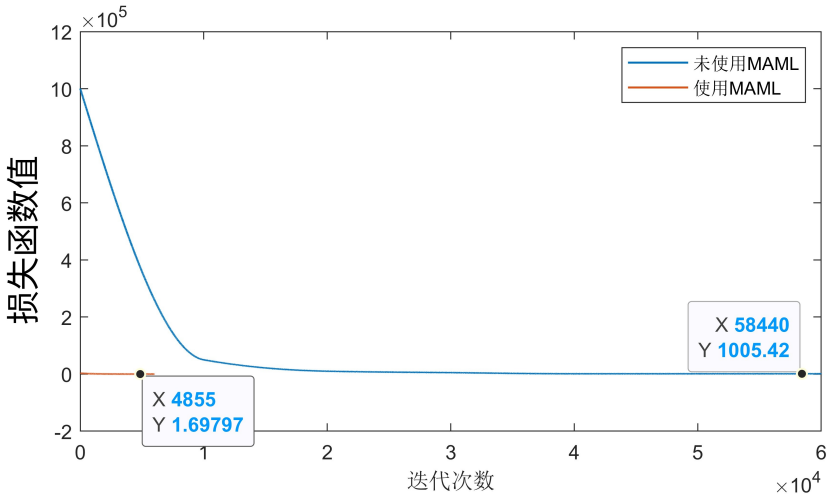


图 4-9 一阶 MAML 算法对控制器模型收敛的提升验证

Figure 4-9 computational efficiency advantages under different flight time constraints

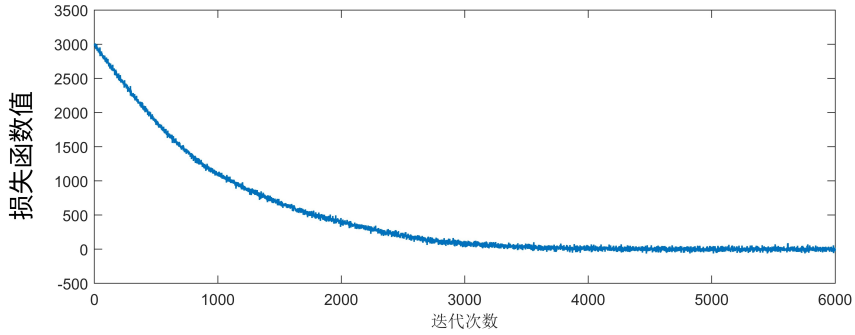


图 4-10 一阶 MAML 算法对控制器模型收敛的提升验证

Figure 4-10 computational efficiency advantages under different flight time constraints

MAML 算法的主要作用是提高网络模型的适应能力，本节验证了 MAML 的预训练模型收敛的更为快捷，这证明了 MAML 算法对网络模型训练和实际模型的部署速度具有明显的提升作用。

4.4 本章小节

本章节制定了各个神经网络的训练顺序、训练超参数、数据收集的过程。同时展示了仿真、实物平台的实际训练效果，验证了模型训练的稳定性和结果的收敛性。另外通过对比实验，保证了元学习算法、反馈机制等改进在模型训练阶段的改善效果。

但是本研究的实验方法和稳定性分析依然存在一定的不足。首先是上下层的交替

中国知网 https://www.cnki.net

训练机制尚显不够成熟，依然需要依靠手动设置超参数，自适应的参数设置是后续发展的趋势；此外，由于强化学习是数据驱动的算法，可以看作一个黑箱模型，目前尚无优秀手段可以进行强化学习控制器稳定性分析，大多数传统稳定性分析方法很难得进行严格的数学证明，这一问题超出了本文的研究范围，因此并未进行详细讨论。

接下来本研究将对训练完毕的模型进行模块测试、消融实验和综合实验，检验其规划控制算法的详细性能，第五章将对这一主题进行详细的介绍和分析。

中国知网　https://www.cnki.net

第五章　实验设计与结果分析

本章通过仿真与实物实验验证了本研究的规划控制方法的性能，包含了各个子模块的实验对比、消融实验验证部分机制的有效性、无人机移动平台的算力需求分析、各个模块的综合实验。实验设计覆盖了算法执行精度、能效、有效性等各个环节。本章节有力验证了本研究算法的实际性能和实用价值。

5.1 实验环境与基准算法

5.1.1 仿真测试平台

为在仿真实验中验证算法的基础性能，实验搭建了仿真测试平台，包括用于控制器和规划算法网络的无人机强化学习仿真平台和用于上位机实时监控的无人机轨迹规划测试平台。仿真环境的运行流程框架如下图所示：

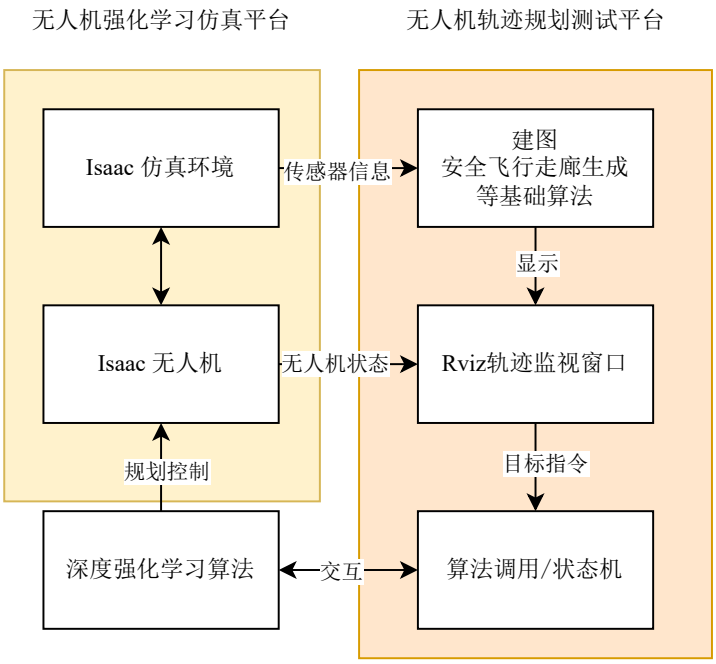


图 5-1 仿真环境的运行流程框架

Figure 5-1 Operational process framework for the simulation environment

如图5-1所示，无人机强化学习仿真平台支撑无人机的控制器和规划算法网络的训练和推理任务，同时对无人机的动力学环境仿真提供了支持；无人机轨迹规划测试平

中国知网　https://www.cnki.net

台支撑了无人机轨迹规划结果监控，同时提供环境建图、凸包生成、用户环境等前序流程和算法的支持。

5.1.1.1 无人机强化学习仿真平台　为进行仿真实验、元学习算法预训练、强化学习网络训练，实验搭建了基于 Nvidia Isaac Gym 仿真环境的仿真平台。该仿真平台的基础信息如下：

表 5-1 强化学习仿真环境基础信息

Table 5-1 Enhanced Learning Simulation Environment Basic Information

平台配置项目	实验平台信息或规格
操作系统	Ubuntu22.04.5 LTS
处理器	Intel Xeon(R) Platinum 8255C
显卡和 CUDA 版本	Nvidia RTX 2080 Ti x2, CUDA 版本为 11.8
内存	48GB
主要环境依赖	ROS2, Python3.8, Isaac GYM

实验采用上述环境进行了模型训练与分析、控制算法的性能分析、反馈机制分析、消融实验。图5-2展示了该仿真平台的运行框架；图5-2展示了该仿真平台运行效果：

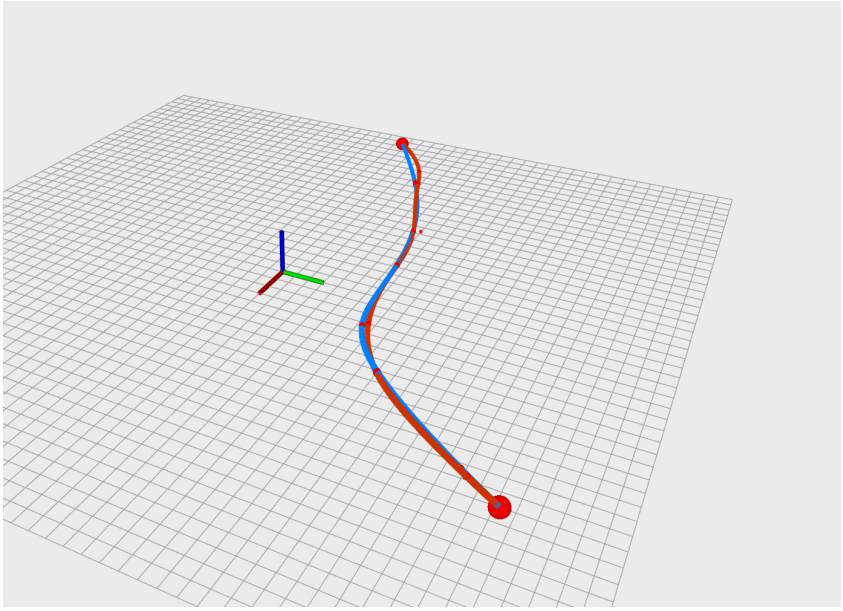


图 5-2 无人机强化学习仿真平台运行效果

Figure 5-2 Operation effect of UAV reinforcement learning simulation platform

中国知网　https://www.cnki.net

5.1.1.2 无人机轨迹规划测试平台 Isaac 仿真平台主要用于机器人强化学习训练，对轨迹规划和机器人避障运动等研究支持度不理想。为了处理前序算法流程、提供数据分析工具，本实验同时搭建无人机轨迹规划测试平台，用于进行地图导入、路径规划、安全飞行走廊生成和规划轨迹监控分析。该仿真平台的基础信息如下：

表 5-2 无人机轨迹规划环境基础信息

Table 5-2 Basic information on the UAV trajectory planning environment

平台配置项目	实验平台信息或规格
操作系统	Ubuntu22.04.5 LTS
处理器	Intel Xeon(R) Platinum 8255C
显卡和 CUDA 版本	Nvidia RTX 2080 Ti x2, CUDA 版本为 11.8
内存	48GB
主要环境依赖	ROS2, Python3.8, Rviz, Plotjoggler, C++ 运行时
前序算法功能	PCL 地图导入、Rviz 监控接口生成、SFC 生成、RRT 规划算法

本章节实验在上述平台上进行了轨迹规划性能分析和消融实验。

5.1.2 实物实验平台

本实验使用实物验证了算法性能，上位机通过搭载 Nvidia Jetson 系列机载电脑实现终端强化神经网络推理，使用激光惯性里程计（LIO）实现同时定位与建图（SLAM）功能。图5-3展示了实验四旋翼无人机细节：

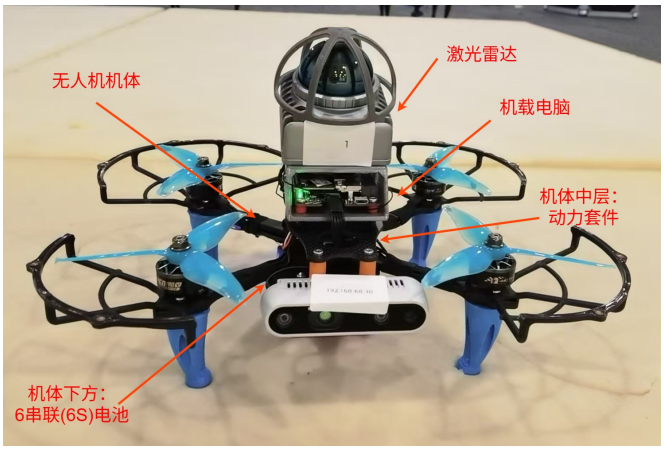


图 5-3 无人机实物平台

Figure 5-3 Physical platforms for drones

中国知网 https://www.cnki.net

Nvidia Jestson 系列机载电脑具有较强的性能，可以满足自主无人机运动过程中的计算需求。机载电脑的硬件和软件环境配置如表5-3所示：

表 5-3 实验无人机机载电脑基础信息

Table 5-3 Experimental UAV on-board computer basic information

平台配置项目	实验平台信息或规格
型号	Nvidia Jetson Orin NX
操作系统	Ubuntu20.04
处理器	8 核心 Arm Cortex A87AE
加速算力	约 117TOPS(INT8)/50TFLOPS(FP16)
内存	8GB
固件版本	JetPack 5.1.1
主要环境依赖	ROS2，Python3.8，TensorRT，C++ 运行时
机载主要算法	FASTER-LIO（建图定位），飞行走廊生成算法，本研究提出的算法

实验过程中，无人机、现场上位机的运行流程如图5-4所示，无人机的实际运行效果如图5-11所示。

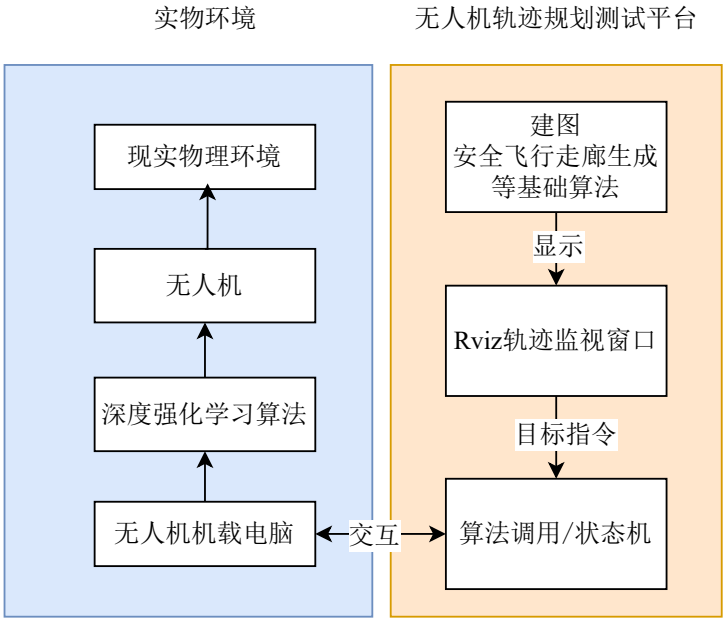


图 5-4 实物无人机实验的运行流程

Figure 5-4 Operational flow of the physical drone experiment

中国知网　https://www.cnki.net

5.2 规划层性能评估

本节为了进行规划算法性能对比分析，实验共选取了三组规划基准方法：

（1）传统规划算法对照：QP 求解多项式轨迹（图表中简称 QP 算法），基于微分平坦求解 QP 问题是轨迹规划问题的常用解法，在本实验中具有一定的参考对比价值。

（2）最小控制量轨迹对照：MINCO 轨迹类及 GCOPTER 求解算法（图表中简称 MINCO 轨迹），MINCO 轨迹类及其配套解法实现了高能效的轨迹生成，是本研究相关算法的基础，本实验通过对比来验证本研究提出算法的提升效果。

（3）本研究提出的算法：基于能量预测的时间分配、多专家 SAC 算法规划（图表中简称 SAC 算法）。

5.2.1 能量预测和时间分配算法性能分析

本研究的能量-耗时预测网络和时间分配算法对规划算法的结果进行了优化，为 MoE-SAC 规划算法的专家算法性能提供了保证。本小节测试了神经网络的预测精度，实验测试了神经网络在不同运行时长、飞行走廊数目和直线飞行距离下对无人机最小能量消耗的预测百分比误差。

实验均匀选取了 10000 组运行时长为 1 秒至 45 秒的飞行任务，并比较了平均百分比误差；为了测试飞行走廊数目对神经网络准确度的影响，实验均匀选取了 5000 组飞行走廊个数为 1 到 15 的飞行任务，同时对预测的百分比误差进行了统计；为了测试开始和结束状态距离对网络的影响，本实验也均匀选取了 14000 组直线距离从 0.5 米至 25 米的飞行任务，并统计了百分比误差。我们使用下面的评测方式计算百分比误差：

$$MAPE(Opt,Opt_{\mathrm{ep}}) = \frac{1}{n}\sum_{\substack{\forall f\in \mathrm{Opt} \\ f:t\leftrightarrow e \\ \forall f_{ep}\in \mathrm{Opt} \\ f_{ep}:t\leftrightarrow e_{ep}}} \left|e-e_{ep}\right| \tag{5.1}$$

式中，$MAPE(Opt,Opt_{\mathrm{ep}})$ 表示绝对平均百分比误差计算函数；n 表示网络预测的点的个数；Opt 是网络预测的可行解；Opt_{ep} 是数据集中可行解的正确结果；f 表示可行解 Opt 中的映射；f_{ep} 表示正确可行解 Opt_{ep} 中的映射关系；f 和 f_{ep} 均映射了无人机能量消耗 e 和时间消耗 t 之间的关系。最终通过计算能量序列之间的 L1 范数，得到绝对平均百分比误差。

对网络准确度的测试结果如图5-5、图5-6和图5-7所示，对于消耗为 1 秒至 30 秒的

中国知网 https://www.cnki.net

轨迹规划任务，神经网络可以取得平均 1% 以内的预测百分比误差；对于飞行走廊个数为 3 个至 15 个的飞行任务，神经网络可以取得平均 2% 以内的预测百分比误差；对于开始和结束位置的直线距离为 2 米至 25 米的飞行任务，神经网络可以取得 4% 以内的预测百分比误差。尽管时间消耗大于 30 秒、飞行走廊个数小于 2、直线距离小于 2 米的测试数据误差较大，但从工程角度看，整体的预测误差在容许范围内。

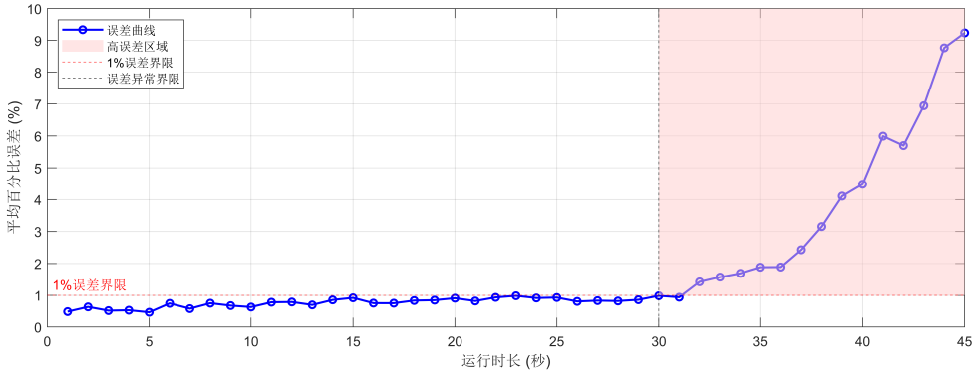


图 5-5 神经网络对不同时长飞行任务的平均预测误差

Figure 5-5 The Average Prediction Error of the Neural Network for Flight Missions with Different Durations

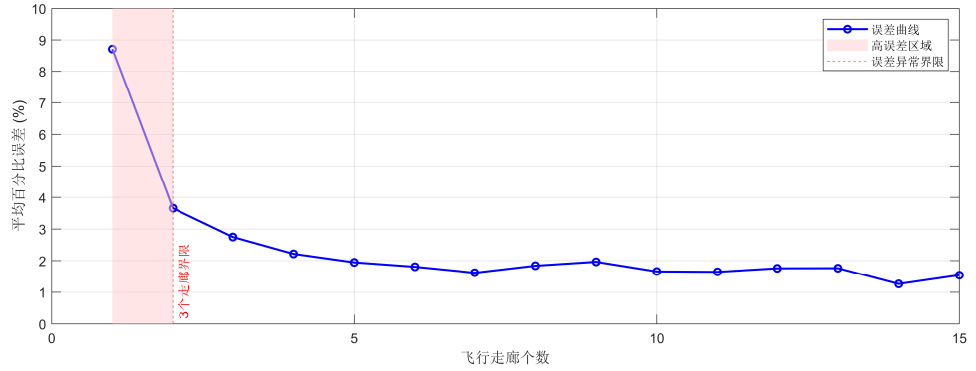


图 5-6 神经网络对不同飞行走廊个数飞行任务的平均预测误差

Figure 5-6 The Average Prediction Error of the Neural Network for Flight Missions with Different Numbers of Flight Corridors

中国知网　https://www.cnki.net

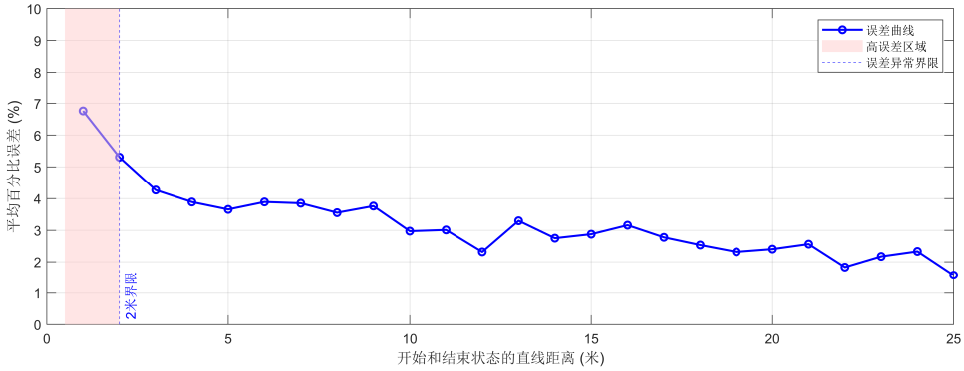


图 5-7 神经网络对不同距离飞行任务的平均预测误差

Figure 5-7 The Average Prediction Error of the Neural Network for Flight Missions with Different Distances

综上所述，本方法的神经网络对无人机轨迹规划问题中能量消耗和时间消耗进行了准确的估计，对于任意一个长宽高尺寸小于 25 米、飞行走廊片数 15 个以内、飞行时长在 45 秒内的飞行任务片段，该网络可以做到平均 4% 以内的预测百分比误差，对于能量量级较小的任务，则可将整体的误差控制在 10% 以内。

5.2.2 MoE-SAC 算法的能效和规划成功率对比

本节验证了 MoE-SAC 算法的能效和规划成功率，算法分别被部署在仿真无人机实物平台上和实物平台上。实验选择了封闭的室内地图，让无人机在已知地图的场景下，对比 MINCO 轨迹类和本方法的轨迹规划，MINCO 轨迹类具有优秀的能耗控制，可以规划出现有算法中能耗最小的轨迹。实验设置了 8.5 米/秒的最快飞行速度，在规划完毕后，无人机需要跟随规划轨迹完成飞行。

本实验首先在 ROS 环境下完成仿真，并对仿真和实物平台的结果进行了详细的数据分析。首先，实验在 $(0, 1000]$ 随机取值，设定每次无人机运动的能量消耗约束，然后执行了 60000 次随机的轨迹规划任务，记录了运行所需能量和时间消耗。同时，实验统计了 MINCO 轨迹类和 B 样条轨迹在上述 60000 次规划任务中的能量消耗和时间消耗。根据运行时长、飞行走廊的数量对上述轨迹生成方法的结果进行了统计。

最终得到的结果如图5-8所示，对于不同飞行走廊个数的飞行任务，B 样条方法因没有过多考虑能量消耗的因素，因此飞行过程中的能量消耗是较大的，而 MINCO 轨迹类因为规划时考虑了消耗最少的能量，因此表现更好，而本方法因通过神经网络预

中国知网 https://www.cnki.net

测和动态规划求解最优的时间分配策略，获得了更好的轨迹规划结果，对于飞行走廊个数相同的同一规划问题，本方法可以平均节约 5.6% 的能量消耗，进一步提高了轨迹的规划质量。

对于飞行任务运行时长不同的飞行任务，这三种轨迹生成方案的表现如图5-8所示，本方法可以平均节约 6% 的能量消耗。本方法的轨迹规划方法在能量消耗上同现有方法相比存在一定的能效优势。

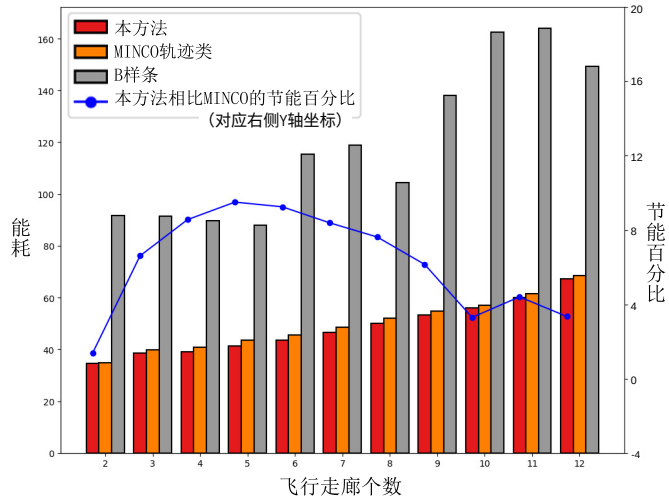


图 5-8 不同飞行走廊个数下各算法的平均能耗

Figure 5-8 The Average Energy Consumption of Each Algorithm under Different Numbers of Flight Corridors

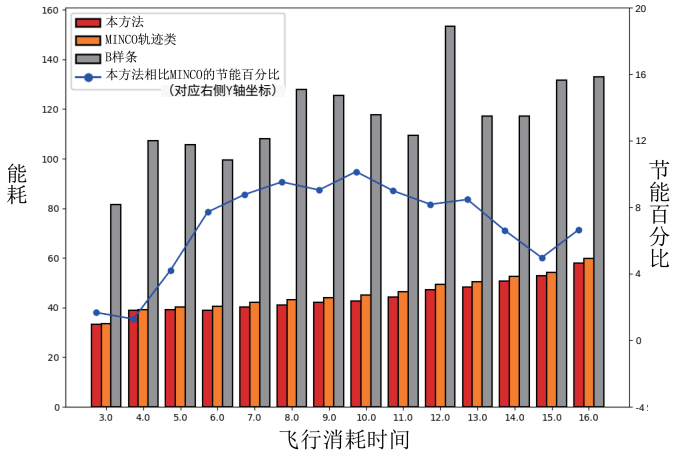


图 5-9 不同飞行时间消耗下各算法的平均能耗

Figure 5-9 The Average Energy Consumption of Each Algorithm under Different Flight Durations

中国知网　https://www.cnki.net

此外，仿真还测试了相较于原有的 MINCO 轨迹类，无人机在执行飞行任务时对任务执行速度的提升效果。实验将能量约束定义为 $(0, 5000]$ 上平均分布的随机变量，然后执行了 20000 次随机指定的轨迹规划任务，并记录了飞行所需的时间，同时也统计了 MINCO 轨迹类的飞行时间。按照能量约束的大小对任务的平均飞行时间进行了统计。最终的统计结果如图5-10所示，相较于 MINCO 轨迹类，无人机在执行飞行任务时的时间平均减少了 35%，这意味着本方法可以使无人机以更快的速度完成相应的飞行任务，可以更好地利用携带的能量。

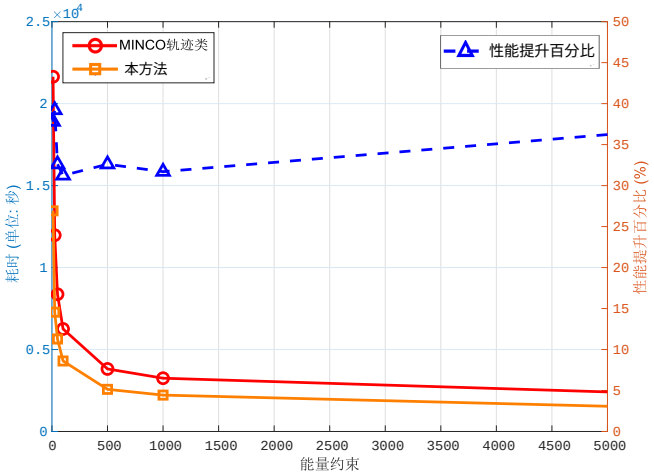


图 5-10 本方法相和 MINCO 轨迹类的运行速度对比

Figure 5-10 Comparison of the Execution Speed Between the Proposed Method and MINCO Trajectories

本实验也在实物平台进行了验证，图5-11展示了室内建图场景下进行本节实验的现场飞行。图5-12展示了本方法在实地场景生成的轨迹效果，



图 5-11 无人机运行规划轨迹的现场

Figure 5-11 Site for planning trajectories for drone operations

中国知网 https://www.cnki.net

实物实验构建了无人机的飞行走廊，使无人机按照图5-12的路径进行轨迹生成。实验统计了 140 组不同能量约束下（7 种能量约束，3 种算法，每组测试 10 次）无人机的电压从 25.2V 满电到 18.0V 略微过放的耗时，并且统计了规划算法在能量约束各异的条件下，生成轨迹的成功率。

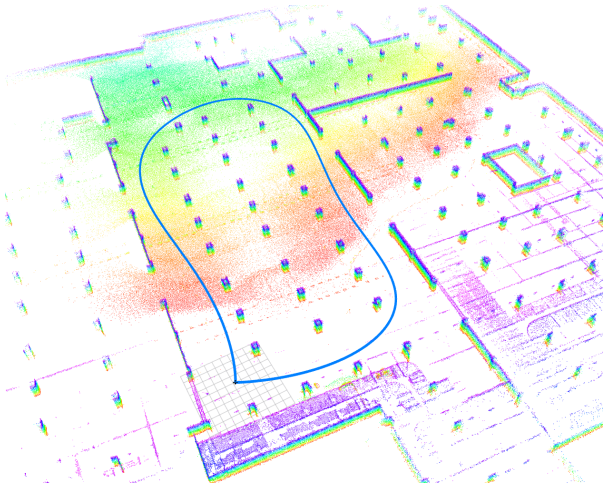


图 5-12 无人机在地下停车场内实时规划轨迹

Figure 5-12 The Operational Performance of the Drone in a Hardware-in-the-Loop Simulation Scenario

图5-13展示了不同规划算法的成功率，由于 B 样条轨迹没有将能量消耗作为优化的约束，因此实验中无法根据能量进行调整，其成功率并不高，本方法和 MINCO 轨迹规划算法都具有较高的成功率，在能量约束严苛的场景下往往表现更佳。

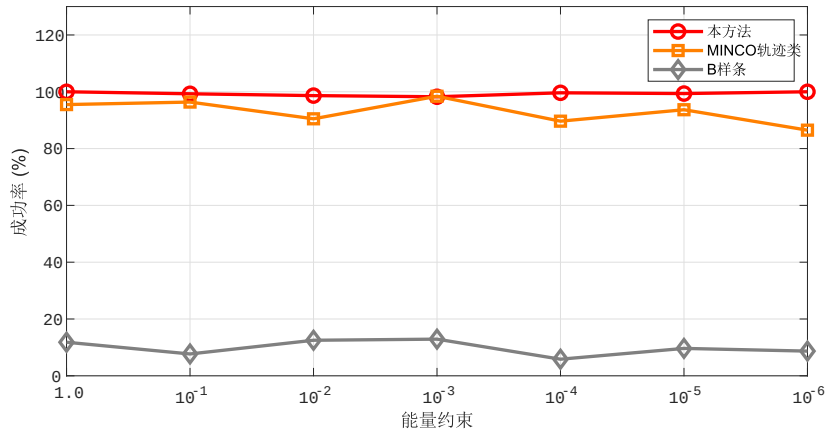


图 5-13 极低能量约束下不同算法的成功率对比

Figure 5-13 Comparison of Success Rates of Different Algorithms Under Extremely Low Energy

中国知网　https://www.cnki.net

图5-14展示了上述实物实验过程中随着电压降低，无人机的平均位置误差的变化，可见 QP 和 MINCO 轨迹类的误差会随着电压下降而扩大，这个误差来自电压变化时无人机模型的增益变化，使得模型发生了时变参数变化，而本方法表现了良好的环境适应性和算法的稳定性。表5-4则反映了无人机在执行同一任务时的电池平均使用时长，这表明规划算法相较于传统算法具有较好的性能，可以获得更为节能的轨迹。

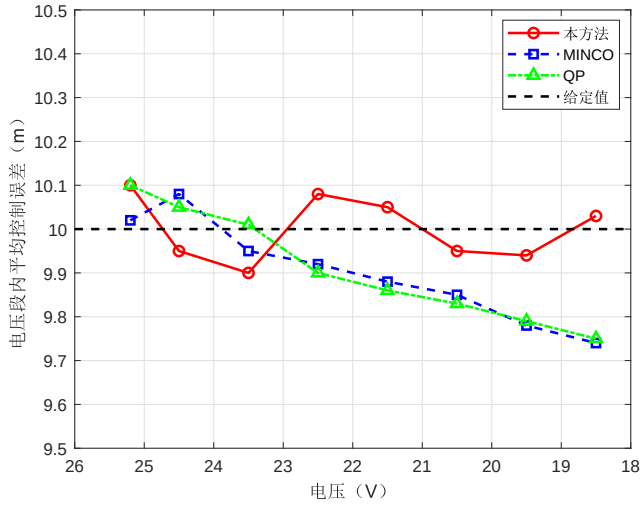


图 5-14 实物运动中平均位置误差随电压变化过程

Figure 5-14 Comparison of Success Rates of Different Algorithms Under Extremely Low Energy

表 5-4 无人机平台在规划运行过程中到达指定电压值所需平均时间

Table 5-4 Average time required for a UAV platform to reach a specified voltage value during a planning run

规划算法类别	剩余 25.0V 平均耗时	剩余 21.5V 平均耗时	剩余 18.0V 平均耗时
本方法	1min	8.45min	14.02min
MINCO	1min	7.96min	13.33min
QP	1min	6.2min	12.01 min

5.2.3 计算效率对比

此外，本实验还统计了本方法和 MINCO 轨迹类的计算时间。实验将能量约束定义为 $[0, 100]$ 上平均分布的随机变量，然后执行了 24000 次随机指定的轨迹规划任务，统计了本方法和 MINCO 轨迹类在优化过程的时间消耗。通过统计不同飞行时间下和

中国知网 https://www.cnki.net

不通过飞行走廊个数下的优化器运行时间，我们得到了图5-15的统计结果。

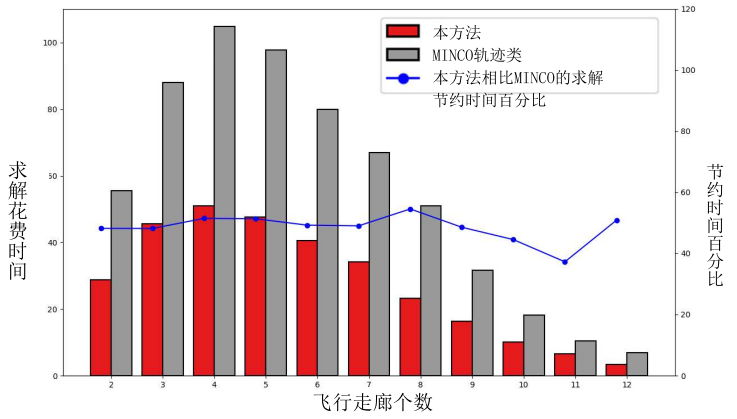


图 5-15 不同飞行走廊片数下的计算效率对比

Figure 5-15 computational efficiency advantages under different numbers of flight corridor segments

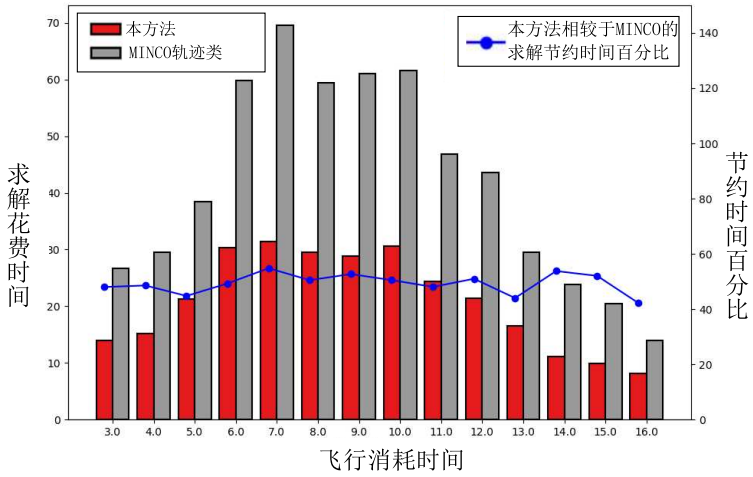


图 5-16 不同飞行时间约束下的计算效率对比

Figure 5-16 computational efficiency advantages under different flight time constraints

从图5-15中可知，对于飞行走廊个数一致的同一飞行任务，本方法在不考虑神经网络的推理时间，且仅计算优化器的计算时间时，相较于 MINCO 算法有较大的优势，平均可以节约 45% 的计算时间，提高了运算效率。之所以规划器的速度得到了提高，是因为本的方法提前确定了合适的时间分配方案，使得优化算法可以更快地找到最优点。而图5-16显示，在面对飞行时间相同的不同飞行任务时，本方法依然可以节约 40% 以上的求解时间。本方法对提高飞行效率具有积极意义。

中国知网　https://www.cnki.net

5.3 控制层跟踪性能

为了测试控制器的精度和整体控制效果，实验共选取了两组控制器基准方法：

（1）无学习算法对照：ADRC 算法。PID 算法是工业上被广泛应用的一类控制器算法，在四旋翼无人机上的控制效果也较为理想，但是在面对高速或高频信号时依然存在静态误差较大和控制器发散的问题，而 ADRC 是一类基于 PID 控制器的改进算法，大大改善了 PID 算法在实际应用过程中的缺陷，同时实现了对误差的观测，在本实验中具有一定的对比价值。目前 ADRC 算法在无人机控制器上大量使用，和 PID 算法一样成为大部分四旋翼无人机控制器的常见选择。

（2）本研究提出的算法：MAML 预训练的 PPO 算法（图表中简称 MAML-PPO 算法）。

5.3.1 静态轨迹跟踪

本实验使无人机在试验场进行绕 8 字的基础测试，并对控制器的平均位置控制误差进行了统计，ADRC 控制器的控制误差分布如图5-17所示，本方法的 SAC 算法控制器如图5-18所示，实验表明，本方法可以将控制误差散布更小，其在 1σ 下的误差范围相较于 ADRC 减少了 47%。

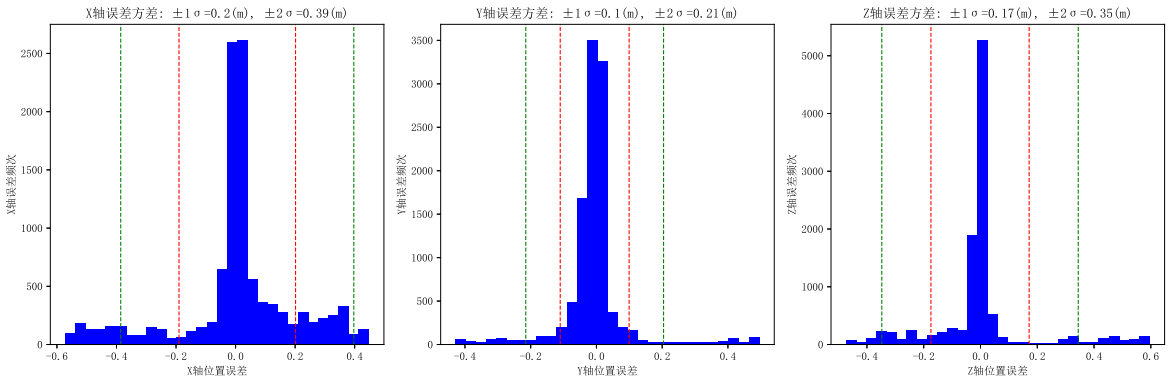


图 5-17 MINCO 轨迹类的速度控制误差分布

Figure 5-17 Control Error Distribution of MINCO-like Trajectories

中国知网 https://www.cnki.net

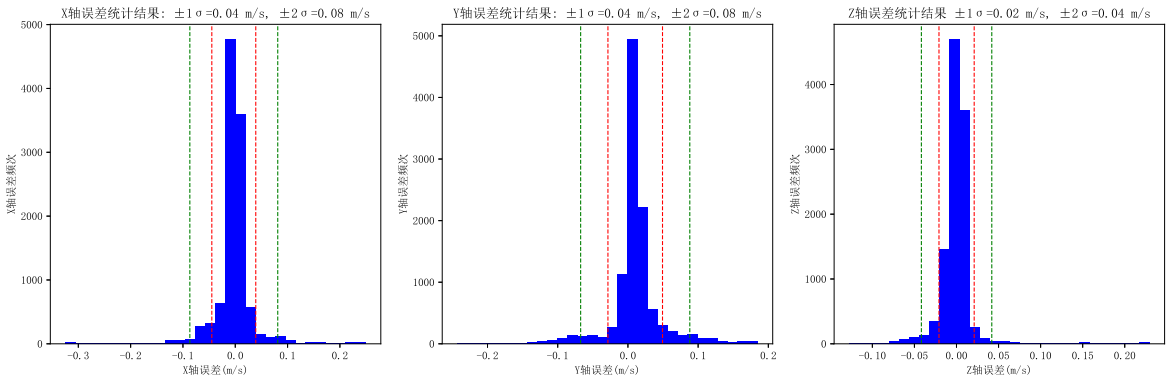


图 5-18 本方法的速度控制误差分布

Figure 5-18 Control Error Distribution of the Proposed Method

5.3.2 抗干扰能力测试

本实验还测试了无人机非对称的力矩挂载，在无人机头部挂载瓶装水，测试其控制器稳定性，测试效果如图5-20所示。

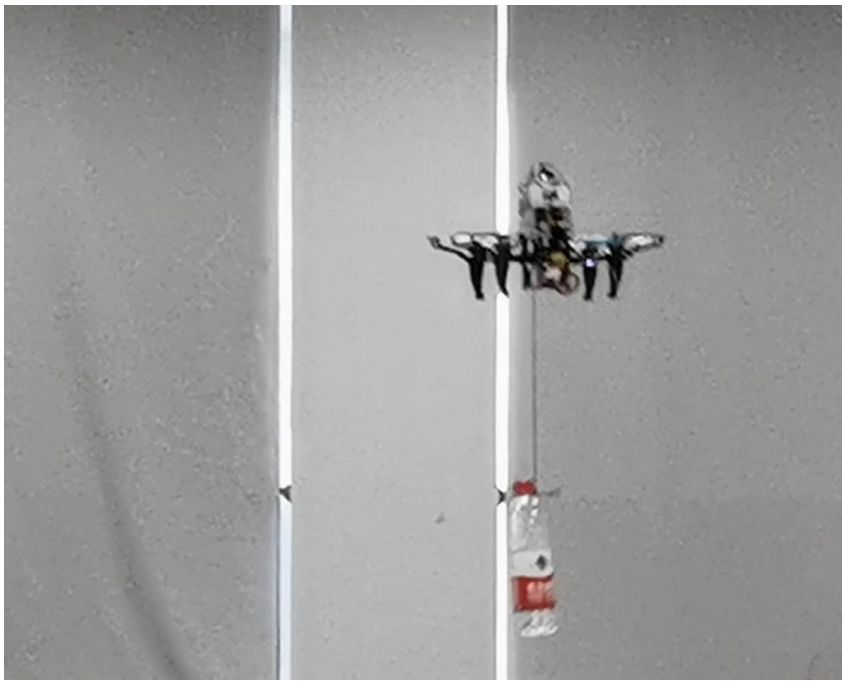


图 5-19 无人机进行抗扰实验的场景

Figure 5-19 Scene of a drone performing an immunity experiment

实验分析了挂载期间的无人机姿态变化，对图5-20的未知控制误差结果进行分析可知，控制器在捕捉到干扰后的约 30ms 内完成了调整，保证了位置和姿态的稳定。

中国知网　https://www.cnki.net

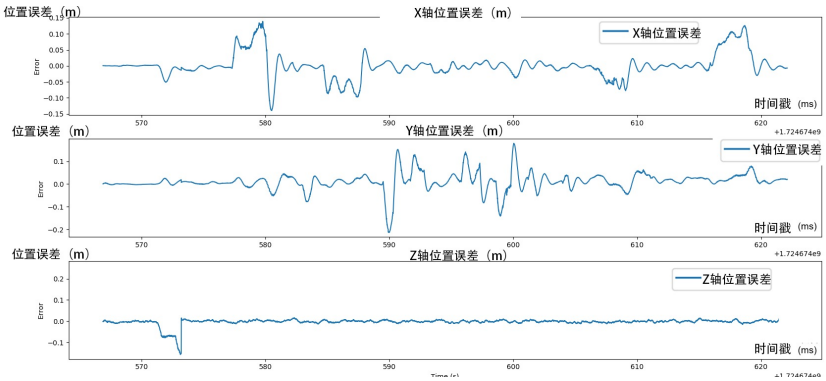


图 5-20 无人机在存在挂载干扰时的位置控制结果 (570ms 处出现扰动)

Figure 5-20 position control results in mounted disturb

5.4 消融和对比实验分析

无人机平台的算力有效，需对每个环节中关键子模型算法的性能开销进行对比实验或消融实验。本小节针对 MoE-SAC 算法的能耗估计和时间分配专家算法和分层强化学习的层间反馈机制等进行了相应的对比实验，证明了各个组件的有效性。

5.4.1 能量预测网络的架构合理性消融实验

实验比较了去除空间约束网络 Net_p、运动学预测网络 Net_{kn} 和混合网络 Net_{mix} 时的精度影响，并对神经网络的模型进行更换，测试其网络结构的合理性。具体而言，当去除空间约束网络 Net_p 或运动学预测网络 Net_{kn} 时，混合网络 Net_{mix} 一侧的输入使用 0 代替；当去除混合网络 Net_{mix} 时，使用运动学预测网络 Net_{kn} 和混合网络 Net_{mix} 相加的结果表示网络预测结果；当更换深度神经网络的模型时，比较了 CNN 卷积模型和编解码器两种网络。

在对上述网络进行训练、部署测试之后，得到的结果如表5-5所示，CNN 卷积和深度神经网络在预测能量时具有相似的推理效果；而编码器-解码器结构由于结构复杂，对算力要求高，并不适合对能量消耗进行预测的场景。同时可以发现在对网络中的部分网络进行去除之后，网络性能都有不同程度的倒退，尽管其运行速度更快了，但是运算精度会降低，由此可知，本方法对网络架构的选取合适且效率较高。

中国知网 https://www.cnki.net

表 5-5 能量预测网络消融实验结果

Table 5-5 Ablation Study Results of the Energy Prediction Network

网络变体	平均百分比误差 (%)	平均推理时间 (ms)	乘加操作数 (MACs)
原模型	4%	6.2	58.6G
无 Net_{kn}	20.3%	4.3	33.9G
无 Net_{p}	15.2%	3.0	27.4G
无 Net_{mix}	11.2%	5.5	55.4G
CNN 模型	9.0%	8.2	56.3G
Encoder-Decoder 模型	6.6%	64.7	232.8G

5.4.2 层间反馈机制消融实验

本研究测试了反馈机制关闭后无人机的参数情况，具体而言，实验将层间反馈机制的缓存区和轨迹稳定性专家网络的经验回放池进行关闭，然后测试了轨迹的速度、加速度、角速度、角加速度的边界值，然后通过无人机实验飞行测试了无人机的运动误差。最终得到无人机的轨迹边界参数如图5-6所示，不难发现由于没有层间反馈，造成无人机的估计边界参数存在偏高，这是因为规划层对控制器和无人机模型的掌控了解能力变弱造成的，无法根据控制器的实时情况进行参数调整。

表 5-6 层间反馈消融结果

Table 5-6 Interlayer feedback ablation results

轨迹参数	有反馈机制		无反馈机制	
	最大值	最小值	最大值	最小值
速度	$10.45m/s$	$-10.3m/s$	$13.5m/s$	$-0.5m/s$
加速度	$11.34m/s^2$	$-11.03m/s^2$	$-11.53m/s^2$	$-11.03m/s^2$
角速度	$0.15rads/s$	$-0.15rads/s$	$0.21rads/s$	$-0.16rads/s$
角加速度	$0.25rads/s^2$	$-0.22rads/s^2$	$0.3rads/s^2$	$-0.25rads/s^2$

同样地，通过查看控制器的控制误差，也可以了解层间反馈机制的作用，实验测定了在实物条件下，去除层间反馈后控制器的速度误差分布。对比图5-21和图5-18中带有反馈机制的速度控制误差分布，不难发现其控制误差的散步更大，平均误差值也更大，不难得出结论，反馈机制使得规划控制算法减少了 50% 的误差。

中国知网　https://www.cnki.net

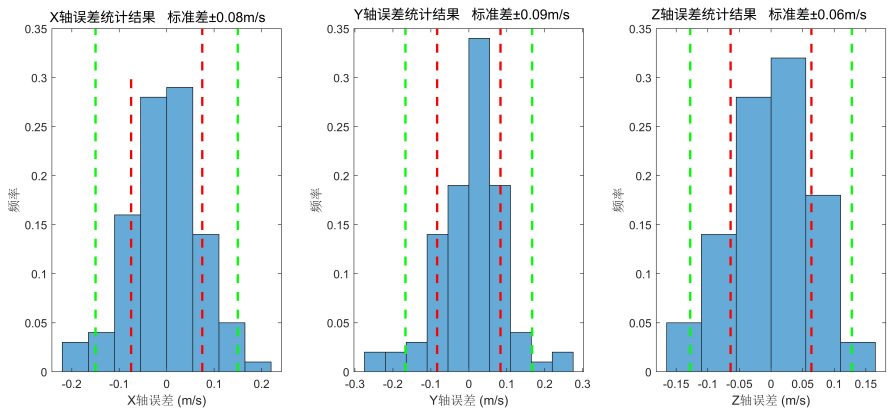


图 5-21 去除反馈机制后控制器的速度误差分布

Figure 5-21 Control Error Distribution of the Proposed Method

综上所述，基于此可以证明分层强化学习的层间反馈机制对无人机的物理约束进行了学习，保证了轨迹满足无人机的运动学约束，同时也增加了规划算法对底层算法和模型的掌控能力，

5.4.3 网络模型算力需求分析

本研究的算法存在多个神经网络的组合，其存在大量的算力需求，无人机的实物模型使用了 Jetson Orin 系列机载电脑，其可以在 fp16 精度下提供约 40TOPS 的算力，本节实验测试了每个网络的算力需求、一轮推理时间、一轮在线训练时间。

表 5-7 不同子网络模型对算力的需求

Table 5-7 Computational power requirements for different subnetwork models

模型功能	算力需求	一轮推理时间	一轮训练时间
控制器 SAC 算法模型	47.31GFLOPS	5.5ms	23ms
MoE-SACS 算法模型	1.5TFLOPS	8ms	40ms
安全飞行走廊安全性预测	11.34GFLOPS	2.0ms	10ms
能耗-耗时预测网络	58.46GFLOPS	6.5ms	30ms
轨迹稳定性预测	400GFLOPS	5.1ms	22ms
合计	2.02TFLOPS	空缺	空缺

如表5-7所示，整个强化学习模型的推理算力需求约为 2TOPS，当前的机载电脑可以满足在线运行的算力需求。同时对于控制器和规划算法，其推理时间也能保证 200Hz 和 30Hz 的在线运行需求。

中国知网 https://www.cnki.net

5.4.4 MoE 框架对规划算法的性能改进验证

为了测试多专家算法这一改进对分层强化学习框架的改进效果，在实验过程中，将 MoE 算法的奖励值进行了移除，并对 SAC 规划算法进行了训练微调，最终进行了约 1000 组凸包内的轨迹生成测试。实验统计了原方法和去除专家网络算法的碰撞障碍次数、轨迹生成成功率、能耗情况，得到如表5.4.4所示的结果。根据表5.4.4中的结论，MoE 算法对规划算法的避障、能耗情况有较大的改进优化，对轨迹的成功率的影响不显著，多专家算法对分层强化学习算法的改进是有效的。

表 5-8 MoE 框架的消融对比实验

Table 5-8 Computational power requirements for different subnetwork models

算法框架	碰撞障碍次数	轨迹生成成功率	单次运行的平均能耗
含 MoE	1	99.2%	122
不含 MoE	26	97.8%	145

表中的平均能耗计算采用加加速度积分的形式进行计算。

5.5 系统集成：多机协同实验下的规划控制与动态避障

实验设计了系统综合集成实验，在仿真环境和实物环境下进行了多机实物动态避障实验。在已知地图的场景下，同时启动三台无人机，使其首先到达目标位置，然后打乱返回时的降落位置。无人机的现场执行回传结果如图5-22所示，实验过程中无人机可根据建图扫描结果和规划层的惩罚项自动进行规划。

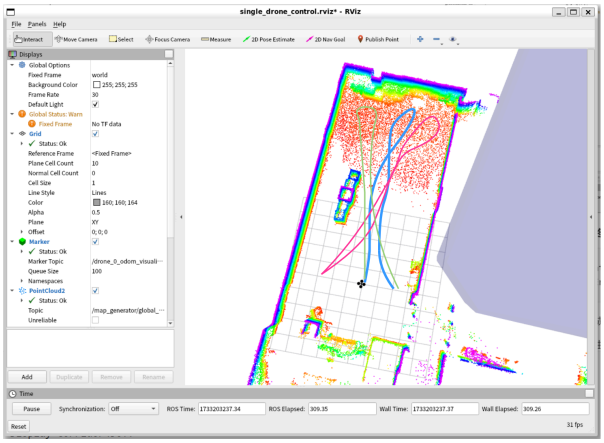


图 5-22 集成实验中无人机的自主避障规划结构

Figure 5-22 Autonomous Obstacle Avoidance Planning Architecture for UAVs in Integrated Experiments

中国知网　https://www.cnki.net

5.6 本章小结

本章节详细验证了本研究算法的多方面性能。首先介绍了实验的仿真平台和实物平台，然后对规划层的能耗情况、计算效率和网络估计的准确性进行了比较，同时对控制器的控制精度和抗干扰能力进行了测试，此外，通过消融实验，实验验证了能量估计网络的结构合理性和反馈结构的作用，最后实验测试在实际应用场景中的模型算力需求、避障能力和功能集成后的整体效果。

经实验统计和实验结果证明，本研究提出的算法在各个场景的表现如下：

（1）在规划算法层面，本研究的能耗估计网络能够以 10% 的误差进行无人机能效预测；MoE-SAC 规划算法的能效表现优秀，相较于 MINCO 轨迹类的生成方法，同耗时下可节约平均 6% 的能量消耗；凭借动态规划算法对最优时间分配方案的求解，同能耗下相比 MINCO 轨迹类节约 30% 的运行时间；在求解轨迹的计算效率上，基于能耗预测和动态规划的方案也大大降低了求解难度，使得轨迹规划算法的求解收敛时间平均减少 40%；对于带有能耗限制的轨迹规划问题，本方法的求解成功率约为 98%，相比于传统方法在稳定性上有较大进步。

（2）在控制性能方面，本研究提出的基于 SAC 的跟踪控制算法保证了无人机的性能不会随着无人机的电池电压而发生显著变化；和 ADRC 控制器相比，其速度控制误差降低 47%；同时控制器具有抗扰能力，在挂载非平衡负载时依然保持稳定。

（3）此外，通过层间反馈，使得无人机相较于没有层间反馈机制的规划控制方案减少了 50% 的运动误差。

中国知网 https://www.cnki.net

第六章　结论与展望

6.1 研究总结

本文针对复杂环境下四旋翼无人机的自主规划与控制难题，提出了一种基于分层元强化学习的创新解决方案。通过理论推导、算法设计与多模态实验验证，主要取得以下成果：

（1）构建了规划层与控制层解耦的双层深度强化学习框架，其中规划层采用多专家软演员-评论家（MoE-SAC）算法，集成轨迹稳定性评估、飞行走廊规划、动态避障及能耗预测四个专家网络，解决了复杂场景下的规划控制问题。实验表明，该架构在能耗约束条件下的规划成果率达 98%，计算效率较 MINCO 轨迹类提高 40%。控制层通过一阶模型无关元学习（MAML）预训练的 SAC 控制器，实现了对复杂动力学特性的快速适应。实物平台测试显示，其姿态跟踪误差较比例积分微分（PID）控制器降低 47%，抗风扰恢复时间缩短至 100 毫秒。

（2）提出基于经验缓存池的层间信息交互方法，将控制器的实时跟踪误差、能耗特征等量化指标反馈至规划层，动态调整时间分配策略与轨迹参数化约束。

（3）设计了能量-耗时预测算法。该模型在时间分配任务中预测误差率低于 10%，使四旋翼无人机在复杂场景下的平均能耗降低 6%，平均耗时降低 30%，在传统方法的基础上作出了较大改进。

（4）搭建了 Isaac GYM 高保真仿真环境与实物无人机测试平台，经过多平台的多次测试。

本研究的将元学习与分层强化学习结合应用于四旋翼系统，通过 MAML 预训练与 MoE-SAC 规划器的协同设计，解决了传统 DRL 算法在复杂场景下的训练不稳定问题；建立基于微分平坦参数化的轨迹可达性证明框架，为强化学习生成的轨迹提供严格数学保障，弥补了数据驱动方法缺乏可解释性的缺陷；研发跨层反馈机制与能耗预测专家网络，实现了规划-控制闭环优化，使四旋翼无人机在能效比与实时性指标上同步提升，为资源受限场景下的工程部署奠定基础。

6.2 研究局限性和未来工作展望

尽管取得上述成果，本研究仍存在以下局限：

中国知网　https://www.cnki.net

（1）环境感知依赖：当前系统假设障碍物信息可通过理想传感器获取，未考虑实际应用中点云噪声、通信延迟等干扰因素。融合视觉 SLAM 与强化学习，构建端到端的” 感知- 决策-控制” 流水线，减少对外部定位系统的依赖；设计对抗性训练策略，提升算法在传感器噪声、部分可观测场景下的鲁棒性将是未来的发展方向。

（2）学习类算法的不可解释性：现有的稳定性分析工具尚无法对强化学习类的方法进行严格说明，尝试引导的神经符号学习（Physics-informed Neuro-Symbolic Learning），将动力学方程作为约束嵌入 DRL 网络，增强模型可解释性是处理这一问题的可能思路。

（3）泛化能力未得到验证：训练数据集中于室内结构化环境，对野外未知地形的适应性尚未验证，研究四旋翼集群在密集动态障碍物中的自主避碰与编队控制；开发基于本文算法的四旋翼-机械臂协同系统，实现复杂工业环境下的抓取-运输一体化作业；探索极端环境（如强电磁干扰、高海拔低气压）下的算法适应性，推动其在灾害救援等领域的应用等等是未来自主无人机的发展方向，随着泛化能力的逐步验证，其应用面会逐渐拓展。

（4）经济性和实际应用的难题：使用高性能的计算平台和传感器系统可以使无人机完成相应的规划控制任务，但系统的整体经济性仍是一个需要考虑的问题。这一问题依然依赖高性能移动算力的普及，因此开发效率更为优秀的算法、通过产业发展降低系统整体成本是未来自主无人机发展过程中的必经之路。

本研究通过理论创新与工程实践的结合，推动了深度强化学习在四旋翼自主系统中的落地应用。未来，随着轻量化部署技术与跨模态感知能力的突破，所提框架有望成为智能无人系统共性技术平台的核心组件，为低空经济与智能装备产业的发展提供关键技术支撑。

中国知网 https://www.cnki.net

参考文献

[1] 牛轶峰, 刘天晴, 李杰, 等. 密集环境中无人机协同机动飞行运动规划方法综述[J]. 国防科技大学学报, 2022, 44(4): 1-12.

[2] 郭启敏, 张鹏, 王应洋, 等. 无人机自主航迹规划智能算法综述[J]. 航空兵器, 2023, 30(3): 29-40.

[3] 吕超, 李慕宸, 欧家骏. 基于分层深度强化学习的无人机混合路径规划[J]. 北京航空航天大学学报, 2023.

[4] 周毅, 马晓勇, 郜富晓, 等. 基于深度强化学习的无人机自主部署及能效优化策略[J]. 物联网学报, 2019(2): 9.

[5] 徐胤勃. 基于深度强化学习的旋翼无人机端到端伺服控制研究[D]. 国防科学技术大学, 2018.

[6] BOUABDALLAH S, MURRIERI P, SIEGWART R. Design and control of an indoor micro quadrotor[C]//Robotics and Automation, 2004. Proceedings. ICRA '04. 2004 IEEE International Conference on. 2004.

[7] YANG Y, ZHANG K, LIU D, et al. Autonomous uav navigation in dynamic environments with double deep q-networks[C]//2020 IEEE/AIAA 39th Digital Avionics Systems Conference (DASC). 2020.

[8] FURRER F, BURRI M, ACHTELIK M, et al. Rotors –a modular gazebo mav simulator framework[J]. Springer International Publishing, 2016.

[9] DONG M, SUN Z. A behavior-based architecture for unmanned aerial vehicles[C]// Intelligent Control, 2004. Proceedings of the 2004 IEEE International Symposium on. 2004.

[10] LOQUERCIO A, KAUFMANN E, RANFTL R, et al. Deep drone racing: From simulation to reality with domain randomization[J]. IEEE Transactions on Robotics, 2019, 36 (1): 1-14.

[11] SHEN G, LEI L, ZHANG X, et al. Multi-uav cooperative search based on reinforcement learning with a digital twin driven training framework[J/OL]. IEEE Transactions on Vehicular Technology, 2023, 72(7): 8354-8368. DOI: 10.1109/TVT.2023.3245120.

中国知网 https://www.cnki.net

[12] CHEN J, LI S E, TOMIZUKA M. Interpretable end-to-end urban autonomous driving with latent deep reinforcement learning[J/OL]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(6): 5068-5078. DOI: 10.1109/TITS.2020.3046646.

[13] PATEL S, SARABAKHA A, KIRCALI D, et al. An intelligent hybrid artificial neural network-based approach for control of aerial robots[J]. Journal of Intelligent & Robotic Systems, 2020, 97(2): 387-398.

[14] MCENROE P, WANG S, LIYANAGE M. A survey on the convergence of edge computing and ai for uavs: Opportunities and challenges[J]. IEEE Internet of Things Journal, 2022, 9(17): 15435-15459.

[15] BOROUJERDIAN B, GENC H, KRISHNAN S, et al. Mavbench: Micro aerial vehicle benchmarking[C]//2018 51st annual IEEE/ACM international symposium on microarchitecture (MICRO). IEEE, 2018: 894-907.

[16] KARAMAN S, FRAZZOLI E. Sampling-based algorithms for optimal motion planning [J]. The international journal of robotics research, 2011, 30(7): 846-894.

[17] WEBB D J, BERG J V D. Kinodynamic rrt*: Optimal motion planning for systems with linear differential constraints[A]. 2012.

[18] LIU M. Robotic online path planning on point cloud[J]. IEEE transactions on cybernetics, 2015, 46(5): 1217-1228.

[19] ZHANG S, XU T, CHENG H, et al. Collision avoidance of fixed-wing uavs in dynamic environments based on spline-rrt and velocity obstacle[C]//2020 International Conference on Unmanned Aircraft Systems (ICUAS). IEEE, 2020: 48-58.

[20] DEITS R, TEDRAKE R. Computing large convex regions of obstacle-free space through semidefinite programming[C]//Algorithmic Foundations of Robotics XI: Selected Contributions of the Eleventh International Workshop on the Algorithmic Foundations of Robotics. Springer, 2015: 109-124.

[21] VAN NIEUWSTADT M J, MURRAY R M. Real-time trajectory generation for differentially flat systems[J]. International Journal of Robust and Nonlinear Control: IFAC-Affiliated Journal, 1998, 8(11): 995-1020.

中国知网 https://www.cnki.net

[22] BO N, LI X, DAI J, et al. A hierarchical optimization strategy of trajectory planning for multi-uavs[C]//2017 9th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC): Vol. 1. IEEE, 2017: 294-298.

[23] USENKO V, VON STUMBERG L, PANGERCIC A, et al. Real-time trajectory replanning for mavs using uniform b-splines and a 3d circular buffer[C]//2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2017: 215-222.

[24] YUE W, ZHOU Y, ZHANG X, et al. Asymmetric actor-critic for adapting to changing environments in reinforcement learning[C]//International Conference on Artificial Neural Networks. Springer, 2024: 325-339.

[25] SEVER G G, DEMIR U, SATIR A S, et al. An integrated imitation and reinforcement learning methodology for robust agile aircraft control with limited pilot demonstration data[J]. Aerospace Science and Technology, 2025, 158: 109682.

[26] YEL E, BEZZO N. A meta-learning-based trajectory tracking framework for uavs under degraded conditions[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2021: 6884-6890.

[27] CARLOS B B, SARTOR T, ZANELLI A, et al. An efficient real-time nmpc for quadrotor position control under communication time-delay[C]//2020 16th International Conference on Control, Automation, Robotics and Vision (ICARCV). IEEE, 2020: 982-989.

[28] LANDRY B, DEITS R, FLORENCE P R, et al. Aggressive quadrotor flight through cluttered environments using mixed integer programming[C]//2016 IEEE international conference on robotics and automation (ICRA). IEEE, 2016: 1469-1475.

[29] SHAO X, SUN G, YAO W, et al. Adaptive sliding mode control for quadrotor uavs with input saturation[J]. IEEE/ASME Transactions on Mechatronics, 2021, 27(3): 1498-1509.

[30] KOCH W, MANCUSO R, WEST R, et al. Reinforcement learning for uav attitude control [J]. ACM Transactions on Cyber-Physical Systems, 2019, 3(2): 1-21.

[31] WU S, XU W, WANG F, et al. Distributed federated deep reinforcement learning based trajectory optimization for air-ground cooperative emergency networks[J]. IEEE Transactions on Vehicular Technology, 2022, 71(8): 9107-9112.

中国知网 https://www.cnki.net

[32] CHEN J, HUANG B, LI J, et al. Learning spatio-temporal attention based siamese network for tracking uavs in the wild[J]. Remote Sensing, 2022, 14(8): 1797.

[33] LE V A, MALIKOPOULOS A A. Controller adaptation via learning solutions of contextual bayesian optimization[A]. 2024.

[34] JI X, CAI Z. Disturbance rejection trajectory tracking control for an unmanned quadrotor based on hybrid controllers[J]. Journal of Robotics, 2021, 2021(1): 5216472.

[35] HUBER J, HÉLÉNON F, WATRELOT H, et al. Domain randomization for sim2real transfer of automatically generated grasping datasets[C]//2024 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2024: 4112-4118.

[36] TAN J, ZHANG T, COUMANS E, et al. Sim-to-real: Learning agile locomotion for quadruped robots[A]. 2018.

[37] CHEN S, LIU G, ZHOU Z, et al. Robust multi-agent reinforcement learning method based on adversarial domain randomization for real-world dual-uav cooperation[J]. IEEE Transactions on Intelligent Vehicles, 2023, 9(1): 1615-1627.

[38] DAN H, JOHN Q, DAVID B, et al. Distributed prioritized experience replay[C]//Proc. 5th Int. Conf. Learning Representations (ICLR, Vancouver, BC, Canada, 2018). 2018.

[39] WANG M, JIA S, NIU Y, et al. Agile flights through a moving narrow gap for quadrotors using adaptive curriculum learning[J]. IEEE Transactions on Intelligent Vehicles, 2024.

[40] SUN Q, LIU Y, CHEN Z, et al. Meta-transfer learning through hard tasks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 44(3): 1443-1456.

[41] LIU Z, CAO Y, CHEN J, et al. A hierarchical reinforcement learning algorithm based on attention mechanism for uav autonomous navigation[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 24(11): 13309-13320.

[42] EMAM Y, NOTOMISTA G, GLOTFELTER P, et al. Safe reinforcement learning using robust control barrier functions[J]. IEEE Robotics and Automation Letters, 2022.

[43] DUAN A, YANG C, ZHAO J, et al. Safe learning by constraint-aware policy optimization for robotic ultrasound imaging[J]. IEEE Transactions on Automation Science and Engineering, 2024.

中国知网 https://www.cnki.net

[44] MELLINGER D, KUMAR V. Minimum snap trajectory generation and control for quadrotors[M]//IEEE International Conference on Robotics and Automation. 2011.

[45] LIU S, WATTERSON M, MOHTA K, et al. Planning dynamically feasible trajectories for quadrotors using safe flight corridors in 3-d complex environments[J]. IEEE Robotics & Automation Letters, 2017: 1-1.

[46] WANG Z, ZHOU X, XU C, et al. Geometrically constrained trajectory optimization for multicopters[J/OL]. IEEE Transactions on Robotics, 2022, 38(5): 3259-3278. DOI: 10.1109/TRO.2022.3160022.

[47] FAESSLER M, FRANCHI A, SCARAMUZZA D. Differential flatness of quadrotor dynamics subject to rotor drag for accurate tracking of high-speed trajectories[J/OL]. IEEE Robotics and Automation Letters, 2018, 3(2): 620-626. DOI: 10.1109/LRA.2017.2776353.

[48] KAUFMANN E, LOQUERCIO A, RANFTL R, et al. Deep drone acrobatics[C/OL]// Proceedings of Robotics: Science and Systems. Corvalis, Oregon, USA, 2020. DOI: 10.15607/RSS.2020.XVI.040.

[49] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[Z]. 2017.

[50] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[M]//Deep Reinforcement Learning Symposium. 2017.

[51] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[Z]. 2017.

[52] LI J, YANG G, CAI Q, et al. Cooperative navigation for uavs in gnss-denied area based on optimized belief propagation[J]. Measurement, 2022, 192: 110797.

中国知网 https://www.cnki.net





中国知网 https://www.cnki.net