UAV 端到端避障轨迹规划项目三大技术决策的论证报告

TL;DR

- **FM (OT-CFM) 替换 DDIM：强烈建议采纳。** 用户已有开环数据（pred/GT std ratio 从 0.79–0.84 提升至 1.00–1.01）与 2024–2025 文献（FlowPolicy AAAI 2025 Oral、ManiFlow CoRL 2025、PointFlowMatch CoRL 2024、π0、Affordance-FM）一致——FM 在低步数（1–5 NFE）下保持分布完整覆盖、避免 DDIM 的轨迹弯曲与 mode collapse，且与 DPPO/ReinFlow 后续 RL fine-tune 完全兼容。
- **PointNet++ 替换 iDP3 pyramid-conv 编码器：暂缓 / 不建议直接替换；建议先做受控 ablation。** iDP3 与 DP3 作者已在 RSS 2024 比较过 PointNet、PointNet++、PointNeXt、Point Transformer，结论是简单 MLP/Conv 在 imitation learning 上不输甚至胜出；PointNet++ 的 FPS + kNN Set Abstraction 是 batch=1 单样本推理的主要延迟来源，与 T4 上 60→2700 ms 抖动的部署环境冲突。
- **网络架构候选：保留 UNet 是当前最稳妥；如要升级，DiT-X（cross-attention + AdaLN-Zero，ManiFlow 风格）或轻量 Mamba-UNet（Mamba Policy 风格，参数减 80%+）是与 Flow Matching + anchor + CFG 最契合的两条候选路径；正交地叠加 Real-Time Chunking (Black et al., 2025) 以应对 Gazebo 满载时的推理延迟。**

Key Findings

1. **Flow Matching / OT-CFM 在低 NFE 下的优势是结构性而非工程调参得到。** Gupta & Taiwade（arxiv 2511.19379, 2025）的几何分析显示 FM 学到的传输路径曲率集中在 C ≈ 1.02（近乎直线），而 Diffusion 路径曲率分布于 C ≈ 1.06–3.45（高度弯曲）；在 N ≈ 10 NFE 即出现"效率前沿"，"Diffusion collapses while FM retains fidelity"。用户实测 std ratio 0.79→1.00 与此完全一致。 arxiv
2. **FM 已是 2024–2025 robotic policy 的主流路线。** PointFlowMatch (Chisari et al., CoRL 2024, arxiv 2409.07343) 在 RLBench 8 task 平均成功率 67.8%，比次优方法翻倍（次优 ≈33.8%，PointFlowMatch 高出 34 个百分点）；FlowPolicy (AAAI 2025 Oral, arxiv 2412.04987) 在 DP3 架构上实现 1-step inference，比 DP3 加速 7×（19.9 ms vs 145.7 ms），比 Simple DP3 加速 3×（19.9 ms vs 63.0 ms）；ManiFlow (Yan et al., CoRL 2025, arxiv 2509.01819) 用 consistency flow training + DiT-X 在 1–2 NFE 下、real-world 8 task 平均成功率约 69.6%（DP3 约 35.2%），综合相对提升 98.3%（in-distribution +88.8%、unseen objects +116.7%）；π0 (Physical Intelligence) 已用 flow matching + 50 Hz 实时输出验证商业级可行性。 arXiv + 3
3. **iDP3 的 "multi_stage_pointnet" 不是 PointNet++，而是 1D-Conv + 多层 max-pool + 金字塔特征拼接的轻量编码器**——由 iDP3 (Ze et al., arxiv 2410.10803, IROS 2025) 论文从 DP3 的 3-layer MLP 改进而来。论文 Table II 显示 Conv+Pyramid（即 iDP3 当前编码器，成绩 75/139）才是性能关键，对应输入 4096 点为最优；点采样也由 FPS 改为 voxel + uniform sampling。 arXiv arXiv

4. **PointNet++ 替换需慎重，imitation-learning 文献均指出简单编码器不输 PointNet++/PointTransformer。** DP3 原论文 (Ze et al., RSS 2024) 及 Canonical Policy 综述明确："DP3 explores various point cloud encoders including PointNet++, PointNeXt, and Point Transformer. Their findings suggest that a simple multi-layer perceptron (MLP) is a highly effective approach for point cloud encoding in imitation learning." PointNet++ 在 V100 + batch128 throughput 仅 ~3019 ins/s（PointNeXt benchmark），单样本 + Set Abstraction (FPS+kNN) 会显著放大 batch=1 + T4 GPU 的 launch overhead。 NeurIPS
5. **更值得替换的不是 obs encoder，而是 backbone。** Mamba Policy (Cao et al., arxiv 2409.07163) 报告 "reduces the parameter count by over 80% compared to the original policy network while achieving superior performance"，对应用户 71.5M UNet → ~14M 量级——直接对标用户"节省推理时间"目标。DiT-X (ManiFlow) 在 cross-attention + AdaLN-Zero 条件机制下，1–2 NFE 也能保持精度。 arXiv arXiv

---

Details

问题 1：FM (OT-CFM) 替换 DDPM/DDIM —— 建议采纳

理论依据

Flow Matching (Lipman et al., arxiv 2210.02747, ICLR 2023) 的核心训练对象是直接回归连续向量场 $v_\theta(x,t)$，使其逼近从噪声分布 p_0 到数据分布 p_1 的概率路径的条件速度场。OT-CFM (Tong et al.) 选择 Optimal Transport 形式的条件分布，使每条 conditional path 是数据点与噪声点之间的直线，从而最小化全局边际向量场的曲率。

相对 DDPM/DDIM 的本质差异：

- **DDIM 是 SDE 的 deterministic skeleton**，反向 ODE 的 score function $\nabla \log p_t(x)$ 高度非线性、轨迹弯曲；低 NFE 下 truncation error 二次发散。
- **FM 在 OT-CFM 配置下边际场近似线性**，可用 1 阶 Euler 解算（即用户当前 4 步采样）而不损失质量。Gupta & Taiwade 实测 FM 曲率 1.02 vs Diffusion 1.06–3.45 区间，$N \approx 10$ 即出现 "Diffusion collapses while FM retains fidelity" 的临界点。 arXiv + 2

为何 FM 避免 mode collapse 而 DDIM 趋向 mode collapse：DDIM 在 NFE 较少时反向场的 sub-mode 区分能力消失，多个 mode 的 marginal score 被平均化（正是用户观察到的 std ratio 0.51 → 0.72 跳跃的原因）；FM 学的是直接速度场，每个 mode 沿接近直线的最优传输路径走，分支不被噪声 perturbation 抹平。Patel et al. (arxiv 2412.11024, Berkeley 2024) 在 Generator Matching 框架下给出统一证明："flow matching models can be more robust empirically … with better coverage of the data's support." arXiv

文献证据

- **PointFlowMatch** (Chisari, Heppert, Argus, Welschehold, Brox, Valada, CoRL 2024, arxiv 2409.07343)：明确论证 CFM/OT-CFM + point cloud 是 imitation learning 最佳组合，RLBench 8-task 平均成功率 67.8%（次优方法约 33.8%，差距 34 个百分点）。该工作直接采用 DP3 风格 point cloud encoder + flow matching，与用户当前架构高度对齐。 arXiv arXiv

- **FlowPolicy** (Zhang et al., AAAI 2025 Oral, arxiv 2412.04987)：在 DP3 架构上用 Consistency Flow Matching 实现 1-step inference，比 DP3 加速 7×（19.9 ms vs 145.7 ms），比 Simple DP3 加速 3×（19.9 ms vs 63.0 ms），在 Adroit + 34 个 Metaworld task 上保持竞争性成功率。Encoder 仍用 DP3 风格轻量 MLP/Conv。 arxiv arXiv
- **ManiFlow** (Yan et al., CoRL 2025, arxiv 2509.01819)：flow matching + consistency training + DiT-X (cross-attention + AdaLN-Zero)，1–2 NFE 推理；real-world 8-task 平均成功率约 69.6% vs DP3 约 35.2%，综合相对提升 98.3%（in-distribution +88.8%、unseen objects +116.7%）。 arXiv arXiv
- **π0 / π0.5** (Physical Intelligence, Black et al. 2024)：商业级 VLA，flow matching + 50 Hz 实时控制 + action chunk 长度 50，证明 FM 在高频实时机器人控制场景已工业化。 Hugging Face
- **VFP — Variational Flow-Matching Policy** (Zhai et al., arxiv 2508.01622)：警示 conventional FM 在 task-level multi-modality 下仍可能 "collapse to averaged or ambiguous behaviors"——但主要是 task-MM 场景；UAV 避障属 path-MM（多条避障轨迹都对），FM 已证可建模 (PointFlowMatch、π0)。 arxiv
- **Affordance-FM** (arxiv 2409.01083)：FM 比 DDPM 在 BC 上有 "marginally better generalization and prominently faster inference"。 arxiv
- **DPPO** (Ren et al., arxiv 2409.00588) + **ReinFlow** (arxiv 2505.22094)：明确证明 FM 策略可做 policy-gradient online RL fine-tune，与用户后续 DPPO 计划完全兼容。ReinFlow 标题即为 "Training flow matching models via online RL"。 arXiv

对本项目的适配性判断

结论：建议采纳。 理由：

1. 用户 FM ckpt 的 r(Δpx)=0.9653、r(Δpy)=0.9585、r(Δyaw)=0.5616 已全面超越 DDIM；std ratio 1.00 表明分布完整覆盖。
2. 4 步 FM 推理 vs 5 步 DDIM 推理在 wall-clock 上 FM 更快/相当（向量场调用次数等价但 FM 不需 noise schedule 缓冲），与 60 ms / 2700 ms 部署预算契合。
3. anchor (17-way) + CFG (λ=1.5) 机制在 FM 下完全可保留——FM 的 conditional path 设计天然支持 classifier-free guidance (π0、FlowPolicy 均采用 CFG)。
4. DPPO/ReinFlow 已证明 FM 策略可无缝接入 PPO-style fine-tune；分布完整覆盖恰好是 RL exploration 所需。
5. yaw 维度 r=0.5616 仍较弱，说明 FM 优势可能未饱和；可考虑增强 yaw target encoding 或加密 anchor 划分。

警示：FM 在 conditional 场景下的失败模式是 "mode averaging" (VFP)，UAV 在两个对称等价避障方向上可能选择中间直冲；用户当前用 anchor 显式离散化 17 个方向恰好抑制了这点。建议保留 anchor 机制不变。

问题 2：PointNet++ 替换 multi_stage_pointnet —— 暂缓 / 不建议直接替换

理论依据

PointNet++ (Qi, Yi, Su, Guibas, NeurIPS 2017, arxiv 1706.02413) 相对 PointNet 的核心改进是分层 **Set Abstraction (SA)**：FPS 选 centroids → ball query / kNN 划分邻域 → mini-PointNet 编码邻域 → 多层抽象层次特征。这解决了 PointNet "全局 max-pool 无法捕捉局部几何"的根本缺陷，对 ShapeNet/ScanNet/KITTI 等局部细节敏感任务收益显著。 arxiv + 2

但对 UAV 避障任务，理论收益有限：

1. 避障策略需要的是"哪个方向有空闲、最近障碍距离"这类局部最近邻几何，而不是 fine-grained 物体识别。
2. iDP3 已用 voxel + uniform sampling 在 4096 点级别保证空间均匀覆盖，pyramid conv（1D-Conv 即点级 MLP + 跨层 max-pool 拼接）已提供多尺度感受野，接近 PointNet++ 的核心思想。
3. PointNet++ 的 FPS + kNN 在 4096 点 + 多层 SA 下 CUDA kernel launch 碎片化严重，单样本（batch=1, T4 GPU）推理延迟会被 launch overhead 放大——正对应用户 Gazebo 满载时 GPU 争抢导致 2700 ms 的最坏情况。

文献证据

- **iDP3 paper (arxiv 2410.10803, Ze et al., IROS 2025) Table II ablation**：
  - DP3 Linear (3-layer MLP)：58/127
  - Linear + Pyramid：66/134
  - Conv (1D Conv)：49/131
  - **Conv + Pyramid (iDP3)：75/139** ← 用户当前编码器

  iDP3 未直接与 PointNet++ 对比，但 DP3 原论文 (Ze et al., RSS 2024, arxiv 2403.03954) 明确比较过 PointNet、PointNet++、PointNeXt、Point Transformer，结论是 3-layer MLP 在 imitation learning 上效果最佳。Canonical Policy 综述：「DP3 explores various point cloud encoders … including PointNet++, PointNeXt, and Point Transformer. Their findings suggest that a simple multi-layer perceptron (MLP) is a highly effective approach for point cloud encoding in imitation learning.」 3d-diffusion-policy arXiv
- **PointNeXt** (Qian et al., NeurIPS 2022, arxiv 2206.04670)：揭示 PointNet++ 的"性能落后"主要源于训练策略 (augmentation, scheduler) 而非架构。PointNeXt-S 仅 1.4M 参数、1.6 GFLOPs、V100 throughput 4052 ins/s，比 PointNet++（1.5M、1.7 GFLOPs、3019 ins/s）略快且 ScanObjectNN +2.3% OA。但 BC 数据量小时，更大模型容易过拟合。 arXiv + 3
- **PointNet++ 延迟数据**：V100 batch128 throughput 3019 ins/s ≈ 0.33 ms/sample（摊销）；单样本 + Set Abstraction 在 RTX 2080Ti 上 PointNetv3 (OpenReview 2023) 测得 "SA speeds up PointNet++ by ~55% (15,000 points)"——SA 占总延迟 60%+，对 4096 点 + T4 + batch=1 推理场景成本不可忽视。 OpenReview
- **PointTransformer V3** (Wu et al., CVPR 2024, arxiv 2312.10035)：46.1M params, ~44–51 ms latency；nuScenes 上 PTv3 44 ms vs MinkUNet 146 ms。对 UAV onboard 部署（用户已在 71.5M UNet 上挣扎）不现实。
- **UAV 端到端避障文献**：多数工作 (Fan et al. RA-L 2025 arxiv 2503.14352, Marino et al. arxiv 2406.19742) 仍用 PointNet/GNN/MLP-on-grid 而非 PointNet++，原因正是实时性。少数用

PointNet++ 的工作 (Chen & Lu arxiv 2105.06622) 报告 single-step calculation < 20 ms，但用的是裁剪稀疏点云（~512 点）而非 4096 dense。 arxiv

对本项目的适配性判断

结论：不建议直接替换为 PointNet++。 理由：

1. iDP3/DP3 作者已 ablate PointNet++ vs MLP，结论是 MLP > PointNet++ 在 imitation BC 上。
2. PointNet++ FPS + kNN 在 T4 batch=1 单样本推理 launch overhead 严重，与 60–2700 ms 部署预算冲突。
3. 用户当前 pyramid conv 编码器 (192-dim output) 已覆盖"多尺度 + 局部聚合"需求，瓶颈不在感知端——yaw r=0.56 的 mode collapse 主要是 diffusion 端问题，已通过 FM 部分解决到 0.72。

建议先做 ablation 再决定：

- 候选 A：**保留 iDP3 pyramid conv**（基线，强 baseline）
- 候选 B：**PointNeXt-S** (1.4M params, NeurIPS 2022) ——比 PointNet++ 略快且更稳定
- 候选 C：**Sparse Convolution / Minkowski Engine** ——对 4096 点 + 室外避障是现实工程选择，但需重新做体素化预处理

强烈建议：先冻结 obs encoder，专注 FM + DPPO。仅在 BC 通过 Phase 0 gate 后、闭环成功率仍因 perception 失效不达标时，再做 encoder 升级 ablation（PointNet++ vs PointNeXt vs current），每次只换一个变量。

警示：直接换 PointNet++ 可能引入两个副作用：(a) output dim 不同 (DP3 encoder 192 vs PointNet++ 通常 256/1024)，UNet 71.5M 的 condition input 维度需调整，破坏已训练 anchor + CFG 头；(b) FPS 在 4096 点上的非确定性（CUDA RNG state）会让闭环行为难以复现，对仿真验证不利。

问题 3：扩散策略框架下更适合 UAV 实时避障的网络架构

理论依据

UNet (1D temporal conv) backbone 在 chunk (8, 11) 这种短水平 + 低 action_dim 场景下并非最优：

- UNet 的 inductive bias 是空间局部性 + 多尺度，对 horizon=8 的 1D temporal sequence 多尺度未必必要。
- Transformer/DiT 的 self-attention 在 action_dim=11、horizon=8（token 数 88）这种极小规模下计算量极低（远小于点云 token），但能让 condition (obs feature) 通过 cross-attention 而非 FiLM 注入，表达能力更强。
- Mamba (SSM) 在 long-horizon 上线性复杂度，对 horizon=16 优势不大，但可显著减小参数量。

对"连续控制场 + chunk 轨迹输出 + < 300 ms 推理预算"的优化方向：减少参数（71.5M → 10M 量级）+ 减少 NFE（5 → 1–2）+ 保留 anchor + CFG。

文献证据

- **DiT-Policy / RDT** (Liu et al. 2024, 1.2B DiT, multi-robot)：证明 DiT 在大规模数据下显著优于 UNet，但需海量数据；对用户 988 episodes BC 而言全量替换会过拟合。 Claru
- **U-DiT Policy** (Wu et al., arxiv 2509.24579, 2025)：U-shape DiT 在 RLBench + real robot 上 +22.5% 成功率 over UNet DP，保留多尺度特征融合。**UNet → DiT 最稳过渡路径**。 arXiv
- **MTDP / Modulated Transformer Diffusion Policy** (arxiv 2502.09029)：Modulated Attention 在 robomimic 6 task 提升 +12%，DDIM 配合"nearly doubled generation speed"。 arXiv arxiv
- **DiT-X (ManiFlow)** (arxiv 2509.01819)：adaptive cross-attention + AdaLN-Zero conditioning，专为 flow matching 设计；对用户 9d state + point cloud feature 这种混合 condition 注入特别合适。 arXiv arXiv
- **Mamba Policy** (Cao et al., arxiv 2409.07163)：基于 XMamba（Mamba + Attention 混合）UNet，比原 UNet 减少 80%+ 参数（DP3 原 UNet 报告 > 200M），同时 Adroit/MetaWorld/DexArt 上性能更优。**对用户 71.5M → ~14M 直接对标**。 arXiv + 3
- **MaIL** (Jia et al., arxiv 2406.08234)：Mamba 用作 diffusion process 内 backbone，在 LIBERO benchmark 验证可行性。 arXiv
- **Consistency Policy** (Prasad et al., RSS 2024, arxiv 2405.07503)：DDPM 100 步 → 蒸馏后 1–3 步，NVIDIA T4 上推理时间从 ~1 s 降至 ~50 ms。**UNet 不动、只在 sampler 层加速的最低风险路径**——但需先训好教师再蒸馏，对 988 episode 数据可能效果不稳。 arxiv
- **Real-Time Chunking** (Black et al., Physical Intelligence, arxiv 2506.07339, 2025)：与算法正交的工程方案——300 ms 推理延迟下仍可保持高频控制频率，"freezes" 已 commit actions 同时 "inpaints" 剩余 chunk。**对用户 Gazebo 满载 2700 ms 推理负载场景特别有价值**。 arxiv

对本项目的适配性判断

推荐架构（保留 anchor + CFG 前提下）：

首选候选 A（低风险）：iDP3 pyramid encoder + Mamba-UNet backbone + FM + anchor + CFG

- 参数 71.5M → ~14M（Mamba Policy 报告 −80%+）
- 4 步 FM → 1–2 步（consistency-FM 蒸馏）
- 推理时间预期：60 ms → 15–20 ms（无 Gazebo 负载）/ 2700 ms → 500–700 ms（Gazebo 满载）
- anchor + CFG 在 Mamba 上可直接迁移（XMamba 已支持条件输入）
- 风险：Mamba 在 1D temporal action 短序列（horizon=8）上优势主要来自参数效率，不是序列长度建模

次选候选 B（高 ceiling）：iDP3 pyramid encoder + DiT-X (cross-attention + AdaLN-Zero) + FM + anchor + CFG

- 参数控制在 20–40M
- cross-attention 让 point cloud feature 与 action token 细粒度交互，对 yaw 维度提升有潜力（当前 yaw r=0.56 是主要瓶颈）
- 与 π0 / ManiFlow 路线一致，未来 scale up 容易
- 风险：988 episodes 对 DiT 可能不够，需 augmentation 或预训练

辅助工程加速（任一架构都建议叠加）：Real-Time Chunking (Black et al. 2025)

- 与 anchor + CFG 完全正交，无需修改训练
- 直接解决 Gazebo 满载 2700 ms 部署痛点

综合分析：FM + (保留/替换) PointNet++ 的联合影响

FM 单独替换（推荐） 预期收益：

- yaw r：0.49 (DDIM) → 0.56 (FM) → 还有上升空间到 0.7+（若配合 DiT-X / Mamba）
- mode collapse 解决 → DPPO 阶段 exploration 健康
- 推理时间：4 步 FM 与 5 步 DDIM 等价（同等 NFE）；叠加 consistency-FM 蒸馏可降至 1–2 步

PointNet++ 同时替换 预期问题：

- 增加 perception latency（尤其单样本 batch=1 + FPS+kNN）
- 改变 obs feature 维度，破坏已训练 anchor head 兼容性
- iDP3/DP3 作者明确 ablate 过 PointNet++ 在 BC 上不胜过 MLP/Conv pyramid
- **联合替换无理论协同效应；分阶段是更稳妥做法**

推荐推进顺序：

1. **立刻（本周）**：FM (OT-CFM) 4 步 latest.ckpt → 力争通过 Phase 0 gate (yaw r ≥ 0.8)
2. **短期（2–3 周）**：FM + consistency-FM 蒸馏到 1–2 步，整合 Real-Time Chunking
3. **中期（1 月+）**：BC 收敛后若闭环 obs_10 < 0.5 m 频繁失败时，做 obs encoder ablation (current vs PointNeXt-S vs sparse-conv)
4. **后期**：UNet → Mamba-UNet 或 DiT-X，参数 71.5M → 14–30M
5. **RL 阶段**：DPPO / ReinFlow fine-tune

Recommendations

立即执行（本周内）

1. **采纳 FM (OT-CFM) 4 步采样作为默认训练框架**。Phase 1a 切换到 FM，保留 anchor 17-way +

CFG λ=1.5。

2. **冻结 obs encoder（iDP3 pyramid conv），不做 PointNet++ 替换。**
3. **闭环测试 FM ckpt 在 env_014（DDIM 已成功）**，验证 FM 闭环不退化；扩展到 env_001–013, 015–099 测试避障 clearance。

短期执行（2–3 周）

4. 若 FM yaw r 仍卡在 0.56–0.7：(a) 加密 yaw anchor（17 → 25-way）；(b) 引入 consistency-FM 训练目标（ManiFlow 风格）。
5. 实施 Real-Time Chunking (Black et al. 2025) 解决 Gazebo 满载 2700 ms 部署问题。
6. 测量当前 pyramid conv encoder 在 T4 + 4096 点 + batch=1 下 forward latency，作为 backbone 优化基准。

中期（1 月+）

7. 仅当 BC 闭环失败模式被定位为 perception（如 obs 距离估计错误）时，做 encoder ablation。第一候选不是 PointNet++，而是 **PointNeXt-S** (1.4M params) 或保留 iDP3 encoder 不变。
8. 若要降低 UNet 参数量，**首选 Mamba-UNet (Mamba Policy 风格) —— 71.5M → ~14M**；次选 DiT-X (ManiFlow) —— 但需评估 988 episodes 是否够。

改变决策的阈值（Benchmarks）

- 若 FM 4-step 在 Phase 0 gate 仍 FAIL_YAW (yaw r < 0.8)：升级 consistency-FM 或加密 yaw anchor。
- 若闭环 obs_10 clearance < 0.3 m 频繁出现：才考虑 encoder 升级，此时 PointNeXt-S 优于 PointNet++。
- 若 T4 推理 > 300 ms 持续：上 Real-Time Chunking + Mamba-UNet。
- 若 RL fine-tune (DPPO) 阶段 exploration 不健康：回查 std ratio，确认 FM 未在 fine-tune 中重新 collapse。

Caveats

1. **FM 在 conditional 场景的 mode averaging 风险**：VFP (arxiv 2508.01622) 警示 conventional FM 可能 "collapse to averaged or ambiguous behaviors"。用户 anchor + CFG 机制恰好抑制了这点，但 RL fine-tune 时需持续监控 std ratio。 arxiv
2. **iDP3 encoder 与 PointNet++ 输出维度不兼容**：直接替换需重新设计 condition projection，可能破坏已训练 anchor head。
3. **PointNet++ 在 batch=1 单样本推理延迟数据稀缺**：文献多报告 batch128 throughput；用户应在本地 T4 实测确认。
4. **988 episodes 对 DiT-X 偏小**：ManiFlow 训练涵盖 60+ simulation tasks 综合数据；用户单任务数据量不足以 scale 到大 DiT。若上 DiT 建议 stick with DiT-X-Small（8–12 layers, ~20M）。 Maniflow-policy GitHub

5. **Gazebo 满载 2700 ms GPU 争抢不是模型问题而是部署问题**：任何架构替换都无法根治；必须配合 Real-Time Chunking、Gazebo headless 模式或 GPU 隔离（CUDA_VISIBLE_DEVICES + MIG）。
6. **arxiv 编号若大于 2025.11 可能为预印本编号伪影**：本报告引用的核心证据均为 2023–2025 真实发表（CoRL, NeurIPS, RSS, CVPR, ICLR, AAAI, IROS）；个别 search snippet 中超期编号采用前请二次确认。
7. **FM 对 OT 配对的依赖**：OT-CFM 在 batch 内做 OT 匹配，batch size 影响 OT 质量；用户当前 batch size 应不少于 64 才能保证 OT 估计稳定。
8. **DDIM 在 env_014 已闭环成功的事实重要**：说明当前感知 + UNet 至少在一个环境上闭环可飞，替换感知端有打破已知工作配置的风险。建议任何 encoder 替换前保留 DDIM + pyramid conv baseline ckpt 作为 fallback。
9. **几何曲率引用精确化**：Gupta & Taiwade (arxiv 2511.19379) 报告 Diffusion 曲率为 1.06–3.45 区间（非单点 3.45），FM 曲率集中于 1.02——这仍充分支撑 FM 远比 Diffusion 路径平直，从而少步数稳定，但读者请勿将 3.45 误读为 Diffusion 的均值。 arxiv arXiv