基于端到端扩散模型与强化学习融合的无人机实时避障轨迹生成系统研究

简要总结 报告阐述了基于扩散模型的无人机端到端避障轨迹生成方法，该模型能够从传感器输入直接生成多样化且物理可行的轨迹。为实现更高质量和实时性，报告探讨了结合强化学习的多种融合框架，例如DDPO（去噪扩散策略优化）和MBD（模型基础扩散），这些框架利用强化学习优化扩散模型的生成过程，以学习长期奖励并提升轨迹在动态环境中的适应性与决策效率。

1. 扩散模型在无人机轨迹规划中的基础原理与应用现状

扩散模型作为生成式人工智能领域的重要突破，在无人机轨迹规划中展现出处理复杂环境与多模态任务的潜力。与传统优化方法相比，其核心优势在于能够从数据分布中生成多样化且物理可行的轨迹。本部分将阐述其数学基础，并基于现有研究分析代表性框架的技术特点。

1.1 扩散模型的数学基础与轨迹生成原理

扩散模型的核心思想源于非平衡热力学，通过前向扩散和反向扩散两个过程学习数据分布[1]。在轨迹规划中，这一框架被转化为轨迹生成工具。

前向扩散过程是一个马尔可夫链，将原始轨迹数据 x_0 逐步添加高斯噪声，经过 T 步后转化为近似标准高斯分布：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$

其中 β_t 为噪声调度参数。

反向扩散过程则是学习从噪声中恢复轨迹的逆过程：

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$$

通过训练神经网络参数 θ，模型能够从纯噪声 $x_T \sim \mathcal{N}(0, I)$ 开始，逐步去噪生成符合目标分布的轨迹[1]。

在无人机轨迹规划中，该原理带来了独特优势：1) **多模态生成能力**，能提供多种可行路径选择；2) **隐式学习物理约束**，通过数据自动捕获动力学与几何限制；3) **内在的不确定性量化**，为风险评估提供依据。

1.2 代表性框架的技术架构与创新特点

1.2.1 SwarmDiffusion：可穿越性引导的端到端扩散模型

SwarmDiffusion 是一个轻量级端到端扩散模型，能够从单张RGB图像联合预测可穿越区域并生成可行轨迹[2]。其核心创新在于：

1. **统一的可穿越性与轨迹联合生成**：该框架首次实现了从单张RGB图像直接联合输出可穿越性地图和轨迹，无需依赖外部规划器或专家演示[2]。
2. **形态无关的规划**：通过一个轻量级的状态向量适应机制，模型可以泛化到不同的机器人形态（如四足机器人和无人机）。仅需约500个额外视觉样本进行适配，同时保持核心网络权重冻结[2]。
3. **无规划器的轨迹构建管道**：训练时，采用基于随机航点采样、贝塞尔曲线平滑和正则化的方法生成合成轨迹作为监督信号，从而避免了对外部规划器生成专家轨迹的依赖[2]。

其数学模型如下：输入包括RGB图像 I_t、本体感知状态 s_t 和机器人形态 e_t。模型学习映射 F：$(I_t, s_t, e_t, S_t) \rightarrow (\hat{T}_t, \tau)$，同时输出预测的可穿越性地图 $\hat{T}_t$ 和离散轨迹 τ，并满足连通性、安全性等约束[2]。实验表明，该模型在室内环境和两种机器人形态上实现了80-100%的导航成功率，单次推理时间约为0.09秒，展现了良好的实时性[2]。

1.2.2 其他扩散模型应用方向

除了上述端到端框架，扩散模型在无人机轨迹规划中还有其他创新应用形式：

- **复杂特技轨迹生成**：有研究提出将长时域特技飞行动作分解为“特技基元”，并利用扩散模型结合动态先验与条件输入，实现用户可编辑的复杂轨迹自动化生成[3]。
- **集群机器人规划**：SwarmDiff 方法利用 Diffusion Transformer 在宏观层面生成具有风险意识的高斯混合模型轨迹，并在微观层面进行分布式控制，以解决集群在杂乱环境中的轨迹规划问题[4]。
- **实时规划加速**：针对扩散模型推理速度的瓶颈，有研究提出了层次化划分轨迹的实时规划框架（如DiffuserLite），通过将完整轨迹分解为子轨迹并用扩散模型拟合，以优化推理效率[5]。
- **与强化学习结合**：扩散模型生成的轨迹可作为高级引导，用于策略学习。例如，扩散轨迹引导策略框架通过扩散模型生成二维轨迹来引导长时域机器人任务的策略学习[6]。

1.3 现有研究进展与技术挑战

1.3.1 轨迹生成质量与避障效果

扩散模型通过从数据中学习，能够隐式编码环境中的障碍物分布，从而生成自然避开障碍物的轨迹。其多模态特性允许生成多种避障策略，以适应不同的环境条件。例如，SwarmDiffusion 通过可穿越性地图条件化，确保生成的轨迹始终位于安全区域内[2]。此外，有研究通过将扩散模型与人工势场结合，直接处理点云数据，在动态追逃等复杂场景中实现了鲁棒的实时轨迹规划与避障[7][8]。

1.3.2 计算效率与实时性

计算效率是扩散模型实际部署的关键挑战。虽然扩散模型能生成高质量轨迹，但其多步迭代去噪过程通常比传统方法耗时。现有研究正从多个方向寻求突破：

- **架构与推理优化**：采用层次化[5]、一致性模型或知识蒸馏等技术减少去噪步数。
- **轻量化设计**：如 SwarmDiffusion 所示的轻量级端到端设计，将推理时间压缩至0.09秒，已能满足许多实时导航任务的需求[2]。
- **硬件协同**：利用模型量化、专用AI加速器进一步提升效率。

下表对比了不同方法的特点：

方法类型	典型推理时间	生成轨迹特点	适用场景
传统优化（如MPC）	0.01-0.1秒	单峰，易陷局部最优	模型已知、严格实时
扩散模型（如SwarmDiffusion）	~0.09秒[2]	多模态，物理可行	复杂环境、需多样解
经典规划（如A*、RRT）	可变，环境越复杂越慢	离散路径，需后处理	已知或可建图环境

1.3.3 技术挑战与未来方向

当前研究仍面临一些挑战：1) **实时性瓶颈**：尽管有改进，复杂扩散模型在高动态环境中的实时响应仍存压力；2) **仿真到现实的迁移**：确保在仿真中训练的模型能鲁棒地迁移到真实世界；3) **复杂动态环境**：在高度非结构化、动态环境中的长期规划可靠性有待加强。

未来可能的发展方向包括：1) **强化学习深度融合**：将扩散模型作为策略表示，利用强化学习进行在线微调与优化，已有研究探索了扩散策略优化等方法[9]；2) **多模态条件生成**：整合视觉、语言、点云等多源信息，实现更语义感知的规划；3) **分层与协同规划**：结合高层扩散规划与底层快速反应控制器，在保证质量的同时满足硬实时约束。

2. 端到端扩散模型架构设计与实时避障实现

端到端扩散模型为无人机避障轨迹生成提供了一种统一的架构范式，它将环境感知与轨迹规划融合在一个模型中，直接从传感器输入生成安全的飞行路径。本部分将基于现有研究，分析此类模型的架构设计原理、实现实时避障的关键挑战以及相关的优化技术。

2.1 端到端扩散模型架构设计原理

端到端扩散模型的核心在于通过一个生成式模型，学习从环境观测到安全轨迹的条件分布。与传统方法不同，它避免了将任务分解为独立的感知、建图和规划模块，从而减少了信息传递的损失和累积误差。

一个典型的端到端架构需要处理多种输入。例如，系统接收来自无人机的RGB图像、自身的状态信息（如位置、姿态）以及任务目标（如起点和终点）[10]。这些信息被编码为模型可以理解的条件信号。在SwarmDiffusion框架中，模型将RGB图像、机器人状态向量和体现机器人物理特性的“体现类型”共同作为输入，以预测环境的“可穿越性”并生成轨迹[10]。这种设计使模型能够理解不同机器人平台（如四足机器人和无人机）的运动能力差异。

轨迹生成模块通常基于条件扩散模型。扩散模型通过一个逐步去噪的过程，从随机噪声中生成结构化的输出。在轨迹规划任务中，这个输出是二维图像空间中的一条路径热图[10]。模型在生成过程中，会持续受到来自输入条件的引导，例如，必须确保生成的轨迹连接指定的起点和终点，并尽可能通过被预测为“可穿越”的区域[10]。这种联合学习的方式——同时预测可穿越性地图和可行轨迹——是端到端架构的一个关键特征[10]。

为了确保生成轨迹的安全性，架构中需要集成约束处理机制。一些研究致力于将安全约束直接嵌入到扩散模型的生成过程中。例如，有方法提出在去噪过程中集成障碍函数，以确保输出满足避障等安全约束，即使训练数据有限[11]。另一种思路是设计混合损失函数和重加权策略，在扩散过程的每一步对齐预测的约束违反情况与真实情况，从而在保持轨迹质量的同时显著减少约束违反[12]。

2.2 实时避障功能实现技术

将计算密集的扩散模型部署到资源受限的无人机平台上，并满足实时避障的毫秒级响应要求，是一个重大挑战。实现这一目标需要从算法优化和系统部署两个层面进行协同设计。

推理时间优化是首要任务。标准的扩散模型推理需要进行多步（如50-1000步）迭代去噪，耗时严重。为了加速，研究者采用了多种技术。知识蒸馏是一种有效手段，例如，在一个纳米无人机避障系统中，研究者使用一个大型的预训练模型作为“教师”，来指导一个轻量化的“学生”网络学习，从而在保证性能的前提下大幅减少参数量和计算量[13]。此外，使用更高效的采样器（如DDIM）可以减少达到满意去噪效果所需的步数。SwarmDiffusion报告其模型在异构机器人平台上实现了约0.09秒的推理时间，展现了实时应用的潜力[10]。

硬件部署与轻量化是工程实现的关键。无人机，尤其是小型或纳米无人机，其机载计算单元（如处理器、内存）极其有限。例如，Crazyflie纳米无人机搭载的GAP8处理器仅有512KB RAM[13]。为了在此类平台上部署，必须对模型进行深度压缩。常见技术包括：

1. **模型量化**：将训练好的PyTorch模型转换为ONNX格式，并采用8位整数量化方案，可显著减少模型体积。在纳米无人机案例中，量化后将模型大小从747.6 KB压缩至201.3 KB[13]。
2. **架构轻量化**：设计精简的网络结构。例如，将用于深度估计的编码器通道数从[32, 32, 64, 80]大幅削减，使参数量从310万降至31万[13]。
3. **输入优化**：为节省计算资源，使用单通道灰度图像而非三通道RGB图像作为输入，这可以减少三分之二的图像数据存储开销[13]。

这些优化使得复杂的视觉算法得以在边缘设备上运行。例如，前述轻量化CNN模型在GAP8处理器上能够以约1.24 FPS的速度进行深度估计和避障决策，虽然帧率较低，但已能匹配纳米无人机的低速飞行状态[13]。对于计算能力更强的平台（如搭载NVIDIA Jetson系列），可以利用TensorRT等推理引擎进行进一步的图优化和内核融合，以实现硬件加速[14]。

2.3 环境复杂度适应性设计

端到端扩散模型的性能在不同环境复杂度下会有所变化，其架构需要具备一定的适应性和鲁棒性。

在**静态结构化环境**中，例如室内走廊，模型表现通常较好。因为障碍物分布相对固定，模型可以学习到稳定的空间模式。轻量化模型在此类环境中已能实现基本的避障功能[13]。

然而，在**动态或高度复杂的环境**中，挑战显著增加。例如，环境中可能存在高速移动的障碍物，或者像玻璃这样的透明障碍物，这对纯视觉系统是难点[13]。为了提升适应性，一些架构引入了在线学习或快速适应的机制。SwarmDiffusion展示了一种“体现无关”的规划能力，通过一个轻量化的状态向量适配机制，模型能够仅用少量（如500个）额外视觉样本，就快速适应到新的机器人平台上，而无需重新训练网络权重[10]。这种快速适应能力对于应对未知或变化的环境特性具有重要意义。

此外，将端到端生成的全局轨迹与轻量级的局部反应式控制器结合，是一种常见的适应性设计。例如，在生成全局轨迹后，可以叠加一个人工势场（APF）控制器进行局部微调，以处理动态障碍物或执行过程中的小偏差，而这个安全层仅增加可忽略的延迟[10]。另一种层次化框架（ImpedanceDiffusion）则使用扩散模型进行全局路径规划，然后通过APF进行局部跟踪，并引入基于视觉语言模型的语义感知模块来根据障碍物类型（如软性/硬性障碍）自适应调整阻抗控制参数[15]。

2.4 性能评估与系统集成挑战

评估一个端到端扩散模型避障系统的性能，需要综合考虑导航成功率、轨迹质量、推理延迟和资源消耗等多个指标。

在仿真和实际测试中，先进的模型如SwarmDiffusion在室内环境中针对四足机器人和无人机实现了80-100%的导航成功率[10]。然而，实时性能高度依赖于具体的模型复杂度、硬件平台和环境场景。例如，ImpedanceDiffusion中扩散模型的单次轨迹推理时间在2.5至3.4秒之间[15]，这显然不适合高动态的实时避障，更适合作为全局规划器。而经过高度优化的轻量级模型则能以超过1Hz的频率运行[13]。

系统集成面临的主要挑战包括：

1. **传感器-控制器接口**：模型生成的通常是图像空间中的二维轨迹，需要将其准确地反投影到三维世界坐标系，并转换为无人机飞控系统可以理解的速度或位置指令。这一过程依赖精确的状态估计和标定[10]。
2. **实时性保障**：必须确保从图像采集、模型推理到控制指令生成的全链路延迟在可接受范围内。这需要优化整个软件流水线，并可能涉及专用的通信管道设计，例如将图像流传输到算力更强的机载计算机进行处理[13]。
3. **安全冗余**：尽管端到端模型旨在直接输出安全轨迹，但在安全关键应用中，通常需要增加额外的安全监控层或冗余传感器（如超声波）来应对模型失效或感知局限的情况[13]。

总之，端到端扩散模型为无人机智能避障提供了一种富有前景的架构。通过精心设计模型、大力优化推理效率，并结合层次化的安全控制策略，有望在资源受限的平台上实现高质量、实时的自主避障能力。

3. 强化学习与扩散模型的融合框架

将强化学习（Reinforcement Learning, RL）与扩散模型（Diffusion Models）相结合，为无人机轨迹规划与避障提供了一种新的技术范式。这种融合旨在利用扩散模型强大的多模态生成能力，同时通过强化学习直接优化与任务目标（如安全性、效率）相关的奖励函数，从而提升生成轨迹的质量和实时决策能力。

3.1 DDPO：去噪扩散策略优化

去噪扩散策略优化（Denoising Diffusion Policy Optimization, DDPO）是一种将扩散模型的逆向去噪过程重新表述为多步决策问题的强化学习框架[16]。其核心思想是将扩散模型生成样本的每一步去噪操作，都视为一个强化学习决策步骤。通过这种形式化转换，便可以使用策略优化算法（如PPO）来直接微调扩散模型，使其生成的样本最大化特定的奖励函数，例如图像的美学质量或无人机轨迹的平滑性[17]。

这种方法的主要优势在于能够直接针对难以通过提示工程表达的复杂下游目标进行优化[18]。在无人机轨迹规划的应用场景中，DDPO可以用于优化轨迹的多个维度：通过碰撞检测奖励提升避障安全性，通过轨迹平滑性奖励提高能量效率，以及通过终点接近度奖励确保目标达成。研究表明，通过强化学习直接优化扩散模型，在生成高质量样本方面可以超越传统的基于加权似然的方法[18]。

3.2 模型基础扩散（MBD）框架

模型基础扩散（Model-Based Diffusion, MBD）是一种专门为轨迹优化设计的、基于模型的扩散方法[19]。与依赖大量离线数据的传统方法不同，MBD的核心在于利用系统的动力学模型来显式地估计得分函数（score function），从而引导扩散过程生成满足动力学约束和优化目标的轨迹[20]。

该框架的技术特点显著。首先，它具备“无数据优化”能力，可以在没有预先收集的训练数据集的情况下，仅凭系统模型（如无人机的运动学模型）进行轨迹优化[21]。其次，通过显式地融入动力学约束，MBD能够确保生成的轨迹在物理上是可行的。实证评估表明，MBD在具有挑战性的接触丰富任务中，其性能能够匹配甚至超越最先进的强化学习和基于采样的轨迹优化方法[22]。对于无人机而言，这意味着MBD能够有效处理空气动力学、推力限制以及复杂避障等多种约束条件。

3.3 D-Fusion：基于直接偏好优化的对齐方法

D-Fusion　是一种针对扩散模型与文本提示对齐问题提出的方法，其重点在于增强生成结果的视觉一致性[23]。该方法通过两个阶段构建适用于强化学习训练的样本对。第一阶段，它使用掩码引导的自注意力融合技术，在高偏好（参考）图像和低偏好（基础）图像之间进行融合，自动识别并对齐关键区域。第二阶段，则利用这些融合生成的图像对来执行直接偏好优化（DPO）[24]。

虽然D-Fusion最初面向文本-图像生成，但其方法论对无人机轨迹规划的偏好学习具有启示意义。例如，可以构建在安全性、平滑性等维度上具有不同偏好的轨迹对，让模型从中隐式学习复杂的、多目标的奖励函数，从而避免手工设计奖励函数的困难。与DDPO相比，D-Fusion通过确保生成样本对的视觉一致性，能为强化学习训练提供更高质量、噪声更少的偏好数据[23]。

3.4 混合人工智能策略与分层控制架构

在实际的无人机导航系统中，纯粹的强化学习或扩散模型方法可能在极端安全关键场景下面临可靠性挑战。因此，结合不同人工智能范式优势的混合策略显得尤为重要。一种有效的架构是分层控制，它将高层决策、中层规划和底层控制解耦。

在这种架构中，高层决策层可以结合扩散模型和强化学习，前者负责生成多样化的候选轨迹，后者负责根据实时奖励函数评估并选择最优轨迹。中层则引入一个基于规则的规划层，用于执行确定性的安全约束检查、紧急避障和故障恢复逻辑。底层则由经典控制器（如PID或模型预测控制）负责稳定的姿态与位置跟踪。研究表明，这种混合策略能够显著提升任务成功率并降低碰撞率，因为规则模块在关键情况下为系统提供了确定性的安全保障[25]。强化学习虽擅长学习自适应策略，但在临界状况下，规则引擎的集成对于确保整体系统的可靠性至关重要[25]。

3.5 奖励函数设计与优化策略

在强化学习与扩散模型的融合框架中，设计合适的奖励函数是引导模型生成高质量轨迹的关键。奖励函数通常需要平衡多个相互竞争的目标。一个综合的奖励函数 R_{total} 可以设计为多个子奖励的加权和：

$$R_{total} = w_1 R_{collision} + w_2 R_{smooth} + w_3 R_{goal} + w_4 R_{time}$$

其中，$R_{collision}$ 惩罚碰撞，R_{smooth} 惩罚轨迹的剧烈变化以提升平滑性与能效，R_{goal} 奖励接近目标点，R_{time} 鼓励快速到达。

为了处理稀疏奖励（如只有到达终点才获得奖励）的难题，可以借助扩散模型生成合理的中间子目标，从而将稀疏奖励分解为密集的中间奖励。此外，采用课程学习策略，从简单的无障碍环境开始训练，逐步增加障碍物的密度和速度，有助于智能体学习长期的规划能力。扩散模型在这里扮演了高质量轨迹先验的角色，而强化学习则在该先验分布的基础上进行精细化的策略搜索与优化，两者结合实现了更高效、更全面的解空间探索。

3.6 面向实时部署的性能优化

尽管扩散模型生成质量高，但其迭代去噪过程计算开销较大，可能影响实时性。在融合强化学习后，可以通过多种策略优化系统性能。

在算法层面，可以探索减少轨迹生成所需的去噪步数，例如利用强化学习学习一个更高效的采样调度策略。另一种策略是采用分层生成：先由扩散模型快速生成稀疏的关键航点，再通过轻量级的插值或局部优化方法补全完整轨迹。在工程层面，模型蒸馏技术可以将训练好的复杂模型压缩为更轻量级的版本，便于在无人机嵌入式处理器上部署。同时，进行硬件感知的优化，如算子融合和特定精度（如INT8量化）转换，能进一步加速推理。这些优化措施的目标是确保基于扩散-强化学习的轨迹规划系统能够在资源受限的机载计算平台上满足动态环境的实时决策需求。

4. 实时性能优化与约束处理技术

扩散模型应用于无人机实时控制时，面临推理延迟与安全约束保证两大核心挑战。现有研究通过模型架构优化、约束集成以及硬件适配等方法，试图在生成高质量轨迹的同时满足实时性要求。然而，基于现有资料，许多关键技术细节和性能数据尚不明确，本节将基于可获得的事实信息进行探讨。

4.1 推理加速与模型轻量化

扩散模型的标准推理过程通常需要多次迭代去噪，计算开销较大，难以满足无人机对低延迟控制的需求。因此，推理加速和模型轻量化是实现实时部署的关键。

模型压缩与量化是直接在资源受限的无人机平台上部署神经网络的有效手段。例如，针对Crazyflie纳米无人机的研究表明，通过采用轻量化的CNN深度估计网络（DDND），将参数量从310万大幅减少至31万，并进一步通过8位量化将模型大小从747.6 KB压缩至201.3 KB，最终在GAP8处理器上实现了1.24 FPS的推理速度[13]。这证明了通过精心设计的网络架构和量化技术，可以在极端有限的算力（如512 KB RAM）下实现可运行的避障功能。然而，这种速度仅适用于低速飞行的纳米无人机，对于需要高速决策的常规无人机而言，仍需探索更高效的加速方法。

专用加速架构与实时性能是另一个重要方向。SwarmDiffusion框架作为一个轻量级的端到端扩散模型，声称其推理时间约为0.09秒[10]。该框架通过联合预测可穿越性地图和生成可行轨迹，避免了传统流程中感知与规划模块分离带来的延迟。其架构采用条件UNet进行轨迹生成，并利用FiLM（Feature-wise Linear Modulation）机制将机器人本体状态作为条件嵌入，以实现跨不同机器人平台（如四足机器人和无人机）的泛化[10]。这表明，设计一体化的、条件化的生成模型是减少系统延迟的一种可行思路。

4.2 安全约束的集成与处理

在追求速度的同时，确保生成的轨迹满足避障、动力学等安全约束至关重要。现有研究尝试将约束信息以不同形式集成到生成过程中。

基于可穿越性引导的轨迹生成是一种常见方法。SwarmDiffusion框架的核心创新在于，它使用一个扩散模型同时完成可穿越性预测和轨迹生成[10]。模型在训练时利用教师模型（如AnyTraverse）提供的可穿越性地图作为监督信号，并在扩散去噪过程中以该预测的可穿越性图为条件，从而引导生成的轨迹倾向于位于可安全通行的区域[10]。这本质上是一种隐式的约束满足机制，通过数据驱动的方式让模型学习“安全”轨迹的分布。

人工势场（APF）作为安全后处理层。为了应对纯视觉方法在几何不确定性上的不足（例如从图像空间投影到3D空间产生的误差），SwarmDiffusion在真实世界部署时集成了一个轻量级的APF层[10]。该层不充当主规划器，而是利用点云距离信息对扩散模型生成的全局轨迹进行微小的局部校正，以增加安全性，且声称不会引入显著延迟[10]。这体现了一种分层安全策略：扩散模型负责全局、语义级的规划，而APF负责局部、几何级的精细避障。

专门针对约束的扩散引导框架。根据文献标题，存在名为“Constraint-Aware Diffusion Guidance (CoDiG)”的方法，旨在解决安全关键应用中的实时约束问题，并通过真实世界实验进行了验证[11]。另一篇题为“Constrained Generative Modeling with Manually Bridged Diffusion Models”的

论文也提出了一个处理多约束的理论框架[26]。然而，现有资料无法提供这些方法具体的技术原理、架构细节和确切的性能指标（如推理时间、成功率），因此其实际效果和系统集成挑战尚不明确。

4.3 系统集成与性能评估挑战

将扩散模型集成到无人机系统中涉及传感器、决策层和控制接口的协同设计。从已解析的论文中，可以窥见一些集成方案。

传感器配置与输入：系统通常依赖视觉传感器作为主要输入。例如，SwarmDiffusion仅需单目RGB图像[10]；而纳米无人机避障系统则使用单色摄像头，并辅以底部的光流传感器来维持固定高度[13]。这表明对于轻量化部署，简化传感器配置是必要的。

决策与控制接口：生成轨迹后，需要将其转化为控制指令。纳米无人机方案采用了一种基于行为仲裁（BA）的简单控制策略，根据生成的深度图计算转向角速度[13]。而SwarmDiffusion框架则与ROS生态系统集成，在无人机上使用Intel NUC进行状态估计和实时控制，生成路径后发送给底层飞控（如ArduPilot）执行[10]。这显示了从高层生成模型到底层控制器的不同接口设计模式。

性能评估数据缺失：尽管部分研究给出了推理速度（如0.09秒[10]、1.24 FPS[13]），但关于在动态环境中严格满足实时控制周期（如<100ms）的全面性能评估，包括轨迹生成成功率、约束违反率以及在不同硬件平台上的基准测试，在当前可获得的事实中信息有限。例如，ImpedanceDiffusion方法被提及推理时间为2.5–3.4秒[15]，这远未达到实时控制的要求，凸显了性能优化的迫切性。

综上所述，扩散模型在无人机实时应用中的优化主要围绕轻量化设计、约束条件集成和系统级协同展开。虽然已有研究展示了初步的可行性和有前景的方向（如SwarmDiffusion），但许多关键技术（如CoDiG）的具体细节、在复杂动态环境下的稳健性以及满足严格实时性要求的可靠部署，仍需进一步深入研究和事实支撑。

5. 系统集成与未来发展方向

5.1 系统集成架构与技术挑战

完整的无人机避障系统集成需要构建一个涵盖传感器输入、决策层与执行控制的多层架构。基于现有研究，可以梳理出系统集成中的核心模块与面临的关键挑战。

1. 传感器融合层设计 无人机系统通常采用多模态传感器来增强环境感知的鲁棒性。一个典型的轻量化案例是部署在Crazyflie纳米无人机上的端到端避障系统。该系统采用HM01B0-MNA单色相机作为主传感器，并在资源极度受限的GAP8处理器（仅512KB RAM）上运行。为了节省计算资源，系统处理单通道灰度图像而非RGB图像，这使324×324分辨率图像的存储需求从315KB降至105KB，从而允许部署更复杂的模型[13]。此外，该系统还集成了底部的Flow Deck v2传感器来测量地面距离，以维持固定的飞行高度[13]。更复杂的平台，如Unitree Go1四足机器人或定制的八轴无人机，则会集成立体相机（如Intel RealSense D435i）和视觉惯性里程计系统，以提供更丰富的RGB图像、深度信息和精确的位姿状态[10]。传感器融合面临的主要挑战包括不同传感器数据流的同步与校准、在有限机载计算资源下的实时处理，以及对特定环境（如透明障碍物）的感知鲁棒性[13]。

2. 决策层架构 决策层是扩散模型与强化学习等智能算法发挥作用的核心。当前研究的一个趋势是构建端到端的轻量级模型，将环境感知与轨迹生成统一起来。例如，SwarmDiffusion框架采用一个单

一的、轻量化的条件扩散模型，从单张RGB图像中联合预测可穿越性地图并生成可行的轨迹[10]。该模型利用冻结的DINO-v2 ViT骨干网络提取视觉特征，并通过一个FiLM（Feature-wise Linear Modulation）机制将机器人的本体状态（如位置、姿态）编码并调制到视觉特征中，从而实现对不同机器人平台（如无人机和四足机器人）的自适应[10]。生成的轨迹在图像空间中以热图形式表示，再通过后处理（如随机航点采样、贝塞尔曲线平滑）得到最终路径[10]。另一种常见架构是分层规划，例如ImpedanceDiffusion方法，它使用扩散模型进行全局路径规划，然后由人工势场（APF）进行局部跟踪和实时避障调整[15]。决策层设计的关键在于平衡模型的表达能力与推理速度，以满足实时性要求。

3. 控制接口与部署 控制接口负责将高层决策转化为底层的执行指令，并确保系统的实时响应与安全。在SwarmDiffusion的实际部署中，无人机（如配备SpeedyBee F405飞控和ArduPilot的八轴无人机）通过机载计算机（如Intel NUC）运行视觉里程计和扩散模型推理，生成的路径被投影到点云上，再发送给飞控系统进行路径跟踪控制[10]。对于资源受限的纳米无人机，控制策略必须极度简化。例如，前述Crazyflie系统采用行为仲裁（BA）方案：基于生成的深度图，对图像中心行进行平均池化以构建一维障碍物地图，然后计算排斥力来调整无人机的角速度，实现避障[13]。为实现高效部署，模型通常需要经过量化压缩，如将PyTorch模型转为ONNX格式并进行8位量化，使模型大小从747.6KB降至201.3KB，从而能在GAP8处理器上以约1.24 FPS的速度运行[13]。

5.2 当前技术局限性分析

尽管相关研究取得了进展，但将扩散模型与强化学习集成于无人机实时避障系统仍面临显著挑战。

1. 实时性约束 扩散模型固有的迭代去噪过程导致较高的推理延迟，难以满足高速动态场景的需求。例如，ImpedanceDiffusion中扩散规划器的推理时间在2.5至3.4秒之间[15]，这对于需要毫秒级响应的避障而言显然过慢。虽然Leapfrog Diffusion Model等优化方法宣称能实现20-30倍的加速[27]，但其在复杂动态环境中的实际性能仍有待验证。在纳米无人机等资源受限平台上，推理速度更是主要瓶颈，1.24 FPS的帧率严重限制了无人机的可飞行速度[13]。

2. 环境适应性与泛化能力 现有系统在环境适应性上存在不足。纯视觉方法难以可靠检测透明物体（如玻璃）[13]。多数研究假设环境静态或障碍物低速运动，对高速动态障碍物的处理能力有限。此外，模型的泛化能力是一大挑战，在训练集之外的新环境或新机器人平台上，性能可能显著下降。虽然SwarmDiffusion通过少量样本（如500张图）适应新机器人本体的机制显示了潜力[10]，但这种小样本适应的普适性仍需更多验证。

3. 系统集成复杂性 构建一个稳定可靠的集成系统面临多重复杂性。不同算法模块（如感知、规划、控制）间缺乏标准化的接口规范，增加了集成难度。机载有限的计算资源需要在传感器数据处理、模型推理和底层控制循环之间进行高效分配，容易产生竞争和冲突。对于无人机群而言，通信带宽、延迟和协调逻辑的复杂度随规模扩大而指数增长，大规模部署仍是一个开放挑战[28] [29]。

5.3 未来研究方向

针对上述局限性，未来的研究可以从以下几个方向深入探索。

1. 多模态学习与自适应感知 未来的感知系统应更深入地融合视觉、深度、惯性及可能的多光谱信息，构建更鲁棒的环境理解。可以借鉴跨模态表示学习方法，例如使用变分自编码器（VAE）学习不同

模态数据的共享隐空间，以提升在光照变化、部分遮挡等挑战下的鲁棒性[30]。研究还应关注自适应感知机制，使系统能根据任务需求和环境不确定性动态调整对不同传感器信号的依赖程度。

2. 面向实时的算法与硬件协同优化 降低扩散模型等生成式模型的推理延迟是走向实际应用的关键。研究需探索更高效的架构，如分层扩散（低频全局规划与高频局部调整结合）[15]、知识蒸馏（用大模型指导小模型训练）[13]以及更先进的采样算法[27]。同时，需要与硬件协同设计，利用模型量化[13]、神经网络的稀疏化以及专用AI加速器（如FPGA、新一代GAP系列处理器）来提升能效比。

3. 面向大规模部署的体系架构 为应对无人机群协同的挑战，需从系统层面创新架构。将无人机群视为网络化控制系统（NCS），统一考虑通信、计算与控制，是一个有前景的框架[28]。边缘-云协同计算范式可以将复杂的模型训练和全局优化卸载到边缘服务器，而机载只保留轻量化的推理模块，从而缓解单机资源压力。此外，设计自适应、可容错的通信协议对于维持大规模集群的协同至关重要。

4. 安全、可靠性与验证 在安全关键应用中，必须增强系统的可靠性与可预测性。未来工作应包括对避障算法进行形式化验证，以确保其在所有可能场景下满足安全边界。扩散模型和强化学习策略应能输出其决策的不确定性量化指标，供系统进行风险评估。同时，需要设计多层故障检测与系统恢复机制，以应对传感器失效、通信中断等异常情况。

5. 人机协同与可解释性 提升系统的可交互性与可解释性有助于建立用户信任并扩展应用场景。例如，SketchPlan展示了如何从人类草图生成飞行路径，提供了直观的人机交互接口[31]。进一步研究可以探索结合自然语言指令、手势理解等更丰富的交互方式。同时，通过可视化等技术解释模型的决策依据（如关注了哪些障碍物），能增强系统的透明度和可调试性。

5.4 总结与展望

将端到端扩散模型与强化学习结合，为无人机生成高质量实时避障轨迹是一个充满活力但挑战重重的研究前沿。当前的研究在轻量化端到端模型设计、跨平台适应性以及分层规划与控制方面已取得初步进展[13] [10] [15]。然而，在实时性能、动态环境适应性、系统集成鲁棒性以及大规模部署等方面仍存在明显短板。

未来的发展需要算法创新、系统架构设计以及硬件进步的深度融合。通过持续探索多模态感知、实时优化算法、安全验证框架以及人机协同接口，有望逐步克服现有局限，最终实现能在复杂动态环境中可靠、高效、自主飞行的智能无人机系统。

6. 参考资料

1. DDPM解读（一）| 数学基础，扩散与逆扩散过程和训练推理方法, https://zhuanlan.zhihu.com/p/530602852 ↩ ↩2

2. [论文评述] SwarmDiffusion: End-To-End Traversability-Guided ..., https://www.themoonlight.io/zh/review/swarmdiffusion-end-to-end-traversability-guided-diffusion-for-embodiment-agnostic-navigation-of-heterogeneous-robots ↩ ↩2 ↩3 ↩4 ↩5 ↩6 ↩7 ↩8 ↩9

3. 扩散模型解锁复杂环境无人机特技自动规划 - 知识星球, https://wx.zsxq.com/group/228244221251/topic/4845521252542228 ↩

4. [论文评述] SwarmDiff: Swarm Robotic Trajectory Planning in ..., https://www.themoonlight.io/zh/review/swarmdiff-swarm-robotic-trajectory-planning-in-cluttered-environments-via-diffusion-transformer ↩

5. 基于扩散模型的实时规划框架DiffuserLite - 知乎专栏, https://zhuanlan.zhihu.com/p/15071859831 ↩ ↩2

6. Diffusion Trajectory-guided Policy for Long-horizonRobot ..., https://blog.csdn.net/qq_33673253/article/details/146205493 ↩

7. Real-Time Adaptive Motion Planning via Point Cloud-Guided, Energy-Based Diffusion and Potential Fields, https://ieeexplore.ieee.org/document/11091408 ↩

8. Real-Time Adaptive Motion Planning via Point Cloud-Guided, Energy-Based Diffusion and Potential Fields, https://arxiv.org/abs/2507.09383v1 ↩

9. Diffusion Policy Policy Optimization, https://arxiv.org/pdf/2409.00588 ↩

10. SwarmDiffusion: End-To-End Traversability-Guided Diffusion for ..., https://arxiv.org/html/2512.02851v3 ↩ ↩2 ↩3 ↩4 ↩5 ↩6 ↩7 ↩8 ↩9 ↩10 ↩11 ↩12 ↩13 ↩14 ↩15 ↩16 ↩17 ↩18 ↩19 ↩20 ↩21 ↩22 ↩23 ↩24 ↩25 ↩26

11. Constraint-Aware Diffusion Guidance for Robotics: Real-Time Obstacle Avoidance for Autonomous Racing, https://arxiv.org/abs/2505.13131v1 ↩ ↩2

12. Aligning Diffusion Model with Problem Constraints for Trajectory Optimization, https://arxiv.org/abs/2504.00342v1 ↩

13. End-to-End Nano-Drone Obstacle Avoidance for Indoor ..., https://www.mdpi.com/2504-446X/8/2/33 ↩ ↩2 ↩3 ↩4 ↩5 ↩6 ↩7 ↩8 ↩9 ↩10 ↩11 ↩12 ↩13 ↩14 ↩15 ↩16 ↩17 ↩18 ↩19 ↩20 ↩21 ↩22 ↩23 ↩24 ↩25

14. NVIDIA TensorRT Edge-LLM 加速汽车与机器人领域的 ..., https://developer.nvidia.cn/blog/accelerating-llm-and-vlm-inference-for-automotive-and-robotics-with-nvidia-tensorrt-edge-llm/ ↩

15. ImpedanceDiffusion: Diffusion-Based Global Path Planning for UAV ..., https://arxiv.org/html/2603.09031v1 ↩ ↩2 ↩3 ↩4 ↩5 ↩6 ↩7

16. Denoising Diffusion Policy Optimization - Emergent Mind, https://www.emergentmind.com/topics/denoising-diffusion-policy-optimization-ddpo ↩

17. Training Diffusion Models with Reinforcement Learning, http://bair.berkeley.edu/blog/2023/07/14/ddpo/ ↩

18. Training Diffusion Models with Reinforcement Learning, https://rl-diffusion.github.io/ ↩ ↩2

19. Model-Based Diffusion for Trajectory Optimization - arXiv, https://arxiv.org/html/2407.01573v1 ↩

20. [PDF] Model-Based Diffusion for Trajectory Optimization - NIPS papers, https://proceedings.neurips.cc/paper_files/paper/2024/file/6a5c38a730b17f3827c09cf6b192be04-Paper-Conference.pdf ↩

21. [PDF] Importance Sampling Model-Based Diffusion for Trajectory ... - OSTI, https://www.osti.gov/servlets/purl/3001119 ↩

22. Model-Based Diffusion for Trajectory Optimization - ResearchGate, https://www.researchgate.net/publication/381922356_Model-Based_Diffusion_for_Trajectory_Optimization ↩

23. D-Fusion: Direct Preference Optimization for Aligning Diffusion ..., https://icml.cc/virtual/2025/poster/45014 ↩ ↩[2]

24. D-Fusion: Direct Preference Optimization for Aligning Diffusion..., https://openreview.net/forum?id=WVlEwFiDGH ↩

25. Hybrid Artificial Intelligence Strategies for Drone Navigation, https://www.mdpi.com/2673-2688/5/4/103 ↩ ↩[2]

26. Constrained Generative Modeling with Manually Bridged Diffusion Models, https://arxiv.org/abs/2502.20371v1 ↩

27. Leapfrog Diffusion Model for Stochastic Trajectory Prediction, https://alphaxiv.org/overview/2303.10895v1 ↩ ↩[2]

28. Drone Swarms as Networked Control Systems by Integration of Networking and Computing, https://www.mdpi.com/1424-8220/21/8/2642 ↩ ↩[2]

29. Multidrone Systems: More Than the Sum of the Parts, https://ieeexplore.ieee.org/document/9427128/ ↩

30. Learning Visuomotor Policies for Aerial Navigation Using Cross-Modal Representations, https://arxiv.org/abs/1909.06993 ↩

31. SketchPlan: Diffusion Based Drone Planning From Human Sketches, https://arxiv.org/abs/2510.03545v1 ↩